

用于 AI 驱动科学研究的 GFlowNets

Moksh Jain^{1,2}, Tristan Deleu^{1,2}, Jason Hartford^{1,2}, Cheng-Hao Liu^{3,2},
Alex Hernandez-Garcia^{1,2}, Yoshua Bengio^{1,2,4}

摘要

解决人类面临的最紧迫问题，如气候危机和全球大流行病的威胁，需要加快科学发现的步伐。虽然科学传统上依赖于试错甚至偶然性，但过去几十年见证了数据驱动的科学发现的激增。然而，为了真正利用大规模数据集和高吞吐量实验设置，机器学习方法需要进一步改进，并更好地整合到科学发现的流程中。当前机器学习方法在此情境下的一个关键挑战是在非常大的搜索空间中进行高效探索，这需要估计可减少的认知不确定性并生成多样且具有信息性的实验集合的技术。这激发了一个新的概率机器学习框架——GFlowNets，它可以应用于实验科学循环中的建模、假设生成和实验设计阶段。GFlowNets 学习从由奖励函数间接给出的分布中采样，该奖励函数对应于未归一化的概率，从而能够采样多样且高回报的候选者。GFlowNets 还可以用于形成有效的贝叶斯后验估计器，这些估计器基于已经获得的实验数据对因果模型进行条件化。拥有这样的后验模型可以提供认知不确定性和信息增益的估计器，这些估计器可以驱动实验设计策略。总的来说，我们将论证 GFlowNets 可以成为 AI 驱动科学研究的有价值的工具，特别是在候选空间非常庞大且我们有廉价但不精确的测量或昂贵但精确的测量的情况下。这种情况在药物和材料发现的背景下很常见，我们在整篇论文中都使用这些例子。

¹ 蒙特利尔大学, ² 魁北克人工智能研究所, ³ 麦吉尔大学, ⁴ CIFAR 研究员及 IVADO

目录

1 引言 3

2 科学研究中 AI 面临的挑战 **5.2.1 数据有限与不确定性** **5.2.2 规格不足与多样性** **5**

5 科学发现中统一框架的研究：基于 GFlowNets 22

5.1 利用摊销因果贝叶斯模型定义实验的效用 22




图 1: 科学研究的迭代实验循环: 从过去的实验中积累的观测数据和数据被分析并用于生成新的假设, 进而产生新的实验, 这些新实验将产生新的数据以继续循环。蓝色边框突出显示的是我们将讨论 GFlowNets 如何应用的步骤。

1 引言

气候危机、抗生素耐药性和新大流行病的前景是人类面临的巨大威胁之一, 对全球健康和粮食安全构成巨大风险。所有这些威胁和其他威胁的一个重要共同点是, 需要重大的新科学发现来缓解它们。根据政府间气候变化专门委员会 (IPCC) 2022 年的报告 [1], 限制全球变暖将需要采用替代燃料, 以及提高能源生产和材料综合的效率。发现新材料, 如能够提高化学反应能量效率的电催化剂, 因此可以在这种转变中发挥关键作用。相应地, 抗菌耐药性和大流行病带来的日益增长的风险使得加速新药发现的进程变得至关重要。因此, 社会的福祉将强烈依赖于我们的科学发现速度。历史上, 科学发现要么是偶然的发现——如青霉素和特氟龙 [2]——要么是相对较慢的实验科学循环的结果: 从过去的实验中积累观察结果, 由专家仔细分析并产生新的假设, 设计实验最终产生新的有价值的观察结果, 继续这个循环 (见图 1)。虽然这种模型在过去几个世纪里很好地推动了科学的进步, 并将在某些领域继续这样做, 但完全手动的循环对于当前紧迫的紧急情况来说太慢了。当数据分析、假设生成和实验规范都是手动进行时, 循环中会出现瓶颈。当候选搜索空间令人望而生畏地庞大时, 这种情况会进一步加剧, 正如在药物发现中所估计的那样, 存在 10^{60} 种可行的小分子 [3]。由于机器人技术、生物技术和计算能力等领域的进步, 科学实验的规模正在迅速增加 [4]。例如, 我们现在可以轻松且廉价地收集高维图像和视频、电子显微镜数据或数百万个细胞的基因表达。此外, 我们还可以同时进行数千甚至数百万次实验, 筛选新的候选分子, 试验一系列反应等。如果实验干预可以组合, 我们可以在每一步从可能实验的组合空间中采样。这种大规模数据和计算资源可用性开辟的道路已被识别为科学发现的第四范式 [5]。尽管如此, 我们目前的工具还不足以真正利用我们所拥有的所有信息和资源 [6]。在这种情况下, 定制化的机器学习 (ML) 方法的发展提供了不仅分析和理解数据, 而且改进假设生成和实验设计的可能性, 从而加速实验科学循环。如图 1 所示, ML 技术已应用于实验科学循环的主要步骤: (a) 分析和建模从实验中积累的数据, (b) 特征化和

生成与数据兼容的假设，(c) 设计下一个实验，以及 (d) 执行实验。数据分析和建模是机器学习方法的自然应用场景，这些方法通常设计用于从大规模数据集中提取预测模式。例如，机器学习方法在建模小分子的量子力学性质方面取得了相当大的成功 [7]。在设计候选实验的背景下也研究了机器学习方法 [8]。一个典型的例子是利用强化学习 (RL) 和贝叶斯优化 (BO) 工具来搜索优化候选物某些属性 (作为奖励) 的候选对象 [9, 10] 然而，正如我们在第 2 节详细讨论的那样，现有方法往往缺乏对科学领域中由有限数据、不确定性和目标欠指定所引入的挑战的系统处理。本文讨论了一种新颖的机器学习框架，称为生成流网络 [11, 12] ——简称 GFlowNets——有助于解决现有机器学习方法在科学领域中的不足。GFlowNets 是一种通用推理机，能够生成与某个奖励函数成比例概率的样本。因此，GFlowNets 作为潜在的变革工具，在科学研究中可以用于生成假设、设计实验和建模实验观察，这些都是实验科学循环的关键步骤 (图 1) ——请注意，增强型机器人学习也可以在实验步骤中发挥作用，但此处不讨论这一点。在本文中，我们将通过以下具体示例来使讨论更加明确。

示例 1.1。对抗日益增长的抗菌素耐药性和新发传染病的一个关键部分是加速发现能够抑制目标细菌或一种到几种目标蛋白质活性的新颖小有机分子 (和肽)。主要目标是在分子空间 (包括肽) 中寻找与目标结合并抑制或激活其功能的候选物。分子空间组合数量庞大，而对所需活性 (如结合亲和力) 进行体外或甚至计算机模拟的准确评估成本高昂。此外，除了与目标结合之外，一个分子还需要满足作为治疗药物使用的其他几个药理学标准，如对人体低毒性、良好的吸收、分布、代谢和排泄 (“ADME”) 以及易于合成。

示例 1.2。发现适用于清洁能源生成、存储和应用的新材料，这些材料具有更高的效率并依赖可持续的原材料，对于帮助减少全球气温上升的努力至关重要。目标是发现新型无机和有机材料，通常需要同时优化多个特定度量。一个典型的例子是开发用于锂/钠离子电池的锂/钠离子存储材料，仅金属氧化物这一类 (例如图 2) 就已经构成了一个组合上庞大的搜索空间。在锂/钠离子电池内部，一种良好的能量存储金属氧化物候选材料应表现出高能量密度，同时其他度量如高容量保持率、低不可逆容量和低合成成本也应得到满足。

示例 1.3。通过建模人类体内疾病进展的遗传途径，在理解人类生物学方面起着关键作用。这些因果模型可以帮助我们理解各种干预措施，如治疗药物在人体复杂环境中的行为。目标是在有针对性的干预帮助下学习这样的因果模型。即使单个细胞的因果结构也是一个重大挑战，并提出了如何适当扩展算法以及如何将从数据中学习来与来自生物学的先验知识相结合的难题。

组织。在第 3 节中，我们讨论现有的机器学习方法论，并突出 GFlowNets 的独特特征。接下来，在第 4 节中，我们介绍摊销推断的相关概念，并讨论 GFlowNets 是如何从这些概念中产生的。在第 4.2 节中，我们强调了一些科学发现问题，这些问题成功地应用了 GFlowNets。在第 4.3 节中，我们讨论了如何利用 GFlowNets 来表示多个感兴趣随机变量之间的因果模型分布，并估计感兴趣的后验分布以及边缘化量，如贝叶斯后验密度，这对于评估实验的信息增益非常重要。最后，在第 5 节中，我们勾画了一条潜在路径，旨在建立一个由 GFlowNets 驱动的统一科学发现框架。

2 科学发现中 AI 面临的挑战

在过去的几十年里，机器学习已经实现了从围棋游戏中超越人类的智能代理 [13] 到蛋白质折叠预测的重大突破 [14] 等一系列显著的技术进步。这些进展部分得益于大量数据集的可用性以及通常明确的目标优化需求。然而，在许多科学发现应用中，有限的数量、测量固有的不确定性以及目标的不充分规定给利用机器学习方法带来了严峻挑战。在本节中，我们将讨论这些挑战的相关性，并阐述 GFlowNets 如何规避这些问题。

2.1 数据有限与不确定性

在利用基于学习的方法进行科学研究时，数据的有限性和相关不确定性是一个关键挑战。不确定性的一部分源于不可靠的测量，称为偶然不确定性，另一部分则由于训练数据量有限，称为认知不确定性，这是与理论或模型及其参数相关的不确定性 [15]，因为数据集的大小是有限的。认知不确定性产生于多个理论或模型或参数设置可以与给定的数据兼容，而这些理论或模型上的贝叶斯后验可以捕捉到认知不确定性。目前最先进的人工智能方法设计上依赖于访问大量数据集来提取有用模式。但由于实验限制，获取大规模精确数据往往极其昂贵或不可能实现，这在许多感兴趣的领域中对现代机器学习方法来说都是如此。例如，在药物发现中，获得用于机器学习方法所需的规模的实验结合亲和力对于配体与目标蛋白而言通常非常具有挑战性。此外，实验技术差异和测量噪声可能导致同一配体的结合亲和力相差几个数量级。材料科学也是如此：例如，在寻找新电池材料的研究中，几千个数据点已经被认为是高吞吐量的 [16]，而诸如能量密度等测量度量可能会根据实验设置的细微差别有很大差异。因此，模型必须考虑到科学发现背景下的偶然不确定性和认知不确定性。此外，自然界中的科学现象往往是复杂的，并且常常是复杂过程的结果。标准的机器学习模型通过从数据中学习输入到输出的函数映射可能无法推广到未见的数据场景。引入现象的因果结构可以引入有效的归纳偏置，使模型能够推广到新的场景中 [17]。虽然给定的模型会考虑结果的不确定性，即偶然不确定性，但通过建模贝叶斯后验，我们可以考虑所有拟合数据良好的模型，从而也捕获认知不确定性，这是希望通过实验减少的内容。正如我们在第 4.3 节中讨论的，GFlowNets 可以用来建模拟合数据良好的因果模型的后验分布。

2.2 欠指定与多样性

在机器学习方法中，通常假设可以访问某种奖励信号或评分函数来评估实验设计的质量和实用性。例如，在设计类似药物的分子时，真正的目标是找到能够特异性抑制人体内靶蛋白的配体。然而，这一目标很难被明确指定并方便地量化为一个简单的标量奖励。实践中，通常使用分子与靶蛋白结合亲和力的估计值作为奖励信号来搜索候选分子。这带来了两个问题：首先，结合亲和力的估计并非不受系统性和随机性误差的影响；其次，仅凭结合能量无法解释许多可能影响配体在人体内效果的因素。例如，一个分子（或一系列类似的分子）如果仅仅优化这种结合能量，可能会在体内无用甚至有害，因为它可能会与许多其他蛋白质结合从而产生毒性（更广泛地说，该分子可能具有较差的 ADME 特性）。这些方面使得寻找多样化的假设——在这种情况下，即多样化分子模式——变得至关重要，以应对奖励信号的不充分规定和不确定性。尽管如此，诸如强化学习 [9] 和贝叶斯优化 [10] 等流行的辅助科学发现的方法旨在发现奖励信号的单一最大化者，而没有考虑到奖励信号本身的不充分规定。候选解决方案的多样性

在新技术世代的发展中也特别相关。例如，在钙钛矿（perovskites）或其他新材料应用于太阳能电池之前，基于硅的太阳能电池在功率转换效率优化和制造方面已逐渐收益递减，只有使用完全不同的材料才能改变这一状况。通过按奖励比例采样，GFlowNets 可以缓解因目标奖励欠指定而错过潜在有趣发现的问题，生成一组多样化的高奖励候选解决方案来解决当前的发现问题。

3 背景

在本节中，我们将回顾与机器学习相关的基础领域，并为第 4 节铺垫，在该节中我们将讨论 GFlowNets 如何应对第 2 节提出的挑战。

预备知识。为了建立符号表示，考虑一个来自有机合成的例子问题，其中化学家希望找到新的和/或高效的合成路径以获得所需的分子（例如，药物候选物）。

- **设计。** 设 $x \in \mathcal{X}$ 为实验设计，其中 $\mathcal{X}$ 表示所有可能实验的设计空间。对于例 1.1 和例 1.2，每个实验设计 x 指定一个候选分子、抗体或金属氧化物材料。对于例 1.3， x 也可以代表对特定基因的干预，或是特定程序（如合成条件）的实验参数。如果实验是在计算环境中建模的，它还可以包括所用近似的精确度以及相关的计算成本。

- **参数。** 我们使用 θ 来表示所研究现象的数学模型的参数。类似地，实验设计 x , θ 可以参数化一系列对象。例如，在例 1.1 中， θ 可以表示超分子相互作用/蛋白质结合的物理过程的参数，或者在例 1.2 中，表示电池能量容量及其容量损失机制模型的一组参数，或者在例 1.3 中，表示描述遗传通路因果交互的结构因果模型的参数，或者更一般的情况，如神经网络的参数。

- **结果。** 我们使用 y 表示实验结果，例如化学反应的产率。结果 y 可能是多维的，并可能包括实验过程中记录的所有测量值。在示例 1.1 中， y 可以代表对目标的结合亲和力、对人体的毒性以及合成可及性。在示例 1.2 中， y 可以代表能量容量和损耗、材料纯度以及 X 射线衍射图案。

y 甚至可以包括特定干预措施下细胞群体的图像和视频。这些

实验结果通常结构丰富，但可能缺乏有效的建模所需的抽象。

- **数据集。** 最后，我们将从先前实验收集的数据表示为 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^M$ 。

我们将结果 y 视为设计 x 的结果。似然性——表示为 $p(y | \theta, x)$ ——由参数 θ 定义，是对给定特定设计 x 和模型参数 θ 的情况下，每个实验结果 y 发生的可能性的一种度量。这种似然性作为我们对潜在现象的抽象模型。如果似然性可以解析地计算或高效地计算，则称为显式模型。例如，我们可以用高斯分布来建模实验结果，均值为某个函数 $f_\theta(x)$ ，使得 $p(y | \theta, x) = \mathcal{N}(f_\theta(x); \sigma)$ 。另一方面，如果似然性难以处理，则称为隐式模型。在科学研究的背景下，隐式模型很常见，因为我们经常通过模拟器来建模过程，这些模拟器允许我们从 $p(y | \theta, x)$ 中采样，而无法评估似然性。我们假设观测变量的数据集 $\mathcal{D} = \{x_1, \dots, x_n\}$ 是从联合分布 $p(x, \theta)$ 中抽取的，对于某些 θ 。为了利用这些数据更新我们对可能结果的模型，我们需要一种解决推理问题的方法：估计给定观测数据的隐变量上的后验概率分布 $p(\theta | \mathcal{D})$ 。这个问题在各个领域都有出现。例如，在观察到实验结果的情况下，比如结合亲和力

对于特定目标上的几种配体，我们可能对估计模型中描述结合过程的参数分布感兴趣。原则上，这个分布可以通过贝叶斯法则来估计，

$$p(\theta | \mathcal{D}) = \frac{p(\mathcal{D} | \theta)p(\theta)}{p(\mathcal{D})}. \quad (1)$$

然而，在实践中，精确计算后验分布对于高维情形是不可行的 θ 和 x 。因此，近似推断方法得到了广泛的研究。我们简要总结两类方法：马尔可夫链蒙特卡洛（MCMC）和变分推断（VI）。

3.1 近似推断

马尔可夫链蒙特卡洛（MCMC）方法 [18] 旨在从目标分布生成样本，其中正确的采样程序未知，但所期望分布的密度在归一化常数内已知。它们通过构建一系列样本序列来近似从期望分布中采样，该序列的渐进分布（随着序列变长）与目标分布相匹配。在序列的每一步中，通过从前一个样本进行微小随机扰动来生成新样本。当尝试从贝叶斯后验分布中采样时 $p(\theta | \mathcal{D})$ ，我们可以计算未归一化的后验形式作为先验和似然函数的乘积， $p(\theta)p(\mathcal{D} | \theta)$ 。不幸的是，在高维问题和分布模式占据极小相对体积且彼此相距甚远的问题中，MCMC 方法可能需要指数级更多的时间来从所有模式中进行适当的采样（甚至只是从一个模式移动到另一个模式）。用于提高 MCMC 在高维分布采样性能的方法 [19, 20, 21] 仅限于某些类型的分布，并不适用于复杂对象（如图和序列）的采样，而这些对象在科学发现的许多应用中非常重要。变分推断方法 [22] 通过采用基于优化的方法来解决从后验分布采样的问题，寻找与我们所求的后验分布最为接近的一族分布中的一个成员。具体而言，他们寻找一种分布 $q(\theta)$ 通过优化值 $\mathbb{E}_{\theta \sim q} [\log q(\theta) - \log p(\theta, \mathcal{D})]$ 或者定义它的参数——以最小化逆 Kullback-Leibler (KL) 发散 $\mathbb{E}_{\theta \sim q} [\log q(\theta) - \log p(\theta, \mathcal{D})]$ 。因为此种“接近性”的测度是一种逆 KL 散度，变分推断方法往往会忽略真实后验分布的大多数模式，甚至仅关注其中一个模式 [23, 24] GFlowNets 解决了困扰 MCMC 和典型 VI 方法的模式丢失问题。它们类似于 amortized 变分方法（即，学习一种参数化表示 q ）但采用了不同的训练目标，该目标通过允许在样本空间中进行探索来青睐更多样化的样本 [25] 正如我们在第 4.1 节中讨论的那样

3.2 实验设计

实验是我们抽象模型与现实世界复杂性之间互动的主要接口。科学研究方法的一个关键要素是精心设计实验，以便获取与底层现象可靠理解相对应的知识。然而，实验成本高昂——无论是计算上、财务上还是时间上。因此，我们需要设计实验的方法，以最大化我们的模型从每次实验中获得的信息量。自动化实验设计的任务已在统计学和机器学习领域得到了广泛研究。实验设计领域探讨的是如何有效地设计“有用的”实验。实验的有用性由一个效用函数（或奖励） $U(\cdot; \mathcal{D}) : \mathcal{X} \rightarrow \mathbb{R}$ 定义，该函数可能会根据我们从先前实验中观察到的数据 $\mathcal{D}$ 而变化。给定这个效用函数，我们通常感兴趣的是选择最有用的设计方案， x^*

$$x^* = \arg \max_{x \in \mathcal{X}} U(x; \mathcal{D}). \quad (2)$$

实验科学的过程往往是迭代的，如图 1 所示。设计实验，执行实验并观察实验结果，根据观察结果更新模型，然后在更新后的模型指导下设计下一个实验。这被称为顺序实验设计。因此，顺序实验设计设置被形式化为

any iteration k as follows, in terms of the estimated utility of the experiment x considered and the past data $\mathcal{D}_{k-1}$:

$$x_k = \arg \max_{x \in \mathcal{X}} U(x; \mathcal{D}_{k-1}) \quad (3)$$

其中 $\mathcal{D}_{k-1} = \{(x_i, y_i)\}_{i=1}^{k-1}$ 包含截至迭代时执行的实验的设计和结果 k 。设计能够准确反映实验价值同时计算高效的效用函数一直是各个社区感兴趣的问题。经典的工作在实验设计上依赖费舍尔信息矩阵来量化参数所含的信息 θ 这些信息包含在实验结果中 y [26, 27]。这种信息的测度可以在线性模型中高效地计算，其中结果与设计呈线性关系 [8]。当这种关系是非线性的时，存在多种方法可以从与我们观察一致的非线性函数版本空间中进行选择；参见 Settles [28] 用于调查。在科学研究中，我们并非对能够解释观察结果的函数集合持不可知态度：通常情况下，我们从文献和之前的实验中积累了大量的先验知识，这些知识可用于评估潜在实验结果的相对可能性。下文介绍的贝叶斯实验设计提供了一种将这些先验知识纳入未来实验选择的原理性方法。

3.3 贝叶斯实验设计

贝叶斯实验设计 (Bayesian Experimental Design, BED) 或贝叶斯最优实验设计 (Bayesian Optimal Experimental Design, BOED) [29, 8] 通过建模一个理性的主体来处理实验设计问题，该主体旨在最大化其关于先验信念的新实验预期效用。效用函数为每个潜在结果提供了一个实数值评分， y ，对于任何潜在的实验设计， x 。在每一轮实验中，主体选择一个实验设计¹， x ，该设计在主体的先验信念下（由参数化表示）赋予最高预期效用，加权于每个结果发生的可能性 θ 。通过指定智能体的先验信念，我们可以将已知关系和观测结果中的不确定性等科学知识编码进去，从而使得探索实验设计空间未知部分的过程更加高效。智能体效用函数的一个常见选择是实验参数之间的互信息 [MI; 30] θ 并且结果 y 在进行实验时观察到 y ，给定数据集 $\mathcal{D}$ 之前的实验。

$$U(x; \mathcal{D}) = I(y; \theta \mid x, \mathcal{D}) \quad (4)$$

$$= \mathbb{E}_{p(y|\theta, x)p(\theta|\mathcal{D})} \left[\log \frac{p(\theta \mid y, x, \mathcal{D})}{p(\theta \mid \mathcal{D})} \right] \quad (5)$$

$$= \mathbb{E}_{p(y|\theta, x)p(\theta|\mathcal{D})} \left[\log \frac{p(y \mid \theta, x)}{p(y \mid x, \mathcal{D})} \right]. \quad (6)$$

互信息可以解释为我们期望能够获取多少关于某个感兴趣随机变量（比如模型参数）的信息——或者等价地说，我们减少了多少不确定性 θ 得益于实验结果。方程 5 和方程 6 给出了互信息的两种等价定义，但两者在一般情况下都是难以处理的，因此我们需要依赖近似方法。假设可以访问到似然函数， $p(y \mid \theta, x)$ ，我们首先需要估计各种后验分布，具体取决于我们选择上述哪种互信息的表述形式。为了采样其中一个求和项，我们需要估计或者至少从参数的未知且通常难以处理的后验分布中进行采样 $p(\theta \mid \mathcal{D})$ ，或边缘似然 $p(y \mid x)$ 。

（其中 θ 已被求和。估计高维后验分布可能具有挑战性，并且边缘化 θ 出 $p(y \mid \theta, x)$ 也可能不可行。此外，互信息本身涉及一个高维积分，这可能是不可行的。因此，开发有效的估计器来近似互信息一直是 BED 中的中心挑战之一。互信息的估计器已经为隐式模型和显式模型开发出来。这些估计器通常利用近似推断工具，包括第 3.1 节讨论的 MCMC 和 VI，来近似参数的后验分布或边际似然 [31, 32, 33, 34, 35, 36]，以及在隐式模型情况下似然函数 [37]。

¹ 实验序列也是可能的，但计算复杂度更高。

面向摊销 上述传统方法包含两个独立步骤：估计或近似参数上的后验分布或边缘似然以估计互信息（MI），然后最大化该 MI 估计器以找到最优实验。尽管这些方法在科学发现的各种情境中被应用 [38, 37]，但其中每一步都可能计算成本高昂。[39] 提出了一种统一的随机梯度方法来结合 MI 的估计和最优实验的选择。他们建议联合优化 MI 估计器的参数 ϕ 和实验设计 x 使用基于梯度的方法。[40] 以设计策略的形式形式化了传统的 BED 方法 π ，该策略直接将实验数据的历史记录 $h_t = [(x_1, y_1), \dots, (x_t, y_t)]$ 映射到下一个实验设计 x_{t+1} 。一旦该策略训练完成，接下来的实验选择可以直接使用该策略，而不是通常的信息增益估计和优化。本质上，策略的训练摊销了信息增益估计和优化的成本。[41] 将此扩展到隐式模型。这些是摊销推断的例子：在运行时，我们预先训练一个函数，直接生成所需量的近似值，而不是通过昂贵的蒙特卡洛采样来估计或最大化某些期望值。我们在第 4 节详细讨论了学习的摊销推断，重点是 GFlowNets 及其相对于 MCMC 方法的优势。当前的 BED 方法仅限于连续的设计空间。尽管最近的工作考虑了将离散设计纳入其中的扩展 [42] 它们仅限于小规模问题领域。总体而言，BED 方法难以扩展到更大规模的问题设置。

3.4 贝叶斯优化

在科学研究的各个领域，一个典型的问题是对某些昂贵的黑箱函数值进行优化 f 。例如，在设计新型分子以抑制特定目标蛋白质活性的任务中，我们感兴趣的是寻找一种分子 x^* ，该分子与目标蛋白质的结合能最小化， f ：

$$x^* = \arg \min_{x \in \mathcal{X}} f(x). \quad (7)$$

此外，我们仅观察到噪声测量值 y 关于评估 f ，如所描述的 $p(y | f(x))$ 。在结合能的背景下，每次实验评估可能既昂贵又耗时，需要几周时间才能在实验室完成，并且观察到的结果存在噪声。因此，这里的目的是发现 x^* 通过尽可能少的评估 f 。这一问题在全局优化的框架内得到了广泛的研究 [43] 解决任意一般函数的全局优化问题 f 在离散空间中是 NP 难的，并且在没有特殊结构约束（例如凸性）的情况下是不可解的 f 在连续情况下。寻找该问题近似解的方法在文献中受到了广泛关注，因为其应用范围广泛。在研究的各种技术中，贝叶斯优化（Bayesian Optimization）[44, 45, 46] 是一种流行且广泛使用的策略。贝叶斯优化已被广泛应用于各种科学问题 [47, 48, 49, 50]。总体而言，贝叶斯优化是一个迭代过程，旨在以样本高效的方式搜索全局最优解，依赖于贝叶斯推断工具。算法 1 提供了贝叶斯优化方法的一般概述。

Algorithm 1: Bayesian Optimization

Input: Oracle $f \sim p(f)$, Initial dataset, $\mathcal{D}_0 = \{(x_i, y_i)\}_{i=1}^M$, Acquisition function α ;

Result: $x_T \approx \arg \max_{x \in \mathcal{X}} f(x)$

for $i = 1 \dots T$ **do**

Infer surrogate model $p(f | \mathcal{D})$ given dataset $\mathcal{D}$;

Acquire $x_i = \arg \max_{x \in \mathcal{X}} \alpha(x, p(f | \mathcal{D}))$;

Observe $y_i \sim p(y | f(x_i))$;

Update dataset $\mathcal{D} = \mathcal{D} \cup \{(x_i, y_i)\}$

end

贝叶斯优化算法的两个关键组成部分是代理模型 $p(f | \mathcal{D})$ 它近似 f （及其认知不确定性）和采集函数 $\alpha(x, p(f | \mathcal{D}))$ ，后者量化获取一个点的效用。高斯过程 [高斯过程; 51] 由于后验具有简单的解析形式，成为代理模型的一个吸引人的选择 $p(f | \mathcal{D})$ 。因此，在现代贝叶斯优化方法中，高斯过程是默认的选择 [52]。

从信息论的角度来看，在每一轮中，我们关注的是获取能够最大化观测值与全局最优值之间互信息的候选者 function:

$$\arg \max_{x \in \mathcal{X}} I(y; x^* | x, \mathcal{D}). \quad (8)$$

此目标类似于第 3.3 节的信息增益，其中感兴趣的参数是 $\theta = x^* = \arg \max_{x \in \mathcal{X}} f(x)$ 。确实，贝叶斯优化可以被视为一种隐式模型上的实验设计实例 f ，我们感兴趣的是特定随机变量，即函数 f 最大值的位置，而不是所有参数。

采集函数 采集函数在贝叶斯优化中扮演着关键角色，多年来已经提出了各种采集函数。预期改进 [53] 是最早的采集函数之一。置信上限 [UCB; 54] 和汤普森采样 [TS; 55, 56] 受到了强盗学习文献的启发。最近，在熵搜索方法方面有了显著的发展，这些方法采用了方程 8 中引入的信息理论视角。[57] 并且 [58] 提出了基于方程 8 的熵搜索 (ES) 和预测熵搜索 (PES) 作为采集函数。[59, 60] 则考虑了结果与最大值之间的互信息 $I(f)$ 而不是 $\arg \max$ ，从而形成了最大值熵搜索 (MES) 采集函数：

$$\arg \max_{x \in \mathcal{X}} I(y; f(x^*) | x, \mathcal{D}). \quad (9)$$

[61] 进一步提出了一个基于互信息下界的采集函数 GIBBON，这是一个通用的信息论采集函数，也可应用于我们在下文讨论的各种扩展。

扩展 受多种实用应用的启发，对标准贝叶斯优化设置进行了若干扩展研究。一个常见的情形是 f 可以在多个不同的候选对象上并行评估。在实践中，我们通常可以几乎以与单个候选对象相同的成本来评估多个候选对象。例如，噬菌体展示技术可以在一批中生成数百万种抗体的库。批量贝叶斯优化 [62, 63] 是贝叶斯优化的一种扩展，在每一轮中我们获取一批候选对象而不是单一候选对象。此外，我们可能拥有具有不同成本和保真度的预言机来进行评估 f ；例如，为了获得分子与蛋白质结合亲和力的模拟值，预言机可以包括自由能扰动和分子对接，其中前者准确度高得多，但计算成本高出几个数量级。这种设置在多保真贝叶斯优化中进行了研究 [64, 65, 66]。实用应用中的另一个重要方面是多目标优化。例如，在药物发现场景中，除了结合能之外，我们还对药物类性、对人体的毒性以及可合成性等多个属性感兴趣。多目标贝叶斯优化方法研究这一问题设置 [58, 67, 68] 最近的工作还将物理归纳偏置作为先验知识，以实现高效的贝叶斯优化 [69, 70]。最终，虽然传统的贝叶斯优化方法主要考虑连续空间 x ，最近的研究使得在离散空间上应用贝叶斯优化成为可能 [71, 72] 尽管近期有所进展，贝叶斯优化方法通常受限于小规模问题，因为难以将代理模型扩展到更大的领域。此外，正如第 2 节所述，由于贝叶斯优化关注的是最大化或最小化一个函数，它可能会忽略多样性，而多样性对于许多科学应用至关重要。

3.5 因果发现

科学研究方法的一个重要目标是基于先前的观察和实验来理解某些现象的原因和结果。因果发现研究从数据中学习因果结构的问题。贝叶斯网络 [73] 是对联合分布的表示 d 随机变量 $\{Y_1, \dots, Y_d\}$ ，其条件独立性以紧凑的图形式编码。这些随机变量对应于有向无环图 (DAG) 的节点 G 这决定了联合分布的因子分解作为

$$P(Y_1, \dots, Y_d; \theta) = \prod_{i=1}^d P(Y_i | \text{Pa}_G(Y_i); \theta_i),$$

其中 $\text{Pa}_G(Y_i)$ 是图 G 中节点 Y_i 的父节点集合，而 θ_i 是与随机变量 Y_i 相关的条件分布的参数。尽管在贝叶斯网络中连接节点 G 的边仅编码随机变量之间的关联，因果图模型在此框架基础上增强了因果性的概念。在因果图模型中，同样由有向无环图（DAG）表示， G ，覆盖随机变量，任何有向边 $Y_i \rightarrow Y_j$ 都表示一个直接的因果影响，即从 Y_i 到 Y_j 。这使得模型不仅能够表示系统的联合分布（即被动观察系统），还能表示对系统进行主动实验的效果。因果模型指定了在任何干预下所获得的分布。例如，“DO-干预”设置变量的值，忽略其通常的原因。然而，由于相同的因果机制（即条件分布 $P(Y_i | \text{Pa}_G(Y_i); \theta_i)$ ）在所有干预中共享，如果因果机制（即 θ ）和图 G 已被正确推断，因果模型可以推广到训练期间从未见过的分布（即分布外），对应于新的干预。

3.5.1 因果结构学习

因果图模型的结构 G 通常假定已知，例如通过专家知识确定因果关系。这使我们能够使用这些模型执行多项任务，如推理（概率推理或因果推理）或从系统观察中学习因果模型的参数 θ 。然而，在科学研究的背景下，目标正是发现可能尚未被专家识别的因果关系。例如，在疾病的发展过程中，我们希望找出哪些因素（如社会因素、蛋白质组、病原体）参与其中。在这种情况下，我们希望通过数据（存储在数据集中 $\mathcal{D}$ ）来学习因果图模型的结构（至少是部分结构）。这些数据可以来自对系统的被动观察（称为观察数据，例如患者蛋白质表达的统计数据），也可以来自主动实验（称为干预数据，例如全基因组基因扰动）。这个问题被称为因果结构学习，或因果发现 [74, 75, 76, 77, 78]。

3.5.2 贝叶斯因果发现

正如可能存在多种理论来解释同一现象一样，也可能存在多个模型能够同样好地解释我们的观察结果，即使在数据量非常大的极限情况下也是如此。具体来说，这意味着许多标准结构学习方法通常会选择一个任意模型，这可能导致不希望的（甚至潜在有害的）结果。例如，如果我们有一个系统，其中只有两个（相关的）随机变量 A 和 B ，那么仅凭观测数据一般无法区分这两个因果模型 $A \rightarrow B$ 和 $B \rightarrow A$ ，尽管这两种模型具有显著不同的因果结论。此外，在实践中，用于识别因果模型的可用数据量在 $\mathcal{D}$ 可能很少，这引入了另一个变异性来源：由于因果发现方法仅返回一个候选模型，某些理论可能仅仅因为证据有限而被青睐。理想情况下，我们希望能够量化我们的认知不确定性，以避免模型误指定。这可以通过给定数据集 $\mathcal{D}$ 的因果结构的贝叶斯后验分布 G 来实现，类似于第 4.1.6 节中的描述。根据贝叶斯法则，后验概率由

$$P(G | \mathcal{D}) = \frac{P(\mathcal{D} | G)P(G)}{P(\mathcal{D})}. \quad (10)$$

在上述表达式中， $P(G)$ 表示我们的先验信念，并可能编码关于结构的一些先验知识 G 。例如，我们可以鼓励因果图是稀疏的，即限制图中任何节点的父节点数量。虽然这种先验可以根据专家知识设计，但它通常只表示对因果模型的软信念，并不代表单个图 G ，不像假设结构已知的情况。术语 $P(\mathcal{D} | G)$ 被称为边缘似然，定义为对所有可能的因果机制值进行积分

$$P(\mathcal{D} | G) = \int_{\Theta} P(\mathcal{D} | \theta, G)P(\theta | G)d\theta, \quad (11)$$

其中， $P(\mathcal{D} | \theta, G)$ 表示在特定因果结构和机制选择下的数据似然性，而 $P(\theta | G)$ 是对因果机制的先验分布。边缘似然性表示给定因果模型 G 的情况下，数据 $\mathcal{D}$ 与某一假设的契合程度，这与因果机制的选择无关。如同贝叶斯统计中通常遇到的情况一样，评估公式 10 的困难在于边缘证据 $P(\mathcal{D})$ ，这几乎总是不可计算的。为了规避这一问题，通常需要对贝叶斯后验进行近似处理，例如基于 MCMC [79, 80, 81, 82, 83]、自助法 [84, 85]，或者最近的变分推断 [86, 87, 88, 89, 90]。

3.5.3 因果结构的主动学习

通过对因果图的贝叶斯后验进行近似，我们可以利用第 3.3 节中贝叶斯实验设计的工具来设计干预措施，从而细化我们对系统因果结构的认识 [91]。这在基于数据估计因果图的不确定性、决定执行哪些实验以及获取新的实验数据之间形成了一个反馈循环（见图 1）。主动因果发现可用于学习整个系统的因果结构 [92, 93, 94, 95]，或者部分系统的因果结构 [85]。最近，Toth 等人 [96] 提出了一种名为主动贝叶斯因果推理（ABCI）的新框架，不仅可以推断出因果图，还可以联合学习感兴趣的因果查询的后验分布。

4 生成流网络

我们首先介绍使用神经网络高效地从采样的观测值到提议的高维概率分布和不可计算求和的映射的更广泛理念，以此作为流行的基于 MCMC 推理方法的一般替代方案。这些理念引出了 GFlowNets，它提供了一个使用神经网络进行摊销推断的一般框架。

4.1 学习执行摊销推断

我们首先探讨如何利用神经网络来摊销第 3.1 节引入的推理问题，即通过训练神经网络来近似执行原本难以处理的采样或求和任务。具体而言，我们考虑如何将一个难以计算的期望或求和转化为一个可计算的训练任务，从而近似得到所需的求和结果。这是 GFlowNets 的基本原理。

4.1.1 摊销难以计算的期望的简单均方误差准则

考虑一组我们希望近似的难以计算的期望，对于一对随机变量 x 和 y ，它们都可以取指数数量的值或存在于高维空间中：

$$S(x) = \sum_y p(y | x) R(x, y) \quad (12)$$

由于求和中指数级数量的项，这变得不可计算。如果我们知道如何从 $p(y | x)$ 采样，我们可以训练一个神经网络 S ，其输入为 x ，随机目标输出为 $R(x, y)$ ，并使用均方误差（MSE）损失

$$L(x, y) = \left(\hat{S}(x) - R(x, y) \right)^2 \quad (13)$$

其中 $y \sim p(y | x)$ ，用于训练估计器 S ，参数为 θ 。当我们采样训练样本时，随机梯度会使 $S(x, y)$ 收敛到 S ，前提是它有足够 $\frac{\partial L(x, y)}{\partial \theta}$ 的容量并且训练时间足够长 [97]。对于任何新的 x ，我们将有一个摊销估计器 $S(x)$ ，它在网络的一次通过中会给出不可计算求和的近似值 $S(x)$ 。我们可以认为这是一个比蒙特卡洛近似更有效的替代方案

$$\hat{S}_{MC}(x) = \text{mean}_{y \sim p(y|x)} R(x, y), \quad (14)$$




图 2: GFlowNet 示例示意图。(a) 由 GFlowNet 建模的对象分布应具有组合性，如图或序列，通过一系列动作构建；(b) 通过一系列动作表示 GFlowNet 可以构造分子的方式，这些动作将较小的片段组合起来形成一个有向无环图 (DAG)，其节点表示部分构造的分子，并在分子完成时提供奖励。




图 3: 系统泛化的可行性示意图, 该泛化由 ML 方法实现: 如果我们已经发现了奖励函数的三种模式, 一个能够泛化的学习者可能会猜测第四个模式的存在, 因为前三种模式似乎在网格上对齐。这种泛化结构的存在是为什么摊销的 ML 采样器可能比 MCMC 采样器表现得更好的原因。

这将需要大量的样本和计算 $\int R(x, y)$ 对于每个 x 在运行时, 特别是当 $\int p(y|x)R(x, y)$ 是一个丰富的多模态函数 (对这样的函数, 仅平均少量样本 y 并不能给出期望的良好估计)。除了运行速度快的优势外, 摊销版本的关键潜在优势在于它可以利用产品中的泛化结构 $\int p(y|x)R(x, y)$: 如果观察到一组训练集 $(x, y, R(x, y))$ 三元组可以让我们推广到新的 (x, y) 对, 则我们可能不需要重新训练 S 需要大量的示例才能捕捉到可泛化的结构并给出良好的答案 (即近似 $E_{Y|x}[R(x, Y)]$ 此句内容不完整, 无法进行有效翻译。请提供完整的句子或上下文。 x 的能力来源于数据结构中的泛化能力, 这实际上解释了机器学习 (尤其是深度学习) 在众多现代 AI 应用中取得显著成功的原因。当我们没有一个 $p(y|x)$ 如果我们能够轻松地从中采样, 原则上我们可以使用形成样本链的 MCMC 方法 y 分布收敛到期望的 $p(y|x)$, 并且下一个样本通常通过一个小的随机变化从上一个样本获得, 这种变化倾向于增加 $p(y|x)$ 。不幸的是, 当求和项的模式, $\int p(y|x)R(x, y)$, 在搜索空间中占据较小体积 (即投掷飞镖无法找到它们), 并且这些模式之间相隔较远 (由低概率区域分隔), 特别是在高维度情况下, 从一个模式转换到另一个模式往往需要指数级的时间。然而, 这种 MCMC 方法仍有改进空间: 尝试 $(x, y, R(x, y))$ 中包含可用于训练机器学习模型的信息。如果空间结构足够清晰, 这样的模型可以根据已观察到的模式的位置推测尚未看到的模式可能在哪里, 如图 3 所示。

4.1.2 GFlowNet 准则以获得采样器并估计不可计算的总和

让我们考虑一种情况, 即我们没有便捷的工具 $p(y|x)$, 我们的目标仅仅是近似一组难以处理的求和 (对于任何 x)

$$S(x) = \sum_y R(x, y) \quad (15)$$

其中约束条件为 $R(x, y) \geq 0$ 和 $S(x) > 0$ 。这可能有助于估计基于能量的模型或贝叶斯后验的概率归一化常数 (其中 y 对应于

可学习参数，而 x 对应于观测数据）。因此，我们可能也对采样策略感兴趣

$$\pi(y | x) = \frac{R(x, y)}{S(x)} \propto R(x, y). \quad (16)$$

现在，GFlowNet 损失是从我们希望成立的一组约束条件推导出来的：

$$\forall(x, y) : \quad \pi(y | x)S(x) = R(x, y). \quad (17)$$

我们可以定义估计器 $\hat{\pi}$ 和 $\hat{S}$ 并使用如下损失进行训练：

$$L(x, y) = \left(\hat{\pi}(y | x) \hat{S}(x) - R(x, y) \right)^2 \quad (18)$$

或者将 R 解释为未归一化的概率，我们希望对数域中对其进行良好校准，

$$L(x, y) = \left(\log(\hat{\pi}(y | x) \hat{S}(x)) - \log R(x, y) \right)^2 \quad (19)$$

其中， (x, y) 是从具有全支撑的训练分布 $\tilde{p}(x, y)$ 中采样的。可以证明 [11, 12]，当 $\hat{\pi}$ 和 $\hat{S}$ 拥有足够的容量并经过足够长时间的训练后，它们都会收敛到期望值：

$$\begin{aligned} \hat{S}(x) &\rightarrow S(x) \\ \hat{\pi}(y | x) &\rightarrow \pi(y | x) \propto R(x, y). \end{aligned}$$

这是 GFlowNets 的一个关键属性：它们被训练以按照给定的奖励函数 $R(x, y)$ 所确定的概率采样对象 y （给定 x ）。

4.1.3 对组合随机变量进行边缘化

为了使不可处理求和的概念更加具体，可以将 y （以及潜在的 x ）视为一个组合对象，比如变量-值对的子集或一个图。例如，我们可以通过一系列步骤顺序地构建组合对象，在每一步中插入组合对象的新部分，就像图 2b 所示的分子片段组成更大的分子一样。采样策略 π 然后在每一步顺序且随机地选择一个构建动作，每一步后我们得到一个部分构建的对象 s ，我们称之为 GFlowNet 状态。这样的一系列状态和动作形成了一个 GFlowNet 轨迹 τ 。在基本的 GFlowNet 框架中，动作是随机的，但下一个状态是从前一个状态和动作确定性地获得的，因为它们不是发生在外部环境中，而是采样器内部计算的一部分。此外，当前的 GFlowNet 数学结果假设每一步都是建设性的，即我们不能两次返回到同一个部分构建的对象 s 。这意味着所有可能轨迹的集合形成一个有向无环图（DAG），如图 2 所示。由于转换是确定性的，我们可以用一系列状态（或者等效地，一个初始状态和一系列动作）来指定一个轨迹 τ 。定义了一个特殊的“退出”动作来表明对象 y 的构建已完成。策略 $\pi(y | x)$ 现在由一个前向转移分布 $P_F(s | s')$ 指定，该分布说明了如何根据前一状态生成每个构建步骤，我们感兴趣的是对该策略进行参数化和学习这一过程 P_F 。例如，考虑图 2 所示的分子图示例。我们可以使用表示原子的节点作为构建块，依次构建分子图。从一个特殊的空状态开始，我们将其表示为 s_0 （这可以是一个空图、空集或空序列，或者基于条件变量的值 x 选择，可能指定了分子的一些期望特性），对象 y 可以通过一系列步骤构建，每一步包括添加一个单独的构建块 $a \in \mathcal{A}$ 。我们假设动作仅限于构建性操作，不允许删除构建块。在每一步中，我们都有一个部分构建的对象 $s \in \mathcal{S}$ ，其中 $\mathcal{S}$ 表示所有可能的部分构建对象的空间，并且 $\mathcal{Y} \subset \mathcal{S}$ 。我们还假设这些状态具有马尔可夫性质，即它们包含了其历史的所有信息。这形成了一个有向无环图（DAG） $\mathcal{G}$ ，它由一个元组 $(\mathcal{S}, \mathcal{E})$ 定义，其中节点集合对应于 $\mathcal{S}$ ，而一条边 $s \rightarrow s' \in \mathcal{E}$ 表示对象 s' 可以通过向 s 添加一个构建块 $a \in \mathcal{A}$ 来构建 $\xrightarrow{a} s'$ 。我们可以将轨迹定义为描述构建过程的一系列步骤。

$\tau = (s_0 \xrightarrow{a_1} s_1 \dots \xrightarrow{a_n} y \text{ 一个对象})$.² 让 $R(x, y)$ 表示在特定上下文 x 中给定对象 y 的效能, it can b 用 (奖励)。例如, 它可以表示配体分子 y 与特定目标蛋白质 x 结合的能量。形式上, 训练目标是学习一个随机策略 π , 该策略按顺序生成一个对象 y , 其概率与其奖励成正比, 即 $\pi(y | x) \propto R(x, y)$ 。

4.1.4 多个父状态

除了生成过程的顺序性质之外 y 一个有趣的复杂之处在于, 可能存在多种方式 (实际上有指数级多的轨迹) 来构建 y 从某个起始点和上下文开始 x 这意味着一个部分构造的对象, 即一种状态 s , 可能有多父节点 s' 对于其中的一项操作 a 导致的存在 s 否则 (当每个状态只有一个父节点时), 有向无环图构成一棵树, 这使得计算变得简单得多。但当它不是一棵树时, 考虑并参数化一个反向转移概率函数会更加方便 $P_B(s' | s)$ 这与该有向无环图及其相关的前向转移概率一致 P_F 方程 17 中的约束可以以几种方式重新表述, 特别是所谓的细致平衡约束:

$$\forall(s, s') : P_F(s | s')F(s') = P_B(s' | s)F(s) \quad (20)$$

其中, $F(s)$ 被称为状态 s 的流, 其作用类似于前述的 $S(x)$, 即它是一个难以处理的求和项, 并且存在一个起始状态 $s_0 = x$, 从该状态开始一条轨迹, 同时终端状态 $s = y$ 流入的流量等于 $R(x, y)$ 。与上述简单情况类似, 这可以转化为一个我们希望最小化的训练损失, 但现在是对所有 (x, τ) 对或所有 (s, s') 对进行。满足所有 (s, s') 对的细致平衡约束后, 初始流就等于归一化常数 [11]。

$$F(s_0) = S(x) = \sum_y R(x, y). \quad (21)$$

4.1.5 学习目标

在实践中, 我们希望用可学习参数 θ 来近似 $P_F(\cdot | \cdot; \theta)$, $P_B(\cdot | \cdot; \theta)$ 和 $F(\cdot; \theta)$, 并且希望选择这些参数尽可能满足细致平衡约束 $\forall s, s' \in \mathcal{S}$ 。细致平衡约束可以转化为以下损失函数来学习参数 θ :

$$\mathcal{L}_{DB}(s, s'; \theta) = \left(\log \frac{P_F(s' | s; \theta)F(s'; \theta)}{P_B(s | s'; \theta)F(s; \theta)} \right)^2. \quad (22)$$

针对 GFlowNets 提出了几种替代的学习目标, 特别是在采样对象的较长轨迹方面 y [98, 99]。轨迹平衡 [98, TB] 是训练 GFlowNets 的一个突出学习目标。与考虑状态对之间约束的细致平衡目标不同, 轨迹平衡将细致平衡约束联合应用于整个轨迹。引入一个可学习参数 Z , 在收敛时等于期望的总和。轨迹平衡损失对于一个轨迹 τ 定义如下:

$$\mathcal{L}_{TB}(\tau; \theta) = \left(\log \frac{Z_\theta \prod_{s \rightarrow s' \in \tau} P_F(s' | s; \theta)}{R(x, y) \prod_{s \rightarrow s' \in \tau} P_B(s | s'; \theta)} \right)^2. \quad (23)$$

算法 2 展示了训练 GFlowNets 的一种典型方法, 通过从采样策略 $\hat{P}_F$ 中抽取轨迹进行, 该策略通常是经过调温的 P_F 或与均匀策略混合的 $\tilde{P}_F$, 以实现探索, 并利用学习目标相对于 θ 的损失进行随机梯度下降优化³。通过这一过程, 我们学习到一个 P_F , 其目标是使终止于终端状态的轨迹的边缘似然度 x , 记作 $\pi(x)$, 与奖励 $R(x)$ 成正比。可学习的对象 P_F, P_B, F 通常由神经网络参数化。这些神经网络必须根据所构建对象的类型具有适当的归纳偏置。这些神经网络还必须具备足够的容量来建模

² 需要注意的是, 可能会有多种轨迹最终导致相同的对象。³ 实现各种 GFlowNet 学习目标的代码在简单合成领域上的应用: [saleml/gfn](https://github.com/saleml/gfn)

潜在分布。在第 4.2 节和第 4.3 节中，我们将讨论利用 GFlowNets 解决分子生成和因果建模问题的具体案例。

Algorithm 2: General recipe for training GFlowNets

Input: Reward function $R(x, y)$, Learning objective or training loss $\mathcal{L}$;
Initialize: $F(\cdot; \theta), P_F(\cdot | \cdot; \theta), P_B(\cdot | \cdot; \theta)$ for DB and $Z_\theta, P_F(\cdot | \cdot; \theta), P_B(\cdot | \cdot; \theta)$ for TB;
for $i = 1 \dots N$ **do**
 Sample trajectory τ from the sampling policy $\hat{P}_F(\cdot | \cdot; \theta)$;
 Compute the training loss $\mathcal{L}$;
 Update parameters θ with stochastic gradient descent;
end
Result: Policy $\pi(x) \propto R(x)$

4.1.6 对贝叶斯机器学习的启示

让我们考虑一个特殊情况，其中 $y = \theta$ 是一个潜在参数，即在贝叶斯设置下，而 $x = \mathcal{D}$ 是可用数据。然后我们可以定义奖励函数

$$R(\mathcal{D}, \theta) = P(\theta)P(\mathcal{D} | \theta) \quad (24)$$

从参数先验（ $P(\theta)$ ）（这些参数在先验上有多合理）和数据似然性（ $P(\mathcal{D} | \theta)$ ）（这种参数选择与数据拟合得有多好）。训练 GFlowNet 为我们提供了一个近似的后验参数采样器（策略 $\pi(\theta | \mathcal{D})$ ）以及贝叶斯后验归一化常数的估计器，通过学习到的初始流（ $S(\mathcal{D})$ ）。因此，我们已经使用了摊销方法将一个可计算函数（先验乘以似然性，作为关于 θ 的函数）转化为这些通常难以计算的数量的估计器。我们得到了一个快速的后验采样器，无需通过大量的候选样本进行马尔可夫链。有了这个采样器，我们可以生成许多独立样本（ $\theta | \mathcal{D}$ ）

（可能并行生成），这些样本很可能访问后验中的较大模式（奖励较大的地方）。为了使计算更符合机器学习（尤其是在大数据集的情况下），在训练 GFlowNet 时，我们可以注意到 GFlowNet 平方损失目标自然适用于奖励或对数奖励是随机的情况，并且是对真实奖励的无偏估计。例如，我们可以将整体数据集的对数似然性（ $\log P(\mathcal{D} | \theta)$ ）分解为每个示例或每个小批量项的总和，并引入一个乘法修正来考虑先验（ $P(\theta)$ ）：

$$\begin{aligned} \log \hat{R}(Z, \theta) &= \log P(\theta) + |\mathcal{D}| \log P(Z | \theta) \\ E_Z[\log \hat{R}(Z, \theta)] &= \log P(\theta) + \sum_{Z \in \mathcal{D}} \log P(Z | \theta) = \log R(\mathcal{D}, \theta) \end{aligned}$$

其中，对 Z 的期望仅仅是对 $\mathcal{D}$ 中所有 Z 的求和。这使得可以使用随机梯度下降方法训练 GFlowNet 后验估计器，无论是单个样本还是小批量样本，这种方法是最先进的深度网络训练方式。

4.1.7 为什么是 GFlowNets?

让我们看看 GFlowNets 与其他相关概念框架有何不同：

- 马尔可夫链蒙特卡罗：GFlowNets 不构建具有类似 MCMC 方法语义的马尔可夫链。GFlowNets 和 MCMC 方法在根本上有所不同：MCMC 方法中的链是不可约的（从任一状态可以到达其他所有状态），并且该链的平稳分布是我们感兴趣的。为了从这个平稳分布生成样本，我们需要运行很长的链（理想情况下是无限长的）。而在 GFlowNets 中，链只需要从初始状态可以访问到每个状态，并且我们拥有的是一系列有界的随机转换。通常由 MCMC 执行的昂贵的随机“搜索”（以达到低能量配置）被 GFlowNet 的训练阶段所取代，该阶段使用摊销推断的原则，使得在推理过程中可以通过策略在一个简短的轨迹中生成样本。举例来说，如果我们运行一个 MCMC 来生成理想的分子样本，那么在每个状态下可能都会有一个分子。

我们可以有随机地将一个分子转化为另一个邻近分子的动作 [100]，而使用 GFlowNets 采样理想分子的一种典型方法是构造性的，即从一个空对象（这实际上不是一个分子）开始，并随机地依次添加分子片段：状态对应于这些中间对象，它们可能对应也可能不对应一个结构良好的分子 [11]。尽管如此，总体目标是相同的：将给定的能量函数（或未归一化的分布）转化为生成该分布样本的过程。MCMC 和 GFlowNets 都可以用于边缘化，即计算不可计算的总和，尽管方式不同。MCMC 将精确的总和转化为其蒙特卡洛近似，而 GFlowNets 执行摊销推断，即训练一个神经网络，其输出在训练后将逼近该总和。当需要进行多次边缘化操作时，例如给定一个上下文，这种方法变得有用，因此神经网络可以将该上下文作为输入，并迅速产生一个不可计算总和的估计器作为输出。

- 强化学习：GFlowNets 学习策略以采样轨迹，这些轨迹以与终端状态奖励成比例的概率终止于一个终端状态，而不是像标准深度强化学习那样最大化预期奖励。正如 Bengio 等人 [11] 和 Jain 等人 [101] 所示，这导致样本多样性，这对于奖励函数作为我们真正关心属性的不完美代理时非常重要：它避免将所有资源集中在错误的目标上。
- 深度生成模型：传统的深度学习生成模型，如变分自编码器（VAEs）[102, 103] 或生成对抗网络（GANs）[104]，需要正样本来建模感兴趣的分布，而 GFlowNets 则是通过奖励函数进行训练。
- 变分推断：变分推断训练一个近似采样器（及其对应的密度函数），以减少与给定分布函数之间的前向 KL 发散（即证据下界或 ELBO）。这需要在线策略训练（从学习到的采样器中进行采样），这种训练倾向于关注单一模式而非寻找多种模式。相反（详见 Malkin 等人的研究 [25]），GFlowNet 目标使得可以进行离线策略训练，无需像使用 ELBO 时那样需要高方差的重要度采样修正。

总之，GFlowNets 在具有以下性质的问题中表现出色：

- 可以定义或学习一个非负奖励函数，该函数将指定 GFlowNet 应从哪个分布进行采样。
- 所关注的奖励函数具有高度多模态特性。这突显了 GFlowNet 在样本多样性方面的优势。如果奖励函数是一模态的，现有的强化学习或变分推断方法（倾向于聚焦于单一模式）可以替代使用。
- 顺序采样是有利的，例如，存在可以通过顺序生成来利用的组合结构。

当前局限性。直到最近，GFlowNets 还仅限于从离散对象（如图）的分布中进行采样。Lahlou 等人的一项近期工作 [105] 提出了一个理论框架，用于将 GFlowNets 扩展到连续空间的分布采样。如何利用这一框架对高维连续或混合（离散和连续）空间的分布进行采样仍然是一个开放问题。另一个潜在的局限性是，与其他强化学习方法一样，在生成大型对象（如蛋白质）的非常长轨迹上进行有效的信用分配更为困难。Pan 等人 [106] 初步尝试解决这个问题，提出了一种方法，即在生成轨迹的早期阶段分配部分奖励，从而实现更有效的信用分配。另一个开放问题是关于 GFlowNet 训练轨迹采样的最佳策略。Bengio 等人的现有理论结果 [12] 假设轨迹采样的策略应具有在整个轨迹空间上的完全支持，但设计这种策略（超出第 4.1.5 节讨论的启发式方法）以实现样本高效的训练仍是一个开放问题。

4.2 多样性候选生成

化学中的一个基本问题是合成满足某些标准的新颖化学结构（例如分子）。正如第 4.1 节所提到的，生成优化特定化学性质的分子是 GFlowNets 的一个有吸引力的应用场景，因为 GFlowNets 倾向于生成优化该性质的一系列多样化的分子。在药物发现的背景下，一个重要的问题是我们已在示例 1.1 中介绍过的，即发现能够与特定目标结合的分子，这一过程可能抑制该目标。从计算设计的角度来看，分子对接仿真可以提供评分函数来近似评估提出的分子。最近，图神经网络被用来近似对接，因为它们的速度更快，这些图神经网络可以近似结合能 [107]。正如第 2 节讨论的那样，由于这些评分函数是对潜在过程的近似，因此生成多样化的候选物对于下游应用至关重要，以避免将所有鸡蛋放在同一个篮子里。[11] 利用 GFlowNets 解决多样化分子生成的问题⁴。研究的目标是在 4JNC 构型下的可溶性环氧化物水解酶（sEH），它是一个有用的靶点，因为它在某些呼吸系统和心脏疾病中发挥作用 [108, 109]。Autodock Vina 软件 [110] 用于对接生成的分子以评估结合能。使用 Autodock Vina 对接每个分子的过程相当缓慢，需要几分钟才能运行，这使得直接使用它作为奖励进行训练变得不切实际。相反，作者依赖于一个图神经网络，该网络使用 300,000 个分子的对接分数数据集进行训练，作为训练策略的奖励。分子是通过片段生成的，如图 2 所示。在每一步中，策略从片段库中选择一个片段添加到部分构建的分子中，并选择放置该片段的位置。片段库是从 Zinc 数据库中导出的 [111]。分子设计问题具备第 4.1.7 节讨论的所有关键属性，使 GFlowNets 有效——(a) 生成过程中存在组合结构，因为分子是使用具有独特化学性质的子图构建的；(b) 奖励函数是对我们真正关心的东西的近似，因为对接分数及其由神经网络（由于有限的训练而具有认知不确定性）的近似都是对分子与目标结合并抑制它的潜在现象的近似；(c) 奖励是多模态的，因为可能存在多种与给定目标结合良好的分子模式。[11] 表明，在分子生成任务上，GFlowNets 相对于现有方法取得了显著改进。特别是，如图 4a 所示，GFlowNets 发现了更多奖励函数的模式（即许多具有高预测对接分数的不同分子），相对于其他强化学习（PPO）和 MCMC（MARS）方法。按奖励比例采样导致高奖励和多样化的样本。需要注意的是，虽然使用 GFlowNets 在生成样本的多样性方面带来了显著改进，但它们并不总是产生最高得分的候选物，因为在多样性和奖励之间存在自然的权衡。[112] 引入度量来研究 GFlowNets 探索分子空间新区域的能力。此外，[11] 还考虑了一个主动学习设置，从包含 2000 个分子的数据集开始。在每一轮中，训练一个代理模型用于数据集。这个代理模型作为 GFlowNet 的奖励。接下来，使用 GFlowNet 策略生成分子，通过对接进行评估，并添加到下一轮的数据集中。使用 GFlowNet 获取分子批次在奖励上相对于初始数据集有了显著提高，如图 4b 所示，展示了 GFlowNets 加速大规模虚拟筛选的潜力。从实用角度来看，我们通常对多个目标而不是单一目标感兴趣。例如，在药物发现的背景下，理想的药物候选物应该特异性地抑制目标，同时还能大量合成、溶解并且对人体无害；或者在材料科学中，高效的太阳能电池意味着电流、电压和填充因子的优化。通常情况下，很少有候选物能够同时满足所有目标，这些目标甚至可能是相互冲突的（例如，在太阳能电池中，具有较低带隙的光活性材料可以增加光电流，但电压会降低）。相反，存在一组候选物，它们在目标之间的最优折衷中，进一步优化一个目标是不可能的，而不牺牲另一个目标，即帕累托前沿。此外，就像单目标情况一样，多样性在多目标情况下仍然至关重要。多目标 GFlowNets [113, MOGFNs;] 扩展了 GFlowNets 以应对多目标优化问题。基于多目标优化中的标量化方法，4Code for 分子生成递归 `pharma/gflownet`




图 4: (a) 使用 GFlowNets 生成的分子覆盖了奖励分布的更多模式，从而产生了多样化的奖励分子。(b) 获取使用 GFlowNets 生成的分子显著改善了初始分子池。图取自 [11] 并获得许可。

优化 [114]，MOGFNs 将多目标优化问题分解成一组可以同时求解的子问题。这组子问题同时通过奖励条件的 GFlowNet 进行建模 [12]。MOGFNs 在多种小分子生成和蛋白质设计任务上展示了最先进的性能。MOGFNs 一致生成多样化的帕累托最优候选物。例如，MOGFNs 能够生成与 sEH 靶点结合的分子，同时实现高合成性和 QED 分数。主动学习设置进一步探讨了 [101]⁵。结合第 3.4 节讨论的贝叶斯优化思想，GFlowNet-AL [101] 在 GFlowNet 的奖励中引入了关于替代模型的认知不确定性的信息，通过采集函数。这种认知不确定性有助于引导 GFlowNet 优化状态空间中较少探索的有前景区域。因此，与算法 1 中最大化采集函数不同，[101] 提出按采集函数比例采样。装备有关于奖励中的认知不确定性和其他改进的信息，GFlowNet-AL 在多种生物序列设计任务上超越了各种现有方法，包括生成具有抗菌特性的肽序列。状态空间 S 包含部分构建的序列，每个动作都是从词汇表（例如氨基酸集合中的一个残基）添加到当前部分序列的末尾。由 GFlowNets 生成的候选序列显著更加多样化，并且具有高奖励。生成候选物的多样性展示了 GFlowNets 加速发现新型抗生素以应对日益严重且令人担忧的抗菌素耐药性现象的潜力 [115]。这些初步的经验成功展示了 GFlowNets 在改善广泛科学问题实验设计方面的潜在重大影响。

4.3 因果模型的后验建模

4.3.1 利用 GFlowNets 进行贝叶斯因果发现

正如我们在第 4.1.6 节中看到的，GFlowNets 提供了近似贝叶斯后验的一般解决方案，如等式 10 所示。GFlowNets 尤其适用于贝叶斯因果发现的问题，因为因果结构 G 表示为有向无环图的对象是组合对象。Deleu 等人 [116] 利用这一观察引入了一种 GFlowNet，其状态为有向无环图，并且其中某些图为 G 通过从完全不连通的图开始，每次添加一条边的方式顺序创建 d 节点；此 GFlowNet 的结构如图 5（左）所示。类似于公式 24，对于一个固定的数据集 $\mathcal{D}$ ，GFlowNet 的奖励函数定义为 $R(G) = P(\mathcal{D} | G)P(G)$ 。通过在每个状态下限制有效动作的集合，边被添加的方式确保永远不会引入循环，从而保证在构造的每一步中图都保持无环。因此，GFlowNet 的所有状态都是有效的因果结构。Deleu 等人 [116] 利用这一特性，并展示了可以通过修改细致平衡损失函数 [12，参见公式 20] 来训练这样的 GFlowNet，特别适用于所有状态均为终止状态的情况。

⁵ 用于生物序列主动学习的代码：mj10/BioSeq-GFN-AL 和 alexhernandezgarcia/gflownet ⁶ 用于建模因果模型后验分布的代码：tristandeleu/jax-dag-gflownet




图 5: 贝叶斯因果发现的 GFlowNet。(左) 根据 [116] 引入的 GFlowNet 结构, 其中有向无环图 (DAG) 是一次构建一条边。每个 DAG 都与一个奖励关联 $R(G)$ 。(右) 使用精确的后验分布计算边缘概率与使用 GFlowNet 近似计算的比较; GFlowNet 能够准确地逼近精确的后验分布 $P(G | \mathcal{D})$ 。经 Tristan Deleu 许可使用。

为了评估奖励函数 $R(G)$ 虽然, 需要评估边缘似然性 $P(\mathcal{D} | G)$ 在公式 11 中, 这通常情况下是难以处理的 [117] 德勒等人。[116] 仅对多项式-狄利克雷模型 (适用于离散数据) 和线性-高斯模型 (适用于连续数据) 进行了实验, 因为这些模型的边缘似然可以在封闭形式下高效计算。然而, 也可以选择近似 (边缘) 贝叶斯后验 $P(G | \mathcal{D})$ 仅在结构上, 我们可以近似后验分布 $P(\theta, G | \mathcal{D})$ 跨越因果结构 G 以及因果机制 θ [118], 以避免在公式 11 中进行难以处理的积分。

超越 DAGs。 因果发现的研究主要集中在第 3.5 节介绍的假设具有有向无环图 (DAG) 结构的因果图模型框架上, 但无环性确实是一个可能在某些领域不成立的假设。例如, 在基因调控网络中, 多个基因之间存在反馈循环 [119]。然而, 当我们考虑时间展开的循环图, 即动态过程时, 我们又回到了有向无环图的情况。一些最近的工作研究了学习非无环因果模型结构的问题 [120, 121, 122]。上述讨论的 GFlowNet 方法自然扩展到了因果图可能是循环的情况。Deleu 等人引入的掩码机制 [116] 防止在每一步添加边时引入循环, 确保生成的图是有向无环图。如果我们移除这一额外约束, 允许 GFlowNet 在生成的图中引入循环, 则它将逼近符合给定观测的循环因果模型的后验分布。

4.3.2 科学发现的贝叶斯后验

后验预测 一旦因果图模型的结构已知, 我们可以利用该模型进行推理, 即在不同干预背景下回答关于感兴趣系统的 (可能具有因果关系的) 问题 (我们可以将其解释为设定某些变量, 即设计实验)。如果我们有关于认知不确定性的信息, 通过贝叶斯后验 $P(G | \mathcal{D})$, 我们可以更进一步, 利用后验分布加权平均所有可能的因果模型所做出的预测。具体来说, 给定一个新的观察值 y 和一个干预背景 x , 这对应于评估

$$P(y | x, \mathcal{D}) = \sum_G P(y | x, G, \mathcal{D}) P(G | \mathcal{D}). \quad (25)$$

这被称为后验预测, 或贝叶斯模型平均 [123, 124]。相比于使用单一因果模型进行预测, 公式 25 的优势在于可以同时让多个理论参与预测过程。这样, 我们可以避免仅依赖可能不正确的单一理论, 并获得更为保守的答案, 从而避免因某一特定理论 (比如某个因果图 G) 自信地错误而导致的灾难性结果。

摊销后验预测 为了避免对每个候选者 x 按照公式 25 进行蒙特卡洛平均来估计 $P(y | x, \mathcal{D})$ （这在考虑大量可能的 x 时可能会相当耗时），我们可以使用神经网络 $g_\phi(x, y)$ 来摊销这一计算。通过训练 g 覆盖 (x, y, G) 三元组并采用平方损失来进行此操作

$$\mathcal{L}(\phi) = \mathbb{E}_{P(G|\mathcal{D})} \left[\mathbb{E}_{P(y|x,G,\mathcal{D})} \left[(g_\phi(x, y) - P(y | x, G, \mathcal{D}))^2 \right] \right]. \quad (26)$$

还有其他可能的摊销方法。例如，可以使用 GFlowNet 框架训练策略 $Q(y_i | x_i, y_1^{i-1}, x_1^{i-1})$ ，使其每次根据实验规格输入 x_i 和先前实验的结果 $y_1^{i-1} \dots x_1^{i-1}$ 采样一个结果 y_i 。需要满足的 GFlowNet 约束是

$$P(\mathcal{D}, G) = Q(\mathcal{D}, G) \quad (27)$$

$$P(G)P(\mathcal{D} | G) = Q(\mathcal{D})Q(G | \mathcal{D}) \quad (28)$$

$$P(G) \prod_{i=1}^{|\mathcal{D}|} P(y_i | x_i, G) = Q(G | \mathcal{D}) \prod_{i=1}^{|\mathcal{D}|} Q(y_i | x_i, y_1^{i-1}, x_1^{i-1}) \quad (29)$$

训练后的后验预测将部分数据集 (x_1^{i-1}, y_1^{i-1}) 作为输入，类似于神过程 [125] 和 $Q(G | \mathcal{D})$ 。GFlowNet 因果图采样器如上所述，只是我们允许对数据进行干预（不同选择的 x ）。

可解释性 贝叶斯因果模型的后验分布也为可解释性提供了一种自然工具，因为它们编码了因果结构与观测数据相符合的信念。通过检查哪些因果结构包含特定边，我们可以获得两个随机变量之间存在某种因果关系的信念 [126]。这被称为边缘分布。

$$P(Y_i \rightarrow Y_j \in G | \mathcal{D}) = \sum_G \mathbb{1}(Y_i \rightarrow Y_j \in G) P(G | \mathcal{D}) \quad (30)$$

图 5（右）展示了通过 DAG-GFlowNet 返回的后验近似值计算出的边缘边际与精确边缘边际的比较，突显了 GFlowNets 在图上准确逼近后验分布的能力 [116]（边缘边际的近似值与精确值进行了对比，表明了 GFlowNets 方法的有效性 $P(G | \mathcal{D})$ ）。需要注意的是，这种比较通常限于小规模问题，在这些问题中，真实的后验分布 $(P(G | \mathcal{D}))$ 可以高效地以封闭形式计算。一般来说，人们可能关注这些估计边缘概率的校准问题 [90]。

5 科学发现的统一框架

GFlowNets

本文介绍了 GFlowNets 作为一种工具，在科学发现循环（图 1）中用于建模和实验设计。总结了它们在两个方面的应用及其未来可能的应用方向。在本结论部分，基于早期工作，概述了一些研究方向，旨在为科学家提供一个强大的基于机器学习的框架，适用于可以迭代生成具有信息量的实验数据的情况。

5.1 利用摊销因果贝叶斯模型定义实验的效用

一个有吸引力的理论框架用于定义实验的目标是在第 3.2 节中引入的信息增益：“我们期望通过实验获得多少关于感兴趣随机变量的信息？”一个好的实验设计策略应该提出具有高信息增益值的实验作为奖励。请注意，这个框架广泛适用于各种交互式学习领域，如强化学习和主动学习，涵盖了探索的基本问题。通常，执行实验的决策不仅仅基于获得的信息比特数，还基于风险

以及涉及的成本 [127]。然而，我们可以引入成本或预算的概念，通过考虑每单位成本所获得的信息增益作为奖励。信息增益原则上可以通过实验结果（尚未进行的随机变量）与感兴趣的变量（我们希望从中获取信息的变量）之间的互信息来衡量，给定实验规格和我们可能已经拥有的任何其他知识（包括数据）。在最简单且纯粹的无监督知识探索场景中，感兴趣的变量可能是解释实验结果的因果模型。在一个更具体的场景中，例如药物发现，它可能是具有某些理想特性的分子集合（例如，与目标蛋白质的亲和力超过某个阈值，毒性低于某个阈值，合成成本低于某个阈值）。设 Y 为实验结果， x 为实验规格， V 为感兴趣的变量。那么，我们的实验设计的信息论效用可以定义为

$$I(Y; V | x, \mathcal{D}) = \sum_{y,v} P(y, v | x, \mathcal{D}) \log \frac{P(y, v | x, \mathcal{D})}{P(y | x, \mathcal{D})P(v | x, \mathcal{D})} \quad (31)$$

$$= \sum_{y,v} P(y, v | x, \mathcal{D}) \log \frac{P(y | v, x, \mathcal{D})}{P(y | x, \mathcal{D})} \quad (32)$$

其中 $\mathcal{D}$ 是我们之前实验结果的数据集 $\{(x, y)\}$ 以及任何其他我们希望利用来条件化概率的约束。由于 V 通常是一个比 Y , Eq. 32 维度更高的对象，因此在数值上往往更实用。为了评估公式 32 中的表达式，我们可以利用摊销和 GFlowNets 的思想来估计 (a) 分子和分母的概率 $P(y | v, x, \mathcal{D})$, $P(y | x, \mathcal{D})$ (b) 联合分布的采样器 $P(y, v | x, \mathcal{D})$ 以及 (c) 互信息本身的估计器 $\hat{I}$ 作为函数的 x 当感兴趣的变量是某个潜在过程的参数时 $v = \theta$ (如第 3.2 节所述)，我们可以按照第 4.3.2 节概述的摊销方法来估计后验预测 $P(y | x, \mathcal{D})$ 在分母中。另一方面，分子中的似然性 $P(y | \theta, x, \mathcal{D}) = P(y | \theta, x)$ 在显式模型的情况下是可以获得的，并且可以在第 3.3 节讨论的隐式模型情况下进行近似。接下来，为了学习联合分布的采样器 $P(y, \theta | x, \mathcal{D})$ 我们首先按照第 4.1.6 节的方法近似来自参数后验分布的样本 $Q(\theta | \mathcal{D})$ 通过结合来自后验分布的样本 $Q(\theta | \mathcal{D})$ 和似然性 $P(y | x, \theta)$ 我们可以学习一个采样器 $Q(y, \theta | x, \mathcal{D}) = Q(\theta | \mathcal{D})P(y | x, \theta)$ 来近似联合分布 $P(y, \theta | x, \mathcal{D})$ 。至于互信息的估计器，一种可能性是训练一个神经网络 $\hat{I}(x)$ 来摊销给定 (θ, y) 的期望值 $x, \mathcal{D}$ 使用来自联合分布的样本 $Q(y, \theta | x, \mathcal{D})$ 和对数概率比中概率的估计器，使用平方损失 $(\hat{I}(x) - \log \frac{P(y | x, \theta)}{P(y | x, \mathcal{D})})^2$

$$Q(y | x, \mathcal{D}) \Big)^2 \quad (33)$$

其中 x 是从数据集或输入的生成模型中采样的， $\theta \sim Q(\theta | \mathcal{D})$ ，并且 $y \sim P(y | x, \theta)$ 。在具备足够的容量和训练时间的情况下， Q 收敛到 P ，而 $\hat{I}(x)$ 收敛到 $I(Y; \theta | x, \mathcal{D})$ 。特别有趣的是，如果 x 处于高维空间中，通常不需要为每个 x 值看到超过一个 y 和 θ 值来训练 $\hat{I}$ ，就像在监督学习中一样。这可以实现，前提是用于训练 $\hat{I}$ 的学习过程能够从 (θ, x, y) 三元组中泛化。

5.2 额外的开放挑战

5.2.1 建模与因果关系

在建模方面，一个公开的挑战是如何利用 GFlowNets 来建模超越因果模型的贝叶斯后验分布。[128] 在此方向上迈出了第一步，使用 GFlowNets 来建模神经网络中随机失活掩码的后验分布。此外，在因果模型的背景下，仍有许多挑战需要扩展 [116] 的工作。这包括 (a) 高效地处理更大的因果图

(b) 使得能够处理未观测到的因果变量，同时也学习原始输入（如图像）与因果变量之间的关系 (c) 学习实验选择如何与对因果变量的干预相关联，当这些关联事先并不完全清楚时

5.2.2 实验设计

我们的讨论主要集中在对参数 θ 的信息增益感兴趣，以驱动实验设计循环中的知识获取。正如上一节所述，我们可以将任何可以建模和采样的随机变量 V (Eq. 31) 纳入其中。一个有趣的情况是随机变量 V 是一个极值，例如，对于某些任务的顶级分子候选者，如等式 9 所示。此外，在许多实用的实验设置中，我们可以通过实验结果获得不同保真度的测量值（例如，具有不同精度-计算成本权衡的计算机仿真）。这种多保真度设置在上述部分（第 3.4 节）中进行了讨论，但需要在 GFlowNet 框架内进行整合。在同一节中介绍的另一个重要实用场景是存在多个目标，Jain 等人在早期工作中将其纳入 GFlowNet 框架中 [113]。最后，如第 3.5 节所述，这些实验设计工具可以集成到因果发现框架中，通过将知识获取集中在因果图本身来实现，这对于科学家来说是一个具有解释性的价值对象。这可以通过将图本身作为目标变量 V （或其一部分）来实现，从而推动实验设计以加速因果结构的发现。

致谢

作者感谢 DreamFold 和 Maksym Korablyov 的重要帮助、建议和反馈，以及来自 CIFAR、Recursion、IVADO、NSERC、IBM、Intel 和魁北克省政府的资金支持。

参考文献

- [1] C. Adler, P. Wester, I. Bhatt, C. Huggel, G.E. Insarov, M.D. Morecroft, V. Muccione, and A. Prakash. *Cross-Chapter Paper 5: Mountains*, pages 2273–2318. Cambridge University Press, Cambridge, UK and New York, USA, 2022. ISBN 9781009325844. doi: 10.1017/9781009325844.022.2273.
- [2] Thomas A Ban. The role of serendipity in drug discovery. *Dialogues in clinical neuroscience*, 2022.
- [3] Regine S. Bohacek, Colin McMartin, and Wayne C. Guida. The art and practice of structure-based drug design: A molecular modeling perspective. *Medicinal Research Reviews*, 16(1):3–50, 1996. doi: [https://doi.org/10.1002/\(SICI\)1098-1128\(199601\)16:1<3::AID-MED1>3.0.CO;2-6](https://doi.org/10.1002/(SICI)1098-1128(199601)16:1<3::AID-MED1>3.0.CO;2-6). URL <https://onlinelibrary.wiley.com/doi/abs/10.1002/%28SICI%291098-1128%28199601%2916%3A1%3C3%3A%3AAID-MED1%3E3.0.CO%3B2-6>.
- [4] Benjamin P MacLeod, Fraser GL Parlane, Thomas D Morrissey, Florian Häse, Loïc M Roch, Kevan E Dettelbach, Raphaell Moreira, Lars PE Yunker, Michael B Rooney, Joseph R Deeth, et al. Self-driving laboratory for accelerated discovery of thin-film materials. *Science Advances*, 6(20):eaaz8867, 2020.
- [5] Anthony JG Hey, Stewart Tansley, Kristin Michele Tolle, et al. *The fourth paradigm: data-intensive scientific discovery*, volume 1. Microsoft research Redmond, WA, 2009.
- [6] Ankit Agrawal and Alok Choudhary. Perspective: Materials informatics and big data: Realization of the “fourth paradigm” of science in materials science. *Apl Materials*, 4(5):053208, 2016.
- [7] Hannes Stärk, Dominique Beaini, Gabriele Corso, Prudencio Tossou, Christian Dallago, Stephan Günnemann, and Pietro Liò. 3d infomax improves gnns for molecular property prediction. In *International Conference on Machine Learning*, pages 20479–20502. PMLR, 2022.
- [8] Elizabeth G Ryan, Christopher C Drovandi, James M McGree, and Anthony N Pettitt. A review of modern computational algorithms for bayesian optimal design. *International Statistical Review*, 84(1):128–154, 2016.

- [9] Christof Angermueller, David Dohan, David Belanger, Ramya Deshpande, Kevin Murphy, and Lucy Colwell. Model-based reinforcement learning for biological sequence design. In *International conference on learning representations*, 2019.
- [10] Samuel Kim, Peter Y Lu, Charlotte Loh, Jamie Smith, Jasper Snoek, and Marin Soljacic. Deep learning for bayesian optimization of scientific problems with high-dimensional structure. *Transactions of Machine Learning Research*, 2022.
- [11] Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow network based generative models for non-iterative diverse candidate generation. In A. Beygelzimer, Y. Dauphin, P. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, 2021. URL <https://openreview.net/forum?id=Arn2E4IRjEB>.
- [12] Yoshua Bengio, Tristan Deleu, Edward J. Hu, Salem Lahlou, Mo Tiwari, and Emmanuel Bengio. Gflownet foundations, 2021.
- [13] David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.
- [14] John Jumper, Richard Evans, Alexander Pritzel, Tim Green, Michael Figurnov, Olaf Ronneberger, Kathryn Tunyasuvunakool, Russ Bates, Augustin Žídek, Anna Potapenko, et al. Highly accurate protein structure prediction with alphafold. *Nature*, 596(7873):583–589, 2021.
- [15] Armen Der Kiureghian and Ove Ditlevsen. Aleatory or epistemic? does it matter? *Structural Safety*, 31(2):105–112, 2009. ISSN 0167-4730. doi: <https://doi.org/10.1016/j.strusafe.2008.06.020>. Risk Acceptance and Risk Communication.
- [16] Shreyas J Honrao, Xin Yang, Balachandran Radhakrishnan, Shigemasa Kuwata, Hideyuki Komatsu, Atsushi Ohma, Maarten Sierhuis, and John W Lawson. Discovery of novel li sse and anode coatings using interpretable machine learning and high-throughput multi-property screening. *Scientific Reports*, 11(1):1–14, 2021.
- [17] Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, Nan Rosemary Ke, Nal Kalchbrenner, Anirudh Goyal, and Yoshua Bengio. Toward causal representation learning. *Proceedings of the IEEE*, 109(5):612–634, 2021.
- [18] Christophe Andrieu, Nando De Freitas, Arnaud Doucet, and Michael I Jordan. An introduction to mcmc for machine learning. *Machine learning*, 50(1):5–43, 2003.
- [19] Glenn M Torrie and John P Valleau. Nonphysical sampling distributions in monte carlo free-energy estimation: Umbrella sampling. *Journal of Computational Physics*, 23(2):187–199, 1977.
- [20] David J Earl and Michael W Deem. Parallel tempering: Theory, applications, and new perspectives. *Physical Chemistry Chemical Physics*, 7(23):3910–3916, 2005.
- [21] Alexandros Beskos, Frank J Pinski, Jesús María Sanz-Serna, and Andrew M Stuart. Hybrid monte carlo on hilbert spaces. *Stochastic Processes and their Applications*, 121(10):2201–2230, 2011.
- [22] David M Blei, Alp Kucukelbir, and Jon D McAuliffe. Variational inference: A review for statisticians. *Journal of the American statistical Association*, 112(518):859–877, 2017.
- [23] Tom Minka et al. Divergence measures and message passing. Technical report, Technical report, Microsoft Research, 2005.
- [24] Richard Eric Turner and Maneesh Sahani. *Two problems with variational expectation maximisation for time series models*, page 104–124. Cambridge University Press, 2011. doi: 10.1017/CBO9780511984679.006.

- [25] Nikolay Malkin, Salem Lahlou, Tristan Deleu, Xu Ji, Edward Hu, Katie Everett, Dinghuai Zhang, and Yoshua Bengio. Gflownets and variational inference. In *International Conference on Learning Representations (ICLR)*, 2023.
- [26] Valerii Vadimovich Fedorov. *Theory of optimal experiments*. Elsevier, 1972.
- [27] Anthony Curtis Atkinson and Alexander N Donev. *Optimum experimental designs*, volume 5. Clarendon Press, 1992.
- [28] Burr Settles. Active learning. *Synthesis lectures on artificial intelligence and machine learning*, 6 (1):1–114, 2012.
- [29] Kathryn Chaloner and Isabella Verdinelli. Bayesian experimental design: A review. *Statistical Science*, pages 273–304, 1995.
- [30] Dennis V Lindley. On a measure of the information provided by an experiment. *The Annals of Mathematical Statistics*, 27(4):986–1005, 1956.
- [31] Jay I Myung, Daniel R Cavagnaro, and Mark A Pitt. A tutorial on adaptive design optimization. *Journal of mathematical psychology*, 57(3-4):53–67, 2013.
- [32] Tom Rainforth, Rob Cornish, Hongseok Yang, Andrew Warrington, and Frank Wood. On nesting monte carlo estimators. In *International Conference on Machine Learning*, pages 4267–4276. PMLR, 2018.
- [33] Adam Foster, Martin Jankowiak, Elias Bingham, Paul Horsfall, Yee Whye Teh, Thomas Rainforth, and Noah Goodman. Variational bayesian optimal experimental design. *Advances in Neural Information Processing Systems*, 32, 2019.
- [34] Steven Kleinegesse and Michael U Gutmann. Efficient bayesian experimental design for implicit models. In *The 22nd International Conference on Artificial Intelligence and Statistics*, pages 476–485. PMLR, 2019.
- [35] Steven Kleinegesse and Michael U Gutmann. Bayesian experimental design for implicit models by mutual information neural estimation. In *International Conference on Machine Learning*, pages 5316–5326. PMLR, 2020.
- [36] Frank Heinrich, Paul A Kienzle, David P Hoogerheide, and Mathias Lösche. Information gain from isotopic contrast variation in neutron reflectometry on protein–membrane complex structures. *Journal of applied crystallography*, 53(3):800–810, 2020.
- [37] Antony Overstall and James McGree. Bayesian design of experiments for intractable likelihood models using coupled auxiliary models and multivariate emulation. *Bayesian Analysis*, 15(1): 103–131, 2020.
- [38] Christopher C Drovandi, James M McGree, and Anthony N Pettitt. Sequential monte carlo for bayesian sequentially designed experiments for discrete data. *Computational Statistics & Data Analysis*, 57(1):320–335, 2013.
- [39] Adam Foster, Martin Jankowiak, Matthew O’Meara, Yee Whye Teh, and Tom Rainforth. A unified stochastic gradient approach to designing bayesian-optimal experiments. In *International Conference on Artificial Intelligence and Statistics*, pages 2959–2969. PMLR, 2020.
- [40] Adam Foster, Desi R Ivanova, Ilyas Malik, and Tom Rainforth. Deep adaptive design: Amortizing sequential bayesian experimental design. In *International Conference on Machine Learning*, pages 3384–3395. PMLR, 2021.
- [41] Desi R Ivanova, Adam Foster, Steven Kleinegesse, Michael U Gutmann, and Thomas Rainforth. Implicit deep adaptive design: policy-based experimental design without likelihoods. *Advances in Neural Information Processing Systems*, 34:25785–25798, 2021.

- [42] Tom Blau, Edwin V Bonilla, Iadine Chades, and Amir Dezfouli. Optimizing sequential experimental design with deep reinforcement learning. In *International Conference on Machine Learning*, pages 2107–2128. PMLR, 2022.
- [43] Reiner Horst, Panos M Pardalos, and Nguyen Van Thoai. *Introduction to global optimization*. Springer Science & Business Media, 2000.
- [44] Jonas Mockus, Vytautas Tiesis, and Antanas Zilinskas. The application of bayesian methods for seeking the extremum. *Towards global optimization*, 2(117-129):2, 1978.
- [45] Donald R Jones, Matthias Schonlau, and William J Welch. Efficient global optimization of expensive black-box functions. *Journal of Global optimization*, 13(4):455–492, 1998.
- [46] Roman Garnett. *Bayesian Optimization*. Cambridge University Press, 2022. in preparation.
- [47] Javier Gonzalez, Joseph Longworth, David C James, and Neil D Lawrence. Bayesian optimization for synthetic gene design. *arXiv preprint arXiv:1505.01627*, 2015.
- [48] Ryan-Rhys Griffiths and José Miguel Hernández-Lobato. Constrained bayesian optimization for automatic chemical design using variational autoencoders. *Chemical science*, 11(2):577–586, 2020.
- [49] Henry B Moss and Ryan-Rhys Griffiths. Gaussian process molecule property prediction with flowmo. *arXiv preprint arXiv:2010.01118*, 2020.
- [50] Benjamin J Shields, Jason Stevens, Jun Li, Marvin Parasram, Farhan Damani, Jesus I Martinez Alvarado, Jacob M Janey, Ryan P Adams, and Abigail G Doyle. Bayesian reaction optimization as a tool for chemical synthesis. *Nature*, 590(7844):89–96, 2021.
- [51] C.E. Rasmussen and C.K.I. Williams. *Gaussian Processes for Machine Learning*. Adaptive Computation and Machine Learning series. MIT Press, 2005. ISBN 9780262182539. URL <https://books.google.ca/books?id=GhoSngEACAAJ>.
- [52] Maximilian Balandat, Brian Karrer, Daniel Jiang, Samuel Daulton, Ben Letham, Andrew G Wilson, and Eytan Bakshy. Botorch: a framework for efficient monte-carlo bayesian optimization. *Advances in neural information processing systems*, 33:21524–21538, 2020.
- [53] Jonas B Mockus and Linas J Mockus. Bayesian approach to global optimization and application to multiobjective and constrained problems. *Journal of optimization theory and applications*, 70(1):157–172, 1991.
- [54] Niranjan Srinivas, Andreas Krause, Sham Kakade, and Matthias Seeger. Gaussian process optimization in the bandit setting: no regret and experimental design. In *Proceedings of the 27th International Conference on International Conference on Machine Learning*, pages 1015–1022, 2010.
- [55] William R Thompson. On the likelihood that one unknown probability exceeds another in view of the evidence of two samples. *Biometrika*, 25(3-4):285–294, 1933.
- [56] Sattar Vakili, Henry Moss, Artem Artemev, Vincent Dutordoir, and Victor Picheny. Scalable thompson sampling using sparse gaussian process models. *Advances in Neural Information Processing Systems*, 34:5631–5643, 2021.
- [57] Philipp Hennig and Christian J Schuler. Entropy search for information-efficient global optimization. *Journal of Machine Learning Research*, 13(6), 2012.
- [58] José Miguel Hernández-Lobato, Matthew W Hoffman, and Zoubin Ghahramani. Predictive entropy search for efficient global optimization of black-box functions. *Advances in neural information processing systems*, 27, 2014.
- [59] Matthew W Hoffman and Zoubin Ghahramani. Output-space predictive entropy search for flexible global optimization. In *NIPS workshop on Bayesian Optimization*, pages 1–5, 2015.

- [60] Zi Wang and Stefanie Jegelka. Max-value entropy search for efficient bayesian optimization. In *International Conference on Machine Learning*, pages 3627–3635. PMLR, 2017.
- [61] Henry B Moss, David S Leslie, Javier Gonzalez, and Paul Rayson. Gibbon: General-purpose information-based bayesian optimisation. *Journal of Machine Learning Research*, 22(235):1–49, 2021.
- [62] Javier González, Zhenwen Dai, Philipp Hennig, and Neil Lawrence. Batch bayesian optimization via local penalization. In *Artificial intelligence and statistics*, pages 648–657. PMLR, 2016.
- [63] Kirthivasan Kandasamy, Akshay Krishnamurthy, Jeff Schneider, and Barnabás Póczos. Parallelised bayesian optimisation via thompson sampling. In *International Conference on Artificial Intelligence and Statistics*, pages 133–142. PMLR, 2018.
- [64] Victor Picheny, David Ginsbourger, and Yann Richet. Noisy expected improvement and on-line computation time allocation for the optimization of simulators with tunable fidelity, 2010.
- [65] Kirthivasan Kandasamy, Gautam Dasarathy, Jeff Schneider, and Barnabás Póczos. Multi-fidelity bayesian optimisation with continuous approximations. In *International Conference on Machine Learning*, pages 1799–1808. PMLR, 2017.
- [66] Shion Takeno, Hitoshi Fukuoka, Yuhki Tsukada, Toshiyuki Koyama, Motoki Shiga, Ichiro Takeuchi, and Masayuki Karasuyama. Multi-fidelity bayesian optimization with max-value entropy search and its parallelization. In *International Conference on Machine Learning*, pages 9334–9345. PMLR, 2020.
- [67] Syrine Belakaria, Aryan Deshwal, and Janardhan Rao Doppa. Max-value entropy search for multi-objective bayesian optimization. *Advances in Neural Information Processing Systems*, 32, 2019.
- [68] Samuel Daulton, David Eriksson, Maximilian Balandat, and Eytan Bakshy. Multi-objective bayesian optimization over high-dimensional search spaces. In *Uncertainty in Artificial Intelligence*, pages 507–517. PMLR, 2022.
- [69] Maxim A Ziatdinov, Yongtao Liu, Anna N Morozovska, Eugene A Eliseev, Xiaohang Zhang, Ichiro Takeuchi, and Sergei V Kalinin. Hypothesis learning in automated experiment: application to combinatorial materials libraries. *Advanced Materials*, 34(20):2201345, 2022.
- [70] Austin McDannald, Matthias Frontzek, Andrei T Savici, Mathieu Doucet, Efrain E Rodriguez, Kate Meuse, Jessica Opsahl-Ong, Daniel Samarov, Ichiro Takeuchi, William Ratcliff, et al. On-the-fly autonomous control of neutron diffraction via physics-informed bayesian active learning. *Applied Physics Reviews*, 9(2):021408, 2022.
- [71] Henry Moss, David Leslie, Daniel Beck, Javier Gonzalez, and Paul Rayson. Boss: Bayesian optimization over string spaces. *Advances in neural information processing systems*, 33:15476–15486, 2020.
- [72] Kevin Swersky, Yulia Rubanova, David Dohan, and Kevin Murphy. Amortized bayesian optimization over discrete spaces. In *Conference on Uncertainty in Artificial Intelligence*, pages 769–778. PMLR, 2020.
- [73] Judea Pearl. *Probabilistic Reasoning in Intelligent Systems*. Morgan Kaufmann, 1988.
- [74] Peter Spirtes, Clark N Glymour, Richard Scheines, and David Heckerman. *Causation, Prediction, and Search*. MIT press, 2000.
- [75] David Maxwell Chickering. Optimal Structure Identification With Greedy Search. *Journal of Machine Learning Research*, 2002.
- [76] Xun Zheng, Bryon Aragam, Pradeep Ravikumar, and Eric P. Xing. DAGs with NO TEARS: Continuous Optimization for Structure Learning. In *Advances in Neural Information Processing Systems*, 2018.

- [77] Nan Rosemary Ke, Olexa Bilaniuk, Anirudh Goyal, Stefan Bauer, Hugo Larochelle, Bernhard Schölkopf, Michael C Mozer, Chris Pal, and Yoshua Bengio. Learning neural causal models from unknown interventions. *arXiv preprint*, 2019.
- [78] Philippe Brouillard, Sébastien Lachapelle, Alexandre Lacoste, Simon Lacoste-Julien, and Alexandre Drouin. Differentiable Causal Discovery from Interventional Data. *Advances in Neural Information Processing Systems*, 2020.
- [79] David Madigan, Jeremy York, and Denis Allard. Bayesian Graphical Models for Discrete Data. *International Statistical Review*, 1995.
- [80] Nir Friedman and Daphne Koller. Being Bayesian About Network Structure. A Bayesian Approach to Structure Discovery in Bayesian Networks. *Machine Learning*, 2003.
- [81] Paolo Giudici and Robert Castelo. Improving Markov chain Monte Carlo model search for data mining. *Machine learning*, 2003.
- [82] Teppo Niinimäki, Pekka Parviainen, and Mikko Koivisto. Structure Discovery in Bayesian Networks by Sampling Partial Orders. *The Journal of Machine Learning Research*, 2016.
- [83] Jussi Viinikka, Antti Hyttinen, Johan Pensar, and Mikko Koivisto. Towards Scalable Bayesian Learning of Causal DAGs. *Advances in Neural Information Processing Systems*, 2020.
- [84] Nir Friedman, Moises Goldszmidt, and Abraham Wyner. Data Analysis with Bayesian Networks: A Bootstrap Approach. *Proceedings of the Fifteenth conference on Uncertainty in Artificial Intelligence*, 1999.
- [85] Raj Agrawal, Chandler Squires, Karren Yang, Karthikeyan Shanmugam, and Caroline Uhler. Abcd-strategy: Budgeted experimental design for targeted causal structure discovery. In *The 22nd International Conference on Artificial Intelligence and Statistics*. PMLR, 2019.
- [86] Yashas Annadani, Jonas Rothfuss, Alexandre Lacoste, Nino Scherrer, Anirudh Goyal, Yoshua Bengio, and Stefan Bauer. Variational Causal Networks: Approximate Bayesian Inference over Causal Structures. *arXiv preprint*, 2021.
- [87] Chris Cundy, Aditya Grover, and Stefano Ermon. BCD Nets: Scalable Variational Approaches for Bayesian Causal Discovery. *Advances in Neural Information Processing Systems*, 2021.
- [88] Benjie Wang, Matthew R Wicker, and Marta Kwiatkowska. Tractable Uncertainty for Structure Learning. *International Conference on Machine Learning*, 2022.
- [89] Lars Lorch, Jonas Rothfuss, Bernhard Schölkopf, and Andreas Krause. DiBS: Differentiable Bayesian Structure Learning. *Advances in Neural Information Processing Systems*, 2021.
- [90] Lars Lorch, Scott Sussex, Jonas Rothfuss, Andreas Krause, and Bernhard Schölkopf. Amortized Inference for Causal Structure Learning. *Advances in Neural Information Processing Systems*, 2022.
- [91] W BUNTINE. Theory refinement on bayesian networks. In *Proc. 7th Conf. Uncertainty in Artificial Intelligence, 1991*, pages 52–60, 1991.
- [92] Simon Tong and Daphne Koller. Active learning for structure in Bayesian networks. *International Joint Conference on Artificial Intelligence*, 2001.
- [93] Kevin Murphy. Active Learning of Causal Bayes Net Structure, 2001.
- [94] Nino Scherrer, Olexa Bilaniuk, Yashas Annadani, Anirudh Goyal, Patrick Schwab, Bernhard Schölkopf, Michael C Mozer, Yoshua Bengio, Stefan Bauer, and Nan Rosemary Ke. Learning Neural Causal Models with Active Interventions. *arXiv preprint*, 2021.
- [95] Panagiotis Tigas, Yashas Annadani, Andrew Jesson, Bernhard Schölkopf, Yarin Gal, and Stefan Bauer. Interventions, Where and How? Experimental Design for Causal Models at Scale. *Neural Information Processing Systems*, 2022.

- [96] Christian Toth, Lars Lorch, Christian Knoll, Andreas Krause, Franz Pernkopf, Robert Peharz, and Julius von Kügelgen. Active Bayesian Causal Inference. *Neural Information Processing Systems*, 2022.
- [97] Christopher M Bishop et al. *Neural networks for pattern recognition*. Oxford university press, 1995.
- [98] Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in gflownets. *arXiv preprint arXiv:2201.13259*, 2022.
- [99] Kanika Madan, Jarrid Rector-Brooks, Maksym Korablyov, Emmanuel Bengio, Moksh Jain, Andrei Nica, Tom Bosc, Yoshua Bengio, and Nikolay Malkin. Learning gflownets from partial episodes for improved convergence and stability. *arXiv preprint arXiv:2209.12782*, 2022.
- [100] Yutong Xie, Chence Shi, Hao Zhou, Yuwei Yang, Weinan Zhang, Yong Yu, and Lei Li. {MARS}: Markov molecular sampling for multi-objective drug discovery. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=kHSu4ebxFXY>.
- [101] Moksh Jain, Emmanuel Bengio, Alex Hernandez-Garcia, Jarrid Rector-Brooks, Bonaventure FP Dossou, Chanakya Ajit Ekbote, Jie Fu, Tianyu Zhang, Michael Kilgour, Dinghuai Zhang, et al. Biological sequence design with gflownets. In *International Conference on Machine Learning*, pages 9786–9801. PMLR, 2022.
- [102] Diederik P. Kingma and Max Welling. Auto-encoding variational Bayes. *International Conference on Learning Representations (ICLR)*, 2014.
- [103] Danilo Jimenez Rezende, Shakir Mohamed, and Daan Wierstra. Stochastic backpropagation and approximate inference in deep generative models. *International Conference on Machine Learning (ICML)*, 2014.
- [104] Ian J Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron C Courville, and Yoshua Bengio. Generative adversarial nets. In *NIPS*, 2014.
- [105] Salem Lahlou, Tristan Deleu, Pablo Lemos, Dinghuai Zhang, Alexandra Volokhova, Alex Hernández-García, Léna Néhale Ezzine, Yoshua Bengio, and Nikolay Malkin. A theory of continuous generative flow networks, 2023. URL <https://arxiv.org/abs/2301.12594>.
- [106] Ling Pan, Nikolay Malkin, Dinghuai Zhang, and Yoshua Bengio. Better training of gflownets with local credit and incomplete trajectories, 2023. URL <https://arxiv.org/abs/2302.01687>.
- [107] Shuo Zhang, Yang Liu, and Lei Xie. Molecular mechanics-driven graph neural network with multiplex graph for molecular structures. *arXiv preprint arXiv:2011.07457*, 2020.
- [108] Nipavan Chiamvimonvat, Chin-Min Ho, Hsing-Ju Tsai, and Bruce D Hammock. The soluble epoxide hydrolase as a pharmaceutical target for hypertension. *Journal of cardiovascular pharmacology*, 50(3):225–237, 2007.
- [109] John D Imig and Bruce D Hammock. Soluble epoxide hydrolase as a therapeutic target for cardiovascular diseases. *Nature reviews Drug discovery*, 8(10):794–805, 2009.
- [110] Oleg Trott and Arthur J Olson. Autodock vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of computational chemistry*, 31(2):455–461, 2010.
- [111] John J Irwin and Brian K Shoichet. Zinc- a free database of commercially available compounds for virtual screening. *Journal of chemical information and modeling*, 45(1):177–182, 2005.
- [112] Andrei Cristian Nica, Moksh Jain, Emmanuel Bengio, Cheng-Hao Liu, Maksym Korablyov, Michael M. Bronstein, and Yoshua Bengio. Evaluating generalization in GFlownets for molecule design. In *ICLR2022 Machine Learning for Drug Discovery*, 2022. URL <https://openreview.net/forum?id=JFSaHKNZ35b>.

- [113] Moksh Jain, Sharath Chandra Raparthy, Alex Hernandez-Garcia, Jarrod Rector-Brooks, Yoshua Bengio, Santiago Miret, and Emmanuel Bengio. Multi-objective gflownets. *arXiv preprint arXiv:2210.12765*, 2022.
- [114] Matthias Ehrgott. *Multicriteria optimization*, volume 491. Springer Science & Business Media, 2005.
- [115] O’Neill UK government study. Antimicrobial resistance: Tackling a crisis for the health and wealth of nations, 2014.
- [116] Tristan Deleu, António Góis, Chris Chinenye Emezue, Mansi Rankawat, Simon Lacoste-Julien, Stefan Bauer, and Yoshua Bengio. Bayesian structure learning with generative flow networks. In *The 38th Conference on Uncertainty in Artificial Intelligence*, 2022.
- [117] David Heckerman, Dan Geiger, and David M Chickering. Learning bayesian networks: The combination of knowledge and statistical data. *Machine learning*, 1995.
- [118] Mizu Nishikawa-Toomey, Tristan Deleu, Jithendaraa Subramanian, Yoshua Bengio, and Laurent Charlin. Bayesian learning of causal structure and mechanisms with gflownets and variational bayes. *arXiv preprint arXiv:2211.02763*, 2022.
- [119] Jacob W Freimer, Oren Shaked, Sahin Naqvi, Nasa Sinnott-Armstrong, Arwa Kathiria, Christian M Garrido, Amy F Chen, Jessica T Cortez, William J Greenleaf, Jonathan K Pritchard, et al. Systematic discovery and perturbation of regulatory genes in human t cells reveals the architecture of immune networks. *Nature Genetics*, 54(8):1133–1144, 2022.
- [120] Antti Hyttinen, Frederick Eberhardt, and Patrik O Hoyer. Learning linear cyclic causal models with latent variables. *The Journal of Machine Learning Research*, 13(1):3387–3439, 2012.
- [121] Lars Lorch, Scott Sussex, Jonas Rothfuss, Andreas Krause, and Bernhard Schölkopf. Amortized inference for causal structure learning. *arXiv preprint arXiv:2205.12934*, 2022.
- [122] Muralikrishna G Sethuraman, Romain Lopez, Rahul Mohan, Faramarz Fekri, Tommaso Biancalani, and Jan-Christian Hütter. Nodags-flow: Nonlinear cyclic causal structure learning. *arXiv preprint arXiv:2301.01849*, 2023.
- [123] David Madigan, Adrian E Raftery, C Volinsky, and Jennifer Hoeting. Bayesian Model Averaging. In *Proceedings of the AAAI Workshop on Integrating Multiple Learned Models*, 1996.
- [124] Jennifer A Hoeting, David Madigan, Adrian E Raftery, and Chris T Volinsky. Bayesian model averaging: a tutorial (with comments by M. Clyde, David Draper and EI George, and a rejoinder by the authors. *Statistical science*, 1999.
- [125] Marta Garnelo, Dan Rosenbaum, Christopher Maddison, Tiago Ramalho, David Saxton, Murray Shanahan, Yee Whye Teh, Danilo Rezende, and SM Ali Eslami. Conditional neural processes. In *International Conference on Machine Learning*, pages 1704–1713. PMLR, 2018.
- [126] Daniel Eaton and Kevin Murphy. Bayesian structure learning using dynamic programming and MCMC. *Uncertainty in Artificial Intelligence*, 2007.
- [127] Sue Zheng, David Hayden, Jason Pacheco, and John W Fisher III. Sequential bayesian experimental design with variable cost structure. *Advances in Neural Information Processing Systems*, 33:4127–4137, 2020.
- [128] Dianbo Liu, Moksh Jain, Bonaventure Dossou, Qianli Shen, Salem Lahlou, Anirudh Goyal, Nikolay Malkin, Chris Emezue, Dinghuai Zhang, Nadhir Hassen, et al. Gflowout: Dropout with generative flow networks. *arXiv preprint arXiv:2210.12928*, 2022.