

分布式的 GFlowNets 与分位数流

Dinghuai Zhang*

Mila, University of Montreal

Ling Pan*

Hong Kong University of Science and Technology

Ricky T. Q. Chen

Meta AI, Fundamental AI Research

Aaron Courville

Mila, University of Montreal

Yoshua Bengio

Mila, University of Montreal

在 OpenReview 上审核: <https://openreview.net/forum?id=vFSsRYGpjW>

摘要

生成流网络 (GFlowNets) 是一种新型的概率采样器, 其中代理通过一系列决策步骤学习生成复杂组合结构的随机策略。最近, 在一些实用领域中成功应用了 GFlowNets, 这些领域的解决方案多样性至关重要, 而强化学习仅基于给定的奖励函数学习最优解, 并未能发现多样性和高质量的解决方案。然而, 当前的 GFlowNet 框架在适用性方面相对有限, 无法处理奖励函数中的随机性。在这项工作中, 我们采用了 GFlowNets 的分布范式, 将每个流函数转化为一个分布, 从而在训练过程中提供更丰富的学习信号。通过参数化每个边缘流的分位数函数, 我们提出的分位数匹配 GFlowNet 学习算法能够学习到风险敏感的策略, 这是处理具有风险不确定性的场景的关键组成部分。此外, 我们发现, 由于我们的增强训练算法, 分布方法在现有基准上的表现相较于先前的方法有了显著的改进, 即使在确定性奖励设置下也是如此。

1 引言

强化学习 (RL) (Sutton & Barto, 2005) 的成功在于能够训练出具备长期序列决策能力的智能体 (Mnih et al., 2015; Vinyals et al., 2019)。这些策略通常通过最大化奖励来寻找单一最优解。然而, 实践者也发现, 生成多样化的解决方案而非仅仅一个最优解在许多实际应用中有其价值, 比如 RL 中的探索 (Hazan et al., 2018; Zhang et al., 2022b), 药物发现 (Huang et al., 2016; Zhang et al., 2021; Jumper et al., 2021), 以及材料设计 (Zakeri & Syri, 2015; Zitnick et al., 2020)。一种有前景的方法是按奖励函数的比例采样 (Bengio et al., 2021a)。最近, GFlowNet (Bengio et al., 2021a;b) 被提出作为解决这一问题的新颖概率框架。受到 RL 的启发, GFlowNet 策略采取一系列决策步骤来。星号*表示同等贡献。联系人: Dinghuai Zhang <dinghuai.zhang@mila.quebec>。

生成复合对象 $\mathbf{x}$ ，其概率与回报成正比 $R(\mathbf{x})$ 。每条“流”中的粒子数量直观地表示了相应路径上的概率规模。参数化策略的使用使 GFlowNet 能够推广到未见过的状态和轨迹，这使得它比传统马尔可夫链蒙特卡洛 (MCMC) 方法 (Zhang et al., 2022c) 更具优势，后者已知存在模式混合问题 (Desjardins et al., 2010; Bengio et al., 2012)。凭借其独特的支持离线训练的能力，GFlowNet 已被证明优于变分推断方法 (Malkin et al., 2022b)。

然而，当前的 GFlowNet 框架只能从确定性的奖励预言机中学习，这一假设对于现实场景来说过于严格。现实环境通常具有随机性（例如，由于观测噪声），在这种情况下，需要进行不确定性建模 (Kendall & Gal, 2017; Guo 等, 2017; Teng 等, 2022)。在本研究中，我们提出了采用概率方法来建模流函数（见图 1），以应对这种随机性。类似于分布型强化学习 (Bellemare 等, 2017) 的方法，我们将每条边的流量视为一个随机变量，并对其分位数函数进行参数化。然后，我们使用分位数回归基于类似时间差分的流约束训练 GFlowNet 模型。所提出的 GFlowNet 学习算法称为分位数匹配 (QM)，能够匹配随机奖励函数。QM 还可以在用户提供的扭曲风险测度下输出风险敏感策略，使其行为更接近人类决策。该方法在训练过程中提供了更强的学习信号，这使得它即使在仅包含确定性环境的标准基准上也能超越现有的 GFlowNet 训练方法。我们的代码公开可用，地址为 <https://github.com/zdhNarsil/Distributional-GFlowNets>。




图 1: 分布式 GFlowNet 及其随机边流的示意图。

综上所述，本研究的主要贡献包括：

- 我们提出了分位数匹配 (QM)，这是一种新颖的分布型 GFlowNet 训练算法，用于处理随机奖励设置。
- 在提供的扭曲风险测度下，可以从 QM 获得风险敏感策略。
- 所提出的方法即使在确定性基准上也优于现有的 GFlowNet 方法。

2 预备知识

2.1 GFlowNets

生成流网络 (GFlowNets) 是一类概率模型，用于通过一系列决策步骤生成复合对象。随机策略被训练以在组合空间 $\mathcal{X}$ 中生成复杂对象 $\mathbf{x}$ ，其概率与给定的奖励函数成正比 $R(\mathbf{x})$ ，其中 $R: \mathcal{X} \rightarrow \mathbb{R}_+$ 。GFlowNets 的顺序性质基于这样一个事实，即其学习策略逐步修改一个部分构造的状态 $\mathbf{s} \in \mathcal{S} \supset \mathcal{X}$ ，并采取某些动作 $(\mathbf{s} \rightarrow \mathbf{s}') \in \mathcal{A} \subset \mathcal{S} \times \mathcal{S}$ 。具体来说，令 $G = (\mathcal{S}, \mathcal{A})$ 是一个有向无环图 (DAG)，GFlowNet 在一个 DAG 中顺序采样轨迹 $\tau = (\mathbf{s}_0 \rightarrow \mathbf{s}_1 \rightarrow \dots)$ ，使用前向策略 $P_F(\mathbf{s}_{t+1} | \mathbf{s}_t)$ 。这里的状态 $\mathbf{s}$ 和动作 $(\mathbf{s} \rightarrow \mathbf{s}')$ 分别是 GFlowNet 轨迹 DAG 中的顶点和边 G 。我们通常假设在这种 DAG 中，动作与未来状态之间的关系是一对一的对应关系。这与典型的强化学习设置不同（环境通常是随机的），更适合于内部动作，如注意力、思考、推理或回答问题或生成问题候选解决方案。我们说 $\mathbf{s}'$ 是 $\mathbf{s}$ 的孩子，而 $\mathbf{s}$ 是 $\mathbf{s}'$ 的父节点，如果 $(\mathbf{s} \rightarrow \mathbf{s}')$ 是边 G 的一部分。我们称状态 1 每个圆圈表示一个状态；右侧的同心圆表示分配了奖励的终端状态。 $\mathbf{s}_0 \rightarrow \mathbf{s}_1 \rightarrow \mathbf{s}_2$ 是从初始状态 $\mathbf{s}_0$ 开始并结束于终端状态 $\mathbf{s}_2$ 的完整轨迹。为了应对随机奖励，我们将每条边的流量表示为一个随机变量，用灰色的概率曲线图标表示。

没有子节点的终端状态。请注意，任何对象 $\mathbf{x} \in \mathcal{X}$ 都是终端状态。我们还定义了一个特殊的初始状态 $\mathbf{s}_0$ （它没有父节点），作为任何对象生成路径的第一个状态的抽象。

一条轨迹 $\tau = (\mathbf{s}_0 \rightarrow \mathbf{s}_1 \rightarrow \dots \mathbf{s}_n)$ 如果从初始状态开始，则它是完整的 $\mathbf{s}_0$ 并终止于终态 $\mathbf{s}_n \in \mathcal{X}$ 我们定义在所有完整轨迹集合上的轨迹流 $\mathcal{T}$ 为非负函数 $F: \mathcal{T} \rightarrow \mathbb{R}_+$ 称为流，因为 $F(\tau)$ 可以视为从初始状态沿轨迹流向终端状态的粒子数量 τ 类似于经典的网络流概念 (Ford & Fulkerson, 1956)。流函数是一个未归一化的测度 $\mathcal{T}$ 我们可以定义一个完整的轨迹上的分布 $P_F(\tau) = F(\tau)/Z$ 其中 $Z \in \mathbb{R}_+$ 是配分函数。流动是马尔可夫的，如果存在一个前向策略满足以下分解：

$$P_F(\tau = (\mathbf{s}_0 \rightarrow \dots \rightarrow \mathbf{s}_n)) = \prod_{t=0}^{n-1} P_F(\mathbf{s}_{t+1}|\mathbf{s}_t). \quad (1)$$

任何由前向策略产生的轨迹分布都满足马尔可夫性质。另一方面，Bengio 等人 (2021b) 展示了不太明显的事实，即任何马尔可夫轨迹分布都源自一个唯一的前向策略。

$P_T(\mathbf{x}) = \sum_{\tau \rightarrow \mathbf{x}} P_F(\tau)$ 我们使用 $P_F(\tau)$ 表示终止概率，即生成对象 $\mathbf{x}$ 的边缘似然，其中求和枚举所有在 $\mathbf{x}$ 处终止的轨迹。GFlowNets 考虑的学习问题是拟合流，使其能够按给定奖励函数的比例采样对象，*i.e.*, $P_T(\mathbf{x}) \propto R(\mathbf{x})$ 。这可以通过奖励匹配约束来表示：

$$R(\mathbf{x}) = \sum_{\tau=(\mathbf{s}_0 \rightarrow \dots \rightarrow \mathbf{s}_n), \mathbf{s}_n=\mathbf{x}} F(\tau). \quad (2)$$

很容易看出归一化因子应满足 $Z = \sum_{\mathbf{x} \in \mathcal{X}} R(\mathbf{x})$ 。然而，这种计算并不简单，因为它涉及到对一个指数级大的组合空间进行求和/枚举。因此，GFlowNets 提供了一种近似不可计算的方法，即给定一个未归一化的概率函数进行采样——类似于 MCMC 方法——以及边缘化——在最简单的场景下，估计配分函数 Z ，但可以扩展到估计联合分布中的通用边缘概率 (Bengio 等, 2021b)。

2.2 控制中的分布建模

分布式强化学习 (Bellemare 等, 2023) 是一种 RL 方法，它建模回报的分布而不是它们的期望值。从数学上讲，它考虑策略的贝尔曼方程 π 如下：

$$Z^\pi(\mathbf{x}, \mathbf{a}) \stackrel{d}{=} r(\mathbf{x}, \mathbf{a}) + \gamma Z^\pi(\mathbf{x}', \mathbf{a}'), \quad (3)$$

其中 $\stackrel{d}{=}$ 表示两个分布之间的相等性， $\gamma \in [0, 1]$ 是折扣因子， $\mathbf{x}, \mathbf{a}$ 是 RL 中的状态和动作， $(r(\mathbf{x}, \mathbf{a}), \mathbf{x}')$ 是与环境交互后的奖励和下一个状态， $\mathbf{a}'$ 是策略 π 在 $\mathbf{x}'$ 时选择的下一个动作，而 Z^π 表示 Q 函数值分布的随机变量。

分布强化学习背后的关键思想是，它允许代理表示其对未来可能获得的不同行动回报的不确定性。在传统的 RL 中，代理只知道在特定状态下采取特定行动的预期奖励，但它没有关于不同奖励可能性的任何信息。相比之下，分布强化学习方法估计整个回报分布，并利用它做出更加明智的决策。

3 形式化定义

3.1 GFlowNet 学习准则

流匹配算法。直接建模轨迹流函数在计算上效率不高，因为这需要学习一个具有高维输入（即轨迹）的函数。相反，利用马尔可夫性质，我们定义状态流和边流函数 $F(\mathbf{s}) = \sum_{\tau: (\dots \rightarrow \mathbf{s} \rightarrow \mathbf{s}' \rightarrow \dots)} F(\tau)$ 和 $F(\mathbf{s} \rightarrow \mathbf{s}') = \sum_{\tau: (\dots \rightarrow \mathbf{s} \rightarrow \mathbf{s}' \rightarrow \dots)} F(\tau)$ 。边流与从 $\mathbf{s}$ 到 $\mathbf{s}'$ 的 GFlowNet 采样的包含边转移的轨迹的边缘似然成正比。根据流粒子守恒定律，自然可 $\tau \ni \mathbf{s} \rightarrow \mathbf{s}'$ 以看到 GFlowNet 的流匹配约束

$$\sum_{\mathbf{s}': (\mathbf{s} \rightarrow \mathbf{s}') \in \mathcal{A}} F(\mathbf{s} \rightarrow \mathbf{s}') = \sum_{\mathbf{s}'': (\mathbf{s}' \rightarrow \mathbf{s}'') \in \mathcal{A}} F(\mathbf{s}' \rightarrow \mathbf{s}''), \quad (4)$$

对于任意 $\mathbf{s}' \in \mathcal{S}$ 。这表明对于每个顶点，流入量（左侧）等于流出量（右侧）。进一步地，两者都等于状态流 $F(\mathbf{s}')$ 。当 $\mathbf{s}'$ 是方程 4 中的终止状态时，这简化为前述奖励匹配的特殊情况。

利用现代机器学习模型的强大泛化能力，可以学习一个参数模型 $F_{\theta}(\mathbf{s}, \mathbf{s}')$ 来表示边流。GFlowNet 训练目标的一般思想是将类似方程 4 的约束转化为损失，当全局最小化这些损失时，会强制执行这些约束。为了近似满足流匹配约束（方程 4），参数 θ 可以通过最小化以下所有中间状态的流匹配（FM）目标来进行训练： $\mathbf{s}'$ ：

$$\mathcal{L}_{\text{FM}}(\mathbf{s}'; \theta) = \left[\frac{\sum_{(\mathbf{s} \rightarrow \mathbf{s}') \in \mathcal{A}} F_{\theta}(\mathbf{s}, \mathbf{s}')}{\sum_{(\mathbf{s}' \rightarrow \mathbf{s}'') \in \mathcal{A}} F_{\theta}(\mathbf{s}', \mathbf{s}'')} \right]^2. \quad (5)$$

实践中，模型通过来自某个具有完全支持的训练分布的轨迹进行训练 $\pi(\tau) \propto_{\tau \sim \pi(\tau)} \left[\sum_{\mathbf{s} \in \tau} \nabla_{\theta} \mathcal{L}_{\text{FM}}(\mathbf{s}; \theta) \right]$ ，其中 $\pi(\tau)$ 可能是由 GFlowNet 采样的轨迹分布（即 $P_F(\tau)$ ），这表示一种策略内训练，或者（用于策略外训练和更好的探索）是 $P_F(\tau)$ 的温度版本或 $P_F(\tau)$ 和均匀策略之间的混合。

轨迹平衡算法。在了解边缘流的情况下，相应的前向策略由

$$P_F(\mathbf{s}' | \mathbf{s}) = \frac{F(\mathbf{s} \rightarrow \mathbf{s}')}{F(\mathbf{s})} \propto F(\mathbf{s} \rightarrow \mathbf{s}'). \quad (6)$$

类似地，后向策略 $P_B(\mathbf{s} | \mathbf{s}')$ 定义为 $F(\mathbf{s} \rightarrow \mathbf{s}') / F(\mathbf{s}') \propto F(\mathbf{s} \rightarrow \mathbf{s}')$ ，即状态 $\mathbf{s}'$ 的父节点上的分布。后向策略在生成对象时不会直接被 GFlowNet 使用，但其益处可以在随后的学习范式中体现。

与方程 1 中的分解等价，完整的轨迹也可以分解为后向策略概率的乘积

$$P_B(\tau = (\mathbf{s}_0 \rightarrow \dots \rightarrow \mathbf{s}_n | \mathbf{s}_n = \mathbf{x})) = \prod_{t=0}^{n-1} P_B(\mathbf{s}_t | \mathbf{s}_{t+1}), \quad (7)$$

如 Bengio 等人 (2021b) 所示。为了在轨迹层面构建前向和后向模型之间的平衡，Malkin 等人 (2022a) 提出了以下轨迹平衡 (TB) 约束：

$$Z \prod_{t=0}^{n-1} P_F(\mathbf{s}_{t+1} | \mathbf{s}_t) = R(\mathbf{x}) \prod_{t=0}^{n-1} P_B(\mathbf{s}_t | \mathbf{s}_{t+1}), \quad (8)$$

其中 $(\mathbf{s}_0 \rightarrow \dots \rightarrow \mathbf{s}_n)$ 是一个完整的轨迹，并且 $\mathbf{s}_n = \mathbf{x}$ 。假设我们有一个参数化形式，包含估计的前向策略 θ 、后向策略 $P_F(\cdot | \mathbf{s}; \theta$ 以及可学习的全局部分 $P_B(\cdot | \mathbf{s}'; \theta$

标量 Z_θ 。然后我们可以将方程 8 转化为优化参数的 $\mathcal{L}_{\text{TB}}$ 目标：

$$\mathcal{L}_{\text{TB}}(\tau; \theta) = \left[\log \frac{Z_\theta \prod_{t=0}^{n-1} P_F(\mathbf{s}_{t+1} | \mathbf{s}_t; \theta)}{R(\mathbf{x}) \prod_{t=0}^{n-1} P_B(\mathbf{s}_t | \mathbf{s}_{t+1}; \theta)} \right]^2, \quad (9)$$

其中 $\tau = (\mathbf{s}_0 \rightarrow \dots \rightarrow \mathbf{s}_n = \mathbf{x})$ 。该模型随后通过随机梯度 $\mathbb{E}_{\tau \sim \pi(\tau)} [\nabla_\theta \mathcal{L}_{\text{TB}}(\tau; \theta)]$ 进行训练。轨迹平衡 (Malkin 等, 2022a) 是详细平衡 (Bengio 等, 2021b) 在轨迹层面上的扩展, 旨在改进信用分配, 但在标准基准测试中可能会导致较大的方差 (Madan 等, 2022)。TB 被归类为蒙特卡洛方法, 而其他 GFlowNet 目标 (例如流匹配、详细平衡和子轨迹平衡) 则是时间差分方法 (结合了蒙特卡洛和动态规划的优点)。

3.2 分位数流

对于具有确定性奖励函数的学习, GFlowNet 策略是随机的, 而边流函数根据方程 6 是确定性的。然而, 这种建模行为无法捕捉到具有随机奖励函数的环境中的潜在不确定性。请参见以下命题中的行为分析。

命题 1 (非正式表述)。假设对象 $\mathbf{x}$ 的奖励 $R(\mathbf{x})$ 是一个随机变量, 那么在给定足够大的容量和计算资源的情况下, 经过训练后获得的 GFlowNet 将生成概率与 $\mathbb{E} R \mathbf{x}$ 成比例的对象。

证明详见附录 B.1。在这项工作中, 我们提出以概率方式处理流函数的建模: 我们将状态和边流视为概率分布, 而不是标量值。沿用 Bellemare 等人 (2017) 的符号, 我们使用 $Z(\mathbf{s})$ 和 $Z(\mathbf{s} \rightarrow \mathbf{s}')$ 表示状态/边流值的随机变量。尽管如此, 流匹配的边流化性质仍然成立, 但在分布层面:

$$Z(\mathbf{s}') \stackrel{d}{=} \sum_{(\mathbf{s} \rightarrow \mathbf{s}') \in \mathcal{A}} Z(\mathbf{s} \rightarrow \mathbf{s}') \stackrel{d}{=} \sum_{(\mathbf{s}' \rightarrow \mathbf{s}'') \in \mathcal{A}} Z(\mathbf{s}' \rightarrow \mathbf{s}''), \quad (10)$$

其中 $\stackrel{d}{=}$ 表示两个随机变量分布之间的等价关系。因此, 我们的目标是将流匹配约束扩展到分布层面。

在不同的标量随机变量参数化方法中, 建模其分位数函数 (Müller, 1997) 是有效的。分位数函数 $Q_Z(\beta) : [0, 1] \rightarrow \mathbb{R}$ 是累积分布函数 (CDF) 的广义逆函数, 其中 Z 是被表示的随机变量, 而 β 是在 $[0, 1]$ 区间内的标量。为了避免歧义, 我们也用 β -分位数来表示 Z 的分布的 Z_β 。为了简化起见, 我们假设所有分位数函数在本研究中都是连续的。分位数函数完全刻画了一个分布。例如, 期望可以通过均匀求积分位数函数 $\mathbb{E}[Z] = \int_0^1 Q_Z(\beta) d\beta$ 来计算。

如果我们使用神经网络来参数化边流分位数 (类似于流匹配参数化), 我们能否表示边际状态流的分布? 幸运的是, Dhaene 等人 (2006) 提出的以下分位数混合命题给出了肯定的答案。

命题 2 (分位数可加性)。对于任意一组 M 维随机变量 $\{Z^m\}_{m=1}^M$ 它们通过共同的随机性共享相同的随机源 $\beta \in [0, 1]$ 的方式 $Z^m = Q^m(\beta), \forall m$, 其中 $Q^m(\cdot)$ 是该分布的分位数函数 m 对于第- m 随机变量, 存在一个随机变量 Z^0 , 使得 $Z^0 \stackrel{d}{=} \sum_{m=1}^M Z^m$

其分位数函数满足 $Q^0(\cdot) = \sum_{m=1}^M Q^m(\cdot)$ 。证明详见附录 B.2。

备注 3。量函数的这种加性性质对于高效实现分布匹配算法至关重要。另一方面, 其他分布表示方法可能需要大量的计算来处理一系列分布的求和问题。例如, 对于离散分类表示 (Bellemare 等, 2017; Barth-Maroon 等, 2018), 两个分布之间的求和需要 M 卷积操作, 这将耗费大量时间。 M -

Algorithm 1 GFlowNet quantile matching (QM) algorithm

Require: GFlowNet quantile flow $Z_\beta(\mathbf{s} \rightarrow \mathbf{s}'; \boldsymbol{\theta})$ with parameters $\boldsymbol{\theta}$, target reward oracle.

repeat

 Sample trajectory τ with the forward policy $P_F(\cdot|\cdot)$ estimated by Equation 13;

$\Delta\boldsymbol{\theta} \leftarrow \sum_{\mathbf{s} \in \tau} \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{QM}}(\mathbf{s}; \boldsymbol{\theta})$ (as per Equation 12);

 Update $\boldsymbol{\theta}$ with some optimizer;

until some convergence condition

分位数匹配算法。我们建议将边流的 β 分位数建模为 $\mathbf{s} \rightarrow \mathbf{s}'$ 作为 $Z_\beta^{\log}(\mathbf{s} \rightarrow \mathbf{s}'; \boldsymbol{\theta})$ ，其中网络参数 $\boldsymbol{\theta}$ 在对数尺度上用于提高学习稳定性。然后根据 Bengio 等人 (2021a) 的流匹配损失 (方程 5) 构造类似时间差分的误差 δ ，但跨越所有分位数：

$$\delta^{\beta, \tilde{\beta}}(\mathbf{s}'; \boldsymbol{\theta}) = \log \sum_{(\mathbf{s}' \rightarrow \mathbf{s}'') \in \mathcal{A}} \exp Z_{\tilde{\beta}}^{\log}(\mathbf{s}' \rightarrow \mathbf{s}''; \boldsymbol{\theta}) - \log \sum_{(\mathbf{s} \rightarrow \mathbf{s}') \in \mathcal{A}} \exp Z_\beta^{\log}(\mathbf{s} \rightarrow \mathbf{s}'; \boldsymbol{\theta}), \quad (11)$$

其中 $\beta, \tilde{\beta} \in [0, 1]$ 且 $\boldsymbol{\theta}$ 是模型参数。由于对数和指数都是单调操作，因此不会影响分位数，此计算仍然有效。请注意，我们的目标是学习分位数而不是平均值，因此我们求助于分位数回归 (Koenker, 2005) 来最小化 pinball 误差 $\rho_\beta(\delta) \triangleq |\beta - \mathbb{1}\{\delta < 0\}| \ell(\delta)$ ，其中 $\ell(\cdot)$ 通常是 ℓ_1 范数或其平滑替代品。总之，我们提出了以下分位数匹配 (QM) 目标用于 GFlowNet 学习：

$$\mathcal{L}_{\text{QM}}(\mathbf{s}; \boldsymbol{\theta}) = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^{\tilde{N}} \rho_{\beta_i}(\delta^{\beta_i, \tilde{\beta}_j}(\mathbf{s}; \boldsymbol{\theta})), \quad (12)$$

其中 $\beta_i, \tilde{\beta}_i$ 是从均匀分布 $\mathcal{U}[0, 1]$ ， $\forall i, i$ 独立同分布采样的。这里 $N, \tilde{N}$ 是两个整数值超参数。对 $\tilde{\beta}_i$ 的平均使分布匹配有效；参见附录 B.3 中的分析。在推理阶段（即生成采样），前向策略通过数值积分估计：

$$P_F(\mathbf{s}'|\mathbf{s}) = \frac{\mathbb{E}[Z(\mathbf{s} \rightarrow \mathbf{s}')] }{\sum_{(\mathbf{s} \rightarrow \tilde{\mathbf{s}}) \in \mathcal{A}} \mathbb{E}[Z(\mathbf{s} \rightarrow \tilde{\mathbf{s}})]} \propto \mathbb{E}[Z(\mathbf{s} \rightarrow \mathbf{s}')] \approx \frac{1}{N} \sum_{i=1}^N \exp \left(Z_{\beta_i}^{\log}(\mathbf{s} \rightarrow \mathbf{s}'; \boldsymbol{\theta}) \right), \quad (13)$$

其中 $\beta_i \sim \mathcal{U}[0, 1], \forall i$ 。我们在算法 1 中总结了算法细节。值得注意的是，由于 Jensen 不等式，这种近似值小于其真实值。所提出的 GFlowNet 学习算法独立于特定的分位数函数建模方法。在文献中，已经研究了显式 (Dabney 等人, 2017) 和隐式 (Dabney 等人, 2018) 方法。实践中，我们选择隐式分位数网络 (IQN) 实现，因为它具有轻量级特性和强大的表现力。我们在附录 C.1 中讨论实现细节和效率，并进行消融实验。

4 风险敏感流

现实世界充满了不确定性。为了应对随机性，金融数学家使用各种风险测度来评估需要预留的资产数量。具体来说，风险测度是从随机变量到实数的映射，具有某些性质 (Artzner 等人, 1999)。普遍采用的风险测度如均值或中位数并不能很好地反映风险/随机性信息。在这项工作中，我们考虑一类特殊的风险测度，即扭曲风险测度 (Hardy, 2002; Balbás 等人, 2009)。

$$\mathbb{E}^g[Z] = \int_0^1 Q_Z(g(\beta)) d\beta, \quad (14)$$

其中 $g: [0, 1] \rightarrow [0, 1]$ 是一个单调扭曲函数²。不同的扭曲函数表示不同的风险敏感效果。在这项工作中，我们关注以下几类扭曲类别。第一个累积概率加权 (CPW) 函数 (Tversky & Kahneman, 1992; Gonzalez & Wu, 1999) 如下所示

$$g(\beta; \eta) = \frac{\beta^\eta}{(\beta^\eta + (1 - \beta)^\eta)^{1/\eta}}, \quad (15)$$

其中 $\eta > 0$ 是一个标量参数，控制其行为表现。然后，我们考虑 Wang (2000) 提出的另一类扭曲风险测度，如下所示，

$$g(\beta; \eta) = \Phi(\Phi^{-1}(\beta) + \eta), \quad (16)$$

其中 $\Phi(\cdot)$ 是标准正态分布的累积分布函数。当 $\eta > 0$ 时，这个扭曲函数是凸的，从而产生寻求风险的行为，反之当 $\eta < 0$ 时则产生厌恶风险的行为。最后但同样重要的是，我们考虑条件价值-at-风险 (CVaR) (Rockafellar 等人, 2000) : $g(\beta; \eta) = \eta\beta$ ，其中 $\eta \in [0, 1]$ 。CVaR 衡量最低 $100 \times \eta$ 百分比数据的平均值，适用于风险厌恶型建模。

给定一个扭曲风险测度 g ，方程 13 现在可以写作 $P_F^g(\mathbf{s}'|\mathbf{s}) \propto \mathbb{E}^g[Z(\mathbf{s} \rightarrow \mathbf{s}')]$ ，这可以通过方程 17 进行估计，其中 $\beta_i \sim \mathcal{U}[0, 1], \forall i$ 。

$$\frac{1}{N} \sum_{i=1}^N \exp\left(Z_{g(\beta_i)}^{\log}(\mathbf{s} \rightarrow \mathbf{s}'; \boldsymbol{\theta})\right). \quad (17)$$

规避风险的分位数匹配。我们现在考虑一个源自超网格领域的风险敏感任务。风险超网格是 Bengio 等人 (2021a) 研究的超网格任务的一个变种 (更详细的描述见第 5.1 节)，其目标是在避免风险区域的同时发现多样化的模式。我们展示了一个二维超网格，其大小为 $\ln a$ D 维地图大小为 H 。

图 2 为例，其中黄色表示高回报区域 (即非风险模式)，绿色表示具有随机性的区域 (即风险模式)。进入风险区域会以很小的概率获得非常低的回报。除此之外，风险模式与正常模式的行为相同 (见图 2 左上和右下模式)。Deming 等人 (1945 年)、Arrow (1958 年)、Hellwig (2004 年) 的研究表明，在决策过程中人类倾向于保守。因此，在此任务中，本文提出将 QM 算法与避险扭曲测度相结合，以避免进入风险区域同时保持性能。




图 2: 一个有风险的超网格环境。

我们将风险敏感的分位数匹配与其风险中性的变体和标准的 GFlowNet (流匹配) 进行了比较。通过违规率量化它们的性能，即进入风险区域的概率比率，并考虑任务的不同维度，包括小规模和大规模。我们还根据每种方法在训练过程中发现的标准 (非风险) 模式数量来评估每种方法。如图 3(a-b) 所示，CVaR(0.1) 和 Wang(-0.75) 导致较小的违规率；CVaR(0.1) 表现最为保守，实现了最小的违规率水平，因为它仅关注最低 10% 分位数的数据。需要注意的是，CPW(0.71) 的表现与风险中性的 QM 和 FM (即基线) 相似，这符合其扭曲函数既不凹也不凸的理论。这表明风险敏感的流能够有效地捕捉环境中的不确定性，并防止代理进入危险区域。图 3(c-d) 展示了每种算法发现的非风险模式的数量，它们都能发现所有模式以实现具有竞争力的性能。结果验证了风险规避的 CVaR 分位数匹配算法能够在避免进入风险区域的同时发现高质量和多样化的解决方案。更多细节请参见 C.2 节。

在某些文献中，使用了一种不同的但等价的记法： $\int^1$

$Q_Z(\beta) dg(\beta) = \int_0^1 Q_Z(g^{-1}(\beta)) d\beta.$




图 3: 在具有不同风险敏感策略的随机超网格问题上的实验结果。上图: CVaR(0.1) 和 Wang(-0.75) 诱导出风险规避策略, 从而实现较小的违规率。下图: 风险敏感方法在捕获非风险模式的数量方面与其他基线方法表现相似, 表明所提出的保守方法不会影响标准性能。




图 4: 在不同规模级别的超网格任务上的实验结果。上图: 学习到的分布密度与真实目标密度之间的 ℓ_1 误差。下图: 训练过程中发现的模式数量。所提出的分位数匹配算法在不同的超网格尺度下, 在两个定量度量指标下均取得了最佳结果。

5 基准实验

所提出的方法已被证明能够捕捉随机环境中的不确定性。另一方面, 在本节中, 我们将评估其在确定性结构生成基准上的性能。这些任务由于其指数级大的组合搜索空间而具有挑战性, 因此需要高效的探索和良好的泛化能力。在本研究中, 所有实验结果均在 NVIDIA Tesla V100 Volta GPU 上运行, 并通过 4 个随机种子进行平均。

5.1 超网格

我们研究了 Bengio 等人 (2021a) 提出的超网格任务。状态空间是一个维度为 D 的超网格立方体, 大小为 $H \times \dots \times H$, 其中 H 是网格的大小, 代理需要在一个长的时间范围内进行规划并从给定的稀疏奖励信号中学习。代理从一个角落开始, 并需要通过每次步骤在其中一个坐标上增加 1 来进行导航。对于每个状态, 还提供了一个特殊的终止动作。当代理决定停止时, 它会根据方程 18 获得奖励。奖励

function is defined by

$$R(\mathbf{x}) = R_0 + R_1 \prod_{d=1}^D \mathbb{I} \left[\left| \frac{\mathbf{x}_d}{H-1} - 0.5 \right| \in (0.25, 0.5] \right] + R_2 \prod_{d=1}^D \mathbb{I} \left[\left| \frac{\mathbf{x}_d}{H-1} - 0.5 \right| \in (0.3, 0.4) \right], \quad (18)$$

其中 $\mathbb{I}$ 是指示函数， $R_0 = 0.001, R_1 = 0.5, R_2 = 2$ 。从公式中可以看出，每个任务有 2^D 种模式，这里的模式指的是能够获得最大奖励值的一个局部区域（可能包含一个或多个状态）。环境设计用于测试 GFlowNet 发现多样化模式和从过去经验中泛化的能力。我们使用学习到的概率密度函数与真实概率密度函数之间的 ℓ_1 误差作为评估度量。此外，在训练阶段发现的模式数量也被用来量化探索能力。在这个任务中，每个任务有 2^D 种模式。我们将 QM 算法与之前的 FM 和 TB 方法进行比较，同时还将其非 GFlowNet 基线方法如 MCMC 纳入比较。

图 4 展示了 QM 在不同规模任务上的有效性，从 $8 \times 8 \times 8$ 到 $20 \times 20 \times 20 \times 20$ 。我们注意到，在小规模问题（ $8 \times 8 \times 8$ ）上，TB 在误差较低方面优于 FM，但在较大规模的任务上不如 FM 和 QM。关于模式发现的速度，QM 是在最短时间内找到所有不同模式的最快算法。我们在该问题中也测试了 PPO (Schulman 等, 2017)，但发现它在我们的规模级别上几乎不收敛，因此没有绘制其曲线。我们在图 9 中还考察了在极稀疏场景下的探索能力。详情见 C.2 节。为了展示相对于分布式强化学习基线的优势，我们在超网络上进行了分布式强化学习方法与 QM 之间的实验，结果见图 8。

5.2 序列生成

在本任务中，我们的目标是以自回归的方式生成二进制比特序列。序列长度固定为 120，每个标记的词汇表简单到只有二进制集合，使得空间为 $\{0, 1\}^{120}$ 。奖励函数定义为负距离到预定义多模态序列集的指数，其定义可以在附录中看到。每个动作向现有部分序列添加一个标记。因此，这是一个自回归生成建模，每个 GFlowNet 状态仅对应一条生成路径。我们将提出的分位数匹配算法与之前的 GFlowNet 算法（TB 和 FM）进行比较，同时包括基于强化的方法（A2C (Mnih 等, 2016)，软演员-评论家 (Haarnoja 等, 2018)）和基于马尔可夫链蒙特卡洛的方法（Xie 等, 2021）。在这个问题设置中，枚举所有可能的状态以计算学习密度函数与目标密度函数之间的误差是不可行的，因此我们仅报告发现的模式数量。我们通过编辑距离小于 28 来定义找到一个模式。图 5 展示了每种方法在探索步骤中找到的模式数量，表明 QM 在发现多样化模式方面实现了最佳样本效率。我们从 Malkin 等 (2022a) 获取基线结果。其他信息被移至第 C.3 节，包括图 10 中顶级候选者的平均奖励。




图 5：在序列生成任务的整个训练过程中，每种算法达到的模式数量。QM 在样本效率方面优于其他基线。

5.3 分子优化

然后，我们研究了一个更现实的分子合成设置。本任务的目标是合成具有所需化学性质的多样化分子（图 6(a)）。每个状态表示一个分子图结构，动作空间是由连接树模型指定的构建块词汇表 (Kumar 等, 2012; Jin 等, 2018)。我们遵循实验设置，包括奖励规范和情节




图 6: 分子合成实验。(a) GFlowNet 策略的说明。该图改编自 Pan 等 (2022)。(b) 算法捕获的模式数量。(c) Tanimoto 相似度 (越低越好)。(d) 前 100 个分子的平均奖励。

Bengio 等 (2021a) 中的约束条件。我们将提出的算法与 FM、TB 以及基于马尔可夫链蒙特卡洛的方法 MARS 和基于强化学习的方法 PPO 进行比较。

在现实的药物设计行业中,许多其他性质,如类药性 (Bickerton 等, 2012 年),可合成性 (Shi 等, 2020 年)或毒性等都应该被考虑在内。为此,一种有前景的方法应该能够找到多样化的候选物供后续选择。因此,我们通过奖励大于 7.5 时发现的模式数量来量化搜索多样化分子的能力 (详见附录 C.4),并在图 6(b) 中展示了结果,其中我们的 QM 方法明显优于其他基线。进一步地,我们还通过测量图 6(c) 中的 Tanimoto 相似度来评估多样性,这表明 QM 能够找到最多多样化的分子。图 6(d) 显示了排名前 100 的候选物的平均奖励,证明了所提出的 QM 方法能够找到高质量的药物结构。

6 Related Work

GFlowNets. 自 Bengio 等人 (2021a;b) 提出以来,该领域见证了关于 **GFlowNets** 不同方面的大量工作。Malkin 等人 (2022b); Zimmermann 等人 (2022) 分析了与变分方法的关系,在 on-policy 情况下期望梯度一致 ($\pi = P_F$),并表明 **GFlowNets** 在 off-policy 训练样本上优于变分推断; Pan 等人 (2022; 2023b) 开发了框架,使 **GFlowNets** 能够利用中间信号来提高信用分配效率; Jain 等人 (2022b) 研究了使用 **GFlowNets** 进行多目标生成的可能性; Pan 等人 (2023c) 将世界建模引入 **GFlowNets**; Pan 等人 (2023a) 提出了一个用于训练 **GFlowNets** 的无监督学习方法; Ma 等人 (2023) 研究了如何利用同构测试来减少 GFlowNet 训练中的流偏差。从概率建模的角度来看, Zhang 等人 (2022c) 联合学习了一个基于能量的模型和一个 GFlowNet 用于生成建模,并在一系列离散数据建模任务中验证了其有效性。它还提出了一种来回提议的方法,被 Kim 等人 (2023) 用于局部搜索。进一步地, Zhang 等人 (2022a) 分析了不同生成模型的建模,并从理论上指出许多模型实际上是 **GFlowNets** 的特例;这项工作还建立了扩散建模与 **GFlowNets** 之间的联系,这一联系被连续采样工作 (Lahlou 等人, 2023; Zhang 等人, 2023b) 所采纳。与上述努力不同,本工作旨在解决具有随机奖励函数的学习 GFlowNet 的开放问题。GFlowNet 在许多对象生成应用领域也表现出潜在的前景。Jain 等人 (2022a) 将其应用于生物序列设计; Deleu 等人 (2022); Nishikawa-Toomey 等人 (2022) 利用它进行因果结构学习; Liu 等人 (2022) 利用它来采样结构化的子网络模块以提高预测鲁棒性; Zhang 等人 (2023a;c) 利用它解决组合优化问题; Zhou 等人 (2023) 学习了一个用于系统发育推断问题的 GFlowNet。

分布建模。 整个分布包含的信息远超第一阶矩 (Yang 等人, 2013; Imani & White, 2018)。因此,从分布中学习可以带来更丰富的信息信号的好处。有趣的是,类似的机制也被发现在人类中存在

大脑 (Dabney 等, 2020)。具体来说, 在分布型强化学习 (Bellemare 等, 2023) 文献中, 人们最小化分布型贝尔曼误差以实现方程 3。提出了许多不同的实现方法: 分类 DQN (Bellemare 等, 2017), 分位数回归 DQN (Dabney 等, 2017), 隐式分位数网络基础的 DQN (Dabney 等, 2018; 杨等, 2019), 以及期望值回归基础的 DQN (Rowland 等, 2019)。分布型建模方法可以与不同类型的方法结合使用, 如 Q 学习 (上述工作), 演员-评论家 (马等, 2020) 或策略梯度 (巴特-马龙等, 2018)。广受认可的 Rainbow 算法 (Hessel 等, 2017) 也采用了分类 DQN 作为重要组成部分。在基于模型的强化学习方法中, 人们发现分布型建模能够提升性能 (Hafner 等, 2023)。在生成型建模领域, Ostrovski 等 (2018) 将 IQN 的思想整合到了自回归模型中。

7 结论与讨论

综上所述, 我们希望强调的是, 本文提出的分位数匹配方法并非直接

结合特征匹配和分布型强化学习, 而是具有相当的技术新颖性。

问题的重要性。我们探讨了 GFlowNets 中的一个重要问题——发现当前 GFlowNets 的公式存在局限性, 即它们无法很好地处理随机奖励, 这在许多实际任务中普遍存在, 并可能限制其应用。因此, 它未能考虑与行动相关的风险, 这对于实际应用 (如医疗保健) 非常重要。算法的新颖性。与强化学习中的贝尔曼方程不同, 我们在流一致性约束中需要考虑状态 $\mathbf{s}$ 的所有可能父节点和子节点, 直接采用 Bellemare 等人 (2017) 的技术并不能实现高效的计算, 具体细节见备注 3。我们提出了基于分位数匹配的方法, 并通过命题 2 进行了合理化, 实现了灵活的计算。分位数匹配为何突出? 除了隐式分位数建模带来的风险敏感性优势外, 令人惊喜的是, 所提出的 QM 方法在确定性奖励设置下也超越了以往的方法。我们假设以下理由解释为什么 QM 能够给 GFlowNet 训练带来益处。(a) 更具信息量的学习信号, 有助于更好的泛化。作为更复杂的模型, 额外的非线性分位数流鼓励捕捉除预期值之外的更多信息, 起到了辅助任务的正则化作用 (Lyle 等, 2019)。在实践中, 由于 GFlowNet 学习者难以看到所有可能的轨迹, 泛化问题变得尤为重要。因此, 从少量训练样本中提取尽可能多的有用泛化信息至关重要。(b) 正则化效果。之前观察到 GFlowNets 可能会过拟合过去的轨迹, 从而对某些流量值产生估计偏差 (Bengio 等, 2021a)。然而, 由于我们维护了一个流量分布, 这有助于传播有用信息并改善流量值的预测, 从而正则化这种高估问题, 有利于优化过程 (Imani & White, 2018)。(c) 拟不确定性。在实际奖励存在不确定性的情况下 (例如, 它们是从数据中估算出来的), 传播奖励分布是有意义的。然而, 即使在确定性环境中, 由于状态表示的复杂性, 两个不同的状态可能会被网络错误地表示为相同的状态。这导致了环境中的拟不确定性, 类似于部分可观测性 (McCallum & Ballard, 1996), 这导致所谓的控制中的状态别名。

致谢

作者感谢 Marc Bellemare、Moksh Jain 和 Emmanuel Bengio。此外, Dinghuai Zhang 感谢 Sagrada Familia 提醒他这个世界上存在美。

参考文献

Kenneth J. Arrow. Essays in the theory of risk-bearing. 1958.

Philippe Artzner, Freddy Delbaen, Jean-Marc Eber, and David Heath. Coherent measures of risk. *Mathematical Finance*, 9, 1999.

- Alejandro Balbás, José Garrido, and Silvia Mayoral. Properties of distortion risk measures. *Methodology and Computing in Applied Probability*, 11:385–399, 2009.
- Gabriel Barth-Maron, Matthew W. Hoffman, David Budden, Will Dabney, Dan Horgan, TB Dhruva, Alistair Muldal, Nicolas Manfred Otto Heess, and Timothy P. Lillicrap. Distributed distributional deterministic policy gradients. *ArXiv*, abs/1804.08617, 2018.
- Marc G. Bellemare, Will Dabney, and Rémi Munos. A distributional perspective on reinforcement learning. In *International Conference on Machine Learning*, 2017.
- Marc G. Bellemare, Will Dabney, and Mark Rowland. *Distributional Reinforcement Learning*. MIT Press, 2023. <http://www.distributional-rl.org>.
- Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow network based generative models for non-iterative diverse candidate generation. *Neural Information Processing Systems (NeurIPS)*, 2021a.
- Yoshua Bengio, Grégoire Mesnil, Yann Dauphin, and Salah Rifai. Better mixing via deep representations. In *International Conference on Machine Learning*, 2012.
- Yoshua Bengio, Tristan Deleu, Edward J. Hu, Salem Lahlou, Mo Tiwari, and Emmanuel Bengio. GFlowNet foundations. *arXiv preprint 2111.09266*, 2021b.
- G. Richard J. Bickerton, Gaia Valeria Paolini, Jérémy Besnard, Sorel Muresan, and Andrew L. Hopkins. Quantifying the chemical beauty of drugs. *Nature chemistry*, 4 2:90–8, 2012.
- Will Dabney, Mark Rowland, Marc G. Bellemare, and Rémi Munos. Distributional reinforcement learning with quantile regression. In *AAAI Conference on Artificial Intelligence*, 2017.
- Will Dabney, Georg Ostrovski, David Silver, and Rémi Munos. Implicit quantile networks for distributional reinforcement learning. *ArXiv*, abs/1806.06923, 2018.
- Will Dabney, Zeb Kurth-Nelson, Naoshige Uchida, Clara Kwon Starkweather, Demis Hassabis, Rémi Munos, and Matthew M. Botvinick. A distributional code for value in dopamine-based reinforcement learning. *Nature*, 577:671–675, 2020.
- Tristan Deleu, Ant’onio G’ois, Chris C. Emezue, Mansi Rankawat, Simon Lacoste-Julien, Stefan Bauer, and Yoshua Bengio. Bayesian structure learning with generative flow networks. *Uncertainty in Artificial Intelligence (UAI)*, 2022.
- William Edwards Deming, John von Neumann, and Oscar Morgenstern. Theory of games and economic behavior. *Journal of the American Statistical Association*, 40:263, 1945.
- Guillaume Desjardins, Aaron C. Courville, Yoshua Bengio, Pascal Vincent, and Olivier Delalleau. Tempered markov chain monte carlo for training of restricted boltzmann machines. In *International Conference on Artificial Intelligence and Statistics*, 2010.
- Jan Dhaene, Steven Vanduffel, Marc J. Goovaerts, Rob Kaas, Q. Tang, and David Vyncke. Risk measures and comonotonicity: A review. *Stochastic Models*, 22:573 – 606, 2006. URL <https://api.semanticscholar.org/CorpusID:11340721>.
- Lester Randolph Ford and Delbert Ray Fulkerson. Maximal flow through a network. *Canadian Journal of Mathematics*, 8:399 – 404, 1956.
- Justin Gilmer, Samuel S. Schoenholz, Patrick F. Riley, Oriol Vinyals, and George E. Dahl. Neural message passing for quantum chemistry. *ArXiv*, abs/1704.01212, 2017.
- Richard Gonzalez and George Wu. On the shape of the probability weighting function. *Cognitive Psychology*, 38:129–166, 1999.

- Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. *ArXiv*, abs/1706.04599, 2017.
- Tuomas Haarnoja, Aurick Zhou, P. Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International Conference on Machine Learning*, 2018.
- Danijar Hafner, J. Pasukonis, Jimmy Ba, and Timothy P. Lillicrap. Mastering diverse domains through world models. *ArXiv*, abs/2301.04104, 2023.
- Mary R. Hardy. Distortion risk measures : Coherence and stochastic dominance. 2002.
- Elad Hazan, Sham M. Kakade, Karan Singh, and Abby Van Soest. Provably efficient maximum entropy exploration. *ArXiv*, abs/1812.02690, 2018.
- Martin F. Hellwig. Risk aversion in the small and in the large. *Max Planck Institute for Research on Collective Goods Research Paper Series*, 2004.
- Matteo Hessel, Joseph Modayil, H. V. Hasselt, Tom Schaul, Georg Ostrovski, Will Dabney, Dan Horgan, Bilal Piot, Mohammad Gheshlaghi Azar, and David Silver. Rainbow: Combining improvements in deep reinforcement learning. *ArXiv*, abs/1710.02298, 2017.
- Po-Ssu Huang, Scott E. Boyken, and David Baker. The coming of age of de novo protein design. *Nature*, 537: 320–327, 2016.
- Ehsan Imani and Martha White. Improving regression performance with distributional losses. In *International Conference on Machine Learning*, 2018.
- Moksh Jain, Emmanuel Bengio, Alex García, Jarrid Rector-Brooks, Bonaventure F. P. Dossou, Chanakya Ajit Ekbote, Jie Fu, Tianyu Zhang, Micheal Kilgour, Dinghuai Zhang, Lena Simine, Payel Das, and Yoshua Bengio. Biological sequence design with GFlowNets. *International Conference on Machine Learning (ICML)*, 2022a.
- Moksh Jain, Sharath Chandra Raparthy, Alex Hernández-García, Jarrid Rector-Brooks, Yoshua Bengio, Santiago Miret, and Emmanuel Bengio. Multi-objective gflownets. *ArXiv*, abs/2210.12765, 2022b.
- Wengong Jin, Regina Barzilay, and T. Jaakkola. Junction tree variational autoencoder for molecular graph generation. *ArXiv*, abs/1802.04364, 2018.
- John M. Jumper, Richard Evans, Alexander Pritzel, Tim Green, Michael Figurnov, Olaf Ronneberger, Kathryn Tunyasuvunakool, Russ Bates, Augustin Zidek, Anna Potapenko, Alex Bridgland, Clemens Meyer, Simon A A Kohl, Andy Ballard, Andrew Cowie, Bernardino Romera-Paredes, Stanislav Nikolov, Rishub Jain, Jonas Adler, Trevor Back, Stig Petersen, David A. Reiman, Ellen Clancy, Michal Zielinski, Martin Steinegger, Michalina Pacholska, Tamas Berghammer, Sebastian Bodenstein, David Silver, Oriol Vinyals, Andrew W. Senior, Koray Kavukcuoglu, Pushmeet Kohli, and Demis Hassabis. Highly accurate protein structure prediction with alphafold. *Nature*, 596:583 – 589, 2021.
- Juha Karvanen. Estimation of quantile mixtures via l-moments and trimmed l-moments. *Comput. Stat. Data Anal.*, 51:947–959, 2006.
- Alex Kendall and Yarin Gal. What uncertainties do we need in bayesian deep learning for computer vision? In *NIPS*, 2017.
- Minsu Kim, Taeyoung Yun, Emmanuel Bengio, Dinghuai Zhang, Yoshua Bengio, Sungsoo Ahn, and Jinkyoo Park. Local search gflownets, 2023.
- Roger W. Koenker. Quantile regression. 2005.
- A. Kumar, Arnout R. D. Voet, and K Y J Zhang. Fragment based drug design: from experimental to computational approaches. *Current medicinal chemistry*, 19 30:5128–47, 2012.

- Salem Lahlou, Tristan Deleu, Pablo Lemos, Dinghuai Zhang, Alexandra Volokhova, Alex Hernández-García, Léna Néhale Ezzine, Yoshua Bengio, and Nikolay Malkin. A theory of continuous generative flow networks. In *International Conference on Machine Learning*, pp. 18269–18300. PMLR, 2023.
- Dianbo Liu, Moksh Jain, Bonaventure F. P. Dossou, Qianli Shen, Salem Lahlou, Anirudh Goyal, Nikolay Malkin, Chris C. Emezue, Dinghuai Zhang, Nadhir Hassen, Xu Ji, Kenji Kawaguchi, and Yoshua Bengio. Gflowout: Dropout with generative flow networks. *ArXiv*, abs/2210.12928, 2022.
- Clare Lyle, Pablo Samuel Castro, and Marc G. Bellemare. A comparative analysis of expected and distributional reinforcement learning. *ArXiv*, abs/1901.11084, 2019.
- Jiangyan Ma, Emmanuel Bengio, Yoshua Bengio, and Dinghuai Zhang. Baking symmetry into gflownets, 2023.
- Xiaoteng Ma, Li Xia, Zhengyuan Zhou, Jun Yang, and Qianchuan Zhao. Dsac: Distributional soft actor critic for risk-sensitive reinforcement learning. *arXiv: Learning*, 2020.
- Kanika Madan, Jarrid Rector-Brooks, Maksym Korablyov, Emmanuel Bengio, Moksh Jain, Andrei Cristian Nica, Tom Bosc, Yoshua Bengio, and Nikolay Malkin. Learning gflownets from partial episodes for improved convergence and stability. *ArXiv*, abs/2209.12782, 2022.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in GFlowNets. *arXiv preprint 2201.13259*, 2022a.
- Nikolay Malkin, Salem Lahlou, Tristan Deleu, Xu Ji, Edward J. Hu, Katie Elizabeth Everett, Dinghuai Zhang, and Yoshua Bengio. Gflownets and variational inference. *ArXiv*, abs/2210.00580, 2022b.
- Andrew McCallum and Dana H. Ballard. Reinforcement learning with selective perception and hidden state. 1996.
- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin A. Riedmiller, Andreas Fidjeland, Georg Ostrovski, Stig Petersen, Charlie Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharmashan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015.
- Volodymyr Mnih, Adrià Puigdomènech Badia, Mehdi Mirza, Alex Graves, Timothy P. Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. *ArXiv*, abs/1602.01783, 2016.
- Alfred Müller. Integral probability metrics and their generating classes of functions. *Advances in Applied Probability*, 29:429 – 443, 1997.
- Mizu Nishikawa-Toomey, Tristan Deleu, Jithendaraa Subramanian, Yoshua Bengio, and Laurent Charlin. Bayesian learning of causal structure and mechanisms with gflownets and variational bayes. *ArXiv*, abs/2211.02763, 2022.
- Georg Ostrovski, Will Dabney, and Rémi Munos. Autoregressive quantile networks for generative modeling. *ArXiv*, abs/1806.05575, 2018.
- L. Pan, Dinghuai Zhang, Aaron C. Courville, Longbo Huang, and Yoshua Bengio. Generative augmented flow networks. *ArXiv*, abs/2210.03308, 2022.
- Ling Pan, Moksh Jain, Kanika Madan, and Yoshua Bengio. Pre-training and fine-tuning generative flow networks. *ArXiv*, abs/2310.03419, 2023a. URL <https://api.semanticscholar.org/CorpusID:263671952>.
- Ling Pan, Nikolay Malkin, Dinghuai Zhang, and Yoshua Bengio. Better training of gflownets with local credit and incomplete trajectories. *arXiv preprint arXiv:2302.01687*, 2023b.
- Ling Pan, Dinghuai Zhang, Moksh Jain, Longbo Huang, and Yoshua Bengio. Stochastic generative flow networks. *arXiv preprint arXiv:2302.09465*, 2023c.

- Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. *Advances in neural information processing systems*, 32, 2019.
- R Tyrrell Rockafellar, Stanislav Uryasev, et al. Optimization of conditional value-at-risk. *Journal of risk*, 2: 21–42, 2000.
- Mark Rowland, Robert Dadashi, Saurabh Kumar, Rémi Munos, Marc G. Bellemare, and Will Dabney. Statistics and samples in distributional reinforcement learning. In *International Conference on Machine Learning*, 2019.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *ArXiv*, abs/1707.06347, 2017.
- Chence Shi, Minkai Xu, Hongyu Guo, Ming Zhang, and Jian Tang. A graph to graphs framework for retrosynthesis prediction. *ArXiv*, abs/2003.12725, 2020.
- Richard S. Sutton and Andrew G. Barto. Reinforcement learning: An introduction. *IEEE Transactions on Neural Networks*, 16:285–286, 2005.
- Matthew Tancik, Pratul P. Srinivasan, Ben Mildenhall, Sara Fridovich-Keil, Nithin Raghavan, Utkarsh Singhal, Ravi Ramamoorthi, Jonathan T. Barron, and Ren Ng. Fourier features let networks learn high frequency functions in low dimensional domains. *ArXiv*, abs/2006.10739, 2020.
- Jiaye Teng, Chuan Wen, Dinghuai Zhang, Yoshua Bengio, Yang Gao, and Yang Yuan. Predictive inference with feature conformal prediction. *ArXiv*, abs/2210.00173, 2022.
- Amos Tversky and Daniel Kahneman. Advances in prospect theory: Cumulative representation of uncertainty. *Journal of Risk and Uncertainty*, 5:297–323, 1992.
- Oriol Vinyals, Igor Babuschkin, Wojciech M. Czarnecki, Michaël Mathieu, Andrew Dudzik, Junyoung Chung, David H. Choi, Richard Powell, Timo Ewalds, Petko Georgiev, Junhyuk Oh, Dan Horgan, Manuel Kroiss, Ivo Danihelka, Aja Huang, L. Sifre, Trevor Cai, John P. Agapiou, Max Jaderberg, Alexander Sasha Vezhnevets, Rémi Leblond, Tobias Pohlen, Valentin Dalibard, David Budden, Yury Sulsky, James Molloy, Tom Le Paine, Caglar Gulcehre, Ziyun Wang, Tobias Pfaff, Yuhuai Wu, Roman Ring, Dani Yogatama, Dario Wünsch, Katrina McKinney, Oliver Smith, Tom Schaul, Timothy P. Lillicrap, Koray Kavukcuoglu, Demis Hassabis, Chris Apps, and David Silver. Grandmaster level in starcraft ii using multi-agent reinforcement learning. *Nature*, pp. 1–5, 2019.
- Shaun S. Wang. A class of distortion operators for pricing financial and insurance risks. *Journal of Risk and Insurance*, 67:15, 2000.
- Yutong Xie, Chence Shi, Hao Zhou, Yuwei Yang, Weinan Zhang, Yong Yu, and Lei Li. Mars: Markov molecular sampling for multi-objective drug discovery. *ArXiv*, abs/2103.10432, 2021.
- Derek Yang, Li Zhao, Zichuan Lin, Tao Qin, Jiang Bian, and Tie-Yan Liu. Fully parameterized quantile function for distributional reinforcement learning. In *Neural Information Processing Systems*, 2019.
- Jiyan Yang, Xiangrui Meng, and Michael W. Mahoney. Quantile regression for large-scale applications. *SIAM J. Sci. Comput.*, 36, 2013.
- Behnam Zakeri and Sanna Syri. Electrical energy storage systems: A comparative life cycle cost analysis. *Renewable and sustainable energy reviews*, 42:569–596, 2015.
- David Zhang, Corrado Rainone, Markus Peschl, and Roberto Bondesan. Robust scheduling with GFlowNets. *International Conference on Learning Representations (ICLR)*, 2023a. To appear.
- Dinghuai Zhang, Jie Fu, Yoshua Bengio, and Aaron C. Courville. Unifying likelihood-free inference with black-box optimization and beyond. In *International Conference on Learning Representations*, 2021.

- Dinghuai Zhang, Ricky T. Q. Chen, Nikolay Malkin, and Yoshua Bengio. Unifying generative models with gflownets. *ArXiv*, abs/2209.02606, 2022a.
- Dinghuai Zhang, Aaron C. Courville, Yoshua Bengio, Qinqing Zheng, Amy Zhang, and Ricky T. Q. Chen. Latent state marginalization as a low-cost approach for improving exploration. *ArXiv*, abs/2210.00999, 2022b.
- Dinghuai Zhang, Nikolay Malkin, Z. Liu, Alexandra Volokhova, Aaron C. Courville, and Yoshua Bengio. Generative flow networks for discrete probabilistic modeling. *International Conference on Machine Learning (ICML)*, 2022c.
- Dinghuai Zhang, Ricky T. Q. Chen, Cheng-Hao Liu, Aaron C. Courville, and Yoshua Bengio. Diffusion generative flow samplers: Improving learning signals through partial trajectory optimization. *ArXiv*, abs/2310.02679, 2023b.
- Dinghuai Zhang, Hanjun Dai, Nikolay Malkin, Aaron Courville, Yoshua Bengio, and Ling Pan. Let the flows tell: Solving graph combinatorial optimization problems with gflownets. *arXiv preprint arXiv:2305.17010*, 2023c.
- Mingyang Zhou, Zichao Yan, Elliot Layne, Nikolay Malkin, Dinghuai Zhang, Moksh Jain, Mathieu Blanchette, and Yoshua Bengio. Phylogfn: Phylogenetic inference with generative flow networks. *arXiv preprint arXiv:2310.08774*, 2023.
- Heiko Zimmermann, Fredrik Lindsten, J.-W. van de Meent, and Christian A. Naesseth. A variational perspective on generative flow networks. *ArXiv*, abs/2210.07992, 2022.
- C Lawrence Zitnick, Lowik Chanussot, Abhishek Das, Siddharth Goyal, Javier Heras-Domingo, Caleb Ho, Weihua Hu, Thibaut Lavril, Aini Palizhati, Morgane Riviere, et al. An introduction to electrocatalyst design using machine learning for renewable energy storage. *arXiv preprint arXiv:2010.09435*, 2020.

符号说明

Symbol	Description
$\mathcal{S}$	state space
$\mathcal{X}$	object (terminal state) space, subset of $\mathcal{S}$
$\mathcal{A}$	action / transition space (edges $\mathbf{s} \rightarrow \mathbf{s}'$)
$\mathcal{G}$	directed acyclic graph $(\mathcal{S}, \mathcal{A})$
$\mathcal{T}$	set of complete trajectories
$\mathbf{s}$	state in $\mathcal{S}$
$\mathbf{s}_0$	initial state, element of $\mathcal{S}$
$\mathbf{x}$	terminal state in $\mathcal{X}$
τ	trajectory in $\mathcal{T}$
$F : \mathcal{T} \rightarrow \mathbb{R}$	Markovian flow
$F : \mathcal{S} \rightarrow \mathbb{R}$	state flow
$F : \mathcal{A} \rightarrow \mathbb{R}$	edge flow
P_F	forward policy (distribution over children)
P_B	backward policy (distribution over parents)
Z	scalar, equal to $\sum_{\tau \in \mathcal{T}} F(\tau)$ for a Markovian flow

附录 B 方法论的缺失细节

B.1 命题 1

证明。对于流匹配算法，实践中奖励匹配训练损失是在对数尺度上：

$$\left(\log \sum_{(\mathbf{s} \rightarrow \mathbf{x}) \in \mathcal{A}} F(\mathbf{s} \rightarrow \mathbf{x}) - \log R(\mathbf{x}) \right)^2.$$

通过假设具有足够大的容量和足够的计算资源，我们认为获得的 GFlowNet 可以按照给定奖励的比例正确采样。由于奖励函数是随机的，并且假设我们拥有无限的计算资源和神经网络容量，平方损失的性质将使流入量的对数拟合奖励的期望对数 $\mathbb{E}[\log R(\mathbf{x})]$ （这是最小化问题中的最优解）。这使得优化具有与最小化 $\left(\log \sum_{(\mathbf{s} \rightarrow \mathbf{x}) \in \mathcal{A}} F(\mathbf{s} \rightarrow \mathbf{x}) - \mathbb{E}[\log R(\mathbf{x})] \right)^2$ 相同的最优解。根据流匹配算法的性质（Bengio 等，2021a，命题 3），GFlowNet 将学会按照由 $\exp$ 定义的奖励比例进行采样（ $\mathbb{E}[\log R(\mathbf{x})]$ ）。对于轨迹平衡算法，由于损失可以表示为

$$\left(\log \frac{P_F(\tau)}{P_B(\tau|\mathbf{x})} - \log R(\mathbf{x}) \right)^2,$$

通过相同的推理，我们知道它等价于最小化 $\left(\log \frac{P_F(\tau)}{P_B(\tau|\mathbf{x})} - \mathbb{E}[\log R(\mathbf{x})] \right)^2$ 。According 性质（Malkin 等人，2022a，命题 1），GFlowNet 将学会按照由 $\exp(\mathbb{E}[\log R(\mathbf{x})])$ 定义的奖励概率进行采样。同样的推理也可以应用于细致平衡算法（Bengio 等人，2021b）。

□

B.2 命题 2

我们首先重新表述该命题如下。

命题。 对于任意一组 $M+1$ 分位数函数 $\{Q_m(\cdot)\}_{m=0}^M$ 满足存在一组随机变量 $\{Z_m\}_{m=1}^M$ 满足 $Q_m(\cdot)$ 是 $Z_m, \forall m$ 的分位数函数，并且 $Z_0 \stackrel{d}{=} \sum_{m=1}^M Z_m$ 。

$$Q_0(\cdot) = \sum_{m=1}^M Q_m(\cdot),$$

以下证明受到 Karvanen (2006) 的启发。

证明。对于 $\forall z \in \mathbb{R}$,

$$\begin{aligned} \mathbb{P}\left(\sum_{m=1}^M Z_m \leq z\right) &= \mathbb{P}\left(\left\{\beta \in [0, 1] : \sum_{m=1}^M Z_m(\beta) \leq z\right\}\right) = \mathbb{P}\left(\left\{\beta \in [0, 1] : \sum_{m=1}^M Q_m(\beta) \leq z\right\}\right) \\ &= \sup \left\{ \beta \in [0, 1] : z \geq \sum_{m=1}^M Q_m(\beta) \right\} = \inf \left\{ \beta \in [0, 1] : z \leq \sum_{m=1}^M Q_m(\beta) \right\} \\ &= \inf \{ \beta \in [0, 1] : z \leq Q_0(\beta) \} = \mathbb{P}(Z_0 \leq z). \end{aligned}$$

This indicates that $Z_0 \stackrel{d}{=} \sum_{m=1}^M Z_m$.

□

对于命题 2 中的陈述，鉴于本工作中假设所有分位数函数都是连续的，几个连续单调函数的和（ $\sum_{m=1}^M Q_m(\cdot)$ ）也是一个连续单调函数，因此可以作为随机变量的分位数函数。然后我们可以使用上述论点。

B.3 关于分位数回归目标

设 Z 是一个随机变量，我们希望得到其 β -分位数。为了实现这一目标，我们应该找到 x 来求解

$$\min_x \mathbb{E}_Z [\rho_\beta(Z - x)] \approx \frac{1}{\tilde{N}} \sum_{j=1}^{\tilde{N}} \rho_\beta(Z_{\tilde{\beta}_j} - x), \quad \tilde{\beta}_j \sim \mathcal{U}[0, 1],$$

其中 $Z_{\tilde{\beta}_j}$ 表示 Z 的 $\tilde{\beta}_j$ -分位数。请注意， β 与 $\{\tilde{\beta}_j\}_{j=1}^{\tilde{N}}$ 不重叠。

让我们来看方程 (根据上述分析) 将引导流入学习流出的 β_i 分位数。当我们对不同的 $\beta_i \sim \mathcal{U}[0, 1], i = 1, \dots, N$ 求和时，这有助于我们将流入（作为分布）与流出（作为分布）相匹配，因为具有相同分位数函数的两个分布是相同的分布。请注意， $\{\beta_i\}_{i=1}^N$ 与 $\{\tilde{\beta}_j\}_{j=1}^{\tilde{N}}$ 不重叠。

C 更多关于实验

C.1 分位数建模的详细信息和消融

本小节解释分位数函数的建模方法。对于显式建模，神经网络直接输出某个分布的 $i/M \times 100$ 百分比分位数， $1 < i < M$ 。这意味着神经网络的输出端应输出 M 维向量。相反，对于隐式建模，神经网络额外接收输入 $\beta \in [0, 1]$ ，并输出 β 分位数值（即标量输出）。后一种建模方式能够提供更大的灵活性，因为我们可以通过这种方式获得模型分布的任意分位数。两种建模方法均基于相同的分位数回归算法，详见第 3.2 节。对于隐式建模，我们使用傅里叶特征（Dabney 等，2018；Tancik 等，2020）来增强标量 β 输入： $\phi(\beta)_j = \text{ReLU}\left(\sum_{i=0}^{D_F} \cos(\pi i \beta) w_{ij} + b_j\right), j = 1, \dots, D_F$ ，其中 D_F 是傅里叶特征的维度，这是一个超参数。然后我们使用逐元素乘法将傅里叶特征与处理后的状态表示结合，用于后续处理；具体建模细节请参见以下各小节的不同任务。我们在图 7(b) 中比较了它们在 $16 \times 16 \times 16$ 超网格上的性能，其中 $M = 200$ 用于显式建模，而 $N = 8, 256$ 维的傅里叶特征用于隐式建模。隐式方法显示出更好的性能，因此我们在本工作的其他实验中都采用了这种方法。关于计算考虑，我们指出尽管隐式方法似乎需要更多的网络评估次数，但由于 PyTorch 中高效的批量网络推理实现 (Paszke 等，2019)，通过批量级操作并行多次调用隐式分位数网络，实际运行时间保持相似。

我们也进行了关于隐式分位数网络实现的消融实验。对于 Algorithm 1 中描述的 N 和 $\tilde{N}$ ，我们在具有 256 维傅里叶特征的 $16 \times 16 \times 16$ 超网格上尝试不同的值。图 7(c) 表明 QM 算法的性能对 N 的选择具有鲁棒性（为了简单起见，我们总是设置 $N = \tilde{N}$ ）。对于傅里叶特征的维度数量，我们进行了图 7(d) 所示的消融实验，仍然使用 $16 \times 16 \times 16$ 超网格和 $N = 8$ 。结果还显示 QM 对傅里叶特征维度的选择具有鲁棒性。

C.2 超网格

图 7(a) 展示了当 $D = 2, H = 8$ 时奖励格局的示意图。通过过去访问过的 200000 个状态来经验估计所学模型的概率密度函数。GFlowNet 使用三层 MLP 网络，隐藏层维度为 256，激活函数为 Leaky ReLU，并以 one-hot 状态表示作为输入。FM 使用一个 MLP 来建模边流。TB 使用一个 MLP 同时输出前向和后向策略的对数概率。QM 采用了与 FM 类似的三层 MLP 建模方式，即状态输入首先经过一层处理，然后与傅里叶特征进行逐元素乘法运算，再经过两层线性层。所有方法均通过 Adam 进行优化。关于超参数，我们没有进行大量调整：QM 使用的学习率与 FM 相同，均为 1×10^{-4} ；




图 7: 超网格图形。(a) 目标奖励函数的示意图, 针对一个 8×8 超网格, 其中颜色越深表示奖励越高。图改编自 Malkin 等人 (2022a)。(b) 隐式与显式建模分位数函数之间的消融实验; 隐式方法在样本效率上表现更优。(c) 关于分位数函数数量的消融实验 β 采样比例。(d) 关于使用的傅里叶特征数量的消融实验。




图 8: IQN 在不同尺度级别的超网格任务上的实验结果 (红色虚线对应 Quantile Matching 的最终结果)。第一行展示了经验误差 L_1 , 而第二行则说明了模式的数量。如图所示, 在收敛性和多样性方面, IQN 显著落后于分位数匹配。

此外, QM 使用了 $N = \tilde{N} = 8$ 和 256 维的傅里叶特征。其他基线方法如 TB、MCMC、PPO 使用了与 Malkin 等人 (2022a) 相同的配置。

风险超网格领域。我们将 $H = 8, D =$ 设置为 2 或 4, 分别对应小环境和大环境。图 2 展示了具有 $D = 2$ 的风险超网格示意图。当智能体到达风险区域 (位于网格的左下角和右上角, 对于 $D = 2$ 的情况, 以及对于 $D = 4$ 的情况对称分布) 时, 会触发低奖励 0.1, 概率为 30%, 而在其他情况下, 智能体会获得原始奖励 2.6 或 0.6。对于风险中立的智能体 (流匹配和分位数匹配), 它们可能会进入风险区域, 而风险规避的智能体应尽量避免进入这些区域。我们跟踪每种方法在训练过程中发现的模式数量, 并评估违规率。后者基于智能体在过去一段时间内进入风险区域的次数进行计算。




图 9: 具有极稀疏信号的超网格结果, 针对 3 种 GFlowNet 方法。我们发现 TB 很容易受到稀疏奖励设置的影响, 导致性能高度不稳定, 而 QM 在不同奖励景观水平上表现稳定。

样本。在风险超网格领域中的实验遵循上述部分所述的超参数设置。

极端稀疏信号下的探索。我们还研究了具有极稀疏学习信号的设置, 其中我们在方程 18 中将 R_0 设置为一个非常小的值 (即从 1×10^{-4} 到 1×10^{-9})。在此部分中, 我们使用一个具有 $H = 8$ 维度的网格。当 R_0 极其小时, 智能体很难获得任何学习信号, 因为超网格中的大部分区域奖励接近零 (尽管在模式附近有高奖励, 但在高维空间中模式所占面积很小)。我们的结果显示, 提出的 QM 方法对奖励景观稀疏性的变化更为鲁棒, 而 FM 和 TB 的探索能力容易受到稀疏奖励的影响。

C.3 序列生成

奖励定义为 $R(\mathbf{x}) = \max_{\mathbf{m} \in M} \exp\{-\text{dist}(\mathbf{x}, \mathbf{m})\}$, 其中 M 是一个预生成的序列集合, 距离是指 Levenshtein 距离。该集合通过随机组合符号构建而成。我们按照 $\{ '00000000', '11111111', '11110000', '00001111', '00111100' \}$ Malkin 等人 (2022a) 的生成协议重新生成目标序列集。我们将前向策略设置为均匀分布, 所有方法的探索概率均为 0.5% 。奖励指数超参数设置为 3。关于网络实现, 我们使用具有 3 个隐藏层和 8 个注意力头的变换器。在评估过程中, 我们在图 10(a) 中绘制了三种 GFlowNet 方法的前 100 个奖励曲线, 并附上了我们的实验结果。我们不使用 Malkin 等人 (2022a) 中 $\log$ 奖励与模型 $\log$ 似然之间的相关性, 因为发现数据集无法适当地覆盖各种模式, 这导致相关性有时甚至在初始化时就达到高点; 见图 10(b)。尽管最终奖励在所有三种方法之间相似, 但提出的 QM 在最短时间内达到平台期。

所有方法均使用 Adam 优化器进行优化, 训练步数为 50000, 小批量大小为 16。我们使用固定随机动作概率 0.005 。对于所有基线, 我们采用 Malkin 等人 (2022a) 的结果。在分位数匹配中, 我们使用两层多层感知机处理傅里叶特征 β , 然后计算其与变换器编码特征的逐元素乘积; 关于超参数, 我们使用相同的学习率 (5×10^{-4}) as FM, $N = \tilde{N} = 16$, 并采用 256 维的傅里叶特征。

C.4 分子综合

我们训练一个代理模型来预测可溶性环氧化物水解酶 (sEH) 蛋白的 4JNC 抑制剂的归一化负结合能量作为奖励。动作的数量范围在 100 到 2000 之间, 使得 $|\mathcal{X}| \approx 10^{16}$ 。关于神经网络架构的选择, 我们使用消息传递神经网络 (Gilmer 等人, 2017, MPNN) 用于所有模型。除了正文中的结果外, 我们还在图 10(c) 中展示了前 10 个奖励曲线。




图 10: (a) 序列生成任务的前 100 个平均奖励。(b) 序列生成任务中模型 log 似然与真实奖励 log 之间的相关性的不稳定性。(c) 分子合成任务的前 10 个平均奖励。

消息传递神经网络 (Gilmer 等人, 2017, MPNN) 用于所有模型。除了正文中的结果外, 我们还在图 10(c) 中展示了前 10 个奖励曲线。

对于模式数量的评估, 我们定义一个集合, 并将新发现的分子添加到其中, 如果其奖励值大于 7.5 且与集合中所有先前元素的 Tanimoto 相似度小于 0.7 。请注意, 这一标准比仅仅计算达到奖励阈值的不同 Bemis-Murcko 骨架的数量更为严格, 参见 Bengio 等 (2021a); Pan 等 (2022)。Pan 等 (2022) 是在一个修改后的任务上进行实验的, 该任务使得信号稀疏化, 从而突显主动探索的重要性。因此, 由于设置不同, 我们没有将其包含在本工作中。使用 Tanimoto 分离模式的方法更适用于从头开始的分子设计, 而基于骨架的度量则更适用于先导化合物优化。进一步地, 从 Bengio 等 (2021a) 的图 14 和图 15 可以看出, 计数 Tanimoto 分离模式是一种更为严格的度量。我们按照 Bengio 等 (2021a) 的方式测量前 1000 个分子的 Tanimoto 相似度。TB 使用均匀的反向策略, 如同 Malkin 等 (2022a), 因为这提供了更好的结果。对于基线设置, 我们简单地遵循 Bengio 等 (2021a); Malkin 等 (2022a) 的超参数。对于分位数匹配, 我们使用相同的 Adam 学习率 5×10^{-4} as FM, $N = \tilde{N} = 16$, 以及 256 维的傅里叶特征。

计算分子模式数量有两种方法: (i) 第一种方法是通过 Tanimoto 相似度来区分分子; (ii) 第二种方法是检查分子的 Bemis-Murcko 骨架 (即表示分子核心结构的简化表示) 是否不同。对于从头开始的药物发现, 应使用第一种方法, 因为它捕捉到了更多的生物信息, 而第二种方法主要用于先导化合物优化的应用。因此, 我们在报告结果时遵循第一个选项。值得注意的是, 在 Bengio 等 (2021a) 中, 作者选择了第二种方法, 因为在项目准备时对领域不熟悉。