

改进的离策略扩散采样训练方法

Marcin Sendera
Mila, Université de Montréal
Jagiellonian University

Minsu Kim
Mila, Université de Montréal
KAIST

Sarthak Mittal
Mila, Université de Montréal

Pablo Lemos
Mila, Université de Montréal
Ciela Institute
Dreamfold

Luca Scimeca
Mila, Université de Montréal

Jarrid Rector-Brooks
Mila, Université de Montréal
Dreamfold

亚历山大·亚当 米拉，蒙特
利尔大学西莱拉研究所

约书亚·本吉奥
米拉，蒙特利尔大学 CIFAR

埃斯梅拉达·S·惠塔默 米
拉，蒙特利尔大学爱丁堡大
学

{marcin.sendera,...,esmeralda.whitammer}@mila.quebec

摘要

我们研究了训练扩散模型以从给定未归一化密度或能量函数的分布中采样的问题。我们对几种基于扩散结构的推断方法进行了基准测试，包括基于仿真的变分方法和离策略方法（连续生成流网络）。我们的结果揭示了现有算法之间的相对优势，同时也质疑了一些过去工作的主张。我们还提出了一种针对离策略方法的新探索策略，该策略基于目标空间中的局部搜索，并使用回放缓冲区，结果显示它在各种目标分布上提高了样本质量。我们公开了用于采样方法和基准测试的代码（链接），作为未来关于扩散模型用于摊销推断的工作的基础。

1 引言

近似和从复杂的多变量分布中采样是概率深度学习 [例如，27, 35, 26, 48, 57] 和科学应用中的基本问题 [3, 52, 38, 1, 32]。当仅给出未归一化的概率密度或能量时，在高维空间中从分布中抽取样本尤其具有挑战性，特别是当感兴趣的分布有许多分离的模式时 [5]。基于马尔可夫链蒙特卡洛（MCMC）的方法——如调整后的 Langevin 算法 [MALA; 24, 65, 64] 和 Hamiltonian MC [HMC; 20, 31]——可能在模式之间混合缓慢，并且每次采样的成本较高。虽然诸如序列蒙特卡洛 [SMC; 25, 13, 16] 和嵌套采样 [69, 10, 43] 等变体具有更好的模式覆盖，但它们的成本可能会随着问题维度的增长而变得过高。这促使了摊销变分推断的使用，即拟合参数模型来采样目标分布。

扩散模型，一种逐渐将简单分布演化为目标复杂分布的连续时间随机过程，是一种强大的密度估计器，具有经过验证的模式混合特性 [15]；因此，它们在从数据中学习生成模型的设置中被广泛使用 [70, 72, 28, 50, 66]。然而，训练扩散模型以从给定黑盒密度或能量函数的分布中采样的问题受到了较少的关注。最近的研究建立了扩散（学习去噪过程）与随机控制（学习 Föllmer

漂移 [21])，导致了诸如路径积分采样器 [PIS; 88]、去噪扩散采样器 [DDS; 78] 和时间反向扩散采样器 [DIS; 8] 等方法的出现；这些方法最近被 [63] 和 [79] 统一。另一条研究路线 [42, 86] 基于连续生成流网络 (GFlowNets)，这是一种适应变分推断的深度强化学习算法，提供了稳定的离策略训练，从而实现灵活的探索 [46]。

尽管在采样方法的进步和理论上统一的努力 [63, 79] 方面取得了进展，该领域仍存在一些基准测试和可重复性方面的失败，具体表现为不同作品在模型架构的选择上有所不同，使用未声明的超参数，甚至对同一目标密度的定义也存在分歧（参见 § B.1）。本文的第一个主要贡献是一个统一的扩散结构化采样器库。该库专注于离策略方法（连续 GFlowNets），但也包括基于仿真的变分目标，如 PIS。利用此代码库，我们能够在可比较条件下对过去的工作方法进行基准测试，并确认关于探索策略和期望归纳偏置的主张，同时质疑其他关于鲁棒性和样本效率的主张。我们的库还包括几种新的建模和训练技术，并提供了初步证据证明它们在未来工作的潜在效用（§ 5.3）。

本文的第二个贡献是对改进探索和信用分配方法的研究——即从目标密度到早期采样步骤参数的学习信号传播——在扩散结构化采样器中的研究（§ 4）。首先，我们的结果（§ 5.2）表明，利用部分轨迹信息的方法 [44, 55]，正如在扩散设置中由 [86] 所做的那样，相比在策略 [88] 或离策略 [42] 轨迹优化提供的益处有限，且训练成本更高。其次，我们考察了一种梯度变体的实用性，该变体将去噪分布参数化为兰金过程的修正 [88]。我们展示了这种归纳偏置即使计算成本较高，在离策略 (GFlowNet) 设置中也是有益的。最后，受到最近离散采样方法的启发，我们提出了一种基于目标空间局部搜索并使用回放缓冲区的高效探索技术，这可以提高各种目标分布下的样本质量。

2 先前工作

变分推断的 amortized 方法 这些方法使用参数模型 q_θ 来近似给定的目标密度 p_{target} ，通常通过随机优化实现这一目标 [30, 58, 2]。值得注意的是，显式密度模型如自回归模型和归一化流已在密度估计中得到广泛应用 [60, 19, 81, 22, 51]。然而，这些模型施加了结构约束，从而限制了它们的表现力 [14, 23, 87]。在生成模型中采用扩散过程激发了对层级模型作为密度估计器的新兴趣 [80, 28, 76]。诸如 PIS 的方法 [88] 利用随机最优控制从未归一化的密度中采样，尽管如此，在高维空间中仍面临可扩展性的挑战。

生成流网络 最初在离散情况下由 [6, 7] 定义，将层级采样（即逐步生成）视为一个顺序决策过程，并表示强化学习和变分推断方法的综合 [46, 90, 73, 18]，从特定的科学领域 [例如，36, 4, 89] 扩展到更广泛的潜在结构上的摊销推断 [例如，77, 34]。它们通过非策略探索高效地导航轨迹空间的能力至关重要，但在训练动态方面仍面临挑战，如信用分配和探索效率 [45, 44, 55, 59, 68, 39, 37]。这些挑战对这些方法在更复杂场景中的可扩展性产生影响，本文将在连续情况下解决这些问题。

3 设置：扩散结构化采样

令 $\mathcal{E} : \mathbb{R}^d \rightarrow \mathbb{R}$ 是一个可微的能量函数，并定义 $R(\mathbf{x}) = \exp(-\mathcal{E}(\mathbf{x}))$ 作为奖励或未归一化的目标密度。假设积分 $Z := \int \int_{\mathbb{R}^d} R(\mathbf{x}) d\mathbf{x}$ 存在， $\mathcal{E}$ 定义了一个玻尔兹曼密度 $p_{\text{target}}(\mathbf{x}) = R(\mathbf{x})/Z$ 在 $\mathbb{R}^d$ 上。我们感兴趣的是从 p_{target} 中采样以及近似计算配分函数 Z ，仅给定能量函数 $\mathcal{E}$ 及其梯度 $\nabla \mathcal{E}$ 的访问权限

本文描述了该问题的两种密切相关视角：通过神经随机微分方程和随机控制（§ 3.1）以及通过连续生成流网络（§ 3.2）。

3.1 欧拉-马鲁雅马分层采样器

基于 SDE 的生成建模。 扩散模型假设一个由神经随机微分方程给出的连续时间生成过程 [SDE; 75, 54, 67]:

$$d\mathbf{x}_t = u(\mathbf{x}_t, t; \theta) dt + g(\mathbf{x}_t, t; \theta) d\mathbf{w}_t, \quad (1)$$

其中 $\mathbf{x}_0$ 遵循一个固定的易于处理的分布 μ_0 (如高斯分布或点质量)。初始分布 μ_0 和由 (1) 指定的随机动力学在每个 $t > 0$ 上诱导边缘密度 p_t 到 $\mathbb{R}^d$ 。函数 u 和 g 具有可学习参数, 我们希望使用某个目标进行优化, 使得终端密度 p_1 接近 p_{target} 。可以通过从 p_1 采样 $\mathbf{x}_0 \sim \mu_0$ 并模拟 SDE (1) 至时间 $t = 1$ 来抽取样本。

驱动 μ_0 到 p_{target} 的 SDE 不是唯一的。然而, 如果固定一个逆向时间 SDE, 或加噪过程, 将 p_{target} 在 $t = 1$ 推至 μ_0 在 $t = 0$, 那么其逆, 即前向 SDE (1), 在温和条件下唯一确定, 并称为去噪过程。对于通常选择的加噪过程, 存在用于学习去噪过程漂移 u 的随机回归目标, 给定来自 p_{target} 的样本, 扩散率 g 可以以封闭形式获得 [28, 72]。

时间离散化。 实际上, SDE (1) 的积分通过离散时间方案近似, 最简单的是 Euler-Maruyama 积分。过程 (1) 被替换为一个离散时间马尔可夫链 $\mathbf{x}_0 \rightarrow \mathbf{x}_{\Delta t} \rightarrow \mathbf{x}_{2\Delta t} \rightarrow \dots \rightarrow \mathbf{x}_1$, 其中 $\Delta t = \frac{1}{T}$ 是时间增量, T 是步数:

$$\mathbf{x}_0 \sim \mu_0, \quad \mathbf{x}_{t+\Delta t} = \mathbf{x}_t + u(\mathbf{x}_t, t; \theta)\Delta t + g(\mathbf{x}_t, t; \theta)\sqrt{\Delta t}\mathbf{z}_t, \quad \mathbf{z}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d). \quad (2)$$

从 $\mathbf{x}_t$ 到 $\mathbf{x}_{t+\Delta t}$ 的转移核密度可以显式地写作

$$p_F(\mathbf{x}_{t+\Delta t} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t+\Delta t}; \mathbf{x}_t + u(\mathbf{x}_t, t; \theta)\Delta t, g(\mathbf{x}_t, t; \theta)^2 \Delta t \mathbf{I}_d), \quad (3)$$

其中 p_F 表示离散化前向 SDE 的转移密度。此密度定义了一个关于从 $\mathbf{x}_0$ 开始的轨迹的联合分布:

$$p_F(\mathbf{x}_{\Delta t}, \dots, \mathbf{x}_1 | \mathbf{x}_0) = \prod_{i=0}^{T-1} p_F(\mathbf{x}_{(i+1)\Delta t} | \mathbf{x}_{i\Delta t}). \quad (4)$$

类似地, 离散时间逆过程 $\mathbf{x}_1 \rightarrow \mathbf{x}_{1-\Delta t} \rightarrow \mathbf{x}_{1-2\Delta t} \rightarrow \dots \rightarrow \mathbf{x}_0$ 具有转移密度 $p_B(\mathbf{x}_{t-\Delta t} | \mathbf{x}_t)$, 通过定义联合分布 p_B 。

$$p_B(\mathbf{x}_0, \dots, \mathbf{x}_{1-\Delta t} | \mathbf{x}_1) = \prod_{t=1}^T p_B(\mathbf{x}_{(i-1)\Delta t} | \mathbf{x}_{i\Delta t}). \quad (5)$$

如果正向和反向过程 (分别从 μ_0 和 p_{target} 开始) 互为逆过程, 则它们定义相同的轨迹分布, 即对于所有 $\mathbf{x}_0 \rightarrow \mathbf{x}_{\Delta t} \rightarrow \dots \rightarrow \mathbf{x}_1$ 。

$$\mu_0(\mathbf{x}_0)p_F(\mathbf{x}_{\Delta t}, \dots, \mathbf{x}_1 | \mathbf{x}_0) = p_{\text{target}}(\mathbf{x}_1)p_B(\mathbf{x}_0, \dots, \mathbf{x}_{1-\Delta t} | \mathbf{x}_1). \quad (6)$$

特别是, 在正向和反向过程中, $\mathbf{x}_1$ 的边缘密度等于 p_{target} , 并且可以使用正向过程来采样目标分布。

由于具有高斯增量的过程的逆过程通常本身不是高斯的, (6) 只能近似满足, 但当 $\Delta t \rightarrow 0$ (即增量是无穷小高斯的) 时, 差异消失, 这是中心极限定理在随机微积分中的关键应用 [54]。

SDE 学习作为层次变分推断。 学习前向过程的参数 θ 以强制执行 (6) 的问题属于层次变分推断。后向过程通过一系列隐变量 $\mathbf{x}_{1-\Delta t}, \dots, \mathbf{x}_0$ 将 $\mathbf{x}_1$ 转换为 $\mathbf{x}_0$, 而前向过程旨在匹配这些变量上的后验分布, 从而近似强制执行 (6)。

在从数据中学习扩散模型的情况下, 其中可以从 p_{target} 获取样本, 可以通过最小化给定逆过程的轨迹分布与给定正向过程的轨迹分布之间的 KL 发散 $D_{\text{KL}}(p_{\text{target}} \cdot p_B \| \mu_0 \cdot p_F)$ 来优化正向过程。

1 当 μ_0 是点质量时, 我们假设分布 $\mathbf{x}_0 | \mathbf{x}_{\Delta t}$ 也是点质量, 其相对于测度 μ_0 的密度为 $p_B(\mathbf{x}_0 | \mathbf{x}_{\Delta t}) = 1$ 。

这等同于扩散模型的典型训练方法，该方法优化数据对数似然性的变分界（参见 [71]）。然而，在密度不可计算的情形下 p_{target} ，这种发散的无偏估计器是不可获得的。相反，可以优化逆 KL 散度：²

$$D_{\text{KL}}(\mu_0 \cdot p_F \| p_{\text{target}} \cdot p_B) = \int \log \frac{\mu_0(\mathbf{x}_0) p_F(\mathbf{x}_{\Delta t}, \dots, \mathbf{x}_1 | \mathbf{x}_0)}{p_{\text{target}}(\mathbf{x}_1) p_B(\mathbf{x}_0, \dots, \mathbf{x}_{1-\Delta t} | \mathbf{x}_1)} d\mu_0(\mathbf{x}_0) p_F(\mathbf{x}_{\Delta t}, \dots, \mathbf{x}_1 | \mathbf{x}_0) d\mathbf{x}_{\Delta t} \dots d\mathbf{x}_1. \quad (7)$$

存在多种对该目标的估计方法。例如，路径积分采样器目标 [PIS; 88] 利用重参数化技巧将 (7) 表示为噪声变量的期望 $\mathbf{z}_t$ 参与对 $\mathbf{x}\Delta$ 的层级采样的 $t, \dots, \mathbf{x}_1$ 从而得到一个无偏的梯度估计器，但需要在前向过程仿真的过程中进行反向传播。相关的去噪扩散采样器 [DDS; 78] 在同一原理下采用了不同的积分方案。

3.2 Euler-Maruyama 采样器作为 GFlowNets

连续生成流网络 (GFlowNets) [42] 将强制执行 (6) 的问题表述为强化学习任务。本节总结这一解释，及其与神经 SDE 的关系，相关学习目标，以及各自的优劣。

生成流网络与扩散模型或 SDE 之间的联系最初由 [46] 在分布匹配设置中非正式地提出，并由 [84] 在最大似然设置中提出，而连续 GFlowNets 的理论基础后来由 [42] 奠定。

状态和动作空间。 为了将采样表述为顺序决策问题，必须定义状态和动作的空间。在通过 T 步 Euler-Maruyama 积分进行采样的情况下，假设 μ_0 是在 $\mathbf{0}$ 处的质量点，状态空间是

$$\mathcal{S} = \{(\mathbf{0}, 0) \cup \{(\mathbf{x}, t) : \mathbf{x} \in \mathbb{R}^d, t \in \{\Delta t, 2\Delta t, \dots, 1\}\}\},$$

其中点 $(\mathbf{x}, t)$ 表示采样代理在时间 t 的位置为 $\mathbf{x}$ 。

采样始于初始状态 $\mathbf{x}_0 := (\mathbf{0}, 0)$ ，经过一系列状态 $(\mathbf{x}\Delta_t, \Delta t)$ ， $(\mathbf{x}_2\Delta_t, 2\Delta t), \dots$ ，最终到达一个状态 $(\mathbf{x}_1, 1)$ ；状态 $(\mathbf{x}, t)$ 与 $t = 1$ 被称为终止状态，它们的集合表示为 $\mathbf{X}$ 。从现在起，我们将经常用 $\mathbf{x}_t$ 代替状态 $(\mathbf{x}_t, t)$ 当时间 t 从上下文中明确时。状态序列 $\mathbf{x}_0 \rightarrow \mathbf{x}\Delta_t \rightarrow \dots \rightarrow \mathbf{x}_1$ 称为完整的轨迹。

从非终止状态 $(\mathbf{x}_t, t)$ 采取的动作对应于可能的下一状态 $(\mathbf{x}_{t+\Delta t}, t + \Delta t)$ ，这些状态可以通过欧拉-马鲁雅马积分器的单步操作从 $(\mathbf{x}_t, t)$ 到达。³

前向策略和学习问题。 一个（前向）策略是非终止状态 $(\mathbf{x}, t)$ 在我们的上下文中，这相当于一组条件概率密度函数 $p_F(\mathbf{x}_{t+\Delta t} | \mathbf{x}_t; \theta)$ ，表示从 $\mathbf{x}_t$ 到 $\mathbf{x}_{t+\Delta t}$ 的状态转移核的密度。GFlowNet 训练优化参数 θ ，这些参数可能是指定在给定 $\mathbf{x}\Delta$ 上的密度的神经网络的权重 $\mathbf{x}_{t+\Delta t}$ 条件下的 $\mathbf{x}\Delta_t$ 。策略 p_F 诱导出完整的轨迹分布 $\tau = (\mathbf{x}_0 \rightarrow \mathbf{x}\Delta_t \rightarrow \dots \rightarrow \mathbf{x}_1)$ 通过

$$p_F(\tau; \theta) = \prod_{i=0}^{T-1} p_F(\mathbf{x}_{(i+1)\Delta t} | \mathbf{x}_{i\Delta t}; \theta).$$

特别是，我们得到了终端状态上的边缘密度：

$$p_F^\top(\mathbf{x}_1; \theta) = \int p_F(\mathbf{x}_0 \rightarrow \mathbf{x}_{\Delta t} \rightarrow \dots \rightarrow \mathbf{x}_1; \theta) d\mathbf{x}_{\Delta t} \dots d\mathbf{x}_{1-\Delta t}. \quad (8)$$

GFlowNets 解决的学习问题是找到策略 p_F 的参数 θ ，其终止密度 $p_F^\top$ 等于 p_{target} ，i.e.，

$$p_F^\top(\mathbf{x}_1; \theta) = \frac{R(\mathbf{x}_1)}{Z} \quad \forall \mathbf{x}_1 \in \mathbb{R}^d. \quad (9)$$

为了精确起见，(7) 中的分数应理解为 Radon-Nikodym 导数，无论 μ_0 是一个点质量还是一个连续分布，它都有意义，并推广到连续时间 [8, 63]。形式上，[42] 中的基础假设了相对于奖励和核密度定义的参考测度。由于我们处理的是欧几里得空间并假设了勒贝格测度，读者无需负担测度论。然而，值得注意的是，这种灵活性允许轻松地推广到其他空间上的采样，例如任何黎曼流形，而其他方法不直接适用。

然而，由于积分 (8) 不可计算且 Z 未知，必须引入辅助对象到优化目标中以强制执行 (9)，如下所述。

值得注意的是，如果策略是一个高斯分布，其均值和方差由神经网络给出，输入分别为 $\mathbf{x}_t$ 和 t ，那么学习策略就等同于学习漂移 $u(\mathbf{x}_t, t; \theta)$ 和扩散 $g(\mathbf{x}_t, t; \theta)$ of a SDE (1)，即拟合一个神经 SDE。第 3.1 节中的 SDE 学习问题因此与拟合具有高斯策略的 GFlowNet 相同。

反向策略与轨迹平衡。 反向策略是一系列条件概率密度 $p_B(\mathbf{x}_{t-\Delta t} | \mathbf{x}_t; \psi)$ 的集合，表示从状态 $\mathbf{x}_t$ 转移到祖先状态 $\mathbf{x}_{t-\Delta t}$ 的概率密度。反向策略在给定终端状态的情况下诱导出完整的轨迹分布 τ (参见 (5))：

$$p_B(\tau | \mathbf{x}_1; \psi) = \prod_{i=1}^T p_B(\mathbf{x}_{(i-1)\Delta t} | \mathbf{x}_{i\Delta t}; \psi),$$

其中特别地 $p_B(\mathbf{x}_0 | \mathbf{x}_{\Delta t}) = 1$ 作为 μ_0 是一个质点。推广离散空间设置下的一个结果 [45], [42] 证明 p_F 从目标分布中采样 (即满足 (9) 式) 当且仅当存在一个反向策略 p_B 以及一个标量 Z_θ 使得对于每一个完整的轨迹平衡条件得以满足 $\tau = (\mathbf{x}_0 \rightarrow \mathbf{x}_{\Delta t} \rightarrow \dots \rightarrow \mathbf{x}_1)$ ：

$$Z_\theta p_F(\tau; \theta) = R(\mathbf{x}_1) p_B(\tau | \mathbf{x}_1; \psi). \quad (10)$$

如果这些条件成立，那么 Z_θ 等于真实的配分函数 $Z = \int R(\mathbf{x}) d\mathbf{x}$ 。轨迹平衡目标 $\int R(\mathbf{x}) d\mathbf{x}$ 对于轨迹 τ 而言是 (10) 两边平方对数比值，即：

$$\mathcal{L}_{TB}(\tau; \theta, \psi) = \left(\log \frac{Z_\theta p_F(\tau; \theta)}{R(\mathbf{x}_1) p_B(\tau | \mathbf{x}_1; \psi)} \right)^2. \quad (11)$$

因此，可以通过最小化损失 $\mathcal{L}_{TB}(\tau; \theta, \psi)$ 关于参数 θ 和 ψ 的值来实现 (9)，其中用于训练的轨迹 τ 是从某个训练策略 $\pi(\tau)$ 中采样的。虽然可以同时优化正向和反向策略的参数，但在某些学习问题中，固定反向策略，仅优化参数 p_F 和配分函数的估计值 Z_θ 。例如，在第 5 节的大多数实验中，我们将反向策略固定为离散化的布朗桥，遵循以往的工作。

离策略优化。 与 KL 目标 (7) 不同，其梯度涉及当前正向过程下轨迹分布的期望，(11) 可以离策略优化，即使用从任意分布采样的轨迹进行优化 π 。因为最小化 $\mathcal{L}_{TB}(\tau; \theta, \psi)$ 对所有值设为 0 τ 在支持上 π 将达到 (9)， π 可以取任意具有全支撑的概率分布，从而促进目标分布模式的发现。受强化学习技术启发，提出了多种选择，包括噪声探索或退火 [6]，回放缓冲区 [17] 汤普森采样 [59]，并通过 MCMC 从终端状态获得反向迹 [43] 在连续情况下，[46, 42] 建议在采样轨迹进行训练时简单地给策略方差添加一个小常数。离策略优化是 GFlowNets 相对于 PIS 等变分方法的关键优势，后者需要在线策略优化 [46]。

然而，当 $\mathcal{L}_{TB}$ 恰好是在线策略优化，即使用从策略中采样的轨迹 p_F 自身，我们得到 KL 发散梯度关于的无偏估计量 (7) p_F 参数相差一个常数 [62, 46, 90] 即：

$$\mathbb{E}_{\tau \sim p_F(\tau)} [\nabla_{\theta'} \mathcal{L}_{TB}(\tau; \theta, \psi)] = 2 \nabla_{\theta'} D_{KL}(p_F(\tau; \theta) \| p_{\text{target}}(\mathbf{x}_1) p_B(\tau | \mathbf{x}_1; \psi)),$$

其中 $\nabla_{\theta'}$ 表示相对于 p_F 参数的梯度，但不包括 Z_θ 。这个无偏估计器倾向于比 PIS 使用的基于重新参数化的估计器具有更高的方差。另一方面，它不需要通过正向过程仿真的反向传播，并可用于优化正向和反向策略的参数。

其他目标函数。 轨迹平衡目标 (11) 并非唯一可用于强制执行 (9) 的目标。一个值得注意的泛化是子轨迹平衡 [子结核; 44]，它涉及建模与每个状态 $\mathbf{x}_t$ 相关的标量状态流 $f(\mathbf{x}_t; \theta)$ ——旨在模拟正向过程在 $\mathbf{x}_t$ 处的边缘密度——并强制执行所有部分轨迹的子轨迹平衡条件

$$\mathbf{x}_{m\Delta t} \rightarrow \mathbf{x}_{(m+1)\Delta t} \rightarrow \dots \rightarrow \mathbf{x}_{n\Delta t}:$$

$$f(\mathbf{x}_{m\Delta t}; \theta) \prod_{i=m}^{n-1} p_F(\mathbf{x}_{(i+1)\Delta t} | \mathbf{x}_{i\Delta t}; \theta) = f(\mathbf{x}_{n\Delta t}; \theta) \prod_{i=m+1}^n p_B(\mathbf{x}_{(i-1)\Delta t} | \mathbf{x}_{i\Delta t}; \psi), \quad (12)$$

其中对于终端状态 $f(\mathbf{x}_1) = R(\mathbf{x}_1)$ 。这种方法与训练状态流相关的计算开销，但在离散空间设置中已被证明是有效的，尤其是在结合由 [55] 提出的向前奖励塑形方案时。它也已连续情况下进行了测试，但我们的实验结果表明，在扩散设置中，它提供的收益超过 TB 目标有限（见 § 4.1 和 § B.1）。

值得注意的是离线策略 VarGrad 估计器 [53, 62]，该方法由 [85] 重新发现应用于 GFlowNets。类似于轨迹平衡（TB），VarGrad 可以在离线策略绘制的轨迹上进行优化。VarGrad 不是强制执行 (10) 中的每个轨迹，而是优化 (10) 两边对数比值的经验方差（在小批量数据上）。正如 [46] 所指出的，这等价于首先相对于 $\log Z_\theta$ 在批次上最优地最小化 $\mathcal{L}_{TB}$ ，然后相对于 p_F 的参数。

4 探索与连续 GFlowNets 中的信用分配

训练离线策略采样模型的主要挑战在于探索效率（发现高回报状态）和信用分配（将奖励信号传播到导致这些状态的动作）。我们描述了几种新旧方法，用于解决扩散结构 GFlowNets 中的这些挑战。这些技术将在第 5 节中进行实证研究和比较。

4.1 信用分配方法

部分能量和基于子轨迹的学习。 [86] 研究了由...引入的扩散采样器学习问题 [42]，但将 TB 学习目标替换为 SubTB 目标。⁴ 此外，一种类似于几何插值的归纳偏置 [47] 被用于状态流函数：

$$\log f(\mathbf{x}_t; \theta) = (1 - t) \log p_t^{\text{ref}}(\mathbf{x}_t) + t \log R(\mathbf{x}_t) + \text{NN}(\mathbf{x}_t, t; \theta), \quad (13)$$

其中 NN 是一个神经网络， $p_t^{\text{ref}}(\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_t; 0, \sigma^2 t I_d)$ 是速率 σ 在时间点 $\mathbf{x}_t$ 的布朗运动的边缘密度。假设在状态流函数中使用目标密度 $\log R(\mathbf{x}_t) = -\mathcal{E}(\mathbf{x}_t)$ 可以提供有效的信号，引导采样器在轨迹早期步骤到达高密度状态。这种对状态流的归纳偏置被 [55] 称为前瞻性的（FL），我们在第 5 节中将其称为 **FL-SubTB**。

朗之万动力学归纳偏置。 [88] 提出了关于漂移神经 SDE 架构的归纳偏置 $u(\mathbf{x}_t, t; \theta)$ （用 GFlowNet 术语来说，即高斯密度的均值 $p_F(\mathbf{x}_{t+\Delta t} | \mathbf{x}_t; \theta)$ ）类似于目标分布上的兰杰文过程。可以写作

$$u(\mathbf{x}_t, t; \theta) = \text{NN}_1(\mathbf{x}_t, t; \theta) + \text{NN}_2(t; \theta) \nabla \mathcal{E}(\mathbf{x}_t), \quad (14)$$

其中 NN1 和 NN2 分别是输出向量和标量的神经网络。公式 (14) 中的第二项是目标能量梯度的缩放值——Langevin SDE 的漂移——而第一项是一个学习的修正项。这种归纳偏置，我们称之为 Langevin 参数化 (**LP**)，已被证明能够提高 PIS 的效率。我们将在第 5 节研究其对连续 GFlowNets 的影响。

放置在策略上的归纳偏置 (14) 代表了一种不同的方式在轨迹的中间步骤中结合奖励信号，并引导采样器朝向低能量区域。它与 (13) 不同之处在于，它直接将能量梯度提供给策略，而不是仅仅通过状态流的参数化 (13) 来使用能量作为策略的学习信号。

考虑到连续时间极限，我们猜想 Langevin 参数化 (14) 与 NN1 独立于 $\mathbf{x}_t$ 在时间增量 $\Delta t \rightarrow 0$ 的极限下等价于前瞻流 (13)，即它们在短部分轨迹上诱导相同的 SubTB 约束 (12) 的差异渐近行为。这样的理论分析可以成为未来工作的主题。

4.2 一种新的基于局部搜索和回放缓冲区的离线探索方法

并行 MALA 的局部搜索。 FL 和 LP 归纳偏置都会导致计算开销：要么是在状态流的评估和优化中，要么是在每次采样步骤中都需要评估能量梯度（见 § C.3）。我们提出了一种不会增加每条训练轨迹额外计算成本的替代技术。

尽管 FL-SubTB 对于扩散采样器声称有诸多好处，但我们发现 [86] 在比较中修改了关键实验变量并报告了不可重复的结果；详见 § B.1。

表 1: 无条件建模任务的函数估计误差 (5 次运行的均值和标准差)。模型分为四组: 基于 MCMC 的采样器、仿真驱动的变分方法、具有不同学习目标的基础 GFlowNet 方法以及附加 Langevin 参数化和局部搜索的方法。更多度量请参见 § C.1。

Energy →	25GMM ($d = 2$)		Funnel ($d = 10$)		Manywell ($d = 32$)		LGCP ($d = 1600$)	
Algorithm ↓ Metric →	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\log \hat{Z}$	$\log \hat{Z}^{\text{RW}}$
SMC	0.569±0.010		0.561±0.801		14.99±1.078		See discussion in §B.1	
GGNS [43]	0.016±0.042		0.033±0.173		0.292±0.454		N/A	
DIS [8]	1.125±0.056	0.986±0.011	0.839±0.169	0.093±0.038	10.52±1.02	3.05±0.46	299.83±0.67	361.15±6.48
DDS [78]	1.760±0.08	0.746±0.389	0.424±0.049	0.206±0.033	7.36±2.43	0.23±0.05	471.64±1.20	489.30±0.62
PIS [88]	1.769±0.104	1.274±0.218	0.534±0.008	0.262±0.008	3.85±0.03	2.69±0.04	381.14±1.42	414.42±2.06
+ LP [88]	1.799±0.051	0.225±0.583	0.587±0.012	0.285±0.044	13.19±0.82	0.07±0.85	471.45±0.18	487.82±2.26
TB [42]	1.176±0.109	1.071±0.112	0.690±0.018	0.239±0.192	4.01±0.04	2.67±0.02	336.70±56.22	379.50±49.99
TB + Expl. [42]	0.560±0.302	0.422±0.320	0.749±0.015	0.226±0.138	4.01±0.05	2.68±0.06	346.10±55.54	389.21±44.13
VarGrad + Expl.	0.615±0.241	0.487±0.250	0.642±0.010	0.250±0.112	4.01±0.05	2.69±0.06	370.37±0.26	410.37±6.70
FL-SubTB	1.127±0.010	1.020±0.010	0.527±0.011	0.182±0.142	3.98±0.07	2.72±0.05	365.20±6.08	402.65±8.36
+ LP [86]	0.209±0.025	0.011±0.024	0.563±0.021	0.155±0.317	4.23±0.12	2.66±0.22	465.44±1.26	483.90±1.95
TB + Expl. + LS (ours)	0.171±0.013	0.004±0.011	0.653±0.025	0.285±0.099	4.57±2.13	0.19±0.29	384.90±0.83	419.55±2.14
TB + Expl. + LP (ours)	0.206±0.018	0.011±0.010	0.666±0.615	0.051±0.616	7.46±1.74	1.06±1.11	452.82±1.50	477.62±1.79
TB + Expl. + LP + LS (ours)	0.190±0.013	0.007±0.011	0.768±0.052	0.264±0.063	4.68±0.49	0.07±0.17	471.14±0.25	489.03±1.38
VarGrad + Expl. + LP + LS (ours)	0.207±0.016	0.015±0.015	0.920±0.118	0.256±0.037	4.11±0.45	0.02±0.21	468.65±0.63	487.34±1.34

Highlight : mean indistinguishable from best in column with $p < 0.05$ under one-sided Welch unpaired t -test.

为了提高训练期间样本的质量, 我们将局部搜索整合到探索过程中, 这一做法受到离散空间中局部探索成功和回放缓冲区方法的启发 [83, 33, 40][例如, 17]。与这些定义 MCMC 核函数通过 GFlowNet 策略的方法不同, 我们的方法直接在目标空间中利用并行 Metropolis 调整 Langevin (MALA)。




图 1: 由不同算法训练的模型生成的 Manywell 样本的二维投影。我们提出的带有局部搜索的回放缓冲区能够防止模式崩塌。

具体而言, 我们最初从采样器中抽取候选样本: $M \sim \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(M)}\} p_F^\top(\cdot)$ 。随后, 我们在 M 条马尔可夫链上并行运行 MALA 算法, 进行 K 次转移, 初始状态为 $\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(M)}\}$ 。经过 $K_{\text{burn-in}}$ 次预热转移后, 接受的样本被存储在本地搜索缓冲区中 $\mathcal{D}_{\text{LS}}$ 。我们偶尔使用 MALA 步骤更新缓冲区, 并从中重放缓冲区样本, 以减少迭代局部搜索的计算需求。MALA 步骤比采样器训练更容易并行化, 且由于缓冲区远大于训练批大小, 因此只需很少进行更新, 所以局部搜索的开销很小。

带有局部搜索和回放缓冲区的训练。 为了在缓冲区的帮助下训练采样器, 我们从 $\mathcal{D}_{\text{LS}}$ 中均匀地或根据优先级方案 (参见 § E) 抽取样本 $\mathbf{x}$, 从反向过程中抽样一条通往 $\mathbf{x}$ 的轨迹 τ , 并对与之相关的目标 (例如, TB) 进行梯度更新 τ 。

当使用局部搜索指导进行训练时, 我们交替执行两步操作, 灵感来源于 [43], 他们交替训练正向轨迹和从一组固定的 MCMC 样本初始化的反向轨迹。步骤 A 涉及使用在线策略或探索性正向采样的训练, 而步骤 B 则使用上述局部搜索缓冲区中的样本。这使得采样器可以探索多样化的样本 (步骤 A) 和低能量样本 (步骤 B)。详见 § E 中自适应步长并行 MALA 和局部搜索引导的 GFlowNet 训练的详细伪代码。

5 实验

我们对各种扩散结构采样器进行了全面的基准测试, 包括 GFlowNet 采样器和诸如 PIS 等方法。对于 GFlowNet 采样器, 我们研究了一系列技术, 包括不同的探索策略和损失函数。此外, 我们还考察了 Langevin 参数化以及新提出的带有缓冲区的局部搜索的有效性。

5.1 任务与基线

我们探讨了两种类型的任务, 在 § B 中提供了更多细节: 从能量分布中进行采样

——一个具有 25 个模式的二维高斯混合模型 (25GMM), 一个十维漏斗分布, 一个三十二维 Manywell 分布, 以及一个一千六百维的 Log-Gaussian Cox 过程——

以及从变分自编码器 (VAE; [41, 61]) 的潜在后验中进行条件采样。这使我们能够研究无条件 and 有条件生成建模技术。

我们评估了三个算法类别:

(1) 传统采样方法: 我们考虑了一个标准的序贯蒙特卡洛 (SMC) 实现和一种最先进嵌套采样方法 (GGNS, [43])。

(2) 基于仿真的变分方法: DIS [8]、DDS [78] 和 PIS [88]。

(3) 基于扩散的 GFlowNet 采样器: 我们的评估集中在基于 TB 的训练以及 § 4 中描述的改进: VarGrad 估计器 (VarGrad)、离策略探索 (Expl.)、Langevin 参数化 (LP) 和局部搜索 (LS)。此外, 我们还评估了由 [86] 研究的基于 FL-SubTB 的连续 GFlowNet, 以进行全面比较。

对于 (2) 和 (3), 我们在各种方法中采用了统一的神经架构 (详情见 § D)。

学习问题和固定的反向过程。 在我们的主要实验中, 我们借鉴了 [88] 中的建模设置。我们的目标是学习一个高斯前向策略 p_F , 该策略能够在 $T = 100$ 步内从目标分布中采样 ($\Delta t = 0.01$)。正如以往的工作 [88, 42, 86] 所示, 后向过程被固定为一个离散的布朗桥, 其噪声率 σ 依赖于领域; 具体来说,

$$p_B(\mathbf{x}_{t-\Delta t} | \mathbf{x}_t) = \mathcal{N}\left(\mathbf{x}_{t-\Delta t}; \frac{t-\Delta t}{t}\mathbf{x}_t, \frac{t-\Delta t}{t}\sigma^2\Delta t\mathbf{I}_d\right), \quad (15)$$

当 $t = \Delta t$ 时被视为位于 $\mathbf{0}$ 处的点质量。为了使学习问题与以往工作保持一致, 我们将正向策略的方差 p_F 固定为 σ^2 。这种简化在连续时间下是合理的, 因为此时正向和反向 SDE 具有相同的扩散率。然而, 在 § 5.3 中, 我们将提供证据表明学习正向策略的方差对于较短轨迹非常有益。

基准度量。 为了评估基于扩散的采样器, 我们使用了过去工作中提出的两个度量 [88, 42], 并将其重新表述为我们自己的记号。给定任何前向 $\mathbb{R}^d$ $R(\mathbf{x}) d\mathbf{x}$: 策略 p_F , 我们有一个对数分区函数的变分下界 $\log Z = \int$

$$\log \int_{\mathbb{R}^d} R(\mathbf{x}) d\mathbf{x} = \log \mathbb{E}_{\tau=(\cdots \rightarrow \mathbf{x}_1) \sim p_F(\tau)} \left[\frac{R(\mathbf{x}_1)p_B(\tau | \mathbf{x}_1)}{p_F(\tau)} \right] \geq \mathbb{E}_{\tau=(\cdots \rightarrow \mathbf{x}_1) \sim p_F(\tau)} \left[\log \frac{R(\mathbf{x}_1)p_B(\tau | \mathbf{x}_1)}{p_F(\tau)} \right].$$

我们使用一个 K 样本 ($K = 2000$) 蒙特卡洛估计此期望值, $\log \hat{Z}$, 作为度量, 其等于真实值 $\log Z$ 如果 p_F 和 p_B 共同满足 (10), 从而 p_F 从目标分布中采样。我们还使用了一个重要性加权变体, 强调模式覆盖而非精确局部建模:

$$\log \hat{Z}^{\text{RW}} := \log \sum_{i=1}^K \left[\frac{R(\mathbf{x}_1^{(i)})p_B(\tau^{(i)} | \mathbf{x}_1^{(i)})}{p_F(\tau^{(i)})} \right],$$

其中 $\tau^{(1)}, \dots, \tau^{(K)}$ 是从 p_F 采样的轨迹, 并导致终端状态 $\mathbf{x}_1^{(1)}, \dots, \mathbf{x}_1^{(K)}$ 。该估计器 $\log \hat{Z}^{\text{RW}}$ 也是对 $\log Z$ 的一个下界, 并随着 $K \rightarrow \infty$ [11] 接近它。在无条件的建模基准中, 我们将这两个估计器与已知解析形式的真实对数分区函数进行比较, 除了 LGCP 任务外, 所有任务都是如此 (这导致了过去工作的差异; 参见 § B.1)。

此外, 我们还包括了一个基于样本的度量 (2-瓦瑟斯坦距离); 参见 § C.1。

5.2 结果

无条件采样。 我们在表 1 中报告了所有算法和能量的度量。

我们观察到, 在没有额外的探索和信用分配机制的情况下, TB 的性能通常较为温和, 除了在 **Funnel** 任务上, 各种方法之间的性能差异可以忽略不计。这证实了过去关于离策略探索的重要性 [46, 42] 以及改进信用分配的重要性 [86] 的工作假设。另一方面, 我们的结果并没有显示出一致




图 2: 探索方差对使用 TB 训练的模型在 25GMM 能量上的影响。探索促进了模式发现, 但应随着时间的推移而衰减, 以便将建模能力最优地分配给高概率轨迹。




图 3: 左: 分布图 $x_0, x_{0.1}, \dots, x_1$ 由具有固定 (顶部) 和学习 (中部) 前向策略方差的 10 步采样器在 25GMM 能量上学习到的。固定方差模型的最后一轮采样添加了接近目标分布成分方差的高斯噪声, 这使得采样器无法精确捕捉模式。最后一行显示了作为函数的学习策略方差 x_t 在不同的时间步骤 t (白色表示高方差, 蓝色表示低方差), 表明在接近峰值周围添加的噪声较少 $t = 1$ 。两个模型的对数划分函数估计值分别为 -1.67 和 -0.62 。右: 对于不同数量的步骤 T , 我们绘制了 $\log \hat{Z}$ 由具有固定和学习方差的模型获得。学习策略方差可以在较少步骤内得到类似的采样器。

以及使用由 [86] 提出的 FL-SubTB 目标相对于 TB 的显著改进。将 TB 替换为 VarGrad 目标会产生类似的结果。

简单的离策略探索方法, 即向策略添加方差, 显著提高了 25GMM 任务上的性能。我们在图 2 中对此现象进行了更详细的调查, 发现逐渐减少探索强度的策略是最好的。

另一方面, 我们的带有回放缓冲区的局部搜索引导探索 (LS) 带来了性能的显著提升, 超越或与 GFlowNet 基线、非 GFlowNet 基线以及大多数任务和度量下的非摊销采样方法竞争。这种优势归因于高效的探索能力和重播过去的低能量区域的能力, 从而防止训练过程中的模式崩塌 (图 1)。关于 LS 增强的进一步细节在 § E 中讨论, 并在 § E.2 中进行了消融研究。

将 Langevin 参数化 (LP) 融入到 TB 或 FL-SubTB 中, 导致了显著的性能提升 (尽管每次迭代速度慢 $2-3 \times$ 倍), 这表明之前的观察结果 [88] 可以转移到离策略算法上。与旨在通过部分能量增强信用分配的 FL-SubTB 相比, LP 通过利用梯度信息实现了更优的信用分配, 类似于连续时间中的部分能量。LP 在大多数任务和度量上要么优于其他方法, 要么与其相当。

在 § C.3 中, 我们研究了算法随维度扩展的效率, 展示了所提出的 LS 的效率。

条件采样。对于 VAE 任务, 我们观察到基于 GFlowNet 的基线采样器的性能通常劣于基于仿真的 PIS (表 2)。虽然 LP 和 LS 改进了 TB 的性能, 但它们并未完全缩小似然估计的差距; 然而, 使用 VarGrad 目标时, 性能可与 PIS 媲美甚至更优。我们假设这种差异是由于难以拟合条件对数划分函数估计器所致, 该估计器是 TB 目标所需, 而 VarGrad 仅学习策略。(在图 D.1 中, 我们展示了使用最佳扩散编码器编码的解码样本。)

表 2: MNIST 数据集上预训练 VAE 解码器的测试集对数似然估计。被采样的潜在空间是 20 维的。VAE 的训练 ELBO (高斯编码器) 为 ≈ -101 。

Algorithm $\downarrow$ Metric $\rightarrow$	$\log \hat{Z}$	$\log \hat{Z}^{\text{RW}}$
GGNS [43]	-82.406 ± 0.882	
PIS [88]	-102.54 ± 0.437	-47.753 ± 2.821
+ LP [88]	-99.890 ± 0.373	-47.326 ± 0.777
TB [42]	-162.73 ± 35.55	-61.407 ± 17.83
VarGrad	-102.54 ± 0.934	-46.502 ± 1.018
TB + Expl. [42]	-148.04 ± 4.046	-49.967 ± 5.683
FL-SubTB	-147.992 ± 22.671	-54.196 ± 3.996
+ LP [86]	-111.536 ± 1.027	-47.640 ± 1.313
TB + Expl. + LS (ours)	-245.78 ± 13.80	-55.378 ± 9.125
TB + Expl. + LP (ours)	-112.45 ± 0.671	-48.827 ± 1.787
TB + Expl. + LP + LS (ours)	-117.26 ± 2.502	-49.157 ± 2.051
VarGrad + Expl. (ours)	-103.39 ± 0.691	-47.318 ± 1.981
VarGrad + Expl. + LS (ours)	-105.40 ± 0.882	-48.235 ± 0.891
VarGrad + Expl. + LP (ours)	-99.472 ± 0.259	-46.574 ± 0.736
VarGrad + Expl. + LP + LS (ours)	-99.783 ± 0.312	-46.245 ± 0.543

5.3 扩展至一般 SDE 学习问题

我们的扩散结构生成流网络实现包括几个额外选项，这些选项偏离了该领域过去大部分工作的建模假设。值得注意的是，它具有以下功能：

- 优化反向（加噪）过程——而不仅仅是去噪过程——正如在相关学习问题中所做的那样 [12, 63, 79]；
- 学习前向过程的扩散率 $g(\mathbf{x}_t, t; \theta)$ ，而不仅仅是均值 $u(\mathbf{x}_t, t; \theta)$ ；
- 假设反向过程的噪声调度可变，使得可以训练使用标准加噪 SDE 的图像扩散模型。

这些扩展将允许其他人在此实现基础上构建，并将其应用于诸如微调图像上的扩散模型等任务，这些模型使用 GFlowNet 目标进行训练。

正如 § 5.1 所指出的，在主要实验中，我们将学习到的正向过程的扩散率固定下来，这一假设源自所有过去的工作，并在连续时间极限下得到了证明。然而，我们进行了一项实验，以展示诸如在离散时间学习正向方差等扩展的重要性。图 3 展示了在 25GMM 能量上遵循实验设置 [43] 的模型样本。我们看到，当正向策略的方差被学习时，模型可以更好地捕捉目标分布的细节，在峰值附近选择低方差以避免通过采样的最后一步添加的噪声而‘模糊’它们。

在 § C.2 中，我们包括了初步结果，使用一种保持方差的反向过程，这在扩散模型中通常使用，代替了主要实验中使用的反向布朗运动。

能够在更少步骤内准确建模分布对于计算效率至关重要。未来的工作可以考虑改进粗略时间离散化性能的方法，例如非高斯转换，其在从数据训练的扩散模型中的实用性已经得到证明 [82]。

6 结论

我们提出了对用于连续变量摊销推断的扩散结构采样器的研究。我们的结果表明，这些模型在提高模式覆盖率和效率方面具有前景的技术。未来关于应用的工作可以考虑动态系统高维参数的推理和逆问题。在概率机器学习中，这项工作的扩展应研究将我们的摊销顺序采样器作为变分后验，在训练潜变量模型的期望最大化循环中集成，最近对于离散组合潜变量由 [33] 完成，以及对高维模型参数的贝叶斯后验抽样。理论工作的最重要方向是理解我们研究的所有算法的连续时间极限（ $T \rightarrow \infty$ ）。

最终版本附注：在本作品发表后出现的一篇论文中，Berner 等人 [9] 展示了这里考虑的扩散采样算法族之间的联系，并分析了它们的连续时间极限。

致谢

感谢刘承浩在方法上的帮助，这些方法来自先前的工作，同时感谢 Julius Berner、Victor Elvira、Lorenz Richter、Alexander Tong 和 Siddarth Venkatraman 提供的有益讨论和建议。

作者感谢 UNIQUE、CIFAR、NSERC、Intel、Recursion Pharmaceuticals 和 Samsung 的资金支持。本研究部分得益于加拿大数字研究联盟（Digital Research Alliance of Canada，<https://alliancecan.ca>）、Mila（<https://mila.quebec>）和 NVIDIA 提供的计算资源。M.S.的研究部 2022/45/N/ST6/03374. 分由波兰国家科学中心资助。

参考文献

- [1] Adam, A., Coogan, A., Malkin, N., Legin, R., Perreault-Levasseur, L., Hezaveh, Y., and Bengio, Y. Posterior samples of source galaxies in strong gravitational lenses with score-based priors. *arXiv preprint arXiv:2211.03812*, 2022.

- [2] Agrawal, A. and Domke, J. Amortized variational inference for simple hierarchical models. *Neural Information Processing Systems (NeurIPS)*, 2021.
- [3] Albergo, M. S., Kanwar, G., and Shanahan, P. E. Flow-based generative models for Markov chain Monte Carlo in lattice field theory. *Physical Review D*, 100(3):034515, 2019.
- [4] Atanackovic, L., Tong, A., Wang, B., Lee, L. J., Bengio, Y., and Hartford, J. DynGFN: Towards bayesian inference of gene regulatory networks with GFlowNets. *Neural Information Processing Systems (NeurIPS)*, 2023.
- [5] Bandeira, A. S., Maillard, A., Nickl, R., and Wang, S. On free energy barriers in Gaussian priors and failure of cold start MCMC for high-dimensional unimodal distributions. *Philosophical transactions. Series A, Mathematical, physical, and engineering sciences*, 381, 2022.
- [6] Bengio, E., Jain, M., Korablyov, M., Precup, D., and Bengio, Y. Flow network based generative models for non-iterative diverse candidate generation. *Neural Information Processing Systems (NeurIPS)*, 2021.
- [7] Bengio, Y., Lahlou, S., Deleu, T., Hu, E. J., Tiwari, M., and Bengio, E. GFlowNet foundations. *Journal of Machine Learning Research*, 24(210):1–55, 2023.
- [8] Berner, J., Richter, L., and Ullrich, K. An optimal control perspective on diffusion-based generative modeling. *arXiv preprint arXiv:2211.01364*, 2022.
- [9] Berner, J., Richter, L., Sendera, M., Rector-Brooks, J., and Malkin, N. From discrete-time policies to continuous-time diffusion samplers: Asymptotic equivalences and faster training. *arXiv preprint arXiv:2501.06148*, 2025.
- [10] Buchner, J. Nested sampling methods. *arXiv preprint arXiv:2101.09675*, 2021.
- [11] Burda, Y., Grosse, R. B., and Salakhutdinov, R. Importance weighted autoencoders. *International Conference on Learning Representations (ICLR)*, 2016.
- [12] Chen, T., Liu, G.-H., and Theodorou, E. A. Likelihood training of Schrödinger bridge using forward-backward SDEs theory. *International Conference on Learning Representations (ICLR)*, 2022.
- [13] Chopin, N. A sequential particle filter method for static models. *Biometrika*, 89(3):539–552, 2002.
- [14] Cornish, R., Caterini, A., Deligiannidis, G., and Doucet, A. Relaxing bijectivity constraints with continuously indexed normalising flows. *International Conference on Machine Learning (ICML)*, 2020.
- [15] De Bortoli, V. Convergence of denoising diffusion models under the manifold hypothesis. *Transactions on Machine Learning Research (TMLR)*, 2022.
- [16] Del Moral, P., Doucet, A., and Jasra, A. Sequential Monte Carlo samplers. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 68(3):411–436, 2006.
- [17] Deleu, T., Góis, A., Emezue, C., Rankawat, M., Lacoste-Julien, S., Bauer, S., and Bengio, Y. Bayesian structure learning with generative flow networks. *Uncertainty in Artificial Intelligence (UAI)*, 2022.
- [18] Deleu, T., Nouri, P., Malkin, N., Precup, D., and Bengio, Y. Discrete probabilistic inference as control in multi-path environments. *Uncertainty in Artificial Intelligence (UAI)*, 2024.
- [19] Dinh, L., Sohl-Dickstein, J., and Bengio, S. Density estimation using Real NVP. *International Conference on Learning Representations (ICLR)*, 2017.
- [20] Duane, S., Kennedy, A., Pendleton, B. J., and Roweth, D. Hybrid Monte Carlo. *Physics Letters B*, 195(2):216–222, 1987.
- [21] Föllmer, H. An entropy approach to the time reversal of diffusion processes. pp. 156–163, 1985.

- [22] Gao, C., Isaacson, J., and Krause, C. i-flow: High-dimensional integration and sampling with normalizing flows. *Machine Learning: Science and Technology*, 1(4):045023, 2020.
- [23] Grathwohl, W., Chen, R. T., Bettencourt, J., Sutskever, I., and Duvenaud, D. FFJORD: Free-form continuous dynamics for scalable reversible generative models. *International Conference on Learning Representations (ICLR)*, 2019.
- [24] Grenander, U. and Miller, M. I. Representations of knowledge in complex systems. *Journal of the Royal Statistical Society: Series B (Methodological)*, 56(4):549–581, 1994.
- [25] Halton, J. H. Sequential Monte Carlo. In *Mathematical Proceedings of the Cambridge Philosophical Society*, volume 58, pp. 57–78. Cambridge University Press, 1962.
- [26] Harrison, J., Willes, J., and Snoek, J. Variational Bayesian last layers. *International Conference on Learning Representations (ICLR)*, 2024.
- [27] Hernández-Lobato, J. M. and Adams, R. Probabilistic backpropagation for scalable learning of Bayesian neural networks. *International Conference on Machine Learning (ICML)*, 2015.
- [28] Ho, J., Jain, A., and Abbeel, P. Denoising diffusion probabilistic models. *Neural Information Processing Systems (NeurIPS)*, 2020.
- [29] Hoffman, M., Sountsov, P., Dillon, J. V., Langmore, I., Tran, D., and Vasudevan, S. NeuTra: lizing bad geometry in Hamiltonian Monte Carlo using neural transport. *arXiv preprint arXiv:1903.03704*, 2019.
- [30] Hoffman, M. D., Blei, D. M., Wang, C., and Paisley, J. W. Stochastic variational inference. *Journal of Machine Learning Research (JMLR)*, 14:1303–1347, 2013.
- [31] Hoffman, M. D., Gelman, A., et al. The No-U-Turn sampler: adaptively setting path lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research (JMLR)*, 15(1):1593–1623, 2014.
- [32] Holdijk, L., Du, Y., Hooft, F., Jaini, P., Ensing, B., and Welling, M. Stochastic optimal control for collective variable free sampling of molecular transition paths. *Neural Information Processing Systems (NeurIPS)*, 2023.
- [33] Hu, E. J., Malkin, N., Jain, M., Everett, K., Graikos, A., and Bengio, Y. GFlowNet-EM for learning compositional latent variable models. *International Conference on Machine Learning (ICML)*, 2023.
- [34] Hu, E. J., Jain, M., Elmoznino, E., Kaddar, Y., Lajoie, G., Bengio, Y., and Malkin, N. Amortizing intractable inference in large language models. *International Conference on Learning Representations (ICLR)*, 2024.
- [35] Izmailov, P., Vikram, S., Hoffman, M. D., and Wilson, A. G. What are Bayesian neural network posteriors really like? *International Conference on Machine Learning (ICML)*, 2021.
- [36] Jain, M., Bengio, E., Hernandez-Garcia, A., Rector-Brooks, J., Dossou, B. F., Ekbote, C. A., Fu, J., Zhang, T., Kilgour, M., Zhang, D., et al. Biological sequence design with gflownets. *International Conference on Machine Learning (ICML)*, 2022.
- [37] Jang, H., Kim, M., and Ahn, S. Learning energy decompositions for partial inference of GFlowNets. *International Conference on Learning Representations (ICLR)*, 2024.
- [38] Jing, B., Corso, G., Chang, J., Barzilay, R., and Jaakkola, T. Torsional diffusion for molecular conformer generation. *Neural Information Processing Systems (NeurIPS)*, 2022.
- [39] Kim, M., Ko, J., Zhang, D., Pan, L., Yun, T., Kim, W., Park, J., and Bengio, Y. Learning to scale logits for temperature-conditional GFlowNets. *arXiv preprint arXiv:2310.02823*, 2023.
- [40] Kim, M., Yun, T., Bengio, E., Zhang, D., Bengio, Y., Ahn, S., and Park, J. Local search GFlowNets. *International Conference on Learning Representations (ICLR)*, 2024.

- [41] Kingma, D. P. and Welling, M. Auto-encoding variational Bayes. *International Conference on Learning Representations (ICLR)*, 2014.
- [42] Lahlou, S., Deleu, T., Lemos, P., Zhang, D., Volokhova, A., Hernández-García, A., Ezzine, L. N., Bengio, Y., and Malkin, N. A theory of continuous generative flow networks. *International Conference on Machine Learning (ICML)*, 2023.
- [43] Lemos, P., Malkin, N., Handley, W., Bengio, Y., Hezaveh, Y., and Perreault-Levasseur, L. Improving gradient-guided nested sampling for posterior inference. *arXiv preprint arXiv:2312.03911*, 2023.
- [44] Madan, K., Rector-Brooks, J., Korablyov, M., Bengio, E., Jain, M., Nica, A., Bosc, T., Bengio, Y., and Malkin, N. Learning GFlowNets from partial episodes for improved convergence and stability. *International Conference on Machine Learning (ICML)*, 2022.
- [45] Malkin, N., Jain, M., Bengio, E., Sun, C., and Bengio, Y. Trajectory balance: Improved credit assignment in gflownets. *Neural Information Processing Systems (NeurIPS)*, 2022.
- [46] Malkin, N., Lahlou, S., Deleu, T., Ji, X., Hu, E., Everett, K., Zhang, D., and Bengio, Y. GFlowNets and variational inference. *International Conference on Learning Representations (ICLR)*, 2023.
- [47] Máté, B. and Fleuret, F. Learning interpolations between Boltzmann densities. *Transactions on Machine Learning Research (TMLR)*, 2023.
- [48] Mittal, S., Bracher, N. L., Lajoie, G., Jaini, P., and Brubaker, M. A. Exploring exchangeable dataset amortization for bayesian posterior inference. In *ICML 2023 Workshop on Structured Probabilistic Inference & Generative Modeling*, 2023.
- [49] Møller, J., Syversveen, A., and Waagepetersen, R. Log Gaussian Cox processes. *Scandinavian Journal of Statistics*, 25(3):451–482, 1998. ISSN 0303-6898.
- [50] Nichol, A. and Dhariwal, P. Improved denoising diffusion probabilistic models. *International Conference on Machine Learning (ICML)*, 2021.
- [51] Nicoli, K. A., Nakajima, S., Strodtzoff, N., Samek, W., Müller, K.-R., and Kessel, P. Asymptotically unbiased estimation of physical observables with neural samplers. *Physical Review E*, 101(2):023304, 2020.
- [52] Noé, F., Olsson, S., Köhler, J., and Wu, H. Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning. *Science*, 365(6457):eaaw1147, 2019.
- [53] Nüsken, N. and Richter, L. Solving high-dimensional Hamilton–Jacobi–Bellman PDEs using neural networks: perspectives from the theory of controlled diffusions and measures on path space. *Partial Differential Equations and Applications*, 2(4):48, 2021.
- [54] Øksendal, B. *Stochastic Differential Equations: An Introduction with Applications*. Springer, 2003.
- [55] Pan, L., Malkin, N., Zhang, D., and Bengio, Y. Better training of GFlowNets with local credit and incomplete trajectories. *International Conference on Machine Learning (ICML)*, 2023.
- [56] Pillai, N. S., Stuart, A. M., and Thiéry, A. H. Optimal scaling and diffusion limits for the langevin algorithm in high dimensions. *The Annals of Applied Probability*, 22(6), December 2012.
- [57] Radev, S. T., Mertens, U. K., Voss, A., Ardizzone, L., and Köthe, U. Bayesflow: Learning complex stochastic models with invertible neural networks. *IEEE transactions on neural networks and learning systems*, 33(4):1452–1466, 2020.
- [58] Ranganath, R., Gerrish, S., and Blei, D. Black box variational inference. *Artificial Intelligence and Statistics (AISTATS)*, 2014.

- [59] Rector-Brooks, J., Madan, K., Jain, M., Korablyov, M., Liu, C.-H., Chandar, S., Malkin, N., and Bengio, Y. Thompson sampling for improved exploration in GFlowNets. *arXiv preprint arXiv:2306.17693*, 2023.
- [60] Rezende, D. and Mohamed, S. Variational inference with normalizing flows. *International Conference on Machine Learning (ICML)*, 2015.
- [61] Rezende, D. J., Mohamed, S., and Wierstra, D. Stochastic backpropagation and approximate inference in deep generative models. *International Conference on Machine Learning (ICML)*, 2014.
- [62] Richter, L., Boustati, A., Nüsken, N., Ruiz, F. J. R., and Ömer Deniz Akyildiz. VarGrad: A low-variance gradient estimator for variational inference. *Neural Information Processing Systems (NeurIPS)*, 2020.
- [63] Richter, L., Berner, J., and Liu, G.-H. Improved sampling via learned diffusions. *International Conference on Learning Representations (ICLR)*, 2023.
- [64] Roberts, G. O. and Rosenthal, J. S. Optimal scaling of discrete approximations to langevin diffusions. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 60(1): 255–268, 1998.
- [65] Roberts, G. O. and Tweedie, R. L. Exponential convergence of Langevin distributions and their discrete approximations. *Bernoulli*, pp. 341–363, 1996.
- [66] Rombach, R., Blattmann, A., Lorenz, D., Esser, P., and Ommer, B. High-resolution image synthesis with latent diffusion models. *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [67] Särkkä, S. and Solin, A. *Applied stochastic differential equations*. Cambridge University Press, 2019.
- [68] Shen, M. W., Bengio, E., Hajiramezanali, E., Loukas, A., Cho, K., and Biancalani, T. Towards understanding and improving GFlowNet training. *International Conference on Machine Learning (ICML)*, 2023.
- [69] Skilling, J. Nested sampling for general Bayesian computation. *Bayesian Analysis*, 1(4):833 – 859, 2006. doi: 10.1214/06-BA127. URL <https://doi.org/10.1214/06-BA127>.
- [70] Sohl-Dickstein, J., Weiss, E. A., Maheswaranathan, N., and Ganguli, S. Deep unsupervised learning using nonequilibrium thermodynamics. *International Conference on Machine Learning (ICML)*, 2015.
- [71] Song, Y., Durkan, C., Murray, I., and Ermon, S. Maximum likelihood training of score-based diffusion models. *Neural Information Processing Systems (NeurIPS)*, 2021.
- [72] Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S., and Poole, B. Score-based generative modeling through stochastic differential equations. *International Conference on Learning Representations (ICLR)*, 2021.
- [73] Tiapkin, D., Morozov, N., Naumov, A., and Vetrov, D. Generative flow networks as entropy-regularized RL. *arXiv preprint arXiv:2310.12934*, 2023.
- [74] Tripp, A., Daxberger, E., and Hernández-Lobato, J. M. Sample-efficient optimization in the latent space of deep generative models via weighted retraining. *Neural Information Processing Systems (NeurIPS)*, 2020.
- [75] Tzen, B. and Raginsky, M. Neural stochastic differential equations: Deep latent Gaussian models in the diffusion limit. *arXiv preprint arXiv:1905.09883*, 2019.
- [76] Tzen, B. and Raginsky, M. Theoretical guarantees for sampling and inference in generative models with latent diffusions. *Conference on Learning Theory (CoLT)*, 2019.

- [77] van Krieken, E., Thanapalasingam, T., Tomczak, J., van Harmelen, F., and ten Teije, A. A-NeSI: A scalable approximate method for probabilistic neurosymbolic inference. *Neural Information Processing Systems (NeurIPS)*, 2023.
- [78] Vargas, F., Grathwohl, W., and Doucet, A. Denoising diffusion samplers. *International Conference on Learning Representations (ICLR)*, 2023.
- [79] Vargas, F., Padhy, S., Blessing, D., and Nüsken, N. Transport meets variational inference: Controlled Monte Carlo diffusions. *International Conference on Learning Representations (ICLR)*, 2024.
- [80] Vincent, P. A connection between score matching and denoising autoencoders. *Neural computation*, 23(7):1661–1674, 2011.
- [81] Wu, H., Köhler, J., and Noé, F. Stochastic normalizing flows. *Neural Information Processing Systems (NeurIPS)*, 2020.
- [82] Xiao, Z., Kreis, K., and Vahdat, A. Tackling the generative learning trilemma with denoising diffusion GANs. *International Conference on Learning Representations (ICLR)*, 2022.
- [83] Zhang, D., Malkin, N., Liu, Z., Volokhova, A., Courville, A., and Bengio, Y. Generative flow networks for discrete probabilistic modeling. *International Conference on Machine Learning (ICML)*, 2022.
- [84] Zhang, D., Chen, R. T. Q., Malkin, N., and Bengio, Y. Unifying generative models with GFlowNets and beyond. *arXiv preprint arXiv:2209.02606*, 2023.
- [85] Zhang, D., Rainone, C., Peschl, M., and Bondesan, R. Robust scheduling with GFlowNets. *International Conference on Learning Representations (ICLR)*, 2023.
- [86] Zhang, D., Chen, R. T. Q., Liu, C.-H., Courville, A., and Bengio, Y. Diffusion generative flow samplers: Improving learning signals through partial trajectory optimization. *International Conference on Learning Representations (ICLR)*, 2024.
- [87] Zhang, Q. and Chen, Y. Diffusion normalizing flow. *Neural Information Processing Systems (NeurIPS)*, 2021.
- [88] Zhang, Q. and Chen, Y. Path integral sampler: a stochastic control approach for sampling. *International Conference on Learning Representations (ICLR)*, 2022.
- [89] Zhu, Y., Wu, J., Hu, C., Yan, J., Hsieh, C.-Y., Hou, T., and Wu, J. Sample-efficient multi-objective molecular optimization with GFlowNets. *Neural Information Processing Systems (NeurIPS)*, 2023.
- [90] Zimmermann, H., Lindsten, F., van de Meent, J.-W., and Naesseth, C. A. A variational perspective on generative flow networks. *Transactions on Machine Learning Research (TMLR)*, 2023.

代码与超参数

代码可在 <https://github.com/GFNOrg/gfn-diffusion> 获取，并将继续维护和扩展。

以下是重现部分结果的命令示例，使用 **Manywell** 和 VAE 模型以及 PIS 和 GFlowNet 模型，展示超参数：PIS：

```
--mode_fwd pis --lr_policy 1e-3
```

PIS + Langevin：

```
--mode_fwd pis --lr_policy 1e-3 --langevin
```

GFlowNet TB：

```
python train.py --t_scale 1. --energy many_well --pis_architectures --zero_init --clipping --mode_fwd tb  
--lr_policy 1e-3 --lr_flow 1e-1
```

GFlowNet TB + 探索性：

```
python train.py --t_scale 1. --energy many_well --pis_architectures --zero_init --clipping --mode_fwd tb  
--lr_policy 1e-3 --lr_flow 1e-1 --exploratory --exploration_wd --exploration_factor 0.2
```

GFlowNet VarGrad + 探索性：

```
python train.py --t_scale 1. --energy many_well --pis_architectures --zero_init --clipping --mode_fwd  
tb-avg --lr_policy 1e-3 --lr_flow 1e-1 --exploratory --exploration_wd --exploration_factor 0.2
```

GFlowNet FL-SubTB：

```
python train.py --t_scale 1. --energy many_well --pis_architectures --zero_init --clipping --mode_fwd  
subtb --lr_policy 1e-3 --lr_flow 1e-2 --partial_energy --conditional_flow_model
```

GFlowNet FL-SubTB + LP：

```
python train.py --t_scale 1. --energy many_well --pis_architectures --zero_init --clipping --mode_fwd  
subtb --lr_policy 1e-3 --lr_flow 1e-2 --partial_energy --conditional_flow_model --langevin --epochs  
10000
```

GFlowNet TB + 探索性 + LS：

```
python train.py --t_scale 1. --energy many_well --pis_architectures --zero_init --clipping --mode_fwd tb  
--lr_policy 1e-3 --lr_back 1e-3 --lr_flow 1e-1 --exploratory --exploration_wd --exploration_factor 0.1  
--both_ways --local_search --buffer_size 600000 --prioritized 秩 --rank_weight 0.01 --ld_step 0.1  
--ld_schedule --target_acceptance_rate 0.574
```

GFlowNet TB + 探索性 + LP：

```
python train.py --t_scale 1. --energy many_well --pis_architectures --zero_init --clipping --mode_fwd tb
--lr_policy 1e-3 --lr_flow 1e-1 --exploratory --exploration_wd --exploration_factor 0.2 --langevin
--epochs 10000
```

GFlowNet TB + 探索性 + LS (VAE):

```
python train.py --energy vae --pis_architectures --zero_init --clipping --mode_fwd
cond-tb-avg --mode_bwd cond-tb-avg --repeats 5 --lr_policy 1e-3 --lr_flow 1e-1
--lr_back 1e-3 --exploratory --exploration_wd --exploration_factor 0.1 --both_ways
--local_search --max_iter_ls 500 --burn_in 200 --buffer_size 90000 --prioritized 秩
--rank_weight 0.01 --ld_step 0.001 --ld_schedule --target_acceptance_rate 0.574
```

GFlowNet TB + 探索性 + 长期 + 短期 (VAE):

```
python train.py --energy vae --pis_architectures --zero_init --clipping --mode_fwd
cond-tb-avg --mode_bwd cond-tb-avg --repeats 5 --lr_policy 1e-3 --lr_flow 1e-1
--lgv_clip 1e2 --gfn_clip 1e4 --epochs 10000 --exploratory --exploration_wd
--exploration_factor 0.1 --both_ways --local_search --lr_back 1e-3 --max_iter_ls 500
--burn_in 200 --buffer_size 90000 --prioritized 秩 --rank_weight 0.01 --langevin
--ld_step 0.001 --ld_schedule --target_acceptance_rate 0.574
```

B 目标密度

具有 25 个模式的高斯混合模型 (25GMM)。该模型被称为 25GMM，由一个二维高斯混合模型组成，包含 25 个不同的模式。每个模式展示出相同的方差 0.3。这些模式的中心被战略性地布置在一个由笛卡尔积形成的网格上 $\{-10, -5, 0, 5, 10\} \times \{-10, -5, 0, 5, 10\}$ ，有效地将它们分布在坐标空间中。

漏斗 [29]。漏斗代表了采样技术中的一个经典基准，其特征是一个十维分布，定义如下：第一维度， x_0 ，遵循均值为 $\mathbf{0}$ ，方差为 9 的正态分布，表示为 $x_0 \sim \mathcal{N}(\mathbf{0}, 9)$ 。条件于 x_0 ，其余维度， $x_{1:9}$ ，根据均值向量为 $\mathbf{0}$ ，协方差矩阵为 $\exp(x_0)\mathbf{I}$ 的多元正态分布进行分布，其中 $\mathbf{I}$ 是单位矩阵。这简明地表示为 $x_{1:9} | x_0 \sim \mathcal{N}(\mathbf{0}, \exp(x_0)\mathbf{I})$ 。

多井 [52]。多井的特征是一个 32 维分布，它是由 16 个相同的二维双井分布构成的乘积。这些二维组件中的每一个都由一个潜在函数， $u(x_1, x_2)$ ，定义，表示为 $u(x_1, x_2) = \exp(-x_1^4 + 6x_1^2 + 0.5x_1 - 0.5x_2^2)$ 。

VAE [41]。该任务涉及从一个 20 维的潜在后验分布中采样 $p(z|x) \propto p(z)p(x|z)$ ，其中 $p(z)$ 是一个固定的先验分布，而 $p(x|z)$ 是一个预训练的 VAE 解码器，使用依赖于输入数据（图像）的条件采样器 $q(z|x)$ 。

LGCP [49]。该密度覆盖一个 1600 维变量，是一个拟合到芬兰松树幼苗分布的对数高斯科斯过程。

B.1 过去工作的差异

错误的漏斗密度定义。正如 [78] 所指出的，[88] 在漏斗密度的第一个组件中使用了不同的方差，即 1 而不是 9。这种任务定义中的明显错误已经传播到了后续的工作中，包括 [42]。

对 LGCP 的评估。LGCP 基准由于缺乏一致的地面真实值 $\log Z$ 来进行比较而存在问题。先前的工作将分区函数的值 $\log Z$ 与“序贯蒙特卡洛的长时间运行”[88] 进行了比较。我们注意到，这种方法对于分区函数的估计会产生噪声，尤其是在高维度问题中（实际上，SMC 很少用于超过一千维度的问题）；因此，不清楚需要运行多长时间的 SMC 才能产生准确的估计。我们发现文献中使用了两个不同的值：一个存储库中的 $\log Z = 512.6$ 和另一个存储库中的 $\log Z = 501.8$ 。

关于在 [86] 中使用的 FL-SubTB。我们有两个观察结果，质疑了 [86] 的主要结果。

首先，[86] 使用的算法与过去工作 [42] 之间的唯一实质性区别在于，将 FL-SubTB 目标 [55, 44] 替换为了 TB[45]。然而，[86] 选择将 FL-SubTB 与具有 Langevin 参数化的 Langevin 参数化进行比较，而 TB 没有 Langevin 参数化。我们在表 1 中的结果显示，虽然 Langevin 参数化对于所有目标的性能至关重要；但 FL-SubTB 并没有提供比 TB 或 VarGrad 更一致的优势。

其次，结果无法复现，无论是使用从 [86] 发布的代码运行‘开箱即用’，还是我们的重新实现。特别是在 LGCP 密度上，训练在分配的时间内未能收敛。我们已联系了 [86] 的作者，他们确认运行其发布的代码无法重现论文中的结果，但无法提供进一步的解释或可行的实现。

附录 C 额外的结果

附录 C.1 扩展的无条件采样结果

表 C.1 是表 1 的扩展版本，展示了集合之间的 Wasserstein 距离 $\cdot_K$ 来自真实分布的样本和由训练好的采样器生成的样本。（请注意，LGCP 的真实值不可用。）

表 C.1: 无条件建模任务的 $\log$ 划分函数估计误差和 2-Wasserstein 距离 (5 次运行的平均值和标准差)。这四组模型分别是: 基于 MCMC 的采样器、仿真驱动的变分方法、具有不同学习目标的基线 GFlowNet 方法以及附加 Langevin 参数化和局部搜索的方法。

Energy $\rightarrow$	25GMM ($d = 2$)			Funnel ($d = 10$)			Manywell ($d = 32$)		
Algorithm $\downarrow$ Metric $\rightarrow$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\mathcal{W}_2^2$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\mathcal{W}_2^2$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\mathcal{W}_2^2$
SMC	0.569 $\pm$ 0.010		0.86 $\pm$ 0.10	0.561 $\pm$ 0.801		50.3 $\pm$ 18.9	14.99 $\pm$ 1.078		8.28 $\pm$ 0.32
GGNS [43]	0.016 $\pm$ 0.042		1.19 $\pm$ 0.17	0.033 $\pm$ 0.173		25.6 $\pm$ 4.75	0.292 $\pm$ 0.454		6.51 $\pm$ 0.32
DIS [8]	1.125 $\pm$ 0.056	0.986 $\pm$ 0.011	4.71 $\pm$ 0.06	0.839 $\pm$ 0.169	0.093 $\pm$ 0.038	20.7 $\pm$ 2.1	10.52 $\pm$ 1.02	3.05 $\pm$ 0.46	5.98 $\pm$ 0.46
DDS [78]	1.760 $\pm$ 0.08	0.746 $\pm$ 0.389	7.18 $\pm$ 0.044	0.424 $\pm$ 0.049	0.206 $\pm$ 0.033	29.3 $\pm$ 9.5	7.36 $\pm$ 2.43	0.23 $\pm$ 0.05	5.71 $\pm$ 0.16
PIS [88]	1.769 $\pm$ 0.104	1.274 $\pm$ 0.218	6.37 $\pm$ 0.65	0.534 $\pm$ 0.008	0.262 $\pm$ 0.008	22.0 $\pm$ 4.0	3.85 $\pm$ 0.03	2.69 $\pm$ 0.04	6.15 $\pm$ 0.02
+ LP [88]	1.799 $\pm$ 0.051	0.225 $\pm$ 0.583	7.16 $\pm$ 0.11	0.587 $\pm$ 0.012	0.285 $\pm$ 0.044	22.1 $\pm$ 4.0	13.19 $\pm$ 0.82	0.07 $\pm$ 0.85	6.55 $\pm$ 0.34
TB [42]	1.176 $\pm$ 0.109	1.071 $\pm$ 0.112	4.83 $\pm$ 0.45	0.690 $\pm$ 0.018	0.239 $\pm$ 0.192	22.4 $\pm$ 4.0	4.01 $\pm$ 0.04	2.67 $\pm$ 0.02	6.14 $\pm$ 0.02
TB + Expl. [42]	0.560 $\pm$ 0.302	0.422 $\pm$ 0.320	3.61 $\pm$ 1.41	0.749 $\pm$ 0.015	0.226 $\pm$ 0.138	21.3 $\pm$ 4.0	4.01 $\pm$ 0.05	2.68 $\pm$ 0.06	6.15 $\pm$ 0.02
VarGrad + Expl.	0.615 $\pm$ 0.241	0.487 $\pm$ 0.250	3.89 $\pm$ 0.85	0.642 $\pm$ 0.010	0.250 $\pm$ 0.112	22.1 $\pm$ 4.0	4.01 $\pm$ 0.05	2.69 $\pm$ 0.06	6.15 $\pm$ 0.02
FL-SubTB	1.127 $\pm$ 0.010	1.020 $\pm$ 0.010	4.64 $\pm$ 0.09	0.527 $\pm$ 0.011	0.182 $\pm$ 0.142	22.1 $\pm$ 4.0	3.98 $\pm$ 0.07	2.72 $\pm$ 0.05	6.15 $\pm$ 0.01
+ LP [86]	0.209 $\pm$ 0.025	0.011 $\pm$ 0.024	1.45 $\pm$ 0.29	0.563 $\pm$ 0.021	0.155 $\pm$ 0.317	22.2 $\pm$ 4.0	4.23 $\pm$ 0.12	2.66 $\pm$ 0.22	6.10 $\pm$ 0.02
TB + Expl. + LS (<i>ours</i>)	0.171 $\pm$ 0.013	0.004 $\pm$ 0.011	1.25 $\pm$ 0.18	0.653 $\pm$ 0.025	0.285 $\pm$ 0.099	21.9 $\pm$ 4.0	4.57 $\pm$ 2.13	0.19 $\pm$ 0.29	5.66 $\pm$ 0.05
TB + Expl. + LP (<i>ours</i>)	0.206 $\pm$ 0.018	0.011 $\pm$ 0.010	1.29 $\pm$ 0.07	0.666 $\pm$ 0.615	0.051 $\pm$ 0.616	22.3 $\pm$ 3.9	7.46 $\pm$ 1.74	1.06 $\pm$ 1.11	5.73 $\pm$ 0.31
TB + Expl. + LP + LS (<i>ours</i>)	0.190 $\pm$ 0.013	0.007 $\pm$ 0.011	1.31 $\pm$ 0.07	0.768 $\pm$ 0.052	0.264 $\pm$ 0.063	21.8 $\pm$ 3.9	4.68 $\pm$ 0.49	0.07 $\pm$ 0.17	5.33 $\pm$ 0.03
VarGrad + Expl. + LP + LS (<i>ours</i>)	0.207 $\pm$ 0.016	0.015 $\pm$ 0.015	1.13 $\pm$ 0.13	0.920 $\pm$ 0.118	0.256 $\pm$ 0.037	21.2 $\pm$ 4.0	4.11 $\pm$ 0.45	0.02 $\pm$ 0.21	5.30 $\pm$ 0.02

突出显示: 均值与列中的最小值无法区分 $p < 0.05$ 在单边 Welch 不配对的情况下 t -test.

表 C.2: 32 维 Manywell 上的 $\log$ 划分函数估计误差和经验 2-Wasserstein 距离, 使用 Brownian 和方差保持的噪声过程。

Backward process $\rightarrow$	Brownian			VP		
Objective $\downarrow$ Metric $\rightarrow$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\mathcal{W}_2^2$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\mathcal{W}_2^2$
TB + Expl. + LP	7.46 $\pm$ 1.74	1.06 $\pm$ 1.11	5.73 $\pm$ 0.31	7.55 $\pm$ 2.85	1.49 $\pm$ 1.30	5.68 $\pm$ 0.42
TB + Expl. + LP + LS	4.68 $\pm$ 0.49	0.07 $\pm$ 0.17	5.33 $\pm$ 0.03	4.52 $\pm$ 0.21	1.23 $\pm$ 0.07	5.75 $\pm$ 0.01
VarGrad + Expl.	4.01 $\pm$ 0.05	2.69 $\pm$ 0.06	6.15 $\pm$ 0.02	4.04 $\pm$ 0.05	2.65 $\pm$ 0.08	6.17 $\pm$ 0.02

附录 C.2 方差保持的噪声过程

根据近期的研究结果 [8, 63, 78] 我们进行了一组额外的实验, 采用了不同的成功噪声调度。我们将布朗运动替换为 Song 等人提出的保持方差的随机微分方程。[72], 由奥恩斯坦-乌伦贝克过程给出:

$$\sigma(t) := \nu\sqrt{2\beta(t)}\mathbf{I} \quad \text{and} \quad \mu(x, t) := -\beta(t)x \quad (16)$$

含 $\nu \in (0, \infty)$.

特别是, 我们遵循常见的程序——使用 $\nu := 1$ 和

$$\beta(t) := (1 - t)\beta_{\min} + t\beta_{\max}, \quad t \in [0, 1],$$

含 $\beta_{\min} = 0.01$ 及 $\beta_{\max} = 4.0$.

我们使用这种方差保持的反向过程评估了三种代表性方法。表 C.2 中的结果显示, 与使用布朗桥过程的结果相似。我们预期, 在高维挑战性问题中, 噪声过程的选择变得尤为重要。

C.3 可扩展性研究


Manywell 能量 ($\S$ B) 定义在任何偶数维度上, 从而允许研究方法随维度变化的可扩展性。我们在维度 8、128 和 512 (除了在正文部分研究的 32 维度外) 评估了几种代表性方法。所有实验设置均与 $d = 32$ 相同。由于运行时间较长, 一些在 128 和 512 维度上的运行不得不限制在 12 小时内, 而在 8 和 32 维度上的所有运行都在 RTX8000 GPU 上不到 3 小时内完成。

这些结果展示在表 C.3 中。我们观察到:

- Langevin 参数化带来的开销随维度增加而增长, 但对性能至关重要。
- 如 [86] 所使用的 FL-SubTB 具有更高的开销。
- 我们新提出的局部搜索具有相对较高的效率和较低的开销。

表 C.3: 在 Manywell 上随维度扩展: log-划分函数估计误差及每次训练迭代的时间 (在 RTX8000 GPU 上)。

Dimension →	$d = 8$		$d = 32$		$d = 128$		$d = 512$	
Objective ↓ Metric →	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$
PIS + LP [88]	0.86	0.14	13.19	0.07	58.0	23.7	251	169
TB [42]	0.95	0.70	4.01	2.68	205.6	119.8	1223	957
FL-SubTB + LP [86]	0.57	0.67	4.23	2.66	48.9	21.7	198	107
TB + LP	0.25	0.04	7.46	1.06	46.4	14.0	259	169
TB + LS	0.44	0.00	4.57	0.19	458.7	139.3	1626	1077
TB + LP + LS	0.25	0.02	4.68	0.07	66.6	14.9	326	209



D 实验细节

采样能量。 本节详细说明了实验中使用的超参数。一个重要参数是前向策略的扩散系数，记为 σ ，也在固定后向过程的定义中使用。基础扩散速率 σ^2 (参数 t_{scale}) 对于 25GMM 设定为 5，对于 **Funnel** 和 **Manywell** 设定为 1，与以往工作一致。

对于 LGCP，我们发现使用过小的扩散率 σ^2 (e.g., $\sigma^2 = 1$ 会阻止方法获得合理的结果。我们测试了不同值的 $\sigma^2 = \{1, 3, 5\}$ ，并选择了 $\sigma^2 = 5$ ，这给出了最佳结果，这符合 Zhang & Chen [88] 的研究发现。

在所有实验中，我们使用的学习率为 10^{-3} 。此外，对于流参数化的学习，我们采用了更高的学习率，在使用 TB 损失时设置为 10^{-1} ，而在使用 SubTB 损失时设置为 10^{-2} 。这些设置被发现是一致稳定的（与更高学习率的情况不同），并且能够在分配的迭代次数内收敛（与更低学习率的情况不同）。

对于子结核损失函数，我们实验了以下设置 $10\times$ 作者所传达的流动模型和策略模型均采用较低的学习率 [86] 但发现结果较差，无论是使用他们发布的代码（以及作者未说明的超参数）还是我们的重新实现。对于具有探索性的模型，我们使用探索因子为 0.2（即，在采样训练轨迹时，向策略添加方差为 0.2 的噪声），该探索因子在训练的前半部分线性衰减，与 [42] 我们对所有模型进行 25,000 次迭代训练，而使用 Langevin 动力学的模型则进行 10,000 次迭代训练。由于每次采样步骤中得分计算带来的额外开销，这导致了大致相等的计算时间。

我们使用与一个基线相同的神经网络架构作为 GFlowNet 的架构 [88]。类似于 [88]，我们在训练开始时也使用了一种初始化方案，即将最后一层权重设为 0。由于 SubTB 需要流函数根据当前状态 $\mathbf{x}_t$ 和时间 t 进行条件化，我们遵循 [86] 的做法，并使用与 Langevin 缩放模型 NN2 在 [88] 中相同的架构来参数化流模型。此外，我们还对网络的输出以及从能量函数获得的得分进行了裁剪，通常将 Langevin 缩放模型的裁剪参数设置为 10^2 ，将策略网络的裁剪参数设置为 10^4 ，这与 [78] 类似：

$$f_{\theta}(k, x) = \text{clip}\left(\text{NN}_1(k, x; \theta) + \text{NN}_2(k; \theta) \odot \text{clip}(\nabla \ln \pi(x), -10^2, 10^2), -10^4, 10^4\right). \quad (17)$$

所有模型均使用批大小为 300 进行训练。在每个实验中，除非另有明确说明，否则我们都在单个 NVIDIA A100-Large GPU 上训练模型。

变分自编码器实验。 在变分自编码器实验中，本文使用了一个在 MNIST 数据集上预训练了 100 个训练轮次的标准变分自编码器模型。编码器 $q(z|x)$ 包含一个输入线性层（784 个神经元），接着是一个隐藏线性层（400 个神经元），修正线性单元激活函数，以及两个线性头（每个 20 个神经元）。这两个线性头的输出被重新参数化为多元正态分布的均值和尺度。解码器由 20 维输入组成，随后是一个隐藏层（400 个神经元），接着是修正线性单元激活函数，最后是 784 维输出。输出通过 Sigmoid 函数处理，以适当地进行缩放。[0, 1] 目标是在给定条件下进行采样 x 潜在的 z 来自未归一化的密度 $p(z, x) = p(z)p(x|z)$ （其中 $p(z)$ 是先验分布和 $p(x|z)$ 是从解码器计算出的可能性），其中

与后验 $p(z|x)$ 成比例。我们复用了无条件采样实验中的模型架构，但同时也将 x 作为表达策略漂移（以及对于 FL-SubTB 的流）的第一层输入，并添加了一个隐藏层来处理高维条件。对于使用 TB 训练的模型， $\log Z_\theta$ 也变成了一个多层感知机，接收 x 作为输入。

VarGrad 和 LS 技术在条件设置下需要调整。对于 LS，缓冲区（ $\mathcal{D}_{\text{buffer}}$ 和 $\mathcal{D}_{\text{LS}}$ ）必须存储与样本 z 相关的条件 x 以及相应的非归一化密度 $R(z;x)$, *i.e.*，即一个包含 $(x, z, R(z;x))$ 的元组。对于 VarGrad，由于分区函数依赖于条件信息 x ，有必要计算具有相同条件的多条轨迹上的方差。我们选择对出现在小批量中的每个条件采样 10 条轨迹，并为每组 10 条轨迹计算 VarGrad 损失。

VAE 模型是在整个 MNIST 训练集上进行训练的，并且从未在 MNIST 的测试部分上更新。为了在一个独特的示例集上评估采样器（相对于变分下界），我们选择了 MNIST 测试数据的前 100 个元素。所有采样器都在访问 MNIST 训练数据和冻结的 VAE 解码器的情况下进行训练。为了公平比较，利用 LP 的采样器训练了 10,000 次迭代，而其余的则训练了 25,000 次迭代。在每次迭代中，都会提供来自 MNIST 的 300 个示例作为条件。在每个实验中，除非另有明确说明，否则我们在单个 NVIDIA A100-Large GPU 上训练模型。




图 D.1：我们的采样器（VarGrad + Expl. + LP）由从未见过的数据子集条件化，这些数据来自真实分布（左）。条件样本随后由固定的 VAE 解码（中）。为了进行比较，我们展示了 VAE 对真实数据的重建（右）。我们观察到，解码后的样本在视觉上与重建非常相似，使得这两张图片几乎无法区分。解码样本和重建都比真实数据更模糊，这是由于 VAE 潜空间容量有限所致。

E 基于局部搜索引导的 GFlowNet

优先级采样方案。我们可以使用均匀或优先级采样从缓冲区中抽取样本进行训练。我们在实验中发现优先级采样略胜一筹（参见消融实验 § E.2），尽管这一选择应在未来工作中进一步研究。

我们使用基于秩的优先优化 [74]，其遵循定义如下概率方法：

$$p(\mathbf{x}; \mathcal{D}_{\text{buffer}}) \propto (k|\mathcal{D}_{\text{buffer}}| + \text{rank}_{\mathcal{D}_{\text{buffer}}}(\mathbf{x}))^{-1}, \quad (18)$$

其中 $\text{rank}_{\mathcal{D}_{\text{buffer}}}(\mathbf{x})$ 表示基于排序函数 $R(\mathbf{x})$ 的样本 $\mathbf{x}$ 的相对秩（在我们的案例中，即样本 $\mathbf{x}$ 处未归一化的目标密度）。参数 k 是优先级的超参数，较低的 k 值会赋予较高秩的样本更高的概率，从而引入一种更贪婪的选择方法。我们为每个任务设置 $k = 0.01$ 。由于采样与 $|\mathcal{D}_{\text{buffer}}|$ 的大小成正比，我们对缓冲区的最大尺寸施加约束： $|\mathcal{D}_{\text{buffer}}| = 600,000$ ，并为每个任务采用先进先出（FIFO）的数据结构，除了 VAE 任务使用 $|\mathcal{D}_{\text{buffer}}| = 90,000$ 。请参见下述算法的详细伪代码。

Algorithm 1 GFlowNet Training with Local search

```

1: Initialize policy parameters  $\theta$  for  $P_F$ , and empty buffers  $\mathcal{D}_{\text{buffer}}, \mathcal{D}_{\text{LS}}$ 
2: for  $i = 1, 2, \dots, I$  do
3:   if  $i \% 2 == 0$  then
4:     Sample  $M$  trajectories  $\{\tau_1, \dots, \tau_M\} \sim P_F(\cdot | \epsilon\text{-greedy})$ 
5:     Update  $\mathcal{D}_{\text{buffer}} \leftarrow \mathcal{D}_{\text{buffer}} \cup \{x | \tau \rightarrow x\}$ 
6:     Minimize  $L(\tau; \theta)$  using  $\{\tau_1, \dots, \tau_M\}$  to update  $P_F$ 
7:   else
8:     if  $i \% 100 == 0$  then
9:       Sample  $\{x_1, \dots, x_M\} \sim \mathcal{D}_{\text{buffer}}$ 
10:       $\mathcal{D}_{\text{LS}} \leftarrow \text{Local Search}(\{x_1, \dots, x_M\}; \mathcal{D}_{\text{LS}})$ 
11:    end if
12:    Sample  $\{x'_1, \dots, x'_M\} \sim p_{\text{buffer}}(\dots; \mathcal{D}_{\text{LS}})$ 
13:    Sample  $\{\tau'_1, \dots, \tau'_M\} \sim P_B(\dots | x')$ 
14:    Minimize  $L(\tau'; \theta)$  using  $\{\tau'_1, \dots, \tau'_M\}$  to update  $P_F$ 
15:  end if
16: end for

```

我们使用每个任务的总迭代次数 $I = 25,000$ 作为默认值。请注意，局部搜索执行更新 $\mathcal{D}_{\text{LS}}$ 偶尔每 100 次迭代，局部搜索更新的数量是 $\text{done } 25,000/100 = 250$ 。

E.1 局部搜索算法 本节描述了详细的局部搜索算法，该算法提供了一个包含低能量样本的更新缓冲区 $\mathcal{D}_{\text{LS}}$ 。

步长的动态调整 n . 为了通过并行 MALA 增强局部搜索，我们动态选择 Langevin 步长 (η)，该步长决定了 MH 接受率。我们的目标是达到平均接受率为 0.574，这是理论上对于高维 MALA 效率最优的值 [56]。尽管用户可以自定义目标接受率，但自适应方法消除了手动调参的需求。

局部搜索的计算成本 局部搜索的计算成本并不显著。迭代 $K = 200$ 的局部搜索需要 6.04 秒（在 Manywell 上进行了五次试验并取平均值），其中我们仅偶尔（每 100 次迭代一次）使用 MALA 更新 $\mathcal{D}_{\text{LS}}$ 。速度评估使用了 Intel Xeon 可扩展 Gold 6338 CPU (2.00GHz) 和 NVIDIA RTX 4090 GPU 的计算资源。

Algorithm 2 Local search (Parallel MALA)

input Initial states $\{x_1^{(0)}, \dots, x_M^{(0)}\}$, current buffer $\mathcal{D}_{\text{LS}}$, total steps K , burn in steps $K_{\text{burn-in}}$, initial step size η_0 , amplifying factor f_{increase} , damping factor f_{decrease} , unnormalized target density R

output Updated buffer $\mathcal{D}_{\text{LS}}$

Initialize acceptance counter $a = 0$

Set $\eta \leftarrow \eta_0$

for $k = 1 : K$ **do**

 Initialize step acceptance count $a_k = 0$

for $m = 1 : M$ **do**

 Sample $\sigma \sim \mathcal{N}(0, I)$

 Propose $x_m^* \leftarrow x_m^{(k-1)} + \eta \nabla \log R(x_m^{(k-1)}) + \sqrt{2\eta} \sigma$

 Compute acceptance ratio $r \leftarrow \min \left(1, \frac{R(x_m^*) \exp \left(-\frac{1}{4\eta} \|x_m^{(k-1)} - x_m^* - \eta \nabla \log R(x_m^*)\|^2 \right)}{R(x_m^{(k-1)}) \exp \left(-\frac{1}{4\eta} \|x_m^* - x_m^{(k-1)} - \eta \nabla \log R(x_m^{(k-1)})\|^2 \right)} \right)$

 With probability r , accept the proposal: $x_m^{(k)} \leftarrow x_m^*$ and increment $a_k \leftarrow a_k + 1$

if $k > K_{\text{burn-in}}$ **then**

 Update buffer: $\mathcal{D}_{\text{LS}} \leftarrow \mathcal{D}_{\text{LS}} \cup \{x_m^*\}$

end if

end for

 Compute step acceptance rate $\alpha_k = a_k / M$

if $\alpha_k > \alpha_{\text{target}}$ **then**

$\eta \leftarrow \eta \times f_{\text{increase}}$

else if $\alpha_k < \alpha_{\text{target}}$ **then**

$\eta \leftarrow \eta \times f_{\text{decrease}}$

end if

end for

我们采用默认参数： $f_{\text{increase}} = 1.1$, $f_{\text{decrease}} = 0.9$, $\eta_0 = 0.01$, $K = 200$, $K_{\text{burn-in}} = 100$

$K = 500$, $K_{\text{burn-in}} = 200$ ，以及对于三项无条件任务的 $\alpha_{\text{target}} = 0.574$ 。对于 VAE 的有条件任务，我们给予更多的局部搜索迭代次数：值得

注意的是，在计算 Metropolis-Hastings 接受比率 r 时，通过将逆温度 β 调整到 R^β ，我们可以促进一种更贪婪的局部搜索策略，旨在探索能量更低（即密度更高 p_{target} ）的样本。这种方法对于导航高维且陡峭的景观特别有利，这些景观通常难以找到低能量样本。对于无条件任务，我们设置 $\beta = 1$ 。

在 VAE 任务（表 2）的背景下，我们使用两个 GFlowNet 损失函数：TB 和 VarGrad。对于 TB 中的局部搜索，我们设置 $\beta = 1$ ，而对于 VarGrad，我们采用 $\beta = 5$ 。如表 2 所示，使用局部搜索与 $\beta = 1$ 未能提升 TB 方法的性能。相反，使用局部搜索与 $\beta = 5$ 在 $\log \hat{Z}^{\text{RW}}$ 度量上对 VarGrad + Expl. + LP 产生了改进，即使 VarGrad + Expl. + LP 的性能远超 TB。这强调了选择适当的 β 值的重要性，这对于优化探索-开发平衡至关重要，取决于目标。

E.2 局部搜索引导的 GFlowNets 的消融实验

增加缓冲区容量。 重放缓冲区的容量影响其保留过去经验的时间长度，使其能够将这些经验重新播放给策略。这种机制有助于在训练过程中防止模式崩塌。表 E.1 表明，提高缓冲区的容量可以改善采样质量。此外，图 1 说明，增加缓冲区的容量——从而鼓励模型回忆过去的低能量经验——增强了其寻找模式的能力。

表 E.1: 比较在 Manywell 中使用不同重放缓冲区容量训练的每个采样器的采样质量。进行了五次独立运行，并报告了均值和标准差。

Buffer Capacity ↓ Metric →	$\Delta \log Z$	$\Delta \log Z^{\text{RW}}$	$\mathcal{W}_2^2$
30,000	4.41 ± 0.10	2.73 ± 0.15	6.17 ± 0.02
60,000	4.06 ± 0.05	2.38 ± 0.38	6.14 ± 0.04
600,000	4.57 ± 2.13	0.19 ± 0.29	5.66 ± 0.05




图 E.1: 展示使用不同容量的重放缓冲区训练的每个采样器，描绘了 2,000 个样本。随着缓冲区容量的增加，采样器捕获的模式数量也增加。

优先级的优势。

秩优先级采样与无优先级（均匀采样）相比，具有更快的收敛速度，如图 E.2a 所示。

动态调整 η 与固定 $\eta = 0.01$ ，如图 E.2b 所示，针对目标接受率的动态调整 $\alpha_{\text{target}} = 0.574$ 比固定 Langevin 步长大小的 η 表现更好，展示了动态调整的有效性。




图 E.2: 优先级回放缓冲区和步长的消融实验 η 局部搜索的调度。基于五次独立运行的结果，绘制了均值和标准差。

NeurIPS 论文检查清单

1. 声称

问题：摘要和引言中提出的主声称是否准确反映了论文的贡献和范围？答案：[是] 解释：请参阅理论和实验部分。指南：

- 答案 NA 意味着摘要和引言中不包含论文中提出的声称。
- 摘要和/或引言应明确陈述所提出的声称，包括论文中的贡献以及重要的假设和局限性。对这个问题的回答为否或 NA 将不会被审稿人看好。
- 提出的声称应与理论和实验结果相匹配，并反映结果在其他设置下可以预期的泛化程度。
- 只要明确这些目标并未在论文中实现，包含作为动机的远大目标是可以的。

2. 局限性

问题：论文是否讨论了作者所做工作的局限性？答案：[是] 解释：是的，请参见第 5.3 节和结论部分，以及相关附录材料的引用。指南：

- 答案“NA”意味着论文没有局限性，而答案“否”则表示论文存在局限性，但这些局限性在论文中未被讨论。
- 鼓励作者在其论文中创建一个单独的“局限性”部分。
- 论文应指出任何强假设及其结果对违反这些假设的鲁棒性（例如，独立性假设、无噪声设置、模型良好规范、仅局部有效的渐近逼近）。作者应反思这些假设在实践中可能如何被违反以及其启示。
- 作者应反思所提出的主张的范围，例如，如果方法仅在一个有限的数据集上进行了测试或进行了几次运行。一般来说，实证结果往往依赖于隐含假设，这些假设应该被明确表述。
- 作者应反思影响方法性能的因素。例如，面部识别算法在图像分辨率低或在低光照条件下拍摄的图像时表现不佳。或者语音转文字系统可能无法可靠地为在线讲座提供字幕，因为它无法处理技术术语。
- 作者应讨论所提出的算法的计算效率及其随数据集大小扩展的情况。
- 如适用，作者应讨论其方法在解决隐私和公平性问题方面的可能局限性。
- 尽管作者可能会担心完全坦诚地讨论局限性会被审稿人作为拒绝的理由，但更糟糕的结果可能是审稿人发现论文中未承认的局限性。作者应运用自己的判断力，并认识到支持透明度的个人行动在维护社区诚信方面发挥着重要作用。审稿人将特别指示不要因局限性的坦诚而处罚。

3. 理论假设与证明

问题：对于每个理论结果，论文是否提供了完整的假设集和完整的（正确的）证明？答案：[NA]

理由：没有新的理论结果。为了阐述算法的数学基础，我们陈述了假设。指南：

- 答案 NA 意味着论文不包含理论结果。• 论文中的所有定理、公式和证明都应编号并交叉引用。
- 所有假设应在任何定理的陈述中明确说明或引用。
- 证明可以出现在主论文或补充材料中，但如果它们出现在补充材料中，鼓励作者提供简短的证明概要以提供直觉。
- 反之，在论文主体中提供的任何非正式证明都应通过附录或补充材料中的正式证明来补充。
- 证明所依赖的定理和引理应当引用。

4. 实验结果可重复性

问题：论文是否充分披露了所有必要的信息，以便能够重复论文的主要实验结果，从而影响论文的主要主张和/或结论（无论是否提供了代码和数据）？ 答案：[是] 理由：请参阅实验部分及对附录材料的引用。 指南：

• 答案 NA 表示论文不包含实验。• 如果论文包含实验，对这个问题回答否将不会被审稿人看好：无论是否提供代码和数据，使论文可复现都是重要的。• 如果贡献是一个数据集和/或模型，作者应描述他们采取的步骤以使其结果可复现或可验证。• 根据不同的贡献，可复现性可以通过多种方式实现。例如，如果贡献是一种新颖的架构，全面描述该架构可能就足够了；如果贡献是一个特定模型及其经验评估，则可能需要让其他人能够使用相同的数据库复制该模型，或者提供访问该模型的方法。一般来说，发布代码和数据通常是实现这一目标的好方法之一，但也可通过详细说明如何复制结果、提供托管模型的访问（例如，在大语言模型的情况下）、发布模型检查点或其他适合所进行研究的方法来提供可复现性。• 尽管 NeurIPS 不要求发布代码，但会议要求所有提交的论文提供某种合理的可复现途径，这取决于贡献的性质。例如 (a) 如果贡献主要是新算法，论文应明确说明如何复现该算法。(b) 如果贡献主要是新模型架构，论文应清晰全面地描述该架构。(c) 如果贡献是一个新模型（例如，一个大语言模型），则应有访问该模型以复现结果的方法，或者有复现该模型的方法（例如，使用开源数据集或构建数据集的说明）。(d) 我们认识到在某些情况下可复现性可能会比较棘手，在这种情况下，作者可以描述他们提供的具体可复现方式。对于闭源模型，可能模型的访问受到限制（例如，仅限注册用户），但其他研究人员应该有可能通过某种途径复现或验证结果。5. 数据和代码的开放访问 问题：论文是否提供了开放访问的数据和代码，并附有充分的说明以忠实再现主要实验结果，如补充材料所述？

答案：[是] 理由：我们提供了几乎可以重现所有实验结果的代码。

指南：

- 答案 NA 表示论文不包含需要代码的实验。• 请参阅 NeurIPS 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>) 以获取更多详细信息。• 尽管我们鼓励发布代码和数据，但我们理解这可能无法实现，因此“否”是一个可接受的答案。除非贡献的核心部分（例如，新的开源基准）需要代码，否则不能仅因未包含代码而拒绝论文。• 说明应包含运行以重现结果的确切命令和环境。请参阅 NeurIPS 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>) 以获取更多详细信息。• 作者应提供有关数据访问和准备的说明，包括如何访问原始数据、预处理数据、中间数据和生成的数据等。• 作者应提供脚本以重现新提出的算法和基线的所有实验结果。如果只有部分实验可复现，他们应说明哪些实验被省略以及原因。• 提交时，为了保持匿名性，作者应发布匿名版本（如适用）。• 建议在补充材料（附加到论文中）中尽可能多地提供信息，但允许包含指向数据和代码的 URL。

6. 实验设置/细节

问题：论文是否指定了所有训练和测试细节（例如，数据划分、超参数、它们是如何选择的、优化器类型等）以理解结果？

答案：[是] 理由：请参见实验部分和对附录材料的引用。

指南：

- 答案 NA 表示论文不包含实验。
- 实验设置应在论文的核心部分详细呈现，以便读者理解结果并对其有充分的认识。
- 完整的细节可以通过代码、附录或补充材料提供。

7. 实验统计显著性

问题：论文是否适当地报告了误差棒或其他关于实验统计显著性的适当信息，并且定义正确？

答案：[是] 理由：所有结果表格和图表均显示标准差，并指出了最佳度量的显著性。

指南：

- 答案 NA 意味着论文不包含实验。• 如果结果伴随有误差棒、置信区间或统计显著性检验，至少对于支持论文主要论点的实验，作者应回答“是”。
- 误差棒所捕获的变化因素应明确说明（例如，训练/测试分割、初始化、某些参数的随机抽取，或在给定实验条件下进行的整体运行）。
- 计算误差棒的方法应予以解释（封闭形式公式、调用库函数、自助法等）。
- 应明确给出所作假设（例如，误差呈正态分布）。

- 应清楚说明误差棒是标准差还是均值的标准误。
- 报告一倍标准差误差棒是可以的，但应明确说明。如果未验证误差正态性的假设，作者最好报告两倍标准差误差棒，而不是声明具有 96% 置信区间。
- 对于非对称分布，作者在表格或图形中展示对称误差棒时应谨慎，以免得出超出范围的结果（例如负误差率）。
- 如果在表格或图中报告了误差棒，作者应在文本中解释其计算方法，并在文本中引用相应的图或表。

8. 实验计算资源

问题：对于每个实验，论文是否提供了足够的信息来复现所需的计算资源（计算节点类型、内存、执行时间）？

回答：[是] 正当理由：参见实验部分及附录材料引用。

指南：

- 答案 NA 表示论文不包含实验。
- 论文应指明计算节点类型（CPU 或 GPU、内部集群或云服务提供商），包括相关内存和存储。
- 论文应提供每个单独实验运行所需的计算量，并估算总计算量。
- 论文应披露整个研究项目是否需要比论文中报告的实验更多的计算资源（例如，未进入论文的初步或失败实验）。

9. 职业道德准则

问题：本文中的研究是否在各个方面都符合 NeurIPS 职业道德准则？ <https://neurips.cc/public/EthicsGuidelines>

答案：[是] 理由：我们认为没有违反职业道德准则的行为。

指南：

- 答案为“不适用”意味着作者未审查 NeurIPS 职业道德准则。
- 如果作者回答“否”，他们应解释需要偏离职业道德准则的特殊情况。
- 作者应确保匿名性（例如，如果由于其所在地区的法律或规定有特殊考虑）。

10. 更广泛影响

问题：本文是否讨论了所进行工作的潜在积极社会影响和消极社会影响？

答案：[不适用] 理由：本文研究了一个没有直接社会影响的机器学习问题。

指南：

- 答案 NA 意味着该工作对社会没有影响。
- 如果作者回答 NA 或 No，他们应解释其工作为何对社会没有影响，或者论文为何未涉及社会影响。
- 社会影响的负面例子包括潜在的恶意或意外用途（例如，传播虚假信息、生成虚假个人资料、监控），公平性考虑（例如，部署可能不公平地影响特定群体的技术），隐私考虑以及安全考虑。

- 大会预期许多论文将是基础研究，并不与特定应用相关，更不用说部署了。然而，如果存在直接通往任何负面应用的路径，作者应该指出这一点。例如，指出改进生成模型的质量可能会被用于制作深度伪造视频来传播虚假信息是合理的。另一方面，不需要指出一个通用的优化神经网络的算法能够使人们更快地训练生成深度伪造视频的模型。
- 作者应考虑技术按预期使用且正常运行时可能出现的危害，技术按预期使用但产生错误结果时可能出现的危害，以及由于技术的故意或无意误用而产生的危害。
- 如果存在负面的社会影响，作者还可以讨论可能的缓解策略（例如，限制模型的发布，提供防御措施而非仅攻击手段，监控误用的机制，监控系统如何随着时间从反馈中学习的机制，提高机器学习的效率和可访问性）。

11. 防护措施

问题：论文是否描述了为负责任地发布具有高误用风险的数据或模型（例如，预训练的语音模型、图像生成器或抓取的数据集）而采取的防护措施？

答案：[NA] 原因：据我们所知，本文研究的机器学习问题没有直接应用于生成新图像或文本内容，或其他可能被滥用的功能。

指南：

- 答案 NA 表示该论文不涉及此类风险。
- 对于存在高误用或双重用途风险的已发布模型，应采取必要的安全措施来允许对模型进行受控使用，例如要求用户遵守使用指南或限制访问模型，或者实施安全过滤器。
- 从互联网抓取的数据集可能带来安全风险。作者应说明他们如何避免发布不安全的图像。
- 我们认识到提供有效防护措施具有挑战性，并且许多论文并不需要这样做，但我们鼓励作者考虑这一点并尽最大努力处理。

12. 现有资产的许可证 问题：论文中使用的资产（例如代码、数据、模型）的创作者或原始所有者是否得到了适当的署名？许可证及使用条款是否明确提及并得到适当尊重？

回答：[是] 理由：我们引用了所有研究数据集的原始作品。

指南：

- 答案 NA 表示该论文未使用现有资源。
- 作者应引用生成代码包或数据集的原始论文。
- 作者应说明所使用的资源版本，并尽可能包含 URL。
- 每个资源的许可证名称（例如，CC-BY 4.0）应被包括。
- 对于从特定来源（例如网站）抓取的数据，应提供该来源的版权和使用条款。
- 如果资源已发布，应在包中提供许可证、版权信息和使用条款。对于流行的数据集，paperswithcode.com/datasets 已整理了一些数据集的许可证。他们的许可指南可以帮助确定数据集的许可证。

- 对于重新打包的现有数据集，应提供原始许可证以及衍生资产的许可证（如果已更改）。
- 若此信息无法在线获取，作者被鼓励联系资产的创建者。

13. 新资产

问题：论文中新引入的资产是否得到了充分的文档记录，并且这些文档是否与资产一同提供？答案：[NA] 理由：没有新资产。指南：

- 答案 NA 表示论文未发布新资产。
- 研究人员应通过结构化模板在提交时沟通数据集/代码/模型的详细信息。这包括关于训练、许可证、局限性等的细节。
- 论文应讨论是否以及如何从使用其资产的人那里获得同意。
- 提交时，请记得匿名您的资产（如果适用）。您可以创建一个匿名的 URL 或包含一个匿名的 zip 文件。

14. 众包和人类受试者研究

问题：对于众包实验和涉及人类受试者的研究，论文是否包含了提供给参与者的完整指令文本和截图（如有），以及有关补偿（如有）的详细信息？答案：[NA] 理由：没有人类研究。指南：

- 答案 NA 表示论文不涉及众包或人类受试者的研究。• 将此信息包含在补充材料中是可以的，但如果论文的主要贡献涉及人类受试者，则应在主文中尽可能多地包含详细信息。
- 根据 NeurIPS 伦理准则，参与数据收集、整理或其他劳动的人员应至少获得数据收集者所在国家的最低工资。

15. 人类研究的机构审查委员会（IRB）批准或等效审批

受试者 问题：论文是否描述了研究参与者可能面临的风险，这些风险是否已告知受试者，以及是否获得了机构审查委员会（IRB）的批准（或基于您所在国家或机构要求的等效审批/审查）？答案：[NA] 解释：没有涉及人类研究。指南：

- 答案 NA 表示论文不涉及众包或人类受试者的研究。
- 根据研究进行的国家，任何涉及人类受试者的研究可能需要 IRB 批准（或等效审批）。如果获得了 IRB 批准，应在论文中明确说明。
- 我们认识到，这一程序可能因机构和地点而有很大差异，我们期望作者遵守 NeurIPS 伦理准则及其机构的指导方针。
- 对于初始提交，不要包含任何会破坏匿名性的信息（如适用），例如进行审查的机构名称。