

生成增强流网络

Ling Pan^{1*} Dinghuai Zhang¹ Aaron Courville¹ Longbo Huang² Yoshua Bengio¹

¹Mila, Université de Montréal ²Tsinghua University

摘要

生成流网络 (Bengio 等人, 2021b, GFlowNet) 是一种概率框架, 在该框架中, 智能体学习一个随机策略来生成对象, 使得生成对象的概率与给定的奖励函数成正比。相比于基于强化学习的奖励最大化方法, 其有效性已在发现高质量和多样化的解决方案方面得到证明。然而, GFlowNets 仅从终端状态的奖励中学习, 这可能限制其应用范围。实际上, 中间奖励在学习中起着关键作用, 例如通过内在动机提供中间反馈, 即使在特别具有挑战性的稀疏奖励任务中也是如此。受此启发, 我们提出了生成增强流网络 (GAFlowNets), 这是一种新型的学习框架, 旨在将中间奖励纳入 GFlowNets。我们通过内在动机指定中间奖励, 以解决稀疏奖励环境中的探索问题。GAFlowNets 可以结合边基和状态基的内在奖励, 以提高探索效率。基于 GridWorld 任务上的广泛实验, 我们展示了 GAFlowNet 在收敛性、性能和解决方案多样性方面的有效性和效率。我们进一步表明, GAFlowNet 可扩展到更复杂和大规模的分子生成领域, 在该领域中它实现了持续且显著的性能改进。

1 引言

深度强化学习 (RL) 近年来在游戏领域取得了显著进展 (Mnih 等, 2015 年; Silver 等, 2016 年; Vinyals 等, 2019 年)。在仅在结束时给予奖励 (即终端状态) 的情况下应用 RL 方法通常旨在最大化该奖励函数以学习最优策略。然而, 在包括分子生成 (Bengio 等, 2021a)、生物序列设计 (Jain 等, 2022b)、推荐系统 (Kunaver 和 Požrl, 2017)、对话系统 (Zhang 等, 2020) 等在内的广泛实用场景中, 生成状态的多样性是可取的。例如, 在分子生成中, 用于计算仿真的奖励函数本身可能是不确定和不完美的 (与更昂贵的体内实验相比)。因此, 仅仅搜索最大化回报的解决方案是不够的。相反, 我们希望采样许多高回报候选对象, 这可以通过按每个终端状态的回报比例进行采样来实现。有趣的是, GFlowNets (Bengio 等, 2021a,b) 学习了一个随机策略, 以与回报成比例的概率采样复合对象 $\mathbf{x} \in \mathcal{X}$ 。GFlowNets 的学习范式与其他 RL 方法不同, 因为它明确地旨在建模目标分布中的多样性, 即奖励函数的所有模式。这使得它自然适用于模型应发现既有趣又多样化的对象的实际应用, 这是之前 GFlowNet 研究的重点 (Bengio 等, 2021a,b; Jain 等, 2022b; Malkin 等, 2022)。

$R(\mathbf{x})$ * penny.ling.pan@gmail.com

然而，GFlowNets 仅从终止状态的奖励中学习，并不考虑中间奖励，这可能限制其适用性，尤其是在更一般的强化学习设置中。奖励在学习过程中扮演着关键角色（Silver 等，2021）。强化学习的巨大成功很大程度上依赖于提供中间反馈的奖励信号。即使在稀疏奖励环境中，通过内在动机，强化学习代理也能激励自己进行高效的探索，在每一步都增加一个密集的内在奖励来补充稀疏的外在学习信号。本文的重点正是引入这样的中间内在奖励到 GFlowNets 中，因为它们可以在外在奖励稀疏的情况下应用（比如只有少数终止状态有非零奖励）。受到 GFlowNets 这一缺失元素的启发，我们提出了一种新的 GFlowNet 学习框架，该框架考虑中间反馈信号，以在训练期间提供探索激励。GFlowNets 中的流概念（Bengio 等，2021a,b）指的是一个边缘化的量，它将给定状态的所有下游终止状态的奖励相加，同时与其他导向相同终止状态的状态共享这些奖励。除了网络中已有的流之外，我们还引入了作为中间奖励的增强流。我们的新框架通过将内在动机视为中间奖励，非常适合处理稀疏奖励任务，因为在这种情况下，GFlowNet 的训练可能会陷入几种模式，因为它可能难以基于已访问过的模式发现新模式（Bengio 等，2021b）。我们首先提出了基于边的增强流，即在每次转换中加入内在奖励。然而，我们发现虽然这提高了学习效率，但它仅进行了局部探索，仍然缺乏足够的探索能力，无法驱动代理访问具有零奖励的解决方案。另一方面，我们发现以基于状态的方式纳入中间奖励（Bengio 等，2021b）可以导致收敛速度变慢和经验上的大偏差，尽管它可以进行更广泛的探索。因此，我们提出了一种结合基于边和基于状态的增强流的方法。我们的方法可以通过取两者之长来提高解决方案的多样性和学习效率。在已经用于基准测试 GFlowNets 的 GridWorld 和分子领域进行的广泛实验验证了我们提出的框架的有效性。本文的主要贡献总结如下：

- 本文提出了一种新颖的 GFlowNet 学习框架，称为生成增强流网络（GAFlowNet），以整合中间奖励，这些奖励通过流网络中的增强流来表示。
- 我们通过内在动机来规定中间奖励，以处理 GFlowNets 在稀疏奖励任务中的状态空间探索问题。我们从理论上证明，我们的增强目标在渐近情况下能够给出原始公式的一个无偏解。
- 我们在 GridWorld 领域进行了广泛的实验，展示了我们的方法在收敛性、多样性和性能方面的有效性。我们的方法具有通用性，适用于不同类型的 GFlowNets。我们进一步将该方法扩展到更大规模和更具挑战性的分子生成任务，在此任务中，我们的方法相对于强基线取得了持续且显著的改进。

2 背景

考虑一个有向无环图（DAG） $G = (\mathcal{S}, \mathbb{A})$ ，其中 $\mathcal{S}$ 表示状态空间，而 $\mathbb{A}$ 表示动作空间，它是 $\mathcal{S} \times \mathcal{S}$ 的一个子集。我们将顶点 $s_0 \in \mathcal{S}$ 定义为没有入边的初始状态，而没有出边的顶点 s_f 被称为汇状态，

并且状态-动作对对应于边。GFlowNets 的目标是学习一个随机策略 π 能够构建离散对象 $\mathbf{x} \in \mathcal{X}$ 以与奖励函数成正比的概率 $R: \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}$, i.e., $\pi(\mathbf{x}) \propto R(\mathbf{x})$ 。GFlowNets 依次构建对象，每一步向构造中添加一个元素。我们将从初始状态到终止状态的状态转换序列称为结果序列 $\tau = (s_0 \rightarrow \dots \rightarrow s_n)$ 一条轨迹，其中 $\tau \in \mathcal{T}$ 与 $\mathcal{T}$ 表示轨迹集合。Bengio 等人 (2021a) 定义了轨迹流 $F: \mathcal{T} \rightarrow \mathbb{R}_{\geq 0}$ 。令 $F(s) = \sum_{\tau \ni s} F(\tau)$ 定义状态 s 的状态流，并且 $F(s \rightarrow s') = \sum_{\tau \ni s \rightarrow s'} F(\tau)$ 定义任意边的边流 $s \rightarrow s'$ 。轨迹流诱导出一个概率测度 $P(\tau) = \frac{F(\tau)}{Z}$ ，其中 $Z = \sum_{\tau \in \mathcal{T}} F(\tau)$ 表示总流。然后我们定义相应的前向策略 $P_F(s'|s) = \frac{F(s \rightarrow s')}{F(s)}$ 和后向策略 $P_B(s|s') = \frac{F(s \rightarrow s')}{F(s')}$ 。这些流可以被视为通过边（像管道）或状态（像连接管道的 T 型接头）的水流（Malkin 等, 2022），其中 $R(\mathbf{x})$ 表示通过终端状态 $\mathbf{x}$ 的水流总量， $P_F(s'|s)$ 从节点 s 流出的边中水流的相对量。

2.1 GFlowNets 训练准则

call a flow consistent if it s 如果对于所有内部状态 s 都满足流匹配约束，则称该流是一致的，即，这意味着流入的流量等于流出的流量。Bengio et al. (2020) 量。Bengio 等人 (2021a) 证明，对于一个一致的流量 F 其中终端流量被设定为奖励，前向策略可以按比例采样对象 x 其概率与之成正比 $R(\mathbf{x})$ 。

流匹配 (FM). Bengio 等人 (2021a) 提出通过一个模型来近似边缘流 $F_\theta(s, s')$ 该模型由 $\log \sum_{(s'' \rightarrow s) \in \mathcal{A}} F_\theta(s'', s) - \log \sum_{(s \rightarrow s') \in \mathcal{A}} F_\theta(s, s')$ 以下 FM 目标参数化， θ 适用于非终止状态。在终止状态，类似的优化目标鼓励流入量与相应的奖励相匹配。i.e., $\mathcal{L}_{\text{FM}}(s) = (\log \sum_{(s \rightarrow s') \in \mathcal{A}} F_\theta(s, s') - R(s))^2$ 该目标通过从训练策略采样的轨迹进行优化， π 该策略具有完整的支持，例如 P_{F_θ} 或 P_{F_θ} 与均匀策略的混合 U , i.e., $\pi_\theta = (1 - \epsilon)P_{F_\theta} + \epsilon \cdot U$ 这类似于 ϵ -贪婪策略和熵正则化策略在强化学习中以改进探索。Bengio 等人 (2021a) 证明，如果我们达到期望损失函数的全局最小值，并且训练策略 π_θ 当具有完全支持时，GFlowNet 从目标分布中采样。

详细平衡 (DB). Bengio 等人 (2021b) 提出了 DB 目标，以避免计算上昂贵的状态父节点或子节点的求和操作。基于 DB 的学习，我们训练一个包含状态流模型 F_θ 、正向策略模型 $P_{F_\theta}(\cdot|s)$ 和反向策略模型 $P_{B_\theta}(\cdot|s)$ 的神经网络，这些模型由参数化 θ 。优化目标是最小化

$\mathcal{L}_{\text{DB}}(s, s') = (\log(F_\theta(s)P_{F_\theta}(s'|s)) - \log(F_\theta(s')P_{B_\theta}(s|s')))^2$ 。如果达到了预期损失的全局最小值并且 π_θ 具有完全支持，它也将目标分布中采样。

轨迹平衡 (TB). Malkin 等人 (2022) 提出了 TB 目标，用于更快的信用分配和更长轨迹的学习。TB 的损失函数是 $\mathcal{L}_{\text{TB}}(\tau) = (\log(Z_\theta \prod_{t=0}^{n-1} P_{F_\theta}(s_{t+1}|s_t)) - \log(R(\mathbf{x}) \prod_{t=0}^{n-1} P_B(s_t|s_{t+1})))^2$ ，其中 Z_θ 是一个可学习参数。

3 相关工作

GFlowNets (GFlowNets). 自 GFlowNets (Bengio 等人, 2021a) 提出以来，人们对改进 (Bengio 等人, 2021b, Malkin 等人, 2022)、理解和将这一框架应用于实用场景的兴趣日益增加。它是一种通用的高级概率推理框架，并诱导出丰富的应用 (Deleu 等人, 2022, Jain 等人, 2022a, Zhang 等人, 2022a,b)。然而，先前的研究仅考虑基于终端奖励的学习，这可能会使

难以提供良好的训练信号给中间状态，尤其是在奖励稀疏的情况下（即，在终端状态中仅有极小部分的状态具有显著非零的奖励）。

强化学习（RL）。与旨在按奖励函数比例采样的 GFlowNets 不同，强化学习学习的是最大化奖励的策略。尽管向强化学习引入熵正则化（Attias, 2003; Haarnoja 等人, 2017, 2018; Ziebart, 2010）可以提高多样性，但这种改进仅限于树结构的有向无环图。这是因为它只能按所有通往终端状态 s_x 的轨迹上的奖励之和的比例来采样终端状态 s_x 。对于一般的（非树状）有向无环图（Bengio 等人, 2021a），由于相同的终端状态 s_x 可以通过大量不同的轨迹获得（并且对于不同的 s_x ，轨迹的数量可能差异很大），这种方法可能会失效。

内在动机。已有研究将内在动机（Burda 等, 2018; Pathak 等, 2017; Zhang 等, 2021）融入强化学习以改进探索策略。然而，这些想法尚未应用于 GFlowNets，因为当前的 GFlowNets 数学框架仅允许终端奖励，与标准的强化学习框架不同。这一不足以及引入内在中间奖励的潜在价值促使了本文的研究。

4 生成式增强流网络

仅从终端奖励学习的潜在困难与强化学习中稀疏奖励的挑战相关，因为在大多数状态下无法获得有信息量的奖励。我们展示了 GFlowNets 在稀疏奖励下的问题，并基于 GridWorld 任务（如图 4 所示）揭示了一些有趣的发现。具体而言，智能体仅在到达世界角落（除了起始状态所在的角落）附近的三个目标之一时才会收到一个奖励值为 $+1$ ，大小为 $H \times H$ （包含 $H \in \{64, 128\}$ ），其他情况下奖励为 0。任务的详细描述可以在第 5.1 节找到。我们评估了通过 TB 训练的 GFlowNet 发现的模式数量，遵循 Bengio 等人（2021a）的方法。如图 1 总结所示，GFlowNet 训练可能会陷入模式的一个子集中。因此，当奖励信号稀疏且不具有信息量时，对于 GFlowNets 来说，高效学习仍然是一个关键挑战。另一方面，最近有关内在动机方法（Burda 等, 2018, Pathak 等, 2017）的进步提高了强化学习算法的探索能力，其中智能体每一步都从稀疏的外在奖励和密集的内在奖励中学习。在此基础上，我们旨在通过在 GFlowNets 中引入中间奖励来解决 GFlowNets 的探索挑战，从而实现内在奖励。我们现在提出了我们的学习框架，称为生成增强流网络（GAFlowNet），以考虑中间奖励。




图 1: Gridworld 环境中稀疏奖励下 GFlowNet 与我们的增强方法（GAFlowNet）的比较。

4.1 基于边的中间奖励增强

我们从流匹配一致性约束开始推导，利用第 2 节讨论的水流比喻带来的洞见。通过将状态 s_t 到状态 s_{t+1} 之间的过渡的中间奖励 $r(s_t \rightarrow s_{t+1})$ 纳入流匹配约束中，

我们得到

$$\sum_{\mathbf{s}_{t-1}} F(\mathbf{s}_{t-1} \rightarrow \mathbf{s}_t) = F(\mathbf{s}_t) = \sum_{\mathbf{s}_{t+1}} [F(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1}) + r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})] \quad (1)$$

通过考虑额外的流出过渡 $\mathbf{s}_t \rightarrow \mathbf{s}_{t+1}$ 的流 $r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})$ 。根据公式 (1)，我们定义相应的正向和反向策略

$$P_F(\mathbf{s}_t|\mathbf{s}_{t-1}) = \frac{F(\mathbf{s}_{t-1} \rightarrow \mathbf{s}_t) + r(\mathbf{s}_{t-1} \rightarrow \mathbf{s}_t)}{F(\mathbf{s}_{t-1})}, \quad P_B(\mathbf{s}_{t-1}|\mathbf{s}_t) = \frac{F(\mathbf{s}_{t-1} \rightarrow \mathbf{s}_t)}{F(\mathbf{s}_t)}. \quad (2)$$

结合这些，我们得到了包含中间奖励的细致平衡目标作为

$$F(\mathbf{s}_{t-1})P_F(\mathbf{s}_t|\mathbf{s}_{t-1}) = P_B(\mathbf{s}_{t-1}|\mathbf{s}_t)F(\mathbf{s}_t) + r(\mathbf{s}_{t-1} \rightarrow \mathbf{s}_t). \quad (3)$$

最后，我们通过公式 (3) 的望远镜计算得到了基于边的奖励增强学习目标，如公式 (4) 所示，其中 $\mathbf{x} = \mathbf{s}_n$ ，和 $Z = \sum_{\mathbf{s}_{t-1} \rightarrow \mathbf{s}_t} r(\mathbf{s}_{t-1} \rightarrow \mathbf{s}_t) + \sum_{\mathbf{x}} R(\mathbf{x})$ 是增强后的总流。

$$Z \prod_{t=0}^{n-1} P_F(\mathbf{s}_{t+1}|\mathbf{s}_t) = R(\mathbf{x}) \prod_{t=0}^{n-1} \left[P_B(\mathbf{s}_t|\mathbf{s}_{t+1}) + \frac{r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})}{F(\mathbf{s}_{t+1})} \right]. \quad (4)$$

我们在图 2(a) 中解释了公式 (4) 的语义。对于从内部状态（黄色圆圈）的转换 $\mathbf{s}_t$ 至 i 第-th 下一状态 $\mathbf{s}_{t+1}^i$ ，我们关联 $\mathbf{s}_{t+1}^i$ 具有特殊状态 $\hat{\mathbf{s}}_{t+1}^i$ （红色圆圈）带有伪出口。具体来说，从状态 $\mathbf{s}_t$ 我们选择相关的下一状态 $\hat{\mathbf{s}}_{t+1}$ 以概率 $(F(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1}) + r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1}))/F(\mathbf{s}_t)$ 根据公式 (2) 中的前向策略。在相关的下一状态 $\hat{\mathbf{s}}_{t+1}$ 我们“虚拟地”选择汇状态（紫色圆圈） $\mathbf{s}_f$ 以概率 $r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})/F(\mathbf{s}_t)$ ，或选择下一个状态 $\mathbf{s}_{t+1}$ 以概率 $F(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})/F(\mathbf{s}_t)$ 。将它们相加，并将这些概率乘以流入量 $F(\mathbf{s}_t)$ 我们有 $F(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1}) + r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})$ 因此，考虑到所有可能的下一状态，我们有增广流一致性方程（流入流 = 流出量）如公式 (1) 所示。中间奖励 $r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})$ 类似于过渡到一个永远不会被选择但仍然吸引更大概率进入其祖先节点的伪出口。从水流的类比来看，可以认为水流从 $\mathbf{s}_t$ 到 $\mathbf{s}_{t+1}$ （从而选择该状态转移的概率）会因所有可访问的下游状态转移中的伪出口而增加中间奖励。与简单地向每个动作添加一个常数均匀概率（这在 GFlowNets 探索中常用）不同，伪出口的中间奖励具有非局部的效果。此外，我们可以指定非均匀的中间奖励作为内在动机 $r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})$ 通过基于新颖性的方法（Burda 等，2018；Pathak 等，2017）来更好地解决稀疏奖励任务中的探索问题。尽管如此准确测度新颖性程度仍然是一个开放问题，但已证明随机网络蒸馏（RND）（Burda 等，2018）是一种简单而有效的方法，能够鼓励智能体访问感兴趣的态。本文采用可训练状态编码器预测特征与固定随机状态编码器之间的差异作为基于 RND 的内在奖励，*i.e.*, $\|\phi(\mathbf{s}) - \bar{\phi}_{\text{random}}(\mathbf{s})\|_2$ 随机蒸馏网络通过最小化这些差异进行训练。因此，测度的新颖性通常对于更常见或相似的状态较小。整体训练流程如算法 1 所示，根据公式 (4) 替换增强轨迹平衡损失。我们现在通过图 2(b) 展示基于边奖励增强的概念优势。它描绘了一个具有稀疏奖励的流网络马尔可夫决策过程（MDP），其中只有 $R(\mathbf{x}_8)$ 和 $R(\mathbf{x}_{12})$ 初始终端奖励为 1，其余终端奖励均为 0。考虑智能体已发现解决方案的情况 $\mathbf{x}_8$ 具有红色流 A。由于大多数其他奖励




图 2: (a) 基于边的奖励增强可以视为在每次转换步骤向汇状态（我们实际上永远不会到达的状态）引入一个伪出口的增强流，其数量为 $r(s_t \rightarrow s_{t+1})$ 。(b) 对于稀疏奖励的任务，智能体很容易陷入几个模式（例如， x_8 ）。我们提出的方法通过增加访问从那里可达的所有转换的概率来激励智能体发现未探索的状态和轨迹，从而找到多样化的模式集合（*i.e.*, x_{12} ）。请注意，为了简化起见，我们省略了终止边上的汇状态。

如果解决方案为 0，智能体很容易陷入模式 x_8 ，从而无法发现其他解决方案。然而，我们的基于边的奖励增强可以激励智能体发现其他路径（例如，蓝色流 B）到 x_8 ，这有助于智能体随后发现其他解决方案（*e.g.*, x_{12} ）。




图 3: 第 4.1-4.3 节提出的不同奖励增强方法。(a) 多样性度量：找到的模式数量。(b) 分布适应度量：经验 L_1 误差。

遵循 (Bengio 等人, 22021a) 中的评估方案，我们在图 3 中总结了 GFlowNet 和 GAFlowNet（带有基于边的奖励增强）发现的模式数量以及经验 L_1 误差。该图还包括了后面章节（第 4.2 节和第 4.3 节）介绍的状态基和联合目标，以确保完整性。 L_1 误差定义为 $\mathbb{E}[\|p(\mathbf{x}) - \pi(\mathbf{x})\|]$ ，其中 $p(\mathbf{x}) = R(\mathbf{x})/Z$ 表示真实的奖励分布，我们通过重复采样并汇总每个可能状态 $\mathbf{x}$ 的访问频率来估计 π 。如图所示，GAFlowNet（边）能够发现更多的模式，与标准 GFlowNet 相比提高了多样性。此外，它学习更有效，并导致更低水平的 L_1 误差。

4.2 基于状态的中间奖励增强 尽管基于边的奖励增强学习框架能够提高所发现解决方案的多样性，但它仍然无法找到所有模式，如图 3 所示。我们假设这是因为其“局部”探索能力，即它能够考虑通往解决方案的不同路径 $\mathbf{x}_i$ 具有非零奖励。然而，它未能充分激励智能体全局探索那些可能具有零奖励的解决方案。因此，它仍然可能会陷入几种模式中，缺乏足够的探索能力来发现其他模式。与基于边的奖励增强不同，Bengio 等人 (2021b) 定义了一个轨迹回报作为状态基奖励增强方式下的中间奖励之和。具体而言，基于状态的奖励增强对于轨迹平衡产生以下准则

$$Z \prod_{t=0}^{n-1} P_F(\mathbf{s}_{t+1}|\mathbf{s}_t) = \left[R(\mathbf{x}) + \sum_{t=0}^{n-1} r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1}) \right] \prod_{t=0}^{n-1} P_B(\mathbf{s}_t|\mathbf{s}_{t+1}), \quad (5)$$

并且我们也使用 RND 作为内在奖励。这样的目标直接激励代理以更全局的方式探索不同的终止状态（图 2(b) 中的 $e.g., \mathbf{x}_2, \mathbf{x}_5, \mathbf{x}_7, \mathbf{x}_9$ ，这对发现 $\mathbf{x}_{12}$ 是有益的）。如图 3(a) 所示，它能够发现所有模式，表现出极大的多样性。然而，它明确改变了潜在的目标概率分布，并且直接且高度地受到轨迹长度的影响。因此，这导致了如图 3(b) 所示的收敛速度明显变慢。

4.3 联合中间奖励增强

如上所述，基于状态的奖励增强在提高多样性方面有效，但未能高效拟合目标分布。另一方面，基于边的奖励增强执行效率更高，但缺乏足够的探索能力，无法发现所有模式。因此，我们提出了一种联合方法，同时考虑基于状态和基于边的中间奖励增强，以充分利用两者的优势。具体而言，我们将轨迹回报重新定义为终端奖励和仅针对终端状态的内在奖励之和。这可以视为我们通过好奇心程度增强了外在终端奖励。另一方面，我们根据基于边的奖励增强包括内部状态的内在奖励。这种整合继承了基于状态和基于边的奖励增强的优点，使得能够在进行更全局探索的同时更高效地学习。

$$Z \prod_{t=0}^{n-1} P_F(\mathbf{s}_{t+1}|\mathbf{s}_t) = [R(\mathbf{x}) + r(\mathbf{s}_n)] \prod_{t=0}^{n-1} \left[P_B(\mathbf{s}_t|\mathbf{s}_{t+1}) + \frac{r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})}{F(\mathbf{s}_{t+1})} \right]. \quad (6)$$

我们的结果流一致性约束如式 (6) 所示，其中 Z 是增强后的总流 $\sum_{\mathbf{x}} R(\mathbf{x}) + \sum_{\mathbf{s}_{t-1} \rightarrow \mathbf{s}_t} r(\mathbf{s}_{t-1} \rightarrow \mathbf{s}_t)$ 。我们的新优化目标 $\mathcal{L}_{\text{GAFlowNet}}(\tau)$ is Eq. (7) 通过算法 1 进行训练。

$$\left(\log \left(Z \prod_{t=0}^{n-1} P_F(\mathbf{s}_{t+1}|\mathbf{s}_t) \right) - \log \left([R(\mathbf{x}) + r(\mathbf{s}_n)] \prod_{t=0}^{n-1} \left[P_B(\mathbf{s}_t|\mathbf{s}_{t+1}) + \frac{r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})}{F(\mathbf{s}_{t+1})} \right] \right) \right)^2 \quad (7)$$

在定理 1 中，我们从理论上证明了所得联合增强方法在渐近情况下导致原始公式的一个无偏解。证明可以在附录 A 中找到。请注意，我们采用了 RND (Burda 等人, 2018 年) 作为内在奖励，随着代理对状态了解的增加，这些奖励会减少。

Algorithm 1 Generative Augmented Flow Networks.

- 1: Initialize the forward and backward policies P_F, P_B , learnable parameter Z , and state flow F
 - 2: Initialize the random fixed target network $\bar{\phi}$ and the predictor network ϕ
 - 3: **for** each training step $t = 1$ to T **do**
 - 4: Collect a batch of B trajectories $\tau = \{s_0 \rightarrow \dots \rightarrow s_n\}$ based on the forward policy P_F
 - 5: Compute intrinsic rewards r for each sample in the batch of trajectories based on the random target network $\bar{\phi}$ and the predictor network ϕ
 - 6: Update the GAFlowNet model according to the augmented trajectory balance loss in Eq. (7)
 - 7: Update the predictor network ϕ by minimizing $\|\bar{\phi}(s) - \phi(s)\|_2$
-

定理 1. 假设 $\forall \tau, \mathcal{L}_{\text{GAFlowNet}}(\tau) = 0$, 和 $\forall \mathbf{x}, R(\mathbf{x}) + r(\mathbf{x}) > 0$ 。当基于边的内在奖励收敛到 0 时, 我们有 (1) $P(\mathbf{x}) = \frac{R(\mathbf{x}) + r(\mathbf{x})}{\sum_{\mathbf{x}} [R(\mathbf{x}) + r(\mathbf{x})]}$; (2) 如果基于状态的内在奖励收敛到 0, 则 $P(\mathbf{x})$ 是一个无偏样本分布。

如图 3 所示, 联合方法能够发现所有模式。此外, 它收敛到最小的 L_1 误差水平, 并且比基于状态和基于边的公式更有效, 这验证了其在实践中的有效性。

5 实验

我们进行了全面的实验来理解我们方法的有效性, 并探讨以下关键问题: i) GAFlowNet 与之前的基线相比如何?

ii) 基于状态和基于边的流增强、内在奖励机制的形式以及关键超参数的效果是什么? iii) 它能否扩展到更大规模和更复杂的任务?

5.1 GridWorld

我们首先基于 GridWorld 进行了稀疏奖励的一系列实验 (图 4)。该任务与 (Bengio 等人, 2021a) 中介绍的任务相同, 不同之处在于奖励函数是稀疏的, 正如第 4 节所述, 这使得探索更具挑战性, 从而使其变得更加困难。随着规模值的增大 H , 它要求代理进行更长时间范围的规划, 并从稀疏的奖励信号中学习。动作包括增加一个坐标的操作, 如同 (Bengio 等人, 2021a) 中所述, 以及一个停止操作, 表示终止, 以确保底层马尔可夫决策过程是一个有向无环图。我们将 GAFlowNet 与强大的基线进行了比较, 这些基线包括 Metropolis-Hastings-MCMC (Dai 等人, 2020), PPO (Schulman 等人, 2017), 以及 GFlowNet (Malkin 等人, 2022)。我们还包含了一个基于 RND (Burda 等人, 2018) 的内在动机机制的 PPO 变体, 加入了内在奖励。所有基线都是基于开源代码实现的¹。每种算法运行五次随机种子, 我们报告它们的均值和标准差。超参数和设置的详细描述可以在附录 B.1 中找到。



图 4: GridWorld 任务。




图 5: 在 GridWorld 中, 随着每列尺寸的增加 (左: 小, 中: 中等, 右: 大), GFlowNets 与基线的比较。第一行和第二行分别对经验性 L_1 误差和发现模式的数量。

5.1.1 性能比较

我们在大小逐渐增加的小型、中型和大型 GridWorlds 上进行了实验 H 其他值的完整结果 H 可以在附录 B.2 中找到。为了研究 GFlowNet 的有效性, 我们首先将其与基线方法在经验上进行比较 L_1 在第 4 节中计算的误差。如图 5 的第一行所示, MCMC 和 PPO 由于奖励特别稀疏而无法收敛。尽管 PPO-RND 具有较小的 L_1 错误, 它仍然大幅落后于 GFlowNets。GFlowNet 收敛速度最快, 并达到最小的 L_1 该误差表明, 我们的方法能够有效地探索并收敛到与外在奖励函数成比例的采样目标, 即使奖励信号稀疏。每种方法在训练过程中发现的模式数量显示在图 5 的第二行。尽管将 PPO 与内在奖励结合可以提高发现模式的数量, 相较于大规模任务中的 PPO, 它仍然会迅速达到平台期。另一方面, GFlowNets 可能会陷入少数几个模式, 而 GFlowNet 能够高效地发现所有模式。关于性能的详细比较, 请参见附录 B.3。

5.1.2 消融实验

我们现在对 GFlowNet 在大型 GridWorld 任务中的重要组件和超参数提供深入的消融实验。我们还研究了不同内在奖励机制的效果, 除了 RND 之外的结果可以在附录 B.4 中找到。

¹<https://github.com/GFNOrg/gflownet>

基于状态和基于边的流增强效果。 在图 6(a) 中，我们探讨了基于边、基于状态以及联合内在奖励的效果。正如第 4 节所述，以基于状态的方式为轨迹引入内在奖励可能导致收敛速度变慢，从而产生较大的 L_1 误差。另一方面，通过基于边的方式增强 TB 目标仍然无法激励代理访问零奖励的状态。相比之下，联合增强机制在多样性和性能方面都是有效的，在我们的实验中达到了最小的 L_1 误差水平。值得注意的是，仅使用基于状态的增强为终端状态引入内在奖励效率较低，这表明基于边和终端状态的内在奖励的重要性。

内在奖励系数的影响。 在实践中，我们将内在奖励乘以一个系数。图 6(b) 展示了内在奖励系数的影响。过小的系数无法提升性能，而过大的系数则收敛速度更慢。存在一个中间值能够提供最佳的权衡。




图 6: 消融实验。(a) 基于状态和边的内在奖励效果。(b) 内在奖励系数的效果。




图 7: 基于 (a) DB 和 (b) FM 的 GFlowNet 和 GAFlowNet 的经验 L_1 误差。

5.1.3 多功能性

我们现在通过构建其他两个基于详细平衡 (DB)(Bengio 等, 2021b) 和流匹配 (FM)(Bengio 等, 2021a) 准则的 GFlowNet 目标来展示我们提出的框架的多功能性。基于不断增加的规模 H 的经验 L_1 误差比较总结见图 7。正如所展示的，GAFlowNet 也显著提高了 DB 和 FM 的训练收敛性，这提供了持续的改进收益。

5.2 分子生成

5.2.1 实验设置

我们现在通过评估更具挑战性的分子生成任务 (Bengio 等, 2021a) 来研究我们的方法在大规模任务中的有效性，如图 8(a) 所示。分子由一个包含构建块词汇表的图表示。代理通过选择在哪里添加一个块以及在每一步考虑化学有效性约束的情况下选择哪个块来顺序生成分子。还有一个退出动作，指示代理是否决定停止生成过程。这个问题具有较大的状态空间 (约 10^{16}) 和动作空间 (大约 100 到 2000)。代理的目标是发现具有高奖励的多样化分子，即与可溶性环氧化物水解酶 (sEH) 结合能量低的分子。

蛋白质。我们使用预训练的代理模型来计算这种结合能量。这里考虑一个稀疏奖励函数，其中智能体仅在对应的分子成功达到目标分数时获得非零奖励，否则奖励为 0。环境的具体描述见附录 B.1.1。我们将我们的方法与之前的 GFlowNet 结果 (Bengio 等人, 2021a)、PPO (Schulman 等人, 2017)、基于 RND 的内在奖励 PPO 以及 MARS (Xie 等人, 2020) 进行了比较。所有基线均基于开源代码²实现，并按照 (Bengio 等人, 2021a) 的方式使用三个随机种子运行。更多设置细节请参见附录 B.1.2。

5.2.2 性能比较

我们遵循 (Bengio 等人, 2021a) 中的评估度量，在性能和多样性方面研究了我们的方法。图 8(b) 展示了每种方法生成的前 10 个唯一分子的平均奖励。图 8(c) 总结了每种方法发现的奖励高于 7.5 的模式数量。我们在图 8(d) 中计算了前 10 个样本的平均成对 Tanimoto 相似性。更多的比较结果可以在附录 B.5 中找到。





图 8: 分子生成任务。(a) 环境。(b) 前 10 个分子的平均奖励。(c) 具有 $R > 7.5$ 的模式数量。(d) Tanimoto 相似性 (越低越好)。

如所示，由于大多数奖励信号是非信息性的，MARS 在给定稀疏奖励的情况下表现不佳。另一方面，PPO 及其具有内在奖励的变体比 MARS 更善于找到高质量的解决方案，但都遭受样本高相似性的困扰。未增强的 GFlowNet 更善于发现多样化的分子，但在解决方案质量方面表现不佳。GAFlowNet 在性能和多样性方面显著优于基线方法。我们还在图 9 中可视化了一次运行中 GFlowNet 和 GAFlowNet 生成的前 10 个分子。如图所示，GAFlowNet 能够高效地生成多样化和高质量的分子，这表明其性能改进是一致且显著的。


6 结论

本文提出了一种新的学习框架 GAFlowNet，用于 GFlowNet 以整合中间奖励。通过内在动机指定中间奖励，以解决 GFlowNet 在稀疏奖励任务中的探索问题，在这些任务中，它可能会陷入少数几种模式。进行了广泛的实验来评估 GAFlowNet 的有效性，结果表明其在多样性、收敛性和性能方面显著优于强大的基线方法。

²https://github.com/GFNOrg/gflownet/tree/trajectory_balance/mols



(a) GFlowNet。Tanimoto 相似度为 0.410，平均奖励为 7.747。



(b) GAFlowNet。Tanimoto 相似度为 0.356，平均奖励为 8.120。

图 9: 展示了由 GFlowNet 和 GAFlowNet 生成的顶级分子（此处展示了前 5 个候选分子，完整的前 10 个分子的结果见附录 B.6）。

当奖励非常稀疏时，GAFlowNet 也能够扩展到复杂的任务，如分子图生成。

可重复性声明

我们的所有实验细节都在附录 B 中详细描述，包括任务说明、超参数、基线方法的网络架构以及设置。所有基线方法和环境的实现都基于开源仓库。定理 1 的证明可以在附录 A 中找到。代码将在工作发表后开源。

参考文献

- Hagai Attias. Planning by probabilistic inference. In *AISTATS*, 2003.
- Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow network based generative models for non-iterative diverse candidate generation. *Advances in Neural Information Processing Systems*, 34:27381–27394, 2021a.
- Yoshua Bengio, Tristan Deleu, Edward J Hu, Salem Lahlou, Mo Tiwari, and Emmanuel Bengio. Gflownet foundations. *arXiv preprint arXiv:2111.09266*, 2021b.
- Yuri Burda, Harrison Edwards, Amos Storkey, and Oleg Klimov. Exploration by random network distillation. In *International Conference on Learning Representations*, 2018.
- Hanjun Dai, Rishabh Singh, Bo Dai, Charles Sutton, and Dale Schuurmans. Learning discrete energy-based models via auxiliary-variable local exploration. *Advances in Neural Information Processing Systems*, 33:10443–10455, 2020.
- Tristan Deleu, Ant’onio G’ois, Chris C. Emezue, Mansi Rankawat, Simon Lacoste-Julien, Stefan Bauer, and Yoshua Bengio. Bayesian structure learning with generative flow networks. *ArXiv*, abs/2202.13903, 2022.
- Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. In *International conference on machine learning*, pages 1263–1272. PMLR, 2017.

- Tuomas Haarnoja, Haoran Tang, Pieter Abbeel, and Sergey Levine. Reinforcement learning with deep energy-based policies. In *International conference on machine learning*, pages 1352–1361. PMLR, 2017.
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. PMLR, 2018.
- Moksh Jain, Emmanuel Bengio, Alex García, Jarrid Rector-Brooks, Bonaventure F. P. Dossou, Chanakya Ajit Ekbote, Jie Fu, Tianyu Zhang, Micheal Kilgour, Dinghuai Zhang, Lena Simine, Payel Das, and Yoshua Bengio. Biological sequence design with gflownets. In *ICML*, 2022a.
- Moksh Jain, Emmanuel Bengio, Alex Hernandez-Garcia, Jarrid Rector-Brooks, Bonaventure FP Dossou, Chanakya Ajit Ekbote, Jie Fu, Tianyu Zhang, Michael Kilgour, Dinghuai Zhang, et al. Biological sequence design with gflownets. In *International Conference on Machine Learning*, pages 9786–9801. PMLR, 2022b.
- Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- Matevž Kunaver and Tomaž Požrl. Diversity in recommender systems—a survey. *Knowledge-based systems*, 123:154–162, 2017.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in gflownets. *arXiv preprint arXiv:2201.13259*, 2022.
- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- Deepak Pathak, Pulkit Agrawal, Alexei A Efros, and Trevor Darrell. Curiosity-driven exploration by self-supervised prediction. In *International conference on machine learning*, pages 2778–2787. PMLR, 2017.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.
- David Silver, Satinder Singh, Doina Precup, and Richard S Sutton. Reward is enough. *Artificial Intelligence*, 299:103535, 2021.
- Oriol Vinyals, Igor Babuschkin, Wojciech M Czarnecki, Michaël Mathieu, Andrew Dudzik, Junyoung Chung, David H Choi, Richard Powell, Timo Ewalds, Petko Georgiev, et al. Grandmaster level in starcraft ii using multi-agent reinforcement learning. *Nature*, 575(7782):350–354, 2019.
- Yutong Xie, Chence Shi, Hao Zhou, Yuwei Yang, Weinan Zhang, Yong Yu, and Lei Li. Mars: Markov molecular sampling for multi-objective drug discovery. In *International Conference on Learning Representations*, 2020.
- Dinghuai Zhang, Ricky T. Q. Chen, Nikolay Malkin, and Yoshua Bengio. Unifying generative models with gflownets. 2022a.

- Dinghuai Zhang, Nikolay Malkin, Z. Liu, Alexandra Volokhova, Aaron C. Courville, and Yoshua Bengio. Generative flow networks for discrete probabilistic modeling. In *ICML*, 2022b.
- Tianjun Zhang, Huazhe Xu, Xiaolong Wang, Yi Wu, Kurt Keutzer, Joseph E Gonzalez, and Yuan-dong Tian. Noveld: A simple yet effective exploration criterion. *Advances in Neural Information Processing Systems*, 34:25217–25230, 2021.
- Yichi Zhang, Zhijian Ou, and Zhou Yu. Task-oriented dialog systems that consider multiple appropriate responses under the same context. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 9604–9611, 2020.
- Brian D. Ziebart. Modeling purposeful adaptive behavior with the principle of maximum causal entropy. 2010.

定理 1 的证明

定理 1. 假设 $\forall \tau, \mathcal{L}_{\text{GAFlowNet}}(\tau) = 0$, 和 $\forall \mathbf{x}, R(\mathbf{x}) + r(\mathbf{x}) > 0$ 。当基于边的内在奖励收敛到 0 时, 我们有 (1) $P(\mathbf{x}) = \frac{R(\mathbf{x})+r(\mathbf{x})}{\sum_{\mathbf{x}} [R(\mathbf{x})+r(\mathbf{x})]}$; (2) 如果基于状态的内在奖励收敛到 0, 则 $P(\mathbf{x})$ 是一个无偏样本分布。

证明。根据定义, 我们有

$$F_{\theta}(\tau) = Z \prod_{t=0}^{n-1} P_F(\mathbf{s}_{t+1}|\mathbf{s}_t). \quad (8)$$

由于 $\forall \tau, \mathcal{L}_{\text{GAFlowNet}}(\tau) = 0$, 我们有

$$Z \prod_{t=0}^{n-1} P_F(\mathbf{s}_{t+1}|\mathbf{s}_t) = (R(\mathbf{x}) + r(\mathbf{x})) \prod_{t=0}^{n-1} \left[P_B(\mathbf{s}_t|\mathbf{s}_{t+1}) + \frac{r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})}{F(\mathbf{s}_{t+1})} \right] \quad (9)$$

因此, 我们得到

$$P_{\theta}(\tau) = \frac{F_{\theta}(\tau)}{Z} = \frac{R(\mathbf{x}) + r(\mathbf{x})}{Z} \prod_{t=0}^{n-1} \left[P_B(\mathbf{s}_t|\mathbf{s}_{t+1}) + \frac{r(\mathbf{s}_t \rightarrow \mathbf{s}_{t+1})}{F(\mathbf{s}_{t+1})} \right]. \quad (10)$$

当基于边的内在奖励收敛到 0 且 F 不消失时, 我们有

$$P_{\theta}(\mathbf{x}) = \sum_{\tau=(\mathbf{s}_0 \rightarrow \dots \rightarrow \mathbf{s}_n=\mathbf{x})} P_{\theta}(\tau) = \frac{R(\mathbf{x}) + r(\mathbf{x})}{Z} \sum_{\tau=(\mathbf{s}_0 \rightarrow \dots \rightarrow \mathbf{s}_n=\mathbf{x})} \prod_{t=0}^{n-1} P_B(\mathbf{s}_t|\mathbf{s}_{t+1}). \quad (11)$$

根据全概率定律, 我们有

$$\sum_{\tau=(\mathbf{s}_0 \rightarrow \dots \rightarrow \mathbf{s}_n=\mathbf{x})} \prod_{t=0}^{n-1} P_B(\mathbf{s}_t|\mathbf{s}_{t+1}) = 1. \quad (12)$$

Therefore, $P_{\theta}(\mathbf{x}) = \frac{R(\mathbf{x})+r(\mathbf{x})}{Z}$ 随着 $\sum_{\mathbf{x}} P_{\theta}(\mathbf{x}) = 1$, 我们也得到

$$Z = \sum_{\mathbf{x}} (R(\mathbf{x}) + r(\mathbf{x})). \text{ 因此, 我们得到第一部分} \quad P_{\theta}(\mathbf{x}) = \frac{R(\mathbf{x}) + r(\mathbf{x})}{\sum_{\mathbf{x}} [R(\mathbf{x}) + r(\mathbf{x})]} \quad (13)$$

基于上述分析, 当基于状态的内在奖励收敛到 0 时, $P(\mathbf{x})$ 是一个无偏估计, 我们得到第二部分。

□

B 实验细节

B.1 实验设置

B.1.1 任务

分子生成任务 本文采用预训练代理模型作为奖励, 该模型基于在 (Bengio 等人, 2021a) 中提供的随机生成的 300,000 分子数据集进行训练。对于原始密集奖励函数, 智能体根据归一化得分获得奖励。在这里, 我们使用稀疏奖励函数, 即只有当归一化得分超过目标分数 (7.0) 时, 智能体才能获得原始非零奖励, 否则奖励为 0。如第 5.2.1 节所述, 智能体可以从基本构建块词汇表 (大小为 105) 中选择一个块进行连接。




图 10: 在 GridWorld 中随着规模增加, GAFlowNets 与基线的比较 $H \in \{8, 16, 32, 64, 128\}$ 。(a), (c), (e), (g), (i) 对应经验误差 L_1 。(b), (d), (f), (h), (j) 对应每种方法发现的模式数量。

B.1.2 基线

所有基线方法均基于正文所述的开源实现进行实现, 其中我们遵循 (Bengio 等人, 2021a) 中的默认超参数和设置。具体而言, 在 GridWorld 中, GFlowNet 模型是一个包含两层隐藏层的前馈网络, 每层有 256 个隐藏单元, 并使用 LeakyReLU 激活函数。我们基于环境中的 16 个并行轨迹样本训练所有模型。我们利用随机网络蒸馏 (RND)(Burda 等人, 2018) 作为内在奖励机制, 其中随机目标网络和预测网络均为包含两层隐藏层的前馈网络, 每层有 256 个隐藏单元, 并使用 LeakyReLU 激活函数。我们基于 Adam(Kingma 和 Ba, 2014) 优化器联合训练 GFlowNet 模型和 RND, 策略模型的学习率为 0.001 (包括 P_F 和 P_B), 而 Z 的学习率为 0.1。对于分子生成任务, 我们使用 (Bengio 等人, 2021a) 提供的奖励代理。由于分子表示为原子图, 我们使用消息传递神经网络 (MPNN)(Gilmer 等人, 2017) 作为所有模型的网络架构。请注意, 我们在分子生成任务中基于流匹配准则构建我们的方法, 因为它在该任务中是最具竞争力的版本, 就发现能力而言。

生成高质量和多样化的候选者。对于 GAFlowNet，唯一需要调优的超参数是内在奖励的系数 α ，我们在状态增强和边增强中使用相同的值。我们通过网格搜索来调优 α 在 $\{0.001, 0.005, 0.01, 0.05, 0.1, 0.5\}$ 。具体来说，对于 GridWorld，除了当视界为 $H = 64$ 时设置 α 为 0.005 之外，其他所有视界值都使用 $\alpha = 0.001$ 。对于分子生成任务，将 α 设置为 0.1。代码将在论文发表后发布。

B.2 GridWorld 中的完整结果

图 10 展示了 GridWorld 中随着规模增加的完整比较结果。如图所示，GAFlowNet 在 $H \in \{8, 16, 32, 64, 128\}$ 的经验性 L_1 误差和发现模式的数量上显著优于基线方法。

B.3 性能比较

除了根据度量（每种方法发现的模式数量和经验性 L_1 误差）评估我们的方法外，我们还关注每次更新后的性能表现。在这里，我们评估基线方法在每次更新后的性能（而不是在整个训练过程中），类似于 RL 算法的评估方案。图 11 展示了 GridWorld 中大小为 $H \in \{8, 16, 32, 64, 128\}$ 的方法在每次更新后 16 个并行回放批次中的前 5 个解决方案的性能。如图所示，尽管 PPO 比 PPO 更有效率，但它们都远远落后于 GAFlowNet（尤其是在较大的 H 值情况下）。我们发现 GAFlowNet 显著优于基线方法，并且比 GAFlowNet 更高效。




图 11: 每次更新后基线方法的前 K 性能，时间范围为 $H \in \{8, 16, 32, 64, 128\}$ 。

B.4 GAFlowNet 的附加消融实验

我们研究了不同类型的内在奖励的影响，包括内在好奇心模块（Intrinsic Curiosity Module, ICM）（Pathak 等，2017 年），新颖性差异（Novelty Difference, NovelD）（Zhang 等，2021 年），以及随机网络蒸馏（Random Network Distillation, RND）（Burda 等，2018 年），这些结果在图 12 中展示，并对内在奖励系数进行了微调。我们还在 GAFlowNet 中包含了一个具有恒定内在奖励的基线，该基线模仿了强化学习算法中通常使用的 ϵ -贪婪探索行为。正如所展示的，GAFlowNet 对内在奖励的形式不敏感，但在我们的仿真中，RND 实现了最快的收敛。这还验证了基于新颖性的方法的有效性，通过比较 GAFlowNet 和具有恒定内在奖励的 GAFlowNet 可以得出这一结论。这是因为基于新颖性的方法比盲目地在迷宫中徘徊更有效。 ϵ




图 12: 不同类型的内在奖励的消融实验。

附录 B.5 分子生成任务上的额外性能比较

根据 (Bengio 等人, 2021a) 中的评估度量, 在正文的图 8 结果之外, 我们也评估了每种方法发现的前 100 个分子的平均奖励以及模式数量 $R > 8.0$ 。如图 13 所示, GAFlowNet 在之前的基线上实现了稳定且显著的性能提升。






图 13: 分子生成任务。(a) 排名前 100 的分子的平均奖励。(b) 模式数量与 $R > 8.0$ 。

附录 B.6 排名前 10 分子的完整可视化

图 14 展示了由 GFlowNet 和 GAFlowNet 生成的排名前 10 分子, 其中 GAFlowNet 发现了更多样化和高质量的解决方案。



(a) GFlowNet。Tanimoto 相似度为 0.410, 平均奖励为 7.747。



(b) GAFlowNet。Tanimoto 相似度为 0.356, 平均奖励为 8.120。

图 14: 由 GFlowNet 和 GAFlowNet 生成的排名前 10 分子的完整可视化。