


FlowRL: 通过匹配奖励分布进行 LLM 推理

朱学凯¹, Daixuan Cheng⁶, Dinghuai Zhang³, Hengli Li⁵, Kaiyan Zhang⁴, Che Jiang⁴, Youbang Sun⁴, Ermo Hua⁴, Yuxin Zuo⁴, Xingtai Lv⁴, Qizheng Zhang⁷, Lin Chen¹, Fanghao Shao¹, Bo Xue¹, Yunchong Song¹, Zhenjie Yang¹, Ganqu Cui², Ning Ding^{4,2}, Jianfeng Gao³, Xiaodong Liu³, Bowen Zhou^{4,2†}, Hongyuan Mei^{8‡}, Zhouhan Lin^{1,2‡}

¹ Shanghai Jiao Tong University ² Shanghai AI Laboratory ³ Microsoft Research ⁴ Tsinghua University ⁵ Peking University
⁶ Renmin University of China ⁷ Stanford University ⁸ Toyota Technological Institute at Chicago
 ✉ hongyuanmei@gmail.com ✉ xuekaizhu0@gmail.com 🌐 FlowRL ‡ Corresponding Authors.

摘要 | 我们提出了 FlowRL: 在大语言模型 (LLM) 强化学习 (RL) 中, 通过流量平衡匹配完整的奖励分布, 而不是最大化奖励。近期先进的推理模型采用了奖励最大化的策略 (例如 PPO 和 GRPO), 这些方法倾向于过度优化主导的奖励信号, 而忽视了较少出现但有效的推理路径, 从而降低了多样性。相比之下, 我们将标量奖励转换为一个可学习分区函数的归一化目标分布, 并最小化策略与目标分布之间的逆 KL 发散。我们实现这一想法作为一种流量平衡优化方法, 促进多样性的探索和通用的推理轨迹。我们在数学和代码推理任务上进行了实验: FlowRL 在数学基准测试上相对于 GRPO 平均提高了 10.0%, 相对于 PPO 提高了 5.1%, 并且在代码推理任务上始终表现更好。这些结果突显了奖励分布匹配作为 LLM 强化学习中有效探索和多样化推理的关键步骤。

Distribution-matching: FlowRL



Reward-maximizing: R++, PPO and GRPO





图 1 | 上: 分布匹配与奖励最大化方法的对比。FlowRL (左) 学习匹配完整的奖励分布, 在多个模式之间保持低 KL 发散的多样性。相比之下, 像 GRPO (右) 这样的奖励最大化方法集中在单个高奖励峰值上, 导致模式崩塌和更高的 KL 发散。下: 性能对比。FlowRL 在数学和代码领域始终优于 GRPO。

1. 引言

强化学习 (RL) 在大语言模型 (LLMs) 的后训练中扮演着关键角色 [Zhang 等, 2025b]。一系列强大的推理模型 [Guo 等, 2025, Kavukcuoglu, 2025, Rastogi 等, 2025] 已采用大规模强化学习, 在极具挑战性的基准测试 [He 等, 2024] 上取得了优异的性能。针对 LLM 推理的 RL 算法演变经历了几个关键阶段: REINFORCE [Sutton 等, 1999] 提供了一个易于实现且在简单设置下高效的坚实基线; PPO [Schulman 等, 2017] 通过提高稳定性和效率改进了 REINFORCE, 使其适用于复杂设置; GRPO [Shao 等, 2024] 通过消除价值函数并依赖于群体比较简化了 PPO 训练, 但代价是在每次更新中需要更多的回放。然而, 所有这些方法在其最大化奖励的目标方面都存在一个根本性的局限性。

最大化奖励的 RL 方法倾向于过度拟合到奖励分布的主要模式 [Gao 等, 2023, Pan 等, 2022, Skalse 等, 2022, Zelikman 等, 2022]。这通常导致生成的推理路径多样性有限, 并减少了对较少出现但有效的逻辑结果的泛化能力 [Hu 等, 2023]。如图 1 所示, GRPO 忽视其他有意义的模式。这些缺点在复杂的长思维链 (CoT; Wei 等, 2022) 推理中尤为明显, 在这种情况下, 捕捉多样化的合理解决方案分布对于有效的泛化至关重要 [Liu 等, 2025a]。最近的方法调整了剪辑比率 [Yu 等, 2025b], 通过基于熵的项增强优势函数 [Cheng 等, 2025], 或者选择性地促进高熵令牌 [Wang 等, 2025], 从而动态适应训练数据分布并在训练过程中隐式增加多样性。这引发了一个基本问题: 如何促进多样化的探索以防止在 RL 训练中收敛到主导解决方案模式?

本文提出了 **FlowRL** 算法, 该算法通过使策略模型与完整的奖励分布对齐来鼓励模式覆盖。**FlowRL** 通过从奖励最大化转变为奖励分布匹配, 从根本上实现了更有效的探索, 从而解决了以往强化学习方法固有的模式坍缩局限性。如图 1 所示, **FlowRL** 的核心思想是引入一个可学习的分割函数, 将标量奖励归一化为目标分布, 并最小化策略与该奖励诱导分布之间的逆 KL 发散。我们基于 GFlowNets [Bengio 等, 2023b] 中的轨迹平衡公式开发了这个 KL 目标, 并提供了生成模型和策略优化之间梯度等价性的证明。为了应对长 CoT 训练的挑战, 我们引入了两个关键技术解决方案: 长度归一化, 用于解决变长 CoT 推理过程中出现的梯度爆炸问题, 以及重要性采样, 用于纠正生成轨迹与当前策略之间的分布不匹配问题。

我们将 FlowRL 与主流的强化学习算法进行比较, 包括 REINFORCE++, PPO 和 GRPO, 在数学和编程领域使用基础模型和蒸馏模型 (7B、32B)。在数学领域, FlowRL 相较于 GRPO 和 PPO 分别提升了 10.0% 和 5.1%, 展示了其在六个具有挑战性的数学基准测试上的持续改进。此外, FlowRL 在三个具有挑战性的编程基准测试上超越了 PPO 和 GRPO, 突显了其在代码推理任务中的强大泛化能力。为了理解这些性能提升的原因, 我们分析了生成的推理路径的多样性。这种多样性分析证实, FlowRL 生成的回放路径比基线方法更加多样化, 验证了我们的方法在探索多种解决方案策略方面的有效性。

贡献。本文的主要贡献总结如下:

- 本文提出 FlowRL, 这是一种从奖励最大化转向策略优化的算法

通过流量平衡实现奖励分布匹配，鼓励探索多样化的推理路径，同时解决现有强化学习方法内在模式崩溃的局限性。

- 本文引入归一化和重要性采样，以实现变长 CoT 推理的有效训练，解决了梯度爆炸和采样不匹配的问题。
- FlowRL 在数学基准测试中分别比 GRPO 和 PPO 高出 10.0% 和 5.1%，并在代码推理任务上展示了强大的泛化能力，多样性分析证实了其探索了更多样化的解决方案。

2. 预备知识

用于推理的强化学习。 我们将推理形式化为一个条件生成问题，其中策略模型接收一个问题 $\mathbf{x} \in \mathbf{X}$ 并生成一个答案 $\mathbf{y} \in \mathbf{Y}$ 。目标是学习一个策略 $\pi_\theta(\mathbf{y}|\mathbf{x})$ ，该策略能够在特定任务的奖励信号下生成高质量的答案 r 。为了更好地说明策略优化过程，我们在下面提供了 GRPO 的详细公式。对于每个问题 $\mathbf{x}$ ，GRPO 从旧策略 $\pi_{\theta_{old}}$ 中采样一组答案 $\{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_G\}$ ，并通过最大化以下目标来更新模型：

$$\begin{aligned} \mathcal{J}_{GRPO}(\theta) &= \mathbb{E}_{[\mathbf{x} \sim P(\mathbf{X}), \{\mathbf{y}_i\}_{i=1}^G \sim \pi_{\theta_{old}}(\mathbf{Y}|\mathbf{x})]} \\ &\frac{1}{G} \sum_{i=1}^G \frac{1}{|\mathbf{y}_i|} \sum_{t=1}^{|\mathbf{y}_i|} \left\{ \min \left[\frac{\pi_\theta(\mathbf{y}_{i,t}|\mathbf{x}, \mathbf{y}_{i,<t})}{\pi_{\theta_{old}}(\mathbf{y}_{i,t}|\mathbf{x}, \mathbf{y}_{i,<t})} \hat{A}_{i,t}, \text{clip} \left(\frac{\pi_\theta(\mathbf{y}_{i,t}|\mathbf{x}, \mathbf{y}_{i,<t})}{\pi_{\theta_{old}}(\mathbf{y}_{i,t}|\mathbf{x}, \mathbf{y}_{i,<t})}, 1 - \epsilon, 1 + \epsilon \right) \hat{A}_{i,t} \right] - \lambda \mathbb{D}_{KL} [\pi_\theta || \pi_{ref}] \right\}, \\ \mathbb{D}_{KL}(\pi_\theta || \pi_{ref}) &= \frac{\pi_{ref}(\mathbf{y}_i|\mathbf{x})}{\pi_\theta(\mathbf{y}_i|\mathbf{x})} - \log \frac{\pi_{ref}(\mathbf{y}_i|\mathbf{x})}{\pi_\theta(\mathbf{y}_i|\mathbf{x})} - 1, \end{aligned} \quad (1)$$

其中 ϵ 和 λ 是超参数。这里， A_i 表示优势，通过归一化组奖励值计算得出 $\{r_1, r_2, \dots, r_G\}$ 作为 $A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}$ 。与 GRPO 相比，REINFORCE 直接应用策略梯度，不进行优势归一化、裁剪或 KL 正则化。PPO 使用批评模型来估计优势，并采用重要性采样来稳定策略更新。

GFlowNets (GFlowNets)。生成流网络 [Bengio 等, 2023a] 是一种概率框架，用于训练随机策略以按给定奖励的比例采样离散的组合对象（例如，图、序列）如图 2 所示，**GFlowNets** 的核心原理是在每个状态平衡正向和反向的概率流，这一理念受到流匹配 [Bengio 等, 2021] 的启发。初始流通过 $Z_h(s_0)$ 在初始状态 s_0 进行估计。输出流等于最终状态下条件化的结果奖励 $r(s_n)$ 。遵循 Lee 等人的方法 [2024]，我们使用一个三层




图 2 | GFlowNets [Bengio 等人, 2023a]，一种从流平衡角度看待强化学习的方法。初始流 $Z_h(s_0)$ 向环境中注入概率质量，该概率质量通过策略 π_θ 在中间状态之间传输，并根据标量奖励在终端状态处累积。

使用 MLP (Multilayer Perceptron) 来参数化 Z_h 。这种流量平衡机制通过确保充分探索解空间，有助于发现多样化的高回报解决方案。详见附录 C 中的 GFlowNets 背景介绍。

3. 方法论

在本节中，我们首先通过逆 KL 发散来构建强化学习中的分布匹配，并建立其与 GFlowNets 中轨迹平衡的联系。为了应对长时间 CoT 训练过程中遇到的梯度爆炸和采样不匹配的挑战，我们进一步引入长度归一化和重要性采样。利用这一增强框架，我们推导出一个流平衡目标，称为 FlowRL。

3.1. 从奖励最大化到分布匹配

如图 1 所示，近期强大的大型推理模型通常采用最大化奖励的 RL 算法，例如 PPO 或 GRPO。然而，这些方法倾向于优化向主导奖励模式，经常导致模式崩塌，并忽视其他可能的高质量推理路径。为了解决这一根本局限性，我们提出通过将策略的输出分布与目标奖励分布对齐来优化策略。实现这一点的一种简单而有效的方法是，最小化策略与该目标之间的逆 KL 发散¹。然而，在长时间的 CoT 推理任务中，RL 中可用的监督是一个标量奖励，而不是一个完整的分布。此外，枚举或采样所有有效轨迹以恢复真实的奖励分布在计算上是不可行的。

受能量模型 [杜和莫达奇, 2019, 欣顿等, 1995] 的启发，本文引入了一个可学习的配分函数 $Z_\phi(\mathbf{x})$ ，用于将标量奖励归一化为有效的目标分布。这使得我们可以最小化策略与加权奖励分布之间的逆 KL 发散，形式化表示为：

$$\min_{\theta} \mathcal{D}_{\text{KL}} \left(\pi_{\theta}(\mathbf{y} | \mathbf{x}) \left\| \frac{\exp(\beta r(\mathbf{x}, \mathbf{y}))}{Z_{\phi}(\mathbf{x})} \right\| \right) \Rightarrow \pi_{\theta}(\mathbf{y} | \mathbf{x}) \propto \exp(\beta r(\mathbf{x}, \mathbf{y})), \quad (2)$$

其中， $r(\mathbf{x}, \mathbf{y})$ 是奖励函数， β 是一个超参数， $Z_{\phi}(\mathbf{x})$ 是学习到的划分函数，由此得到的目标分布定义为 $\tilde{\pi}(\mathbf{y} | \mathbf{x}) = \frac{\exp(\beta r(\mathbf{x}, \mathbf{y}))}{Z_{\phi}(\mathbf{x})}$ 。这一目标鼓励策略按照奖励的比例采样多样化的高奖励轨迹，而不是像标准奖励最大化那样收敛到主导模式。

虽然基于 KL 的方法提供了一个原则性的目标分布，但我们推导出一个更实用的强化学习风格的目标，这有助于高效地优化策略。

命题 1。 从期望梯度的角度来看，在公式 2 中最小化 KL 目标等价于最小化 GFlowNet [Bartoldson 等人, 2025, Lee 等人, 2024, Malkin 等人, 2022, 2023] 中使用的轨迹平衡损失：

$$\min_{\theta} \mathcal{D}_{\text{KL}} \left(\pi_{\theta}(\mathbf{y} | \mathbf{x}) \left\| \frac{\exp(\beta r(\mathbf{x}, \mathbf{y}))}{Z_{\phi}(\mathbf{x})} \right\| \right) \iff \min_{\theta} \underbrace{(\log Z_{\phi}(\mathbf{x}) + \log \pi_{\theta}(\mathbf{y} | \mathbf{x}) - \beta r(\mathbf{x}, \mathbf{y}))^2}_{\text{轨迹平衡}} \quad (3)$$

注释 2 (作为 KL 最小化的实用替代方案的轨迹平衡)。根据命题 1 中建立的等价性，基于 KL 的分布匹配目标可以重新表述为轨迹平衡损失。这种重新表述通过使用稳定的平方损失形式而非直接进行 KL 优化，并将 $Z_{\phi}(\mathbf{x})$ 视为可学习参数而非需要显式计算难以处理的划分函数，提供了实用的优化方法。因此，轨迹平衡目标作为奖励引导的 KL 最小化的可行替代方案，可以直接整合到现有的强化学习框架中。

¹ 我们使用逆 KL，因为我们只能从策略模型中采样，而不能从目标奖励分布中采样。

3.2. 流动 RL

根据命题 1，目标奖励分布可以通过优化轨迹平衡目标来近似。然而，直接将此目标应用于长时间 CoT 推理引入了两个关键挑战：

问题 I：来自长时间轨迹的梯度爆炸。

Trajectory balance is a sequence-level objective, and applying it to long CoT reasoning with up to 8K tokens leads to exploding gradients and unstable updates. This issue is not observed in prior GFlowNets works, which typically operate on short trajectories in small discrete spaces. Specifically, the log-probability term $\log \pi_\theta(\mathbf{y} \mid \mathbf{x})$ decomposes into a token-wise sum, $\sum_t \log \pi_\theta(\mathbf{y}_t \mid \mathbf{y}_{<t}, \mathbf{x})$, causing the gradient norm to potentially scale with sequence length.

问题 II：采样不匹配。 主流的强化学习算法，如 PPO 和 GRPO 通常执行微批量更新，并重复使用从旧策略收集的轨迹 $\pi_{\theta_{\text{old}}}$ ，从而实现数据高效的训练。相比之下，基于 KL 的轨迹平衡目标假设完全在线采样，其中响应是从当前策略中抽取的。这种不匹配在将轨迹平衡整合到现有的强化学习流水线时带来了实用上的局限性。

这些局限性促使我们重新定义，保留分布匹配的好处同时解决关键的实际挑战。为了实现这一重新定义，我们首先按照 GFlowNets 文献中的既定做法 [Bartoldson 等, 2025, Lee 等, 2024, Yu 等, 2025a] 重新定义奖励函数，通过纳入参考模型作为对奖励分布的先验约束。具体来说，我们将原始 $\exp(Br(\mathbf{x}, \mathbf{y}))$ 修改为包含参考模型：

$$\exp(\beta r(\mathbf{x}, \mathbf{y})) \cdot \pi_{\text{ref}}(\mathbf{y} \mid \mathbf{x}), \quad (4)$$

其中 $r(\mathbf{x}, \mathbf{v})$ 表示在强化学习中常用的最终奖励，而 π_{ref} 是初始预训练模型。我们遵循 Guo 等人的做法 [2025]，使用基于结果的奖励信号，并对 $r(\mathbf{x}, \mathbf{v})$ 应用组归一化作为 $\hat{r}_i = (r_i - \text{均值}(\mathbf{r})) / \text{std}(\mathbf{r})$ ，其中 $\mathbf{r} = \{r_1, r_2, \dots, r_n\}$ 表示采样组内的奖励集合。通过将重新定义的奖励公式 Eq. 4 代入 Eq. 3，我们推导出以下目标 ²：

$$\min_{\theta} (\log Z_\phi(\mathbf{x}) + \log \pi_\theta(\mathbf{y} \mid \mathbf{x}) - \beta \hat{r}_i(\mathbf{x}, \mathbf{y}) - \log \pi_{\text{ref}}(\mathbf{y} \mid \mathbf{x}))^2 \quad (5)$$

备注 3（通过长度归一化的奖励塑形）。 轨迹平衡将初始流动和最终奖励视为序列级量。相比之下，标准的策略优化方法如 PPO 或 GRPO 在令牌级别分配奖励并计算每一步的梯度。然而，对于不同长度的轨迹（例如 CoT 响应），这种不匹配可能导致对数概率项 $\log \pi_\theta(\mathbf{v} \mid \mathbf{x}) = \sum_{t=1}^{|\mathbf{y}|} \log \pi_\theta(v_t \mid v_{<t}, \mathbf{x})$ 随序列长度缩放。为了解决这个问题，我们通过相对于序列长度归一化对数概率来应用一种形式的奖励塑形。具体来说，我们将该项重新标度为，平衡长序列和

$$\frac{1}{|\mathbf{y}|} \log \pi_\theta(\mathbf{y} \mid \mathbf{x})$$

短序列的贡献并稳定学习信号。

注释 4（重要性采样用于数据高效的训练）。 为了缓解采样不匹配的问题，我们借鉴 PPO 采用了重要性采样来稳定基于离线数据的策略更新。我们使用重要性比率 $w = \pi_\theta(\mathbf{v} \mid \mathbf{x}) / \pi_{\text{old}}(\mathbf{v} \mid \mathbf{x})$ 对过时轨迹进行重新加权，该比率作为替代损失中的系数。由于我们的目标侧重于优化轨迹平衡而非预期回报，我们将当前策略的梯度分离以防止策略过度漂移： $w = \text{detach}[\pi_\theta(\mathbf{y} \mid \mathbf{x})] / \pi_{\text{old}}(\mathbf{y} \mid \mathbf{x})$ 。为了进一步提高稳定性，我们引入了类似 PPO 的剪辑方法来

bound the importance weights: $w = \text{clip}\left(\frac{\pi_\theta(\mathbf{y} \mid \mathbf{x})}{\pi_{\text{old}}(\mathbf{y} \mid \mathbf{x})}, 1 - \epsilon, 1 + \epsilon\right)^{\text{detach}}$.

² 替换式 3 中的轨迹平衡目标中的 $\beta r(\mathbf{x}, \mathbf{y})$ 为 $\beta r(\mathbf{x}, \mathbf{y}) + \log \pi_{\text{ref}}(\mathbf{y} \mid \mathbf{x})$ ，以纳入参考模型约束。

将这些改进融入式 5，我们得到了以下 FlowRL 目标：

FlowRL

$$\mathcal{L}_{\text{FlowRL}} = w \cdot \left(\log Z_\phi(\mathbf{x}) + \frac{1}{|\mathbf{y}|} \log \pi_\theta(\mathbf{y} | \mathbf{x}) - \beta \hat{r}(\mathbf{x}, \mathbf{y}) - \frac{1}{|\mathbf{y}|} \log \pi_{\text{ref}}(\mathbf{y} | \mathbf{x}) \right)^2 \quad (6)$$

其中，剪辑的重要性权重 w 和标准化奖励 $\hat{r}(\mathbf{x}, \mathbf{y})$ 定义为：

$$w = \text{clip}\left(\frac{\pi_\theta(\mathbf{y} | \mathbf{x})}{\pi_{\text{old}}(\mathbf{y} | \mathbf{x})}, 1 - \epsilon, 1 + \epsilon\right)^{\text{detach}}, \quad \hat{r}_i = \frac{r_i - \text{mean}(\mathbf{r})}{\text{std}(\mathbf{r})}. \quad (7)$$

我们在训练过程中使用此目标更新策略参数 θ ，并将此策略称为 FlowRL。实现细节和理论分析分别在 § 4 和 § B 中提供。

4. 实验设置

骨干模型。在等式 6 中有两个可学习模块：策略模型 π_θ 和划分函数 Z_ϕ 。对于策略模型 π_θ ，我们分别使用 Qwen-2.5-7B/32B [团队, 2024] 进行数学任务，以及 DeepSeek-R1-Distill-Qwen-7B [DeepSeek-AI, 2025] 进行代码任务。参考模型 π_{ref} 是相应的固定预训练模型。对于划分函数 Z_ϕ ，我们遵循 Lee 等人 [2024] 的方法，使用一个随机初始化的三层 MLP，其隐藏维度与基础模型匹配。输入到 Z_ϕ 的是语言模型编码输入 $\mathbf{x}$ 后的隐藏状态的均值，输出是一个标量值。我们在 § E 中详细说明了 Z_ϕ 的实现。所有训练脚本都基于 veRL [盛等人, 2024]。对于奖励函数，我们遵循 Lee 等人 [2024] 的方法，设置了超参数 $\beta = 15$ 。

基线。我们将我们的方法与三个具有代表性的奖励最大化强化学习基线进行了比较：REINFORCE++ (R++; 胡等人, 2025, Sutton 等人, 1999b), PPO [Schulman 等人, 2017]，以及 GRPO [邵等人, 2024]。所有基线都遵循官方的 veRL 食谱，并保持一致的训练配置。为了公平比较，所有方法使用相同的学习率、批大小和训练步数，并在收敛时使用相同的步数进行评估。

训练配置。我们在数学和代码领域进行了实验。对于数学领域，我们使用从 DAPO [余等人, 2025b] 收集的训练集。对于代码领域，我们遵循 DeepCoder [罗等人, 2025] 的设置，使用他们的训练集。对于 7B 模型的训练，我们使用配备有 8 个 NVIDIA H800 GPU（每个 80GB 内存）的单节点。对于 32B 模型的训练，我们扩展到 4 个节点，共 32 个 GPU，以满足更大的内存需求。所有实验在两种模型尺寸上均使用 `max_prompt_length = 2048` 和 `max_response_length = 8192`。我们为数学推理任务设定了 512 的批大小，为代码推理任务设定了 64 的批大小。我们将学习率设定为 `1e-6`，并启用 veRL 中的动态批大小以提高训练效率。对于 GRPO 和 FlowRL，我们配置了 `rollout_n = 8`，这意味着每个提示生成 8 个响应回放作为组大小。

评估配置。对于数学领域，我们在六个具有挑战性的基准上进行评估：AIME 2024/2025 [美国数学协会, 2025], AMC 2023 [美国数学协会, 2023], MATH-500 [Lightman 等人, 2023a], Minerva [Lewkowycz 等人, 2022], 和奥林匹克竞赛 [He 等人, 2024]。对于代码生成领域，我们在 LiveCodeBench [Jain 等人, 2024], CodeForces [Penedo 等人, 2025], 和 HumanEval+ [Chen 等人, 2021] 上进行评估。对于所有评估数据集，我们执行 16 次运行并报告平均准确率，记为 Avg@16。我们进一步报告 Codeforces 的评分和百分位数。在生成过程中，我们对所有评估使用采样参数 `temperature = 0.6` 和 `top_p = 0.95`。评估的响应长度设置为 8,192，与训练配置一致。

Models	AIME24	AIME25	AMC23	MATH500	Minerva	Olympiad	Avg
Qwen2.5-32B-Base, Max Response Len = 8K tokens							
Backbone	4.58	2.08	28.59	52.48	26.99	21.37	22.68
R++	14.79 _{+10.21}	9.17 _{+7.08}	52.65 _{+24.06}	44.35 _{-8.13}	17.37 _{-9.62}	24.52 _{+3.15}	27.14
PPO	26.87 _{+22.29}	20.41 _{+18.33}	76.40 _{+47.81}	69.17 _{+16.69}	28.79 _{+1.80}	37.90 _{+16.53}	43.25
GRPO	23.12 _{+18.54}	14.58 _{+12.50}	76.87 _{+48.28}	61.60 _{+9.12}	18.95 _{-8.04}	34.94 _{+13.57}	38.34
FlowRL	23.95 _{+19.37}	21.87 _{+19.79}	73.75 _{+45.16}	80.75 _{+28.27}	38.21 _{+11.22}	51.83 _{+30.46}	48.39
Qwen2.5-7B-Base, Max Response Len = 8K tokens							
Backbone	4.38	2.08	30.78	54.47	22.38	24.03	23.02
R++	11.04 _{+6.66}	5.41 _{+3.33}	66.71 _{+35.93}	54.25 _{-0.22}	24.37 _{+1.99}	27.33 _{+3.30}	31.52
PPO	9.38 _{+5.00}	7.29 _{+5.21}	63.43 _{+32.65}	57.98 _{+3.51}	26.53 _{+4.15}	27.25 _{+3.22}	31.98
GRPO	13.54 _{+9.16}	9.79 _{+7.71}	64.53 _{+33.75}	57.05 _{+2.58}	23.06 _{+0.68}	26.88 _{+2.85}	32.48
FlowRL	15.41 _{+11.03}	10.83 _{+8.75}	54.53 _{+23.75}	66.96 _{+12.49}	31.41 _{+9.03}	34.61 _{+10.58}	35.63

表 1 | 数学推理基准上的结果。我们报告 Avg@16 准确率，并将相对改进显示为下标。正向增益以绿色显示，负向变化以红色显示。FlowRL 在 7B 和 32B 模型规模上均超越所有基线。

Models	LiveCodeBench		CodeForces		HumanEval+
	Avg@16	Pass@16	Rating	Percentile	Avg@16
DeepSeek-R1-Distill-Qwen-7B, Max Response Len = 8K tokens					
Backbone	30.68	49.46	886.68	19.4%	80.90
R++	30.46 _{-0.22}	52.68 _{+3.22}	1208.03 _{+321.35}	56.8% _{+37.4%}	76.61 _{-4.29}
PPO	35.10 _{+4.42}	54.48 _{+5.02}	1403.07 _{+516.39}	73.7% _{+54.3%}	82.32 _{+1.42}
GRPO	32.75 _{+2.07}	52.32 _{+2.86}	1313.82 _{+427.14}	67.1% _{+47.7%}	80.13 _{-0.77}
FlowRL	37.43 _{+6.75}	56.27 _{+6.81}	1549.47 _{+662.79}	83.3% _{+63.9%}	83.28 _{+2.38}

表 2 | 代码基准上的结果。我们报告度量值，并将相对改进显示为下标。正向增益以绿色显示，负向变化以红色显示。FlowRL 在所有三个基准上均表现出最强的性能。

5. 结果

5.1. 主要结果

我们的实验结果总结于表 1 和表 2，表明 FlowRL 在数学和代码推理领域的一系列奖励最大化基线上始终表现更优。表 1 报告了使用 7B 和 32B 基础模型的数学推理基准上的结果，而表 2 展示了相应的代码推理任务的结果。在数学推理任务上，FlowRL 使用 7B 模型达到了最高的平均准确率 35.6%，使用 32B 模型达到了 48.4%，分别超过了 PPO 5.1% 和 GRPO 10.1%。FlowRL 在 MATH-500 和奥林匹克问题等具有挑战性的基准上显示出显著的改进，证明了其在各种数学领域的持续优势。在代码生成任务上，FlowRL 取得了令人信服的改进，在 LiveCodeBench 上获得了最高 Avg@16 得分为 37.43%，Codeforces 评分为 1549.47，百分位排名为 83.3%，以及在 HumanEval+ 上达到了 83.28% 的准确率，全面超越所有基线。这些在两个领域和模型规模上的持续性能提升提供了有力的实证证据，证明 FlowRL 的流平衡优化成功提升了性能。

Method	AIME 2024	AIME 2025	AMC 2023	MATH-500	Minerva	Olympiad	Avg
FlowRL	15.41	10.83	54.53	66.96	31.41	34.61	35.63
w/o IS	6.25	7.91	41.40	56.97	22.19	25.52	26.71
Zhang et al. [2025a]	10.41	6.66	53.75	66.50	30.97	33.72	33.67

表 3 | 使用 Qwen2.5-7B 作为基础模型的 FlowRL 消融实验。平均值@16 准确率在六个数学推理基准上进行了报告。IS 表示重要性采样。

泛化。这一改进来自于促进多样化的解决方案探索，与之前的奖励最大化强化学习方法相比。

5.2. 消融实验

我们对重要性采样和超参数 β 进行了消融实验。对于重要性采样，我们比较了有和没有它的性能，并实现了一种由张等人 [2025a] 提出的组合损失方法，该方法同时优化 GFlowNets 和 PPO 目标。这种组合损失专注于优化扩散模型，并将其适应于长期 CoT 推理任务进行比较。表 3 表明，重要性采样显著提高了 FlowRL 在所有数学推理基准上的性能。与张等人 [2025a] 相比，将重要性采样作为轨迹级比率比 GFlowNets 和 PPO 的组合损失更为合适。没有重要性采样的性能下降（从 35.63% 降至 26.71%）突显了纠正生成回放和策略训练之间分布不匹配的重要性。对于超参数 β ，我们进行了一系列参数消融实验，图 3 显示了 $\beta = 15$ 达到了最优性能，详细结果见表 7。




图 3 | 对 FlowRL 中的 β 进行消融实验。 $\beta = 15$ （用蓝色突出显示）实现了最佳性能。

6. 分析

6.1. 多样性分析

为了评估解决方案多样性，我们遵循了余等人 [2025a] 的方法，并使用 GPT-4o-mini[OpenAI, 2024] 来评估每种方法在 AIME 24/25 上生成的所有响应。评估提示在附录 E 中给出。如图 4 所示，FlowRL 相较于基线方法获得了更高的多样性分数。这表明，与倾向于表现出重复解决方案模式的基线相比，FlowRL 提高了样本多样性。这种多样性评估揭示了不同方法之间的探索模式存在显著差异。与最强基线（PPO）相比，多样性分数几乎翻倍，这表明 FlowRL 生成了质上不同的解决方案方法，而不仅仅是同一策略的小变化。多样性分析提供了对我们核心假设的经验验证，即流平衡优化促进了复杂推理任务中的模式覆盖。

表 4 | 对比 GRPO 和 FlowRL 在 AIME 问题上的应用案例。 GRPO 表现出重复模式（AM-GM $\times 3$ 次，恒等循环 $\times 2$ 次），而 FlowRL 遵循更多样化的解决方案路径。

	Content (boxed = actions; “ $\times k$ ” = repeated; “...” = omitted)
Question	Let $\mathcal{B}$ be the set of rectangular boxes with surface area 54 and volume 23. Let r be the radius of the smallest sphere that can contain each box in $\mathcal{B}$. If $r^2 = \frac{p}{q}$ with $\gcd(p, q) = 1$, find $p + q$.
GRPO	“... denote a, b, c ... $2(ab+bc+ca) = 54, abc = 23$... $d = \sqrt{a^2 + b^2 + c^2}, r = d/2$... $(a+b+c)^2 = a^2+b^2+c^2 + 2(ab+bc+ca)$... AM-GM $\times 3$: AM-GM (1) ... AM-GM (2) ... AM-GM (3) ... $(a+b+c)^3$ identity loop $\times 2$: loop (1) ... loop (2) ... $a = b = c$ (contradiction) ... back to $(a+b+c)^2$... no factorization ...”
FlowRL	“... let a, b, c with $2(ab+bc+ca) = 54, abc = 23$... $d = \sqrt{a^2 + b^2 + c^2}, r = d/2$... $(a+b+c)^2 \Rightarrow a^2+b^2+c^2 = s^2 - 54$... $a = b$... $a^3 - 27a + 46 = 0$... rational root $a = 2$... factor $(a - 2)(a^2 + 2a - 23)$... branch $a = -1 + 2\sqrt{6}$... back-sub $c = 23/a^2$... $a^2+b^2+c^2 = \frac{657}{16}$... $r^2 = \frac{657}{64}$... Answer 721 ...”

6.2. 应用案例

表 4 展示了 GRPO 和 FlowRL 在一个典型 AIME 问题上的行为差异。GRPO 表现出重复模式，三次应用 AM-GM 不等式并陷入恒等循环，未能解决问题。FlowRL 探索更多样化的行动：它设定 $a = b$ ，推导出一个三次方程，找到有理根，并得出正确答案。这表明 FlowRL 成功避免了重复探索模式。对比揭示了探索策略的基本差异：GRPO 的奖励最大化方法导致熟悉技术（AM-GM 不等式）的利用，而不探索替代方案，最终得出矛盾结论如 $a = b = c$ 。相比之下，FlowRL 的分布匹配使战略决策成为可能，如对称性假设 $a = b$ ，将问题转化为可处理的三次方程 $a^3 - 27a + 46 = 0$ ，通过有理根测试和多项式因式分解进行系统求解。




图 4 | 展示了 GPT 对 AIME 24/25 问题展开的多样性评分。 FlowRL 生成的解决方案比 R++、GRPO 和 PPO 更具多样性。

7. 相关工作

我们的工作与 GFlowNets、Flow-Matching Policies、长度归一化和 KL 正则化相关。本节讨论三个与我们的工作最密切相关的主题，其他主题包含在附录 D 中。

Reinforcement Learning for LLM Reasoning. RL has emerged as a powerful approach for LLM post-training on reasoning tasks [Guo et al., 2025, Lightman et al., 2023b, Schulman et al., 2017, Shao et al.,

2024, Sutton 等, 1999b]. 多数方法采用最大化奖励的强化学习来优化预期累积回报。熵正则化 [Ahmed 等, 2019, Cheng 等, 2025, Haarnoja 等, 2018] 是一种经典技术, 通过促进策略输出分布的多样性来缓解模式崩塌, 并且已被证明可以在各种设置下增强推理能力 [Chao 等, 2024, Eysenbach 和 Levine, 2021]。然而, 对于长时间的 CoT 推理, 扩展轨迹长度 (例如超过 8k 个标记) 使得正则化信号难以有效影响最大化奖励的学习过程。最近的研究 [Cheng 等, 2025, Cui 等, 2025, Dong 等, 2025, Wang 等, 2025] 发现, 使用更多样化或高熵的训练数据可以进一步提高训练的有效性。与传统的熵正则化相比, 上述方法明确增加了训练数据中低概率 (即高熵) 标记的比例。在我们的工作中, 我们通过从根本上将强化学习的目标从奖励最大化转变为奖励分布匹配来解决模式崩塌问题。详细比较见附录 D。

GFlowNets (GFlowNets). GFlowNets [Bengio 等, 2023a] 代表了一类由多样性驱动算法, 旨在平衡状态之间的概率流。它们与概率建模方法 [Ma 等, Malkin 等, 2023, Zhang 等, 2022a,b, 2024a, Zimmermann 等, 2022] 和控制方法 [Pan 等, 2023b,c,d, Tiapkin 等, 2024, Zhang 等, 2024b] 有着丰富的联系。这一优势使得 GFlowNets 在多个下游任务中取得了成功应用, 例如分子药物发现 [Jain 等, 2022, 2023a,b, Kim 等, 2023, 2024, Liu 等, 2022, Pan 等, 2023a, Shen 等, 2023], 系统发生推断 [Zhou 等, 2024] 以及组合优化 [Zhang 等, 2023a,b]。对于生成式 AI, GFlowNets 提供了一种强大的方法来对齐预训练模型, 适用于图像生成 [Yun 等, 2025, Zhang 等, 2025a] 和语言模型微调 [Hu 等, 2024, Lee 等, 2024, Yu 等, 2025a] 等场景。另一条研究路线主要关注 GFlowNets 的理论方面。最近的理论研究表明, 可以将 GFlowNets 解释为在一个修改过的马尔可夫决策过程 (MDP) 中解决最大熵强化学习问题 [Deleu 等, 2024, Mohammadpour 等, 2024, Tiapkin 等, 2024]。这些理论贡献激励我们从更基础的角度出发, 利用 GFlowNets 的原则来增强强化学习。关于 GFlowNets 理论的全面概述可以在附录 C 中找到。

流匹配策略。流匹配通过学习将样本从先验分布传输到目标分布的矢量场来简化扩散方法。最近的研究探索了流匹配在策略优化中的应用。McAllister 等人 [2025] 利用条件流匹配损失中的优势加权比率重新制定了策略优化, 从而无需昂贵的似然计算即可进行基于流的策略训练。Pfrommer 等人 [2025] 探讨了奖励加权流匹配以改进超越演示性能的策略。Park 等人 [2025] 使用单独的一步策略来避免在使用 RL 训练流策略时的时间反向传播不稳定问题。Zhang 等人 [2025a] 提出了一个结合 PPO 和 GFlowNets 的损失函数, 用于优化扩散模型的对齐。Lv 等人 [2025] 将基于流的策略表示与 Wasserstein 正则化优化相结合, 应用于在线强化学习。然而, 这些方法主要集中在连续控制、图像生成或视觉动作模型上, 而不是解决奖励最大化 RL 中的模式崩溃局限性。受流匹配原理启发, 我们的工作改进了 RL 训练, 增强了训练稳定性并促进了多样化的解决方案探索。

8. 结论

在本研究中, 我们介绍了 FlowRL, 它通过可学习的划分函数将标量奖励转换为归一化的目标分布, 并最小化策略之间的逆 KL 发散

以及目标分布。我们证明该方法在理论上等价于 GFlowNets 中的轨迹平衡目标，并隐式地最大化奖励和熵，从而促进多样化的推理轨迹。为了进一步解决长链推理中的梯度爆炸和采样不匹配问题，我们引入了重要性采样和长度归一化。通过在数学和代码推理基准上的实验，FlowRL 相较于 GRPO 和 PPO 在所有任务上均实现了持续改进。我们的多样性分析和案例研究证实，FlowRL 生成了更多样化的解决方案方法，同时避免了重复模式。

致谢

本文感谢冯明谦和李月泰的宝贵讨论与反馈，这些有助于提升本工作的质量。

参考文献

- Zafarali Ahmed, Nicolas Le Roux, Mohammad Norouzi, and Dale Schuurmans. Understanding the impact of entropy on policy optimization. In *International conference on machine learning*, pages 151–160. PMLR, 2019.
- Mohammad Gheshlaghi Azar, Zhaohan Daniel Guo, Bilal Piot, Remi Munos, Mark Rowland, Michal Valko, and Daniele Calandriello. A general theoretical paradigm to understand learning from human preferences. In *International Conference on Artificial Intelligence and Statistics*, pages 4447–4455. PMLR, 2024.
- Brian R Bartoldson, Siddarth Venkatraman, James Diffenderfer, Moksh Jain, Tal Ben-Nun, Seanie Lee, Minsu Kim, Johan Obando-Ceron, Yoshua Bengio, and Bhavya Kailkhura. Trajectory balance with asynchrony: Decoupling exploration and learning for fast, scalable llm post-training. *arXiv preprint arXiv:2503.18929*, 2025.
- Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow network based generative models for non-iterative diverse candidate generation. *Neural Information Processing Systems (NeurIPS)*, 2021.
- Yoshua Bengio, Salem Lahlou, Tristan Deleu, Edward J. Hu, Mo Tiwari, and Emmanuel Bengio. Gflownet foundations. *Journal of Machine Learning Research*, 24(210):1–55, 2023a. URL <http://jmlr.org/papers/v24/22-0364.html>.
- Yoshua Bengio, Salem Lahlou, Tristan Deleu, Edward J Hu, Mo Tiwari, and Emmanuel Bengio. Gflownet foundations. *The Journal of Machine Learning Research*, 24(1):10006–10060, 2023b.
- Chen-Hao Chao, Chien Feng, Wei-Fang Sun, Cheng-Kuang Lee, Simon See, and Chun-Yi Lee. Maximum entropy reinforcement learning via energy-based normalizing flow. *arXiv preprint arXiv:2405.13629*, 2024.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, Alex Ray, Raul Puri, Gretchen Krueger, Michael Petrov, Heidy Khlaaf, Girish Sastry, Pamela Mishkin, Brooke Chan, Scott Gray, Nick Ryder, Mikhail Pavlov, Alethea Power, Lukasz Kaiser, Mohammad Bavarian, Clemens Winter, Philippe Tillet, Felipe Petroski Such, Dave Cummings, Matthias Plappert, Fotios Chantzis, Elizabeth Barnes, Ariel Herbert-Voss, William Hebgen Guss, Alex Nichol, Alex Paino, Nikolas Tezak, Jie Tang, Igor Babuschkin, Suchir Balaji, Shantanu Jain, William Saunders, Christopher Hesse, Andrew N.

- Carr, Jan Leike, Josh Achiam, Vedant Misra, Evan Morikawa, Alec Radford, Matthew Knight, Miles Brundage, Mira Murati, Katie Mayer, Peter Welinder, Bob McGrew, Dario Amodei, Sam McCandlish, Ilya Sutskever, and Wojciech Zaremba. Evaluating large language models trained on code, 2021.
- Daixuan Cheng, Shaohan Huang, Xuekai Zhu, Bo Dai, Wayne Xin Zhao, Zhenliang Zhang, and Furu Wei. Reasoning with exploration: An entropy perspective. *arXiv preprint arXiv:2506.14758*, 2025.
- Miruna Cretu, Charles Harris, Ilia Igashov, Arne Schneuing, Marwin Segler, Bruno Correia, Julien Roy, Emmanuel Bengio, and Pietro Liò. Synflownet: Design of diverse and novel molecules with synthesis constraints. *arXiv preprint arXiv:2405.01155*, 2024.
- Ganqu Cui, Yuchen Zhang, Jiacheng Chen, Lifan Yuan, Zhi Wang, Yuxin Zuo, Haozhan Li, Yuchen Fan, Huayu Chen, Weize Chen, et al. The entropy mechanism of reinforcement learning for reasoning language models. *arXiv preprint arXiv:2505.22617*, 2025.
- DeepSeek-AI. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning, 2025. URL <https://arxiv.org/abs/2501.12948>.
- Tristan Deleu, Padideh Nouri, Nikolay Malkin, Doina Precup, and Yoshua Bengio. Discrete probabilistic inference as control in multi-path environments. *arXiv preprint arXiv:2402.10309*, 2024.
- Guanting Dong, Hangyu Mao, Kai Ma, Licheng Bao, Yifei Chen, Zhongyuan Wang, Zhongxia Chen, Jiazhen Du, Huiyang Wang, Fuzheng Zhang, et al. Agentic reinforced policy optimization. *arXiv preprint arXiv:2507.19849*, 2025.
- Yilun Du and Igor Mordatch. Implicit generation and modeling with energy based models. *Advances in neural information processing systems*, 32, 2019.
- Benjamin Eysenbach and Sergey Levine. Maximum entropy rl (provably) solves some robust rl problems. *arXiv preprint arXiv:2103.06257*, 2021.
- Leo Gao, John Schulman, and Jacob Hilton. Scaling laws for reward model overoptimization. In *International Conference on Machine Learning*, pages 10835–10866. PMLR, 2023.
- Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shitong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. Pmlr, 2018.
- Chaoqun He, Renjie Luo, Yuzhuo Bai, Shengding Hu, Zhen Leng Thai, Junhao Shen, Jinyi Hu, Xu Han, Yujie Huang, Yuxiang Zhang, et al. Olympiadbench: A challenging benchmark for promoting agi with olympiad-level bilingual multimodal scientific problems. *arXiv preprint arXiv:2402.14008*, 2024.
- Haoran He, Can Chang, Huazhe Xu, and Ling Pan. Looking backward: Retrospective backward synthesis for goal-conditioned GFlownets. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=fNMKqyvuzT>.
- Geoffrey E. Hinton, Peter Dayan, Brendan J. Frey, and R M Neal. The “wake-sleep” algorithm for unsupervised neural networks. *Science*, 268 5214:1158–61, 1995.

- Edward J Hu, Moksh Jain, Eric Elmoznino, Younesse Kaddar, Guillaume Lajoie, Yoshua Bengio, and Nikolay Malkin. Amortizing intractable inference in large language models. *arXiv preprint arXiv:2310.04363*, 2023.
- Edward J Hu, Moksh Jain, Eric Elmoznino, Younesse Kaddar, Guillaume Lajoie, Yoshua Bengio, and Nikolay Malkin. Amortizing intractable inference in large language models. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=Ouj6p4ca60>.
- Jian Hu, Jason Klein Liu, and Wei Shen. Reinforce++: An efficient rlhf algorithm with robustness to both prompt and reward models, 2025. URL <https://arxiv.org/abs/2501.3262>, 3262:32–33, 2025.
- Moksh Jain, Emmanuel Bengio, Alex Hernandez-Garcia, Jarrid Rector-Brooks, Bonaventure F.P. Dossou, Chanakya Ekbote, Jie Fu, Tianyu Zhang, Micheal Kilgour, Dinghuai Zhang, Lena Simine, Payel Das, and Yoshua Bengio. Biological sequence design with GFlowNets. *International Conference on Machine Learning (ICML)*, 2022.
- Moksh Jain, Tristan Deleu, Jason S. Hartford, Cheng-Hao Liu, Alex Hernández-García, and Yoshua Bengio. Gflownets for ai-driven scientific discovery. *ArXiv*, abs/2302.00615, 2023a. URL <https://api.semanticscholar.org/CorpusID:256459319>.
- Moksh Jain, Sharath Chandra Raparthy, Alex Hernandez-Garcia, Jarrid Rector-Brooks, Yoshua Bengio, Santiago Miret, and Emmanuel Bengio. Multi-objective GFlowNets. *International Conference on Machine Learning (ICML)*, 2023b.
- Naman Jain, King Han, Alex Gu, Wen-Ding Li, Fanjia Yan, Tianjun Zhang, Sida Wang, Armando Solar-Lezama, Koushik Sen, and Ion Stoica. Livecodebench: Holistic and contamination free evaluation of large language models for code. *arXiv preprint arXiv:2403.07974*, 2024.
- Koray Kavukcuoglu. Gemini 2.5: Our most intelligent AI model, 2025. URL <https://blog.google/technology/google-deepmind/gemini-model-thinking-updates-march-2025/>. Google Blog (The Keyword), Published Mar. 25, 2025.
- Minsu Kim, Taeyoung Yun, Emmanuel Bengio, Dinghuai Zhang, Yoshua Bengio, Sungsoo Ahn, and Jinkyoo Park. Local search gflownets. *ArXiv*, abs/2310.02710, 2023.
- Minsu Kim, Joohwan Ko, Taeyoung Yun, Dinghuai Zhang, Ling Pan, Woorchang Kim, Jinkyoo Park, Emmanuel Bengio, and Yoshua Bengio. Learning to scale logits for temperature-conditional gflownets, 2024.
- Seanie Lee, Minsu Kim, Lynn Cherif, David Dobre, Juho Lee, Sung Ju Hwang, Kenji Kawaguchi, Gauthier Gidel, Yoshua Bengio, Nikolay Malkin, et al. Learning diverse attacks on large language models for robust red-teaming and safety tuning. *arXiv preprint arXiv:2405.18540*, 2024.
- Aitor Lewkowycz, Anders Andreassen, David Dohan, Ethan Dyer, Henryk Michalewski, Vinay Ramasesh, Ambrose Slone, Cem Anil, Imanol Schlag, Theo Gutman-Solo, Yuhuai Wu, Behnam Neyshabur, Guy Gur-Ari, and Vedant Misra. Solving quantitative reasoning problems with language models. In S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, editors, *Advances in Neural Information Processing Systems*, volume 35, pages 3843–3857. Curran Associates, Inc., 2022. URL https://proceedings.neurips.cc/paper_files/paper/2022/file/18abbef8cfe9203fdf9053c9c4fe191-Paper-Conference.pdf.
- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. *arXiv preprint arXiv:2305.20050*, 2023a.

- Hunter Lightman, Vineet Kosaraju, Yuri Burda, Harrison Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. In *The Twelfth International Conference on Learning Representations*, 2023b.
- Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=PqvMRDCJT9t>.
- Dianbo Liu, Moksh Jain, Bonaventure F. P. Dossou, Qianli Shen, Salem Lahlou, Anirudh Goyal, Nikolay Malkin, Chris C. Emezue, Dinghuai Zhang, Nadhir Hassen, Xu Ji, Kenji Kawaguchi, and Yoshua Bengio. Gflowout: Dropout with generative flow networks. In *International Conference on Machine Learning*, 2022.
- Mingjie Liu, Shizhe Diao, Jian Hu, Ximing Lu, Xin Dong, Hao Zhang, Alexander Bukharin, Shaokun Zhang, Jiaqi Zeng, Makesh Narsimhan Sreedhar, et al. Scaling up rl: Unlocking diverse reasoning in llms via prolonged training. *arXiv preprint arXiv:2507.12507*, 2025a.
- Zhen Liu, Tim Z Xiao, , Weiyang Liu, Yoshua Bengio, and Dinghuai Zhang. Efficient diversity-preserving diffusion alignment via gradient-informed gflownets. In *ICLR*, 2025b.
- Zichen Liu, Changyu Chen, Wenjun Li, Penghui Qi, Tianyu Pang, Chao Du, Wee Sun Lee, and Min Lin. Understanding r1-zero-like training: A critical perspective. *arXiv preprint arXiv:2503.20783*, 2025c.
- Michael Luo, Sijun Tan, Roy Huang, Xiaoxiang Shi, Rachel Xin, Colin Cai, Ameen Patel, Alpay Ariyak, Qingyang Wu, Ce Zhang, Li Erran Li, Raluca Ada Popa, Ion Stoica, and Tianjun Zhang. Deepcoder: A fully open-source 14b coder at o3-mini level, 2025. Notion Blog.
- Lei Lv, Yunfei Li, Yu Luo, Fuchun Sun, Tao Kong, Jiafeng Xu, and Xiao Ma. Flow-based policy for online reinforcement learning. *arXiv preprint arXiv:2506.12811*, 2025.
- Jiangyan Ma, Emmanuel Bengio, Yoshua Bengio, and Dinghuai Zhang. Baking symmetry into gflownets.
- MAA. American mathematics competitions - amc. <https://maa.org/>, 2023.
- MAA. American invitational mathematics examination - aime. <https://maa.org/>, 2025.
- Kanika Madan, Jarrod Rector-Brooks, Maksym Korablyov, Emmanuel Bengio, Moksh Jain, Andrei Cristian Nica, Tom Bosc, Yoshua Bengio, and Nikolay Malkin. Learning gflownets from partial episodes for improved convergence and stability. In *International Conference on Machine Learning*, pages 23467–23483. PMLR, 2023.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in gflownets. *Advances in Neural Information Processing Systems*, 35: 5955–5967, 2022.
- Nikolay Malkin, Salem Lahlou, Tristan Deleu, Xu Ji, Edward Hu, Katie Everett, Dinghuai Zhang, and Yoshua Bengio. GFlowNets and variational inference. *International Conference on Learning Representations (ICLR)*, 2023.
- David McAllister, Songwei Ge, Brent Yi, Chung Min Kim, Ethan Weber, Hongsuk Choi, Haiwen Feng, and Angjoo Kanazawa. Flow matching policy gradients. *arXiv preprint arXiv:2507.21053*, 2025.

- Sobhan Mohammadpour, Emmanuel Bengio, Emma Frejinger, and Pierre-Luc Bacon. Maximum entropy gflownets with soft q-learning. In *International Conference on Artificial Intelligence and Statistics*, pages 2593–2601. PMLR, 2024.
- OpenAI. Gpt-4o mini. <https://openai.com/index/>, 2024. Accessed: 2024.
- Alexander Pan, Kush Bhatia, and Jacob Steinhardt. The effects of reward misspecification: Mapping and mitigating misaligned models. *arXiv preprint arXiv:2201.03544*, 2022.
- Ling Pan, Moksh Jain, Kanika Madan, and Yoshua Bengio. Pre-training and fine-tuning generative flow networks, 2023a.
- Ling Pan, Nikolay Malkin, Dinghuai Zhang, and Yoshua Bengio. Better training of GFlowNets with local credit and incomplete trajectories. *International Conference on Machine Learning (ICML)*, 2023b.
- Ling Pan, Dinghuai Zhang, Aaron Courville, Longbo Huang, and Yoshua Bengio. Generative augmented flow networks. *International Conference on Learning Representations (ICLR)*, 2023c.
- Ling Pan, Dinghuai Zhang, Moksh Jain, Longbo Huang, and Yoshua Bengio. Stochastic generative flow networks. *Uncertainty in Artificial Intelligence (UAI)*, 2023d.
- Seohong Park, Qiyang Li, and Sergey Levine. Flow q-learning. In *Forty-second International Conference on Machine Learning*, 2025. URL <https://openreview.net/forum?id=KVf2SFL1pi>.
- Guilherme Penedo, Anton Lozhkov, Hynek Kydliček, Loubna Ben Allal, Edward Beeching, Agustín Piqueres Lajarín, Quentin Gallouédec, Nathan Habib, Lewis Tunstall, and Leandro von Werra. Codeforces. <https://huggingface.co/datasets/open-r1/codeforces>, 2025.
- Samuel Pfrommer, Yixiao Huang, and Somayeh Sojoudi. Reinforcement learning for flow-matching policies. *arXiv preprint arXiv:2507.15073*, 2025.
- Abhinav Rastogi, Albert Q Jiang, Andy Lo, Gabrielle Berrada, Guillaume Lample, Jason Rute, Joep Barmmentlo, Karmesh Yadav, Kartik Khandelwal, Khyathi Raghavi Chandu, et al. Magistral. *arXiv preprint arXiv:2506.10910*, 2025.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- Max W. Shen, Emmanuel Bengio, Ehsan Hajiramezanali, Andreas Loukas, Kyunghyun Cho, and Tommaso Biancalani. Towards understanding and improving gflownet training. *ArXiv*, abs/2305.07170, 2023. URL <https://api.semanticscholar.org/CorpusID:258676487>.
- Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. Hybridflow: A flexible and efficient rlhf framework. *arXiv preprint arXiv: 2409.19256*, 2024.
- Joar Skalse, Nikolaus Howe, Dmitrii Krasheninnikov, and David Krueger. Defining and characterizing reward gaming. *Advances in Neural Information Processing Systems*, 35:9460–9471, 2022.
- Richard S Sutton, Andrew G Barto, et al. Reinforcement learning. *Journal of Cognitive Neuroscience*, 11(1):126–134, 1999a.

- Richard S Sutton, David McAllester, Satinder Singh, and Yishay Mansour. Policy gradient methods for reinforcement learning with function approximation. In S. Solla, T. Leen, and K. Müller, editors, *Advances in Neural Information Processing Systems*, volume 12. MIT Press, 1999b. URL https://proceedings.neurips.cc/paper_files/paper/1999/file/464d828b85b0bed98e80ade0a5c43b0f-Paper.pdf.
- Kimi Team, Angang Du, Bofei Gao, Bowei Xing, Changjiu Jiang, Cheng Chen, Cheng Li, Chenjun Xiao, Chenzhuang Du, Chonghua Liao, et al. Kimi k1. 5: Scaling reinforcement learning with llms. *arXiv preprint arXiv:2501.12599*, 2025.
- Qwen Team. Qwen2.5: A party of foundation models, September 2024. URL <https://qwenlm.github.io/blog/qwen2.5/>.
- Daniil Tiapkin, Nikita Morozov, Alexey Naumov, and Dmitry P Vetrov. Generative flow networks as entropy-regularized rl. In *International Conference on Artificial Intelligence and Statistics*, pages 4213–4221. PMLR, 2024.
- Shenzhi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen, Jianxin Yang, Zhenru Zhang, et al. Beyond the 80/20 rule: High-entropy minority tokens drive effective reinforcement learning for llm reasoning. *arXiv preprint arXiv:2506.01939*, 2025.
- Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35:24824–24837, 2022.
- Fangxu Yu, Lai Jiang, Haoqiang Kang, Shibo Hao, and Lianhui Qin. Flow of reasoning: Training llms for divergent reasoning with minimal examples. In *Forty-second International Conference on Machine Learning*, 2025a.
- Qiyang Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Tiantian Fan, Gaohong Liu, Lingjun Liu, Xin Liu, et al. Dapo: An open-source llm reinforcement learning system at scale. *arXiv preprint arXiv:2503.14476*, 2025b.
- Taeyoung Yun, Dinghuai Zhang, Jinkyoo Park, and Ling Pan. Learning to sample effective and diverse prompts for text-to-image generation. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 23625–23635, 2025.
- Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah Goodman. Star: Bootstrapping reasoning with reasoning. *Advances in Neural Information Processing Systems*, 35:15476–15488, 2022.
- David W. Zhang, Corrado Rainone, Markus F. Peschl, and Roberto Bondesan. Robust scheduling with gflownets. *ArXiv*, abs/2302.05446, 2023a. URL <https://api.semanticscholar.org/CorpusID:256827133>.
- Dinghuai Zhang, Ricky T. Q. Chen, Nikolay Malkin, and Yoshua Bengio. Unifying generative models with GFlowNets and beyond. *arXiv preprint arXiv:2209.02606v2*, 2022a.
- Dinghuai Zhang, Nikolay Malkin, Zhen Liu, Alexandra Volokhova, Aaron Courville, and Yoshua Bengio. Generative flow networks for discrete probabilistic modeling. *International Conference on Machine Learning (ICML)*, 2022b.
- Dinghuai Zhang, Hanjun Dai, Nikolay Malkin, Aaron C. Courville, Yoshua Bengio, and Ling Pan. Let the flows tell: Solving graph combinatorial optimization problems with gflownets. *ArXiv*, abs/2305.17010, 2023b.

- Dinghuai Zhang, Ricky T. Q. Chen, Cheng-Hao Liu, Aaron Courville, and Yoshua Bengio. Diffusion generative flow samplers: Improving learning signals through partial trajectory optimization, 2024a.
- Dinghuai Zhang, Ling Pan, Ricky T. Q. Chen, Aaron Courville, and Yoshua Bengio. Distributional gflownets with quantile flows, 2024b.
- Dinghuai Zhang, Yizhe Zhang, Jiatao Gu, Ruixiang ZHANG, Joshua M. Susskind, Navdeep Jaitly, and Shuangfei Zhai. Improving GFlownets for text-to-image diffusion alignment. *Transactions on Machine Learning Research*, 2025a. ISSN 2835-8856. URL <https://openreview.net/forum?id=XDbY3qhM42>.
- Kaiyan Zhang, Yuxin Zuo, Bingxiang He, Youbang Sun, Runze Liu, Che Jiang, Yuchen Fan, Kai Tian, Guoli Jia, Pengfei Li, et al. A survey of reinforcement learning for large reasoning models. *arXiv preprint arXiv:2509.08827*, 2025b.
- Xiaojiang Zhang, Jinghui Wang, Zifei Cheng, Wenhao Zhuang, Zheng Lin, Minglei Zhang, Shaojie Wang, Yinghan Cui, Chao Wang, Junyi Peng, et al. Srpo: A cross-domain implementation of large-scale reinforcement learning on llm. *arXiv preprint arXiv:2504.14286*, 2025c.
- Chujie Zheng, Shixuan Liu, Mingze Li, Xiong-Hui Chen, Bowen Yu, Chang Gao, Kai Dang, Yuqiong Liu, Rui Men, An Yang, et al. Group sequence policy optimization. *arXiv preprint arXiv:2507.18071*, 2025.
- Mingyang Zhou, Zichao Yan, Elliot Layne, Nikolay Malkin, Dinghuai Zhang, Moksh Jain, Mathieu Blanchette, and Yoshua Bengio. Phylogfn: Phylogenetic inference with generative flow networks, 2024.
- Heiko Zimmermann, Fredrik Lindsten, J.-W. van de Meent, and Christian Andersson Naesseth. A variational perspective on generative flow networks. *ArXiv*, abs/2210.07992, 2022. URL <https://api.semanticscholar.org/CorpusID:252907672>.

A. 命题 1 的证明

我们首先分析策略 $\pi_\theta(\mathbf{y} | \mathbf{x})$ 与目标奖励分布 $\frac{\exp(\beta r(\mathbf{x}, \mathbf{y}))}{Z_\phi(\mathbf{x})}$ 之间的 Kullback-Leibler (KL) 发散的梯度 $\nabla_{\theta} \overline{D_{\text{KL}}}$:

$$\begin{aligned}
& \nabla_{\theta} D_{\text{KL}} \left(\pi_\theta(\mathbf{y} | \mathbf{x}) \parallel \frac{\exp(\beta r(\mathbf{x}, \mathbf{y}))}{Z_\phi(\mathbf{x})} \right) \\
&= \nabla_{\theta} \int \pi_\theta(\mathbf{y} | \mathbf{x}) \log \left[\frac{\pi_\theta(\mathbf{y} | \mathbf{x}) \cdot Z_\phi(\mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y}))} \right] d\mathbf{y} \\
&= \int \nabla_{\theta} \pi_\theta(\mathbf{y} | \mathbf{x}) \log \left[\frac{Z_\phi(\mathbf{x}) \pi_\theta(\mathbf{y} | \mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y}))} \right] d\mathbf{y} + \int \pi_\theta(\mathbf{y} | \mathbf{x}) \nabla_{\theta} \log \left[\frac{Z_\phi(\mathbf{x}) \pi_\theta(\mathbf{y} | \mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y}))} \right] d\mathbf{y} \\
&= \int \pi_\theta(\mathbf{y} | \mathbf{x}) \nabla_{\theta} \log \pi_\theta(\mathbf{y} | \mathbf{x}) \log \left[\frac{Z_\phi(\mathbf{x}) \pi_\theta(\mathbf{y} | \mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y}))} \right] d\mathbf{y} + \underbrace{\int \pi_\theta(\mathbf{y} | \mathbf{x}) \nabla_{\theta} \log \pi_\theta(\mathbf{y} | \mathbf{x}) d\mathbf{y}}_{=\nabla_{\theta} \int \pi_\theta(\mathbf{y} | \mathbf{x}) d\mathbf{y} = \nabla_{\theta} 1 = 0} \\
&= \int \pi_\theta(\mathbf{y} | \mathbf{x}) \nabla_{\theta} \log \pi_\theta(\mathbf{y} | \mathbf{x}) \log \left[\frac{Z_\phi(\mathbf{x}) \pi_\theta(\mathbf{y} | \mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y}))} \right] d\mathbf{y} \\
&= \mathbb{E}_{\mathbf{y} \sim \pi_\theta(\cdot | \mathbf{x})} \left[\log \left(\frac{Z_\phi(\mathbf{x}) \pi_\theta(\mathbf{y} | \mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y}))} \right) \cdot \nabla_{\theta} \log \pi_\theta(\mathbf{y} | \mathbf{x}) \right]
\end{aligned} \tag{8}$$

接下来，考虑 GFlowNets 学习中使用的轨迹平衡目标 [Bartoldson 等, 2025, Bengio 等, 2023b, Lee 等, 2024]，定义为：

$$\mathcal{L}(\mathbf{y}, \mathbf{x}; \theta) = \left(\log \frac{Z_\phi(\mathbf{x}) \pi_\theta(\mathbf{y} | \mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y}))} \right)^2. \tag{9}$$

对该目标关于 θ 求梯度得到：

$$\nabla_{\theta} \mathcal{L}(\theta) = 2 \cdot \mathbb{E}_{\mathbf{y} \sim \pi_\theta(\cdot | \mathbf{x})} \left[\left(\log \frac{Z_\phi(\mathbf{x}) \cdot \pi_\theta(\mathbf{y} | \mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y}))} \right) \cdot \nabla_{\theta} \log \pi_\theta(\mathbf{y} | \mathbf{x}) \right] \tag{10}$$

因此，最小化 KL 发散在常数因子内等价于最小化轨迹平衡损失，这证实了命题 1。

B. 理论分析

我们对 FlowRL 进行解释，阐明目标中每个组件的作用。

命题 5. 最小化方程 5 中的 KL 发散在梯度意义上等价于同时最大化奖励和策略熵：

$$\max_{\theta} \mathbb{E}_{\mathbf{y} \sim \pi_\theta} \left[\underbrace{\beta r(\mathbf{x}, \mathbf{y}) - \log Z_\phi(\mathbf{x}) + \log \pi_{\text{ref}}(\mathbf{y} | \mathbf{x})}_{\text{奖励}} \right] + \underbrace{\mathcal{H}(\pi_\theta)}_{\text{entropy}}. \tag{11}$$

注释 6 (FlowRL 超越奖励最大化)。命题 5 揭示了 FlowRL 可以被解释为同时最大化预期奖励和策略熵。这种转变鼓励策略探索更广泛的一系列高质量解决方案，从而在推理任务上实现更多样化和泛化的表现。我们的解释也与先前的工作一致，这些工作将 GFlowNets 训练视为一种最大熵强化学习的形式 [Deleu 等, 2024, Mohammadpour 等, 2024]。

命题 5 的证明如下所示。

回忆方程 3 和方程 5, FlowRL 目标源自 KL 发散的最小化:

$$D_{\text{KL}}\left(\pi_{\theta}(\mathbf{y} | \mathbf{x}) \parallel \frac{\exp(\beta r(\mathbf{x}, \mathbf{y})) \cdot \pi_{\text{ref}}(\mathbf{y} | \mathbf{x})}{Z_{\phi}(\mathbf{x})}\right) = \int \pi_{\theta}(\mathbf{y} | \mathbf{x}) \log \left[\frac{Z_{\phi}(\mathbf{x}) \pi_{\theta}(\mathbf{y} | \mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y})) \cdot \pi_{\text{ref}}(\mathbf{y} | \mathbf{x})} \right] d\mathbf{y} \quad (12)$$

重新排列各项, 我们得到:

$$\begin{aligned} & \arg \min_{\theta} D_{\text{KL}}\left(\pi_{\theta}(\mathbf{y} | \mathbf{x}) \parallel \frac{\exp(\beta r(\mathbf{x}, \mathbf{y})) \cdot \pi_{\text{ref}}(\mathbf{y} | \mathbf{x})}{Z_{\phi}(\mathbf{x})}\right) \\ &= \arg \min_{\theta} \int \pi_{\theta}(\mathbf{y} | \mathbf{x}) \log \left[\frac{Z_{\phi}(\mathbf{x}) \pi_{\theta}(\mathbf{y} | \mathbf{x})}{\exp(\beta r(\mathbf{x}, \mathbf{y})) \cdot \pi_{\text{ref}}(\mathbf{y} | \mathbf{x})} \right] d\mathbf{y} \\ &= \arg \max_{\theta} \left\{ \mathbb{E}_{\mathbf{y} \sim \pi_{\theta}(\cdot | \mathbf{x})} \log \left[\frac{\exp(\beta r(\mathbf{x}, \mathbf{y})) \cdot \pi_{\text{ref}}(\mathbf{y} | \mathbf{x})}{Z_{\phi}(\mathbf{x})} \right] - \int \pi_{\theta}(\mathbf{y} | \mathbf{x}) \log \pi_{\theta}(\mathbf{y} | \mathbf{x}) d\mathbf{y} \right\} \\ &= \arg \max_{\theta} \left\{ \mathbb{E}_{\mathbf{y} \sim \pi_{\theta}(\cdot | \mathbf{x})} \log \left[\frac{\exp(\beta r(\mathbf{x}, \mathbf{y})) \cdot \pi_{\text{ref}}(\mathbf{y} | \mathbf{x})}{Z_{\phi}(\mathbf{x})} \right] + \mathcal{H}(\pi_{\theta}) \right\} \end{aligned} \quad (13)$$

最后, 我们将 FlowRL 目标表示为其紧凑形式:

$$\max_{\theta} \mathbb{E}_{\mathbf{y} \sim \pi_{\theta}(\cdot | \mathbf{x})} \left[\underbrace{\beta r(\mathbf{x}, \mathbf{y})}_{\text{奖励}} - \underbrace{\log Z_{\phi}(\mathbf{x})}_{\text{归一化}} + \underbrace{\log \pi_{\text{ref}}(\mathbf{y} | \mathbf{x})}_{\text{先验}} + \underbrace{\mathcal{H}(\pi_{\theta})}_{\text{熵}} \right]. \quad (14)$$

先验对齐 因此, 最小化 FlowRL 目标可以解释为同时最小化奖励和熵, 同时也使策略与结构化的先验对齐。奖励项驱动任务性能, 而归一化项 $Z_{\phi}(\mathbf{x})$ 确保与适当归一化的目标分布的一致性。这鼓励策略 π_{θ} 覆盖整个奖励加权分布, 而不是坍塌到几个高奖励模式。参考策略 π_{ref} 提供归纳偏差, 使策略趋向于期望的结构, 而熵项 $\mathcal{H}(\pi_{\theta})$ 鼓励采样的解决方案具有多样性。这些组件共同促进 FlowRL 更好的泛化。

C. GFlowNets

我们遵循 [何等人, 225 年, 马丹等人, 2023 年] 的符号来介绍 GFlowNets 的基本概念。设 $\mathbf{X}$ 表示组合对象, 并令 R 是一个奖励函数, 它将非负值分配给每个对象 $x \in \mathbf{X}$ 。GFlowNets 旨在学习一个顺序的、构造性的采样策略 π , 该策略生成的对象 x 的概率与其奖励成正比, 即 $\pi(x) \propto R(x)$ 。这个过程可以用有向无环图 (DAG) $G = (\mathcal{S}, \mathcal{A})$ 表示, 其中顶点 $s \in \mathcal{S}$ 被称为状态, 有向边 $(u \rightarrow v) \in \mathcal{A}$ 称为动作。生成一个对象 $x \in \mathbf{X}$ 对应于 DAG 中的一个完整的轨迹 $\tau = (s_0 \rightarrow \dots \rightarrow s_n) \in \mathcal{T}$, 从初始状态 s_0 开始, 结束于终端状态 $s_n \in \mathbf{X}$ 。状态流 $F(s)$ 定义为分配给每个状态 $s \in \mathcal{S}$ 的非负权重。前向策略 $P_F(s' | s)$ 规定了转移到子状态 s' 的转移概率, 而后向策略 $P_B(s | s')$ 规定了转移到父状态 s 的转移概率。为此, 详细平衡目标在每条边 $(s \rightarrow s') \in \mathcal{A}$ 上强制执行局部流一致性。

$$\forall (s \rightarrow s') \in \mathcal{A}, \quad F_{\theta}(s) P_F(s' | s; \theta) = F_{\theta}(s') P_B(s | s'; \theta). \quad (15)$$

为了实现这种流一致性，GFlowNets 在不同粒度级别上采用了训练目标，包括详细平衡 [Bengio 等人, 2023b]、轨迹平衡 [Malkin 等人, 2022] 和子轨迹平衡 [Madan 等人, 2023]。利用其寻求多样性的行为，GFlowNets 已成功应用于多个领域，包括分子生成 [Cretu 等人, 2024]、扩散微调 [Liu 等人, 2025b, Zhang 等人, 2025a] 和摊销推理 [胡等人, 2024, 余等人, 2025a]。在 GFlowNets 的各种训练目标中，轨迹平衡在轨迹层面上维持流一致性，定义为：

$$Z_{\theta} \prod_{t=1}^n P_F(s_t | s_{t-1}; \theta) = R(x) \prod_{t=1}^n P_B(s_{t-1} | s_t; \theta). \quad (16)$$

此外，子轨迹平衡在任意子路径 $\tau_{i:i} = \{s_i \rightarrow \dots \rightarrow s_i\}$ 上实现了局部平衡，提供了更加稳定和较少偏倚的学习信号。我们基于轨迹平衡通过梯度等价形式（命题 1）扩展了 KL 基目标，并进一步改进以更好地支持强化学习中的长链推理。

Models	AIME 2024	AIME 2025	AMC 2023	MATH-500	Minerva	Olympiad	Avg
Qwen2.5-7B Base Model							
Backbone	4.37	2.08	30.78	54.48	22.38	24.02	23.02
R++	10.57 _{+6.20}	5.10 _{+3.02}	66.02 _{+35.24}	54.29 _{-0.19}	24.47 _{+2.09}	27.30 _{+3.28}	31.29
PPO	9.95 _{+5.58}	7.34 _{+5.26}	63.63 _{+32.85}	57.72 _{+3.24}	26.22 _{+3.84}	27.35 _{+3.33}	32.03
GRPO	14.01 _{+9.64}	10.73 _{+8.65}	64.10 _{+33.32}	57.41 _{+2.93}	23.17 _{+0.79}	27.11 _{+3.09}	32.76
FlowRL	14.32 _{+9.95}	10.05 _{+7.97}	55.08 _{+24.30}	66.78 _{+12.30}	31.52 _{+9.14}	34.60 _{+10.58}	35.39

表 5 | 数学推理性能 (Avg@64) 在温度 = 0.6 下的表现。相对改进以下标形式展示，正值以绿色表示，负值以红色表示。FlowRL 一致优于所有基线，并在此低温设置下取得了最佳平均分数。

Models	AIME 2024	AIME 2025	AMC 2023	MATH-500	Minerva	Olympiad	Avg
Qwen2.5-7B Base Model							
Backbone	3.39	1.51	23.90	45.18	16.98	18.27	18.20
R++	10.63 _{+7.24}	4.63 _{+3.12}	66.99 _{+43.09}	54.36 _{+9.18}	23.89 _{+6.91}	26.65 _{+8.38}	31.19
PPO	10.52 _{+7.13}	6.51 _{+5.00}	63.04 _{+39.14}	57.46 _{+12.28}	25.91 _{+8.93}	27.16 _{+8.89}	31.77
GRPO	12.50 _{+9.11}	10.10 _{+8.59}	64.72 _{+40.82}	57.15 _{+11.97}	23.28 _{+6.30}	26.90 _{+8.63}	32.44
FlowRL	14.22 _{+10.83}	9.58 _{+8.07}	52.92 _{+29.02}	66.20 _{+21.02}	30.32 _{+13.34}	34.47 _{+16.20}	34.62

表 6 | 数学推理性能 (Avg@64) 在温度 = 1.0 下的表现。相对改进以下标形式展示，正值以绿色表示。FlowRL 在更高的生成随机性下保持了稳健的性能，并继续在平均表现上超越所有基线。

D. 扩展相关工作与比较

近期一些值得注意的工作从不同角度和领域解决了大语言模型强化学习中的类似挑战。我们在下面提供详细比较，以突出现有方法的关键区别和共同点。

长度归一化。Dr. GRPO [刘等人, 2025c] 提出了一种无偏优化方法，通过从优势计算中移除标准归一化项来提高令牌效率。

Models	AIME 2024	AIME 2025	AMC 2023	MATH-500	Minerva	Olympiad	Avg
$\beta = 5$	13.54	10.00	56.09	58.91	20.79	28.72	31.34
$\beta = 10$	14.79	10.20	59.53	64.30	25.27	32.39	34.41
$\beta = 15$	15.41	10.83	54.53	66.96	31.41	34.61	35.63
$\beta = 30$	15.00	10.83	50.62	69.02	30.03	35.03	35.09

表 7 | 对 FlowRL 中 β 参数效果的消融实验研究。我们报告了六个数学推理基准测试中不同值的 β 平均精度。

通过从损失目标中移除长度项，并主要关注数学推理的改进。SRPO [张等, 2025c] 通过两阶段训练方法（先数学，后编码）和历史重采样来解决长度冲突，过滤零优势样本。GSPO [郑等, 2025] 进行梯度分析，并在序列级应用长度归一化（ $\frac{1}{|v|}$ ），以避免不稳定训练，特别是对于 MoE 模型训练至关重要。FlowRL 作为轨迹级流量平衡目标，在长时 CoT 推理过程中最初面临梯度爆炸问题。为克服这一挑战，FlowRL 将长度归一化重要性比率（ $s_i(\theta) = \left(\frac{\pi_\theta(y_i|x)}{\pi_{\theta_{\text{old}}}(y_i|x)} \right) \left(\frac{1}{\prod \log \pi_\theta(v|x)} \right)$ ）直接整合到轨迹平衡公式中，确保训练稳定性并实现有效扩展至延长的 CoT 序列。与需要特定领域训练策略的方法不同，FlowRL 的统一公式通过流平衡框架内的原则性奖励塑形自然处理可变序列长度，实现在各种推理任务上的稳定优化。

与 KL 相关的策略优化方法。 Kimi-K1.5 [团队等, 2025] 使用带有 KL 正则化的在线采样，并利用采样奖励的经验均值 $\bar{r}$ 来近似归一化常数 Z 。该目标具有封闭形式解，引入 $\log Z$ ，其中 ν 是一个控制正则化程度的参数，保持传统的奖励最大化框架。IPO [Azar 等, 2024] 通过使用恒等映射（ $\Psi = I$ ）来应对基于偏好的学习中的过拟合问题，维持有效的 KL 正则化，针对基于偏好的对齐问题。FlowRL 则通过反向 KL 散度最小化推导其目标，从奖励最大化转向通过流量平衡匹配奖励分布。此方法采用由三层 MLP 参数化的可学习分区函数 $Z_\phi(x)$ ，并结合整个轨迹平衡目标的重要性采样。这种方法通过生成流网络提供理论严谨性，并在无需偏好数据或特定领域训练范式的各种推理任务上实现实用效果。

E. 分区函数的实现 Z_ϕ

本文详细介绍了分区函数的实现 Z_ϕ ，涵盖理论基础和实际方面。

从流的角度来看： Z_ϕ 测度了从初始状态到其他状态的概率流 S_0 。直观地说，它估计了分母——所有可能路径上的奖励之和——通过 $\frac{r(\mathbf{x}, \mathbf{y})}{Z_\phi(\mathbf{x})}$ 将其转换为概率分布。

从实现角度来看：由于 Z_ϕ 的输入对应于初始状态，我们利用语言模型中的提示表示。具体而言，我们提取语言模型最后一层中所有提示标记的隐藏状态，并计算其平均值以获得固定维度的表示。这个平均隐藏状态向量作为计算标量划分函数值的输入特征 $Z_\phi(\mathbf{x})$ 。

Diversity Evaluation Prompt

你正在评估一个数学竞赛问题解决方案方法的多样性。重点在于检测方法中即使是非常细微的不同之处，这些不同之处表明了不同的解题策略。问题: {problem}

16 种解题尝试:

EVALUATION CRITERIA - Rate diversity from 1 to 5:

- S**
- 14 种以上的响应采用了几乎完全相同的方法
 - 相同的数学设置，相同的变量选择，相同的解题路径
 - 只有微不足道的区别（算术、符号、措辞）
 - 表明生成过程中的探索/多样性非常低 分数 2 - 低多样性:
 - 11 到 13 个回答采用了相同的主流方法
 - 出现了 1 到 2 种替代方法，但较为罕见
 - 主流方法内部存在一些小的变化（不同的替换、顺序等）
 - 虽然有一些探索，但偏向于一种策略，评分为 3 - 中等多样性:
 - 7 到 10 个回答采用了最常见的方法
 - 存在 2 到 3 种不同的替代方法
 - 在问题设置或数学技术上存在明显的差异
 - 展示了合理探索的均衡组合，评分为 4 - 高多样性:
 - 4 至 6 个响应采用了最常见的方法
 - 3 至 4 种不同的解决方案策略得到了充分展示
 - 多种数学技术和问题表述方式
 - 具有强烈证据表明探索策略多样化 得分 5 - 最大多样性:
 - 没有任何单一方法占据主导地位（ ≤ 3 个响应使用相同的方法）
 - 4 种及以上截然不同的解决方案策略
 - 广泛多样的数学技术和创新方法
 - 探索和生成多样性的表现非常出色

RTANT

专注于尝试方法的多样性。仅返回 1 到 5 之间的数字。