

通过学习扩散改进采样

Lorenz Richter*

Zuse Institute Berlin
dida Datenschmiede GmbH
richter@zib.de

Julius Berner*

Caltech
jberner@caltech.edu

摘要

近期，一系列论文提出了基于深度学习的方法，利用受控扩散过程从目标分布中采样，仅需训练未归一化的目标密度，而无需访问样本。在此基础上，我们将这些方法视为广义薛定谔桥问题的特例，寻求给定先验分布与指定目标之间的随机演化。我们进一步推广这一框架，引入了一种基于时间反向扩散过程路径空间测度之间发散的变分形式。这种抽象视角导致了可以由梯度算法优化的实际损失，并将先前的目标作为特例包含在内。同时，它允许我们考虑其他发散度，而不仅仅是已知会导致模式崩塌的逆 Kullback-Leibler 发散。特别是，我们提出了所谓的对数方差损失，其具有良好的数值性质，并在所有考虑的方法中显著提升了性能。

1 引言

给定一个函数 $\rho: \mathbb{R}^d \rightarrow [0, \infty)$ ，我们考虑从密度中采样的任务

$$p_{\text{target}} := \frac{\rho}{Z} \quad \text{含} \quad Z := \int_{\mathbb{R}^d} \rho(x) dx,$$

这里，归一化常数 Z 通常是不可计算的。这在贝叶斯统计、计算物理、化学或生物学等众多科学领域中是一个关键且具有挑战性的问题，参见 Liu & Liu (2001); Stoltz 等人 (2010)。受到去噪扩散概率模型 (Song & Ermon, 2020; Ho 等人, 2020; Kingma 等人, 2021; Vahdat 等人, 2021; Nichol & Dhariwal, 2021) 和深度学习方法解决薛定谔桥 (SB) 问题 (De Bortoli 等人, 2021; Chen 等人, 2021a; Koshizuka & Sato, 2022) 的成功推动，使用受控神经网络的随机微分方程 (SDEs) 来运输给定的先验分布 p_{prior} 到目标分布 p_{target} ，以解决采样问题引起了极大的兴趣。

近期的研究包括路径积分采样器 (Path Integral Sampler, 简称 PIS) 及其变体 (Tzen & Raginsky, 2019; Richter, 2021; Zhang & Chen, 2022; Vargas et al., 2023b)，以及时间反向扩散采样器

(DIS) (伯纳尔等, 2024)，以及去噪扩散采样器 (DDS) (瓦尔加斯等, 2023a)。

尽管基于受控扩散过程的此类采样方法的思想可以追溯到早期的工作，例如 Dai Pra (1991 年)；Pavon (1989 年)，但基于深度学习的相应数值方法的发展在近年来变得流行。

然而，迄今为止，更多的关注点集中在生成建模上，在这种情况下，可以从 p_{target} 获得样本。因此，对于经典的采样问题，即仅有分析表达式 $\rho \propto p_{\text{target}}$ 而没有样本的情况，基于扩散的方法似乎尚未达到最先进的性能。潜在的问题可能包括训练期间的稳定性问题、需要通过随机微分方程求解器进行微分，或者由于使用基于逆 Kullback-Leibler (KL) 发散的目标函数而导致模式崩塌，参见例如 Zhang & Chen (2022); Vargas 等 (2023a)。

在这项工作中，我们克服了这些问题，并推进了通过学习扩散过程进行采样的潜在能力，使其能够应对更具挑战性的问题。我们的贡献可以总结如下：* 同等贡献（作者顺序由 `numpy.random.rand(1)` 决定）。

- 本文提供了一个统一的框架，基于路径空间上的测度和控制扩散的时间反转来实现采样，首次将 SB、DIS、DDS 和 PIS 等方法联系起来。
- 这种路径空间视角使得我们可以考虑任意发散作为优化目标，而现有方法仅依赖于最小化逆 KL 发散，这容易导致模式崩塌。
- 特别地，本文提出了对数方差发散，该方法避免了通过随机微分方程求解器进行微分，并能够平衡探索与开发，从而显著提升了数值稳定性和性能，详见图 1。




图 1: 我们提出的对数方差损失在双井问题上的改进收敛性，详见第 4 节。

1.1 相关工作

存在大量基于蒙特卡洛的方法用于从未归一化的密度中进行采样，例如退火重要性采样 (AIS) (Neal, 2001 年)，序贯蒙特卡洛 (SMC) (Del Moral 等人, 2006 年; Doucet 等人, 2009 年)，或者马尔可夫链蒙特卡洛 (MCMC) (Kass 等人, 1998 年)。需要注意的是，MCMC 方法通常仅保证渐近地达到目标密度，而在许多实用场景下，其收敛速度可能过慢 (Robert 等人, 1999 年)。变分方法，如平均场近似 (Wainwright 等人, 2008 年) 和归一化流 (Papamakarios 等人, 2021 年; Wu 等人, 2020 年; Midgley 等人, 2023 年; Vaitl 等人, 2024 年)，提供了另一种选择。类似于我们的设置，密度估计问题被转化为一个通过拟合参数化的可处理分布族到目标密度的优化问题。

我们理论基础建立在 Chen 等人 (2021a) 提出的桥问题的变分表述之上。回顾一下，这些基本思想几十年前就已经确立 (Nelson, 1967 年; Anderson, 1982 年; Haussmann & Pardoux, 1986 年; Föllmer, 1988 年)，然而，直到最近才被应用于扩散模型 (Song 等人, 2020 年) 和 SBs (Vargas, 2021 年; Liu 等人, 2022 年)。虽然 SB 问题的经典数值处理通常是通过迭代嵌套方案来实现的，但 Chen 等人 (2021a) 的方法使用倒向随机微分方程 (BSDEs) 来得出一个基于 KL 发散的单一目标。这个目标包括扩散模型的 (连续时间) ELBO (Huang 等人, 2021 年) 作为一个特殊情况，也可以从最优控制的角度来探讨 (Berner 等人, 2024 年)。关于生成建模上下文中的最优控制的先前工作，我们参考 De Bortoli 等人 (2021 年); Tzen & Raginsky (2019 年); Pavon (2022 年); Holdijk 等人 (2022 年)。

至关重要的是，我们注意到从路径空间视角对桥梁问题的变分表述尚未被先前的研究所知。我们的新颖推导仅依赖于扩散过程的时间反转，并表明，一般而言，相应的损失函数 (特别是 Chen 等人 (2021a) 中的一个) 没有唯一解，因为它们缺乏经典 SB 问题中的熵约束。然而，在特殊情况下，我们恢复了与最近开发的采样方法相对应的独特目标，例如 DIS、DDS 和 PIS。此外，路径空间视角使我们能够将桥梁问题的变分表述扩展到不同的发散度，特别是最初由 Nüsken & Richter (2021) 引入的对数方差发散度。这种损失函数的变体之前仅在变分推断 (Richter 等, 2020) 和偏微分方程 (PDEs) 的神经求解器 (Richter & Berner, 2022) 的背景下进行过分析。在此基础上，我们证明了对数方差损失的良好性质也适用于包含两个而非一个受控随机过程的一般桥梁目标。最后，我们参考 Vargas 等 (2024) 关于基于扩散的采样的路径空间视角的同期工作。

1.2 文章概述

文章其余部分组织如下。在第 2 节中，我们将从路径空间测度和时间反转 SDE 的角度介绍基于扩散的采样。这可以理解作为一种统一框架，允许推广至 KL 发散以外的其他发散度。我们提出了对数方差发散，并证明其具有优越的性质。在第 3 节中，我们将随后概述与已知方法的多种新颖联系，如第 3.1 节中的 SBs，第 3.2 节中的基于扩散的生成建模 (即 DIS)，以及第 3.3 节中基于参考过程的方法 (即 PIS 和 DDS)。对于所有考虑的方法，我们都能找到有力的数值证据证明对数方差发散的优越性，详见第 4 节。

2 基于扩散的采样

在本节中，我们将重新表述我们的采样问题作为路径空间测度视角下扩散过程的时间反转。首先，让我们定义我们的设置和符号。

2.1 符号与设置

我们用 p_X 表示随机变量 X 的概率密度。对于一个合适的取值于 $\mathbb{R}^d$ 的随机过程 $X = (X_t)_{t \in [0, T]}$ ，我们定义其关于勒贝格测度的概率密度 p_X 为 $p_X(\cdot, t) := p_{X_t}$ 。对 $t \in [0, T]$ 于合适的函数 $f \in C(\mathbb{R}^d \times [0, T], \mathbb{R})$ 和 $w \in C(\mathbb{R}^d \times [0, T], \mathbb{R}^d)$ ，我们进一步定义确定性和随机积分

$$R_f(X) := \int_0^T f(X_s, s) ds \quad \text{和} \quad S_w(X) := \int_0^T w(X_s, s) \cdot dW_s, \quad (1)$$

其中 W 是一个标准的 d 维布朗运动。记 $\mathcal{P}$ 为连续函数空间上的所有概率测度的集合 $C([0, T], \mathbb{R}^d)$ ，并定义路径空间测度 $\mathbb{P}_X \in \mathcal{P}$ 为 X 的分布。对于一个时间依赖函数 μ ，记其时间反演为 $\bar{\mu}$ ，给定为 $\bar{\mu}(t) := \mu(T - t)$ 。技术假设请参见附录 A.1。

2.2 抽样作为时间反转问题

扩散采样的目标是从密度 $p_{\text{target}} = \rho$ 中进行抽样 通过将先验密度 p_{prior} 经由受控随机过程传输。我们考虑由 SDE 给出的两个过程

$$dX_s^u = (\mu + \sigma u)(X_s^u, s) ds + \sigma(s) dW_s, \quad X_0^u \sim p_{\text{prior}}, \quad (2)$$

$$dY_s^v = (-\bar{\mu} + \bar{\sigma} v)(Y_s^v, s) ds + \bar{\sigma}(s) dW_s, \quad Y_0^v \sim p_{\text{target}}, \quad (3)$$

其中我们的目标是在合适的可接受控制空间 $\mathcal{U} \subset C(\mathbb{R}^d \times [0, T], \mathbb{R}^d)$ 中识别控制函数 $u, v \in \mathcal{U}$ ，以实现 $X_T^u \sim p_{\text{target}}$ 和 $Y_T^v \sim p_{\text{prior}}$ 。具体而言，我们寻求满足

$$p_{\text{prior}} \xrightarrow[Y^v]{X^u} p_{\text{target}}$$

意义上的控制，即 Y^v 是过程 X^u 的时间反转，反之亦然，即 $\tilde{p}_{X^u} = p_{Y^v}$ 在这一

背景下，我们回顾关于随机过程时间反转的一个众所周知的结果（Nelson, 1967; Anderson, 1982; Haussmann & Pardoux, 1986; Föllmer, 1988）。

引理 2.1（时间反转的随机微分方程）。时间反转过程 $\tilde{Y}^v$ ，由随机微分方程给出

$$d\tilde{Y}_s^v = (\mu - \sigma v + \sigma \sigma^\top \nabla \log \tilde{p}_{Y^v})(\tilde{Y}_s^v, s) ds + \sigma(s) dW_s, \quad \tilde{Y}_0^v \sim Y_T^v, \quad (4)$$

满足 $p_{\tilde{Y}^v} = \tilde{p}_{Y^v}$ 。

Proof. The result can be derived by comparing the Fokker-Planck equations governing $p_{\tilde{Y}^v}$ and p_{Y^v} , see, e.g., Chen et al. (2021a); Huang et al. (2021); Berner et al. (2024). $\square$

我们现在定义识别所需控制函数的问题 u 以及 v 从路径空间测度在轨迹空间上的视角 $C([0, T], \mathbb{R}^d)$ ，具体细节如下。

问题 2.2（时间反转）。设 $\mathbb{P}_{X^u}$ 是过程 X^u 在 (2) 中定义的路径测度，并设 $\mathbb{P}_{\tilde{Y}^v}$ 是 $\tilde{Y}^v$ 的路径测度，即给定在 (4) 中的 $\tilde{Y}^v$ 的时间反转。进一步，设 $D : \mathcal{P} \times \tilde{\mathcal{P}} \rightarrow \mathbb{R}_{\geq 0}$ 是一个发散，即一个非负函数，满足 $D(\mathbb{P}, \mathbb{Q}) = 0$ 当且仅当 $\mathbb{P} = \mathbb{Q}$ 。我们的目标是找到最优控制 u^*, v^* s.t.

$$u^*, v^* \in \arg \min_{u, v \in \mathcal{U} \times \mathcal{U}} D(\mathbb{P}_{X^u} | \mathbb{P}_{\tilde{Y}^v}). \quad (5)$$

我们注意到问题 2.2 旨在互逆过程 X^u 和 Y^v ，同时遵守各自的初始值 $X_0^u \sim p_{\text{prior}}$ 和 $Y_0^v \sim p_{\text{target}}$ 。为了实际计算合适的发散性，我们推导出以下基本恒等式。

命题 2.3 (路径测度的可能性)。设 X^w 是一个在 (2) 中定义的过程，其中 u 被 $w \in \mathcal{U}$ 替换，并设 S 和 R 如 (1) 所示。我们可以计算 Radon-Nikodym 导数为

$$\frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{\tilde{Y}^v}}(X^w) = Z \exp(R_{f_{u,v,w}^{\text{Bridge}}} + S_{u+v} + B)(X^w) \quad (6)$$

$$\text{with } B(X^w) := \log \frac{p_{\text{prior}}(X_0^w)}{\rho(X_T^w)} \quad \text{and} \quad f_{u,v,w}^{\text{Bridge}} := (u+v) \cdot \left(w + \frac{v-u}{2}\right) + \nabla \cdot (\sigma v - \mu).$$

证明。该证明结合了 Girsanov 定理、Itô 引理、管理 $\log p_{\tilde{Y}^v}$ 的 HJB 方程以及 $\rho = Z p_{\text{target}}$ 的事实，详见附录 A.2。□

请注意，我们可以通过求助于向后随机积分来消除 (6) 中的发散性 $\nabla \cdot (\sigma v - \mu)$ ，参见附录中的备注 A.1。利用路径空间视角和命题 2.3 中 Radon-Nikodym 导数的表示，原则上我们现在可以选择任何合适的发散性 D 来解决 2.2 问题。根据我们的路径空间表述，据我们所知，我们是第一个如此广泛地研究这个问题的人。接下来，我们将展示这个通用框架统一了先前的方法，并使我们能够轻松地推导出新方法。

2.3 KL 与对数方差发散的比较

大多数基于扩散的采样工作依赖于 KL 发散。选择 $D = D_{\text{KL}}$ ，这意味着在 (6) 中 $w = u$ ，我们可以直接计算

$$D_{\text{KL}}(\mathbb{P}_{X^u} | \mathbb{P}_{\tilde{Y}^v}) = \mathbb{E} \left[(R_{f_{u,v,u}^{\text{Bridge}}} + B)(X^u) \right] + \log Z$$

含 $f_{u,v,u}^{\text{Bridge}} = \frac{\|u+v\|^2}{2} + \nabla \cdot (\sigma v - \mu)$ ，这里我们利用了随机积分 S_{u+v} 的期望为零的事实。请注意，在实践中我们最小化目标函数

$$\mathcal{L}_{\text{KL}}(u, v) := D_{\text{KL}}(\mathbb{P}_{X^u} | \mathbb{P}_{\tilde{Y}^v}) - \log Z. \quad (7)$$

此目标函数类似于 Chen 等人 (2021a) 为桥梁问题推导的目标函数，也请参阅第 3.1 节和附录 A.4。不幸的是，KL 发散已知存在一些明显的缺点，如模式崩塌 (Minka 等人, 2005; Midgley 等人, 2023) 或蒙特卡洛估计器可能具有高方差 (Roeder 等人, 2017)。为了解决这些问题，我们提出了一种最初由 Natusen & Richter (2021) 提出的发散性，并将其扩展到两个受控随机过程的设置中。

定义 2.4 (对数方差发散)。设 $\tilde{\mathbb{P}}$ 是一个参考测度。测度 $\mathbb{P}$ 和 $\mathbb{Q}$ 关于参考测度 $\tilde{\mathbb{P}}$ 的对数方差发散定义为

$$D_{\tilde{\mathbb{P}}}^{\text{LV}}(\mathbb{P}, \mathbb{Q}) := \mathbb{V}_{\tilde{\mathbb{P}}} \left[\log \frac{d\mathbb{P}}{d\mathbb{Q}} \right].$$

请注意，对数方差发散在 $\mathbb{P}$ 和 $\mathbb{Q}$ 上是对称的，并且实际上对应于一组由参考测度 $\tilde{\mathbb{P}}$ 参数化的发散。在我们的设置中，显然的选择是 $\mathbb{P} := \mathbb{P}_{X^w}, \mathbb{P} := \mathbb{P}_{X^u}$ ，和 $\mathbb{Q} := \mathbb{P}_{\tilde{Y}^v}$ 从而导致对数方差损失

$$\mathcal{L}_{\text{LV}}^w(u, v) := D_{\tilde{\mathbb{P}}}^{\text{LV}}(\mathbb{P}_{X^u}, \mathbb{P}_{\tilde{Y}^v}) = \mathbb{V} \left[(R_{f_{u,v,w}^{\text{Bridge}}} + S_{u+v} + B)(X^w) \right]. \quad (8)$$

由于方差具有平移不变性，我们可以省略上述目标中的 $\log Z$ 。

与基于 KL 的损失 (7) 相比，对数方差损失 (8) 展现出以下有益性质。首先，通过选择参考测度 $\mathbb{P}_{X^w}$ ，可以平衡开发和探索。为了利用当前控制 u ，可以设置 $w = u$ ，也可以选择另一个控制或初始条件 X_0^w 。我们可以利用这一点来对抗模式崩塌，通过优化损失 (8) 中的 (子-) 轨迹，其中 $\mathbb{P}_{X^u}$ 的概率较低，详见附录 A.7。接下来，请注意，对数方差损失 (8) 不需要过程 X^w w.r.t. 控制 w 的导数（对于情况 $w = u$ ，这可以通过断开或停止梯度来实现，详见附录 A.6）。虽然我们仍然需要模拟过程 X^w ，但可以依赖任何（黑盒）SDE 求解器，并不需要跟踪 X^w 的计算以进行自动微分。这

意味着对数方差损失不需要未归一化目标密度 ρ 的导数¹，这对于目标仅作为黑盒可用的问题至关重要。相比之下，基于 KL 的损失 (7) 需要对 X^u w.r.t. u 进行微分，要求通过 SDE 求解器进行微分，从而导致更高的计算成本。特别有趣的是以下属性，有时被称为着陆粘连 (Roeder 等, 2017)。它表明对数方差损失的梯度在最优解处方差为零。这一性质通常不适用于基于 KL 的损失，使得梯度下降的变体可能会在最优值附近振荡。

命题 2.5 (解决方案的鲁棒性)。设 $\mathcal{L}_{LV}$ 是对数方差损失 (8) 的蒙特卡洛估计量，且控制 $u = u_\theta$ 和 $v = v_\gamma$ 分别由 θ 和 γ 参数化。各自的导数的方差在最优解 $(u^*, v^*) = (u_{\theta^*}, v_{\gamma^*})$, i.e. 处消失

$$\mathbb{V} \left[\nabla_\theta \hat{\mathcal{L}}_{LV}^w(u_{\theta^*}, v_{\gamma^*}) \right] = 0 \quad \text{and} \quad \mathbb{V} \left[\nabla_\gamma \hat{\mathcal{L}}_{LV}^w(u_{\theta^*}, v_{\gamma^*}) \right] = 0,$$

对于所有 $w \in \mathcal{U}$ 。对于基于 KL 的损失 (7) 的估计量 $\mathcal{L}_{KL}$ ，方差不会消失。证明：该证明基于技术计算和命题 2.3，详见附录 A.2。 $\square$

对于情形 $w = u$ ，我们可以进一步将对数方差损失解释为基于 KL 散度损失的控制变量版本，详见附录中的推论 A.2。我们可以在附录的图 5 中观察到损失及其梯度的方差缩减效果。

3 扩散模型采样的连接与等价性

方法

一般来说，问题 2.2 有无穷多解，特别是对于我们在 (7) 和 (8) 中的目标而言。事实上，Girsanov 定理表明这些目标仅强制执行 Nelson 恒等式 (Nelson, 1967 年)，即，

$$u^* + v^* = \sigma^\top \nabla \log p_{X^{u^*}} = \sigma^\top \nabla \log \tilde{p}_{Y^{v^*}}, \quad (9)$$

参见命题 2.3 的证明。在本节中，我们将展示我们的设定如何推广现有的基于扩散的采样方法，这些方法反过来确保了问题 2.2 具有唯一的解。此外，利用我们的框架，我们可以直接推导出对数方差损失 (8) 的相应版本。关于之前基于扩散的采样方法的高层次概述，请参阅附录 A.3。

3.1 薛定谔桥问题 (SB)

在所有解决方案中 u^* 满足 (9)，薛定谔桥问题考虑其解 u^* 使 KL 发散最小化 $D_{KL}(\mathbb{P}_{X^{u^*}} | \mathbb{P}_{X^r})$ 相对于给定的参考过程 X^r ，定义如 (2) 所示 u 被替换为 $r \in \mathcal{U}$ ，详见附录 A.4。传统上， $r = 0$ 即未受控的过程 X^0 被选中。定义

$$f_{u,r,w}^{\text{ref}} := (u - r) \cdot \left(w - \frac{u + r}{2} \right), \quad (10)$$

Girsanov 定理表明， $\frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{X^r}}(X^w) = \exp(R_{f_{u,r,w}^{\text{ref}}} + S_{u-r})(X^w)$, which implies that

$$D_{KL}(\mathbb{P}_{X^u} | \mathbb{P}_{X^r}) = \mathbb{E} \left[R_{f_{u,r,u}^{\text{ref}}}(X^u) \right], \quad (11)$$

参见 Natusken 与 Richter (2021, 引理 A.1) 以及命题 2.3 的证明。SB 目标因此可以表示为

$$\min_{u \in \mathcal{U}} \mathbb{E} \left[R_{f_{u,r,u}^{\text{ref}}}(X^u) \middle| X_T^u \sim p_{\text{target}} \right], \quad (12)$$

参见 De Bortoli 等人 (2021)；Caluya 与 Halder (2021)；Pavon 与 Wakolbinger (1991)；Benamou 与 Brenier (2000)；Chen 等人 (2021b)；Bernton 等人 (2019)。我们注意到上述内容也可以解释为一个熵正则化的最优传输问题 (Leonard, 2014)。 (11) 中的熵约束现在可以通过考虑例如以下内容与我们的目标 (5) 相结合：

$$\min_{u,v \in \mathcal{U} \times \mathcal{U}} \left\{ \mathbb{E} \left[R_{f_{u,r,u}^{\text{ref}}}(X^u) \right] + \lambda D(\mathbb{P}_{X^u} | \mathbb{P}_{\tilde{Y}^v}) \right\},$$

¹ 虽然，默认情况下，以下呈现的采样器使用 $\nabla \log \rho$ 在其控制参数化中 u 我们在附录 A.7 中展示了无导数情况下的有前景的结果。

其中 $\lambda \in (0, \infty)$ 是一个足够大的拉格朗日乘子。在附录 A.4 中，我们展示了如何将 SB 问题 (12) 重新表述为一组耦合的偏微分方程或倒向随机微分方程系统，这可以用来替代地正则化问题 2.2，参见 Liu 等人 (2022)；Koshizuka 与 Sato (2022)。有趣的是，倒向随机微分方程系统恢复了我们在 (7) 中最初由 Chen 等人 (2021a) 推导出的基于 KL 的目标。

请注意，通过 Nelson 的身份 (9)，SB 问题的最优解 u^* 唯一定义了一个最优控制 v^* ，反之亦然。对于 SB 的一些特殊情况，我们可以计算这样的 v^* 或其近似 $\bar{v} \approx v^*$ 。固定 (5) 中的 $v = \bar{v}$ 并仅优化出现在生成过程 (2) 中的 u ，使我们能够获得问题 2.2（或其近似）的独特解决方案。我们注意到这种近似 $\bar{v} \approx v^*$ 导致了一个不可减少的损失，给定为

$$\frac{d\mathbb{P}_{X^{u^*}}}{d\mathbb{P}_{\bar{Y}^{\bar{v}}}}(X^w) = \frac{d\mathbb{P}_{\bar{Y}^{v^*}}}{d\mathbb{P}_{\bar{Y}^{\bar{v}}}}(X^w), \quad (13)$$

因此需要明智地选择 $\bar{v}$ 和 p_{prior} ，使得 $Y^{\bar{v}} \approx Y^{v^*}$ 。我们将在接下来的部分中考虑两种这样的设置。

3.2 扩散基础生成模型 (DIS)

我们可以设置 $\bar{v} := 0$ ，这可以解释为一个 SB，其中包含 $u^* = r = \sigma^\top \nabla \log \bar{p}_{Y^0}$ 和 $p_{\text{prior}} = p_{Y_T^0}$ ，使得熵约束 (11) 能够被最小化到零。需要注意的是，只有当 SDE 中的函数 μ 和 σ 被选择得使得 $p_{Y_T^0}$ 的分布（近似）已知，并且可以从该分布中容易地进行采样时，这才会导致可行的采样方法。在实践中，人们会选择函数 μ 和 σ 使得 $p_{Y_T^0} \approx p_{\text{prior}} := \mathcal{N}(0, \nu^2 I)$ ，详见附录 A.6。相关的方法通常被称为基于扩散的生成建模或去噪扩散概率建模，因为（最优控制下的）生成过程 X^{u^*} 可以理解为将样本从目标密度移动到高斯噪声的过程 Y^0 的时间反转（Ho 等，2020；Pavon，1989；Huang 等，2021；Song 等，2020）。让我们回顾命题 2.3 中的符号并定义 $f_{u,w}^{\text{DIS}} := f_{u,0,w}^{\text{Bridge}} = u \cdot w - \frac{\|u\|^2}{2} - \nabla \cdot \mu$ 。将 $v = 0$ 设置在 (7) 中，我们很容易得到损失

$$\mathcal{L}_{\text{KL}}(u) = \mathbb{E} \left[(R_{f_{u,u}^{\text{DIS}}} + B)(X^u) \right],$$

这对应于 Berner 等人 (2024 年) 推导的时间反转扩散采样器 (DIS)。类似地，我们的路径空间视角和 (8) 给出了相应的对数方差损失

$$\mathcal{L}_{\text{LV}}^w(u) = \mathbb{W} \left[(R_{f_{u,w}^{\text{DIS}}} + S_u + B)(X^w) \right]. \quad (14)$$

3.3 参考过程的时间反转 (PIS 与 DDS)

一般来说，我们也可以设置 $\bar{v} := \sigma^\top \nabla \log p_{X^r} - r$ 。根据引理 2.1，这意味着 $\mathbb{P}_{X^r} = \mathbb{P}$ 其中 $\bar{v}, \text{ref}$ ， $Y^{v,\text{ref}}$ 是过程 Y^v 如 (3) 所示，但将 p_{target} 替换为 $p_{\text{ref}} := p_{X_T^r}$ ，i.e.，

$$dY^{v,\text{ref}} = (-\bar{\mu} + \bar{\sigma}\bar{v})(Y^{v,\text{ref}}, s) ds + \bar{\sigma}(s) dW_s, \quad Y^{v,\text{ref}} \sim p_{\text{ref}}.$$

换句话说， $Y^{\bar{v},\text{ref}}$ 是参考过程 X^r 的时间反转。使用 (6) 并将 p_{ref} 替换为 $p_{\text{target}} = \frac{\rho}{2}$ ，我们从而得到

$$1 = \frac{d\mathbb{P}_{X^r}}{d\mathbb{P}_{\bar{Y}^{\bar{v},\text{ref}}}}(X^w) = \frac{p_{\text{prior}}(X_0^w)}{p_{\text{ref}}(X_T^w)} \exp(R_{f_{r,\bar{v},w}^{\text{Bridge}}} + S_{r+\bar{v}})(X^w). \quad (15)$$

这个恒等式导致了命题 2.3 的以下替代表示。

引理 3.1 (相对于参考过程的可能性)。假设 $\mathbb{P}_{X^r} = \mathbb{P}_{\bar{Y}^{\bar{v},\text{ref}}}$ ，则成立

$$\frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{\bar{Y}^{\bar{v}}}}(X^w) = Z \exp \left(R_{f_{u,r}^{\text{ref}}} + S_{u-r} + B^{\text{ref}} \right)(X^w),$$

其中 u, r, w 如 (10) 中定义， $B^{\text{ref}}(X^w) := \log \frac{p_{\text{ref}}}{p_{\text{prior}}}(X_T^w)$ 。证明。结果来自将 $d\mathbb{P}_{X^u}$ 除以 (15) 中的内容。我们还参考附录 A.3

中的另一种推导方法，该方法不依赖于 $d\mathbb{P}_{\bar{Y}^{\bar{v}}}(X^w)$ in (6) by $\frac{d\mathbb{P}_{X^r}}{d\mathbb{P}_{\bar{Y}^{\bar{v},\text{ref}}}}(X^w)$ 时间反转的概念。 $\square$

表 1: 与 $R_f, S_u, B, B^{\text{ref}}, f_{u,v,w}^{\text{Bridge}}, f_{u,r,w}^{\text{ref}}$ 如文中定义的目标进行比较。

	$\mathcal{L}_{\text{KL}}$	$\mathcal{L}_{\text{LV}}^w$ (ours)	p_{prior}	v	r
Bridge	$\mathbb{E} \left[(R_{f_{u,v,u}^{\text{Bridge}}} + B)(X^u) \right]$	$\mathbb{V} \left[(R_{f_{u,v,w}^{\text{Bridge}}} + S_{u+v} + B)(X^w) \right]$	arbitrary	learned	–
DIS	$\mathbb{E} \left[(R_{f_{u,0,u}^{\text{Bridge}}} + B)(X^u) \right]$	$\mathbb{V} \left[(R_{f_{u,0,w}^{\text{Bridge}}} + S_u + B)(X^w) \right]$	$\approx p_{Y_T^0}$	0	–
PIS	$\mathbb{E} \left[(R_{f_{u,0,u}^{\text{ref}}} + B^{\text{ref}})(X^u) \right]$	$\mathbb{V} \left[(R_{f_{u,0,w}^{\text{ref}}} + S_u + B^{\text{ref}})(X^w) \right]$	δ_{x_0}	$\sigma^\top \nabla \log p_{X^0}$	0
DDS	$\mathbb{E} \left[(R_{f_{u,r,u}^{\text{ref}}} + B^{\text{ref}})(X^u) \right]$	$\mathbb{V} \left[(R_{f_{u,r,w}^{\text{ref}}} + S_{u-r} + B^{\text{ref}})(X^w) \right]$	$p_{Y_T^0, \text{ref}}$	0	$\sigma^\top \nabla \log \tilde{p}_{Y^0, \text{ref}}$

请注意，计算引理 3.1 中的 Radon-Nikodym 导数需要选择 r, p_{prior}, μ ，和 σ 使得 $p_{\text{ref}} = p_{X_T^r}$ 是可处理的²。对于适当的选择 r （见下文），可以使用附录 A.5 中给出的具有可处理密度的 SDEs，即 $p_{\text{prior}} = \delta_{x_0}, p_{\text{prior}} = \mathcal{N}(0, \nu^2 \text{I})$ ，或此类分布的混合。回顾 (13) 和选择 $\bar{v} := \sigma^\top \nabla \log p_{X^r} - r$ ，我们也需要保证 $Y^{\bar{v}} \approx Y^{v^*}$ 。下面概述两种这样的情况。

PIS: 我们首先考虑情形 $r := 0$ 。引理 3.1 和在问题 2.2 中取 $D = D_{\text{KL}}$ 则得出

$$\mathcal{L}_{\text{KL}}(u) = D_{\text{KL}}(\mathbb{P}_{X^u} | \mathbb{P}_{Y^{\bar{v}}}) - \log Z = \mathbb{E} \left[(R_{f_{u,0,u}^{\text{ref}}} + B^{\text{ref}})(X^u) \right].$$

此目标先前已被 Tzen & Raginsky (2019)；Dai Pra (1991) 考虑过；相应的数值算法，在 Zhang & Chen (2022) 中被称为路径积分采样器 (Path Integral Sampler, PIS)，已在 Richter (2021)；Zhang & Chen (2022)；Vargas 等 (2023b) 中独立提出。选择 $D = D_{\text{LV}}$ ，我们得到相应的对数方差损失

$$\mathcal{L}_{\text{LV}}^w(u) = \mathbb{V} \left[(R_{f_{u,0,w}^{\text{ref}}} + S_u + B^{\text{ref}})(X^w) \right],$$

这已经在 Richter (2021, 例 7.1) 中陈述过。通常，目标与 $p_{\text{prior}} := \delta_{x_0}$ 一起使用，因为 Doob 的 h 变换保证了 $\bar{v} = v^*$ ，即我们可以精确地求解 SB，参见 Rogers & Williams (2000) 以及附录 A.4.1。在这种特殊情况下，SB 通常被称为薛定谔半桥。

去噪扩散采样器 (Denoising Diffusion Sampler, DDS): 接下来，我们考虑选择 $p_{\text{ref}} = \delta_{x_0}, \bar{v} = \sigma^\top \nabla \log 0$ 和 $p_{\text{prior}} := p_{Y_T^0, \text{ref}}$, which in 转换产生了一个特殊情况，即第 3.2 节设置下的特殊情况。利用引理 3.1，我们得到目标

$$\mathcal{L}_{\text{KL}}(u) = \mathbb{E} \left[(R_{f_{u,r,u}^{\text{ref}}} + B^{\text{ref}})(X^u) \right].$$

这对应于 Vargas 等 (2023a) 提出的去噪扩散采样器 (DDS) 目标，当选择 μ 和 σ 使得 Y^0 是一个 VP SDE 时，参见附录 A.5。选择 VP SDE 的不变分布 $p_{\text{ref}} := \mathcal{N}(0, \nu^2 \text{I})$ ，见附录中的 (26)，我们有 $p_{X^r}(\cdot, t) =$ 对于

最终，(利用我们的通用框架，相应的对数方差损失可以轻松计算为) $p_{X^r}(\cdot, t) = -\frac{\sigma^\top}{\nu^2}$

$$\mathcal{L}_{\text{LV}}^w(u) = \mathbb{V} \left[(R_{f_{u,r,w}^{\text{ref}}} + S_{u-r} + B^{\text{ref}})(X^w) \right].$$

请参见表 1，比较我们所有不同的目标函数。

4 数值实验

在本节中，我们将基于 KL 的损失与三种不同方法上的对数方差损失进行比较，即第 2.3 节、第 3.2 节和第 3.3 节中介绍的一般桥梁、PIS 和 DIS。由于 DDS 可以视为 DIS 的一个特例（两者都具有 $\bar{v} = 0$ ，另见 Berner 等人，2024 年，附录 A.10.1），我们不单独考虑它。我们可以证明，对数方差的吸引特性

²一般来说，能够计算 $p_{X_T^r}$ 就足够了直到其归一化常数。




图 2: GMM 问题的 KDE 图 (从左到右): (1) 来自真实分布的样本, (2 和 3) 使用 KL 发散和对数方差损失的 PIS, 以及 (4 和 5) 使用 KL 发散和对数方差损失的 DIS。可以看出, 对数方差损失不会像反向 KL 发散那样遭受模式崩塌, 后者仅恢复了 $p_{\text{prior}} = \mathcal{N}(0, I)$ 的模式。




图 3: 来自 PIS 和 DIS 的样本的第一个坐标边缘分布 (左图为 PIS, 右图为 DIS), 针对的是具有 $d = 5, m = 5, \delta = 4$ 的 DW 问题。再次观察到对数方差损失相较于反向 KL 发散的模式覆盖情况。类似的行为也可以在其他边缘分布 (见图 6) 和更高维度的设置 (见图 7 中的一个例子在 $d = 1000$) 中观察到。

损失确实可以显著提高所有考虑方法的性能。请注意, 我们始终比较相同的设置, 特别是目标评估次数, 对于对数方差和 KL 散度损失, 并使用足够多的梯度步数以达到收敛。计算细节见附录 A.6 和算法 13。尽管如此, 我们观察到两种损失之间的定性差异在各种超参数设置下是一致的。更多实验见附录 A.8。

4.1 基准问题

我们在以下三个数值基准示例上评估不同的方法。

高斯混合模型 (GMM): 我们考虑 $\rho(x) = \frac{1}{m} \sum_{i=1}^m \mathcal{N}(x; \mu_i, \Sigma_i)$ 并选择 $m = 9, \Sigma_i = 0.3I, (\mu_i)_{i=1}^9 = \{-5, 0, 5\} \times \{-5, 0, 5\} \subset \mathbb{R}^2$ 以获得良好的分离模式, 参见图 2。

漏斗: 10 维漏斗分布 (Neal, 2003) 是一个常用于测试 MCMC 方法的具有挑战性

的例子。其密度由 $\rho(x) p_{\text{target}}(x) = \mathcal{N}(x_1; 0, \eta^2) \prod_{i=2}^d \mathcal{N}(x_i; 0, e^{x_1})$ $x = (x_i)_{i=1}^{10} \in \mathbb{R}^{10}$ $\eta = 3.$ 给出。含

双井 (DW): 分子动力学中的典型问题是从 Langevin 动力学的平稳分布中采样。在我们的示例中, 我们考虑一个 d 维的双井势, 对应的 (未归一化的) 密度为 $\rho(x) = \frac{1}{2} \sum_{i=1}^d \exp(-\frac{x_i^2}{2}) \exp(-\frac{x_i^2}{2\delta})$ (即 2^m 模式) 和一个分离参数 $\delta \in (0, \infty)$, 另见吴等 (2020) 及图 3。本文选择一个较大的值 δ 使得采样特别具有挑战性, 原因是存在高能量壁垒。由于 ρ 在维度上进行分解, 我们通过数值积分获得参考解, 并使用带有高斯混合提议分布的拒绝采样方法获取真实样本, 详见 Midgley 等 (2023)。

4.2 结果

让我们从桥梁方法及其在 (7) 和 (8) 中的总体损失开始。表 5 (见附录) 显示, 对数方差损失可以显著提高我们考虑的各项指标。然而, 总体桥梁框架仍然面临效率降低和数值不稳定的问题。

对于高维问题, 计算 v 的发散可能因自动 3 该存储库可在

https://github.com/juliusberner/sde_sampler 找到。

表 2: 不同维度基准问题的 PIS 和 DIS 度量 d 。我们报告了五次独立运行的中位数, 图 9 显示了相应的箱线图。具体而言, 我们报告了估计对数归一化常数 $\Delta \log Z$ 的误差以及边缘的标准差 Δstd 。此外, 我们还报告了归一化的有效样本大小 ESS 和 Sinkhorn 距离 W_γ^2 (Cuturi, 2013), 详见附录 A.6。箭头 $\uparrow$ 和 $\downarrow$ 表示我们希望最大化或最小化某个给定的度量。

Problem	Method	Loss	$\Delta \log Z \downarrow$	$W_\gamma^2 \downarrow$	ESS $\uparrow$	$\Delta \text{std} \downarrow$
GMM ($d = 2$)	PIS	KL (Zhang & Chen, 2022)	1.094	0.467	0.0051	1.937
		LV (ours)	0.046	0.020	0.9093	0.023
	DIS	KL (Berner et al., 2024)	1.551	0.064	0.0226	2.522
		LV (ours)	0.056	0.020	0.8660	0.004
Funnel ($d = 10$)	PIS	KL (Zhang & Chen, 2022)	0.288	5.639	0.1333	6.921
		LV (ours)	0.277	5.593	0.0746	6.850
	DIS	KL (Berner et al., 2024)	0.433	5.120	0.1383	5.254
		LV (ours)	0.430	5.062	0.2261	5.220
DW ($d = 5, m = 5, \delta = 4$)	PIS	KL (Zhang & Chen, 2022)	3.567	1.699	0.0004	1.409
		LV (ours)	0.214	0.121	0.6744	0.001
	DIS	KL (Berner et al., 2024)	1.462	1.175	0.0012	0.431
		LV (ours)	0.375	0.120	0.4519	0.001
DW ($d = 50, m = 5, \delta = 2$)	PIS	KL (Zhang & Chen, 2022)	0.101	6.821	0.8172	0.001
		LV (ours)	0.087	6.823	0.8453	0.000
	DIS	KL (Berner et al., 2024)	1.785	6.854	0.0225	0.009
		LV (ours)	1.783	6.855	0.0227	0.009

微分, 依赖于 Hutchinson 的迹估计器会引入额外的方差。关于进一步讨论, 请参阅附录 A.1 中的备注。这些不稳定性可能源于最优控制的非唯一性 (这由我们的分析得出, 参见第 3 节)。此外, 在 SBs 的背景下也经常观察到此类问题 (De Bortoli 等人, 2021; Chen 等人, 2021a; Fernandes 等人, 2021), 其中需要优化两个控制。因此, 对于更具挑战性的问题, 我们将重点放在 DIS 和 PIS 上, 它们不会导致上述病态现象。

我们观察到, 对数方差损失在所考虑的基准问题和度量上显著提升了 DIS 和 PIS 的表现, 详见表 2。考虑到我们仅将基于 KL 的损失 $\mathcal{L}_{\text{KL}}$ 替换为对数方差损失 $\mathcal{L}_{\text{LV}}$ 而未调整后者的超参数, 这种改进尤为显著。在少数情况下, KL 发散表现更好, 但差异似乎并不重要。特别是, 图 2 和图 3 显示, 对数方差损失成功地对抗了模式崩塌, 带来了相当大的改进。对于 Wu 等人 (2020) 提出的基准测试, 即旨在从类似于拉布拉多犬图片的目标分布中采样, 也可以观察到对数方差损失的好处, 见附录中的图 8。在附录 A.8 中, 我们展示了更多 (高维) 目标的结果, 表明带有对数方差损失的扩散采样器与其它最先进的采样方法具有竞争力。

5 结论

在这项工作中, 我们提供了一个基于时间反向扩散过程路径空间测度的统一视角来理解扩散生成模型, 并首次将 SB、DIS、PIS 和 DDS 等方法联系起来。我们的新框架还允许我们将任意路径测度之间的发散作为相应任务的目标。虽然 KL 发散产生了已知的方法, 但我们发现选择对数方差发散可以产生特别适用于从 (未归一化) 密度中采样的新颖算法。具体而言, 这种发散表现出有益的特性, 如较低的方差、计算效率以及探索与利用之间的权衡。我们可以在多个数值示例中证明, 对数方差损失在一系列度量上极大地提高了采样质量。我们认为, 针对特定问题和方法的具体微调可能会进一步提升对数方差损失的性能, 从而为具有竞争力的扩散采样方法铺平道路。

致谢

我们感谢刘关鸿的许多有用讨论。L.R.的研究得到了德国研究基金会 (DFG) 通过 CRC 1114“复杂系统中的尺度级联”项目 (A05, 项目编号 235221301) 的资金支持。J.B.感谢 Wally Baer 和 Jeri Weiss 博士后奖学金的支持。

参考文献

- Brian DO Anderson. Reverse-time diffusion equation models. *Stochastic Processes and their Applications*, 12(3):313–326, 1982.
- Michael Arbel, Alex Matthews, and Arnaud Doucet. Annealed flow transport Monte Carlo. In *International Conference on Machine Learning*, pp. 318–330. PMLR, 2021.
- Ludwig Arnold. *Stochastic Differential Equations: Theory and Applications*. A Wiley-Interscience publication. Wiley, 1974.
- P. Baldi. *Stochastic Calculus: An Introduction Through Theory and Exercises*. Universitext. Springer International Publishing, 2017.
- Jean-David Benamou and Yann Brenier. A computational fluid mechanics solution to the Monge-Kantorovich mass transfer problem. *Numerische Mathematik*, 84(3):375–393, 2000.
- Julius Berner, Lorenz Richter, and Karen Ullrich. An optimal control perspective on diffusion-based generative modeling. *Transactions on Machine Learning Research*, 2024.
- Espen Bernton, Jeremy Heng, Arnaud Doucet, and Pierre E Jacob. Schrödinger Bridge Samplers. *arXiv preprint arXiv:1912.13170*, 2019.
- Kenneth F Caluya and Abhishek Halder. Wasserstein proximal algorithms for the Schrödinger bridge problem: Density control with nonlinear drift. *IEEE Transactions on Automatic Control*, 67(3): 1163–1178, 2021.
- Tianrong Chen, Guan-Hong Liu, and Evangelos A Theodorou. Likelihood training of Schrödinger Bridge using Forward-Backward SDEs theory. *arXiv preprint arXiv:2110.11291*, 2021a.
- Yongxin Chen, Tryphon T Georgiou, and Michele Pavon. Stochastic control liaisons: Richard Sinkhorn meets Gaspard Monge on a Schrödinger bridge. *SIAM Review*, 63(2):249–313, 2021b.
- Marco Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. *Advances in neural information processing systems*, pp. 2292–2300, 2013.
- Paolo Dai Pra. A stochastic control approach to reciprocal diffusion processes. *Applied mathematics and Optimization*, 23(1):313–329, 1991.
- Valentin De Bortoli, James Thornton, Jeremy Heng, and Arnaud Doucet. Diffusion Schrödinger bridge with applications to score-based generative modeling. *Advances in Neural Information Processing Systems*, 34:17695–17709, 2021.
- Pierre Del Moral, Arnaud Doucet, and Ajay Jasra. Sequential Monte Carlo samplers. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 68(3):411–436, 2006.
- Arnaud Doucet, Adam M Johansen, et al. A tutorial on particle filtering and smoothing: Fifteen years later. *Handbook of nonlinear filtering*, 12(656-704):3, 2009.
- David Lopes Fernandes, Francisco Vargas, Carl Henrik Ek, and Neill DF Campbell. Shooting Schrödinger’s cat. In *Fourth Symposium on Advances in Approximate Bayesian Inference*, 2021.
- Wendell H Fleming and Halil Mete Soner. *Controlled Markov processes and viscosity solutions*, volume 25. Springer Science & Business Media, 2006.
- Hans Föllmer. Random fields and diffusion processes. In *École d’Été de Probabilités de Saint-Flour XV–XVII, 1985–87*, pp. 101–203. Springer, 1988.

- Carsten Hartmann, Lorenz Richter, Christof Schütte, and Wei Zhang. Variational characterization of free energy: Theory and algorithms. *Entropy*, 19(11):626, 2017.
- Ulrich G Haussmann and Etienne Pardoux. Time reversal of diffusions. *The Annals of Probability*, pp. 1188–1205, 1986.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 33:6840–6851, 2020.
- Lars Holdijk, Yuanqi Du, Ferry Hooft, Priyank Jaini, Bernd Ensing, and Max Welling. Path integral stochastic optimal control for sampling transition paths. *arXiv preprint arXiv:2207.02149*, 2022.
- Chin-Wei Huang, Jae Hyun Lim, and Aaron C Courville. A variational perspective on diffusion-based generative models and score matching. *Advances in Neural Information Processing Systems*, 34, 2021.
- Robert E Kass, Bradley P Carlin, Andrew Gelman, and Radford M Neal. Markov chain Monte Carlo in practice: a roundtable discussion. *The American Statistician*, 52(2):93–100, 1998.
- Diederik Kingma, Tim Salimans, Ben Poole, and Jonathan Ho. Variational diffusion models. *Advances in Neural Information Processing Systems*, 34:21696–21707, 2021.
- Takeshi Koshizuka and Issei Sato. Neural Lagrangian Schrödinger bridge. *arXiv preprint arXiv:2204.04853*, 2022.
- Hiroshi Kunita. *Stochastic flows and jump-diffusions*. Springer, 2019.
- Christian Léonard. Some properties of path measures. In *Séminaire de Probabilités XLVI*, pp. 207–230. Springer, 2014.
- Guan-Hong Liu, Tianrong Chen, Oswin So, and Evangelos A Theodorou. Deep generalized Schrödinger bridge. *arXiv preprint arXiv:2209.09893*, 2022.
- Jun S Liu and Jun S Liu. *Monte Carlo strategies in scientific computing*, volume 10. Springer, 2001.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in gflownets. *Advances in Neural Information Processing Systems*, 35: 5955–5967, 2022a.
- Nikolay Malkin, Salem Lahlou, Tristan Deleu, Xu Ji, Edward Hu, Katie Everett, Dinghuai Zhang, and Yoshua Bengio. GFlowNets and variational inference. *arXiv preprint arXiv:2210.00580*, 2022b.
- Laurence Illing Midgley, Vincent Stimper, Gregor N. C. Simm, Bernhard Schölkopf, and José Miguel Hernández-Lobato. Flow annealed importance sampling bootstrap. In *The Eleventh International Conference on Learning Representations*, 2023.
- Tom Minka et al. Divergence measures and message passing. Technical report, Citeseer, 2005.
- Radford M Neal. Annealed importance sampling. *Statistics and computing*, 11(2):125–139, 2001.
- Radford M Neal. Slice sampling. *The Annals of Statistics*, 31(3):705–767, 2003.
- E Nelson. Dynamical theories of Brownian motion. *Press, Princeton, NJ*, 1967.
- Alexander Quinn Nichol and Prafulla Dhariwal. Improved denoising diffusion probabilistic models. In *International Conference on Machine Learning*, pp. 8162–8171. PMLR, 2021.
- Nikolas Nüsken and Lorenz Richter. Solving high-dimensional Hamilton–Jacobi–Bellman PDEs using neural networks: perspectives from the theory of controlled diffusions and measures on path space. *Partial Differential Equations and Applications*, 2(4):1–48, 2021.
- Bernt Øksendal and Bernt Øksendal. *Stochastic differential equations*. Springer, 2003.
- George Papamakarios, Eric T Nalisnick, Danilo Jimenez Rezende, Shakir Mohamed, and Balaji Lakshminarayanan. Normalizing flows for probabilistic modeling and inference. *J. Mach. Learn. Res.*, 22(57):1–64, 2021.

- Michele Pavon. Stochastic control and nonequilibrium thermodynamical systems. *Applied Mathematics and Optimization*, 19(1):187–202, 1989.
- Michele Pavon. On local entropy, stochastic control and deep neural networks. *arXiv preprint arXiv:2204.13049*, 2022.
- Michele Pavon and Anton Wakolbinger. On free energy, stochastic control, and Schrödinger processes. In *Modeling, Estimation and Control of Systems with Uncertainty*, pp. 334–348. Springer, 1991.
- H. Pham. *Continuous-time Stochastic Control and Optimization with Financial Applications*. Stochastic Modelling and Applied Probability. Springer Berlin Heidelberg, 2009.
- Lorenz Richter. *Solving high-dimensional PDEs, approximation of path space measures and importance sampling of diffusions*. PhD thesis, BTU Cottbus-Senftenberg, 2021.
- Lorenz Richter and Julius Berner. Robust SDE-based variational formulations for solving linear PDEs via deep learning. In *International Conference on Machine Learning*, pp. 18649–18666. PMLR, 2022.
- Lorenz Richter, Ayman Boustati, Nikolas Nüsken, Francisco Ruiz, and Omer Deniz Akyildiz. VarGrad: low-variance gradient estimator for variational inference. *Advances in Neural Information Processing Systems*, 33:13481–13492, 2020.
- Christian P Robert, George Casella, and George Casella. *Monte Carlo statistical methods*, volume 2. Springer, 1999.
- Geoffrey Roeder, Yuhuai Wu, and David K Duvenaud. Sticking the landing: Simple, lower-variance gradient estimators for variational inference. *Advances in Neural Information Processing Systems*, 30, 2017.
- L Chris G Rogers and David Williams. *Diffusions, Markov processes and martingales: Volume 2, Itô calculus*, volume 2. Cambridge university press, 2000.
- Abul Hasan Siddiqi and Sudarsan Nanda. *Functional analysis with applications*. Springer, 1986.
- Yang Song and Stefano Ermon. Improved techniques for training score-based generative models. *Advances in neural information processing systems*, 33:12438–12448, 2020.
- Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*, 2020.
- Vincent Stimper, Bernhard Schölkopf, and José Miguel Hernández-Lobato. Resampling base distributions of normalizing flows. In *International Conference on Artificial Intelligence and Statistics*, pp. 4915–4936, 2022.
- Gabriel Stoltz, Mathias Rousset, et al. *Free energy computations: A mathematical perspective*. World Scientific, 2010.
- Belinda Tzen and Maxim Raginsky. Theoretical guarantees for sampling and inference in generative models with latent diffusions. In *Conference on Learning Theory*, pp. 3084–3114. PMLR, 2019.
- Arash Vahdat, Karsten Kreis, and Jan Kautz. Score-based generative modeling in latent space. *Advances in Neural Information Processing Systems*, 34:11287–11302, 2021.
- Lorenz Vaitl, Ludwig Winkler, Lorenz Richter, and Pan Kessel. Fast and unified path gradient estimators for normalizing flows. In *The Twelfth International Conference on Learning Representations*, 2024.
- Francisco Vargas. Machine-learning approaches for the empirical Schrödinger bridge problem. Technical report, University of Cambridge, Computer Laboratory, 2021.
- Francisco Vargas, Will Grathwohl, and Arnaud Doucet. Denoising diffusion samplers. In *International Conference on Learning Representations*, 2023a.

- Francisco Vargas, Andrius Ovsianas, David Fernandes, Mark Girolami, Neil D Lawrence, and Nikolas Nüsken. Bayesian learning via neural Schrödinger–Föllmer flows. *Statistics and Computing*, 33(1):1–22, 2023b.
- Francisco Vargas, Shreyas Padhy, Denis Blessing, and N Nüsken. Transport meets variational inference: Controlled Monte Carlo diffusions. In *The Twelfth International Conference on Learning Representations*, 2024.
- Martin J Wainwright, Michael I Jordan, et al. Graphical models, exponential families, and variational inference. *Foundations and Trends in Machine Learning*, 1(1–2):1–305, 2008.
- Hao Wu, Jonas Köhler, and Frank Noé. Stochastic normalizing flows. *Advances in Neural Information Processing Systems*, 33:5933–5944, 2020.
- Dinghuai Zhang, Ricky Tian Qi Chen, Cheng-Hao Liu, Aaron Courville, and Yoshua Bengio. Diffusion generative flow samplers: Improving learning signals through partial trajectory optimization. *arXiv preprint arXiv:2310.02679*, 2023.
- Qinsheng Zhang and Yongxin Chen. Path Integral Sampler: a stochastic control approach for sampling. In *International Conference on Learning Representations*, 2022.

附录 A

A.1 假设

在我们的证明中，假设所有出现的随机微分方程的系数函数足够光滑，使得诺维科夫条件得到满足，并且这些随机微分方程具有唯一的强解，其密度函数平滑且严格正 p_{X_t} 对于 $t \in (0, T)$ ，参见 Arnold (1974)；Øksendal & Øksendal (2003)；Baldi (2017)。

A.2 证明

命题 2.3 的证明。定义路径空间测度 $\mathbb{P}_{X^{u,x}}$ 和 $\mathbb{P}$ 作为测度和 $X_0 = x$ 的 $\tilde{Y}^v$ conditioned on $X_0^u = x$ and Y^v with $x \in \mathbb{R}^d$ ，分别。然后我们可以计算

$$\begin{aligned} \log \frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{\tilde{Y}^v}}(X^w) &= \log \frac{d\mathbb{P}_{X^{u,x}}}{d\mathbb{P}_{\tilde{Y}^v,x}}(X^w) + \log \frac{d\mathbb{P}_{X_0^u}}{d\mathbb{P}_{\tilde{Y}_0^v}}(X_0^w) \\ &= \log \frac{d\mathbb{P}_{X^{u,x}}}{d\mathbb{P}_{\tilde{Y}^v,x}}(X^w) + \log \frac{p_{\text{prior}}(X_0^w)}{p_{\tilde{Y}^v}(X_0^w, 0)}. \end{aligned} \quad (16)$$

我们遵循 Liu 等人 (2022) 的方法，首先注意到过程 Y^v 在 (3) 中定义的时间反演由下式给出

$$d\tilde{Y}_s^v = (\mu + \sigma \sigma^\top \nabla g - \sigma v)(\tilde{Y}_s^v, s) ds + \sigma(s) dW_s,$$

其中我们简记 $g := \log \tilde{p}_{Y^v}$ ，参见引理 2.1。进一步定义简写符号 $h := u + v - \sigma^\top \nabla g$ 和 $b := \mu + \sigma(u - h)$ 。那么，我们可以将 (2) 和 (3) 中的随机微分方程写为

$$\begin{cases} dX_s^u = (b + \sigma h)(X_s^u, s) ds + \sigma(s) dW_s, \\ d\tilde{Y}_s^v = b(\tilde{Y}_s^v, s) ds + \sigma(s) dW_s. \end{cases}$$

我们现在可以应用 Girsanov 定理 (参见 Nusken & Richter, 2021, 引理 A.1)

)，将 Radon-Nikodym 导数的对数 $\mathcal{R} := \log \frac{d\mathbb{P}_{X^{u,x}}}{d\mathbb{P}}$ 在 (16) 式中重写为

$$\begin{aligned} \mathcal{R} &= \int_0^T (\sigma^{-\top} h)(X_s^w, s) \cdot dX_s^w - \int_0^T (\sigma^{-1} b \cdot h)(X_s^w, s) ds - \frac{1}{2} \int_0^T \|h(X_s^w, s)\|^2 ds \\ &= \int_0^T \left((w - u) \cdot h + \frac{1}{2} \|h\|^2 \right) (X_s^w, s) ds + S_h(X^w) \\ &= \int_0^T \left((w - u) \cdot (u + v - \sigma^\top \nabla g) + \frac{1}{2} \|u + v - \sigma^\top \nabla g\|^2 \right) (X_s^w, s) ds + S_h(X^w) \\ &= R_{f_{u,v,w}^{\text{Bridge}}} - \int_0^T \left(\nabla \cdot (\sigma v - \mu) + (v + w) \cdot \sigma^\top \nabla g - \frac{1}{2} \|\sigma^\top \nabla g\|^2 \right) (X_s^w, s) ds + S_h(X^w). \end{aligned} \quad (17)$$

进一步地，我们可以对函数 g 应用 Itô 引理，得到

$$g(X_T^w, T) - g(X_0^w, 0) = \int_0^T \left(\partial_s g + \nabla g \cdot (\mu + \sigma w) + \frac{1}{2} \text{Tr}(\sigma \sigma^\top \nabla^2 g) \right) (X_s^w, s) ds + S_{\sigma^\top \nabla g}(X^w).$$

注意到 $g = \log p_{Y^v}$ 满足 Hamilton-Jacobi-Bellman 方程 (参见 Berner 等, 2024)

$$\partial_s g = -\frac{1}{2} \text{Tr}(\sigma \sigma^\top \nabla^2 g) + (\sigma v - \mu) \cdot \nabla g + \nabla \cdot (\sigma v - \mu) - \frac{1}{2} \|\sigma^\top g\|^2,$$

我们得到

$$g(X_T^w, T) - g(X_0^w, 0) = \int_0^T \left(\nabla \cdot (\sigma v - \mu) + (v + w) \cdot \sigma^\top \nabla g - \frac{1}{2} \|\sigma^\top g\|^2 \right) (X_s^w, s) ds + S_{\sigma^\top \nabla g}(X^w).$$

最后，结合 (16) 和 (17)，并注意到

$$g(X_T^w, T) = \log p_{\tilde{Y}^v}(X_T^w, T) = \log p_{Y^v}(X_T^w, 0) = p_{\text{target}}(X_T^w),$$

得出所需的表达式。□

备注 A.1 (无发散目标)。可以通过注意到恒等式来从 Radon-Nikodym 导数 (6) 中移除发散，从而将其从相应的损失中移除

$$\int_0^T \nabla \cdot (\sigma v - \mu)(X_s^w, s) ds = \int_0^T (v - \sigma^{-1} \mu)(X_s^w, s) \cdot (\tilde{d}W_s - dW_s),$$

对于一个合适的函数 $\varphi \in C(\mathbb{R}^d \times [0, T], \mathbb{R}^d)$ ，布朗运动的反向积分定义为

$$\int_0^T \varphi(X_s^w, s) \cdot \tilde{d}W_s := \lim_{\Delta t \rightarrow 0} \sum_{n=1}^N \varphi(X_{t_{n+1}}^w, t_{n+1}) \cdot (W_{t_{n+1}} - W_{t_n}),$$

which, in contrast to the definition of the usual Itô integral,

$$\int_0^T \varphi(X_s^w, s) \cdot dW_s := \lim_{\Delta t \rightarrow 0} \sum_{n=1}^N \varphi(X_{t_n}^w, t_n) \cdot (W_{t_{n+1}} - W_{t_n}),$$

在时间网格上离散化积分时考虑右端点 $0 = t_0 < t_1 < \dots < t_N = T$ ，步长为 $\Delta t := t_{n+1} - t_n$ 。上述通过细化划分的定义可以方便地带来固定步长 $\Delta t > 0$ 下的两种积分实现方案。在高维度下，无发散目标可能特别有益，因为在这种情况下，通常计算自动微分的发散代价较高。更多细节，请参见 Vargas 等 (2024) 和 Kunita(2019)。

命题 2.5 的证明。首先回顾 Gâteaux 导数的概念，详见 Siddiqi & Nanda (1986, 第 5.2 节)。我们说函数 $\mathcal{L}: \mathcal{U} \times \mathcal{U} \rightarrow \mathbb{R}_{\geq 0}$ 在点 $u \in \mathcal{U}$ 处是 Gâteaux 可微的，如果对于所有 $v, \phi \in \mathcal{U}$ ，映射 $\varepsilon \mapsto \mathcal{L}(u + \varepsilon \phi, v)$ 在点 $\varepsilon = 0$ 处是可微的。函数 $\mathcal{L}$ w.r.t. u 在方向 ϕ 上的 Gâteaux 导数定义为

$$\frac{\delta}{\delta u} \mathcal{L}(u, v; \phi) := \left. \frac{d}{d\varepsilon} \right|_{\varepsilon=0} \mathcal{L}(u + \varepsilon \phi, v).$$

$\mathcal{L}$ w.r.t. v 的导数类似地定义。现在令 $u = u_\theta$ 和 $v = v_\gamma$ 由 4 参数化，分别为 $\theta \in \mathbb{R}^p$ 和 $\gamma \in \mathbb{R}^p$ 。将 Gâteaux 导数与关于 θ 和 γ 的偏导数联系起来，我们特别关注的方向是 $\phi = \partial_{\theta_i} u_\theta$ 和 $\phi = \partial_{\gamma_i} v_\gamma$ 对于 $i \in \{1, \dots, p\}$ 。这一选择是由 Gâteaux 导数的链式法则所驱动的，在适当的假设下，该法则表明

$$\partial_{\theta_i} \mathcal{L}(u_\theta, v_\gamma) = \left. \frac{\delta}{\delta u} \right|_{u=u_\theta} \mathcal{L}(u, v_\gamma; \partial_{\theta_i} u_\theta) \quad \text{和} \quad \partial_{\gamma_i} \mathcal{L}(u_\theta, v_\gamma) = \left. \frac{\delta}{\delta v} \right|_{v=v_\gamma} \mathcal{L}(u_\theta, v; \partial_{\gamma_i} v_\gamma).$$

类似于 Nüsken & Richter (2021) 中的计算，蒙特卡洛估计器 $\hat{\mathcal{L}}_{\text{LV}}^w$ 对数方差损失 $\mathcal{L}_{\text{LV}}^w$ 在 (8) 中的 Gâteaux 导数，使用 $K \in \mathbb{N}$ 个样本给出为

$$\frac{\delta}{\delta u} \hat{\mathcal{L}}_{\text{LV}}^w(u, v; \phi) = \frac{2}{K} \sum_{k=1}^K \mathcal{A}_{u,v,w}^{(k)} \left(\mathcal{B}_{u,w,\phi}^{(k)} - \frac{1}{K} \sum_{i=1}^K \mathcal{B}_{u,w,\phi}^{(i)} \right), \quad (18)$$

其中上标 (k) 表示蒙特卡洛估计器中第 k 个独立同分布样本的索引，并定义简写符号 $\hat{\mathcal{L}}_{\text{LV}}^w$

$$\mathcal{A}_{u,v,w}^{(k)} := \left(R_{f_{u,v,w}^{\text{Bridge}}} + S_{u+v}^{(k)} + B \right) (X^{w,(k)}) + \log Z$$

and

$$\mathcal{B}_{u,w,\phi}^{(k)} := \left(R_{f_{u,w,\phi}^{\text{gen}}} + S_\phi^{(k)} \right) (X^{w,(k)}) \quad f_{u,w,\phi}^{\text{gen}} = (w - u) \cdot \phi.$$

由此，注意到对数方差损失的定义和命题 2.3 意味着对于最优选择 $u = u^*, v = v^*$ ，有 $\mathcal{A}_{u^*,v^*,w}^{(k)} = 0$

4 我们仅假设 θ 和 γ 处于同一空间 $\mathbb{R}^p$ ，以简化记号。

几乎处处对于每一个 $k \in \{1, \dots, K\}$ 和 $w \in \mathcal{U}$ 。这直接意味着关于控制的导数的陈述成立 u_γ 。类似地，关于的导数的陈述也成立 v_γ ，因为我们可以计算

$$\frac{\delta}{\delta v} \hat{\mathcal{L}}_{\text{LV}}^w(u, v; \phi) = \frac{2}{K} \sum_{k=1}^K \mathcal{A}_{u,v,w}^{(k)} \left(\mathcal{C}_{v,w,\phi}^{(k)} - \frac{1}{K} \sum_{i=1}^K \mathcal{C}_{v,w,\phi}^{(i)} \right),$$

其中

$$\mathcal{C}_{v,w,\phi}^{(k)} = \left(R_{f_{v,w,\phi}^{\text{inf}}} + S_\phi^{(k)} \right) (X^{w,(k)}) \quad \text{含} \quad f_{v,w,\phi}^{\text{inf}} = (v + w) \cdot \phi + \nabla \cdot (\sigma \phi).$$

对于损失函数的蒙特卡洛版本的导数 $\mathcal{L}_{\text{KL}}$ ，如在 (7) w.r.t. to v 中定义的，我们可以计算

$$\frac{\delta}{\delta v} \hat{\mathcal{L}}_{\text{KL}}(u, v; \phi) = \frac{1}{K} \sum_{k=1}^K \int_0^T ((u + v) \cdot \phi + \nabla \cdot (\sigma \phi)) (X_s^{u,(k)}, s) \, ds.$$

我们注意到，即使对于 $u = u^*$ 和 $v = v^*$ ，通常也不能期望相应的蒙特卡洛估计量的方差为零。关于 u 的导数的计算，请参见 Nusken & Richter (2021, 命题 5.3)。 $\square$

备注 A.2 (控制变量解释)。对于损失函数的梯度 $\mathcal{L}_{\text{KL}}$ w.r.t. to u ，我们可以计算

$$\begin{aligned} \frac{\delta}{\delta u} \mathcal{L}_{\text{KL}}(u, v; \phi) &= \mathbb{E} \left[\int_0^T ((u + v) \cdot \phi) (X_s^u, s) \, ds + \left(R_{f_{u,v,u}^{\text{Bridge}}} (X^u) + B(X^u) \right) S_\phi(X^u) \right] \\ &= \mathbb{E} \left[\mathcal{A}_{u,v,u} S_\phi(X^u) \right], \end{aligned}$$

其中我们使用了 Girsanov 定理和 Itô 等式。与 (18) 比较，我们发现对于选择 $w = u$ 的 $\mathcal{L}_{\text{LV}}$ w.r.t. u 的导数可以解释为 $\mathcal{L}_{\text{KL}}$ 的导数的控制变量版本，从而有望减少相应蒙特卡洛估计量的方差，参见 Nusken & Richter (2021); Richter et al. (2020)。

在强化学习的背景下，这样的控制变量也被称为局部基线。作为替代方案，提出了全局基线，其中局部基线的批次依赖缩放被指数移动平均所取代。这相当于将损失中的方差替换为二阶矩，并且进一步优化对数归一化常数的近似值（具有特定的学习率），参见 Malkin et al. (2022b)。由此产生的损失称为（第二）矩损失 (Nusken & Richter, 2021; Richter et al., 2020) 或轨迹平衡目标 (Malkin et al., 2022a)。备注 A.3 (引理 3.1 的替代推导)。引理 3.1 中的表达式也可以通过

$$\frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{\tilde{Y}^{\bar{v}}}}(X^w) = \frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{X^r}}(X^w) \frac{d\mathbb{P}_{\tilde{Y}^{\bar{v},\text{ref}}}}{d\mathbb{P}_{\tilde{Y}^{\bar{v}}}}(X^w) = \frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{X^r}}(X^w) \frac{p_{X_T^r}}{p_{\text{target}}}(X_T^w),$$

其中第一个因子可以通过召回来计算

$$\frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{X^r}}(X^w) = \exp \left(R_{f_{u,r,w}^{\text{ref}}} + S_{u-r} \right) (X^w). \quad (19)$$

另一种视角基于路径空间的重要性采样，参见 Hartmann 等人 (2017)。由于我们的目标是找到一个最优控制 u^* 使得我们能够获得样本 $X_T^{u^*} \sim p_{\text{target}}$ ，我们可以定义目标路径空间测度 $\mathbb{P}_{X^{u^*}}$ 通过 $d \frac{\mathbb{P}_{X^{u^*}}}{d\mathbb{P}_{X^r}}(X^w) = \frac{p_{\text{target}}}{p_{X_T^r}}(X_T^w)$ 。We can then compute

$$\frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{X^{u^*}}}(X^w) = \frac{d\mathbb{P}_{X^u}}{d\mathbb{P}_{X^r}}(X^w) \frac{d\mathbb{P}_{X^r}}{d\mathbb{P}_{X^{u^*}}}(X^w),$$

这与引理 3.1 中的表达式等价，结合 (19)。需要注意的是，在重要性采样的视角下，我们不需要时间反转的概念。

附录 A.3 基于学习扩散的过程采样

在下面的内容中，我们将提供基于受控扩散过程的采样方法的高层次概述。我们的解释基于 (7) 中所述的一般 KL 损失，因为大多数先前的方法都是这种表述的特例，参见表 1。

让我们回忆一下，我们希望学习一个控制 u 使得 $X_T^u \sim p_{\text{target}}$ 。我们首先观察到终端成本 $B(X^u)$ 或 $B^{\text{ref}}(X^u)$ 包含项 $-\log \rho = -\log p_{\text{target}} + \log Z$ ，该项惩罚 X_T^u 结束于目标密度低概率区域。终端成本的其他项，连同运行成本 $R_{f_{u,v,u}}^{\text{Bridge}}$ ，对过程轨迹 X^u 施加额外的约束。在我们的表述中，它们通常强制 X^u 成为 Y^v 的时间反转。对于 v 的特殊选择，这会产生以下设置：

- 对于 PIS 方法，我们最小化受控过程 X^u 到未受控过程 X^0 的逆 KL 发散，促进 u 尽可能接近零。这对应于经典薛定谔桥问题，参见附录 A.4，对于简单的初始条件 $X_0^0 \sim \delta_{x_0}$ ，可以在没有顺序优化程序的情况下求解，参见第 1.1 节和附录 A.4.1。
- DIS 和 DDS 方法受到基于扩散的生成建模的启发 (Ho 等人, 2020; Kingma 等人, 2021; Nichol&Dhariwal, 2021; Vahdat 等人, 2021; Song&Ermon, 2020)。特别是，它们最小化逆 KL 发散到时间反转的“加噪”过程 Y^0 。换句话说， X^u 被强制去去除样本 Y_T^0 的噪声，从而产生来自 $Y_0^0 \sim p_{\text{target}}$ 的样本。

虽然我们在第 2 节中基于路径测度的视角构建了统一框架，但 KL 发散的相关方法也可以从潜在的偏微分方程或倒向随机微分方程系统推导出来，参见附录 A.4 和 Berner 等人 (2024)。

A.4 薛定谔桥问题

本节提供一些关于经典薛定谔桥问题的背景信息。回顾第 3.1 节的内容，所有满足问题 2.2 中所述一般桥问题的解 u^* ，该问题可以通过 Nelson 恒等式 (9) 来描述，薛定谔桥问题考虑的是使 KL 发散 u^* 最小化的解 $D_{\text{KL}}(\mathbb{P}_{X^{u^*}} | \mathbb{P}_{X^r})$ 到给定参考过程 X^r ，定义如 (2) 所示，其中 u 被 $r \in \mathcal{U}$, i.e. 替换

$$dX_s^r = (\mu + \sigma r)(X_s^r, s) ds + \sigma(s) dW_s, \quad X_0^r \sim p_{\text{prior}}.$$

传统上，选择未受控过程 X^0 与 $r = 0$ ，即

$$dX_s^0 = \mu(X_s^0, s) ds + \sigma(s) dW_s, \quad X_0^0 \sim p_{\text{prior}}.$$

在以下内容中，我们将针对标准情形下定义于 (12) 中的薛定谔桥问题制定最优性条件 $r = 0$ 。此外，我们将概述与之相关的倒向随机微分方程系统如何导致与 (7) 和 (8) 中给出的相同损失。这些思想基于 Chen 等 (2021a); Vargas(2021); Liu 等 (2022); Caluya 及 Halder(2021) 的工作。

首先，我们可以定义

$$\phi(x, t) := \min_{u \in \mathcal{U}} \mathbb{E} \left[\frac{1}{2} \int_t^T \|u(X_s^u, s)\|^2 ds \middle| X_t^u = x, X_T^u \sim p_{\text{target}} \right].$$

根据动态规划原理， ϕ 求解 Hamilton-Jacobi-Bellman (HJB) 方程

$$\partial_t \phi = -\mu \cdot \nabla \phi - \frac{1}{2} \text{Tr}(\sigma \sigma^\top \nabla^2 \phi) + \frac{1}{2} \|\sigma^\top \nabla \phi\|^2 \quad (20)$$

(未知边界条件)，并且最优控制满足

$$u^* = -\sigma^\top \nabla \phi.$$

结合相应的 Fokker-Planck 方程对于 X^{u^*} ，这给出了 (11) 解的必要和充分条件。现在，我们可以将 Fokker-Planck 方程和 HJB 方程 (20) 转化为线性方程组，使用指数变换

$$\psi := \exp(-\phi) \quad \hat{\psi} := p_{X^{u^*}} \exp(\phi) = \frac{p_{X^{u^*}}}{\psi}, \quad (21)$$

通常被称为 Hopf-Cole 变换。这给出了在 (12) 中定义的 Schroedinger 桥问题的以下众所周知的最优性条件。定理 A.4 (最优性偏微分方程)。Schrödinger 桥问题 (12) 的解 u^* 等价于

1. $u^* := -\sigma^\top \nabla \phi$ 其中 $p_{X^{u^*}}$ 和 ϕ 是耦合偏微分方程的唯一解

$$\begin{cases} \partial_t p_{X^{u^*}} = -\nabla \cdot (p_{X^{u^*}} (\mu - \sigma \sigma^\top \nabla \phi)) + \frac{1}{2} \text{Tr} (\sigma \sigma^\top \nabla^2 p_{X^{u^*}}) \\ \partial_t \phi = -\mu \cdot \nabla \phi - \frac{1}{2} \text{Tr} (\sigma \sigma^\top \nabla^2 \phi) + \frac{1}{2} \|\sigma^\top \nabla \phi\|^2, \end{cases}$$

with boundary conditions

$$\begin{cases} p_{X^{u^*}}(\cdot, 0) = p_{\text{prior}}, \\ p_{X^{u^*}}(\cdot, T) = p_{\text{target}}. \end{cases}$$

2. $u^* := \sigma^\top \nabla \log \psi$ 其中 ψ 和 $\hat{\psi}$ 是偏微分方程的唯一解

$$\begin{cases} \partial_t \psi = -\nabla \psi \cdot \mu - \frac{1}{2} \text{Tr} (\sigma \sigma^\top \nabla^2 \psi), \\ \partial_t \hat{\psi} = -\nabla \cdot (\hat{\psi} \mu) + \frac{1}{2} \text{Tr} (\sigma \sigma^\top \nabla^2 \hat{\psi}), \end{cases} \quad (22)$$

具有耦合边界条件

$$\begin{cases} \psi(\cdot, 0) \hat{\psi}(\cdot, 0) = p_{\text{prior}}, \\ \psi(\cdot, T) \hat{\psi}(\cdot, T) = p_{\text{target}}. \end{cases} \quad (23)$$

最优控制 v^* 由 Nelson 恒等式 (9) 给出, 即

$$v^* = \sigma^\top \nabla \log p_{X^{u^*}} - u^* = \sigma^\top \nabla \log \hat{\psi}. \quad (24)$$

利用伊藤引理, 我们现在推导出与 (22) 中的偏微分方程系统相对应的倒向随机微分方程系统。

命题 A.5 (Schrödinger 桥问题的 BSDEs)。假设 ψ 和 $\hat{\psi}$ 满足具有边界条件 (23) 的偏微分方程 (22), 并定义过程

$$\begin{cases} \mathcal{Y}_s^w = \log \psi(X_s^w, s), \\ \hat{\mathcal{Y}}_s^w = \log \hat{\psi}(X_s^w, s), \\ \mathcal{Z}_s^w = \sigma^\top \nabla \log \psi(X_s^w, s) = u^*(X_s^w, s), \\ \hat{\mathcal{Z}}_s^w = \sigma^\top \nabla \log \hat{\psi}(X_s^w, s) = v^*(X_s^w, s), \end{cases}$$

其中过程 X^w 由下式给出

$$dX_s^w = (\mu + \sigma w)(X_s^w, s) ds + \sigma(s) dW_s$$

其中 $w \in \mathcal{U}$ 是一个任意控制函数。然后我们得到 BSDE 系统

$$\begin{cases} d\mathcal{Y}_s^w = (\mathcal{Z}_s^w \cdot w(X_s^w, s) - \frac{1}{2} \|\mathcal{Z}_s^w\|^2) ds + \mathcal{Z}_s^w \cdot dW_s, \\ d\hat{\mathcal{Y}}_s^w = \left(\frac{1}{2} \|\hat{\mathcal{Z}}_s^w\|^2 + \nabla \cdot (\sigma \hat{\mathcal{Z}}_s^w - \mu(X_s^w, s)) + \hat{\mathcal{Z}}_s^w \cdot w(X_s^w, s) \right) ds + \hat{\mathcal{Z}}_s^w \cdot dW_s. \end{cases}$$

进一步地, 有

$$\mathcal{Y}_s^w + \hat{\mathcal{Y}}_s^w = \log p_{X^{u^*}}(X_s^w, s) = \log \tilde{p}_{Y^{v^*}}(X_s^w, s). \quad (25)$$

证明。证明类似于 Chen 等人 (2021a) 中的证明。为了简洁起见, 我们定义 $D = \frac{1}{\psi}$ 并对随机过程 $\sigma \sigma^\top$ 。We $\mathcal{Y}_s^w = \log \psi(X^w)$ 应用伊藤引理, 得到

$$d\mathcal{Y}_s^w = (\partial_s \log \psi + \nabla \log \psi \cdot (\mu + \sigma w) + \text{Tr} (D \nabla^2 \log \psi)) (X_s^w, s) ds + \sigma^\top \nabla \log \psi(X_s^w, s) \cdot dW_s.$$

进一步地, 通过 (22) 有

$$\partial_s \log \psi = \frac{1}{\psi} (-\nabla \psi \cdot \mu - \text{Tr} (D \nabla^2 \psi)) = -\nabla \log \psi \cdot \mu - \text{Tr} \left(\frac{D \nabla^2 \psi}{\psi} \right),$$

并且我们注意到恒等式

$$\nabla^2 \log \psi = \frac{\nabla^2 \psi}{\psi} - \frac{\nabla \psi (\nabla \psi)^\top}{\psi^2}.$$

结合前面三个方程，我们得到

$$\begin{aligned} d\mathcal{Y}_s^w &= \left(\sigma^\top \nabla \log \psi \cdot w - \text{Tr} \left(D \frac{\nabla \psi (\nabla \psi)^\top}{\psi^2} \right) \right) (X_s^w, s) ds + \sigma^\top \nabla \log \psi (X_s^w, s) \cdot dW_s \\ &= \left(\mathcal{Z}_s^w \cdot w(X_s^w, s) - \frac{1}{2} \|\mathcal{Z}_s^w\|^2 \right) ds + \mathcal{Z}_s^w \cdot dW_s. \end{aligned}$$

类似地，我们可以对 $\hat{\mathcal{Y}}_s^w = \log \hat{\psi}(X_s^w)$ 应用伊藤引理 并得到 (X_s^w, s)

$$d\hat{\mathcal{Y}}_s^w = \left(\partial_s \log \hat{\psi} + \nabla \log \hat{\psi} \cdot (\mu + \sigma w) + \text{Tr} \left(D \nabla^2 \log \hat{\psi} \right) \right) (X_s^w, s) ds + \hat{\mathcal{Z}}_s^w \cdot dW_s.$$

现在，通过 (22) 可知

$$\partial_s \log \hat{\psi} = \frac{1}{\hat{\psi}} \left(-\nabla \cdot (\hat{\psi} \mu) + \text{Tr} \left(D \nabla^2 \hat{\psi} \right) \right) = -\nabla \log \hat{\psi} \cdot \mu - \nabla \cdot \mu + \text{Tr} \left(\frac{D \nabla^2 \hat{\psi}}{\hat{\psi}} \right).$$

结合前面两个方程，我们得到

$$d\hat{\mathcal{Y}}_s^w = \left(\text{Tr} \left(D \frac{\nabla^2 \hat{\psi}}{\hat{\psi}} + D \nabla^2 \log \hat{\psi} \right) - \nabla \cdot \mu + \sigma^\top \nabla \log \hat{\psi} \cdot w \right) (X_s^w, s) ds + \hat{\mathcal{Z}}_s^w \cdot dW_s.$$

现在，注意到恒等式

$$\begin{aligned} \text{Tr} \left(D \frac{\nabla^2 \hat{\psi}}{\hat{\psi}} + D \nabla^2 \log \hat{\psi} \right) &= 2 \text{Tr} \left(D \frac{\nabla^2 \hat{\psi}}{\hat{\psi}} \right) - \frac{1}{2} \|\sigma^\top \nabla \log \hat{\psi}\|^2 \\ &= \frac{1}{2} \|\sigma^\top \nabla \log \hat{\psi}\|^2 + \nabla \cdot (\sigma \sigma^\top \nabla \log \hat{\psi}), \end{aligned}$$

我们可以得到关系

$$\begin{aligned} d\hat{\mathcal{Y}}_s^w &= \left(\frac{1}{2} \|\sigma^\top \nabla \log \hat{\psi}\|^2 + \nabla \cdot (\sigma \sigma^\top \nabla \log \hat{\psi} - \mu) + \sigma^\top \nabla \log \hat{\psi} \cdot w \right) (X_s^w, s) ds + \hat{\mathcal{Z}}_s^w \cdot dW_s \\ &= \left(\frac{1}{2} \|\hat{\mathcal{Z}}_s^w\|^2 + \nabla \cdot (\sigma \hat{\mathcal{Z}}_s^w - \mu) + \hat{\mathcal{Z}}_s^w \cdot w \right) (X_s^w, s) ds + \hat{\mathcal{Z}}_s^w \cdot dW_s, \end{aligned}$$

这完成了证明。 $\square$

请注意，BSDE 系统比 Chen 等人 (2021a) 引入的略微一般化，可以通过选择 $w(X_s^w, s) = \mathcal{Z}_s^w$ 得到。此外，在 Chen 等人 (2021a) 中， p_{prior} 和 p_{target} 的角色被互换，因为他们考虑的是生成建模而不是从密度中采样。

一个有效的损失函数现在可以通过将两个 BSDE 相加并回顾关系 (25) 来推导，从而得出

$$\begin{aligned} -B(X^w) - \log(Z) &= \log \frac{p_{\text{target}}(X_T^w)}{p_{\text{prior}}(X_0^w)} = (\mathcal{Y}_T^w + \hat{\mathcal{Y}}_T^w) - (\mathcal{Y}_0^w + \hat{\mathcal{Y}}_0^w) \\ &= (R_{f_{u^*, v^*, w}}^{\text{Bridge}} + S_{u^* + v^*})(X^w) \end{aligned}$$

几乎必然成立。类似于 Berner 等人 (2024) 和 Huang 等人 (2021) 在生成模型中的做法，上述等式暗示了一个参数化的对数似然下界 $\log p_{\text{prior}}$ 当用最优控制的近似值替换 $\mathcal{Z}_s^w = u^*(X_s^w, s)$ 和 $\hat{\mathcal{Z}}_s^w = v^*(X_s^w, s)$ 它们的近似值 u 参见 Chen 等人 (2021a)。这个下界精确地恢复了 (7) 中给出的损失函数 v ，进一步地，注意到左侧减去右侧的方差为零，这直接给出了我们在 (8) 中定义的对数方差损失

A.4.1 薛定谔半桥 (PIS)

对于薛定谔半桥，也称为 PIS，在第 3.3 节中介绍的内容，我们可以找到一个由附录 A.4 中概述的偏微分方程视角所启发的替代推导。在这个推导中，关键假设是先验密度集中在单个点上，即 $p_{\text{prior}} := \delta_{x_0}$ 对于某个 $x_0 \in \mathbb{R}^d$ （通常为 $x_0 = 0$ ），参见 Tzen & Raginsky (2019); Dai Pra (1991)。我们可以通过观察到，在情形 $p_{\text{prior}} = \delta_{x_0}$ 下，方程组 (22) 可以解耦来恢复相应的目标。更具体地说，我们注意到方程 (22) 中的第二个方程是关于 X^0 的福克-普朗克方程，并且我们有

$$\hat{\psi} = p_{X^{u^*}} \exp(\phi) = p_{X^0} \quad \hat{\psi}(\cdot, 0) = p_{X_0^0} = \delta_{x_0}.$$

根据 (24)，我们注意到这定义了 $v^* = \sigma^\top \nabla \log p_{X^0}$ 。通过 (21)，我们观察到 $\psi = \frac{p_{X^{u^*}}}{p_{X^0}}$ ，了边界条件

$$\phi(\cdot, T) = -\log \psi(\cdot, T) = \log \frac{p_{X_T^0}}{p_{\text{target}}} = \log \frac{Z p_{X_T^0}}{\rho}$$

到方程 (20) 中的哈密顿-雅可比-贝尔曼方程。根据验证定理 (Dai Pra, 1991; Pavon, 1989; Nüsken & Richter, 2021; Fleming & Soner, 2006; Pham, 2009)，我们从而得到了 PIS 目标

$$\mathcal{L}_{\text{KL}}(u) = \mathbb{E} \left[\frac{1}{2} \int_0^T \|u(X_s^u, s)\|^2 ds + \log \frac{p_{X_T^0}(X_T^u)}{\rho(X_T^u)} \right] = \mathbb{E} \left[(R_{f_{u,0,u}^{\text{ref}}} + B^{\text{ref}})(X^u) \right].$$

此外，最优控制由 $u^* = -\sigma^\top \nabla \phi = \sigma^\top \nabla \log \psi$ 给出。我们也可以从命题 A.5 中的倒向随机微分方程系统推导出这一目标。由于 $\psi(\cdot, 0) = \delta_{x_0}$ ，我们可以专注于过程 $\mathcal{Y}_s^w = \log \psi(X_s^w, s)$ ，并得到

$$\mathcal{Y}_T^w - \mathcal{Y}_0^w = \int_0^T \mathcal{Z}_s^w \cdot w(X_s^w, s) - \frac{1}{2} \|\mathcal{Z}_s^w\|^2 ds + \int_0^T \mathcal{Z}_s^w \cdot dW_s.$$

The PIS objective now follows by choosing $w(X_s^w, s) = \mathcal{Z}_s^w$ and noting that

$$\mathcal{Y}_T^w = \log \psi(X_T^w, T) = \log \frac{p_{\text{target}}}{p_{X_T^0}}(X_T^w).$$

回顾我们在 (1) 中的记号，这也表明对数方差损失可以表示为

$$\mathcal{L}_{\text{LV}}^w(u) = \mathbb{V} \left[(R_{f_{u,0,w}^{\text{ref}}} + S_u + B^{\text{ref}})(X^w) \right].$$

A.5 可处理的 SDE

本文展示一些常见形式的随机微分方程 $dX_s^u = \mu(X_s^u, s) ds + \sigma(s) dW_s$ ，其具有仿射漂移项，并且在给定初始值条件下边缘分布可解析，参见 Song 等人 (2020)。为了方便表示，定义

$$\alpha(t) := \int_0^t \beta(s) ds$$

合适的 $\beta \in C([0, T], (0, \infty))$ 。

方差保持 (VP) 随机微分方程：此 Ornstein-Uhlenbeck 过程由下式给出

$$\sigma(t) := \nu \sqrt{2\beta(t)} \mathbf{I} \quad \mu(x, t) := -\beta(t)x.$$

并且对于 $\nu \in (0, \infty)$ 。于是，我们有

$$X_t | X_0 \sim \mathcal{N} \left(e^{-\alpha(t)} X_0, \nu^2 \left(1 - e^{-2\alpha(t)} \right) \mathbf{I} \right).$$

这表明当 $\alpha(T)$ 足够大时，成立 $X_T \approx \mathcal{N} \left(0, \nu^2 \mathbf{I} \right)$ 。对于 $X_0 \sim \mathcal{N}(m, \Sigma)$ ，we

进一步有

$$X_t \sim \mathcal{N} \left(e^{-\alpha(t)} m, e^{-2\alpha(t)} (\Sigma - \nu^2 \mathbf{I}) + \nu^2 \mathbf{I} \right). \quad (26)$$

Algorithm 1 Training of a generalized time-reversed diffusion sampler

Input: neural networks u_θ, v_γ with initial parameters θ, γ , optimizer method step for updating the parameters, number of steps K , batch size m

Output: optimized parameters θ, γ

```

for  $k \leftarrow 1, \dots, K$  do
   $\mathcal{L} \leftarrow$  choose KL-based loss  $\mathcal{L}_{\text{KL}}$  in (7) or log-variance loss  $\mathcal{L}_{\text{LV}}$  in (8) ▷ Setup
  if  $\mathcal{L} = \mathcal{L}_{\text{KL}}$  then
     $w \leftarrow u_\theta$ 
     $p \leftarrow p_{\text{prior}}$ 
     $w \leftarrow$  choose (detached) control for the forward process
     $p \leftarrow$  choose initial distribution for the forward process
  end if

  for  $i = 1, \dots, m$  do ▷ Approximate cost (batched in practice)
     $x \leftarrow$  sample from  $p$ 
     $(W, X^w) \leftarrow$  simulate discretizations of Brownian motion  $W$  and SDE  $X^w$  with  $X_0^w = x$ 
     $(R_{f_{u_\theta, v_\gamma, w}}^{\text{Bridge}}, B) \leftarrow$  compute approximations of the running and terminal costs using  $X^w$ 
     $\text{rnd}_i \leftarrow R_{f_{u_\theta, v_\gamma, w}}^{\text{Bridge}} + B$ 
    if  $\mathcal{L} = \mathcal{L}_{\text{LV}}$  then
       $S_{u_\theta + v_\gamma} \leftarrow$  compute approximation of the stochastic integral using  $W$ 
       $\text{rnd}_i \leftarrow \text{rnd}_i + S_{u_\theta + v_\gamma}$ 
    end if
  end for

   $\text{mean} \leftarrow \frac{1}{m} \sum_{i=1}^m \text{rnd}_i$  ▷ Compute loss
  if  $\mathcal{L} = \mathcal{L}_{\text{KL}}$  then
     $\hat{\mathcal{L}} \leftarrow \text{mean}$ 
  else
     $\hat{\mathcal{L}} \leftarrow \frac{1}{m-1} \sum_{i=1}^m (\text{rnd}_i - \text{mean})^2$ 
  end if

   $\theta \leftarrow \text{step}(\theta, \nabla_\theta \hat{\mathcal{L}})$  ▷ Gradient descent
   $\gamma \leftarrow \text{step}(\gamma, \nabla_\gamma \hat{\mathcal{L}})$ 
end for

```

方差爆炸 (VE) SDE / 缩放布朗运动: 此 SDE 由缩放布朗运动给出, 即, $\mu := 0$ 和 σ 如上定义。成立如下关系:

$$X_t | X_0 \sim \mathcal{N}(X_0, 2\nu^2 \alpha(t) \mathbf{I}).$$

对于 $X_0 \sim \mathcal{N}(m, \Sigma)$, 我们有:

$$X_t \sim \mathcal{N}(m, 2\nu^2 \alpha(t) \mathbf{I} + \Sigma).$$

A.6 计算细节

为了方便起见, 我们首先在算法 1 中概述我们的方法。回忆 DIS、PIS 和 DDS 方法可以通过对 v, r 和 p_{prior} 做特定选择来恢复, 参见表 1。我们在下文指定相应的设置和进一步的计算细节。

一般设置: 每个实验都在单个 GPU 上执行, 在我们的 PyTorch 实现中, 我们通常遵循 Berner 等人 (2024) 提出的 DIS 和 PIS 的设置和超参数, 而 Berner 等人的实现基于 Zhang & Chen (2022) 的实现。具体来说, 我们使用 Zhang & Chen (2022) 的傅里叶 MLPs, 批大小为 2048, 并使用 Adam 优化器。为了便于比较, 我们使用固定数量的 200 步进行 Euler-Maruyama 方案。与 Berner 等人 (2024) 的不同之处在于, 我们发现通过从 0.005 开始并每 100

步指数衰减到最终的学习率为 10^{-4} ，可以获得更好的性能（对于所有考虑的方法和损失）。我们使用 60000 梯度步进行具有 $d \leq 10$ 的实验，否则使用 120000 梯度步以大致实现收敛。然而，我们观察到在收敛之前，损失之间的差异已经显现出来，参见例如图 1。

路径积分采样器 (PIS)：我们遵循张与陈 (2022) 的方法，使用从 δ_0 开始的布朗运动作为未控制的随机微分方程 X^0 。此外，我们还利用目标密度的得分 $\nabla \log \rho$ （通常以闭合形式给出或通过自动微分计算）来参数化控制 u ，参见张与陈 (2022)；伯纳等人 (2024)。

DIS：我们使用宋等人 (2020) 中的 VP-SDE 作为随机微分方程 Y^0 。具体来说，我们使用 $\nu := 1$ 和

$$\beta(t) := (1 - t)\beta_{\min} + t\beta_{\max}, \quad t \in [0, 1],$$

其中 $\beta_{\min} = 0.05$ 和 $\beta_{\max} = 5$ ，详见附录 A.5。此外，我们采用 $\nabla \log \rho$ 和 $\nabla \log p_{\text{prior}}$ 之间的线性插值来参数化控制 u ，参见伯纳等人 (2024)。

桥接：对于一般的桥接，我们考虑损失函数 (7)，这对应于陈等人 (2021a) 中适应未归一化密度的设置。我们采用了类似于 DIS 的设置；然而，我们还额外使用了一个傅里叶 MLP 来控制过程 Y^v 。由于通过 VP-SDE 的构造， Y_T^0 已经接近 p_{prior} ，我们为控制 v 设定了一个较低的初始学习率 10^{-4} 。尽管这些选择已经提供了更好的 KL 发散结果，见表 5，但我们注意到更复杂且可能特定于问题的选择可以在未来的研究中进行探讨。特别是对于一般的桥接，我们可以自由选择 SDEs (2) 和 (3) 中的先验密度 p_{prior} 以及漂移函数 μ 。

对数方差损失：对于对数方差损失，我们仅将目标从 $\mathcal{L}_{\text{KL}}$ 更改为 $\mathcal{L}_{\text{IV}}^w$ ，其中我们使用默认选择的 $w := u$ ，i.e., $X^w := X^u$ 。我们强调无需关于 w 进行微分，这导致训练时间减少，请参见图 9。在实践中，我们可以将 X^w 从计算图中分离出来而不引入任何偏差。这可以通过 PyTorch 和 TensorFlow 中的 detach 和 stop gradient 操作来实现。我们将其他选择的 w 留给未来的研究，并预期在训练初期选择噪声版本的 u 可能会带来更好的探索和性能。此外，我们为对数方差损失使用的超参数与基于 KL 的损失相同。由于这些设置源自 Berner 等人 (2024)，并且已针对基于 KL 的损失进行了调整，我们怀疑优化对数方差损失的超参数可以进一步提高性能。

评估：为了评估我们的度量，我们考虑 $n = 10^5$ 样本 $(x^{(i)})_{i=1}^n$ 并使用 ELBO 作为对数归一化常数的近似 $\log Z$ ，请参见附录 A.6.1。我们进一步计算（归一化的）有效样本大小

$$\text{ESS} := \frac{(\sum_{i=1}^n w^{(i)})^2}{n \sum_{i=1}^n (w^{(i)})^2},$$

其中 $(w^{(i)})_{i=1}^n$ 是路径空间中样本 $(x^{(i)})_{i=1}^n$ 的重要性权重。最后，我们估计 Sinkhorn 距离⁵ $\mathcal{W}_\gamma^2$ (Cuturi, 2013) 并报告估计边缘平均标准差的误差，即

$$\text{std} := \frac{1}{d} \sum_{k=1}^d \sqrt{\mathbb{V}[G_k]}, \quad \text{其中} \quad G \sim p_{\text{target}}.$$

A.6.1 对数归一化常数的计算

对于一般桥接设置下的对数归一化常数 $\log Z$ 的计算，我们注意到对于任意 $u, v \in \mathcal{U}$ ，都成立

$$\mathbb{E} \left[\frac{d\mathbb{P}_{\tilde{Y}^v}}{d\mathbb{P}_{X^u}}(X^u) \right] = 1.$$

⁵ 我们的 Sinkhorn 距离实现基于 <https://github.com/fwilliams/scalable-pytorch-sinkhorn>，默认参数。

结合命题 2.3, 这表明

$$\log Z = \log \mathbb{E} \left[\exp \left(- \left(R_{f_{u,v,u}^{\text{Bridge}}} + S_{u+v} + B \right) (X^u) \right) \right]. \quad (27)$$

如果 $u = u^*$ 和 $v = v^*$ 成立, 期望中的表达式几乎处处为常数, 这意味着

$$\log Z = - \left(R_{f_{u^*,v^*,u^*}^{\text{Bridge}}} + S_{u^*+v^*} + B \right) (X^{u^*}). \quad (28)$$

若仅拥有 u^* 和 v^* 的近似值, Jensen 不等式表明 (28) 式的右侧给出了 $\log Z$ 的一个下界。对于 PIS 和 DIS, 对数归一化常数可以类似计算, 参见 Zhang & Chen (2022); Berner 等人 (2024)。除非另有说明, 在我们的实验中, 我们使用该下界作为 $\log Z$ 的估计器。

A.7 部分轨迹优化

在本节中, 本文提出了一种方法, 该方法无需对整个轨迹进行仿真, 而只需依赖子轨迹即可。一方面, 这有望实现更快的计算; 另一方面, 它可用于探索策略, 因为子轨迹可以在任意指定的位置开始, 而不受控制的影响 u 。关键在于, 这种策略仅适用于对数方差损失, 而不适用于基于 KL 的损失。

让我们回忆一下, 在 (8) 中定义的对数方差损失适用于任何过程 X^w 。特别是, 除了控制 w 之外, 我们还可以自由选择初始条件 X^w , 参见命题 2.3 的证明。受到 Zhang 等人 (2023) 的启发, 我们可以利用这一事实来训练 DIS 或 DDS 方法在更小的时间区间上 $[t, T]$ 。具体来说, 回忆一下 DIS 方法在 (14) 中的对数方差损失由

$$\mathcal{L}_{\text{LV}}^w(u) = \mathbb{V} \left[\left(R_{f_{u,w}^{\text{DIS}}} + S_u + B \right) (X^w) \right], \quad (29)$$

其中最优控制由

$$u^* = \sigma^\top \nabla \log \bar{p}_{Y^0}, \quad (30)$$

参见第 3.2 节。此外, 回忆一下

$$B(X^w) = \log \frac{p_{\text{prior}}(X_0^w)}{\rho(X_T^w)}, \quad (31)$$

在 $p_{\text{prior}} \approx p_{Y_t^0}$ 处 τ 。现在, 假设一个近似值 $\Phi(\cdot, t) \approx \log p_{Y_t^0}$ 对于 $t \in [0, T]$, 我们可以将 $\log p_{\text{prior}}$ 替换为 $\Phi(\cdot, t)$, 并在时间区间 $[t, T]$ 上考虑相应的子问题。对于对数方差损失, 然后可以采样 $t \sim \text{Unif}([0, T])$, 选择任意初始条件 X_t^w , 并在时间区间 $[t, T]$ 上最小化损失 (29)。

为了获得近似值 $\Phi(\cdot, t) \approx \log p_{Y_t^0}$, 我们可以训练一个独立的神经网络, 例如, 使用附录 A.4 中的基础最优性偏微分方程。然而, 对于 DIS 方法, 如果我们将控制参数化为 u , 则无需这样做

$$u = \sigma^\top \nabla \bar{\Phi}, \quad (32)$$

其中 Φ 是一个神经网络。基于 (30), 我们可以将 $\Phi(\cdot, t)$ 作为训练期间的近似值 $\log p_{Y_t}$ 。因此, 我们可以优化损失函数

$$\mathcal{L}_{\text{LV,sub}}^w(\Phi) := \mathbb{V} \left[\left(R_{f_{\sigma^\top \nabla \bar{\Phi}, w}^{\text{DIS}}} + S_{\sigma^\top \nabla \bar{\Phi}} + B_{\Phi, \text{sub}} \right) (X^w) \right],$$

关于函数 Φ 。在上述内容中, 我们可以选择 $t \sim \text{Unif}([0, T])$, $X_t^w \sim \nu$, 其中 ν 是在 $\mathbb{R}^d$ 上的一个合适的概率测度, 并且

$$B_{\Phi, \text{sub}}(X^w) := \Phi(X_t^w, t) - \log \rho(X_T^w),$$

其中 (稍有滥用符号) 积分 R 和 S 在 (1) 中定义, 现在从 t 到 T 进行。

子轨迹训练过程具有三个潜在的好处。首先, 由于我们考虑较小的时间间隔 $[t, T]$, 这可能会加速训练, 因为 SDE 的模拟会更快。其次, 我们可以适当地选择 X_t^w , 以防止模式崩塌, 例如, 我们可以从一个具有足够大方差的分布 X_t^w 中采样

表 3: 我们比较了在参数化中不使用目标信息 $\nabla \log \rho$ 的 DIS 性能。在这种情况下, KL 基础损失的性能通常会下降, 正如 Zhang & Chen (2022) 所观察到的那样。对于对数方差损失, 我们可以通过依赖于从随机点开始的子轨迹 $t \sim \text{Unif}([0, T])$ 和 $x \sim \text{Unif}([-a, a]^d)$ (对于足够大的 $a \in (0, \infty)$) 以促进探索, 见附录 A.7) 来抵消这种下降。这使得在不使用任何目标梯度信息的情况下也能获得具有竞争力的结果。

Problem	Loss	$\Delta \log Z \downarrow$	$\mathcal{W}_\gamma^2 \downarrow$	ESS $\uparrow$	$\Delta \text{std} \downarrow$
GMM ($d = 2$)	KL-DIS (Berner et al., 2024)	2.291	3.661	0.8089	3.566
	LV-DIS-Subtraj. (ours)	0.059	0.020	0.8613	0.008
DW ($d = 5, m = 5, \delta = 4$)	KL-DIS (Berner et al., 2024)	3.983	5.517	0.3430	1.795
	LV-DIS-Subtraj. (ours)	0.394	0.121	0.4378	0.002




图 4: 高斯混合模型 p_{target} 的等高线图, 具有 40 个模式, 类似于 Midgley 等人 (2023) 提出的问题。我们绘制了先验分布的样本 $p_{\text{prior}} = \mathcal{N}(0, \text{I})$ (左图) 和使用 KL 基础损失、对数方差损失以及部分轨迹优化训练的 DIS 方法 (从左至右), 见附录 A.7。对于所有方法, 我们使用 $T = 2$ 以保证 $p_{Y_T^0} \approx p_{\text{prior}}$ 。根据表 3 中的设置, 子轨迹训练可以在没有目标梯度信息的情况下恢复所有模式, 而其他方法则遭受模式崩塌——尽管它们利用了 $\nabla \log \rho$ 。Midgley 等人 (2023) 报告称, 在这个基准上, 几种最先进的方法都出现了模式崩塌。我们注意到, LV-DIS (与 KL-DIS 不同) 在略微增加先验方差时可以恢复所有模式。

分布 ν 具有足够的方差。第三, 在 (32) 中, 我们考虑了一个不依赖于 $\nabla \log \rho$ 的 u 参数化, 这可能不可用或计算成本高昂。

除了这些优点外, 我们在表 3 中展示了子轨迹训练可以达到与表 2 结果相当的性能。相反, 我们展示了当不使用包含项 $\nabla \log \rho$ 的参数化时, 基于 KL 损失的 DIS 方法性能变差。请注意, 由于需要根据 X_t^u 采样初始条件, 子轨迹训练不能与基于 KL 的损失一起使用。

在图 4 中, 我们将性能与 Midgley 等人 (2023) 提出的基准进行了比较。我们展示了部分轨迹优化能够识别高斯混合模型的所有 40 种模式, 显著优于 DIS 方法, 即使在使用对数方差损失和目标导数进行参数化的情况下也是如此。我们注意到, Midgley 等人 (2023) 报告了其他最先进方法在这种基准上的模式崩塌现象, 如随机归一化流 (Wu 等人, 2020), 持续重复退火流传输蒙特卡洛 (Arbel 等人, 2021), 以及具有重采样基础分布的流 (Stimper 等人, 2022)。

附录 A.8 进一步实验和比较

本节中, 我们展示了进一步的结果和消融研究。在表 4 中, 我们展示了对数方差损失也导致了较小批大小下的改进。这可以通过其方差缩减效果来解释, 参见命题 2.5, 附注 A.2 和图 5。在图 6 和图 7 中, 我们

表 4: 考虑了与表 2 相同的设置, 但批大小从 2048 减少到 512。我们再次观察到, 对数方差损失始终带来更好的性能。这可以通过其梯度估计器固有的方差缩减效果来解释 (特别是对于较小的批大小非常有帮助), 参见命题 2.5, 附注 A.2 和图 5。

Problem	Method	Loss	$\Delta \log Z \downarrow$	$\mathcal{W}_\gamma^2 \downarrow$	ESS $\uparrow$	$\Delta \text{std} \downarrow$
GMM ($d = 2$)	PIS	KL (Zhang & Chen, 2022)	2.201	2.708	0.0002	3.576
		LV (ours)	2.200	2.629	0.0002	3.564
	DIS	KL (Berner et al., 2024)	1.725	0.088	0.0045	2.711
		LV (ours)	0.063	0.020	0.8517	0.004
DW ($d = 5, m = 5, \delta = 4$)	PIS	KL (Zhang & Chen, 2022)	3.693	4.949	0.0001	1.793
		LV (ours)	0.285	0.124	0.5957	0.008
	DIS	KL (Berner et al., 2024)	4.047	5.068	0.0015	1.797
		LV (ours)	0.447	0.121	0.3917	0.002




图 5: 我们比较了使用基于 KL 的损失或对数方差损失的损失和 (平均) 梯度估计器的标准差。每个标准差都是通过对损失进行 40 次仿真的计算得出, 而不更新参数。我们展示了 DIS 方法在 5 维 DW 目标上的结果。正如我们的理论预测的那样, 对数方差损失显示出损失及其梯度的标准差显著更小。

证明对数方差损失可以在中等维度和极高维度下缓解模式崩塌。此外, 我们在表 5 中展示了通用桥接方法的结果, 并在图 8 中考虑了 Wu 等人 (2020) 提出的问题。在图 9 中, 我们通过箱线图展示了我们的结果在表 2 中对于不同随机种子的鲁棒性。

最后, 在表 6 中, 我们展示了我们的方法与最先进采样基线相比具有竞争力。然而, 我们希望强调的是, 我们的研究重点不是广泛地与 MCMC 方法或归一化流进行比较。我们的目标是展示最近开发的方法, 如 PIS、DDS 和 DIS, 可以在一个共同框架下统一, 这使得可以使用不同的发散度量。然后, 我们提出了对数方差发散, 这使得基于扩散的采样器更具竞争力, 并减轻了与其他方法相比可能存在的缺点。关于所考虑的基于扩散的采样器和 MCMC 变体之间存在一般权衡的事实已经在介绍相应方法的论文中进行了讨论和数值分析, 参见 Zhang & Chen (2022); Vargas et al. (2023a)。




图 6: PIS 和 DIS (左和右) 在 DW 问题中维度为 $d = 5$, 且 $m = 5$ 和 $\delta = 4$ 的样本边缘分布。对数方差损失的模式覆盖优于 KL 损失的所有边缘分布 (从上到下)。




图 7: 高维偏移双井问题中 DIS 样本的第一个四个坐标边缘分布, 维度为 $d = 1000$, 且 $m = 3$ 和 $\delta = 2$ (参见第 4.1 节), 分别使用 KL 或对数方差损失。再次观察到对数方差损失的模式覆盖优于反向 KL 发散。

表 5: 第 2.3 节中通用桥接方法在选定基准问题上的度量。我们观察到使用对数方差损失有明显的改进。此外, 对于 KL 发散, 我们注意到通用桥接框架可以获得比 DIS 或 PIS 更好的结果, 参见表 2。如同表 2 一样, 我们报告了五次独立运行的中位数。我们展示了估计对数归一化常数 $\Delta \log Z$ 的误差以及边缘的标准差 Δstd 。此外, 我们报告了归一化的有效样本大小 ESS 和 Sinkhorn 距离 $\mathcal{W}_\gamma^2$ (Cuturi, 2013)。箭头 $\uparrow$ 和 $\downarrow$ 指示我们是否希望最大化或最小化给定的度量。

Problem	Method	Loss	$\Delta \log Z \downarrow$	$\mathcal{W}_\gamma^2 \downarrow$	ESS $\uparrow$	$\Delta \text{std} \downarrow$
GMM ($d = 2$)	Bridge	KL (Chen et al., 2021a)	0.328	0.393	0.0180	0.698
		LV (ours)	0.084	0.020	0.9669	0.010
DW ($d = 5, m = 5, \delta = 4$)	Bridge	KL (Chen et al., 2021a)	0.872	0.132	0.0561	0.099
		LV (ours)	0.215	0.119	0.5940	0.002




图 8: 比较了 Wu 等 (2020) 目标样本的结果。对于基于 KL 的损失函数, 大部分样本 (PIS: 86%, DIS: 67%) 位于域外, 尽管密度值较低。另一方面, 对数方差损失显著提升了性能, 与 Wu 等 (2020) 提出的随机归一化流相比具有竞争力。

表 6: 我们将方法与持续重复退火流传输蒙特卡洛 (CRAFT) 进行了比较, 参见 Arbel 等 (2021)。我们调整了提议的配置文件 6, 使其使用相同的批大小和迭代次数, 并使用 10^5 样本评估所有方法。可以看到, 结合对数方差损失的扩散采样在多种度量上可以提供具有竞争力的性能。我们报告了五次独立运行的中位数, 并比较了对数归一化常数 (使用公式 (27) 中的重新加权估计器)、到真实样本的 Sinkhorn 距离以及平均标准差估计误差。

Problem	Method	$\Delta \log Z (rw) \downarrow$	$\mathcal{W}_\gamma^2 \downarrow$	$\Delta \text{std} \downarrow$
GMM ($d = 2$)	CRAFT (Arbel et al., 2021)	0.012	0.020	0.019
	LV-PIS (ours)	0.001	0.020	0.023
	LV-DIS (ours)	0.017	0.020	0.004
Funnel ($d = 10$)	CRAFT (Arbel et al., 2021)	0.123	5.517	6.139
	LV-PIS (ours)	0.097	5.593	6.852
	LV-DIS (ours)	0.028	5.075	5.224
DW ($d = 5, m = 5, \delta = 4$)	CRAFT (Arbel et al., 2021)	0.001	0.118	0.000
	LV-PIS (ours)	0.000	0.121	0.001
	LV-DIS (ours)	0.043	0.120	0.001
DW ($d = 50, m = 5, \delta = 2$)	CRAFT (Arbel et al., 2021)	0.000	6.821	0.001
	LV-PIS (ours)	0.001	6.823	0.000
	LV-DIS (ours)	0.422	6.855	0.009

配置文件可以在 https://github.com/deepmind/annealed_flow_transport/blob/master/configs 找到。




图 9: 五个独立运行的箱线图, 针对每个问题和方法 (从左至右分别为 KL-PIS, LV-PIS (我们的方法), KL-DIS, LV-DIS (我们的方法)), 设置如表 2 所示, 以及相应的真值或最优值 (虚线)。可以看出, 对数方差损失的性能改进在不同的种子下是稳健的。同时, 通过对数方差损失避免通过 SDE 求解器进行微分, 减少了每次梯度步骤的平均时间。