

图上的广义薛定谔桥

Panagiotis Theodoropoulos¹ Juno Nam² Evangelos Theodorou^{1†} Jaemoo Choi^{1†}

摘要

在许多领域中，图上的运输是一个基本挑战，其中决策必须遵守拓扑和操作约束。尽管需要可行的策略，现有的图运输方法缺乏这种表达能力。它们依赖于限制性的假设，无法推广到稀疏拓扑，并且随着图的大小和时间范围的增加而扩展性差。为了解决这些问题，我们引入了图上的广义薛定谔桥（GSBoG），这是一种新型的可扩展的数据驱动框架，用于在任意图上学习可执行的受控连续时间马尔可夫链（CTMC）策略，在状态成本增强动力学下进行学习。值得注意的是，GSBoG 学习轨迹级策略，避免密集的全局求解器，从而提高可扩展性。这是通过似然优化方法实现的，该方法满足端点边缘分布，同时在状态相关的运行成本下优化中间行为。在具有挑战性的现实世界图拓扑上的广泛实验表明，GSBoG 可靠地学习准确的、尊重拓扑的策略，同时优化特定应用的中间状态成本，突显其广泛的适用性并开辟了成本意识动态运输的新途径。

1. 引言

图是对复杂系统的一种普遍抽象（Easley & Kleinberg, 2010），通过网络提供了一个共同的状态空间表示，适用于诸如供需系统（Zhang 等人, 2003）、道路和交通基础设施（Chiu 等人, 2011b）、通信和社会网络（Newman, 2003）、电力

¹ 佐治亚理工学院 ² 麻省理工学院。联系信息：Jaemoo Choi <jchoi843@gatech.edu>, Evangelos Theodorou <evangelos.theodorou@gatech.edu>。




图 1. 从源节点（蓝色）到目标节点（红色）的学习图路由策略，跨越时间 t 和训练迭代。边强度和颜色遵循轨迹演化色图，展示了学习策略如何逐步将流量从源区域重新分配到目标区域，随着训练收敛。

网络（Pagani & Aiello, 2013），甚至是分子动力学的离散模型（Husic & Pande, 2018）。在这些设置中，节点表示离散状态，如实体、对象或数据点，而边编码状态之间的可行转换，连同相关的成本，通常受包括容量限制、拥堵和吞吐量在内的物理约束（Bertsekas, 1998）。

图上的运输问题自然被表述为节点上的概率分布匹配问题（例如，供给和需求）。因此，最优传输（OT）在图上通常用于提供一种原则性的方法来运输质量（Peyré & Cuturi, 2017）。这些框架通常输出一个单一的静态耦合，该耦合匹配源分布和目标分布（Essid & Solomon, 2018; Peyré & Cuturi, 2017）。虽然这种耦合指定了节点之间应移动多少质量的总体情况，但它没有描述质量如何随时间移动，也不产生图上的可执行控制策略（Chizat 等人, 2018）。因此，在部署时不会优化或控制中间轨迹（O'Connor 等人, 2022）。

在实际部署中，运输本质上是时间依赖的；因此，重要的是要指定质量如何随时间在网络中移动，而不仅仅是静态计划（Chiu 等人, 2011a）。核心挑战在于构建一个可行的、尊重拓扑结构的演化过程，以控制中间分布——

表 1. 连续空间中的广义薛定谔桥问题与任意离散空间中的比较 $\mathbb{R}^d$ ，以及任意离散空间中的比较 $\mathcal{X}$ 。

Continuous state space $\mathbb{R}^d$		Discrete State Space $\mathcal{X}$
Reference Dyn. p^r	$dX_t = r_t(X_t) dt + \sigma_t dW_t, X_0 \sim \mu$	CTMC (X_t) with transition rate $(r_t), X_0 \sim \mu$
Controlled Dyn. p^u	$dX_t = (r_t + \sigma_t u_t) dt + \sigma_t dW_t, X_0 \sim \mu$	CTMC (X_t) with transition rate $(u_t), X_0 \sim \mu$
GSB	$\mathbb{E}_{X \sim p^u} \left[\int_0^1 f_t(X_t, p_t^u) dt \right] + \text{KL}(p^u \parallel p^r)$	
Continuity Equation	$\partial_t p_t^u = -\nabla \cdot ((r_t + \sigma_t u_t) p_t^u) + \frac{\sigma_t^2}{2} \Delta p_t^u$	$\partial_t p_t^u(x) = \sum_{z \in \mathcal{X}} u_t(x, z) p_t^u(z)$
Iterative Proportional Fitting	Eqs. (10) and (11)	Eqs. (26) and (27)
Temporal Difference	Eq. (16) (Liu et al., 2022b)	Eqs. (28) and (29)

同时最小化网络成本并适应操作约束，如容量和时间变化 (Peyré & Cuturi, 2017; Koch & Nasrabadi, 2014)。这促使了动态形式的提出，这些形式优化了时间索引的流，并明确地在网络域上建模分布演化 (Burger 等人, 2023)。在此基础上，Chow 等人 (2022) 引入了一种动态薛定谔桥方法，通过求解所有节点上的概率单纯形上的哈密顿流，在图上构造随机的时间索引流。然而，在实践中，现有的动态方法在大规模情况下可能计算昂贵且脆弱，尤其是在大型稀疏网络上，通常需要在精度和可行性之间进行权衡，实施近似方案 (Arqué 等人, 2022; Facca 等人, 2024)。

在这项工作中，我们介绍了广义薛定谔桥在图上的应用 (GSBoG)，一种在一般图上学习有限时间范围传输策略的迭代且可扩展的框架。最接近我们的设置的是图上的动态 SB (Chow 等, 2022)；然而，与解决整个图上的全局时间扩展流不同，我们的 GSBoG 采用了基于粒子和数据驱动的表述，这缓解了现有基于图的方法的可扩展性挑战。具体而言，我们将广义薛定谔桥 (GSB) 原理 (Liu 等, 2022a; Chen 等, 2021; De Bortoli 等, 2021; Vargas 等, 2021) 从连续状态空间扩展到图结构域。表 1 并排比较了连续状态下的 GSB $\mathbb{R}^d$ 和离散状态 $\mathcal{X}$ 空间。类似于连续状态设置，GSBoG 支持依赖于状态和分布的一般运行成本，任意源-目标传输以及一般的图拓扑结构。据我们所知，这项工作首次以数据驱动的方式在图上制定 GSB 传输。这种设置从根本上不同于最近的离散扩散或 SB 方法 (Kim 等, 2024; Ksenofontov & Korotin, 2025; Lou 等, 2024)，后者主要关注图生成或离散状态综合。相比之下，GS-BoG 解决了从给定源到固定图上的目标分布的分布传输问题，如图 1 所示，在优化轨迹级行为的同时也考虑了应用特定的成本函数。

确切地说，我们基于连续时间马尔可夫链 (CTMC) 动力学，在图上制定了一个 GSB 问题。我们推导出离散最优条件，这些条件与连续状态表述相平行，提供了 GSB 的原理图类比。在此分析的基础上，我们开发了一种数据驱动的迭代比例拟合算法，并附带了一个时间差目标，能够在图上的任意分布之间进行传输，同时最小化一般成本函数。最后，我们通过具有挑战性的现实世界图上的代表性示例展示了我们提出的框架的广泛适用性，实现了具有成本意识的动态传输在一般网络系统上的应用。我们的贡献总结如下：

- 我们引入了 GSBoG，这是一种首次在任意图上实现的数据驱动广义薛定谔桥，同时实现了端点边缘分布匹配和在一般运行成本下的中间轨迹优化。
- 我们将图传输形式化为在连续时间马尔可夫链 (CTMC) 动力学下受控粒子运动，并通过路径空间特征推导出可处理的目标函数。
- 广泛的实验表明，GSBoG 学习到的拓扑尊重传输策略具有精确的端点匹配和优于基线方法的中间成本行为。

2. 广义薛定谔桥问题

符号约定。 设 $\mathcal{X}$ 是一个连续状态空间（假设为波莱空间），并设 $\mu, \nu \in \mathcal{P}(\mathcal{X})$ 分别表示定义在 $\mathcal{X}$ 上的源概率测度和目标概率测度。这里， $\mathcal{P}(\mathcal{X})$ 表示定义在 $\mathcal{X}$ 上的概率测度集合。我们考虑由随机微分方程 (SDE) 给出的参考随机动力学

$$dX_t = r_t(X_t) dt + \sigma_t dW_t, \quad X_0 \sim \mu, \quad (1)$$

其中 $r : [0, 1] \times \mathcal{X} \rightarrow \mathcal{X}$ 是预设的基本漂移， $\sigma : [0, 1] \rightarrow \mathbb{R}_{>0}$ 是时间依赖的噪声调度，而 $\{W_t\}_{t \in [0, 1]}$ 是标准布朗运动。

广义薛定谔桥 (GSB) 问题 本工作中考虑的问题是薛定谔桥问题的一种广义设置 (GSB; Chen 等人 (2014))。运输问题寻求一个控制函数 $u : [0, 1] \times \mathcal{X} \rightarrow \mathcal{X}$, 使得受控动力学

$$dX_t = (r_t(X_t) + \sigma_t u_t(X_t)) dt + \sigma_t dW_t, \quad X_0 \sim \mu, \quad (2)$$

将源分布 μ 在 $t=0$ 转换为目标分布 ν 在 $t=1$, i.e., $X_1 \sim \nu$, 同时动力学受到状态和边缘依赖运行成本的影响。令 $f : [0, 1] \times \mathcal{X} \times \mathcal{P}(\mathcal{X}) \rightarrow \mathbb{R}$ 表示一个可能依赖于时间、状态以及时间- t 边缘分布的代价函数。GSB 寻求解决受控概率路径 p^u

$$\min_{p^u} \mathbb{E}_{X \sim p^u} \left[\int_0^1 f_t(X_t, p_t^u) dt \right] + \text{KL}(p^u \| p^r), \quad (3)$$

$$\text{s.t. } \partial_t p_t^u = -\nabla \cdot ((r_t + \sigma_t u_t) p_t^u) + \frac{\sigma_t^2}{2} \Delta p_t^u, \quad (4)$$

$$p_0^u = \mu, \quad p_1^u = \nu,$$

其中, 方程 (4) 中的偏微分方程是描述受控路径边缘密度的时间演化的福克-普朗克方程 (FPE) p_t^u 。请注意, Kullback-Leibler (KL) 发散 $\text{KL}(p^u \| p^r)$ 对受控动力学进行正则化, 使其趋向参考过程, 从而形成一个路径空间上的熵正则化最优传输问题。通过应用吉尔萨诺夫定理 (Särkkä & Solin, 2019), 该问题可以转化为等价的控制理论表述:

$$\min_u \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t\|^2 + f_t dt \right], \text{ s.t. (4), } X_0 \sim \mu, X_1 \sim \nu.$$

这种表述突出了控制努力与由 f_t 编码的任务相关成本之间的权衡。

霍普夫-科尔变换和广义薛定谔系统 根据 SB 理论, 最优漂移 $u_t = \sigma_t \nabla \log \varphi_t(X_t)$ 移由给出, 其中函数 $(\varphi, \hat{\varphi})$ 被称为薛定谔潜在函数, 并满足以下一组耦合偏微分方程

$$\begin{aligned} \partial_t \varphi_t &= -\nabla \varphi_t^\top r_t - \frac{\sigma_t^2}{2} \Delta \varphi_t + f_t \varphi_t, \quad \varphi_0 \hat{\varphi}_0 = \mu, \\ \partial_t \hat{\varphi}_t &= -\nabla \cdot (\hat{\varphi}_t r_t) + \frac{\sigma_t^2}{2} \Delta \hat{\varphi}_t - f_t \hat{\varphi}_t, \quad \varphi_1 \hat{\varphi}_1 = \nu. \end{aligned} \quad (5)$$

因此, 学习 $(\nabla \log \varphi, \nabla \log \hat{\varphi})$ 足以解决 (广义) SB 问题。

FBSDE 表示 与其直接求解耦合偏微分方程组方程 (5), 我们可以通过伊藤公式 (Liu et al., 2022b) 沿高概率路径获得局部解, 通过前向-后向随机微分方程 (FBSDE) 表示。为了方便起见, 让我们定义沿前向轨迹 $Y_t := \log \varphi_t, \hat{Y}_t :=$

$\log \hat{\varphi}_t$, 并计算它们的梯度 $Z_t := \sigma_t \nabla \log \varphi_t, \hat{Z}_t := \sigma_t \nabla \log \hat{\varphi}_t$ 。然后, 相应的正倒向随机微分方程 (FBSDE) 的一种典型形式由下式给出

$$dX_t = (r_t(X_t) + \sigma_t Z_t) dt + \sigma_t dW_t, \quad X_0 \sim \mu, \quad (6)$$

$$dY_t = \left(\frac{1}{2} \|Z_t\|^2 + f_t \right) dt + Z_t^\top dW_t, \quad (7)$$

$$\begin{aligned} d\hat{Y}_t &= \left(\frac{1}{2} \|\hat{Z}_t\|^2 + \nabla \cdot (\sigma \hat{Z}_t - r_t) \right. \\ &\quad \left. + \hat{Z}_t^\top Z_t - f_t \right) dt + \hat{Z}_t^\top dW_t, \end{aligned} \quad (8)$$

等价地, 我们可以获得一组关于时间反演动力学的类似三元组的正倒向随机微分方程 (FBSDEs) $s := 1-t$, 在这种情况下, $d\tilde{X}_s$ 受控于 Z (参见 Liu 等人, 22b)。请注意, 在基础漂移 $b_t(x)$ 相对于状态变量 x 呈线性关系的假设下, 这些表达式成立。

gIPF 目标函数 方程 (6) 和 (8) 中的耦合正倒向随机微分方程 (FBSDEs) 提供了方程 (5) 中偏微分方程 (PDEs) 的一个随机表示。因此, 无需在整个函数空间求解偏微分方程, 只需在由 FBSDEs 刻画的高概率区域附近局部求解即可。特别地, 注意到端点似然可以表述如下

$$\log \mu(X_0) = \mathbb{E}_{p_{1|0}^Z} [\log \nu(X_1)] - \mathbb{E}_{p_{1|0}^Z} \left[\int_0^1 dY_t + d\hat{Y}_t \right], \quad (9)$$

因此, 为了最大化似然, 我们应该最小化终端项。因此, 展开方程 (7) 和 (8), 我们得到更新反向策略 Z_t 的 gIPF 目标函数:

$$\begin{aligned} \mathcal{L}_{\text{IPF}}^Z(\hat{Z}) &:= \mathbb{E}_\mu \mathbb{E}_{p_{1|0}^Z} \left[\int_0^1 dY_t + d\hat{Y}_t \right] \\ &= \mathbb{E}_{p^Z} \left[\int_0^1 \frac{1}{2} \|\hat{Z}_t\|^2 + \hat{Z}_t^\top Z_t + \nabla \cdot (\sigma \hat{Z}_t - r_t) dt \right]. \end{aligned} \quad (10)$$

同样, 更新 Z_t 的 gIPF 损失函数为:

$$\begin{aligned} \mathcal{L}_{\text{IPF}}^{\hat{Z}}(Z) &:= \mathbb{E}_\nu \mathbb{E}_{p_{1|1}^{\hat{Z}}} \left[\int_0^1 dY_t + d\hat{Y}_t \right] \\ &= \mathbb{E}_{p^{\hat{Z}}} \left[\int_0^1 \frac{1}{2} \|Z_t\|^2 + Z_t^\top \hat{Z}_t + \nabla \cdot (\sigma Z_t - r_t) dt \right]. \end{aligned} \quad (11)$$

交替最小化方程 (10) 和 (11) 可以视为相应路径之间的连续 KL 投影, 收敛到 Schrödinger 桥 (Vargas, 2021; De Bortoli 等人, 2021)。

时间差分目标函数 然而, 在广义设置下, 注意到等式 (10) 和 (11) 中的附加状态成本项在朴素的 IPF 聚合中相互抵消。因此, 仅靠 IPF 损失无法显式地强制与状态和分布相关的成本的一致性。为了将运行成本显式地注入学习过程中, 潜在动力学被离散化, 并通过时间差损失

(刘等, 2022b), 相邻增量之间的偏差受到惩罚, 迫使学习到的潜在函数在局部上与增强成本的动力学一致。实践中, gIPF 算法交替最小化 IPF 目标和 TD 目标, 形成一个迭代方案, 既强制边缘约束又与运行成本保持一致。

3. 方法论

本节介绍广义薛定谔

桥在图上的应用 (GSBoG), 一种在给定有向图上的最优传输框架 $\mathcal{G} = (\mathcal{X}, \mathcal{E})$ 。其中, $\mathcal{X} := \{1, \dots, n\}$ 表示有限节点集, $\mathcal{E} \subset \mathcal{X} \times \mathcal{X}$ 表示有向边集, $(x, y) \in \mathcal{E}$ 表示从节点 x 到节点 y 的有向转移。给定源分布 μ 和目标分布 ν 在节点集 $\mathcal{X}$ 上, 我们的目标是在 $\mathcal{G}$ 上构造一个受控随机过程, 将 μ 运输到 ν 并最小化广义成本泛函。所提出的框架可以视为广义迭代比例拟合 (gIPF)(刘等, 2022a) 的离散、图结构对应物, 其将一般的状态和分布相关成本泛函扩展到图上的连续时间马尔可夫链。

我们强调, GSBoG 解决的问题与先前的数据驱动工作, 如 DDSBM(金等, 2024), 有着根本的不同, 后者专注于图结构的生成建模。相比之下, 我们的设置假设固定图拓扑并研究在给定节点空间上运输概率质量的问题 $\mathcal{X}$ 。据我们所知, 这一视角尚未在机器学习文献中系统地进行探讨。

3.1. 图上的 GSB 问题

连续时间 马尔可夫链 (CTMCs) 令 $(X_t)_{t \in [0, 1]}$ 是一个取值于有限状态空间 $\mathcal{X}$ 的随机过程。该过程由其转移速率矩阵 $r = (r_t(y, x))_{x, y \in \mathcal{X}, t \in [0, 1]}$ 刻画, 定义为

$$r_t(y, x) := \lim_{h \rightarrow 0} \frac{\Pr(X_{t+h} = y \mid X_t = x) - \mathbf{1}_{\{y=x\}}}{h},$$

其中 $\mathbf{1}_{\{\cdot\}}$ 表示指示函数。直观地, $r_t(y, x)$ 指定了从状态 x 到状态 y 在时间 t 的瞬时转移速率。

我们考虑由有向图 $\mathcal{G} = (\mathcal{X}, \mathcal{E})$ 约束的 CTMCs。相应地, 转移速率 r_t 需要满足

$$\begin{cases} r_t(y, x) \geq 0, & \text{whenever } (x, y) \in \mathcal{X} \times \mathcal{X}, \\ r_t(y, x) = 0, & \text{whenever } (x, y) \notin \mathcal{E}, \\ r_t(x, x) = -\sum_{y \neq x} r_t(y, x). \end{cases} \quad (12)$$

对于所有 $x, y \in \mathcal{X}$ 和 $t \in [0, 1]$ 。第二个条件通过禁止沿不存在的边进行转移来强制执行图结构, 而最后一个条件确保质量守恒, 即 $\sum_y r_t(y, x) = 0$ 对所有 x 成立。

图上的广义薛定谔桥 我们在 $\mathcal{G}$ 上考虑方程 (3) 的离散模拟。令 u_t 表示满足相同结构约束的受控转移速率。我们用 p^r 和 p^u 分别表示基础速率 r_t 和受控速率 u_t 诱导的路径测度。接下来, 我们将根据受控转移速率 u_t 明确表达 CTMC 路径测度之间的 KL 发散, 从而将 GSB 问题表述为

$$\min_u \mathbb{E}_{p^u} \mathbb{E}_t \left[\underbrace{\sum_{y \neq X_t} \left(u_t \log \frac{u_t}{r_t} - u_t + r_t \right) (y, X_t)}_{=: \text{KL}(p^u || p^r)} \right] \quad (13)$$

$$\begin{aligned} & + \mathbb{E}_{p^u} \mathbb{E}_t [f_t(X_t, p_t)] \quad \text{s.t.} \quad X_1 \sim \nu, \\ & \partial_t p_t^u(x) = \sum_{y \in \mathcal{X}} u_t(x, y) p_t^u(y), \quad X_0 \sim \mu, \end{aligned} \quad (14)$$

其中方程 (14) 是连续性方程 (CE), 描述了受控路径 p_t^u 在 $\mathcal{G}$ 上的时间演化, 作为方程 (4) 中 FPE 的离散模拟。请注意, 方程 (3) 中的连续状态动力学约束方程 (4) 被离散 CE 方程 (14) 所取代。同时, Guo 等人 (2026) 考虑了相同的公式, 并为 CTMCs 提供了类似的薛定谔桥分析。

3.2. 图上的 GSB 分析

本文刻画了与连续性方程相关的最优控制动力学, 并证明它们可以用一个时间依赖的潜在函数表示 V_t 。这种刻画自然地导致了 Hopf-Cole 变换的一个离散类比, 这构成了我们后续发展的基础。

定理 3.1 (对偶表示)。在温和的正则性假设下, 存在一个时间依赖函数 $V : [0, 1] \times \mathcal{X} \rightarrow \mathbb{R}$ 使得最优概率路径 p_t^* 满足

$$\begin{aligned} \partial_t p_t^*(x) &= \sum_{y \in \mathcal{X}} r_t(x, y) \exp(-V_t(x) + V_t(y)) p_t^*(y), \\ \partial_t V_t(x) &= \sum_{y \in \mathcal{X}} r_t(y, x) \exp(-V_t(y) + V_t(x)) - f_t(x, p_t^*), \end{aligned} \quad (15)$$

边界条件为最优控制转移 $= \mu$ 及 $p_1^* = \nu$ 率为 u_t^* , 由

$$u_t^*(y, x) = r_t(y, x) \exp(-V_t(y) + V_t(x)). \quad (16)$$

注释 3.2。 该结果通过考虑 GSB 目标方程 (13) 的拉格朗日对偶得到，其中连续性方程 (14) 通过一个状态时间依赖的伴随变量 V_t 来强制执行。优化所得的对偶泛函给出了耦合系统方程 (15)。或者， V_t 可以解释为与图上随机最优控制问题相关联的离散 Hamilton-Jacobi-Bellman(HJB) 方程的解。进一步讨论请参见附录 B。

注释 3.3。 重要的是，强调方程 (16) 意味着对于任意 $(x, y) \in \mathcal{X} \times \mathcal{X}$ ，如果 $r_t(y, x) = 0$ ，那么 $u_t^*(y, x) = 0$ 。因此，满足 u_t^* 相同的图作为约束 r_t 。

命题 3.4。 我们定义 Hopf-Cole 变换 (Hopf-Cole Transformation) 于 $\mathcal{G}$ ，类似于动态对应的定义方式

$$\varphi(t, x) := e^{-V(t, x)}, \quad \hat{\varphi}(t, x) := \frac{p_t^*(x)}{\varphi(t, x)}. \quad (17)$$

那么 Schrödinger 势 $(\varphi_t, \hat{\varphi}_t)$ 满足

$$\begin{aligned} \partial_t \varphi_t(x) &= - \sum_y r_t(y, x) \varphi_t(y) + f_t(x, p_t^*) \varphi_t(x), \\ \partial_t \hat{\varphi}_t(x) &= \sum_y r_t(x, y) \hat{\varphi}_t(y) - f_t(x, p_t^*) \hat{\varphi}_t(x), \end{aligned} \quad (18)$$

含 $p_t^* = \varphi_t \hat{\varphi}_t$, $\forall t \in [0, 1]$ 特别是 $\nu = \varphi_1 \hat{\varphi}_1$ 。

此外，最优控制转移率可以表示为

$$u_t^*(y, x) = r_t(y, x) \frac{\varphi_t(y)}{\varphi_t(x)}. \quad (19)$$

因此，恢复最优动力学归结为估计局部比率 $\varphi_t(y)/\varphi_t(x)$ 沿边缘 $(x, y) \in \mathcal{E}$ 。

3.3. 图的广义 IPF

生成器与 Dynkin 公式 直接求解高维 Hopf-Cole 方程组在大图上的计算成本过高。因此，我们采取基于粒子的观点，即 gIPF 和时间差分 (TD) 目标的离散模拟。与连续设置不同，在连续设置中这些目标通过基于 Itô 微分分的表示来实现，而离散动力学需要不同的动态表达式。为此，我们考虑 Dynkin 公式 (Dynkin, 1965; Norris, 1997)

$$\mathbb{E}_{p_{t|s}^u} [h_t(X_t)] = h_s(X_s) + \mathbb{E}_{p_{\cdot|s}^u} \left[\int_s^t \mathcal{A}_\tau^u h(X_\tau) d\tau \right], \quad (20)$$

对于任何测试函数 $h: [0, 1] \times \mathcal{X} \rightarrow \mathbb{R}$ ，其中 $\mathcal{A}_t^u$ 表示与控制转移率 u_t 相关的无穷小生成元，定义如下

$$\mathcal{A}_t^u h(x) := \lim_{\Delta t \rightarrow 0} \frac{\mathbb{E}[h_{t+\Delta t}(X_{t+\Delta t}) | X_t = x] - h_t(x)}{\Delta t}.$$

上述生成器的定义使我们在下面的定理中引入了一对在 $\mathcal{G}$ 上受控的 CTMC，其生成器支持在边 $(x, y) \in \mathcal{E}$ 上。

命题 3.5。 设 $(X_t)_{t \in [0, 1]}$ 是在 $\mathcal{X}$ 上的 CTMC 过程，其演化遵循控制转移率 $u_t(y, x) = e^{Z_t(y, x)} r_t(y, x)$ 。为了方便起见，我们定义

$$\begin{aligned} Y_t(X_t) &:= \log \varphi(t, X_t), \quad Z_t(y, X_t) = Y_t(y) - Y_t(X_t), \\ \hat{Y}_t(X_t) &:= \log \hat{\varphi}(t, X_t), \quad \hat{Z}_t(y, X_t) = \hat{Y}_t(y) - \hat{Y}_t(X_t). \end{aligned}$$

那么，这对 $(Y_t, \hat{Y}_t)$ 通过生成器可以表示为 $\mathcal{A}_t^u$

$$\mathcal{A}_t^u Y(x) = \sum_y r_t e^{Z_t} (Z_t - 1) + f_t(x, p_t^u), \quad (21)$$

$$\mathcal{A}_t^u \hat{Y}(x) = \sum_y r_t(x, y) e^{\hat{Z}_t} + \hat{Z}_t r_t e^{Z_t} - f_t(x, p_t^u), \quad (22)$$

当函数参数 (y, x) 时，我们省略了它们。此外，给定反向转移率 $\hat{u}_s(x, y) =$ ，其中 $s := 1 - t$

$$\mathcal{A}_s^{\hat{u}} \hat{Y}(x) = \sum_y r_s(x, y) e^{\hat{Z}_s} (\hat{Z}_s - 1) + f_s(x, p_s^u), \quad (23)$$

$$\mathcal{A}_s^{\hat{u}} Y(x) = \sum_y r_s e^{Z_s} + Z_s r_s(x, y) e^{\hat{Z}_s} - f_s(x, p_s^u). \quad (24)$$

gIPF 目标函数 强调方程 (21) 和 (22) 是扩散 SB-FBSDE 在方程 (7) 和 (8) 中的离散模拟。它们通过描述沿轨迹的 $(\log \varphi_t(X_t), \log \hat{\varphi}_t(X_t))$ 演化来刻画 GSB 解，从而避免了所有节点和时间索引上的全局时间扩展求解。我们利用这些方程推导出一个基于数据驱动的最大化对数似然目标，通过沿 CTMC 轨迹展开 SB 势能：

$$\begin{aligned} -\log \mu(X_0) &= \mathbb{E}_t \mathbb{E}_{p_{\cdot|0}^Z} [\mathcal{A}_t^u \log p_t^Z(X_t)] + C \\ &= \mathbb{E}_t \mathbb{E}_{p_{\cdot|0}^Z} [\mathcal{A}_t^u Y_t(X_t) + \mathcal{A}_t^u \hat{Y}_t(X_t)] + C, \end{aligned} \quad (25)$$

其中 $C = -\mathbb{E}_{p_{1|0}^Z} [\log \nu(X_1)]$ $p^Z := p^u$ (resp. $p^{\hat{Z}} :=$ 和 $p^{\hat{u}}$)。这给出了离散 gIPF 损失。

命题 3.6。 假设受控过程 $(X_t)_{t \in [0, 1]}$ 上 $\mathcal{X}$ ，采样于 u_t 在公式 19 中展开生成器项，得到正向 IPF 目标函数。

$$\mathcal{L}_{\text{IPF}}^Z(\hat{Z}) := \mathbb{E}_{p^Z} \left[\int_0^1 \sum_{y \in \mathcal{X}} \left(r_t(X_t, y) e^{\hat{Z}_t(y, X_t)} + r_t(y, X_t) e^{Z_t(y, X_t)} (-1 + Z_t(y, X_t) + \hat{Z}_t(y, X_t)) \right) dt \right]. \quad (26)$$

同样对于时间反转动力学，相应的反向 IPF 目标也具有类似的展开

$$\mathcal{L}_{\text{IPF}}^{\hat{Z}}(Z) = \mathbb{E}_{p_{\hat{Z}}} \left[\int_0^1 \sum_{y \in \mathcal{X}} \left(r_s(y, \tilde{X}_t) e^{Z_s(y, \tilde{X}_s)} + r_s(\tilde{X}_t, y) e^{\hat{Z}_s(y, \tilde{X}_s)} (-1 + Z_s(y, \tilde{X}_t) + \hat{Z}_s(y, \tilde{X}_s)) \right) ds \right]. \quad (27)$$

时差 (TD) 目标 一个关键的观察是在 IPF 目标函数中，状态成本项带有相反的符号：在 $\mathcal{A}^u Y(t, x)$ 其贡献是 $+f_t$ ，而在 $\mathcal{A}^u Y(t, x)$ 它表现为 $-f_t$ ，因此，在求和中抵消 $\mathcal{A}_t^u Y(x) + \mathcal{A}_t^u Y_t(x)$ 。因此，仅最小化 IPF 在存在非零运行成本的情况下是不够的，因为它可以强制执行端点边缘分布，但不显式地强制与状态/分布相关的运行成本的一致性。

为了恢复正确的成本感知动力学，我们通过时间差分 (TD) 损失额外强制局部生成器一致性，惩罚违反方程 (21) 和 (22) 沿轨迹的行为。在短时间段内， (Y_t, Y_t) 的增量必须在期望上与受控生成器的作用一致，这正是运行成本出现的地方。更具体地说，对于正向 CTMC $(X_t)_{t \in [0, 1]}$ 通过 $u_t(y, x) = e^{Z_t(y, x)} r_t(y, x)$ ，应用 Dynkin 公式方程 (20)，对 $[t, t + \Delta t]$ ， Y_t 强制局部生成器一致性，因为一步增量 $\delta Y_t := Y_{t+\Delta t}(X_{t+\Delta t}) - Y_t(X_t)$ 应匹配生成器预测的增量 $\mathcal{A}_t^u Y(X_t) \Delta t$ 。同样，对于时间反转过程 $\tilde{X}_s$ ，我们在 $[s - \Delta s, s]$ 上应用方程 (20)，对 Y_t 并强制相同的相容条件。因此，我们得到以下正反向 TD 损失对作为此条件的平方残差：

$$\mathcal{L}_{\text{TD}}^Z(\hat{Y}) = \mathbb{E}_{y \sim p_{t+\Delta t}^Z(\cdot|x)} \left[\|\delta \hat{Y}_t - \mathcal{A}_t^u \hat{Y} \Delta t\|^2 \right] \quad (28)$$

$$\mathcal{L}_{\text{TD}}^{\hat{Z}}(Y) = \mathbb{E}_{y \sim p_{s-\Delta s}^{\hat{Z}}(\cdot|x)} \left[\|\delta Y_s - \mathcal{A}_s^u Y \Delta s\|^2 \right], \quad (29)$$

其中，对于正向过程， $Y_0 = \log p_0 - Y_0$ ，以及对于反向过程， $Y_T = \log p_1 - Y_1$ 。实际上，我们的训练交替进行最小化 IPF 目标——以匹配端点边缘分布——和最小化 TD 目标——以强制局部生成器与运行成本的一致性——产生一种同时满足边界约束和成本一致路径空间最优性的方案。

训练目标和参数化 算法 1 总结了我们的训练方案。实际上，我们参数化对数势 (θ, ϕ) ： $Y_t^\theta(X_t) \approx$

Algorithm 1 Generalized Schrödinger Bridge on Graphs

- 1: **Input:** graph $\mathcal{G}$, reference rates r_t , endpoint marginals p_0, p_1 , cost $f_t(x, p_t)$
- 2: Initialize parameters θ, ϕ ; choose time grid $\{t_k\}_{k=0}^K$, $\Delta t = 1/K$
- 3: **for** iterations $m = 1, 2, \dots$ **do**
- 4: **Forward rollouts:** sample $X_0^{(i)} \sim p_0$; simulate CTMC under u_t^θ in Eq. (30)
- 5: **Update ϕ :** minimize $\mathcal{L}_{\text{IPF}}^Z(\hat{Z}^\phi) + \lambda_{\text{TD}} \mathcal{L}_{\text{TD}}^Z(\hat{Y}^\phi)$ from Eqs. (26) and (28) using forward-sampled trajectories
- 6: **Backward rollouts:** sample $\tilde{X}_0^{(i)} \sim p_1$; simulate time-reversed dynamics under $\hat{u}_t^\phi$ in Eq. (31)
- 7: **Update θ :** minimize $\mathcal{L}_{\text{IPF}}^{\hat{Z}}(Z^\theta) + \lambda_{\text{TD}} \mathcal{L}_{\text{TD}}^{\hat{Z}}(Y^\theta)$ from Eqs. (27) and (29) using backward trajectories
- 8: **end for**

$\log \varphi_t(X_t)$, $Y_t(X_t) \approx \log \hat{\varphi}_t(X_t)$ ，由此控制转移率给出

$$u_t^\theta(y, x) = r_t(y, x) \exp(Z_t^\theta(y, x)), \quad (30)$$

$$\hat{u}_t^\phi(y, x) = r_t(y, x) \exp(\hat{Z}_t^\phi(y, x)) \quad (31)$$

。最后，我们在实践中使用的损失如下

$$\mathcal{L} = \mathcal{L}_{\text{IPF}}^Z(\hat{Z}^\phi) + \mathcal{L}_{\text{IPF}}^{\hat{Z}}(Z^\theta) + \lambda_{\text{TD}} \left(\mathcal{L}_{\text{TD}}^Z(\hat{Y}^\phi) + \mathcal{L}_{\text{TD}}^{\hat{Z}}(Y^\theta) \right),$$

其中， $\lambda_{\text{TD}} \geq 0$ 用于相对于 IPF 项加权 TD 正则化。

4. 实验

4.1. 供应链

我们研究了模型在图上导航复杂和稀疏动态的能力。我们将一个现实世界的供需网络 (Kovács, 2015) 建模为一个有向加权图 $\mathcal{G}$ ，其中包含 $N = 9559$ 个节点，每个节点代表一个设施/位置 (例如，供应商、仓库、港口、零售商)，每条有向边表示一个可接受的运输路径，如图 2 所示。稀疏 CTMC 参考生成器通过路径成本 $f_t(x, p_t)$ 和节点供需的奇拓拓扑结构和名义路由偏差。给定边界边缘分布 (p_0, p_1) (e.g., (代表供应和需求))，我们解决了一个有限时间范围内的运输问题，并在目标函数中加入了一个运行成本 $f_t(x, p_t)$ 来惩罚拥堵，从而避免高占用率的节点，同时仍然匹配需求 (p_0, p_1) 。更多细节请参见附录 C.2。

表 2. 我们的 GSBog 与 $\mathcal{W}1$ 流、GrSB 和 Attr. 流在总变差 (TV)、100 个最拥挤节点的平均拥堵度、峰值节点占用率以及超过容量的最大边流量方面的供应链比较。(越低越好)

Method	TV ↓	Mean congestion ↓	Peak occupancy ↓	Max flow/cap ↓
GrSB	—	—	—	—
Attr. Flow	0.27	84.09	1033.72	1.59
$\mathcal{W}1_{\text{flow}}$	0.03	178.19	1807.66	1.41
GSBoG	0.03	21.13	271.49	0.64

本文将 GSBog 与动态图薛定谔桥 (GrSB; (Chow 等, 2022)) 以及两种基于图的动态流基线进行了比较: (i) 一种趋向目标偏置转换的吸引力流, 以及 (ii) 一种动态 $\mathcal{W}1$ 最小费用流基线在图上 ($\mathcal{W}1$ 流动). 由于流动方法产生的是通量而非逐步路由策略, 我们采用马尔可夫嵌入将其转换为随机转移核, 并模拟轨迹。下文报告的所有度量均基于展开策略, 所有方法使用相同的预测范围和展开预算。我们报告: (i) 终端总变差, (ii) 100 个最繁忙节点的平均拥堵程度, (iii) 节点占用峰值, 以及 (iv) 诱导边流量与容量的最大比率。

表 2 显示, 终端匹配并不是主要的难点; 挑战在于在不引发不可行的、高度拥挤的中间行为的情况下实现它。由于内存耗尽问题, GrSB 未能在此图上完成任务, 即使减少了时间范围和滚动次数, 也突显了这一规模下的可扩展性局限性。在基于流的基线方法中, 诱导的滚动表现出显著更高的拥堵和较大的实际容量超载。特别是, $\mathcal{W}1$ 流达到了近乎完美的终端匹配, 但大多数质量通过一小部分瓶颈边进行路由, 导致严重的中间拥挤。相比之下, GSBog 保持了接近最优的终端匹配, 同时大幅抑制了中间拥挤。重要的是, GSBog 是我们研究中唯一一种其诱导轨迹在此规模下仍保持在边容量内的方法。尽管容量满足没有被强制作为硬约束, 但它通过拥堵惩罚隐式地实现了这一点, 这激励了将质量分散到较少拥挤路线上的策略, 从而避免了拥堵。

重要的是, 图 3b 强调了纳入非平凡的应用特定状态成本的强烈影响。特别是, 包括拥堵成本 ($f \neq 0$) 进一步抑制了拥挤, 因为它引导了更均匀分布质量的策略, 而不是集中在少数瓶颈节点上, 同时保持了端点匹配。值得注意的是, 拥堵感知策略相对于 $f = 0$ 变体几乎将峰值占用率减半。这缓解了拥堵, 使拥堵感知解决方案更具鲁棒性,




图 3. 左: GSBog 策略与 Dijkstra 相比的相对路径长度开销分布。右: GSBog 无 ($f = 0$) 和有 ($f \neq 0$) 状态成本: 峰值边负载, 按总粒子遍历数计算的最常用的 100 条边的平均负载以及使用的边总数。

表 3. 分配任务度量

n	Optimal Cost	Assigned Cost	Mass on opt. selection	Row Entropy	Accuracy
6	160	160	97.3%	0.07	100%
8	205	205	94.2%	0.13	100%
10	239	239	87.6%	0.16	100%
20	538	546	85.0%	0.17	90%

中断。最后, 图 3a 显示, GSBog 保持了接近最短路径的行为, 在所有源的平均跳数开销上仅略有增加。

4.2. 分配任务

我们在一个平衡的任务分配上测试 GSBog n 供应节点 $A_1, \dots, A_n$ 和 n 需求节点 $B_1, \dots, B_n$, 与 $n \in \{6, 8, 10, 20\}$. 真实的计划 π^* 是最小成本分配下 $C \in \mathbb{R}^{n \times n}$ 匹配边缘分布 p_0, p_1 为了利用状态惩罚编码成对成本, 我们构建了一个带有中间节点的有向图 E_{xy} 对于每个 (x, y) 以及边 $A_x \rightarrow E_{xy} \rightarrow B_y$, 分配 $f(E_{xy}) = C_{xy}$ 和 $f(A_x) = f(B_y) = 0$ 在该图上运行 GSBog 算法可得到受控的动力学轨迹, 这些轨迹定义了所学的分配 $\hat{\pi}$ 从边上的预期通量出发 $A_x \rightarrow E_{xy}$ 并与之比较 π^* 更多细节请参见附录 C.1。

图 4 展示了二部分分配图, 以及软计划的热图 $\hat{\pi}$, 连同相应的硬分配 (红色框), 叠加了通过求解静态 OT 获得的 Oracle 解决方案 (橙色标记) π^* 。定量来看, 对于 $n \leq 10$, 硬分配与 OT 解决方案完全匹配 (100% 重叠), 并且在最优边上保持较高的质量百分比。对于 $n = 20$, 学习策略仍然将 85% 的质量放在正确的边上, 而硬重叠降至 90%, 表明仅有一对分配被误置。重要的是, 注意到表 3 表明这种误置仅略微增加了成本, 这意味着所选的替代方案接近最优, 且 GSBog




图 4. 左侧：工人-任务二部图上的分配概率。边的粗细和颜色编码了在学习策略下将每个工人 W_i 分配给任务 T_j 的概率。右侧：热图显示了工人（行）和任务（列）之间的学习耦合（GSBoG）。橙色标记表示最优分配。

表 4. Chignolin 折叠比较，我们的 GSBoG 与未控制 CTMC、Committer-Guided 偏差、GrSB 和 Attr. Flow 在折叠速率和能量障碍方面的比较

Method	Energy barrier	
	$(k_B T_{\text{sim}})$	Fold rate (%)
Uncontr. CTMC	6.94	0.55
Committer-guided bias	6.59	71.69
GrSB	5.43	25.11
Attr. Flow	7.32	62.08
GSBoG ($f = 0$)	1.80	99.70
GSBoG ($f \neq 0$)	1.39	99.36

仍接近地面真相最优解。

4.3. 离散化分子动力学

最后，我们在离散构型空间中评估 GSBoG 对稀有事件分子动力学的引导效果，该空间由马尔可夫状态模型（MSM; Husic & Pande (2018)）表示。在此任务中，目标是双重的：在固定的时间范围内增加观察到动力学抑制转换的概率，同时避免状态空间中热力学上不合理区域。作为测试系统，我们考虑水中的 chignolin 折叠，这是一种 10 个残基的迷你蛋白质，能够在展开（未折叠）和 β 发夹（折叠）结构，这是一种用于蛋白质折叠动力学的标准模型系统（Lindorff-Larsen 等，2011）。

这里的 MSM 是一个定义在有限集上的马尔可夫链 $|\mathcal{X}| = 500$ 通过聚类平衡的分子动力学轨迹获得构型微状态。从这些轨迹中，得到微状态的分布 π_i ，每个微观状态对应自由能 $F_i/k_B T_{\text{sim}} = -\log \pi_i$ 在仿真温度下 T_{sim} 以及参考利率生成器被估计出来。尽管 MSMs 是分析分子动力学的标准工具，但在元稳定盆地之间识别主要过渡路径仍然困难重重由于




图 5. 上：不同方法生成轨迹的平均 chignolin C_{α} 均方根偏差，阴影区域表示标准差。下：GSBoG 生成的轨迹样本（彩色）叠加在透明的天然 chignolin 结构上。GSBoG 随时间正确折叠了该结构。

由于转换极为罕见：一个未受控的 CTMC 从展开状态分布初始化 μ 达到折叠状态分布 ν 在时间范围内 $T = 200$ 概率低于 1%（表 4）。我们将此问题表述为 MSM 图上的 GSB 问题，控制从 μ 到 ν 的传输，在参考动力学下。此外，我们引入了一个运行成本 f 使用每个微观状态的自由能，这使控制动力学偏向 MSM 中的热力学稳定区域，从而鼓励物理上合理的折叠路径。额外的实验细节见附录 C.3。

在表 4 中，所有引导基线都增加了折叠概率，但简单地到达终点与通过低势垒中间体到达之间存在差距。Committer-guided 偏差和 Attraction Flow 分别将折叠率提高到 60% 至 70%，但仍需穿越高势垒，表明成功的轨迹通常会经过高能量区域。GrSB 优于未控制的先验（折叠率为 25%，并将势垒降低到 $5.43 k_B T_{\text{sim}}$ ），但仍未能可靠地诱导在此时间范围内的折叠。相比之下，GSBoG 实现了高折叠概率和显著降低的势垒：具有 $f = 0$ 的变体达到了 99.7% 的折叠率，并且势垒为 $1.80 k_B T_{\text{sim}}$ ，而结合自由能运行成本进一步将势垒降低到 $1.39 k_B T_{\text{sim}}$ ，同时保持高折叠率。此外，通过测量沿轨迹的几何偏差（RMSD，公式 (97)）从天然折叠结构出发，使用聚类代表性结构（图 5），我们确认 GSBoG 轨迹遵循平滑的折叠路径并在折叠状态 RMSD 阈值内终止。

总体而言，这表明 GSBog 对于稀有事件引导是有效的：端点约束确保折叠，而自由能成本 f 进一步使轨迹偏向热力学上合理的路径。

4.4. GSBog 的可扩展性

GSBog 的一个主要优势在于它避免了全局时间扩展图求解器。GSBog 学习的是轨迹级 CTMC 策略，其控制速率仅在局部图邻域上进行评估，而不是优化所有节点边缘或时间索引通量变量。由于 $u_t^*(y, x) = r_t(y, x)\phi_t(y)/\phi_t(x)$ 对于 $(x, y) \in E$ ，并且 $u_t^*(y, x) = 0$ 否则，位于节点 x 的每个粒子只需考虑 $y \in \mathcal{N}(x)$ 。因此，每步计算由局部分支因子 Δ 决定，而非总节点数 n 。

这种局部性在稀疏图上特别有益。GSBog 存储并更新稀疏边集和采样轨迹上的量，而全局动态 OT 和图 SB 求解器则操作于所有节点、边和时间层。例如，在供应链图中， $n = 9559$ 而最大度仅为 6。因此，每个 GSBog 粒子每步最多与六个邻居交互，解释了其实现可扩展性的原因以及当全局求解器变得内存受限或无法完成时仍保持可行的能力。

运行时间和内存。图 6 报告了动态最优传输（Dynamic OT）和 GSBog 在四个扩展轴上的内存使用（顶部）和实际时间（底部）。这些轴分别是节点数量、边密度、时间步数和展开预算。标记为“N/A”的条目表示在该设置下，动态最优传输未完成。在两种方法都能运行的所有情况下，GSBog 明显更节省资源。例如，在 5×10^4 个节点的情况下，GSBog 仅使用 1.4 GB 内存，并在大约 1 小时内完成，而动态最优传输则需要 22.0 GB 内存并耗时约 4.6 小时。当改变边密度、时间跨度和展开预算时，也出现了类似的减少：GSBog 始终使用较少的内存和时间，而动态最优传输要么成本大幅增加，要么变得不可行。

扩展行为。四个面板突出了基于局部轨迹的学习与全局时间扩展优化之间的差异。随着图从 5×10^4 个节点增长到 10^6 个节点，动态最优传输在最小实例后变得不可行，而 GSBog 仍可执行至 10^6 个节点，且内存逐渐增加。增加边的数量显示出相同趋势：动态最优传输在最密集的 5×10^6 边设置下失败，而 GSBog 仍然能够完成。沿着时间维度，动态最优传输随时间步数增加而扩展性差，并在 400 步时失败，而 GSBog 保持低内存和适度运行时间。最后，展开预算消融显示，GSBog 可以通过牺牲计算来获得更精确的粒子




图 6. 动态最优传输和 GSBog 在不同节点数量、边密度、时间步数和展开预算下的可扩展性。GSBog 始终比动态最优传输使用更少的内存和运行时间，并在动态最优传输变得不可行（标记为 N/A）的设置下保持可行。

近似。将预算从 10^3 增加到 4×10^3 会增加运行时间，但内存仍低于 1GB。总体而言，这些结果支持主要的计算图景：全局动态最优传输和图 SB 方法在整个时间扩展图上操作，而 GSBog 则在采样的局部轨迹上操作。这使得 GSBog 特别适合于大型稀疏图，其中每个节点只有少量可行邻居。

4.5. 局限性

GSBog 目前假设底层图拓扑结构固定且完全已知，因为参考 CTMC 生成器和学习到的控制速率都是基于允许的边集定义的。虽然通过时间依赖的生成器和支持可能扩展到时变图，但处理部分观测、不确定或动态演化的连通性仍然是一个不平凡的方向，因为展开可行性评估和损失评估需要访问有效的转换。因此，我们将 GSBog 扩展到不确定、部分观测和时演变化的图结构作为重要的未来工作。

5. 讨论

在这项工作中，我们提出了一个针对最优随机策略的图本源薛定谔桥框架，该策略在运输质量的同时考虑网络结构和诸如拥堵和容量等操作约束。这项工作朝着数据驱动、原理性的大规模网络运输方法迈进了一步，为将现代基于学习的动力学与复杂网络系统中的最优传输启发的控制相结合开辟了新途径。

致谢

感谢刘关鸿在理论分析方面的帮助，以及他对手稿的见解深刻的讨论和评论。本研究部分得到了 DARPA AIQ 计划的支持，通过 DARPA CMO 合同号 HR00112520010 提供资金。感谢 AIQ 计划经理 Pat Shafto 博士进行的技术讨论。

影响声明

本文介绍的工作旨在推动机器学习领域的发展。我们的工作有许多潜在的社会后果，但没有哪一点是我们认为在这里特别需要强调的。

参考文献

- Arqué, F., Uribe, C. A., and Ocampo-Martinez, C. Approximate wasserstein attraction flows for dynamic mass transport over networks. *Automatica*, 143:110432, 2022.
- Bertsekas, D. P. *Network Optimization: Continuous and Discrete Models*. Athena Scientific, Belmont, MA, 1998. ISBN 1-886529-02-7.
- Burger, M., Humpert, I., and Pietschmann, J.-F. Dynamic optimal transport on networks. *ESAIM: Control, Optimization and Calculus of Variations*, 29:54, 2023.
- Chen, T., Liu, G.-H., and Theodorou, E. A. Likelihood training of schrödinger bridge using forward-backward sdes theory. *arXiv preprint arXiv:2110.11291*, 2021.
- Chen, Y., Georgiou, T. T., and Pavon, M. Optimal steering of inertial particles diffusing anisotropically with losses, 2014. URL <https://arxiv.org/abs/1410.1605>.
- Chen, Y., Georgiou, T. T., and Pavon, M. On the relation between optimal transport and Schrödinger bridges: A stochastic control viewpoint. *Journal of Optimization Theory and Applications*, 169:671–691, 2016. doi: 10.1007/s10957-015-0803-z.
- Chiu, Y.-C., Bottom, J., Mahut, M., Paz, A., Balakrishna, R., Waller, S. T., and Hicks, J. Dynamic traffic assignment: A primer. Transportation Research Circular E-C153, Transportation Research Board, 2011a. URL <https://onlinepubs.trb.org/onlinepubs/circulars/ec153.pdf>.
- Chiu, Y.-C., Bottom, J., Mahut, M., Paz, A., Balakrishna, R., Waller, S. T., and Hicks, J. Dynamic traffic assignment: A primer. Transportation Research Circular E-C153, Transportation Research Board, 2011b.
- Chizat, L., Peyré, G., Schmitzer, B., and Vialard, F.-X. Unbalanced optimal transport: Dynamic and kantorovich formulations. *Journal of Functional Analysis*, 274(11): 3090–3123, 2018.
- Chow, S.-N., Li, W., Mou, C., and Zhou, H. Dynamical schrödinger bridge problems on graphs. *Journal of Dynamics and Differential Equations*, 34(3):2511–2530, 2022.
- Cuturi, M. Sinkhorn distances: Lightspeed computation of optimal transport. *Advances in neural information processing systems*, 26, 2013.
- De Bortoli, V., Thornton, J., Heng, J., and Doucet, A. Diffusion Schrödinger bridge with applications to score-based generative modeling. In Beygelzimer, A., Dauphin, Y., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems*, 2021. URL <https://openreview.net/forum?id=9BnCwiXB0ty>.
- De Bortoli, V., Liu, G.-H., Chen, T., Theodorou, E. A., and Nie, W. Augmented bridge matching. *arXiv preprint arXiv:2311.06978*, 2023.
- Doob, J. L. Conditional brownian motion and the boundary limits of harmonic functions. *Bulletin de la Société mathématique de France*, 85:431–458, 1957.
- Dynkin, E. B. *Markov Processes*. Springer, Berlin, 1965.
- Easley, D. and Kleinberg, J. *Networks, Crowds, and Markets: Reasoning about a Highly Connected World*. Cambridge University Press, 2010.
- Essid, M. and Solomon, J. Quadratically regularized optimal transport on graphs. *SIAM Journal on Scientific Computing*, 40(4):A1961–A1986, 2018.
- Facca, E., Todeschi, G., Natale, A., and Benzi, M. Efficient preconditioners for solving dynamical optimal transport via interior point methods. *SIAM Journal on Scientific Computing*, 46(3):A1397–A1422, 2024.
- Ghosal, P., Nutz, M., and Bernton, E. Stability of entropic optimal transport and schrödinger bridges. *Journal of Functional Analysis*, 283(9):109622, 2022.
- Guo, W., Zhu, Y., Du, X., Nam, J., Chen, Y., Gómez-Bombarelli, R., Liu, G.-H., Tao, M., and Choi, J. Discrete adjoint schrödinger bridge sampler. *International Conference on Machine Learning*, 2026.
- Gushchin, N., Kholkin, S., Burnaev, E., and Korotin, A. Light and optimal schrödinger bridge matching. In *Forty-first International Conference on Machine Learning*, 2024.

- Husic, B. E. and Pande, V. S. Markov state models: From an art to a science. *Journal of the American Chemical Society*, 140(7):2386–2396, 2018. doi: 10.1021/jacs.7b12191.
- Iida, S. Molecular dynamics trajectories of protein folding, March 2022. URL <https://doi.org/10.5281/zenodo.6349893>.
- Kim, J. H., Kim, S., Moon, S., Kim, H., Woo, J., and Kim, W. Y. Discrete diffusion schrödinger bridge matching for graph transformation. *arXiv preprint arXiv:2410.01500*, 2024.
- Koch, R. and Nasrabadi, E. Flows over time in time-varying networks: Optimality conditions and strong duality. *arXiv preprint arXiv:1401.6053*, 2014.
- Kovács, P. Benchmark data for the minimum-cost flow problem (lemon). <https://lemon.cs.elte.hu/trac/lemon/wiki/MinCostFlowData>, 2015. Accessed 2026-01-27.
- Ksenofontov, G. and Korotin, A. Categorical schrödinger bridge matching. *arXiv preprint arXiv:2502.01416*, 2025.
- Léger, F. A gradient descent perspective on sinkhorn. *Applied Mathematics & Optimization*, 84(2):1843–1855, 2021.
- Lindorff-Larsen, K., Piana, S., Dror, R. O., and Shaw, D. E. How fast-folding proteins fold. *Science*, 334(6055):517–520, 2011.
- Liu, G.-H., Chen, T., So, O., and Theodorou, E. Deep generalized schrödinger bridge. *Advances in Neural Information Processing Systems*, 35:9374–9388, 2022a.
- Liu, G.-H., Chen, T., So, O., and Theodorou, E. A. Deep generalized schrödinger bridge, 2022b. URL <https://arxiv.org/abs/2209.09893>.
- Liu, G.-H., Vahdat, A., Huang, D.-A., Theodorou, E. A., Nie, W., and Anandkumar, A. I²SB: Image-to-Image Schrödinger bridge. In *International Conference on Machine Learning (ICML)*, 2023.
- Liu, G.-H., Lipman, Y., Nickel, M., Karrer, B., Theodorou, E. A., and Chen, R. T. Generalized Schrödinger bridge matching. In *International Conference on Learning Representations*, 2024.
- Lou, A., Meng, C., and Ermon, S. Discrete diffusion modeling by estimating the ratios of the data distribution. In Salakhutdinov, R., Kolter, Z., Heller, K., Weller, A., Oliver, N., Scarlett, J., and Berkenkamp, F. (eds.), *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, pp. 32819–32848. PMLR, 21–27 Jul 2024. URL <https://proceedings.mlr.press/v235/lou24a.html>.
- Newman, M. E. J. The structure and function of complex networks. *SIAM Review*, 2003. Also available as arXiv:cond-mat/0303516.
- Norris, J. R. *Markov Chains*. Cambridge University Press, Cambridge, 1997.
- Nutz, M. Introduction to entropic optimal transport. *Lecture notes, Columbia University*, 2021.
- O’Connor, K., McGoff, K., and Nobel, A. B. Optimal transport for stationary markov chains via policy iteration. *Journal of Machine Learning Research*, 23(45):1–52, 2022. URL <https://www.jmlr.org/papers/v23/21-0519.html>.
- Pagani, G. A. and Aiello, M. The power grid as a complex network: A survey. *Physica A: Statistical Mechanics and its Applications*, 392(11):2688–2700, 2013. doi: 10.1016/j.physa.2013.01.023.
- Pavon, M., Trigila, G., and Tabak, E. G. The data-driven schrödinger bridge. *Communications on Pure and Applied Mathematics*, 74(7):1545–1573, 2021.
- Peluchetti, S. Diffusion bridge mixture transports, schrödinger bridge problems and generative modeling. *Journal of Machine Learning Research*, 24(374):1–51, 2023.
- Peyré, G. and Cuturi, M. Computational optimal transport: With applications to data science. *Center for Research in Economics and Statistics Working Papers*, 2017.
- Peyré, G. and Cuturi, M. Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607, 2019.
- Rapakoulas, G., Pedram, A. R., Liu, F., Zhu, L., and Tsiontras, P. Go with the flow: Fast diffusion for gaussian mixture models. *arXiv preprint arXiv:2412.09059*, 2024.
- Saravanos, A., Kuperman, H., Oshin, A., Abdul, A. T., Pacelli, V., and Theodorou, E. Deep distributed optimization for large-scale quadratic programming. In *International Conference on Learning Representations*, volume 2025, pp. 93580–93619, 2025.
- Särkkä, S. and Solin, A. *Applied stochastic differential equations*, volume 10. Cambridge University Press, 2019.
- Scherer, M. K., Trendelkamp-Schroer, B., Paul, F., Pérez-Hernández, G., Hoffmann, M., Plattner, N., Wehmeyer, C., Prinz, J.-H., and Noé, F. Pyemma 2: A software package for estimation, validation, and analysis of markov

- models. *Journal of chemical theory and computation*, 11 (11):5525–5542, 2015.
- Schrödinger, E. *Über die Umkehrung der Naturgesetze*. Sitzungsberichte der Preussischen Akademie der Wissenschaften, Physikalisch-mathematische Klasse, 1931.
- Shi, Y., De Bortoli, V., Campbell, A., and Doucet, A. Diffusion schrödinger bridge matching. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=qy07OHsJT5>.
- Somnath, V. R., Pariset, M., Hsieh, Y.-P., Martinez, M. R., Krause, A., and Bunne, C. Aligned diffusion schrödinger bridges. In *Uncertainty in Artificial Intelligence*, pp. 1985–1995. PMLR, 2023.
- Theodoropoulos, P., Komianos, N., Pacelli, V., Liu, G.-H., and Theodorou, E. A. Feedback schrödinger bridge matching. *arXiv preprint arXiv:2410.14055*, 2024.
- Theodoropoulos, P., Saravanos, A., Theodorou, E., and Liu, G.-H. Momentum multi-marginal schrödinger bridge matching. *Advances in Neural Information Processing Systems*, 38:85885–85922, 2026.
- Tong, A., Malkin, N., Fatras, K., Atanackovic, L., Zhang, Y., Huguët, G., Wolf, G., and Bengio, Y. Simulation-free schrödinger bridges via score and flow matching. *arXiv preprint arXiv:2307.03672*, 2023.
- Vanden-Eijnden, E. et al. Transition-path theory and path-finding algorithms for the study of rare events. *Annual review of physical chemistry*, 61:391–420, 2010.
- Vargas, F. Machine-learning approaches for the empirical schrödinger bridge problem. Technical Report UCAM-CL-TR-958, University of Cambridge, Computer Laboratory, 2021.
- Vargas, F., Thodoroff, P., Lamacraft, A., and Lawrence, N. Solving schrödinger bridges via maximum likelihood. *Entropy*, 23(9):1134, 2021.
- Villani, C. et al. *Optimal transport: Old and new*, volume 338. Springer, 2009.
- Yang, M. Topological schrödinger bridge matching. *arXiv preprint arXiv:2504.04799*, 2025.
- Zhang, D., Dong, J., and Nagurney, A. A supply chain network economy: Modeling and qualitative analysis. In Nagurney, A. (ed.), *Innovations in Financial and Economic Networks*, pp. 197–213. Edward Elgar Publishing, 2003.

A. 证明

A.1. 定理 3.1 的证明

定理 A.1. 在温和的正则性假设下, 存在一个时间依赖函数 $V : [0, 1] \times \mathcal{X} \rightarrow \mathbb{R}$, 使得最优概率路径 p_t^* 满足

$$\begin{aligned}\partial_t p_t^*(x) &= \sum_{y \in \mathcal{X}} r_t(x, y) \exp(-V_t(x) + V_t(y)) p_t^*(y), \\ \partial_t V_t(x) &= \sum_{y \in \mathcal{X}} r_t(y, x) \exp(-V_t(y) + V_t(x)) - f_t(x, p_t^*),\end{aligned}\tag{32}$$

边界条件为 $p_0^* = \mu$ 和 $p_1^* = \nu$ 。特别地, 最优控制转移率为 u_t^* , 由下式给出

$$u_t^*(y, x) = r_t(y, x) \exp(-V_t(y) + V_t(x)).\tag{33}$$

证明。设 $\mathcal{X}$ 为有限 (或可数) 状态空间。我们约定, 从 x 跳转到 y (so x 的速率是 $u_t(y, x)$ (即列为索引)。因此, 受控生成元满足

$$u_t(x, x) = - \sum_{y \in \mathcal{X}, y \neq x} u_t(y, x), \quad r_t(x, x) = - \sum_{y \in \mathcal{X}, y \neq x} r_t(y, x),$$

其中 r_t 是参考生成元。我们考虑在 $\mathcal{X}$ 上的广义薛定谔桥问题, 这里已经替换了 KL

$$\inf_u \int_0^1 \sum_{x \in \mathcal{X}} \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} \left[-u_t(y, x) + r_t(y, x) + u_t(y, x) \log\left(\frac{u_t(y, x)}{r_t(y, x)}\right) + f_t(x, p_t) \right] p_t(x) dt\tag{34}$$

$$\text{s.t. } \partial_t p_t(x) = \sum_{y \in \mathcal{X}} u_t(x, y) p_t(y)\tag{35}$$

$$p_0 = \mu, \quad p_1 = \nu.\tag{36}$$

引入拉格朗日乘子 $V : [0, 1] \times \mathcal{X} \rightarrow \mathbb{R}$, 将等式 (34) 和 (35) 中的约束优化问题重新表述如下:

$$\begin{aligned}\mathcal{L}(u, p, V) &= \int_0^1 \sum_{x \in \mathcal{X}} \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} \left[-u_t(y, x) + r_t(y, x) + u_t(y, x) \log\left(\frac{u_t(y, x)}{r_t(y, x)}\right) + f_t(x, p_t) \right] p_t(x) dt \\ &\quad - \int_0^1 \sum_{x \in \mathcal{X}} V_t(x) \left[\partial_t p_t(x) - \sum_{y \in \mathcal{X}} u_t(x, y) p_t(y) \right] dt.\end{aligned}\tag{37}$$

其中 L 是我们问题在公式 (34) 和 (35) 中的拉格朗日量。

随后, 我们对 $\sum$ 执行分部积分,

follows: $\sum_{x \in \mathcal{X}} V_t(x) \partial_t p_t(x)$ 并重写 $\sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{X}} V_t(x) u_t(x, y) p_t(y)$ 如下

$$\begin{aligned}& \bullet \sum_{x \in \mathcal{X}} V_t(x) \partial_t p_t(x) \\ & \int_0^1 \sum_{x \in \mathcal{X}} V_t(x) \partial_t p_t(x) dt = - \int_0^1 \sum_{x \in \mathcal{X}} (\partial_t V_t(x)) p_t(x) dt + \sum_{x \in \mathcal{X}} [V_1(x) p_1(x) - V_0(x) p_0(x)] \\ & = - \int_0^1 \sum_{x \in \mathcal{X}} (\partial_t V_t(x)) p_t(x) dt + \sum_{x \in \mathcal{X}} [V_1(x) \nu(x) - V_0(x) \mu(x)].\end{aligned}\tag{38}$$

$$\begin{aligned}
 & \bullet \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{X}} V_t(x) u_t(x, y) p_t(y) \\
 & \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{X}} V_t(x) u_t(x, y) p_t(y) = \sum_{y \in \mathcal{X}} \sum_{x \in \mathcal{X}} V_t(x) u_t(x, y) p_t(y) \\
 & = \sum_{x \in \mathcal{X}} \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} V_t(y) u_t(y, x) p_t(x) + \sum_{x \in \mathcal{X}} V_t(x) u_t(x, x) p_t(x) \\
 & = \sum_{x \in \mathcal{X}} \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} (V_t(y) - V_t(x)) u_t(y, x) p_t(x) \tag{39}
 \end{aligned}$$

where we used $u_t(x, x) = -\sum_{y \neq x} u_t(y, x)$.

将公式 (38) 和 (39) 代入公式 (37) 得到

$$\begin{aligned}
 \mathcal{L}(u, p, V) &= \int_0^1 \sum_{x \in \mathcal{X}} \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} \left[-u_t(y, x) + r_t(y, x) + u_t(y, x) \log\left(\frac{u_t(y, x)}{r_t(y, x)}\right) + f_t(x, p_t) \right] p_t(x) dt \\
 &+ \int_0^1 \sum_{x \in \mathcal{X}} (\partial_t V_t(x)) p_t(x) dt - \sum_{x \in \mathcal{X}} [V_1(x) \nu(x) - V_0(x) \mu(x)] \\
 &+ \int_0^1 \sum_{x \in \mathcal{X}} \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} (V_t(y) - V_t(x)) u_t(y, x) p_t(x) dt. \tag{40}
 \end{aligned}$$

我们调用强对偶性

$$\sup_V \inf_{(u, p)} \mathcal{L}(u, p, V)$$

并将重点放在公式 (40) 中依赖于 $u_t(y, x)$ 的项上:

$$-u + u \log\left(\frac{u}{r}\right) + (V_t(y) - V_t(x))u.$$

关于 u_t 求导得到

$$\begin{aligned}
 0 &= \frac{\partial}{\partial u} \left[-u + u \log\left(\frac{u}{r}\right) + (V_t(y) - V_t(x))u \right] = \log\left(\frac{u}{r}\right) + V_t(y) - V_t(x), \\
 \implies u_t^*(y, x) &= r_t(y, x) \exp(-V_t(y) + V_t(x)). \tag{41}
 \end{aligned}$$

因此, GSB 问题在 $\mathcal{X}$ 上的最优控制由下式给出

$$u_t^*(y, x) = r_t(y, x) \exp(-V_t(y) + V_t(x)). \tag{42}$$

最后, 将 u^* 代入拉格朗日函数, 并将方程 (41) 代入方程 (40), 得到

$$\begin{aligned}
 \mathcal{L}(u^*, p, V) &= \int_0^1 \sum_{x \in \mathcal{X}} \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} \left[(1 - e^{-V_t(y) + V_t(x)}) r_t(y, x) + f_t(x, p_t) \right] p_t(x) dt \\
 &+ \int_0^1 \sum_{x \in \mathcal{X}} (\partial_t V_t(x)) p_t(x) dt - \sum_{x \in \mathcal{X}} [V_1(x) \nu(x) - V_0(x) \mu(x)] \\
 &= \int_0^1 \sum_{x \in \mathcal{X}} \left[\partial_t V_t(x) + \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} (1 - e^{-V_t(y) + V_t(x)}) r_t(y, x) + f_t(x, p_t) \right] p_t(x) dt \\
 &+ \sum_{x \in \mathcal{X}} [V_0(x) \mu(x) - V_1(x) \nu(x)]. \tag{43}
 \end{aligned}$$

为了使 $\inf_p \mathcal{L}(u^*, p, V)$ 非平凡（有限），方程 (43) 中的括号项必须消失（在 (t, x) ），i.e. 上逐点消失）

$$0 = \partial_t V_t(x) + \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} r_t(y, x) - \sum_{\substack{y \in \mathcal{X} \\ y \neq x}} e^{V_t(x) - V_t(y)} r_t(y, x) + f_t(x, p_t). \quad (44)$$

Using $r_t(x, x) = -\sum_{y \neq x} r_t(y, x)$, equivalently

$$\partial_t V_t(x) = \sum_{y \in \mathcal{X}} e^{V_t(x) - V_t(y)} r_t(y, x) - f_t(x, p_t). \quad (45)$$

同时，在最优速率下的连续性方程为

$$\partial_t p_t^*(x) = \sum_{y \in \mathcal{X}} u_t^*(x, y) p_t(y) = \sum_{y \in \mathcal{X}} e^{-V_t(x) + V_t(y)} r_t(x, y) p_t^*(y), \quad p_0 = \mu, \quad p_1 = \nu. \quad (46)$$

由此耦合的“连续性-对偶”系统由方程 (45) 和 (46) 组成。 $\square$

A.2. 命题 3.4 的证明

命题 A.2. 我们定义 Hopf-Cole 变换（Hopf-Cole Transformation）于 $\mathcal{G}$ ，类似于动态对应的定义方式

$$\varphi(t, x) := e^{-V(t, x)}, \quad \hat{\varphi}(t, x) := \frac{p_t^*(x)}{\varphi(t, x)}. \quad (47)$$

那么 Schrödinger 势 $(\varphi_t, \hat{\varphi}_t)$ 满足

$$\begin{aligned} \partial_t \varphi_t(x) &= -\sum_y r_t(y, x) \varphi_t(y) + f_t(x, p_t^*) \varphi_t(x), \\ \partial_t \hat{\varphi}_t(x) &= \sum_y r_t(x, y) \hat{\varphi}_t(y) - f_t(x, p_t^*) \hat{\varphi}_t(x), \end{aligned} \quad (48)$$

含 $p_t^* = \varphi_t \hat{\varphi}_t$ 对于所有 $t \in [0, 1]$ 特别是 $\nu = \varphi_1 \hat{\varphi}_1$.

证明。定义 Hopf-Cole 变换于 Schrödinger 潜在函数上

$$\varphi_t(x) = e^{-V_t(x)}, \quad \hat{\varphi}_t(x) = \frac{p_t(x)}{\varphi_t(x)} \iff p_t(x) = \varphi_t(x) \hat{\varphi}_t(x).$$

方程对于 φ . 根据链式法则， $\partial_t \varphi_t(x) = -\varphi_t(x) \partial_t V_t(x)$ 我们可以得到与 Schrödinger 潜在函数相关的微分方程如下

$$\begin{aligned} \partial_t \varphi(t, x) &= -\partial_t V_t(x) e^{-V(t, x)} \\ &= \left[\sum_{y \neq x} r_t(y, x) (1 - e^{V_t(x) - V_t(y)}) + f_t(x_t, p_t) \right] \varphi(t, x) \\ &= -\sum_{y \neq x} r_t(y, x) (e^{V_t(x) - V_t(y)} - 1) \varphi(t, x) + f_t(x_t, p_t) \varphi(t, x) \\ &= -\sum_{y \neq x} r_t(y, x) \left(\frac{\varphi(t, y)}{\varphi(t, x)} - 1 \right) \varphi(t, x) + f_t(x_t, p_t) \varphi(t, x) \\ &= -\left(\sum_{y \neq x} r_t(y, x) \varphi(t, y) - \sum_{y \neq x} r_t(y, x) \varphi(t, x) \right) + f_t(x_t, p_t) \varphi(t, x) \\ &= -\sum_y \varphi(t, y) r_t(y, x) + f_t(x_t, p_t) \varphi(t, x) \end{aligned} \quad (49)$$

其中我们使用标准惯例 $r_t(x, x) = -\sum_{y \neq x} r_t(y, x)$ 收进总和中

$y \in \mathcal{X}$.

方程对于 $\hat{\varphi}$. 同样地, 对于 $\hat{\varphi}(t, x)$, 在求导后 $\hat{\varphi}_t(x) = p_t(x)/\varphi_t(x)$:

$$\partial_t \hat{\varphi}_t(x) = \frac{\partial_t p_t(x)}{\varphi_t(x)} - \frac{p_t(x)}{\varphi_t(x)^2} \partial_t \varphi_t(x).$$

利用前进方程 (46) 对于 p_t 和方程 (49) 对于 φ_t , 并回顾 $p_t = \varphi_t \hat{\varphi}_t$, 直接抵消给出

$$\begin{aligned} \partial_t \hat{\varphi}_t(x) &= \partial_t \left(\frac{p_t^*(x)}{\varphi_t(x)} \right) = \frac{1}{\varphi_t(x)} \sum_y u_t^*(x, y) p_t(y) - \frac{p_t^*(x)}{\varphi_t^2(x)} \partial_t \varphi_t(x) \\ &= \frac{1}{\varphi_t(x)} \left[\sum_{y \neq x} u_t(x, y) p_t(y) + u_t(x, x) p_t(x) \right] - \frac{p_t(x)}{\varphi_t^2(x)} \left[- \sum_y \varphi_t(y) r_t(y, x) + f_t(x_t, p_t) \varphi_t(x) \right] \\ &= \frac{1}{\varphi_t(x)} \left[\sum_{y \neq x} u_t(x, y) p_t(y) - \sum_{y \neq x} u_t(y, x) p_t(x) \right] + \frac{p_t(x)}{\varphi_t^2(x)} \sum_y \varphi_t(y) r_t(y, x) - f_t(x_t, p_t) \varphi_t(x) \frac{p_t(x)}{\varphi_t^2(x)} \\ &= \frac{1}{\varphi_t(x)} \left[\sum_{y \neq x} r_t(x, y) \frac{\varphi_t(x)}{\varphi_t(y)} p_t(y) - \sum_{y \neq x} r_t(y, x) \frac{\varphi_t(y)}{\varphi_t(x)} p_t(x) \right] + \frac{p_t(x)}{\varphi_t^2(x)} \sum_y \varphi_t(y) r_t(y, x) - f_t(x_t, p_t) \hat{\varphi}_t(x) \\ &= \sum_{y \neq x} r_t(x, y) \hat{\varphi}_t(y) + u_t(x, x) \frac{p_t(x)}{\varphi_t(x)} - f_t(x_t, p_t) \hat{\varphi}_t(x) \\ &= \sum_y r_t(x, y) \hat{\varphi}_t(y) - f_t(x_t, p_t) \hat{\varphi}_t(x). \end{aligned} \tag{50}$$

方程 (49) 和 (50) 给出了所需的 Hopf-Cole 耦合微分方程系统, 该系统刻画了广义 Schrödinger 桥问题在方程 (34) 中的解。

备注 A.3. 因此, 在 Hopf-Cole 变换下, 最优控制可以重写为 $u_t(y, x) = r_t(y, x) \frac{\varphi(y)}{\varphi(x)}$, 而反向控制由以下给出

$$\begin{aligned} \hat{u}_s(y, x) &:= u_{1-t}(x, y) \frac{p_{1-t}(y)}{p_{1-t}(x)} \\ &= r_{1-t}(x, y) \frac{\varphi_{1-t}(x)}{\varphi_{1-t}(y)} \frac{(\varphi \hat{\varphi})_{1-t}(y)}{(\varphi \hat{\varphi})_{1-t}(x)} \\ &= r_{1-t}(x, y) \frac{\hat{\varphi}_{1-t}(y)}{\hat{\varphi}_{1-t}(x)} \end{aligned} \tag{51}$$

具体来说, 我们有 $\hat{u}_s(y, x) = r_{1-t}(x, y) \frac{\varphi_{1-t}(y)}{\hat{\varphi}_{1-t}(x)}$, 其中时间被反转为 $s := 1 - t$ 。

□

A.3. 命题 3.5 的证明

命题 A.4. 设 $(X_t)_{t \in [0, 1]}$ 是在 $\mathcal{X}$ 上的 CTMC 过程, 其演化遵循受控转移率 $u_t(y, x) =$ 。为了方便起见, 我们定义 $e^{Z_t(y, x)} r_t(y, x)$

$$\begin{aligned} Y_t(X_t) &:= \log \varphi(t, X_t), \quad Z_t(y, X_t) = Y_t(y) - Y_t(X_t), \\ \hat{Y}_t(X_t) &:= \log \hat{\varphi}(t, X_t), \quad \hat{Z}_t(y, X_t) = \hat{Y}_t(y) - \hat{Y}_t(X_t). \end{aligned}$$

然后, 对 (Y_t, Y_t) 的表示通过生成元 $\mathcal{A}_t^u$ 给出如下所示

$$\mathcal{A}_t^u Y(x) = \sum_y \left(r_t e^{Z_t} (Z_t - 1) \right) (y, x) + f_t(x, p_t^u) \tag{52}$$

$$\mathcal{A}_t^u \hat{Y}(x) = \sum_y r_t(x, y) e^{\hat{Z}_t(y, x)} + \left(\hat{Z}_t r_t e^{Z_t} \right) (y, x) - f_t(x, p_t^u) \tag{53}$$

Moreover, given the backward transition rate $\hat{u}_s(x, y) = e^{\hat{Z}_s(y, x)} r_s(x, y)$, with $s = 1 - t$

$$\begin{aligned} \mathcal{A}_s^{\hat{u}} \hat{Y}(x) &= \sum_y r_s(x, y) e^{\hat{Z}_s(y, x)} (\hat{Z}_s(y, x) - 1) + f_s(x, p_s^u) \\ \mathcal{A}_s^{\hat{u}} Y(x) &= \sum_y r_s(x, y) e^{Z_s(y, x)} + Z_s(y, x) r_s(x, y) e^{\hat{Z}_s(x, y)} - f_s(x, p_s^u) \end{aligned} \quad (54)$$

证明。根据命题 3.4，对数潜在值定义为

$$Y_t(x) := \log \varphi_t(x), \quad \hat{Y}_t(x) := \log \hat{\varphi}_t(x),$$

使得 $\log p_t(x) = Y_t(x) + \hat{Y}_t(x)$ 。

引理 A.5. 受控连续时间马尔可夫链的（时间非齐次）生成元，作用于测试函数 $h(t, \cdot)$ ，是

$$\mathcal{A}_t^u h(x) = \partial_t h(t, x) + \sum_{y \in \mathcal{X}} (h(t, y) - h(t, x)) u_t(y, x).$$

证明。给定受控转移速率 u_t ，注意到 $X_{t+dt} \sim (I + u_t dt)(\cdot, X_t)$, i.e.

$$p_{t+dt|t}^u(y|x) = \begin{cases} u_t(y, x) dt & \text{when } y \neq x, \\ 1 - \sum_{z \neq x} u_t(z, x) dt & \text{when } y = x. \end{cases} \quad (55)$$

结合概率密度，我们得到随机函数 $h(t, \cdot)$ 的以下生成元，其基础随机过程由 $X_{t+dt} \sim (I + u_t dt)(\cdot, X_t)$ 支配：

$$\mathcal{A}_t^u h := \lim_{\Delta t \rightarrow 0+} \frac{\mathbb{E}_{y \sim p_{t+\Delta t|t}^u(\cdot|x)} [h(t + \Delta t, y)] - h(t, x)}{\Delta t} \quad (56)$$

$$= \frac{1}{dt} \sum_y h(t + dt, y) p_{t+dt|t}^u(y|x) - h(t, X_t) \quad (57)$$

$$= \sum_{y \neq X_t} h(t + dt, y) u_t(y, X_t) - \frac{1}{dt} \sum_{y \neq X_t} u_t(y, X_t) h(t + dt, X_t) + \frac{h(t + dt, X_t) - h(t, X_t)}{dt} \quad (58)$$

$$= \sum_{y \neq X_t} \left(h(t, y) + \frac{\partial h(t, y)}{\partial t} dt \right) u_t(y, x) - \frac{1}{dt} \sum_{y \neq X_t} \left(h(t, x) + \frac{\partial h(t, x)}{\partial t} dt \right) u_t(y, x) dt + \frac{\partial h}{\partial t}(t, X_t) \quad (59)$$

$$= \sum_{y \neq X_t} (h(t, y) - h(t, X_t)) u_t(y, x) + \frac{\partial h}{\partial t}(t, X_t) \quad (60)$$

$$= \sum_y (h(t, y) - h(t, X_t)) u_t(y, x) + \frac{\partial h}{\partial t}(t, X_t) \quad (61)$$

□

备注 A.6. 类似地，我们可以证明反向过程的生成元遵循：

$$A_s^u h = \sum_{y \neq x} [h(s - \Delta s, y) - h(s - \Delta s, x)] u_s(y|x) - \frac{\partial h}{\partial s}(s, x) \quad (62)$$

对于测试函数 h ，其中回忆反向时间坐标是 $s = 1 - t$ 。

根据定理 3.1，正向控制跳跃速率是

$$u_t(y, x) = r_t(y, x) e^{Y_t(y) - Y_t(x)}.$$

的生成元 $\hat{Y}$. 从方程 (48) 和恒等式 $\partial_t \hat{Y}_t(x) = \hat{\varphi}_t(x)^{-1} \partial_t \hat{\varphi}_t(x)$,

$$\begin{aligned} \partial_t \hat{Y}_t(x) &= \frac{1}{\hat{\varphi}_t(x)} \left(\sum_{y \in \mathcal{X}} r_t(x, y) \hat{\varphi}_t(y) - f_t(x, p_t) \hat{\varphi}_t(x) \right) \\ &= \sum_{y \in \mathcal{X}} r_t(x, y) \exp(\hat{Y}_t(y) - \hat{Y}_t(x)) - f_t(x, p_t). \end{aligned} \quad (63)$$

因此,

$$\mathcal{A}_t^u \hat{Y}(x) = \sum_{y \in \mathcal{X}} r_t(x, y) e^{\hat{Y}_t(y) - \hat{Y}_t(x)} - f_t(x, p_t) + \sum_{y \in \mathcal{X}} (\hat{Y}_t(y) - \hat{Y}_t(x)) r_t(y, x) e^{Y_t(y) - Y_t(x)}. \quad (64)$$

的生成元 Y . 类似地, 从方程 (50) 和 $\partial_t Y_t(x) = \varphi_t(x)^{-1} \partial_t \varphi_t(x)$,

$$\begin{aligned} \partial_t Y_t(x) &= \frac{1}{\varphi_t(x)} \left(- \sum_{y \in \mathcal{X}} r_t(y, x) \varphi_t(y) + f_t(x, p_t) \varphi_t(x) \right) \\ &= - \sum_{y \in \mathcal{X}} r_t(y, x) \exp(Y_t(y) - Y_t(x)) + f_t(x, p_t). \end{aligned} \quad (65)$$

将方程 (65) 代入生成元公式得到紧凑形式

$$\begin{aligned} \mathcal{A}_t^u Y(x) &= \partial_t Y_t(x) + \sum_{y \in \mathcal{X}} (Y_t(y) - Y_t(x)) r_t(y, x) e^{Y_t(y) - Y_t(x)} \\ &= f_t(x, p_t) + \sum_{y \in \mathcal{X}} r_t(y, x) e^{Y_t(y) - Y_t(x)} (Y_t(y) - Y_t(x) - 1). \end{aligned} \quad (66)$$

方程 (64) 和方程 (66) 是所声称的生成元恒等式。

时间反演生成元 类似地, 从附录 A.6 中的时间反演动力学生成元表达式和方程 (62), 以及方程 (51) 中逆向过程的最优控制, 我们得到:

$$\mathcal{A}_s^u Y(x) = \sum_y (Y(s, y) - Y(s, x)) r_s(x, y) e^{(\hat{Y}_s(y) - \hat{Y}_s(x))} - \frac{\partial Y}{\partial s}(s, x) \quad (67)$$

其中

$$\frac{\partial Y}{\partial s}(s, x) = \frac{1}{\varphi_s(x)} \left(- \sum_y r_s(y, x) \varphi_s(y) + f_s(x, p_t) \varphi_s(x) \right) \quad (68)$$

类似地, 对于 Y_t , 我们得到:

$$\mathcal{A}_s^u \hat{Y} = \sum \left(\hat{Y}(s, y) - \hat{Y}(s, x) \right) r_s(x, y) e^{(\hat{Y}_s^\varphi(y) - \hat{Y}_s^\varphi(x))} - \frac{\partial \hat{Y}}{\partial s}(s, x) \quad (69)$$

其中

$$\frac{\partial \hat{Y}}{\partial s}(s, x) = \frac{1}{\hat{\varphi}_s(x)} \left(\sum_y r_s(x, y) \hat{\varphi}_s(y) - f_s(x, p_t) \hat{\varphi}_s(x) \right) \quad (70)$$

□

A.4. 命题 3.6 的证明

命题 A.7. 假设受控过程 $(X_t)_{t \in [0, 1]}$ 上 $\mathcal{X}$ ，采样于 u_t 在公式 19 中展开生成器项，得到正向 IPF 目标函数。

$$\mathcal{L}_{\text{IPF}}^Z(\hat{Z}) := \mathbb{E}_{p^Z} \left[\int_0^1 \sum_{y \in \mathcal{X}} \left(r_t(X_t, y) e^{\hat{Z}_t(y, X_t)} + r_t(y, X_t) e^{Z_t(y, X_t)} (-1 + Z_t(y, X_t) + \hat{Z}_t(y, X_t)) \right) dt \right]. \quad (71)$$

同样对于时间反转动力学，相应的反向 IPF 目标也具有类似的展开

$$\mathcal{L}_{\text{IPF}}^{\hat{Z}}(Z) = \mathbb{E}_{p^{\hat{Z}}} \left[\int_0^1 \sum_{y \in \mathcal{X}} \left(r_t(y, \tilde{X}_t) e^{Z_t(y, \tilde{X}_t)} + r_t(\tilde{X}_t, y) e^{\hat{Z}_t(y, \tilde{X}_t)} (-1 + Z_t(y, \tilde{X}_t) + \hat{Z}_t(y, \tilde{X}_t)) \right) dt \right]. \quad (72)$$

证明。根据引理 A.5，对于控制函数 $h_t(x) := \log p_t(x) = Y_t(x) + \hat{Y}_t(x)$ ，从 $X_0 = x_0$ 开始的受控过程的 Dynkin 公式为

$$\mathbb{E}[g_1(X_1) \mid X_0 = x_0] = g_0(x_0) + \mathbb{E} \left[\int_0^1 (\mathcal{A}^u g_t)(X_t) dt \mid X_0 = x_0 \right].$$

重新排列并乘以 -1 得到

$$-\log p_0(x_0) = -\mathbb{E}[\log p_1(X_1) \mid X_0 = x_0] + \mathbb{E} \left[\int_0^1 (\mathcal{A}^u \log p_t)(X_t) dt \mid X_0 = x_0 \right]. \quad (73)$$

在 IPF 风格的训练目标中，我们将真实的对数潜在值 $(Y, \hat{Y})$ 替换为其参数化的替代 (Y, Y) ，从而得到一个上界（在最优处紧致）的形式

$$-\log p_0(x_0) \lesssim \mathbb{E} \left[\int_0^1 (\mathcal{A}^u Y_t + \mathcal{A}^u \hat{Y})(X_t) dt \mid X_0 = x_0 \right] := \mathcal{L}_{\text{IPF}}^Z(\hat{Z}) \quad (74)$$

为了使等式 (74) 明确，定义边增量

$$Z_t(y, x) := Y_t(y) - Y_t(x), \quad \hat{Z}_t(y, x) := \hat{Y}_t(y) - \hat{Y}_t(x),$$

and recall $u_t(y, x) = r_t(y, x) e^{Z_t(y, x)}$. Using Eq. (64)–Eq. (66), we obtain

$$\mathcal{L}_{\text{IPF}}^Z(\hat{Z}) = \mathbb{E} \left[\int_0^1 \sum_{y \in \mathcal{X}} \left(r_t(y, x) e^{Z_t(y, x)} (-1 + Z_t(y, x) + \hat{Z}_t(y, x)) + r_t(x, y) e^{\hat{Z}_t(y, x)} \right) dt \mid X_0 = x_0 \right]. \quad (75)$$

这是前向传递 IPF 目标。

后向传递目标。 将相同论点应用于从 $X_1 = x_1$ 开始的时间反转（后向）采样动力学，给定后向过程生成器和最优控制 $\hat{u}_s$ 的表达式，得出类似的界限

$$-\log p_1(x_1) \lesssim \mathbb{E} \left[\int_0^1 (\mathcal{A}_s^u Y + \mathcal{A}_s^u \hat{Y})(\tilde{X}_s) ds \mid X_1 = x_1 \right] := \mathcal{L}_{\text{IPF}}^{\hat{Z}}(Z),$$

因此，展开生成器得到

$$\mathcal{L}_{\text{IPF}}^{\hat{Z}}(Z) = \mathbb{E} \left[\int_0^1 \sum_{y \in \mathcal{X}} \left(r_s(x, y) e^{\hat{Z}_s(y, x)} (-1 + Z_s(y, x) + \hat{Z}_s(y, x)) + r_s(y, x) e^{Z_s(y, x)} \right) ds \mid X_1 = x_1 \right]. \quad (76)$$

最小化 $\mathcal{L}_{\text{IPF}}^Z(\hat{Z})$ 及 $\mathcal{L}_{\text{IPF}}^{\hat{Z}}(Z)$ 交替给出 IPF 训练方案。 $\square$

B. 与随机最优控制的联系

令 p^u 表示时间非齐次连续时间马尔可夫链 (CTMC) 在 $\mathcal{X}$ 上具有受控跳转率 $u_t(\cdot, \cdot)$ 的马尔可夫路径测度, 并令 p^r 是在参考速率 $r_t(\cdot, \cdot)$ 下对应的路径测度。我们考虑 KL 正则化的有限时间最优控制问题

$$\min_u \mathbb{E}_{X \sim p^u} \left[\int_0^1 f(t, X_t, p_t) dt + g(X_1) + D_{\text{KL}}(p^u \| p^r) \right]. \quad (77)$$

该目标函数是“软”控制的连续时间类比: 它权衡运行成本和终端成本与路径空间 KL 惩罚之间的关系, 以使控制动力学接近参考 CTMC。

动态规划与一步扩展。 定义值函数

$$V(t, x) := \inf_u \mathbb{E}^u \left[\int_t^1 f(\tau, X_\tau, p_\tau) d\tau + g(X_1) + D_{\text{KL}}(p_{[t,1]}^u \| p_{[t,1]}^r) \mid X_t = x \right].$$

应用动态规划原理在一个很短的时间间隔 $[t, t + \Delta t]$ 上得出

$$V(t, x) = \inf_{u_t(\cdot, x)} \left\{ \mathbb{E}^u[V(t + \Delta t, X_{t+\Delta t}) \mid X_t = x] + f(t, x, p_t) \Delta t + D_{\text{KL}}(p_{[t,t+\Delta t]}^u \| p_{[t,t+\Delta t]}^r) \right\}. \quad (78)$$

对于具有速率 $u_t(\cdot, x)$ 的 CTMC, 一步转移在 Δt 上满足

$$\mathbb{P}(X_{t+\Delta t} = x \mid X_t = x) = 1 - \sum_{y \neq x} u_t(y, x) \Delta t + o(\Delta t), \quad \mathbb{P}(X_{t+\Delta t} = y \mid X_t = x) = u_t(y, x) \Delta t + o(\Delta t),$$

从而有

$$\mathbb{E}^u[V(t + \Delta t, X_{t+\Delta t}) \mid X_t = x] = V(t + \Delta t, x) \left(1 - \sum_{y \neq x} u_t(y, x) \Delta t \right) + \sum_{y \neq x} u_t(y, x) \Delta t V(t + \Delta t, y) + o(\Delta t). \quad (79)$$

此外, 由 $u_t(\cdot, x)$ 和 $r_t(\cdot, x)$ 诱导的无穷小跳跃法则之间的 KL 发散在 $[t, t + \Delta t]$ 上展开 as (up to $o(\Delta t)$)

$$D_{\text{KL}}(p_{[t,t+\Delta t]}^u \| p_{[t,t+\Delta t]}^r) = \sum_{y \neq x} \left[u_t(y, x) \log \frac{u_t(y, x)}{r_t(y, x)} - u_t(y, x) + r_t(y, x) \right] \Delta t + o(\Delta t). \quad (80)$$

最优控制与 HJB 方程。 将方程 (79) - 方程 (80) 代入方程 (78), 消去 $V(t + \Delta t, x)$, 除以 Δt , 并令 $\Delta t \rightarrow 0$ 得到

$$0 = \inf_{u_t(\cdot, x)} \left\{ \partial_t V(t, x) + \sum_{y \neq x} u_t(y, x) (V(t, y) - V(t, x)) + f(t, x, p_t) + \sum_{y \neq x} \left[u_t(y, x) \log \frac{u_t(y, x)}{r_t(y, x)} - u_t(y, x) + r_t(y, x) \right] \right\}. \quad (81)$$

方程 (81) 中的最小化问题相对于 $y \neq x$ 解耦。对目标函数关于 $u_t(y, x)$ 求导得到最优速率

$$u_t^*(y, x) = r_t(y, x) \exp(V(t, x) - V(t, y)), \quad y \neq x. \quad (82)$$

将方程 (82) 代入方程 (中并简化得到 HJB 方程

$$-\partial_t V(t, x) = \sum_{y \neq x} r_t(y, x) \left(1 - \exp(V(t, x) - V(t, y)) \right) + f(t, x, p_t). \quad (83)$$

与广义薛定谔桥的关系。注意到公式 (83) 与我们在图上的 GSB 形式中定理 3.1 所获得的 HJB 相匹配。主要的概念差异在于终端条件：在薛定谔桥中，端点分布通过硬边缘约束强制执行，而在上述 SOC 形式中，终端目标则是通过终端成本软性施加的 $g(X_1)$ （并且，如果需要，可以通过选择

g 适当）。

C. 实验详情

在所有任务中，我们对每种方法进行相同的有限时间范围评估 T ，并使用相同的展开预算 B 粒子，采用相同的端点边缘分布 (p_0, p_1) 以及统一的度量评估代码。对于基线方法，我们分配相等的调优预算（网格搜索设置 $\leq M$ ），并报告在保真验证目标上表现最佳的配置。

C.1. 分配

平衡分配作为图传输。我们展示了 GSB_{oG} 在平衡分配问题上的有效性 n 供应节点 $\{A_i\}_{i=1}^n$ 和 n 需求节点 $\{B_j\}_{j=1}^n$ ，具有源和目标边缘分布 $p_0, p_1 \in \Delta^n$ （与 $n \in \{6, 8, 10, 20\}$ ），其中 $p_0(A_i) = (p_0)_i$ 和 $p_1(B_j) = (p_1)_j$ 。

给定成本 $C \in \mathbb{R}^{n \times n}$ ，预言机运输计划解决了静态线性规划问题

$$\pi^* \in \arg \min_{\pi \geq 0} \langle C, \pi \rangle \quad \text{s.t.} \quad \pi \mathbf{1} = p_0, \quad \pi^\top \mathbf{1} = p_1. \quad (84)$$

图编码成对成本（使用 x 作为当前节点和 y 作为下一个节点）。为了通过图上的状态成本来表示成对分配成本，我们为每一对 (i, j) 引入中间节点 E_{ij} 并构建一个有向图 $\mathcal{G} = (V, E)$ ，包含 $V = \{A_i\}_{i=1}^n \cup \{E_{ij}\}_{i,j=1}^n \cup \{B_j\}_{j=1}^n$ 。

Edges are

$$(x, y) \in E \Leftrightarrow (x = A_i, y = E_{ij}) \text{ or } (x = E_{ij}, y = B_j), \quad \forall i, j,$$

（并可选地引入自环 (x, x) 以提高数值稳定性）。我们定义运行状态成本 $f: V \rightarrow \mathbb{R}_+$ 为

$$f(x) := \begin{cases} C_{ij}, & x = E_{ij}, \\ 0, & x \in \{A_i\}_{i=1}^n \cup \{B_j\}_{j=1}^n. \end{cases} \quad (85)$$

端点分布于 V 上，支持供应/需求分区：

$$p_0(x) = \begin{cases} (p_0)_i, & x = A_i, \\ 0, & \text{otherwise}, \end{cases} \quad p_1(x) = \begin{cases} (p_1)_j, & x = B_j, \\ 0, & \text{otherwise}. \end{cases} \quad (86)$$

在整个过程中，我们使用 x 表示当前节点，并使用 y 表示沿转换过程中的下一个节点（例如，在离散时间 $X_{t+1} = y$ 给定 $X_t = x$ ，或在连续时间中跳跃的速率 $u_t(y, x) \quad x \rightarrow y$ ）。

从学习的动力学中解码软分配。设 $(X_t)_{t=0}^T$ 表示在学习动力学下的展开。我们从供应到中间边的预期边缘通量中解码软计划 $\hat{\pi} \in \mathbb{R}_+^{n \times n}$ ：

$$\hat{\pi}_{ij} \propto \mathbb{E} \left[\sum_{t=0}^{T-1} \mathbf{1}\{X_t = A_i, X_{t+1} = E_{ij}\} \right], \quad (87)$$

然后进行归一化，使得 $\hat{\pi} \mathbf{1} = p_0$ 和 $\hat{\pi}^\top \mathbf{1} = p_1$ （在数值容差范围内）。然后将 $\hat{\pi}$ 与 oracle 计划 π^* 进行比较。

实例生成。对于每个 n ，我们通过抽样生成合成实例：(i) 边缘分布来自狄利克雷分布（e.g., $p_0 \sim \text{Dir}(\alpha \mathbf{1})$, $p_1 \sim \text{Dir}(\alpha \mathbf{1})$ 并与 $\alpha = 1$ ），以及 (ii) 通过二维嵌入生成结构化成本矩阵：均匀抽样点 $u_i, v_j \in [0, 1]^2$ 并设置

$$C_{ij} := \|u_i - v_j\|_2. \quad (88)$$

在实践中，可以使用任何其他确定性的成本构造方法代替方程 88。

表 5. 分配任务度量

n	Optimal Cost	Assigned Cost	Mass on opt. selection	Row Entropy	Accuracy
6	160	160	97.3%	0.07	100%
8	205	205	94.2%	0.13	100%
10	239	239	87.6%	0.16	100%
20	538	546	85.0%	0.22	90%

基线。我们将 (i) 方程 (84) 的确切最小费用流/OT 解作为地面真实值进行比较 π^* 。

度量。对于返回软计划的每种方法 $\tilde{\pi}$ ，我们报告

$$\text{Cost: } \langle C, \tilde{\pi} \rangle, \quad \text{成本差距: } \frac{\langle C, \tilde{\pi} \rangle - \langle C, \pi^* \rangle}{\langle C, \pi^* \rangle}, \quad (89)$$

$$\text{边际误差 (TV): } \text{TV}(\tilde{\pi}, p_0) + \text{TV}(\tilde{\pi}^\top \mathbf{1}, p_1), \quad \text{TV}(p, q) := \frac{1}{2} \|p - q\|_1, \quad (90)$$

$$\text{Mean row entropy: } \frac{1}{n} \sum_{i=1}^n H(\tilde{\pi}_{i:}), \quad H(r) := - \sum_{j=1}^n r_j \log(r_j + \epsilon), \quad (91)$$

$$\text{Mass on optimal edges: } \sum_{(i,j) \in \text{supp}(\pi^*)} \tilde{\pi}_{ij}, \quad \text{Edge overlap (Accuracy): } \frac{|\{(i, \hat{\sigma}(i))\} \cap \text{supp}(\pi^*)|}{n}. \quad (92)$$

C.2 供应链

为了研究模型在图上处理复杂和稀疏动态的能力，我们将一个实际的供应链网络 (Kovács, 2015) 建模为有向图 $\mathcal{G} = (\mathcal{X}, \mathcal{E})$ ，其中每个节点 $x \in \mathcal{X}$ 代表一个设施/位置 (例如，供应商、仓库、港口、零售商)，每条有向边 $(x, y) \in \mathcal{E}$ 代表一个可接受的运输路径。随着现代决策规模的增加，有效架构来处理高维问题的需求日益显现 (Saravanos 等, 2025)。该图示于图 7。我们定义稀疏 CTMC 参考生成器 $r_{\text{ref}} \in \mathbb{R}^{|\mathcal{X}| \times |\mathcal{X}|}$ ，其支持在 $\mathcal{E}$ 上：对于 $(x, y) \in \mathcal{E}$, $r(y, x) := (r_{\text{ref}})_{yx} \geq 0$ 表示基本跳跃率，对角线由 $(r_{\text{ref}})_{xx} = - \sum_{y \neq x} r(y, x)$ 设置，使得各列之和为零。此参考过程捕捉了拓扑结构，即哪些移动是可能的，并带有名义上的路由偏差 (例如，与边容量成比例或与旅行时间的逆成比例)，而不强制边界边缘。表 6 总结了所考虑图的属性。

边界边缘 $p_0, p_1 \in \Delta^{|\mathcal{X}|-1}$ ，其中 $\Delta^{|\mathcal{X}|-1}$ 是概率单纯形。源节点 $\mathcal{S}$ 和需求节点 $\mathcal{D}$ 上的质量，均匀分布或体积加权，我们在 $T = 100$ 步上解决一个具有均匀离散化的有限时间范围运输问题，学习一个尊重拓扑结构的随机路由策略，其展开从 p_0 开始并到达 p_1 ，同时在传输过程中优化运营目标。

为了反映超出最短路径路由的操作约束，我们包括一个依赖于状态和分布的运行成本 $f_t(x, p_t)$ ，它惩罚不希望的位置，如拥堵的枢纽，鼓励轨迹绕过高成本/高占用节点，同时仍然匹配 (p_0, p_1) 在规定的时间内。具体来说，我们通过定义节点占用来惩罚交互驱动的拥堵

$$\text{occ}_t(x) = \sum_{b=1}^B \mathbf{1}\{X_t^{(b)} = x\}, \quad t = 1, \dots, T, x \in \mathcal{X}$$

排除源和目标端点节点，并对每个粒子收取暴露费用。这种设置突显了 GSBoG 的优势所在：(i) 它学习的是路径上的可执行策略，而不是静态耦合，(ii) 直接在给定的稀疏拓扑上操作，因此每次转换都是可行的，(iii) 原生支持状态/路径相关的成本，如集体占用引起的拥堵。相比之下，传统的图 OT 和网络流基线通常输出的是静态计划，这并不针对中间行为进行优化，可能会将交通集中在枢纽上。

表 6. 道路流量图统计 (DIMACS 最小成本流实例)。

Statistic	Value
Nodes N	9559
Sparsity	99.97 %
Density (unique edges)	3×10^{-4}
Mean out-degree / in-degree	3.105 / 3.105
Out-degree min / median / max	1 / 3 / 6
In-degree min / median / max	1 / 3 / 6
Arc cost min / median / mean / max	1.0 / 250 / 293.3 / 4537
Arc capacity min / median / mean / max	120 / 480 / 459.6 / 480

表 7. 道路流量实例的供需节点 (净不平衡)。

类型	节点 ID (数量)
Supply (+)	6923 (+1920), 5780 (+1440), 8243 (+1080), 5250 (+960), 7093 (+480), 5570 (+480)
Demand (-)	4455 (-1920), 7404 (-1440), 2490 (-1440), 1889 (-600), 5218 (-480), 2105 (-480)

表 8. 有向弧上的容量分布。

Capacity	# arcs	Share
120	476	1.60%
240	674	2.26%
360	2288	7.69%
480	26330	88.45%

基线 本文展示了供应链网络实验设置所使用的基线方法。所有方法均在同一时间范围 $T = 100$ 上进行评估, 该时间范围具有均匀离散化, 并且具有相同的回滚预算 $B = 5,000$ 。图上的薛定谔桥令 $\mathcal{G} = (V, E)$ 为加权图, 令 ρ_0, ρ_1 为端点分布。Chow 等人 (2022) 将图上的动态薛定谔桥表述为

$$\min_{\rho(\cdot), b(\cdot)} \int_0^1 \frac{1}{2} \langle b(t), b(t) \rangle_{\rho(t)} dt \quad \text{s.t.} \quad \begin{cases} \dot{\rho}(t) + \operatorname{div}_{\mathcal{G}}(\rho(t)(b(t) - \beta \nabla_{\mathcal{G}} \log \rho(t))) = 0, \\ \rho(0) = \rho_0, \quad \rho(1) = \rho_1, \end{cases} \quad (93)$$

其中 $\beta > 0$ 控制熵/噪声水平, 而 $\nabla_{\mathcal{G}}, \operatorname{div}_{\mathcal{G}}$ 是图梯度/发散算子; 内积 $\langle \cdot, \cdot \rangle_p$ 编码了一个离散的 W_2 型几何结构在 Δ^{N-1} 。单纯形上的哈密顿流。引入一个节点势 (共态) $\phi(t) \in \mathbb{R}^N$, 方程 (93) 的一阶最优性条件可以表示为一个两点边值哈密顿系统:

$$\dot{\rho}(t) = \nabla_{\phi} \mathcal{H}(\rho(t), \phi(t)), \quad \dot{\phi}(t) = -\nabla_{\rho} \mathcal{H}(\rho(t), \phi(t)), \quad \rho(0) = \rho_0, \quad \rho(1) = \rho_1, \quad (94)$$

对于由离散动能和熵/噪声项诱导的哈密顿量 $\mathcal{H}(p, \phi)$ 。因此, 该桥通过求解辛 BVP 获得, 其边缘分布 $\rho(t)$ 作为概率单纯形 Δ 上的哈密顿流演化 N^{-1} 。计算。数值上, 公式 (94) 是一个在 $\mathbb{R}^{2N}$ 中的耦合常微分方程系统, 每个节点有一对 $(\rho_i(t), \phi_i(t))$, 通过图算子耦合, 形成一个维度随 N 变化的大边值问题

吸引流。 本文包含一种基于图的吸引力流基线, 该方法通过拉普拉斯算子潜在场迭代地将质量运输到目标边缘。此基线通过反复沿边朝向吸引目标的潜在场方向推动质量, 构建了一个 T 跳传输过程。在每次跳跃 $t = 0, \dots, T-1$, 节点潜在值 ϕ_t 通过当前边缘 ρ_t 与目标 ρ_1 之间的差异计算得出 (通过图上的拉普拉斯/泊松求解)。然后根据下降的潜在值差 $\phi_t(x) - \phi_t(y)$, 将质量从一个节点 x 导向其邻居 y , 从而产生有向流




图 7. 我们的供需设置图。

$\rho_t(x \rightarrow y)$ 。为了获得可用于基于展开评估的操作策略，我们通过归一化出流 $P_t(y | x) \propto \rho_t(x \rightarrow y)$ （如有需要可添加自环/回退质量）应用马尔可夫嵌入，并通过 $x_{t+1} \sim P_t(\cdot | x_t)$ 模拟轨迹。嵌入参数的选择旨在最小化终端不匹配（TV），在 GSBog 使用的相同时间范围和展开预算下，确保公平比较。

时间扩展动态 $\mathcal{W}_1$ （最小费用流/离散 Benamou – Brenier 方法）。本文包含一个精确的动态 $\mathcal{W}_1$ 通过在一个时间范围上解决单一的时间扩展最小成本流问题所获得的基线 T 步骤。给定一个有向图 $\mathcal{G} = (\mathcal{X}, \mathcal{E})$ 每条边的容量为 $\text{cap}(x \rightarrow y)$ 以及成本 $c(x \rightarrow y)$ 我们构建了一个具有节点的分层网络 (t, x) 对于 $t = 0, \dots, T$ 和 $x \in \mathcal{X}$ 对于每条原始边 $(x \rightarrow y) \in \mathcal{E}$ ，我们添加一个运输弧 $(t, x) \rightarrow (t+1, y)$ 对于每一个 $t = 0, \dots, T-1$ ，继承相同的容量和成本。为了允许等待（使得每一步策略总是定义良好的），我们也添加持有弧 $(t, x) \rightarrow (t+1, x)$ 其成本为 0 且具有容量 M 。

令 $\rho_0, \rho_1 \in \Delta_{|\mathcal{X}|-1}$ 表示端点边缘，令 M 表示总运输质量（用于将概率转换为流量单位）。我们求解每步弧流 $q_t(x \rightarrow y)$ 并保持流 $q_t(x \rightarrow x)$ ：

$$\min_{q \geq 0} \sum_{t=0}^{T-1} \left(\sum_{(x \rightarrow y) \in \mathcal{E}} c(x \rightarrow y) q_t(x \rightarrow y) \right) \quad \text{s.t.} \quad (95)$$

$$\begin{cases} \sum_{y:(x \rightarrow y) \in \mathcal{E}} q_0(x \rightarrow y) + q_0(x \rightarrow x) = M p_0(x), & \forall x, \\ \sum_{y:(x \rightarrow y) \in \mathcal{E}} q_t(x \rightarrow y) + q_t(x \rightarrow x) = \sum_{y:(y \rightarrow x) \in \mathcal{E}} q_{t-1}(y \rightarrow x) + q_{t-1}(x \rightarrow x), & \forall x, t = 1, \dots, T-1, \\ \sum_{y:(y \rightarrow x) \in \mathcal{E}} q_{T-1}(y \rightarrow x) + q_{T-1}(x \rightarrow x) = M p_1(x), & \forall x, \\ 0 \leq q_t(x \rightarrow y) \leq \text{cap}(x \rightarrow y), & \forall (x \rightarrow y) \in \mathcal{E}, \forall t, \\ 0 \leq q_t(x \rightarrow x) \leq M, & \forall x, \forall t. \end{cases} \quad (96)$$

这产生了一个时间索引的可行流 $\{q_t\}_{t=0}^{T-1}$ ，其诱导的节点边缘在 $t=0$ 处匹配 p_0 ，在 $t=T$ 处匹配 p_1 。为了获得可操作策略，我们再次使用马尔可夫嵌入 $P_t(y | x) \propto \rho_t(x \rightarrow y)$ 并展开轨迹 $x_{t+1} \sim P_t(\cdot | x_t)$ ，调整任何嵌入平滑/回退质量以最小化终端不匹配（TV），在与 GSBog 相同的展开预算下。

备注（容量度量鲁棒性）。最小成本流对分数计划 ρ_t 施加了容量约束，但我们的报告

容量统计是从嵌入策略的采样轨迹中计算得出的。值得注意的是，尽管底层流在时间扩展形式下可能是容量可行的，但其随机执行将质量集中在少数瓶颈边上。特别是，流解饱和了许多边（ $\rho_t(x \rightarrow y) \approx \text{cap}(x \rightarrow y)$ ），随机抽样会导致瞬时边负载超过容量，因此基于回滚的最大（ flow / cap ）可能为 > 1 ，即使潜在的流是可行的。相比之下，GSBoG 的拥塞感知目标通常避免广泛的饱和，并留下更多的余地，从而导致在回滚变异性方面经验上更稳健的策略，同时仍然匹配端点。

Metrics. Let $\{X_t^{(b)}\}_{t=0}^T$ 对于 $b = 1, \dots, B$ 表示 B 在共同的时间范围内展开轨迹 T 离散步骤。令 $\mathcal{X} = \{x\}$ 为节点 $n_t(x) := \sum_{b=1}^B \mathbf{1}\{X_t^{(b)} = x\}$ 点 x 在步骤 t (so $\sum_x n_t(x) = B$ 处的粒子数量，并定义经验 marginal

$$\hat{p}_t(x) := \frac{1}{B} \sum_{b=1}^B \mathbf{1}\{X_t^{(b)} = x\}$$

- **终端不匹配。** 我们形成经验终端分布 $\hat{p}_T$ 并报告

$$\text{TV}(\hat{p}_T, p_1) = \frac{1}{2} \sum_{x \in \mathcal{X}} |\hat{p}_T(x) - p_1(x)|.$$

- **占有率和拥塞。** 我们使用占有率 $\text{occ}_t(x)$ ，并报告峰值占有率 $\max_{t,x} \text{occ}_t(x)$ 以及最拥挤的前 100 个节点的平均拥塞情况，

$$\frac{1}{T|\mathcal{I}_{100}|} \sum_{t=1}^T \sum_{x \in \mathcal{I}_{100}} \text{occ}_t(x), \quad \mathcal{I}_{100} := \text{Top100}\left(\{S(x)\}_{x \in \mathcal{X}}\right), \quad S(x) := \sum_{t=1}^T \text{occ}_t(x),$$

排除端点节点（源和目标）。请注意，由于所有方法都使用相同的 B ，这些量可以在所有方法之间直接比较。

- **容量可行性。** 给定每步边容量 $\text{cap}(e) > 0$ ，我们通过回放估计每步边流量作为

$$\widehat{\text{flow}}_t(e) := \sum_{b=1}^B \mathbf{1}\{(X_t^{(b)}, X_{t+1}^{(b)}) = e\},$$

本文报告了违反情况使用

$$V_{\max} := \max_{t,e} \frac{\widehat{\text{flow}}_t(e)}{\text{cap}(e)},$$

若方法具备容量可行性，则 $V_{\max} \leq 1$

备注 我们并未显式优化边容量约束；然而，拥塞感知策略通常通过将流量分散到替代路径而非集中于瓶颈来隐式减少违规情况。

GSBoG 实现和超参数 我们在 PyTorch 中通过稀疏图操作在有向边列表上实现了 GSBoG。在每次迭代中，我们在当前由学习到的潜在函数所诱导的正向/反向速率参数化下，模拟批次的 B 粒子进行 T 个离散时间步（均匀步长 Δt ），并通过经验计数估计中间占用量 $\hat{p}_t$ 。潜在函数 $Y^\theta(t, x)$ 和 $Y^\phi(t, x)$ 使用共享节点嵌入和一个基于（归一化）时间 t 的小型 MLP 建模，产生每个节点的标量输出；控制速率在边上局部形成，形式为 $u_t(y, x) = r_t(y, x) \exp(Y^\theta(t, y) - Y^\theta(t, x))$ （对于 $\hat{u}$ 类似），确保图可行的转换而无需密集求解器。我们通过交替进行正向/反向更新，并结合 gIPF 端点似然目标和带有 $\lambda_{\text{TD}} \in \{0, 0.05, 0.1, 0.2, 0.3, 0.5\}$ 的 TD 正则化器进行训练，使用 AdamW 优化器，学习率为 $\eta = 5 \cdot 10^{-5}$ 。表 2 中的结果是在使用 $\lambda_{\text{TD}} = 0.2$ 的情况下获得的。

关于消融实验的 λ_{TD} 图 8 研究了折衷参数 λ_{TD} 对终端准确率和中间拥挤程度的影响。随着 λ_{TD} 的增加，峰值占用率单调下降（从 ~ 320 到 ~ 240 ），这表明诱导的动力学使质量分布更加均匀，并避免了瓶颈。这种拥挤的减少是以终端匹配变差为代价的：最终分布与目标之间的总变化量（TV）增加（从 $\sim 2.3 \times 10^{-2}$ 到 $\sim 3.7 \times 10^{-2}$ ）。曲线在约 $\lambda_{TD} \approx 0.2$ 处表现出一个明显的拐点，在此点附近，拥堵急剧下降，而 TV 仅适度增加；超过这一点后，进一步降低拥堵的效果有限，而终端不匹配继续增长。总体而言， λ_{TD} 控制了一个准确率-可行性折衷，实验中 $\lambda_{TD} \approx 0.2$ 提供了较为有利的平衡。




图 8. 消融实验在 λ_{TD} 上显示了峰值拥堵的减少以及总变差的轻微增加。

C.3. 离散化的分子动力学

Chignolin Chignolin (CLN025 变体) 是一种广泛使用的分子仿真的基准，因为它是一个最小的、由 10 个残基组成的肽（166 个原子），尽管如此，它仍然保留了蛋白质折叠的基本特征（Lindorff-Larsen 等，2011）。具体来说，它表现出良好分离的未折叠和折叠的亚稳态构型，通过罕见的激活过渡连接，使其成为一种有用的测试平台，用于建模方法，旨在解决蛋白质折叠的热力学和动力学问题，同时保持计算上的可行性。

参考仿真和 MSM 构建 参考分子动力学 (MD) 仿真的轨迹在 $T_{\text{sim}} = 300$ chignolin 的 K 值来自 Iida (2022)，构象状态通过 PyEMMA (Scherer et al., 2015) 离散化为 MSM。作为输入特征，我们使用了主链扭转角 (ϕ 和 ψ 以正弦和余弦分量编码。本文利用 k-均值聚类将扭转特征划分为 $|\mathcal{X}| = 500$ 微状态聚类。为了提高计算效率，聚类是在以步长 10 采样的帧子集上进行的。然后，在固定滞后时间为 10 步（以采样间隔为单位，相当于 1 纳秒仿真时间）的情况下，从离散化轨迹中估计出一个马尔可夫状态模型 (MSM)。通过累积跨越轨迹的、由该滞后时间隔开的微状态之间的转移次数，并进行归一化处理，得到了微状态到微状态的转移概率矩阵。由此，可以得到平稳分布 π_i 跨越微状态 $i \in \mathcal{X}$ 被计算，微观状态自由能（单位为 $k_B T$ ）得以获得作为 $F_i/k_B T_{\text{sim}} = -\log \pi_i$ 。

为了定义折叠/未折叠的微状态盆地，我们首先计算每个帧 $\tilde{X}_i \in \mathbb{R}^{10 \times 3}$ 与天然折叠结构 (PDB 5AWL) $\tilde{Y} \in \mathbb{R}^{10 \times 3}$ 之间十个 C α 原子的对齐根均方偏差 (RMSD)。对齐的 RMSD 定义为

$$\text{RMSD}(X, Y) := \sqrt{\frac{1}{N} \min_{R \in \text{SE}(3)} \|X \circ R - Y\|_F^2} \quad (97)$$

for 3-D point clouds $X, Y \in \mathbb{R}^{N \times 3}$, where $R = (Q, t) \in \text{SE}(3)$ with $Q \in \text{SO}(3), t \in \mathbb{R}^3$ acts on X as $X \circ R := XQ + \mathbf{1}t^\top$. With an RMSD threshold of 0.5 纳米和 $d_{\text{unfolded}} = 0.5$ 纳米，对于每个微状态，我们计算折叠/未折叠的概率，即该微状态中 RMSD 小于 d_{folded} 和大于 d_{unfolded} 的帧的比例。

最后，将折叠概率高于 0.9 的微观状态分配到折叠盆地 $\mathcal{F}$ ，将展开概率高于 0.8 的微观状态分配到展开盆地 $\mathcal{U}$ 。端点分布 μ 和 ν 由限定在展开和折叠盆地内的微状态概率定义：
 $\mu(i) = \pi_i \mathbf{1}[i \in \mathcal{U}] / \sum_{k \in \mathcal{U}} \pi_k$ 及此外，我们计 $\nu(i) = \pi_i \mathbf{1}[i \in \mathcal{F}] / \sum_{k \in \mathcal{F}} \pi_k$
 of the frames in the mi 算每个微状态的平均 C α RMSD r_i
 通过求该微状态下各帧的 C α RMSD 的平均值。

在定义连续时间马尔可夫链 (CTMC) 参考动力学之前，我们先修剪参考马尔可夫状态模型 (MSM) 图中导致变化较大的远程边

几何跳跃。给定选定滞后时间下的马尔可夫状态模型转移矩阵 T^{MSM} ，我们移除均方根偏差跳跃超过阈值 $\delta = 0.1$ 纳米的转移，即当 $|d_i - d_j| > \delta$ 时，我们将 $T_{ij}^{\text{MSM}} \leftarrow 0$ 设为零。为了避免图的断开，对于任何出边（或入边）都会被上述标准移除的状态 i ，我们保留具有最小均方根偏差差异的单一边缘。得到的稀疏转移矩阵 $T_{ij}^{\text{MSM,pruned}}$ 然后通过分配与剩余转移概率成比例的非对角线速率，并强制列和为零，转换为稀疏 CTMC 生成器： $(Q_{\text{ref}})_{ij} = \frac{1}{\tau} T_{ij}^{\text{MSM,pruned}}$ 对于 $i \neq j$ 和 $(Q_{\text{ref}})_{ii} = -\sum_{j \neq i} (Q_{\text{ref}})_{ij}$ ，其中 $\tau = 0.1$ 是一个超参数，它将 CTMC 时间尺度与 MSM 滞后时间相关联。这种构造等同于二阶映射 $T^{\text{MSM}} = e^{\tau Q} \approx I + \tau Q$ ，同时保留修剪后的 MSM 拓扑结构，并防止离散轨迹进行大幅度的结构转变。

基线 我们将 GSBog 与两种基于图的传输基线和一种动力学启发的偏置基线进行了比较。首先，我们包含了 Chow 等人 (2022) 提出的有限图上的动态薛定谔桥形式 (GraphSB)，该方法通过求解一个单纯形值的边值系统来生成一个时间非齐次马尔可夫过程，使其匹配给定的端点。其次，我们包含了一个吸引流基线，它通过将静态边流/潜在驱动的路由规则转化为行随机转移核，并运行 T 步来诱导一个马尔可夫过程，并将其展开 T 步。

除了基于 SB 的基线外，我们还包括了一个由通行子引导的偏置动力学基线。微观状态的正向通行子 i 被定义为 $q(i) := \mathbb{P}_i(\tau_{\mathcal{F}} < \tau_{\mathcal{U}})$ 即，从 i 达到 $\mathcal{F}$ 之前 $\mathcal{U}$ ，带有边界条件 $q(i) = 0$ 对于 $i \in \mathcal{U}$ 和 $q(i) = 1$ 对于 $i \in \mathcal{F}$ (Vanden-Eijnden 等, 2010)。对于内部状态 $\mathcal{I} = \mathcal{X} \setminus (\mathcal{U} \cup \mathcal{F})$ ， q 满足狄利克雷问题 $q(i) = \sum_j T_{ij}^{\text{MSM}} q(j)$ ， $i \in \mathcal{I}$ 为了使采样偏向折叠，我们应用 Doob- h 变换 (Doob, 1957) 重新调整向较大通过值转移的概率： $T_{ij}^{(h)} = T_{ij}^{\text{MSM}} h(j) / \sum_k T_{ik}^{\text{MSM}} h(k)$ ，并利用从此偏倚马尔可夫链中采样的轨迹。

度量 我们在表 4 中报告了展开过程中达到的最大状态自由能（自由能障碍）和正确终止于折叠盆地的轨迹的比例 $\mathcal{F}$ （折叠率）。更具体地说，设 $F(x)/k_B T_{\text{sim}} = -\log \pi_x$ 为参考 MSM 微状态自由能。对于一个展开轨迹 $(X_t)^T$ ，我们将其障碍定义为

$$\Delta F(X_{0:T}) := \max_{0 \leq t \leq T} F(X_t) - \min_{x \in \text{sup}} \sup_{\text{upp}(\nu)} F(x),$$

因此，较低的 ΔF_{eff} 表明诱导的动力学能够在参考 MSM 能量下到达折叠盆地同时避免高- F 中间体。我们还报告了独立轨迹在每次展开时间上的 C_α 均方根偏差平均值

图 5。

GSBoG 实现和超参数 我们直接在 MSM 微状态图上运行 GSBog，节点由 MSM 微状态给出，边由 MSM 转移矩阵的非零支持给出。训练遵循我们的交替前向/后向 IPF 方案，并附加 TD 样式的惩罚以纳入非平凡的 f ：我们反复 (i) 在当前前向（或后向）控制动力学下展开一批轨迹，(ii) 根据离散时间生成器/迪尼金恒等式形成相应的 IPF 损失，以及 (iii) 更新 (Y, Y) 。我们使用固定的时间范围为 $T = 200$ 步， $B = 1024$ 次展开，100 次 IPF 迭代， λ_{TD} 的值设置为 0.2，AdamW 优化方法，学习率为 $\eta = 10^{-4}$ ，以及 MLP 参数化。

D. 扩展相关工作

薛定谔桥 近期，生成建模领域出现了一波基于最优传输 (Villani 等, 2009) 的原则性方法。其中特别有影响力的一种形式是薛定谔桥 (SB; Schrödinger, 1931)。在引入迭代比例拟合 (IPF) 训练程序——本质上是 Sinkhorn 算法的连续状态类比——来解决动态薛定谔桥问题后，SB 在生成建模中变得尤为突出 (De Bortoli 等, 2021; Vargas 等, 2021)。概念上，SB 通过完全非线性随机动力学使任意分布之间的传输成为可能，从而将标准扩散模型扩展到固定端点选择之外，并确定了最小化动能类型目标的（唯一）路径测度。从路径测度的角度来看，薛定谔桥问题 (薛定谔, 1931) 寻求最小化以下最小化的最优测度 π_0 和 π_1 ，即最优测度 $\mathbb{P}^*$

$$\min_{\mathbb{P}} \text{KL}(\mathbb{P} | \mathbb{Q}), \quad \mathbb{P}_0 = \pi_0, \mathbb{P}_1 = \pi_1 \quad (98)$$

其中 $\mathbb{Q}$ 是一个马尔可夫参考测度。因此，动态 SB $\mathbb{P}^*$ 的解被认为是与 $\mathbb{Q}$ 最接近的路径测度。通过应用 Girsanov 定理来构建，动态 SB 的另一种表述至关重要地出现了

将问题视为随机最优控制 (Stochastic Optimal Control, SOC) 问题 (陈等, 2016; 2021)。

$$\min_{u_t, p_t} \int_0^1 \mathbb{E}_{p_t} [\|u_t\|^2] dt \quad \text{s.t.} \quad \frac{\partial p_t}{\partial t} = -\nabla \cdot (u_t p_t) + \frac{\sigma^2}{2} \Delta p_t, \quad \text{and} \quad p_0 = \pi_0, \quad p_1 = \pi_1 \quad (99)$$

召回率, 我们的 GSB 目标与在 B 节中提出的相应 SOC 问题之间的联系。最后, 需要注意的是, 静态 SB 等价于熵正则化 OT 公式 (Pavon 等, 2021; Nutz, 2021; Cuturi, 2013)。

$$\min_{\pi \in \Pi(\pi_0, \pi_1)} \int_{\mathbb{R}^d \times \mathbb{R}^d} \|x_0 - x_1\|^2 d\pi(x_0, x_1) + \epsilon \text{KL}(\pi | \pi_0 \otimes \pi_1) \quad (100)$$

这一正则化项通过 Sinkhorn 算法实现了高效求解, 并展现出诸多优势, 如平滑性和其他统计特性 (Ghosal 等, 2022; Léger, 2021; Peyré & Cuturi, 2019)。

连续薛定谔桥的迭代比例拟合 (IPF) 一种看待薛定谔桥 (SB) 的标准方法是将其视为路径空间上的 KL 投影: 在所有路径测度中, 其端点匹配 (π_0, π_1) , SB 选择与参考马尔可夫过程最接近 (在相对熵意义上) 的一个。这种变分结构自然地产生了迭代比例拟合 (IPF), 即交替进行 KL 投影到满足一个端点约束的路径测度集合上。在有限空间中, 这一特化恢复了经典 Sinkhorn/迭代缩放程序用于 Schrödinger 问题和熵 OT 的方法, 等价于通过前向/后向潜在函数的乘法重新加权来迭代 Schrödinger 系统。在连续状态扩散中, IPF 可以解释为交替优化前向和后向动力学 (或它们相关的潜在函数), 使得诱导的时间边缘分布逐步满足端点约束, 将 SB 计算与随机控制和 PDE/FBSDE 表示连接起来。最近的生成模型研究集中在使这些 IPF 更新在高维度下实用, 通过用学习的近似值替换精确的潜在/漂移更新。扩散薛定谔桥 (DSB; (De Bortoli 等人, 2021)) 明确地将训练表述为对 IPF 的近似, 其中每次迭代都拟合前向/后向得分/漂移模型, 以便终端边缘更好地匹配规定的端点。互补的方法通过似然或发散目标重新解释交替更新: Vargas (2021) 提出了一个最大似然途径来学习 SB, 这可以被看作是一个交替过程, 强制执行端点一致性, 而 SB-FBSDE (Chen 等人, 2021) 利用非线性费曼-卡茨/FBSDE 公式获得无需网格化状态空间的可处理训练损失。深度广义薛定谔桥 (DeepGSB; (Liu 等人, 2022b)) 进一步强调, 在参数化的前向/后向路径测度之间交替最小化对应于迭代 KL 投影——即 IPF——并将此模板扩展到平均场相互作用, 产生类似 TD 学习的计算结构。除了生成建模之外, 相关的基于样本和数据驱动的变体在只有端点分布的样本可用时适应 Fortet/Sinkhorn 样式的迭代 (Pavon 等人, 2021)。

连续薛定谔桥的迭代马尔可夫拟合 (IMF) 最近, 在连续空间中, 针对可扩展的薛定谔桥 (SB) 求解器取得了显著进展。Peluchetti (2023) 提出了 SB 的马尔可夫投影视角, 提供了一条原理性的途径来生成再现目标边缘分布的马尔可夫动力学。基于这一解释, 扩散薛定谔桥匹配 (DSBM; (Shi 等, 2023)) 使用迭代马尔可夫拟合 (IMF) 来逼近 SB 解。相关地, De Bortoli 等人 (2023) 研究了流和桥匹配过程, 并引入了旨在保存耦合信息的修改, 展示了在图像翻译任务混合上的高效学习能力。 $SF^2 - M$ (Tong 等 (2023) 提供了一个无需仿真的目标来推断随机动力学, 并在实践中对 SB 问题有效, 而 GSBM (Liu 等, 2024) 通过引入机制将任务特定的状态依赖成本纳入分布匹配中。除了主要针对未配对边缘的最优耦合求解器外, Somnath 等 (2023) 和 Liu 等 (2023) 考虑了具有先验配对数据 (如干净/损坏的图像或配对的生物模态) 环境下的桥匹配, 其目标是利用给定的对齐而不是从零开始通过静态 SB 进行推断。最后, 一些工作扩展到了多边缘设置 (Theodoropoulos 等, 2026) 或提高了基于匹配的 SB 流水线的计算效率, 例如通过使用高斯混合参数化的轻量级求解器 (Gushchin 等, 2024; Rapakoulis 等, 2024), 以及通过反馈式表述 (Theodoropoulos 等, 2024)。

具有 CTMC 动力学的离散 SB。最近的离散空间 SB 求解器也采用了连续时间马尔可夫链 (CTMC) 动力学, 这与我们的控制理论视角大致一致。然而, 与我们的设定不同, 这些方法通常不将运输视为受固定稀疏路由拓扑约束的粒子运动, 也不自然支持应用特定的状态依赖运行成本以塑造中间行为。算法上, 下面的两项工作通过迭代马尔可夫拟合 (IMF) 解决了 SB 问题, 即迭代拟合对于 SB 的马尔可夫链类比。对于

示例，离散扩散薛定谔桥匹配（DDSBM；（Kim 等人，2024））旨在实现图到图的转换，通过在图空间生成编辑序列（转换对应于编辑操作），而不是在预定物流网络上的边可行路径。与此相关的是，用于通用离散域（例如，令牌/代码簿空间）的分类 SB 方法同样依赖于离散时间 IMF 样式的迭代拟合进行翻译和匹配，但并未作为拓扑约束路由与状态成本成形提出（Ksenofontov & Korotin，2025）。同时，Guo 等人（2026）提出了基于伴随匹配的 CTMC 动力学的离散薛定谔桥公式。虽然这与我们的控制理论视角密切相关，但他们的公式侧重于参考转移结构的具体选择，如均匀基础转移率，并未直接解决具有应用特定状态相关运行成本的稀疏拓扑约束路由。

图上的拓扑信号的 SB。拓扑感知 SB（TSBM；（Yang，2025））则通过拉普拉斯/霍奇驱动扩散来建模图和单纯复形上连续拓扑信号的演化（在特殊情况下允许闭式高斯桥，并更一般地允许神经参数化）。尽管它遵循基于 SDE 的 SB 公式并因此共享连续状态 SB 工具箱，包括类似于（De Bortoli 等人，2021）的 IPF 样式的训练，但其重点与边对边路由语义以及固定稀疏运输网络上的状态成本控制粒子流不同。因此，其重点在于定义在拓扑上的信号的分布匹配，而非稀疏物流网络中质量的拓扑约束路由。