

无监督学习预测不平衡图之间的最优传输计划

Sonia Mazelet

CMAP, Ecole Polytechnique
Palaiseau, France
sonia.mazelet@polytechnique.edu

Rémi Flamary

CMAP, Ecole Polytechnique
Palaiseau, France
remi.flamary@polytechnique.edu

Bertrand Thirion

Mind, Inria-Saclay
Palaiseau, France
bertrand.thirion@inria.fr

摘要

基于 Gromov-Wasserstein 及其扩展的图之间最优传输是一种强大的工具，用于比较和对齐图结构。然而，解决相关的非凸优化问题计算成本高昂，这限制了这些方法在大规模图上的可扩展性。在这项工作中，我们提出了不平衡最优传输学习（ULOT），这是一种深度学习方法，用于预测两个图之间的最优传输计划。我们的方法通过最小化融合不平衡 Gromov-Wasserstein（FUGW）损失进行训练。我们提出了一种具有交叉注意力的新颖神经架构，该架构依赖于 FUGW 权衡超参数。我们在合成随机块模型（SBM）图和来自 fMRI 的真实皮层表面数据上评估了 ULOT。ULOT 以比经典求解器快两个数量级的速度预测传输计划，并具有竞争力的损失。此外，预测的计划可以用作经典求解器的初始值，以加速其收敛。最后，预测的传输计划相对于图输入和 FUGW 超参数完全可微，从而可以优化 ULOT 计划的功能。

1 引言

图对齐 在许多图数据应用中，需要在两个图之间对齐或匹配节点。例如，在目标检测中，两个不同域图像中对象之间的语义对应可以使模型更具适应性 [12]；在图编辑距离中 [22, 18]，目标是计算两个图之间的距离，这需要找到它们节点之间的最佳对应关系；形状匹配 [20]，或者跨受试者的大脑对齐 [30]。然而，图匹配的问题由于其组合性质而具有挑战性，通常可以重新表述为一个已知的 NP 难问题——二次分配问题（QAP）[16]。最近提出的一种策略是使用深度学习在监督设置下学习匹配 [36], [25]。这些方法通常依赖于图神经网络（GNN）来学习节点的表示，然后使用匹配算法来计算节点之间的对应关系。然而，当图不平衡，即它们具有不同数量的节点或某些节点具有噪声特征或连接时，问题变得更加困难。

图之间的最优传输 近年来，最优传输（Optimal Transport，简称 OT）作为一种强大的工具，被用于解决图匹配问题。它可以被视为 QAP 的一种连续松弛形式，其中 Gromov-Wasserstein（GW）距离 [17, 21, 40] 是对经典 Wasserstein 距离在不同度量空间分布上的推广。对于带标签的图，已经提出了 GW 距离的扩展，例如融合 Gromov-Wasserstein（FGW）距离 [31]。然而，这些 OT 问题对传输计划施加了强烈的约束，使得它们对噪声、异常值和局部变形非常敏感。这就是为什么提出了不平衡 GW（Unbalanced GW）[27, 5] 和融合不平衡 GW（FUGW）[30] 来将 GW 和 FGW 距离推广到不平衡设置，并应用于正无标签学习和脑部对齐。

经典最优传输求解器的复杂度 二次 OT 问题，如 FGW 和 FUGW 是非凸的。经典的求解器依赖于块坐标下降算法迭代地求解问题的线性化版本。这种线性化的复杂度为 $O(n_1 n_2^2 + n_2^2 n_1)$ ，其中 n_1 和 n_2 是两个图中的节点数 [21]。这使得该方法对于大型图不可扩展，特别是在需要计算许多图对之间的传输计划或验证超参数的应用场景下。这种情况在不平衡情况下尤为严重，因为解决方案对参数非常敏感。最近，机器学习社区提出了使用深度学习加速或解决 OT 问题的方法。例如，[11] 提出使用神经网络估计 OT 映射，并在 [19, 38] 中提出了对 GW 的扩展。但对我们目前最相关的工作是 Meta OT [2]，它提出使用神经网络预测熵正则化 OT 问题的对偶势。然而，这种方法仅限于经典熵正则化 OT，不直接适用于二次 FUGW 问题，这正是我们提出的解决方案所详细阐述的内容。

贡献 本文提出了一种新的方法来学习一个预测 FUGW 问题运输计划的神经网络，该方法称为无监督最优传输计划预测（ULOT）。本文提出了一种基于图神经网络（GNN）和交叉注意力机制的新架构，用于预测具有复杂度为 $O(n_1 n_2)$ 的 OT 计划，这比经典求解器快得多。此外，神经网络由 FUGW 问题的参数条件化，从而能够高效地预测所有可能参数值的 OT 计划。在不平衡情况下，这种方法特别有用，因为解决方案对参数非常敏感，通常需要验证。我们在模拟数据和实际数据上的实验表明，我们的方法在速度上比经典求解器快两个数量级，同时提供的 OT 计划具有竞争力的损失。预测的运输计划也可以作为经典求解器的初始点，减少迭代次数和算法总时间。我们还展示了我们的方法提供了一个平滑的运输计划估计，可用于多种应用，如标签传播的参数验证或 FUGW 损失的梯度下降。

2 图之间的 OT 计划预测学习

本节首先介绍 FUGW 最优传输问题及其相关损失函数。接下来，我们介绍了称为无平衡最优传输（ULOT）的摊销优化策略，并详细说明了神经网络的架构。最后，我们讨论了深度学习在最优传输和图匹配方面的工作。

2.1 融合不平衡 Gromov-Wasserstein（FUGW）

融合不平衡 Gromov-Wasserstein（FUGW）损失的定义 考虑两个图

$\{G_k = (\mathbf{F}_k, \mathbf{D}_k, \boldsymbol{\omega}_k)\}_{k=\{1,2\}}$ 分别具有 n_1 和 n_2 个节点。对于 $k \in \{1,2\}$ ，它们通过节点特征 $\mathbf{F}_k \in \mathbb{R}^{n_k \times d}$ ，连接矩阵 $\mathbf{D}_k \in \mathbb{R}^{n_k \times n_k}$ （通常是邻接矩阵或最短路径距离矩阵）以及节点权重 $\boldsymbol{\omega}_k \in \Delta_{n_k} \triangleq \{(\omega_k^1, \dots, \omega_k^{n_k}), \sum_{i=1}^{n_k} \omega_k^i = 1\}$ 来表征，这些权重表征节点的相对重要性 [34]。请注意，在下文中我们将假设这些权重是均匀的，即 $\omega_k^i = 1/n_k$ 对于 $i = 1, \dots, n_k$ 。FUGW [30] 的目标是学习一个正运输计划 $\mathbf{P} \in \mathbb{R}^{n_1, n_2}$

在节点之间 G_1 和 G_2 ，以最小化以下损失函数：

$$\mathbf{L}^{\alpha,\rho}(G_1, G_2, \mathbf{P}) = (1 - \alpha) \sum_{i,j=1}^{n_1, n_2} \left\| (\mathbf{F}_1)_i - (\mathbf{F}_2)_j \right\|_2^2 \mathbf{P}_{i,j} \quad (1)$$

$$+ \alpha \sum_{i,j,k,l=1}^{n_1, n_2, n_1, n_2} |(D_1)_{i,k} - (D_2)_{j,l}|^2 \mathbf{P}_{i,j} \mathbf{P}_{k,l} \quad (2)$$

$$+ \rho (\text{KL}(\mathbf{P}_{\#1} \otimes \mathbf{P}_{\#1} | \omega_1 \otimes \omega_1) + \text{KL}(\mathbf{P}_{\#2} \otimes \mathbf{P}_{\#2} | \omega_2 \otimes \omega_2)). \quad (3)$$

FUGW 损失函数结合了衡量节点特征保存的 Wasserstein 距离 (1)，衡量局部几何结构保守性的 Gromov Wasserstein 距离 (2)，以及通过 KL 发散 (3) 对最优传输计划边际违反的惩罚。条款 (1) 和 (2) 由权衡参数 $\alpha \in [0, 1]$ 加权，而边际惩罚 (3) 由 ρ 加权。不平衡最优传输是一种非常通用且鲁棒的框架，能够适应图顶点几何结构的差异。

求解复杂度 $\min_{\mathbf{P} \geq 0} \mathbf{L}^{\alpha,\rho}(G_1, G_2, \mathbf{P})$ 为了解决 FUGW 问题，需要最小化最优传输计划下的 FUGW 损失 $\mathbf{P}$ 由于 Gromov-Wasserstein 项的存在，给定计划下的 FUGW 损失或其梯度的复杂度 $\mathbf{P}$ 理论上为四次方 $O(n_1^2 n_2^2)$ 在平方损失的情况下，Peyré等人 [21] 展示了复杂度可以降低到立方复杂度 $O(n_1 n_2^2 + n_1^2 n_2)$ ，对于通常节点数超过的大图而言，计算量仍然较大 10k 节点。现有的最小化 FUGW 损失的方法采用对目标函数的下界进行坐标下降的方案，该下界在每次迭代中求解二次问题的线性化 [8], [30] 并且在每次迭代中都需要计算三次梯度。接下来我们将 ULOT 与线性化问题的三种不同类型的内求解器进行比较：主要化最小化 (Majorization-minimization, MM) 算法 [6]，不精确的 Bregman 近点 (IBPP) 算法 [39] 以及更为经典的 L-BFGS-B 算法 [4] 本文还将比较我们的方法与 FUGW 损失的熵正则化方法，后者可以使用 Sinkhorn 算法解决内部问题。所有这些方法都是迭代的，并需要一个 $O(n_1 n_2^2 + n_1^2 n_2)$ 每次迭代中的梯度/线性化计算。这是 FUGW 问题的主要瓶颈，尤其是在图规模较大或需要多次求解 FUGW 的情况下，例如在选择参数的同时计算 FUGW 重心 (α, ρ) 方法的有效性。

2.2 ULOT 优化问题及架构

学习预测融合不平衡 Gromov Wasserstein (FUGW) 最优传输 (OT) 计划 本文提出训练一个模型 $\mathbf{P}_{\theta}^{\rho,\alpha}(G_1, G_2)$ ，其参数由 θ 表示，该模型在给定两个图 G_1, G_2 和 (ρ, α) 参数的情况下，能够预测它们之间的 FUGW 传输计划，或者至少是一个接近最优解的方案。为了避免以监督方式训练模型，在训练集中每对图 (G_1, G_2) 都需要预先计算对应的传输计划 $\mathbf{F}$ 。因此，我们提议使用摊销优化 [3] 以无监督的方式训练模型。我们通过从训练数据集 $\mathcal{D}$ 中采样图对 (G_1, G_2) 和参数 (ρ, α) ，并最小化预期的 FUGW 损失来实现这一点。ULOT 模型被训练以最小化：

$$\min_{\theta} \mathbb{E}_{G_1, G_2 \sim \mathcal{D}^2, \alpha, \rho \sim \mathcal{P}} [\mathbf{L}^{\alpha,\rho}(G_1, G_2, \mathbf{P}_{\theta}^{\rho,\alpha}(G_1, G_2))]. \quad (4)$$

其中 $\mathcal{P}$ 是实验中选定的参数 (ρ, α) 的分布作为 $\mathcal{P}_{\rho}, \mathcal{P}_{\alpha}$ ，其中 $\mathcal{P}_{\rho}$ 是在 10^{-7} 和 1 之间的对数均匀分布，而 $\mathcal{P}_{\alpha}$ 遵循具有参数 (0.5, 0.5) 的 Beta 分布。通过对参数的某些区间优化损失的事实 (ρ, α) ，使得模型能够推广到不同的参数值进行探索甚至优化它们。

参数编码 (ρ, α) 由于我们希望模型 $\mathbf{P}_{\theta}^{\rho,\alpha}(G_1, G_2)$ 依赖于参数 (ρ, α) ，我们需要以一种可以被神经网络使用的编码方式来表示它们。为此，我们将它们添加到网络每一层的图节点特征中。 ρ 是一个影响 OT 计划质量的正标量，可以直接包含进去。但 α 是一个在 $[0, 1]$ 范围内的标量，用于固定 Wasserstein 和 Gromov-Wasserstein 项之间的权衡，这在接近 0 和 1 时可能有较大的影响。为了便于在神经网络中使用，我们建议使用更具表现力的方式来编码它，




图 1: 用于 OT 计划预测的 ULOT 架构 该架构包括两部分。一个重复 N 次的节点嵌入层，依赖于跨图注意力和自节点更新（GCN），以及最终的传输计划预测层，该层预测节点权重和输出传输计划。

使用一种位置编码技术以更富有表现力的方式进行。我们选择了与 [32] 相同的技术，使用傅里叶基在流匹配应用中编码时间，如下所示：

$$\hat{\alpha} = \left[(\cos(k\pi\alpha))_{k=1,\dots,d} | (\sin(k\pi(1-\alpha)))_{k=1,\dots,d} \right]. \quad (5)$$

其中我们在实验中设置 $d = 10$ 。 $\hat{\alpha}$ 和 ρ 在下文详细说明了网络每一层中与节点特征连接。

2.3 提出的交叉注意力神经架构

本文详细介绍了所提出的神经网络架构，该架构将两个图 G_1 和 G_2 以及参数 (ρ, α) 作为输入，并预测运输计划 $P_{\theta}^{\rho, \alpha}(G_1, G_2)$ 。如图 1 所示，所提出的 ULOT 架构由两部分组成。第一部分包含 N 层节点嵌入和基于交叉注意力的跨图交互，这些交互结合了每个图的几何结构。最后一层根据学习到的节点特征和节点重新加权的交互来预测运输计划。

具有交叉注意力的节点嵌入 架构的第一部分受到来自 [13] 的图匹配网络的启发，该网络学习反映两个图之间节点相似性的节点特征。在每一层中，节点嵌入通过两条路径计算。一条路径称为自路径，它简单地由一个独立处理每个图的 GCN 组成。对于每个图 G_k ，自节点特征通过 GCN 学习 $k \in \{1, 2\}$ ，。

$$\mathbf{F}_k^{\text{self}} = \text{GCN}(\mathbf{F}_k). \quad (6)$$

此路径允许图根据其几何结构更新节点特征。第二条路径是交叉路径，它计算两个图之间节点特征的相似性矩阵，并学习表征它们相互作用的新特征。同时，交叉节点特征 $\mathbf{F}_{1 \rightarrow 2}^{\text{cross}}, \mathbf{F}_{2 \rightarrow 1}^{\text{cross}}$ 通过注意力模块计算得出，对于 $k, k' \in \{1, 2\}, k \neq k'$ ，以如下方式学习：

1. Compute embeddings:

$$\mathbf{F}_k^{\text{cross}} = \text{MLP}(\mathbf{F}_k, \rho, \hat{\alpha}). \quad (7)$$

2. 计算相似性矩阵 S 和行/列注意力矩阵 S_1, S_2 ，对于 s ，使用余弦相似度和 $i \in [1, n_1], j \in [1, n_2]$:

$$S_{i,j} = s((\mathbf{F}_1^{\text{cross}})_i, (\mathbf{F}_2^{\text{cross}})_j) \quad \text{and} \quad \begin{cases} S_1 = \text{softmax}_{\text{row}}(a^2 S) \\ S_2 = \text{softmax}_{\text{column}}(a^2 S) \end{cases} \quad (8)$$

其中 $a \in \mathbb{R}$ 是一个超参数。3. 计算更新后的

节点特征 $\mathbf{F}_{1 \rightarrow 2}^{\text{cross}}$ 和 $\mathbf{F}_{2 \rightarrow 1}^{\text{cross}}$:

$$\mathbf{F}_{1 \rightarrow 2}^{\text{cross}} = \text{Linear}(\mathbf{F}_2^{\text{cross}} - S_2^T \mathbf{F}_1^{\text{cross}}), \quad \mathbf{F}_{2 \rightarrow 1}^{\text{cross}} = \text{Linear}(\mathbf{F}_1^{\text{cross}} - S_1 \mathbf{F}_2^{\text{cross}}), \quad (9)$$

在层结束时, 对于 $k, k' \in 1, 2, \dots$, 从自 (GCN) 和交叉注意力路径学习到的节点特征与输入节点特征通过以下方程合并:

$$\mathbf{F}_k^{\text{final}} = \text{MLP}(\text{Linear}(\mathbf{F}_k), \text{Linear}(\mathbf{F}_k^{\text{self}}), \text{Linear}(\mathbf{F}_{k' \rightarrow k}^{\text{match}}), \rho, \hat{\alpha}), \quad (10)$$

多层感知机的输入被拼接在一起。使用这两条路径可以学习考虑图几何结构和图之间交叉交互的节点特征。

带有交叉注意力和节点缩放的运输计划预测 最小化 FUGW 距离的最优传输计划是不平衡的。为了使网络能够学习不平衡的计划, 我们在图的节点上预测表示从每个节点运输多少权重的权重向量 $\mathbf{v}_k \in \mathbb{R}^{m_k}, k \in \{1, 2\}$ 。

$$\mathbf{v}_1 = \text{sigmoid}(\text{Linear}(\mathbf{F}_1^{\text{final}}, \rho, \hat{\alpha})), \quad \mathbf{v}_2 = \text{sigmoid}(\text{Linear}(\mathbf{F}_2^{\text{final}}, \rho, \hat{\alpha})) \quad (11)$$

我们从最后一层的相似性矩阵 S_1, S_2 中学习传输计划。

$$\mathbf{P}_{\theta}^{\rho, \alpha}(G_1, G_2) = \frac{1}{2} \left(\frac{1}{n_1} S_1 \text{diag}(\mathbf{v}_1) + \frac{1}{n_2} \text{diag}(\mathbf{v}_2) S_2 \right). \quad (12)$$

这使我们能够学习一个不平衡的传输计划, 并将跨图寻找节点交互的问题 (通过交叉注意力完成) 与学习特定于不平衡 OT 的单个节点权重的问题分开。

2.4 相关工作

深度最优传输学习 为了加速深度学习解决最优传输问题的方法, 已经提出了几种方法。例如, [26] 提出使用神经网络来建模熵正则化 OT 问题的对偶势。Neural OT [11] 使用神经网络学习两个分布之间的经典 OT 映射。最近, Neural OT 的扩展也被提出用于解决 GW 问题, 如在 [19, 38] 中所述。这通常允许解决大规模 OT 问题, 但得到的神经网络仅适用于特定的一对分布, 并需要针对新的分布对进行重新优化。Meta OT [2] 使用一种称为摊销优化的策略 [3] 来学习一个多层感知器神经网络, 该网络可以预测样本的熵正则化 OT 问题的对偶势。他们的模型可以用来预测两个新分布之间的熵传输计划, 使用原始-对偶关系。然而, Meta OT 不能用于二次 OT 问题, 如 Gromov-Wasserstein 或 FUGW 问题, 因为优化问题是非凸的, 原始-对偶关系更为复杂 [42]。实际上, 为了使用类似于 Meta OT 的方法, 需要使用问题的线性化, 即 $O(n^3)$, 这会取消部分使用高效神经网络的优势。ULOT 被设计为具有 $O(n^2)$ 复杂度执行 OT 计划预测。我们的方法也专注于图数据。有必要超越多层感知器, 以便设计能够利用图结构的神经网络。从这个意义上说, ULOT 可以被视为将 Meta OT 推广到不平衡 OT 之间图的情况。最后, 我们学习了一个可以根据 OT 问题参数预测传输计划的模型, 在我们的案例中是 (α, ρ) , 这特别新颖, 据我们所知以前没有做过。

深度学习用于图匹配 针对深度图匹配问题, 即在图之间寻找结构对应关系, 已经提出了多种神经架构。然而, 这些方法通常面临显著的局限性。一些方法仅限于预测图对之间的全局相似度得分, 而无法预测节点对应关系 [13, 14]。其他提供节点级匹配的方法通常依赖于监督训练 [36, 25, 41], 这限制了它们的应用范围, 使其仅适用于具有可用真实对应关系的数据集, 如图像。另一方面, 无监督方法依赖于特定任务的目标, 例如强制循环一致性 [33, 37], 或者通过对比学习方法将图与其增强副本进行匹配, 对于后者, 它们知道真实对应关系 [15]。为了提高不同大小图之间匹配的鲁棒性, 一些方法会丢弃一部分对应关系。已提出的各种方法包括选择最自信的前 k 个匹配 [35] 或添加虚拟节点 [10]。然而, 尽管这些方法与 ULOT 有类似的目标, 但它们执行的是硬节点选择, 这对于异常值是有用的, 但在需要一种更连续的方式来减少某些节点的重要性时则不适用。




图 3: 不同值的 OT 计划示意图 ρ 。(左) 由 ULOT 预测 (上) 和 IBPP 求解器估计 (下) 的 OT 计划 (红线)。红线的透明度与运输的质量成正比。(右) 两个图节点上的边缘分布对于不同的值 ρ , 按所属聚类着色。

最后, 虽然我们的方法与用于图匹配的神经网络有一些相似之处, 但值得注意的是, 不平衡 OT 的目标从根本上不同于图匹配。

3 数值实验

在本节中, 我们在模拟数据集上的随机块模型 (SBM) 以及不同数量的聚类 and 个体脑图谱 (IBC) 数据集 [23] 的功能 MRI 激活脑表面数据集上评估并比较了 ULOT 与其他经典求解器。

3.1 模拟图上的说明和解释

数据集和训练设置 本文首先在模拟数据集上训练 ULOT, 该数据集由具有 3 个线性连接簇的随机块模型 (SBMs) 组成, 节点特征为簇类别的独热编码, 维度为 3 (1, 2 或者带有加性中心高斯噪声的 3)。为了研究由 ULOT 学习到的传输计划与传统求解器估计的传输计划的性质, 我们构建了三种不同聚类的图。第一种类型包括所有三个聚类的图 (1, 2, 3) 当存在时, 第二种类型的图具有聚类 (1, 2) 第三项有聚类 (2, 3) 所有图的数据集包含随机数量的节点, 范围从 30 到 60, 训练数据集由 50000 个模拟对组成 (G_1, G_2, ρ, α) 。通过这三种类型的图, 不平衡最优传输应能找到一个传输计划, 该计划能够匹配两个图中共有的簇, 但会忽略那些不共有的簇 (当 α, ρ 被恰当选择)。我们将 ULOT 与数值求解器 IBPP 进行比较, 后者在性能和速度之间提供了良好的平衡。




图 2: 由 ULOT 预测 (上) 和 IBPP 求解器估计 (下) 的不同值的运输计划 (红线) 示例 α 。红线的透明度与运输的质量成正比。

正则化路径相对于参数 ρ 和 α 我们首先展示了 ρ 对包含簇的图之间的预测传输计划的影响 (1, 2) 和 (2, 3)。我们在图 3 (左) 中看到, 随着 ρ 的增加, 传输质量对于 ULOT 和求解器都增加, 但求解器被困在一个质量为零的局部最小值中, 而 ULOT 能够找到一个具有质量和较低成本的计划对于 $\rho = 0.002$ 。我们在图 3 (右) 中还提供了节点边缘的正则化路径, 显示了当 ρ 增加时, 来自绿色簇 2 的节点首先接收到质量, 从而找到了簇的适当对齐。




图 5: 源图 (第 0 步) 和目标图之间的 ULOT FUGW 损失最小化的梯度下降步骤, 对于 $\alpha = 0.5$ (顶部) 和 $\alpha = 1$ (底部)。

接下来, 我们展示了两种类型为 $(1, 2, 3)$ 的图之间的 OT 计划, 对于不同值的 α , 如图 2 所示。由于节点特征带有噪声, 损失中的 Gromov-Wasserstein 和 Wasserstein 项都是预测准确计划所必需的。我们看到, 虽然 ULOT 和求解器的传输计划对于 $\alpha < 1$ 是可比的, 但对于 $\alpha = 1$, 求解器错误地匹配了簇, 因为它没有使用节点特征信息并且可以置换类别。ULOT 不会置换簇对于 $\alpha = 1$, 因为它相对于 α 是连续的, 并且已经学会了使用节点特征来找到更好的计划。

超参数优化用于预测任务 我们现在考虑图之间标签传播的任务, 其中源图上的节点标签已知, 但在目标图上部分缺失。为了推断缺失的标签, 我们将源图节点标签的一热编码传输到目标图, 生成每个节点的标签概率, 类似于在 [28, 24] 中提出的那样。当图类型可以不同时, 这种方法的关键挑战在于选择适当的 FUGW 参数 (ρ, α) , 以确保计划对标签传播相关。得益于我们的高效 ULOT 框架, 我们可以轻松计算并可视化作为参数函数的标签传播任务的准确率 (ρ, α) , 针对不同图对。由于篇幅限制, 这在补充材料的图 10 中提供。我们发现准确率表面相对平滑, 并且最优参数很大程度上取决于所运输的图类型。由于 ULOT OT 计划相对于 ρ 和 α 完全可微, 我们建议优化它们, 但将目标设为经典光滑代理准确率: 一热编码目标类与预测标签分数之间的 Kullback-Leibler 发散。我们在图 4 中展示了不同模拟图对的参数优化轨迹 (ρ, α) 。我们看到两种类型的图对之间的轨迹变化显著。确实, 在不同类型的图之间, ρ 需要较小以避免质量在两个图中均不存在的簇之间转移, 而对于相同类型的图, ρ 可以较大以允许质量在两个图中都存在的簇之间转移。有趣的是, 我们看到对于相同的图对类型, 总体趋势相似, 但轨迹收敛到不同的值, 强调了个体对参数验证的必要性。这一概念验证表明, ULOT 参数可以根据给定任务进行优化, 允许在内部优化问题为 FUGW 时实现高效的双层优化。




图 4: (α, ρ) 优化轨迹对于 (上) 不同类型 $(1, 2, 3) \rightarrow (1, 2)$, (下) 相同类型 $(1, 2, 3)$ 。

针对融合不平衡 Gromov-Wasserstein (FUGW) 损失优化图 我们方法的一个非常有趣的特点是, 预测的传输计划相对于图结构和特征而言是完全可微的。我们通过优化一个图的功能来说明这一点。给定目标图 G^* , 我们优化函数 $F(G) = L^{\alpha, \rho}(G, G^*, P_{\theta}^{\rho, \alpha}(G, G^*))$, 我们期望图 G 收敛到或接近图 G^* 。从 $G_0 = G$ 开始, 在每个时间步骤 t , 我们预测传输计划 $P_{\theta}^{\rho, \alpha}(G_t, G^*)$ 。




图 6: (左) 模拟 SBM 图之间 ULOT 传输质量的相似性矩阵, 按类型排序, 分别具有集群 (1,2), (2,3) 和 (1,2,3)。 (右) 相似性矩阵的 MDS。

在 G_t 和 G^* 之间, 计算相关的 FUGW 损失, 并使用反向传播更新图 G_t 的节点特征和最短路径距离矩阵。我们在时间步骤 $t+1$ 处通过阈值化最短路径距离矩阵恢复邻接矩阵。权衡参数 α 的影响显示在图 5 上。对于 $\alpha = 0.5$ 的轨迹表明, 该图收敛到一个具有正确标签的两簇图。相比之下, 对于 $\alpha = 1$ 的轨迹表明, 该图收敛到一个具有错误标签的两簇图。这是因为仅优化 Gromov-Wasserstein 项, 因此节点特征未被更新。

使用 ULOT 传输计划质量 FUGW 损失通过 ULOT 计划计算提供了一种有意义的图间距离, 但其计算复杂度为 $O(n_1^2 n_2 + n_2^2 n_1)$, 其中 n_1, n_2 是图节点的数量。相比之下, 计算 ULOT 传输计划的时间复杂度仅为二次。在不平衡 OT 中, 当两个图非常不同时, OT 计划的总质量 $m(P) = \sum_{i,j} P_{i,j}$ 将减少, 因为在这种情况下, 边缘违反的成本低于传输成本。这就是为什么我们建议使用 ULOT 传输计划质量作为图相似性度量 (正值且介于 0 和 1 之间)。我们在三种集群配置的合成 SBM 上评估此方法: (1,2), (2,3) 和 (1,2,3)。我们使用固定的超参数 $\alpha = 0.5$ 和 $\rho = 0.01$ 计算 ULOT 传输计划。如图 6 (左) 所示, 所得的相似性矩阵揭示了数据集的结构。此相似性矩阵可以自然地用于 (谱) 图聚类, 甚至可用于降维和可视化, 如图 6 (右) 所示, 通过相似性矩阵的多维缩放, 图类型的关联关系被清晰地恢复。

3.2 解决功能性 MRI 大脑的 FUGW 问题

数据集描述 我们现在对 ULOT 在个体脑图谱 (IBC) 数据集上进行评估 [23], 该数据集包含功能性磁共振成像在脑表面的激活数据。数据集由表面网格组成, 包含与不同 fMRI 激活相关的顶点数 160k。由于数据集侧重于个体信息, 它包括特定于个体的脑几何模型, 以及相应的个体 fMRI 激活。这证明了不平衡框架的必要性, 以便在不同个体之间大小可能变化的区域之间调整质量 [30]。

实验设置 数据集中网格的高维度使其特别适合数据增强。为了获得更多的训练图, 我们使用 Ward 算法进行分区 [29], 并将图的大小减少到 1000 个节点, 其中节点特征是分组顶点上的 fMRI 激活的平均值。数据增强包括为每个 12 个受试者生成 10 个不同的图, 作为使用随机采样的激活进行的 Ward 聚类的结果。几何信息矩阵 D 是最短路径距离矩阵, 3D 节点位置与节点激活特征连接起来以提供位置编码。我们构建了一个包含 14400 个不同图对的数据集, 并使用一个 60/20/20 训练/验证/测试分割来训练网络。我们在 C 节中提供了更多关于实验设置的细节。

与求解器在损失和时间方面的比较 我们首先比较了由 ULOT 和 IBPP 求解器预测的 OT 计划的 FUGW 损失。我们在图 7 (左) 中发现, 两种损失非常接近并且高度相关, 皮尔逊相关系数为 0.99。接下来, 我们比较了 ULOT 和其他求解器的损失误差 (相对于所有求解器中的最佳结果)




图 7: (左) ULOT 和 IBPP 求解器获得的损失比较, 虚线对应于相等。(右) ULOT 和其他求解器的损失误差与时间的关系图。彩色正方形对应于两个度量的 20-80% 分位数。




图 8: (左) ULOT 和 IBPP 求解器对于不同图尺寸的 FUGW 传输计划预测时间。(右) 带有和不带 ULOT 预热启动的 IBPP 求解器迭代过程中的损失, 报告了 20% – 80% 分位数。

在第 2.1 节中介绍的方法, 即 IBPP [39]、MM [6]、LBFGSB 和 Sinkhorn 用于熵正则化的 FUGW [8, 30], 这些方法均使用 Python 库 POT [9] 实现。从图 7 (右) 可以看出, 尽管 ULOT 存在误差, 但它比传统求解器快 100 倍, 并且比 Sinkhorn 快 10 倍, 同时具有较小的误差。对于大小为 1000 的图, 这种计算效率的提高非常重要, 因为传统求解器的时间复杂度与节点数量的立方成正比, 而 ULOT 的时间复杂度仅为二次。这一点在图 8 (左) 中得到了验证, 该图展示了计算时间随节点数量的变化。

将 ULOT 作为预热启动。当需要高精确率时, 我们可以将 ULOT 作为 IBPP 求解器的一个非常高效的预热启动。从图 8 (右) 可以看出, 使用 ULOT 作为预热启动可以使求解器更快地收敛。这意味着如果需要高精确率, 使用 ULOT 作为求解器的预热启动是一个有效的替代方案。

4 结论、局限性和未来工作

本文提出了 ULOT, 这是一种新的无监督深度学习方法, 用于预测图之间的最优传输计划, 通过最小化 FUGW 损失进行训练。我们已经证明, ULOT 能够在模拟数据集和真实数据集上预测出低误差的传输计划, 其速度比传统求解器快 100 倍。由于其低复杂度和可微性, ULOT 自然高效地适用于最小化最优传输计划的功能以及执行 FUGW 参数选择。ULOT 还允许发现使用 FUGW 传输计划的新方法, 例如使用它们的总质量作为不同大小图之间相似性或复杂度的测度 $O(n^2)$ 。虽然我们认为 ULOT 是深度学习应用于最优传输的一个很有前景的步骤, 但我们也承认它的局限性, 并提出了一些研究方向来解决这些问题。非常快速的预测是以预测传输计划中存在小误差为代价的, 这可能限制了它在需要高精确率的应用场景中的应用。虽然可以通过将 ULOT 作为求解器的预热启动来避免这一问题, 但直接预测更准确的计划仍有改进的空间。此外, 在实验中, 我们受到 GPU 内存限制, 只能处理特定大小的图 $n \leq 10000$, 进一步扩展可能需要专门开发的技术, 如惰性张量或其他节省内存的技术 [7] 来实现交叉注意力。在未来, 我们计划

将此方法应用于大规模应用，如高分辨率脑表面的激活预测和图重心的计算。尽管这些应用需要大量的训练数据集，而这并非 fMRI 数据的常态，我们计划进一步研究我们的随机分区数据增强技术，以训练一个更通用的模型，使其在不同受试者之间有效。

致谢与资金披露

本工作获得了 IDRIS 高性能计算资源的访问权限，该资源由 GENCI 分配，编号为 2025-AD011016350。本研究还部分得到了法国国家研究机构 (ANR) 通过 MATTER 项目 (ANR-23-ERCC-0006-01) 的支持。

本工作得益于由 Agence Nationale de la Recherche 管理的法国 2030 计划下的国家援助，参考号为 ANR-22-PESN-0012，并且从欧盟的地平线 2020 研究与创新框架计划下的特定赠款协议 HORIZON-INFRA-2022-SERV-B-01 中获得了资助。

最后，本工作还得到了 École polytechnique 基金会的资金支持。感谢 Quang Huy Tran 提供 FUGW 求解器的代码以及有益的讨论。

参考文献

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *The 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631, 2019.
- [2] Brandon Amos, Samuel Cohen, Giulia Luise, and Ievgen Redko. Meta optimal transport. *arXiv preprint arXiv:2206.05262*, 2022.
- [3] Brandon Amos et al. Tutorial on amortized optimization. *Foundations and Trends® in Machine Learning*, 16(5):592–732, 2023.
- [4] Richard H Byrd, Peihuang Lu, Jorge Nocedal, and Ciyu Zhu. A limited memory algorithm for bound constrained optimization. *SIAM Journal on scientific computing*, 16(5):1190–1208, 1995.
- [5] Laetitia Chapel, Mokhtar Z Alaya, and Gilles Gasso. Partial gromov-wasserstein with applications on positive-unlabeled learning. *Advances in Neural Information Processing Systems*, 2020.
- [6] Laetitia Chapel, Rémi Flamary, Haoran Wu, Cédric Févotte, and Gilles Gasso. Unbalanced optimal transport through non-negative penalized linear regression. *Advances in Neural Information Processing Systems*, 34:23270–23282, 2021.
- [7] Benjamin Charlier, Jean Feydy, Joan Alexis Glaunes, François-David Collin, and Ghislain Durif. Kernel operations on the gpu, with autodiff, without memory overflows. *Journal of Machine Learning Research*, 22(74):1–6, 2021.
- [8] Lenaïc Chizat, Gabriel Peyré, Bernhard Schmitzer, and François-Xavier Vialard. Unbalanced optimal transport: Dynamic and kantovich formulations. *Journal of Functional Analysis*, 274(11):3090–3123, 2018.
- [9] Rémi Flamary, Nicolas Courty, Alexandre Gramfort, Mokhtar Z. Alaya, Aurélie Boisbunon, Stanislas Chambon, Laetitia Chapel, Adrien Corenflos, Kilian Fatras, Nemo Fournier, Léo Gautheron, Nathalie T.H. Gayraud, Hicham Janati, Alain Rakotomamonjy, Ievgen Redko, Antoine Rolet, Antony Schutz, Vivien Seguy, Danica J. Sutherland, Romain Tavenard, Alexander Tong, and Titouan Vayer. Pot: Python optimal transport. *Journal of Machine Learning Research*, 22(78):1–8, 2021.
- [10] Zheheng Jiang, Hossein Rahmani, Plamen Angelov, Sue Black, and Bryan M Williams. Graph-context attention networks for size-varied deep graph matching. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2343–2352, 2022.
- [11] Alexander Korotin, Daniil Selikhanovych, and Evgeny Burnaev. Neural optimal transport. *arXiv preprint arXiv:2201.12220*, 2022.

- [12] Wuyang Li, Xinyu Liu, and Yixuan Yuan. Sigma: Semantic-complete graph matching for domain adaptive object detection. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 5291–5300, 2022.
- [13] Yujia Li, Chenjie Gu, Thomas Dullien, Oriol Vinyals, and Pushmeet Kohli. Graph matching networks for learning the similarity of graph structured objects. In *International conference on machine learning*, pages 3835–3845. PMLR, 2019.
- [14] Xiang Ling, Lingfei Wu, Saizhuo Wang, Tengfei Ma, Fangli Xu, Alex X Liu, Chunming Wu, and Shouling Ji. Multilevel graph matching networks for deep graph similarity learning. *IEEE Transactions on Neural Networks and Learning Systems*, 34(2):799–813, 2021.
- [15] Chang Liu, Shaofeng Zhang, Xiaokang Yang, and Junchi Yan. Self-supervised learning of visual graph matching. In *European Conference on Computer Vision*, pages 370–388. Springer, 2022.
- [16] Eliane Maria Loiola, Nair Maria Maia De Abreu, Paulo Oswaldo Boaventura-Netto, Peter Hahn, and Tania Querido. A survey for the quadratic assignment problem. *European journal of operational research*, 176(2):657–690, 2007.
- [17] Facundo Mémoli. Gromov–wasserstein distances and the metric approach to object matching. *Foundations of computational mathematics*, 11:417–487, 2011.
- [18] Aldo Moscatelli, Jason Piquenot, Maxime Bérar, Pierre Héroux, and Sébastien Adam. Graph node matching for edit distance. *Pattern Recognition Letters*, 184:14–20, 2024.
- [19] Maksim Nekrashevich, Alexander Korotin, and Evgeny Burnaev. Neural gromov-wasserstein optimal transport. *arXiv e-prints*, pages arXiv–2303, 2023.
- [20] Maks Ovsjanikov, Mirela Ben-Chen, Justin Solomon, Adrian Butscher, and Leonidas Guibas. Functional maps: a flexible representation of maps between shapes. *ACM Transactions on Graphics (ToG)*, 31(4):1–11, 2012.
- [21] Gabriel Peyré, Marco Cuturi, and Justin Solomon. Gromov-wasserstein averaging of kernel and distance matrices. In *International conference on machine learning*, pages 2664–2672. PMLR, 2016.
- [22] Chengzhi Piao, Tingyang Xu, Xiangguo Sun, Yu Rong, Kangfei Zhao, and Hong Cheng. Computing graph edit distance via neural graph matching. *Proceedings of the VLDB Endowment*, 16(8):1817–1829, 2023.
- [23] Ana Luísa Pinho, Alexis Amadon, Torsten Ruest, Murielle Fabre, Elvis Dohmatob, Isabelle Denghien, Chantal Ginisty, Séverine Becuwe-Desmidt, Séverine Roger, Laurence Laurier, et al. Individual brain charting, a high-resolution fmri dataset for cognitive mapping. *Scientific data*, 5(1):1–15, 2018.
- [24] Ievgen Redko, Nicolas Courty, Rémi Flamary, and Devis Tuia. Optimal transport for multi-source domain adaptation under target shift. In *The 22nd International Conference on artificial intelligence and statistics*, pages 849–858. PMLR, 2019.
- [25] Paul-Edouard Sarlin, Daniel DeTone, Tomasz Malisiewicz, and Andrew Rabinovich. Superglue: Learning feature matching with graph neural networks. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 4938–4947, 2020.
- [26] Vivien Seguy, Bharath Bhushan Damodaran, Rémi Flamary, Nicolas Courty, Antoine Rolet, and Mathieu Blondel. Large-scale optimal transport and mapping estimation. *arXiv preprint arXiv:1711.02283*, 2017.
- [27] Thibault Séjourné, François-Xavier Vialard, and Gabriel Peyré. The unbalanced gromov wasserstein distance: Conic formulation and relaxation. *Advances in Neural Information Processing Systems*, 34:8766–8779, 2021.
- [28] Justin Solomon, Raif Rustamov, Leonidas Guibas, and Adrian Butscher. Wasserstein propagation for semi-supervised learning. In *International Conference on machine learning*, pages 306–314. PMLR, 2014.

- [29] Bertrand Thirion, Gaël Varoquaux, Elvis Dohmatob, and Jean-Baptiste Poline. Which fmri clustering gives good brain parcellations? *Frontiers in neuroscience*, 8:167, 2014.
- [30] Alexis Thual, Quang Huy Tran, Tatiana Zemskova, Nicolas Courty, Rémi Flamary, Stanislas Dehaene, and Bertrand Thirion. Aligning individual brains with fused unbalanced gromov wasserstein. *Advances in neural information processing systems*, 35:21792–21804, 2022.
- [31] Vayer Titouan, Nicolas Courty, Romain Tavenard, and Rémi Flamary. Optimal transport for structured data with application on graphs. In *International Conference on Machine Learning*, pages 6275–6284. PMLR, 2019.
- [32] Alexander Tong, Kilian Fatras, Nikolay Malkin, Guillaume Huguet, Yanlei Zhang, Jarrid Rector-Brooks, Guy Wolf, and Yoshua Bengio. Improving and generalizing flow-based generative models with minibatch optimal transport. *arXiv preprint arXiv:2302.00482*, 2023.
- [33] Siddharth Tourani, Muhammad Haris Khan, Carsten Rother, and Bogdan Savchynskyy. Discrete cycle-consistency based unsupervised deep graph matching. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 5252–5260, 2024.
- [34] Titouan Vayer, Laetitia Chapel, Rémi Flamary, Romain Tavenard, and Nicolas Courty. Fused gromov-wasserstein distance for structured objects. *Algorithms*, 13(9):212, 2020.
- [35] Runzhong Wang, Ziao Guo, Shaofei Jiang, Xiaokang Yang, and Junchi Yan. Deep learning of partial graph matching via differentiable top-k. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 6272–6281, 2023.
- [36] Runzhong Wang, Junchi Yan, and Xiaokang Yang. Learning combinatorial embedding networks for deep graph matching. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 3056–3065, 2019.
- [37] Runzhong Wang, Junchi Yan, and Xiaokang Yang. Graduated assignment for joint multi-graph matching and clustering with application to unsupervised graph matching network learning. *Advances in neural information processing systems*, 33:19908–19919, 2020.
- [38] Tao Wang and Ziv Goldfeld. Neural entropic gromov-wasserstein alignment. *arXiv preprint arXiv:2312.07397*, 2023.
- [39] Yujia Xie, Xiangfeng Wang, Ruijia Wang, and Hongyuan Zha. A fast proximal point method for computing exact wasserstein distance. In *Uncertainty in artificial intelligence*, pages 433–453. PMLR, 2020.
- [40] Hongteng Xu, Dixin Luo, Hongyuan Zha, and Lawrence Carin Duke. Gromov-wasserstein learning for graph matching and node embedding. In *International conference on machine learning*, pages 6932–6941. PMLR, 2019.
- [41] Andrei Zanfir and Cristian Sminchisescu. Deep learning of graph matching. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2684–2693, 2018.
- [42] Zhengxin Zhang, Ziv Goldfeld, Youssef Mroueh, and Bharath K Sriperumbudur. Gromov-wasserstein distances: Entropic regularization, duality and sample complexity. *The Annals of Statistics*, 52(4):1616–1645, 2024.




图 9: (左) 模拟图中使用 ULOT 和 IBPP 求解器获得的损失比较, 虚线对应于相等值。(右) 随着 ρ 值增加的传输计划值, 颜色表示它们是否连接相同的集群或不同的集群。

附录 A 训练设置细节

计算资源 我们在 NVIDIA V100 GPU 上对网络进行了训练, 针对 IBC 数据集训练了 100 小时, 而对于较小的模拟数据集则训练了几小时。需要注意的是, 尽管网络 $O(n^2)$ 与 n 图节点的数量, 主要的训练瓶颈来自于需要计算 $O(n^3)$ 每个训练轮次中每种运输计划的 FUGW 损失。

超参数 用于在模拟图和 IBC 数据集上训练 ULOT 的超参数详见表 1。所有多层感知机和 GMN 都有一个隐藏层, 并且两个图分支之间的权重共享。此外, 在节点嵌入层中的第一个多层感知机保留了输入节点特征的维度。超参数优化是在训练数据的一个子集上使用 Optuna 库进行的 [1]。代码可以在补充材料中找到, 并将在发表后发布到 github。我们还将分享两个数据集的预训练模型权重。

表 1: ULOT 超参数

Hyperparameter	Simulated dataset	IBC dataset
Learning rate	0.001	0.0001
Batch size	256	64
Optimizer	Adam	Adam
Number of node embedding layers N	5	3
Embedding dimension for α	10	10
Node embedding layer final out dimension	256	256
MLP hidden dimension	64	256
GCN hidden dimension	16	128
Temperature value a	3	5

B 对模拟图的额外实验

比较融合不平衡 Gromov-Wasserstein (FUGW) 损失在模拟图上的 ULOT 和求解器 我们在第 3.1 节介绍的模拟 SBM 数据集上训练 ULOT, 并在从同一分布采样的新模拟图对上进行测试。我们在图 9 (左) 中发现, 类似于 IBC 数据集, ULOT 找到的运输计划具有与 IBPP 求解器获得的 FUGW 损失完全相关的 FUGW 损失。

正则化路径上的运输计划组件 $P_{i,j}$ 关于 ρ 我们预测具有聚类配置 (1, 2) 和 (2, 3) 的一对图之间的 ULOT 运输计划, 并展示不同值的 ρ 下每个运输计划条目的正则化路径 $(P_{\theta}^{\alpha, \rho})_{i,j}$ 在图 9 (右) 中对于 $i \in [1, n_1]$ 和 $j \in [1, n_2]$ 。我们观察到, 共享聚类 2 中的节点对应的运输计划值随着 ρ 的增长速度比非重叠聚类中的节点之间的值更快。此外, 我们发现存在一个最优值大约在 $\rho \simeq 0.05$, 此时运输




图 10: ULOT FUGW 运输的标签传播准确率关于 (ρ, α) 在 (左) 不同类型 $(1, 2, 3) \rightarrow (1, 2)$ 之间, 在 (右) 相同类型 $(1, 2, 3)$ 。




图 11: 从配备各自几何结构的源脑传输激活到目标脑。

运输计划的质量主要分配给与共同聚类相对应的条目, 有效地排除了无关的对应关系。

标签传播准确性的可视化 我们在图 10 中可视化了第 3.1 节介绍的标签传播任务在一系列范围内的准确率曲面 (α, ρ) 值。我们考虑两种不同类型的配对: 具有聚类的配对 $(1, 2, 3)$ 和 $(1, 2)$ 并与聚类配对 $(1, 2, 3)$ 。我们观察到准确率曲面平滑, 并且最优参数值在不同类型的配对间有所差异。我们进行优化 ρ 和 α 通过最小化预测类别概率与真实目标类别独热编码之间的 KL 发散, 对每一对图应用梯度下降算法, 其中预测类别概率由 ULOT 传输计划获得, 基于 50% 的节点。我们达到了 0.87 ± 0.092 关于具有相似聚类的配对 $(1, 2, 3)$ 和 0.74 ± 0.11 对于不同聚类的成对数据。

附录 C fMRI 对齐的说明

关于个体脑图谱 (IBC) 数据集的实验细节 我们使用 IBC 数据集的大脑皮层表面, 该数据集包含大约 16 万个顶点, 每个顶点与受试者执行特定任务时获得的功能磁共振成像 (fMRI) 对比度相关联。我们使用来自 ArchiEmotional、ArchiSocial、ArchiSpatial 和 ArchiStandard 任务的 23 个对比度, 这些任务涉及视觉运动、语言、算术、社交和情感领域。对于每位受试者, 我们使用 Ward 层次聚类算法对表面进行分区, 形成 1000 个脑区。然后将每个对比度在每个脑区的顶点上取平均值。从这种分区中, 我们构建了 1000 节点的图, 其中边连接空间相邻的区域。每个节点具有一个由区域对比度与其三维节点位置拼接而成的 26 维特征向量。为了扩充数据集, 我们通过随机选择 20% 到 40% 的任务为每位受试者生成多个分区, 这导致所有生成的大脑几何形状和激活情况的变化。最终数据集由所有可能的图对构成, 我们将其随机划分为 60% 的训练集、20% 的验证集和 20% 的测试集。

使用 ULOT 计划预测 fMRI 激活 给定两个脑图之间的 ULOT 传输计划 $P_{\theta}^{\alpha, \rho}$, 我们可以将激活 F_1 从图 G_1 传输到预测激活 F_2 于

nodes of G_2 , following the method in [30]:

$$\hat{F}_2 = \text{diag} \left(\frac{1}{(P_\theta^{\alpha, \rho})_{\#2}} \right) (P_\theta^{\alpha, \rho})^\top F_1. \quad (13)$$

我们在图 11 中可视化了传输的 fMRI 激活，该图展示了 ArchiSpatial 对比度 `rotation_side`，即受试者看到手的图像时的功能磁共振成像激活。我们在分区的脑区上可视化了激活，并观察到总体 fMRI 趋势在传输过程中得以保存。虽然这只是定性实验，但这为未来在大规模 fMRI 数据实验中使用 OT 打开了大门。