

分类薛定谔桥匹配

Grigoriy Ksenofontov^{1,2} Alexander Korotin^{1,3}

摘要

薛定谔桥 (Schrödinger Bridge, SB) 是一种强大的框架，用于解决生成建模任务，如未配对领域转换。大多数与 SB 相关的研究集中在连续数据空间 $\mathbb{R}^D$ 上，并留下了关于将 SB 方法应用于离散数据（例如有限空间上的数据）的理论和算法问题 $\mathbb{S}^D$ 。这类集合的典型例子包括现代自编码器的向量量化 (Vector Quantized, VQ) 表示的码本、文本中的标记、分子中原子的类别等 $\mathbb{S}$ 。本文提供了在离散空间中使用最近引入的迭代马尔可夫拟合 (Iterative Markovian Fitting, IMF) 过程解决 SB 问题的理论和算法基础。具体而言，我们从理论上证明了离散时间 IMF (D-IMF) 在离散空间中收敛到 SB。这使我们能够开发出一种实用的计算算法来实现 SB，我们称之为分类薛定谔桥匹配 (Categorical Schrödinger Bridge Matching, CSBM)。我们通过一系列合成数据和图像的 VQ 表示的实验展示了 CSBM 的性能。CSBM 的代码可以在这个仓库中找到。

1 引言

薛定谔桥问题 (薛定谔, 1931 年, SB) 由于与生成模型和未配对学习等现代挑战的相关性，最近引起了机器学习社区的关注。最近，提出了多种方法来解决连续空间中的 SB 问题；参见 (Gushchin 等人, 2023b) 的最新综述。

解决 SB 的一种现代方法是迭代马尔可夫拟合 (IMF) 框架 (Peluchetti, 2023; Shi 等人, 2023; Gushchin 等人, 2024b)。具体而言，在该框架内，离散时间 IMF 过程 (Gushchin 1Skoltech, 莫斯科, 俄罗斯 2MIPT, 莫斯科, 俄罗斯 3AIRI, 莫斯科, 俄罗斯。通讯作者: Grigoriy Ksenofontov <g.ksenofontov@skoltech.ru>, Alexander Korotin <a.korotin@skoltech.ru>。

Proceedings of the 42nd International Conference on Machine Learning, Vancouver, Canada. PMLR 267, 2025. Copyright 2025 by the author(s).

et al., 2024b, D-IMF) 在某些无配对学习问题上展现了有前景的结果，实现了比其前身更快的生成 (推理) 时间。

不幸的是，D-IMF 过程严重依赖于连续空间中特定 SB 设置的某些理论属性。同时，大量的现实世界数据要么本质上是离散的，如文本 (Austin 等, 2021; Gat 等, 2024)、分子图 (Vignac 等, 2022; Qin 等, 2024; Luo 等, 2024)、序列 (Campbell 等, 2024) 等，要么是通过构造离散化的，如图像和音频的向量量化表示 (Van Den Oord 等, 2017; Esser 等, 2021)。这些情况突显了一个根本性的局限性，即 D-IMF 不能直接应用于此类数据。在本研究中，我们通过以下贡献来解决这一差距：

- **理论。**我们提供了将 D-IMF 应用于离散空间中解决 SB 问题的理论基础。
- **实践。**本文提供了一种计算算法，用于在离散空间中实现 D-IMF。

符号。考虑状态空间 $\mathcal{X}$ 和时间集合 $\{t_n\}_{n=0}^{N+1}$ ，其中 $0 = t_0 < t_1 < \dots < t_N < t_{N+1} = 1$ 是 $N \geq 1$ 个时间点。空间 $\mathcal{X}^{N+2}$ 被称为路径空间，表示所有可能的轨迹 $(x_0, x_{\text{in}}, x_{t_{N+1}})$ ，其中 x_{in} 定义 $\stackrel{\text{def}}{=} (x_{t_1}, \dots, x_{t_N})$ 对应中间状态。令 $\mathcal{P}(\mathcal{X}^{N+2})$ 为路径上的概率分布空间。每个 $q \in \mathcal{P}(\mathcal{X}^{N+2})$ 可以解释为一个离散时间的 $\mathcal{X}$ 值随机过程。我们使用 $q(x_0, x_{\text{in}}, x_{t_{N+1}})$ 来表示其在 $(x_0, x_{\text{in}}, x_{t_{N+1}}) \in \mathcal{X}^{N+2}$ 处的密度，并使用 $q(\cdot|\cdot)$ 来表示其条件分布，例如 $q(x_1|x_0), q(x_{\text{in}}|x_0, x_1)$ 。最后，我们引入 $\mathcal{M}(\mathcal{X}^{N+2}) \subset \mathcal{P}(\mathcal{X}^{N+2})$ 作为所有马尔可夫过程 q 的集合，即满足等式

$$q(x_0, x_{\text{in}}, x_{t_{N+1}}) = q(x_0) \prod_{n=1}^{N+1} q(x_{t_n}|x_{t_{n-1}})$$
 的过程。

2 背景及相关工作

本节回顾薛定谔桥 (Schrödinger Bridge, SB) 问题的表述及其现有方法，重点在于其生成应用。我们首先讨论静态 SB 问题 (§2.1)。接着，我们强调将 SB 方法从连续状态空间扩展到离散状态空间所面临的挑战 (§2.3)。然后，我们转向动态 SB 的表述，

阐述其在实践中的重要性（§2.4）。这引出了迭代马尔可夫拟合（Iterative Markovian Fitting, IMF）程序及其离散时间变体 D-IMF（§2.5）。最后，我们总结已知的 SB 特征（表 1），并确定我们的研究对象，即为离散状态和时间设定建立理论保证（§2.6）。

2.1 静态薛定谔桥问题

考虑两个分布 $p_0, p_1 \in \mathcal{P}(\mathcal{X})$ 以及所有边缘分布分别为 p_0, p_1 的分布 $q \in \mathcal{P}(\mathcal{X}^2)$ 。这样的分布集合 $\Pi(p_0, p_1) \subset \mathcal{P}(\mathcal{X}^2)$ 被称为运输计划集。此外，假设给定一个参考分布 $q^{\text{ref}} \in \mathcal{P}(\mathcal{X}^2)$ 。

静态薛定谔桥 (SB) 问题 (Schrödinger, 1931; Léonard, 2013) 在于寻找最接近 q^{ref} 的运输计划 $q \in \Pi(p_0, p_1)$ ，其衡量标准为 Kullback-Leibler(KL) 发散度：

$$q^*(x_0, x_1) = \operatorname{argmin}_{q \in \Pi(p_0, p_1)} \text{KL}(q(x_0, x_1) || q^{\text{ref}}(x_0, x_1)), \quad (1)$$

在对问题组件 $(\mathcal{X}, p_0, p_1, q^{\text{ref}})$ 进行轻微假设的情况下，该问题的解 q^* 唯一存在；它被称为静态 SB。

值得注意的是，静态 SB 问题等价于另一个著名的熵正则化最优传输 (EOT) 问题 (Cuturi, 2013)。实际上，(1) 可以写作

$$\begin{aligned} \min_{q \in \Pi(p_0, p_1)} \mathbb{E}_{q(x_0, x_1)} \log \frac{q(x_0, x_1)}{q^{\text{ref}}(x_0, x_1)} &= \\ \min_{q \in \Pi(p_0, p_1)} \left\{ \mathbb{E}_{q(x_0, x_1)} \underbrace{[-\log q^{\text{ref}}(x_0, x_1)]}_{\stackrel{\text{def}}{=} c(x_0, x_1)} - H(q) \right\} &= \\ \min_{q \in \Pi(p_0, p_1)} \left\{ \mathbb{E}_{q(x_0, x_1)} c(x_0, x_1) - H(q) \right\}, \quad (2) \end{aligned}$$

其中 $H(q)$ 表示运输计划的熵 $q(x_0, x_1)$ 而 $c(x_0, x_1)$ 是一个运输代价函数。

2.2 实用的学习设置

在过去十年中，由于 SB/EOT 问题与实际任务的相关性，研究人员在多项研究中探讨了这些问题 (Peyr'e 等, 2019; Gushchin 等, 2023b)。本文考虑以下学习设置，通常称为生成式设置。

假设学习者获得经验数据集 $\{x_0^m\}_{m=1}^M \subset \mathcal{X}$ 和 $\{x_1^k\}_{k=1}^K \subset \mathcal{X}$ ，它们分别是未知数据分布 p_0 和 p_1 的独立同分布样本。目标是利用这些样本找到分布 p_0, p_1 之间 SB 问题 (2) 的解 $\hat{q} \approx q^*$ 。该解应允许进行样本外估计，即对于任意的 x_0^{new} ，应当能够生成新的 $x_1^{\text{new}} \sim \hat{q}(x_1 | x_0^{\text{new}}, 0)$ 。

在相关文献中，这种设置主要是在未配对（无监督）领域转换的背景下进行探讨的。在这个任务中，数据集由来自两个不同数据分布（领域）的样本组成，目标是从一个领域学习到另一个领域的转换 (Zhu 等, 2017, 图 2)。这个问题本质上是不适定的，因为理论上可能存在多种可能的转换。在许多未配对学习的应用中，保持语义信息在转换过程中至关重要，例如，在图像到图像转换中的图像内容。因此，SB 和 EOT 是适合此任务的工具，它们允许通过选择参考分布 q^{ref} 在 (1) 式或运输成本 c 在 (2) 式来控制所学转换的属性。在过去的几年里，已经开发了许多这样的 SB/EOT 方法用于未配对学习；参见 (Gushchin 等, 2023b) 的综述。

2.3 离散和连续状态空间 $\mathcal{X}$ in SB

大多数方法 (Mokrov 等, 2024; De Bortoli 等, 2021; Vargas 等, 2021; Gushchin 等, 2023a; 2024b; Korotin 等, 2024; Gushchin 等, 2024a; Shi 等, 2023; Liu 等, 2022a; Chen 等, 2022) 使用神经网络进行近似 q^* ，并特别关注在连续状态空间中解决 SB 问题，e.g., $\mathcal{X} = \mathbb{R}^D$ 。这使我们能够将 SB 应用于许多未配对的转换问题，例如上述的图像到图像转换或与单细胞数据分析和建模相关的生物任务 (Pariset 等, 2023; Tong 等, 2024)。

尽管计算 SB 方法取得了进展，但在将这些生成方法适应离散状态空间时仍存在重大挑战 $\mathcal{X}$ ：

1. 其基础方法论原则大多与离散空间不兼容 $\mathcal{X}$ 。例如，(Shi 等, 2023; Gushchin 等, 2023a; Vargas 等, 2021; Liu 等, 2022a) 使用随机微分方程 (SDE)，这些方程在离散空间中并不容易推广和应用；(Mokrov 等, 2024) 严重依赖于从未归一化的密度中进行 MCMC 采样，这也是在大型离散空间中的一项独立挑战 $\mathcal{X}$ ；(Gushchin 等, 2024a; Korotin 等, 2024; Gushchin 等, 2024b) 只能在具有二次成本的 EOT 问题上理论上适用 $\mathcal{X} = \mathbb{R}^D$ ，等等。

2. 将任何生成建模技术扩展到离散数据通常是一个挑战。例如，像 GANs (Goodfellow 等, 2014 年) 这样的模型需要通过生成器进行反向传播——对于离散数据通常是通过与 Gumbel 技巧相关的启发式方法来实现 (Jang 等, 2017 年)；流匹配方法 (Liu 等, 2022b) 可以用于离散数据 (Gat 等, 2024 年)，但需要大量的方法论改变等等。

同时，现代数据中有相当一部分是

本质上离散的，正如在 §1 中讨论的那样。尽管它普遍存在，但薛定谔桥框架在离散空间的应用仍然不成熟，这促使我们关注这一领域。

假设状态空间 $\mathcal{X}$ 是离散的，并表示为 $\mathcal{X} = \mathbb{S}^D$ 。这里， $\mathbb{S}$ 是一个有限集，为了方便起见，我们称其为类别空间，例如 $\mathbb{S} = \{1, 2, \dots, S\}$ 。也可以考虑使用 $\mathcal{X} = \mathbb{S}_1 \times \dots \times \mathbb{S}_D$ 来表示 D 类别集。这不会产生任何原则性的差异，因此我们使用 $\mathbb{S}_1 = \dots = \mathbb{S}_D$ 以使论文表述简单。

离散 EOT 方法。为了完整性起见，我们提到存在一个广泛的研究领域，称为离散 EOT，它可能与我们的工作密切相关。这包括著名的 Sinkhorn 算法 (Cuturi, 2013) 和基于梯度的方法 (Dvurechensky 等人, 2018; Dvurechenskii 等人, 2018)。然而，这些算法与我们的工作不相关，因为它们考虑的是生成设置之外的不同场景 (§2.2)，并且针对不同的问题。具体来说，离散 EOT 假设可用的数据样本本身就是离散分布，即 $p_0 = \frac{1}{M} \sum_{m=1}^M \delta_{x_0^m}$ ， $p_1 = \frac{1}{K} \sum_{k=1}^K \delta_{x_1^k}$ (权重可以是非均匀的)，目标是找到一个双随机矩阵 $\in \mathbb{R}^{M \times K}$ (即离散 EOT 计划) 最优地匹配给定样本。由于该矩阵是一个离散对象，此类方法被称为离散方法。文献 (Hütter & Rigollet, 2021; Pooladian & Niles-Weed, 2021; Manole 等, 2024; Deb 等, 2021) 旨在通过提供外推估计器来推进离散 EOT 方法在生成设置中的应用。然而，这些方法仅适用于连续状态空间 $\mathcal{X} = \mathbb{R}^D$ 。离散求解器是否可以在离散空间的生成场景中使用仍是一个开放问题 $\mathcal{X} = \mathbb{S}^D$ 。

2.4 从静态到动态 SB 问题

静态 SB 问题 (1) 可以被视为寻找一个在特定时刻作用的随机过程的问题 $t = 0, 1$ 。通常，人们会通过引入额外的时间点来扩展这个问题 (De Bortoli 等, 2021; Gushchin 等, 2024b)。我们引入 $N \geq 1$ 中间时间点 $0 = t_0 < t_1 < \dots < t_N < t_{N+1} = 1$ ，扩展 q 到这些时刻。因此， q 成为一个跨越所有时间步长状态的过程，即， $q \in \mathcal{P}(\mathcal{X}^{N+2})$ 类似静态公式 (1)，给定边缘分布 $p_0, p_1 \in \mathcal{P}(\mathcal{X})$ 通过参考过程 $q^{\text{ref}} \in \mathcal{P}(\mathcal{X}^{N+2})$ 然后动态薛定谔桥问题为

$$\min_{q \in \Pi_N(p_0, p_1)} \text{KL}(q(x_0, x_{\text{in}}, x_1) || q^{\text{ref}}(x_0, x_{\text{in}}, x_1)), \quad (3)$$

其中 $\Pi_N(p_0, p_1) \subset \mathcal{P}(\mathcal{X}^{N+2})$ 是所有离散时间随机过程的集合，其初始和终端边缘

分布为 p_0 和 p_1 。进而，该问题的解 q^* 本身成为了一个取值为 $\mathcal{X}$ 的随机过程。请注意：

$$\begin{aligned} \text{KL}(q(x_0, x_{\text{in}}, x_1) || q^{\text{ref}}(x_0, x_{\text{in}}, x_1)) = \\ \text{KL}(q(x_0, x_1) || q^{\text{ref}}(x_0, x_1)) + \\ \mathbb{E}_{q(x_0, x_1)} [\text{KL}(q(x_{\text{in}} | x_0, x_1) || q^{\text{ref}}(x_{\text{in}} | x_0, x_1))] . \end{aligned} \quad (4)$$

由于条件分布 $q(x_{\text{in}} | x_0, x_1)$ 可以独立于 $q(x_0, x_1)$ 选择，我们可以考虑 $q(x_{\text{in}} | x_0, x_1) = q^{\text{ref}}(x_{\text{in}} | x_0, x_1)$ 。由此得出第二项对于每一个 x_0, x_1 都变为 0。结果表明，时间 $t = 0, 1$ 的动态 SB (3) 的联合分布 $q^*(x_0, x_1)$ 是给定参考分布由 $q^{\text{ref}}(x_0, x_1)$ 的静态 SB (1) 的解。

到此为止，读者可能会自然地质疑：为何要考虑更为复杂的动态 SB，尤其是考虑到它最终归结为更简单的静态 SB？

简而言之，动态解法允许利用所谓的互逆性和马尔可夫性质 q^* (将在下文讨论)，这些性质可以有效地用于开发 SB 的计算算法 (Liu 等, 2023; Shi 等, 2023; Peluchetti, 2023)。事实上，大多数在文章开头列出的计算方法 §2.3 都基于动态 SB 公式。虽然一些方法 (De Bortoli 等, 2021; Gushchin 等, 2024b) 考虑离散时间且有限的时间点的公式 (3) N 而 (Shi 等, 2023; Chen 等, 2022; Gushchin 等, 2024a) 则处理连续时间 $t \in [0, 1]$ 。非正式地，可以将其识别为离散时间但 $N = \infty$ 在后续讨论中，我们将以这种方式指代连续时间情况，以避免不必要的对象和符号。

本文的研究范围仅限于动态 SB ($N < \infty$) 的离散时间情形，因为这种形式更便于分析和理解。

为了结束本节，我们引入一个与动态 SB 特别相关的定义。

互逆过程。一个过程 $r \in \mathcal{P}(\mathcal{X}^{N+2})$ 被称为相对于参考过程 q^{ref} 的互逆过程，如果给定端点条件下的分布 x_0, x_1 与参考过程的分布相匹配，即：

$$r(x_{\text{in}} | x_0, x_1) = q^{\text{ref}}(x_{\text{in}} | x_0, x_1).$$

对于参考过程 q^{ref} 的所有互逆过程集合表示为 $\mathcal{R}^{\text{ref}}(\mathcal{X}^{N+2}) \subset \mathcal{P}(\mathcal{X}^{N+2})$ 。

2.5 迭代马尔可夫拟合 (IMF) 程序

在实践中，最常考虑的动态 SB 情形是当 $q^{\text{ref}} \in \mathcal{M}(\mathcal{X}^{N+2}) \subset \mathcal{P}(\mathcal{X}^{N+2})$, i.e., q^{ref} is a

	Continuous time ($N = \infty$)		Discrete time ($N < \infty$)	
	Theory (SB characterization)	Practice (SB algorithm)	Theory (SB characterization)	Practice (SB algorithm)
Continuous space $\mathcal{X} = \mathbb{R}^D$	Theorem 3.2 (Léonard et al., 2014)	DSBM §4 (Shi et al., 2023)	Theorem 3.1 (Gushchin et al., 2024b)	ASBM §3.5 (Gushchin et al., 2024b)
Discrete space $\mathcal{X} = \mathbb{S}^D$		DDSBM §3.1 (Kim et al., 2024)	Our work (§3)	

表 1. SB 问题设置及其现有 (D-)IMF 相关结果的总结。该表列出了描述 SB 解（作为两个给定分布之间唯一的既是马尔可夫过程又是互惠过程）的理论陈述，这使得可以应用 (D-)IMF 过程来证明性地获得 SB 解 q^* ，参见 (Shi 等, 2023, 定理 8)。该表还列出了相关的计算算法。

马尔可夫过程。在这种情况下，求解 q^* SB 的方法也被认为是一种马尔可夫过程。这一特性促使研究人员开发了迭代马尔可夫拟合 (IMF) 程序，基于随机过程的马尔可夫和互逆投影来解决 SB 问题。

最初，国际货币基金组织程序 (Peluchetti, 2023; Shi 等, 2023) 被视为连续时间 ($N = \infty$)，但最近，该程序已扩展到有限的时间点 (Gushchin 等, 2024b), i.e., $N < \infty$)。我们回顾他们在有限时间上的投影定义 N 。在这种情况下，该过程被称为 **D-IMF** (离散时间 IMF)。

互逆投影。考虑一个过程 $q \in \mathcal{P}(\mathcal{X}^{N+2})$ 。那么相对于参考过程 q^{ref} 的互逆投影 $\text{proj}_{\mathcal{R}^{\text{ref}}}(q)$ 是由以下过程给出的：

$$[\text{proj}_{\mathcal{R}^{\text{ref}}}(q)](x_0, x_{\text{in}}, x_1) = q^{\text{ref}}(x_{\text{in}}|x_0, x_1)q(x_0, x_1).$$

马尔可夫投影。考虑 $q \in \mathcal{P}(\mathcal{X}^{N+2})$ 。则马尔可夫投影 $\text{proj}_{\mathcal{M}}(q)$ 由下式给出：

$$\begin{aligned} [\text{proj}_{\mathcal{M}}(q)](x_0, x_{\text{in}}, x_1) &= \\ &= \underbrace{q(x_0) \prod_{n=1}^{N+1} q(x_{t_n}|x_{t_{n-1}})}_{\text{forward representation}} \\ &= \underbrace{q(x_1) \prod_{n=1}^{N+1} q(x_{t_{n-1}}|x_{t_n})}_{\text{backward representation}} \end{aligned} \quad (5)$$

显然，互逆投影保持联合分布 $q(x_0, x_1)$ 过程在时间点上 $t = 0, 1$ 马尔可夫投影通常会改变 $q(x_0, x_1)$ 但保留联合分布 $\{q(x_{t_n}, x_{t_{n-1}})\}_{n=1}^{N+1}$ 在相邻的时间点和边缘分布 $q(x_{t_n})$ 。

D-迭代马尔可夫拟合 (IMF) 程序 被初始化为任意过程 $q^0 \in \Pi_N(p_0, p_1)$ 然后该过程在

互逆 $\text{proj}_{\mathcal{R}^{\text{ref}}}$ 马尔可夫 $\text{proj}_{\mathcal{M}}$ 投影：

$$\begin{aligned} q^{2l+1} &= \text{proj}_{\mathcal{R}^{\text{ref}}}(q^{2l}), \\ q^{2l+2} &= \text{proj}_{\mathcal{M}}(q^{2l+1}). \end{aligned} \quad (6)$$

由于马尔可夫投影和互逆投影分别保持边缘分布 p_0, p_1 在特定时间点上 $t = 0, 1$ 因此，对于 $q^l \in \Pi_N(p_0, p_1)$ 在某些配置下 $N, \mathcal{X}, q^{\text{ref}}$ IMF 可证明收敛到动态 SB q^*

in KL, i.e., $\lim_{l \rightarrow \infty} \text{KL}(q^l \| q^*) = 0$ 。具体而言，收敛性很容易从 (Shi 等, 2023 年, 定理 8) 中的通用证明论据得出，只要知道 q^* 是 $\Pi_N(p_0, p_1)$ 中唯一既是马尔可夫过程又是互惠过程的过程。我们提供了表 1，总结了已知 SB 特性的配置。我们还列出了相关的实用算法。

最后，我们想强调的是，(D-)IMF 过程的收敛速率显著依赖于时间步数 N 。事实上，对于每个 N ，它都是一个具有不同马尔可夫投影 (5) 的独立过程，参见 (Gushchin 等, 2024b, 图 6a)。

2.6 研究对象

从表 1 中可以看出，在离散空间的设置下 $\mathcal{X} = \mathbb{S}^D$ 以及有限数量的时间点 $N < \infty$ ，目前尚无理论保证 SB 是唯一的马尔可夫和互易过程。这在该情况下给 D-IMF 的应用留下了很大的空白，本文将填补这一空白。

同时，我们注意到最近有一种基于 IMF 的算法 DDSBM (Kim 等人, 2024)，适用于离散状态空间 $\mathcal{X}$ 但连续时间的情形 ($N = \infty$)。然而，由于在实际应用中处理连续时间不可行，作者将时间网格离散化为一个较大的有限值 N 。因此，作者应用了 D-IMF 过程，尽管在这种情况下仍缺乏理论基础。相比之下，我们的工作表明理论上甚至 $N = 1$ 就足够了。

3 类别薛定谔桥匹配

我们首先建立 D-IMF 框架 ($N < \infty$) 在一般马尔可夫参考过程 (§3.1) 下收敛到 SB 的证明, 证明过程见附录 B。然后, 我们提供了一种实用的优化方法及所提方法的实现细节 (§3.2)。

3.1 理论基础

(Gushchin 等人, 2024b, 定理 3.6) 的结果刻画了在 $\mathcal{X} = \mathbb{R}^D$ 和 $N < \infty$ 中的 SB 解作为唯一的马尔可夫过程和互惠过程, 允许使用 D-IMF 程序。然而, 该证明假设了一个由维纳过程 W 诱导的特定参考过程 $q^{\text{ref}} = q^W$ (具有二次成本的 EOT), 因此无法处理一般的马尔可夫过程 q^{ref} 或离散情形 $\mathcal{X}$ 。

以下是我们在离散空间 $\mathcal{X}$ 和一般的马尔可夫参考过程 q^{ref} 下关于 SB 的主要理论结果, 该结果立即允许使用 D-IMF ($N < \infty$) 程序来获得它。¹

定理 3.1 (离散空间上的动态 SB 问题解的特征, 其参考过程为马尔可夫过程 $[Q_n]$ 令 q^{ref})。为有限离散空间, 令 $\mathcal{X}$ 为具有全支撑的概率分布 $[p_0, p_1] \in \mathcal{P}(\mathcal{X})$ 设 $[q^{\text{ref}}] \in \mathcal{M}(\mathcal{X}^{N+2})$ 是在 $\mathcal{X}^{N+2}$ 上具有全支撑的参考马尔可夫过程。若 $[q^*] \in \mathcal{P}(\mathcal{X}^{N+2})$ 满足以下条件:

1. $q^*(x_0) = p_0(x_0)$ and $q^*(x_1) = p_1(x_1)$, i.e., $q^*(x_0, x_1)$ is a **transport plan** from $\Pi(p_0, p_1)$;
2. $q^* \in \mathcal{M}(\mathcal{X}^{N+2})$ and $q^* \in \mathcal{R}^{\text{ref}}(\mathcal{X}^{N+2})$, i.e., q^* is both the **reciprocal** and **Markov**,

then q^* is the unique solution of the dynamic SB (3).

Our theorem immediately yields the following corollary.

推论 3.2 (离散空间上 D-IMF 的收敛性)。该序列 $\{q^l\}^\infty$ 由 D-IMF 程序在离散空间上生成 $\mathcal{X}$ 并且对于上述定理中的马尔可夫参考过程 q^{ref} 收敛到 q^* in KL:

$$\lim_{l \rightarrow \infty} KL(q^l \| q^*) = 0.$$

3.2 实用实现

在本小节中, 我们讨论用于实现 D-IMF 并获得 SB 问题解的计算算法 q^* 。

由于我们考虑有限的数量 N 时间步长, 过程 $q \in \mathcal{P}(\mathcal{X}^{N+2})$ 是离散时间马尔可夫链

¹ 事实上, 我们的证明方法可以应用于任何 $\mathcal{X}$, 即不仅限于离散情况, 因此, 连续 $\mathcal{X} = \mathbb{R}^D$ 的 ASBM 算法 (Gushchin 等, 2024b) 可以应用于一般的马尔可夫 q^{ref} 。

(离散时间马尔可夫链)。离散时间马尔可夫链由 $N+1$ 大小的转移矩阵定义 Q_n $|\mathcal{X}| \times |\mathcal{X}|$, 其中 $[Q_n]_{x_t, x_{t-1}}$ 表示从状态 x_{t-1} 转移到状态 x_t 的概率:

$$q(x_t | x_{t-1}) = [Q_n]_{x_{t-1}, x_t}.$$

因此, 在理论上, 可以对任何这样的离散时间马尔可夫链 (DTMC) 进行建模 q 明确地。然而, 在实际应用中, 大小 $|\mathcal{X}|$ 可能较大。特别是, 我们考虑以下情况 $\mathcal{X} = \mathbb{S}^D$, 其中 $\mathbb{S}$ 是一个分类空间, 导致指数数量 S^D 元素的 $\mathcal{X}$ 。

这引发了两个自然的问题: (a) 如何选择参考过程 q^{ref} 并与其配合工作? 以及 (b) 如何在 D-IMF 步骤中对过程 q 进行参数化和更新? 这两个问题将在接下来关于互逆投影和马尔可夫投影的参数化与实现的一般讨论中得到解答。

3.2.1 实现互逆投影。 如果我们可以从当前过程 $q(x_0, x_1)$ 和参考桥 $q^{\text{ref}}(x_{t_{n-1}} | x_0, x_1)$ 中抽取样本, 那么互逆投影就相当直接。实际上, 抽样 $(x_0, x_{t_{n-1}}, x_1) \sim \text{proj}_{\mathcal{R}^{\text{ref}}}(q)$ 只不过是这两个样本合并。

3.2.2 选择参考过程。 从上文可以看出, 考虑易于从其桥梁 $q^{\text{ref}} \in \mathcal{M}(\mathcal{X}^{N+2})$ 进行采样的参考过程

$q^{\text{ref}}(x_{t_{n-1}} | x_0, x_1)$ 是合理的。我们给出两个在相关工作中出现的流行例子 q^{ref} , 这些例子导致了 EOT (2) 的实际有意义的成本 c 。对于这两个例子, 我们从维度 $D = 1$ 开始。

情形 1 (均匀参考 q^{unif}). 在这种情况下, 我们假设类别集合 $\mathbb{S}$ 是无序的, 例如原子类型、文本标记、隐变量等。定义一个过程, 在该过程中状态停留在当前类别 $x_{t_{n-1}}$ 的概率较高, 而剩余的概率均匀分布在所有其他类别上。此过程 q^{unif} 被称为均匀过程, 并具有转移矩阵 Q_n :

$$[Q_n]_{x_{t_{n-1}}, x_t} = \begin{cases} 1 - \alpha, & \text{if } x_t = x_{t_{n-1}}, \\ \frac{\alpha}{S-1}, & \text{if } x_t \neq x_{t_{n-1}}, \end{cases} \quad (7)$$

其中 $\alpha \in [0, 1]$ 是控制转换到不同类别概率的随机参数。

情形 2 (高斯参考 q^{gauss}). 如果我们知道类别是有顺序的, 具体来说, $\mathbb{S} = (1, 2, \dots, S)$, 并且假设两个相邻的类别是相关的, 那么可以将转换选择为反映这一点。考虑类似高斯的参考过程 q^{gauss} 具有 $[Q_n]_{x_{t_{n-1}}, x_t} =$

$$\begin{cases} \frac{\exp\left(-\frac{4(x_t - x_{t_{n-1}})^2}{(\alpha\Delta)^2}\right)}{\sum_{\delta=-\Delta}^{\Delta} \exp\left(-\frac{4\delta^2}{(\alpha\Delta)^2}\right)}, & x_t \neq x_{t_{n-1}}, \\ 1 - \sum_{x_t \neq x_{t_{n-1}}} [Q_n]_{x_{t_{n-1}}, x_t}, & x_t = x_{t_{n-1}}, \end{cases} \quad (8)$$

其中 $\alpha > 0$ 是方差参数的类似物, 而 $\Delta = S - 1$ 是类别之间的最大距离。

维度 $D > 1$. 构造 q^{unif} (或 q^{gauss}) 通过结合几个这样的独立过程 (每个维度一个) 推广到更高 D 。桥梁 $q^{\text{ref}}(x_{\text{in}}|x_0, x_1)$ 可以借助马尔可夫性质和贝叶斯公式轻松地进行解析推导和采样。

关于参考过程的构建与选择的更多细节 q^{ref} ，请参见附录 D.1。

3.2.3 可学习过程的参数化。 空间中有 $|\mathbb{S}^D| = S^D$ 种可能的状态 $x = (x^1, \dots, x^D)$ ，其中 S 是每个变量的类别数量。因此，每个转移矩阵 Q_n 的大小为 $S^D \times S^D$ ，即维度 D 呈指数级增长。由于这一点，显式建模我们所学习的过程的转移矩阵在计算上是不可行的。我们遵循离散生成模型中的标准做法 (Hoogeboom 等, 2021; Austin 等, 2021; Gat 等, 2024; Campbell 等, 2024)，并通过结合两种流行的技术来建模转移概率：后验采样和维度上的分解。首先，我们将转移参数化如下： $q_\theta(x_{t_n}|x_{t_{n-1}})$

$$q_\theta(x_{t_n}|x_{t_{n-1}}) = \mathbb{E}_{\tilde{q}_\theta(\tilde{x}_1|x_{t_{n-1}})}[q^{\text{ref}}(x_{t_n}|x_{t_{n-1}}, \tilde{x}_1)], \quad (9)$$

其中 $\tilde{q}_\theta(\tilde{x}_1|x_{t_{n-1}})$ 是一个可学习的分布。这种参数化假设给定 $x_{t_{n-1}}$ 后对 x_{t_n} 的采样可以通过首先采样某个“端点” $\tilde{x}_1 \sim \tilde{q}_\theta(\tilde{x}_1|x_{t_{n-1}})$ ，然后从桥梁 $q^{\text{ref}}(x_{t_n}|x_{t_{n-1}}, \tilde{x}_1)$ 中采样来完成。其次，对于 $\tilde{q}_\theta(\tilde{x}_1|x_{t_{n-1}})$ 的参数化是分解为：

$$\tilde{q}_\theta(\tilde{x}_1|x_{t_{n-1}}) \approx \prod_{d=1}^D \tilde{q}_\theta(\tilde{x}_1^d|x_{t_{n-1}}^d).$$

在这种情况下，对于每个 $x_{t_{n-1}}$ ，我们只需要预测一个行随机的概率矩阵 $D \times S$ $\tilde{q}_\theta(\tilde{x}_1^d|x_{t_{n-1}}^d)$ 。关于这种方法的局限性的讨论，请参见附录 A。遵循常见的做法，我们采用一个神经网络 $S^D \rightarrow D \times S$ ，它为每个输入输出一个行随机矩阵 $x_{t_{n-1}}$ 。通常，在每个时间步骤预测端点会需要针对每个步骤的不同模型 $n-1 \dots N+1$ $\tilde{q}_\theta(\tilde{x}_1|x_{t_{n-1}})$ 。

相反，我们使用一个带有额外输入表示时间步的单一神经网络。

3.2.4 实现马尔可夫投影。 马尔可夫投影比互逆投影稍微复杂一些，并需要学习一个过程。从 §2.5，投影的目标是找到一个其转移概率与给定互逆过程相同的马尔可夫过程 q 。幸运的是，我们证明这可以通过最小化一个目标来实现，该目标与扩散模型中使用的变分界优化非常相似 (Ho 等, 2020; Austin 等, 2021; Hoogeboom 等, 2021)。

命题 3.3. 设 $q \in \mathcal{R}^{\text{ref}}(\mathcal{X}^{N+2})$ 是一个给定的互逆过程。那么，马尔可夫投影 $\text{proj}_{\mathcal{M}}(q) \in \mathcal{M}(\mathcal{X}^{N+2})$ 可以通过最小化以下内容获得：

Algorithm 1 Categorical SB matching (CSBM)

Input: number of intermediate time steps N ;
number of outer iterations $L \in \mathbb{N}$;
initial coupling $q^0(x_0, x_1)$;
reference process q^{ref} .

Output: forward model $q_\theta(x_{t_n}|x_{t_{n-1}})$;
backward model $q_\eta(x_{t_{n-1}}|x_{t_n})$.

for $l = 1$ **to** L **do**

Forward step (repeat until convergence):

 Sample $n \sim U[1, N+1]$;

 Sample $(x_0, x_1) \sim p_1(x_1) \prod_{n=1}^{N+1} q_\eta(x_{t_{n-1}}|x_{t_n})$;

 Sample $x_{t_{n-1}} \sim q^{\text{ref}}(x_{t_{n-1}}|x_0, x_1)$;

 Train q_θ by minimizing L_θ (21);

Backward step (repeat until convergence):

 Sample $n \sim U[1, N+1]$;

 Sample $(x_0, x_1) \sim p_0(x_0) \prod_{n=1}^{N+1} q_\theta(x_{t_n}|x_{t_{n-1}})$;

 Sample $x_{t_n} \sim q^{\text{ref}}(x_{t_n}|x_0, x_1)$;

 Train q_η by minimizing L_η (22);

end for

$$L(m) \stackrel{\text{def}}{=} \mathbb{E}_{q(x_0, x_1)} \left[\sum_{n=1}^N \mathbb{E}_{q^{\text{ref}}(x_{t_{n-1}}|x_0, x_1)} \left[\text{KL} \left(q^{\text{ref}}(x_{t_n}|x_{t_{n-1}}, x_1) \| m(x_{t_n}|x_{t_{n-1}}) \right) - \mathbb{E}_{q^{\text{ref}}(x_{t_N}|x_0, x_1)} [\log m(x_1|x_{t_N})] \right] \right], \quad (10)$$

在所有马尔可夫过程之中 $m \in \mathcal{M}(\mathcal{X}^{N+2})$ 。此外，这个目标也等价于优化

$$\sum_{n=1}^{N+1} \mathbb{E}_{q(x_{t_{n-1}})} \text{KL} \left(q(x_{t_n}|x_{t_{n-1}}) \| m(x_{t_n}|x_{t_{n-1}}) \right).$$

需要注意的是，与扩散模型中的标准损失函数，如 (Austin 等人, 2021 年, 方程 1) 的关键区别在于对 $x_{t_{n-1}}$ 的采样方式。不是从加噪过程 $q^{\text{ref}}(x_{t_{n-1}}|x_1)$ 中抽取样本，而是从参考桥分布 $q^{\text{ref}}(x_{t_{n-1}}|x_0, x_1)$ 中进行采样。因此，通过所提出的参数化和马尔可夫投影表示，可以有效地应用 D3PM (Austin 等人, 2021 年) 的学习方法。明确的损失函数形式在附录 D.2 中给出。

3.2.5 D-IMF 过程的实用实现。 在互逆和马尔可夫投影完全建立后，我们现在进行 D-IMF 过程的实现。该方法通常以双向方式进行应用 (Shi 等人, 2023; Gushchin 等人, 2024b)，结合正向和反向表示 (5)。这是因为单向训练已被证明会引入 IMF 中的误差 (De Bortoli 等人, 2024, 附录 I)。因此，我们遵循双向方法，这自然导致了分类薛定谔桥匹配 (CSBM) 算法 1。

4 实验说明

我们对 CSBM 算法进行了多项设置下的评估。首先，我们分析了 D-IMF 在离散数据上的收敛性 (§4.1)。接着，展示了 CSBM 在二维实验中使用不同参考过程的表现 (§4.2)。随后，我们测试了 CSBM 利用彩色 MNIST 数据集进行图像转换的能力 (§4.3)，并变化步数的数量 N 。然后，我们在 CelebA 数据集上进行了实验 (§4.4)，展示了 CSBM 在潜空间中的表现。最后，我们通过解决 Amazon Reviews 数据集上的情感转移问题来探索文本领域 (附录 C.4)。实验细节见附录 D.3，额外的图像见附录 D.4。

4.1 D-IMF 在离散空间上的收敛性

在本节中，我们推导出 D-IMF 的解析表达式，并比较其在几种设置下的离散数据收敛性。正如在 §2.5 中所指出的，马尔可夫投影保留了给定过程的一步转移概率 q^{2l+1} 。因此，我们的任务简化为复制：

$$q^{2l+2}(x_{t_n}|x_{t_{n-1}}) = q^{2l+1}(x_{t_n}|x_{t_{n-1}}), \quad \forall n \in [1, N+1].$$

对于每个 D-IMF 迭代，这些转移矩阵可以从联合分布中提取：

$$q^{2l+1}(x_{t_n}, x_{t_{n-1}}) = \sum_{x_0, x_1 \in \mathcal{X}} \left[q^{2l+1}(x_0, x_1) \cdot q^{\text{ref}}(x_{t_n}|x_0, x_1) q^{\text{ref}}(x_{t_{n-1}}|x_{t_n}, x_1) \right],$$

其中 $q^{\text{ref}}(x_{t_n}|x_0, x_1)$ 及 $q^{\text{ref}}(x_{t_{n-1}}|x_{t_n}, x_1)$ could be de-通过马尔可夫性质和贝叶斯公式推导得出。

给定 $q^{2l+1}(x_{t_n}, x_{t_{n-1}})$ ，通过规范化联合分布到边缘 $q^{2l+1}(x_{t_{n-1}})$ 上获得所需的转移分布 $q^{2l+2}(x_{t_n}|x_{t_{n-1}}) = [Q_n^{2l+2}]_{x_{t_{n-1}}, x_{t_n}}$ ，其中边缘分布是通过 $q^{2l+1}(x_{t_n}, x_{t_{n-1}})$ 中的所有 $x_{t_n} \in \mathbb{S}^D$ 求和计算得到的。然后，通过乘以转移矩阵得到条件分布 $q^{2l+2}(x_1|x_0)$

$$\text{trices } Q_n^{2l+2}, \text{ i.e., } q^{2l+2}(x_1|x_0) = \left[\prod_{n=1}^{N+1} Q_n^{2l+2} \right]_{x_0, x_1}.$$


最后，我们用以下方式重新加权此条件分布：

$$p_0(x_0) \text{ 以获得一个新的耦合 } q^{2l+2}(x_0, x_1) = p_0(x_0) \left[\prod_{n=1}^{N+1} Q_n^{2l+2} \right]_{x_0, x_1} \text{ 下一次迭代的结果。}$$


所有这些方程都是可处理的，并且可以在 S 和 D 取较小值时高效计算。因此，在我们的实验中，我们在以下边缘之间求解 SB 问题： $S = 50$ 和 $D = 1$ 。

$$p_0(x_0) = \frac{1}{S}, \quad p_1(x_1) = \frac{x_1}{\sum_{s=1}^S s}.$$


为了评估如推论 3.2 所示的收敛性，我们也需要具备真实桥梁 q^* ，我们通过计算获得



(a) Dependence on the stochasticity parameter α .



(b) 时间步数 N 与 q^{gauss} 的关系。



(c) 时间步数 N 与 q^{unif} 的关系。

图 1. D-IMF 过程在不同 N , α 和 q^{ref} 下的离散数据收敛性依赖关系。

Sinkhorn 算法 (Cuturi, 2013)。作为代价矩阵，我们使用累积转移矩阵 $\prod_{n=1}^{N+1} Q_n$ 的负对数 Q_n 。图 1 所示的收敛曲线表明 KL (的收敛速度显著加快 $q^l \| q^*$)。

4.2 具体的二维实验

在本实验中，初始分布 p_0 as a 为二维高斯分布，目标分布 p_1 为瑞士卷。两者均被离散化为 $S = 50$ 类，形成一个具有 $|\mathcal{X}| = S^2 = 50 \times 50$ 个点的二维分类空间。与之前的实验相比，此设置涉及处理大小为 2500×2500 的 N 矩阵，使其成为计算上更为复杂的任务。因此，从现在起，我们使用所提出的算法 1 来解决 SB 问题。本实验的目标是考察参考过程 q^{gauss} 和 q^{unif} 的影响。为此，我们使用不同 α 和 q^{ref} 的 $N = 10$ 中间步骤训练 CSBM。对于 q^{gauss} ，我们测试 $\alpha \in \{0.02, 0.05\}$ 。在 q^{unif} 的情况下，我们使用 $\alpha \in \{0.01, 0.005\}$ 。

图 2 表明，增加参数 α 会增加跳跃次数。在 q^{gauss} 的情况下，跳跃主要发生在相邻类别之间 (图 2c 和 2d)。在 q^{unif} 的情况下，跳跃发生在所有类别之间 (图 2e 和 2f)。这与参考过程的构建相一致。




图 2. 二维高斯分布与瑞士卷分布之间的 SB，由我们的 CSBM 算法通过不同的参考过程 q^{unif} 和 q^{gauss} 以及变化的参数 α 学习得到。

注释。除了命题 3.3 中建立的理论目标外，还可以通过使用不同的损失函数，如均方误差 (MSE)，或者通过对抗方法，如 ASBM (Gushchin 等, 2024b) 来匹配分布。为了完整性，我们进行了额外的实验，使用 MSE 损失，并观察到的结果与使用 KL 损失获得的结果相当。关于实验设置和损失泛化的详细信息，请参见附录 C.1。

4.3 未配对的彩色 MNIST 翻译

在此，我们使用带有随机颜色数字的 MNIST 数据集。受 (Gushchin 等, 2024b, 附录 C.3) 启发，我们考虑在数字类别“2”和“3”之间进行未配对的翻译问题。在我们的案例中，我们在图像的离散空间中工作，而不是在连续空间中。




图 3. 未配对颜色数字翻译“3”的结果 $\rightarrow$ 通过我们的 CSBM 算法并参考过程学习到的“2” q^{gauss} 以及不同时间点的数量变化 N 。

具体而言，每个像素使用三个 8 位通道 (RGB) 表示，即 $S = 256$ ，数据空间大小为 256^D ，其中

$D = 32 \times 32 \times 3$ 。本实验旨在评估 CSBM 在不同中间步骤数量下进行未配对转换的能力 N 。由于每个颜色通道值具有内在顺序，我们利用高斯参考过程 q^{gauss} ，其中 $\alpha = 0.01$ 。

图 3 的结果表明，即使在低 $N = 2$ 的情况下，生成的输出仍保持良好的视觉质量和颜色。然而，样本中出现了像素化现象，这可能是由于学习过程的分解（召回率 §3.2.3）所致。随着 N 的增加，这种效应略有下降，反映了模型简单性和捕捉特征间依赖性的能力之间的权衡。此外，可以观察到相似性与 N 成比例减少。我们假设这个问题与欠拟合有关，因为所有模型都是在相同的梯度更新次数下进行训练的。推测更大的 N 需要相应更多的更新来充分训练所有的转换概率 (9)。此外，我们在附录 C.2 中提供了关于实验 q^{unif} 的详细信息。




图 4. 男性比较 $\rightarrow$ CelebA 数据集上的女性翻译 128×128 数据集使用 CSBM（我们的方法）、ASBM 和 DSBM。ASBM 和 DSBM 在连续像素空间中运行，而 CSBM 在 VQ-GAN 的离散潜空间中操作 (Esser 等, 2021)。CSBM 的低随机性设置对应于 $\alpha = 0.005$ ，而高随机性设定对应于 $\alpha = 0.01$ 参考过程的 q^{unif} 图中的 ASBM 和 DSBM 图像来自 (Gushchin 等, 2024b)。

4.4 CelebA 人脸的无配对翻译

在此，我们展示了在 CelebA 数据集上进行未配对的图像到图像转换实验，使用向量量化方法。具体而言，我们将重点放在将男性图像转换为女性图像。我们训练 VQ-GAN 自编码器 (Esser 等, 2021) 以将 128×128 图像表示为 $D = 256$ 特征，并具有 $S = 1024$ 类别（即码本）。这种表述降低了复杂度，因为待建模的数据维度为 $S^D = 1024^{256}$ 。确实，这比原始彩色 MNIST 图像空间（§4.3）小，而且远小于 CelebA 的原始像素空间。由于码本元素之间没有明确的关系，我们使用均匀参考 q^{ref} 。我们测试了 $\alpha \in \{0.005, 0.01\}$ 和 $N = 100$ 。

为了完整性，我们将我们的 CSBM 方法与 ASBM (Gushchin 等, 2024b) 和 DSBM (Shi 等, 2023) 进行了比较，这些方法在连续像素空间中运行。关于为何不在潜空间中训练它们的原因，请参见附录 C.3。我们从 (Gushchin 等, 2024b, § 4.2) 中采用了它们的结果。从定性的角度来看，我们达到了可比较的视觉效果（图 4）。值得注意的是，背景几乎

对于 CSBM 方法，在所有图像上该值是相同的，而对于其他方法则并非如此，尤其是在高随机性设置中。

表 2. 未配对男性的 CSBM（我们的工作）、(Gushchin 等人, 2024b, ASBM) 和 (Shi 等人, 2023, DSBM) 的度量比较 $\rightarrow$ CelebA 数据集上的女性翻译 128×128 数据集。

Metric	Low stochasticity			High stochasticity		
	CSBM $\alpha = 0.005$	ASBM $\epsilon = 1$	DSBM $\epsilon = 1$	CSBM $\alpha = 0.01$	ASBM $\epsilon = 10$	DSBM $\epsilon = 10$
FID ($\downarrow$)	10.60	16.86	24.06	14.68	17.44	92.15
CMMD ($\downarrow$)	0.165	0.216	0.365	0.212	0.231	1.140
LPIPS ($\downarrow$)	0.175	0.242	0.246	0.170	0.294	0.386

表 2 中的 FID (Heusel 等, 2017 年)，CMMD (Jayasumana 等, 2024 年) 和 LPIPS (Zhang 等, 2018 年) 度量比较定量地证明了我们的方法在测试集上取得了优于其他方法的结果。然而，值得注意的是，我们的实验是在 D-IMF 中使用了 $N = 100$ ，这高于连续空间 D-IMF 在 ASBM 中使用的 $N = 3$ ，即时间步数的数量 N 与生成质量之间的权衡应予以考虑。

致谢

本工作得到了俄罗斯经济发展部提供的 AI 研究机构资助，根据协议 000000C313925P4F0002 以及与 Skoltech 的协议 №139-10-2025-033 进行。

影响声明

本文提出了旨在推动机器学习领域发展的研究工作。我们的工作可能带来许多潜在的社会影响，但其中没有我们认为需要在此特别强调的内容。

参考文献

- Austin, J., Johnson, D. D., Ho, J., Tarlow, D., and Van Den Berg, R. Structured denoising diffusion models in discrete state-spaces. *Advances in Neural Information Processing Systems*, 34:17981–17993, 2021.
- Banerjee, A., Merugu, S., Dhillon, I. S., and Ghosh, J. Clustering with Bregman divergences. *Journal of machine learning research*, 6(Oct):1705–1749, 2005.
- Campbell, A., Yim, J., Barzilay, R., Rainforth, T., and Jaakkola, T. Generative flows on discrete state-spaces: Enabling multimodal flows with applications to protein co-design. In Salakhutdinov, R., Kolter, Z., Heller, K., Weller, A., Oliver, N., Scarlett, J., and Berkenkamp, F. (eds.), *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, pp. 5453–5512. PMLR, 21–27 Jul 2024. URL <https://proceedings.mlr.press/v235/campbell124a.html>.
- Chen, T., Liu, G.-H., and Theodorou, E. Likelihood training of Schrödinger bridge using forward-backward SDEs theory. In *International Conference on Learning Representations*, 2022.
- Cuturi, M. Sinkhorn distances: Lightspeed computation of optimal transport. *Advances in neural information processing systems*, 26, 2013.
- De Bortoli, V., Thornton, J., Heng, J., and Doucet, A. Diffusion Schrödinger bridge with applications to score-based generative modeling. *Advances in Neural Information Processing Systems*, 34:17695–17709, 2021.
- De Bortoli, V., Korshunova, I., Mnih, A., and Doucet, A. Schrödinger bridge flow for unpaired data translation. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024. URL <https://openreview.net/forum?id=1F32iCJFfa>.
- Deb, N., Ghosal, P., and Sen, B. Rates of estimation of optimal transport maps using plug-in estimators via barycentric projections. *Advances in Neural Information Processing Systems*, 34:29736–29753, 2021.
- Dvurechenskii, P., Dvinskikh, D., Gasnikov, A., Uribe, C., and Nedich, A. Decentralize and randomize: Faster algorithm for Wasserstein barycenters. In *Advances in Neural Information Processing Systems*, pp. 10760–10770, 2018.
- Dvurechensky, P., Gasnikov, A., and Kroshnin, A. Computational optimal transport: Complexity by accelerated gradient descent is better than by Sinkhorn’s algorithm. In *International conference on machine learning*, pp. 1367–1376. PMLR, 2018.
- Esser, P., Rombach, R., and Ommer, B. Taming transformers for high-resolution image synthesis. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 12873–12883, 2021.
- Gat, I., Remez, T., Shaul, N., Kreuk, F., Chen, R. T., Synnaeve, G., Adi, Y., and Lipman, Y. Discrete flow matching. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. Generative adversarial nets. In *Advances in neural information processing systems*, pp. 2672–2680, 2014.
- Gu, S., Chen, D., Bao, J., Wen, F., Zhang, B., Chen, D., Yuan, L., and Guo, B. Vector quantized diffusion model for text-to-image synthesis. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 10696–10706, 2022.
- Gushchin, N., Kolesov, A., Korotin, A., Vetrov, D., and Burnaev, E. Entropic neural optimal transport via diffusion processes. In *Advances in Neural Information Processing Systems*, 2023a.
- Gushchin, N., Kolesov, A., Mokrov, P., Karpikova, P., Spiridonov, A., Burnaev, E., and Korotin, A. Building the bridge of Schrödinger: A continuous entropic optimal transport benchmark. In *Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, 2023b.
- Gushchin, N., Kholkin, S., Burnaev, E., and Korotin, A. Light and optimal Schrödinger bridge matching. In *Forty-first International Conference on Machine Learning*, 2024a.
- Gushchin, N., Selikhanovych, D., Kholkin, S., Burnaev, E., and Korotin, A. Adversarial Schrödinger bridge matching. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024b. URL <https://openreview.net/forum?id=L3Knnigicu>.

- He, J., Wang, X., Neubig, G., and Berg-Kirkpatrick, T. A probabilistic formulation of unsupervised text style transfer. In *International Conference on Learning Representations*, 2020.
- Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., and Hochreiter, S. GANs trained by a two time-scale update rule converge to a local Nash equilibrium. In *Advances in neural information processing systems*, pp. 6626–6637, 2017.
- Ho, J., Jain, A., and Abbeel, P. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 33:6840–6851, 2020.
- Hoogetboom, E., Nielsen, D., Jaini, P., Forré, P., and Welling, M. Argmax flows and multinomial diffusion: Learning categorical distributions. *Advances in Neural Information Processing Systems*, 34:12454–12465, 2021.
- Hütter, J.-C. and Rigollet, P. Minimax estimation of smooth optimal transport maps. 2021.
- Jang, E., Gu, S., and Poole, B. Categorical reparameterization with Gumbel-softmax. In *International Conference on Learning Representations*, 2017.
- Jayasumana, S., Ramalingam, S., Veit, A., Glasner, D., Chakrabarti, A., and Kumar, S. Rethinking FID: Towards a better evaluation metric for image generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 9307–9315, 2024.
- Kholkin, S., Ksenofontov, G., Li, D., Kornilov, N., Gushchin, N., Burnaev, E., and Korotin, A. Diffusion & adversarial Schrödinger bridges via iterative proportional Markovian fitting. *arXiv preprint arXiv:2410.02601*, 2024.
- Kim, J. H., Kim, S., Moon, S., Kim, H., Woo, J., and Kim, W. Y. Discrete diffusion Schrödinger bridge matching for graph transformation. *arXiv preprint arXiv:2410.01500*, 2024.
- Korotin, A., Gushchin, N., and Burnaev, E. Light Schrödinger bridge. In *The Twelfth International Conference on Learning Representations*, 2024.
- Kudo, T. and Richardson, J. SentencePiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pp. 66–71, 2018.
- Léonard, C. A survey of the Schrödinger problem and some of its connections with optimal transport. *arXiv preprint arXiv:1308.0215*, 2013.
- Léonard, C., Roelly, S., and Zambrini, J.-C. Reciprocal processes. a measure-theoretical point of view. *Probability Surveys*, 11:237–269, 2014.
- Li, J., Jia, R., He, H., and Liang, P. Delete, retrieve, generate: a simple approach to sentiment and style transfer. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pp. 1865–1874, 2018.
- Liu, A., Broadrick, O., Niepert, M., and Broeck, G. V. d. Discrete copula diffusion. *arXiv preprint arXiv:2410.01949*, 2024.
- Liu, G.-H., Chen, T., So, O., and Theodorou, E. Deep generalized Schrödinger bridge. *Advances in Neural Information Processing Systems*, 35:9374–9388, 2022a.
- Liu, G.-H., Vahdat, A., Huang, D.-A., Theodorou, E., Nie, W., and Anandkumar, A. I² sb: Image-to-image Schrödinger bridge. In *International Conference on Machine Learning*, pp. 22042–22062. PMLR, 2023.
- Liu, X., Gong, C., et al. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *The Eleventh International Conference on Learning Representations*, 2022b.
- Luo, F., Li, P., Yang, P., Zhou, J., Tan, Y., Chang, B., Sui, Z., and Sun, X. Towards fine-grained text sentiment transfer. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pp. 2013–2022, 2019.
- Luo, X., Wang, Z., Lv, J., Wang, L., Wang, Y., and Ma, Y. CrystalFlow: A flow-based generative model for crystalline materials. *arXiv preprint arXiv:2412.11693*, 2024.
- Manole, T., Balakrishnan, S., Niles-Weed, J., and Wasserman, L. Plugin estimation of smooth optimal transport maps. *The Annals of Statistics*, 52(3):966–998, 2024.
- Mokrov, P., Korotin, A., Kolesov, A., Gushchin, N., and Burnaev, E. Energy-guided entropic neural optimal transport. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=d6tUsZeVs7>.
- Mukherjee, S., Kasner, Z., and Dušek, O. Balancing the style-content trade-off in sentiment transfer using polarity-aware denoising. In *International Conference on Text, Speech, and Dialogue*, pp. 172–186. Springer, 2022.
- Ni, J., Li, J., and McAuley, J. Justifying recommendations using distantly-labeled reviews and fine-grained aspects.

- In *Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP)*, pp. 188–197, 2019.
- Papineni, K., Roukos, S., Ward, T., and Zhu, W.-J. BLEU: a method for automatic evaluation of machine translation. In *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*, pp. 311–318, 2002.
- Pariset, M., Hsieh, Y.-P., Bunne, C., Krause, A., and De Bortoli, V. Unbalanced diffusion Schrödinger bridge. *arXiv preprint arXiv:2306.09099*, 2023.
- Peebles, W. and Xie, S. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 4195–4205, 2023.
- Peluchetti, S. Diffusion bridge mixture transports, Schrödinger bridge problems and generative modeling. *Journal of Machine Learning Research*, 24(374):1–51, 2023.
- Peyré, G., Cuturi, M., et al. Computational optimal transport. *Foundations and Trends® in Machine Learning*, 11(5-6): 355–607, 2019.
- Pooladian, A.-A. and Niles-Weed, J. Entropic estimation of optimal transport maps. *arXiv preprint arXiv:2109.12004*, 2021.
- Prabhumoye, S., Tsvetkov, Y., Salakhutdinov, R., and Black, A. W. Style transfer through back-translation. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 866–876, 2018.
- Qin, Y., Madeira, M., Thanou, D., and Frossard, P. DeFoG: Discrete flow matching for graph generation. *arXiv preprint arXiv:2410.04263*, 2024.
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., Sutskever, I., et al. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9, 2019.
- Rombach, R., Blattmann, A., Lorenz, D., Esser, P., and Ommer, B. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 10684–10695, 2022.
- Ronneberger, O., Fischer, P., and Brox, T. U-net: Convolutional networks for biomedical image segmentation. In *Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18*, pp. 234–241. Springer, 2015.
- Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., and Chen, X. Improved techniques for training GANs. In *Advances in neural information processing systems*, pp. 2234–2242, 2016.
- Schrödinger, E. *Über die Umkehrung der Naturgesetze*. Verlag der Akademie der Wissenschaften in Kommission bei Walter De Gruyter u. Company, 1931.
- Shen, T., Lei, T., Barzilay, R., and Jaakkola, T. Style transfer from non-parallel text by cross-alignment. *Advances in neural information processing systems*, 30, 2017.
- Shi, Y., Bortoli, V. D., Campbell, A., and Doucet, A. Diffusion Schrödinger bridge matching. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=qy07OHsJT5>.
- Tong, A. Y., Malkin, N., Fatras, K., Atanackovic, L., Zhang, Y., Huguët, G., Wolf, G., and Bengio, Y. Simulation-free Schrödinger bridges via score and flow matching. In *International Conference on Artificial Intelligence and Statistics*, pp. 1279–1287. PMLR, 2024.
- Van Den Oord, A., Vinyals, O., et al. Neural discrete representation learning. *Advances in neural information processing systems*, 30, 2017.
- Vargas, F., Thodoroff, P., Lamacraft, A., and Lawrence, N. Solving Schrödinger bridges via maximum likelihood. *Entropy*, 23(9):1134, 2021.
- Vignac, C., Krawczuk, I., Siraudin, A., Wang, B., Cevher, V., and Frossard, P. Digress: Discrete denoising diffusion for graph generation. *arXiv preprint arXiv:2209.14734*, 2022.
- Wang, K., Hua, H., and Wan, X. Controllable unsupervised text attribute transfer via editing entangled latent representation. *Advances in Neural Information Processing Systems*, 32, 2019.
- Xu, M., Geffner, T., Kreis, K., Nie, W., Xu, Y., Leskovec, J., Ermon, S., and Vahdat, A. Energy-based diffusion language models for text generation. *arXiv preprint arXiv:2410.21357*, 2024.
- Zhang, R., Isola, P., Efros, A. A., Shechtman, E., and Wang, O. The unreasonable effectiveness of deep features as a perceptual metric. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 586–595, 2018.
- Zhu, J.-Y., Park, T., Isola, P., and Efros, A. A. Unpaired image-to-image translation using cycle-consistent adversarial networks. In *Proceedings of the IEEE international conference on computer vision*, pp. 2223–2232, 2017.

A 局限性

所提算法的一个局限性源于对转移概率进行因子分解（见 §3.2.3）。这种简化导致失去了一些信息，因为没有明确考虑同一步骤中特征之间的依赖关系。然而，应当注意到这一局限性是现代流式（Campbell 等, 2024; Gat 等, 2024）和扩散式（Hoogeboom 等, 2021; Austin 等, 2021）方法处理离散数据时固有的。近期的方法旨在通过使用 copulas（Liu 等, 2024）或能量函数（Xu 等, 2024）来建模转移联合分布来解决这个问题。此外，在彩色 MNIST 实验（§4.3）中，参考过程会因实现细节而略有不同与 N 。累积转移矩阵间的均方误差被限制在 10^{-4} 内，这证实了由此产生的差异在统计上是不显著的。因此，这些差异可以忽略，并不会影响实验目标或更广泛的启示。

附录 B 证明 定理 3.1 的证明。 根据定理所述，我们考虑一个过程 $q(x_0, x_{\text{in}}, x_1) \in \Pi_N(p_0, p_1)$ ，它具有 $N \geq 1$ 中间时间步，并且既是马尔可夫过程又是互惠过程，以及一个参考马尔可夫过程 $q^{\text{ref}} \in \mathcal{M}(\mathcal{X}^{N+2})$ 。我们关注边界元素 x_0, x_1 和选定的中间状态 x_{t_n} 的联合分布，其中 $n \in [1, N]$ 。该分布 $p(x_0, x_{t_n}, x_1)$ 可以通过马尔可夫性质或互惠性质以两种等价的方式表示：

$$\underbrace{q(x_0, x_1)q^{\text{ref}}(x_{t_n}|x_0, x_1)}_{\text{by reciprocal property}} = q(x_0, x_{t_n}, x_1) = \underbrace{p(x_0)q(x_{t_n}|x_0)q(x_1|x_{t_n})}_{\text{by Markov property}}.$$

重新排列此方程并应用对数，我们得到：

$$\log q(x_1|x_0) = \log q(x_{t_n}|x_0) + \log q(x_1|x_{t_n}) - \log q^{\text{ref}}(x_{t_n}|x_0, x_1).$$

请注意，根据定理的假设，所有概率项都是严格正的。已知最后一项 $\log q^{\text{ref}}(x_{t_n}|x_0, x_1)$ 是马尔可夫的，从而得出以下方程：

$$\begin{aligned} \log q(x_1|x_0) &= \log q(x_{t_n}|x_0) + \log q(x_1|x_{t_n}) - \log \left(\frac{q^{\text{ref}}(x_0)q^{\text{ref}}(x_{t_n}|x_0)q^{\text{ref}}(x_1|x_{t_n})}{q^{\text{ref}}(x_0, x_1)} \right) = \\ &= \underbrace{\log q(x_{t_n}|x_0) - \log q^{\text{ref}}(x_{t_n}|x_0) - \log q^{\text{ref}}(x_0)}_{\stackrel{\text{def}}{=} f_0(x_0, x_{t_n})} + \underbrace{\log q(x_1|x_{t_n}) - \log q^{\text{ref}}(x_1|x_{t_n})}_{\stackrel{\text{def}}{=} f_1(x_{t_n}, x_1)} + \log q^{\text{ref}}(x_0, x_1). \end{aligned}$$

Thus, we get:

$$f(x_0, x_1) \stackrel{\text{def}}{=} \log q(x_1|x_0) - \log q^{\text{ref}}(x_0, x_1) = f_0(x_0, x_{t_n}) + f_1(x_{t_n}, x_1). \quad (11)$$

值得注意的是， $f(x_0, x_1)$ 可以表示为两个单变量函数之和，即 $g_0(x_0)$ 和 $g_1(x_1)$ 。这一观察可以通过在 (11) 式中设置 $x_1 = x^\dagger$ 来实现，其中 $x^\dagger \in \mathcal{X}$ 是状态空间中的某个固定点。确实，我们有：

$$f(x_0, x_1) - f(x_0, x^\dagger) = \underbrace{f_0(x_0, x_{t_n})}_{\cancel{f_0(x_0, x_{t_n})}} + f_1(x_{t_n}, x_1) - \underbrace{f_0(x_0, x_{t_n})}_{\cancel{f_0(x_0, x_{t_n})}} - f_1(x_{t_n}, x^\dagger) = f_1(x_{t_n}, x_1) - f_1(x_{t_n}, x^\dagger).$$

固定 $x_1 = x^\dagger$ 使得 $f(x_0, x^\dagger)$ 仅依赖于 x_0 ，因此，我们定义 $g_0(x_0) \stackrel{\text{def}}{=} f(x_0, x^\dagger)$ 。同样地，当固定 x_{t_n} 时，差值 $f(x_0, x_1) - f(x_0, x^\dagger)$ 仅依赖于 x_1 。因此，我们设定 $g_1(x_1) \stackrel{\text{def}}{=} f(x_0, x_1) - f(x_0, x^\dagger)$ 。最终，我们得到：

$$\log q(x_1|x_0) = g_0(x_0) + g_1(x_1) + \log q^{\text{ref}}(x_0, x_1).$$

Exponentiating both sides and multiplying by $p(x_0)$, we derive:

$$q(x_0, x_1) = \underbrace{e^{g_0(x_0)}}_{\psi(x_0)} q^{\text{ref}}(x_1|x_0) \underbrace{e^{g_1(x_1)}}_{\phi(x_1)}.$$

根据 (Leonard, 2013, 定理 2.8)，这种表述描述了静态薛定谔桥问题中从 p_0 到 p_1 的最优传输计划 q^* 。或者，这也可以通过 (Gushchin et al., 2024b) 中的方法推导出来。由于定理的假设确保了 $q(x_{\text{in}}|x_0, x_1) = q^{\text{ref}}(x_{\text{in}}|x_0, x_1)$ ，因此可以得出结论， $q(x_0, x_{\text{in}}, x_1)$ 是一个动态薛定谔桥 $q^*(x_0, x_{\text{in}}, x_1)$ 。 $\square$

命题 3.3 的证明。得益于 (Gushchin et al., 2024b, 命题 3.5), 已知

$$[proj_{\mathcal{M}}(q)](x_0, x_{\text{in}}, x_1) = \underset{m \in \mathcal{M}(\mathcal{X}^{N+2})}{\operatorname{argmin}} \operatorname{KL}(q(x_0, x_{\text{in}}, x_1) \| m(x_0, x_{\text{in}}, x_1)), \quad (12)$$

其中, $q \in \mathcal{R}^{\text{ref}}(\mathcal{X}^{N+2})$ 是一个互逆过程。因此, 我们可以将此 KL 发散分解如下:

$$\begin{aligned} \operatorname{KL}(q(x_0, x_{\text{in}}, x_1) \| m(x_0, x_{\text{in}}, x_1)) &= \mathbb{E}_{q(x_0, x_{\text{in}}, x_1)} \log \frac{q(x_0, x_{\text{in}}, x_1)}{m(x_0, x_{\text{in}}, x_1)} \\ &= \mathbb{E}_{q(x_0, x_{\text{in}}, x_1)} \log \frac{p_0(x_0)q(x_1|x_0)q^{\text{ref}}(x_{\text{in}}|x_0, x_1)}{m(x_0)m(x_1|x_N)\prod_{n=1}^N m(x_{t_n}|x_{t_{n-1}})}. \end{aligned} \quad (13)$$

这里, 分母可以这样表示, 因为 m 是一个马尔可夫过程, 而分子则使用 q 的互逆性质来表示。接下来, 我们将相应的彩色项分开, 得到:

$$\begin{aligned} (13) &= \underbrace{-\mathbb{E}_{q(x_0, x_{t_N}, x_1)} [\log m(x_1|x_{t_N})]}_{L_1} + \mathbb{E}_{q(x_0, x_{\text{in}}, x_1)} \log \frac{\prod_{n=1}^N q^{\text{ref}}(x_{t_n}|x_{t_{n-1}}, x_1)}{\prod_{n=1}^N m(x_{t_n}|x_{t_{n-1}})} + \\ &\quad + \underbrace{\operatorname{KL}(p_0(x_0) \| m(x_0))}_{L_0} + \underbrace{\mathbb{E}_{q(x_1, x_0)} [\log q(x_1|x_0)]}_{C_1}. \end{aligned} \quad (14)$$

将对数内的乘积 (紫色项) 重写为 KL 发散之和, 我们得到以下方程:

$$(14) = L_1 + \sum_{n=1}^N \mathbb{E}_{q(x_1, x_{t_{n-1}})} \operatorname{KL}(q^{\text{ref}}(x_{t_n}|x_{t_{n-1}}, x_1) \| m(x_{t_n}|x_{t_{n-1}})) + L_0 + C_1. \quad (15)$$

我们观察到, 通过构造, 马尔可夫过程 m 在正向表示时 (5), i.e., $m(x_0) = p_0(x_0)$ 保持终端分布不变。因此, 可以省略 L_0 , 因为 $\operatorname{KL} = 0$, 这完成了证明:

$$(15) = L_1 + \sum_{n=1}^N \mathbb{E}_{q(x_1, x_{t_{n-1}})} \operatorname{KL}(q^{\text{ref}}(x_{t_n}|x_{t_{n-1}}, x_1) \| m(x_{t_n}|x_{t_{n-1}})) + C_1. \quad (16)$$

此外, 由于马尔可夫投影 (5) 使相邻时间联合分布 $q(x_{t_{n-1}}, x_{t_n})$ 保持不变, 我们可以使用替代目标训练 m :

$$\begin{aligned} \operatorname{KL}(q(x_0, x_{\text{in}}, x_1) \| m(x_0, x_{\text{in}}, x_1)) &= \mathbb{E}_{q(x_0, x_{\text{in}}, x_1)} \log \frac{q(x_0, x_{\text{in}}, x_1)}{m(x_0, x_{\text{in}}, x_1)} = \\ &= \sum_{n=1}^{N+1} \mathbb{E}_{q(x_{t_{n-1}})} \operatorname{KL}(q(x_{t_n}|x_{t_{n-1}}) \| m(x_{t_n}|x_{t_{n-1}})) + \underbrace{\operatorname{KL}(p_0(x_0) \| m(x_0))}_{L_0}. \end{aligned} \quad (17)$$

类似地, 我们舍弃 L_0 , 留下一个目标, 该目标最小化给定过程 q 与期望马尔可夫过程 m 之间一步转移概率的发散。□

附录 C 额外实验

附录 C.1 替代损失函数

命题 3.3 表明两个等价的基于 KL 的训练目标产生相同的最优解。这自然引出一种推广到更广泛发散类别的泛化方法 D 。

原始目标函数。首先，让我们考虑在 (16) 中给出的原始目标函数。为了确保替代发散不会改变其极小值，替换必须在此上下文中等价。具体来说， L_1 项可以重新表述为克罗内克德尔塔分布与 m , i.e.: 转移分布之间的 KL 发散。

$$\begin{aligned} L_1 &= -\mathbb{E}_{q(x_0, x_{t_N}, x_1)} [\log m(x_1 | x_{t_N})] = \mathbb{E}_{q(x_0, x_{t_N}, x_1)} \mathbb{E}_{\delta_{x_1}(\tilde{x}_1)} \left[\log \frac{\delta_{x_1}(\tilde{x}_1)}{m(\tilde{x}_1 | x_{t_N})} \right] = \\ &= \mathbb{E}_{q(x_0, x_{t_N}, x_1)} \text{KL}(\delta_{x_1}(\tilde{x}_1) \| m(\tilde{x}_1 | x_{t_N})) = \mathbb{E}_{q(x_0, x_{t_N}, x_1)} \text{KL}(q(x_1 | x_{t_N}, x_1) \| m(\tilde{x}_1 | x_{t_N})). \end{aligned}$$

因此， L_1 项可以移至紫罗兰项的求和之下，从而得到：

$$(16) = \sum_{n=1}^{N+1} \mathbb{E}_{q(x_1, x_{t_{n-1}})} \text{KL}(q^{\text{ref}}(x_{t_n} | x_{t_{n-1}}, x_1) \| m(x_{t_n} | x_{t_{n-1}})) + C_1.$$

通过将发散的选择限制在 Bregman 族内，我们确保最小值在同一数值处取得， $= q(x_{t_n} | x_{t_{n-1}})$ (Banerjee 等, 2005)。因 namely, $\mathbb{E}_{q(x_1 | x_{t_{n-1}})} [q^{\text{ref}}(x_{t_n} | x_{t_{n-1}}, x_1)]$ 此，任何 Bregman 发散都可以作为目标函数使用。例如，我们将均方误差损失视为 KL 发散的替代方案：

$$\begin{aligned} \argmin_{m \in \mathcal{M}(\mathcal{X}^{N+2})} \sum_{n=1}^{N+1} \mathbb{E}_{q(x_1, x_{t_{n-1}})} \text{KL}(q^{\text{ref}}(x_{t_n} | x_{t_{n-1}}, x_1) \| m(x_{t_n} | x_{t_{n-1}})) &= \\ = \argmin_{m \in \mathcal{M}(\mathcal{X}^{N+2})} \sum_{n=1}^{N+1} \mathbb{E}_{q(x_1, x_{t_{n-1}})} \left[q^{\text{ref}}(x_{t_n} | x_{t_{n-1}}, x_1) - m(x_{t_n} | x_{t_{n-1}}) \right]^2 \end{aligned} \quad (18)$$

应用此损失参数化方法从 §3.2.3 并重复推导过程，得出以下目标函数：

$$L_{\text{MSE}}(\theta) = \sum_{n=1}^{N+1} \mathbb{E}_{q(x_0, x_1)} \mathbb{E}_{q^{\text{ref}}(x_{t_{n-1}} | x_0, x_1)} \left[q^{\text{ref}}(x_{t_n} | x_{t_{n-1}}, x_1) - \mathbb{E}_{\tilde{q}_\theta(\tilde{x}_1 | x_{t_{n-1}})} [q^{\text{ref}}(x_{t_n} | x_{t_{n-1}}, \tilde{x}_1)] \right]^2, \quad (19)$$

$$L_{\text{MSE}}(\eta) = \sum_{n=1}^{N+1} \mathbb{E}_{q(x_0, x_1)} \mathbb{E}_{q^{\text{ref}}(x_{t_n} | x_0, x_1)} \left[q^{\text{ref}}(x_{t_{n-1}} | x_{t_n}, x_0) - \mathbb{E}_{\tilde{q}_\eta(\tilde{x}_0 | x_{t_n})} [q^{\text{ref}}(x_{t_{n-1}} | x_{t_n}, \tilde{x}_0)] \right]^2, \quad (20)$$

分别用于正向和反向参数化。为了测试均方误差损失函数，我们在高斯分布和瑞士卷分布之间的二维域转换实验中重复实验。可以观察到，图 5 中使用均方误差损失生成的样本和轨迹在视觉上与图 2 中使用 KL 散度损失获得的结果相似。




图 5. 高斯分布和瑞士卷分布之间的 SB，通过我们的 CSBM 算法学习，使用方程 (19) 和 (20) 中的均方误差损失，针对不同的参考过程 q^{unif} 和 q^{gauss} 以及不同的参数设置 α 。

替代目标函数。类似的推理扩展到 (17) 中的替代目标函数。尽管条件分布 $q(x_{t_n} | x_{t_{n-1}})$ 通常没有封闭形式，但可以对其进行采样。这一特性表明应采用对抗训练策略，遵循 (Gushchin 等, 2024b) 中的方法。

附录 C.2 未配对的 Colored MNIST 翻译实验 q^{unif} 我们进行了一项额外的 Colored-MNIST 实验，使用均匀参考过程 q^{unif} 。这里我们设定 $N = 25$ 并测试 $\alpha \in \{0.01, 0.05\}$ 。在 D-IMF 1 迭代中不应用 Mini-batch OT。图 6 中的样本展示了未能匹配数字颜色的情况，表明均匀转移矩阵不适合该领域。




图 6. 由我们的 CSBM 算法通过参考过程 q^{unif} 和不同随机性参数 α 学习到的未配对数字颜色转换结果。

C.3 潜空间中的连续方法

为了完整性，我们也将潜在空间中训练 DSBM。为了公平比较，我们在 CSBM 使用的相同潜空间上训练 DSBM，遵循 (Rombach 等, 2022, 附录 G) 中的方法。具体来说，由于解码器期望离散的标记，我们的流程如下：(1) 将图像映射到其连续的潜表示，(2) 在此连续空间中应用 DSBM，(3) 量化得到的潜变量，(4) 将量化的标记通过解码器。不幸的是，结果并不令人满意，因为模型倾向于退化为恒等映射 $\epsilon = 1$ 和 $\epsilon = 10$ （见图 7）。由于这些局限性，我们不继续训练 ASBM，并选择不在这种设置下将两种方法与 CSBM 进行比较。人们可能会问为什么 CSBM 在这种设置下表现更好。我们假设这是因为参考过程的选择 q^{unif} ，这更适合 VQ-GAN 潜空间。




图 7. 在 CelebA 数据集上的 VQ-GAN 潜在空间训练 DSBM (石等, 2023) 的结果。VQ-GAN 模型与主要实验中的相同 (§4.4).

表 3. CSBM (我们的工作)、CAAE (Shen 等, 2017 年)、Del.&Ret. (Li 等, 2018 年)、Seq2SentiSeq (Luo 等, 2019 年)、BST (Prabhumoye 等, 2018 年)、FGIM (Wang 等, 2019 年)、PST (He 等, 2020 年) 和 SCT1 (Mukherjee 等, 2022 年) 在 Amazon Reviews 数据集上未配对的负面到正面风格转换的度量比较。↔ 加粗表示最优值, 下划线表示次优值。基线方法的度量来自 (Mukherjee 等, 2022), 并用上标 † 标记

Metric	CSBM $\alpha = 0.005$	CSBM $\alpha = 0.01$	CAAE†	Del.&Ret.†	Seq2SentiSeq†	BST†	FGIM†	PST†	SCT1†
Accuracy (↑)	79.3	76.5	88.6	69.9	<u>92.4</u>	93.5	79.3	91.5	82.0
NLL (↓)	5.4	5.4	74.0	85.1	<u>42.0</u>	61.0	116.8	65.9	79.6
BLEU (↑)	<u>72.5</u>	74.8	3.2	14.7	0.0	0.9	10.6	9.5	13.7

表 4. 在 Amazon Reviews 数据集上的 CSBM (我们的方法)、Del.&Ret. (李等, 2018 年)、BST (Prabhumoye 等, 2018 年)、FGIM (王等, 2019 年)、PST (何等, 2020 年) 和 SCT1 (穆克吉等, 2022 年) 的风格转换。基线方法的样本取自 (穆克吉等, 2022 年), 并用上标标记 †。

	<i>negative → positive</i>	<i>positive → negative</i>
Source	<i>movie was a waste of money : this movie totally sucks .</i>	<i>my daughter loves them :)</i>
CSBM $\alpha = 0.005$	<i>movie was great value for the money : this movie totally wass .</i>	<i>my daughter hates them :(</i>
CSBM $\alpha = 0.01$	<i>movie was great value for the money : this movie totally superb .</i>	<i>my daughter hates them :(</i>
Del.&Ret.†	<i>our favorite thing was a movie story : the dream class roll !</i>	<i>my daughter said i was still not acknowledged .</i>
BST†	<i>stan is always a great place to get the food .</i>	<i>do n't be going here .</i>
FGIM†	<i>movie is a delicious atmosphere of : this movie totally sucks movie !</i>	<i>i should not send dress after me more than she would said not ?</i>
PST†	<i>this theater was a great place , we movie totally amazing .</i>	<i>yup daughter has left ourselves .</i>
SCT1†	<i>movie : a great deal of money : this movie is absolutely perfect .</i>	<i>my daughter hates it : my daughter .</i>
Source	<i>nothing truly interesting happens in this book .</i>	<i>best fit for my baby : this product is wonderful ! !</i>
CSBM $\alpha = 0.005$	<i>everything truly interesting happens in this book .</i>	<i>not fit for my baby : this product is junk !!</i>
CSBM $\alpha = 0.01$	<i>everything truly interesting happens in this book .</i>	<i>not fit for my baby : this product is bad !!</i>
Del.&Ret.†	<i>nothing truly interesting happens in this book .</i>	<i>my mom was annoyed with my health service is no notice .</i>
BST†	<i>very good for the best .</i>	<i>bad customer service to say the food , and it is n't .</i>
FGIM†	<i>nothing truly interesting happens in this book make it casual and spot .</i>	<i>do not buy my phone : this bad crap was worst than it ?</i>
PST†	<i>haha truly interesting happens in this book .</i>	<i>uninspired .</i>
SCT1†	<i>in this book is truly a really great book .</i>	<i>not good for my baby : this product is great ! ! ! ! ! ! ! !</i>

C.4 亚马逊评论的无配对文本风格转换

本节探讨文本领域, 重点关注 Amazon Reviews 数据集上的风格转换任务 (Ni 等, 2019)。该任务旨在将具有负面情感的评论转化为正面情感的评论, 反之亦然。我们采用了 (Mukherjee 等, 2022) 的过滤和预处理划分。评论使用一元 SentencePiece 模型进行分词 (Kudo & Richardson, 2018), 其词汇量设置为 $S = 8192$ 每篇评论随后被填充或截断至固定长度为 $D = 100$ 我们评估了一致参考过程 q^{ref} 对于 $\alpha \in \{0.005, 0.01\}$ 报告的分数的在两种转移方向上取平均值的负值 ↔ 积极地与基线进行了比较, 采用了 (Mukherjee 等, 2022) 中的度量。

为了镜像图像域协议, 我们选择了类似的文本度量。目标对齐使用 Hugging Face 管道的默认情感分类器进行测量, 并辅以 GPT-2 Large (Radford 等, 2219) 下的负对数似然 (NLL)。转移文本与其来源之间的相似性通过 BLEU (Papineni 等, 2002) 进行测量。定量度量出现在表 3 中, 而代表性样本则展示在表 4 中。

CSBM 在内容保存方面表现出色, 实现了最高的 BLEU 分数和最低的 NLL, 这表明其生成流畅且忠实于原文的重写。其情感转移准确率低于一半的方法, 但对表 4 中样本的手动检查表明大多数生成结果传达了正确的极性。

D 实用细节 D.1 参考过程的构建与选择 q^{ref} 构建 文章仅简要提及参考处理的方式 q^{ref} 被构建。在当前方案中， q^{ref} 通过连接中间转移概率进行组装 $q^{\text{ref}}(x_{t_n}|x_{t_{n-1}})$ 因此，完整的端到端转换 $q^{\text{ref}}(x_1|x_0)$ 随选择的不同而变化 α ，转移矩阵 Q_n ，以及离散化级别 N 而不是在各种设置下保持固定。因此，例如，步数的增加 N 迫使我们选择一个更小的值。如果 α 仍然过大，整体转移概率 $q^{\text{ref}}(x_1|x_0)$ 将收敛到平稳分布，使得每个起始状态到达每个结束状态的可能性相同。均匀分布本身并无错误，但它违背了我们的目标，因为我们希望 α 控制整个过程中的随机性。因此，构建一个非均匀、非高斯的 q^{ref} 分布更具挑战性，这促使我们在未来探索新的构建策略。

选择 α 在多次实验中，我们观察到了选择 α 的模式。总体而言，这一思路与连续 SB 方法中选择 ϵ 的直觉相同（史等，2023；古什钦等，2024b）。具体来说，较低的 α 值会导致轨迹的随机性降低，从而使得生成的数据更接近输入数据，但对目标分布的近似质量较低。当值非常低时，模型可能会因为随机性不足而崩溃。相反，较高的 α 值会引入更多的变异性，减少与初始数据的相似性。超过一定点后，过大的值 α 会使模型难以训练，导致质量和相似性的下降。不幸的是，这些行为的有效范围高度依赖于数据集和所选参考过程。尽管如此，我们提供了一些合理的基线值，可以从这些值开始并根据需要进行调整。

D.2 CSBM 的损失函数

本节概述了通过将 $m = q_\theta$ 代入 (10) 获得的 (9) 参数化的优化过程。遵循 (Austin 等人，2021)，我们将模型参数化为预测终端点 x_1 或 x_0 ，分别对应于前向或后向重新参数化，并采用一种混合损失，该损失将基础损失与损失 L_{simple} 相加，后者乘以一个权重因子 λ 。因此，得到的训练目标由下式给出：

$$L(\theta) = \mathbb{E}_{q(x_0, x_1)} \left[\sum_{n=1}^N \mathbb{E}_{q^{\text{ref}}(x_{t_{n-1}}|x_0, x_1)} \left[\text{KL} \left(q^{\text{ref}}(x_{t_n}|x_{t_{n-1}}, x_1) \parallel \mathbb{E}_{\tilde{q}_\theta(\tilde{x}_1|x_{t_{n-1}})} [q^{\text{ref}}(x_{t_n}|x_{t_{n-1}}, \tilde{x}_1)] \right) - \lambda \overbrace{\log \tilde{q}_\theta(\tilde{x}_1|x_{t_{n-1}})}^{L_{\text{simple}}} \right. \right. \\ \left. \left. - \mathbb{E}_{q^{\text{ref}}(x_{t_N}|x_0, x_1)} [\log \tilde{q}_\theta(x_1|x_{t_N})] \right] \right]. \quad (21)$$

由于命题 10 也适用于 m 的后向分解，我们可以应用类似的参数化。在这种情况下，我们使用具有参数 η 的神经网络来预测 x_0 ：

$$L(\eta) = \mathbb{E}_{q(x_0, x_1)} \left[\sum_{n=2}^{N+1} \mathbb{E}_{q^{\text{ref}}(x_{t_n}|x_0, x_1)} \left[\text{KL} \left(q^{\text{ref}}(x_{t_{n-1}}|x_{t_n}, x_0) \parallel \mathbb{E}_{\tilde{q}_\eta(\tilde{x}_0|x_{t_n})} [q^{\text{ref}}(x_{t_{n-1}}|x_{t_n}, \tilde{x}_0)] \right) - \lambda \overbrace{\log \tilde{q}_\eta(\tilde{x}_0|x_{t_n})}^{L_{\text{simple}}} \right. \right. \\ \left. \left. - \mathbb{E}_{q^{\text{ref}}(x_{t_1}|x_0, x_1)} [\log \tilde{q}_\eta(x_0|x_{t_1})] \right] \right]. \quad (22)$$

关于训练过程的更多细节，请参阅 (Austin 等人，2021)。

D.3 训练方面

对于训练逻辑的实现，我们参考了官方的 D3PM 仓库 (Austin 等，2021 年)：

<https://github.com/google-research/google-research/tree/master/d3pm>

表 5. 实验超参数。Lr 表示学习率，m 代表百万。Params 表示模型参数的数量，其中对于 CelebA 数据集，第一个值对应于模型，第二个值对应于 VQ-GAN。

Experiment	Initial coupling	D-IMF outer iterations	D-IMF=1 grad updates	D-IMF grad updates	N	Batch size	Lr	Params
2D	Ind	10	400 000	40 000	10	512	0.0004	46588
Colored MNIST	MB	3	200 000	40 000	2, 4, 10, 25, 50, 100	128	0.0002	34m
CelebA	Ind	4	800 000	40 000	100	32	0.0004	93m + 70m
Amazon Reviews	Ind	5	800 000	40 000	100	32	0.0004	100m

共享方面。在所有实验中，我们使用 AdamW 优化器，并将固定系数设置为 0.95 和 0.99。此外，我们应用指数移动平均 (EMA) 平滑来稳定训练并增强最终模型性能。EMA 衰减率在所有实验中均一致调整并设置为 0.999，除了 Colored MNIST 实验，其设置为 0.9999。在所有实验中，我们将权重因子 L_{simple} 设置为 0.001。

对于二维和彩色 MNIST 实验，我们遵循 (Austin 等, 2021) 中的预处理方法，其中 $q_\theta(\tilde{x}_1|x_{t_{n-1}})$ 的对数几率直接作为神经网络的输出进行建模。

值得注意的是，先前的各种研究引入了不同的初始耦合方法 $q^0(x_0, x_1)$ ，例如标准独立耦合 $p_0(x_0)p_1(x_1)$ (Shi 等, 2023; Gushchin 等, 2024b)，从参考过程导出的耦合，例如 $p_0(x_0)q^{\text{ref}}(x_1|x_0)$ (Shi 等, 2023)，以及被称为 MB 的批量最优传输耦合，即在小批量样本上求解离散最优传输 (Tong 等, 2024)。关于耦合策略的更全面概述，请参见 (Kholkin 等, 2024)。本文仅专注于独立和小批量初始耦合。

特定实验方面的内容。对于二维实验 (§4.2)，我们使用一个简单的多层感知机模型，隐藏层大小为 [128, 128, 128]，激活函数为修正线性单元。为了对时间进行条件设置，我们使用了一个简单的查找表，即大小为 2 的嵌入层。

对于彩色 MNIST 实验 (§4.3)，我们遵循 (Austin 等人, 2021) 的方法，并使用基于 PixelCNN++ 骨干架构 (Salimans 等人, 2016) 的设计，该设计采用了具有 ResNet 结构的 U-Net (Ronneberger 等人, 2015)。模型在四个特征图分辨率上运行，每个分辨率级别有两个卷积残差块，通道乘数为 (1, 2, 2, 2)。在第 16×16 分辨率级别上，在卷积块之间加入了一个自注意力块。对于时间编码，我们将变换器正弦位置嵌入应用于每个残差块。我们在大小为 60,000 的训练子集上训练模型，并从保留集生成图像。

对于 CelebA 实验 (§4.4)，我们采用了 VQ-扩散模型 (Gu 等, 2022)，该模型由两个部分组成：VQ-GAN (Esser 等, 2021) 和基于变换器的扩散模型。VQ-GAN 部分使用官方仓库进行训练：

<https://github.com/CompVis/taming-transformers>.

我们对 CelebA-HQ 无条件生成的实验设置进行了轻微调整，将分辨率级别减少到三个，缩放因子为 (1, 2, 4)。这一调整考虑到我们在 128×128 分辨率下使用 CelebA，而 CelebA-HQ 的分辨率是 256×256 。离散扩散模型来源于：

<https://github.com/microsoft/VQ-Diffusion>.

我们的扩散模型由多个变换器块组成，每个块都包含完整的注意力机制和前馈网络 (FFN)。我们遵循 (顾等, 2022) 中的小型模型配置，该配置包含 18 个变换器块，通道大小增加到 256。FFN 通过两个卷积层实现，卷积核大小为 3，通道扩展率为 2。此外，我们通过 AdaLN 操作符注入时间步信息。

我们在 162 770 张预量化名人图像上训练模型。对于评估，我们使用 11 816 张保留图像计算 FID 和 CMMD，以确保与 (古什钦等, 2024b) 中的评估协议保持一致性。同样，论文正文部分展示的图像也是使用此保留集生成的。

对于 Amazon 实验（附录 C.4），我们训练了一个包含显式句首（ $\langle s \rangle$ ）和填充（ $\langle \text{pad} \rangle$ ）标记的一元 SentencePiece 分词器（Kudo & Richardson, 2018），遵循（Austin 等, 2021）的方法。骨干模型为 DiT 模型（Peebles & Xie, 2023），其实现可在以下地址获取：

<https://github.com/kuleshov-group/mdlm>.

我们采用了“小”变体，包含 12 个变换器块，每个块的隐藏层大小为 768，并具有 12 个自注意力头。每个块包含多头自注意力、旋转位置嵌入以及一个随机失活率为 0.1 的 MLP。噪声级别信息通过一个 128 维的 AdaLN 调制向量注入。模型在 104 000 条预分词的评论上进行训练，并在预留的测试集中的 2 000 条评论上进行评估。其余超参数见表 5。

计算时间。训练二维实验需要在单个 A100 GPU 上花费数小时。彩色 MNIST 实验使用两个 A100 GPU 进行训练，大约需要两天时间。计算需求最大的任务是 CelebA 和 Amazon Reviews 实验，它们需要在四个 A100 GPU 上训练大约五天。

D.4 额外图像




图 8. 非配对翻译“2”的彩色数字结果 $\rightarrow$ 通过我们的 CSBM 算法与参考过程学习到的“3” q^{gauss} 以及不同时间点的数量变化 N .



图 9. 女性的比较 $\rightarrow$ CelebA 数据集上的男性翻译 128×128 数据集使用 CSBM (我们的方法)、ASBM 和 DSBM。CSBM 的低随机性设置对应于 $\alpha = 0.005$ ，而高随机性设置对应于 $\alpha = 0.01$ ASBM 和 DSBM 的随机性参数取自 (Gushchin 等, 2024b)。




图 10. 使用 CSBM 在 CelebA 数据集上的男性到女性转换轨迹 $\rightarrow$ 。每一列对应时间点 0, 10, 25, 50, 75, 90 和 101。 128×128 $\alpha = 0.01$



图 11. 使用 CSBM 在 CelebA 数据集上的男性到女性转换轨迹 $\rightarrow$ 。每一列对应时间点 0, 10, 25, 50, 75, 90 和 101。 128×128
 $\alpha = 0.005$



图 12. 使用 CSBM 方法在 CelebA 数据集上进行女性到男性转换轨迹。每一列对应时间点 0, 10, 25, 50, 75, 90 和 101。 → CelebA
 128×128 CSBM $\alpha = 0.01$



图 13. 女性 $\rightarrow$ CelebA 数据集上的男性翻译轨迹 128×128 使用 CSBM 的数据集 $\alpha = 0.005$ 每一列对应的时间点分别为 0、10、25、50、75、90 和 101。