

引言

1976 年，著名的英国统计学家乔治·E·P·博克斯写道：“所有的模型都是错误的，但有些是有用的”，以此来评论科学研究渐进和互动的本质（这一确切的陈述仅在三年后出现；博克斯，1979）。他进一步指出

“在将数学应用于物理学或统计学等主题时，我们对现实世界做出了一些试探性的假设，我们知道这些假设是错误的，但我们认为它们可能仍然有用。”——乔治·E·P·博克斯（1976）

模型的本质在于：它是对现实世界复杂现象的一种便捷简化（Cox，1990）。尽管这些模型可能仅限于统计解释所观察到的现象，但使用这些模型的科学家们力求尽可能忠实的表示，甚至朝着因果理解的方向前进，以解释世界如何响应主动交互（Pearl，2009）。然而，如果所有模型都是不完美的，我们如何找到那些有用的模型呢？这一问题至关重要，因为一个糟糕的模型可能具有潜在的危害性，就像一个好的模型可能具有实用性一样（如果不是更多的话）。这一点现在比以往任何时候都更为重要，因为人工智能的发展速度如此之快，而我们的模型的安全性变得尤为关键（Bengio，2023）。

寻找一个有用的模型尤为困难，因为它通常基于证据。在许多情况下，尤其是在证据有限（但不仅限于此）的情况下，多个并存的模型可能同样很好地解释我们的观察结果，并且坚持单一候选模型容易导致超出我们观察范围的灾难性失败（霍奇斯，1987；本吉奥，2024）。面对风险选择时，理性决策者倾向于采取某种不确定条件下的效用最大化行为（马，2022）。为了考虑这种认知不确定性，采用贝叶斯方法似乎是自然的选择，而 Box 本人就是这一方法的热心倡导者（Box 和 Tiao，1973），其中不确定性通过给定某些观察结果后的模型后验分布来量化。采用贝叶斯视角来量化模型的结构不确定性可以追溯到 Draper 等人提出的科研议程（1987），并在整个 1990 年代得到了部分解决（Madigan 和 Raftery，1994；Chatfield，1995；Draper，1995）。

这现在提出了两个问题：(1) 我们如何表示一个系统感兴趣的统计（甚至是因果）模型，以及 (2) 我们如何表示这些模型上的后验分布？对于前者，我们选择了成熟的贝叶斯网络框架（Pearl，1988），因其灵活性及潜在扩展到因果关系的能力。然而，对于后者，定义模型上的分布

贝叶斯网络 (Bayesian network) 的完整特征化 (即其参数和结构) 证明特别具有挑战性。主要原因在于贝叶斯网络的结构被定义为有向无环图, 因此后验分布必须是在大量离散对象 (有向图) 上带有复杂无环约束的分布。虽然我们可以利用诸如马尔可夫链蒙特卡洛方法 (Markov chain Monte Carlo methods) 等通用工具进行贝叶斯推断 (Gelfand 和 Smith, 1990; Madigan 和 York, 1995), 但是否存在基于现代生成模型和深度学习 (LeCun 等人, 2015; Goodfellow 等人, 2016) 结合优势的更合适的方法?

在本论文中, 我们介绍了生成流网络 (GFlowNets; Bengio 等, 2021; Bengio 等, 2023), 将其作为一种通用框架, 用于从具有某种组合性质的离散量分布中进行采样, 例如有向无环图。生成流网络在以下意义上是离散的、顺序的和摊销的生成模型:

- 离散性: 生成流网络生成的对象是离散的, 并通常具有第 2 章所述的组合结构 (特别是参见第 2.1.3 节中的示例)。这是现代生成建模中一个尚未充分开发的领域, 该领域主要关注连续问题 (Kingma 和 Welling, 2014; Rezende 等, 2014) 或离散问题的连续松弛 (Maddison 等, 2017; Jang 等, 2017)。我们将在第 6 章中看到如何将生成流网络扩展到离散状态空间之外, 包括连续情况;
- 顺序性: 生成流网络将生成视为一个顺序决策问题, 在此过程中对象是一步一步构建起来的。它们与最近将生成模型视为顺序过程的趋势相一致 (Song 和 Ermon, 2019; Brown 等, 2020; Lipman 等, 2023; Tong 等, 2024), 而不是静态过程 (Goodfellow 等, 2014)。对于生成流网络而言, 这一观点受到了强化学习框架的启发 (Sutton 和 Barto, 2018), 并且我们将在第 5 章中看到, 它们实际上与熵正则化的强化学习密切相关 (Haarnoja 等, 2017);
- 摊销性: 生成流网络通过训练一个策略来摊销采样的成本, 该策略最终可用于生成新对象。这种策略通常由神经网络参数化, 利用其在不同但具有某些共享结构的上下文中的泛化能力, 并通过最小化我们在第 4.2.1 节中介绍的一些目标函数来进行训练。我们还将看到, 在第 4.3 节中, 生成流网络深深植根于摊销变分推断的文献之中 (Kingma 和 Welling, 2014)。

尽管 GFlowNets 在‘经典’意义上属于生成模型 (在概率建模中的生成/判别二分法; Ng 和 Jordan, 2001), 但它们与现代对生成模型的预期有显著不同: GFlowNets 并不依赖于从示例数据集 (如图像生成) 中学习生成过程的模型, 而是依靠一个预定义的奖励函数来表示对某些对象相对于其他对象的偏好 (即, 具有较高奖励的对象将比具有较低奖励的对象更频繁地被采样)。这种设置在贝叶斯推断中经常遇到, 但也更广泛地出现在科学发现中 (Noé 等, 2019)。

提纲

本论文的第一部分将专注于生成流网络理论的一般性讨论。在第二章中，我们将介绍从基于能量的模型中采样的问题，这是一种定义到难以处理的归一化的分布，它将在第一部分中作为贯穿始终的主题。通过多个示例，我们将论证如何将离散和组合对象上的分布中采样视为一个顺序决策问题，在某些情况下，这可以归入最大熵强化学习 (MaxEnt RL) 的框架。

然而，在一般情况下，基于最大熵强化学习的方法存在偏差，并不能如预期那样从目标分布中采样。这促使引入 GFlowNets 作为一种普遍解决方案，避免了同样的偏差问题。第三章将介绍流网络的一些性质，这些性质构成了 GFlowNets 的基础，并给出了各种条件来刻画它们。在此基础上，第四章将展示如何结合适当的边界条件，利用流网络进行生成建模。我们将说明如何将描述流网络的守恒定律转化为实用的学习目标，并展示了近似分布向目标分布收敛的新颖保证，从而使 GFlowNets 扎根于变分推断领域。

然后在第五章中，我们将回到主题，展示 GFlowNets 和最大熵强化学习实际上是“同一枚硬币的两面”，前提是奖励函数得到适当的修正。我们展示了第四章中引入的许多目标在最大熵强化学习文献中有自然的对应物。最后，在第六章中，通过探讨马尔可夫链，我们展示了如何将 GFlowNets 扩展到一般状态空间，包括连续状态空间，尽管最初它是专门为离散设置创建的。

本论文的第二部分将专门关注贝叶斯结构学习的问题，即利用 GFlowNets 来建模贝叶斯网络上的后验分布。在第七章中，我们首先介绍如何使用 GFlowNets 从有向无环图的分布中进行采样，通过逐步构建一个有向图并确保每一步的无环性来实现这一目标。这不仅使我们能够建模贝叶斯网络结构上的边缘后验分布，还为建模整个贝叶斯网络特征的联合后验分布提供了基础。在第八章中，我们最终介绍了两种不同的方法，利用 GFlowNets 来建模贝叶斯网络结构和参数的联合后验分布，其中包括一种利用第六章引入的一般状态空间扩展的单一 GFlowNNet 的方法。

第一章

背景

本章简要概述了概率建模中贯穿全文所需的基本概念。其他领域将在后续章节中介绍，例如第 2.2.2 节中的图论概念和第 2.3.1 节中的强化学习。

1.1 贝叶斯网络

概率图模型 (Koller 和 Friedman, 2009; Murphy, 2023) 提供了一种以紧凑和模块化的方式表示复杂系统概率分布的方法。尽管存在多种编码模块化的方法，例如因子图 (Kschischang 等人, 2001)，但在本论文中我们将主要关注贝叶斯网络 (Pearl, 1988)，因为它们构成了最终表示因果知识的基础，正如我们在第 1.5 节中将看到的那样。

在进一步探讨之前，我们需要首先回顾条件独立性的概念，它在贝叶斯网络中起着关键作用。两个随机变量 X 和 Y 在给定第三个随机变量 Z 的情况下被认为是独立的，并记作 $X \perp Y \mid Z$ ，当且仅当

$$P(X, Y \mid Z) = P(X \mid Z)P(Y \mid Z). \quad (1.1.1)$$

这一定义可以自然地扩展到 $Z \equiv \emptyset$ ，在这种情况下， X 和 Y 被称为边缘独立，也可以扩展到其中 X, Y 或 Z 是随机变量集合的情况。在 (1.1.1) 中条件独立性的这种表述可以等价地写作 $P(X \mid Y, Z) = P(X \mid Z)$ 。换句话说，如果我们观察到 Z 的值，那么了解关于 Y 的信息不会提供关于 X 的任何额外信息。

1.1.1. 条件独立性的表示

遵循模块化原则，贝叶斯网络是一种紧凑的联合分布表示方法，涉及 d 个随机变量 $X_1, \dots, X_d$ ，描述了某个感兴趣的系统。给定一个有向无环图 (DAG) G ，其中每个节点对应于这些随机变量之一，




图 1.1. 联合分布的因子分解 (Lauritzen 和 Spiegelhalter, 1988) 作为贝叶斯网络。(a) 贝叶斯网络结构及其对应的条件分布的示意图。 $P(A, B, D, E, L, S, T, X)$ (b) 马尔可夫等价的贝叶斯网络示例, 表示相同的条件独立性, 其中边 $A \rightarrow T$ 和边 $S \rightarrow L$ 的方向已被反转。

联合分布按照图 G 以如下方式进行分解

$$P_{\theta}(X_1, \dots, X_d) = \prod_{i=1}^d P(X_i \mid \text{Pa}_G(X_i); \theta_i), \quad (1.1.2)$$

其中 $\text{Pa}_G(X_i)$ 表示在 G 中变量 X_i 的父随机变量, 而 $\theta = (\theta_1, \dots, \theta_d)$ 是条件分布的参数。贝叶斯网络的结构通常基于专家知识固定下来, 尽管我们在第 1.4 节以及本论文的第二部分将看到, 可以从数据中学习这种结构。图 1.1a 展示了一个贝叶斯网络的例子。

例 1.1.1 (线性高斯模型)。本论文后面将研究的一类贝叶斯网络称为线性高斯模型。给定一个有向无环图 (DAG) $\overline{G}$, 出现在 (1.1.2) 中的条件概率是正态分布, 其均值是父变量的线性组合。我们可以将这样的模型表示为一组结构方程的形式

$$X_i := \sum_{j=1}^d \mathbb{1}(X_j \in \text{Pa}_G(X_i)) \theta_{ji} X_j + \varepsilon_i \quad \text{where} \quad \varepsilon_i \sim \mathcal{N}(0, \sigma_i^2). \quad (1.1.3)$$

我们采用“ θ_{ji} ”这一约定来与邻接矩阵的约定保持一致, 实际上将参数 θ 解释为一个加权邻接矩阵, 在两个节点之间没有边的情况下, 对应的条目为零。我们可以证明在这种情况下, 联合分布是一个均值为 0 的多元正态分布, 其协方差矩阵依赖于 θ 和 σ_i^2 ’s.

根据图对联合分布 $P_{\theta}(X_1, \dots, X_d)$ 进行分解揭示了随机变量集合之间的若干条件独立性。这些条件独立性通过 d-分离的概念 (Pearl, 1188) 在 G 中进行了编码, 这是一个纯粹的图形概念。

定义 1.1.2 (d-分离)。若无向路径（即忽略边的方向性的边序列）包含以下子结构之一，则该路径被节点集合 X_C d-分离：- 至少包含一个如下子结构： X_C

(1) 形式为 $A \rightarrow C \rightarrow B$ 的链结构，其中包含 $C \in X_C$ ；(2) 形式为 $A \leftarrow C \rightarrow B$ 的叉结构，其中包含 $C \in X_C$ ；(3) 形式为 $A \rightarrow C \leftarrow B$ 的 v 结构，其中既不包含 C 也不包含其任何后代节点在 X_C 中。

若两组节点 X_A 和 X_B 被 X_C d-分离，则节点 X_A 和 X_B 之间的任何无向路径都被 X_C d-分离。

尽管这可能看起来是一个非常复杂的验证标准，但存在算法解决方案可以轻松揭示 d-分离 (Shachter, 1998)。将其应用于贝叶斯网络的结构时，我们可以从其表示的联合分布中读取条件独立性（或缺乏条件独立性）。例如，可以验证在图 1.1a 所示的贝叶斯网络描述的联合分布中，即使 $A \not\perp B | X$ ，也有 $A \perp B$ 。能够从图中读取条件独立性称为全局马尔可夫性质。

命题 1.1.3 (全局马尔可夫性质)。设 F 是一个根据具有结构 G 的贝叶斯网络因子化的分布。设 X_A, X_B 和 X_C 是三个随机变量集（在 G 中的节点）。如果在 G 中， X_A 和 X_B 被 X_C 所 d-分离，则有 $X_A \perp X_B | X_C$ 。

回忆一下，这是一个纯粹基于图的（因此是非参数化的）准则：它仅保证如果存在 d-分离，则在 P_θ 中必然存在条件独立性，无论参数如何 θ 。然而，可能存在一些额外的条件独立性，这些独立性并未反映在结构 G 中，而是由于特定的参数化而存在 θ 。最后，尽管将图中边的方向解释为一个变量对另一个变量的“因果”影响是很诱人的，但重要的是要注意，贝叶斯网络仅编码统计关系（条件独立性），而不是因果关系。尽管如此，它们作为因果模型的基础，在第 1.5 节中我们将介绍这些模型。

1.1.2. 马尔可夫等价

由于贝叶斯网络的有向无环图结构编码了其表示的联合分布中可以找到的条件独立性，一个可能提出的问题是这种编码是否唯一。不幸的是，答案是否定的：存在多个有向无环图结构可以表示相同的条件独立性集合。两个有向无环图 (DAGs) G_1 和 G_2 如果编码相同的条件独立性集合，则称为马尔可夫等价。这种等价关系将有向无环图的空间划分为马尔可夫等价类。图 1.1 展示了两个尽管结构不同但马尔可夫等价的有向无环图。下一定理给出了一个图形标准来检验两个图是否马尔可夫等价。

定理 1.1.4 (Verma 和 Pearl, 1990)。两个具有有向无环图结构的贝叶斯网络

G_1 和

G_2 若两个有向无环图具有相同的骨架和相同的 V 结构, 则它们是 Markov 等价的。

在此背景下, 有向图的骨架对应于同一无向图, 其边没有方向性。马尔可夫等价类可以紧凑地表示为一个完成的部分有向无环图 (CPDAG), 由等价类中所有成员共享的骨架和 v 结构组成。马尔可夫等价的存在强化了我们在上一节中的观察, 即箭头的方向不具备因果解释。

1.1.3. 抽样与概率推理

贝叶斯网络是一种生成模型, 这意味着它们可以建模整个系统的联合分布。具体来说, 如果模型的结构和参数已知, 则可以从该模型生成虚拟数据。图的无环性质暗示了一种非常简单的采样算法, 称为祖先采样。在这种方法中, 根据有向无环图的拓扑排序, 按照因子分解 (1.1.2) 中的条件概率分布, 依次对每个随机变量的值进行采样。

除了生成数据外, 贝叶斯网络主要作为一种工具来回答关于其建模系统的各种问题。这被称为概率推理。概率推理非常广泛地指估计形式为 $\mathbb{E}_{P_\theta}[f(X_1, \dots, X_d)]$ 的数量的问题, 其中 f 是一些函数。然而, 在贝叶斯网络的背景下, 它通常指的是估计条件概率的形式为 $P_\theta(Z | X)$, 其中 $\{X, Y, Z\}$ 构成 $X_1, \dots, X_d$ 的一个划分 (即, 我们在 Y 中的变量上进行边缘化)。这就是为什么推理与回答系统相关问题有关: 我们希望在观察到某些其他变量 X 的情况下, 概率性地了解某个未知量 Z , 忽略 (边缘化) 所有其他变量 Y 。未观测到的 Z 称为隐变量。尽管可以利用贝叶斯网络编码的条件独立性来简化某些特殊情况下的 $P_\theta(Z | X)$, 但总体而言, 计算这种类型的条件分布是 NP 难的 (Dagum 和 Luby, 1993)。因此, 我们经常求助于近似方法, 如变分推断, 这将在后续部分介绍。

1.1.4 参数学习

迄今为止, 我们假设贝叶斯网络的结构 G 及其条件分布的参数 θ 是已知且固定的。然而, 可以从观测数据集 $\mathcal{D} = \{\mathbf{x}^{(n)}\}_{n=1}^N$ 中学习它们中的任何一个 $n=1$ 。虽然我们在第 1.4 节将看到如何从数据中学习 G , 但一个非常常见的任务是从已知结构的贝叶斯网络中学习参数 θ 。

如果我们观察整个系统, 意味着每个数据点 $\mathbf{x}^{(n)} \in \mathbb{R}^d$ 在 $\mathcal{D}$ 中是对所有随机变量的完整赋值, 那么我们可以通过最大化可用数据的 (对数) 似然来学习参数:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \log P_\theta(\mathcal{D}) = \arg \max_{\theta} \sum_{n=1}^N \log P_\theta(\mathbf{x}^{(n)}). \quad (1.1.4)$$

得益于贝叶斯网络 (1.1.2) 中联合分布的分解, 该最大化可以完全独立地针对每个单独的参数 θ_i 进行。然而, 如果我们仅观察系统的部分状态 (*i.e.*, $\mathbf{x}^{(n)}$ 仅为部分赋值, 某些变量仍处于潜伏状态), 那么学习 θ 就需要一个概率推理步骤来“完成”数据。这就是变分期望最大化算法的基本思想, 我们将在第 1.2.3 节中介绍该算法。

1.2. 变分推断

我们考虑一种形式为 $P(\mathbf{z} | \mathbf{x})$ 的广义推理问题, 其中 $\mathbf{z}$ 是隐变量, 我们观察到的是 $\mathbf{x}$ 。例如, 这可以由一个贝叶斯网络描述的联合分布 $P(\mathbf{z}, \mathbf{x})$ 推导而来, 该网络具有已知的结构和参数化。除了某些特殊情况, 比如当贝叶斯网络接近树结构 (Zhang 和 Poole, 1996) 时, 计算这种条件分布通常是不可行的。虽然如果我们能够获得到 $P(\mathbf{z} | \mathbf{x})$ 的样本, 我们可以采取基于采样的推理方法 (我们将在第 2.1.2 节中回到这一点), 但在本节中, 我们将重点放在获得目标分布的近似值上。我们认为生成模型 $P(\mathbf{z}, \mathbf{x})$ 是已知且可处理的 (即, 如果我们拥有完整信息, 则可以计算这个联合概率)。

1.2.1. 推断作为优化问题

变分推断是将推断视为一个优化问题的一般原则。目标是用一个可处理的 (通常更简单的) 分布 $P(\mathbf{z} | \mathbf{x})$ 来近似不可处理的分布 $Q_\phi(\mathbf{z})$, 该分布来自参数化分布族 $\mathcal{Q} = \{Q_\phi | \phi \in \Phi\}$ 。例如, 变分分布族 ϕ 可能是由其自然参数参数化的正态分布集合 $\mathcal{Q}$ 。这种近似可以通过两个分布之间的某种差异度量 $\phi = (\mu, \sigma^2)$ 来量化, 我们希望最小化这一差异度量 D

$$Q_{\phi^*} = \arg \min_{Q_\phi \in \mathcal{Q}} D(Q_\phi(\mathbf{z}), P(\mathbf{z} | \mathbf{x})). \quad (1.2.1)$$

该分布 $Q_\phi(\mathbf{z})$ 近似条件 $P(\mathbf{z} | \mathbf{x})$ 对于特定的 $\mathbf{x}$, 因此它对 $\mathbf{x}$ 的依赖是隐含的; 然而, 我们将在下一节中看到如何摊销推理并考虑一个显式依赖于 $Q_\phi(\mathbf{z} | \mathbf{x})$ 的分布 $\mathbf{x}$ 为了衡量两个分布 P 之间的差异 $\mathcal{Q}$ 存在一类称为 f 发散的广义类, 基于非负凸函数 f 定义为 $f(1) = 0$, 由

$$D_f(P(\mathbf{z} | \mathbf{x}) \| Q(\mathbf{z})) = \int_{\mathbf{z}} Q(\mathbf{z}) f\left(\frac{P(\mathbf{z} | \mathbf{x})}{Q(\mathbf{z})}\right) d\mathbf{z}. \quad (1.2.2)$$

发散的一个流行例子是 Kullback-Leibler 发散, 也称为 KL 发散, 它对应于与凸函数 $f(x) = -\log x$ 相关的 f -发散:

$$\text{KL}(Q(\mathbf{z}) \| P(\mathbf{z} | \mathbf{x})) = \int_{\mathbf{z}} Q(\mathbf{z}) \log \frac{Q(\mathbf{z})}{P(\mathbf{z} | \mathbf{x})} d\mathbf{z}. \quad (1.2.3)$$

一个关于 f 发散的一般性质是, 当且仅当两个分布相等时, 它在 0 处达到最小值, 这证明了我们选择用其量化近似准确性的合理性。通过最小化

$Q_\phi(\mathbf{z})$ 与 $P(\mathbf{z} | \mathbf{x})$ 之间的差异可能显得令人生畏，因为 $P(\mathbf{z} | \mathbf{x})$ 是不可计算的，但在定义如 KL 发散这样的 f -发散时又是必要的。幸运的是，我们可以重写 KL 发散，明确地将不可计算的证据 $P(\mathbf{x})$ 分离出来

$$\text{KL}(Q_\phi(\mathbf{z}) \| P(\mathbf{z} | \mathbf{x})) = \int_{\mathbf{z}} Q_\phi(\mathbf{z}) \log \frac{Q_\phi(\mathbf{z})}{P(\mathbf{z} | \mathbf{x})} = \underbrace{\int_{\mathbf{z}} Q_\phi(\mathbf{z}) \log \frac{Q_\phi(\mathbf{z})}{P(\mathbf{z}, \mathbf{x})} + \log P(\mathbf{x})}_{\triangleq -\mathcal{J}(\phi)}. \quad (1.2.4)$$

量 $\mathcal{J}(\phi)$ 被称为证据下界 (ELBO)，其名称来源于它是 (log-) 证据 $\log P(\mathbf{x}) \geq \mathcal{J}(\phi)$ 的一个下界（由于 KL 发散是非负的）。很明显，最小化 KL 发散等价于最大化 ELBO，通常写作

$$\mathcal{J}(\phi) = \mathbb{E}_{Q_\phi}[\log P(\mathbf{x} | \mathbf{z})] - \text{KL}(Q_\phi(\mathbf{z}) \| P(\mathbf{z})). \quad (1.2.5)$$

以找到分布 $Q_\phi(\mathbf{z})$ 最佳逼近 $P(\mathbf{z} | \mathbf{x})$ (从 KL 发散的角度来看)，因此通常获得变分参数 ϕ^* 达到最大值 $\mathcal{J}(\phi)$ 利用梯度下降方法。

1.2.2. 摊销推断

这种变分方法考虑的是对单个观测值进行推断 $\mathbf{x}$ 。如果我们希望对一个新的观测值进行推断 $\mathbf{x}'$ ，则需要重复同样的过程，找到一个完全不同的最小化 KL ($Q'_\phi(\mathbf{z}) \| P(\mathbf{z} | \mathbf{x}')$)，的变分分布 $Q'_\phi(\mathbf{z})$ ，从而解决一个全新的优化问题。这很快就会变得繁琐，因为每个观测值都需要自己的变分分布。

与其将每个问题视为独立的优化问题，我们可以利用观测值之间共享的一些共同信息来简化推理。可以构造变分分布 $Q_\phi(\mathbf{z} | \mathbf{x})$ 依赖于观测值 $\mathbf{x}$ ，并学习一组变分参数 ϕ 这将适用于任何观测 $\mathbf{x}$ 这一跨观测共享参数的过程称为摊销 (Amortization, Gershman 和 Goodman, 2014; Amos, 2023)。 $Q_\phi(\mathbf{z} | \mathbf{x})$ 被称为推理模型，与生成模型相对 $P(\mathbf{z}, \mathbf{x})$ 。例如，推理模型可以定义为正态分布 $Q_\phi(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z} | \mu_\phi(\mathbf{x}), \sigma_\phi^2(\mathbf{x}))$ ，此时正态分布的参数是观测值的函数 $\mathbf{x}$ 由...参数化 ϕ 。

1.2.3. 参数估计

迄今为止，我们假设生成模型 (generative model) $P_\theta(\mathbf{z}, \mathbf{x})$ 是已知的（例如，具有固定结构和参数化的贝叶斯网络）。在实践中，我们可能希望同时学习该模型的参数 θ 以及推理模型 (inference model) 的变分参数 $Q_\phi(\mathbf{z} | \mathbf{x})$ ，基于一组观测数据 $\mathcal{D} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}\}$ 。为了通过最大似然估计在存在隐变量的情况下估计模型的参数 (latent variable) $P_\theta(\mathcal{D})$ ，通常使用期望最大化算法 (EM; Dempster 等人, 1977)。当这与变分近似方法结合时 (latent variable) $P(\mathbf{z} | \mathbf{x})$ ，这被称为变分 EM 算法 (Neal 和 Hinton, 1998)。

在这种情况下，ELBO 变为

$$\mathcal{J}(\theta, \phi) = \sum_{n=1}^N \mathbb{E}_{Q_\phi(z|\mathbf{x}^{(n)})} [\log P_\theta(\mathbf{x}^{(n)} | \mathbf{z})] - \text{KL}(Q_\phi(\mathbf{z} | \mathbf{x}^{(n)}) \| P_\theta(\mathbf{z})) \quad (1.2.6)$$

我们在此明确指出了生成模型和推理模型参数之间的依赖关系 θ 和 ϕ 。为了规范化目标函数的值，通常做法是根据观测数量重新加权 $\mathcal{J}(\theta, \phi)$

紧随 EM 算法的推导，ELBO 可以通过坐标上升的方法来最大化，交替进行 (1) 寻找变分参数 ϕ ，使其能够忠实逼近 $P_\theta(\mathbf{z} | \mathbf{x})$ (*i.e.*，即最大化 $\mathcal{J}(\theta, \phi)$ 关于 ϕ (E 步)，和 (2) 寻找生成模型的参数 θ ，使其能够最好地解释用 $Q_\phi(\mathbf{z} | \mathbf{x})$ 补充后的观测数据 (即最大化 $\mathcal{J}(\theta, \phi)$ 关于 θ ，M 步)。然而，最近由于深度学习和自动微分的进步，通常的做法是联合最大化 $\mathcal{J}(\theta, \phi)$ ，使用基于梯度的方法 (Kingma 和 Welling, 2014; Rezende 等, 2014)。

ELBO 梯度的估计。基于梯度的方法进行优化需要访问到 $\mathcal{J}(\theta, \phi)$ 的梯度。特别是， $\nabla_\phi \mathcal{J}(\theta, \phi)$ 要求计算形式为 $\mathbb{E}_{Q_\phi}[f(\mathbf{z})]$ 的量的梯度，在 (1.2.6) 的第一项中使用适当的函数 f (*e.g.*, $f(\mathbf{z}) = \log P_\theta(\mathbf{x}^{(n)} | \mathbf{z})$)。为了在计算梯度 $\nabla_\phi \mathbb{E}_{Q_\phi}[f(\mathbf{z})]$ 时考虑到分布 Q_ϕ 对参数 ϕ 的依赖性，我们可以利用变量变换 (Rubinstein, 1992; Schulman 等, 2015) 将参数 ϕ 推入期望值内部。为了使问题更具体，假设变分族的形式为 $Q_\phi(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z} | \mu_\phi(\mathbf{x}), \sigma_\phi^2(\mathbf{x}))$ 。我们可以将期望重写为 Q_ϕ 如下

$\mathbb{E}_{Q_\phi}[f(\mathbf{z})] = \mathbb{E}_{\varepsilon \sim \mathcal{N}(0,1)}[f(\mu_\phi(\mathbf{x}) + \sigma_\phi(\mathbf{x})\varepsilon)]$. (1.2.7) 这样，我们就可以通过直接对期望内部进行求导来计算该期望关于 ϕ 的梯度，因为分布 $\mathcal{N}(0, 1)$ 不再依赖于 ϕ $\nabla_\phi \mathbb{E}_{Q_\phi}[f(\mathbf{z})] = \mathbb{E}_{\varepsilon \sim \mathcal{N}(0,1)}[\nabla_\phi f(\mu_\phi(\mathbf{x}) + \sigma_\phi(\mathbf{x})\varepsilon)]$. (1.2.8) 这被称为路径导数 (Mohamed 等人, 2020)，或者重新参数化技巧 (Kingma 和 Welling, 2014)。这导致了基于 (1.2.8) 的蒙特卡洛估计的 ELBO 梯度的自然估计。另一方面，估计梯度 $\nabla_\theta \mathcal{J}(\theta, \phi)$ 通常更容易，因为不需要重新参数化。

这是一种有效的估计 ELBO 梯度的方法，当隐变量连续时。但当 $\mathbf{z}$ 是离散时，变分推断变得更加具有挑战性，因为在一般情况下没有直接对应的重参数化技巧。如果隐变量 $\mathbf{z}$ 可能取值的数量足够小，(1.2.6) 中出现的期望可以进行解析计算。然而，枚举由 $\mathbf{z}$ 所取的值通常是不可行的，而离散隐变量的存在往往需要对问题进行连续松弛 (Jang 等, 2017; Maddison 等, 2017)，或者使用通常具有高方差的得分函数估计器 (Williams, 1992; Kleijn 和 Rubinstein, 1996; Rubinstein 等, 1996)，或者通过直通估计器进行梯度的有偏估计 (Bengio 等, 2013)。

1.2.4. 觉醒-睡眠算法

在隐变量离散的情况下最大化 ELBO 的困难来自于估计 $\nabla_{\phi} \mathcal{J}(\theta, \phi)$ （在变分 EM 设置中的 E 步骤）。这是因为期望是相对于变分推断模型 Q_{ϕ} 在 KL 发散中计算的。由于 KL 发散的不对称性，选择最小化 KL ($Q_{\phi}(z | x) \| P_{\theta}(z | x)$) 这种顺序（也称为逆 KL）可能看起来是任意的，因为任何衡量这两个分布差异的测度都可以使用。虽然这在变分推断中被认为是标准做法，但我们也可以使用其他任何形式的 f -发散，其中包含另一个凸函数 f 。

类似于变分 EM 算法，睡眠-唤醒算法（Hinton 等人，1995；Bornschein 和 Bengio，2015）最小化由生成模型诱导的条件分布之间的差异 $P_{\theta}(z, x)$ 以及推理模型 $Q_{\phi}(z | x)$ 通过在两个阶段之间交替实现：（1）清醒阶段，在此阶段中，反向 KL 发散 KL 相对于生成模型参数的值 θ 。这与变分 EM 中的 M 步骤完全等价（即，最大化 ELBO 相对于 θ ）；

$$(Q_{\phi}(z | x) \| P_{\theta}(z | x))$$

（2）一个睡眠阶段，在此阶段最小化的是前向 KL 发散（与变分 EM 算法 E 步中的反向 KL 发散相反），相对于推理模型的参数 ϕ 。前向 KL 发散是 f -发散，其中 $f(x) = x \log x$ 对应于 KL $KL(P_{\theta}(z | x) \| Q_{\phi}(z | x))$ 。根据第 1.2.1 节相同的论点，这相当于最大化对数似然目标。

$$\mathcal{J}_{\text{sleep}}(\phi) = \mathbb{E}_{P_{\theta}(z, x)} [\log Q_{\phi}(z | x)]. \quad (1.2.9)$$

与在变分 EM 算法中同时更新 θ 和 ϕ 时使用反向 KL 发散不同，这不再需要推理模型可重新参数化，因此可以应用于隐变量离散的情况。然而，与 EM 算法不同，wake-sleep 算法没有保证收敛到似然的最大值（Neal 和 Dayan，1997）。

1.3 贝叶斯统计

在引入贝叶斯网络（Bayesian networks）时，我们假设它们由某些参数化参数 θ 定义，这些参数可能从数据中学习得到。这些学习到的参数有时可能不可靠，尤其是在数据量相对较少且过拟合风险较高的情况下。在这些情况下，采取贝叶斯方法并将参数视为随机量是有益的。贝叶斯推断的问题在于刻画后验分布 $P(\theta | \mathcal{D})$ ，根据贝叶斯法则定义为

$$P(\theta | \mathcal{D}) = \frac{P(\mathcal{D} | \theta)P(\theta)}{P(\mathcal{D})}, \quad (1.3.1)$$

其中 $P(\theta)$ 称为参数的先验分布， θ , $P(\mathcal{D} | \theta)$ 表示数据集的似然函数，而 $P(\mathcal{D})$ 表示边缘似然（或证据），它是通过对所有可能的 θ 进行边缘化得到的

$$P(\mathcal{D}) = \int_{\theta} P(\mathcal{D} | \theta)P(\theta)d\theta. \quad (1.3.2)$$

一般来说，计算上述边缘似然是不可行的，这使得后验分布的计算也同样不可行。一个值得注意（但罕见）的例外情况是，当似然函数和先验分布彼此“共轭”时，后验分布 $P(\theta | \mathcal{D})$ 将保持在与先验相同的分布族中。虽然我们在第 1.3.2 节中会简要提到一种变分方法来近似后验分布，但在本论文的第一部分中，近似已知归一化常数的分布将是核心内容，正如在 $P(\theta | \mathcal{D})$ 中所示。

1.3.1 贝叶斯模型平均

相比于仅对同一模型参数的不确定性进行建模，贝叶斯方法同样适用于完整的假设（ h ），其中后验分布（ $p(h | \mathcal{D})$ ）是对数据模型的分布。例如，一个假设可以是贝叶斯网络的参数及其结构的完整规范；这将在本论文的第二部分进行深入研究。我们将假设这些假设（ $h \in \mathcal{H}$ ）属于一个空间，该空间可能是离散的（例如，贝叶斯网络的有向无环图（DAG）（ G ）），连续的（例如，具有固定结构的贝叶斯网络的参数（ θ ）），或者是二者的混合（例如，结构（ G ）和参数（ θ ）都是未知的）。

贝叶斯模型选择。假设我们要在两个假设 h_1 和 h_2 之间选择，哪一个最符合可用的数据。如果我们知道后验分布，可以通过选择具有最高后验概率的假设来实现这一点。尽管我们看到这种分布通常是难以处理的，但我们幸运地可以比较概率的比率并消去难以处理的边缘似然性

$$\frac{P(h_1 | \mathcal{D})}{P(h_2 | \mathcal{D})} = \frac{P(\mathcal{D} | h_1) P(h_1)}{P(\mathcal{D} | h_2) P(h_2)}. \quad (1.3.3)$$

似然项的比率也称为贝叶斯因子（Kass 和 Raftery, 11995），并且作为衡量证据强度的测度，在先验均匀的情况下用于任一假设（Jeffreys, 1948）。更一般地说，我们可以考察整个假设族，并选择具有最高后验（对数）概率的那个

$$\hat{h} = \arg \max_{h \in \mathcal{H}} \log P(h | \mathcal{D}) = \arg \max_{h \in \mathcal{H}} \log P(\mathcal{D} | h) + \log P(h). \quad (1.3.4)$$

当假设 $h \equiv G$ 是贝叶斯网络的结构，并且 $P(\mathcal{D} | G)$ 对应于边缘似然（其中参数 θ 已被边缘化），这被称为经验贝叶斯（Carlin 和 Louis, 2000）。

贝叶斯模型平均。我们可以通过计算所有假设加权后的后验预测分布来对预测进行平均，而不是选择具有最大后验概率的单一假设。我们可以通过对新数据点 x_{new} 进行后验预测分布的计算来实现这一点。

$$P(x_{\text{new}} | \mathcal{D}) = \int_{\mathcal{H}} P(x_{\text{new}} | h) P(h | \mathcal{D}) dh, \quad (1.3.5)$$

在满足条件 $x_{\text{new}} \perp \mathcal{D} | h$ 的情况下；我们将在第 7.6.3 节回到这个条件（以及重要的是，失败案例）。例如，当假设 $h \equiv \theta$ 是具有固定结构的贝叶斯网络的参数时，这种情况成立。

贝叶斯模型组合。虽然从多个模型的预测值进行平均的方法类似于频率统计学中的集成方法（Breiman, 1996），但贝叶斯方法本质上有所不同。贝叶斯模型平均依赖于一个隐含假设，即数据是由一个确切的“真实”模型生成的（Reichelt 等, 2024; Bernardo 和 Smith, 2009）。软权重 $P(h | \mathcal{D})$ 仅反映了基于有限数据无法区分模型的统计局限性（Minka, 2000）。因此，在大量独立同分布（iid.）数据的极限情况下，如果真实模型包含在模型族中 $\mathcal{H}$ （Clydec 和 Iversen, 2013），后验概率通常会集中在单一模型上，从而忽略不一致的假设，并将 (1.3.5) 简化为单个模型的预测。

但最重要的是，尽管贝叶斯模型平均具有坚实的理论基础，其预测结果在与频率派集成方法的比较中往往表现不佳（Domingos, 2000）。有人推测，这是因为假设类不够丰富，无法捕捉现实世界的所有细微之处；假设存在的“真实”模型并不包含在 $\mathcal{H}$ 内。为了在遵循贝叶斯原则的同时解决这一问题，可以将多个模型结合在一起（Monteith 等, 2011; Kim 和 Ghahramani, 2012）。

1.3.2. 变分贝叶斯

第 1.2.3 节提出的变分方法使我们能够找到最优参数 θ 生成模型与某些隐变量的关系 z 。若感兴趣的隐变量是模型参数 θ ，尽管如此，在贝叶斯推断的情况下呢？例如，如果参数可以自然分解为 $\theta = (\theta_1, \theta_2)$ ，我们可以选择如下变分族的形式 $Q_\phi(\theta) = Q_{\phi_1}(\theta_1)Q_{\phi_2}(\theta_2)$ （平均场近似），忽略之间的依赖关系 θ_1 & θ_2 在后验近似中。

通过类似于第 1.2 节的论证，可以证明近似 $Q_\phi(\theta)$ 与不可计算的后验 $P(\theta | \mathcal{D})$ 之间的 KL 发散可以分解为其中 $\mathcal{J}(\phi_1, \phi_2)$ 是一个证据下界（ELBO），可以写作

$$\text{KL}(Q_\phi(\theta) \| P(\theta | \mathcal{D})) = -\mathcal{J}(\phi_1, \phi_2) + \log P(\mathcal{D}), \quad (1.3.6)$$

$$\mathcal{J}(\phi_1, \phi_2) = -\text{KL}(Q_{\phi_1}(\theta_1) \| \tilde{Q}_1(\theta_1)) + C_2(\phi_2) \quad (1.3.7)$$

$$\text{where } \tilde{Q}_1(\theta_1) \propto \exp\left(\int_{\theta_2} Q_{\phi_2}(\theta_2) \log P(\mathcal{D} | \theta_1, \theta_2) d\theta_2\right), \quad (1.3.8)$$

and $C_2(\phi_2)$ is only a function of ϕ_2 (independent of ϕ_1). In a completely symmetric fashion, it is also easy to show that the ELBO can be written as $\mathcal{J}(\phi_1, \phi_2) = -\text{KL}(Q_{\phi_2}(\theta_2) \| \tilde{Q}_2(\theta_2)) + C_1(\phi_1)$, where $\tilde{Q}_2(\theta_2)$ is defined similarly to (1.3.8), but replacing Q_{ϕ_2} by Q_{ϕ_1} , and integrating wrt. θ_1 .

我们可以找到后验分布的最佳近似 $P(\theta | \mathcal{D})$ （在 KL 发散的意义上）通过最大化 ELBO $\mathcal{J}(\phi_1, \phi_2)$ 在 (1.3.6)。松散地受到第 1.2.3 节中变分 EM 的启发，我们可以使用坐标上升法来最大化它，即重复（1）最小化 $\text{KL}(Q_{\phi_1}(\theta_1) \| Q_1(\theta_1))$ 关于（wrt.） ϕ_1 在固定的情况下 Q_{ϕ_2} ，以及（2）最小化 $\text{KL}(Q_{\phi_2}(\theta_2) \| Q_2(\theta_2))$ 关于（wrt.） ϕ_2 在固定的情况下 Q_{ϕ_1} 。这

算法称为变分贝叶斯 (Beal, 2003)。在某些情况下, 上述最小化步骤之一可以进行解析计算。

1.4 结构学习

我们在第 1.1.4 节和第 1.2.3 节中讨论了如何基于一组 (可能不完整的) 观测数据 θ 来学习参数 $\mathcal{D}$, 前提是贝叶斯网络的结构 G 已知且固定。在本节中, 我们将更进一步, 考虑从数据集 $\mathcal{D}$ 中学习贝叶斯网络结构的“逆问题” G 。这是一个在科学发现中至关重要的问题, 因为揭示系统中潜在的新统计依赖关系是主要目标, 其重要性至少与使用模型进行推理相当。

1.4.1. 忠实性与可识别性

为了学习贝叶斯网络的结构, 必须确保可以从数据中发现的所有条件独立性都能在最终找到的图中得到反映。否则, 无论有多少数据可用于准确检测条件独立性, 这个逆问题都是不适定的。这被称为数据生成分布的“忠实性”。

定义 1.4.1 (忠实性)。若分布 P 对有向无环图 G 忠实, 则在 P 中的任何条件独立性都能反映在 G 中的 d-分离上。设 A, B 和 C 是 G 中的三个节点集, 它们各自对应的随机变量集为 X_A, X_B 和 X_C 。如果 $X_A \perp\!\!\!\perp X_B \mid X_C$, 那么在 G 中, A 和 B 被 C d-分离。

忠实性可以非正式地视为命题 1.1.3 中全局马尔可夫性质的“逆”。尽管任何由贝叶斯网络表示的分布都满足全局马尔可夫性质, 但忠实性的概念并非自动成立。

例 1.4.2 (违反忠实性)。考虑由图 1.2a 所示的贝叶斯网络描述的联合分布 $P(X, Y, Z)$ 。贝叶斯网络的结构遵循条件分布的“自然”描述, 其中 Y 依赖于 X , 而 Z 依赖于 X 和 Y 。由于图 G 是完全的, 它不会先验地编码任何 (非平凡的) 条件独立性。然而, 可以证明联合分布 $P(X, Y, Z)$ 是一个多元正态分布, 其唯一的条件独立性是 $X \perp\!\!\!\perp Z$ 和 $X \not\perp\!\!\!\perp Z \mid Y$ 。因此, 分布 P 对 G 不忠实, 从 P 学习贝叶斯网络结构的任何尝试最多只能得到图 1.2b 所示的有向无环图。

幸运的是, 对于几乎所有的根据某个有向无环图分解的分布 P , 忠实性都是得到保证的, 这意味着违反忠实性的分布集合的测度为零 (Koller 和 Friedman, 2009, 定理 3.5)。在上述例子中, 条件分布被精心设计为不忠实的 (Spirtes 等人, 2000, 定理 3.2)。因此, 在本论文中, 我们将始终假设忠实性而不再次明确提及。




图 1.2. 违反忠实性假设的分布示例。(a) 贝叶斯网络及其分解中的条件分布示例 ($P(X, Y, Z)$)。(b) 从 $P(X, Y, Z)$ 中提取的唯一条件独立陈述是 $X \perp\!\!\!\perp Z$ 和 $X \not\perp\!\!\!\perp Z | Y$ 。以完全非参数化的方式, 这个有向无环图是唯一一个精确表示这两个陈述的图。

回到寻找贝叶斯网络结构的问题上, 以下定理表明, 如果我们能够完全访问分布 P , 那么在忠实性的前提下, 我们可以恢复该有向无环图直到马尔可夫等价类。

定理 1.4.3 (结构可识别性)。如果分布 P 对 G^* 忠实, 则可以从 G^* 识别出 P 的马尔可夫等价类。

在没有任何假设的情况下, 恢复 DAG (有向无环图) 仅限于马尔可夫等价性的限制是不可避免的, 因为马尔可夫等价结构编码相同的条件独立性。如果对数据生成过程做出额外假设, 则可能实现更强的可识别性形式, 有时甚至可以识别出分布忠实的单一 DAG。例如, 如果 P 是非线性加性噪声模型, 其中每个变量的结构方程模型可以表示为

$$X_i := f_i(\text{Pa}_{G^*}(X_i)) + \varepsilon_i \quad \text{with} \quad \varepsilon_i \sim \mathcal{N}(0, \sigma_i^2), \quad (1.4.1)$$

and where the functions f_i are non-linear and depend on the parent variables of X_i , then the DAG G^* is identifiable from P (Peters et al., 2014). Another classic example of identifiability of a single DAG is in the case where P is a linear-Gaussian model with equal variance (i.e., $\sigma_i^2 = \sigma^2$ in (1.1.3); Peters and Bühlmann, 2014). We can also further identify the structure more precisely if we have access to experimental data (Hauser and Bühlmann, 2012); see Section 1.5.1 for an informal example.

1.4.2. 基于评分的方法

如果我们完全知晓 P , 那么这将导致一种简单的结构学习策略 (再次强调, 是在马尔可夫等价性的意义上): 找出在 P 中编码的条件独立性, 并构建一个遵循这些独立性的结构 (从 d-分离的角度)。然而, 在实践中, 我们无法直接访问到 P 本身, 而只能获得有限的观测数据集 $\mathcal{D}$ 。基于约束的方法以类似的方式进行结构学习, 通过使用频率主义独立性检验来测试数据中的条件独立性 (Spirtes 等人, 2000; Pearl, 2009)。

在本文中更为重要的是, 基于评分的方法将学习贝叶斯网络结构的问题视为一个优化问题。对于某个评分函数 “score($G; \mathcal{D}$)”, 该函数量化了 G 与数据集的契合程度, 问题就变成了寻找一个有向无环图

maximizes this score:

$$\hat{G} = \arg \max_{G \in \text{DAG}} \text{score}(G; \mathcal{D}). \quad (1.4.2)$$

评分函数。评分函数最自然的例子是似然评分，它对应于最大似然模型的对数似然值

$$\text{score}_L(G; \mathcal{D}) \triangleq \max_{\theta} \log P(\mathcal{D} \mid G, \theta) = \log P(\mathcal{D} \mid G, \hat{\theta}_{\text{MLE}}). \quad (1.4.3)$$

该评分具有一个显著的缺点，即不可避免地倾向于密集结构（类似于机器学习中的标准过拟合效应），这意味着使用此评分总是会导致所有节点相互连接的平凡结构（Koller 和 Friedman, 2009）。为了缓解这一问题，可以通过在 G 中的自由参数数量来正则化此评分，从而惩罚密集结构。贝叶斯信息准则（BIC）评分（Schwarz, 1978）就是一个例子。另一个我们将广泛用于第七章的正则化评分是所谓的贝叶斯评分，它将结构学习视为整个有向无环图空间上的贝叶斯模型选择问题（在第 1.3.1 节中介绍），评分为

$$\text{score}_B(G; \mathcal{D}) \triangleq \log P(\mathcal{D} \mid G) + \log P(G). \quad (1.4.4)$$

尽管计算边缘似然 $P(\mathcal{D} \mid G)$ 在一般情况下是不可行的，但在附录 B.1.1 中我们将看到，对于某些类别的贝叶斯网络（例如线性-高斯模型或具有狄利克雷先验的离散贝叶斯网络），这个评分可以进行解析计算。

评分的优化。尽管概念上简单，但实践中 (1.4.2) 中的优化问题由于两个原因极其具有挑战性：

- (1) 有向无环图（DAG）的空间是离散的，这意味着我们无法使用连续优化中的常规工具，如基于梯度的方法；
- (2) 有向无环图（DAG）的空间在组合上是庞大的。顶点上的有向无环图数量为 d 可以构建的节点数量级为 $2^{\Theta(d^2)}$ （罗宾逊, 1973；罗迪奥诺夫, 1992）。为了提供一些视角，大约有 10^{18} 有向无环图（DAGs）之上 $d = 10$ 个节点，大约 10^{72} 有向无环图（DAGs）之上 $d = 20$ 个节点。

这意味着这个组合优化问题是 NP 难的。更糟糕的是，即使我们将搜索空间限制为最多有 p 个父节点的有向无环图（DAG）（其中 $p \geq 2$ ），该问题仍然保持 NP 难（Chickering, 1996）。因此，需要依赖启发式方法来寻找最大化得分的 DAG（Cooper 和 Herskovits, 1992），例如进化算法（Wong 和 Leung, 2004）或贪婪方法（Chickering, 2002；Tsamardinos 等, 2006）。

1.4.3. 连续松弛

另一种最近流行的方法是将组合优化问题 (1.4.2) 放松为一个连续且受限的优化问题。这一方法源于 Zheng 等人 (2018) 的观察，即一个具有邻接矩阵 A 的图 G 是一个 DAG 当且仅当

$$\text{Tr}(\exp(A)) = d, \quad (1.4.5)$$

其中是图中节点的数量，在

d 有效地计算图中循环的数量，并根据其长度重新加权，等于 d 意味着有向无环图中存在的唯一“循环”是长度为 0 的那些。基于邻接矩阵操作的其他有向无环图特征也已存在（Yu 等，2019；Yu 等，2021；Bello 等，2022）。如果得分函数可以表示为邻接矩阵的函数，就像上一节提到的得分那样，我们可以将 (1.4.5) 视为一个约束条件，并在所有松弛邻接矩阵的空间中进行搜索

$$\max_{A \in [0,1]^{d \times d}} \text{score}(A; \mathcal{D}) \quad (1.4.6)$$

$$\text{s.t. } \text{Tr}(\exp(A)) = d. \quad (1.4.7)$$

该约束优化问题可以通过梯度方法求解，前提是得分函数相对于 A 可微，例如使用增广拉格朗日算法（Bertsekas，2016）。尽管郑等人（2018）仅将此应用于线性-高斯模型的发现，但我们将其扩展到非线性模型（Lachapelle 等，2020）。

1.4.4. 可识别性与贝叶斯视角

定理 1.4.3 的结果仅保证了马尔可夫等价类的可识别性 G^* 如果我们知道 F 本身。然而，在结构学习的实际操作中，我们无法访问整个分布，而只能访问来自该分布的有限数据集 $\mathcal{D}$ 的样本；可识别性实际上是一个渐近的概念，在无限数据的极限下成立。实际操作中的风险有两方面：(1) 我们可能没有足够的数据在 $\mathcal{D}$ 中完全识别出的马尔可夫等价类（MEC） G^* ，以及 (2) 即使我们识别出了它，一个结构学习算法也可能选择等价类中的任意元素，因为在 MEC 内存在不可识别性。

为了获得更全面的观点，我们可以采取贝叶斯方法，正如我们在第 1.3 节所述，通过后验分布获得一种“软”的识别概念（Cole，2020）。在模型不可识别的情况下，这一点会在后验分布中反映出来 $P(G | \mathcal{D})$ ，而后验分布则在整个不可识别类上具有支撑（例如，在无限数据极限下的 MEC），前提是先验赋予这些模型非零概率。但先验可以提供额外信息来打破非识别情况下的对称性（Lindley，1972）；例如，考虑诱导稀疏性的惩罚以证明可识别性变得越来越流行（Lachapelle 等，2024）。如果模型是可识别的（例如，识别到单一的有向无环图，参见第 1.4.1 节中的示例），那么在满足某些正则条件下，后验分布是一致的，并收敛到狄拉克分布（例如，通过 Bernstein-von Mises 定理；Ma，2022）。

这还不包括贝叶斯推断的主要优势：能够处理模型的不确定性，尤其是在数据集有限的情况下。所有这些优势促使我们在结构学习中采用贝叶斯方法，这一方法将在本论文的第二部分详细阐述。然而，这将以需要近似一个难以处理的后验分布为代价。

1.5. 因果性

在第 1.1 节中，我们强调了贝叶斯网络中的有向边并不编码任何直接因果关系的概念。这些模型仅用于描述我们被动观察的系统的统计关系。另一方面，因果模型扩展了贝叶斯网络的概念，此时 DAG 的边对应于直接因果关系。尽管功能上相似，但因果模型不仅允许我们被动地观察系统，还能够推理如何积极地对其进行实验，就像科学家为了验证假设所做的那样。这是通过干预的概念来实现的。因果模型还使我们能够推理虚构的情况，即“反事实”（Pearl, 2009），这部分内容我们不作详细说明。

1.5.1. 干预

我们先通过一个示例来突出观察系统与对系统进行干预之间的基本差异。假设我们有两个感兴趣的随机变量：一个变量 X 编码天气（例如作为分类变量），另一个变量 Y 编码气压计的测量值（连续测度的大气压力）。从历史数据来看，被动地观察天气并每天记录相应的气压计读数，显然这两个变量之间存在依赖关系（高压与好天气相关联），特别是只有有向无环图 DAGs $X \rightarrow Y$ 或 $Y \rightarrow X$ 可以编码该系统。然而，根据第 1.1.2 节关于马尔可夫等价性的讨论，这两个有向无环图编码相同的条件独立性（由定理 1.1.4），因此它们可以同样地建模该系统。

如果我们只能被动观察 X & Y ，那么这是我们唯一能得出的结论（定理 1.4.3）。但假设我们主动改变气压计的测量值（例如，将指针移向更高的数值）。这（不幸的是）对天气没有影响。主动改变 Y 值的操作称为对 Y 进行干预，它会在 (X, Y) 上诱导出一种分布，该分布具有使关于 X 的边缘分布不变的性质（即，干预 Y 不会影响我们在 X 上的观测分布）。因此我们可以自信地得出结论，最好描述系统的因果模型是 $X \rightarrow Y$ (*i.e.* (天气导致气压计的测量值))。

我们观察到，对系统进行干预会诱导出感兴趣的变量上的新联合分布。现在我们将更一般地形式化这一概念，适用于具有有向无环图结构的因果模型 G 。对于一组索引 $\mathcal{I}$ ，如果成对 $\{X_{\mathcal{I}}, X_{-\mathcal{I}}\}$ 形成对 $X_1, \dots, X_d$ 的划分，则通过将变量 $X_{\mathcal{I}}$ 设置为 $x_{\mathcal{I}}$ 所引起的干预分布由以下给出

$$P_{\theta}(X_{-\mathcal{I}} \mid \text{do}(X_{\mathcal{I}} = x_{\mathcal{I}})) = \mathbb{1}(X_{\mathcal{I}} = x_{\mathcal{I}}) \prod_{i \notin \mathcal{I}} P(X_i \mid \text{Pa}_G(X_i); \theta_i). \quad (1.5.1)$$

我们使用记号“ $\text{do}(X_{\mathcal{I}} = x_{\mathcal{I}})$ ”来区分它与标准条件化，并使干预的主动性更加明确（即执行一个动作）。从这个方程中，可以清楚地看出干预对分布的影响：它设定了变量的值 $X_{\mathcal{I}}$ ，而不考虑它们父节点的值在 G 。从图形的角度来看，这可以被视为用截断的有向无环图（DAG）来编码该分布，其中进入 $X_{\mathcal{I}}$ 的边已被移除；参见图 1.3。虽然我们看到贝叶斯网络编码了一个关于 $X_1, \dots, X_d$ 的联合分布




图 1.3. 干预对因果图的影响。(a) 表示分布族的因果图示例，包括联合（观察性）分布 $P(A, B, D, E, L, S, T, X)$ 。(b) 对随机变量干预后的残缺图 E （并将其设置为值 e ）；变量 E 的入边已被移除。

因果模型有效地表示了一组分布族，每个可能的干预对应一组随机变量的分布；这特别包括了“观察”分布，即没有任何变量被干预的情况，与贝叶斯网络中表示的联合分布相匹配。通过对系统进行干预收集的数据称为干预数据，与观察数据相对（例如，我们在前面部分考虑的观察数据集 $\mathcal{D}$ ）。

回到天气和气压计的例子，并使用我们的新符号，我们得出结论：对于某个压力值 y , $P_\theta(X \mid \text{do}(Y = y)) = P_\theta(X)$ ；干预气压计对天气没有影响。这与条件分布 $P_\theta(X \mid Y = y) = P_\theta(X, Y = y) / P_\theta(Y = y)$ 形成对比，后者仅编码统计关系；如果 y 较大，则有较好的天气的概率更高，通常与 $P_\theta(X)$ 不同。

1.5.2. 因果可识别性

在第 1.4.1 节中，我们关注了贝叶斯网络（或其马尔可夫等价类）结构的可识别性问题，特别是在结构学习的背景下。但可识别性具有多种形式，尤其是在因果关系领域。例如，在因果推断的背景下，可识别性也可以指通过“do”算子表达干预查询的能力，并将其转换为可以通过数据估计的数量（即条件分布）(Bareinboim 等, 2022)。最近，因果表示学习背景下的可识别性也引起了越来越多的关注 (Schölkopf 等, 2021; Lachapelle 等, 2023)。

回到结构可识别性的问题上，这与本论文研究的设置更为一致。我们对贝叶斯网络的许多考虑同样直接适用于因果模型。特别是，大多数用于因果结构学习（也称为因果发现）的工具都是从之前介绍的内容衍生出来的。然而，干预的存在有助于更精确地识别因果结构（比马尔可夫等价类更精确；Hauser 和 Bühlmann, 2012）。当用于结构学习的数据集还包括干预数据时，这一点尤为有用。

第一部分

生成流网络

第二章

结构对象上的概率推理

本章包含以下论文的内容： • Moksh Jain, Tristan Deleu, Jason Hartford, Cheng-Hao Liu, Alex Hernandez-Garcia, Yoshua Bengio (2023). GFlowNets 在 AI 驱动的科学中的应用. 数字发现, 英国皇家化学学会.

- 特里斯坦·德勒 帕迪代赫·努里, 尼古拉伊·马尔金, 多伊纳·普雷库普, 约书亚·本乔 (2024)。多路径环境中的离散概率推理作为控制。人工智能中的不确定性会议 (UAI)。

在本论文中，我们将重点研究从定义在高度结构化对象上的分布进行采样的方法，并在第二部分从贝叶斯视角探讨结构学习的应用。通过本章中的多个示例，我们将看到如何将从这类分布中采样视为一个顺序决策问题，最终将其作为控制问题来解决，尽管是在有限的情况下。本论文第一部分的目标将是扩展这些思想，以便更广泛地应用它们。

2.1. 基于能量的模型

在本论文的第一部分中，我们关注从基于能量的模型 (EBM; LeCun 等, 2006) 中抽取样本的广泛问题，该模型定义在一个离散且结构化的样本空间上。 $\mathcal{X}$ “结构化”的方面将在第 2.1.3 节进一步展开。给定一个能量函数 $\mathcal{E}(x)$ ，我们假设其已知且固定（即，这是一个可以查询任何 $x \in \mathcal{X}$ ），我们的目标是从以下吉布斯分布中抽样：

$$P^*(x) = \frac{\exp(-\mathcal{E}(x))}{Z}. \quad (2.1.1)$$

该能量函数编码了对某些对象的偏好概念，这种偏好可以有不同的形式（例如，图像与标签之间的兼容性，或者句子与

英语及其候选的法语翻译)。通常使用基于能量的方法是方便的,因为它可以是任意函数,并不一定需要归一化。所有与归一化相关的复杂度都推迟到了划分函数 $Z = \sum_{x' \in \mathcal{X}} \exp(-\mathcal{E}(x'))$, 当空间 $\mathcal{X}$ 在组合上非常大时,这通常是不可处理的,而这正是我们在大多数应用中所考虑的情况。

2.1.1. 为何从基于能量的模型中采样?

尽管从 (2.1.1) 中采样的问题乍一看似乎有些局限,但它实际上是基于能量的模型推理和学习的基本组成部分。

基于采样的推理。 概率推理作为一个一般原则,可以表述为计算如下形式的量 $\mathbb{E}_{P^*}[f(x)]$, 并选择合适的函数 f , 其中期望是关于 Gibbs 分布取的。例如,如果我们想要找到概率 $P^*(x \in A)$ 具有某些属性的对象 A , 然后我们会使用 $f(x) = \mathbb{1}(x \in A)$ 在我们的通用形式中。即使在某些特定情况下可能实现精确推理 (Wainwright 和 Jordan, 2008), 通常这些量只能被近似,因为期望需要对 (组合上庞大的) 空间中的所有元素进行求和 $\mathcal{X}$ 。若我们有一个过程可以从 (2.1.1) 中获取样本, 则可以得到此期望的蒙特卡洛估计: 如果 $\{x^{(1)}, \dots, x^{(N)}\}$ 是独立同分布的样本来自 P^* , 然后

$$\mathbb{E}_{P^*}[f(x)] \approx \frac{1}{N} \sum_{n=1}^N f(x^{(n)}). \quad (2.1.2)$$

此感兴趣查询的估计值是无偏的,并且根据大数定律是一致的。这是对第 1.2 节所述变分推断的一种替代方法。

学习能量函数。 仅在此段落中,我们将假设能量函数 $\mathcal{E}_\theta(x)$ 由某些未知参数 θ 参数化,我们希望基于观察数据集 $\mathcal{D} = \{x^{(1)}, \dots, x^{(N)}\}$ 来学习这些参数。学习参数 θ 可以通过最大化数据在 (现在参数化的) 吉布斯分布 P^* 下的 (平均) 对数似然性来完成 $\mathcal{L}_\theta(x)$

$$\mathcal{L}(\theta) \triangleq \mathbb{E}_{P_{\mathcal{D}}}[\log P_\theta^*(x)] = -\frac{1}{N} \sum_{n=1}^N \mathcal{E}_\theta(x^{(n)}) - \log Z_\theta, \quad (2.1.3)$$

其中 $P_{\mathcal{D}}$ 是数据集上的经验分布 $\mathcal{D}$ 。这可以通过梯度方法来最大化,只要可以轻松计算出关于参数 θ 的 $\mathcal{L}(\theta)$ 的梯度。可以证明 (Hinton, 2002), 该梯度具有特别简单的形式

$$\nabla_\theta \mathcal{L}(\theta) = -\mathbb{E}_{P_{\mathcal{D}}}[\nabla_\theta \mathcal{E}_\theta(x)] + \mathbb{E}_{P_\theta^*}[\nabla_\theta \mathcal{E}_\theta(x)]. \quad (2.1.4)$$

虽然第一项可以通过对 $\mathcal{D}$ 进行平均来轻松计算,前提是能够计算 $\nabla_\theta \mathcal{E}_\theta(x)$, 但第二项是在吉布斯分布本身下的期望值,我们在 (2.1.2) 中看到,如果我们能够从 P 中采样,就可以获得其蒙特卡洛估计值。 $\hat{\theta}^*$

然而,除了统计学上的单一兴趣外,抽样在科学研究中也扮演着关键角色,例如在生成具有特定结构和性质的多样化蛋白质方面 (Watson 等, 2023; Huguet 等, 2024)。与科学研究相一致,抽样同样发挥了作用。

Algorithm 1 Metropolis-Hastings algorithm

Inputs: An initial state $x^{(0)} \in \mathcal{X}$, the proposal distribution $Q(x' | x)$.

```
1: for  $t \geq 0$  do
2:   Sample a proposed move:  $x' \sim Q(x' | x^{(t)})$ 
3:   Compute the acceptance probability  $A(x^{(t)}, x')$  (2.1.5)
4:   Sample  $u \sim U(0, 1)$ 
5:   Update the state:
       
$$x^{(t+1)} = \begin{cases} x' & \text{if } u \leq A(x^{(t)}, x') \quad (\text{accept}) \\ x^{(t)} & \text{otherwise} \quad (\text{reject}) \end{cases}$$

```

在主动学习中发挥着重要作用，其中最具信息量和前景的元素被采样用于后续评估。最后，讨论采样时不能不提生成式人工智能当前的巨大影响（Brown 等，2020；Betker 等，2023），它似乎拥有无限的潜在能力，但也伴随着社会风险（OECD，2024）。

2.1.2. 利用 MCMC 从 EBM 中采样

从能量基模型（或归一化常数已知的大分布）采样的最灵活工具之一是一种称为马尔可夫链蒙特卡洛（MCMC；Gelfand 和 Smith，1990）的技术。其思想是在样本空间上构建一个马尔可夫链 $\mathcal{X}$ 使其平稳分布为 (2.1.1) 中的吉布斯分布，这意味着在运行足够长时间后，样本最终将大致按照该分布分布 P^* 。构建这样一个马尔可夫链的一种流行策略是 Metropolis-Hastings 算法（Metropolis 等，1953；Hastings，1970），其中从当前状态 $x \in \mathcal{X}$ 转移到新状态 $x' \in \mathcal{X}$ 的提议由一个已知的（且易于采样的）分布给出 $Q(x' | x)$ 。这种提议分布通常是关于局部“突变”的分布 x ，*e.g.* 在图中添加或移除单个边；另见第 7.1.1 节的一个示例，其中 P^* 是一个关于图的概率分布。为了确保该链的平稳分布确实是 P^* ，新状态 x' 仅在满足以下条件时被接受（ $x^{(t+1)} = x'$ ）随机地以概率 $\min(1, A(x^{(t)}, x'))$ ，其中 $A(x^{(t)}, x') \triangleq \frac{P^*(x')Q(x^{(t)} | x')}{P^*(x^{(t)})Q(x' | x^{(t)})} = \frac{Q(x^{(t)} | x')}{Q(x' | x^{(t)})} \exp(\mathcal{E}(x^{(t)}) - \mathcal{E}(x'))$ ，(2.1.5)，否则，状态保持不变（ $x^{(t+1)} = x^{(t)}$ ）。我们可以观察到接受概率 A 仅取决于能量差之间 $x^{(t)}$ 和 x' ，而不依赖于难以处理的配分函数 Z 。对于足够大的 $t \gg 1$ ， $x^{(t)}$ 通过此过程采样的样本近似服从于 P^* 。Metropolis-Hastings 算法的伪代码见算法 1

值得注意的是，通过 MCMC 获得样本的质量在很大程度上取决于马尔可夫链接近平稳状态的程度。达到这一状态所需的时间称为混合时间，它既依赖于目标分布 (2.1.1) (以及由此延伸的能量函数 $\mathcal{E}(x)$)，也依赖于提议分布。例如，当目标分布具有多个模式，并且这些模式之间存在大面积的低概率区域时，MCMC 已知会缓慢收敛，并且仅此而已 $Q(x' | x)$

提出了局部移动围绕 x (罗伯茨和特维迪 (2008))。为了最大化获得近似样本的机会 P^* , 通常的做法是在“预热期”丢弃早期样本。尽管有关分析和改进 MCMC 方法收敛性的文献非常丰富 (斯文德森和王, 1986; 罗伯特等, 2018) , 但对这一主题的详尽讨论超出了本论文的范围。除了混合问题外, MCMC 还受到自相关的影响: 由于其顺序性质, 样本可能高度相关, 从而使得估计量 (2.1.2) 中的数量效率降低。

这一算法 (以及马尔可夫链蒙特卡洛方法) 的重要性不容小觑。它被《IEEE 科学与工程计算》杂志评为 20 世纪十大算法之一 (Beichl 和 Sullivan, 2000 年) , 并且在重大科学发现中起到了基石作用, 包括高能物理和格点场论 (Lautrup, 1985 年) , 宏观经济政策效果的估计 (该研究获得了 2005 年的诺贝尔经济学奖; Sims, 2012 年) , 以及不同尺度下复杂化学系统的建模 (Minary 和 Levitt, 2010 年; 该研究再次赢得了 2013 年的诺贝尔化学奖; Levitt, 2014 年) 。

利用梯度信息。在上述 Metropolis-Hastings 算法的标准版本中, 提议分布 $Q(x' | x)$ 不了解当前状态周围的“能量表面” $\mathcal{E}(x)$ (能量差异仅出现在 (2.1.5) 中) , 这意味着移动是非自适应的。相反, 我们可以设想在 $\mathcal{E}(x)$ 变化较大时提出较大的移动。假设本段中 $\mathcal{X} \subseteq \mathbb{R}^d$ 是一个连续样本空间, 并且能量函数可微; 这是在 EBM 文献中被广泛研究的设置。我们可以使用 Langevin 动力学来提议新移动, 其中 $Q(x' | x) \propto \exp\left(-\frac{1}{4\beta}\|x' - x + \beta\nabla_x \mathcal{E}(x)\|^2\right)$, (2.1.6) 其中 $\beta > 0$ 是一个固定的步长。在算法 1 中使用这个提议分布称为 Metropolis 调整的 Langevin 算法 (MALA; Roberts 和 Tweedie, 1996) 。Langevin 蒙特卡洛方法由于其在基于评分模型中的应用 (Song 和 Ermon, 2019) 而最近变得流行, 这些模型与 EBM 密切相关。然而, 尽管有一些工作将这些想法应用于离散空间 (Grathwohl 等, 2021; Zhang 等, 2022c) , 但总体而言, 这些方法不能应用于我们的场景, 因为 $\mathcal{X}$ 是离散和有结构的, 因为它们依赖于评分函数 $\nabla_x \mathcal{E}(x)$, 在我们的情况下事先未定义。

2.1.3. 组合对象

我们将注意力集中在样本空间 $\mathcal{X}$ 为离散且具有结构的情况。这种空间的结构通常来自于待生成对象的组合特性, 意味着元素 $x \in \mathcal{X}$ 可以分解成各个部分, 这些部分又可以重新组装成新的对象。我们在图 2.1 中提供了多个组合对象及其组成部分的例子。在本论文中, 我们特别感兴趣的是, 例如可以将编码贝叶斯网络结构的有向无环图 (DAG) 视为连接固定节点集的一组边的集合。我们故意使组合性的概念较为模糊, 以避免过于限制, 并可能考虑一些较为宽松的概念




图 2.1. 组合对象示例。有机分子是由多个分子片段组合而成的集合。蛋白质序列是一系列氨基酸。无机材料由多种元素组成（通常排列成晶体结构；Mila AI4Science 等，2023）。有向无环图是由一系列边组合而成，这些边不会形成任何循环。

组合性。例如，在自然语言的背景下，一个句子可以被视为具有“组合性”，即它是由一系列词语组成的。

若要在组合对象上的分布进行采样，则可能需要使用 MCMC 方法。在样本空间中移动所需的局部“突变”可能对应于将一个部件替换为另一个部件，或将部件添加到/从对象中移除，前提是这些操作能够生成另一个有效的对象在 $\mathcal{X}$ 。这相当受限，并可能导致验证移动是否合法的复杂性显著增加。例如，从分子中移除一个片段可能是也可能不是物理上合理的。在有向无环图（DAGs）上下文中应用 MCMC 将在第 7.1.1 节详细说明。

2.2. 边缘采样作为顺序决策

与其直接从 P^* 中采样一个对象，可能通过 MCMC 在 $\mathcal{X}$ 中移动来实现，我们可以利用每个对象的组合结构 $x \in \mathcal{X}$ ，从零开始通过顺序添加部分来构建它。在本节中，我们将通过多个示例展示如何通过一系列（更简单）的决策从组合对象的复杂分布中进行采样。我们还将介绍图论和概率论的概念，这些概念将在本论文的其余部分中发挥核心作用。

2.2.1. 高尔顿板

在 1889 年关于《自然继承》的著作中，弗朗西斯·高尔顿提出了一种机械装置来说明他所谓的“频率曲线”。该装置被称为高尔顿板，如图所示

图 2.2a 由顶部的一个漏斗组成，引导珠子进入一系列呈梅花形排列的钉子。由于重力作用，珠子会从每个钉子上向左或向右弹开，经过每一排后最终落入装置底部的某个槽中。Galton (1889) 观察到，随着珠子和槽的数量增加，珠子在板底形成的形状类似于“频率的正态曲线”；这正是我们现在所知的中心极限定理的一个例证。




图 2.2. 加尔通板。(a) 加尔通板的可视化展示，蓝色珠子从装置顶部落下并进入五个槽之一。(b) 珠子落入特定槽可能经过多条路径，弹过不同顺序的钉子。(c) 作为尖状有向无环图 (DAG) 的加尔通板表示法 G 。中间状态 s_i 代表按棋盘式排列的不同钉子，终止状态 x_k 代表各个槽。

超越这一渐近奇观以及高尔顿从其中得出的令人不安的结论，该模型足够简单，我们可以分析其在固定数量的 $n + 1$ 个槽（记为 $\{0, \dots, n\}$ ）中的行为。假设某个珠子每次弹起时向左移动的概率为 p ，向右移动的概率为 $1 - p$ （实际上， $p = 0.5$ ），众所周知，珠子落入的槽是一个随机变量 B ，其分布遵循二项式分布，其中

$$P(B = k) = \binom{n}{k} p^k (1 - p)^{n-k}. \quad (2.2.1)$$

尽管二项分布可以表示为能量函数的形式，其样本空间 $\mathcal{X} = \{0, \dots, n\}$ 是离散的，但这个例子与我们在第 2.1.3 节中强调的设置有所不同，因为 $\mathcal{X}$ 没有明显的结构。然而，这作为一个直观的例子说明了一般原则，我们将在此后的论文中广泛使用这一原则：我们有一个过程可以从一个更复杂的分布中获取样本，作为一系列简单的决策序列。

在我们的示例中，我们从中采样的分布可以说是复杂的，因为珠子落入特定槽的概率遵循二项分布 $\text{Binomial}(n, p)$ ，对应的决策序列是在每个针处向左移动的概率为 p （或 $\text{Bernoulli}(p)$ ）。

第二个基本原则是我们关注的是珠子落入哪个槽的概率分布，而不是珠子可能采取的确切路径的分布（即它们如何到达某个槽）。

我们只关心顺序过程的结果，而不关心决策的确切序列。例如，当 $p = 0.5$ 时，由于有许多不同的路径可以到达这些槽，珠子更有可能落在中间的槽里（参见图 2.2b）；这一点

二项式系数在 (2.2.1) 中反映了到达 bin k 路径的数量。通过调整每个独立决策的概率分布，可以在这一过程结束时得到各种边缘分布；我们的目标最终将是仔细调整这些分布，使得这个边缘分布与一个复杂的感兴趣分布相匹配。

2.2.2. 图论基础

为了形式化高尔顿板的例子，并为进一步复杂的场景做准备，我们需要引入一些图论的概念。我们将每个决策点（例如，每个钉子）表示为一个状态 s 在一个状态空间中 $\mathcal{S}$ 连接成一个有向无环图，以表示每个决策的结果（参见图 2.2c）。

定义 2.2.1（有根有向无环图）。设 $\bar{\mathcal{S}} = \mathcal{S} \cup \{\perp\}$ 是一个状态空间 $\mathcal{S}$ ，并增加了一个终止状态 $\perp \notin \mathcal{S}$ ，令 $\mathcal{A} \subseteq \mathcal{S} \times \bar{\mathcal{S}}$ 是连接这些状态的一组边。一个（连通的）有向无环图（DAG） $\mathcal{G} = (\bar{\mathcal{S}}, \mathcal{A})$ 被称为有根有向无环图，如果存在唯一的初始状态 $s_0 \in \mathcal{S}$ ，使得 s_0 是该 DAG 的根（即它没有父节点），并且 $\perp$ 是唯一没有子节点的状态。

与大多数关于生成流网络（Bengio 等，2023）的工作不同，其中终端状态表示为“ s_f ”在整个论文中，我们将使用“ $\perp$ ”使用特定符号表示终止状态，如 Lahlou 等（2023）所述。本文采用与“符号不同的表示方法 s ”（用于状态的 $\mathcal{S}$ 以强调终端状态不是状态空间的元素（尽管它是扩展空间的元素） $\bar{\mathcal{S}}$ ）。我们将始终假设所有状态都是 $\mathcal{G}$ 可从 s_0 ，并且终端状态 $\perp$ 也可从所有状态访问到 $\mathcal{G}$ 我们记作 $\text{Pa}_{\mathcal{G}}(s)$ 和 $\text{Ch}_{\mathcal{G}}(s)$ 分别为一个状态的父节点和子节点 $s \in \bar{\mathcal{S}}$ 在 $\mathcal{G}$ 。

高尔顿板的槽也表示为图中的状态（*i.e.*, $\mathcal{X} \subseteq \mathcal{S}$ ）；在这个例子中，这些状态只有一个决策通向终止状态，标志着顺序过程的结束。可能终止的状态称为终止状态。

定义 2.2.2（终止状态）。设 $\mathcal{G} = (\bar{\mathcal{S}}, \mathcal{A})$ 为一个有向无环图。终止状态集合 $\mathcal{X} \subseteq \mathcal{S}$ 在 $\mathcal{G}$ 中被定义为终端状态在 $\mathcal{G}$: $\mathcal{X} \triangleq \text{Pa}_{\mathcal{G}}(\perp)$ 中的父节点

基于上一节的例子，我们可以看出为何选择 $\mathcal{X}$ ，即感兴趣的分布样本空间，来表示终止状态集并非偶然。虽然在那个例子中所有终止状态都有唯一的子节点 $\perp$ （即一旦珠子到达其中一个槽，我们就被迫终止），但需要注意的是，在一般情况下到达终止状态并不一定意味着强制终止，只有通过过渡到终止状态的转移 $x \rightarrow \perp$ 才会导致终止。换句话说，完全有可能一个有向无环图包含从终止状态到某些非终止状态的边 $s \in \mathcal{S}$ ；请参见图 3.1 进一步了解示例。到达特定终止状态所采取的决策序列（例如，某个珠子弹过的针）通过在 $\mathcal{G}$ 中的轨迹进行编码。

定义 2.2.3（完整轨迹）。设 $\mathcal{G} = (\mathcal{S}, \mathcal{A})$ 是一个有根有向无环图，其初始状态为 s_0 。若对于所有 $t \geq 0, s_t \rightarrow s_{t+1} \in \mathcal{A}$ （约定 $s_{T+1} = \perp$ ），轨迹 $\tau = (s_0, s_1, \dots, s_T, \perp)$ 被称为完整轨迹。所有在 $\mathcal{G}$ 上的完整轨迹集合记为 $\mathcal{T}$ 。

对于完整的轨迹 $\tau = (s_0, s_1, \dots, s_T, \perp), s_T \in \mathcal{X}$ 来说，终止状态是明确的。在某些情况下，讨论部分轨迹也会很方便，这部分轨迹的定义与完整轨迹类似，但起点和终点不一定分别是初始状态 s_0 或终止状态 $\perp$ 。我们将使用“ $s_m \rightsquigarrow s_n$ ”表示从 $s_m \in \mathcal{S}$ 到 $s_n \in \mathcal{S}$ 的部分轨迹集合（其中终点可能就是终止状态）；特别地，显然有 $\mathcal{T} \equiv s_0 \rightsquigarrow \perp$ 。如果 τ 和 τ' 是两个部分轨迹，并且 τ 的终点与 τ' 的起点相匹配，我们将用 $\tau \oplus \tau'$ 表示这两个轨迹的连接。当上下文文明确时，我们还会使用“ $s \rightarrow s' \in \mathcal{G}$ ”来表示 $s \rightarrow s' \in \mathcal{A}$ ，其中 $\mathcal{A}$ 是 $\mathcal{G}$ 的边集。

记号。我们将经常可视化一个有根的有向无环图（pointed DAG） $\mathcal{G}$ 作为一种图形结构，如图 2.2c 所示。本文将使用标准圆圈来表示状态 $\mathcal{S}$ ，并用双圆圈标出终止状态 $\mathcal{X}$ 。我们确定初始状态 s_0 具有三角形节点，并将终止状态作为 $\perp$ 。我们用 $\rightarrow$ 表示终止边，这些边导向 $\perp$ 。需要注意的是，当上下文文明确时（例如在图 2.3 中），我们可以复制节点 $\perp$ 为了视觉清晰，尽管它必须被视为单一状态 $\perp$ 。我们将对这些符号在注释的图 3.1b 中进行总结。在本论文的第二部分，我们将放宽这些符号的定义（例如，终止状态将隐含给出，如图 7.2 所示）。

2.2.3 前向转移概率

除了状态空间的结构编码了每个顺序决策的结果之外，我们还需要指定这些决策是如何做出的。例如，在高尔夫球中，如果一个珠子从一个钉子上弹开，它向左掉落的概率为 p 。我们可以用概率分布来形式化这一过程，从而从任何状态转移到下一状态（例如，转移的概率为

伯努利 (p)。

定义 2.2.4（一致的前向转移概率）。设 $\mathcal{G} = (\mathcal{S}, \mathcal{A})$ 是一个有根 DAG。函数 $P_F: \mathcal{S} \rightarrow \Delta(\text{Ch}_{\mathcal{G}})$ 被称为与 $\mathcal{G}$ 一致的前向转移概率分布，如果对于任意的 $s \in \mathcal{S}$ ， $P_F(\cdot | s)$ 是在 $\text{Ch}_{\mathcal{G}}(s)$, i.e. 上的一个恰当定义的概率分布，对于所有的 $s' \in \text{Ch}_{\mathcal{G}}(s)$ ， $P_F(s' | s) \geq 0$ 且 $\sum$

$$P_F(s' | s) = 1. \quad (2.2.2)$$

$s' \in \text{Ch}_{\mathcal{G}}(s)$

在上述定义中，对于某个状态 $s \in \mathcal{S}$ ，我们使用记号“ $\Delta(\text{Ch}_{\mathcal{G}})$ ”表示状态 s 在 $\mathcal{G}$ 中的子节点上的概率分布空间。在强化学习的背景下，当底层环境是确定性的（即动作与下一状态之间存在一对一映射）时，前向转移概率也被称为策略（Puterman, 1994）。

尽管我们在第 2.3 节将使用“策略”，但“前向转移概率”这一术语将在第 3 章和第 4 章中广泛使用。我们也可以自然地扩展部分轨迹 P_F 的定义

$$\tau = (s_m, s_{m+1}, \dots, s_n) \text{ 作为}$$

$$P_F(\tau) = \prod_{t=m}^{n-1} P_F(s_{t+1} | s_t). \quad (2.2.3)$$

一致的前向转移概率具有一个有趣的性质，即它们也在从任意状态 s 开始并结束于 $\perp$ 的部分轨迹上诱导出一个分布。

引理 2.2.5 (后缀上的分布)。设 $\mathcal{G} = (\mathcal{S}, \mathcal{A})$ 是一个有向无环图，并设 $P_F : \mathcal{S} \rightarrow \Delta(\text{Ch}_{\mathcal{G}})$ 是与 $\mathcal{G}$ 一致的前向转移概率。对于任意状态 $s \in \mathcal{S}$, P_F ，它诱导了一个从 s 开始并结束于终止状态 $\perp$, i.e., $P_F(\tau) \geq 0$ 的部分轨迹分布 τ 和 $\sum$

$$P_F(\tau) = 1. \quad (2.2.4)$$

$\tau: s \rightsquigarrow \perp$

证明。由于 P_F 是前向转移概率，显然我们有 $P_F(\tau) \geq 0$ 。我们可以通过对部分轨迹的最大长度进行强归纳来证明 (2.2.4)。对于任意状态 $s \in \mathcal{S}$ ，设 d_s 表示从 s 到终止状态 $\perp$ 的部分轨迹的最大长度。

基本情况：由于 $\mathcal{G}$ 是一个有向无环图，至少存在一个状态 $s \in \mathcal{S}$ 使得 $d_s = 1$ 。在这种情况下， $\perp$ 是 s 唯一的子节点（否则从 s 到 $\perp$ 将存在更长的轨迹，使得 $d_s > 1$ ），并且存在单一的部分轨迹形式为 $s \rightsquigarrow \perp$ ，即转换 $s \rightarrow \perp$ 。因此 $\sum$

$$P_F(\tau) = P_F(\perp | s) = 1. \quad (2.2.5)$$

$\tau: s \rightsquigarrow \perp$

归纳步骤：假设对于所有满足 $d_{s'} \leq d$ 的某个 $d > 0$ 的状态 s' ，(2.2.4) 成立。由于 $\mathcal{G}$ 是一个有向无环图，存在一个状态 $s \in \mathcal{S}$ 使得 $d_s = d + 1$ 。我们可以将从 s 出发的所有部分轨迹集分解成通过每个子节点 $s' \in \text{Ch}_{\mathcal{G}}(s)$ 的部分轨迹的不相交并集，即 $\{(s \rightarrow s') \oplus \tau' \mid \tau': s' \rightsquigarrow \perp\}$ 。 (2.2.6) 由于所有形式为 $s' \rightsquigarrow \perp$ 的部分轨迹具有最大深度 $d_{s'} \leq d$ ，我们可以对它们应用归纳步骤。利用上述分解，我们得到

$$\{\tau: s \rightsquigarrow \perp\} = \bigcup$$

$$\sum_{\tau: s \rightsquigarrow \perp} P_F(\tau) = \sum_{s' \in \text{Ch}_{\mathcal{G}}(s)} P_F(s' | s) \sum_{\tau': s' \rightsquigarrow \perp} P_F(\tau') = \sum_{s' \in \text{Ch}_{\mathcal{G}}(s)} P_F(s' | s) = 1. \quad (2.2.7)$$

这证明了 (2.2.4) 对于具有最大轨迹长度的状态 s 也是有效的 $d + 1$ 。□

该引理直接导致的结果是 P_F 特别诱导出一个完整的轨迹的概率分布（即，从 s_0 开始）。然而正如我们在 2.2.1 节中所指出的，我们感兴趣的是终止状态的概率分布（即，珠子落入的各个槽的概率分布）

是从这个完整的轨迹概率分布中推导出来的，而不是 $P_F(\tau)$ 本身。这被称为终止状态概率分布。

定义 2.2.6 (终止状态概率)。设 $\mathcal{G} = (\mathcal{S}, \mathcal{A})$ 为一个有向无环图， $\mathcal{X} \subseteq \mathcal{S}$ 为在 $\mathcal{G}$ 中的所有终止状态集合。设 $P_F: \mathcal{S} \rightarrow \Delta(\text{Ch}_{\mathcal{G}})$ 为与 $\mathcal{G}$ 一致的任意向前转移概率。与 P_F 相关的终止状态概率分布 $P_F^\top$ 定义为对于所有的 $x \in \mathcal{X}$ 均有

$$P_F^\top(x) \triangleq \sum_{\tau: x \rightarrow \perp \in \tau} P_F(\tau) = \sum_{\tau: s_0 \rightsquigarrow x} \prod_{t=0}^{T_\tau} P_F(s_{t+1} | s_t), \quad (2.2.8)$$

约定 $s_{T_\tau+1} = \perp$ ，并且对于所有完整的轨迹 τ 均有必然成立 $s_{T_\tau} = x$
 $x \rightarrow \perp \in \tau$.

用语言表述，终止状态的概率分布是轨迹在终止于 x (i.e., $x \rightarrow \perp \in \tau$) 时， $P_F(\tau)$ 上的边缘分布。需要注意的是，这与简单经过 x 的轨迹的边缘分布不同，因为这些轨迹不一定直接进行到转换 $x \rightarrow \perp$ 。例如，在图 3.1 中，尽管轨迹 $(s_0, s_2, x_4, x_6, \perp)$ 经过终止状态 x_4 ，但它不会对 $P_F^\top(x_4)$ 产生贡献。接下来的命题保证了对于任何向前转移概率 P_F ，其对应的终止状态概率是在终止状态集合 $\mathcal{X}$ 上定义良好的分布。

命题 2.2.7. 终止状态的概率分布

布，覆盖所有终止状态，这意味着对于所有的

$$\sum_{x \in \mathcal{X}} P_F^\top(x) = 1.$$

$P_F^\top$ 是一个定义良好的概率分
 $x \in \mathcal{X}$, $P_F^\top(x) \geq 0$ ，以及

证明。由于 P_F 是一个向前转移概率，显然有 $P_F^\top(x) \geq 0$ 对于任何归一化都是 $(x) \geq 0$ $x \in \mathcal{X}$. The
 引理 2.2.5 应用于初始状态的结果 s_0 :

$$\sum_{x \in \mathcal{X}} P_F^\top(x) = \sum_{x \in \mathcal{X}} \sum_{\tau: x \rightarrow \perp \in \tau} P_F(\tau) = \sum_{\tau: s_0 \rightsquigarrow \perp} P_F(\tau) = 1. \quad (2.2.9)$$

□

解释 $P_F^\top$ 作为边缘分布，它暗示了一种自然的采样程序，具体步骤见算法 2: (1) 根据前向转移概率采样一个完整的轨迹 P_F ，以及 (2) 仅返回在轨迹结束时到达的终止状态，在即将转换之前 $\perp$ 这与从 $P_F^\top = \text{二项式}(n, p)$ 相关的 $P_F(\cdot | s) = \text{伯努利}(p)$ 通过让一个珠子沿高尔顿板落下，并返回它最终落入的槽。由于 $\mathcal{G}$ 是无环的，该过程保证在有限时间内终止 $O(|\mathcal{S}|)$ (最坏情况)。然而，在许多有趣的情况下，从初始状态到所有终止状态的“深度” s_0 将远小于状态总数，如图 2.2 所示，

Algorithm 2 Sampling from the terminating state probability distribution $P_F^\top$ – Definition 2.2.6

Inputs: A pointed DAG $\mathcal{G} = (\bar{\mathcal{S}}, \mathcal{A})$, a forward transition probability $P_F : \mathcal{S} \rightarrow \Delta(\text{Ch}_{\mathcal{G}})$.

Outputs: A sample $x \sim P_F^\top$ of the terminating state probability distribution associated with P_F .

```

1: Initialize the state:  $s_0$ 
2: repeat
3:   | Sample the next state:  $s_{t+1} \sim P_F(\cdot | s_t)$ 
4: until  $s_{T+1} = \perp$ 
5: return  $x \equiv s_T$ 

```

但当状态空间 $\mathcal{S}$ 具有一些反映在结构中的组合特性时更是如此

$\mathcal{G}$.

2.2.4. 小分子有机物的生成

尽管第 2.2.1 节中的高尔顿板示例有助于直观理解顺序过程如何诱导终止状态的概率分布，但它存在局限性，即 $\mathcal{X}$ 不是一个结构化的样本空间。在本节中，我们将考虑一个更现实的情景，即从包含 C-H 或 C-C 键的小分子分布中进行采样。分子具有天然的组合结构，由多个片段组成，如图 2.1 所示。由于可能存在的分子数量极其庞大（Fink 等，2005 年），定义一个分布并通过分配每个单独分子的概率来满足归一化约束在实际操作中是不可能的。忽略归一化并为每个分子分配一个特定值会简单得多。在这种情况下，能量函数 $\mathcal{E}(x)$ 在 (2.1.1) 中可能对应于与目标蛋白的结合亲和力，以便生成更有可能与该蛋白结合的分子（例如，Bengio 等人（2021 年）使用了与可溶性环氧化物水解酶（sEH）蛋白的结合亲和力，这是一种在呼吸系统和心脏病中起作用的已知蛋白质（Imig 和 Hammock，2009 年）。）

与使用 MCMC 方法从该分布中采样（Seff 等，2019; Xie 等，2021）不同，我们可以从零开始构建分子，每次添加一个片段（You 等，2018; Bengio 等，2021），如图 2.3 所示。从空状态开始，我们在每一步从某个词汇表中选择一个片段添加到一个（可能是部分的）分子上，直到达到终止状态。这个例子突显了与 MCMC 的主要区别：生成完整分子的一系列决策可能会经过在物理上不可行的部分分子，而 MCMC 方法仅允许从一个完整分子移动到另一个完整分子（即，在算法 1 中提出的移动 $Q(x' | x)$ 仅限于 $\mathcal{X}$ 的有效元素）。使用前面章节引入的术语，终止状态集合 $\mathcal{X}$ 对应完整的分子，而 $\mathcal{S} \setminus \mathcal{X}$ 是部分分子的集合。

正如第 2.1.3 节所指出的，拥有组合对象的优势在此变得明显：不同分子之间共享子结构意味着在到达任何完整分子的完整轨迹上存在许多状态（决策点）。因此，目标吉布斯分布的复杂度可以分解成一系列更为简单的分布（ $P_F(\cdot | s)$ ）。这也显著减少了使用算法 2 采样完整分子所需的步骤数量。




图 2.3. 小型有机分子生成的有向无环图。在生成过程的每一步，都会从固定片段词汇表中选择一个新的分子片段，并将其添加到部分分子的一端。这一过程最终会生成完整的分子（例如阿司匹林），并且可以终止。遵循定义在此图上的向前转移概率分布 P_F ，可以得到一个关于完全形成的分子的终止状态概率分布 $P_F^\top$ 。

然而，完整轨迹的长度与每个状态转移概率的复杂度之间存在权衡：我们可以设想拥有一个简单的指向性有向无环图（DAG） $\mathcal{G}$ 哪里 s_0 与所有元素直接相连 $\mathcal{X}$ (e.g., 所有完整的分子)，这将使得 $P_F(\cdot | s_0)$ 极其复杂（事实上，我们将回到寻找 P^* 直接地）。我们将在第 2.3 节及后续章节中讨论如何找到一个前向转移概率，其对应的终止状态分布 $P_F^\top$ 匹配给定的能量函数 (2.1.1) $\mathcal{E}(x)$ 。

2.2.5. 从因子图进行自回归采样

作为最后一个示例，这次我们将锚定在概率建模领域，考虑 Buesing 等人 (2020) 引入的因子图中的推理问题。假设我们有 d 个离散随机变量 $(X_1, \dots, X_d)$ ，每个 X_i 取值于 $\{1, \dots, K\}$ ，这意味着样本空间 $\mathcal{X} = \{1, \dots, K\}^d$ 呈指数级增长。我们假设这些随机变量的联合分布由一个因子图给出，可以表示为类似于 (2.1.1) 的吉布斯分布，其中能量函数

$$\mathcal{E}(x_1, \dots, x_d) = \sum_{m=1}^M \psi_m(x_{[m]}). \quad (2.2.10)$$

每个因子 ψ_m 都是一个仅依赖于随机变量子集的已知函数（这些变量的值由“ $x_{[m]}$ ”表示）。因子图可以表示为一个二部图，其节点一边是随机变量 $\{X_1, \dots, X_d\}$ ，另一边是因子 $\{\psi_1, \dots, \psi_M\}$ ；参见图 2.4，这是一个具有 $d = 3$ 个变量和 $M = 3$ 个因子连接它们的因子图示例。

因子图中的推理是一个非常成熟的研究领域，无论是精确推理 (Dechter, 1999) 还是近似推理 (Murphy 等, 1999; Kschischang 等, 2001; De Sa 等, 2015)。作为另一种方法，并类似于我们之前的例子，Buesing 等 (2020) 将从该因子图中采样视为一个顺序决策问题，其中每个变量的值依次被赋予。




图 2.4. 从有向无环图 (DAG) 的顺序生成视角观察离散因子图的自回归采样。(左) 一个包含 3 个二值随机变量的因子图示例 X_1 , X_2 , 和 X_3 , 包含 3 个因素 ψ_1 , ψ_2 , 和 ψ_3 因子图所表示的分布的能量函数是其所有因子之和。(右) 表示变量完全赋值的顺序生成过程 (x_1, x_2, x_3) 作为有向无环图 $\mathcal{G}$. $\perp$ 仅为了清晰起见而显示为单独的节点, 应理解为单一状态。

按照固定顺序。图 2.4 展示了因子图中二进制变量 ($K = 2$) 的指向 DAG $\mathcal{G}$, 其中我们首先赋值给 X_1 , 然后是 X_2 , 最后是 X_3 。因此, 为了从 $P^*(x)$ 中获得一个完整的样本, 这一过程需要恰好 d 步。有趣的是, 这一次与之前的例子不同, $\mathcal{G}$ 具有树结构 (除了终止状态 $\perp$, 其父节点始终是根据定义 2.2.2 在 $\mathcal{X}$ 中的所有终止状态), 这通常是自回归序列生成任务的情况 (Bachman 和 Precup, 2015; Weber 等人, 2015; Angermueller 等人, 2020; Jain 等人, 2022; Feng 等人, 2022; Rafailov 等人, 2024)。

2.3. 概率推理作为控制问题

继续我们在第 2.2.5 节中的示例, 如果前向转移概率 P_F 已知, 则遵循此分布将得到终止状态分布的样本 $P_F^\top$ 。然而, 我们不想从任何分布中采样, 而是非常具体地从具有能量函数 (2.2.10) 的吉布斯分布中采样。如何找到 P_F 使得 $P_F^\top$ 与给定能量函数 $\mathcal{E}(x)$ 的兴趣分布相匹配? 在本节中, 我们将展示可以将其视为熵正则化强化学习框架内的控制问题 (Ziebart, 2010; Fox 等人, 2016)。我们将使用“策略”并用“ π ”表示它们 (而不是“前向转移概率”和“ P_F ”), 以便与强化学习中的命名约定保持一致。

2.3.1. 最大熵强化学习

本文回顾一些最大熵强化学习的概念 (Sutton 和 Barto, 2018), 并根据我们的设定调整符号和概念。考虑一个有限时间范围的马尔可夫决策过程 (MDP) $\mathcal{M} = (\mathcal{G}, r)$, 其中 $\mathcal{G} = (\bar{\mathcal{S}}, \mathcal{A})$ 是一个指定的有向无环图, 用于描述 MDP 的结构, 而 r 是一个特定的奖励函数, 定义如下。 $\bar{\mathcal{S}}$ 充当状态空间的角色, 而 $\mathcal{A}$ 则作为动作空间, 两者都是离散且有限的。该 MDP 是确定性的, 即从某个状态 $s \in \bar{\mathcal{S}}$ 执行一个动作 $a = s \rightarrow s' \in \mathcal{A}$ 后, 必定会转移到某个特定的状态 s' 。由于 $\mathcal{G}$ 是一个指定的有向无环图, 因此在这个 MDP 中的所有 (完整的) 轨迹都始于

在初始状态 s_0 ，并且保证最终会结束于终止状态 $\perp$ （有限时间范围）。我们还假设处于无折扣模式，意味着折扣因子 $\gamma = 1$ 。

由于马尔可夫决策过程（MDP）是确定性的，我们可以将从状态 s 到新状态 s' 的动作与转移 $s \rightarrow s' \in \mathcal{G}$ 本身关联起来。因此，我们将所有涉及状态-动作对 (s, a) （其中还包括奖励或状态-动作值 $a \in \mathcal{A}$ (e.g.) 的量直接表示为 (s, s') 的形式。此 MDP 的奖励函数 $r(s, s')$ 定义为：沿着完整轨迹（也称为回报）的奖励之和仅取决于终止状态的能量：对于一个轨迹 $\tau = (s_0, s_1, \dots, s_T, \perp)$ ，我们有

$$\sum_{t=0}^T r(s_t, s_{t+1}) = -\mathcal{E}(s_T), \quad (2.3.1)$$

按照惯例 $s_{T+1} = \perp$ 。特别是，这涵盖了仅在轨迹结束时收到稀疏奖励的情况（*i.e.*, $r(s_T, \perp) = -\mathcal{E}(s_T)$ ），而在其他地方均为零。在强化学习中，目标通常是找到一个最优策略（ $\pi_{\text{RL}}^*(s' | s)$ ），以最大化期望回报

$$\pi_{\text{RL}}^* = \arg \max_{\pi} \mathbb{E}_{\tau} \left[\sum_{t=0}^T r(s_t, s_{t+1}) \right], \quad (2.3.2)$$

其中，期望是关于由 π 诱导的完整轨迹分布 $\pi(\tau)$ 取的（参见第 2.2.3 节）。通过我们在 (2.3.1) 中选择的特定奖励函数，这种最大化将对应于找到一个策略（可能是确定性的），该策略会导致具有最低能量的状态 $x \in \mathcal{X}$ ，或者等价地说，找到 Gibbs 分布的模式之一 P^* 。这与我们最初的目标不同，我们的目标是从整个分布中采样 P^* ，而不仅仅是获得概率最高的对象。

为了考虑可能次优的对象，我们需要对 (2.3.2) 中的目标函数进行正则化。在最大熵强化学习（MaxEnt RL；Ziebart, 2010；Fox 等人, 2016）中，我们的目标是寻找一个随机策略，该策略不仅最大化期望回报，同时也最大化熵 $\mathcal{H}(\pi(\cdot | s)) = -\sum_{s' \in \text{Ch}_G(s)} \pi(s' | s) \log \pi(s' | s)$ 政策的概率密度函数值 π 在状态 s ，以鼓励所采取行动的多样性：

$$\pi_{\text{MaxEnt}}^* = \arg \max_{\pi} \mathbb{E}_{\tau} \left[\sum_{t=0}^T r(s_t, s_{t+1}) + \mathcal{H}(\pi(\cdot | s_t)) \right], \quad (2.3.3)$$

其中，期望再次相对于 $\pi(\tau)$ 计算。通常，可能存在一个温度参数 $\alpha > 0$ ，用于控制熵正则化相对于原始目标的重要性，在此为了简化，我们假设其等于 1；我们将在第五章回到温度参数的影响。这种熵正则化属于更广泛的正则化马尔可夫决策过程（MDPs）领域（Geist 等, 2019），在第 5.3 节我们将看到另一个基于相对熵的正则化示例。最大熵强化学习已被证明特别有利于改进探索（Haarnoja 等, 2017）以及在模型规格不匹配情况下的鲁棒控制（Eysenbach 和 Levine, 2022）。

Haarnoja et al. (2017) showed that the policy maximizing the objective in (2.3.3) can be written explicitly as $\pi_{\text{MaxEnt}}^*(s' | s) = \exp(Q_{\text{soft}}^*(s, s') - V_{\text{soft}}^*(s))$, where Q_{soft}^* is the soft state-action value function and V_{soft}^* the soft state value function which satisfy the following *soft Bellman optimality equations* (adapted to our setting, i.e., undiscounted and deterministic MDP):

$$Q_{\text{soft}}^*(s, s') = r(s, s') + V_{\text{soft}}^*(s') \quad (2.3.4)$$

$$V_{\text{soft}}^*(s) = \log \sum_{s'' \in \text{Ch}_{\mathcal{G}}(s)} \exp(Q_{\text{soft}}^*(s, s'')). \quad (2.3.5)$$

这些方程与标准的贝尔曼最优性方程 (Sutton 和 Barto, 2018) 不同之处在于, 最优策略中的贪婪操作 π_{RL}^* 被在 π_{MaxEnt}^* 中的 Softmax 操作所取代, 并且最优状态价值函数中的“max”操作 V^* 被 (2.3.5) 中的 log-sum-exp 操作所取代。

2.3.2. 从软 MDP 中采样终止状态

根据控制作为推理的文献 (Ziebart 等, 2008; Levine, 2018), 可以证明最大化 (2.3.3) 中的最大熵 RL 目标的策略诱导出一个依赖于轨迹上获得的奖励总和的动态一致轨迹分布。

命题 2.3.1. 设 $\mathcal{M}$ 是一个确定性的、无折扣的有限时间范围马尔可夫决策过程。策略 π_{MaxEnt}^* (2.3.3) 会在完整的轨迹上诱导出一个分布 $\tau = (s_0, s_1, \dots, s_T, \perp)$, 使得

$$\pi_{\text{MaxEnt}}^*(\tau) = \prod_{t=0}^T \pi_{\text{MaxEnt}}^*(s_{t+1} | s_t) \propto \exp\left(\sum_{t=0}^T r(s_t, s_{t+1})\right), \quad (2.3.6)$$

with the convention $s_{T+1} = \perp$.

证明。使用软贝尔曼最优性方程 (2.3.4) 在 π_{MaxEnt}^* 中, 我们得到

$$\pi_{\text{MaxEnt}}^*(s' | s) = \exp(Q_{\text{soft}}^*(s, s') - V_{\text{soft}}^*(s)) = \exp(r(s, s') + V_{\text{soft}}^*(s') - V_{\text{soft}}^*(s)). \quad (2.3.7)$$

通过展开状态值函数, 我们可以得出

$$\pi_{\text{MaxEnt}}^*(\tau) = \prod_{t=0}^T \pi_{\text{MaxEnt}}^*(s_{t+1} | s_t) = \prod_{t=0}^T \exp(r(s_t, s_{t+1}) + V_{\text{soft}}^*(s_{t+1}) - V_{\text{soft}}^*(s_t)) \quad (2.3.8)$$

$$= \exp\left(\sum_{t=0}^T (r(s_t, s_{t+1}) + V_{\text{soft}}^*(s_{t+1}) - V_{\text{soft}}^*(s_t))\right) \quad (2.3.9)$$

$$= \exp\left(\sum_{t=0}^T r(s_t, s_{t+1}) + V_{\text{soft}}^*(\perp) - V_{\text{soft}}^*(s_0)\right) \quad (2.3.10)$$

$$= \frac{1}{\exp(V_{\text{soft}}^*(s_0))} \exp\left(\sum_{t=0}^T r(s_t, s_{t+1})\right) \quad (2.3.11)$$

since $V_{\text{soft}}^*(\perp) = 0$ (终止状态没有子状态)。 $V_{\text{soft}}^*(s_0)$ 是一个与 τ 无关的常数。 $\square$

Algorithm 3 Soft Q-Learning algorithm

Inputs: A MDP $\mathcal{M} = (\mathcal{G}, r)$, a step size $\beta > 0$, a behavior policy $\pi_b(\cdot | s)$

Outputs: A stochastic policy π_{MaxEnt}^* maximizing (2.3.3)

```
1: Initialize  $Q(s, s')$  for all  $s \rightarrow s' \in \mathcal{G}$ , such that  $Q(x, \perp) = 0$  for all  $x \in \mathcal{X}$ .
2: loop
3:   Start a trajectory at the initial state  $s_0$ 
4:   repeat
5:     Sample the next state:  $s_{t+1} \sim \text{Categorical}(\pi_b(\cdot | s_t))$ 
6:      $Q(s_t, s_{t+1}) \leftarrow Q(s_t, s_{t+1}) + \beta[r(s_t, s_{t+1}) + \text{LogSumExp}_{s'} Q(s_{t+1}, s') - Q(s_t, s_{t+1})]$ 
7:   until  $s_{t+1} = \perp$ 
8: return  $\pi_{\text{MaxEnt}}^*(s' | s) \propto \exp(Q(s, s'))$ 
```

通过我们在 (2.3.1) 中选择的奖励函数，其中奖励之和仅取决于终止状态的能量，在命题 2.3.1 中的分布几乎完全对应于 P^* 在 (2.1.1) 中。然而，(2.3.6) 与我们的目标从吉布斯分布中采样的关键区别在于，

$\pi_{\text{MaxEnt}}^*(\tau)$ 是一个完整的轨迹分布，而 P^* 仅覆盖 $\mathcal{X}$ 。换句话说，我们感兴趣的是终止状态分布 $\pi_{\text{MaxEnt}}^{\top}(x)$ ，即顺序过程结果的分布，而不是到达该状态的过程分布。

幸运的是，当存在唯一的完整轨迹时 $s_0 \rightsquigarrow x$ 对于任意 $x \in \mathcal{X}$ ，终止状态分布完全匹配 $\pi_{\text{MaxEnt}}^*(\tau)$ (i.e. 定义 2.2.6 中的求和仅包含一个项。例如，在我们第 2.2.5 节的因子图推理示例（见图 2.4）中，这种情况成立，并且更一般地，当 $\mathcal{G}$ 具有树结构时也是如此。因此，在这些情况下，如果我们知道最大化 (2.3.3) 的策略 π_{MaxEnt}^* ，那么可以通过简单地应用算法 2（即，使用此策略采样一个完整的轨迹，并返回到达 P^* 之前的状态）来从 $\perp$ 中进行采样。此外，与产生自相关样本的 MCMC 不同，我们可以轻松地获得独立样本 P^* 通过多次运行此程序。

寻找最优策略。为了找到 π_{MaxEnt}^* ，我们可以使用最大熵强化学习文献中的任何算法（Nachum 等人，2017；Haarnoja 等人，2018）。最简单的可能是软 Q 学习算法（Haarnoja 等人，2017），它是标准强化学习中著名的 Q 学习算法的直接对应物（Watkins，1989），其目标是找到一个状态-动作价值函数 $Q(s, s')$ ，该函数满足软贝尔曼最优性方程；参见算法 3。软 Q 学习是一种离策略算法，这意味着我们可以使用任意的行为策略 π_b 来过渡到下一个状态 s_{t+1} ，在第 5 行（与在线策略不同，在线策略迫使我们使用当前策略推导出的策略 $Q(s, s')$ ）。Buesing 等人（2020）在其应用于第 2.2.5 节描述的因子图推理时，利用了 $\mathcal{G}$ 的树结构，并使用了一种基于蒙特卡洛树搜索（MCTS；Coulom，2006）的算法来找到 π_{MaxEnt}^* 。

2.3.3. 多路径环境与有偏采样

我们观察到当 $\mathcal{G}$ 具有树结构，即存在一条唯一的完整轨迹到达任何终止状态 $x \in \mathcal{X}$ 时，简单地遵循 π_{MaxEnt}^* 即可获得来自吉布斯分布的样本，前提是奖励定义为 (2.3.1)。但在存在多种构造方式的情况下




图 2.5. 终止状态分布与 π_{MaxEnt}^* 相关偏差的示意图，在具有 DAG 结构的软 MDP 上。MDP 中每条转移上的标签对应于奖励函数，满足 (2.3.1)（即稀疏奖励设置）。终止状态分布 $\pi_{\text{MaxEnt}}^{*\top}(x)$ 通过轨迹边缘化 $\pi_{\text{MaxEnt}}^*(\tau)$ 计算得出，这些轨迹导向 x （例如，两条轨迹 $s_0 \rightarrow s_1 \rightarrow x_4$ 和 $s_0 \rightarrow s_2 \rightarrow x_4$ 到 x_4 ）。 $\pi_{\text{MaxEnt}}^*(\tau)$ 基于命题 2.3.1 进行计算。终止状态分布 $\pi_{\text{MaxEnt}}^{*\top}(x)$ 应与 (2.1.1) 中的 Gibbs 分布 $P^*(x) \propto \exp(-\mathcal{E}(x))$ 进行对比。归一化常数是 $Z' = \exp(-\mathcal{E}(x_3)) + 2 \exp(-\mathcal{E}(x_4)) + \exp(-\mathcal{E}(x_5))$ 。这是第 2.2.4 节中描述的分子生成任务的简化版本。

终止状态，正如第 2.2.1 节和第 2.2.4 节所述，这一结论不再成立。重要的是要记住，尽管生成对象的概率分布（即完整的轨迹）根据命题 2.3.1 与 $\exp(-\mathcal{E}(x))$ 成比例，但我们感兴趣的却是结果的概率分布（即对应的终止状态分布）。事实上，基于定义 2.2.6 和命题 2.3.1，可以很容易地证明，一般情况下，与 π_{MaxEnt}^* 相关的终止状态分布由 $\pi_{\text{MaxEnt}}^{*\top}(x) = \sum_{\tau: x \rightarrow \perp \in \tau} \pi_{\text{MaxEnt}}^*(\tau) \propto n(x) \exp(-\mathcal{E}(x))$ ，给出 (2.3.12)，其中 $n(x) = |\{\tau \in \mathcal{T} \mid x \rightarrow \perp \in \tau\}|$ 是在 x 处结束的完整轨迹的数量，而 $s_T = x$ 和 $s_{T+1} = \perp$ （Bengio 等，2021）。当奖励函数 $r(s, s')$ 定义为 (2.3.1) 时，这意味着 $\pi_{\text{MaxEnt}}^{*\top}(x) \propto n(x) \exp(-\mathcal{E}(x))$ ，这并不对应于我们的目标分布 (2.1.1)。为了说明这一点，我们考虑图 2.5 中第 2.2.4 节的小分子生成示例的一个简化版本，其中样本空间仅包含 3 个分子。如果我们遵循最优策略 π_{MaxEnt}^* ，那么分子 x_4 将被人为地过度表示，因为它有两条完整的轨迹通向它。

本论文的第一部分旨在构建一个不再受此偏差影响的框架。我们的目标仍然是找到一个其终止状态分布与感兴趣的 Gibbs 分布相匹配的策略，但这种方法将从控制视角来看与我们在本节中采用的方法有根本的不同。该策略（或正向转移概率分布 P_F ）将通过流网络中的流推导出，正如我们将在接下来的章节中看到的那样，但最终我们将将其与第五章中的最大熵强化学习联系起来。

第三章

流网络

本章包含以下论文的内容： • Yoshua Bengio *, Salem Lahlou *, Tristan Deleu *, Edward Hu, Mo Tiwari, Emmanuel Bengio (2023). GFlowNet 基础理论. 《机器学习研究期刊》(JMLR)。

在上一章中，我们看到当对象具有某种组合结构时，我们可以自然地将 (2.1.1) 中的吉布斯分布作为通过有向无环图的顺序决策过程进行采样 $\mathcal{G}$ 其终止状态 $\mathcal{X}$ 是样本空间 $\mathcal{P}^*$ 主要挑战在于寻找前向转移概率 P_F 使得其对应的终止状态分布与目标吉布斯分布相匹配。我们在第 2.3 节中看到，单纯应用（最大熵）强化学习来寻找这一 P_F 可能导致有偏的分布当 $\mathcal{G}$ 是一个一般的有向无环图，具有多种构造感兴趣对象的方法。为了消除这种偏差，我们将在下一章中看到如何找到这样的 P_F 在一般情况下对于任何结构 $\mathcal{G}$ 本解决方案将基于图论中的一个标准工具——流网络。我们在本章中介绍其基础概念。

3.1. 流网络与马尔可夫流

在第 2.3.3 节中，最大熵强化学习方法失败的原因在于，在所指的有向无环图 $\mathcal{G}$ 中可能存在多条路径通向同一个对象，而这些路径的概率被简单相加。这实际上将通往同一对象的不同路径视为完全“独立”的，尽管它们可能有一些共同的部分（甚至共享相同的终点）。为了缓解这一问题，我们需要一种能够考虑路径之间依赖关系的结构。这种结构将以流网络的形式呈现，本节将介绍流网络及其马尔可夫对应形式，后者将在第四章中用于生成模型时发挥核心作用。

3.1.1 流网络

在第 2.2.2 节中，本文介绍了带点有向无环图（pointed DAG）的概念，用于编码状态空间的结构 $\mathcal{G} = (\mathcal{S}, \mathcal{T})$ 。我们在该有向无环图中引入一个函数 F^* ，该函数定义在完整的轨迹 $\mathcal{T}$ 上，称为流。

定义 3.1.1（轨迹流）。设 $\mathcal{G}$ 是一个有根 DAG， $\mathcal{T}$ 是 $\mathcal{G}$ 上的所有完整轨迹集合。一个在完整轨迹上的非负函数 $F^*: \mathcal{T} \rightarrow \mathbb{R}^+$ 被称为轨迹流。所有轨迹流的集合记作 $\mathcal{F}(\mathcal{G}) \triangleq \mathcal{F}(\mathcal{T}, \mathbb{R}^+)$ (i.e.)，即所有在 $\mathcal{T}$ 上的非负函数集合。对 $(\mathcal{G}, F^*)$ 称为流网络。

尽管轨迹流 F^* 被定义为完整轨迹上的一个函数，它也可以自然地诱导出完整轨迹可测空间上的一个测度 $(\mathcal{T}, \Sigma)$ ，其中 σ -代数 $\Sigma = 2^{\mathcal{T}}$ 是 $\mathcal{T}$ 的幂集。此处我们滥用记号，用 F^* 表示轨迹流（一个函数）及其对应的测度，对于任意完整轨迹的子集 $A \subseteq \mathcal{T}$ ，我们有 $F^*(A) = \sum_{\tau \in A} F^*(\tau)$ 。

$$F^*(\tau). \quad (3.1.1)$$

在特殊情况下，当子集 A 是一个单一轨迹 $\{\tau\}$ 时，我们将简单地将其测度写作 $F^*(\tau)$ ，以与轨迹流函数相对应。通过另一种符号滥用，我们将使用 F^* 来表示经过特定状态、转换或部分轨迹的流（参见第 3.1.4 节）。例如，状态流 $F^*(s)$ 对应于经过状态 $s \in \mathcal{S}$ 的流的数量，并由

$$F^*(s) \triangleq F^*(\{\tau \in \mathcal{T} \mid s \in \tau\}) = \sum_{\tau: s \in \tau} F^*(\tau). \quad (3.1.2)$$

定义。我们始终假设轨迹流 F^* 是非零的，并且对于任何状态 $s \in \mathcal{S}$ ，至少存在一条经过 s 的正流量轨迹，以保证 $F^*(s) > 0$ 。类似地，边流 $F^*(s \rightarrow s')$ 对应于经过转换 $s \rightarrow s' \in \mathcal{G}$ 的流的数量。这些状态和边流在整个本节中将发挥关键作用，特别是对于终止转换形式的边流 $F^*(x \rightarrow \perp)$ 对于 $x \in \mathcal{X}$ ，我们将在第四章中看到这一点。对于任何流网络，这些流通过“流量守恒”规则相互关联，我们将在第 3.2 节中详细说明。

命题 3.1.2. 给定一个流网络

$(\mathcal{G}, F^*)$ ，状态和边流量满足

$$\forall s \in \mathcal{S}, \quad F^*(s) = \sum_{s' \in \text{Ch}_{\mathcal{G}}(s)} F^*(s \rightarrow s') \quad (3.1.4)$$

$$\forall s' \neq s_0, \quad F^*(s') = \sum_{s \in \text{Pa}_{\mathcal{G}}(s')} F^*(s \rightarrow s') \quad (3.1.5)$$