

路径依赖的离散摊销推断

Tiago da Silva¹ Esmeralda S. Whitammer^{2,3} Salem Lahlou¹

摘要

我们考虑从给定的未归一化后验分布中采样组合性和离散性对象的问题。值得注意的是，最近的研究表明，通过学习一个确定性的马尔可夫决策过程（MDP），可以高效地解决这个问题，该过程逐步构建每个对象，其比例与后验分布成正比。然而，在本研究中，我们展示了马尔可夫假设不仅会阻碍训练期间信号的传播，还会由于状态别名而极大地降低所学采样的表达能力。为了解决这些问题，我们提出了通过可学习的潜在动力系统提升 MDP 的方法，使得底层策略能够依赖于整个过去的轨迹，而不仅仅是当前状态。基于此，我们将这种方法称为路径依赖离散摊销推断。重要的是，我们证明性地扩展了现有的离散摊销采样器学习算法到我们的设置。在标准基准问题上的实验中，我们也展示了我们的方法通常会导致更快的学习收敛和改进的状态空间探索，相对于先前的技术。

链蒙特卡洛（MCMC）技术，HMC 通过构建一个目标分布为其平稳分布的马尔可夫链来运作。然而，其核心思想是通过引入动量变量来扩充状态空间，该动量变量通过由哈密顿动力学（Hamilton, 1833）支配的部分确定性过程演化，从而增强探索并减少收敛（混合）时间（Betancourt, 2017）。

除了在低维设置下通过持续放松状态空间（Maddison 等, 2017; Jang 等, 2017; Han 等, 2020）之外，离散分布的采样问题至今尚未找到通用解决方案。这一问题在处理组合对象（如图和序列）时尤为棘手，因为诱导空间的组合爆炸往往使得通用采样器不切实际，并迫使依赖于特定技术（Dinh 等, 2017）。为了填补这一空白，Bengio 等（2021; 2023）最近引入了一类新型模型——生成流网络（Generative Flow Networks, 简称 GFlowNets），将采样问题转化为学习一个马尔可夫决策过程（MDP），该过程根据给定的未归一化分布构建每个组合对象。自那时以来，GFlowNets 已被广泛研究（Lahlou 等, 2023; Deleu & Bengio, 2023; Shen 等, 2023a; Yu, 2025），并在诸如系统发生推断（Zhou 等, 2024）和因果发现（Deleu 等, 2022; 2023）等应用中展示了其相对于特定马尔可夫链蒙特卡洛（MCMC）方法的竞争优势。除此之外，它们与分层变分推断（Malkin 等, 2023）及强化学习（RL; Tiapkin 等, 2024; Deleu 等, 2024）方法的关系也已正式建立。

1. 引言

当处理复杂的随机模型时，仅凭分析手段所能取得的成就有限。相反，实践者经常依赖近似算法来从目标分布中抽取样本，这些样本用于生成所需的函数的蒙特卡洛近似（Kirkpatrick 等, 1983; Geyer, 1991; Robert 等, 1999; Blei 及合作者, 2017）。对于连续状态空间，可以通过著名的哈密顿蒙特卡洛算法（HMC; Neal 等, 2011; Carpenter 等, 2017）有效地解决这一抽样问题。类似于其他马尔可夫。同等贡献 1MBZUI 2 爱丁堡大学 3CIFAR 研究员。联系人: Tiago da Silva <tiago.dasilva@mbzuai.ac.ae>。

从强化学习的角度来看，特别地，GFlowNet 可以被视为解决由构建组合对象的迭代过程（例如，在系统发生树中添加祖先节点）定义的有限且完全可观测环境中的 MDP 问题（Sutton 等, 1998; Mohri 等, 2018）。重要的是，由于我们不能直接将未归一化的概率——即奖励——分配给不完整的状态（Pan 等, 2023b; a），GFlowNets 通常会受到奖励稀疏性的影响，并在训练过程中导致信用分配效率低下（Jang 等, 2024）。此外，尽管 Bengio 等（2023）的开创性工作表明，总是存在一个确定性的 MDP，能够按照给定的目标分布生成每个完整状态，但最近的理论结果表明，常用的深度神经网络可能不足以表示这种最优策略（Silva 等, 2025a; Kim 等, 2025a）。

一个确定性的 MDP，能够按照给定的目标分布生成每个完整状态，但最近的理论结果表明，常用的深度神经网络可能不足以表示这种最优策略（Silva 等，2025a；Kim 等，2025a）。

为缓解这些问题，本文提出通过引入依赖历史的辅助变量来扩展给定的马尔可夫决策过程（MDP）。生成过程的图形模型以及原始 GFlowNet 的图形模型如图 1b 所示。与哈密顿蒙特卡洛（HMC）类似，该变量遵循由离散化的微分方程定义的确定性和状态条件动力学。（尽管也可以使其具有随机性；参见附录 D）。值得注意的是，正如我们在第 4 节中解释的那样，动力学的基础向量场和策略函数可以通过在单一损失函数上的随机梯度下降联合学习。从算法学习的角度来看，引入的隐变量也可以被视为循环神经网络的记忆组件（Schmidhuber, 1992; Hochreiter & Schmidhuber, 1997; Irie & Gershman, 2025）。

在此背景下，我们将我们的方法称为路径依赖离散摊销推断。类似于隐马尔可夫模型（Baum & Petrie, 1966），通过引入动态隐变量来扩展原始状态空间后，我们无法再确保仅基于状态的随机过程（图 1b 中的蓝色部分 $\{s_t\}_{t \geq 1}$ ）是马尔可夫性的。然而，正如我们在第 3 节中论证的那样，引入路径依赖的状态转换可以严格提高由参数化策略空间定义的假设类的表达能力。为了证明这一点，我们展示了可以通过路径依赖参数化解决但不能通过其马尔可夫对应物解决的示例环境和分布。

此外，传统的 GFlowNets 学习目标（Malkin 等，2022；Madan 等，2022；Zhang 等，2023b；Tiapkin 等，2024）需要调整以确保在我们的提升空间内的有效性。我们在第 4 节对轨迹平衡（TB）、子轨迹平衡（SubTB）和对比平衡（CB）损失函数进行了这一调整。补充地，我们在第 5 节的经验分析表明，所提出的路径依赖算法经常能够实现更快的学习收敛，并更好地拟合目标，优于参数相似的马尔可夫模型。此外，我们在附录 E 中展示了特定任务的技术可以无缝适应非马尔可夫设置中的分布式和流式推理（da Silva 等，2024b）。总之，我们的贡献如下。1. 我们介绍了一种用于离散和组合空间中摊销推断的路径依赖算法，概述了传统马尔可夫方法的局限性。

2. 我们证明性地扩展了现有的离散摊销采样器学习算法到这个新设置，并展示了它们在标准基准问题上的有效性。




图 1. 我们的算法的图形模型。我们提议将一个状态条件潜在动力系统 $\{W_t\}_{t=1}^T$ (b) 附加到 GFlowNet 的传统仅状态马尔可夫链 $\{s_t\}_{t=1}^T$ (a)。由此产生的随机过程， $\{(s_t, W_t)\}_{t=1}^T$ ，可以通过 $s_t | s_{t-1}, W_{t-1} \sim p(\cdot | s_{t-1}, W_{t-1})$ 和 $W_t = W_{t-1} + \phi(s_t, W_{t-1})$ 来描述，对于 $1 \leq t \leq T$ 和可学习的 p, ϕ （见第 4 节）。

2. 预备知识

记号。 设 $\mathcal{X}$ 是一个有限集， $R: \mathcal{X} \rightarrow \mathbb{R}_+$ be a 是在 $\mathcal{X}$ 上定义的正函数。我们的目标是从由 R 诱导的分布 $\pi(x) \propto R(x)$ 中生成样本，该分布定义在 $\mathcal{X}$ 上。为此，我们假设 $\mathcal{X}$ 具有组合结构，即每个 $x \in \mathcal{X}$ 可以通过向初始状态 s_o 添加简单组件获得。这一迭代过程刻画了一个有根 DAG，或状态图，这是我们工作的核心（Bengio 等，2023）。

定义 2.1（有根 DAG）。有根 DAG 是一个元组 $G = (\mathcal{S}, \mathcal{X}, E)$ ，由终端（或完整）状态 $\mathcal{X}$ 、（不完整）状态 $\mathcal{S}$ 和有向边 $E \subseteq \mathcal{S} \times (\mathcal{S} \cup \mathcal{X})$ 组成。 $\mathcal{X}$ 的元素是 G 中唯一没有出边的节点。此外，存在唯一的 $s_o \in \mathcal{S}$ ，称为初始状态，没有入边并通过有向路径（或轨迹）连接到每个 $x \in \mathcal{X}$ 。参见图 2。

我们说一条轨迹 $\tau = (s_t)_{t=0}^T \in \mathcal{S}^{T-1} \times \mathcal{X}$ 是完整的，如果它从初始状态 s_o 开始并在 $s_T \in \mathcal{X}$ 结束。

GFlowNets. A GFlowNet (Bengio et al., 2021; Lahlou et al., 2023) learns a Markovian forward policy $p_F: \mathcal{S} \times (\mathcal{S} \cup \mathcal{X}) \rightarrow [0, 1]$ over a state graph such that the marginal of $p_F(s_o, \cdot)$ over the terminal states $\mathcal{X}$,

$$p_T(x) := \sum_{\tau=(s_t)_{t=0}^T \rightsquigarrow x} \prod_{1 \leq t \leq T} p_F(s_t | s_{t-1}), \quad (1)$$

匹配 $R(x)$ 相差一个归一化常数； $\tau \rightsquigarrow x$ 意味着 τ 是完整的，并在 x 处结束。在这种情况下， $p_F(\cdot | s) := p_F(s, \cdot)$ 支持状态 s' 对于那些 $(s, s') \in E$ 在有向无环图中标记的状态。GFlowNet 还引入了一个反向策略 p_B ，这是一种在转置状态图上的前向策略，用于实现可处理的学习 p_F 读者可参阅附录 C 及 (Bengio 等人, 2023; Malkin 等人, 2022)，以获取关于 GFlowNets 的全面文献综述。




图 2. 长度为 N ，步长为 $M = 2$ 的 LINES 环境示意图。从起点 p_o 开始，智能体可以选择向上移动最多 M 步，或者转移到终止状态 (q) 并停止。

3. 马尔可夫采样的局限性

本节阐述了马尔可夫采样的实证和理论局限性。在第 3.1 节和第 3.2 节中，我们展示了路径依赖性的引入在某些条件下严格提高了模型的表达能力。在第 3.3 节中，我们通过实验表明，从智能体的角度来看，不同状态变得难以区分的现象——即状态别名现象 (Whitehead & Ballard, 1991; Pardo 等人, 2022)——通过路径依赖参数化得到了显著缓解。

运行示例。在本节中，我们将考虑图 2 所示的简单状态图，称为长度为 N 的 LINES 环境。在那里，智能体从起点 p_o 开始，在任何状态 p_k 下，可以选择两个动作之一：要么沿着主路径向前移动最多 M 个状态（即移动到 p_{k+j} 对于 $1 \leq j \leq \min\{M, N-k\}$ ），或者直接转移到终止状态 q_k 并停止。在每个状态 p_k 和 q_k 上唯一可用的信息是状态的位置 k 。为了方便起见，我们设 $\mathcal{P} = \{p_o, p_1, \dots, p_N\}$ 和 $\mathcal{Q} = \{q_o, q_1, \dots, q_N\}$ 。根据定义， $\mathcal{S} = \mathcal{P}$ 和 $\mathcal{X} = \mathcal{Q}$ 是终止状态集。显然，当 $M = 1$ 时，LINES 环境对应于标准超网格环境的一维版本 (Bengio 等人, 2021; Madan 等人, 2025)。我们的目标是以给定的正函数 $R: \mathcal{Q} \rightarrow \mathbb{R}_+$ 的比例对每个状态 q_k 进行采样。

3.1. 线性策略

这个问题可以通过学习一个正向策略来解决 对于反向策略 $p_F: \mathcal{P} \rightarrow [0, 1]$ ，满足轨迹平衡条件 (Malkin 等, 2022 年)：

$$\frac{p_F(q_{i_k} | p_{i_k:i_o}) \prod_{1 \leq j \leq k} p_F(p_{i_j} | p_{i_{j-1}:i_o})}{p_B(p_{i_k} | q_{i_k}) \prod_{1 \leq j \leq k} p_B(p_{i_{j-1}} | p_{i_j})} = \frac{R(q_{i_k})}{Z} \quad (2)$$

对于每个递增序列 $(i_o, \dots, i_k)$ ，使得和 $\sum_{j=0}^k (i_j - i_{j-1}) = M$ ， $0 \leq i_j \leq N$ ， $0 \leq k \leq N$ 及 $i_o = 0$ ，其中 $i_j: i_o = (i_o, i_1, \dots, i_j)$ 对 $0 \leq j \leq k$ 。

尽管足够宽 (Cybenko, 1989 年; Hornik 等, 1989 年) 或深 (Lu 等, 2017 年; Hanin 与 Sellke, 2018 年) 的神经网络可以逼近任何平滑函数，包括符合方程 (2) 的策略，但这样的模型在数学上不可处理 (Laurent 与 Brecht, 2018 年)。

相反，受深度线性网络文献 (Baldi 与 Hornik, 1989 年; Baldi 与 Lu, 2012 年; Saxe 等, 2014 年; Laurent 与 Brecht, 2018 年) 和逆强化学习 (Arora 与 Doshi, 2020 年; Metelli 等, 2023 年) 的启发，我们考虑线性参数化的策略，以便理解马尔可夫方法和路径依赖方法在离散摊销推断中的差异。也就是说，我们固定中间状态的状态嵌入函数 $\psi: \mathcal{P} \rightarrow \mathbb{R}^d$ ，并考察形式为

$$p_F(p_{i+k} | p_i, \mathbf{W}_i) = \text{Softmax}((\mathbf{W}_i \psi(p_i)) \odot \mathbf{m}_i)_k \quad (3)$$

对 $1 \leq k \leq M$ ， $\mathbf{W} \in \mathbb{R}^{d \times (M+1)}$ 的策略函数，其中作为可学习参数，而

$\mathbf{m}_i \in \{1, -\infty\}^{M+1}$ 作为抑制导致索引大于 N 的位置的动作

的掩码。在传统的马尔可夫线性模型下， $\mathbf{W}_i = \mathbf{W}$ 是固定的。这代表了一个标准的 GFlowNet 实现 (Viviano 等, 2025 年)。在这种情况下，我们说一个未归一化的分布 $R: \mathcal{Q} \rightarrow \mathbb{R}_+$ 可以通过我们的采样器学习，如果存在一个 $\mathbf{W}$ ，使得 $p_F(\cdot | s_o)$ 在 $\mathcal{Q}$ 上的边缘分布匹配 R 到一个归一化常数 (参见 (1))。值得注意的是，当 $\{\mathbf{W}_t\}_{t \geq 1}$ 遵循线性动力学时，

$$\begin{aligned} \mathbf{W}_t &= \mathbf{b} \mathbf{a}_t^T, \\ \mathbf{a}_t &= \mathbf{a}_{t-1} + (\mathbf{w}_a^T \psi(s_t)) \cdot \mathbf{v}_a, \end{aligned} \quad (4)$$

与 $\mathbf{a}_o \in \mathbb{R}^d$ ， $\mathbf{w} \in \mathbb{R}^d$ 和 $\mathbf{v}_a \in \mathbb{R}^d$ 作为可学习参数，并且 $\mathbf{b} \in \mathbb{R}^{M+1}$ 通常随机固定，那么在方程 (4) 下的可学习分布空间严格大于相应的马尔可夫模型；这是下一个命题的内容。

命题 3.1。 设 $M = 1$ 和 $\mathbf{r} = (R(q_i))_{i=0}^N$ 是状态概率向量。显然，both $\lambda \mathbf{r}$ 和 $\mathbf{r}$ 在 $\lambda > 0$ 上诱导相同的分布 over $\mathcal{Q}$ ；令 $[\mathbf{r}]$ 为对应的等价类。然后，定义

$$\begin{aligned} \mathcal{W}_M &= \{[\mathbf{r}]: \exists \mathbf{W} \text{ s.t. } p_T(q_i) \propto [\mathbf{r}]_i\} \\ \mathcal{W}_P &= \{[\mathbf{r}]: \exists \mathbf{a}_o, \mathbf{w}_a, \mathbf{v}_a \text{ s.t. } p_T(q_i) \propto [\mathbf{r}]_i\} \end{aligned}$$

和作为马尔可夫模型和路径依赖参数化的可学习分布空间。在这些条件下， $\dim \text{span}(\mathcal{W}_M) \leq \dim \text{span}(\mathcal{W}_P)$ 几乎肯定 (相对于 $\mathbf{b}$) 对于所有状态嵌入函数 $\psi: \mathcal{P} \rightarrow \mathbb{R}^d$ ，并且 $\dim \text{span}(\mathcal{W}_M) < \dim \text{span}(\mathcal{W}_P)$ 对于某些 ψ ，包括自然嵌入 $\psi(p_i) = i$ 。

在命题 3.1 中，张成 (span) 和维度 (dim) 是指欧几里得意义上的。简而言之，它表明通过特定线性确定性动力学增强 (或提升) 的 MDP 具有显著更大的表示能力，超过简单的线性 MDP。

Empirical illustration. 为了说明命题 3.1，我们考虑一个具有形式的分布 $R: \mathcal{Q} \rightarrow \mathbb{R}_+$

$$R(q_i) = \sum_{1 \leq j \leq 4} w_j \exp\{-|i - k_j|\}, \quad (5)$$




图 3. 命题 3.1 的说明。虽然线性马尔可夫模型（左）完全错过了目标的高概率区域（右；参见方程 (5)），我们的路径依赖参数化（中）提供了近乎完美的分布拟合。

其中 $k_j \in \{1, \dots, N\}$ 对 $1 \leq j \leq 4$ 并以 $\sum_{j=1}^4 w_j$ 为权重因子；参见我们也将 $\mathcal{P}$ 的自然嵌入，即 $\psi(p_i) = i$ 对于每个 $1 \leq i \leq N$ 。为了简化起见，我们设 $N = 16$ 和 $M = 1$ ，并通过最小化 TB 损失来训练两个模型；详见第 4 节和推论 B.1。如预期的那样，图 3 显示，我们的非马尔可夫模型所学习到的分布与目标分布非常吻合，而其马尔可夫替代模型则严重低估了目标分布的高概率区域。

3.2. 基于图神经网络的策略

值得注意的是，路径依赖模型证明的额外表达能力也可以扩展到线性策略之外。基于 (Silva 等人, 2025a; Kim 等人, 2025a) 最近的分析以及关于图神经网络 (GNNs; Kipf&Welling, 2017; Hamilton, 2020; Bronstein 等人, 2021; Corso 等人, 2024) 局限性的长期理论，我们将展示图 1b 所示的提升过程可以证明地增强用于离散平均抽样的 GNN 参数化策略网络的表达能力。为此，我们简要回顾 (Silva 等人, 2025a) 中的设置以及用于动态图学习的 GNN 结构 (Xu 等人, 2020; Wang 等人, 2022)。

首先，读者应回忆，一个 GNN 通过邻域聚合变换修改具有节点特征 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 和边 $\mathcal{E}$ 的特征图 $\mathcal{G} = (\mathbf{X}, \mathcal{E})$ ，即 $\mathbf{x}'_i = \mu(\{\zeta(\mathbf{x}_j) : (i, j) \in \mathcal{E}\}) := f(\mathbf{x}_i; \mathcal{G})$ ，其中 $\mathbf{x}_i \in \mathbb{R}^d$ 是第 i 个节点的特征； $\zeta: \mathbb{R}^d \rightarrow \mathbb{R}^{d'}$ 是一个参数函数（例如，多层感知机）；而 μ 是对 $\mathbb{R}^{d'}$ 的置换不变函数 (Hamilton, 2020)。根据这一公式，很明显单层 GNN 将无法区分节点 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ ，因为 $\mathbf{x}_i = \mathbf{x}_j$ 并且两者 i 和 j 都具有同构的 1 跳邻域。事实上，在 Weisfeiler-Lehman 层次 (WL; Weisfeiler&Lehman, 1968; Grohe, 2022) 的背景下，深度 GNN 的表达能力已经被很好地理解。

在此基础上，Silva 等人 (2025a) 已经证明，构建在简单边添加生成过程上的 GFlowNet (参见图 4)，其策略函数定义为

$$p_F(\mathcal{G}^{+(m,n)} | \mathcal{G}) \propto \exp\{\zeta(f(\mathbf{x}_m; \mathcal{G}) \oplus f(\mathbf{x}_n; \mathcal{G}))\}, \quad (6)$$

其中 $\mathcal{G}^{+(m,n)}$ 是从添加

边 (i, j) 到 $\mathcal{G}$ ， $\oplus$ 是连接操作符， f 是一个 1-WL 多层图神经网络，而 $\zeta: \mathbb{R}^{2d'} \rightarrow \mathbb{R}$ 是一个前馈深度网络，无法从某些简单的图结构分布中采样。这是状态别名现象的另一种表现形式，因为采样器由于其有限的表现能力而无法区分不同的状态。我们在下面展示了我们的路径依赖参数化可以缓解这一问题。

命题 3.2 (时间图神经网络提高 GFlowNet 的表达能力)。设 SGs 是由特征图上的边加过程定义的状态图空间 (图 4)，并令 $\mathcal{R}(S)$ 为所有未归一化分布的空间，这些分布在 $S \in \text{SGs}$ 中。同样，通过令 $\mathbf{A}_i$ 为第 i 个图的邻接矩阵， $\mathbf{1} \in \mathbb{R}^{|\mathbf{X}|}$ 为全 1 的列向量，定义 $\mathbf{m}^{(0)} = \mathbf{0}$ ， $\mathbf{m}^{(i+1)} = \mathbf{m}^{(i)} + \alpha(\mathcal{G}_i) \cdot (\mathbf{A}_{i+1} - \mathbf{A}_i)\mathbf{1}$

and $\mathbf{V}^{(i+1)} = [\mathbf{X} \ \mathbf{m}^{(i+1)}] \in \mathbb{R}^{n \times (d+1)}$ and $\alpha(\mathcal{G}_i) \in (0, 1]$ 。类似地，对于 $S \in \text{SGs}$ ，令 $\mathcal{R}_P(S) \subseteq \mathcal{R}(S)$ 为基

图神经网络 f_F 和前馈深度网络 ζ_F 的路径依赖摊销采样器能够采样的分布集合，


$$p_F(\mathcal{G}^{+(m,n)} | \mathcal{G}_i) \propto \exp\{\zeta_F(f_F(\mathbf{v}_m^{(i)}; \mathcal{G}) \oplus f_F(\mathbf{v}_n^{(i)}; \mathcal{G}))\}, \quad (7)$$

并令 $\mathcal{R}_M(S) \subseteq \mathcal{R}(S)$ 为可由方程 (6) 形式的摊销采样器学习的分布集合。那么，对于每一个 $S \in \text{SGs}$ ，都有 $\mathcal{R}_M(S) \subseteq \mathcal{R}_P(S)$ ，并且存在集合 S ，使得 $\mathcal{R}_M(S) \neq \mathcal{R}_P(S)$ 。直观地说，命题 3.2 表明，在生成过程中包含节点度数变化的时间信息 (方程 (7)) 严格提高了所学采样器的表达能力，与方程 (6) 中的原始公式相比。这样，生成过程显然符合图 1b 中描述的路径依赖框架，因为策略函数不再满足马尔可夫性质。考虑到这一点，理解这种模型族在图结构任务 (如 Pandey 等, 2024 年) 下的性能和局限性将是非常有趣的，这可以通过 (Souza 等, 2022) 中的分析来实现。我们将这一研究留待未来的工作。

经验说明。为了阐明命题 3.2，我们在图 4a 中展示了一个状态图 S ，其中 $\mathcal{R}_P(S) \neq \mathcal{R}_M(S)$ 。特别注意的是，

S 有两个终端节点 (q_1 和 q_2)，它们之前有一个非终端节点 (p)。由于节点对 (a, b) 和 (a, c) 在 p 中不可区分，基于方程 (6) 的 GFlowNet 将无法学习任何非均匀分布于 q_1 和 q_2 上。相比之下，由于在通往 p 的不同轨迹中， a 和 c 在不同时刻被修改，我们方程 (7) 中的路径依赖参数化能够拟合任何分布。这一事实在图 4b 中得到了说明，其中我们让

$$R(q_1) = \alpha \text{ 及 } R(q_2) = 1 - \alpha$$



(a) 常见的 GNN 架构（如 GCN、GAT）无法区分边 (a, b) 和 (a, c) 关于图 p 因此，参数化如方程 (6) 所示的 GFlowNet 将无法学习任何非均匀分布 $\{q_1, q_2\}$ 当在该状态图上训练时。

(b) 然而，由于其更大的表达能力，依赖路径的采样器可以完美地拟合任何目标分布。

图 4. 命题 3.2 的示意图。我们展示了一个例子，在这个例子中，基于 1-WL GNN 的马尔可夫近似采样器（方程 (6)）无法从非均匀目标分布中采样 $\{q_1, q_2\}$ ，而相应的依赖路径模型可以（右侧）。

对于 $\alpha \in \{0.1, 0.2, \dots, 0.9\}$ ，我们使用标准的两层 GCN (Kipf & Welling, 2017) 来参数化策略，这些策略通过最小化推论 B.1 中的 TB 损失进行训练。正如预期的那样，目标 R 与 GFlowNet 学习到的均匀分布之间的总变差距离是

$$\text{TV}(R, p_\tau) := \frac{1}{2} \left(\left| \alpha - \frac{1}{2} \right| + \left| (1 - \alpha) - \frac{1}{2} \right| \right) = \left| \alpha - \frac{1}{2} \right|,$$

而我们的依赖路径模型在方程 (7) 中的相同总变差距离则非常小。

3.3. 多层修正线性单元网络

修正线性单元网络通过组合分段线性函数来学习每个状态的表示， $f_i: \mathbb{R}^{d_i} \rightarrow \mathbb{R}^{d_{i+1}}$ ，由 $f_i(\mathbf{x}) = \max(\mathbf{W}_i \mathbf{x}, 0)$ 定义，在其中最大操作符按元素应用； d_o 是每个状态自然嵌入到欧几里得空间中的维度（例如，对于 LINES 环境，维度为 $d_o = 1$ ）。尽管组合 $f_1 \circ f_2$ 可以在给定足够大的 d_1 （时近似任何目标连续函数从 $\mathbb{R}^{d_o}$ 到 $\mathbb{R}^{d_2}$ (Hornik 等人, 1189 年)，但通过梯度下降找到适当的参数 $\mathbf{W}_o$ 、 $\mathbf{W}_1$ 和 $\mathbf{W}_2$ 通常很困难——尤其是在目标具有较大的利普希茨常数的情况下 (Scaman & Virmaux, 2019 年)。在强化学习领域，这种局限性通常表现为状态别名的形式，在这种形式下，学习模型无法准确区分状态 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ ，无论它们对应的最优动作分布如何。换句话说，从智能体的角度来看，环境变得部分可观测。

为了理解这种现象在马尔可夫近似采样器中的出现方式，请考虑具有 $M = 2$ 的 LINES 环境以及图 5a 所示的在 $\mathcal{Q}$ 上的目标 R 。在那里， $R(q_2) = 1000R(q_1)$ 和 $R(q_{20}) = R(q_2)$ 。在这种情况下，最优策略 p_F^* 在 p_2 和 p_3 之间存在显著差异。因此，如图 5b 所示，基于两层修正线性单元网络和 Softmax 输出的马尔可夫采样器难以区分 p_2 和 p_3 ，因为

Kullback-Leibler 发散 (Kullback & Leibler, 1951)

$$\max_{\tau: p_o \rightsquigarrow p_2, \tau': p_o \rightsquigarrow p_3} \text{KL}[p_F(\cdot | p_3, \tau') || p_F(\cdot | p_2, \tau)] \quad (8)$$

在整个训练过程中，基本保持恒定并接近于 0（图 5b，蓝色）。相反，一个路径依赖模型——具有为不同 τ 学习不同 $p_F(\cdot | p_2, \tau)$ 值的能力——可以在训练初期平滑地学习到 p_2 和 p_3 的不同表示（图 5b，橙色）。这也导致了更快的学习收敛，并在给定有限轨迹预算的情况下更好地拟合目标分布；见图 5c，其中我们使用了方程 (4) 来建模路径依赖。

4. 路径依赖摊销采样器


上一节展示了路径依赖算法可以为离散摊销采样器提供可证明的表达能力提升。然而，它留下了一个未回答的问题：如何定义潜在动力学过程 $\{W_t\}_{t \geq 1}$ ？在介绍了我们的框架的正式定义（第 4.1 节和定义 4.1）后，我们将介绍一种用于学习向量场 ϕ 的一般用途算法，该向量场刻画了潜在的动力学系统 $\{W_t\}_{t \geq 1}$ ——通过规则

$W_t = W_{t-1} + \phi(W_{t-1}, s_t)$ ——并证明其正确性（第 4.2 节和命题 4.5）。

4.1. 路径依赖离散摊销推断

基于之前的例子，我们提供了对路径依赖离散摊销推断框架的正式描述。关键在于，尽管命题 3.2 表明不同的应用可能受益于专门的实现，但在第 4 和第 5 节中，我们将看到一个由近期递归 RL 进展启发的单一架构 (Irie 等, 2022; Irie & Gershman, 2025) 能够在大多数基准问题上超越标准马尔可夫模型。鉴于此，我们首先定义了一个提升的有向无环图。

定义 4.1 (提升的有向无环图)。设 $\text{SG} = (\mathcal{S}, \mathcal{X}, E)$ 是一个有向无环图（根据定义 2.1），其状态空间为 $\mathcal{S}$ ，5



(a) Sparse LINES environment; (b) KL-divergence between policies at p_3 and p_2 ; see Equation (8). (c) 马尔可夫采样器和路径依赖采样器在稀疏 LINES 环境中的学习收敛性。

图 5. 马尔可夫采样器难以区分相似状态（第 3.3 节）。(a) 具有稀疏目标的 LINES 环境；在状态 p_2 处，最优动作分布倾向于向上移动（由于 $R(q_2)$ 较大），而在其相邻状态 p_3 处，则偏向于向右移动。(b) 训练过程中状态 p_2 和状态 p_3 之间的策略 KL 散度；一个由修正线性单元网络参数化的马尔可夫采样器需要大约 100 倍的迭代次数来区分状态 p_2 和状态 p_3 ，而路径依赖的采样器则不需要。(c) 这导致了更好的收敛速率。右侧快照显示了虚线标记的迭代次数下采样器的状态。

边 E 和终止状态 $\mathcal{X}$ 。另设 $\phi: \mathcal{S} \times \Omega \rightarrow \Omega$ 是定义在集合 Ω 上的一个函数，并且 $W_o \in \Omega$ 。我们有 $SG^* = (\mathcal{S}^*, E^*, \phi, W)$ is a 向无环图被指针提升并且当 ϕ 满足以下条件时 W_o 。

1. $\mathcal{S}^* \subseteq \mathcal{S} \times \Omega, E^* \subseteq \mathcal{S}^* \times (\mathcal{S}^* \cup \mathcal{X}), s_o^* := (s_o, W_o) \in \mathcal{S}^*$;
2. $(s, W) \in \mathcal{S}^*$ 当且仅当存在一条路径 $\{(s_t, W_t)\}_{t=0}^T$ 使得 $(s_T, W_T) = (s, W), W_t = W_{t-1} + \phi(s_t, W_{t-1})$ 和 $(s_{t-1}, s_t) \in E$ 对于所有 $1 \leq t \leq T$;
3. $((s, W), (s', W')) \in E^*$ iff $(s, s') \in E$ 在 SG 中连接。 $W' = W + \phi(s', W)$; 并且
4. $((s, W), x) \in E^*$ iff $(s, W) \in \mathcal{S}^*$ 及 $(s, x) \in E$.

当 ϕ, W_o 和 SG 从上下文中明确时，我们将简单地将 SG^* 称为提升的有向无环图。

在定义 4.1 中，我们通常会令 $\Omega = \mathbb{R}^d$ 为某个整数。如图 1b 所示，提升的有向无环图通过一个潜在的动力系统 $\{W_t\}_{t \geq 1}$ 扩展了一个状态图，该动力系统遵循由 ϕ 确定的差分方程，并受制于 $\{s_t\}_{t \geq 1}$ （状态条件）。在接下来的例子中，我们将展示前一节概述的问题如何适应定义 4.1 所呈现的结构。例 4.2 (LINES)。在图 2, $\mathcal{S}$ 的上下文中

4.2
 $\mathcal{P}, \mathcal{X} = \mathcal{Q}$ 和 $E = \bigcup_{i=0}^N \{(p_i, p_{i+k}) \text{ for } 1 \leq k \leq \min\{M, N-i\}\} \cup \{(p, q_i)\}$. For Proposition 3.1, $W_o = \mathbf{a}_o$, $\Omega = \mathbb{R}^d$ ($\mathbf{b}$ 是固定的)，并且 $\phi: \mathcal{S} \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 被定义为 $\phi(s, \mathbf{a}) = (\mathbf{w}_a^T \psi(s)) \cdot \mathbf{v}_a$,

其中 $\mathbf{w}_a$ 和 $\mathbf{v}_a$ 是可学习参数，而 ψ 是一个嵌入函数。同时请注意， ϕ 与 $\mathbf{a}$ 无关。例 4.3 (GRAPHS)。我们考虑命题 3.2 中说明的边加性过程。在那里， $\mathcal{S}$ 和 $\mathcal{X}$ 是具有固定数量节点的特征图集合，记为 N ，表示边集。同样， $\mathcal{G} = (\mathbf{X}, \mathcal{E})$; $\mathcal{E}$ 对于 $E = \{(\mathcal{G}, \mathcal{G}')\}$ ，对于 $|\mathcal{E}' \setminus \mathcal{E}| = 1$ 和 $\mathcal{E} \subseteq \mathcal{E}'$ 。例如， $|\mathcal{X}| = 2$ 且 $|\mathcal{S}| = 5$ 在图 4a 中。在命题 3.2, $W_o = \mathbf{0}$

($\mathbf{m}_o, \mathbf{A}_o$)，其中 $\mathbf{m}_o = \mathbf{0} \in \mathbb{R}^N$ 和 $\mathbf{A}_o$ 作为初始状态 $\Omega = \mathbb{R}^N \times \{1, 0\}^{N \times N}$ 和 $\phi: \mathcal{S} \times \Omega \rightarrow \Omega$ by the recurrence rela

Ω 由递推关系 $\phi(s, (\mathbf{m}, \mathbf{A})) = (\alpha(s) \cdot (\mathbf{A}_s - \mathbf{A})\mathbf{1}, \mathbf{0}_{N \times N})$ ，刻画，其中 $\alpha: \mathcal{S} \rightarrow (0, 1]$, $\mathbf{1}$ is a N 是全 1 的向量，而 $\mathbf{A}_s$ 是 s 的邻接矩阵。相应地，动态系统的更新步骤 $\{W_t\}_{t \geq 1}$ 可以写作

$$\mathbf{A}_{t+1} = \mathbf{A}_t, \mathbf{m}_{t+1} = \mathbf{m}_t + \alpha_t (\mathbf{A}_{t+1} - \mathbf{A}_t) \mathbf{1},$$

$\mathbf{A}_{t+1} = \mathbf{A}_t, \mathbf{m}_{t+1} = \mathbf{m}_t + \alpha_t (\mathbf{A}_{t+1} - \mathbf{A}_t) \mathbf{1}$ ，其中 $\alpha_t = \alpha(s_t)$ 。这里， ϕ 依赖于 s 和 $W = (\mathbf{m}, \mathbf{A})$ 。

有趣的是，也可以开发随机潜在动力系统（例如 Särkkä & Solin (2019) 中的情况）。然而，这显著增加了问题的复杂度，因为提升域变得不可数；请参见 D 节以获得正式阐述和初步推导。

4.2. 选择潜在的动力系统

循环策略网络。 为了选择一个适合于更新规则的 $\{W_t\}_{t \geq 1}$ ，我们首先指出， $W_t = W_{t-1} + \phi(s_t, W_{t-1})$ 可以直接通过循环神经网络 (RNN; Rumelhart 等, 1986; Cho 等, 2014) 实现。例如，具有恒等激活函数的单层 vanilla RNN 将提供方程

$$\phi(s_t, W_t) = \psi(s_t) \mathbf{W}_s + W_{t-1} (\mathbf{W}_h - \mathbf{I}) + \mathbf{b}_h,$$

与 $W \in \mathbb{R}^d, \mathbf{W}_s \in \mathbb{R}^{d \times d}, \mathbf{W}_h \in \mathbb{R}^{d \times d}, \mathbf{b}_h \in \mathbb{R}^d$ ，以及作为可优化参数和 $\psi: \mathcal{S} \rightarrow \mathbb{R}^d$ 作为（可能可学习的）嵌入函数 $\mathcal{S}$ 所得的表示， W_t 可以作为标准

多层神经网络的输入，用于计算概率分布 s_t 状态图中节点的孩子（如方程 (3) 所示）。实际操作中，这一过程会重复进行，直到采样到终止状态 $x \in \mathcal{X}$ 如第 2 节所述。

我们提到一个前向策略 p_F 由这样的循环神经网络参数化作为循环策略网络 (Karkus 等, 2017; Ni 等, 2022)。

自参照权重矩阵 (Self Referential Weight Matrix (SRWM))。基于快速权重程序员 (FWPs; Schlag 等, 2021; Irie 和 Gershman, 2025) 在强化学习上的长期成功以及我们自己的实证评估 (见第 5 节), 我们提议使用修改后的自参照权重矩阵 (SRWM; Schmidhuber, 1993b; Irie 等, 2022) 来学习采样器的循环策略网络。简单来说, 我们的修改后的 SRWM 实现了形式如下更新规则:

$$\begin{aligned} \mathbf{q}_t, \mathbf{k}_t, \mathbf{v}_t, \beta_t &= \mathbf{W}\psi(s_t) + \mathbf{b}, \\ \bar{\mathbf{v}}_t &= \mathbf{W}_{t-1}\zeta(\mathbf{k}_t), \\ \mathbf{W}_t &= \mathbf{W}_{t-1}\mathbf{R} + \sigma(\beta_t) \cdot (\mathbf{v}_t - \bar{\mathbf{v}}_t) \otimes \zeta(\mathbf{q}_t), \end{aligned} \quad (9)$$

in which $\mathbf{W} \in \mathbb{R}^{(3d+1) \times d}$ and $\mathbf{b} \in \mathbb{R}^{3d+1}$ are parameters, $\zeta: \mathbb{R}^d \rightarrow \Delta_{d-1}$ is an activation function that maps a vector in $\mathbb{R}^d$ into the $(d-1)$ -dimensional simplex (e.g., softmax), $\mathbf{R}$ is a (fixed) ergodic rotation matrix, and $\sigma(x) = (1 + \exp\{-x\})^{-1}$ 是 Sigmoid 函数。直观上, $\mathbf{R}$ 通过在整个轨迹展开过程中旋转 $\mathbf{W}_t$ 的特征向量, 从而引入多样性到策略中, 这减少了第 3.3 节中描述的相关别名效应。根据 Schmidhuber (1993b; a) 引入的术语, $\mathbf{W}$ 和 $\mathbf{b}$ 是通过随机梯度下降优化的缓慢变化变量, 而 $\mathbf{W}_{t-1}$ 是一个快速演变矩阵, 其自我确定的学习率为 $\sigma(\beta_t)$ 。相应地, 我们也对潜在动力系统的初始状态进行了参数化, 即 $\mathbf{W}_0 = \mathbf{a}_0\mathbf{b}_0^T$, 其中 $\mathbf{a}_0 \in \mathbb{R}^{d \times 1}$ 和 $\mathbf{b}_0 \in \mathbb{R}^{d \times 1}$ 都是可优化参数。

值得注意的是, 其他架构, 如长短时记忆网络 (LSTM) (Hochreiter & Schmidhuber, 1997) 和门控循环单元 (GRU) (Cho et al., 2014), 在早期实验中也用于参数化更新规则 ϕ 。然而, 我们发现它们通常不如同样大小的 SRWM 有效, 这与先前的研究结果一致 (Irie et al., 2022)。

4.3. 学习潜在动力系统

路径依赖采样的准则。鉴于基于 SRWM 的架构, 我们面临的问题是如何估计模型的参数。在此背景下, 我们展示了 GFlowNets 的学习准则也可以用于学习提升 DAG 上的策略函数。(感兴趣的读者可以参考附录 B, 了解流网络类比我们上下文中的扩展)。我们首先回顾状态流的定义 (Bengio et al., 2021)。

定义 4.4. 目标 $R: \mathcal{X} \rightarrow \mathbb{R}_{+}$ 的初始流为任何 function $F: \mathcal{S}^* \cup \mathcal{X} \rightarrow \mathbb{R}_{+}$ s.t. $F(x) \in \mathcal{X}$.

实践中, F 是一个表示到达每个 $s^* \in \mathcal{S}^*$ 的总流量的已学习函数。在某些条件下 (如下所述), 这也等同于从初始状态 s_o^* 开始并遵循前向策略 p_F 时到达 s^* 的未归一化的边缘概率 (Bengio et al., 2021)。因此, 自然地限制 F 在 $\mathcal{X}$

通过让 $F(x) = R(x)$ 对于 $x \in \mathcal{X}$ 成立 (Deleu et al., 2022), 正如我们在定义 4.4 中所做的那样。从这个角度来看, 我们在下一个命题中证明 Madan et al. (2022) 的子轨迹平衡 (SubTB) 条件足以确保在定义 4.1 的提升 DAG 上进行正确的采样。

命题 4.5 设 $\mathcal{S}^*$ 是一个提升的有向无环图, 并且 p_F , p_B , 和 F 作为递归的前向策略、后向策略和流函数于 $\mathcal{S}^*$ 假设, 对于每条完整的轨迹 $\tau = (s_t^*)_{t=0}^T$ 与 $s_T^* = x \in \mathcal{X}$ 并且每个 $i < j$,

$$F(s_i^*)p_F(s_{i+1:j}^*|s_i^*) = p_B(s_{i:j-1}^*|s_j^*)F(s_j^*), \quad (10)$$

其中 p_F 根据图 1b 所示的图形模型计算, 而 $p_B(s_i^*|s_{i+1:j}^*) = \prod_{t=i}^{j-1} p_B(s_t^*|s_{t+1}^*)$ 则根据转置后的 $\text{SG}^{\dagger}$ 计算。然后, 记 $\tau \rightsquigarrow s^*$ 为从 s_o^* 开始并在 $s^* \in \mathcal{S}^* \cup \mathcal{X}$ 结束的轨迹,

$$p_{\tau}(s^*) = \sum_{\tau \rightsquigarrow s^*} p_F(\tau|s_o^*) \propto F(s^*). \quad (11)$$

特别是, $p_{\tau}(x) \propto R(x)$ 对 $x \in \mathcal{X}$ 。

鉴于我们的兴趣仅限于完整对象的采样, 当方程 (10) 仅适用于 $i=0$ 和 $j=T$ (Madan 等, 2022) 时, 显然方程 (11) 在 $\mathcal{X}$ 处仍然成立。这导致了轨迹平衡 (TB) 条件 (Malkin 等, 2022)。

推论 4.6. 类似于命题 4.5, 假设

$$F(s_o^*)p_F(\tau|s_o^*) = R(x)p_B(\tau|x) \quad (12)$$

对于每个完整的轨迹 $\tau = (s_t^*)_{t=0}^T$ 。然后, $p_{\tau}(x) \propto R(x)$ 对于每个终止状态 $x \in \mathcal{X}$ 。

正如 Bengio 等人 (2023, 例 6) 所述, 推论 4.6 仅依赖于初始状态相关的流, $F(s_o^*)$, 等于目标值 R 当满足方程 (12) 时的划分函数 (Malkin 等, 2022)。下文将证明 F -独立对比平衡 (CB) 条件 (张等, 2023b; 达席尔瓦等, 2024a) 也足以确保边缘分布的 p_F 超过 $\mathcal{X}$ 匹配 R 。

推论 4.7. 在命题 4.5 的设定下, 令 $\tau = (s_t^*)_{t=0}^T$, $\tau' = (s_t^*)_{t=0}^T$ 为完整的轨迹。如果 $\text{SG}^{\dagger}$

$$p_F(\tau|s_o^*)p_B(\tau'|s_T^*)R(s_T^*) = p_F(\tau'|s_o^*)p_B(\tau|s_T^*)R(s_T^*)$$

对于每一对 (τ, τ') , then $p_{\tau}(x) \propto R(x)$ 。

综上所述, 命题 4.5 和推论 4.6 及 4.7 表明, 传统的 GFlowNets 学习目标可以无缝适应提升后的有向无环图 (参见定义 4.1)。在实践中, 我们通过最小化其左侧与右侧之间的对数平方差的期望来强制这些条件 (如同 Bengio 等人在 2023 年的例子 4-6 中所示)。值得注意的是, 当 p_B 不依赖于潜在的动力系统 $\{W_t\}_{t \geq 1}$ 时, 满足推论 4.6 或 4.7 的最优解 p_F 相对于未提升的有向无环图而言是马尔可夫的; 详见命题 4.8。

命题 4.8. 在命题 4.5 的设定下, 假设 $\tilde{p}_B$ 是一个在 SG 上的逆向策略, 使得 $p_B(s_t^*|s_{t+1}^*) = \tilde{p}_B(s_t|s_{t+1})$ 对于每条轨迹 $(s_t^*)_{t=0}^T$ 在 SG^* . 我们记 s_t 为未提升实例化 $s_t^* := (s_t, W_t)$. 令 p_F 是一个遵循推论 4.6 或 4.7 的正向策略. 那么, 存在一个策略 $\tilde{p}_F$ 关于 SG 的情况 $p_F(s_{t+1}^*|s_t^*) = \tilde{p}_F(s_{t+1}|s_t)$.

图 6 说明了命题 4.8 在 LINES 环境中的应用 (参见图 2), 测量的是相同状态、不同轨迹的 KL 发散值, 在非终止状态下取平均值 $s \in \{p_1, \dots, p_N\}$. 当 (i) p_B 是马尔可夫过程时, (ii) p_B 是非马尔可夫过程. (i) 下, p_F 收敛到一个马尔可夫策略, 这由 KL 发散值趋于零所表明; 而在 (ii) 下, p_F 稳定为一个非马尔可夫模型.




图 6. 命题 4.8 的示意图。一个 (非) 马尔可夫过程 p_B 在平衡状态下蕴含另一个 (非) 马尔可夫过程 p_F . 令 $\text{KL}(s) = \max_{\tau, \tau'}: s_{\tau} \sim s \text{KL}(p_F(\cdot|\tau, s)||p_F(\cdot|\tau', s))$ 表示在相同状态下但不同轨迹下的策略之间的最大 KL 散度; $\text{KL}(s) > 0$ 对于某个 s 表明 p_F 具有路径依赖性。

重要的是, 鉴于第 3 节所述与混叠相关的挑战, 选择马尔可夫模型 (Markovian) p_B 可能是有效的, 因为依赖路径的参数化可能比其马尔可夫等价形式更好地逼近命题 4.8 中概述的最优策略 $\tilde{p}_F$.

5. 实验

我们的实验的主要目的是验证我们的路径依赖模型在拟合目标分布方面相对于其马尔可夫等价物的有效性。为此, 我们在 GFlowNet 文献中考虑以下四个标准基准任务。此外, 我们在补充材料中提供了偏好学习、比特序列和懒惰随机游走任务的结果。我们在 JAX (Bradbury 等人, 2021) 中实现了我们的模型; 请参阅附录 F 以获取更多详细信息。

集合生成 (Bengio 等人, 2023). 该任务包括生成一个固定超集的固定大小子集。设 $\Gamma = \{1, 2, \dots, S\}$ 为这样的超集, $u: \Gamma \rightarrow \mathbb{R}$ 为元素的对数效用函数 Γ . 在此背景下, 初始状态为空集, $s_0 = \emptyset$, 每次转换包括将 Γ 中的一个元素 i 添加到当前状态 s , 直到 $|s| = K$. 我们的目标是以比例 $\gamma \subseteq \Gamma$ 与 $|\gamma| = K$ 成正比地抽样 $R(\gamma) = \sum_{i \in \gamma} \exp\{u(i)\}$. 在这种情况下, 表 1 显示路径依赖性

表 1. 集合生成的 FCS, 其中包含 $S = 64$ 且 K 变化。

K	Markovian	Path-dependent
16	0.091 ± 0.012	0.053 ± 0.006
24	0.105 ± 0.009	0.064 ± 0.002

表 2. 序列设计任务的 FCS。Syn- S 表示长度为 S 的合成分布, 而 SIX6 和 PHO4 指的是 DNA 序列生成任务。

Task	Markovian	Path-dependent
Syn-8	0.084 ± 0.001	0.011 ± 0.001
Syn-16	0.165 ± 0.006	0.024 ± 0.001
Syn-32	0.243 ± 0.015	0.055 ± 0.002
SIX6	0.165 ± 0.006	0.135 ± 0.003
PHO4	0.175 ± 0.004	0.130 ± 0.001

参数化对于 $S = 64$ 和 $K \in \{16, 32\}$ (λ 具有更好的拟合优度, 其中包含大约 10^{14} 和 10^{18} 分别以 FCS (即在可处理子集上的平均 TV 距离) 来衡量 λ ; 参见方程 (18))。

序列设计 (Jain 等, 2022). 对于该问题, 我们自回归地生成固定大小的序列 S 也就是说, 我们从一个空序列开始 $s_0 = \emptyset$ 并从给定的词汇表中添加标记 v 到当前状态

s 直到 $s \in \mathcal{V}^S$. 首先, 我们考虑一个合成分布, 其中包含 $\mathcal{V} = \{1, \dots, 6\}$, $S \in \{8, 16, 32\}$, 并且

$$R(s) = \sum_{i=1}^S u(i) \cdot v(s_i) \quad \text{其中包含 } u: \{1, \dots, S\} \rightarrow \mathbb{R}_+$$

和 $v: \mathcal{V} \rightarrow \mathbb{R}_+$ 作为效用函数。表 2 显示, 我们的路径依赖参数化在每个目标分布上具有更好的拟合度 S . 图 10 (补充材料) 显示这些结果在模型大小上具有一致性。其次, 同样地, 我们在表 2 中展示了我们的模型在 Jain 等人 (2022) 设计的 8 (或 10) 大小生物序列任务中也实现了更好的分布拟合度, 在该任务中, 目标分布测度 DNA 序列与人类 (或酵母) 转录因子 (Barrera 等, 2016; Trabucco 等, 2022) SIX6 (或 PHO4) 的结合亲和力。

网络世界 (Bengio 等人, 2021)。

网络世界表示一个稀疏分布于 $\{0, \dots, N-1\}^2$, 如图 7

(右) 所示。初始状态是原点, $s_0 = (0, 0)$, 转移包括停止、向上移动或向右移动, 类似于图 2 中的 LINES 任务。同样地, 我们在图 7 中展示了我们的路径依赖模型比其马尔可夫模型更好地逼近目标——后者在导航空间方面遇到困难。




图 7. 网络世界中的目标拟合优度。

6. 结论

在处理连续分布时，最有效的采样器依赖于通过引入辅助动量（潜在）变量来加速收敛（Neal 等人，2011；Cheng 等人，2018），这一过程我们称之为提升。在这项工作中，我们证明了一种类似的策略可以有效地应用于组合空间中的离散化采样器。我们也指出了现有未提升状态空间上操作的采样器的局限性，并展示了潜在的动力学过程可以通过自参照权重矩阵高效学习。

最后，我们注意到关于路径依赖模型随机动力学可行性的疑问仍然存在，我们认为这代表了一个有趣的未来研究方向。总体而言，我们的结果进一步表明，部分可观测马尔可夫决策过程的算法适用于离散摊销采样，这证实了 Randlov（1998 年）和 Boussif 等人（2024 年）早期的观察。

影响声明

我们的工作界定了马尔可夫摊销采样器在离散和组合对象上的局限性，这些对象引起了我们社区越来越多的兴趣，并引入了一种通用的路径依赖算法来缓解这些问题。然而，我们不认为这项具体的工作会产生任何直接的负面社会影响。

致谢

ESW 感谢 CIFAR 学习在机器与大脑项目的支持。

参考文献

Arora, S. and Doshi, P. A survey of inverse reinforcement learning: Challenges, methods and progress, 2020. URL <https://arxiv.org/abs/1806.06877>.

Atanackovic, L. and Bengio, E. Investigating Generalization Behaviours of Generative Flow Networks. *ICML 2024 Workshop on Structured Probabilistic Inference & Generative Modeling*, 2024. URL <https://arxiv.org/abs/2402.05309>.

Baldi, P. and Hornik, K. Neural networks and principal component analysis: Learning from examples without local minima. *Neural networks*, 2(1):53–58, 1989.

Baldi, P. and Lu, Z. Complex-valued autoencoders. *Neural Networks*, 33:136–147, 2012.

Barrera, L. A., Vedenko, A., Kurland, J. V., Rogers, J. M., Gisselbrecht, S. S., Rossin, E. J., Woodard, J., Mariani, L., Kock, K. H., Inukai, S., et al. Survey of variation

in human transcription factors reveals prevalent DNA binding changes. *Science*, 351(6280):1450–1454, 2016.

Baum, L. E. and Petrie, T. Statistical inference for probabilistic functions of finite state markov chains. *The annals of mathematical statistics*, 37(6):1554–1563, 1966.

Bengio, E., Jain, M., Korablyov, M., Precup, D., and Bengio, Y. Flow Network based Generative Models for Non-Iterative Diverse Candidate Generation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

Bengio, Y., Lahlou, S., Deleu, T., Hu, E. J., Tiwari, M., and Bengio, E. GFlowNet Foundations. *Journal of Machine Learning Research (JMLR)*, 2023.

Betancourt, M. A conceptual introduction to hamiltonian monte carlo. *arXiv preprint arXiv:1701.02434*, 2017.

Blei, D. M. and et al. Variational Inference: A Review for Statisticians. *Journal of the American Statistical Association*, 2017.

Boussif, O., Ezzine, L. N., Viviano, J. D., Koziarski, M., Jain, M., Malkin, N., Bengio, E., Assouel, R., and Bengio, Y. Action abstractions for amortized sampling, 2024. URL <https://arxiv.org/abs/2410.15184>.

Bradbury, J., Frostig, R., Hawkins, P., Johnson, M. J., Leary, C., Maclaurin, D., Necula, G., Paszke, A., VanderPlas, J., Wanderman-Milne, S., and Zhang, Q. JAX: composable transformations of Python+NumPy programs, 2018. URL <http://github.com/google/jax>.

Bronstein, M. M., Bruna, J., Cohen, T., and Velicković, P. Geometric deep learning: Grids, groups, graphs, geodesics, and gauges, 2021. URL <https://arxiv.org/abs/2104.13478>.

Brunswic, L., Li, Y., Xu, Y., Feng, Y., Jui, S., and Ma, L. A theory of non-acyclic generative flow networks. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(10):11124–11131, March 2024. ISSN 2159-5399. doi: 10.1609/aaai.v38i10.28989. URL <http://dx.doi.org/10.1609/aaai.v38i10.28989>.

Carpenter, B., Gelman, A., Hoffman, M. D., Lee, D., Goodrich, B., Betancourt, M., Brubaker, M., Guo, J., Li, P., and Riddell, A. Stan: A probabilistic programming language. *Journal of statistical software*, 76:1–32, 2017.

Cheng, X., Chatterji, N. S., Bartlett, P. L., and Jordan, M. I. Underdamped langevin mcmc: A non-asymptotic analysis, 2018. URL <https://arxiv.org/abs/1707.03663>.

Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., and Bengio, Y. Learning phrase representations using rnn encoder-decoder

- for statistical machine translation. *arXiv preprint arXiv:1406.1078*, 2014.
- Cole, T. J. Algorithm AS 281: Scaling and Rounding Regression Coefficients to Integers. *Applied Statistics*, 42 (1), 1993. ISSN 0035-9254. doi: 10.2307/2347432.
- Corso, G., Stark, H., Jegelka, S., Jaakkola, T., and Barzilay, R. Graph neural networks. *Nature Reviews Methods Primers*, 4(1):17, 2024.
- Cybenko, G. Approximation by superpositions of a sigmoidal function. *Mathematics of control, signals and systems*, 2(4):303–314, 1989.
- da Silva, T., Carvalho, L. M., Souza, A., Kaski, S., and Mesquita, D. Embarrassingly Parallel GFlowNets, 2024a. URL <https://arxiv.org/abs/2406.03288>.
- da Silva, T., de Souza, D. A., and Mesquita, D. Streaming bayes gflownets, 2024b. URL <https://arxiv.org/abs/2411.05899>.
- Dall’Antonia, P., da Silva, T., de Souza, D. A., Mattos, C. L. C., and Mesquita, D. Boosted gflownets: Improving exploration via sequential learning, 2026. URL <https://arxiv.org/abs/2511.09677>.
- Deleu, T. and Bengio, Y. Generative Flow Networks: a Markov Chain Perspective. *arXiv preprint arXiv:2307.01422*, 2023. URL <https://arxiv.org/abs/2307.01422>.
- Deleu, T., Góis, A., Emezue, C. C., Rankawat, M., Lacoste-Julien, S., Bauer, S., and Bengio, Y. Bayesian Structure Learning with Generative Flow Networks. In *Uncertainty in Artificial Intelligence (UAI)*, 2022.
- Deleu, T., Nishikawa-Toomey, M., Subramanian, J., Malkin, N., Charlin, L., and Bengio, Y. Joint Bayesian Inference of Graphical Structure and Parameters with a Single Generative Flow Network. In *Advances in Neural Processing Systems (NeurIPS)*, 2023.
- Deleu, T., Nouri, P., Malkin, N., Precup, D., and Bengio, Y. Discrete Probabilistic Inference as Control in Multi-path Environments, 2024. URL <https://arxiv.org/abs/2402.10309>.
- Dinh, V., Darling, A. E., and Matsen IV, F. A. Online Bayesian Phylogenetic Inference: Theoretical Foundations via Sequential Monte Carlo. *Systematic Biology*, 67(3), December 2017. ISSN 1076-836X. doi: 10.1093/sysbio/syx087.
- Garipov, T., Peuter, S. D., Yang, G., Garg, V., Kaski, S., and Jaakkola, T. S. Compositional Sculpting of Iterative Generative Processes. In *Advances in Neural Information Processing Systems*, 2023.
- Gelfand, A. E. and Smith, A. F. Sampling-based approaches to calculating marginal densities. *Journal of the American statistical association*, 85(410):398–409, 1990.
- Geyer, C. J. Markov chain monte carlo maximum likelihood. Technical report, University of Minnesota, 1991.
- Grohe, M. The logic of graph neural networks, 2022. URL <https://arxiv.org/abs/2104.14624>.
- Hamilton, W. L. *Graph representation learning*. Morgan & Claypool Publishers, 2020.
- Hamilton, W. R. *On a General Method of Expressing the Paths of Light, & of the Planets, by the Coefficients of a Characteristic Function*. PD Hardy, 1833.
- Han, J., Ding, F., Liu, X., Torresani, L., Peng, J., and Liu, Q. Stein variational inference for discrete distributions, 2020. URL <https://arxiv.org/abs/2003.00605>.
- Hanin, B. and Sellke, M. Approximating continuous functions by relu nets of minimal width, 2018. URL <https://arxiv.org/abs/1710.11278>.
- Hochreiter, S. and Schmidhuber, J. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
- Hornik, K., Stinchcombe, M., and White, H. Multilayer feedforward networks are universal approximators. *Neural networks*, 2(5):359–366, 1989.
- Hu, E. J., Jain, M., Elmoznino, E., Kaddar, Y., and et al. Amortizing intractable inference in large language models. In *International Conference on Learning Representations*, 2024a. URL <https://arxiv.org/abs/2310.04363>.
- Hu, R., Zhang, Y., Li, Z., and Huang, L. Beyond squared error: Exploring loss design for enhanced training of generative flow networks, 2024b. URL <https://arxiv.org/abs/2410.02596>.
- Irie, K. and Gershman, S. J. Fast weight programming and linear transformers: from machine learning to neurobiology, 2025. URL <https://arxiv.org/abs/2508.08435>.
- Irie, K., Schlag, I., Csordás, R., and Schmidhuber, J. A modern self-referential weight matrix that learns to modify itself, 2022. URL <https://arxiv.org/abs/2202.05780>.
- Jain, M., Bengio, E., Hernandez-Garcia, A., Rector-Brooks, J., Dossou, B. F. P., Ekbote, C. A., Fu, J., Zhang, T., Kilgour, M., Zhang, D., Simine, L., Das, P., and Bengio, Y. Biological Sequence Design with GFlowNets. In *International Conference on Machine Learning (ICML)*, 2022.

- Jang, E., Gu, S., and Poole, B. Categorical Reparameterization with Gumbel-Softmax. In *International Conference on Learning Representations*, 2017.
- Jang, H., Kim, M., and Ahn, S. Learning Energy Decompositions for Partial Inference in GFlowNets. In *International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=P15CHILQlg>.
- Jones, G. L. and Hobert, J. P. Honest exploration of intractable probability distributions via markov chain monte carlo. *Statistical Science*, pp. 312–334, 2001.
- Karkus, P., Hsu, D., and Lee, W. S. Qmdp-net: Deep learning for planning under partial observability, 2017. URL <https://arxiv.org/abs/1703.06692>.
- Kim, H., Lee, S., and hwan Oh, M. Symmetry-aware gflownets, 2025a. URL <https://arxiv.org/abs/2506.02685>.
- Kim, M., Ko, J., Yun, T., Zhang, D., Pan, L., Kim, W., Park, J., Bengio, E., and Bengio, Y. Learning to Scale Logits for Temperature-Conditional GFlowNets, 2024a. URL <https://arxiv.org/abs/2310.02823>.
- Kim, M., Yun, T., Bengio, E., Zhang, D., Bengio, Y., Ahn, S., and Park, J. Local Search GFlowNets, 2024b. URL <https://arxiv.org/abs/2310.02710>.
- Kim, M., Choi, S., Yun, T., Bengio, E., Feng, L., Rector-Brooks, J., Ahn, S., Park, J., Malkin, N., and Bengio, Y. Adaptive teachers for amortized samplers. In *The Thirteenth International Conference on Learning Representations*, 2025b. URL <https://openreview.net/forum?id=BdmVgLMvaf>.
- Kipf, T. N. and Welling, M. Semi-supervised classification with graph convolutional networks, 2017. URL <https://arxiv.org/abs/1609.02907>.
- Kirkpatrick, S., Gelatt Jr, C. D., and Vecchi, M. P. Optimization by simulated annealing. *Science*, 220(4598), 1983.
- Kullback, S. and Leibler, R. A. On information and sufficiency. *The annals of mathematical statistics*, 22(1): 79–86, 1951.
- Lahlou, S., Deleu, T., Lemos, P., Zhang, D., Volokhova, A., Hernández-García, A., Ezzine, L. N., Bengio, Y., and Malkin, N. A theory of continuous generative flow networks. In *International Conference on Machine Learning*, pp. 18269–18300. PMLR, 2023.
- Lahlou at al., S. A Theory of Continuous Generative Flow Networks. In *International Conference on Machine Learning (ICML)*, 2023. URL <https://proceedings.mlr.press/v202/lahlou23a.html>.
- Lau, E., Vemgal, N. M., Precup, D., and Bengio, E. DGfN: Double Generative Flow Networks. In *NeurIPS 2023 Generative AI and Biology (GenBio) Workshop*, 2023.
- Lau, E., Lu, S. Z., Pan, L., Precup, D., and Bengio, E. QGFN: Controllable Greediness with Action Values, 2024. URL <https://arxiv.org/abs/2402.05234>.
- Laurent, T. and Brecht, J. Deep linear networks with arbitrary loss: All local minima are global. In *International conference on machine learning*, pp. 2902–2907. PMLR, 2018.
- Liu, S., Ramadge, P. J., and Adams, R. P. Generative marginalization models, 2024. URL <https://arxiv.org/abs/2310.12920>.
- Loshchilov, I. and Hutter, F. Decoupled Weight Decay Regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- Lu, Z., Pu, H., Wang, F., Hu, Z., and Wang, L. The expressive power of neural networks: A view from the width. *Advances in neural information processing systems*, 30, 2017.
- Madan, K., Rector-Brooks, J., Korablyov, M., Bengio, E., Jain, M., Nica, A. C., Bosc, T., Bengio, Y., and Malkin, N. Learning GFlowNets from partial episodes for improved convergence and stability. In *International Conference on Machine Learning*, 2022. URL <https://proceedings.mlr.press/v202/madan23a.html>.
- Madan, K., Lamb, A., Bengio, E., Berseth, G., and Bengio, Y. Towards improving exploration through sibling augmented GFlowNets. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=HH4KWP8RP5>.
- Maddison, C. J., Mnih, A., and Teh, Y. W. The Concrete Distribution: A Continuous Relaxation of Discrete Random Variables. In *International Conference on Learning Representations*, 2017.
- Malik, S. A., Lahlou, S., Jesson, A., Jain, M., Malkin, N., Deleu, T., Bengio, Y., and Gal, Y. BatchGFN: Generative Flow Networks for Batch Active Learning, 2023. URL <https://arxiv.org/abs/2306.15058>.
- Malkin, N., Jain, M., Bengio, E., Sun, C., and Bengio, Y. Trajectory balance: Improved credit assignment in GFlowNets. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

- Malkin, N., Lahlou, S., Deleu, T., Ji, X., Hu, E., Everett, K., Zhang, D., and Bengio, Y. GFlowNets and variational inference. In *International Conference on Learning Representations (ICLR)*, 2023.
- Metelli, A. M., Lazzati, F., and Restelli, M. Towards theoretical understanding of inverse reinforcement learning, 2023. URL <https://arxiv.org/abs/2304.12966>.
- Mohri, M., Rostamizadeh, A., and Talwalkar, A. *Foundations of machine learning*. MIT press, 2018.
- Morozov, N., Maksimov, I., Tiapkin, D., and Samsonov, S. Revisiting non-acyclic gflownets in discrete environments, 2025. URL <https://arxiv.org/abs/2502.07735>.
- Neal, R. M. et al. Mcmc using hamiltonian dynamics. *Handbook of markov chain monte carlo*, 2(11):2, 2011.
- Ni, T., Eysenbach, B., and Salakhutdinov, R. Recurrent model-free rl can be a strong baseline for many pomdps, 2022. URL <https://arxiv.org/abs/2110.05038>.
- Nica, A. C., Jain, M., Bengio, E., Liu, C.-H., Korablyov, M., Bronstein, M. M., and Bengio, Y. Evaluating generalization in GFlowNets for molecule design. *ICLR2022 Machine Learning for Drug Discovery workshop*, 2022.
- Pan, L., Malkin, N., Zhang, D., and Bengio, Y. Better Training of GFlowNets with Local Credit and Incomplete Trajectories. In *International Conference on Machine Learning (ICML)*, 2023a.
- Pan, L., Zhang, D., Courville, A., Huang, L., and Bengio, Y. Generative Augmented Flow Networks. In *International Conference on Learning Representations (ICLR)*, 2023b.
- Pandey, M., Subbaraj, G., and Bengio, E. GFlowNet Pre-training with Inexpensive Rewards. *NeurIPS 2024 Workshop AIDrugX*, 2024.
- Pardo, F., Tavakoli, A., Levdi, V., and Kormushev, P. Time limits in reinforcement learning, 2022. URL <https://arxiv.org/abs/1712.00378>.
- Randlov, J. Learning macro-actions in reinforcement learning. In Kearns, M., Solla, S., and Cohn, D. (eds.), *Advances in Neural Information Processing Systems*, volume 11. MIT Press, 1998. URL https://proceedings.neurips.cc/paper_files/paper/1998/file/8f19793b2671094e63a15ab883d50137-Paper.pdf.
- Richter, L., Boustati, A., Nüsken, N., Ruiz, F. J. R., and Ömer Deniz Akyildiz. Vargrad: A low-variance gradient estimator for variational inference, 2020. URL <https://arxiv.org/abs/2010.10436>.
- Robert, C. P., Casella, G., and Casella, G. *Monte Carlo statistical methods*, volume 2. Springer, 1999.
- Rumelhart, D. E., Hinton, G. E., and Williams, R. J. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, October 1986. ISSN 1476-4687. doi: 10.1038/323533a0. URL <http://dx.doi.org/10.1038/323533a0>.
- Särkkä, S. and Solin, A. *Applied Stochastic Differential Equations*. Cambridge University Press, April 2019. ISBN 9781316649466. doi: 10.1017/9781108186735. URL <http://dx.doi.org/10.1017/9781108186735>.
- Saxe, A. M., McClelland, J. L., and Ganguli, S. Exact solutions to the nonlinear dynamics of learning in deep linear neural networks, 2014. URL <https://arxiv.org/abs/1312.6120>.
- Scaman, K. and Virmaux, A. Lipschitz regularity of deep neural networks: analysis and efficient estimation, 2019. URL <https://arxiv.org/abs/1805.10965>.
- Schlag, I., Irie, K., and Schmidhuber, J. Linear transformers are secretly fast weight programmers, 2021. URL <https://arxiv.org/abs/2102.11174>.
- Schmidhuber, J. Learning to control fast-weight memories: An alternative to dynamic recurrent networks. *Neural Computation*, 4(1):131–139, January 1992. ISSN 1530-888X. doi: 10.1162/neco.1992.4.1.131. URL <http://dx.doi.org/10.1162/neco.1992.4.1.131>.
- Schmidhuber, J. An ‘introspective’ network that can learn to run its own weight change algorithm. In *1993 third international conference on artificial neural networks*, pp. 191–194. IET, 1993a.
- Schmidhuber, J. A ‘self-referential’ weight matrix. In *International conference on artificial neural networks*, pp. 446–450. Springer, 1993b.
- Shen, M. W., Bengio, E., Hajiramezanali, E., Loukas, A., Cho, K., and Biancalani, T. Towards Understanding and Improving GFlowNet Training. In *International Conference on Machine Learning*, 2023a.
- Shen, M. W., Bengio, E., Hajiramezanali, E., Loukas, A., Cho, K., and Biancalani, T. Towards Understanding and Improving GFlowNet Training. In *International Conference on Machine Learning*, 2023b. arXiv preprint arXiv:2305.07170.

- Silva, T., Alves, R. B., de Souza da Silva, E., Souza, A. H., Garg, V., Kaski, S., and Mesquita, D. When do GFlowNets learn the right distribution? In *The Thirteenth International Conference on Learning Representations*, 2025a. URL <https://openreview.net/forum?id=9GsgCUJtic>.
- Silva, T., Souza, A. H., Rivasplata, O., Garg, V., Kaski, S., and Mesquita, D. Generalization and distributed learning of GFlowNets. In *The Thirteenth International Conference on Learning Representations*, 2025b. URL <https://openreview.net/forum?id=PJNhZoCjLh>.
- Souza, A. H., Mesquita, D., Kaski, S., and Garg, V. Provably expressive temporal graph networks, 2022. URL <https://arxiv.org/abs/2209.15059>.
- Sutton, R. S., Barto, A. G., et al. *Reinforcement learning: An introduction*, volume 1. MIT press Cambridge, 1998.
- Tiapkin, D., Morozov, N., Naumov, A., and Vetrov, D. Generative Flow Networks as Entropy-Regularized RL. In *International Conference on Artificial Intelligence and Statistics*, pp. 4213–4221. PMLR, 2024. URL <https://arxiv.org/abs/2310.12934>.
- Trabucco, B., Geng, X., Kumar, A., and Levine, S. Design-bench: Benchmarks for data-driven offline model-based optimization. In *International Conference on Machine Learning*, pp. 21658–21676. PMLR, 2022.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. Attention is all you need, 2023. URL <https://arxiv.org/abs/1706.03762>.
- Venkatraman, S., Jain, M., Scimeca, L., Kim, M., Sendera, M., Hasan, M., Rowe, L., Mittal, S., Lemos, P., Bengio, E., Adam, A., Rector-Brooks, J., Bengio, Y., Berseth, G., and Malkin, N. Amortizing intractable inference in diffusion models for vision, language, and control. In *Advances in Neural Information Processing Systems*, 2024. URL <https://arxiv.org/abs/2405.20971>.
- Viviano, J. D., Younis, O. G., Choi, S., Schmidt, V., Bengio, Y., and Lahlou, S. torchgfn: A pytorch gflownet library, 2025. URL <https://arxiv.org/abs/2305.14594>.
- Wang, H., Fu, T., Du, Y., Gao, W., Huang, K., Liu, Z., Chandak, P., Liu, S., Van Katwyk, P., Deac, A., et al. Scientific discovery in the age of artificial intelligence. *Nature*, 620(7972):47–60, 2023.
- Wang, Y., Chang, Y.-Y., Liu, Y., Leskovec, J., and Li, P. Inductive representation learning in temporal networks via causal anonymous walks, 2022. URL <https://arxiv.org/abs/2101.05974>.
- Weisfeiler, B. and Lehman, A. A. A Reduction of a Graph to a Canonical Form and an Algebra Arising During This Reduction. *Nauchno-Tekhnicheskaya Informatsia*, Ser. 2 (N9):12–16, 1968.
- Whitehead, S. D. and Ballard, D. H. Learning to perceive and act by trial and error. *Machine Learning*, 7 (1):45–83, July 1991. ISSN 1573-0565. doi: 10.1023/a:1022619109594. URL <http://dx.doi.org/10.1023/A:1022619109594>.
- Xu, D., Ruan, C., Korpeoglu, E., Kumar, S., and Achan, K. Inductive representation learning on temporal graphs, 2020. URL <https://arxiv.org/abs/2002.07962>.
- Yu, T. Secrets of gflowNets’ learning behavior: A theoretical study, 2025. URL <https://arxiv.org/abs/2505.02035>.
- Zhang, D., Malkin, N., Liu, Z., Volokhova, A., Courville, A., and Bengio, Y. Generative flow networks for discrete probabilistic modeling, 2022. URL <https://arxiv.org/abs/2202.01361>.
- Zhang, D., Dai, H., Malkin, N., Courville, A., Bengio, Y., and Pan, L. Let the Flows Tell: Solving Graph Combinatorial Optimization Problems with GFlowNets. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023a.
- Zhang, D. W., Rainone, C., Peschl, M., and Bondesan, R. Robust scheduling with GFlowNets. In *International Conference on Learning Representations (ICLR)*, 2023b.
- Zhang, N., Yang, J., Cao, Z., and Chi, X. Adversarial generative flow network for solving vehicle routing problems, 2025. URL <https://arxiv.org/abs/2503.01931>.
- Zhou, M. Y., Yan, Z., Layne, E., Malkin, N., Zhang, D., Jain, M., Blanchette, M., and Bengio, Y. PhyloGFN: Phylogenetic inference with generative flow networks. In *International Conference on Learning Representations*, 2024.

A. 证明

本节提供了文本中各命题及其所需的推论的证明。我们在第 4.3 节的结果与 (Bengio 等, 223 年; Malkin 等, 22 年; Madan 等, 22 年) 的研究结果紧密吻合, 详情请参阅上述文献。

A.1. 命题 3.1 的证明

本证明分为两个步骤。首先, 我们刻画了马尔可夫参数化和路径依赖参数化下可学习分布的空间。其次, 我们论证在命题 3.1 的条件下, 后者大于前者。对于 $M = 1, \mathbf{W}_i = \mathbf{W} \in \mathbb{R}^{2 \times d}$ 马尔可夫模型而言。为了清晰起见, 令

$$\text{Softmax}(\mathbf{W}\psi(p_i)) = [\alpha_i \quad 1 - \alpha_i];$$

等价地, 对于 $\mathbf{y}_i = \mathbf{W}\psi(p_i) \in \mathbb{R}^2, \log \frac{\alpha_i}{1-\alpha_i} = \mathbf{y}_i^T(\mathbf{e}_1 - \mathbf{e}_2)$, 其中 $\mathbf{e}_1, \mathbf{e}_2 \in \{1, 0\}^{2 \times 1}$ 作为单位矩阵的第一列和第二列。(按照标准惯例, 向量在 $\mathbb{R}^d$ 表示列向量)。我们省略 $\mathbf{m}_i$ 因为 $\mathbf{m}_i = \mathbf{1}$ 对于每个 i 除了 $i = N$ ——在这种情况下 $\alpha_N = 0$ 是唯一解。

从这个角度来看, 采样的目标可以通过线性系统来表示

$$\mathbf{o} = \Psi \mathbf{k}, \quad (13)$$

其中 $\mathbf{o} \in \mathbb{R}^N, \mathbf{o}_i = \log \alpha_i / (1 - \alpha_i)$, 以及 $\Psi, \Psi_i = \psi(p_i)^T$, 是固定的, 而 $\mathbf{k}_i = \mathbf{W}^T(\mathbf{e}_1 - \mathbf{e}_2)$ 是我们希望通过 $\mathbf{W}$ 学习的数量。因此, 我们只能学习那些策略的对数几率 $\mathbf{o}$ 位于状态嵌入矩阵的列空间内的分布, 即 Ψ 。根据命题 3.1 的记号, 这意味着 $\dim \mathcal{W}_M = \text{rank } \Psi \leq d$ 。

在我们线性控制系统的非马尔可夫参数化下, 相应的学习问题变为

$$\mathbf{o}_i = \psi(p_i)^T \mathbf{a}_i \mathbf{b}^T (\mathbf{e}_1 - \mathbf{e}_2),$$

其中

$$\mathbf{a}_i = \mathbf{a}_o + \left[\sum_{0 \leq j \leq i} \mathbf{w}_a^T \psi(p_j) \right] \mathbf{v}_a.$$

显然, $\delta := \mathbf{b}^T(\mathbf{e}_1 - \mathbf{e}_2)$ 几乎总是非零标量 (相对于 $\mathbf{b}$)。因此, 我们设 $\tilde{\mathbf{o}}_i = \mathbf{o}_i / \delta$ 。类似地定义

$$\mathbf{c}_i = \sum_{0 \leq j \leq i} \psi(p_j) \quad (14)$$

作为状态嵌入 $\psi(p_j)$ 的累积和。然后, $\mathbf{a}_i = \mathbf{a}_o + (\mathbf{w}_a^T \mathbf{c}_i) \mathbf{v}_a$,

$$\tilde{\mathbf{o}}_i = \psi(p_i)^T \mathbf{a}_o + \psi(p_i)^T (\mathbf{w}_a^T \mathbf{c}_i) \mathbf{v}_a = \psi(p_i)^T \mathbf{a}_o + (\psi(p_i)^T \mathbf{v}_a) \cdot (\mathbf{c}_i^T \mathbf{w}_a).$$

设 $\mathbf{C}$ 为矩阵 $N \times d$, 其第 i 行是 $\mathbf{c}_i$ 。根据上述方程,

$$\tilde{\mathbf{o}} = \Psi \mathbf{a}_o + [\Psi \mathbf{v}_a] \odot [\mathbf{C} \mathbf{w}_a]. \quad (15)$$

因此, 我们的路径依赖线性模型可以表示任何对应的策略对数几率位于由 Ψ 张成的线性空间以及 $\mathbf{C}$ 和 Ψ 的哈达玛张成空间内的分布。换句话说, 令

$$\mathcal{C} = \{\mathbf{v} : \mathbf{v} = \Psi \mathbf{w} \text{ 对于某些 } \mathbf{w} \text{ 及 } \mathcal{H} = \{\mathbf{v} : \mathbf{v} = (\mathbf{C} \mathbf{a}) \odot \mathbf{b} \text{ 对于某些 } \mathbf{a} \in \mathbb{R}^d\}.$$

b) 对于某些 在这种情况下, 马尔可夫参数化表示的分布范围的维度是 $\dim \mathcal{C}$, 而路径依赖模型能够表示维度为 $\dim(\mathcal{C} + \mathcal{H})$ 的空间中的分布。因此, $\dim \mathcal{W}_P := \dim(\mathcal{C} + \mathcal{H}) \geq \dim \mathcal{C} =: \dim \mathcal{W}_M$, 无论 ψ 如何, 显然有 $\dim \mathcal{W}_P \geq \dim \mathcal{W}_M$ 对于某些 ψ ; 一个简单的例子是当 $\psi(p_i) = \mathbf{1}_d \in \mathbb{R}^d$ 为常数时, 此时 $\mathcal{C} = \{\alpha \mathbf{1}_N : \alpha \in \mathbb{R}\} \subset \mathbb{R}^N$ 和 $\mathcal{H} = \{\alpha [0 \dots N-1]^T : \alpha \in \mathbb{R}\}$; 因此, $\dim \mathcal{C} = 1$ 和 $\dim(\mathcal{H} + \mathcal{C}) = 2$ 。

$[0 \quad 1 \quad \dots \quad N-1]$ 我们发现自然嵌入 $\psi(p_i) = i$ 下的情况 $d = 1 [c_0 \quad c_1 \quad \dots \quad c_{N-1}]$, $c_i = \frac{i(i-1)}{2}$ 具有启发性。在这些条件下, $\mathcal{C}$ 仅仅是被 $\mathbf{1}_N$ 张成的, 而 $\mathcal{H}$ 是 $\mathbf{C}$ 与 $\mathbf{N}$ 之间的哈达玛乘积。显然, $\mathbf{N}$ 和 $\mathbf{C}$ 对于 $N \geq 3$ 是线性无关的。感兴趣的读者可以补充细节。

¹ 我们省略 $\mathbf{o}$ 中的第 N 项, 因为它是 $\alpha_N = 0$ (在 p_N 处唯一的动作是前往 q_N)。

A.2. 命题 3.2 的证明

与前一节类似，本证明分为两步：首先证明每个可由马尔可夫参数化表示的分布也可以被其路径依赖的对应模型所学习；然后，展示存在只能被后者学习的分布。

一方面，显然由循环 GNN 定义的路径依赖模型至少与它的马尔可夫对应模型一样具有表现力。为了看到这一点，只需注意到我们可以将 $\mathbf{V}$ 的第一个 GNN 层中附加的（最右侧）坐标置零；这样做后，得到的模型等同于方程 (6) 中的模型 thefirst GNN 。

$$\mathcal{R}_P(S) \subseteq \mathcal{R}_M(S).$$

另一方面，考虑图 4 中的状态图 S^* 。正如正文所示，参数化为方程 (6) 的 GFlowNet 只能从终端状态的均匀分布中采样， q_1 和 q_2 。相比之下，由于边 (a, b) 和 (a, c) 具有不同的时间特征（在生成过程中， b 修改了一次； c ，两次），从 p 到 q_1 和 q_2 的动作可以通过循环 GNN 区分。因此，我们的路径依赖模型可以逼近任何分布在 $\{q_1, q_2\}$ 上的分布。也就是说， $\mathcal{R}_M(S^*) \neq \mathcal{R}_P(S^*)$ 。这结束了我们的证明。

A.3. 命题 4.5 的证明

我们直接计算每个增强状态 s^* 的边缘分布 p_τ ，以表明

$$p_\tau(s^*) = \sum_{\tau \rightsquigarrow s^*} p_F(\tau | s_o^*) \propto F(s^*);$$

由于终端对象的空间， $\mathcal{X}$ ，在提升的 DAG 中保持不变，这意味着我们的路径依赖模型的边缘分布与 R 在 $\mathcal{X}$ 上匹配（相差一个归一化常数）。应该指出的是，由于潜在动力系统的确定性性质，在 SG^* 中对于 $p_F(\tau | s_o^*) > 0$ 的轨迹数量是有限的。缺乏有限性是设计随机潜在动力系统比确定性系统困难得多的原因——参见 D 节。

Our assumption is that

$$F(s_i^*) p_F(s_{i+1:j}^* | s_i^*) = p_B(s_{i:j-1}^* | s_j^*) F(s_j^*)$$

对于每个轨迹的每一部分 $\tau = (s_t^*)_{t=0}^T$ 。固定 $i = 0$ 。那么，由 $p_F(\cdot | s_o^*)$ 诱导的 s^* 的边缘分布是

$$p_\tau(s^*) = \sum_{\tau: s_o^* \rightsquigarrow s^*} p_F(\tau | s_o^*) = \sum_{\tau: s_o^* \rightsquigarrow s^*} p_B(\tau | s^*) \cdot \frac{F(s^*)}{F(s_o^*)}.$$

显然， $\sum_{\tau: s_o^* \rightsquigarrow s^*} p_F(\tau | s_o^*) = 1$ 由于 s_o^* 是逆策略在 SG^* 上诱导的马尔可夫链中唯一的吸收状态。这一点也可以通过该和的递归特征来观察。确实，设 $Q(s_o^*) = 1$ 和

$$Q(g^*) = \sum_{\tau: s_o^* \rightsquigarrow g^*} p_B(\tau | g^*)$$

对于提升后的有向无环图上的每个状态 g^* 。那么，

$$Q(s^*) = \sum_{\tau: s_o^* \rightsquigarrow s^*} p_B(\tau | s^*) = \sum_{g^* \in \text{Pa}(s^*)} p_B(g^* | s^*) \sum_{\tau: s_o^* \rightsquigarrow g^*} p_B(\tau | g^*) = \sum_{g^* \in \text{Pa}(s^*)} p_B(g^* | s^*) Q(g^*).$$

因为 $\sum_{g^* \in \text{Pa}(s^*)} p_B(g^* | s^*) = 1$ ，上述方程意味着 $\mathbf{Q} := (Q(g^*))_{g^* \in \mathcal{S}^* \cup \mathcal{X}}$ 是对应于单位特征值的随机矩阵的特征向量。由于有向无环图的有限性， $\mathbf{Q} = \mathbf{1}$ 是唯一的特征向量（由于边界条件， $Q(s_o^*) = 1$ ，因为 s_o^* 是逆策略的吸收状态）。形式上，通过写作 $\mathbf{Q} = \mathbf{M}\mathbf{Q}$ 对于随机矩阵 $\mathbf{M}$ ，我们可以按照拓扑顺序重新索引底层有向无环图的节点。这样， $\mathbf{M}$ 成为上三角矩阵，并且 $\mathbf{Q}$ 的值可以通过反向归纳唯一地确定，给定边界条件在 s_o^* 。总体而言，我们注意到

$$p_\tau(s^*) = \frac{F(s^*)}{F(s_o^*)} \sum_{\tau: s_o^* \rightsquigarrow s^*} p_B(\tau | s^*) \propto F(s^*).$$

推论 4.6、4.7、B.1 直接来自命题 3.2。事实上，推论 4.7 蕴含推论 4.6，而推论 B.1 中的全局最小值满足推论 4.6 或 4.7。

附录 A.4. 命题 4.8 的证明

在正式展示正向策略路径独立性的证明之前，读者应回顾图 1b 中的图形模型。如果 p_B 与 $\{W_t\}_{t \geq 1}$ 独立——因为两者在满足（轨迹或对比）平衡条件时诱导相同的轨迹分布。因此， p_F 也应该与 $\{W_t\}_{t \geq 1}$ 独立。下面的证明基于这一直觉：我们计算由 p_F 诱导的轨迹联合分布，并通过 TB 条件将其转换为 p_B 诱导的联合分布。然后，我们边缘化所有跟随给定转移的后续状态 (s_t, s_{t+1}) ，以表明从 s_t 到 s_{t+1} 的概率不依赖于在 s_t 之前的任何状态。

为了简洁起见，设 $\bar{S} = S \cup \mathcal{X}$ 和 $\bar{S}^* = S^* \cup \mathcal{X}$ 。设 $p_B: \bar{S}^* \times \mathcal{S}^* \rightarrow [0, 1]$ 和 $\tilde{p}_B: \bar{S} \times \mathcal{S} \rightarrow [0, 1]$ 是命题 4.8 中的逆策略，它们满足 $p_B(s_t^* | s_{t+1}^*) = \tilde{p}_B(s_t | s_{t+1})$ 对于 $s_t^* = (s_t, W_t) \in \mathcal{S}^*$ 和 $(s_t^*)_{t=0}^{T-1} \in (\mathcal{S}^*)^{T-1} \times \mathcal{X}$ as a 有效的轨迹在 SG^* 。在这些条件下，请记住，遵守 CB 条件的正向策略也满足 TB 条件 (da Silva 等, 2024a)。因此，我们假设存在一个 Z^* 使得

$$Z^* \prod_{0 \leq t \leq T-1} p_F(s_{t+1}^* | s_t^*) = R(s_T) \prod_{0 \leq t \leq T-1} p_B(s_t^* | s_{t+1}^*) = R(s_T) \prod_{0 \leq t \leq T-1} \tilde{p}_B(s_t | s_{t+1}) \quad (16)$$

对于每条完整的轨迹 $(s_t^*)_{t=0}^T$ 在提升后的有向无环图上 SG^* 。此外，回忆一下存在策略 p_S 和 p_W 使得

$$p_F(s_{t+1}^* | s_t^*) = p_S(s_{t+1} | s_t, W_t) \cdot p_W(W_{t+1} | s_{t+1}, W_t);$$

$p_W(W_{t+1} | s_{t+1}, W_t)$ 要么是 1 要么是 0 —— 取决于是否 $SG^*, p_W(W_{t+1} | s_t, W_t) = 1$ $W_{t+1} = W_t + \phi(W_t, s_{t+1})$ 。根据方程 (16)，这仅适用于轨迹在 Z^* 中。

$$Z^* \prod_{0 \leq t \leq T-1} p_S(s_{t+1} | s_t, W_t) = R(s_T) \prod_{0 \leq t \leq T-1} \tilde{p}_B(s_t | s_{t+1}). \quad (17)$$

我们将证明 $p_F(s_{t+1}^* | s_t^*)$ 是路径无关的；等价地说， W_t 不依赖于通往 s_t^* 的路径。为此，我们定义了特定的 $\tilde{p}_F(s_{t+1} | s_t) = p_F(s_{t+1} | s_t, W_t)$ 对于这个 W_t ，从而完成证明。设 $\xi^* = (s_t^*)_{t=0}^{l-1}$ 是一个（可能是不完整的）轨迹， $\xi = (s_t)_{t=0}^{l-1}$ ，并根据方程 (16) 中的分解，有 $p_B(\xi^*) := (R(s_T)/Z^*) p_B(\xi^* | s_T)$

重要的是，当 $l = 1$ 时结果是显然的，因为 W_0 是固定的。从现在开始，假设 $l \geq 2$ 。在这种情况下，很容易看出

$$p_S(s_l | \xi^*) = \frac{p_F(s_l^*, \xi^*)}{p_F(\xi^*)} = \frac{\sum_{\tau: s_l^* \rightsquigarrow \mathcal{X}} p_F(\xi^*, s_l^*, \tau)}{\sum_{\tau': s_{l-1}^* \rightsquigarrow \mathcal{X}} p_F(\xi^*, \tau')};$$

$\tau: s_l \rightsquigarrow \mathcal{X}$ 指的是从 s_l^* 开始并结束于任何 $x \in \mathcal{X}$ 的轨迹空间。因此，

$$p_S(s_l | \xi^*) = \frac{\sum_{\tau: s_l \rightsquigarrow \mathcal{X}} \tilde{p}_B(\xi, s_l, \tau)}{\sum_{\tau': s_{l-1} \rightsquigarrow \mathcal{X}} \tilde{p}_B(\xi, \tau')}$$

根据方程 (16)；轨迹 $\tau: s_l \rightsquigarrow \mathcal{X}$ 存在于未提升的 DAG 中。由于 $\tilde{p}_B(\xi, s_l, \tau) = \tilde{p}_B(\xi | s_{l-1}) \cdot \tilde{p}_B(s_{l-1}, \tau)$ 和 $\tilde{p}_B(\xi, \tau') = \tilde{p}_B(\xi | s_{l-1}) \cdot \tilde{p}_B(s_{l-1}, \tau')$ ， $p_S(s_l | s_{l-1}, W_{l-1}) = p_S(s_l | \xi^*) = \frac{\tilde{p}_B(\xi | s_{l-1}) \sum_{\tau: s_l \rightsquigarrow \mathcal{X}} \tilde{p}_B(s_{l-1}, \tau)}{\sum_{\tau': s_{l-1} \rightsquigarrow \mathcal{X}} \tilde{p}_B(s_{l-1}, \tau')} = \tilde{p}_B(s_l | s_{l-1})$ 。也就是说， $p_S(s_l | \xi^*)$ 仅依赖于 s_{l-1} 和 s_l —— 而不依赖于过去的潜在动力系统 $\{W_t\}_{t \geq 0}$ 。这刻画了 p_F 的马尔可夫性（相对于未提升状态空间的自然过滤）。

B. 学习循环流

本节提供了关于学习循环策略网络的进一步细节——即满足定义 D.1 的提升 DAG 上策略 p_F 的定理 4.7 或 4.6。我们也详细阐述了我们的路径相关算法与用于描述 GFlowNets 的流网络类比之间的联系。




图 8. 多门限流网络对路径依赖 (a) 和马尔可夫 (b) 近似采样的解释。在我们的框架下，每个节点根据流过去的轨迹（例如，对于 x_1 的父节点，可能是绿色或红色）向其子节点发送不同数量的流。两种情况下，到达每个终端状态 (x_1, x_2, x_3) 的流相同；详情见第 4 节。

关于流网络的类比。 Bengio 等人 (2021) 开创性工作的重要贡献之一是对 GFlowNets 提出了物理解释，即将采样视为一个流分配问题。在这种认识论下，终端状态 $x \in \mathcal{X}$ 的未归一化分布 $R(x)$ 被视为应从初始状态 (s_0 通过状态图的边传输到 x 的流的数量；参见 (Kim 等人, 2024b, 图 2) 和图 8b)。有趣的是，图 8a 显示，我们提出的框架也可以被解释为在一个多门限流网络中学习流分配，在这个网络中，每个节点可以根据提升状态图 (定义 D.1) 中隐变量 W 的值向其子节点发送不同数量的流。基于此，读者可以注意到许多最近针对 GFlowNets 的算法改进（例如，(Kim 等人, 2024a; Malik 等人, 2023; Lau 等人, 2023; 2024; Kim 等人, 2025a)）可以轻松适应我们的设置。我们在正文的第 4 节以及补充材料的第 E 节（如下）讨论了一些这些改进。

学习递归策略网络。 为了完整性，我们也详细阐述了寻找满足引入的任何平衡条件的策略 p_F 和 p_B 的过程。为此，我们只需通过随机梯度下降最小化命题 4.5 中左侧和右侧之间的对数平方差的期望。由于相应的随机规划问题已经在其他地方 (Bengio 等人, 2021; Malkin 等人, 2022; 2023; Madan 等人, 2022; da Silva 等人, 2024a; Hu 等人, 2024b; Zhang 等人, 2023a) 在马尔可夫采样的背景下进行了介绍和研究，它们仅在命题 4.5 的以下推论中简要描述。

推论 B.1 (学习目标)。设 p_E 是一个探索性策略²，它可能依赖于 p_F (e.g., an ϵ 贪婪策略： $p_E(\cdot|s) = (1 - \epsilon)p_F(\cdot|s) + \epsilon p_U(\cdot|s)$ (其中 p_U 是均匀策略))。那么，所有策略上各自目标函数的无约束全局最优分别满足 TB (推论 4.6) 和 CB (推论 4.7) 条件。

1. (TB 损失)。设 $Z = F(s_0^*)$ 为初始状态的流。则，

$$\mathcal{L}_{TB}(p_F, p_B, Z) = \mathbb{E}_{\tau \sim p_E} \left[\left(\log \frac{Z p_F(\tau | s_0^*)}{p_B(\tau | x) R(x)} \right)^2 \right]$$

2. (CB 损失)。由于独立同分布随机变量平方差的方差恒等式 (Richter 等人, 2020; Zhang 等人, 2023b)，

$$\begin{aligned} \mathcal{L}_{CB}(p_F, p_B) &= \mathbb{E}_{\tau, \tau' \sim p_E} \left[\left(\log \frac{p_F(\tau | s_0^*) p_B(\tau' | x') R(x')}{p_B(\tau | x) p_F(\tau' | s_0^*) R(x)} \right)^2 \right] \\ &= 2 \text{Var}_{\tau \sim p_E} \left[\log \frac{p_F(\tau | s_0^*)}{p_B(\tau | x) R(x)} \right] \end{aligned}$$

其中 x, x' 表示 τ, τ' 的终端状态。

重要的是，推论 B.1 确保了图 1b 中 $\{s_t\}_{t \geq 1}$ 和 $\{W_t\}_{t \geq 1}$ 的转移动态可以通过最小化单一随机目标来联合学习。值得注意的是，上述公式的简洁性仅因潜在转换的确定性性质而成为可能。当 $\{W_t\}_{t \geq 1}$ 遵循随机规则时，状态 2 一个探索策略是在每个状态下将正概率分配给状态图的每个子节点。根据 D 节的形式化，这意味着相应的核函数 P_E 与基准测度 κ_F 相互绝对连续。

空间不再可数；因此，对由此产生的方法的严格处理依赖于更复杂的数学形式化——见 D 节。有趣的是，我们的分析有意避免考虑非无环环境中的采样，例如 (Brunswic 等人, 2024; Morozov 等人, 2025)。尽管如此，我们的路径依赖框架可以自然地扩展到这一更广泛的设置。事实上，我们认为潜在的动力系统可以自然用于在循环生成的背景下偏向较短轨迹的近似采样器——这是一个未来研究的有趣方向。

C. 相关工作

对离散和组合空间中的摊销神经采样器进行系统研究始于生成流网络 (Generative Flow Networks, GFlowNets; Bengio 等, 2021) 的引入。最初, GFlowNets 被提议作为一种追求多样性的强化学习算法 (Bengio 等, 2021; 2023)。在 Bengio 等 (2021) 开创性工作之后不久, GFlowNets 成功应用于分子和生物序列发现 (Bengio 等, 2021; Jain 等, 2022; Wang 等, 2023; Nica 等, 2022)、结构学习 (Deleu 等, 2022; 2023)、组合优化 (Zhang 等, 2023a;b; 2025)、系统发育推断 (Zhou 等, 2024) 以及大语言模型的微调 (Hu 等, 2024a; Venkatraman 等, 2024)。与此同时, 人们投入了大量精力来开发算法改进, 以降低 GFlowNets 的样本复杂度。这些方法主要集中在通过奖励塑形 (Pan 等, 2023b;a) 进行改进的信用分配、更有效的学习目标 (Madan 等, 2022; Deleu 等, 2024) 以及用于增强高概率区域探索 (Kim 等, 2024b; 2025b) 和缩短轨迹长度 (Boussif 等, 2024; Silva 等, 2025b) 的启发式方法, 以减少复杂度。根据命题 4.5, 我们注意到我们的方法补充而非替代这些技术。除此之外, 还有一系列文献致力于构建一个基于优化 (Yu, 2025)、表达能力 (Silva 等, 2025a) 和泛化 (Shen 等, 2023b; Atanackovic & Bengio, 2024) 的理解 GFlowNets 的原则框架。特别地, 在 (Silva 等, 2025a) 中, 对于第 5 节描述的问题, 子图中的流一致性 (FCS),

$$\text{FCS}(p, q) = \mathbb{E}_{\mathcal{B} := \{x_1, \dots, x_B\} \sim r} \left[\frac{1}{2} \sum_{1 \leq i \leq B} \left| \frac{p(x_i)}{p(\mathcal{B})} - \frac{q(x_i)}{q(\mathcal{B})} \right| \right] = \mathbb{E}_{\mathcal{B} \sim r} [\text{TV}(p|_{\mathcal{B}}, q|_{\mathcal{B}})], \quad (18)$$

其中 p, q 和 r 是分布, B 是一个常数, 且 $p(\mathcal{B}) = \sum_{x \in \mathcal{B}} p(x)$, $p|_{\mathcal{B}}$ 是 p 在 $\mathcal{B}$ 上的限制, 提供了衡量 GFlowNets 拟合优度的可靠指标, 其与整个空间上学习分布和目标分布之间的 TV 距离的 (Spearman) 相关性超过 90%; 我们遵循了 (Silva 等, 2025a, 附录 E) 中的指导来评估 FCS。有趣的是, 我们的采样算法类似于吉布斯采样 (Jones & Hobert, 2001; Gelfand & Smith, 1990), 实施了一种系统扫描策略来修改状态: $(s, \omega) \rightarrow (s', \omega) \rightarrow (s', \omega')$ 。

D. 随机潜在动力系统

本节基于 Lahlou 等人 (2023) 的框架, 将图 1b 所示的路径依赖算法扩展到潜在动力系统 $\{W_t\}_{t \geq 1}$ 按照随机规则演化的场景。下面定义的结果提升有向无环图在图 9 中进行了说明。与我们在第 4.1 节中的阐述不同, 在那里我们的目标仅仅是从分布 $\mathcal{X}$ 上进行采样, 我们现在专注于从联合分布 $\pi(x, \omega)$ 上进行采样, 该联合分布在 $\mathcal{X}$ 和用户定义的集合 Ω 上, 使得 π 在 $\mathcal{X}$ 上的边缘分布匹配我们的目标分布 (R , 在正文中标记)。

定义 D.1. 设 $(\bar{\mathcal{S}}, \Sigma_{\bar{\mathcal{S}}})$ 和 $(\Omega, \Sigma_{\Omega})$ 是具有 Borel σ -代数 Σ 和 Σ_{Ω} 的可测拓扑空间。另外, 设 ν 是乘积空间 $(\bar{\mathcal{S}} \times \Omega, \Sigma)$ 上的正概率测度, 其中 Σ 是由乘积 $\Sigma_{\bar{\mathcal{S}}} \times \Sigma_{\Omega}$ 诱导的 σ -代数。设 $\mathcal{S}^* = \bar{\mathcal{S}} \times \Omega$ 是提升状态空间。我们定义 $\bar{\mathcal{S}} = \{s_0\} \cup \mathcal{S} \cup \mathcal{X}$, 其中 $\{s_0\}$ 和 $\mathcal{X}$ 是分别称为初始状态和终端状态的特殊开集。我们假设存在向前 $\kappa_F: \mathcal{S}^* \rightarrow \mathcal{M}(\Sigma)$ 和向后 $\kappa_B: \mathcal{S}^* \rightarrow \mathcal{M}(\Sigma)$ 核函数, 它们将每个 $s^* \in \mathcal{S}^*$ 映射到 Σ 上的概率测度, 并满足以下性质。




图 9. 定义 D.1 的示意图。我们将每个未提升有向无环图 (参见定义 2.1) 中的节点赋予一个潜在的随机变量 (用红色表示)。

1. **(Duality).** $\nu(ds)\kappa_F(s, ds') = \nu(ds')\kappa_B(s', ds)$ on $\Sigma|_{(\{s_0\} \cup \mathcal{S}) \times \Omega} \times \Sigma|_{(\mathcal{S} \cup \mathcal{X}) \times \Omega}$.

2. (向前吸收性)。存在一个 $N \in \mathbb{N}$, 使得 κ_F^N 对于所有 $(s, \mathcal{X} \times \Omega) = 1$ $s \in (\{s_0\} \cup \mathcal{S}) \times \Omega$, 其中

$\kappa_F^N(s, B) = \int_{\mathcal{S}^*} \kappa_F(s, ds') \kappa_F^{N-1}(s', B)$ 是递归定义的。另外, $\kappa_F(x^*, \{x\} \times \Omega) = 1$ ν -几乎处处成立, 对于和 $x^* \in \{x\} \times \Omega$ $x \in \mathcal{X}$ $\kappa_F(s, (\mathcal{S} \cup \mathcal{X}) \times \Omega) = 1$ 对每个 $s \in \mathcal{S}^*$. 及

3. (可达性)。对于每个可测的 $B \in \Sigma$, 存在一个整数 $k \in \mathbb{N}$, 使得 $\int_{\mathcal{S}_o} \nu(ds_o^*) \kappa_F^k(s_o^*, B) > 0$, 其中 $\mathcal{S}_o^* = \{s_o\} \times \Omega$ 。

4. (Backward absorption) 对于 κ_B , i.e., $\kappa_B(s_o^*, \mathcal{S}_o^*) = 1$ ν -几乎处处唯一的吸收集对于 $s_o^* \in \mathcal{S}_o^*$ 。同样, 几乎处处对于 $\kappa_B(s^*, (\mathcal{S} \setminus \mathcal{X}) \times \Omega) = \kappa_B|_{\mathcal{S}^*}$ $\mathcal{S}^* \nu$ -几乎处处, $s^* \in \mathcal{S}^*$ 尤其是, $\kappa_B(s^*, \mathcal{S}^* \times \Omega) = 1$ 几乎处处。

5. (连续性)。对于所有 $B \in \Sigma$, $s \mapsto \kappa_F(s, B)$ 和 $s \mapsto \kappa_B(s, B)$ 均为连续函数 (相对于给定拓扑)。6. (绝对连续性)。对于所有 $s \in \mathcal{S}^*$, $\kappa_F(s, \cdot)$ 和 $\kappa_B(s, \cdot)$ 相对于 ν 均绝对连续。

7. (ν -非退化性)。对于每个 $s \in \mathcal{S}^*$, 如果 $\kappa_B(s, E) > 0$ $E \in \Sigma$, then $\kappa_B(s, \tilde{E}) > 0$ 对于某些 subset $\tilde{E} \subseteq E$ 与 $\nu(\tilde{E}) > 0$ 。可测的

定义 D.1 刻画了一个配备有连续随机隐变量的提升有向无环图, 该隐变量存在于集合 Ω 中。在继续之前, 我们回顾一下 $\Sigma|_A$ 是 σ -代数 Σ 到可测集 A 上的限制; 由于 σ -代数对于交集是封闭的, 这个定义是合理的。给定一个在 $\Sigma \times \Omega$ 上的测度 $\nu|_{\{s_o\} \times \Omega}$, 我们的目标是得到该测度下的边缘分布 $\mathcal{X} \times \Omega$ 由 (学习到的) 核函数诱导的 $\Omega: P_F: \mathcal{S}^* \rightarrow \mathcal{M}(\Sigma)$ 关于... 绝对连续 κ_F 与给定的目标 (可能是未归一化的) 相匹配 $\Pi: \Sigma|_{\mathcal{X} \times \Omega} \rightarrow [0, 1]$ 。换句话说,

$$\int_{\{s_o\} \times \Omega} \xi(ds_o^*) P_F^N(s_o, B) = \Pi(B)$$

对于每个 $B \in \Sigma|_{\mathcal{X} \times \Omega}$ 。当存在概率测度 $R: \Sigma|_{\mathcal{X}} \rightarrow [0, 1]$ 和 $P_\Omega: \Sigma\Omega \rightarrow [0, 1]$ 使得 $\Pi(B_S \times B_\Omega) = R(B_S) P_\Omega(B_\Omega)$ 对于 $B_S \times B_\Omega \in \Sigma$, 上述条件确保了当隐变量在 Ω 被边缘化时, $\xi(ds_o^*) \kappa_F(s_o^*, B)$ 在 $\mathcal{X}$ 上的边缘分布与 $R(B)$ 匹配。接下来需要回答如何学习这样的 κ_F 和 ξ 以及如何定义 P_Ω 。我们将在下面简要评论这些事实。为了实现这一目标, 我们首先陈述关于提升连续有向无环图 (Definition D.1) 的一些一般事实。我们首先展示 $\mathcal{X} \times \Omega$ 是 κ_F 的一个有限吸收状态; 根据以下陈述, 我们说 κ_F 是一个具有时间范围 N 的有限吸收核。

引理 D.2. 设 $\mathcal{X}^* = \mathcal{X} \times \Omega$ 。则, $\kappa_F^n(s, \mathcal{X}^*) = 1$ $n \geq N$ 对于所有

证明。我们通过简单的归纳进行证明。基本情况, $\kappa_F^N(s, \mathcal{X}^*) = 1$, 由定义得出。假设 $\kappa_F^n(s, \mathcal{X}^*) = 1$ 对某个 $n \geq N$ 成立。那么,

$$\kappa_F^{n+1}(s, \mathcal{X}^*) = \int_{\mathcal{S}^*} \kappa_F(s, ds') \kappa_F^n(s', \mathcal{X}^*) = \int_{\mathcal{S}^*} \kappa_F(s, ds') = 1.$$

By induction, $\kappa_F^n(s, \mathcal{X}^*) = 1$ 对于所有 $n \geq N$. □

我们还证明了定义 D.1 中的对偶性对于轨迹也成立。

Lemma D.3. $\nu(ds_1) \prod_{i=1}^n \kappa_F(s_i, ds_{i+1}) = \nu(ds_{n+1}) \prod_{i=1}^n \kappa_B(s_{i+1}, ds_i)$ 对于每个 $n \geq 2$ on $\Sigma(\{s_o\} \cup \mathcal{S}) \times \Omega \times (\times_{i=2}^n \Sigma_{\mathcal{S} \times \Omega}) \times \Sigma_{(\mathcal{S} \cup \mathcal{X}) \times \Omega}$.

证明。我们将证明这适用于 $n = 2$, 然后进行归纳。为了简洁起见, 令 $A = \{s_o\} \cup \mathcal{S}$ 和 $B = \mathcal{S} \cup \mathcal{X}$ $f: K_2 \rightarrow \mathbb{R}$ 对于 $K_2 = (A \times \Omega) \times (\mathcal{S} \times \Omega) \times (B \times \Omega)$,

$$\begin{aligned} \int_{K_2} f(s_1, s_2, s_3) \nu(ds_1) \kappa_F(s_1, ds_2) \kappa_F(s_2, ds_3) &= \int_{K_2} f(s_1, s_2, s_3) \nu(ds_2) \kappa_B(s_2, ds_1) \kappa_F(s_2, ds_3) \\ &= \int_{K_2} f(s_1, s_2, s_3) \nu(ds_3) \kappa_B(s_3, ds_2) \kappa_B(s_2, ds_1) \end{aligned}$$

通过对偶性。归纳地，假设该恒等式对于 n 成立。那么，令 $f: K_{n+1} \rightarrow \mathbb{R}$ 为任意实值可测函数，在其中 $K_{n+1} = (A \times \Omega) \times (S \times \Omega)^n \times (B \times \Omega)$ 。因此，

$$\begin{aligned} \int_{K_{n+1}} f(s_1, \dots, s_{n+2}) \nu(ds_1) \prod_{i=1}^{n+1} \kappa_F(s_i, ds_{i+1}) &= \int_{K_{n+1}} f(s_1, \dots, s_{n+2}) \nu(ds_{n+1}) \prod_{i=1}^n \kappa_B(s_{i+1}, ds_i) \kappa_F(s_{n+1}, ds_{n+2}) \\ &= \int_{K_{n+1}} f(s_1, \dots, s_{n+2}) \nu(ds_{n+2}) \prod_{i=1}^{n+1} \kappa_B(s_{i+1}, ds_i), \end{aligned}$$

其中第一个等式由归纳假设（以及 $f_{s_{n+2}}: K_n \rightarrow \mathbb{R}$ ，和 $f_{s+2}(s_1, \dots, s_{n+1}) := f(s_1, \dots, s_{n+2})$ 的可测性）得出，第二个等式则由 $\Sigma|_{S \times \Omega} \times \Sigma|_{(S \cup \mathcal{X}) \times \Omega}$ 中的对偶性 κ_F 和 κ_B 得出。由于 f 是任意选择的，我们验证了对于 $\Sigma(\{s_o\} \cup S) \times \Omega \times$ 上的每个 $n \geq 2$ ，均有 $\nu(ds_1) \prod_{i=1}^n \kappa_F(s_i, ds_{i+1}) = \nu(ds_{n+1}) \prod_{i=1}^n \kappa_B(s_{i+1}, ds_i)$ 成立 $(\times_{i=2}^n \Sigma_{S \times \Omega}) \times \Sigma_{(S \cup \mathcal{X}) \times \Omega}$ 。□

根据引理 D.3，我们递归地定义操作 $\kappa_F^{\circ n}$ 对 (s, A) $s \in (\{s_o\} \cup S) \times \Omega$ 及 $A \in \Sigma|_{(S \cup \mathcal{X}) \times \Omega}$ 作为

$$\kappa_F^{\circ n}(s, A) = \int_{(S \times \Omega)} \kappa_F^{\circ(n-1)}(s, ds') \kappa_F(s', A),$$

类似地对于 κ_B 。在这些条件下， $\nu(ds) \kappa_F^{\circ n}(s, ds') = \nu(ds') \kappa_B^{\circ n}(s', ds)$ 对于 $\Sigma(\{s_o\} \cup S) \times \Omega \times \Sigma_{(S \cup \mathcal{X}) \times \Omega}$ 。显然， $\kappa_F^{\circ n}(s, A) \geq \kappa^{\circ n}(s, A)$ 对于每个 n, s ，以及 A ，并且定义 D.1 中的可达性条件意味着存在 k 对于每个可测 $E \subseteq S^*$ 使得 $\int_{S_o^*} \nu(ds_o^*) \kappa_F^{\circ k}(s_o^*, E) > 0$ 。我们将证明 $\kappa_B^{\circ n}(s, \cdot)$ 关于 ν 是绝对连续且非退化的。

引理 D.4. 对于每个整数 $n \geq 1$ 和 $s \in S^*$ ， $\kappa_B^{\circ n}(s, \cdot)$ ， ν -非退化且相对于 ν 绝对连续。

证明。我们通过归纳法进行证明。定义 $\kappa_B^{\circ 1}(s, \cdot) := \kappa_B(s, \cdot)$ 。根据定义， $\kappa_B(s, \cdot)$ 相对于 ν 既是绝对连续的又是非退化的。假设对于某个 $n \geq 1$ ， $\kappa_B^{\circ n}(s, \cdot)$ 也满足这些性质。那么，对于每个可测的 A ，

$$\kappa_B^{\circ n+1}(s, A) := \int_{S \times \Omega} \kappa_B(s, ds') \kappa_B^{\circ n}(s', A).$$

对于绝对连续性，注意到 $\nu(A) = 0$ 意味着 $\kappa_B^{\circ n}(s, A) = 0$ ，这由我们的归纳假设得出。因此， $\kappa_B^{\circ n+1}(s, A) = 0$ 。也就是说， $\kappa_B^{\circ n+1}(s, \cdot)$ 相对于 ν 是绝对连续的。对于非退化性，令可测的 $E \subseteq S^*$ 满足 $\kappa_B^{\circ n+1}(s, E) > 0$ 。那么，存在一个具有正 $\kappa_B(s, \cdot)$ -测度的集合 D ，使得 $\kappa_B^{\circ n}(s', E) > 0$ 对于每个 $s' \in D$ 成立。根据归纳假设，如果 $\tilde{E} \subseteq E$ 是 E 的一个可测子集，使得 $\nu(\tilde{E}) > 0$ ，则 $\kappa_B^{\circ n}(s', \tilde{E}) > 0$ 对于每个 $s' \in D$ 成立。因此， $\kappa_B^{\circ n+1}(s, \tilde{E}) > 0$ 。归纳地，我们已经证明了 $\kappa_B^{\circ n+1}(s, \cdot)$ 相对于 ν 是非退化的。□

接下来的引理表明，当从状态集 $\mathcal{X} \times \Omega$ 开始时，遵循 κ_B 的马尔可夫链在至多 N 步内会到达状态集 $\{s_o\} \times \Omega$ 。直觉上，如果这不是情况，那么该链会在 N 步后以正概率到达某个集合 $B \in \Sigma|_{S \times \Omega}$ 。由于每个集合 B 都可以从状态集 $\{s_o\} \times \Omega$ 以正概率到达，通过对偶性我们可以构造一个基于 κ_F 的马尔可夫链，从状态集 $\{s_o\} \times \Omega$ 开始，并且以正概率在 N 步后仍然位于状态集 $\mathcal{X} \times \Omega$ 之外。这与上述引理相矛盾。因此， κ_B 也是一个具有时间范围 N 的

Lemma D.5. $\kappa_B^N(x^*, \{s_o\} \times \Omega) = 1$ $x^* \in \{x\} \times \Omega$ 及 $x \in \mathcal{X}$ 。有限吸收核。

证明。假设存在矛盾，即对于某些 x^* ， $\kappa_B^N(x^*, S_o^*) < 1$ 成立。我们将证明存在一个至少 N 大小的轨迹，从 S_o^* 到 $S^* \setminus \mathcal{X}^*$ 的子集，其测度为正。然而，根据引理 D.2，这样的轨迹不可能存在。首先，引理 D.3 确保了 $\kappa_B^{\circ N}(x^*, S_o^*) \leq \kappa_B^N(x^*, S_o^*) < 1$ 。因为 $\kappa_B^{\circ N}(x^*, S_o^*) < 1$ ， $\kappa_B^{\circ N}(x^*, S^* \setminus S_o^*) > 0$ 。根据定义，

$$\kappa_B^{\circ N}(x^*, (S^* \setminus S_o^*)) := \int_{S \times \Omega} \kappa_B(x^*, ds) \kappa_B^{\circ N-1}(s, S^* \setminus S_o^*) = \int_{S \times \Omega} \kappa_B(x^*, ds) \kappa_B^{\circ N-1}(s, S^* \setminus S_o^*) > 0.$$

由于 $s \mapsto \kappa_B^{\circ N-1}(s, S^* \setminus S_o^*)$ 是一个非负且连续的函数，上述方程意味着存在一个具有正 $\kappa_B(x^*, \cdot)$ 测度的开集 D ，使得对于所有 $s \in D$ ， $\kappa_B^{\circ N-1}(s, S^* \setminus S_o^*) > 0$ 成立。根据绝对连续性的逆命题， D 也有 ν 正测度。此外，由于积分域的原因， $D \subseteq S \times \Omega$ 。固定 $s \in D$ 。然后，存在一个可测集 $E \subseteq S$ ，使得 $\kappa_B^{\circ N-1}(s, E) > 0$ 。由连续性，存在一个邻域 $\tilde{D} \subseteq D$ ，对于其中的 s ， $\kappa_B^{\circ N-1}(s, E) > 0$

对于所有 $s \in \tilde{D}$ 。由于可达性，存在一个 k ，使 $\nu(ds_o^*)\kappa_F^{\circ k}(s_o^*, E) > 0$ 。By Lemma D.3, since $E \subseteq (\mathcal{S} \cup \mathcal{X}) \times \Omega$ ，得

$$\int_{S_o^*} \nu(ds_o^*)\kappa_F^{\circ k}(s_o^*, E) = \int_E \nu(ds)\kappa_B^{\circ k}(s, S_o^*) > 0.$$

再次，由于非负性和连续性 $s \mapsto \kappa_B^{\circ k}(s, S_o^*)$ ，存在一个集合 $\tilde{E} \subseteq E$ 对于 $\kappa_B^{\circ k}(s, S_o^*) > 0$ 对所有 $s \in \tilde{E}$ ，和 $\tilde{E}$ 具有正面的 ν -测度。换句话说，一个马尔可夫链遵循 κ_B 转换为 $\tilde{D}$ 至 $\tilde{E}$ 在 $N-1$ 步长，以及从 $\tilde{E}$ 至 S_o^* 在 $k \geq 1$ 步长（回忆一下 $\kappa_B^{\circ N-1}(s, \tilde{E}) > 0$ 对于所有 $s \in \tilde{D}$ 由于 E 是一个可测子集 E 正向的 ν -测度—通过 ν -非退化性；参见引理 D.4。由对偶性和引理 D.3，

$$\begin{aligned} 0 &= \int_{S_o^*} \nu(ds_o^*)\kappa_F^{N+k-1}(s_o^*, \tilde{D}) \geq \int_{S_o^*} \nu(ds_o^*)\kappa_F^{\circ N+k-1}(s_o^*, \tilde{D}) \\ &= \int_{\tilde{D}} \nu(ds^*)\kappa_B^{\circ N+k-1}(s^*, S_o^*) \\ &= \int_{\tilde{D}} \nu(ds^*) \int_S \kappa_B^{\circ N-1}(s^*, ds^*)\kappa_B^{\circ k}(s^*, S_o^*) \\ &\geq \int_{\tilde{D}} \nu(ds^*) \int_{\tilde{E}} \kappa_B^{\circ N-1}(s^*, ds^*)\kappa_B^{\circ k}(s^*, S_o^*) > 0, \end{aligned}$$

因为 $\kappa_B^{\circ k}(s, S_o^*)$ 是在 $\tilde{E}$ 上的严格正函数，且 $\tilde{D}$ 和 $\tilde{E}$ 都是相对于各自测度的正集合。初始等式来自引理 D.2，因为 $\tilde{D} \in \mathcal{S}^* \setminus \mathcal{X}^*$ 。这种矛盾确保了对于所有 x^* ， $\kappa_B^N(x^*, S_o^*) = 1$ 成立。 $\square$

Similarly to Lemma D.2, κ_B^{N+k} 对于每个 $k \geq 0$ ， $(x^*, S_o^*) = 1$ 成立。这是下一个引理的内容。

引理 D.6。 令 $S_o^* = \{s_o\} \times \Omega$ 。则对于所有 $\kappa_B^n(x^*, S_o^*) = 1$ 和 $x^* \in \mathcal{X}^*$ ，有 $n \geq N$ 。

证明。我们按照引理 D.2 的方式进行——利用数学归纳法。根据引理 D.5, $\kappa_B^N(x^*, S_o^*) = 1$ 。假设对于某个 $\kappa_B^n(x^*, S_o^*) = 1$ 有 $n \geq N$ 。那么，

$$\kappa_B^{n+1}(x^*, S_o^*) = \int_{S^*} \kappa_B^n(x^*, ds)\kappa_B(s, S_o^*) = \int_{S_o^*} \kappa_B^n(x^*, ds)\kappa_B(s, S_o^*).$$

如 S_o^* 是一个吸收集 $\kappa_B, \kappa_B(s, S_o^*) = 1$ 对于每个 $s \in S_o^*$ ν -几乎处处成立。由于绝对连续性， $\kappa_B(s, S_o^*) = 1$ $\kappa_B(x^*, \cdot)$ 几乎处处对于 $s \in S_o^*$ 因此，

$$\kappa_B^{n+1}(x^*, S_o^*) = \int_{S_o^*} \kappa_B^n(x^*, ds)\kappa_B(s, S_o^*) = \int_{S_o^*} \kappa_B(x^*, ds) = \kappa_B(x^*, S_o^*) = 1.$$

归纳地， $\kappa_B^n(x^*, S_o^*) = 1$ 对于所有 $n \geq N$ 。 $\square$

值得注意的是，定义 D.1 及其后续引理提供了一个具有连续潜在状态的提升指针 DAG 的完整特征。有趣的是，我们在定义 D.1 中的假设与 Lahlou 等人 (2023, 定义 1) 略有不同，例如，我们假设 $\{s_o\}$ 是对于 κ_B 的吸收集，而 Lahlou 等人 (2023) 指出 $\kappa_B(s_o, \cdot)$ 是平凡（零）测度。下面，我们将解释如何学习定义 D.1 中提升空间上的摊销采样器。随后，我们将详细说明我们提出的框架在第 3 节描述的 LINES 环境中的实现。

学习摊销采样器。 在实践中，我们学习核函数 $P_F(s, \cdot)$ 和 $P_B(s, \cdot)$ 分别相对于 $\kappa_F(s, \cdot)$ 和 $\kappa_B(s, \cdot)$ 绝对连续，以及一个测度 ξ 在 S_o^* 上相对于 ν 绝对连续。给定一个目标测度 Π 在 $\mathcal{X}^*$ 上相对于 ν 绝对连续，我们的目标是寻找一组满足条件的 ξ, P_F 和 P_B ，即

$$\xi(ds_o^*)P_F^N(s_o^*, dx) = \Pi(dx)P_B^N(x, ds_o^*).$$

通过这样做，我们验证对于每个可测的 B ，

$$\int_{S_o^*} \xi(ds_o^*)P_F^N(s_o^*, B) = \int_B \Pi(dx)P_B^N(x, S_o^*).$$

由于 $P_B(x, \cdot) \ll \kappa_B(x, \cdot)$ ，一个类似于引理 D.4 的论证表明 $P_B^N(x, \cdot) \ll \kappa_B^N(x, \cdot)$ 。根据引理 D.5， $\kappa_B^N(x, \mathcal{S}_o^*) = 1$ ；因此， $\kappa_B^N(x, (\mathcal{S}_o^*)^c) = 0$ 和 $P_B^N(x, (\mathcal{S}_o^*)^c) = 0$ 。也就是说， $P_B^N(x, (\mathcal{S}_o^*)^c) = 1$ 因为 $P_B^N(x, \cdot)$ is a 概率测度。因此，

$$\xi(ds_o^*)P_F^N(s_o^*, B) = \int_B \Pi(dx)P_B^N(x, \mathcal{S}_o^*) = \Pi(B).$$

从实现的角度来看，我们表示 P_F, P_B, ξ ，以及 Π 与其密度 p_F, p_B, π ，和 ξ 相对于 κ_F, κ_B, ν ，和 ν 。当 π 仅在归一化常数内已知， $\pi(x) = Z\tilde{\pi}(x)$ ，我们也估计 Z 。通过参数化 p_F, P_B, ξ ，和 Z 使用神经网络，学习基于预期轨迹平衡损失的最小化，

$$\mathcal{L}(s_o, s_1, \dots, s_N) = \left(\log \xi(s_o) + \log \prod_{0 \leq i \leq N-1} p_F(s_i, s_{i+1}) - \log Z - \log \tilde{\pi}(s_N) - \log \prod_{0 \leq i \leq N-1} p_B(s_{i+1}, s_i) \right)^2,$$

相对于探索性策略 P_E （相对于 κ_F 绝对连续）通过随机梯度下降。根据引理 D.2， $s_N \in \mathcal{X}^*$ 几乎肯定是因为 $P_E \ll \kappa_F$ 。

总之，我们也提供了一个定义 D.1 的具体实例。示例 D.7（LINES 环境的随机潜在动力系统）。示意地考虑 $\Omega = \mathbb{R}^d, \mathcal{S} = \mathcal{P} \setminus \{p_o\}$ ， $\mathcal{X} = \mathcal{Q}$ ，和 $s_o = p_o$ 在图 2 中，步长为 $M = 1$ 。在这些条件下， $\mathcal{S}$ 是一个配备离散拓扑的拓扑可测空间，而 Ω 是一个配备勒贝格测度的欧几里得空间。同样， Σ 是由这些可测空间的 σ -代数的乘积诱导的 σ -代数，其唯一定义是因为 $\mathcal{S}$ 和 Ω 都是 σ -有限的。自然地，对于 $s^* = (p_i, \omega) \in \mathcal{S}^*$ ， $\kappa_F(s^*, \cdot)$ 支持在 $\{q_i, p_{i+1}\} \times \mathbb{R}^d$ 上，和 $\kappa_B(s^*, \cdot)$ 支持在 $\{p_i\} \times \mathbb{R}^d$ 上。在实践中，我们可以参数化 p_F 在 $s_i^* = (s_i, \omega_i)$ 和 $s_{i+1}^* = (s_{i+1}, \omega_{i+1})$ 作为

$$\log p_F(s_i^*, s_{i+1}^*) = \log p_{F,\omega}((s_{i+1}, \omega_i), \omega_{i+1}) + \log p_{F,s}((s_i, \omega_i), s_{i+1}),$$

其中 $p_{F,\omega}((s_{i+1}, \omega_i), \cdot) = \mathcal{N}(\phi(s_{i+1}, \omega_i), \sigma^2)$ 被参数化为高斯分布和 $p_{F,s}((s_i, \omega_i), s_{i+1}) = \text{分类分布}(\psi(s_i, \omega_i))$ ，其中 ϕ 和 ψ 是神经网络。类似地， $\xi(s_o)$ 可以被参数化为（混合）高斯分布，类似于 Lahlou 等人（2203 年）。在此基础上， $\pi(x, \omega) = Zr(x) \cdot \mathcal{N}(\omega | \mu, \Lambda)$ ，其中 r 是一个未归一化的目标分布。直观地说，这种扩展的高斯分布会平滑目标分布的景观，并可能促进精确采样的学习。尽管如此，我们把对这一效果的全面研究留待未来的工作。

E. 路径依赖模型中的分布式和流式推理

可组合的摊销离散采样器（Garipov 等人，2023）的性质允许实现有效的分治算法，用于流处理和分布式学习（da Silva 等人，2024a）。在本节中，我们将扩展 B 节中的分析，展示现有的非集中化学习摊销马尔可夫采样器的技术可以无缝适应我们的路径依赖设置。为此目标，我们回顾这些方法的核心假设。假设 E.1（可分解的目标分布）。设 $\{R_t\}_{t \geq 1}$ 为函数序列

$$R_t: \mathcal{X} \rightarrow \mathbb{R}_+。我们假设目标分布， $R: \mathcal{X} \rightarrow \mathbb{R}_+$ ，始终可以表示为 $R(x) := \prod_{t=1}^T R_t(x)$ 对于某些 $T \in \mathbb{N}$ 。$$

假设 E.1 简单地说明目标分布可以分解为独立函数的乘积。在贝叶斯推断的背景下， $\mathcal{X}$ 可以被视为参数空间，而 $\{R_t\}_{t \geq 1}$ 则是由独立数据流诱导的一系列子后验分布 $\{\mathcal{D}_t\}_{t \geq 1}$ ，i.e., $R_1(x) := \ell(\mathcal{D}_1|x)p(x)$ 和 $R_t(x) := \ell(\mathcal{D}_t|x)$ 对于 $t > 1$ ，其中 ℓ 是似然函数，而 p 是先验分布。当每个 R_t 的评估成本较高（例如，由于 $\mathcal{D}_t$ 的大小）时，学习整个后验分布 $R(x) := \prod_{t=1}^T R_t(x)$ 的采样器可能不可行。在这种情况下，先前的研究表明，可以高效地并行学习每个 R_t 的小型采样器，并随后以集中方式将它们组合起来。接下来，我们将证明这种方法可以自然地融入我们的路径依赖框架。命题 E.2（分布式摊销采样）。设 $\{R_t\}_{1 \leq t \leq T}$ 是一系列 T 目标分布。同时，设 $(p_F^{(t)}, p_B^{(t)}, R_t)_{t=1}^T$ 是一组遵循命题 4.5 的路径依赖摊销采样器（相对于各自的目标）。假设 (p_F, p_B) 满足

$$\left(\frac{p_F(\tau|s_o^*)}{p_B(\tau|x)} \right) \left(\prod_{1 \leq t \leq T} \frac{p_F^{(t)}(\tau'|s_o^*)}{p_B^{(t)}(\tau'|x')} \right) = \left(\prod_{1 \leq t \leq T} \frac{p_F^{(t)}(\tau|s_o^*)}{p_B^{(t)}(\tau|x)} \right) \left(\frac{p_F(\tau'|s_o^*)}{p_B(\tau'|x)} \right) \quad (19)$$

对于每对完整的轨迹 (τ, τ') 结束于 (x, x') 在提升的有向无环图上（参见定义 D.1）。那么， p_F 关于 $\mathcal{X}$ 的边缘分布与 $\prod_{t=1}^T R_t$ 相匹配，即 $\sum_{\tau \sim x} p_F(\tau | s_o^*) \propto \prod_{t=1}^T R_t(x)$ 对于每个 $x \in \mathcal{X}$ 。

命题 E.3 (流式摊销采样)。设 $\{R_t\}_{t \geq 1}$ 为一个无界的目标分布序列。在此基础上，设 $\{(p_F^{(t)}, p_B^{(t)}, R_t)\}_{t \geq 1}$ 为一系列递归遵循 $p_F^{(T)}(\tau | s_o^*)$ 的摊销采样器

$$\left(p_B^{(T)}(\tau | x) \right) \left(R_T(x') \cdot \frac{p_F^{(T-1)}(\tau' | s_o^*)}{p_B^{(T-1)}(\tau' | x')} \right) = \left(R_T(x) \cdot \frac{p_F^{(T-1)}(\tau | s_o^*)}{p_B^{(T-1)}(\tau | x)} \right) \left(\frac{p_F^{(T)}(\tau' | s_o^*)}{p_B^{(T)}(\tau' | x)} \right) \quad (20)$$

对于每个 $T > 1$ 和轨迹对 (τ, τ') 结束于 (x, x') ，并假设 $(p_F^{(1)}, p_B^{(1)})$ 满足命题 4.5 中的条件。那么，每个 $p_F^{(T)}$ 的边 $\mathcal{X}$ 边缘分布 $\prod_{t=1}^T R_t$ 对 $T \geq 1$ (参见命题 E.3)。

命题 E.2 和 E.3 都直接由命题 4.5 得出。特别是，命题 E.3 可以通过简单的归纳论证来验证。从学习的角度来看，命题 E.2 暗示了一种用于从目标分布中采样的分而治之算法 R 满足假设 E.1：我们首先训练每个 $p_F^{(t)}$ 并行地进行 $1 \leq t \leq T$ ，并随后学习一个 p_F 通过最小化方程 (19) 左右两边的期望对数平方差。类似地，命题 E.3 指出，一个迭代算法更新当前模型 $(p_F^{(T-1)}, p_B^{(T-1)})$ 根据方程 (20) 得到的结果是一个无偏的采样器，适用于目标分布的乘积。这样，我们可以避免重复评估 R_t 对于每个 $t < T$ 在流式方式中学习一个摊销采样器。

F. 额外实验及进一步细节

本节提供了我们实验实现的更多细节，以及一组额外的实验，用于确认我们的假设，即路径依赖参数化能够更好地拟合目标分布。

F.1. 实现细节

计算机代码。我们在补充材料中提供了用于复现实验的计算机代码。环境和深度神经网络都是基于高度优化的 JAX 原始操作构建的 (Bradbury 等, 2018)。我们的实验是在配备有 64GB AMD MI210 GPU 的计算机上执行的。

模型、优化器、超参数。本文实验采用了标准超参数 (Viviano 等, 2025)。特别是在第 5 节中，我们的马尔可夫模型通过三层（带泄漏的）修正线性单元网络进行参数化。马尔可夫模型和路径依赖模型的隐藏层大小被选择为确保生成的神经网络在参数数量上具有相似规模。本文使用 AdamW 优化器 (Loshchilov & Hutter, 2019)，学习率为 10^{-3} 对于策略的参数以及在需要时，一个学习率 10^{-1} 对于 $\log Z$ 参数。此外，我们最小化了序列和集合环境中的方差损失，而在其他情况下则最小化 TB 损失 (参见推论 B.1)，以此来估计策略的参数。对于第 3 节中的图结构任务，我们遵循了 Silva 等人 (2025a) 的实验设置。

自参照权重矩阵 (Self Referential Weight Matrix, SRWM) 的定义。我们采用了归一化的 ELU 链接函数 σ ，该函数在方程 (23) 中有描述，并为了降低每步计算成本，使用了一个较小的 ($d = 32$) 维度来表示潜在的动力系统，其输出经过了一个单层感知机。这样做的原因是我们的 SRWM 的成本主要由旋转矩阵所需的 $\mathcal{O}(d^3)$ 矩阵乘法决定。更具体地说，令 $\mathbf{W}_t$ 和 $\mathbf{y}_t = \mathbf{W}_t \psi(s_t)$ 如方程 (9) 所示。为了计算 $p_F(\cdot | s_t, \mathbf{W}_t)$ ，我们引入 $\mathbf{W}_{\text{MLP},1} \in \mathbb{R}^{d_{\text{MLP}} \times d}$ 和 $\mathbf{W}_{\text{MLP},2} \in \mathbb{R}^{d_{\text{MLP}} \times d_{\text{out}}}$ 并评估 $p_F(\cdot | s_t, \mathbf{W}_t)$ 作为 LeakyReLU(

$$\text{Softmax}(\mathbf{W}_{\text{MLP},2} \quad \mathbf{W}_{\text{MLP},1} \mathbf{y}_t) \odot \mathbf{m}(s_t)),$$

其中我们将 LeakyReLU 的 $\alpha = 10^{-2}$ 设置为环境给定的 x, d_{out} ，而 $\mathbf{m}(s_t) \in \{1, -\infty\}^{d_{\text{out}}}$ 是一个划分允许转换的掩码函数，在 s_t 处——如方程 (3) 所示。重要的是，我们通过实验证明减少 d 对学习收敛的影响微乎其微，但显著提高了计算效率。

附录 F.2. 额外的实验

我们在第 5 节的分析基础上，进一步针对 GFlowNets 的标准任务进行了实验。




图 10. 序列环境中不同模型大小的目标 TV 距离。我们展示了基于修改后的 SRWM 架构的路径依赖参数化始终优于其马尔可夫对应参数化（基于三层修正线性单元网络）。在每种情况下，我们通过扩展潜在维度——例如，在方程 (9) 中的 d 来增加参数数量。参见第 5 节。




图 11. (左) 我们的路径依赖参数化改善了标准 16×16 超网格任务的拟合优度。(右) 通过学习一个潜在动力系统，我们也改进了高概率区域的探索，这通过训练期间遇到的 20 个最可能状态的平均 $R(x)$ 来衡量。（我们考虑了表 2 中介绍的 Syn-8 环境）。

偏好学习 (da Silva 等, 2024b)。我们考虑在整数值线性模型参数上近似后验分布的问题，该模型用于偏好学习 (Cole, 1993)。简而言之，每个对象 i 具有一组二进制特征， $\mathbf{x}_i \in \{1, 0\}^d$ ，并且对象 i 被优选于对象 j 的概率由下式建模，其中对于某个正整数 m 。我们 $p(i \succ j | \mathbf{w}) = \sigma(\mathbf{w}^T(\mathbf{x}_i - \mathbf{x}_j))$ $\mathbf{w} \in \mathbb{R}^d$ ， $m, m+1, \dots, m$ 在 $\mathbf{w}$ 上设置均匀先验。如补充材料中的表 3 所示，我们的模型也比其马尔可夫对应模型提供了更好的近似，适用于不同样本量的问题（我们固定了 $d = 8$ 和 $m = 4$ ）。

表 3. 马尔可夫和路径依赖参数化在偏好学习任务中的拟合优度，以目标的 TV 距离表示。

Sample size	Markovian	Path-dependent
50	0.135 ± 0.022	0.097 ± 0.016
100	0.177 ± 0.035	0.128 ± 0.046
150	0.274 ± 0.074	0.236 ± 0.092

GridWorld (Bengio 等, 2021)。我们在图 11a 中展示了一个二维网格环境，其中目标分布定义为点 (x, y) 的

$$R(x, y) = 10^{-3} + 2 \cdot r_1(x) \cdot r_1(y) + 0.5 \cdot r_2(x) \cdot r_2(y),$$

其中 $r_1(x) := [n(x) > 0.6] \cdot [n(x) > 0.8]$, $r_2(x) = [x > 0.5]$ 和 $n(x) = \frac{2x}{H-1} - 1$ 对于一个 H 大小的网格；是逆尔森括号，当评估的表达式为真时其值为 1，否则为 0。此 R 是 GFlowNet 评估中的标准，例如 (Malkin 等, 2023; Pan 等, 2023b)。值得注意的是，我们的路径依赖模型在此场景中也对目标提供了更好的拟合优度——这证实了我们在第 5 节中的观察结果。除此之外，

图 11 还表明我们的方法改进了状态空间探索。

位序列。我们还对位序列生成进行了实验，这是 GFlowNets 的标准基准（例如，Malkin 等人, 2022 年; Tiapkin 等人, 2024 年; Silva 等人, 2025b）。为此，我们考虑了大小为 $S \in \{16, 32, 64\}$ 的序列。我们采用了 Malkin 等人 (2022 年, 第 5.3.1 节) 提出的参考分布，并遵循了 Silva 等人 (2025b) 的实验设置。表 4 的结果表明，我们的方法也为该任务提供了更好的拟合优度。

表 4. 位序列生成任务中目标分布的距离。

Seq. Size	Markovian	Path-dependent
16	0.025 ± 0.001	0.001 ± 0.000
32	0.057 ± 0.001	0.002 ± 0.000
64	0.064 ± 0.005	0.002 ± 0.000




图 12. 懒惰随机游走的结果。路径依赖参数化在 RINGS (左) 和 SINUSOIDAL (右) 目标上比马尔可夫参数化提供了更好的分布逼近，我们在方程 (21) 和 (22) 中描述了这些目标。




图 13. 旋转矩阵在加速学习收敛中起着关键作用。所选择的链接函数 σ (方程 (23)) 和旋转矩阵 R 都有利于训练，但移除 R 会有效阻碍训练。

懒惰随机游走。我们在懒惰随机游走 (LRR) 任务上评估了我们的算法，Dall’Antonia 等人 (2026 年) 也考虑了这一任务。类似于 GridWorld，采样器从 $\mathbf{0} \in \mathbb{R}^d$ 开始，在每一步更新其当前状态 $\mathbf{s}$ 作为 $\mathbf{s} \leftarrow \mathbf{s} + \mathbf{v}$ ，其中 $\mathbf{v} \in \{\mathbf{e}_1, \dots, \mathbf{e}_d, \mathbf{0}\}$ 和 $\mathbf{e}_i$ 是 i 列的 d 维单位矩阵。与 GridWorld 不同的是，生成过程不会在实现对应于 $\mathbf{0}$ 的转换时停止；相反，它会进行确切的 T 步。从基本角度来看，这确保了潜在的随机过程是非周期性的，我们实证发现这样的生成过程比图 11a 中的更不易崩溃。在这种情况下，我们将状态 $\mathbf{s}$ 与当前时间步骤 t , $(\mathbf{s}, t)$ 相结合，并将采样器限制为 $[-M, M]^d$ 。因此，终止集是 $\mathcal{X} = \{(\mathbf{s}, T) : \mathbf{s} \in [-M, M]^d\}$ 。我们用傅里叶的位置编码 (Vaswani 等人, 2023 年) 来参数化 t 。此外，我们考虑了 RINGS 和 SINUSOIDAL 目标分布，如图 12 (a-b) (右) 所示，定义为

$$R_{\text{Rings}}(\mathbf{s}) = 0.6 \cdot \exp\{-10(\|\tilde{\mathbf{s}}\| - 0.2)^2\} + 0.3 \cdot \exp\{-10(\|\tilde{\mathbf{s}}\| - 0.9)^2\}, \quad (21)$$

其中 $\tilde{\mathbf{s}} = M^{-1}\mathbf{s} \in [-1, 1]$ 和 $\|\cdot\|$ 是欧几里得范数，以及

$$R_{\text{Sinusoidal}}(\mathbf{s}) = \cos(\mathbf{s}_2). \quad (22)$$

直观上，两个目标分布要求采样器在相似状态下执行显著不同的动作。在这种情况下，正如我们在图 5 中所展示的，状态别名阻碍了学习收敛。图 12 展示了 LRR 任务的结果，证实了我们的路径依赖参数化具有更高的拟合质量。

Ising 模型。我们进一步评估了在 Ising 模型仿真中的方法，这是一个文献中常用的离散采样的基准 (例如, (张等, 2022; 刘等, 2024))。简单来说，状态空间是 $\{-1, 1\}^d$ ，其中 -1 和 1 表示粒子的自旋，而 (未归一化的) 目标分布是

$2^{\mathbf{x}^T \mathbf{J} \mathbf{x}}$ ，其中 $\mathbf{x} \in \{-1, 1\}^d$ 、 $\mathbf{h} \in \mathbb{R}^d$ 和 $\log R(\mathbf{x}) = \mathbf{x}^T \mathbf{h} + \mathbf{J} \in \mathbb{R}^{d \times d}$ 固定。直观上， $-1/2 \mathbf{x}^T \mathbf{J} \mathbf{x}$ 代表粒子成对相互作用的能量，而 $-\mathbf{x}^T \mathbf{h}$ 衡量来自外部磁场的能量。我们设 $\mathbf{J} = \mathbf{v} \mathbf{v}^T - \text{diag}(\mathbf{v} \mathbf{v}^T)$ 为 25

表 5. Ising 模型仿真的 FCS。

d	Markovian	non-Markovian
36	0.15 ± 0.03	0.06 ± 0.01
64	0.20 ± 0.02	0.08 ± 0.01




图 14. 我们的 SRWM 比门控 RNN 更快地收敛。与 LSTM 和 GRU 不同，基于 SRWM 的策略网络通过旋转矩阵促进了模型隐藏表示的多样性，减少了别名并加速了收敛。

$\mathbf{v} \sim \mathcal{U}(\{\mathbf{v} \in \mathbb{R}^d: \|\mathbf{v}\|_2 = 1\})$ ，表示一个铁磁系统（即，当粒子自旋对齐时，成对相互作用能量最小），以及 $\mathbf{h} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。在表 5 中，我们选择了 $d \in \{36, 64\}$ ，并对马尔可夫和路径依赖采样器的 FCS 进行了三次独立运行的平均。再次观察到，我们的非马尔可夫参数化比其马尔可夫对应物更好地逼近目标分布。

F.3. 消融研究

旋转矩阵与链接函数。我们所学习的潜在动力系统参数化基于一个自参照权重矩阵，主要包含两个部分：旋转矩阵（ R ）和链接函数（ σ ）。如同 (Irie 等人, 2022) 所述，我们设定

$$\sigma(\mathbf{x}) = \frac{\text{ELU}(\mathbf{x}) + 1}{\mathbf{1}^T \text{ELU}(\mathbf{x}) + d} \quad (23)$$

对于 $\mathbf{x} \in \mathbb{R}^d$ 和 $\mathbf{1}$ 作为 d 维全 1 向量。（元素级应用的 ELU 定义为 $x \mapsto x$ 如果 $x \geq 0$ 和 $x \mapsto \exp\{x\} - 1$ 如果 $x < 0$ ）。为了更好地理解这些设计选择对我们路径依赖参数化有效性的影响，我们在图 13 中展示了移除旋转矩阵后 (i) 以及设置恒等链接函数后 (ii) 我们的模型的 TV 距离。我们考虑了 Lazy 随机游走 (RINGS) 和 GridWorld(图 7) 领域，在这些领域中可以有效地计算该度量。值得注意的是，两项实验均证实了旋转矩阵在加速学习收敛方面起着关键作用——而尽管链接函数有益，但其重要性相对较小。这验证了我们的机械直觉，即通过旋转底层权重矩阵的特征向量，旋转矩阵有效地缓解了状态别名问题。

与门控 RNN 的比较。正如提到的，我们将修改后的 SRWM 与传统的门控 RNN 进行了比较，包括 LSTM (Hochreiter & Schmidhuber, 1997) 和 GRU (Cho 等人, 2014)，用于参数化潜在的动力系统，并发现我们的 SRWM 在许多任务中极大地加快了学习收敛速度。我们在图 14 中展示了这一点。其原因是，不同于 LSTM 和 GRU，我们的 SRWM 内置了一个机制——如前所述的旋转矩阵——来缓解状态别名问题。