

通过通用软操作符和鲁棒强化学习实现离散组合式生成

马可·吉拉勒斯蓬^{*1,2}, 埃斯特·德曼^{1,2}, 达尼洛·武切蒂奇^{1,2}, 尼古拉伊·马尔金^{3,4},
Bilun Sun⁵, Tianyu Zhang^{1,2}, Pierre-Luc Bacon^{1,2,4}, Gauthier Gidel^{1,2,4}

1 蒙特利尔大学 2Mila 3 爱丁堡大学 4CIFAR 5 独立研究者

摘要

在科学研究中，一个主要瓶颈在于从指数级庞大的对象集合（如蛋白质或分子）中筛选出具有理想属性的小部分有前景的候选物。虽然这一过程可以依赖于专家知识，但最近的方法利用由代理奖励函数引导的强化学习（RL）来实现这一过滤过程。通过采用多种形式的熵正则化，这些方法旨在学习能够生成多样化的高评分候选物的采样器。在这项工作中，我们做出了两个主要贡献。首先，我们展示了这些方法倾向于在大规模搜索空间中生成过于多样化且次优的候选物。为了解决这个问题，我们引入了一种新颖的统一操作符，它将几种正则化的 RL 操作符整合到一个更针对尖峰采样分布的一般框架中。其次，我们提供了对这一过滤过程的一种新颖且鲁棒的 RL 视角。正则化可以被解释为对代理函数中组合形式的不确定性（即候选物的真实评估与代理函数的评估之间的差异）的鲁棒性。我们的分析导致了一个新颖且易于使用的算法，我们将其命名为轨迹通用温和最大（TGM）：我们展示了它能够在合成任务和现实世界任务中识别出比基线更高的质量和多样性的候选物。代码：<https://github.com/marcojira/tgm>。

1 引言

科学研究的核心任务在于发现具有理想属性的新颖对象，如抗微生物性或结合亲和力。这些对象通常是离散且结构化的，可以通过一系列组合步骤构建，例如蛋白质由氨基酸序列组成，分子由各种较小的片段组成（Angermueller 等，2019；王等，2023）。由于这种组合性，可能的对象数量随着对象大小呈指数增长，变得过大而无法进行穷尽搜索。此外，实验评估潜在对象可能会过于技术化或成本过高。尽管如此，在许多情况下，研究人员可以访问一个代理奖励模型，该模型定量地近似感兴趣属性的满足程度（Davis 等，2018；杜等，2022）。

大量研究工作利用这个代理奖励函数将对象集缩小到一小部分有前景的候选者，以便在实验室中测试（Currin 等，2015；Gubernatis & Lookman，2018；吴等，2021；AI4Science 等，2023）。另一种日益流行且有效的替代方法是将此问题表述为强化学习任务（De Cao & Kipf，2018；Darvari 等，2021；Bou 等，2024）。在我们称之为离散组合过程（DCP）中，对象构造被视为马尔可夫决策过程（MDP），其中终端状态对应于完整的对象，并根据代理奖励模型对该对象的评估给出奖励。然后，学习到的策略可以用作生成模型，抽样出有前景的候选者。

在这些方法中，生成流网络（GFNs）已经显示出相当的成功（Bengio 等，2021；Jain 等，2023；周等，2024；Cipcigan 等，2024）。GFNs 学习了一个推销策略 * 通信地址为 marco.jiralerspong@mila.quebec

在最优情况下，以奖励值指数形式的比例采样对象（公式 2）。已建立了与最大熵强化学习的联系，表明这一目标支撑了生成样本的多样性（Tiapkin 等，2024；Mohammadpour 等，2024a；Deleu 等，2024）。虽然这种精确采样目标在某些应用中有用，但在指数级大的集合中存在问题：高奖励值的一小部分对象被采样的概率会被低奖励值的指数级大集合对象所主导。本文利用 GFNs 与正则化强化学习之间的联系，采用软强化学习算子进行科学研究。通过结合这些方法，我们推导出一种改进的算子，并提供了关于正则化的全新视角。我们的贡献可以总结如下：

我们的贡献：(1) 我们引入了一般温和最大（general mellowmax），这是一种插值算子，相较于之前的算子，它能够更灵活地平衡质量和多样性之间的权衡；(2) 我们推导出该算子的一个轨迹约束，称之为轨迹一般温和最大（Trajectory General Mellowmax, TGM）。TGM 使我们能够提出一种类似于生成对抗网络（GFN）的算法，用于科学研究任务，实证结果显示其能找到比软温和最大、GFN 和其他强化学习基线具有更高奖励的多样化模式；(3) 我们提供了这些基线在决策过程（DCPs）中的鲁棒强化学习解释。具体而言，我们展示了由 TGM 诱导的奖励不确定性集比与熵正则化或 GFN 相关的不确定性集更具可解释性。我们所采用的分析技术为通过可解释等价关系实现更一般的轨迹约束铺平了道路，这种等价关系存在于正则化和奖励鲁棒集之间。

2 相关工作

GFNs 旨在按奖励比例进行采样的目标历史上是通过马尔可夫链蒙特卡洛（MCMC）方法来实现的（Gilks 等，1995）。这些方法通过随机游走构建链：从一组初始点出发，提出新点，并根据其函数值（此处为代理奖励）接受或拒绝。尽管理论上具有吸引力，但这些方法在高维度下表现不佳，尤其是在发现分离模式方面（Bengio 等，2021）。

另一方面，GFNs 在蛋白质设计（Jain 等，2022 年）、药物发现（Shen 等，2023 年）和材料设计（AI4Science 等，2023 年）方面取得了成功。解决 GFN 策略过度平滑的标准方法是通过温度调节（Zhang 等，2023 年；Kim 等，2023 年；Zhou 等，2024 年）：GFN 目标可以被设定为学习 $p(x) \propto e^{\beta r(x)}$ 其中 β 是一个逆温度参数。温度调节涉及根据 β 条件学习策略，而 β 在整个训练过程中变化。这与我们的方法相辅相成，因为可以在我们的框架之上应用温度调节。Mohammadpour 等（2024b）还提出了一个基于动作数量的动态正则化系数，用于最大熵强化学习。这种改变也可以用来解决 GFNs 中的过度平滑问题，或者通过在我们的公式 7 中变化的 ω_s 来实现。

从强化学习的角度看，许多软强化学习方法符合 Geist 等人（2019）提出的正则化框架。其他形式的正则化及其对应的算子包括 mellowmax 算子（Asadi & Littman，2017），该算子计算 Q 值的 logmeanexp 而非 logsumexp，以及其扩展，soft mellowmax 算子（Gan 等，2021）。Jiralerspong 等人（2024）通过开发一种称为 AFlowNets 的对抗版本 mellowmax 算子，将生成流网络视角与强化学习相结合。这些工作均未将其算子应用于差分约束问题，而我们对其进行了推广，将其与轨迹约束结合，并成功应用于实际的差分约束问题任务。

3 背景与动机

马尔可夫决策过程。马尔可夫决策过程是一个元组 $(\mathcal{S}, \mathcal{A}, \gamma, P, r)$ ，其中 $\mathcal{S}$ 和 $\mathcal{A}$ 分别是有限的状态空间和动作空间， $\gamma \in [0, 1)$ 是折扣因子， $P: \mathcal{S} \times \mathcal{A} \rightarrow \Delta \mathcal{S}$ 是转移核函数， $r: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 是奖励函数。定义 Π 为策略映射集合 $\{ \pi: \mathcal{S} \rightarrow \Delta \mathcal{A} \mid \pi(s) \in \Delta \mathcal{A}, \forall s \in \mathcal{S} \}$ 。目标是找到使价值函数最大化的策略集 $\pi \in \Pi$ ，即

价值函数对 $v_r^\pi(s) := \mathbb{E}^\pi [\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s]$ 的影响通过下标 r 明确表示，具体解释见下文。对于任何策略 $\pi \in \Pi$ ，期望奖励为 $r^\pi(s) := \sum_{a \in \mathcal{A}} \pi_s(a) r(s, a)$ ，期望转移为 $P^\pi(s, s') := \sum_{a \in \mathcal{A}} \pi_s(a) P(s, a, s')$ 。评估贝尔曼算子由 $T_r^\pi v(s) := r^\pi(s) + \gamma \sum_{s'} P^\pi(s, s') v(s')$ 给出。对所有的 $v \in \mathbb{R}^{\mathcal{S}}$ 已知为收缩的，允许 v_r^* 作为不动点。类似地，最优值函数 $v_r^*(s) := \max_{\pi \in \Pi} v_r^\pi(s)$ 是最优贝尔曼算子的不动点 $T_r^* v(s) := \max_{\pi \in \Pi} T_r^\pi v(s)$ 。最优策略可以通过迭代贝尔曼更新推导得出，这构成了强化学习的 2 基础（Puterman，2014）。




图 1: (左) 按奖励比例采样的问题示意图。最优序列 (绿色) 的巨大奖励被更长子序列组合爆炸产生的所有奖励所淹没。(右) 蛋白质序列生成任务中的 DCP。(A) 从空字符串开始, 氨基酸依次添加直至终止。(B) 然后, 通过代理奖励函数 $\Phi(x)$ 评估整个序列, 其值作为终止动作的奖励给出。(C) 在蛋白质生成过程中, 不确定性通过 δ_i 累积。(D) 真实奖励取决于 $\Phi(x)$ 和累积的不确定性。

鲁棒 MDPs。MDP 的真实奖励或转移函数在实践中很少为人所知。它可能从轨迹数据中估计出来, 但 MDP 模型上的小误差可能会改变策略性能 (Mannor 等, 2004)。鲁棒 MDP 设置通过假设 (P, r) 未知, 位于给定的不确定性集合内来解决这一问题。在我们的 DCP 应用设置中, 由于转移完全由执行的动作决定, 我们合理地假设奖励模型 $r \in \mathcal{R}$ 是唯一不确定的元素。然后, 我们的目标是在最坏情况模型下最大化性能, 即:

$$v_{\mathcal{R}}^{\pi}(s) := \min_{r \in \mathcal{R}} v_r^{\pi}(s), \quad \forall s \in \mathcal{S}.$$

为了解决这个极大极小问题, 可以求助于鲁棒贝尔曼算子 $T_{\mathcal{R}}^{\pi}v := \min_{r \in \mathcal{R}} T_r^{\pi}v$ 和 $T_{\mathcal{R}}^*v := \max_{\pi \in \Pi} T_{\mathcal{R}}^{\pi}v$, $\forall v \in \mathbb{R}^{\mathcal{S}}$ 。确实, 两者都是收缩的, 并分别承认鲁棒值 $v_{\mathcal{R}}^{\pi}$ 和最优鲁棒值 $v_{\mathcal{R}}^*$ 作为不动点 (Iyengar, 2005; Wiesemann 等, 2013)。

正则化 MDPs 提供一种强化学习正则化的通用框架, 恢复了诸如软 Q 学习 (Haarnoja 等人, 2017 年) 等著名算法。正则化马尔可夫决策过程是一个马尔可夫决策过程 $(\mathcal{S}, \mathcal{A}, \gamma, P, r)$ 结合一个凸函数族 $\Omega := (\Omega_s)_{s \in \mathcal{S}}$, $\Omega_s : \Delta_{\mathcal{A}} \rightarrow \mathbb{R}$ 。在每个状态 $s \in \mathcal{S}$, Ω_s 定义了一个策略正则化项 $\Omega_s(\pi_s)$, 对于 $\pi_s \in \Delta_{\mathcal{A}}$ 。正则化贝尔曼算子由下式给出:

$$[T^{\pi, \Omega}v](s) := T_r^{\pi}v(s) - \Omega_s(\pi_s), \quad \forall v \in \mathbb{R}^{\mathcal{S}}, s \in \mathcal{S}.$$

及其贪婪等价形式由 $[T^{*, \Omega}v](s) := \max_{\pi_s \in \Delta_{\mathcal{A}}} [T^{\pi, \Omega}v](s)$ 给出 (Geist 等, 2019)。Derman 等 (2021) 已经建立了策略正则化和鲁棒贝尔曼算子之间的等价性, 从而强调了正则化强化学习的形式动机。下面的陈述是对 (Derman 等, 2021, Thm. 3.1) 的直接重新表述。

定理 3.1 (Derman 等, 2021)。假设奖励函数 r 不确定, 并满足 $r_s \in \mathcal{R}_s := r_0(s, \cdot) + \tilde{\mathcal{R}}_s$, 其中对于所有 $\tilde{\mathcal{R}}_s \subseteq [-R, R]^{\mathcal{A}}$, $s \in \mathcal{S}$ 是闭合且凸的。那么, 对于任何策略集合 $\pi \in \Pi$, 鲁棒值函数 $v_{\mathcal{R}}^{\pi}$ 是正则化贝尔曼算子 $T^{\pi, \Omega}$ 在 $\Omega_s(\pi_s) := \max_{r_s \in \tilde{\mathcal{R}}_s} \langle -\pi_s, r_s \rangle$ 下的不动点。换句话说, 成立 $v_{\mathcal{R}}^{\pi}(s) = T_{r_0}^{\pi}v_{\mathcal{R}}^{\pi}(s) - \Omega_s(\pi_s)$, $\forall s \in \mathcal{S}$ 。

离散组合过程 (DCP) 是具有确定性转移的标准马尔可夫决策过程 (MDP) 的特例。它们可以完全由一个元组 $(\mathcal{G}, \Phi)$ 来描述, 其中 $\mathcal{G}$ 是一个有向无环图, 包含一个源状态 s_0 和一组终止状态 $\mathcal{X}$ (参见图 1)。图中的每个节点对应于一组部件, s_0 为空集。一条边 $(s \rightarrow s')$ 表示将部件添加到集合 s 中得到 s' , 或者如果 $s' \in \mathcal{X}$ 则表示终止操作。每个完成的对象 $x \in \mathcal{X}$ 都有一个与之关联的奖励 $\Phi(x)$, 该奖励由代理奖励模型 Φ 给出: $\mathcal{X} \rightarrow \mathbb{R}$ 。

在标准强化学习中, 目标是最大化折现累积奖励。相比之下, 在科学研究中, 我们感兴趣的是找到最有前景的一组 k 候选物, 这些候选物彼此之间具有足够的差异性 (Jain 等, 2022)。实践中, 使用一个不完美但计算效率高的代理分数 Φ 来估计每个候选物的有用性, 因此盲目地最大化有用性可能会有问题。相反, 给定某个度量 d 已完成对象之间的度量, 实践者旨在近似找到一组多样且新颖 (相对于训练集而言) 的候选物 $\{x_1, \dots, x_k\}$ 并具有高分 (Jain 等, 2022)。这一目标可以形式化为最大化平均模式奖励 (为了简化, 我们仅形式化多样性约束):

$$\max_{\{x_1, \dots, x_k\} \subset \mathcal{X}} \frac{1}{k} \sum_{i=1}^k e^{\Phi(x_i)} \quad \text{subject to} \quad d(x_i, x_j) > \delta, \quad \forall i \neq j. \quad (1)$$




图 2: 从 1 百万个均匀随机抽取的样本中获得的指数奖励分布与 TGM 在训练结束时采样的分布相比。

3.1 科学发现中 GFLOWNETS 的局限性

从 GFN 的角度来看，代理奖励函数的指数可以被视为未归一化的概率质量。然后，目标是学习一个按状态策略 π_s ，其顺序应用按照此函数的比例抽样对象。正式地，如果我们用 $\mathcal{T}(x)$ 表示在状态空间 $\mathcal{G}$ 中以终止状态 $x \in \mathcal{X}$ 结束的所有轨迹，并用 $\pi_{\tau(x)}$ 表示在策略 π 下从轨迹 $\tau(x)$ 中选择所有边的概率，则目标是匹配以下分布：

$$p(x) := \sum_{\tau(x) \in \mathcal{T}(x)} \pi_{\tau(x)} \propto e^{\beta \Phi(x)}, \quad \forall x \in \mathcal{X}. \quad (2)$$

其中 β 是逆温度。我们认为这个目标对于解决方程 1 是次优的。

激励示例。等式 2 的主要问题是它生成了一个分布，该分布将较高的概率分配给大量次优奖励对象，而不是少量高奖励对象。为了说明这一点，请考虑一个 DCP（如图 1 所示），其目标是从大小为 d 的词汇表中生成尽可能长的序列 B 。假设采样器处于长度为 s^* 的最佳序列 $n < d$ 上。然后，采样器的策略需要决定是否终止并返回 x^* ，或者添加更多令牌从而损害序列的有用性。在这样做时，它会权衡 $e^{\Phi(x^*)}$ 与所有以 s 开头的序列的奖励。存在 $\Omega(B^{d-n})$ 这样的序列。假设采样器完美匹配 (2)，这些序列的奖励下界为 $r > 0$ 。那么， $\pi(x^* | s) \leq e^{\Phi(x^*)} / r \cdot B^{d-n}$ ，并且在 s 处返回最佳序列的概率随着 $d - n$ 呈指数级下降。这个问题出现在许多应用中，因为几乎所有对象都有不可忽略的奖励（见图 2）。当这些经验分布具有代表性时，GFNs 可能会保守地估计抽样出有前景候选者的概率。

4 替代算子

为解决这一局限性，本文提出从正则化 RL 的角度出发，并修改 GFNs 所使用的算子。为了简化讨论，我们考察 DCP 中的 $\mathcal{G}$ 为树的情况。在这种设置下，GFN 流算子与温度为 $\omega = 1$ 的软 Bellman 算子之间存在直接等价关系。记 $Q_s[a] := v_{s_a} + r(s, a)$ （其中从 s 采取动作 a 到达的状态为 s_a ）和状态下的 Q 值向量为 $\mathbf{Q}_s$ ，软 Bellman 算子表示为：

$$T^{\text{SB}} v_s := \frac{1}{\omega} \text{logsumexp}(\omega \mathbf{Q}_s). \quad (3)$$

递归地应用此算子，在从 $\mathcal{G}$ 的叶节点到根节点的过程中，会导致价值累积。在最优状态下，一个状态的价值是从该状态可以到达的所有对象的奖励的 logsumexp。大量次优对象的价值累积可能会压倒一个高奖励对象。

与其求和，我们可以取 Q 值的 logmeanexp。这样会产生 mellowmax 算子 (Asadi & Littman, 2017)。虽然 mellowmax 算子解决了累积问题，但它容易产生相反的问题，即稀释。由于这种平均，树深处的一个对象的高奖励会在接近根节点时被较低奖励的对象稀释（因为我们会在每个状态除以子节点的数量）。

$$T^{\text{MM}} v_s := \frac{1}{\omega} \log \sum_{a \in \text{Ch}(s)} \frac{1}{|\text{Ch}(s)|} e^{\omega Q_s(a)}. \quad (4)$$

幸运的是，我们可以通过按其值的比例加权求和元素来缓解稀释问题。具体来说，我们可以使用 Q 值的 Softmax 函数（由 α 控制）作为权重（而不是

	GFN	Soft Bellman	MM	SMM	GM (ours)
Accumulation	$\log(k)$	$\frac{\log(k)}{\omega}$	0	0	$\frac{(1-q)\log(k)}{\omega}$
Dilution	0	0	$\frac{\log(k)}{\omega}$	$\frac{\log(k)}{\alpha+\omega}$	$\frac{q\log(k)}{q\alpha+\omega}$
$ \Delta_s^T $	$\log(k)$	$\frac{\log(k)}{\omega}$	$\frac{\log(k)}{\omega}$	$\frac{\log(k)}{\alpha+\omega}$	$\max\left(\frac{(1-q)\log(k)}{\omega}, \frac{q\log(k)}{q\alpha+\omega}\right)$

表 1: 最坏情况下的累积、稀释和 $|\Delta_s^T|$ 对于不同的算子, 当 $\frac{q\alpha+\omega}{\alpha} > 1$. k 是给定状态下的动作数量, ω 是正则化系数, α 是 Softmax 逆温度, q 是 GM 插值因子。对于相同的 (α, ω, k) 值, 广义 mellowmax 通过 $q \in (0, 1)$ 权衡累积和稀释以获得比其他算子更低的最坏情况 $|\Delta_s^T|$ 。证明见附录 C。

等权重的情况下), 从而得到软温和最大值算子 (Gan 等人, 2021 年):

$$T^{\text{SMM}} v_s = \frac{1}{\omega} \log \langle \text{softmax}(\alpha \mathbf{Q}_s), e^{\omega \mathbf{Q}_s} \rangle. \quad (5)$$

累积和稀释都表现为算子应用与最大 Q 值之间的偏差: $\Delta_s^T := T v_s - \max_{a \in \text{Ch}(s)} Q(s, a)$ 。形式上, 我们定义它们如下:

$$\text{Acc}^T(s) := \max(\Delta_s^T, 0) \quad \text{Dil}^T(s) := \max(-\Delta_s^T, 0). \quad (6)$$

分别表示状态值相对于其最大 Q 值的增加或减少。最终, 对于科学发现应用, 理想的算子/相关策略应将概率分配给所有动作, 并且对累积和稀释具有抵抗力。

我们提出了一种新的算子, 它通过超参数 q 在软 Bellman 算子的累积和软温和最大值算子的稀释之间进行插值。当 q 的值在 $(0, 1)$ 范围内时, 会有少量的累积和稀释, 而不是大量的任何一种。因此, 所得算子在两个问题之间进行了权衡, 并且在 $|\Delta_s^T| = \max\{\text{Acc}^T(s), \text{Dil}^T(s)\}$ 上的最坏情况界限更好, 如表 1 所示。

4.1 广义温和最大值

上述提到的算子可以通过正则化 MDP 的角度来观察。一方面, 软 Bellman 算子对应于通过 Shannon 熵进行正则化。另一方面, 给定分布 $d_s \in \Delta_{\mathcal{A}}$, 温和最大值/软温和最大值算子是由 $\text{KL}(\pi_s, d_s)$ 正则化得到的, 其中 d_s 是均匀分布或 $\text{softmax}(\alpha \mathbf{Q}_s)$ 。

我们定义广义温和最大 (General Mellowmax, GM) 正则化子通过在这些正则化子之间进行插值。然后, 我们可以将这些算子作为特殊情况恢复, 并权衡它们各自的影响。我们将广义正则化子记为 $\Omega_q^{\alpha} d_s$, 并将特定情况记为 $d_s = \text{softmax}(\alpha \mathbf{Q}_s)$ 由 Ω_{α}^{α} 。

$$\Omega_{d_s}^q(\pi_s) := \frac{1}{\omega} [q \text{KL}(\pi_s, d_s) + (1-q)(-\text{H}(\pi_s))], \quad \forall s \in \mathcal{S}, \pi_s \in \Delta_{\mathcal{A}}, \omega \in \mathbb{R}_{>0}, q \in [0, 1]. \quad (7)$$

值得注意的是, 与其它正则化器不同, $\Omega_q^{\alpha} d_s$ 依赖于当前状态的 Q 值。因此, 相关的算子不是凸共轭, 并且偏离了 (Geist 等人, 2019) 的框架。尽管如此, 我们仍然可以使用类似的技术推导出相关算子 (见附录 E):

$$\Omega_{\alpha}^{q,*}(\mathbf{Q}_s) = \frac{1}{\omega} \log \langle \text{softmax}(\alpha \mathbf{Q}_s)^q, e^{\omega \mathbf{Q}_s} \rangle. \quad (8)$$

利用正则化的解释, q 在最大化策略熵和接近 Q 值的 Softmax 函数之间进行权衡。 α 允许我们在高 Q 值的动作上赋予更多或更少的权重, 而 ω 控制正则化的权重。特别是, 设置 $q = 0$ 使我们能够恢复标准的熵正则化/GFN 算子和策略。另一方面, 通过设置 $q = 1$, 我们恢复了软 mellowmax 算子 (当设置为 $\alpha = 0$ 时, 我们恢复了 mellowmax 算子)。插值算子捕捉到了三个重要的软 RL 算子, 并允许我们通过 q 和 α 平滑地控制积累/稀释之间的张力。

我们还观察到, $\Omega_{d_s}^q$ 等价于策略和倾斜 Softmax 分布之间的 KL 散度, 如下所述。

Proposition 4.1. For all $q \in [0, 1]$, $\Omega_{d_s}^q(\pi_s) = \frac{1}{\omega} \text{KL}(\pi_s, d_s^{(q)}) - \frac{1}{\omega} \log(Z_q(d_s))$, where $Z_q(d_s) := \sum_{a \in \mathcal{A}} d_s(a)^q$ and $d_s^{(q)} = d_s^q / Z_q(d_s)$ 是 q 倾斜的 Softmax 分布。

4.2 轨迹级一般 mellowmax

代替在转换上训练，有可能利用轨迹级别的约束，这些约束将策略/价值函数关联起来，跨越多个步骤，从而恢复使用子轨迹作为数据单元的训练算法。在软 RL 中，这种联系首先由 Nachum 等人 (2017) 通过路径一致性学习 (PCL) 在最大熵 RL 中形式化。自那时以来，路径一致性目标已经为 Tsallis 熵 (Chow 等人, 2018) 以及一般类别的 α -发散 (Brekelmans 等人, 2022) 所推导。

轨迹级别的约束已被证明对 DCP 任务的方法性能至关重要。轨迹平衡 (TB) (Malkin 等人, 2022) 和子轨迹平衡 (Madan 等人, 2023) 在 GFNs 中一直被使用，因为 DCP 任务只有终端奖励。通过将早期状态的策略连接到这个终端奖励，这些约束明显更好地传播信号，从而改善信用分配。

定理 4.1 (轨迹 GM)。对于任意 DCP $(\mathcal{G}, \Phi)$ ，设 (π^*, Q^*) 为 $\Omega_{\alpha}^{q,*}$ 的唯一最优值/策略函数。那么，对于给定的 Q 函数 Q^θ ，以下两个陈述对于所有状态在 DCP 中是等价的

$$\text{softmax}([\alpha q + \omega]Q_s^\theta) = \arg \max_{\pi_s} \langle \pi_s, Q_s^* \rangle - \frac{1}{\omega} \Omega_{\alpha}^q(\pi_s), \quad s \in \mathcal{G}. \quad (9)$$

$$\left. \begin{aligned} v_0^* + \sum_{i=0}^n \frac{1}{\omega} \left(\log \text{softmax}([\alpha q + \omega]Q_{s_i}^\theta)[a_i] - q \log \text{softmax}(\alpha Q_{s_i}^\theta)[a_i] \right) &= r(x), \\ \text{for all trajectories } s_0 \xrightarrow{a_0} \dots \xrightarrow{a_{n-1}} s_n \xrightarrow{a_n} x &\text{ 在 DCP 中。} \end{aligned} \right\} \quad (10)$$

我们推导出一个新颖的、等价的轨迹约束条件用于一般的 mellowmax 算子。特别是，定理 4.1 明确指出满足轨迹约束条件公式 10 的所有轨迹可以得到 Q_θ ，使得 $\text{softmax}([\alpha q + \omega]Q_\theta)$ 成为正则化问题的最优策略。证明见附录 E.2。

轨迹一般 mellowmax (TGM)。我们现在将插值正则化器实例化为一种实用算法，用于 DCP。具体来说，我们做出三个设计决策。

(1) 使用带有 $d_s = \text{softmax}(\alpha Q_s)$ 的一般 mellowmax 算子。这样做允许我们在策略内和策略外使用 TGM，并不需要单独的 d_s 。相反，策略寻求最大化奖励同时接近于学习到的 Q 值的 Softmax 函数。(2) 力求满足在附录 E.2 中推导出的新颖轨迹约束条件。这样做恢复了轨迹约束条件对 DCP 的好处。(3) 通过 Richter 等人 (2020); Zhang 等人 (2023) 的 VarGrad 目标训练单个 Q 值网络 Q^θ 。可以证明最小化轨迹约束条件公式 10 等同于最小化以下损失 (其中 σ_t 表示带有逆温度 t) 的 Softmax 函数

$$\mathcal{L}_{\text{TGM}, Q_\theta}(\tau) = \text{Var} \left[\frac{1}{\omega} \left(\sum_{i=1}^n \log \sigma_{q\alpha + \omega}[Q_{s_i}^\theta(a_i)] - q \log \sigma_\alpha[Q_{s_i}^\theta(a_i)] \right) - \beta r(x) \right].$$

从 Q^θ ，最优策略很容易计算得出。结果算法易于实现，高效 (尤其是对于变换器)，并且当 $q = 0, \omega = 1$ 时等同于 GFN 训练。

5 离散组合式生成通过鲁棒强化学习

本节提供了一种关于 DCPs 正则化算子的鲁棒 RL 解释。根据定理 3.1，正则化 MDP 已知等价于具有不确定奖励的鲁棒 MDP。在科学研究的背景下，由于奖励是由代理函数对对象进行的评估，我们可以概念性地认为存在一个隐藏的真实奖励 r^* ，我们希望最大化它¹。过滤过程可以被解释为试图稳健地最大化代理奖励 Φ ，同时考虑到 Φ 和 r^* 之间的差异 δ 。因此，目标是解决：

$$\max_{p \in \Delta_{\mathcal{X}}} \min_{\delta \in \mathcal{R}} \mathbb{E}_{x \sim p} [\Phi(x) + \delta(x)] \quad (11)$$

¹ 该奖励将对应于实验室测量的兴趣有效属性。

其中 $\mathcal{R} \in \mathbb{R}^{|\mathcal{X}|}$ 是不确定性集。那么问题就变成了如何在 $\mathcal{G}$ 中建模这种不确定性。传统上，DCP 中的奖励除了终止动作外处处为 0。然而，假设不确定性仅存在于最后一个动作会忽略任务的组合性质。相反，我们将 $\delta(x)$ 分解为生成过程中每一步发生的扰动之和。更具体地说，给定轨迹 $s_0 \xrightarrow{a_0} \dots \xrightarrow{a_{n-1}} s_n = x$ ，我们有

$$\delta(x) = \sum_{i=0}^n \delta_i[a_i], \quad \text{其中 } \delta_i \in \mathcal{R}_{s_i}. \quad (12)$$

在这个表述中，对 Φ 的不确定性被分配到构建对象的所有动作中，而不是仅存在于最终动作，如图 1 所示。从鲁棒 RL 的角度来看，这种不确定性集结构对应于状态矩形性的常见假设（Wiesemann 等人, 2013; Gadot 等人, 2024）。下一节将使这种不确定性模型更加明确，并分析不同算子的不确定性集。特别是，我们展示了由 GFNs 引起的奖励不确定性集是不充分的，而由软温和最大算子诱导的集合提供了更有意义的不确定性概念。

5.1 FENCHEL-ROBUST 形式的正则化 MDP

本小节使用第 3 节介绍的鲁棒 MDP 符号。以下结果提供了奖励鲁棒 MDP 与正则化 MDP 之间的显式映射，通过等价的价值函数。

定理 5.1 (Fenchel-Robust MDP)。对于任何状态 $s \in \mathcal{S}$ ，设 $\Omega_s : \Delta_{\mathcal{A}} \rightarrow \mathbb{R}$ 是一个适当的凸正则化函数。记其凸共轭为 $\Omega_s^* : \mathbb{R}^{\mathcal{A}} \rightarrow \mathbb{R}$ ，已知它是适当的且凸的。对于任何 $s \in \mathcal{S}$ ，定义奖励集

$$\mathcal{R}_s := r_0(s, \cdot) + \{r_s \in \mathbb{R}^{\mathcal{A}} : \Omega_s^*(-r_s) \leq 0\}.$$

然后，用 $T_{\mathcal{R}_s}^\pi$ 表示 $\mathcal{R}_s$ 的鲁棒算子，并用 T^{π, Ω_s} 表示 Ω_s 的正则化算子：

$$T_{\mathcal{R}_s}^\pi v = T^{\pi, \Omega_s} v, \quad \forall \pi \in \Pi, v \in \mathbb{R}^{\mathcal{S}}.$$

基于该定理，求解方程 11 等价于求解相关的正则化 MDP。定理 5.1 在动态规划的背景下使用凸共轭。类似的结果可以在之前的工作中找到（Eysenbach & Levine, 2021; Husain et al., 2021; Brekelmans et al., 2022; Derman et al., 2021），但正如我们在附录 A.5 中详细说明的那样，它们并不直接适用于我们的设置。

5.2 常见正则化器诱导的鲁棒集

鉴于这一视角，我们现在分析与上述正则化器对应的不确定性集。由于每个都是 GM 的一个特例，我们首先给出 GM 的不确定性集：

$$\mathcal{R}_s := r_0(s, \cdot) + \left\{r_s \in \mathbb{R}^{\mathcal{A}} : \frac{1}{\omega} \sum_{a \in \mathcal{A}} d_s(a) q e^{-\omega r_s(a)} \leq 1\right\}. \quad (13)$$

证明见附录 A.4。与 (Derman et al., 2021) 不同，我们的不确定性集是状态矩形的，这使得它们独立于执行的策略，从而形成一个符合标准鲁棒 MDP 设置的表述（Wiesemann et al., 2013）。

图 3 展示了由三个正则化器诱导的不确定性集：负香农熵、软温和最大值和 GM。为了这个说明，我们考虑一个单步生成过程，其中有两个可能的对象及其关联的代理奖励 $[1, -1]$ 。类似于 (Brekelmans et al., 2022)，我们发现熵正则化的贝尔曼算子（左）未能捕捉到有意义的鲁棒性概念。实际上，不确定性集从未包含代理 $\Phi(x)$ ，尽管更高的 ω 值会使集合更接近代理奖励。这个问题在多步 DCP 中显著加剧：在每一层，不确定性集都进一步远离代理奖励（参见附录 D）。

6 实验

我们的实验旨在回答三个主要问题：

[Q1] 参数 q 如何影响在小型和合成环境中采样的尖锐度？**[Q2]** TGM 是否能在大型生物设计 DCP 任务中找到比标准方法更好的候选者？**[Q3]** TGM 对超参数设置变化的鲁棒性如何？




图 3: (左) 无论 ω 如何, 不确定性集从不包含 $\Phi(x)$ 。因此, 软 Bellman/GFN 算子仅对奖励增加具有鲁棒性。(中) 对于软温和最大算子, 对于不同值的 α 与 $d_s[1] > d_s[2]$, 不确定性集包含 $\Phi(x)$ 。因此, 该算子对一个对象奖励减少具有鲁棒性 (但不是同时两个)。当 $\alpha = 0$ (温和最大) 时, 这种权衡存在对称性, 而增加 α 会使它偏向于只有更高 d_s 的对象允许较小的奖励减少。(右) GM 的不确定性集在两种效应之间进行插值。虽然 $0 < q < 1$ 的不确定性集不包含 $\Phi(x)$, 但它确实包含对应于奖励减少的点。




图 4: (左) GFN 及其 TGM 变体的最优采样分布比较。对于相同的 $\beta = 4$, TGM 显著地将更多的质量集中在奖励分布的上分位数上。(中) TGM 和 GFN 找到的模式数量。TGM 采样的尖锐度增加并未损害其发现不同模式的能力。(右) 每个模式最近样本的距离平均值 (跨模式)。平均而言, 增加 q 使 TGM 能够找到更接近真实模式的样本。

6.1 参数 q 在小型和合成环境中的影响 [Q1]

TF-Bind-8. 最初由 (Trabucco 等人, 22) 提出, **TF-Bind-8** 生成长度为 8 的 DNA 序列, 以寻找那些对人类转录因子具有高结合活性的序列。奖励是从 (Barrera 等人, 2016) 中获得的序列实验结合活性。由于只有 4^8 这样的序列, 搜索空间足够小, 可以计算每个算子的最佳值。我们在图 4 中比较了每个算法的最佳采样密度, 分别针对 $\beta = 4, \alpha = 2$ 和 $\omega = 2$ 。

比特序列。 在 (Malkin 等, 2022) 提出的比特序列任务中, 可能的序列数量显著增加至 2^{120} 种。目标是通过每次添加 n 个比特来生成长度为 k 的比特序列。 M 种模式被半随机选择, 奖励由 $r(x) = 1 - \min_{y \in M} d(x, y)/n$ 给出, 其中 d 是莱文斯坦编辑距离 (Levenshtein 等, 1966)。大致而言, 一个序列的奖励是其到最近模式的负归一化编辑距离。

由于在这种情况下我们可以访问真实模式, 我们根据以下度量评估方法: (1) 找到的模式数量, 如果生成的样本与某个模式的距离小于 $\delta = 28$, 则认为该模式已被找到; (2) 对于每个模式, 我们追踪训练过程中生成的最接近样本的距离。我们报告最佳超参数下所有 M 种模式的平均值 (详见附录 F.3)。虽然最佳 GFN 运行匹配到 $q = 0$, 但非零 q 值的峰值增加带来了明显的益处。最佳表现的 $q > 0$ 运行发现的样本更接近模式, 同时发现了更多的模式。

6.2 生物序列设计 [Q2]

我们现在关注基于实际领域的任务, 这些任务的代理奖励是在实际数据集上训练的。任务基于 Malkin 等 (2022) 的设置, 并使用 Trabucco 等 (2022) 的数据集。对于每个任务, 首先在一个训练集上训练变换器 Φ (用于分类或回归)。变换器的输出在用作代理奖励之前进行归一化处理 (详见附录 F.4)。

5'非翻译区序列 (UTR)。 5' UTR 是 mRNA 的一个区域, 它调节主要编码序列的转录。任务的目标是找到一个长度为 50 的 UTR 序列, 使其最大化

	SAC	PPO	GFN	TGM (ours)					Valid.
				q = 0	q = 0.25	q = 0.5	q = 0.75	q = 1.0	Max
UTR	3.82±.03	3.46±.02	4.12±.00	4.19±.01	4.15±.01	4.25±.00	4.27±.01	4.17±.01	4.26
AMP	5.69±.35	9.79±.02	10.04±.04	10.13±.04	9.93±.03	9.82±.02	10.43±.07	10.29±.05	9.96
GFP	—	0.66±.02	1.90±.03	2.44±.09	2.95±.08	2.66±.12	2.34±.11	2.05±.11	3.63

表 2: TGM 与基线在生物序列设计任务上的平均模式奖励比较。我们报告了 15 个种子的平均值和标准误。在所有领域中, TGM 的各种变体要么匹配要么优于 GFN/PPO/SAC, 特别是在 GFP 这一最大领域中差异尤为明显。Valid. max 指的是用于训练代理函数的数据集中验证集中的最高代理奖励对象。

预测的基因表达水平。我们采用了 Trabucco 等 (2022) 的 280,000 个过滤序列及其相关的核糖体负荷数据集。我们训练了一个变换器作为回归器来预测从序列到核糖体负荷的预测值。词汇表由 4 种核苷酸组成。

抗菌肽 (AMP)。 抗菌肽是一系列氨基酸的短序列, 对微生物 (细菌、病毒等) 具有影响。目标是发现可能具有抗菌特性的新型肽。DBAASP 数据库收集了已知的具有和不具有抗菌活性的肽 (Pirtskhalava 等, 2021)。我们使用来自 Trabucco 等 (2022) 的数据集, 该数据集包含 9222 个非 AMP 序列和 6438 个 AMP 序列, 并训练一个二元分类器 (预测序列是否具有抗菌特性)。我们将分类器的归一化 logit 作为代理奖励。此任务的词汇表由 20 种氨基酸组成, 加上一个表示序列终止的标记。我们对标记进行掩码处理, 使得最小序列长度为 14, 最大序列长度为 60。这是唯一允许可变长度序列的任务 (因为只有这个任务的数据集包含可变长度的序列)。

绿色荧光蛋白 (GFP)。 绿色荧光蛋白是一种长度为 237 的蛋白质, 其荧光在生物学中有多种应用。本任务的目标是发现其他具有高预测荧光的蛋白质。我们采用 Trabucco 等 (22) 处理过的数据集, 该数据集包含原始序列的 56086 种变异及其测量的荧光。我们训练一个回归器来预测测量的荧光, 词汇表由 20 种氨基酸组成。

评估。 每种方法在生成 100000 个样本的过程中定期评估所学网络。通过改变策略的温度系数, 我们可以沿着每个采样的质量/多样性曲线移动。为了近似评估公式 1, 我们生成一系列温度系数范围内的样本集合。然后聚合这些样本, 并试图近似确定策略找到的最佳 k 不同样本 (即, 使得最小距离是 δ)。虽然这个问题是 NP 完全问题 Karp (2009) (可以看作是寻找最大独立集的一个实例), 但在实践中贪心算法似乎效果很好。对于每种方法, 都会执行超参数的扫描。基于最终平均模式奖励的最佳设置将使用 15 个不同的种子运行。详见附录 F.4 以获取更多细节。

结果。 如表 2 所示, 对于所有三项任务, TGM 的所有变体要么大致匹配, 要么超过 GFN、软演员-评论家 (SAC) (Haarnoja 等人, 22018) 和近端策略优化 (PPO) (Schulman 等人, 2017) 的性能。与 (Malkin 等人, 2022; Madan 等人, 2023) 中发现的情况类似, SAC 和 PPO 的表现相对较差。我们假设从终端奖励分配信用的问题对这些方法来说是一个重大问题。在 AMP 中, 生成较短序列是可能的, PPO 能够达到与 TGM/GFN 相似的结果。TGM 与 GFN 之间的差异在最大的环境 GFP 中最为明显, 在那里 TGM 找到的模式具有比图 2 中均值显著更高的奖励。我们希望这一结果展示了 TGM 潜在的可扩展性。有趣的是, q 的效果在这些环境中变化较大, 显示了 GM 算子中插值的好处。表现最佳的变体通过使用 $q \in (0, 1)$ 来平衡稀释和积累。

6.3 超参数鲁棒性 [Q3]

表 2 的最佳运行结果是从学习率的网格搜索中选取的 $\{0.00001, 0.0001, 0.001\}$, $\beta \in \{4, 16, 64, 256\}$ 并从逆温度参数中选取 $\omega \in \{1, 4, 16\}$ 对于 SAC 和 PPO, 本文将熵系数设置为 $1/\omega$ 对于 GFN, 本文将策略的采样温度设置为 $1/\omega$ 为了




图 5: 各种算法在学习率网格搜索中的最终平均模式奖励分布, 包括 β 和 ω 。TGM 在平均性能上优于 AMP 和 GFP, 并在 UTR 中表现出类似的性能。

确保每种方法的运行次数相等, 我们固定 $\alpha = 1$, 仅对 TGM 的 ω 进行变化。变化 α 可能会更有益。我们在图 5 中绘制了此次搜索的性能分布。

TGM 变体似乎相对稳健于这些超参数的变化。平均而言, SAC 运行相对稳定但表现较差。PPO 对超参数设置非常敏感, 最佳运行在 AMP 中表现出强大的性能。TGM 的平均模式奖励高于 GFN, 无论是在 q 还是在环境中。值得注意的是, 在 AMP 中使用 $q = 1$ 的 TGM 几乎没有变化, 几乎所有运行都表现良好, 尽管超参数有显著不同。对于 GFP, 变化显著更大, 每种方法的最佳表现来自异常值。

7 结论

本文受按奖励比例采样的不足启发, 推广了多种软强化学习算子, 并提出了 GM 作为插值正则化器。基于此正则化器, 我们开发了一种新颖的算法 (TGM), 并展示了它能够在各种 DCP 任务上持续超越 GFNs。最后, 我们将奖励鲁棒性强化学习框架应用于 DCP 任务, 在该任务中, 奖励是针对整个轨迹给出的, 从而为这些问题中的正则化提供了一个新的视角。最终, 我们认为 TGM 有可能成为一种更通用和有效的框架, 用于在科学发现应用中寻找有前景的候选者。

8 致谢

作者感谢格伦·贝瑟思、穆克提·穆罕默德和索布汉·莫哈米普尔提供的有益讨论和反馈，以及莫克斯·杰恩在设置生物序列/比特序列实验方面的有用建议。这项研究部分得益于 Mila 提供的计算资源。G. 吉德尔是 CIFAR 人工智能主席，他得到了加拿大自然科学与工程研究理事会（NSERC）的发现基金的支持。M. 吉拉勒斯蓬得到了加拿大第一研究卓越基金下 IVADO 基金的支持，用于开发稳健、推理和负责任的人工智能。E. 德曼得到了三星公司的支持。M. 吉拉勒斯蓬感谢加拿大自然科学与工程研究理事会（NSERC）[资助参考号 600916] 的支持。

参考文献

- Mila AI4Science, Alex Hernandez-Garcia, Alexandre Duval, Alexandra Volokhova, Yoshua Bengio, Divya Sharma, Pierre Luc Carrier, Yasmine Benabed, Michał Koziarski, and Victor Schmidt. Crystal-GFN: sampling crystals with desirable properties and constraints. *arXiv preprint 2310.04925*, 2023.
- Christof Angermueller, David Dohan, David Belanger, Ramya Deshpande, Kevin Murphy, and Lucy Colwell. Model-based reinforcement learning for biological sequence design. In *International Conference on Learning Representations (ICLR)*, 2019.
- Kavosh Asadi and Michael L Littman. An alternative softmax operator for reinforcement learning. In *International Conference on Machine Learning (ICML)*, 2017.
- Luis A Barrera, Anastasia Vedenko, Jesse V Kurland, Julia M Rogers, Stephen S Gisselbrecht, Elizabeth J Rossin, Jaie Woodard, Luca Mariani, Kian Hong Kock, Sachi Inukai, et al. Survey of variation in human transcription factors reveals prevalent DNA binding changes. *Science*, 351 (6280):1450–1454, 2016.
- Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow network based generative models for non-iterative diverse candidate generation. *Neural Information Processing Systems (NeurIPS)*, 2021.
- Dimitri Bertsekas. *Convex optimization theory*, volume 1. Athena Scientific, 2009.
- Albert Bou, Morgan Thomas, Sebastian Dittert, Carles Navarro, Maciej Majewski, Ye Wang, Shivam Patel, Gary Tresadern, Mazen Ahmad, Vincent Moens, et al. ACEGEN: Reinforcement learning of generative chemical agents for drug discovery. *Journal of Chemical Information and Modeling*, 64 (15):5900–5911, 2024.
- James Bradbury, Roy Frostig, Peter Hawkins, Matthew James Johnson, Chris Leary, Dougal Maclaurin, George Necoala, Adam Paszke, Jake VanderPlas, Skye Wanderman-Milne, and Qiao Zhang. JAX: composable transformations of Python+NumPy programs, 2018. URL <http://github.com/google/jax>.
- Rob Brekelmans, Tim Genewein, Jordi Grau-Moya, Grégoire Delétang, Markus Kunesch, Shane Legg, and Pedro Ortega. Your policy regularizer is secretly an adversary. *arXiv preprint 2203.12592*, 2022.
- Yinlam Chow, Ofir Nachum, and Mohammad Ghavamzadeh. Path consistency learning in Tsallis entropy regularized MDPs. In *International Conference on Machine Learning (ICML)*, 2018.
- Petros Christodoulou. Soft actor-critic for discrete action settings. arXiv 2019. *arXiv preprint 1910.07207*, 2019.
- Flaviu Cipcigan, Jonathan Booth, Rodrigo Neumann Barros Ferreira, Carine Ribeiro Dos Santos, and Mathias Steiner. Discovery of novel reticular materials for carbon dioxide capture using GFlowNets. *Digital Discovery*, 3(3):449–455, 2024.

- Andrew Currin, Neil Swainston, Philip J Day, and Douglas B Kell. Synthetic biology for the directed evolution of protein biocatalysts: navigating sequence space intelligently. *Chemical Society Reviews*, 44(5):1172–1239, 2015.
- Victor-Alexandru Darvari, Stephen Hailes, and Mirco Musolesi. Goal-directed graph construction using reinforcement learning. *Proceedings of the Royal Society A*, 477(2254):20210168, 2021.
- Sarah E Davis, Selen Cremaschi, and Mario R Eden. Efficient surrogate model development: impact of sample size and underlying model dimensions. In *Computer aided chemical engineering*, volume 44, pp. 979–984. Elsevier, 2018.
- Nicola De Cao and Thomas Kipf. MolGAN: An implicit generative model for small molecular graphs. *arXiv preprint 1805.11973*, 2018.
- Tristan Deleu, Padideh Nouri, Nikolay Malkin, Doina Precup, and Yoshua Bengio. Discrete probabilistic inference as control in multi-path environments. *Conference on Uncertainty in Artificial Intelligence (UAI)*, 2024.
- Esther Derman, Matthieu Geist, and Shie Mannor. Twice regularized MDPs and the equivalence between robustness and regularization. *Neural Information Processing Systems (NeurIPS)*, 2021.
- Yuanqi Du, Tianfan Fu, Jimeng Sun, and Shengchao Liu. Molgensurvey: A systematic survey in machine learning models for molecule design. *arXiv preprint 2203.14500*, 2022.
- Benjamin Eysenbach and Sergey Levine. Maximum entropy RL (provably) solves some robust RL problems. *arXiv preprint 2103.06257*, 2021.
- Uri Gadot, Esther Derman, Navdeep Kumar, Maxence Mohamed Elfatih, Kfir Levy, and Shie Mannor. Solving non-rectangular reward-robust MDPs via frequency regularization. In *AAAI Conference on Artificial Intelligence*, 2024.
- Yaozhong Gan, Zhe Zhang, and Xiaoyang Tan. Stabilizing q learning via soft mellowmax operator. In *AAAI Conference on Artificial Intelligence*, 2021.
- Matthieu Geist, Bruno Scherrer, and Olivier Pietquin. A theory of regularized markov decision processes. In *International Conference on Machine Learning (ICML)*, 2019.
- Walter R Gilks, Sylvia Richardson, and David Spiegelhalter. *Markov chain Monte Carlo in practice*. CRC press, 1995.
- JE Gubernatis and TJPRM Lookman. Machine learning in materials design and discovery: Examples from the present and suggestions for the future. *Physical Review Materials*, 2(12):120301, 2018.
- Tuomas Haarnoja, Haoran Tang, Pieter Abbeel, and Sergey Levine. Reinforcement learning with deep energy-based policies. In *International Conference on Machine Learning (ICML)*, 2017.
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International Conference on Machine Learning (ICML)*, 2018.
- Shengyi Huang, Rousslan Fernand Julien Dossa, Chang Ye, Jeff Braga, Dipam Chakraborty, Kinal Mehta, and João G.M. Araújo. CleanRL: High-quality single-file implementations of deep reinforcement learning algorithms. *Journal of Machine Learning Research*, 23(274):1–18, 2022. URL <http://jmlr.org/papers/v23/21-1342.html>.
- Hisham Husain, Kamil Ciosek, and Ryota Tomioka. Regularized policies are reward robust. In *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2021.
- Garud N Iyengar. Robust dynamic programming. *Mathematics of Operations Research*, 30(2): 257–280, 2005.
- Moksh Jain, Emmanuel Bengio, Alex Hernandez-Garcia, Jarrid Rector-Brooks, Bonaventure FP Dossou, Chanakya Ajit Ekbote, Jie Fu, Tianyu Zhang, Michael Kilgour, Dinghuai Zhang, et al. Biological sequence design with GFlowNets. In *International Conference on Machine Learning (ICML)*, 2022.

- Moksh Jain, Tristan Deleu, Jason Hartford, Cheng-Hao Liu, Alex Hernandez-Garcia, and Yoshua Bengio. GFlowNets for AI-driven scientific discovery. *Digital Discovery*, 2(3):557–577, 2023.
- Marco Jiralerspong, Bilun Sun, Danilo Vucetic, Tianyu Zhang, Yoshua Bengio, Gauthier Gidel, and Nikolay Malkin. Expected flow networks in stochastic environments and two-player zero-sum games. In *International Conference on Learning Representations (ICLR)*, 2024.
- Richard M Karp. Reducibility among combinatorial problems. In *50 Years of Integer Programming 1958-2008: from the Early Years to the State-of-the-Art*, pp. 219–241. Springer, 2009.
- Minsu Kim, Joohwan Ko, Taeyoung Yun, Dinghuai Zhang, Ling Pan, Woosung Kim, Jinkyoo Park, Emmanuel Bengio, and Yoshua Bengio. Learning to scale logits for temperature-conditional GFlowNets. *arXiv preprint 2310.02823*, 2023.
- Diederik P Kingma. Adam: A method for stochastic optimization. *arXiv preprint 1412.6980*, 2014.
- Vladimir I Levenshtein et al. Binary codes capable of correcting deletions, insertions, and reversals. In *Soviet physics doklady*, volume 10, pp. 707–710. Soviet Union, 1966.
- Kanika Madan, Jarrid Rector-Brooks, Maksym Korablyov, Emmanuel Bengio, Moksh Jain, Andrei Cristian Nica, Tom Bosc, Yoshua Bengio, and Nikolay Malkin. Learning GFlowNets from partial episodes for improved convergence and stability. In *International Conference on Machine Learning (ICML)*, 2023.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in GFlowNets. *Neural Information Processing Systems (NeurIPS)*, 2022.
- Shie Mannor, Duncan Simester, Peng Sun, and John N Tsitsiklis. Bias and variance in value function estimation. In *International Conference on Machine Learning (ICML)*, 2004.
- Sobhan Mohammadpour, Emmanuel Bengio, Emma Frejinger, and Pierre-Luc Bacon. Maximum entropy GFlowNets with soft q-learning. In *International Conference on Artificial Intelligence and Statistics*, 2024a.
- Sobhan Mohammadpour, Emma Frejinger, and Pierre-Luc Bacon. Decoupling regularization from the action space. In *International Conference on Learning Representations (ICLR)*, 2024b.
- Ofir Nachum, Mohammad Norouzi, Kelvin Xu, and Dale Schuurmans. Bridging the gap between value and policy based reinforcement learning. *Neural Information Processing Systems (NeurIPS)*, 2017.
- Malak Pirtskhalava, Anthony A Armstrong, Maia Grigolava, Mindia Chubinidze, Evgenia Alimbarashvili, Boris Vishnepolsky, Andrei Gabrielian, Alex Rosenthal, Darrell E Hurt, and Michael Tartakovsky. DBAASP v3: database of antimicrobial/cytotoxic activity and structure of peptides as a resource for development of new therapeutics. *Nucleic acids research*, 49(D1):D288–D297, 2021.
- Martin L Puterman. *Markov decision processes: Discrete stochastic dynamic programming*. John Wiley & Sons, 2014.
- Lorenz Richter, Ayman Boustati, Nikolas Nüsken, Francisco Ruiz, and Omer Deniz Akyildiz. Vargrad: A low-variance gradient estimator for variational inference. *Neural Information Processing Systems (NeurIPS)*, 2020.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint 1707.06347*, 2017.
- Tony Shen, Mohit Pandey, and Martin Ester. Tacogfn: Target conditioned GFlowNet for drug design. In *NeurIPS 2023 Generative AI and Biology (GenBio) Workshop*, 2023.
- Daniil Tiapkin, Nikita Morozov, Alexey Naumov, and Dmitry P Vetrov. Generative flow networks as entropy-regularized rl. In *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2024.

- Brandon Trabucco, Xinyang Geng, Aviral Kumar, and Sergey Levine. Design-bench: Benchmarks for data-driven offline model-based optimization. In *International Conference on Machine Learning (ICML)*, 2022.
- Hanchen Wang, Tianfan Fu, Yuanqi Du, Wenhao Gao, Kexin Huang, Ziming Liu, Payal Chandak, Shengchao Liu, Peter Van Katwyk, Andreea Deac, et al. Scientific discovery in the age of artificial intelligence. *Nature*, 620(7972):47–60, 2023.
- Michael L. Waskom. seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60):3021, 2021. doi: 10.21105/joss.03021. URL <https://doi.org/10.21105/joss.03021>.
- Wolfram Wiesemann, Daniel Kuhn, and Berç Rustem. Robust Markov decision processes. *Mathematics of Operations Research*, 38(1):153–183, 2013.
- Zachary Wu, Kadina E Johnston, Frances H Arnold, and Kevin K Yang. Protein sequence design with deep generative models. *Current opinion in chemical biology*, 65:18–27, 2021.
- David W Zhang, Corrado Rainone, Markus Peschl, and Roberto Bondesan. Robust scheduling with GFlowNets. *International Conference on Learning Representations (ICLR)*, 2023.
- Mingyang Zhou, Zichao Yan, Elliot Layne, Nikolay Malkin, Dinghuai Zhang, Moksh Jain, Mathieu Blanchette, and Yoshua Bengio. PhyloGFN: Phylogenetic inference with generative flow networks. *International Conference on Learning Representations (ICLR)*, 2024.

附录

A 鲁棒性-正则化对偶性

A.1 凸分析

在证明我们的结果之前，我们简要回顾一下 Bertsekas (2009) 下的凸分析概念。定义 A.1（凸共轭）。设一个函数 $f : \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$ 其定义域为 $\text{dom}(f) \subseteq \mathbb{R}^n$ 。函数 f 的凸共轭定义为

$$f^*(y) := \sup_{x \in \text{dom}(f)} \langle x, y \rangle - f(x).$$

定义 A.2 (下确界卷积)。给定两个函数 $f, g : \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$ ，函数 f 和函数 g 的下确界卷积定义为：
 $[f \square g](x) := \inf_{z \in \mathbb{R}^n} \{f(x - z) + g(z)\}$ 。

性质 A.1 (共轭变换上的运算) 设有两个函数 $f_1, f_2 : \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$ 和一个正实数 $\omega > 0$ 。

(i). ~~Defining $g(x) = \omega f_1(x)$ and $f_2(x) = f_1(x)$, the convex conjugate of g satisfies $g^*(y) = \omega f_1^*(y)$.~~

(iii) 凸函数和的共轭函数是它们各自共轭函数的下确界卷积 $f_1 + f_2$

$f_1^* \square f_2^*$, namely:

$$[f_1 + f_2]^*(y) = [f_1^* \square f_2^*](y), \quad \forall y \in \mathbb{R}^n.$$

A.2 应用到策略发散

对于香农熵和 KL 发散，其凸共轭可以以封闭形式导出，并已知是一个 logsumexp 函数，因此我们省略了证明 Geist 等 (2019); Derman 等 (2021). 命题 A.1（香农共轭）。定义负香农熵 $-H : \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$ 为在单纯形域上的函数 $[-H](x) := \sum_{i=1}^n x_i \log(x_i)$ 。它是一个凸函数，其凸共轭是对数和指数函数： Δ_n

$$\text{LSE}_n(y) := \log \left(\sum_{i=1}^n e^{y_i} \right), \quad \forall y \in \mathbb{R}^n.$$

命题 A.2 (KL 共轭)。设 $d \in \mathbb{R}^n$ 满足 $d > 0$ ，并定义 KL- 发散函数 $\text{KL}_d(x) := \sum_{i=1}^n x_i \log \left(\frac{x_i}{d_i} \right)$ ， $\forall x \in \Delta_n$ 。这是一个凸函数，其凸共轭是加权对数和指数函数：

$$\text{WLSE}_{n,d}(y) := \log \left(\sum_{i=1}^n d_i e^{y_i} \right), \quad \forall y \in \mathbb{R}^n.$$

我们现在感兴趣的是推导 Shannon 熵与 KL 散度的凸组合的 Fenchel 共轭。其显式形式如下。命题 A.3 (Shannon-KL 共轭)。对于任意 $q \in [0, 1]$ ，凸组合 $(1-q)(-H) + q\text{KL}_d$ 满足：

$q\text{KL}_d$

$$[(1-q)(-H) + q\text{KL}_d](x) = \sum_{i=1}^n x_i \log \left(\frac{x_i}{(d_i)^q} \right), \quad \forall x \in \mathbb{R}^n.$$

并且其凸共轭函数为：

$$[(1-q)(-H) + q\text{KL}_d]^*(y) = \log \left(\sum_{i=1}^n (d_i)^q e^{y_i} \right), \quad \forall y \in \mathbb{R}^n.$$

证明。第一个陈述来自基本代数：

$$\begin{aligned}
[(1-q)(-H) + q\text{KL}_d](x) &= (1-q) \sum_{i=1}^n x_i \log(x_i) + q \sum_{i=1}^n x_i \log\left(\frac{x_i}{d_i}\right) \\
&= (1-q+q) \sum_{i=1}^n x_i \log(x_i) - q \sum_{i=1}^n x_i \log(d_i) \\
&= \sum_{i=1}^n x_i \log(x_i) - \sum_{i=1}^n x_i \log((d_i)^q) \\
&= \sum_{i=1}^n x_i \log\left(\frac{x_i}{(d_i)^q}\right) = \text{KL}_{d^q}(x).
\end{aligned}$$

对于第二个陈述，我们简单应用命题 A.2 得到：

$$[(1-q)(-H) + q\text{KL}_d]^*(y) = \text{WLSE}_{n,d^q}(y) = \log\left(\sum_{i=1}^n (d_i)^q e^{y_i}\right).$$

一个更复杂的证明将结合下确界卷积的概念以及两个发散的相应共轭。为了简洁起见，此处省略。□

A.3 定理 5.1 的证明

我们在下面提供了一个稍微一般的证明，其中使用任意 ϵ_s -水平集而不是仅仅 0。定理 A.1 (Fenchel-鲁棒正则化 MDP)。对于任意 $s \in \mathcal{S}$ ，定义奖励集

$$\mathcal{R}_s := r_0(s, \cdot) + \{r_s \in \mathbb{R}^A : f_s^*(-r_s) \leq \epsilon_s\},$$

and the regularization function $\Omega_s(\pi_s) := f_s(\pi_s) + \epsilon_s$, $\forall s \in \mathcal{S}$ 。然后，对于任何策略 $\pi \in T_{\mathcal{R}}^\pi v = T^{\pi, \Omega} v$, $\forall v \in \mathbb{R}^S$, $v_{\mathcal{R}}^\pi = v^{\pi, \Omega}$ 。□, 和

证明。首先，我们建立集合 $\tilde{\mathcal{R}}_s := \{r'_s \in \mathbb{R}^A : f_s^*(r'_s) \leq \epsilon_s\}$ 在任意状态下的支撑函数。根据定义， $s \in \mathcal{S}$ 对于任何策略 $\pi_s \in \Delta_A$ ，我们有

$$\begin{aligned}
\max_{r'_s \in \tilde{\mathcal{R}}_s} \langle \pi_s, r'_s \rangle &= \max_{\{r'_s \in \mathbb{R}^A : f_s^*(r'_s) \leq \epsilon_s\}} \langle \pi_s, r'_s \rangle \\
&= f_s(\pi_s) + \epsilon_s.
\end{aligned}$$

接下来，我们计算与不确定性集 $\mathcal{R} = \times_s \mathcal{R}_s$ 相关的鲁棒贝尔曼算子：

$$\begin{aligned}
T_{\mathcal{R}}^\pi v(s) &= \min_{r_s \in \mathcal{R}_s} r^\pi(s) + \gamma P^\pi v(s) \\
&= \min_{r_s \in r_0(s, \cdot) + \tilde{\mathcal{R}}_s} r^\pi(s) + \gamma P^\pi v(s) \\
&= r_0^\pi(s) + \min_{r'_s \in \tilde{\mathcal{R}}_s} \langle \pi_s, r'_s \rangle + \gamma P^\pi v(s) \\
&= r_0^\pi(s) - \max_{r'_s \in \tilde{\mathcal{R}}_s} \langle \pi_s, -r'_s \rangle + \gamma P^\pi v(s) \\
&= T_{r_0}^\pi v(s) - \max_{r'_s \in \tilde{\mathcal{R}}_s} \langle \pi_s, -r'_s \rangle.
\end{aligned}$$

接下来计算

$$\begin{aligned}
\max_{r'_s \in \tilde{\mathcal{R}}_s} \langle \pi_s, -r'_s \rangle &= \max_{r'_s} \langle \pi_s, -r'_s \rangle \text{ s. t. } f_s^*(-r'_s) \leq \epsilon_s \\
&= \max_{\bar{r}_s} \langle \pi_s, \bar{r}_s \rangle \text{ s. t. } f_s^*(\bar{r}_s) \leq \epsilon_s
\end{aligned}$$

运用上述支撑函数的表达式，我们可以写出：

$$\max_{\bar{r}_s} \langle \pi_s, \bar{r}_s \rangle \text{ s. t. } f_s^*(\bar{r}_s) \leq \epsilon_s = f_s(\pi_s) + \epsilon_s$$

使得 $T_{\mathcal{R}}^\pi v = T^{\pi, \Omega} v$, $\forall v \in \mathbb{R}^S$ 。每个算子的唯一不动点分别是 $v_{\mathcal{R}}^\pi$ 和 $v^{\pi, \Omega}$ ，这导致了结论。□

方程 13 来自结合定理 5.1 与命题 A.3。我们可以通过类似的方法获得 KL 散度和负香农正则化的不确定性集，基于它们在附录 A.1 中描述的对偶关系。这使我们得出以下表格，总结了本文中使用的不同正则化器及其对应的不确定性集。

附录 A.4 定理 4.1 的证明

Proposition A.4. For all $q \in [0, 1]$, $\Omega_s^q(\pi_s) = \frac{1}{\omega_s} \text{KL}(\pi_s, d_s^{(q)}) - \frac{1}{\omega_s} \log(Z_q(d_s))$, where $Z_q(d_s) := \sum_{a \in \mathcal{A}} d_s(a)^q$ and $d_s^{(q)} = d_s^q / Z_q(d_s)$ is the q -tilted softmax distribution.

证明。根据定义，

$$\begin{aligned}
\omega_s \Omega_s^q(\pi_s) &= [q \text{KL}(\pi_s, d_s) + (1 - q)(-\text{H}(\pi_s))] \\
&= q \sum_{a \in \mathcal{A}} \pi_s(a) \log \left(\frac{\pi_s(a)}{d_s(a)} \right) + (1 - q) \sum_{a \in \mathcal{A}} \pi_s(a) \log(\pi_s(a)) \\
&= -q \sum_{a \in \mathcal{A}} \pi_s(a) \log(d_s(a)) + \sum_{a \in \mathcal{A}} \pi_s(a) \log(\pi_s(a)) \\
&= \sum_{a \in \mathcal{A}} \pi_s(a) \log \left(\frac{\pi_s(a)}{d_s(a)^q} \right) \\
&= \sum_{a \in \mathcal{A}} \pi_s(a) \log \left(\frac{\pi_s(a)}{d_s(a)^q / Z_q(d_s)} \right) - \sum_{a \in \mathcal{A}} \pi_s(a) \log(Z_q(d_s)) \\
&= \sum_{a \in \mathcal{A}} \pi_s(a) \log \left(\frac{\pi_s(a)}{d_s(a)^q / Z_q(d_s)} \right) - \log(Z_q(d_s)),
\end{aligned}$$

从而得到所期望的结果。 $\square$

表 3: 策略正则化的总结表。

	Neg. Shannon	KL divergence	GSM	General convex
Regularizer Ω_s	$-\text{H}(\pi_s)$	$\text{KL}(\pi_s, d_s)$	$\frac{1}{\omega_s} (q \text{KL}(\pi_s, d_s) + (1 - q)(-\text{H}(\pi_s)))$	$f_s(\pi_s) + \epsilon_s$
Conjugate Ω_s^*	$\text{LSE}_{\mathcal{A}}(q_s)$	$\text{WLSE}_{\mathcal{A}, d_s}(q_s)$	$\omega_s^{-1} \text{WLSE}_{\mathcal{A}, d_s^q}(\omega_s q_s)$	$f_s^*(q_s) - \epsilon_s$
Reward Uncertainty	$\{r_s : \Omega_s^*(-r_s) \leq 0\}$	$\{r_s : \Omega_s^*(-r_s) \leq 0\}$	$\{r_s : \Omega_s^*(-r_s) \leq 0\}$	$\{r_s : f_s^*(-r_s) \leq \epsilon_s\}$

附录 A.5 与其他正则化强化学习工作的比较

Eysenbach & Levine (2021) 关注 Shannon 熵，而我们涵盖了一大类正则化器。Husain 等 (2021)；Brekemans 等 (2022) 从强化学习的 LP 对偶视角分析鲁棒性。尽管在最优情况下等价，但这种方法可能不适用于任何给定的策略。在 DCP 背景下，占用测度的概念也显得模糊，因为转移完全由代理的决策和有限的时间范围决定。不同地，定理 5.1 建立了

通过贝尔曼评估算子，对于任何策略的鲁棒性-正则化等价性。因此，它提供了一个原则性的身份，即 (Iyengar, 2005) 意义上的鲁棒动态规划与 (Geist 等, 2019) 意义上的正则化 MDP 之间的联系。最后，由于 Derman 等 (2021) 的研究动机不同，他们采取了与我们相反的方法：他们从通用不确定性集推导出正则化器，而我们从通用正则化器推导出不确定性集。这使我们能够澄清由正则化引起的鲁棒性属性。

附录 B 额外结果

B.1 GFN 性能的影响因素 β ON

另一个解决按比例采样问题的潜在方案是 $e^{\Phi(x)}$ 包括修改奖励函数。具体而言，奖励指数超参数 β 可以用来任意增加高回报对象的价值，希望即使面对指数级数量的低回报对象也能占据优势。为了验证这一假设，我们对 GFNs 进行了额外的网格扫描，使用更高的值 β 我们遍历相同的学习率 $\{0.00001, 0.0001, 0.001\}$ 以及采样温度 $\{1, 4, 16\}$ 但同时也超越 $\beta \in \{512, 1024, 2048, 4096, 8192\}$ 我们绘制了每种设置下表现最佳的最终平均模式奖励 β 在图 6 中。

超过 256 会恶化 UTR 和 AMP 的性能，但对 GFP 的性能有明显的提升。然而，对于所有值的 β ，GFN 都无法达到最佳的 TGM 设置。这种差异表明 TGM 正在探索质量更好、多样性更强的尖峰分布。令人惊讶的是，即使在非常高 β 值的情况下（高达 8192），GFN 仍然表现得相当不错。似乎梯度裁剪和 VarGrad 目标足以确保在这些高 β 值下有一定的训练稳定性。这些值会产生同样高的损失，在 GFP 上的损失值可达数百万 $\beta = 8192$ 。




图 6: 不同值的 β 下最佳 GFN 设置的平均模式奖励与最佳 TGM 设置的比较。

B.2 计算复杂度

TGM 是 TB 的一种泛化形式，但在计算复杂度方面几乎相同（本质上只需要在损失计算中添加一个 log-softmax）。特别是对于使用变换器的序列任务，通过作用于轨迹，TGM/TB 比作用于转换的方法快得多。损失计算只需要每个轨迹批次进行一次前向传递，而不是每个转换批次进行一次前向传递。我们在下面包含了一个 L40s GPU 上的训练速度表格。当后者将生成的轨迹分割成小批量时，TGM/TB 大约比 PPO/SAC 快 10 倍。TGM 的实现比 GFN 稍微复杂一些，但比 PPO 简单（详见代码提交详情）。

表 4: L40s 上各种方法在生物序列任务上的墙钟训练速度。

Algorithm	UTR (samples/s) $\uparrow$	AMP (samples/s) $\uparrow$	GFP (samples/s) $\uparrow$
SAC	115	92	5
PPO	191	144	8
TGM/TB	1680	1216	120

C 积累与稀释

我们在表 1 中证明了这些界限。为了方便起见，我们表示 $Q_s^* := \max_{a \in \text{Ch}(s)} Q(s, a)$ ，和 $k := |\text{Ch}(s)|$ $\beta := \frac{q\alpha + \omega}{\alpha}$ 。

软贝尔曼方程：对于软贝尔曼算子， $\Delta_s^{T^{\text{SB}}} \geq 0$ 因为 logsumexp 总是大于或等于最大值。然后，由于 logsumexp 严格

格递增，最坏情况下的累积发生在所有 Q 值相等的情况下，此时 $|\Delta$

$$\Delta_s^{T^{\text{SB}}} = \frac{1}{\omega} \log k e^{\omega Q_s^*} - Q_s^* = \frac{\log k}{\omega}。$$

温和最大值：对于温和最大值算子， $\Delta_s^{T^{\text{MM}}} \leq 0$ 因为 logmeanexp 由最大输入值限制。在最坏情况下，我们有以下界限 $\frac{1}{\omega} \log \sum_{i=1}^k \frac{1}{k} e^{\omega Q_s(a_i)} \leq \frac{1}{\omega} \log \frac{e^{\omega Q_s^*}}{k} =$

$$Q_s^* - \frac{\log(k)}{\omega}。 \text{ Thus, } |\Delta_s^{T^{\text{MM}}}| = -\Delta_s^{T^{\text{MM}}} \leq \frac{\log(k)}{\omega}。$$

C.0.1 GENERAL MELLOWMAX

一般的温和最大值算子 Ω_α^q 可以显示累积或稀释，这取决于 q 的值。为了限定 $|\Delta_s^{T^{\text{GM}}}|$ ，我们分别考虑 $\Delta_s^{T^{\text{GM}}}$ 和 $-\Delta_s^{T^{\text{GM}}}$ 的情况。我们展示了当 $\beta > 1$ 时， $\alpha > 0, \omega > 0, q \in (0, 1]$ 和 $k \in \mathbb{N}$ 的界限。

我们首先注意到通过提取公因子 Q_s^* 并表示 $\delta_i := Q(s, a_i) - Q_s^*$ ，我们可以将 $\Delta_s^{T^{\text{GM}}}$ 重写如下。不失一般性，我们假设第一个 Q 值是最大的，即 $Q_s^* = Q(s, a_1)$ ：

$$\Delta_s^{T^{\text{GM}}} = \frac{1}{\omega} \log(\sigma(\alpha \mathbf{Q}_s))^q, e^{\omega Q_s} - Q_s^* = \frac{1}{\omega} \left[\log\left(1 + \sum_{i=2}^k e^{(q\alpha + \omega)\delta_i}\right) - q \log\left(1 + \sum_{i=2}^k e^{\alpha\delta_i}\right) \right]。 \quad (14)$$

然后我们可以进行变量替换 $y_i = e^{\alpha\delta_i}$ ，它在 $[0, +\infty)$ 上是连续且双射的。特别是，因为 $\delta_i \leq 0$ ，我们只关注 $y_i \in [0, 1]$ 。为了简化我们的分析，我们考虑定义如下 g_β

$$g_\beta(y_2, \dots, y_k) := \log\left(1 + \sum_{i=2}^k y_i^\beta\right) - q \log\left(1 + \sum_{i=2}^k y_i\right), \quad (15)$$

$$\text{含 } \frac{1}{\omega} g_\beta(e^{\alpha\delta_2}, \dots, e^{\alpha\delta_k}) = \Delta_s^{T^{\text{GM}}}。$$

累积界限：我们首先证明 (15) 在 $y_2 = \dots = y_k = 1$ 处达到最大

$y_i \in [0, 1]$ 。为了证明这一点，我们考虑偏导数 $\frac{\partial g_\beta}{\partial y_i} = \beta y_i^{\beta-1} - \frac{q}{1 + \sum_{i=2}^k y_i}$ 。

这个值对于 $y_i < 1$ 来说严格为正（因为 $\beta > 1$ ）。因此，函数在所有 y_i 上 $[0, 1]$ 是递增的，这意味着最大值是在边界处取得的。因此，

$$\Delta_s^{T^{\text{GM}}} \leq \frac{1}{\omega} g_\beta(1, \dots, 1) = \frac{1}{\omega} (\log(k) - q \log(k)) = \frac{(1-q) \log(k)}{\omega}。$$

稀释界限：稀释界限更为复杂。根据上述内容，我们有 $-\Delta_s^{T^{\text{GM}}} = -\frac{1}{\omega}$ ，

$$g_\beta(y_2, \dots, y_k) \leq -\frac{1}{\omega} \min_{\{y_2, \dots, y_k\} \in [0, 1]^k} g_\beta(y_2, \dots, y_k)。$$

命题 C.1. 设 $\alpha > 0, q \in (0, 1], \omega > 0$ 和 $k \in \mathbb{N}$ 满足 $\beta > 1$ 。该函数

$$g_\beta(y_2, \dots, y_k) := \log\left(1 + \sum_{i=2}^k y_i^\beta\right) - q \log\left(1 + \sum_{i=2}^k y_i\right)$$

在区间 $[0, 1]^k$ 上达到唯一的最小值，并且在这个最小值处， $0 < y_2 = \dots = y_k < 1$ 。

证明。计算是基本的

$$\frac{\partial g_\beta}{\partial y_i} - \frac{\partial g_\beta}{\partial y_j} = \beta \left(\frac{y_i^{\beta-1} - y_j^{\beta-1}}{1 + \sum_{l=2}^k y_l^\beta} \right)。$$

Since $\beta - 1 > 0$, for $(y_1, \dots, y_k) \in [0, 1]^k$, $\frac{\partial g_\beta}{\partial y_i} > \frac{\partial g_\beta}{\partial y_j}$ 当且仅当 $y_i > y_j$ 这表明所有的局部极小值 g_β 在 $[0, 1]^n$ 都位于对角线上 $y_2 = \dots = y_n$ 。为了证明最小值点是唯一的，我们现在考虑

$$h_\beta(y) := g_\beta(y, y, \dots, y) = \log(1 + ny^\beta) - q \log(1 + ny),$$

其中 $n := k - 1$ 。通过计算， $h_\beta(0) = 0$ 和 $h_\beta(1) = (1 - q) \log(1 + n) > 0$ 。为了证明最小值点在 $y \in (0, 1)$ 中，我们需要一个 y 的值使得

$$\log(1 + ny^\beta) - q \log(1 + ny) < 0 \iff \frac{1 + ny^\beta}{1 + qny} < 1 \iff ny^\beta < qny.$$

其中第二个不等式来自于伯努利不等式的应用。最后一个不等式

对于 $y = \frac{q^{\frac{1}{\beta-1}}}{2}$ 成立。进一步注意到

$$h'_\beta(y) = \frac{\beta ny^{\beta-1}}{1 + ny^\beta} - q \frac{n}{1 + ny} = \frac{n[n(\beta - q)y^\beta] + \beta y^{\beta-1} - q}{(1 + ny)(1 + ny^\beta)}. \quad (16)$$

特别地， $h'_\beta(y) > 0$ 对 $y \geq 0$ 。因此，由于 $h_\beta(0) = 0$, $h_\beta\left(\frac{q^{\frac{1}{\beta-1}}}{2}\right) < 0$ 和 $h_\beta(y) > 0$ 并且对于 $y \geq 1$ ，由连续性， h_β 在 $[0, +\infty)$ 上的最小值存在，至少在一个点上达到最小，并且所有极小值点都在 $(0, 1)$ 内。为了证明唯一性，我们注意到 (16) 式的分子是关于 y 的严格递增函数，当 $y \geq 0$ 成立时。因此， $h'_\beta(y) = 0$ 最多有一个解。□

根据命题 C.1，我们有

$$-\min_{\{y_2, \dots, y_k\} \in [0, 1]^k} g_\beta(y_2, \dots, y_k) = -\min_{y \in [0, 1]} h_\beta(y) = \max_{y \in [0, 1]} -h_\beta(y).$$

我们的目标是找到 $-h_\beta(y)$ 的一个上界。对于 $c \geq 0, \beta \geq 1$ ，定义

$$g(x, \beta, c) := -h_\beta(x) = q \log(1 + cx) - \log(1 + cx^\beta).$$

命题 C.2. 令 $q \in (0, 1]$, $\beta > 1$ 和 $c > 0$ 。令 $x^*(\beta, c)$ 和 $M(\beta, c)$ 分别为 $g(\cdot, \beta, c)$ （定义见上文）在区间 $x \in [0, 1]$ 上的 $\arg\max$ 和 $\max$ 。于是，我们有

$$M(\beta, c) \leq q \left(1 - \frac{1}{\beta}\right) \log(1 + c).$$

证明。由命题 C.1， $x^*(\beta, c)$ 是良好定义的，并且 $0 < x^*(\beta, c) < 1$ 对于 $\beta > 1$ 并且 $c > 0$ 。 $x^*(\beta, c)$ 当 $\beta = 1$ 或 $c = 0$ 因为 $g(\cdot, 1, \cdot)$ 并且 $g(\cdot, \cdot, 0)$ 是常数。尽管如此， $M(\beta, c)$ 在右侧是连续的，在 $c = 0$ 处其极限为 0，并且在 $\beta = 1$ 处其极限为 $[q - 1] \log(1 + cx)$ 。

我们将 g 的偏导数记作 g_x, g_β, g_c 。约束条件 $g_x(x^*(\beta), \beta, c) = 0$ 简化为

$$\frac{\beta x^*(\beta, c)^{\beta-1}}{1 + cx^*(\beta, c)^\beta} = \frac{q}{1 + cx^*(\beta, c)}. \quad (17)$$

利用这一点，我们可以简化 M 关于 c 的导数：

$$\begin{aligned} \frac{\partial M(\beta, c)}{\partial c} &= g_c(x^*(\beta, c), \beta, c) + g_x(x^*(\beta, c), \beta, c) \frac{\partial x^*(\beta, c)}{\partial c} \\ &= \frac{qx^*(\beta, c)}{1 + cx^*(\beta, c)} - \frac{x^*(\beta, c)^\beta}{1 + cx^*(\beta, c)^\beta} \\ &= \frac{qx^*(\beta, c)}{1 + cx^*(\beta, c)} \left(1 - \frac{1}{\beta}\right) \quad (\text{Using (17)}) \\ &\leq \frac{q}{1 + c} \left(1 - \frac{1}{\beta}\right). \quad (\text{Using that } x^*(\beta, c) < 1) \end{aligned}$$

Integrating this inequality, for $c \geq 0$,

$$M(\beta, c) \leq M(\beta, 0) + \int_0^c \frac{q}{1+t} \left(1 - \frac{1}{\beta}\right) dt = q \left(1 - \frac{1}{\beta}\right) \log(1+c).$$

□

利用命题 C.2, 我们可以将感兴趣的参数代入, 即将 β 替换为 $q\alpha + \omega$ α 及 c 含 $k-1$ to get

$$M(\beta, c) \leq q \left(\frac{q\alpha + \omega - \alpha}{q\alpha + \omega} \right) \log(k) \leq q \left(\frac{\omega}{q\alpha + \omega} \right) \log(k)$$

最后回到 $-\Delta_s^{T^{\text{GM}}}$, 我们得到

$$-\Delta_s^{T^{\text{GM}}} \leq -\frac{1}{\omega} \min_{\{y_2, \dots, y_k\} \in [0,1]^k} g_\beta(y_2, \dots, y_k) = \frac{1}{\omega} \max_{y \in [0,1]} -h_\beta(y) = \frac{M(\beta, k-1)}{\omega} \leq \frac{\log(k)}{q\alpha + \omega}.$$

值得注意的是, 此界限允许我们在最坏情况下恢复软温和最大操作符的稀释界限 $\frac{\log(k)}{\alpha + \omega}$ (其中 $q = 1$)。结合这些界限, 我们可以求解出使得累积和稀释具有相同界

限的 q 值 T^{GM} 。这样做得到的结果是 $q = \frac{\alpha - 2\omega + \sqrt{\alpha^2 + 4\omega^2}}{2\alpha}$ 。

D 多步不确定性集合

虽然图 3 考察了单步不确定性集合的情况，我们现在寻求探索在整个轨迹过程中可以由 δ_i 取到的值以及这对最终不确定性集合的影响。对于熵正则化器，如果 ω_s 对所有 s 都是相同的，那么 $\mathcal{R}_{s_i}$ 在每个状态都相同。然而，对象 $x = s_1 s_2 \dots s_n$ 的最终不确定性集合 $\mathcal{R}$ 由 $\sum_i \mathcal{R}_{s_i}$ 给出（即各个不确定性集合的闵可夫斯基和）。

我们将二进制生成示例扩展到一个包含两个令牌序列生成任务的 DCP（即二叉树）和长度为 d 。然后，利用命题 D.1，在图 7 中，我们展示了随着树深度增加不同操作符下不确定性集合之和的变化。

Proposition D.1. *For a convex regularizer f and associated robust set $\mathcal{R}_f = \{\delta \in \mathbb{R}^{|\mathcal{A}|} : f^*(\delta) \leq 0\}$, we have that:*

$$\sum_{i=1}^k \mathcal{R}_f = \{r \in \mathbb{R}^{|\mathcal{A}|} : kf^*\left(\frac{r}{k}\right) \leq 0\}. \quad (18)$$

证明。我们希望证明，对于给定的 $r \in \mathbb{R}^{|\mathcal{A}|}$ ，存在 $\delta_1, \delta_2 \dots \delta_k$ 使得 $\sum_{i=1}^k \delta_i = r$ 并且 $\delta_i \in \mathcal{R}_f$ 当且仅当 $kf^*\left(\frac{r}{k}\right) \leq 0$ 。

[$\Rightarrow$] 由于 f 是凸的，所以 f^* 也是凸的。因此，利用詹森不等式，我们得到：

$$kf^*\left(\frac{r}{k}\right) = kf^*\left(\frac{\sum_i \delta_i}{k}\right) \leq \sum_i f^*(\delta_i) \leq 0,$$

其中最后一个不等式源自于 $\delta_i \in \mathcal{R}_f \Rightarrow f^*(\delta_i) \leq 0$ 。

[$\Leftarrow$] Taking $\delta_i = \frac{r}{k}$ for all δ_i , we have that $\sum_i \delta_i = r$. Then, $kf^*\left(\frac{r}{k}\right) \leq 0 \Rightarrow \forall i : f^*(\delta_i) = f^*\left(\frac{r}{k}\right) \leq 0$ and thus $\delta_i \in \mathcal{R}_f$. $\square$




图 7：沿轨迹的不确定性集合之和的说明。（左）随着我们增加 d ，最终不确定性集合远离 $(0,0)$ 更远。因此，对于树中较深的对象，该操作符仅对其具有比其代理评估高得多的奖励时才稳健。这种行为为偏好软贝尔曼算子处理较长对象提供了另一种视角。（中）另一方面，SMM 操作符围绕 $(0,0)$ 居中，并且越来越稳健于奖励的减少。（右）GM 操作符的最终不确定性集合接近 $(0,0)$ ，并对一些奖励减少具有鲁棒性。

E 轨迹广义 MellowMax

记号：我们用 $\text{Ch}(s)$ 表示从状态 s 出发的所有可能动作的集合。 $\sigma_\tau(Q_s) := \frac{e^{\tau Q_s}}{\sum_{a' \in \text{Ch}(s)} e^{\tau Q_s[a']}}$ 是逆温度为 τ 的 Softmax 函数。对于一个 DCP 和给定的状态 s ，我们用 s'_a 表示采取动作 a 后到达的状态（由于转移是确定性的，这个状态是唯一的）。我们用 E 表示在 $\mathcal{G}$ 中的边集，每条边代表一个转移 (s, a, s'_a) 。最后，为了方便起见，我们记 $g(Q_s, a) := \frac{1}{\omega} \log \sigma_{q\alpha+\omega}(Q_s)[a] - q \log \sigma_\alpha(Q_s)[a]$ ， $g^*(Q_s) := \frac{1}{\omega} \log \langle \sigma_\alpha(Q_s)^q, e^{\omega Q_s} \rangle$ 。

E.1 最优性证明

命题 E.1. *In a DCP $(\mathcal{G}, r)$, for any state s ,*

$$v_s^* := \max_{\pi_s} \langle \pi_s, Q_s \rangle - \frac{1}{\omega} \Omega_\alpha^q(\pi_s) = \frac{1}{\omega} \log \langle \sigma_\alpha(Q_s)^q, e^{\omega Q_s} \rangle = g^*(Q_s), \quad (19)$$

及

$$\pi_s^* = \sigma_{q\alpha+\omega}(Q_s). \quad (20)$$

是状态逐点正则化问题的唯一最大化值。

证明。与一般情况不同的是， π , (19) 不是凸共轭，因为 Q_s 同时出现在点积和 Ω 中。尽管如此， Ω 仍然是关于 π 的凸函数。因此，类似于 (Nachum 等人, 2217) 的做法，我们考虑拉格朗日函数：

$$L(\pi_s, \lambda) = \langle \pi_s, Q_s \rangle - \frac{1}{\omega} \Omega_\alpha^q(\pi_s) + \lambda(1 - \langle \mathbf{1}, \pi_s \rangle).$$

由于 Ω 是凸的，待优化的整体函数是凹的。鉴于 Slater 条件成立，KKT 条件对于最优性既是充分的也是必要的。由于 DCPs 中不存在循环，我们有 $\nabla_{\pi_s} Q_s = 0$ 。因此，KKT 条件给出了以下方程组：

$$0 = Q_s - \frac{1}{\omega} (q[\log \pi_s - \log \pi_{Q_s} + 1] + (1 - q)[\log \pi_s + 1]) - \lambda \quad (21)$$

$$1 = \langle \pi_s, \mathbf{1} \rangle \quad (22)$$

其中我们表示 $\pi_{Q_s} := \sigma_\alpha(Q_s)$ 。在第一个方程中求解 π_s ，我们得到最优策略 π_s^* 由下式给出： $\pi_s^* = \exp([Q_s - \lambda]\omega + q \log \pi_{Q_s} - 1)$ 这确保了 $\pi_s \geq 0$ 。将上述内容代入 (22)，我们得到：

$$\lambda^* = \frac{1}{\omega} \left(\log \sum_{a \in \text{Ch}(s)} e^{(\alpha q + \omega) Q_s[a]} - q \log \sum_{a \in \text{Ch}(s)} e^{\alpha Q_s[a]} \right) = \frac{1}{\omega} (\log \langle \sigma_\alpha(Q_s)^q, e^{\omega Q_s} \rangle - 1).$$

我们注意到 λ^* 与最大值 (19) 之间的相似性。将 λ^* 重新代入 π_s^* ，我们得到

$$\pi_s^* = \sigma_{q\alpha+\omega}(Q_s). \quad (20)$$

最后，将 π_s^* 代入 $\langle \pi_s, Q_s \rangle - \frac{1}{\omega} \Omega_\alpha^q(\pi_s)$ 并进行一些简单的代数运算，我们得到 (1.9)。由于 KL 发散和负熵都是严格凸的，(20) 是唯一的最大化器。 $\square$

推论 E.1. 对于任何 DCP $(\mathcal{G}, \Phi)$ ，GM 算子具有唯一最优值/策略函数 (v^*, π^*) 。

证明。我们通过状态的逆拓扑排序 $s_0, s_1, \dots, s_n$ 来进行归纳证明 $\mathcal{G}$ 。对于没有子节点的状态，定义其最优值为 0，并且没有策略。然后，假设每个状态 $s_i, i < N$ 具有唯一的最优值/策略。根据拓扑排序的性质，所有 s_N 的子节点都具有唯一的最优值/策略。然后，根据命题 E.1， $(v_{s_N}^*, \pi_{s_N}^*)$ is also 被唯一定义。 $\square$

引理 E.1. 对于任意 Q_s 和 a , 我们有

$$g(Q_s, a) = Q_s[a] - g^*(Q_s). \quad (23)$$

Proof. By simple algebra,

$$\begin{aligned} g(Q_s, a) &= \frac{1}{\omega} (\log \sigma_{\mathbf{q}\alpha+\omega}(Q_s)[a] - \mathbf{q} \log \sigma_\alpha(Q_s)[a]) \\ &= \frac{1}{\omega} ((\mathbf{q}\alpha + \omega)Q_s[a] - \mathbf{q}\alpha Q_s[a]) \\ &\quad - \frac{1}{\omega} \left(\log \sum_{a' \in \text{Ch}(s)} e^{(\mathbf{q}\alpha+\omega)Q_s[a']} - \log \left[\sum_{a' \in \text{Ch}(s)} e^{\alpha Q_s[a']} \right]^\mathbf{q} \right) \\ &= \frac{1}{\omega} (\omega Q_s[a]) - \frac{1}{\omega} \log \left[\sum_{a' \in \text{Ch}(s)} \frac{e^{\mathbf{q}\alpha Q_s[a']} e^{\omega Q_s[a']}}{\left(\sum_{a' \in \text{Ch}(s)} e^{\alpha Q_s[a']} \right)^\mathbf{q}} \right] \\ &= Q_s[a] - \frac{1}{\omega} (\log \langle \sigma_\alpha(Q_s)^\mathbf{q}, e^{\omega Q_s} \rangle) \\ &= Q_s[a] - g^*(Q_s) \end{aligned}$$

□

引理 E.2. 对于 DCP 中的任意状态 s , 下列是等价的:

$$\sigma_{\alpha\mathbf{q}+\omega}(Q_s^\theta) = \arg \max_{\pi_s} \langle \pi_s, Q_s^* \rangle - \frac{1}{\omega} \Omega_{\sigma_\alpha(Q_s^*), s}^\mathbf{q}(\pi_s), \quad (24)$$

$$\forall a \in \text{Ch}(s) : v_{s'_a}^* = v_s^* + g(Q_s^\theta, a) - r(s, a). \quad (25)$$

证明。

[(24) $\Rightarrow$ (25)] Since π_s^* is unique, by (24) and (20), by the properties of the softmax, we have that $\sigma_{\alpha\mathbf{q}+\omega}(Q_s^\theta) = \sigma_{\mathbf{q}\alpha+\omega}(Q_s^*)$ and $\sigma_\alpha(Q_s^\theta) = \sigma_\alpha(Q_s^*)$. Then, for any $a \in \text{Ch}(s)$:

$$\begin{aligned} v_s^* + g(Q_s^\theta, a) &= v_s^* + \frac{1}{\omega} (\log \sigma_{\mathbf{q}\alpha+\omega}(Q_s^\theta)[a] - \mathbf{q} \log \sigma_\alpha(Q_s^\theta)[a]) \\ &= \frac{1}{\omega} (\log \langle \sigma_\alpha(Q_s^*)^\mathbf{q}, e^{\omega Q_s^*} \rangle + \log \sigma_{\mathbf{q}\alpha+\omega}(Q_s^*)[a] - \mathbf{q} \log \sigma_\alpha(Q_s^*)[a]) \quad \text{Using (19).} \\ &= \frac{1}{\omega} \left(\frac{\sum_{a' \in \text{Ch}(s)} e^{(\mathbf{q}\alpha+\omega)Q_s^*[a']}}{\text{对数} \sum_{a' \in \text{Ch}(s)} e^{\alpha Q_s^*[a']}} + \log \sigma_{\mathbf{q}\alpha+\omega}(Q_s^*)[a] - \mathbf{q} \log \sigma_\alpha(Q_s^*)[a] \right) \\ &= \frac{1}{\omega} (\log e^{(\mathbf{q}\alpha+\omega)Q_s^*[a]} - \mathbf{q} \log e^{\alpha Q_s^*[a]}) \\ &= Q_s^*[a] \\ &= v_{s'_a}^* + r(s, a) \quad \text{Using the definition of } Q_s[a]. \end{aligned}$$

[(24) $\Leftarrow$ (25)] 对于任意 $a \in \text{Ch}(s)$, 我们有:

$$\begin{aligned} v_{s'_a}^* &= v_s^* + g(Q_s^\theta, a) - r(s, a) \\ \iff v_{s'_a}^* &= v_s^* + Q_s^\theta[a] - g^*(Q_s^\theta) - r(s, a) \quad \text{Using (23)} \\ \iff v_s^* - g^*(Q_s^\theta) &= Q_s^*[a] - Q_s^\theta[a] \end{aligned}$$

由于上述等式对所有动作成立, 并且 v_s^* 和 $g^*(Q_s^\theta)$ 不依赖于 a , 我们有 $Q_s^*[a] - Q_s^\theta[a]$ 必须对所有动作都相等。因此, $\forall a \in \text{Ch}(s) : Q_s^*[a] - Q_s^\theta[a] = c$ 这表明

$$Q_s^\theta[a] = Q_s^*[a] - c, \quad (26)$$

for some action independent value c . Finally, we have

$$\sigma_{\alpha\mathbf{q}+\omega}(Q_s^\theta) = \sigma_{\alpha\mathbf{q}+\omega}(Q_s^* - c) = \sigma_{\alpha\mathbf{q}+\omega}(Q_s^*),$$

by the properties of the softmax. □

E.2 定理 4.1 的证明

我们注意到，推导等价子轨迹约束是直接明了的。

定理 E.1 (轨迹 GM) 对于任意 DCP $(\mathcal{G}, \Phi)$ ，设 (v^*, π^*) 为 GM 算子的唯一最优值/策略函数。那么，对于给定的 Q 函数 Q^θ ，

$$\sigma_{\alpha q + \omega}(Q_s^\theta) = \arg \max_{\pi_s} \langle \pi_s, Q_s \rangle - \frac{1}{\omega} \Omega_\alpha^q(\pi_s), \quad (9)$$

对所有状态 s 成立当且仅当

$$v_0^* + \sum_{i=0}^n \frac{1}{\omega} \underbrace{(\log \sigma_{\alpha q + \omega}(Q_{s_i}^\theta)[a_i] - q \log \sigma_\alpha(Q_{s_i}^\theta)[a_i])}_{g(Q_{s_i}^\theta, a_i)} - r(s_i, a_i) = 0, \quad (10)$$

对所有完整的轨迹 $s_0 \xrightarrow{a_0} \dots \xrightarrow{a_{n-1}} s_n \xrightarrow{a_n} x$

成立在 DCP 中。

证明。类似于 (Nachum 等人, 2217)，我们的目标是证明最优性蕴含一致性，反之亦然。相关符号的复习可以在附录 E 的开头找到。

最优性蕴含一致性 [(9) $\Rightarrow$ (10)] 根据引理 E.2，对于任何给定轨迹，(25) 对该轨迹中的所有转移都成立。然后，通过递归方式将 (25) 扩展到该轨迹上，(10) 直接成立。

一致性蕴含最优性 [(9) $\Leftarrow$ (10)] 考虑一种逆拓扑排序 $s^1, s^2 \dots s^M$ ，使得对于任意状态 s ，其任意子节点 s^i 的索引 s^j 均满足条件 s^i ，任何子节点 $j < i$

现在，我们希望通过归纳证明对于任何状态 s 和结束于 $s_0 \rightarrow s_1 \dots \rightarrow s_n \rightarrow s$ 的子轨迹 s ，以下内容成立：

$$v_0^* + \sum_{i=0}^n \frac{1}{\omega} (\log \sigma_{\alpha q + \omega}(Q_{s_i}^\theta)[a_i] - q \log \sigma_\alpha(Q_{s_i}^\theta)[a_i]) - r(s_i, a_i) = v_s^*. \quad (27)$$

对于基本情况， s^1, s^1 必须是一个叶节点并且属于 $\mathcal{X}$ 。那么，根据假设 $v_{s^1} = 0$ 和 (27) 由 (11) 成立。现在，假设 (27) 对任何 $s^i, i < N$ 都成立。那么，根据排序的定义，对于所有 $a \in \text{Ch}(s^N)$ ，(27) 对 s_a 成立，其中 $s^N \xrightarrow{a} s_a$ 。

令 $s_0 \rightarrow s_1 \dots \rightarrow s_n \rightarrow s^N$ 是一个结束于 s^N 的轨迹。根据归纳假设，
 $\forall a \in \text{Ch}(s) :$

$$\begin{aligned} v_0^* + \sum_{i=0}^n g(Q_{s_i}^\theta, a_i) - r(s_i, a_i) + g(Q_{s^N}^\theta, a) - r(s^N, a) &= v_{s_a}^* \\ v_0^* + \sum_{i=0}^n g(Q_{s_i}^\theta, a_i) - r(s_i, a_i) - g^*(Q_{s^N}^\theta) &= Q_{s^N}^*[a] - Q_{s^N}^\theta[a] \quad \text{Using (23).} \end{aligned}$$

类似于引理 E.1 的证明，我们有左边独立于 a ，但必须等于 $Q_{s^N}^*[a] - Q_{s^N}^\theta[a]$ 对所有 a 。因此，我们保证

$$Q_{s^N}^\theta[a] = Q_{s^N}^*[a] - c$$

对于某个与动作无关的值 c 和所有 $a \in \text{Ch}(s^N)$ 。然后，直接计算。将两者代入并消去 c ，我们得到

$$v_0^* + \sum_{i=0}^n g(Q_{s_i}^\theta, a_i) - r(s_i, a_i) = g^*(Q_{s^N}^*) = v_{s^N}^*$$

归纳即完成。最后，还需证明对于所有 s ， $\sigma_{\alpha q + \omega}(Q_s^\theta)$ 是最优的。如果 s 没有子节点，则最优性显然成立。如果 s 至少有一个子节点 a ，取一个轨迹

$s_0 \rightarrow s_1 \dots \rightarrow s_n \rightarrow s$ 以 s 结尾。根据 (27)，我们有两者都成立：

$$v_0^* + \sum_{i=0}^n g(Q_{s_i}^\theta, a_i) - r(s_i, a_i) = v_s^*$$

$$\forall a \in \text{Ch}(s) : v_0^* + \sum_{i=0}^n g(Q_{s_i}^\theta, a_i) - r(s_i, a_i) + g(Q_s^\theta, a) - r(s, a) = v_{s_a}^*.$$

从第二个式子减去第一个式子，我们得到， $\forall a \in \text{Ch}(s)$:

$$g(Q_s^\theta, a) - r(s, a) = v_{s_a}^* - v_s^*$$

$$v_s^* + g(Q_s^\theta, a) - r(s, a) = v_{s_a}^*.$$

根据引理 E.2, $\sigma_{\alpha\mathbf{q}+\omega}(Q_s^\theta)$ 在 s 处最优，证毕。

□

附录 F 实验细节

附录 F.1 算法

我们遵循 (Malkin 等人, 22) 中的大部分超参数决策。对于每种方法，我们训练一个具有 3 层、8 个注意力头和嵌入维度为 64 的变换器。我们将随机失活设置为 0.1，并使用因果掩码。每个输出头使用一个具有两个隐藏层（维度为 256）的全连接网络。

我们使用权重衰减率为 10^{-4} ，并使用梯度裁剪阈值为 10 来帮助稳定在较高 β 值下的训练。在生成训练样本时，我们使用与该方法策略和均匀策略（权重为 0.01）混合对应的策略。每种方法均使用 Adam (Kingma, 2014) 进行训练，其参数为 $\epsilon = 10^{-5}$ 。

TGM/GFN: 由于 GFNs 对应于 TGM 的一种特定超参数设置，两种方法的训练细节基本上是相同的。两种方法均在线训练，批大小为 16 个轨迹，并且只有一个输出对数概率的头。我们通过取 logits 的温度 Softmax 来采样轨迹，使用的温度 $\alpha q + \omega$ 来自最优策略 (20)。对于 GFNs， ω 影响采样策略但不影响实际训练目标，因为这确保了网络正在学习实际的 GFN 目标。

SAC: 对于 SAC，我们使用三个网络：两个 Q 网络（以减少过估计偏差）和一个策略网络，实现方式参考 (Christodoulou, 2019; Huang et al., 2022)。我们使用大小为 100 000 的经验回放池，并设置批大小为 1 024 个转换。生成/训练调整至经验回放比率为 1.0。熵系数固定为 $1/\omega$ ，并且我们使用目标网络（针对 Q 网络），每 10 次迭代更新一次。

PPO: 对于 PPO，我们使用两个网络：策略网络和价值网络，实现方式参考 (Huang 等, 2022)。我们采用 (Huang 等, 2022) 中的超参数设置，并使用广义优势估计器 λ ，取值为 0.95 和 $\gamma = 1$ ，以避免折扣。剪辑 epsilon 设为 0.1，价值系数设为 0.5。在线训练过程中，生成 16 条轨迹，所得转换被划分为 4 个小批量进行训练。熵系数设置为 $1/\omega$ 。

F.2 序列

对于每个序列生成任务，我们在词汇表中添加以下 3 个标记：起始标记（BOS），填充标记（PAD），结束标记（EOS）。序列被填充至等于该任务的最大长度，并在前后分别加上起始标记和结束标记。序列的形式如下所示：[起始标记, $x_1, \dots, x_n$, 填充标记, $\dots$, 填充标记, 结束标记]。在生成序列时，序列以起始标记开始，然后不断添加标记，直到选择了一个终止动作，此时会自动添加填充标记/结束标记。终止动作会被屏蔽，直到达到任务的最小长度。

F.3 合成任务

TF-Bind-8. 超参数如论文所述。我们对每种方法使用其各自的最优策略采样 10 000 个序列。图 4 是使用这些样本并采用 seaborn 默认参数计算的核密度估计 (Waskom, 2021)。

比特序列。我们使用 $n = 120$ 和 $k = 8$ 以及 $M = 60$ 模式，并通过动作掩码强制序列长度为 120。模式随机采样并在运行过程中固定，以确保某些运行不会因为难以找到的模式而产生变化。每种方法训练 200 000 个样本。

F.4 生物序列设计

对于每个任务，在代理奖励模型训练完成后，我们在验证集上计算 logits 的均值和标准差。然后，我们使用以下归一化值作为奖励

$$r(x) = \beta \Phi(x) = \beta \frac{\phi(x) - \mu_{\text{val}}}{\sigma_{\text{val}}}, \quad (28)$$

其中 $\phi(x)$ 是由训练模型输出的 logit。为了训练代理奖励模型，我们遵循 (Malkin et al., 2022) 使用的超参数。

UTR: 使用所描述的数据集，我们训练一个具有 4 层、8 个注意力头和嵌入维度为 64 的变换器。80% 的数据用于训练，其余用于验证。我们训练 250 个训练轮次，并采用早停（耐心值为 15）。学习率设置为 10^{-4} ，批大小为 128，权重衰减为 $1e-6$ 。我们将最小和最大长度都设为 50，因为数据集中所有序列的长度均为 50。

AMP: 我们使用与 UTR 相同的超参数来训练模型。由于数据集中的序列长度可变，我们将最小长度设为 14，最大长度设为 60。与其他任务不同，该模型用于二分类任务，我们使用传递给 Sigmoid 函数的 logit 作为 $\phi(x)$ 。

绿色荧光蛋白 (GFP) : GFP 是最大的任务。我们训练一个具有 3 层、8 个注意力头和嵌入维度为 128 的变换器。由于所有序列长度均为 237，我们将最小长度和最大长度均设为 237。

F.4.1 评估

对于平均模式奖励的评估，我们遍历逆温度修正值 $t \in \{0.005, 0.01, 0.02, 0.05, 0.1, 0.2, 0.5, 1, 2, 5\}$ （即如果常规采样策略是 $\pi \propto e^{\tau x}$ ，我们使用 $\pi' \propto e^{\tau t x}$ 进行采样），并为每种情况生成 512 个样本。然后，我们汇总这些样本，并贪婪地找到彼此之间距离至少为 δ 的前 100 个样本。我们使用 Levenshtein 编辑距离作为度量（Levenshtein 等, 11966），并将 $\delta = 0.25 \cdot \frac{\text{minLen} + \text{maxLen}}{2}$ 设为 2（即对于 UTR 为 $\delta = 13$ ，对于 AMP 为 $\delta = 10$ ，对于 GFP 为 $\delta = 60$ ）。该约束可以粗略解释为要求序列至少有 25% 的不同才能被视为不同的序列。在表 2 中，我们报告了在整个训练过程中实现的最大值。

F.5 计算资源

实验在一个混合 GPU 的集群上进行。所有实验均使用请求 1xL40s、24G 内存和 4 个 CPU 的核心数运行。该集群允许同时运行数十个任务。总体而言，实验（包括所有超参数搜索、基线和各种种子）大约使用了：

- **位序列:** 35 个 GPU 小时。
- **UTR:** 48 个 GPU 小时。
- **AMP:** 48 个 GPU 小时。
- **GFP:** 300 个 GPU 小时。

总计约为 ≈ 20 个 GPU 天。整个代码库使用 Jax (Bradbury 等人, 2218 年) 并采用并行化环境，从而实现快速生成。由于我们使用变换器，对 TGM/GFN 的生成轨迹进行训练仅需一次前向/后向传播。这显著加快了训练速度（大约快 4 倍），与基于单个转换的基线 PPO/SAC 相比（尽管可以通过工程优化来提高这些基线的速度）。