

利用生成流网络学习最短路径

Nikita Morozov¹

Ian Maksimov¹

Daniil Tiapkin^{2,3}

Sergey Samsonov¹

¹HSE University ²CMAP, CNRS, École polytechnique ³LMO, Université Paris-Saclay

摘要

本文提出了一种新颖的学习框架，用于在图中寻找最短路径，该框架利用了生成流网络（GFlowNets）。首先，我们研究了 GFlowNets 在非有向无环图环境下的理论性质及其与最短路径的关系。我们证明了，如果总流量最小化，则正向和反向策略仅沿初始状态和终止状态之间的最短路径遍历环境图。基于这一结果，我们展示了任意图中的路径搜索问题可以通过训练具有流量正则化的非有向无环图 GFlowNet 来解决。我们在排列环境中的路径搜索以及解决魔方问题上实验性地展示了我们方法的性能。对于后者，我们的方法在解决方案长度方面与专门为该任务设计的最先进机器学习方法相比具有竞争力，同时在测试时需要较小的搜索预算。

1 引言

在大型离散图中寻找最短路径是人工智能中的一个基本问题，它支撑着规划、路由、机器人学和组合优化等应用 [Hart 等人, 1968 年, Gallo 和 Pallottino, 1988 年, Sutton 等人, 1998 年, Schrijver 等人, 2003 年, Madkour 等人, 2017 年, Karur 等人, 2021 年]。经典方法如 Dijkstra 算法和 A* 在可以探索图并有合适的启发式函数可用时提供了完整且通常是最优的解决方案 [Hart 等人, 1968 年]。然而，在高维空间中设计精确的启发式函数往往具有挑战性，许多实用领域诱导的状态空间如此之大，以至于即使存储有意义的一部分状态空间也变得困难。通信地址：Nikita Morozov <nmorozov@hse.ru>

该图是不可行的。特别是对于那些转换结构形成凯莱图的组合谜题和规划问题而言，可达配置的数量可能随着问题规模的增长而呈阶乘增长 [Cooperman 等人, 1990]。因此，现代研究工作集中在基于学习的方法上，这些方法近似目标距离函数，并在测试时将其与启发式搜索相结合。值得注意的例子包括用于解决魔方的深度强化学习方法 [McAleer 等人, 2018, Agostinelli 等人, 2019] 以及最近关于基于学习估计随机行走距离并使用这些估计来指导束搜索的一般置换谜题的进展 [Chervov 等人, 2025b]。

另一方面，生成流网络（GFlowNets）作为一种概率框架，用于学习按给定奖励函数的比例采样组合对象 [Bengio 等人, 2021]，代表了变分推断和强化学习范式的综合 [Malkin 等人, 2023, Zimmermann 等人, 2023, Tiapkin 等人, 2024, Deleu 等人, 2024]。GFlowNets 定义了有向无环图中过渡的正向和反向策略，并通过各种目标强制它们之间的一致性 [Malkin 等人, 2022, Bengio 等人, 2023, Madan 等人, 2023]。这些模型在离散领域的不同领域取得了成功，包括分子生成 [Kozlarski 等人, 2024, Cretu 等人, 2025]、组合优化 [Zhang 等人, 2023, Kim 等人, 2025]、因果发现 [Manta 等人, 2023, Atanackovic 等人, 2024]、贝叶斯结构学习 [Deleu 等人, 2022, 2023] 以及大语言模型中的贝叶斯推断 [胡等人, 2023]。

对于路径寻找而言，许多感兴趣的环境是循环的：动作可以撤销，轨迹可能会重新访问状态。近期的工作 [Brunswic 等人, 2024, Morozov 等人, 2025] 将 GFlowNets 从无环生成图扩展到非无环环境，并指出，在这种情况下，预期轨迹长度成为控制采样效率和避免病态循环行为的关键量。然而，最小化这一量的结构-

影响尚未在这类工作中得到充分分析。

本文建立了在非无环 GFlowNets 中最小化预期轨迹长度与寻找最短路径之间未曾探索过的理论联系。基于这一联系，我们展示了如何将 GFlowNets 作为概率学习框架用于解决一般的路径查找问题。我们的贡献可以总结如下：

- 我们证明了，在最小化预期轨迹长度的情况下，GFlowNet 策略仅沿初始状态和终端状态之间的最短路径遍历环境图，并将所有非最短路径分配零概率。
- 基于此特征，我们提出了一个从任意无权图中最短路径问题到训练一个最小化其预期轨迹长度的非无环 GFlowNet 的构造性归约。与基于启发式方法学习价值函数来引导搜索的方法不同 [Agostinelli 等, 2019, Chervov 等, 2025b]，我们的方法直接旨在学习一个最优解恢复精确最短路径的策略。
- 我们提出了一种基于正则化的轨迹平衡目标变体的训练算法 [Malkin 等, 2022]，并在合成排列谜题（交换）以及 2x2x2 和 3x3x3 魔方上提供了实验验证。虽然我们的方法旨在通过单一学习策略恢复精确最短路径，但我们还展示了它可以在测试时结合束搜索以改进解决方案长度。我们将我们的方法与魔方路径查找的最先进方法 [Chervov 等, 2025a] 进行了比较，结果表明我们的方法在解决方案长度方面表现出竞争力，同时在使用较小束宽度时具有更好的扩展性。

源代码: github.com/GreatDrake/gfn-pathfinding。

2 背景知识

2.1 非无环 GFlowNets

Brunswic 等 [2024] 和 Morozov 等 [2025] 将 GFlowNets [Bengio 等, 2023] 的理论构建推广到了可能包含循环的环境中。我们遵循 Morozov 等 [2025] 的理论和符号，其内容总结如下。

顺序决策过程由有向图 $\mathcal{G} = (\mathcal{S}, \mathcal{E})$ 描述，其中 $\mathcal{S}$ 是一个有限状态空间，而 $\mathcal{E} \subseteq \mathcal{S} \times \mathcal{S}$ 是一个有限边集（或转换集）。关于结构 $\mathcal{G}$ ，我们做出以下假设：

假设 2.1。 (1) 存在一个特殊的初始状态 s_0 ，它没有入边，并且存在一个特殊的汇状态 s_f ，它没有出边；(2) 对于任何状态 $s \in \mathcal{S}$ ，都存在一条从 s_0 到 s 和从 s 到 s_f 的路径。

令 $\mathcal{T}$ 表示所有从 s_0 到 s_f 的有限长度轨迹 $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_{n_\tau} \rightarrow s_f)$ 的集合，其中我们用 n_τ 表示轨迹 τ 的长度。我们采用惯例 $s_{n_\tau+1} = s_f$ 。我们说轨迹 τ 终止于状态 s ，如果它的最后一次转换是 $s \rightarrow s_f$ 。形式为 $(s \rightarrow s_f)$ 的边被称为终止转换，具有指向 s_f 的出边的状态 s 被称为终端状态。终端状态的集合记为 $\mathcal{X}$ ，在其上定义了感兴趣的概率分布 $\mathcal{R}(x)/\mathcal{Z}$ ，其中 $\mathcal{R}(x) > 0$ 被称为 GFlowNet 奖励，而 $\mathcal{Z} = \sum_{x \in \mathcal{X}} \mathcal{R}(x)$ 是一个未知的归一化常数。

GFlowNets 操作一对策略，其中正向策略 $\mathcal{P}_F(s' | s)$ 是每个状态子节点上的分布，反向策略 $\mathcal{P}_B(s | s')$ 是每个状态父节点上的分布。在训练过程中，GFlowNets 旨在找到一对策略，使得它们诱导的轨迹分布一致：

$$\mathcal{P}(\tau) = \prod_{t=0}^{n_\tau} \mathcal{P}_F(s_{t+1} | s_t) = \prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t | s_{t+1}). \quad (1)$$

主要目标是使这样的 $\mathcal{P}$ 成立，对于任意的 $x \in \mathcal{X}$ ，轨迹 $\tau \sim \mathcal{P}$ 终止于状态 x 的概率与 $\mathcal{R}(x)/\mathcal{Z}$ 相匹配。这一性质称为奖励匹配条件，可以简单地写作 w.r.t $\mathcal{P}_B$

$$\mathcal{P}_B(x | s_f) = \mathcal{R}(x)/\mathcal{Z} \quad \forall x \in \mathcal{X}. \quad (2)$$

如果方程 (1) 和方程 (2) 都得到满足，那么 $\mathcal{P}_F$ 可以用于从奖励分布中采样终端状态（参见 Bengio 等人 [2023] 和 Morozov 等人 [2025] 以获取更多细节）。

Brunswic 等人 [2024] 和 Morozov 等人 [2025] 指出，非循环 GFlowNets 与其标准循环对应物之间的主要区别在于轨迹长度 n_τ 通常是无界的。由于 $\mathbb{E}[n_\tau]$ 精确表示了 GFlowNet 需要进行的正向策略步骤的平均数量以生成一个样本，这也表明了采样的实用效率。因此，自然地将训练一个最小化 $\mathbb{E}[n_\tau]$ 的非循环 GFlowNet 的问题表述出来。

Morozov 等人 [2025] 通过预期访问次数定义状态流

$$\mathcal{F}(s) = \mathcal{Z} \cdot \mathbb{E}_{\tau \sim \mathcal{P}} \left[\sum_{t=0}^{n_\tau+1} \mathbb{I}\{s_t = s\} \right]. \quad (3)$$

然后，预期轨迹长度与归一化总流量相符 $\mathbb{E}[n_\tau] = \frac{1}{\mathcal{Z}} \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathcal{F}(s)$ ，因此学习具有最小值的模型等价于学习 $\mathbb{E}[n_\tau]$

具有最小总流量的模型。Brunswic 等人在 [2024] 中提出了一种简单实用的方法，并在 Morozov 等人的研究 [2025] 中进一步探讨，该方法涉及向所使用的损失函数中添加一个正则化项 $\lambda \mathcal{F}_\theta(s)$ ，其中 λ 是正则化系数。例如，详细平衡 [Bengio 等, 2023] 损失与状态流正则化的定义为

$$\mathcal{L}(s \rightarrow s') = \left(\log \frac{\mathcal{F}_\theta(s) \mathcal{P}_F(s' | s, \theta)}{\mathcal{F}_\theta(s') \mathcal{P}_B(s | s', \theta)} \right)^2 + \lambda \mathcal{F}_\theta(s),$$

其中奖励匹配通过替换 $\mathcal{F}_\theta(s_f)$ 实现 $\mathcal{P}_B(x | s_f, \theta) = \mathcal{R}(x)$ 。

2.2 在凯莱图上的路径寻找

在凯莱图上的路径寻找问题引起了机器学习社区的特别关注 [麦克利尔等, 2018, 阿戈斯蒂内利等, 2019, 高野, 2023, 切沃夫等, 2025b,c]。这个问题最著名的实例是解决魔方。在这里，所有可能的魔方配置都被表示为顶点，而边则对应于它们之间的移动（转动魔方的一面），主要目标是找到通往已解状态的最短路径。许多其他现有的谜题、游戏和难题都可以用凯莱图来描述，其中游戏过程对应于寻找通向预定义目标状态的路径 [穆兰德, 2016]。

现有方法通常遵循类似的想法：训练一个神经网络来评估某个状态距离目标状态有多远，并在其预测的基础上引导一些启发式搜索算法进行推理。麦克利尔等 [2018] 和阿戈斯蒂内利等 [2019] 使用强化学习通过深度近似价值迭代 [Sutton 等, 1998] 来学习价值函数。然后，麦克利尔等 [2018] 将学习到的价值用于蒙特卡洛树搜索 [库洛姆, 2006]，而阿戈斯蒂内利等 [2019] 将其用于 A* 算法的一种变体 [Ebdet 和 Drechsler, 2009]，以搜索通往目标状态的路径。

Chervov 等人最近的工作 [2025b] 通过对目标状态生成非回溯随机游走 [Alon 等人, 2007] 并在图中训练一个神经网络来逼近随机游走到达某个状态所需的平均步数，在魔方和其他置换谜题上获得了最先进的结果。然后，在推理过程中寻找最短路径时，使用神经网络的预测来指导束搜索算法的一个变体。

我们的工作遵循不同的范式，旨在直接训练一个策略，使其能够沿着最短路径移动到预定义的目标状态。

3 学习最短路径 GFLOWNETS

3.1 最小期望值的条件 轨迹长度

在本节中，我们从理论上考察最小化各自预期轨迹长度的非循环 GFlowNets。我们证明了 $\mathbb{E}[n_\tau]$ 被最小化的充要条件是 $\mathcal{P}_F$ 和 $\mathcal{P}_B$ 仅沿 s_0 与终止状态之间的最短路径移动。我们将 $\ell(s')$ 定义为从 s_0 到 s' 的最短路径的长度；根据假设 2.1，这样的路径总是存在的。

为了定义一个概率分布于 $\mathcal{T}$ ，Morozov 等人 [2025] 假设 $\mathcal{P}_B(s | s') > 0$ 对于任何转移 $(s \rightarrow s')$ 。正如我们将展示的，最小化 $\mathbb{E}[n_\tau]$ 需要 $\mathcal{P}_B$ 将零概率分配给不位于最短路径上的转移。因此我们替换假设 $\mathcal{P}_B(s | s') > 0$ 为一个更普遍和自然的假设，要求 $\mathbb{E}[n_\tau] < +\infty$ 。这里 n_τ 是从 s_f 出发的后向随机游走需要采取的步数的平均值，其转移概率由 $\mathcal{P}_B$ 给出，以到达 s_0 。

假设 3.1. 反向策略

$\mathcal{P}_B$ 满足

$$\mathbb{E}[n_\tau] < +\infty.$$

这一假设意味着 $\mathcal{P}_B$ 可以被视为一个吸收马尔可夫链的转移核函数 [Kemeny 和 Snell, 1969]，并且定义了一个有效的概率分布于 $\mathcal{T}$ ，其概率函数为 $\mathcal{P}(\tau) = \prod_{t=0}^{n_\tau-1} \mathcal{P}_B(s_t | s_{t+1})$ 。对于正式推导和详细讨论，我们请读者参阅附录 A。接下来，我们提供两个引理，将 $\mathbb{E}[n_\tau]$ 与最短路径长度联系起来。

引理 3.2. 给定假设 2.1。那么对于任何满足假设 3.1 的反向策略 $\mathcal{P}_B$ ，有

$$\mathbb{E}[n_\tau] \geq \sum_{x \in \mathcal{X}} \mathcal{P}_B(x | s_f) \ell(x). \quad (4)$$

证明。首先，我们应用条件期望的塔性质

$$\begin{aligned} \mathbb{E}[n_\tau] &= \mathbb{E}[\mathbb{E}[n_\tau | s_{n_\tau} = x]] \\ &= \sum_{x \in \mathcal{X}} \mathcal{P}_B(x | s_f) \mathbb{E}[n_\tau | s_{n_\tau} = x]. \end{aligned} \quad (5)$$

然后，对于任意 $x \in \mathcal{X}$ ，由于从 s_0 到 x 的任何轨迹长度按定义至少为 $\ell(x)$ ，我们有 $\mathbb{E}[n_\tau | s_{n_\tau} = x] \geq \ell(x)$ ，完成证明。□

这是一个相当直观的结果，表明 $\mathbb{E}[n_\tau]$ 下界于从 s_0 到终端状态的最短路径期望长度乘以 $\mathcal{P}_B(x | s_f)$ 。接下来，我们将展示总是存在一个反向策略 $\mathcal{P}_B(\cdot | s)$ ，在方程 (4) 中实现等式。回忆我们用 $\mathcal{R}(x)$ 表示 GFlowNet 奖励。

引理 3.3. 假设 2.1 成立，则始终存在一个满足奖励匹配条件的反向策略

$\mathcal{P}_B(s | s_f) = \mathcal{R}(s)$ ，并诱导出预期轨迹长度等于

$$\mathbb{E}[n_\tau] = \sum_{x \in \mathcal{X}} \frac{\mathcal{R}(x)}{\mathcal{Z}} \ell(x). \quad (6)$$

证明。定义映射 $\text{par} : \mathcal{S} \setminus \{s_0, s_f\} \rightarrow \mathcal{S} \setminus \{s_f\}$ ，对于任意 $s \in \mathcal{S} \setminus \{s_0, s_f\}$ ，状态 $\text{par}(s)$ 被任意定义，使得 $(\text{par}(s) \rightarrow s) \in \mathcal{E}$ 和 $\ell(s) = \ell(\text{par}(s)) + 1$ 。这样的状态总是存在的，因为从 s_0 到 s 总是存在路径，并且在相应的最短路径上从 s_0 到 s 的前驱状态满足。然后，定义对于所有 $x \in \mathcal{X}$ (以满足奖励匹配条

$\ell(s) = \ell(\text{par}(s)) + 1$ $\mathcal{P}_B(x | s_f) = \mathcal{R}(x) / \mathcal{Z}$ 件)，并且 $\mathcal{P}_B(s | s') = \mathbb{1}\{s = \text{par}(s')\}$ 对于所有 $s' \in \mathcal{S} \setminus \{s_f\}$ 。因此，当使用 $\mathcal{P}_B$ 采样轨迹时，我们首先从 s_f 到达某个终止状态 x ，然后，在每一步，我们恰好向 s_0 靠近一条边，这意味着从 s_0 到 x 的最短路径总是被采样。因此，对于所有 $x \in \mathcal{X}$ ，我们有 $\mathbb{E}[n_\tau | s_{n_\tau} = x] = \ell(x)$ 。应用方程 (5)，我们完成证明。 $\square$

该证明是构造性的，表明沿着从 s_0 到终止状态的最短路径行进的反向策略具有最小可能的 $\mathbb{E}[n_\tau]$ 。最后，结合两个引理的结果，我们陈述主要定理。

定理 3.4. 在假设 2.1 成立的情况下，设 $\mathcal{P}_B$ 是一个满足奖励匹配条件

$\mathcal{P}_B(s | s_f) = \mathcal{R}(s)$ 并符合假设 3.1 的反向策略。那么 $\mathcal{P}_B$ 最小化 $\mathbb{E}[n_\tau]$ 当且仅当对于每个终止于任意状态 $\tau \in \mathcal{T}$ 的轨迹 $x \in \mathcal{X}$, $n_\tau \neq \ell(x)$ ，有 $\mathcal{P}(\tau) = 0$ 。换句话说，预期轨迹长度的最小化

$\mathbb{E}[n_\tau]$ 等价于将所有非最短路径从终止状态出发的轨迹赋予零概率 s_0 to a

证明直接来自引理 3.2 和

引理 3.3；我们参考附录 B 进行详细推导。

直观上，我们已经证明，如果有一个反向策略能够最小化 $\mathbb{E}[n_\tau]$ ，从该策略中采样一条轨迹意味着从概率分布 x 中采样一个终止状态 $\mathcal{R}(x) / \mathcal{Z}$ ，然后在反向方向上从 s_0 到 x 采样一条最短路径。值得注意的是，这样的 $\mathcal{P}_B$ 通常不是唯一的：对于任意的 $s \in \mathcal{S} \setminus \{s_f\}$ ，它可以为其父节点分配任意的概率 s 位于最短路径之间的 s_0 和 s (但必须将不在最短路径上的父节点的概率赋值为零)

备注 3.5。Morozov 等人提出的命题 3.8[2025] 指出，对于任何反向策略 $\mathcal{P}_B$ ，存在一个唯一的正向策略 $\mathcal{P}_F$ ，它诱导相同的概率分布覆盖 $\mathcal{T}$ 作为 $\mathcal{P}_B$ ，反之亦然。因此，定理 3.4

可以等价地重新表述为关于前向策略的情况，因为定理的条件仅与策略诱导的轨迹分布相关，而非策略本身。

备注 3.6。引理 3.3 的证明提供了一种构造性的方法来设计一个具有最小值的反向策略 $\mathbb{E}[n_\tau]$ 。它还可以用于构造性地提供唯一的相应前向策略。再次强调，对于任何 $s \in \mathcal{S} \setminus \{s_0, s_f\}$ 我们选取一个任意的状态参数 (s) 使得存在一条边 $(\text{par}(s) \rightarrow s) \in \mathcal{E}$ 和 $\ell(s) = \ell(\text{段落}(s)) + 1$ ，定义 $\mathcal{P}_B(s | s') = \mathbb{1}\{s = \text{段落}(s')\}$ 对所有 $s' \in \mathcal{S} \setminus \{s_f\}$ 。如果我们排除 s_f ，结构部分 (s) 定义了一个有向树子图 $\mathcal{G}$ 以 s_0 为根，并且 $\mathcal{P}_B$ 本质上是退化的，总是选择状态的唯一父节点。在这种情况下，存在一个对应的前向策略的简单表达式：

$\mathcal{P}_F(s' | s) = V(s') / V(s)$ ，其中 $V(s)$ 是从节点到达的树叶子中 GFlowNet 奖励之和 s ，参见 Bengio 等人 [2021]。

3.2 路径搜索应用 一般图

基于所提出的理论，接下来展示如何将 GFlowNets 应用于在一般图中寻找最短路径。

令 $G = (V, E)$ 为任意有限有序图。任务是从每个顶点 v 到指定的目标顶点 v_g 找到最短路径。我们注意到，这里考虑的是未加权图上的路径搜索问题，并假设从每个顶点到目标顶点都存在路径。

我们方法的核心思想是对图 G 进行轻微修改，以定义这样一个非无环的 GFlowNet 环境，其中具有最小 $\mathcal{P}_B$ 的 $\mathbb{E}[n_\tau]$ 解决了感兴趣的路径搜索任务。

首先，我们在 v_g 中移除所有从 G 出发的边。这不会改变任务，因为没有这样的边位于通往 v_g 的最短路径上。然后，我们定义一个非无环的 GFlowNet 环境 $\mathcal{G} = (\mathcal{S}, \mathcal{E})$ ，其中

1. 状态 $\mathcal{S}$ 对应于图 G 中的顶点，并额外增加了一个特殊的汇状态 s_f 。初始状态具体对应于 s_0 。
2. 转移 $\mathcal{E}$ 对应于从图 G 中的边反向而来。此外，从每个状态到 s_f 都添加了一个转移（除了状态 s_f 本身）。

这是一个满足假设 2.1 的有效 GFlowNet 环境。首先，状态 s_0 没有入边，状态 s_f 没有出边。由于每个状态都有一个转移到状态 s_f 的转移，因此从每个状态到状态 s_f 都存在路径，这意味着除了状态 s_f 之外的所有状态都是终端状态。最后，从状态 s_0 到每个状态 s 都存在路径，因为在图 G 中，从每个顶点 v 到顶点 v_g 都存在路径，而转移 $\mathcal{G}$ 是从图 G 中的边反向而来。

设 $\mathcal{R}$ 是在图 $\mathcal{S} \setminus \{s_f\}$ 上定义的任何正奖励函数。根据定理 3.4, 满足关于 $\mathcal{R}$ 的奖励匹配条件且具有最小 $\mathbb{E}[n_\tau]$ 的逆向策略只会将非零概率分配给从状态 s_0 到终端状态的最短路径, 其中前者与状态 v_g 一致, 后者与图 G 中的所有顶点一致。由于状态 $\mathcal{P}_B$ 在反方向遍历图 $\mathcal{G}$, 并且转移 $\mathcal{G}$ 是从图 G 中的边反向而来, 因此从任意状态 $s \in \mathcal{S} \setminus \{s_f\}$ 开始并通过策略 $\mathcal{P}_B$ 采样轨迹将导致从顶点 v (对应于状态 s) 到顶点 v_g (对应于状态 s_0) 的最短路径。

因此, 训练一个最小化其预期轨迹长度的非有向环 GFlowNet 将产生一个能够解决图 G 中的路径查找任务的模型, 特别是通过获得的逆向策略 $\mathcal{P}_B$ 。图 1 可视化了整体构造。

奖励的选择。 虽然所提出的构造允许使用任何正奖励函数, 但最自然的任务无关选择是均匀奖励分布: $\mathcal{R}(s) = 1$ 。此外, 在这种情况下, 最优的 $\mathbb{E}[n_\tau]$ 与到达目标状态的最短路径的平均长度一致: $\frac{1}{|V|} \sum_{v \in V} \ell(v)$ 。我们在下面讨论的训练算法以及所有实验中遵循这一设计选择。

前向策略。 在所提出的构造中, 反向策略的目标是在目标状态找到最短路径 s_0 。然而, 正向策略是一个辅助组件, 用于训练并服务于不同的目的。它从目标状态开始, 并以相反的方向遍历图, 旨在从指定的奖励分布中采样状态, 在我们的案例中, 该分布是均匀的。它还需要在每个状态下分配一个停止的概率, 对应于向汇合状态的转换 $\mathcal{P}_F(s_f | s)$ 。例如, 在魔方的情况下, 需要以尽可能少的步数解决任何可能的配置, 而另一方面则需要以尽可能少的步数打乱已解决的魔方 (包括决定何时停止打乱), 从而获得均匀分布的配置 $\mathcal{P}_B$, $\mathcal{P}_F$ 。

3.3 训练算法

3.3.1 以往文献中的考虑因素

Morozov 等人 [2025] 对非循环 GFlowNets 进行了在线训练, 在每次训练步骤中从 $\mathcal{P}_F$ 采样一批轨迹来计算损失。作者采用了细致平衡损失 [Bengio 等, 2023] 并结合状态流正则化 (见 2.1 节)。我们在尝试将此方法应用于路径寻找模型训练时遇到了两个关键问题。

首先, 正如 Morozov 等人观察到的 [2025], 预期轨迹长度 $\mathbb{E}[n_\tau]$ 在训练早期阶段的模型




图 1: 使用魔方作为示例, 展示了所提出的 GFlowNet 环境的可视化。正向转换由蓝色箭头表示, 反向转换由红色箭头表示。请注意, 在我们的构造中, 从目标状态 s_0 出发的反向转换被移除——它是关于 $\mathcal{P}_B$ 的吸收状态, 而在 s_1 和 s_3 之间存在双向的正向和反向转换 (因为魔方的凯莱图在这两个状态之间也有双向转换)。每个状态都有一个指向 s_f 的正向转换, 这对应于停止操作, 而 $\mathcal{P}_B(s | s_f)$ 对应于奖励分布, 我们将其设置为均匀分布。

可能非常高, 而从模型中采样一个完整的轨迹会引入高昂的训练成本, 尤其是在较大的环境情况下。为了缓解这一成本, 我们在训练过程中对采样的轨迹长度进行了限制。这种设计选择也在 Brunswic 等人的研究中被采用 [2024]。

其次, 在我们的早期实验中, 我们观察到使用详细平衡损失进行训练时收敛速度非常慢。相反, 我们选择使用轨迹平衡损失的修改版本 [Malkin 等, 2022] 来训练模型, 这在我们的案例中产生了显著更好的结果。我们假设这是因为轨迹平衡损失被证明比详细平衡具有更有效的信用分配 [Malkin 等, 2022]。此外, 可以注意到, 我们模型的主要训练信号来自目标状态本身。详细平衡定义在单个转换上, 大多数转换不包含目标状态, 而轨迹平衡定义在整个轨迹上, 每个轨迹都设计包含目标状态。我们将这种现象的考察留作进一步研究的一个有趣的研究方向。

3.3.2 带流量正则化的轨迹平衡

具体而言, 我们的方法如下。模型参数化并学习正向和反向策略: $\mathcal{P}_F(s' | s, \theta)$ 和 $\mathcal{P}_B(s | s', \theta)$ 。在每一步, 我们从正向策略 $\mathcal{P}_F$ 开始生成一批固定长度 $N_{\max}$ 的部分轨迹, 起始于 s_0 。为了确保轨迹

为了防止轨迹过早终止，我们在采样过程中简单地屏蔽了 action $\mathcal{P}_F(s_f \text{ 停止符号} \mid s, \theta)$ 。我们将这样的部分轨迹

$$\tau' = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_{N_{\max}}).$$

表示为。由于环境

中的每个状态都是终止状态（参见第 3.2 节），每个前缀 $\tau'_{0:i}$ 加上一个终止转换 $(s_i \rightarrow s_f)$ 可以被视为一个完整的轨迹 $(s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_i \rightarrow s_f) \in \mathcal{T}$ 。然后，我们计算所有前缀的轨迹平衡损失 [Malkin 等, 2022] 并求和：

$$\sum_{i=0}^{N_{\max}} \left(\log \frac{\mathcal{P}_F(s_f \mid s_i, \theta) \prod_{t=1}^i \mathcal{P}_F(s_t \mid s_{t-1}, \theta)}{(\mathcal{R}(s_i)/\mathcal{Z}) \prod_{t=1}^i \mathcal{P}_B(s_{t-1} \mid s_t, \theta)} \right)^2. \quad (7)$$

这种设计选择的动机在于，考虑所有前缀的平衡条件而非仅整个轨迹，能够提供更多关于采样轨迹的信息，从而形成一种更高效的采样方法。通常情况下，在 GFlowNets 中归一化常数是未知的，并将一个可学习的标量 $\log \mathcal{Z}_\theta$ 插入到损失函数中。然而，在我们的奖励选择 $\mathcal{R}(s) = 1$ 的情况下，它仅仅对应于图中的顶点数量 $\mathcal{Z} = |V|$ ，因此无需进行学习。

为了在损失函数中添加状态流正则化 [Brunswic 等, 2024, Morozov 等, 2025]，可以注意到，在我们的构造环境中，从每个其他状态到 s_f 的状态转移存在，此时流可以表示为 $\mathcal{F}(s) = \mathcal{R}(s)/\mathcal{P}_F(s_f \mid s)$ ，无需作为额外组件进行学习，参见 Deleu 等的研究 [2022]。理论上，这种参数化可以通过结合终端边流的条件 $\mathcal{F}(s \rightarrow s_f) = \mathcal{R}(s)$ (Morozov 等的命题 3.10[2025]) 和详细平衡条件的一部分 $\mathcal{F}(s \rightarrow s_f) = \mathcal{F}(s)\mathcal{P}_F(s_f \mid s)$ (Morozov 等的命题 3.8[2025]) 获得。

最后，结合均匀奖励的选择和上述讨论的流参数化，我们得到了以下正则化的训练目标：

$$\mathcal{L}_{\text{regTB}}(\theta, \tau) = \sum_{i=0}^{N_{\max}} \left\{ \mathcal{L}_{\text{TB}}(\theta, \tau_{0:i}) + \frac{\lambda}{\mathcal{P}_F(s_f \mid s_i, \theta)} \right\}, \quad (8)$$

其中

$$\mathcal{L}_{\text{TB}}(\theta, \tau_{0:i}) = \left(\log \frac{\mathcal{P}_F(s_f \mid s_i, \theta) \prod_{t=1}^i \mathcal{P}_F(s_t \mid s_{t-1}, \theta)}{(1/|V|) \prod_{t=1}^i \mathcal{P}_B(s_{t-1} \mid s_t, \theta)} \right)^2.$$

完整的训练过程总结于算法 1 中。这里需要指出的是，关于 $\mathcal{P}_F$ 和 $\mathcal{P}_B$ 的优化是我们算法的关键部分。GFlowNet 文献中存在专门用于优化反向策略的方法 [Jang 等, 2024, Gritsaev 等, 2025]，这些方法可能被应用于进一步提高训练效果。

Algorithm 1 Training a GFlowNet for pathfinding with regularized trajectory balance objective

- 1: **Input:** Model and optimizer, regularization coefficient λ , maximum length of training trajectories $N_{\max}$, batch size B
 - 2: **repeat**
 - 3: Sample a batch of trajectories $\tau^{1:B}$ of length up to $N_{\max}$ from the policy $\mathcal{P}_F(s' \mid s, \theta)$ starting in s_0
 - 4: Compute $\frac{1}{B} \sum_{i=1}^B \nabla_\theta \mathcal{L}_{\text{regTB}}(\theta, \tau^i)$ and update model parameters θ
 - 5: **until** convergence
-

3.4 束搜索

虽然理论上，我们的方法中的最优反向策略能够精确找到最短路径，但在实际应用中，对于较大的图，学习到的策略只能提供近似解，这一点在第 4 节的实验评估中进一步得到证明。借鉴 Chervov 等 [2025b] 的研究，我们在测试时使用束搜索作为一种启发式方法来改进解决方案。

令 W 为束搜索的宽度。在束搜索的每一步中，我们考虑继续当前存储的所有轨迹的所有方式，并基于轨迹上反向转移概率乘积的对数，保留前 W 个候选者。当达到目标状态 s_0 时，搜索停止。由此产生的算法与广泛应用于文本生成模型中的算法 [Sutskever 等, 2014, Meister 等, 2020] 非常相似，可以视为一种近似寻找模型赋予最高概率轨迹的方法。我们还发现 Chervov 等 [2025b] 提出的额外启发式方法可以略微改善结果，该方法包括在束搜索的每一步中从当前批次中删除重复状态，并在我们的实验中使用了这一方法。

当算法的光束宽度 W 设置为 1 时，这对应于对学习到的反向策略进行贪心评估：在每一步中，选择具有最高概率 $\arg\max_s \mathcal{P}_B(s \mid s', \theta)$ 的状态转移，而不是从 $\mathcal{P}_B$ 中忠实采样一条轨迹。若所学策略为最优，则仍会产生最短路径，因为所有不位于最短路径上的转移必须被赋予零概率（定理 3.4）。

值得注意的是，其他搜索算法也可以在此处应用，例如 Morozov 等人 [2024] 展示了熵正则化的蒙特卡洛树搜索 [Xiao 等, 2019] 可以应用于 GFlowNets 的测试阶段，这是一个未来研究的有趣方向。

4 实验

我们在合成交换任务以及 $2 \times 2 \times 2$ 和 $3 \times 3 \times 3$ 魔方上进行了实验评估。我们的神经网络架构与 Chervov 等人 [2025b] 所使用的非常相似：带有残差连接和层归一化的多层感知机。在每个任务中，状态对应于固定大小的排列，并提供一个独热编码作为神经网络的输入。对于详细的实验细节，我们请读者参阅附录 C。




图 2: 交换谜题 $n = 15$ 和 $n = 20$ 在三种评估协议下的结果: 1) 路径忠实采样自 $\mathcal{P}_B$, 2) 路径通过贪婪评估获得 $\mathcal{P}_B$, 3) 路径通过小宽度束搜索生成 $W = 4$ 。对于贪婪评估的结果, 在未能找到测试集中每个排列的有效解的检查点上未予展示。对于 $n = 20, 100k$, 训练迭代在 NVIDIA H200 GPU 上运行了 15 分钟。

我们的神经网络架构与 Chervov 等人 [2025b] 所使用的非常相似: 带有残差连接和层归一化的多层感知机。在每个任务中, 状态对应于固定大小的排列, 并提供一个独热编码作为神经网络的输入。对于详细的实验细节, 我们请读者参阅附录 C。

4.1 交换谜题

为了评估所提方法寻找最短路径的能力, 以及推广到大型图中未见过的状态的能力, 我们首先考虑了一个合成环境, 它是 Mulholland[2016] 描述的交换谜题的一种变体。

假设你得到一组任意排列的 n 元素, 任务是使用尽可能少的操作次数对其进行排序, 每一步允许交换任何一对相邻元素。该任务对应于对称群 S_n 的凯莱图中, 生成集由相邻元素的置换组成的情况下的路径寻找问题。解决方案相当直接: 每一步都应交换处于降序的一对相邻元素。这一策略之所以最优, 基于两个事实: 1) 单位置换 (目标状态) 是唯一具有 0 逆序数的置换, 2) 交换




图 3: 正则化系数 λ 对交换谜题 $n = 15$ 和 $2 \times 2 \times 2$ 魔方子集所获得的解长度的影响。在这两种情况下, 选择更大的 λ 导致模型无法找到任何有效路径。

一对相邻元素要么减少逆序数 (如果它们处于降序), 要么增加逆序数 (如果它们处于升序)。因此, 任何排列 s 的解长度对应于其中的逆序数。目标是验证我们的模型是否成功地学习了最优策略。

图 2 展示了针对 $n = 15$ 和 $n = 20$ 的评估结果, 分别对应于具有 $\approx 1.3 \cdot 10^{12}$ 和 $\approx 2.4 \cdot 10^{18}$ 状态的凯莱图。对于每个任务, 我们固定一个包含 500 个均匀采样的排列作为测试集, 并报告模型在整个训练过程中找到的路径的平均长度。我们绘制了三种评估协议的结果: 1) 路径忠实于从 $\mathcal{P}_B$ 中采样, 2) 路径通过贪婪评估 $\mathcal{P}_B$ 获得, 3) 路径通过小宽度束搜索生成 $W = 4$ 。

我们观察到, 在充分训练后, 无论是贪婪策略还是束搜索评估协议都能为测试集中的每个排列生成精确的最短路径 (束搜索协议需要较少的训练即可产生最优解), 而该策略本身产生的解在平均意义上接近最优。值得注意的是, 例如在 $n = 20$, 图 2 所示的模型在训练过程中仅见到了 10^9 种状态中的 $2.4 \cdot 10^{18}$ 种, 这展示了其泛化能力。

4.2 魔方

接下来, 我们在 $2 \times 2 \times 2$ 和 $3 \times 3 \times 3$ 的魔方上评估了我们的方法, 对比对象是 CayleyPy Cube [Chervov 等, 2025b]。这是一种最先进的机器学习方法, 专门设计

表 1: 与 CayleyPy Cube [Chervov 等, 225b] 的比较。我们使用了 [Chervov 等, 225b] 中的测试集, 包含 100 个 2x2x2 魔方示例, 以及 [Agostinelli 等, 2019] 中的测试集, 包含 1000 个 3x3x3 魔方示例, 展示了不同束搜索预算下两种方法找到解决方案的平均长度。解出率对应于测试集中模型在 100 步内找到有效路径的示例比例。对于 2x2x2 魔方, 平均长度 10.64 是针对测试集的最优值, 已通过 BFS 算法验证。

2x2x2 Rubik's Cube					3x3x3 Rubik's Cube				
Beam size	Ours		CayleyPy Cube		Beam size	Ours		CayleyPy Cube	
	Avg. length	Solve rate	Avg. length	Solve rate		Avg. length	Solve rate	Avg. length	Solve rate
$W = 2^0$	11.62	1.0	x	0.00	$W = 2^0$	x	0.471	x	0.000
$W = 2^2$	11.24	1.0	x	0.00	$W = 2^3$	x	0.984	x	0.001
$W = 2^4$	10.78	1.0	x	0.00	$W = 2^6$	25.33	1.0	x	0.687
$W = 2^6$	10.64	1.0	x	0.06	$W = 2^9$	23.49	1.0	24.34	1.0
$W = 2^8$	10.64	1.0	x	0.89	$W = 2^{12}$	22.42	1.0	22.44	1.0
$W = 2^{10}$	10.64	1.0	10.64	1.0	$W = 2^{15}$	21.70	1.0	21.61	1.0
$W = 2^{12}$	10.64	1.0	10.64	1.0	$W = 2^{18}$	21.24	1.0	21.15	1.0

专门用于解决魔方及其他类似谜题, 结果显示其在解决方案长度和运行效率方面均优于先前的方法, 如 Deep-CubeA [Agostinelli 等, 2019] 和 EfficientCube [高野, 2023]。为了确保比较的公平性, 对于 CayleyPy Cube, 我们训练了一个模型, 其神经网络超参数与原始工作 [Chervov 等, 2025b] 中指定的一致, 并训练了一个具有与我们相同规模的神经网络的模型, 从中选取最优者。对于这两种谜题, 我们仅允许 90 度的面转动, 因此所呈现的解决方案长度是以 QTM——四分之一转度量表示。我们采用与 Chervov 等 [2025b] 相同的方式对状态和转换进行编码, 将其视为置换。

两种方法在模型训练后都利用束搜索寻找最短路径, 并在表 1 中提供了不同束搜索宽度 W 的比较。对于 2x2x2 魔方, 我们的方法需要的束搜索宽度仅为 CayleyPy Cube 的十六分之一即可找到最优解, 并且即使在贪婪评估下也能为整个测试集提供有效解 ($W = 1$), 而 CayleyPy Cube 在较小的束搜索宽度下无法找到任何有效路径。对于 3x3x3 魔方, 我们的模型在较小的束搜索宽度从 1 到 2^9 上也表现出更好的性能, 而对于较大的值 $W = \{2^{12}, 2^{15}, 2^{18}\}$ 则显示出相当的结果。

此外, 我们在 3x3x3 魔方上对两个模型的运行效率进行了评估, 使用了表 1 中产生最佳结果的大束搜索预算 $W = 2^{18}$ 。在单个 NVIDIA H200 GPU 上运行时, 我们的模型平均需要 1.74 秒来解决一个带有 25M 参数神经网络的魔方配置, 而 CayleyPy Cube 平均需要 6.19 秒来解决一个带有 4M 参数神经网络的魔方配置。即使使用更大的神经网络, 速度提升的主要原因是 CayleyPy Cube

类似的方法如 DeepCubeA [Agostinelli 等, 2019] 需要进行 12 倍的神经网络评估 (此处 12 是指每个状态的邻居数量), 在相同的束宽下。实际上, 这些方法需要对每个状态的邻居执行一次前向传播来估计值或距离, 而我们的模型仅需一次前向传播即可输出与每个邻居对应的反向策略对数概率。

4.3 正则化的消融系数

最后, 我们讨论正则化系数的作用 λ (参见方程 (8)), 这是非循环 GFlowNet 训练中带有流正则化的主超参数之一。在我们的实验中, 我们观察到当使用较大的值进行训练时, 模型表现更好。` $\lambda$ `, 但在某些情况下可能完全失效 λ 过大。我们展示了其影响 λ 关于图 3 的结果。因此, 可以使用一个简单的经验法则来快速调整 λ 在我们的方法中: 在训练迭代次数非常少的情况下评估模型, 并选择最大的值 λ 生成能够找到通往目标状态的有效路径的模型。

5 结论

在本研究中, 我们建立了非循环 GFlowNets 与路径搜索之间的直接理论联系。我们的主要结果表明, 最小化预期轨迹长度等价于将概率质量集中于最短路径上。这为非循环 GFlowNets 中的流最小化提供了新的解释, 并以概率论的形式重新诠释了最短路径最优性。基于

这一结果展示了如何利用带有流正则化的非循环 GFlowNets 来训练随机策略，以在任意无权图中寻找最短路径。我们的实验评估，包括与在鲁比克魔方上表现强劲的基线进行比较，证明了所提出方法在凯莱图上的路径搜索问题中具有强大的能力。

总体而言，我们的结果将非循环 GFlowNets 定位为离散环境中最短路径学习的原理性和通用框架。进一步的工作可以将该框架扩展到加权图和成本敏感设置，并探索其在极大图中的可扩展性以及 Cayley 图以外领域的应用。

致谢

本研究部分通过 HSE 大学的高性能计算设施提供的计算资源支持 [Kostenetskiy 等, 2021]。

参考文献

- Forest Agostinelli, Stephen McAleer, Alexander Shmakov, and Pierre Baldi. Solving the rubik’s cube with deep reinforcement learning and search. *Nature Machine Intelligence*, 1(8):356–363, 2019.
- Noga Alon, Itai Benjamini, Eyal Lubetzky, and Sasha Sodin. Non-backtracking random walks mix faster. *Communications in Contemporary Mathematics*, 9(04):585–603, 2007.
- Lazar Atanackovic, Alexander Tong, Bo Wang, Leo J Lee, Yoshua Bengio, and Jason S Hartford. Dyngfn: Towards bayesian inference of gene regulatory networks with gflownets. *Advances in Neural Information Processing Systems*, 36, 2024.
- Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
- Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow network based generative models for non-iterative diverse candidate generation. *Advances in Neural Information Processing Systems*, 34: 27381–27394, 2021.
- Yoshua Bengio, Salem Lahlou, Tristan Deleu, Edward J Hu, Mo Tiwari, and Emmanuel Bengio. Gflownet foundations. *Journal of Machine Learning Research*, 24(210):1–55, 2023.
- James Bradbury, Roy Frostig, Peter Hawkins, Matthew James Johnson, Chris Leary, Dougal Maclaurin, George Necula, Adam Paszke, Jake VanderPlas, Skye Wanderman-Milne, and Qiao Zhang. JAX: composable transformations of Python+NumPy programs, 2018. URL <http://github.com/jax-ml/jax>.
- Leo Brunswic, Yinchuan Li, Yushun Xu, Yijun Feng, Shangling Jui, and Lizhuang Ma. A theory of non-acyclic generative flow networks. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 11124–11131, 2024.
- A Chervov, A Soibelman, S Lytkin, Igor Kiselev, S Fironov, A Lukyanenko, A Dolgorukova, A Ogurtsov, F Petrov, S Krymskii, et al. Cayleypy rl: Pathfinding and reinforcement learning on cayley graphs. *arXiv preprint arXiv:2502.18663*, 2025a.
- Alexander Chervov, Kirill Khoruzhii, Nikita Bukhal, Jalal Naghiyev, Vladislav Zamkovoy, Ivan Koltsov, Lyudmila Cheldieva, Arsenii Sychev, Arsenii Lenin, Mark Obozov, Egor Urvanov, and Alexey M. Romanov. A machine learning approach that beats rubik’s cubes. In *Proceedings of the 39th Conference on Neural Information Processing Systems (NeurIPS 2025)*, 2025b.
- Gene Cooperman, Larry Finkelstein, and Namita Sarawagi. Applications of cayley graphs. In *International symposium on applied algebra, algebraic algorithms, and error-correcting codes*, pages 367–378. Springer, 1990.
- Rémi Coulom. Efficient selectivity and backup operators in monte-carlo tree search. In *International conference on computers and games*, pages 72–83. Springer, 2006.
- Miruna Cretu, Charles Harris, Ilia Igashov, Arne Schneuing, Marwin Segler, Bruno Correia, Julien Roy, Emmanuel Bengio, and Pietro Lio. SynFlowNet: Design of diverse and novel molecules with synthesis constraints. In *The Thirteenth International Conference on Learning Representations*, 2025.
- Tristan Deleu, António Góis, Chris Emezue, Mansi Rankawat, Simon Lacoste-Julien, Stefan Bauer, and Yoshua Bengio. Bayesian structure learning with generative flow networks. In *Uncertainty in Artificial Intelligence*, pages 518–528. PMLR, 2022.
- Tristan Deleu, Mizu Nishikawa-Toomey, Jithendaraa Subramanian, Nikolay Malkin, Laurent Charlin, and Yoshua Bengio. Joint bayesian inference of graphical structure and parameters with a single generative flow network. *Advances in neural information processing systems*, 36: 31204–31231, 2023.
- Tristan Deleu, Padideh Nouri, Nikolay Malkin, Doina Precup, and Yoshua Bengio. Discrete probabilistic inference as control in multi-path environments. In *The 40th Conference on Uncertainty in Artificial Intelligence*, 2024.

- Rüdiger Ebendt and Rolf Drechsler. Weighted A* search—unifying view and application. *Artificial Intelligence*, 173(14):1310–1342, 2009.
- Giorgio Gallo and Stefano Pallottino. Shortest path algorithms. *Annals of operations research*, 13(1):1–79, 1988.
- Timofei Gritsaev, Nikita Morozov, Sergey Samsonov, and Daniil Tiapkin. Optimizing backward policies in GFlowNets via trajectory likelihood maximization. In *The Thirteenth International Conference on Learning Representations*, 2025.
- Peter E Hart, Nils J Nilsson, and Bertram Raphael. A formal basis for the heuristic determination of minimum cost paths. *IEEE transactions on Systems Science and Cybernetics*, 4(2):100–107, 1968.
- Edward J Hu, Moksh Jain, Eric Elmoznino, Younesse Kaddar, Guillaume Lajoie, Yoshua Bengio, and Nikolay Malkin. Amortizing intractable inference in large language models. In *The Twelfth International Conference on Learning Representations*, 2023.
- Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International conference on machine learning*, pages 448–456. pmlr, 2015.
- Hyosoon Jang, Yunhui Jang, Minsu Kim, Jinkyoo Park, and Sungsoo Ahn. Pessimistic backward policy for GFlowNets. In *Advances in Neural Information Processing Systems*, volume 37, pages 107087–107111, 2024.
- Karthik Karur, Nitin Sharma, Chinmay Dharmatti, and Joshua E Siegel. A survey of path planning algorithms for mobile robots. *Vehicles*, 3(3):448–468, 2021.
- John G Kemeny and J Laurie Snell. *Finite markov chains*, volume 26. van Nostrand Princeton, NJ, 1969.
- Minsu Kim, Sanghyeok Choi, Hyeonah Kim, Jiwoo Son, Jinkyoo Park, and Yoshua Bengio. Ant colony sampling with gflownets for combinatorial optimization. In *International Conference on Artificial Intelligence and Statistics*, pages 469–477. PMLR, 2025.
- PS Kostenetskiy, RA Chulkevich, and VI Kozyrev. Hpc resources of the higher school of economics. In *Journal of Physics: Conference Series*, volume 1740, page 012050. IOP Publishing, 2021.
- Michał Koziarski, Andrei Rekesh, Dmytro Shevchuk, Almer van der Sloot, Piotr Gaiński, Yoshua Bengio, Chenghao Liu, Mike Tyers, and Robert Batey. Rgfn: Synthesizable molecular generation using gflownets. *Advances in Neural Information Processing Systems*, 37:46908–46955, 2024.
- Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- Kanika Madan, Jarrid Rector-Brooks, Maksym Korablyov, Emmanuel Bengio, Moksh Jain, Andrei Cristian Nica, Tom Bosc, Yoshua Bengio, and Nikolay Malkin. Learning gflownets from partial episodes for improved convergence and stability. In *International Conference on Machine Learning*, pages 23467–23483. PMLR, 2023.
- Amgad Madkour, Walid G Aref, Faizan Ur Rehman, Mohamed Abdur Rahman, and Saleh Basalamah. A survey of shortest-path algorithms. *arXiv preprint arXiv:1705.02044*, 2017.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in gflownets. *Advances in Neural Information Processing Systems*, 35:5955–5967, 2022.
- Nikolay Malkin, Salem Lahlou, Tristan Deleu, Xu Ji, Edward J Hu, Katie E Everett, Dinghuai Zhang, and Yoshua Bengio. GFlownets and variational inference. In *The Eleventh International Conference on Learning Representations*, 2023.
- Dragos Cristian Manta, Edward J Hu, and Yoshua Bengio. Gflownets for causal discovery: an overview. In *ICML 2023 Workshop on Structured Probabilistic Inference & Generative Modeling*, 2023.
- Stephen McAleer, Forest Agostinelli, Alexander Shmakov, and Pierre Baldi. Solving the rubik’s cube without human knowledge. *arXiv preprint arXiv:1805.07470*, 2018.
- Clara Meister, Ryan Cotterell, and Tim Vieira. If beam search is the answer, what was the question? In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 2173–2185, 2020.
- Nikita Morozov, Daniil Tiapkin, Sergey Samsonov, Alexey Naumov, and Dmitry Vetrov. Improving gflownets with monte carlo tree search. In *ICML 2024 Workshop on Structured Probabilistic Inference & Generative Modeling*, 2024.
- Nikita Morozov, Ian Maksimov, Daniil Tiapkin, and Sergey Samsonov. Revisiting non-acyclic gflownets in discrete environments. In *International Conference on Machine Learning*, pages 44887–44910. PMLR, 2025.
- Jamie Mulholland. Permutation puzzles: a mathematical perspective. *Department Of mathematics Simon fraser University*, 54, 2016.
- Alexander Schrijver et al. *Combinatorial optimization: polyhedra and efficiency*, volume 24. Springer, 2003.

Ilya Sutskever, Oriol Vinyals, and Quoc V Le. Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27, 2014.

Richard S Sutton, Andrew G Barto, et al. *Reinforcement learning: An introduction*, volume 1. MIT press Cambridge, 1998.

Kyo Takano. Self-supervision is all you need for solving rubik’s cube. *Transactions on Machine Learning Research*, 2023. ISSN 2835-8856.

Daniil Tiapkin, Nikita Morozov, Alexey Naumov, and Dmitry P Vetrov. Generative flow networks as entropy-regularized rl. In *International Conference on Artificial Intelligence and Statistics*, pages 4213–4221. PMLR, 2024.

Daniil Tiapkin, Artem Agarkov, Nikita Morozov, Ian Maksimov, Askar Tsyganov, Timofei Gritsaev, and Sergey Samsonov. gfnx: Fast and scalable library for generative flow networks in jax. *arXiv preprint arXiv:2511.16592*, 2025.

Chenjun Xiao, Ruitong Huang, Jincheng Mei, Dale Schuurmans, and Martin Müller. Maximum entropy monte-carlo planning. *Advances in Neural Information Processing Systems*, 32, 2019.

Dinghuai Zhang, Hanjun Dai, Nikolay Malkin, Aaron C Courville, Yoshua Bengio, and Ling Pan. Let the flows tell: Solving graph combinatorial problems with gflownets. In *Advances in Neural Information Processing Systems*, volume 36, pages 11952–11969, 2023.

Heiko Zimmermann, Fredrik Lindsten, Jan-Willem van de Meent, and Christian A Naesseth. A variational perspective on generative flow networks. *Transactions on Machine Learning Research*, 2023. ISSN 2835-8856.

Learning Shortest Paths with Generative Flow Networks (Supplementary Material)

Nikita Morozov¹

Ian Maksimov¹

Daniil Tiapkin^{2,3}

Sergey Samsonov¹

¹HSE University ²CMAP, CNRS, École polytechnique ³LMO, Université Paris-Saclay

逆策略假设

考虑一个在 $\mathcal{G}$ 上的随机游走，其边被反转，并由逆策略给出转移概率 $\mathcal{P}_B$ 。具体来说，定义一个马尔可夫链 $\{X_n\}_{n=0}^\infty$ ，使得 $X_0 = s_f$ 几乎处处成立，并且 $\mathbb{P}[X_t = s \mid X_{t-1} = s'] = \mathcal{P}_B(s \mid s')$ 。同时定义 $\mathbb{P}[X_t = s_0 \mid X_{t-1} = s_0] = 1$ 。假设 3.1 意味着这个游走的期望长度是有限的： $\mathbb{E}[n_\tau] = \mathbb{E}[\sum_{t=0}^\infty \mathbb{1}\{X_t \neq s_0\}] < \infty$ 。

这意味着随机游走 X 以概率 1: $\mathbb{P}[\exists t : X_t = s_0] = 1$ 终止于 s_0 ，因为否则事件 $\{\sum_{t=0}^\infty \mathbb{1}\{X_t \neq s_0\} = \infty\}$ 具有非零概率，这与 $\mathbb{E}[n_\tau]$ 的有限性相矛盾。由此自动得出 $\mathcal{P}(\tau)$ 是关于 $\mathcal{T}$ 的一个正确的测度，因为对于任意的 $\tau = (s_0, s_1, \dots, s_{n_\tau}, s_f)$ ，它满足

$$\mathbb{P}[(X_{n_\tau+1}, \dots, X_0) = \tau] = \prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t \mid s_{t+1}) = \mathcal{P}(\tau),$$

并且我们有

$$\sum_{\tau \in \mathcal{T}} \mathbb{P}[(X_{n_\tau+1}, \dots, X_0) = \tau] = \mathbb{P}[\exists \tau \in \mathcal{T} : (X_{n_\tau+1}, \dots, X_0) = \tau] = \mathbb{P}[\exists t : X_t = s_0] = 1,$$

因为事件 $\{(X_{n_\tau+1}, \dots, X_0) = \tau\}$ 对于不同的 τ 不相交。

上述推理直接遵循 Morozov 等人引理 3.4 的证明的一部分 [2025]。同样的引理 3.4 表明事实 $\mathcal{P}_B(s \mid s') > 0 \forall \tau \in \mathcal{T}$ 蕴含 $\mathbb{E}[n_\tau] < \infty$ ，使其成为比假设 3.1 更强的假设。这一假设的主要问题是它通常不适用于具有最小 $\mathbb{E}[n_\tau]$ 的 $\mathcal{P}_B$ ，正如定理 3.4 所暗示的那样，使得 Morozov 等人的理论 [2025] 不能直接应用于学习具有最小预期轨迹长度的非循环 GFlowNets 的任务。然而，仔细审视 Morozov 等人的理论结果 [2025] 可以发现，实际上使用这一假设的部分只有引理 3.4 本身，而其他所有结果的证明只需要事实 $\mathbb{E}[n_\tau] < \infty$ 和事实 $\mathcal{P}(\tau)$ 是定义在 $\mathcal{T}$ 上的正确概率测度，因此可以在假设 3.1 下仔细重写。

在更一般的假设 3.1 下，相同的理论结果也可以直接从那些假设中导出 $\mathcal{P}_B(s \mid s') > 0$ 例如，注记 3.5 引用了 Morozov 等人的命题 3.8 [2025]，这需要 $\mathcal{P}_B(s \mid s') > 0$ 以将此结果应用于 $\mathcal{P}_B$ 可以将某些转移赋予零概率，从而考虑其子集 $\mathcal{T}' \subseteq \mathcal{T}$ 由轨迹组成 τ' 与 $\mathcal{P}(\tau') > 0$ 这一子集诱导出一个子图 $\mathcal{G}'$ 的 $\mathcal{G}$ 满足假设 2.1，因为 1) 它包含 s_f 和 s_0 ，2) 任何状态 s 它所包含的状态根据构造位于某些轨迹上 $\tau' \in \mathcal{T}'$ 。然后，对于任意 $\mathcal{P}_B(s \mid s')$ 在假设 3.1 下，存在唯一的 $\mathcal{P}_F$ 诱导相同的分布于 $\mathcal{T}'$ 根据 Morozov 等人的命题 3.8 [2025] 应用到 $\mathcal{G}'$ ，其中 $\mathcal{P}_B$ 为所有状态转移分配非零概率。对于不属于 $\mathcal{G}'$ 的状态转移 $\mathcal{P}_F$ 则简单定义为零。

附录 B 定理 3.4 的证明

证明。我们的证明包括两个主要步骤。首先，我们证明仅取最短路径保证最小预期长度。其次，我们证明最小化预期长度严格禁止取非最短路径。

第一部分：如果策略仅取最短路径，则最小化预期长度 ($\Leftarrow$). 假设如果终止于状态 x 的轨迹 τ 具有非零概率 ($\mathcal{P}(\tau) > 0$)，其长度 n_τ 必须恰好等于到达该状态的最短可能路径长度，记为 $\ell(x)$ 。由于策略满足奖励匹配条件，我们知道终止于任何状态的概率 $x \in \mathcal{X}$ 固定为 $\frac{\mathcal{R}(x)}{\mathcal{Z}} > 0$ 。根据方程 ()

$$\mathbb{E}[n_\tau] = \sum_{x \in \mathcal{X}} \frac{\mathcal{R}(x)}{\mathcal{Z}} \mathbb{E}[n_\tau | s_{n_\tau} = x] = \sum_{x \in \mathcal{X}} \frac{\mathcal{R}(x)}{\mathcal{Z}} \ell(x).$$

根据引理 3.2，这个和表示任何有效反向策略预期长度的绝对理论下限。由于我们的策略达到了这个确切的下限，它成功地最小化了预期轨迹长度。

第二部分：如果策略最小化了预期长度，它必须仅采取最短路径 ($\Rightarrow$). 我们将通过反证法证明这一点。假设至少存在一条轨迹 τ 结束于某个终端状态 x' ，其长度超过从 s_0 到 x' ($n_\tau > \ell(x')$) 的最短路径，并且该策略赋予这条轨迹一个非零概率 ($\mathcal{P}(\tau) > 0$)。那么，我们有

$$\mathbb{E}[n_\tau | s_{n_\tau} = x'] > \ell(x').$$

对于所有其他终端状态 $x \in \mathcal{X}$ ，平均路径长度至少是最短路径长度，这意味着 $\mathbb{E}[n_\tau | s_{n_\tau} = x] \geq \ell(x)$ 。现在，应用方程 (5)

$$\mathbb{E}[n_\tau] = \sum_{x \in \mathcal{X}} \frac{\mathcal{R}(x)}{\mathcal{Z}} \mathbb{E}[n_\tau | s_{n_\tau} = x] > \sum_{x \in \mathcal{X}} \frac{\mathcal{R}(x)}{\mathcal{Z}} \ell(x).$$

然而，引理 3.3 证明可以构造一个反向策略，使其达到右侧的确切理论最小值。因为我们的策略 $\mathcal{P}_B$ 导致严格更大的预期轨迹长度，它没有最小化 $\mathbb{E}[n_\tau]$ ，这与我们的初始假设相矛盾。 $\square$

附录 C 实验细节

在所有实验中，类似于之前的工作 [Agostinelli 等人, 2019, Chervov 等人, 2025b]，我们使用一种残差 MLP 架构的变体来参数化我们的模型，由六个修正线性单元（线性（层归一化 (x)) + x ）块组成。与之前工作不同的是，我们用层归一化 [Ba 等人, 2016] 替换了批归一化 [Ioffe 和 Szegedy, 2015]，以提高训练和评估稳定性。 $\mathcal{P}_F(s' | s, \theta)$ 和 $\mathcal{P}_B(s | s', \theta)$ 共享相同的骨干结构，不同的线性头分别预测正向策略和反向策略的对数几率。请注意，正向策略的对数几率数量是从初始图中的状态到下一个状态的转换数量加上一个对应的停止动作的对数几率。

我们使用 JAX [Bradbury 等人, 2018] 实现我们的方法，因为它具有即时加速的能力

整个训练循环的即时编译 (JIT compilation)，这被证明可以显著加快 GFlowNet 的训练速度 [蒂亚普金等, 2025]。

C.1 交换拼图

我们对所有模型进行 100,000 次迭代的训练，批大小为 128，并使用 AdamW 优化器 [洛什奇洛夫和赫特, 2019]，带有权重衰减 10^{-5} 。我们将学习率设置为 $3 \cdot 10^{-4}$ ，并使用隐藏层大小为 1024。我们发现限制梯度范数有助于稳定训练，并使用阈值为 100。图 2 中的模型使用正则化系数 $\lambda = 10^{-3}$ 对 $n = 15$ 和 $\lambda = 10^{-4}$ 对 $n = 20$ 进行训练。我们将其设置为 $N_{\max} = 50$ 。

C.2 魔方

对于 $2 \times 2 \times 2$ 魔方，我们使用批大小为 128 的 500,000 次训练迭代；对于 $3 \times 3 \times 3$ 魔方，我们使用批大小为 2048 的 1,000,000 次训练迭代。我们将学习率设置为 $3 \cdot 10^{-4}$ ，并使用 $2 \times 2 \times 2$ 魔方的隐藏层大小为 1024， $3 \times 3 \times 3$ 魔方的隐藏层大小为 2048。所有模型均使用带有权重衰减 10^{-5} 的 AdamW 优化器 [洛什奇洛夫和赫特，2019] 进行训练。我们发现限制梯度范数有助于稳定训练，并使用阈值为 100。表 1 中的模型使用正则化系数 $\lambda = 10^{-2}$ 对 $2 \times 2 \times 2$ 魔方和 $\lambda = 5 \cdot 10^{-7}$ 对 $3 \times 3 \times 3$ 魔方进行训练。我们将其设置为 $2 \times 2 \times 2$ 魔方的 $N_{\max} = 12$ 和 $3 \times 3 \times 3$ 魔方的 $N_{\max} = 24$ 。我们发现这些值能够实现高效的训练，尽管它们小于各自环境中的最长路径。这进一步展示了所提方法的泛化能力。

为了与 CayleyPy 魔方 [切沃夫等，2025b] 进行比较，我们使用作者提供的官方实现¹。我们使用相同数量的采样魔方配置来训练所有模型，以确保公平的比较。

¹<https://github.com/khoruzhii/cayleypy-cube>