

您的 GFlowNet 隐秘地学习了一个最优传输计划

伊恩·马克斯莫夫¹ 尼基塔·莫罗佐夫¹ 德尼斯·贝洛梅斯内^{1,2} 谢尔盖·萨姆松诺夫¹

摘要

生成流网络 (GFlowNets) 是一种通过有向图中的随机轨迹来采样结构化对象的框架。在本研究中，我们建立了非无环 GFlowNets 与最优传输 (OT) 之间的理论联系。我们证明，固定最小流 GFlowNets 的初始流分布会将其目标简化为具有由图诱导的最短路径成本的康托罗维奇 (Kantorovich) 最优传输问题。在最优情况下，所学的 GFlowNet 策略因此编码了从源分布到目标分布的最优传输计划：我们展示了从最小流 GFlowNet 中采样轨迹可以恢复相应的最优耦合。我们的公式使得可以通过边缘流和神经参数化将 GFlowNet 学习框架应用于大型图上的最优传输问题。实验结果证实了与精确最优传输求解器的一致性，并表明 GFlowNets 能够学习高质量的传输计划。

1. 引言

生成流网络 (GFlowNets, Bengio 等人, 2021 年) 是一类方法，用于根据未归一化的概率质量函数从概率分布中采样结构化离散对象。GFlowNet 通过前向策略诱导的随机转换顺序构建对象。GFlowNets 已在多种应用中成功使用，包括分子生成 (Bengio 等人, 2021 年; 沈等人, 2024 年; 科济亚尔斯基等人, 2024 年; 克雷图等人, 2025 年)、生物序列设计 (贾因等人, 2022 年; 金等人, 2024 年)、组合优化 (张等人, 2023a; b; 金等人, 2025 年) 以及大语言模型和扩散模型的微调 (胡等人, 2023 年; 文卡特拉曼等人, 2024 年; 上原等人, 2024 年; 张等人, 2025 年; 坤等人, 2024 年; 李等人, 2025 年; 朱等人, 2025 年)。GFlowNets 的理论基础在 (Bengio 等人, 2023 年; 拉卢等人, 2023 年) 中建立。

GFlowNet 定义了一个生成过程，该过程遵循一系列离散随机转换，从而诱导出一个图结构 $\mathcal{G}$ 。生成从一个特殊的初始状态开始 s_0 ，然后沿着图的边移动，直到到达一个特殊的终止状态 s_f 。最后的状态 x ，即过程从中转换进入的状态 s_f ，被视为最终样本。虽然 GFlowNet 最初是在无环图环境中开发的 (Bengio 等, 2021)，但后续工作将其推广到了非无环图 (Brunswic 等, 2024; Morozov 等, 2025)。在这种情况下，图中采样的轨迹的期望长度成为控制采样效率的关键量。为了在实践中有效最小化它，Brunswic 等 (2024) 和 Morozov 等 (2025) 提出了流正则化技术。此外，非无环 GFlowNet 最近被应用于采样领域之外的任务，例如模仿学习 (Brunswic 等, 2025a)、多智能体学习 (Brunswic 等, 2025b) 和最短路径问题 (Morozov 等, 2026)，进一步证明了框架的通用性。

另一方面，最优传输提供了一种通过考虑底层空间的几何和结构来比较概率分布的原则方法 (Villani, 2008; Peyr e & Cuturi, 2019)。中心对象是一个运输计划：一种耦合，规定了应从每个源点向每个目标点移动多少质量，同时最小化规定的运输成本。这种表述在机器学习中特别有吸引力，因为许多数据对象——图像、文档、点云、经验样本和学习表示可以自然地视为离散分布。与纯粹的点对点发散不同，最优传输距离仍然具有意义，并可以通过基础成本利用语义或几何结构。这导致了通过 Earth Mover’s Distance 进行图像检索 (Rubner 等, 2000)、通过 Word Mover’s Distance 进行自然语言处理 (Kusner 等, 2015)、领域自适应 (Courty 等, 2017) 以及通过 Wasserstein 目标进行生成建模 (Arjovsky 等, 2017) 的应用，还包括表示学习和基于重心的方法 (Tolstikhin 等, 2018; Agueh & Carlier, 2011)。

本文揭示了非无环 GFlowNet 的最小流公式与离散最优传输之间的联系。这一联系的主要思想是——

¹ 莫斯科国立高等经济学院 2 杜伊斯堡-埃森大学。通讯作者：伊恩·马克斯莫夫 < yavmaksimov@edu.hse.ru >




图 1. 在超网格环境中 GFlowNet 线性规划问题解和康托罗维奇最优传输最优计划的可视化。OT 诱导出最优耦合，连接源状态和目标状态，并表明它们之间转移了多少质量。另一方面，GFlowNet 构建了一个策略，从源状态开始采样目标状态，从而根据最短路径度量诱导出一个耦合。两种表述都实现了相同的传输成本 4.351。

该理论基于两个事实：1) 如果在初始状态转移概率上增加额外约束 s_0 ，GFlowNet 有效地诱导了两个概率分布之间的传输计划；2) 最小化总流量等价于最小化上述传输计划的图距离传输成本。这种等价性为 GFlowNet 学习问题提供了新颖的观点，并允许现有的大量 GFlowNet 学习算法应用于最优传输问题。

本文的主要贡献可以总结如下：

1. 我们展示了最小流非无环 GFlowNet 学习问题 (Morozov 等人, 2250 年) 可以等效地表述为一个线性规划问题。然后，我们理论上证明，在其中固定初始边流分布有效地将最小流目标转化为一个康托罗维奇最优传输问题，其中成本定义为图中的距离，这也等同于贝克曼问题的离散图基表述 (Beckmann, 1952 年; Essid & Solomon, 2018 年)。在此表述下的最优 GFlowNet 正向策略会采样初始分布与终端分布之间的最优路径，从而诱导出一个最优耦合。作为特殊情况，这一构造恢复了 Morozov 等人 (2026 年) 的最短路径理论。

2. 我们展示了 GFlowNet 学习框架提供了一种有效的方法来近似解决图上的最优传输问题。基于神经参数化，GFlowNet 目标允许学习一个旨在恢复最优耦合的策略。我们实验性地证明了该框架在可处理的情况下恢复精确 OT 解决方案的能力，以及其可扩展性，表现为随着增长能够高效地近似解决方案

组合空间中的精确解变得不可行。因此，我们扩展了 GFlowNet 框架的通用性，表明它延伸到了计算最优传输领域。

2. 背景

2.1. 非循环 GFlowNets

Brunswic et al. (2024) and Morozov et al. (2025) extend the theoretical construction of GFlowNets (Bengio et al., 2023) to non-acyclic environments. We use theory and notation of Morozov et al. (2025) which is summarized below as a starting point.

顺序采样过程由有向图 $\mathcal{G} = (\mathcal{S}, \mathcal{E})$ 描述，其中 $\mathcal{S}$ 是一个有限状态空间， $\mathcal{E} \subseteq \mathcal{S} \times \mathcal{S}$ 是一个有限边集（或转换）。我们将 s 记为 s 的子节点集，将 $\text{in}(s)$ 记为 s 的父节点集。

设 $\mathcal{T}$ 是从 s_0 到 s_f 的所有有限轨迹 $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_{n_\tau} \rightarrow s_f)$ 的集合，其中我们用 n_τ 表示轨迹 τ 的长度。我们遵循一个标准约定，即 $s_{n_\tau+1} = s_f$ 。如果最后一个转换是 $s \rightarrow s_f$ ，我们将说 τ 在 s 处终止。形式为 $(s \rightarrow s_f)$ 的边称为终止转换，具有指向 s_f 的出边的状态 s 称为终端状态。终端状态的集合记为 $\mathcal{X}$ ，感兴趣的概率分布 $\mathcal{R}(x)/\mathcal{Z}$ 在其上定义，其中 $\mathcal{R}(x) > 0$ 被称为 GFlowNet 奖励， $\mathcal{Z} = \sum_{x \in \mathcal{X}} \mathcal{R}(x)$ 是一个未知的归一化常数。

GFlowNet 本质上是一对双向策略，其中正向策略 $\mathcal{P}_F(s' | s)$ 是每个状态子节点上的分布，反向策略 $\mathcal{P}_B(s | s')$ 是每个状态父节点上的分布。GFlowNet 的训练方式是为了找到这样一对策略，使得它们诱导的轨迹分布一致：

$$\mathcal{P}(\tau) = \prod_{t=0}^{n_\tau} \mathcal{P}_F(s_{t+1} | s_t) = \prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t | s_{t+1}). \quad (1)$$

采样的主要目标是实现这样的 $\mathcal{P}$ 对于任意 $x \in \mathcal{X}$ ，概率为 $\tau \sim \mathcal{P}$ 终止于 x 一致于 $\mathcal{R}(x)/\mathcal{Z}$ 这一性质被称为奖励匹配条件，并关于 $\mathcal{P}_B$ 可以简单表示为

$$\mathcal{P}_B(x | s_f) = \mathcal{R}(x)/\mathcal{Z} \quad \forall x \in \mathcal{X}. \quad (2)$$

如果同时满足 (1) 和 (2)，则可以使用 $\mathcal{P}_F$ 从奖励分布中采样终端状态（参见 Bengio 等人 (2023) 和 Morozov 等人 (2025) 以获取更多细节）。

Morozov et al. (2025) defines state and edge flows through

某个状态预期访问次数

$$\begin{aligned}\mathcal{F}(s) &= \mathcal{Z} \cdot \mathbb{E}_{\tau \sim \mathcal{P}} \left[\sum_{t=0}^{n_\tau+1} \mathbb{I}\{s_t = s\} \right], \\ \mathcal{F}(s \rightarrow s') &= \mathcal{Z} \cdot \mathbb{E}_{\tau \sim \mathcal{P}} \left[\sum_{t=0}^{n_\tau} \mathbb{I}\{s_t = s, s_{t+1} = s'\} \right]\end{aligned}\quad (3)$$

根据定义，流函数满足以下条件（Morozov 等，2025 年提出的命题 3.6）：

$$\sum_{s \rightarrow s'} \mathcal{F}(s \rightarrow s') = \sum_{s'' \rightarrow s} \mathcal{F}(s'' \rightarrow s) \quad (4)$$

$\mathcal{F}(s_0) = \mathcal{F}(s_f) = \mathcal{Z}$. 主要问题在于将标准 GFlowNet 框架扩展到非有向无环图时， n_τ 是无界的，因为策略可以形成循环。 $\mathbb{E}[n_\tau]$ 精确表示了从目标分布中获取样本所需的平均轨迹长度，这同时也体现了采样的实用效率。因此，自然地提出了训练一个最小化 $\mathbb{E}[n_\tau]$ 的非有向无环图 GFlowNet 的问题。根据上述定义，可以验证预期轨迹长度与归一化的总流量相吻合 $\mathbb{E}[n_\tau] = \frac{1}{\mathcal{Z}} \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathcal{F}(s)$ ，因此 Morozov 等（2025 年）为学习具有最小 $\mathbb{E}[n_\tau]$ 的模型提供了理论基础，这相当于学习具有最小总流量的模型。

Morozov 等（2025 年；2026 年）将非有向无环图 GFlowNet 问题表述为以下约束优化问题。定义内部状态集合 $I := \mathcal{S} \setminus \{s_0, s_f\}$ ，然后：

$$\begin{aligned}\min_{\mathcal{F}, \mathcal{P}_F, \mathcal{P}_B} \quad & \sum_{s \in I} \mathcal{F}(s) \\ \text{s.t.} \quad & \mathcal{F}(s) \mathcal{P}_F(s' | s) = \mathcal{F}(s') \mathcal{P}_B(s | s'), \forall (s, s') \in \mathcal{E}, \\ & \mathcal{F}(s_f) \mathcal{P}_B(x | s_f) = \mathcal{R}(x), \quad x \in X.\end{aligned}\quad (5)$$

该约束 $\mathcal{F}(s) \mathcal{P}_F(s' | s) = \mathcal{F}(s') \mathcal{P}_B(s | s')$ is 被称为细致平衡条件。正如（Bengio 等，2023 年；Malkin 等，2022 年；Morozov 等，2025 年）所示，对于每一对相邻状态满足细致平衡等价于轨迹平衡条件（1）。

这个优化问题自然编码了训练 GFlowNet 所需的所有必要约束。等式约束满足方程 1 和 2，而目标是最小化总流量，这等同于最小化 $\mathbb{E}[n_\tau]$ ，正如 Morozov 等（2025 年）所述。

Brunswic 等（2024 年）提出的解决这个问题的最简单方法，并在 Morozov 等（2025 年）中进一步探讨，是在所使用的 GFlowNet 损失函数中添加 $\lambda \mathcal{F}_\theta(s)$ ，例如详细

平衡（Bengio 等人，2023 年）或轨迹平衡损失的变体（Madan 等人，2023 年；Malkin 等人，2022 年；Morozov 等人，2026 年），其中 λ 是一个正则化系数。

2.2. 康托罗维奇最优传输通过线性规划

虽然 GFlowNet 框架旨在从某个目标分布中采样 $\mathcal{R}(x)/\mathcal{Z}$ ，但最优传输问题则寻求两个给定源和目标分布之间的最优耦合，将概率质量从源分布移动到目标分布，根据定义的代价函数（Villani，2008 年）。

定义 2.1. 设 μ 和 ν 是在有限离散空间 $\mathcal{X}$ 和 $\mathcal{Y}$ 上的两个概率测度。一个耦合 Π 和 ν is a 的联合概率分布 Π 在空间 $\mathcal{X} \times \mathcal{Y}$ 上，满足如下条件：

$$\sum_{i=1}^n \Pi_{i,j} = \nu_j, \quad \sum_{j=1}^m \Pi_{i,j} = \mu_i$$

假设我们有两个有限状态集 $\{x_1, \dots, x_n\}$ 和 $\{y_1, \dots, y_m\}$ ，它们具有概率分布 μ, ν 。那么康托罗维奇最优传输问题可以表述如下：

$$\begin{aligned}\min_{\Pi \geq 0} \quad & \sum_{i,j=1}^{n,m} d(x_i, y_j) \Pi_{i,j} \\ \text{s.t.} \quad & \sum_i \Pi_{i,j} = \nu_j, \quad \sum_j \Pi_{i,j} = \mu_i.\end{aligned}\quad (6)$$

其中 $d(x_i, y_j)$ 是从 x_i 移动质量的一些代价。通常这 y_j 个线性规划问题可以通过经典方法如单纯形法（Dantzig，1951 年）来解决。

3. GFlowNets 与最优传输

考虑一个非无环的 GFlowNet 环境图 $\mathcal{G} = (\mathcal{S}, \mathcal{E})$ 。我们在图的结构上施加以下假设 $\mathcal{G}$ ，类似于 Essid & Solomon (2018) 中的做法：假设 3.1。• 存在一个特殊的初始状态 s_0 ，它没有入边；一个特殊的汇状态 s_f ，它没有出边；• 存在一组状态 U ，其中 X s.t. s_0 仅向 U 发出边，而 s_f 仅从 X ；接收边；• 任意两个状态 $u \in U$ 和 $x \in X$ ；之间存在有限长度的路径；• 给定两个分布在状态集上的分布 $\mathcal{L}(u)$ 和 $\mathcal{R}(x)$ ，分别定义在 U 和 X 上，即，

$$\sum_{u \in U} \mathcal{L}(u) = \sum_{x \in X} \mathcal{R}(x) = 1.$$

我们约定， $\mathcal{L}$ 和 $\mathcal{R}$ 在其支持范围之外扩展为零，并且定义在整个内部状态集 I 上。

接下来，定义代价函数 $d(u, x)$ 对于成对的 $u \in U$ 作为 $x \in X$

$$d(u, x) = |\tau_{u,x}|, \quad (7)$$

其中 $\tau_{u,x}$ 是从 u 到 x 的最短路径， $|\tau_{u,x}|$ 表示其长度。因此，可以考虑康托罗维奇最优传输问题 (6) 之间的分布 $\mathcal{L}$ 和 $\mathcal{R}$ ，使用代价函数 $d(u, x)$ ：

$$\begin{aligned} \min_{\Pi \geq 0} \quad & \sum_{i,j=1}^{n,m} d(u_i, x_j) \Pi_{i,j} \\ \text{s.t.} \quad & \sum_i \Pi_{i,j} = \mathcal{R}(x_j), \quad \sum_j \Pi_{i,j} = \mathcal{L}(u_i). \end{aligned} \quad (8)$$

其中 $\Pi \in \mathbb{R}_{\geq 0}^{n \times m}$ 是一个矩阵，定义了分布在 $\mathcal{L}(u)$ 上的 U 和分布在 $\mathcal{R}(x)$ 上的 X 之间的耦合。这里 $|U| = n$ ，和 $|X| = m$ 。值得注意的是，这种具有最短路径基础代价的图最优传输问题有一个经典的最小费用流形式化 (Essid & Solomon, 2018)。接下来我们将展示，在非无环 GFlowNets 中，一旦初始边流分布被固定，最小流目标精确地归结为此图 OT 问题。

3.1. 最小流 LP 形式化

我们从 GFlowNet 最小流问题 (5) 开始，该问题由 Morozov 等人 (2025) 引入。在 (5) 中的详细平衡约束是决策变量的双线性关系，因为

$$\mathcal{F}(s \rightarrow s') = \mathcal{F}(s) \mathcal{P}_F(s' | s) = \mathcal{F}(s') \mathcal{P}_B(s | s'). \quad (9)$$

当策略 $\mathcal{P}_F$ 和 $\mathcal{P}_B$ 被消除并替换为独立的状态流和边流变量后，问题变为线性的。我们现在将每个状态流 $\mathcal{F}(s), s \in \mathcal{S}$ ，和边流 $\mathcal{F}(s \rightarrow s'), s \rightarrow s' \in \mathcal{E}$ 视为独立变量。

在这种情况下，优化问题 (5) 中的细致平衡条件 (9) 可以用流匹配约束 (4) 替代，从而将 (5) 等价地重新表述为线性规划问题。我们在附录 A.1 中提供了这种等价性的证明。

我们固定在 U 上定义分布 $\mathcal{L}(u)$ ，将其称为 Leward (左侧奖励)。然后，我们类似地固定由基础 GFlowNet 诱导的第一步分布，类似于奖励匹配条件 (2)：

$$\mathcal{F}(s_0 \rightarrow u) = \mathcal{L}(u).$$

添加此约束后，扩展的 GFlowNet 线性

规划问题可以写作

$$\begin{aligned} \min_{\mathcal{F}(s), \mathcal{F}(s \rightarrow s')} \quad & \sum_{s \in I} \mathcal{F}(s) \\ \text{s.t.} \quad & \sum_{v \in \text{out}(s)} \mathcal{F}(s \rightarrow v) = \mathcal{F}(s), \quad s \in \mathcal{S} \setminus \{s_f\}, \\ & \sum_{u \in \text{in}(s)} \mathcal{F}(u \rightarrow s) = \mathcal{F}(s), \quad s \in \mathcal{S} \setminus \{s_0\}, \quad (10) \\ & \mathcal{F}(x \rightarrow s_f) = \mathcal{R}(x), \quad x \in X, \\ & \mathcal{F}(s_0 \rightarrow u) = \mathcal{L}(u), \quad u \in U, \\ & \mathcal{F}(s \rightarrow s') \geq 0, \quad (s, s') \in \mathcal{E}. \end{aligned}$$

从 GFlowNets 的理论构造来看，尚不清楚带有额外等式约束的问题是否有可行解。然而，我们进一步证明了一个解总是存在的 (定理 3.2) 扩展原问题可以通过省略流变量 $\mathcal{F}(s)$ 来简化。定义

$$E^\circ := \{s \rightarrow s' \in \mathcal{E} : s \neq s_0, s' \neq s_f\},$$

简化的原问题形式为：

$$\begin{aligned} \min_{\mathcal{F}(s \rightarrow s') \geq 0} \quad & \sum_{s \rightarrow s' \in E^\circ} \mathcal{F}(s \rightarrow s') \\ \text{s.t.} \quad & \sum_{v: s \rightarrow v \in E^\circ} \mathcal{F}(s \rightarrow v) \\ & - \sum_{u: u \rightarrow s \in E^\circ} \mathcal{F}(u \rightarrow s) = \mathcal{L}(s) - \mathcal{R}(s), \quad s \in I. \end{aligned} \quad (11)$$

请注意，在简化初始问题时，我们有关系

$$\begin{aligned} \sum_{s \in I} \mathcal{F}(s) &= \sum_{s_0 \rightarrow u} \mathcal{F}(s_0 \rightarrow u) + \sum_{s \rightarrow s' \in E^\circ} \mathcal{F}(s \rightarrow s') \\ &= 1 + \sum_{s \rightarrow s' \in E^\circ} \mathcal{F}(s \rightarrow s'). \end{aligned}$$

我们将忽略这个常数，因为它不会改变问题的最小值。

需要注意的是，如果将所有内部状态的流匹配约束相加，将会得到：

$$\sum_{x \in X} \mathcal{R}(x) = \sum_{u \in U} \mathcal{L}(u).$$

这个等式施加了一个质量平衡约束：两个函数要么具有相同的总质量，要么被归一化为概率分布。我们采用后者的形式，因为它消除了处理未知归一化常数的需要。这在理论分析和实用实现中都是有利的，在这些情况下，否则需要学习或估计该常数。相应地，我们在假设 3.1 中包含了这一条件。

3.2. GFlowNet-OT 等价性

我们现在准备建立康托罗维奇 OT 问题 (8) 与 GFlowNet 问题 (11) 之间的等价性。记 GFlow^* 为泛函 (11) 的最优值，记 OT^* 为康托罗维奇问题中泛函 (8) 的最优值。则有以下等价关系成立：

定理 3.2. 在假设 3.1 下，简化后的原问题 (11) 等价于康托罗维奇 (Kantorovich) 最优传输问题 (8)，即 $\mathcal{L}$ 上的 U 与 $\mathcal{R}$ 上的 X 之间的关系，也就是

$$\text{GFlow}^* = \text{OT}^*. \quad (12)$$

此外，如果 $\mathcal{P}^*$ 是由 GFlow^* 的解诱导的轨迹分布，它会在 (8) 中诱导一个最优耦合 $\Pi_{u,x}^* := \sum_{\tau: u \rightsquigarrow x} \mathcal{P}^*(\tau), u \in U, x \in X$ 。

证明。1. 假设我们给出一个最优耦合 $\Pi_{u,x}^*$ ，它是最小化问题 (8) 的解。 $\Pi_{u,x}^*$ 的存在性由 (Villani, 2008, p. 43) 中的定理 4.1 保证。我们按照 (11) 的意义构造一个可行流如下。对于每一个 $u \in U$ 和 $x \in X$ ，我们选择从 u 到 x 的一条任意最短路径 $\tau_{u,x}$ 。然后我们设定

$$\mathcal{F}(s \rightarrow s') = \sum_{u \in U} \sum_{x \in X} \Pi_{u,x}^* \cdot \mathbb{I}[s \rightarrow s' \in \tau_{u,x}]$$

我们检查此流的可行性。定义对于 $s \in I$ 、 $u \in U$ 和 $x \in X$ ，辅助函数

$$\Delta_s^{u,x} = \sum_{v: s \rightarrow v \in E} \mathbb{I}[s \rightarrow v \in \tau_{u,x}] - \sum_{v: v \rightarrow s \in E} \mathbb{I}[v \rightarrow s \in \tau_{u,x}].$$

由于 $\tau_{u,x}$ 是一个有向路径，它在起点只有出边，在终点只有入边，并且在每个中间节点的入边数与出边数相等。因此我们可以等价地写出

$$\Delta_s^{u,x} = \mathbb{I}[s = u] - \mathbb{I}[s = x]$$

令 $\Delta \mathcal{F}(s)$ 表示等式约束 (11) 左侧的部分。利用 $\Delta_{u,x}^{u,x}$ 、 $\Delta_s^{u,x} = \mathbb{I}[s = u] - \mathbb{I}[s = x]$ 以及 Π^* 的边际约束，我们得到

$$\begin{aligned} \Delta \mathcal{F}(s) &= \sum_{u \in U, x \in X} \Pi_{u,x}^* (\mathbb{I}[s = u] - \mathbb{I}[s = x]) \\ &= \sum_{u \in U} \mathbb{I}[s = u] \mathcal{L}(u) - \sum_{x \in X} \mathbb{I}[s = x] \mathcal{R}(x) \quad (13) \\ &= \mathcal{L}(s) - \mathcal{R}(s). \end{aligned}$$

上述方程表明了来自 (11) 的等式约束，因此我们已经验证所定义的流

是可行的，从而解集非空。现在我们计算 (11) 的值：

$$\begin{aligned} \sum_{s \rightarrow s' \in E^\circ} \mathcal{F}(s \rightarrow s') &= \sum_{\substack{s \rightarrow s' \in E^\circ \\ u \in U, x \in X}} \Pi_{u,x}^* \mathbb{I}[s \rightarrow s' \in \tau_{u,x}] \\ &= \sum_{u \in U, x \in X} \Pi_{u,x}^* \sum_{s \rightarrow s' \in E^\circ} \mathbb{I}[s \rightarrow s' \in \tau_{u,x}] \\ &= \sum_{u \in U, x \in X} \Pi_{u,x}^* |\tau_{u,x}|, \end{aligned} \quad (14)$$

其中 $|\tau_{u,x}|$ 是从 u 到 x 的路径长度。由于 $\tau_{u,x}$ 是最短路径， $|\tau_{u,x}| = d(u, x)$ ，并且

$$\sum_{s \rightarrow s' \in E^\circ} \mathcal{F}(s \rightarrow s') = \sum_{u, x} d(u, x) \Pi_{u,x}^*. \quad (15)$$

我们构造的流是可行的，但可能不是最优的。因此，我们得到不等式

$$\text{GFlow}^* \leq \text{OT}^*. \quad (16)$$

2. 注意在假设 3.1 下最优解存在，并且问题是有下界的。取问题 (11) 的最优解，并记为 $\mathcal{F}^*(s \rightarrow s')$ 。此流遵循 (A.1) 中建立的等价关系，这意味着我们现在可以引入前向策略：

$$\mathcal{P}_F^*(s' | s) = \mathcal{F}^*(s \rightarrow s') / \sum_{s \rightarrow s''} \mathcal{F}^*(s \rightarrow s'')$$

相应的轨迹上的概率 $\tau = (v_0 = s_0, v_1 \dots v_{n_\tau-1}, v_{n_\tau} = s_f)$ ：

$$\mathcal{P}^*(\tau) = \prod_{i=0}^{n_\tau} \mathcal{P}_F^*(v_{i+1} | v_i).$$

然后，Morozov 等人 (2025) 给出的定义 (3) 意味着

$$\mathcal{F}^*(s \rightarrow s') = \mathcal{Z} \sum_{\tau \in \mathcal{T}} \mathcal{P}^*(\tau) \sum_{t=0}^{n_\tau} \mathbb{I}[s_t = s, s_{t+1} = s'].$$

假设 3.1 表明 $\mathcal{Z} = 1$ ，因此我们在后续推导中省略它。现在定义联合分布 Π 在 $U \times X$ 上通过

$$\Pi_{u,x} := \sum_{\tau: u \rightsquigarrow x} \mathcal{P}^*(\tau), \quad u \in U, \quad x \in X.$$

显然

$$\begin{aligned} \sum_{x \in X} \Pi_{u,x} &= \sum_{x \rightarrow s_f} \sum_{\tau: u \rightsquigarrow x} \mathcal{P}^*(\tau) \\ &= \sum_{\tau \ni s_0 \rightarrow u} \mathcal{P}^*(\tau) = \mathcal{P}_F^*(u | s_0) = \mathcal{L}(u), \end{aligned}$$

同样地

$$\sum_{u \in U} \Pi_{u,x} = \mathcal{R}(x).$$

因此，上述定义的联合分布 Π 是 $\mathcal{R}(x)$ 和 $\mathcal{L}(u)$ 的一个耦合。让我们写出原问题的值，使用我们的流：

$$\begin{aligned} \text{GFlow}^* &= \sum_{s \rightarrow s' \in E^\circ} \mathcal{F}^*(s \rightarrow s') \\ &= \sum_{s \rightarrow s' \in E^\circ} \sum_{\tau} \mathcal{P}^*(\tau) \sum_{t=0}^{n_\tau} \mathbb{I}[s_t = s, s_{t+1} = s'] \\ &= \sum_{\tau} \mathcal{P}^*(\tau) \sum_{s \rightarrow s' \in E^\circ} \sum_{t=0}^{n_\tau} \mathbb{I}[s_t = s, s_{t+1} = s'] \\ &= \sum_{\tau} |\tau| \mathcal{P}^*(\tau). \end{aligned} \quad (17)$$

回忆一下 $|\tau_{u,x}| \geq d(u, x)$ ，因为 $d(u, x)$ 是最短路径的长度。因此：

$$\begin{aligned} \sum_{\tau} |\tau| \mathcal{P}^*(\tau) &= \sum_{s_0 \rightarrow u} \sum_{x \rightarrow s_f} \sum_{\tau: u \rightsquigarrow x} |\tau| \mathcal{P}^*(\tau) \\ &\geq \sum_{s_0 \rightarrow u} \sum_{x \rightarrow s_f} \sum_{\tau: u \rightsquigarrow x} d(u, x) \mathcal{P}^*(\tau) \\ &= \sum_{s_0 \rightarrow u} \sum_{x \rightarrow s_f} d(u, x) \sum_{\tau: u \rightsquigarrow x} \mathcal{P}^*(\tau) \\ &= \sum_{u \in U} \sum_{x \in X} d(u, x) \Pi_{u,x}. \end{aligned} \quad (18)$$

因此，我们构造了一个耦合 Π 使得

$$\text{GFlow}^* \geq \sum_{u \in U} \sum_{x \in X} d(u, x) \Pi_{u,x}.$$

对于最优耦合 Π^* ，因此有

$$\text{GFlow}^* \geq \text{OT}^*. \quad (19)$$

结合 (16) 和 (19)，我们得出 GFlow 最优值与 OT 最优值相同，因此证明了 (12)。□

该定理给出了将 GFlowNet 作为一种隐式方法来解决康托罗维奇最优传输的特征，作为推论，我们得到了对偶等价性，这本质上源于线性规划优化问题的严格对偶性。关于 OT 泛函的 GFlowNet 问题的对偶详细推导可以在附录 A.4 找到。

此外，在适当的结构假设下，最优传输问题可以简化为最短路径问题。我们展示了，在这种情况下，非无环 GFlowNet 隐式恢复这样的最短路径解。结果正式陈述如下。

定理 3.3. 考虑原问题 (10) 的对偶问题，不包括第一步条件。

$$\begin{aligned} \max_{\pi} \quad & \sum_{x \in X} \mathcal{R}(x) \pi_x \\ \text{s.t.} \quad & \pi_{s_0} = 0, \\ & \pi_{s'} - \pi_s \leq 1, \quad \forall (s \rightarrow s') \text{ 含 } s' \neq s_f. \end{aligned}$$

那么：1. 每个可行解 π 满足： $\pi_s \leq d(s) \quad \forall s \neq s_f$ ；2. 函数 $d(\cdot) = |\tau_{s_0, \cdot}|$ 是一个可行的对偶解，并且它是对偶最优的；如果 $\mathcal{R}(x) > 0$ 对于每个 $x \in X$ ，则每个最优解 π^* 满足： $\pi_x^* = d(x) \quad \forall x \in X$ 。

此外，最优解中的互补松弛条件给出了以下关系：

$$\mathcal{F}^*(s \rightarrow s')(\pi_{s'}^* - (1 + \pi_s^*)) = 0$$

这也是原始对偶间隙。

互补松弛条件提供了最优流的特征：它只能在紧子图上非零，其中 $(\pi_{s'}^* - (1 + \pi_s^*)) = 0$ 。由于 π_x^* 与最短路径度量一致，因此流只能支持在最短路径的子图上。这恢复了 Morozov 等人（2026 年）的相关主张。定理 3.3 的详细证明可以在附录 A.5 中找到。

3.3. 基于学习的算法

为了使用神经网络近似求解 (11)，我们采用了非循环 GFlowNet 训练方法论。虽然可以应用各种现有的 GFlowNet 损失函数和流正则化来训练模型（Brunswic 等，2024；Morozov 等，2024），但 Morozov 等（2026 年）最近展示了轨迹平衡（TB）目标（Malkin 等，2022）对于训练非循环 GFlowNets 在路径寻找问题中的有效性，我们也发现这种方法在我们的设置中最合适。

对于图中的每个状态，模型预测向前和向后策略的转移概率 $\mathcal{P}_F$ 和 $\mathcal{P}_B$ 。在训练过程中，我们使用向前策略采样一批轨迹 $\mathcal{P}_F$ ，并计算正则化的 TB 目标：

$$\begin{aligned} \mathcal{L}_{\text{TB}}(\theta, \tau) &= \left(\log \frac{\mathcal{L}(s_1) \prod_{t=1}^{n_\tau} \mathcal{P}_F(s_{t+1} | s_t, \theta)}{\mathcal{R}(s_{n_\tau}) \prod_{t=0}^{n_\tau-1} \mathcal{P}_B(s_t | s_{t+1}, \theta)} \right)^2 \\ &\quad + \lambda \frac{\mathcal{R}(s_{n_\tau})}{\mathcal{P}_F(s_f | s_{n_\tau}, \theta)}. \end{aligned} \quad (20)$$

与通常的 TB 目标不同的是，由于 (11) 中初始分布的附加条件，出现了 leward $\mathcal{L}$ 。就策略而言，奖励

表 1. 方法在 Hypergrid 环境中的比较。 $\mathbb{E}|\tau|$ TV 是从模型和真实分布中抽取样本的经验总变差距离， TV^* 是通过完美抽样器获得的总变差， $\mathbb{E}|\tau|$ 是学习抽样器的平均轨迹长度，而 OT^* 是通过 POT 求解器 (Flamary 等, 2021) 获得的最佳 OT 成本。

H	$\mathcal{L} = \text{Ball}$				$\mathcal{L} = \text{Moon}$			
	$\widehat{\text{TV}} \downarrow$	$\text{TV}^* \downarrow$	$\mathbb{E} \tau $	OT^*	$\widehat{\text{TV}} \downarrow$	$\text{TV}^* \downarrow$	$\mathbb{E} \tau $	OT^*
10	0.024 ± 0.0004	0.024	3.990 ± 0.015	3.997	0.022 ± 0.018	0.024	4.352 ± 0.015	4.351
15	0.036 ± 0.0009	0.033	6.325 ± 0.011	6.303	0.023 ± 0.006	0.033	6.907 ± 0.010	6.868
20	0.037 ± 0.0006	0.040	8.326 ± 0.021	8.325	0.032 ± 0.008	0.040	9.001 ± 0.112	9.059

表 2. 在置换环境上通过消融 λ 获得的结果。参考 OT^* 成本通过 POT 求解器 (Flamary 等, 2021) 获得，对于 $n = 4$ 是 **0.567**，对于 $n = 8$ 是 **1.008**，对于更大的置换 OT^* 是不可处理的。 $C(k)L^1$ 是模型获得的固定点概率与真实概率之间的经验 L_1 误差。(Morozov 等, 2025) $\mathbb{E}|\tau|$ 是预期轨迹长度。所有结果都是基于 3 个种子平均得到的。

λ	$n = 4$		$n = 8$		$n = 20$	
	$C(k)L^1 \downarrow$	$\mathbb{E} \tau $	$C(k)L^1 \downarrow$	$\mathbb{E} \tau $	$C(k)L^1 \downarrow$	$\mathbb{E} \tau $
$\lambda = 10^{-1}$	0.012 ± 0.001	0.445 ± 0.002	0.011 ± 0.005	0.645 ± 0.013	0.016 ± 0.000	2.313 ± 0.018
$\lambda = 10^{-2}$	0.002 ± 0.000	0.557 ± 0.001	0.001 ± 0.002	1.010 ± 0.011	0.002 ± 0.000	4.436 ± 0.014

匹配可以表示为 $\mathcal{P}_B(s | s_f) = \mathcal{R}(s)$ ，而 leward 匹配为 $\mathcal{P}_F(s | s_0) = \mathcal{L}(s)$ ，这解释了损失函数 (20) 的形式。正则化项 $\lambda \mathcal{R}(s) / \mathcal{P}_F(s_f | s)$ 对应于终端状态的状态流 $\mathcal{F}(s)$ ，这是由于奖励匹配条件 (5)。Morozov 等 (2026) 还表明，如果内部状态 $\mathcal{G}$ 中的每个状态都是终端状态，即 $\mathcal{X} = I$ ，目标 (20) 可以在采样的轨迹的每个前缀上计算，从而实现更有效的样本方法。我们在实验中利用了这一选项。

4. 实验

在本节中，我们通过实验评估所提出的基于 GFlowNet 的方法来解决图 OT 任务。我们考虑的任务基于 Brunswic 等 (2024); Morozov 等 (2025) 研究的环境。在一个较小的超网格任务上，我们实证地证明了 GFlowNet LP 公式 (11) 的确切解等同于康托罗维奇 OT 公式 (8)，并且可以通过精确的 LP 求解器和第 3.3 节描述的学习型神经网络近似获得。然后，我们在更大规模的置换环境中验证我们的学习方法。特别是，我们恢复了长度为 $n = 4$ 和 $n = 8$ 的置换的最优 OT 解，并展示了对 $n = 20$ 的收敛性。最后，我们消融了状态流正则化参数 λ 的影响，说明其对方法达到的最优值的影响。

4.1. 超网格

我们在 Brunswic 等 (2024) 提出的非循环超网格环境上的 OT 任务中评估我们的方法。

由于这些环境仍然足够小，可以进行精确的 LP 优化，它们允许直接比较学习到的抽样器和最优 OT 解。更多细节请参见附录 B.1。

状态为格点上的点，在 $\{0, \dots, H-1\}^D$ 的基础上增加了源状态和终端状态 s_0, s_f 。采样从 U 开始，分布为 $\mathcal{L}$ ，并且每次转移仅修改一个坐标值，同时保持在网格内。每个状态也允许向 ± 1 进行终止转移 s_f 。我们假设奖励 $\mathcal{L}$ 可以进行有效的采样，并专注于测量两个量：1) 训练模型的平均运输成本是多少 2) 模型采样的终端状态分布与奖励分布的接近程度 $\mathcal{R}$ 。

我们考虑多模态奖励，其中模式位于网格角落附近 (Bengio 等, 2021 年)，并使用月牙形和球形奖励分布。采样质量通过奖励分布与模型样本的经验证布之间的总变差距离来衡量。 $2 \cdot 10^5$ 表 1 报告了结果 $\mathbb{E}|\tau|$ TV，并将其与完美抽样器参考值 TV^* 进行比较（该值非零是因为考虑了经验分布），同时通过平均轨迹长度评估了收敛到 OT 最优值的情况 OT^* 。可以看出，我们的学习策略在所有选定的奖励分布和所有超网格边上的采样过程中均无偏地恢复了最优值 OT^* 。所有结果都是基于三个种子的平均值。

图 1 进一步可视化了 Moon 的 OT 解决方案对于 $H = 10$ 和 $\mathcal{L} =$ ，以及等价 GFlowNet LP 公式 (11) 的精确解，该解是通过 scipy.linprog 求解器 (Virtanen 等, 2020 年) 获得的。

4.2. 排列

接下来，我们考虑由对称群的凯莱图诱导的环境 S_n ，该群是对 n 个元素进行排列的群 $1, 2, \dots, n$ ，这一构想来源于 Morozov 等人 (2025) 的研究。每个内部状态 $s \in \mathcal{S} \setminus s_0, s_f$ 对应一个固定长度的排列， $(s(1), \dots, s(n))$ ，转换由相邻置换定义：从给定的状态出发，可以交换两个相邻的条目 $s(k)$ 和 $s(k+1)$ 。我们取 $\mathcal{L}$ 为所有排列上的均匀分布，并将奖励分布设为 $\mathcal{R}(s) = \frac{\exp(\frac{1}{2} \sum_{k=1}^n \mathbb{1}\{s(k) = k\})}{\sum_{\pi \in \mathcal{S}} \exp(\frac{1}{2} \sum_{k=1}^n \mathbb{1}\{\pi(k) = k\})}$ (Morozov 等人, 2025 年) 推导出了它的归一化常数的闭式表达式。我们采用了 Morozov 等人 (2025 年) 的诊断协议；关于相应度量的详细描述见附录 B.2。表 2 报告了排列环境的结果，测量了奖励采样的质量和运输成本，类似于第 4.1 节。所有结果都是基于三个随机种子的平均值。

对于较小的置换规模，如 $n = 4$ 和 $n = 8$ ，我们的方法能够恢复接近最优的解，平均轨迹长度几乎等于 OT^* 。对于较大的置换，如 $n = 20$ ，计算精确的最优传输解已不再可行；然而，我们的方法仍能生成合理的近似解。我们进一步消融了状态流正则化系数 λ 的影响。与 Morozov 等人 (2025) 一致，我们观察到 λ 控制着学习采样器的轨迹长度与采样最优性之间的权衡。更大的 λ 会使采样产生偏差但减少轨迹长度，相反，较低的值会诱导准确的采样但产生较长的轨迹。

5. 结论

本文扩展了非循环 GFlowNets 的理论框架，通过建立与图上的最优传输的等价关系。与仅学习耦合的标准 OT 方法不同，我们的框架学习了一个随机策略，该策略通过可行的局部移动将样本运输到具有接近最优预期路径成本的位置，从而解决了运输发生的位置和方式。我们还提供了 Morozov 等人 (2026) 提出的 GFlowNets 最短路径形式的新解释。定理 3.2 所建立的等价关系开启了几个有前景的方向，包括反向策略优化算法 (Jang 等人, 2024; Gritsaev 等人, 2025) 以及由 GFlowNets 与熵正则化 RL 连接所激发的强化学习技术 (Tiapkin 等人, 2024; Deleu 等人, 2024; Mohammadpour 等人, 2024; Lau 等人, 2024; Morozov 等人, 2024; He 等人, 2025)。未来的工作还可以解决实验评估中突出的实际挑战。尽管提供了一种计算效率高的训练方法，但非循环 GFlowNets 包含了 reg-

正则化系数 λ 需要仔细调整以平衡最优传输和采样的质量。此外，现有的 GFlowNet 方法论可能被应用于学习未归一化概率分布之间的传输映射。

致谢

本研究部分得到了 HSE 大学高性能计算设施 (Kostenetskiy 等人, 2021) 的计算资源支持。感谢 FORTUNA 812 的灵感音乐，在此研究期间使我们保持清醒。

参考文献

- Agueh, M. and Carlier, G. Barycenters in the wasserstein space. *SIAM Journal on Mathematical Analysis*, 43(2): 904–924, 2011.
- Arjovsky, M., Chintala, S., and Bottou, L. Wasserstein generative adversarial networks. In *Proceedings of the 34th International Conference on Machine Learning*, pp. 214–223, 2017.
- Beckmann, M. A continuous model of transportation. *Econometrica: Journal of the Econometric Society*, pp. 643–660, 1952.
- Bengio, E., Jain, M., Korablyov, M., Precup, D., and Bengio, Y. Flow network based generative models for non-iterative diverse candidate generation. *Advances in Neural Information Processing Systems*, 34:27381–27394, 2021.
- Bengio, Y., Lahlou, S., Deleu, T., Hu, E. J., Tiwari, M., and Bengio, E. Gflownet foundations. *Journal of Machine Learning Research*, 24(210):1–55, 2023.
- Brunswic, L., Li, Y., Xu, Y., Feng, Y., Jui, S., and Ma, L. A theory of non-acyclic generative flow networks. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pp. 11124–11131, 2024.
- Brunswic, L. M., Cl  mente, M., Yang, R. H., Sigal, A., Rasouli, A., and Li, Y. Ergodic generative flows. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pp. 5649–5668. PMLR, 2025a.
- Brunswic, L. M., Wang, H., Luo, S., Hao, J., Rasouli, A., and Li, Y. A theory of multi-agent generative flow networks. *arXiv preprint arXiv:2509.20408*, 2025b.
- Courty, N., Flamary, R., Tuia, D., and Rakotomamonjy, A. Optimal transport for domain adaptation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(9):1853–1865, 2017.

- Cretu, M., Harris, C., Igashov, I., Schneuing, A., Segler, M., Correia, B., Roy, J., Bengio, E., and Lio, P. SynFlowNet: Design of diverse and novel molecules with synthesis constraints. In *The Thirteenth International Conference on Learning Representations*, 2025.
- Dantzig, G. B. Maximization of a linear function of variables subject to linear inequalities. In Koopmans, T. C. (ed.), *Activity Analysis of Production and Allocation*, pp. 339–347. John Wiley & Sons, New York, 1951.
- Deleu, T., Nouri, P., Malkin, N., Precup, D., and Bengio, Y. Discrete probabilistic inference as control in multi-path environments. In *The 40th Conference on Uncertainty in Artificial Intelligence*, 2024.
- Essid, M. and Solomon, J. Quadratically regularized optimal transport on graphs. *SIAM Journal on Scientific Computing*, 40(4):A1961–A1986, 2018. doi: 10.1137/17M1132665. URL <https://epubs.siam.org/doi/10.1137/17M1132665>.
- Flamary, R., Courty, N., Gramfort, A., Alaya, M. Z., Boissunon, A., Chambon, S., Chapel, L., Corenflos, A., Fatras, K., Fournier, N., Gautheron, L., Gayraud, N. T. H., Janati, H., Rakotomamonjy, A., Redko, I., Rolet, A., Schutz, A., Seguy, V., Sutherland, D. J., Tavenard, R., Tong, A., and Vayer, T. Pot: Python optimal transport. *Journal of Machine Learning Research*, 22(78):1–8, 2021.
- Gritsaev, T., Morozov, N., Samsonov, S., and Tiapkin, D. Optimizing backward policies in GFlowNets via trajectory likelihood maximization. In *The Thirteenth International Conference on Learning Representations*, 2025.
- He, H., Bengio, E., Cai, Q., and Pan, L. Random policy evaluation uncovers policies of generative flow networks. In *International Conference on Machine Learning*, pp. 22351–22367. PMLR, 2025.
- Hu, E. J., Jain, M., Elmoznino, E., Kaddar, Y., Lajoie, G., Bengio, Y., and Malkin, N. Amortizing intractable inference in large language models. In *The Twelfth International Conference on Learning Representations*, 2023.
- Jain, M., Bengio, E., Hernandez-Garcia, A., Rector-Brooks, J., Dossou, B. F., Ekbote, C. A., Fu, J., Zhang, T., Kilgour, M., Zhang, D., et al. Biological sequence design with gflowNets. In *International Conference on Machine Learning*, pp. 9786–9801. PMLR, 2022.
- Jang, H., Jang, Y., Kim, M., Park, J., and Ahn, S. Pessimistic backward policy for GFlowNets. In *Advances in Neural Information Processing Systems*, volume 37, pp. 107087–107111, 2024.
- Kim, H., Kim, M., Yun, T., Choi, S., Bengio, E., Hernández-García, A., and Park, J. Improved off-policy reinforcement learning in biological sequence design. *arXiv preprint arXiv:2410.04461*, 2024.
- Kim, M., Choi, S., Kim, H., Son, J., Park, J., and Bengio, Y. Ant colony sampling with GFlowNets for combinatorial optimization. In *International Conference on Artificial Intelligence and Statistics*. PMLR, 2025.
- Kostenetskiy, P., Chulkevich, R., and Kozyrev, V. Hpc resources of the higher school of economics. In *Journal of Physics: Conference Series*, volume 1740, pp. 012050. IOP Publishing, 2021.
- Koziarski, M., Rekesh, A., Shevchuk, D., van der Sloot, A., Gaiński, P., Bengio, Y., Liu, C., Tyers, M., and Batey, R. Rgfn: Synthesizable molecular generation using gflowNets. *Advances in Neural Information Processing Systems*, 37:46908–46955, 2024.
- Kusner, M. J., Sun, Y., Kolkin, N. I., and Weinberger, K. Q. From word embeddings to document distances. In *Proceedings of the 32nd International Conference on Machine Learning*, pp. 957–966, 2015.
- Kwon, O. J., Matsunaga, D. E., and Kim, K.-E. Gdpo: Learning to directly align language models with diversity using gflowNets. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pp. 17120–17139, 2024.
- Lahlou, S., Deleu, T., Lemos, P., Zhang, D., Volokhova, A., Hernández-García, A., Ezzine, L. N., Bengio, Y., and Malkin, N. A theory of continuous generative flow networks. In *International Conference on Machine Learning*, pp. 18269–18300. PMLR, 2023.
- Lau, E., Lu, S., Pan, L., Precup, D., and Bengio, E. Qgfn: Controllable greediness with action values. *Advances in neural information processing systems*, 37:81645–81676, 2024.
- Lee, S., Kim, M., Cherif, L., Dobre, D., Lee, J., Hwang, S. J., Kawaguchi, K., Gidel, G., Bengio, Y., Malkin, N., and Jain, M. Learning diverse attacks on large language models for robust red-teaming and safety tuning. In *The Thirteenth International Conference on Learning Representations*, 2025.
- Madan, K., Rector-Brooks, J., Korablyov, M., Bengio, E., Jain, M., Nica, A. C., Bosc, T., Bengio, Y., and Malkin, N. Learning gflowNets from partial episodes for improved convergence and stability. In *International Conference on Machine Learning*, pp. 23467–23483. PMLR, 2023.

- Malkin, N., Jain, M., Bengio, E., Sun, C., and Bengio, Y. Trajectory balance: Improved credit assignment in gflownets. *Advances in Neural Information Processing Systems*, 35:5955–5967, 2022.
- Mohammadpour, S., Bengio, E., Frejinger, E., and Bacon, P.-L. Maximum entropy gflownets with soft q-learning. In *International Conference on Artificial Intelligence and Statistics*, pp. 2593–2601. PMLR, 2024.
- Morozov, N., Tiapkin, D., Samsonov, S., Naumov, A., and Vetrov, D. Improving gflownets with monte carlo tree search. *arXiv preprint arXiv:2406.13655*, 2024.
- Morozov, N., Maksimov, I., Tiapkin, D., and Samsonov, S. Revisiting non-acyclic GFlowNets in discrete environments. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pp. 44887–44910. PMLR, 2025.
- Morozov, N., Maksimov, I., Tiapkin, D., and Samsonov, S. Learning shortest paths with generative flow networks. *arXiv preprint arXiv:2603.01786*, 2026.
- Peyré, G. and Cuturi, M. *Computational optimal transport: With applications to data science*. Now Foundations and Trends, 2019.
- Rubner, Y., Tomasi, C., and Guibas, L. J. The earth mover’s distance as a metric for image retrieval. *International Journal of Computer Vision*, 40(2):99–121, 2000.
- Shen, T., Seo, S., Lee, G., Pandey, M., Smith, J. R., Cherkasov, A., Kim, W. Y., and Ester, M. TacoGFN: Target-conditioned GFlowNet for structure-based drug design. *Transactions on Machine Learning Research*, 2024. ISSN 2835-8856.
- Tiapkin, D., Morozov, N., Naumov, A., and Vetrov, D. P. Generative flow networks as entropy-regularized rl. In *International Conference on Artificial Intelligence and Statistics*, pp. 4213–4221. PMLR, 2024.
- Tolstikhin, I., Bousquet, O., Gelly, S., and Schoelkopf, B. Wasserstein auto-encoders. In *International Conference on Learning Representations*, 2018. URL <https://openreview.net/forum?id=HkL7n1-0b>.
- Uehara, M., Zhao, Y., Biancalani, T., and Levine, S. Understanding reinforcement learning-based fine-tuning of diffusion models: A tutorial and review. *arXiv preprint arXiv:2407.13734*, 2024.
- Venkatraman, S., Jain, M., Scimeca, L., Kim, M., Sendera, M., Hasan, M., Rowe, L., Mittal, S., Lemos, P., Bengio, E., Adam, A., Rector-Brooks, J., Bengio, Y., Berseth, G., and Malkin, N. Amortizing intractable inference in diffusion models for vision, language, and control. *Neural Information Processing Systems (NeurIPS)*, 2024.
- Villani, C. *Optimal Transport: Old and New*. Grundlehren der mathematischen Wissenschaften. Springer Berlin Heidelberg, 2008. ISBN 9783540710493. URL <https://books.google.ru/books?id=NZXiNAEACAAJ>.
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., Carey, C. J., Polat, İ., Feng, Y., Moore, E. W., VanderPlas, J., Laxalde, D., Perktold, J., Cimrman, R., Henriksen, I., Quintero, E. A., Harris, C. R., Archibald, A. M., Ribeiro, A. H., Pedregosa, F., van Mulbregt, P., and SciPy 1.0 Contributors. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17:261–272, 2020. doi: 10.1038/s41592-019-0686-2.
- Zhang, D., Dai, H., Malkin, N., Courville, A. C., Bengio, Y., and Pan, L. Let the flows tell: Solving graph combinatorial problems with gflownets. In *Advances in Neural Information Processing Systems*, volume 36, pp. 11952–11969, 2023a.
- Zhang, D., Zhang, Y., Gu, J., Zhang, R., Susskind, J. M., Jaitly, N., and Zhai, S. Improving gflownets for text-to-image diffusion alignment. *Transactions on Machine Learning Research*, 2025. ISSN 2835-8856.
- Zhang, D. W., Rainone, C., Peschl, M., and Bondesan, R. Robust scheduling with gflownets. In *The Eleventh International Conference on Learning Representations*, 2023b.
- Zhu, X., Cheng, D., Zhang, D., Li, H., Zhang, K., Jiang, C., Sun, Y., Hua, E., Zuo, Y., Lv, X., et al. Flowrl: Matching reward distributions for llm reasoning. *arXiv preprint arXiv:2509.15207*, 2025.

A. 完整的理论结果

A.1. 线性规划形式的正确性

考虑原始最小流形式 (5)，我们将证明它可以被重新表述为线性规划问题。

$$\begin{aligned}
 & \min_{\mathcal{F}, \mathcal{P}_F, \mathcal{P}_B} \sum_{s \in I} \mathcal{F}(s) \\
 & \text{s.t. } \mathcal{F}(s) \mathcal{P}_F(s' | s) = \mathcal{F}(s') \mathcal{P}_B(s | s'), \\
 & \quad s \rightarrow s' \in \mathcal{E}, \\
 & \quad \mathcal{F}(s_f) \mathcal{P}_B(x | s_f) = \mathcal{R}(x), \quad x \in X.
 \end{aligned} \tag{21}$$

命题 A.1 (消除前向策略)。固定 $s \neq s_f$ 。以下两者等价：

1. 存在一个概率分布 $\mathcal{P}_F(\cdot | s) \in \Delta(\text{out}(s))$ 使得

$$\mathcal{F}(s \rightarrow v) = \mathcal{F}(s) \mathcal{P}_F(v | s), \quad \forall v \in \text{out}(s).$$

2. 变量 $\mathcal{F}(s \rightarrow v)$ 满足线性条件

$$\mathcal{F}(s \rightarrow v) \geq 0 \quad \forall v \in \text{out}(s), \quad \sum_{v \in \text{out}(s)} \mathcal{F}(s \rightarrow v) = \mathcal{F}(s).$$

证明。假设 (i) 成立。由于 $\mathcal{P}_F(\cdot | s)$ 是一个概率分布，

$$\sum_{v \in \text{out}(s)} \mathcal{F}(s \rightarrow v) = \sum_{v \in \text{out}(s)} \mathcal{F}(s) \mathcal{P}_F(v | s) = \mathcal{F}(s) \sum_{v \in \text{out}(s)} \mathcal{P}_F(v | s) = \mathcal{F}(s),$$

and clearly $\mathcal{F}(s \rightarrow v) \geq 0$ for all v .

Now assume (ii). If $\mathcal{F}(s) > 0$, define

$$\mathcal{P}_F(v | s) := \frac{\mathcal{F}(s \rightarrow v)}{\mathcal{F}(s)}, \quad v \in \text{out}(s).$$

Then $\mathcal{P}_F(v | s) \geq 0$ 及

$$\sum_{v \in \text{out}(s)} \mathcal{P}_F(v | s) = \frac{1}{\mathcal{F}(s)} \sum_{v \in \text{out}(s)} \mathcal{F}(s \rightarrow v) = 1.$$

Hence $\mathcal{P}_F(\cdot | s) \in \Delta(\text{out}(s))$, and by construction

$$\mathcal{F}(s \rightarrow v) = \mathcal{F}(s) \mathcal{P}_F(v | s).$$

If $\mathcal{F}(s) = 0$, then $\sum_v \mathcal{F}(s \rightarrow v) = 0$ 及 $\mathcal{F}(s \rightarrow v) \geq 0$ imply $\mathcal{F}(s \rightarrow v) = 0$ 对所有的 v , so any choice of $\mathcal{P}_F(\cdot | s) \in \Delta(\text{out}(s))$ works. $\square$

命题 A.2 (消除反向策略)。固定 $s' \neq s_0$ 。下列条件是等价的：

1. 存在一个概率分布 $\mathcal{P}_B(\cdot | s') \in \Delta(\text{in}(s'))$ 中使得

$$\mathcal{F}(u \rightarrow s') = \mathcal{F}(s') \mathcal{P}_B(u | s'), \quad \forall u \in \text{in}(s').$$

2. 变量 $\mathcal{F}(u \rightarrow s')$ 满足线性条件

$$\mathcal{F}(u \rightarrow s') \geq 0 \quad \forall u \in \text{in}(s'), \quad \sum_{u \in \text{in}(s')} \mathcal{F}(u \rightarrow s') = \mathcal{F}(s').$$

证明. 该证明与前一个证明相同, 只是将入边替换为出边。 $\square$

推论 A.3 (提升的线性规划). 在消除了 $\mathcal{P}_F$ 和 $\mathcal{P}_B$ 之后, 最小总流量问题变为

$$\begin{aligned}
 (\text{P}) \quad & \min_{\mathcal{F}(s), \mathcal{F}(s \rightarrow s')} \sum_{s \in I} \mathcal{F}(s) \\
 \text{s.t.} \quad & \sum_{v \in \text{out}(s)} \mathcal{F}(s \rightarrow v) = \mathcal{F}(s), \quad \forall s \in S \setminus \{s_f\}, \\
 & \sum_{u \in \text{in}(s)} \mathcal{F}(u \rightarrow s) = \mathcal{F}(s), \quad \forall s \in S \setminus \{s_0\}, \\
 & \mathcal{F}(x \rightarrow s_f) = \mathcal{R}(x), \quad \forall x \in X, \\
 & \mathcal{F}(s \rightarrow s') \geq 0, \quad \forall (s, s') \in E.
 \end{aligned}$$

这是一个线性规划。

证明. 目标函数在 $(\mathcal{F}(s), \mathcal{F}(s \rightarrow s'))$ 中是线性的, 并且所有约束都是仿射的。 $\square$

附录 A.2 对偶性证明

为了方便表示, 定义成本向量 c 为

$$c_s := \begin{cases} 1, & s \in I, \\ 0, & s \in \{s_0, s_f\}. \end{cases}$$

那么原始目标函数是

$$c^\top \mathcal{F} = \sum_{s \in I} \mathcal{F}(s).$$

引入对偶变量:

- $\alpha_s \in$ 用于流出流量约束, $s \in S \setminus \{s_f\}$;
- $\beta_s \in$ 用于流入流量约束, $s \in S \setminus \{s_0\}$;
- $\eta_x \in$ 用于终端约束, $x \in X$ 。

We also define padded vectors $\bar{\alpha}, \bar{\beta}$ by

$$\bar{\alpha}_s := \begin{cases} \alpha_s, & s \neq s_f, \\ 0, & s = s_f, \end{cases} \quad \bar{\beta}_s := \begin{cases} \beta_s, & s \neq s_0, \\ 0, & s = s_0. \end{cases}$$

命题 A.4. (A.3) 的对偶问题是

$$\begin{aligned}
 \max_{\alpha, \beta, \eta} \quad & \sum_{x \in X} \mathcal{R}(x) \eta_x \\
 \text{s.t.} \quad & c = \bar{\alpha} + \bar{\beta}, \\
 & \alpha_s + \beta_{s'} \geq 0, \quad \forall s \rightarrow s' \text{ 含 } s' \neq s_f, \\
 & \eta_x \leq \alpha_x + \beta_{s_f}, \quad \forall x \in X.
 \end{aligned} \tag{22}$$

此外, 这个对偶可以简化为:

$$\begin{aligned}
 \max_{\pi} \quad & \sum_{x \in X} \mathcal{R}(x) \pi_x \\
 \text{s.t.} \quad & \pi_{s_0} = 0, \\
 & \pi_{s'} - \pi_s \leq 1, \quad \forall (s, s') \in E \text{ 含 } s' \neq s_f.
 \end{aligned} \tag{23}$$

证明。拉格朗日函数为

$$\begin{aligned} L(\mathcal{F}(s), \mathcal{F}(s \rightarrow s'), \alpha, \beta, \eta) = & c^T \mathcal{F} + \sum_{s \neq s_f} \alpha_s \left(\sum_{v \in \text{out}(s)} \mathcal{F}(s \rightarrow v) - \mathcal{F}(s) \right) \\ & + \sum_{s \neq s_0} \beta_s \left(\sum_{u \in \text{in}(s)} \mathcal{F}(u \rightarrow s) - \mathcal{F}(s) \right) + \sum_{x \in X} \eta_x (\mathcal{R}(x) - \mathcal{F}(x \rightarrow s_f)). \end{aligned}$$

Now collect all terms involving $\mathcal{F}(s)$ and $\mathcal{F}(s \rightarrow s')$. Since each edge $s \rightarrow s'$ contributes α_s through the outgoing constraint at s , and $\beta_{s'}$ through the incoming constraint at s' , we obtain

$$\begin{aligned} L(\mathcal{F}(s), \mathcal{F}(s \rightarrow s'), \alpha, \beta, \eta) = & \sum_{x \in X} \mathcal{R}(x) \eta_x + \sum_{s \in S} (c_s - \bar{\alpha}_s - \bar{\beta}_s) \mathcal{F}(s) \\ & + \sum_{\substack{(s, s') \in E \\ s' \neq s_f}} (\alpha_s + \beta_{s'}) \mathcal{F}(s \rightarrow s') \\ & + \sum_{x \in X} (\alpha_x + \beta_{s_f} - \eta_x) \mathcal{F}(x \rightarrow s_f). \end{aligned}$$

The dual function is

$$g(\alpha, \beta, \eta) := \inf_{\mathcal{F}(s), \mathcal{F}(s \rightarrow s') \geq 0} L(\mathcal{F}(s), \mathcal{F}(s \rightarrow s'), \alpha, \beta, \eta).$$

我们现在确定何时这个下确界是有限的。

步骤 1: 关于 $\mathcal{F}(s)$. 拉格朗日函数中的变量 $\mathcal{F}(s)$ 不受符号限制。因此, 关于 $\mathcal{F}(s)$ 的下确界是有限的当且仅当每个系数为 $\mathcal{F}(s)$ 零:

$$c_s - \bar{\alpha}_s - \bar{\beta}_s = 0, \quad \forall s \in S.$$

等价地,

$$c = \bar{\alpha} + \bar{\beta}.$$

步骤 2: 关于 $\mathcal{F}(s \rightarrow s')$. 每个变量 $\mathcal{F}(s \rightarrow s')$ 只受 $\mathcal{F}(s \rightarrow s') \geq 0$ 的约束。因此, 关于 $\mathcal{F}(s \rightarrow s')$ 的下确界有限当且仅当 $\mathcal{F}(s \rightarrow s')$ 的每个系数非负:

$$\alpha_s + \beta_{s'} \geq 0, \quad \forall (s \rightarrow s') \text{ 含 } s' \neq s_f,$$

并且

$$\alpha_x + \beta_{s_f} - \eta_x \geq 0, \quad \forall x \in X.$$

后一条件等价于

$$\eta_x \leq \alpha_x + \beta_{s_f}, \quad \forall x \in X.$$

在这些条件下,

$$g(\alpha, \beta, \eta) = \sum_{x \in X} \mathcal{R}(x) \eta_x.$$

因此对偶问题正好是 (22)。

由于 $\mathcal{R}(x) > 0$ 对于每个 $x \in X$, 最优选择的 η_x 饱和不等式

$$\eta_x \leq \alpha_x + \beta_{s_f},$$

从而

$$\eta_x = \alpha_x + \beta_{s_f}.$$

因此 (22) 等价于

$$\begin{aligned} \max_{\alpha, \beta} \quad & \sum_{x \in X} R(x)(\alpha_x + \beta_{s_f}) \\ \text{s.t.} \quad & c = \bar{\alpha} + \bar{\beta}, \\ & \alpha_s + \beta_{s'} \geq 0, \quad \forall (s \rightarrow s') \text{ 含 } s' \neq s_f. \end{aligned}$$

From $c = \bar{\alpha} + \bar{\beta}$, we obtain

$$\alpha_{s_0} = 0, \quad \beta_{s_f} = 0, \quad \beta_s = 1 - \alpha_s \quad \forall s \in I.$$

代入边缘不等式得到

$$\alpha_s + \beta_{s'} \geq 0 \iff \alpha_s + (1 - \alpha_{s'}) \geq 0 \iff \alpha_{s'} - \alpha_s \leq 1.$$

Renaming α_s as π_s yields (23).

请注意，扩展问题 10 的对偶推导与原问题完全相同，只是增加了一个等式约束来自固定的初始步骤。 □

A.3. 利用对偶势函数求最短路径

定理 A.5 (最短路径的对偶特征) 考虑原问题 A.4 的对偶

$$\max_{\pi} \sum_{x \in X} \mathcal{R}(x)\pi_x \quad \text{subject to} \quad \pi_{s_0} = 0, \quad \pi_{s'} - \pi_s \leq 1 \quad \forall (s \rightarrow s') \text{ with } s' \neq s_f.$$

对于每一个非汇点状态 s ，定义

$$d(s) := \min\{k \geq 0 : \exists s_0 = v_0 \rightarrow v_1 \rightarrow \dots \rightarrow v_k = s\}.$$

那么：

1. every feasible solution π satisfies

$$\pi_s \leq d(s) \quad \forall s \neq s_f;$$

2. 函数 $d(\cdot)$ 是一个可行的对偶解，并且它是对偶最优的；

3. 如果 $\mathcal{R}(x) > 0$ 对于每一个 $x \in X$ 成立，那么每一个最优解 π^* 满足

$$\pi_x^* = d(x) \quad \forall x \in X.$$

此外，最优解中的互补松弛条件给出了以下关系：

$$\mathcal{F}^*(s \rightarrow s')(\pi_{s'}^* - (1 + \pi_s^*)) = 0$$

这也是原始-对偶间隙。

证明。我们逐一证明这三个陈述。

Step 1: every feasible π satisfies $\pi_s \leq d(s)$.

设 π 是对偶问题的任意可行解，并固定一个状态 $s \neq s_f$ 。从 s_0 到 s 取任意有向路径：

$$s_0 = v_0 \rightarrow v_1 \rightarrow \dots \rightarrow v_k = s.$$

对于该路径上的每条边 $v_i \rightarrow v_{i+1}$ ，可行性给出

$$\pi_{v_{i+1}} - \pi_{v_i} \leq 1.$$

现在对 $i = 0, \dots, k-1$ 求和：

$$\sum_{i=0}^{k-1} (\pi_{v_{i+1}} - \pi_{v_i}) \leq \sum_{i=0}^{k-1} 1 = k.$$

左侧是一个望远镜求和，因此简化为

$$\pi_{v_k} - \pi_{v_0} = \pi_s - \pi_{s_0}.$$

Since $\pi_{s_0} = 0$, we obtain

$$\pi_s \leq k.$$

这适用于从 s_0 到 s 的每条路径。因此，对所有这样的路径取最小值，

$$\pi_s \leq d(s).$$

这证明了第 (i) 部分。

步骤 2：函数 $d(\cdot)$ 是可行的。

定义

$$\pi_s^{\max} := d(s).$$

我们证明了 $\pi^{\max}$ 满足所有对偶约束。

First,

$$\pi_{s_0}^{\max} = d(s_0) = 0.$$

Next, take any edge $s \rightarrow s'$ with $s' \neq s_f$. By definition of $d(s)$, there exists a shortest path from s_0 to s of length $d(s)$:

$$s_0 = v_0 \rightarrow v_1 \rightarrow \dots \rightarrow v_{d(s)} = s.$$

Appending the edge $s \rightarrow s'$ gives a path from s_0 to s' of length $d(s) + 1$. Since $d(s')$ is the length of the shortest path from s_0 to s' , we must have

$$d(s') \leq d(s) + 1.$$

等价地，

$$d(s') - d(s) \leq 1.$$

因此

$$\pi_{s'}^{\max} - \pi_s^{\max} \leq 1.$$

So $\pi^{\max}$ 是可行的。

$d(\cdot)$ **步骤 3：** 是二重最优的。

设 π 为任意可行解。根据第一步，对于每一个终端状态 $x \in X$ ，

$$\pi_x \leq d(x).$$

由于奖励是非负的，

$$\sum_{x \in X} \mathcal{R}(x) \pi_x \leq \sum_{x \in X} \mathcal{R}(x) d(x).$$

但步骤 2 表明选择 $\pi_s^{\max} = d(s)$ 是可行的，并且对于这个选择目标值正好是

$$\sum_{x \in X} \mathcal{R}(x) d(x).$$

因此没有可行解的目标值会更大，从而 $d(\cdot)$ 是偶对最优的。这证明了第 (ii) 部分。

步骤 4：每个最优解在终端上都与 d 一致。

设 π^* 为任意最优解。根据步骤 1，

$$\pi_x^* \leq d(x) \quad \forall x \in X.$$

假设存在某个终端状态 $x_0 \in X$ 使得

$$\pi_{x_0}^* < d(x_0).$$

因为所有奖励都是严格正的，这将意味着

$$\sum_{x \in X} \mathcal{R}(x) \pi_x^* < \sum_{x \in X} \mathcal{R}(x) d(x).$$

但是右边是最优值，因为它是由可行解 $d(\cdot)$ 实现的。这与最优性相矛盾 of π^* 。

因此不存在这样的 x_0 ，从而

$$\pi_x^* = d(x) \quad \forall x \in X.$$

这证明了第 (iii) 部分。

□

附录 A.4 最优传输与 GFlowNet 的对偶等价性证明

证明：容易看出，扩展后的原问题的对偶形式如下（详见附录 A.4 中的推导）

$$\begin{aligned} \max_{\pi} \quad & \sum_{x \in X} \mathcal{R}(x) \pi_x + \sum_{u \in U} \mathcal{L}(u) (-\pi_u) \\ \text{s.t.} \quad & \pi_{s'} - \pi_s \leq 1, \forall s \rightarrow s' : s \neq s_0, s' \neq s_f \\ & \pi_{s_0} = 0 \end{aligned} \tag{24}$$

如果我们现在重新定义 $a_x = \pi_x, b_u = -\pi_u$ ，然后取任意路径 p ：

$$a_x + b_u = \pi_x - \pi_u = \sum_{i=0}^{|p|} \pi_{p_{i+1}} - \pi_{p_i} \leq d(u, x)$$

因此：

$$\begin{aligned} \max_{a, b} \quad & \sum_{x \in X} \mathcal{R}(x) a_x + \sum_{u \in U} \mathcal{L}(u) b_u \\ \text{s.t.} \quad & a_x + b_u \leq d(u, x) \end{aligned} \tag{25}$$

其在决策变量 a_x, b_u 上的函数形式与问题 6 的对偶完全相同

□

附录 B 实验细节

所有模型均由具有两个隐藏层和 128 隐藏大小的多层感知机参数化，接受 s 的一热编码作为输入。

$\mathcal{F}_\theta(s), \mathcal{P}_F(s' | s, \theta), \mathcal{P}_B(s | s', \theta)$ 共享相同的主干网络，不同的线性头预测正向策略和反向策略的对数几率。我们在策略上训练我们的模型，批大小为 512。我们使用 AdamW 优化器，并在所有实验中设置权重衰减为 $\text{lr} = 10^{-3}$ 和 10^{-4} 。我们的实现基于 (Morozov 等, 2025) 发布的代码。所有实验均在 CPU 上进行。

B.1 超网格分布定义

我们通过以下公式定义月牙形状分布：

$$\mathcal{L}(s) \triangleq \mathbb{I}[\|z - c\|_2^2 \leq r_{\text{out}}^2] (1 - \mathbb{I}[\|z - (c - \delta e_1)\|_2^2 \leq r_{\text{in}}^2]) \left(0.5 + 2 \min \left\{ 1, \max \left\{ 0, 1 - \frac{\|z - b\|_2}{r_{\text{out}}} \right\} \right\} \right) + \varepsilon,$$




图 2. 实验中使用的分布可视化：月牙形（左），角落形（中），球形（右）。

其中：

$$z = \frac{s}{M-1}, \quad c = \left(\frac{1}{2}, \dots, \frac{1}{2}\right), \quad e_1 = (1, 0, \dots, 0), \quad b = c + \frac{r_{\text{out}}}{2} e_1.$$

和 $r_{\text{in}}, r_{\text{out}}$ 分别是内球和外球的半径。

球形分布定义如下：

$$\mathcal{L}(s) \triangleq \mathbb{I}[\|z - c\|_2^2 \leq r_{\text{out}}^2] \left(0.5 + 2 \min \left\{ 1, \max \left\{ 0, 1 - \frac{\|z - b\|_2}{r_{\text{out}}} \right\} \right\} \right) + \varepsilon,$$

角落形分布的定义遵循先前的工作 (Madan 等, 2023; Malkin 等, 2022)：

$$\mathcal{R}(s) \triangleq R_0 + R_1 \prod_{i=1}^D \mathbb{I} \left[0.25 < \left| \frac{s^i}{H-1} - 0.5 \right| \right] + R_2 \prod_{i=1}^D \mathbb{I} \left[0.3 < \left| \frac{s^i}{H-1} - 0.5 \right| < 0.4 \right],$$

参见图 2 进行可视化。

B.2. 排列

记 $C(k)$ 为从奖励分布中采样的排列具有 k 固定点的概率。我们计算向量 $(C(0), C(1), \dots, C(n))$ 与其在训练过程中最后 10^5 个样本上的经验估计之间的 L^1 误差，用于收敛性诊断。

假设 $x_1, \dots, x_m$ 是从 $\mathcal{P}_{\text{F}}$ 中采样的 GFlowNet 样本集（轨迹的终端状态）。那么，固定点概率的经验 L_1 误差定义为：

$$\sum_{k=0}^N \left| C(k) - \frac{1}{m} \sum_{i=1}^m \mathbb{I}\{x_i(k) = k\} \right|,$$

我们使用 (Morozov 等, 2025) 中的精确公式来计算 $C(k)$ 。