

生成流网络基础

Yoshua Bengio*

Mila, Université de Montréal, CIFAR, IVADO

YOSHUA.BENGIO@MILA.QUEBEC

Salem Lahlou*

Mila, Université de Montréal

LAHLOSAL@MILA.QUEBEC

Tristan Deleu*

Mila, Université de Montréal

DELEUTRI@MILA.QUEBEC

Edward J. Hu

Mila, Université de Montréal, Microsoft

EDWARD@EDWARDJHU.COM

Mo Tiwari

Stanford University

MOTIWARI@STANFORD.EDU

埃马纽埃尔·本吉奥 bengioem@mila.quebec 米拉, 麦吉尔大学

编辑: 大卫·桑塔格

摘要

生成流网络 (GFlowNets) 作为一种方法被引入到主动学习环境中, 用于采样多样化的候选集, 其训练目标使它们能够按照给定的奖励函数近似采样。本文展示了 GFlowNets 的一些额外理论性质, 包括一种新的局部和高效的训练目标, 称为细致平衡, 与 MCMC 类比。GFlowNets 可以用来估计联合概率分布及其对应的边缘分布, 在某些变量未指定的情况下, 特别是可以表示集合和图等复合对象上的分布。GFlowNets 将通常由计算昂贵的 MCMC 方法完成的工作在单次但经过训练的生成过程中完成。它们还可以用于估计配分函数和自由能, 给定子集 (子图) 时超集 (超图) 的条件概率, 以及给定集合 (图) 的所有超集 (超图) 的边缘分布。我们介绍了几种变体, 使熵和互信息的估计成为可能, 从帕累托前沿进行采样, 与最大化奖励策略的联系, 以及对随机环境、连续动作和模块化能量函数的扩展。

1 引言

在 Bengio 等人 (2021) 引入生成流网络 (Generative Flow Networks, 简称 GFlowNets) 的基础上, 本文提供了深入的形式化基础, 并扩展了理论结果集, 这些结果可能对 Bengio 等人 (2021) 提出的主动学习场景感兴趣, 但其应用范围远不止于此。

*. 同等贡献

1.1 什么是 GFlowNet?

GFlowNets 具有使其适用于一般概率推理的特性，无论是用于采样还是边缘化。训练期间进行采样，而在运行时的采样或边缘量的计算可以通过一系列构造性随机步骤一次性完成。这使得 GFlowNets 成为蒙特卡洛马尔可夫链 (Monte-Carlo Markov chains, 简称 MCMC) 的一个有趣替代方案，并与变分推断的摊销方法 (Malkin 等人, 2023) 相关。

由于对组合对象进行采样 s 可以通过一系列随机步骤实现，具有非常丰富的多模态分布 $P_T(s)$ 对于此类对象，可以表示覆盖其上的分布，并且离线训练目标使得能够探索和发现感兴趣的分布模式。GFlowNets 的关键属性在于，其采样策略被训练以使概率 $P_T(s)$ 采样对象的概率 s 与值近似成正比 $R(s)$ 给定奖励函数应用于该对象的能量值。我们也讨论能量函数 $\mathcal{E}(s) = -\log R(s)$ ，即奖励函数是非负的，并对应于一个未归一化的概率。通常情况下，生成模型是从正例数据集集中进行训练的，而 GFlowNet 则是被训练来匹配给定的能量函数或奖励函数，并将其转换为采样器。我们将该采样器视为生成策略，因为复合对象 s 通过一系列较小的随机步骤构建（见图 1），通常对应于构造性地组合不同的元素 s_i ，如同图的边。

将能量函数或未归一化概率函数转换为采样器的过程类似于 MCMC 方法所实现的，但是一旦训练完成，GFlowNets 将在一次操作中生成样本，而不是生成一系列样本，其分布逐渐接近所需的分布。因此，GFlowNets 避免了在这些对象空间中的长时间随机搜索以及与之相关的 MCMC 方法的模式混合不可处理挑战 (Jasra 等, 2005; Bengio 等, 2013; Pompe 等, 2020)。通过多次调用采样器，可以从 GFlowNet 获得多个独立同分布样本。GFlowNets 用生成策略的摊销训练挑战交换了与 MCMC 采样的不可处理性。如果奖励函数的模式没有内在（但不一定已知）的结构，使得学习者能够泛化，即学习者几乎没有任何机会根据已经访问过的那些模式正确猜测新模式的位置，那么后者问题同样会变得不可处理。

能量函数或奖励函数（能量的负指数）仅在对象顺序构造过程结束时进行评估 s ，在我们称之为终止状态的状态中。每个这样的构造序列都从单一的初始状态开始 s_0 并终止于一个终态。如图 2 所示，我们可以可视化从 s_0 并以终态结束 s 在“生成流网络”中，“流”一词指的是可以通过 GFlowNet 学习程序学习到的未归一化的概率。中间状态中的流 s 是一个可以从其到达的终止状态的非负奖励的加权和 s 这些权重旨在避免重复计算：如果我们注入固定流量的液体 s_0 并将该液体分配给任意状态下的每个子状态 s 与 GFlowNet 策略选择子节点的比例 s 我们将获得每个状态的流，并且终止状态的流将与那些状态的奖励函数相匹配。正如在这里更详细地展示的，这是首次在 GFlowNet 中实现




图 1: GFlowNet 迭代构建对象的过程示意图。我们采用了强化学习文献中常用的符号表示： s_t 表示部分构造对象（在这种情况下，是一个图）在时间上的状态 t ， a_t 表示 GFlowNet 在时间上采取的动作 t 转换到状态 $s_{t+1} = T(s_t, a_t)$ 。在此示意图中，GFlowNet 接收一个包含 3 个节点的图作为输入，并确定要采取的操作。该操作与环境转移函数结合 $T(s_t, a_t)$ ，确定 s_{t+1} ：一个四节点图。此过程重复直至采样到退出动作，样本完成。

正如论文（Bengio 等人，2021）所述，这可以通过在每个状态下施加一个流约束来实现：流入的流之和必须等于流出的流之和。

1.2 本文的贡献

本文的重要贡献在于提出了条件 GFlowNet 的概念，这使得能够估计与对象构建多步边缘化对应的难以处理的求和，并可用于计算不同类型的联合分布上的自由能¹，其中最有趣的是集合和图。这种边缘化还使得能够估计熵、条件熵和互信息。因此，GFlowNet 可以被推广用于估计多个流，从而建模丰富的结果（而不是标量奖励函数）。关于相关方法及其与常见生成模型和强化学习（RL）方法的区别，读者可参考 Bengio 等人（2021）及第 7 节的讨论。在 RL 背景下，GFlowNet 已经注意到的两个有趣的性质是：（1）可以在离线模式下训练，轨迹采样自与 GFlowNet 表示的分布不同的分布；（2）它们匹配概率上的奖励函数，而不是试图找到最大化奖励或回报的配置。后一性质在探索背景下特别有趣，确保从生成策略中采样的配置既有趣又多样。

1. 在机器学习中，自由能是指未归一化的边缘概率的对数，这是一个通常难以处理的负能量指数和。




图 2: 生成流网络 (GFlowNet) 结构示意图, 作为状态上的有向无环图 s , 通过粒子沿边缘流动来表示流函数。GFlowNet 策略采样的任何对象都可以从初始状态开始获得 s_0 然后在每一步选择一个子节点, 其概率与 GFlowNet 策略的转移概率成正比。当从终止状态选择了一个终止动作时, 该过程停止 s (达到终止状态 s_f), 此时给予奖励 $R(s)$ 获得。图示展示了一个小型 GFlowNet 及其可能的轨迹从 s_0 到达任意终止状态。这说明一般情况下一个状态可以通过多条轨迹到达。GFlowNet 算法学习一种策略, 使得采样终止状态的概率 s 与 $R(s)$ 成正比。它试图学习一个流函数 $F(s)$ 和 $F(s \rightarrow s')$ 对所有状态 (包括中间状态) 进行求和 s 以及转换 $s \rightarrow s'$ 与 $F(s) = R(s)$ 在终止状态时 $F(s_0)$ 终端状态下的奖励之和。实现这一目标的一个充分性质是在每个状态下, 流入的流量之和等于流出的流量之和。

在将 GFlowNets 转化为概率推理机方面也颇具趣味性: 如果我们选择奖励函数为先验 (关于某个随机变量) 乘以似然 (给定该随机变量值时数据拟合程度如何), 那么 GFlowNets 策略将学会从相应的贝叶斯后验分布中采样 (该后验分布与先验乘以似然成正比)。GFlowNets 生成多样样本的能力则对应于从目标分布的模式中采样的能力。GFlowNets 的重要启发之一来自于时间差分强化学习方法 (Sutton 和 Barto, 2018) 中信息传播的方式。两者都依赖于一种信用分配的一致性原则, 这种一致性可能只有在训练收敛时才能实现。尽管精确梯度计算可能是不可行的, 因为需要考虑的状态空间路径数量呈指数级增长, 但两种方法都依赖于不同组件之间的局部一致性和一个训练目标, 即如果所有学习到的组件在局部上相互一致, 那么我们将获得一个能够全局估计感兴趣量的系统。这些例子包括时间差分方法中的预期折扣回报估计以及 GFlowNets 中的概率测度估计。本文从多个方向扩展了原始 GFlowNets 构造的理论 (Bengio 等, 2021), 包括一个新的局部训练目标, 称为细致平衡 (与蒙特卡洛马尔可夫链的细致平衡条件类比), 它避免了形成先前提出的流匹配损失所需的显式求和, 以及允许计算边缘概率 (或自由能) 的公式, 用于子-

变量集，更广泛地说，对于更大集合的子集或子图，它们在估计熵和互信息方面的应用，以及引入了一种无监督形式的 GFlowNets（训练过程中不需要奖励函数，只需观察结果），从而能够从帕累托前沿进行采样。尽管基础的 GFlowNets 更类似于强盗问题（即只有在一系列动作结束时才提供奖励），但可以扩展以考虑中间奖励，从而形成一种回报的概念，并根据这些回报进行采样。GFlowNets 的原始表述也仅限于离散和确定性环境，而本文则探讨了如何克服这两个局限性。最后，虽然 GFlowNets 的基本表述假设给定的奖励或能量函数，本文还讨论了如何联合学习能量函数和 GFlowNets，这为新型基于能量的建模方法和能量函数及 GFlowNets 的模块化结构打开了大门。

1.3 其他文献中的 GFlowNets

除了本文提出的理论外，Malkin 等人（2023）和 Zimmermann 等人（2022）证明了 GFlowNets 与分层变分方法之间的一些部分等价性，进一步提供了关于 GFlowNets 在学习按给定奖励函数比例采样的有效性的理论证据。这些研究还提供了 GFlowNets 在离线策略设置中优越性的证据。

GFlowNets 由于其生成样本的多样性，在许多应用中找到了广泛的应用。在存在廉价代理奖励函数的情况下，GFlowNets 被用于查询代理之前，在真实奖励函数下进行更昂贵的评估。在这种情况下，GFlowNets 生成样本的多样性可以用于对抗代理指定的鲁棒性，并纳入认知不确定性。例如，张等人（2023）使用 GFlowNets 来生成计算图中操作的样本计划，通过代理评估样本计划的运行时间是快速的，但在目标硬件上评估相同的计划则是昂贵的。在主动学习问题中，贾因等人（2022, 2023）将 GFlowNet 采样作为主动学习循环中的一个子程序，替代贝叶斯优化或基于强化学习的方法。贾因等人（2022）将 GFlowNets 应用于寻找新型抗微生物肽，发现与人类转录因子具有高结合活性的 DNA 序列，以及找到具有高荧光性的蛋白质。此外，贾因等人（2023）开发了偏好条件下的 GFlowNets，其中偏好权重向量用于将多个目标函数标量化为单一奖励。作者将其技术应用于各种分子和 DNA 序列生成任务，并发现他们的方法能够找到帕累托前沿上的不同帕累托最优样本。

GFlowNets 在其他机器学习问题中也找到了应用。例如，张等人（2022）同时训练基于能量的模型和 GFlowNet；能量函数通过来自 GFlowNet 的样本进行训练，而 GFlowNet 则使用能量函数形成其奖励。他们的方法产生了一个生成模型，用于高维度的二进制向量，例如二值化的数字。德卢等人（2022）使用 GFlowNet 进行结构学习；GFlowNet 生成的样本近似给定数据集的真实因果图后验分布。他们的方法适用于观察性和干预性数据，并优于基于 MCMC 和变分推断的方法。胡等人

(2023) 通过联合训练 GFlowNet 来近似样本，从而找到具有离散组合隐变量的潜变量模型的最大似然估计，在期望最大化 (EM) 算法的 E 步骤中，通常难以处理的后验分布。

2 流网络和马尔可夫流

2.1 图论的一些元素

本节回顾一些图的基本定义和性质，这些是流网络和 GFlowNets 的基础。

定义 1 有向图是一个元组 $G = (\mathcal{S}, \mathbb{A})$ ，其中 $\mathcal{S}$ 是一个有限的状态集，并且 $\mathbb{A}$ 一个子集 $\mathcal{S} \times \mathcal{S}$ 表示有向边。元素为 $\mathbb{A}$ 表示 $s \rightarrow s'$ 并称为边或转移。此类图中的轨迹是一个序列 $\tau = (s_1, \dots, s_n)$ 元素的 $\mathcal{S}$ 使得每次转移 $s_t \rightarrow s_{t+1} \in \mathbb{A}$ 并且 $n > 1$ 。我们记作 $s \in \tau$ 表示 s 位于轨迹中 τ ，i.e., $\exists t \in \{1, \dots, n\} s_t = s$ ，类似地 $s \rightarrow s' \in \tau$ 表示 $\exists t \in \{1, \dots, n-1\} s_t = s, s_{t+1} = s'$ 。为了方便起见，我们也使用以下记法 $\tau = s_1 \rightarrow \dots \rightarrow s_n$ 轨迹的长度是指其中边的数量（长度为 $\tau = (s_1, \dots, s_n)$ 因此是 $n-1$ ）。有向无环图 (DAG) 是有向图中不存在满足条件的轨迹 $\tau = (s_1, \dots, s_n)$ 满足 $s_n = s_1$ 。

给定一个 DAG $G = (\mathcal{S}, \mathbb{A})$ ，以及两个状态 $s, s' \in \mathcal{S}$ ，如果在 G 中存在一条从 s 开始到 s' 结束的轨迹，则我们写作 $s < s'$ 。二元关系“ $<$ ”定义了一个严格的偏序（即它是反身的、不对称的和传递的）。我们写作 $s \leq s'$ 如果 $s < s'$ 或 $s = s'$ 。二元关系“ $\leq$ ”是一个（非严格）偏序（即它是自反的、反对称的和传递的）。如果在 s 和 s' 之间没有顺序关系，我们写作 $s \not\leq s'$ 。

Definition 2 Given a DAG $G = (\mathcal{S}, \mathbb{A})$, the **parent set** of a state $s \in \mathcal{S}$, which we denote $\text{Par}(s)$, contains all of the direct parents of s in G , i.e., $\text{Par}(s) = \{s' \in \mathcal{S} : s' \rightarrow s \in \mathbb{A}\}$; similarly, the **child set** $\text{Child}(s)$ contains all of the direct children of s in G , i.e., $\text{Child}(s) = \{s' \in \mathcal{S} : s \rightarrow s' \in \mathbb{A}\}$.

定义 3 给定一个 DAG $G = (\mathcal{S}, \mathbb{A})$ 。 G 被称为指明的 DAG，如果存在两个状态 s_0, s_f 满足：和

$$\forall s \in \mathcal{S} \setminus \{s_0\} \quad s_0 < s \quad \forall s \in \mathcal{S} \setminus \{s_f\} \quad s < s_f.$$

s_0 被称为源状态或初始状态， s_f 被称为汇状态或最终状态。因为“ $<$ ”是一个严格的偏序，这两个状态是唯一的。这样的 DAG 中的完全轨迹是从 s_0 开始到 s_f 结束的任何轨迹。我们用 $\tau = (s_0, s_1, \dots, s_n, s_{n+1} = s_f)$ 表示这样的轨迹。我们用 $\mathcal{T}$ 表示在 G 中的所有完全轨迹的集合，用 $\mathcal{T}^{\text{partial}}$ 表示在 G 中的（可能是不完整的）轨迹的集合。如果一个状态 $s \in \mathcal{S}$ 是汇状态的父节点，即 $s \rightarrow s_f \in \mathbb{A}$ ，则该状态被称为终止状态。转移 $s \rightarrow s_f$ 被称为终止边。我们用：

- $\mathbb{A}^{-f} = \{s \rightarrow s' \in \mathbb{A}, s' \neq s_f\}$, the set of non-terminating edges in G ,
- $\mathbb{A}^f = \{s \rightarrow s' \in \mathbb{A}, s' = s_f\} = \mathbb{A} \setminus \mathbb{A}^{-f}$, the set of terminating edges in G ,
- $\mathcal{S}^f = \{s \in \mathcal{S}, s \rightarrow s_f \in \mathbb{A}^f\} = \text{Par}(s_f)$, 在 G 中的终止状态集合。

在图 3 中，我们可视化了前一定义中引入的概念。




图 3: 一个带源点的有向无环图 G 示例，说明初始状态 (s_0)、最终或汇状态 (s_f)、在 $\mathcal{S}^f$ 中的终止状态，以及到 s_f 的过渡称为终止边，在 $\mathbb{A}^f$ 中。终止状态可能有不同于汇状态的其他子节点 (例如，终止状态 s_7)。

请注意，单一源状态和单一汇状态的约束仅是一种数学上的便利，因为一般有向无环图与具有这种约束的有向无环图之间存在双射（通过添加唯一连接到所有其他源/汇状态的源/汇状态）。

定义 4 设 G 是一个带源状态 s_0 和汇状态 s_f 的有向无环图，向前（分别向后）概率函数与 G 一致是指在 $\mathbb{A}$ 上定义的任何非负函数 $\hat{P}_F$ （分别 $\hat{P}_B$ ），满足 $\forall s \in \mathcal{S} \setminus \{s_f\}, \sum_{s' \in \text{Child}(s)} \hat{P}_F(s' | s) = 1$ （分别 $\forall s \in \mathcal{S} \setminus \{s_0\}, \sum_{s' \in \text{Par}(s)} \hat{P}_B(s' | s) = 1$ ）。

利用带源点的有向无环图，可以使用一致的向前和向后概率函数来定义轨迹的概率，即在 $\mathcal{T}^{\text{partial}}$ 的一些子集上的概率测度。以下引理展示了如何构造这样的因子化概率测度：

引理 5 设 $G = (\mathcal{S}, \mathbb{A})$ 是一个带源点的有向无环图，并考虑一个向前概率函数 $\hat{P}_F$ 和一个向后概率函数 $\hat{P}_B$ ，两者都与 G 一致。对于任何状态 $s \in \mathcal{S} \setminus \{s_f\}$ ，我们记 $\mathcal{T}_{s,f} \subseteq \mathcal{T}^{\text{partial}}$ 为在 G 中从 s 开始并在 s_f 结束的轨迹集合；对于任何状态 $s \in \mathcal{S} \setminus \{s_0\}$ ，我们记 $\mathcal{T}_{0,s} \subseteq \mathcal{T}^{\text{partial}}$ 为在 G 中从 s_0 开始并在 s 结束的轨迹集合。

考虑在 $\mathcal{T}^{partial}$ 上定义的 $\hat{P}_F$ 和 $\hat{P}_B$ 的扩展:

$$\forall \tau = (s_1, \dots, s_n) \in \mathcal{T}^{partial} \quad \hat{P}_F(\tau) := \prod_{t=1}^{n-1} \hat{P}_F(s_{t+1} | s_t) \quad (1)$$

$$\forall \tau = (s_1, \dots, s_n) \in \mathcal{T}^{partial} \quad \hat{P}_B(\tau) := \prod_{t=1}^{n-1} \hat{P}_B(s_t | s_{t+1}) \quad (2)$$

我们有如下内容:

$$\forall s \in \mathcal{S} \setminus \{s_f\} \quad \sum_{\tau \in \mathcal{T}_{s,f}} \hat{P}_F(\tau) = 1 \quad (3)$$

$$\forall s' \in \mathcal{S} \setminus \{s_0\} \quad \sum_{\tau \in \mathcal{T}_{0,s'}} \hat{P}_B(\tau) = 1 \quad (4)$$

证明 为了方便起见, 我们将 $\mathcal{T}_{s \rightarrow s', s_f}$ 表示从 $s \rightarrow s'$ 开始并在 s_f 结束的轨迹集合, 并将 $\mathcal{T}_{0, s \rightarrow s'}$ 表示从 s_0 开始并在 $s \rightarrow s'$ 结束的轨迹集合。这使得我们可以写出:

$$\begin{aligned} \forall s \neq s_f \quad \mathcal{T}_{s,f} &= \bigcup_{s' \in Child(s)} \mathcal{T}_{s \rightarrow s', s_f}, \quad \{\mathcal{T}_{s \rightarrow s', s_f}, s' \in Child(s)\} \text{ pairwise disjoint,} \\ \forall s' \neq s_0 \quad \mathcal{T}_{0,s'} &= \bigcup_{s \in Par(s')} \mathcal{T}_{0, s \rightarrow s'}, \quad \{\mathcal{T}_{0, s \rightarrow s'}, s \in Par(s')\} \text{ pairwise disjoint.} \end{aligned}$$

此外, 对于任意 $s \neq s_f$, 我们用 $d_{s,f}$ 表示在 $\mathcal{T}_{s,f}$ 中的最大轨迹长度; 对于任意 $s' \neq s_0$, 我们用 $d_{0,s'}$ 表示在 $\mathcal{T}_{0,s'}$ 中的最大轨迹长度。我们将通过强归纳法证明等式 (3), 其中归纳对象为 $d_{s,f}$, 并通过强归纳法证明等式 (4), 其中归纳对象为 $d_{0,s'}$ 。基础情形: 如果 $d_{s,f} = 1$ 且 $d_{0,s'} = 1$, 则 $\mathcal{T}_{s,f} = \{(s \rightarrow s_f)\}$ 和 $\mathcal{T}_{0,s'} = \{(s_0 \rightarrow s')\}$ 。因此,

$\sum_{\tau \in \mathcal{T}_{s,f}} \hat{P}_F(\tau) = \hat{P}_F(s \rightarrow s_f) = \hat{P}_F(s_f | s) = 1$, 因为 s_f 是 s 唯一的子节点 (否则 $d_{s,f}$ 不能为 1), 并且 $\sum_{\tau \in \mathcal{T}_{0,s'}} \hat{P}_B(\tau) = \hat{P}_B(s_0 \rightarrow s') = 1$, 因为 s_0 是 s' 唯一的父节点 (否则 $d_{0,s'}$ 不能为 1)。归纳步骤: 考虑 $s \neq s_f$ 使得 $d_{s,f} > 1$, 并考虑 $s' \neq s_0$ 使得 $d_{0,s'} > 1$ 。由于上述给出的不相交并集, 我们有:

$$\begin{aligned} \sum_{\tau \in \mathcal{T}_{s,f}} \hat{P}_F(\tau) &= \sum_{\tilde{s} \in Child(s)} \sum_{\tau \in \mathcal{T}_{s \rightarrow \tilde{s}, f}} \hat{P}_F(\tau) = \sum_{\tilde{s} \in Child(s)} \hat{P}_F(\tilde{s} | s) \sum_{\tau \in \mathcal{T}_{\tilde{s}, f}} \hat{P}_F(\tau) = 1, \\ \sum_{\tau \in \mathcal{T}_{0,s'}} \hat{P}_B(\tau) &= \sum_{\tilde{s}' \in Par(s')} \sum_{\tau \in \mathcal{T}_{0, \tilde{s}' \rightarrow s'}} \hat{P}_B(\tau) = \sum_{\tilde{s}' \in Par(s')} \hat{P}_B(\tilde{s}' | s') \sum_{\tau \in \mathcal{T}_{0, \tilde{s}'}} \hat{P}_B(\tau) = 1, \end{aligned}$$

其中我们在每行的第三个等式中使用了归纳假设。 ■

2.2 轨迹与流

我们给定点向 DAG 增加一个称为流的函数 F 。有助于想象流的一个类比是在网络中流动的粒子流，每个粒子从 s_0 开始并通过某些轨迹终止于 s_f 。与每个完整的轨迹 τ 相关的流 $F(\tau)$ 包含共享相同路径的粒子数量 τ 。

定义 6 给定一个有根 DAG，轨迹流（或“流”）是任何非负函数 $F : \mathcal{T} \mapsto \mathbb{R}^+$ 定义在所有完整轨迹的集合上 $\mathcal{T}$ 。 F 诱导出一个测度在 σ -代数上 $\Sigma = 2^{\mathcal{T}}$ ，即所有完整轨迹集合的幂集 $\mathcal{T}$ 。特别地，对于每个子集 $A \subseteq \mathcal{T}$ ，我们有

$$F(A) = \sum_{\tau \in A} F(\tau). \quad (5)$$

对 (G, F) 称为流网络。

此定义确保 $(\mathcal{T}, 2^{\mathcal{T}}, F)$ 是一个测度空间。此处滥用记号，使用 F 表示完整的轨迹函数及其在 $(\mathcal{T}, 2^{\mathcal{T}})$ 上的相应测度。当事件 A 是单一轨迹 $\{\tau\}$ 时，其测度直接写作 $F(\tau)$ 。同样地，我们也滥用记号来定义通过特定状态 s 或特定边 $s \rightarrow s'$ 的流如下：

定义 7 通过一个状态（或状态流） $F : \mathbb{S} \mapsto \mathbb{R}^+$ 对应于经过特定状态的所有完整轨迹集合的测度：

$$F(s) := F(\{\tau \in \mathcal{T} : s \in \tau\}) = \sum_{\tau \in \mathcal{T} : s \in \tau} F(\tau). \quad (6)$$

类似地，通过一条边（或边流） $F : \mathbb{A} \mapsto \mathbb{R}^+$ 对应于经过特定边的所有完整轨迹集合的测度：

$$F(s \rightarrow s') := F(\{\tau \in \mathcal{T} : s \rightarrow s' \in \tau\}) = \sum_{\tau \in \mathcal{T} : s \rightarrow s' \in \tau} F(\tau). \quad (7)$$

根据这一定义，我们有 $F(s \rightarrow s') = 0$ 若 $s \rightarrow s' \notin \mathbb{A}$ 不是指向的有向无环图中的边（因为 $F(\emptyset) = 0$ ）。我们称终止转换的流 $F(s \rightarrow s_f)$ 为终止流。以下命题关联状态流与边流：

命题 8 给定一个流网络 (G, F) 。状态流和边流满足：

$$\forall s \in \mathcal{S} \setminus \{s_f\} \quad F(s) = \sum_{s' \in \text{Child}(s)} F(s \rightarrow s') \quad (8)$$

$$\forall s' \in \mathcal{S} \setminus \{s_0\} \quad F(s') = \sum_{s \in \text{Par}(s')} F(s \rightarrow s') \quad (9)$$

Proof Given $s \neq s_f$, the set of complete trajectories going through s is the (disjoint) union of the sets of trajectories going through $s \rightarrow s'$, for all $s' \in \text{Child}(s)$:

$$\{\tau \in \mathcal{T} : s \in \tau\} = \bigcup_{s' \in \text{Child}(s)} \{\tau \in \mathcal{T} : s \rightarrow s' \in \tau\}.$$

因此，可以得出：

$$F(s) = \sum_{\tau: s \in \tau} F(\tau) = \sum_{s' \in \text{Child}(s)} \sum_{\tau: s \rightarrow s' \in \tau} F(\tau) = \sum_{s' \in \text{Child}(s)} F(s \rightarrow s')$$

类似地，通过将经过 $s' \neq s_0$ 的所有完整轨迹集写作所有经过 $s \rightarrow s'$ 的轨迹集的（不相交）并集，可以得到公式 (9) $s \in \text{Par}(s')$. —

2.3 由流诱导的概率测度

定义 9 给定一个流网络 (G, F) ，总流 Z 是整个集合 $\mathcal{T}$ 的测度，对应于所有完整轨迹的流之和：

$$Z := F(\mathcal{T}) = \sum_{\tau \in \mathcal{T}} F(\tau). \quad (10)$$

命题 10 初始状态的流等于最终状态的流等于总流 Z 。

证明 由于 $\forall \tau \in \mathcal{T}, s_0, s_f \in \tau$ ，对 s_0 和 s_f 应用式 (6) 可得

$$F(s_0) = \sum_{\tau \in \mathcal{T}} F(\tau) = Z, \quad (11)$$

$$F(s_f) = \sum_{\tau \in \mathcal{T}} F(\tau) = Z. \quad (12)$$

■

直观上，定理 11 通过类比粒子从初始状态流向最终状态的流，证明了 Bengio 等人（2021）引入的“流”一词的合理性。我们在定理 9 中使用字母 Z ，它通常用于表示概率模型和统计力学中的配分函数，因为它是一个归一化常数，可以将上述定义的测度空间 $(\mathcal{T}, 2^{\mathcal{T}}, F)$ 转化为概率空间 $(\mathcal{T}, 2^{\mathcal{T}}, P)$ ：

定义 11 给定一个流网络 (G, F) ，流概率是与 F 关联的可测空间 $(\mathcal{T}, 2^{\mathcal{T}})$ 上的概率测度 P ：

$$\forall A \subseteq \mathcal{T} \quad P(A) := \frac{F(A)}{F(\mathcal{T})} = \frac{F(A)}{Z}. \quad (13)$$

对于两个事件 $A, B \subseteq \mathcal{T}$ ，条件概率 $P(A | B)$ 满足如下关系：

$$P(A | B) := \frac{F(A \cap B)}{F(B)}. \quad (14)$$

类似于流 F ，我们滥用记号 F 来定义经过某个状态的概率：

$$\forall s \in \mathcal{S} \quad P(s) := \frac{F(s)}{Z}, \quad (15)$$

同样地，对于经过一条边的概率也是如此。需要注意的是， $P(s)$ 并不对应于状态上的分布，因为 $\sum_{s \in \mathcal{S}} P(s) = 1$ ；特别地，很容易看出 $P(s_0) = 1$ （换句话说，轨迹通过初始状态 s_0 的概率为 1）。此外，对于一个轨迹 $\tau \in \mathcal{T}$ ，我们也使用记号 $P(\tau)$ 而不是 $P(\{\tau\})$ 来表示通过特定轨迹的概率 τ 。

定义 12 给定一个流网络 (G, F) ，前向转移概率算子 P_F 是定义在 $\mathcal{S} \times \mathcal{S}$ 上的函数，它是由 F (Eq. (14)) 诱导出的条件概率的一个特例。

$$\forall s \rightarrow s' \in \mathbb{A} \quad P_F(s' | s) := P(s \rightarrow s' | s) = \frac{F(s \rightarrow s')}{F(s)}. \quad (16)$$

类似地，后向转移概率算子是由下列定义给出的：

$$\forall s \rightarrow s' \in \mathbb{A} \quad P_B(s | s') := P(s \rightarrow s' | s') = \frac{F(s \rightarrow s')}{F(s')}. \quad (17)$$

请注意， P_F 和 P_B 与 G 是一致的（从定理 4 的角度来看），这是定理 8 的结果。

由于流定义了状态和边上的概率，它们可以用来定义图终止状态上的概率分布（记为 $\mathcal{S}^f = \text{Par}(s_f)$ ），如下所示：

定义 13 给定一个流网络 (G, F) ，终止状态概率 P_T 是在流概率 P 下的终止状态上的概率分布 $\mathcal{S}^f$ ：

$$\forall s \in \mathcal{S}^f \quad P_T(s) := P(s \rightarrow s_f) = \frac{F(s \rightarrow s_f)}{Z} \quad (18)$$

与概率相反 $P(s \rightarrow s_f)$ 经过某个状态的 s 终止状态的概率 P_T 是在终止状态上的一个良好定义的分佈 $s \in \mathcal{S}^f$ 具体而言：

命题 14 终止状态的概率 P_T 是在终止状态上定义良好的分佈 $s \in \mathcal{S}^f$ ，即 $P_T(s) \geq 0$ 对于所有的 $s \in \mathcal{S}^f$ ，并且

$$\sum_{s \in \mathcal{S}^f} P_T(s) = 1.$$

Proof Since the flow $F(s \rightarrow s_f)$ is non-negative, it is easy to see that $P_T(s) \geq 0$. Moreover, using the definition of $\mathcal{S}^f = \text{Par}(s_f)$, Theorem 8 (relating the edge flows and the state flows), and Theorem 10 ($F(s_f) = Z$), we have

$$\sum_{s \in \mathcal{S}^f} P_T(s) = \frac{1}{Z} \sum_{s \in \mathcal{S}^f} F(s \rightarrow s_f) = \frac{1}{Z} \sum_{s \in \text{Par}(s_f)} F(s \rightarrow s_f) = \frac{F(s_f)}{Z} = 1. \quad \blacksquare$$

终止状态概率在估计流网络（见第 3 节）的上下文中尤为重要，因为它表明一个流网络 (G, F) 诱导了一个关于终止状态的概率分布，该分布与终止流量 $F(s \rightarrow s_f)$ 成正比，归一化常数 Z 由初始流量给出 $F(s_0)$ 。

2.4 马尔可夫流

定义一个流需要指定 $|\mathcal{T}|$ 非负值（每个轨迹 $\tau \in \mathcal{T}$ 一个），这通常与图边的数量呈指数关系。然而，马尔可夫流具有一个显著的性质，即它们可以用更少的“数字”来定义，因为轨迹流根据 G 进行分解。

定义 15 设 (G, F) 是一个流网络，其流概率测度 P 。 F 被称为马尔可夫流（或等价地 (G, F) 为马尔可夫流网络），如果对于任何状态 $s \neq s_0$ ，出边 $s \rightarrow s'$ ，以及任何从 $\tau = (s_0, s_1, \dots, s_n = s) \in \mathcal{T}^{partial}$ 开始并在 s 结束的轨迹 s ：

$$P(s \rightarrow s' \mid \tau) = P(s \rightarrow s' \mid s) = P_F(s' \mid s). \quad (19)$$

请注意，并非之前部分定义的所有流都具备马尔可夫性质（例如图 4）。直观地说，如果“流”中的粒子能够记住它的过去历史，则可以认为该流是非马尔可夫的；否则，其未来行为只能依赖于当前状态，流必须是马尔可夫的。在这项工作中，我们将主要关注马尔可夫流，尽管稍后我们将通过引入条件状态流的形式重新引入记忆，使每个流“粒子”能够记住其历史的一部分。以下命题表明，马尔可夫流具有这样的性质，即完整的轨迹流（或轨迹的概率）根据图进行分解，并且这是定义马尔可夫流的充分条件。

命题 16 设 (G, F) 是一个流网络， F 是相应的流概率。以下三个陈述是等价的：

1. F is a Markovian flow
2. 存在一个唯一的概率函数 $\hat{P}_F$ 与 G 相一致，使得对于所有完整的轨迹 $\tau = (s_0, \dots, s_{n+1} = s_f)$ ：

$$P(\tau) = \prod_{t=1}^{n+1} \hat{P}_F(s_t \mid s_{t-1}). \quad (20)$$

此外，概率函数 $\hat{P}_F$ 正好是与流概率 P ： $\hat{P}_F = P_F$ 相关联的前向转移概率。

3. 存在一个唯一的概率函数 $\hat{P}_B$ 与 G 相一致，使得对于所有完整的轨迹 $\tau = (s_0, \dots, s_{n+1} = s_f)$ ：

$$P(\tau) = \prod_{t=1}^{n+1} \hat{P}_B(s_{t-1} \mid s_t). \quad (21)$$

此外，概率函数 $\hat{P}_B$ 正好是与流概率 P ： $\hat{P}_B = P_B$ 相关联的后向转移概率。

证明 回忆定理 5 中的记号 $\mathcal{T}_{0,s}$ 表示从 s_0 到 s 的部分轨迹集合, 以及 $\mathcal{T}_{s',f}$ 表示从 s' 到 s_f 的部分轨迹集合。我们将证明等价性 $1 \Leftrightarrow 2$ 和 $1 \Leftrightarrow 3$ 。

- $1 \Rightarrow 2$: 假设 F 是一个马尔可夫流。然后利用概率定律, 方程 (19) 中的马尔可夫性质, 以 $(s_0, \dots, s_{n+1} = s_f)$: 及 $P(s_0) = 1$, 对于某个完整的轨迹 $\tau =$

$$\begin{aligned} P(\tau) &= P(s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_{n+1}) = P(s_0 \rightarrow s_1) \prod_{t=1}^n P(s_t \rightarrow s_{t+1} \mid s_0 \rightarrow \dots \rightarrow s_t) \\ &= P(s_0 \rightarrow s_1) \prod_{t=1}^n P(s_t \rightarrow s_{t+1} \mid s_t) \\ &= P(s_0) P_F(s_1 \mid s_0) \prod_{t=1}^n P_F(s_{t+1} \mid s_t) \\ &= \prod_{t=1}^{n+1} P_F(s_t \mid s_{t-1}), \end{aligned}$$

其中第二行使用了马尔可夫性质, 第三行使用了前向转移概率的定义 P_F . P_F , 从而满足方程 (20) 对于所有完整的轨迹。

为了证明 P_F 的独特性, 假设对于所有完整的轨迹, 存在某个 $\hat{P}_F$ 满足方程 (20)。根据前向转移概率的定义:

$$P_F(s' \mid s) := P(s \rightarrow s' \mid s) = \frac{P(s \rightarrow s')}{P(s)}.$$

任何完整的轨迹 (τ) 经过一个状态 (s) 可以被唯一地分解为从 (s_0) 到 (s) 的部分轨迹 ($\tau' \in \mathcal{T}_{0,s}$), 以及从 (s) 到 (s_f) 的部分轨迹 ($\tau'' \in \mathcal{T}_{s,f}$)。根据 ($P(s)$) 的定义, 我们有:

$$\begin{aligned} P(s) &= \sum_{\tau: s \in \tau} P(\tau) = \sum_{\tau: s \in \tau} \prod_{(s_t \rightarrow s_{t+1}) \in \tau} \hat{P}_F(s_{t+1} \mid s_t) \\ &= \left[\sum_{\tau' \in \mathcal{T}_{0,s}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau'} \hat{P}_F(s_{t+1} \mid s_t) \right] \underbrace{\left[\sum_{\tau'' \in \mathcal{T}_{s,f}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau''} \hat{P}_F(s_{t+1} \mid s_t) \right]}_{=1 \quad (\text{Theorem 5})} \\ &= \sum_{\tau' \in \mathcal{T}_{0,s}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau'} \hat{P}_F(s_{t+1} \mid s_t). \end{aligned}$$

类似地, 任何经过的完整轨迹 $s \rightarrow s'$ 可以 (唯一地) 分解为部分轨迹 $\tau' \in \mathcal{T}_{0,s}$ 从 s_0 到 s , 以及部分轨迹 $\tau'' \in \mathcal{T}_{s',f}$ 从

s' 到 s_f 。再次，利用 $P(s \rightarrow s')$ 的定义

$$\begin{aligned}
 P(s \rightarrow s') &= \sum_{\tau: (s \rightarrow s') \in \tau} P(\tau) = \sum_{\tau: (s \rightarrow s') \in \tau} \prod_{(s_t \rightarrow s_{t+1}) \in \tau} \hat{P}_F(s_{t+1} | s_t) \\
 &= \underbrace{\left[\sum_{\tau' \in \mathcal{T}_{0,s}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau'} \hat{P}_F(s_{t+1} | s_t) \right]}_{= P(s)} \hat{P}_F(s' | s) \underbrace{\left[\sum_{\tau'' \in \mathcal{T}_{s',f}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau''} \hat{P}_F(s_{t+1} | s_t) \right]}_{= 1 \quad (\text{Theorem 5})} \\
 &= P(s) \hat{P}_F(s' | s).
 \end{aligned}$$

将上述两个结果结合，我们得到：

$$P_F(s' | s) = \frac{P(s \rightarrow s')}{P(s)} = \hat{P}_F(s' | s).$$

- $2 \Rightarrow 1$: 假设存在一个概率函数 $\hat{P}_F$ 与 G 一致，使得对于某个完整的轨迹 $\tau = (s_0, \dots, s_{n+1} = s_f)$

$$P(\tau) = \prod_{t=1}^{n+1} \hat{P}_F(s_t | s_{t-1}).$$

出于与证明 $1 \Rightarrow 2$ 唯一性时相同的理由， $\hat{P}_F$ 必然等于向前转移概率 P_F ，与之相关联的是 P 。

我们现在希望证明与 F 相关的流 F 具有马尔可夫性，通过展示来自公式 (19) 的马尔可夫性质。设 $\tau' \in \mathcal{T}_{0,s}$ 是从 s_0 到 s 的任意部分轨迹；利用条件概率的定义：

$$P(s \rightarrow s' | \tau') = \frac{P(s_0 \rightarrow \dots \rightarrow s \rightarrow s')}{P(s_0 \rightarrow \dots \rightarrow s)}.$$

沿用上述相同的思想，我们现在将 $P(s_0 \rightarrow \dots \rightarrow s)$ 重写为具有相同前缀轨迹的完整轨迹之和 τ' 。任何这样的完整轨迹 τ 都可以（唯一地）分解为这个共同的前缀 τ' 以及从 s 到 s_f 的部分轨迹 $\tau'' \in \mathcal{T}_{s,f}$ 。

$$\begin{aligned}
 P(s_0 \rightarrow \dots \rightarrow s) &= \sum_{\tau: \tau' \subseteq \tau} P(\tau) = \sum_{\tau: \tau' \subseteq \tau} \prod_{(s_t \rightarrow s_{t+1}) \in \tau} P_F(s_{t+1} | s_t) \\
 &= \left[\prod_{s_{t-1} \rightarrow s_t \in \tau'} P_F(s_t | s_{t-1}) \right] \underbrace{\left[\sum_{\tau'' \in \mathcal{T}_{s,f}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau''} P_F(s_{t+1} | s_t) \right]}_{= 1 \quad (\text{Theorem 5})} \\
 &= \prod_{s_{t-1} \rightarrow s_t \in \tau'} P_F(s_t | s_{t-1}).
 \end{aligned}$$

类似地，任何完整的轨迹 τ 如果共享相同的前缀轨迹 $(s_0, \dots, s, s')$ 可以被（唯一地）分解为这个共同的前缀和一个从 s' 到 s_f 的部分轨迹 $\tau'' \in \mathcal{T}_{s',f}$ ，从而导致：

$$P(s_0 \rightarrow \dots \rightarrow s \rightarrow s') = P(s_0 \rightarrow \dots \rightarrow s)P_F(s' | s)$$

结合上述两个结果，我们可以得出结论， F 满足马尔可夫性质，因此流 F 是马尔可夫的：

$$P(s' \rightarrow s | \tau') = \frac{P(s_0 \rightarrow \dots \rightarrow s \rightarrow s')}{P(s_0 \rightarrow \dots \rightarrow s)} = P_F(s' | s) = P(s' \rightarrow s | s)$$

- $\{1, 2\} \Rightarrow 3$: 假设 F 是一个马尔可夫流。我们在上面已经证明这等价于 F 可以被分解成前向转移概率的乘积。对于某个完整的轨迹 $\tau = (s_0, \dots, s_{n+1} = s_f)$:

$$P(\tau) = \prod_{t=1}^{n+1} P_F(s_t | s_{t-1}) = \prod_{t=1}^{n+1} \frac{P(s_{t-1} \rightarrow s_t)}{P(s_{t-1})} = \prod_{t=1}^{n+1} \frac{P(s_{t-1} \rightarrow s_t)}{P(s_t)} = \prod_{t=1}^{n+1} P_B(s_{t-1} | s_t),$$

where the third equality uses the fact that $P(s_0) = P(s_f) = 1$, and using the definition of the backwards transition probability P_B . The proof of uniqueness of P_B is similar to that of P_F in $1 \Rightarrow 2$, and uses:

$$\begin{aligned} P(s \rightarrow s') &= \sum_{\tau: (s \rightarrow s') \in \tau} P(\tau) = \sum_{\tau: (s \rightarrow s') \in \tau} \prod_{(s_t \rightarrow s_{t+1}) \in \tau} \hat{P}_B(s_t | s_{t+1}) \\ &= \underbrace{\left[\sum_{\tau' \in \mathcal{T}_{0,s}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau'} \hat{P}_B(s_t | s_{t+1}) \right]}_{=1 \quad (\text{Theorem 5})} \hat{P}_B(s | s') \underbrace{\left[\sum_{\tau'' \in \mathcal{T}_{s',f}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau''} \hat{P}_B(s_t | s_{t+1}) \right]}_{=P(s')} \\ &= P(s') \hat{P}_B(s | s'), \end{aligned}$$

- $3 \Rightarrow 1$: 类似于证明 $2 \Rightarrow 1$, $\hat{P}_B$ 必然等于与 P 相关的后向转移概率 P_B 。此外， P_B 与前向转移概率 P_F 有关：

$$P(s \rightarrow s') = P_B(s | s')P(s') = P_F(s' | s)P(s).$$

因此，我们可以用 P_F 来表示 F 的分解，而不是 P_B 。对于某个完整的轨迹 $\tau = (s_0, \dots, s_{n+1} = s_f)$:

$$\begin{aligned} P(\tau) &= \prod_{t=1}^{n+1} P_B(s_{t-1} | s_t) = \prod_{t=1}^{n+1} \frac{P(s_{t-1})}{P(s_t)} P_F(s_{t+1} | s_t) = \frac{P(s_0)}{P(s_f)} \prod_{t=1}^{n+1} P_F(s_{t+1} | s_t) \\ &= \prod_{t=1}^{n+1} P_F(s_{t+1} | s_t), \end{aligned}$$

其中我们利用了事实，即 $P(s_0) = P(s_f) = 1$ 。使用“ $2 \Rightarrow 1$ ”，我们可以得出结论， F 是一个马尔可夫流。

■

方程 (20) 的分解展示了如何使用马尔可夫流从终止状态的概率 P_T (方程 (18)) 中抽取终止状态。具体来说, 我们有以下推论:

推论 17 设 (G, F) 是一个马尔可夫流网络, P_F 是相应的前向转移概率。考虑从 $s = s_0$ 开始的过程, 并迭代地从 $P_F(\cdot | s)$ 中抽取一个样本直到到达 s_f 。那么该过程在状态 s 终止的概率是 $P_T(s)$ 。

证明 首先注意到, 在给定 G 是有向无环图的情况下, 该过程以概率 1 终止。对于过程在状态 s 终止意味着, 在过程中隐式构造的轨迹 $\tau \in \mathcal{T}$ 包含边 $s \rightarrow s_f$ 。过程在状态 s 终止的概率为:

$$\sum_{\tau \in \mathcal{T}: s \rightarrow s_f \in \tau} \prod_{\substack{s' \rightarrow s'' \in \tau \\ P(\tau), \text{ 根据公式 (20)}}} P_F(s'' | s') = P(s \rightarrow s_f) = P_T(s)$$

■

以下命题表明, 作为定理 16 的结果, 我们得到了 Markov 流的三种不同参数化。

命题 18 给定一个有根有向无环图 $G = (\mathbb{A}, \mathbb{E})$, 一个马尔可夫流在 G 完全且唯一地由以下一项指定: 1. 总流的组合

对于所有边 $s \rightarrow s' \in \mathbb{A}$, $\hat{Z}$ 以及前向转移概率 $\hat{P}_F(s' | s)$

对于所有边 $s \rightarrow s' \in \mathbb{A}$, $\hat{Z}$ 以及后向转移概率 $\hat{P}_B(s | s')$

对于所有终止边 $s \rightarrow s_f$, $\hat{F}(s \rightarrow s_f)$ 以及反向转移概率 $\hat{P}_B(s | s')$ 对于所有非终止边 $s \rightarrow s' \in \mathbb{A}^{-f}$, 证明 在前两种设置中, 我们定义了一个流函数

$F : \mathcal{T} \rightarrow \mathbb{R}^+$ 在轨迹) 上表示

$\tau = (s_0, s_1, \dots, s_n, s_{n+1} = s_f)$ 为:

1. $F(\tau) := \hat{Z} \prod_{t=1}^{n+1} \hat{P}_F(s_t | s_{t-1}),$
2. $F(\tau) := \hat{Z} \prod_{t=1}^{n+1} \hat{P}_B(s_{t-1} | s_t)$

我们需要证明它是唯一可以为这两种情况定义的 Markov 流。第三种情况的证明将从第二种情况的证明中得出。第一种情况:

首先，我们需要证明与流函数 F (公式 (10)) 相关的总流量 Z 匹配 $\hat{Z}$ 。这是定理 5 的结果：

$$Z = \sum_{\tau \in \mathcal{T}} F(\tau) = \hat{Z} \underbrace{\sum_{\tau=(s_0, s_1, \dots, s_{n+1}=s_f) \in \mathcal{T}} \prod_{t=1}^{n+1} \hat{P}_F(s_t | s_{t-1})}_{=1, \text{ according to Theorem 5}} = \hat{Z}$$

然后，我们需要证明与 F (公式 (16)) 相关的前向转移概率函数 P_F 匹配 $\hat{P}_F$ ，并且流 F 是 Markov 的。为此，请注意相应的流概率 F 满足公式 (20)。因此，作为定理 16 的结果， F 是一个 Markov 流，其前向转移概率函数是 $\hat{P}_F$ 。最后的要求是，如果一个 Markov 流 F' 有一个分区函数 $Z' = \hat{Z}$ 和一个前向转移概率函数 $P'_F = \hat{P}_F$ ，那么它必然等于 F 。这是定理 16 的直接结果，因为对于任何 $\tau = (s_0, \dots, s_{n+1} = s_f) \in \mathcal{T}$ ：

$$F'(\tau) = Z' \prod_{t=1}^{n+1} P'_F(s_t | s_{t-1}) = \hat{Z} \prod_{t=1}^{n+1} \hat{P}_F(s_t | s_{t-1}) = F(\tau)$$

第二种情况：首先，我们证明作为定理 5 的结果，与 F 相关的总流 Z 匹配 $\hat{Z}$ ：

$$Z = \sum_{\tau \in \mathcal{T}} F(\tau) = \hat{Z} \underbrace{\sum_{\tau=(s_0, s_1, \dots, s_{n+1}=s_f) \in \mathcal{T}} \prod_{t=1}^{n+1} \hat{P}_B(s_{t-1} | s_t)}_{=1, \text{ according to Theorem 5}} = \hat{Z}$$

其次，我们注意到与之相关的流概率 F 满足方程 (21)。因此，根据定理 16， F 是一个马尔可夫流，其后向转移概率函数为 $\hat{P}_B$ 。最后，如果一个马尔可夫流 F' 具有一个划分函数 $Z' = \hat{Z}$ 和一个后向转移概率函数 $P'_B = \hat{P}_B$ ，那么根据定理 16， $\forall \tau \in \mathcal{T}$ ， $F'(\tau) = F(\tau)$ 。第三种设定：从终止流 $\hat{F}(s \rightarrow s_f)$ 和非终止边的后向转移概率 $\hat{P}_B(s | s')$ ，我们可以唯一地定义一个总流 $\hat{Z}$ ，并将 $\hat{P}_B$ 扩展到所有边如下：

$$\hat{Z} := \sum_{s \in \text{Par}(s_f)} \hat{F}(s \rightarrow s_f)$$

$$\hat{P}_B(s | s') := \begin{cases} \hat{P}_B(s | s') & \text{if } s' \neq s_f \\ \frac{\hat{F}(s \rightarrow s_f)}{\hat{Z}} & \text{otherwise.} \end{cases}$$

这将我们带回第二个设定，在该设定中，我们已经证明当所有边上的 $\hat{Z}$ 和 $\hat{P}_B$ 被定义时，一个马尔可夫流是唯一确定的。 ■

2.5 流匹配条件

在定理 18 中，我们看到了如何使用前向和后向概率函数来唯一地定义一个马尔可夫流。接下来我们将展示如何使用状态和边的非负函数来定义一个马尔可夫流。这样的函数不能是无约束的（如同定理 18 中的 $\hat{P}_F$ 和 $\hat{Z}$ ），正如我们在定理 8 中所看到的。

命题 19 设 $G = (\mathcal{S}, \mathbb{A})$ 是一个有根 DAG。考虑一个非负函数 $\hat{F}$ ，其输入要么是一个状态 s ，要么是一个转换 $s \rightarrow s' \in \mathbb{A}$ 。那么， $\hat{F}$ 对应于一个流当且仅当满足流匹配条件：

$$\begin{aligned} \forall s' > s_0, \quad \hat{F}(s') &= \sum_{s \in \text{Par}(s')} \hat{F}(s \rightarrow s') \\ \forall s' < s_f, \quad \hat{F}(s') &= \sum_{s'' \in \text{Child}(s')} \hat{F}(s' \rightarrow s'') \end{aligned} \quad (22)$$

这些条件得到满足。更具体地说， $\hat{F}$ 唯一地定义了一个马尔可夫流 F 匹配状态和转换上的 $\hat{F}$ ：

$$\forall \tau = (s_0, \dots, s_{n+1} = s_f) \in \mathcal{T} \quad F(\tau) = \frac{\prod_{t=1}^{n+1} \hat{F}(s_{t-1} \rightarrow s_t)}{\prod_{t=1}^n \hat{F}(s_t)}. \quad (23)$$

证明 必要性是定理 8 的直接结果。现在我们证明充分性。设 $\hat{P}_F$ 是由下式定义的前向概率函数：

$$\forall s \rightarrow s' \in \mathbb{A} \quad \hat{P}_F(s' | s) := \frac{\hat{F}(s \rightarrow s')}{\hat{F}(s)}.$$

$\hat{P}_F$ 与 G 一致，前提是 $\hat{F}$ 满足流匹配条件（公式 (22)）。令 $\hat{Z} = \hat{F}(s_0)$ 。根据定理 18，存在唯一的马尔可夫流 F ，其具有前向转移概率函数 $P_F = \hat{P}_F$ 和分割函数 $Z = \hat{Z}$ ，并且对于轨迹 $\tau = (s_0, \dots, s_{n+1} = s_f) \in \mathcal{T}$ ：

$$\forall \tau = (s_0, \dots, s_{n+1} = s_f) \in \mathcal{T} \quad F(\tau) = \hat{Z} \prod_{t=1}^{n+1} \hat{P}_F(s_t | s_{t-1}) = \frac{\prod_{t=1}^{n+1} \hat{F}(s_{t-1} \rightarrow s_t)}{\prod_{t=1}^n \hat{F}(s_t)}. \quad (24)$$

此外，类似于定理 16 的证明，我们可以写出对于任意状态 $s' \neq s_0$ ：

$$\begin{aligned} F(s') &= \hat{Z} \sum_{\tau \in \mathcal{T}_{0,s'}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau} \hat{P}_F(s_{t+1} | s_t) \\ &= \hat{Z} \frac{\hat{F}(s')}{\hat{F}(s_0)} \underbrace{\sum_{\tau \in \mathcal{T}_{0,s'}} \prod_{(s_t \rightarrow s_{t+1}) \in \tau} \hat{P}_B(s_t | s_{t+1})}_{=1, \text{ according to Theorem 5}} \\ &= \hat{F}(s'), \end{aligned}$$

$B(s' | s) := \frac{\hat{F}(s \rightarrow s')}{F(s)}$ 其中定义了一个与 G 一致的后向概率函数。并且
 因为 $\forall s \rightarrow s' \in \mathbb{A} \quad P_F(s' | s) = \hat{P}_F(s' | s)$, 可以得出 $\forall s \rightarrow s' \in \mathbb{A} \quad F(s \rightarrow s') = \hat{F}(s \rightarrow s')$ 。为了证明唯一性, 考虑一个马尔可夫流 F' , 它在状态和边上与 $\hat{F}$ 匹配。根据定理 16, 对于任何轨迹 $\tau = (s_0, \dots, s_{n+1} = s_f) \in \mathcal{T}$

$$F'(\tau) = \hat{Z} \prod_{t=1}^{n+1} \hat{P}_F(s_t | s_{t-1}) = \frac{\prod_{t=1}^{n+1} \hat{F}(s_{t-1} \rightarrow s_t)}{\prod_{t=1}^n \hat{F}(s_t)} = F(\tau).$$

■

请注意, 公式 (22) 可以用来递归地定义所有状态的流, 如果给定了 Z , 并且给出了前向或后向转移概率。无论哪种情况, 我们都将从流向的一个极端状态 s_0 或 s_f 开始, 然后通过流向网络的有向无环图递归地分配它, 要么向前, 要么向后。一个特别有趣的情况, 在第 3 节中将处于中心地位, 是我们给出所有终端流向 $F(s \rightarrow s_f)$, 并希望推断出其余流向网络的状态流向函数 $F(s)$ 和前向转移概率函数 $P_F(s' | s)$ 。接下来, 我们将看到如何使用与 DAG 一致的前向和后向概率函数来参数化马尔可夫流。与定理 19 中的条件不同, 新条件不涉及跨越转换的求和, 这可能会有问题, 如果每个状态可以有許多后续状态或者状态空间是连续的。有趣的是, 得到的条件类似于蒙特卡罗马尔可夫链的细致平衡条件。

定义 20 给定一个带点的有向无环图 (DAG) $G = (S, \mathbb{A})$, 一个前向转移概率函数

和一个后向转移概率函数 $\hat{P}_B$ 与 G 一致, 如果存在一个边流函数 $F : \mathbb{A} \rightarrow \mathbb{R}$ 使得

$$\forall s \rightarrow s' \in \mathbb{A} \quad \hat{P}_F(s' | s) = \frac{\hat{F}(s \rightarrow s')}{\sum_{s'' \in \text{Child}(s)} \hat{F}(s \rightarrow s'')}, \quad \hat{P}_B(s | s') = \frac{\hat{F}(s \rightarrow s')}{\sum_{s'' \in \text{Par}(s')} \hat{F}(s'' \rightarrow s')} \quad (25)$$

命题 21 设 $G = (S, \mathbb{A})$ 是一个带点的有向无环图 (DAG)。考虑一个非负函数 $\hat{F}$ 覆盖状态, 一个前向转移概率函数 $\hat{P}_F$ 和一个后向转移概率函数 $\hat{P}_B$ 与 G 一致。那么, $\hat{F}, \hat{P}_B$, 和 $\hat{P}_F$ 共同对应于一个流当且仅当细致平衡条件成立:

$$\forall s \rightarrow s' \in \mathbb{A} \quad \hat{F}(s) \hat{P}_F(s' | s) = \hat{F}(s') \hat{P}_B(s | s'). \quad (26)$$

更具体地说, $\hat{F}, \hat{P}_F$, 和 $\hat{P}_B$ 唯一地定义了一个马尔可夫流 F , 匹配状态上的 $\hat{F}$, 并且转移概率匹配 $\hat{P}_F$ 和 $\hat{P}_B$ 。此外, 当满足这一条件时, 正向和反向转移概率函数 $\hat{P}_F$ 和 $\hat{P}_B$ 是兼容的。

证明 必要性方面，考虑一个流 F ，其状态流函数表示为 $\hat{F}$ ，以及正向和反向转移 P_F 和 P_B 。从 $\hat{P}_F$ 和 $\hat{P}_B$ （定理 12）的定义可以看出等式 (26) 成立。我们通过首先定义边流来证明该条件的充分性。

$$\forall s \rightarrow s' \in \mathbb{A} \quad \hat{F}(s \rightarrow s') := \hat{F}(s) \hat{P}_F(s' | s). \quad (27)$$

然后将等式 (26) 两边对 s 求和，得到

$$\forall s' > s_0 \quad \sum_{s \in \text{Par}(s')} \hat{F}(s) \hat{P}_F(s' | s) = \hat{F}(s') \sum_{s \in \text{Par}(s')} \hat{P}_B(s | s') = \hat{F}(s') \quad (28)$$

其中我们利用了 $\hat{P}_B$ 是一个归一化的概率分布的事实。结合等式 (27)，我们得到

$$\forall s' > s_0 \quad \hat{F}(s') = \sum_{s \in \text{Par}(s')} \hat{F}(s \rightarrow s') \quad (29)$$

这是流匹配条件（等式 (22)）的第一个等式（定理 19）。我们可以通过首先使用 $\hat{P}$ 的归一化，然后使用边流的定义（等式 (27)）来获得第二个等式：

$$\begin{aligned} \forall s' > s_0 \quad \hat{F}(s') &= \hat{F}(s') \sum_{s'' \in \text{Child}(s')} \hat{P}_F(s'' | s') \\ &= \sum_{s'' \in \text{Child}(s')} \hat{F}(s') \hat{P}_F(s'' | s') \\ &= \sum_{s'' \in \text{Child}(s')} \hat{F}(s' \rightarrow s''). \end{aligned} \quad (30)$$

根据定理 119，存在唯一的马尔可夫流 F ，其状态和边流由 $\hat{F}$ 给出。利用等式 (27) 和等式 (26)，可以得出 F 具有所需的转移概率 $\hat{P}_F$ 和 $\hat{P}_B$ 。唯一性也是等式 (27) 的结果。这证明了充分性。为了证明 $\hat{P}_F$ 和 $\hat{P}_B$ 是兼容的（定理 20），我们首先结合等式 (27) 和等式 (30)（重新标记变量）以获得

$$\forall s \rightarrow s' \in \mathbb{A} \quad \hat{P}_F(s' | s) = \frac{\hat{F}(s \rightarrow s')}{\sum_{s'' \in \text{Child}(s)} \hat{F}(s \rightarrow s'')},$$

we then isolate $\hat{P}_B$ in Eq. (26), yielding

$$\forall s \rightarrow s' \in \mathbb{A} \quad \hat{P}_B(s | s') = \frac{\hat{F}(s)}{\hat{F}(s')} \hat{P}_F(s' | s) = \frac{\hat{F}(s \rightarrow s')}{\hat{F}(s')} = \frac{\hat{F}(s \rightarrow s')}{\sum_{s'' \in \text{Par}(s')} \hat{F}(s'' \rightarrow s')},$$

因此我们得到了定理 20 中的等式 (25)，如所期望的。 ■

乍一看，当 $\hat{P}_B$ 不受约束时，详细的平衡条件似乎可以通过设置来轻易实现

$$\forall s \rightarrow s' \in \mathbb{A} \quad \hat{P}_B(s | s') = \frac{\hat{P}_F(s' | s) \hat{F}(s)}{\hat{F}(s')} \quad (31)$$

然而，由于我们也存在约束 $\sum_{s \in \text{Par}(s')} \hat{P}_B(s | s') = 1$ ，则公式 (31) 可以仅在流与前向转移一致的情况下得到满足：

$$\sum_{s \in \text{Par}(s')} \hat{P}_F(s' | s) \hat{F}(s) = \hat{F}(s').$$

2.6 后向转移可以自由选择


考虑给定终止流进行匹配的情形，即目标是找到具有正确终止流的流函数。这是 Bengio 等人在 2021 年引入的情境，并将在第 3 节中进行研究。在这种情况下，定理 18 告诉我们，为了完全确定正向转移概率和状态或状态-动作流，通常仅指定终止流是不够的；还需要指定除终端边之外的其他边上的反向转移概率（后者由终止流给出）。这意味着终止流并不能完全指定流，例如，因为许多不同的路径可以到达同一个终止状态。对于实现相同最终结果的不同方式的偏好，由反向转移概率来指定 P_B （除...之外 $P_B(s | s_f)$ 这是一个终止流函数的组成部分 Z ）。例如，我们可能希望给予节点的所有父节点相同的权重 s ，或者我们可能更倾向于较短的路径，这可以通过在状态中记录路径长度来实现 s 最短路径到该节点的长度 s ，或者我们可以让学习者发现一个 P_B 这使得学习 P_F 或者 F 更简单。

2.7 流之间的等价性

在前几节中，我们已经看到马尔可夫流具有轨迹流或概率根据有向无环图分解的性质，并且我们已经看到了表征马尔可夫流的不同方法。在第 3 节中，我们将展示如何近似马尔可夫流以定义终止状态上的概率测度。在本节中，通过轨迹流之间的等价关系，我们证明了对马尔可夫流的关注是有道理的。给定一个有向无环图的指定点 $G = (\mathcal{S}, \mathbb{A})$ ，我们表示：
 • $\mathcal{F}(G)$ ：在 G 上的流集合，即从 $\mathcal{T}$ ，即在 G 中的完整轨迹集合，到 $\mathbb{R}^+$ ，的函数集合
 • $\mathcal{F}_{\text{Markov}}(G)$ ：在 $\mathcal{F}(G)$ 中的马尔可夫流集合。

定义 22 设 $G = (\mathcal{S}, \mathbb{A})$ 是一个有向无环图，并且 $F_1, F_2 \in \mathcal{F}(G)$ 两个轨迹流函数。我们说 F_1 和 F_2 当它们在边流上一致时是等价的，即：

$$\forall s \rightarrow s' \in \mathbb{A} \quad F_1(s \rightarrow s') = F_2(s \rightarrow s')$$



τ	$F_1(\tau)$	$F_2(\tau)$	$F_3(\tau)$	$F_4(\tau)$
s_0, s_2, s_f	1	4/5	1	6/5
s_0, s_1, s_2, s_f	1	6/5	1	4/5
s_0, s_2, s_3, s_f	1	6/5	2	9/5
s_0, s_1, s_2, s_3, s_f	2	9/5	1	6/5

图 4: 等价流和马尔可夫流。流 F_1 和 F_2 是等价的。 F_3 和 F_4 是等价的, 但不等价于 F_1 和 F_2 。 F_4 是马尔可夫流。 F_1 和 F_3 不是马尔可夫流。 F_1, F_2, F_3 和 F_4 在终止流上一致, 即在 $s_2 \rightarrow s_f$ 和 $s_3 \rightarrow s_f$ 处。

图 4 展示了一个简单的尖状 DAG 中四个两两等价的流函数。这定义了一个等价关系（即一个自反的、对称的和传递的关系）。因此，每个流 F 属于一个等价类，所有流的集合 $\mathcal{F}(G)$ 可以划分为若干等价类。需要注意的是，如果两个流等价，则相应的状态流函数也相同（这是定理 8 的直接结果）。

命题 23 给定一个有根 DAG G 。如果两个流函数 $F_1, F_2 \in \mathcal{F}_{Markov}(G)$ 是等价的，则它们相等。此外，对于任何流函数 $F \in \mathcal{F}_{Markov}(G)$ ，使得 F 和 F' 是等价的。

证明 因为 F_1 和 F_2 具有马尔可夫性，则对于任意轨迹 $\tau = (s_0, \dots, s_{n+1} = s_f)$:

$$\begin{aligned}
 F_1(\tau) &= \frac{\prod_{t=1}^{n+1} F_1(s_{t-1} \rightarrow s_t)}{\prod_{t=1}^n F_1(s_t)} \\
 &= \frac{\prod_{t=1}^{n+1} F_2(s_{t-1} \rightarrow s_t)}{\prod_{t=1}^n F_2(s_t)} \\
 &= F_2(\tau),
 \end{aligned}$$

本文结合等价流的定义和定理 16。给定一个流函数 F' ，由于其状态和边流函数满足流匹配条件（根据定理 8 的结果），则根据定理 19，流 F 被定义为：

$$\forall \tau := (s_0, \dots, s_{n+1} = s_f) \in \mathcal{T} \quad F(\tau) = \frac{\prod_{t=1}^{n+1} F'(s_{t-1} \rightarrow s_t)}{\prod_{t=1}^n F'(s_t)}$$

具有马尔可夫性，并与状态和边流量上的 F' 一致。结合上述陈述，我们得出结论， F 是唯一等价于 F' 的马尔可夫流。

■

之前的命题表明，在每个等价类中突出一个特定的流函数，该函数具有其他同类别流函数所不具备的性质：它是马尔可夫的。这一结果的推论是，如果我们主要关心状态和边的流，那么无需处理全部的流集合 $\mathcal{F}(G)$ ，只需将任何流学习问题限制于

马尔可夫流的集合 $\mathcal{F}_{Markov}(G)$ 。这种限制的优势在于定义一个流需要指定 $F(\tau)$ 对于所有轨迹 $\tau \in \mathcal{T}$ ，而定义一个马尔可夫流则只需指定 $F(s \rightarrow s')$ 对于所有边 $s \rightarrow s' \in \mathbb{A}$ ，这通常比 $\mathcal{T}$ 要小得多（请注意，边流仍需满足定理 19 中的流匹配条件）。因此，为了近似或学习一个满足某些边或状态值条件的流函数，只需近似或学习一个马尔可夫流，即学习边流函数，这比实际的流函数要小得多。

3 GFlowNets: 学习流

在第 1 节和第 2 节建立了理论基础后，我们现在考虑 Bengio 等人 (2021) 引入的一类问题，其中给出了关于流的一些约束或偏好。我们的目标是找到诸如状态流函数 $F(s)$ 或转移概率函数 $P(s \rightarrow s' | s)$ 这样的函数，这些函数最好地匹配这些需求，使用相应的估计器 $\hat{F}(s)$ 和 $\hat{P}(s \rightarrow s' | s)$ ，它们可能不对应于一个合适的流。这种学习机被称为生成流网络（简称 GFlowNets）。我们关注给定目标奖励函数 $R: \mathcal{S}^f \rightarrow \mathbb{R}^+$ 的情况下，估计满足条件的流 F 。

$$\forall s \in \mathcal{S}^f \quad F(s \rightarrow s_f) = R(s) \quad (32)$$

由于流集合中存在的等价性，不失一般性，我们选择 GFlowNets 来近似马尔可夫流。因此，我们对以下流集合感兴趣：

$$\mathcal{F}_{Markov}(G, R) = \{F \in \mathcal{F}_{Markov}(G), \forall s \in \mathcal{S}^f \quad F(s \rightarrow s_f) = R(s)\} \quad (33)$$

目前，我们非正式地定义 **GFlowNet** 为马尔可夫流函数 $F \in \mathcal{F}_{Markov}(G, R)$ 的估计器。稍后我们将提供更正式的定义。有了这样一个马尔可夫流 F 的估计器 $\hat{F}$ ，我们可以定义一个近似的前向转移概率函数 $\hat{P}_F$ ，如定理 16 所示，以便绘制轨迹 $\tau \in \mathcal{T}$ （在 G 中的完整轨迹集）通过迭代采样每个状态，从 s_0 开始，然后使用 $s_{t+1} \sim \hat{P}_F(\cdot | s_t)$ 直到到达汇状态 $s_{n+1} = s_f$ 对于某些 n 。接下来，我们将阐明如何获得这样的估计器。

3.1 GFlowNets 作为 MCMC 抽样的替代方案

大约从与能量函数 $\mathcal{E}$ 相关的分布中抽样的主要已建立方法是蒙特卡洛马尔可夫链（MCMC）方法，这需要大量的计算（运行可能非常长的马尔可夫链）来获取样本。相反，GFlowNet 方法预先计算以训练生成器，该生成器产生非常高效的计算（构建单个配置，不需要链）用于每个新样本。例如，Bengio 等人 (2021) 构建了一个 GFlowNet，它通过一系列小动作构建分子，每个动作都添加一个原子或分子亚结构到由图表示的现有分子中，从空图开始。

与 MCMC 方法相比，仅需考虑一种配置即可。MCMC 方法需要生成可能非常长的配置链，并且会受到模式混合挑战的影响（Jasra 等，2005；Bengio 等，2013；Pompe 等，2020），这可能导致在模式间距离上的计算时间呈指数级增长。而在 GFlowNets 中，这种计算挑战得以避免，但计算需求转化为训练 GFlowNet 的需求。为了说明这一点如何极其有益，假设已经构建了一些配置 x 并获得了它们的未归一化概率或奖励 $R(x)$ 。通过这些配对 $(x, R(x))$ ，一个机器学习系统可能能够泛化关于其他地方的 R 的价值，并且如果它是一个生成模型，可以在大 $R(x)$ 的地方采样新的 x 。因此，如果在如何关联 R 模式之间存在潜在的统计结构，那么一个能够泛化的生成学习者可以猜测尚未访问过的模式的存在，利用已经从 $(x, R(x))$ 配对中发现的模式。另一方面，如果没有结构（模式随机放置），则不应期望 GFlowNets 比 MCMC 有显著更好的表现，因为在高维空间中训练变得不可行（因为它需要访问配置空间的每个区域以确定其奖励）。

3.2 GFlowNets 和流匹配损失

我们在第 2.4 节和第 2.5 节中看到了参数化流的不同方式。例如，使用分区函数和前向转移概率，或者使用满足流匹配条件的边流。由于有许多方法可以参数化 GFlowNets，我们从一个抽象的表述开始，其中 $o \in \mathcal{O}$ 表示参数配置（例如，在训练 GFlowNet 期间的结果）， $\Pi(o)$ 给出相应的轨迹概率测度 $\tau \in \mathcal{T}$ ，而 $\mathcal{H}$ 将马尔可夫流 F 映射到其参数化 o 。在以下定义中，我们展示了这样的参数化应满足哪些条件。

Definition 24 *Given a pointed DAG $G = (\mathcal{S}, \mathbb{A})$, with an initial and sink states s_0 and s_f respectively, and a target reward function $R: \mathcal{S}^f \rightarrow \mathbb{R}^+$, we say that the triplet $(\mathcal{O}, \Pi, \mathcal{H})$ is a **flow parametrization** of (G, R) if:*

1. $\mathcal{O}$ 是非空集合，2. Π 是将每个对象 $o \in \mathcal{O}$ 映射到元素 $\Pi(o) \in \Delta(\mathcal{T})$ ，即在 $\mathcal{T}$ 上的概率分布集合，3. $\mathcal{H}$ 是从 $\mathcal{F}_{\text{Markov}}(G, R)$ 到 $\mathcal{O}$ 的单射泛函，4. 对于任何 $F \in \mathcal{F}_{\text{Markov}}(G, R)$ ， $\Pi(\mathcal{H}(F))$ 是与其相关的概率测度。

flow F

对于每个对象 $o \in \mathcal{O}$ ，分布 $\Pi(o)$ 隐式定义了一个终止状态的概率测度：

$$\forall s \in \mathcal{S}^f \quad P_T(s) := \sum_{\tau \in \mathcal{T}: s \rightarrow s_f \in \tau} \Pi(o)(\tau), \quad (34)$$

其中省略了在 o 中对 P_T 的依赖关系以使表达更清晰。

引入 $(\mathcal{O}, \Pi, \mathcal{H})$ 的直觉是我们可以为每个对象 $o \in \mathcal{O}$ 定义一个概率测度 $\mathcal{T}$ ，但只有其中某些对象对应于具有正确终止流的马尔可夫流。对于此类对象 o （即可以表示为 $o = \mathcal{H}(F)$ 的形式，对于某个流 $F \in \mathcal{F}_{Markov}(G, R)$ ），根据定理 13，测度概率 P_T 对应于感兴趣的分布，即：

$$\forall s \in \mathcal{S}^f \quad P_T(s) \propto R(s)$$

因此，GFlowNets 提供了一种解决从目标奖励函数 R 或其相关能量函数进行采样的通常难以处理的问题的方法：

$$\forall s \in \mathcal{S}^f \quad \mathcal{E}(s) := -\log R(s) \quad (35)$$

直接逼近流 $F \in \mathcal{F}_{Markov}(G, R)$ 是一个难题，而对某些集合而言 $\mathcal{O}$ 寻找一个对象 $o \in \mathcal{H}(\mathcal{F}_{Markov}(G, R)) \subseteq \mathcal{O}$ 则是一个可以通过函数逼近技术解决的简单问题。需要注意的是，该集合 $\mathcal{O}$ 不能是任意的，因为需要定义一个从 $\mathcal{F}_{Markov}(G, R)$ 到 $\mathcal{O}$ 的单射函数。下面，对于给定的有向无环图 G ，我们将展示三个例子来阐明参数化的抽象概念：

示例 1 边缘流参数化：考虑 $\mathcal{O}_{edge} = \mathcal{F}(\mathbb{A}^{-f}, \mathbb{R}^+)$ ，函数集合从

$\mathbb{A}^{-f}$ 到 $\mathbb{R}^+$ ，以及泛函 $\mathcal{H}_{edge}$ $\mathcal{O}_{edge}$ 和 $\Pi_{edge} : \mathcal{O}_{edge} \rightarrow \Delta(\mathcal{T})$ 定义为：

$$\mathcal{H}_{edge}(F) : (s \rightarrow s') \in \mathbb{A}^{-f} \mapsto F(s \rightarrow s'),$$

$$\forall \tau = (s_0, \dots, s_n = s_f) \in \mathcal{T} \quad \Pi_{edge}(\hat{F})(\tau) \propto \prod_{t=1}^n P_{\hat{F}}(s_t \mid s_{t-1}),$$

其中

$$P_{\hat{F}}(s' \mid s) = \begin{cases} \frac{\hat{F}(s \rightarrow s')}{\sum_{s'' \neq s_f} \hat{F}(s \rightarrow s'') + R(s)} & \text{if } s' \neq s_f \\ \frac{R(s)}{\sum_{s'' \neq s_f} \hat{F}(s \rightarrow s'') + R(s)} & \text{if } s' = s_f \end{cases} \quad (36)$$

$\mathcal{H}_{edge}$ 的单射性直接由定理 23 得出（两个马尔可夫流如果在终止边和非终止边的流量值上都相同，则这两个流相等）。对于任意马尔可夫流 $F \in \mathcal{F}_{Markov}(G, R)$ ， $\Pi_{edge}(\mathcal{H}_{edge}(F))$ 等于与之关联的概率测度 F ，这一点在定理 16 中已证明。 $(\mathcal{O}_{edge}, \Pi_{edge}, \mathcal{H}_{edge})$ 是有效流参数化之一 (G, R) 。

例 2 前向转移概率参数化：考虑集合 $\mathcal{O}_{PF} = \mathcal{F}(\mathcal{S} \setminus \{s_f\}, \mathbb{R}^+)$ 是从 $\mathcal{S} \setminus \{s_f\}$ 到 $\mathbb{R}^+$ 的函数集，并且 $\mathcal{O}_2$ 是一组与 G 一致的前向概率函数 $\hat{P}_F$ ，以及函数 $F : \mathcal{F}_{Markov}(G, R) \rightarrow \mathcal{O}_{PF}$ $P_F : \mathcal{O}_{PF} \rightarrow \Delta(\mathcal{T})$ 数泛函和 Π 定义为：

$$\mathcal{H}_{PF}(F) = (s \in \mathcal{S} \setminus \{s_f\} \mapsto F(s), (s \rightarrow s') \in \mathbb{A} \mapsto P_F(s' \mid s)),$$

$$\forall \tau = (s_0, \dots, s_n = s_f) \in \mathcal{T} \quad \Pi_{PF}(\hat{F}, \hat{P}_F)(\tau) \propto \prod_{t=1}^n \hat{P}_F(s_t | s_{t-1}),$$

其中 P_F 是与 F (Eq. (16)) 相关的前向转移概率函数。为了验证 $\mathcal{H}_{PF}$ 是单射的，考虑 $F_1, F_2 \in \mathcal{F}_{Markov}(G, R)$ 使得 $\mathcal{H}_{PF}(F_1) = \mathcal{H}_{PF}(F_2)$ 。这意味着 $\forall s \in \mathcal{S}^f, F_1(s) = F_2(s)$ ，并且 $\forall s \rightarrow s' \in \mathbb{A}, \frac{F_1(s \rightarrow s')}{F_1(s)} = \frac{F_2(s \rightarrow s')}{F_2(s)}$ 。由此得出 $\forall s \rightarrow s' \in \mathbb{A}, F_1(s \rightarrow s') = F_2(s \rightarrow s')$ 。根据定理 23，这意味着 $F_1 = F_2$ 。对于任意马尔可夫流 $F \in \mathcal{F}_{Markov}(G, R)$ ， $\Pi_{PF}(\mathcal{H}_{PF}(F))$ 等于与 F 相关的概率测度，如定理 16 所示。因此， $(\mathcal{O}_{PF}, \Pi_{PF}, \mathcal{H}_{PF})$ 是 (G, R) 的有效流参数化。

例 3 转移概率参数化：类似于例 2，我们可以使用状态流函数及其正向和反向转移概率来参数化马尔可夫流，即使用 $\mathcal{O}_{PFB} = \mathcal{O}_{PF} \times \mathcal{O}_3$ ， $\mathcal{H}_{PFB}$ 和 Π_{PFB} 定义如下：

$$\mathcal{H}_{PFB}(F) = (\mathcal{H}_{PF}(F), (s \rightarrow s') \in \mathbb{A}^{-f} \mapsto P_B(s | s')),$$

$$\forall \tau = (s_0, \dots, s_n = s_f) \in \mathcal{T} \quad \Pi_{PFB}(\hat{F}, \hat{P}_F, \hat{P}_B)(\tau) \propto \prod_{t=1}^n \hat{P}_F(s_t | s_{t-1}),$$

其中 P_B 是由式 (17) 定义的函数。 $\mathcal{O}_3$ 是与 G 一致的后向概率函数集合 $\hat{P}_B$ 。 $\mathcal{H}_{PFB}$ 的单射性是 $\mathcal{H}_{PF}$ 的直接结果。对于任何马尔可夫流 F ， $\Pi_{PFB}(\mathcal{H}_{PFB}(F))$ 等于与 F 相关的概率测度，这在命题 3 中已证明。 $(\mathcal{O}_{PFB}, \Pi_{PFB}, \mathcal{H}_{PFB})$ 是 (G, R) 的有效流参数化。

我们现在有了正式定义 GFlowNet 的所有要素：

Definition 25 A *GFlowNet* is a tuple $(G, R, \mathcal{O}, \Pi, \mathcal{H})$, where:

- $G = (S, \mathbb{A})$ is a pointed DAG with initial state s_0 and sink state s_f ,
- $R : \mathcal{S}^f \rightarrow \mathbb{R}^+$ a target reward function,
- $(\mathcal{O}, \Pi, \mathcal{H})$ a flow parametrization of (G, R) .

每个对象 $o \in \mathcal{O}$ 被称为 GFlowNet 配置。当上下文明确时，我们将使用 GFlowNet 一词指代 $(G, R, \mathcal{O}, \Pi, \mathcal{H})$ 以及特定配置 o ；类似于“神经网络”一词既指代可以由特定架构表示的函数类，也指代该类/权重配置的具体元素。如果 $o \in \mathcal{H}(\mathcal{F}_{Markov}(G, R))$ ，则相应的终止状态概率测度（等式 (34)）与目标奖励 R 成比例。

一旦我们有了一个 GFlowNet $(G, R, \mathcal{O}, \Pi, \mathcal{H})$ ，我们仍然需要一种找到对象的方法 $o \in \mathcal{H}(\mathcal{F}_{Markov}(G, R)) \subseteq \mathcal{O}$ 。为此，设计一个损失函数 $\mathcal{L}$ 在 $\mathcal{O}$ 上等于零的对象 $o \in \mathcal{H}(\mathcal{F}_{Markov}(G, R))$ 就足够了，并且仅在这些对象上等于零。如果我们的损失函数

$\mathcal{L}$ 被选择为非负，则通过逼近函数 $\mathcal{L}$ 的最小值，可以获得目标分布（在 $\mathcal{S}^f$ ）上的近似值）。这提供了一种将感兴趣的搜索问题转化为最小化问题的方法，正如我们在机器学习中通常所做的那样。对于我们在例 1、例 2 和例 3 中考虑的自然参数化，可以轻松设计出这样的损失函数，我们将在下面进行说明。

定义 26 设 $(G, R, \mathcal{O}, \Pi, \mathcal{H})$ 是一个 GFlowNet。流匹配损失是任何满足以下条件的函数 $\mathcal{L} : \mathcal{O} \rightarrow \mathbb{R}^+$:

$$\forall o \in \mathcal{O} \quad \mathcal{L}(o) = 0 \Leftrightarrow \exists F \in \mathcal{F}_{Markov}(G, R) \quad o = \mathcal{H}(F) \quad (37)$$

我们说 $\mathcal{L}$ 是边可分解的，如果存在一个函数 $L : \mathcal{O} \times \mathbb{A} \rightarrow \mathbb{R}^+$ 使得：

$$\forall o \in \mathcal{O} \quad \mathcal{L}(o) = \sum_{s \rightarrow s' \in \mathbb{A}} L(o, s \rightarrow s'),$$

我们说 $\mathcal{L}$ 是状态可分解的，如果存在一个函数 $L : \mathcal{O} \times \mathcal{S} \rightarrow \mathbb{R}^+$ 使得：

$$\forall o \in \mathcal{O} \quad \mathcal{L}(o) = \sum_{s \in \mathcal{S}} L(o, s),$$

我们说 $\mathcal{L}$ 是轨迹可分解的，如果存在一个函数 $L : \mathcal{O} \times \mathcal{T} \rightarrow \mathbb{R}^+$ such that:

$$\forall o \in \mathcal{O} \quad \mathcal{L}(o) = \sum_{\tau \in \mathcal{T}} L(o, \tau)$$

正如上面提到的，通过这样一个损失函数，我们的搜索问题可以被写作形式为最小化问题的

$$\min_{o \in \mathcal{O}} \mathcal{L}(o), \quad (38)$$

该问题可以通过梯度学习方法来解决，前提是函数 $\mathcal{L}$ 是可微的。需要注意的是，对于边可分解的 is equivalent to: 流匹配损失，在等式 (38) 中的最小化问题

$$\min_{o \in \mathcal{O}} \mathbb{E}_{(s \rightarrow s') \sim \pi_T} [L(o, s \rightarrow s')], \quad (39)$$

其中 π_T 是定义在 $\mathbb{A}$ 上的任意全支持概率分布，即一个满足 $\forall s \rightarrow s' \in \mathbb{A} \quad \pi_T(s \rightarrow s') > 0$ 的概率分布。类似的陈述也可以应用于状态可分解或轨迹可分解的流匹配损失。

例 4 考虑边流参数化 $(\mathcal{O}_{edge}, \Pi_{edge}, \mathcal{H}_{edge})$ ，以及定义为每个 $\hat{F} \in \mathcal{O}_{edge}$ 和 $s' \in \mathcal{S}$ 的函数 $L_{FM} : \mathcal{O}_{edge} \times \mathcal{S} \rightarrow \mathbb{R}^+$

$$L_{FM}(\hat{F}, s') = \begin{cases} \left(\log \left(\frac{\delta + \sum_{s \in \text{Par}(s')} \hat{F}(s \rightarrow s')}{\delta + R(s') + \sum_{s'' \in \text{Child}(s') \setminus \{s_f\}} \hat{F}(s' \rightarrow s'')} \right) \right)^2 & \text{if } s' \neq s_f, \\ 0 & \text{否则为 } 0 \end{cases}$$

其中 $\delta \geq 0$ 是一个超参数。函数 $\mathcal{L}_{FM}$ 将每个 $\hat{F} \in \mathcal{O}_{edge}$ 映射到

$$\mathcal{L}_{FM}(\hat{F}) = \sum_{s \in \mathcal{S}} L_{FM}(\hat{F}, s) \quad (40)$$

这是一个流匹配损失，根据定义，它是状态可分解的。为了说明这一点，设 $\hat{F} \in \mathcal{O}_{edge}$ 使得 $\mathcal{L}_{FM}(\hat{F}) = 0$ ，并将其扩展到终止边：

$$\forall s \in \mathcal{S}^f \quad \hat{F}(s \rightarrow s_f) := R(s)$$

现在 $\hat{F}$ 对所有在 G 中的边都已定义，我们可以写出

$$\forall s' \in \mathcal{S} \quad \sum_{s \in \text{Par}(s')} \hat{F}(s \rightarrow s') = \sum_{s'' \in \text{Child}(s')} \hat{F}(s' \rightarrow s'').$$

根据定理 19，这意味着存在一个马尔可夫流 $F \in \mathcal{F}_{Markov}(G, R)$ 使得 $\mathcal{H}_{edge}(F) = \hat{F}$ 。反之

$$\forall F \in \mathcal{F}_{Markov}(G, R) \quad \mathcal{L}_{FM}(\mathcal{H}_{edge}(F)) = 0$$

是定理 19 的一个直接推论。这就是 Bengio 等人 (2021) 提出的损失函数。 δ 允许减少对小流量的重要性（那些小于 δ 的），并且使用对数比的平方作为确保大流量状态不会比小流量状态更多地影响 $\mathcal{L}_{FM}$ 梯度的方法是合理的。

Example 5 Detailed-balance loss: Consider the transition probabilities parametrization $(\mathcal{O}_{PFB}, \Pi_{PFB}, \mathcal{H}_{PFB})$, and the function $L_{DB} : \mathcal{O}_{PFB} \times \mathbb{A} \rightarrow \mathbb{R}^+$ defined for each $(\hat{F}, \hat{P}_F, \hat{P}_B) \in \mathcal{O}_{PFB}$ and $s \rightarrow s' \in \mathbb{A}$ as

$$L_{DB}(\hat{F}, \hat{P}_F, \hat{P}_B, s \rightarrow s') = \begin{cases} \left(\log \left(\frac{\delta + \hat{F}(s) \hat{P}_F(s' | s)}{\delta + \hat{F}(s') \hat{P}_B(s | s')} \right) \right)^2 & \text{if } s' \neq s_f, \\ \left(\log \left(\frac{\delta + \hat{F}(s) \hat{P}_F(s' | s)}{\delta + R(s)} \right) \right)^2 & \text{otherwise,} \end{cases}$$

其中 $\delta \geq 0$ 是一个超参数。函数 $\mathcal{L}_{DB}$ 将每个 $(\hat{F}, \hat{P}_F, \hat{P}_B) \in \mathcal{O}_{PFB}$ 映射到

$$\mathcal{L}_{DB}(\hat{F}, \hat{P}_F, \hat{P}_B) = \sum_{s \rightarrow s' \in \mathbb{A}} L_{DB}(\hat{F}, \hat{P}_F, \hat{P}_B, s \rightarrow s')$$

这是一个流匹配损失，根据定义，它是边可分解的。该陈述的证明类似于上述示例，使用定理 21。

根据第 2.6 节，奖励函数并不能完全指定流。因此，示例 5 中的细致平衡损失可以与 $(\mathcal{O}_{PF}, \Pi_{PF}, \mathcal{H}_{PF})$ 参数化一起使用，使用任何函数 $\hat{P}_B \in \mathcal{O}_3$ 作为细致平衡损失的输入。

示例 6 轨迹平衡损失：该损失在 Malkin 等人的 (2022) 研究中被引入用于参数化 $(\mathcal{O}_{TB}, \Pi_{TB}, \mathcal{H}_{TB})$ ，其中 $\mathcal{O}_{TB} = \mathcal{O}_1 \times \mathcal{O}_2 \times \mathcal{O}_3$ ，并且 $\mathcal{O}_1 = \mathbb{R}^+$ 参数化配分函数 $\hat{Z}$ ，而 $\mathcal{O}_2$ 和 $\mathcal{O}_3$ 在例 2 和例 3 中被引入（即与 G ）。 $\mathcal{H}_{TB}$ 一致的前向和后向概率集合）将马尔可夫流映射到 $\mathcal{F}_{Markov}(G, R)$ 对应到相应的三元组 (Z, P_F, P_B) ，并且 Π_{TB} 映射一个参数化

$(\hat{Z}, \hat{P}_F, \hat{P}_B)$ 到由 $\hat{P}_F$ 定义的轨迹的概率，如同示例 2 所示。定理 18 证明了这种参数化的有效性。损失 $\mathcal{L}_{TB}$ 将每个 $(\hat{Z}, \hat{P}_F, \hat{P}_B) \in \mathcal{O}_{TB}$ 映射为：

$$\mathcal{L}_{TB}(\hat{Z}, \hat{P}_F, \hat{P}_B) = \sum_{\tau \in \mathcal{T}} L_{TB}(\hat{Z}, \hat{P}_F, \hat{P}_B, \tau),$$

其中

$$\forall \tau = (s_0, \dots, s_{n+1} = s_f) \in \mathcal{T} \quad L_{TB}(\hat{Z}, \hat{P}_F, \hat{P}_B, \tau) = \left(\log \frac{\hat{Z} \prod_{t=1}^{n+1} \hat{P}_F(s_t | s_{t-1})}{R(s_n) \prod_{t=1}^n \hat{P}_B(s_{t-1} | s_t)} \right)^2. \quad (41)$$

Malkin et al. (2022) prove that $\mathcal{L}_{TB}$ is a flow-matching loss and call it trajectory balance. It is trajectory-decomposable by definition.

通过随机梯度下降进行训练：在上一节的例子中，给定一个 GFlowNet $(G, R, \mathcal{O}, \Pi, \mathcal{H})$ 和一个流匹配损失 $\mathcal{L}$ ，对象 $o \in \mathcal{O}$ 本身是函数或函数组合，并且我们可以使用诸如神经网络之类的函数逼近器来参数化 $\mathcal{O}$ 。然而，大多数情况下，评估（更不用说最小化） $\mathcal{L}(o)$ 是不可行的，因为即使具有完全支持分布，也只能在有限时间内访问边集（或状态或轨迹）的子集。实际上，对于边缘可分解损失，例如，我们求助于随机梯度，如

$$\nabla_o L(o, s \rightarrow s'), \quad s \rightarrow s' \sim \pi_o \quad (42)$$

对于边缘可分解损失，或者

$$\nabla_o L(o, \tau), \quad \tau \sim \pi_o \quad (43)$$

对于轨迹可分解损失，其中 π_o ，称为训练分布，是在边缘或轨迹上的分布，可以与 $\Pi(o)$ 关联，对应于在线设置中的 RL，或者以其他方式定义，对应于离线 RL 的行为策略，见下文 3.3.3 节。

3.3 扩展

在本节中，我们将讨论对迄今为止介绍的 GFlowNet 训练范式的可能放宽。

3.3.1 引入时间戳以允许循环

请注意，GFlowNet 的状态空间可以轻松修改，以适应其转换不形成有向无环图 (DAG) 的基础状态空间，例如允许循环的情况。令 $\mathcal{S}$ 为这样的基础状态空间。定义扩展状态空间

$\mathcal{S}' = \mathcal{S} \times \mathbb{N}$ ，其中 $\mathbb{N} = \{0, 1, 2, \dots\}$ 是自然数集，而 $s'_t = (s_t, t)$ 是扩展状态，其中 t 是状态 s_t 在轨迹中的位置。通过这种扩展状态空间，我们自动避免了循环。此外，我们可以设计或训练反向转换概率 $P_B(s'_t | s'_{t+1} = (s_{t+1}, t+1))$ 以创建对通往 s_{t+1} 的较短路径的偏好，正如第 2.6 节所讨论的那样。请注意，我们可以通过将 $\mathbb{N}$ 替换为任何全序索引集来进一步泛化此设置；扩展状态空间仍将具有关联的 DAG。原始状态空间中的“ $<$ ”排序被提升到扩展状态空间： $(s_t, t) < (s'_t, t')$ 当且仅当 $t < t'$ 和 $s_t < s'_t$ 。

3.3.2 随机奖励

我们也考虑给定奖励是随机而非状态的确定性函数的情况，从而产生基于随机梯度下降的训练程序。例如，对于等式 (41) 中的轨迹平衡损失，如果 $R(s)$ 是随机的（即使给定 s ），我们可以认为真正优化的是平方损失，其中 $\log R(s)$ 被其期望值（给定 s ）所替代。这是最小化平方误差损失的期望值的直接结果（例如，在使用平方误差损失和随机目标输出训练的神经网络中，神经网络实际上试图估计该目标的期望值）。

3.3.3 GFlowNets 可以离线训练 如第 3.2 节所述，我们无需使用来自其自身轨迹分布的样本对 GFlowNet 进行训练 $\hat{P} = \Pi(o)$ 。这些训练轨迹可以来自任何具有全支持的训练分布 π_T ，正如 Bengio 等人（2021 年）所展示的那样。这意味着 GFlowNet 可以像离线强化学习一样进行离线训练（Ernst 等人，2005 年；Riedmiller，2005 年；Lange 等人，2012 年）。还应指出的是，通过适当地选择 π_T ，并假设计算 R 的成本低于或与在轨迹上运行 GFlowNet 相当，那么从 π_T 中连续抽取新的训练样本比重复相同的轨迹更有效率。唯一的例外可能是重复那些导致高奖励的轨迹，如果这些情况很少见的话。应该如何选择训练分布 π_T ？它需要覆盖 R 的支持范围，但如果它是均匀分布的，则会非常浪费，如果它等于当前 GFlowNet 策略 π ，则可能没有足够的有效支持，从而错过 R 的模式，即那些 $R(x)$ 显著大于 0 但 $R(x) \gg P_T(x)$ 的区域。因此，训练分布应该从一个探索性策略中采样，该策略访问尚未被访问过且可能有高奖励的地方。围绕当前策略的高认知不确定性是有意义的，贝叶斯优化中的采集函数文献（Srinivas 等人，2010 年）可能会是一个很好的指导。更一般地说，这意味着训练分布应该是自适应的。例如， π_T 可以是第二个 GFlowNet 的策略，该 GFlowNet 主要训练以匹配不同的奖励函数，当主 GFlowNet 观察到的损失较大时，该奖励函数较高。定期访问那些已知较大的 R 的轨迹，即根据从 π 中采样的样本，确保这些不会被遗忘，即使只是暂时的，也是有益的。

3.4 利用已知终止状态的数据

在某些应用中，我们可能拥有一个包含 $(s, R(s))$ 对的数据集，并希望纯粹以离线方式使用它们来训练 GFlowNet，或者我们可能希望将此类数据与奖励函数的查询 R 结合起来以训练 GFlowNet。例如，该数据集可能包含一些高回报终止状态的例子 s ，这些状态通过从随机初始化的 GFlowNet 中采样难以获得。如何使用这样的 $(s, R(s))$ 对计算 GFlowNet 参数的梯度更新？如果我们选择参数化反向转移概率 P_B （这是实现细致平衡损失所必需的），那么我们可以仅通过采样一条轨迹

τ 导向 s 使用 P_B 并使用这些轨迹来更新流和沿遍历转移的正向转移概率。然而，这本身并不能保证产生正确的 GFlowNet 采样分布，因为定义如上的训练轨迹的经验分布 τ 没有完全的支持。假设例如数据集仅包含具有 $R(s) = 1$ 的高回报终止状态。那么 GFlowNet 可以均匀地采样轨迹（这是错误的，我们希望训练集中未包含的大多数状态的概率非常小）。另一方面，如果我们将数据集中导向终端转换的轨迹分布与支持涵盖所有可能轨迹的训练分布相结合，那么 GFlowNet 的离线属性保证我们可以恢复一个流匹配模型。

4 条件流和自由能

流动网络的一个显著特性是我们可以从初始状态流 $F(s_0)$ (定理 10) 中恢复归一化常数 Z 。 Z 还为我们提供了与给定终端奖励函数相关的配分函数 R 指定终止流。

关于内部状态 s 与 $s_0 < s < s_f$ 的问题？如果我们有一个仅针对从 s 可达的终止流的归一化常数，我们将能够获得给定状态 s 的边缘化形式，即给定 s 的终止状态的条件概率 $s' \geq s$ 。自然地，人们可能会问：通过状态 s 的流 $F(s)$ 是否为我们提供了仅对下游终止流的这种边缘化？不幸的是，一般情况下，答案是否定的，如图 5 所示：在这个例子 $F(s_2)$ 中， $= 4$ ，而从 s_2 可达的终止流之和为 6（从 s_2 可达的终止状态是 $\{s_5, s_6, s_7\}$ ）。这种差异是由通过 (s_0, s_1, s_5) 的流引起的，它贡献于终止流 $F(s_5 \rightarrow s_f)$ ，但不贡献于 $F(s_2)$ ，因为 s_1 和 s_2 之间没有顺序关系。




图 5：状态条件流网络示例。(a) 原始（马尔可夫）流网络。(b) 从 s_2 可达的状态子图；存在一个通过 (s_0, s_1, s_5) 的流，它贡献于 $F(s_5 \rightarrow s_f)$ ，但不贡献于 $F(s_2)$ ，表明 $F(s_2)$ 不对其后代的奖励进行边缘化。(c) 状态条件流网络 F_{s_2} ，它与原始流 F 在子图上有所不同，但满足所需的边缘化性质。

在第 5.3 节中，我们展示了如何将 GFlowNets 应用于随机变量集的采样，以估计分配给变量子集的值的边缘概率。这需要计算上述讨论的难以处理的总和（与状态 s 的所有后代相关的奖励之和，其中 s 对应这样的变量子集，后代是对所有变量的完整指定）。这促使了以下定义：

定义 27 给定一个有根 DAG $G = (S, \mathbb{A})$ ，相应的偏序关系表示为 $\geq$ ，以及一个称为能量函数的函数 $\mathcal{E} : S \rightarrow \mathbb{R}$ ，我们定义一个状态的自由能如下：

$$\mathcal{F}(s) = -\log \sum_{s' : s' \geq s} e^{-\mathcal{E}(s')}. \quad (44)$$

自由能是与能量函数相关的边缘化操作（即对大量项求和）的一般表述，我们发现其估计为有趣的应用打开了大门，在这些应用中，通常会主要采用昂贵的 MCMC 方法。

4.1 条件流网络

在第 2.2 节中，我们将流网络定义为带有某些函数 F 的有向无环图，该函数作用于完整的轨迹集合 $\mathcal{T}$ 。我们可以扩展流网络的概念，通过使每个组件依赖于某些信息 x 。通常，这种条件变量可以表示任何条件信息，无论是流网络外部（但影响终止流）的信息，还是内部信息（例如， x 可以是另一个流网络上完整轨迹的属性，比如经过特定状态）。

定义 28 设 $\mathcal{X}$ 为一组条件变量。我们考虑由 $x \in \mathcal{X}$ 索引的一族有向无环图 $G_x = (S_x, \mathcal{A}_x)$ ，以及分别由 $(s_0 | x) \in S_x$ 和 $(s_f | x) \in S_x$ 表示的一族初始状态和终端状态。对于每个有向无环图 G_x ，记 $\mathcal{T}_x$ 为在 G_x 中的所有完整轨迹的集合，并记它们的并集为 $\mathcal{T}$ ：

$$\mathcal{T} = \bigcup_{x \in \mathcal{X}} \mathcal{T}_x.$$

条件流网络是 $\mathcal{X}$ 的规范，即家庭 $\{G_x, x \in \mathcal{X}\}$ 以及一个条件流函数 F ，也就是说一个函数 $F : \mathcal{X} \times \mathcal{T} \rightarrow \mathbb{R}^+$ ，使得当 $\tau \notin \mathcal{T}_x$ 时 $F(x, \tau) = 0$ 成立。为了清晰起见，我们将对每个 $x \in \mathcal{X}$ ，用 F_x 表示将每个 $\tau \in \mathcal{T}_x$ 映射到 $F(x, \tau)$ 的函数。类似于第 2.2 节， F_x 对于每个 x 诱导出一个测度的 σ -代数 $2^{\mathcal{T}_x}$ 。

条件流网络有效地表示了一类流网络，其索引由 x 的值决定。由于条件流网络使用与无条件流网络相同的组件定义，它们继承了所有有向无环图 G_x 和流函数 F_x 的流网络属性。特别是，我们可以直接扩展关于流的概率分布概念，状态和边流，正向和反向转移概率（第 2.3 节），马尔可夫流（第 2.4 节），以及任何流匹配条件

(第 2.5 节) 到条件流；唯一的区别在于现在每一项都明确依赖于条件变量 x 。在第 4.2 节和第 4.3 节中，我们将详细讨论两个重要的条件流网络示例：依赖外部信息改变奖励的条件流网络 $R(s | x)$ 以及依赖内部信息（即先前访问过的状态）的状态条件流网络 x

4.2 奖励条件流网络

定义 29 设 $\mathcal{X}$ 为一组条件变量。考虑由一个有向无环图 $G = (S, \mathbb{A})$ 给出的流网络和一个流函数 F 。考虑一组非负函数 $\mathcal{R}$ 关于 $\mathcal{S} : \{R_x : \mathcal{S}^f \rightarrow \mathbb{R}^+, x \in \mathcal{X}\}$ 。如果奖励条件流网络与 $\mathcal{R}$ 相容，则是一个条件流网络（定理 28），其中 $G_x = G$ 对于每一个 $x \in \mathcal{X}$ 使得由条件流函数诱导出的边流函数 F 满足：

$$\forall x \in \mathcal{X} \quad \forall s \in \mathcal{S}^f \quad F_x(s \rightarrow s_f) = R_x(s).$$

我们将交替使用符号 $R_x(s)$ 和 $R(s | x)$ 。

请注意，上述定义意味着奖励条件流网络中的所有 DAG 都是相同的，只有终止流在家族成员之间有所不同。

例 7 我们将在第 4.4 节中看到，给定一个奖励函数 $R(s | x)$ ，我们可以使用 GFlowNet（第 3 节）来估计一个条件流网络。在基于能量的模型中，模型 $P_\theta(s)$ 与给定的能量函数 $\mathcal{E}_\theta(s)$ 相关，参数化为 θ ，其中 $P_\theta(s) = \frac{\exp(-\mathcal{E}_\theta(s))}{Z(\theta)}$ 。这个模型可以使用基于奖励的条件流网络进行参数化，条件为 θ ，奖励函数为 $R(s | \theta) = \exp(-\mathcal{E}_\theta(s))$ 。我们在第 4.5 节中展示了如何使用这样的条件流网络来学习基于能量的模型。

4.3 状态条件流网络

定义 30 考虑由有向无环图给出的流网络 $G = (S, \mathbb{A})$ 以及一个流函数 F 对于每个状态 $s \in S$ ，令 G_s 为其子图 G 包含所有状态 s' 使得 $s' \geq s$ 。如果状态条件流网络由以下族给出 $\{G_s, s \in S\}$ ，以及一个条件流函数 $F : S \times \mathcal{T} \rightarrow \mathbb{R}^+$ ，其中 $\mathcal{T} = \bigcup_{s \in S} \mathcal{T}_s$ ，并且 $\mathcal{T}_s$ 在 G_s 中的完整轨迹集合 $\mathcal{G}_s$ ，满足：

$$F_s(s' \rightarrow s_f) = F(s' \rightarrow s_f). \quad (45)$$

请注意，在上述定义中，我们滥用符号 F 来指代流函数和边流函数，但也使用 F_s 来指代条件流函数（或相应的边流函数） $\tau \mapsto F(s, \tau)$ 。与第 4.2 节中定义的基于奖励的条件流网络不同，状态条件流网络中的 DAG 结构

取决于锚定状态 s 。特别是这意味着初始状态 $(s_0 | s) = s$ 变化，但最终状态 $(s_f | s) = s_f$ 保持不变，对于任何状态 s 。由于状态条件流网络的定义依赖于原始流网络，我们必须确保这个定义是正确的，即满足等式 (45) 的状态条件流网络确实存在。

命题 31 对于由有向无环图 (DAG)

$G = (S, \mathbb{A})$ 和流 F 给定的任何流网络，

我们可以根据定理 30 定义一个状态条件流网络。

证明 设 $s \in S$ 是一个状态。由于 DAG G_s 的结构显然是明确定义的，我们只需要证明存在一个满足方程 (45) 的流函数 $F_s : \mathcal{T}_s \rightarrow \mathbb{R}^+$ 。如果对于每一个 $s \in S$ 都存在这样的函数，则足以将条件流函数 $F : S \times \mathcal{T} \rightarrow \mathbb{R}^+$ 定义为：

$$F(s, \tau) = \begin{cases} F_s(\tau) & \text{if } \tau \in \mathcal{T}_s \\ 0 & \text{否则} \end{cases}.$$

设 $A_{s'|s}$ 是终止于 $s' \geq s$ 的在 $\mathcal{T}_s$ 中的所有完整轨迹的集合；则方程 (45) 中的条件可以表示为：

$$F_s(s' \rightarrow s_f) = F_s(A_{s'|s}) = \sum_{\tau \in A_{s'|s}} F_s(\tau) = F(s' \rightarrow s_f). \quad (46)$$

请注意，在方程 (46) 中， $F(s' \rightarrow s_f)$ 是一个已知量，因为流 F 是已知的。由于轨迹的集合 $\{A_{s'|s}, s' \geq s\}$ 构成了所有完整轨迹的划分 $\mathcal{T}_s$ ，方程 (46) 是一个线性方程组，其未知数是 $F_s(\tau)$ 对于所有 $\tau \in \mathcal{T}_s$ ，其中每个方程涉及不同的未知数集。因此，该系统至少存在一个解 $F_s(\tau)$ 。我们可以按照以下方式构造这样一个解。对于某些 $\tau \in \mathcal{T}_s$ ，我们可以首先选择包含 τ 的完整轨迹 $\bar{\tau} \in \mathcal{T}$ ：

$$C_\tau = \{\bar{\tau} \in \mathcal{T} : \tau \subseteq \bar{\tau}\}.$$

DAG G 与子图 G_s 之间的关键区别在于， G 可能包含一些终止于某个 $s' \geq s$ 但不通过 s 的轨迹，因此这些轨迹没有被 G_s 的轨迹覆盖。设 $U_{s'|s}$ 是定义为 G 的完整轨迹的集合：

$$U_{s'|s} = \{\bar{\tau} \in \mathcal{T} : \exists s'' > s, s'' \in \bar{\tau}, s' \in \bar{\tau}, s \notin \bar{\tau}\}.$$

对于所有 $\tau \in \mathcal{T}_s$ 使得 τ 在某些 $s' \geq s$ 处终止，因此我们可以构造流) 作为

$F_s(\tau)$

$$F_s(\tau) := F(C_\tau) + \frac{1}{n} F(U_{s'|s}),$$

其中 $n = |A_{s'|s}|$ 表示终止于 s' 的轨迹数量 $\tau' \in \mathcal{T}_s$ 。容易验证， $F_s(\tau)$ 是方程 (46) 的一个解。 ■

虽然我们在定理 10 中看到初始流 $F(s_0)$ 等于分区函数，但初始状态条件流也具有边缘化性质，并且现在与自由能在 s 处相关。

Proposition 32 *Given a state-conditional flow network (G, F) as in Theorem 30, for any state s , the initial flow of the state-conditional flow network corresponds to marginalizing the terminating flows $F(s' \rightarrow s_f)$ for $s' \geq s$:*

$$F_s(s_0 | s) = F_s(s) = \sum_{s' : s' \geq s} F(s' \rightarrow s_f) = \exp(-\mathcal{F}(s)),$$

where $\mathcal{F}(s)$ is the free energy associated to the energy function $\mathcal{E}(s') = -\log F(s' \rightarrow s_f)$.

证明 这是定理 10 直接的结果，应用于状态条件流函数 F_s ，以及定理 27。

$$\begin{aligned} F_s(s_0 | s) &= \sum_{\tau \in \mathcal{T}_s} F_s(\tau) = \sum_{s' : s' \geq s} F_s(s' \rightarrow s_f) \\ &= \sum_{s' : s' \geq s} F(s' \rightarrow s_f) = \sum_{s' : s' \geq s} e^{-\mathcal{E}(s')} \end{aligned}$$

■

请注意，状态条件流网络的定义与我们在第 2.1 节中对（无条件）流网络的原始定义一致，即原始流网络是一个锚定在初始状态的有效状态条件流网络。状态条件流网络还允许我们评估另一个感兴趣的量，即如果所有终止边流都转向较早的状态 $s < s'$ ，则终止轨迹于某个状态 s' 的概率：

推论 33 考虑由有向无环图给出的流网络 $(G = (\mathcal{S}, \mathbb{A}))$ 以及一个流 F ，根据定理 30，我们定义任意状态条件下的流网络。给定一个状态 s ，流函数 F_s 在 $\{s'' \in \mathcal{S}^f : s'' \geq s\} \subseteq \mathcal{S}^f$ 上诱导出一个概率分布，记为 $P_T(\cdot | s)$ 。在此测度下，终止轨迹于状态 s' 的概率 $P_T(s' | s)$ (i.e. 轨迹的最后一边是 $s' \rightarrow s_f$) 为：

$$P_T(s' | s) = \mathbf{1}_{s' \geq s} e^{-\mathcal{E}(s') + \mathcal{F}(s)}, \quad (47)$$

其中 $\mathcal{E}$ 是能量函数，将每个作为 s_f 父节点的状态 s' 映射到 $-\log F(s' \rightarrow s)$ ，而 $\mathcal{F}$ 是相应的自由能函数。

证明 因为 F_s 是一个流函数，定理 11 和定理 10 告诉我们：

$$P_T(s' | s) = \begin{cases} \frac{F_s(s' \rightarrow s_f)}{F_s(s)} & \text{if } s' \geq s \\ 0 & \text{否则为 } 0 \end{cases}$$

结合这个结果与定理 32 和等式 (45)，我们得到对于 $s' \geq s$ ：

$$\begin{aligned} P_T(s' | s) &= \mathbf{1}_{s' \geq s} \frac{F(s' \rightarrow s_f)}{e^{-\mathcal{F}(s)}} \\ &= \mathbf{1}_{s' \geq s} \frac{e^{-\mathcal{E}(s')}}{e^{-\mathcal{F}(s)}} \end{aligned}$$

■

4.4 条件 GFlowNets

类似于我们使用 GFlowNet 来估计流网络的流量，我们也可以使用（条件）GFlowNet 来估计条件流网络，给定目标奖励函数。条件 GFlowNet 遵循第 3 节所述的构造方法，不同之处在于所有需要学习的数量现在都依赖于条件变量（ $x \in \mathcal{X}$ (e.g., x 是神经网络的附加输入）。第 3.2 节中提出的参数化和损失原则上可用于训练条件 GFlowNet，无论条件集为何。下面我们将讨论 Deleu 等人 (2022) 首次提出的另一种损失，该损失可用于训练 GFlowNet 和条件 GFlowNet。

例 8 给定一组有向无环图 G_x 和由 $x \in \mathcal{X}$ 索引的奖励函数 R_x ，其中每个状态 $s \in G_x$ 都是终止的（即它是 s_f 的父节点），并参考例 2 和例 3，我们考虑由正向和反向转移概率 $\mathcal{O}_P^x = \mathcal{O}_2^x \times \mathcal{O}_3^x$ 给出的参数化，其中 $\mathcal{O}_2^x$ （分别 $\mathcal{O}_3^x$ ）是与 G_x 一致的正向（分别反向）概率函数集合 $\hat{P}_F$ （分别 $\hat{P}_B$ ）对于每个 $x \in \mathcal{X}$ ，以及 $(\Pi_P^x, \mathcal{H}_P^x)$ 定义如例 3 所示。每个 $(\mathcal{O}_P^x, \Pi_P^x, \mathcal{H}_P^x)$ 是 (G_x, R_x) 的流量参数化，可以使用边可分解的流量匹配损失进行训练，如 Deleu 等人 (2022) 证明的那样，并对每个 $s \rightarrow s' \in \mathbb{A}^{-f}$ 定义如下：

$$\mathcal{L}_{DB}(\hat{P}_F, \hat{P}_B, s \rightarrow s', x) = \left(\log \frac{R_x(s') P_B(s | s', x) P_F(s_f | s, x)}{R_x(s) P_F(s' | s, x) P_F(s_f | s', x)} \right)^2$$

4.5 利用 GFlowNet 训练基于能量的模型

GFlowNet 可以被训练成将能量函数转换为近似的相应采样器。因此，它可以作为 MCMC 采样的替代方法（参见第 3.1 节）。考虑模型 $P_\theta(s)$ 与给定参数化的能量函数相关联 $\mathcal{E}_\theta(s)$ ，其参数为 θ ： $P_\theta(s) = \frac{e^{-\mathcal{E}_\theta(s)}}{Z}$ 。从 $P_\theta(s)$ 进行采样可以通过从经过目标终端奖励 $P_T(s)$ 训练的 GFlowNet 的终止概率分布 $R(s) = e^{-\mathcal{E}_\theta(s)}$ 中采样来近似（参见公式 (34)）。在实践中， $\hat{P}_T$ 会成为真实值的估计器 P_θ 由于 GFlowNet 训练目标未归零（容量不足或有限的训练时间）。根据 GFlowNet 抽取的样本 $\hat{P}_T$ 可用于获得观测数据负对数似然的随机梯度估计器 x 关于参数 θ 能量函数的 $\mathcal{E}_\theta$ ：

$$\frac{\partial -\log P_\theta(x)}{\partial \theta} = \frac{\partial \mathcal{E}_\theta(x)}{\partial \theta} - \sum_s P_\theta(s) \frac{\partial \mathcal{E}_\theta(s)}{\partial \theta}. \quad (48)$$

通过采样一个或多个终止状态，可以得到第二项的一个近似随机估计量 $s \sim \hat{P}_T(s)$ ，即来自训练好的 **GFlowNet** 的采样器。此外，如果 **GFlowNet** 的损失为 0，即 $\hat{P}_T = P_\theta$ 梯度估计器将是无偏的。因此，理论上可以联合训练一个能量函数 $\mathcal{E}_\theta$ 并通过交替更新来相应地构建 **GFlowNet**。 θ 利用上述方程（通过采样来自 P_θ 通过采样替换 $\hat{P}_T$ ）以及使用更新后的能量函数对目标终端奖励的 **GFlowNet** 进行更新。如果我们固定 $\hat{F}(s \rightarrow s_f) = R(s)$ 通过构造（如果我们能够确定奖励函数的话），我们可以使用计算流的同一神经网络来参数化能量函数，因为 $\mathcal{E}(s) = -\log R(s) = -\log \hat{F}(s \rightarrow s_f)$ 。因此，能量函数和 **GFlowNet** 使用的参数相同，这一点颇具吸引力。上述同时学习能量函数和从其采样的策略可以通过使用条件 **GFlowNet** 来推广到学习条件分布。设 x 为观测随机变量， h 为隐藏变量，**GFlowNet** 生成 (x, h) 对的过程分为两个子轨迹：要么先生成 x ，然后在给定 h 的情况下生成 x ，或者先生成 h ，然后生成 x 给定 h 。这可以通过在状态中引入一个六值组件来实现 u 以确保在进入 h 之前 x 和 s_f 都已生成，并满足以下值和约束条件：

$$s = s_0 \Rightarrow u = 0 \quad (49)$$

$$s = s_f \Rightarrow u = 5 \quad (50)$$

$$(u_t \rightarrow u_{t+1}) \in \{0 \rightarrow 1, 0 \rightarrow 2, 1 \rightarrow 1, 2 \rightarrow 2, 1 \rightarrow 3, 2 \rightarrow 4, 3 \rightarrow 3, 4 \rightarrow 4, 3 \rightarrow 5, 4 \rightarrow 5\} \quad (51)$$

其中 $u = 1$ 表示生成的是 x （在生成之前 h ）， $u = 2$ 表示生成的是 h （在生成之前 x ）， $u = 3$ 表示生成的是 h （基于 x ），和 $u = 4$ 表示生成的是 x （给定 h ）。**GFlowNet** 无法到达最终状态 s_f 直到 x 和 h 都被生成。条件 **GFlowNet** 可以近似采样

$P_T(x)$, $P_T(h | x)$, $P_T(h)$, $P_T(x | h)$ 以及 $P_T(x, h)$ 。如果我们只想采样 x （或者只有 h ），我们允许一旦生成即可退出（或者当 h 被生成）。参见第 5.3 节关于如何表示、估计和采样边缘分布的更广泛讨论。令 $P_\theta(x, h) \propto e^{-\mathcal{E}_\theta(x, h)}$ 表示与能量函数相关的 (x, h) 的联合分布，即，与 $F(s \rightarrow s_f)$ 。当 x 被观测但 h 未被观测时， θ 可以通过近似边缘对数似然梯度来更新

$$\frac{\partial -\log P_\theta(x)}{\partial \theta} = \sum_h P_T(h | x) \frac{\partial \mathcal{E}_\theta(x, h)}{\partial \theta} - \sum_{x', h} P_T(x', h) \frac{\partial \mathcal{E}_\theta(x', h)}{\partial \theta} \quad (52)$$

利用训练好的 **GFlowNet** 的估计终端采样概率 $\hat{P}_T$ 样本，以随机梯度方式近似上述求和（使用一个或一批样本）。请注意，我们现在有了外部循环更新（能量函数，即奖励函数）来自实际数据，以及内部循环更新（**GFlowNet**）使用能量函数作为 **GFlowNet** 的目标驱动。需要多少次内部循环更新

才能使这种方案有效是一个有趣的开放问题，但很可能取决于潜在数据生成分布的形式。如果 GANs (Goodfellow 等人, 2022 年) 的工作是一个良好的类比，一个好的策略可能是交错更新能量函数 (作为 GFlowNet 的负对数终端流) 基于一批数据，以及基于这些样本 (可以从终止状态反向采样轨迹 s 使用 P_B) 和由 GFlowNet 的前向转移概率定义的温度训练策略 π_T 的正向样本更新 GFlowNet。

4.6 利用 GFlowNet 进行主动学习

上述方案的一个有趣变体是将 GFlowNet 采样器不仅用于生成能量函数的负样本，还用于主动探索环境。Jain 等人 (2022) 采用了一种主动学习方案，在该方案中，GFlowNet 被用来抽样候选对象 x ，我们预期这些候选对象的奖励 $R(x)$ 通常较大 (因为 GFlowNet 近似按比例抽样到 $R(x)$)。挑战在于，评估任何 x 的真实奖励 R 在计算上是昂贵的，并且可能具有噪声 (例如，测量药物与特定目标蛋白质结合能的生物测定)。因此，作者引入了一个代理 $\hat{f}$ (它近似真实奖励函数 f)，而不是直接使用真实奖励进行训练。这将导致一个类似于第 4.5 节的设置，在内部循环中，训练 GFlowNet 以匹配代理 $\hat{f}$ ，而在外部循环中，通过使用 (x, y) 对来监督式地学习代理 $\hat{f}$ ，其中 x 由 GFlowNet 提出，而 y 是来自环境的真实奖励 (例如，生物学或化学测定的结果)。需要注意的是，GFlowNet 和代理之间紧密相连，因为代理 $\hat{f}$ 在 x 域上的覆盖范围依赖于 GFlowNet 提供的多样化候选对象。同样，由于 GFlowNet 匹配由代理奖励函数 $\hat{f}$ 定义的奖励分布，它也依赖于真实奖励函数 f 的质量。

此设置可以通过纳入关于候选的新颖性程度，或认知不确定性程度的信息来进一步扩展， $u(x, f)$ ，在预测中存在 $\hat{f}$ 我们可以利用贝叶斯优化中的采集函数启发式方法 (如置信上限 (UCB) 或预期改进 (EI)) 来综合预测的有用性 [Moćkus, 1975; Srinivas 等, 2010] $\hat{f}(x)$ 的配置 x 通过对该预测的认知不确定性进行估计。将此作为奖励可以允许 GFlowNet 探索预测有用性高的区域 ($\hat{f}(x)$ (较大) 的同时探索那些关于有用配置仍有更多信息待收集的区域 x 预测的不确定性 $\hat{f}$ 通过合适的采集函数可以对 GFlowNets 的探索行为提供更多的控制。

正如 Bengio 等人 (2021) 在比较 GFlowNets 与最大化回报的强化学习方法时所讨论的，充分训练的 GFlowNets 的一个有趣性质是它们可以从奖励函数的所有模式中进行采样，这在需要探索的情境下特别有利，如主动学习。论文中的实验也通过比较 GFlowNet 与 PPO (一种之前用于生成分子图并倾向于关注奖励函数单一模式的强化学习方法) 所采样的解的多样性，实证地展示了这一优势。

4.7 估计熵、条件熵和互信息

定义 34 给定一个奖励函数

R' 与...相关

R 与...如: $0 \leq R(s) < 1 \forall s$ 我们定义熵奖励函数

$$R'(s) = -R(s) \log R(s). \quad (53)$$

简而言之，在本节中，我们展示了可以通过训练两个 GFlowNets 来估计熵：一个用于估计目标终端奖励函数 $R(s)$ 的流，另一个用于估计相应的熵奖励函数的流。我们将在初始状态下查找流以获得熵的估计值，如果我们对条件流进行同样的操作，则可以得到条件熵。一旦我们有了条件熵，也可以估计互信息。

命题 35 考虑一个流网络 (G, F) ，使得终止流匹配给定的奖励函数 R ，i.e. $\forall s \in \mathcal{S}^f$, $F(s \rightarrow s_f) = R(s)$ ，对于所有 s ，有 $R(s) < 1$ ，以及第二个具有相同有向无环图的流网络 (G, F') ，但其流函数使得终止流匹配熵奖励函数 R' (Eq. (53))，则与终止状态随机变量 $S \in \mathcal{S}^f$ 相关联的熵 $H[S]$ ，其分布为 $P_T(S = s) = \frac{R(s)}{Z}$ (公式 (18)) 是：

$$H[S] := - \sum_s P_T(s) \log P_T(s) = \frac{F'(s_0)}{F(s_0)} + \log F(s_0). \quad (54)$$

证明 首先应用 $P_T(s)$ 的定义，然后对两个流应用公式 (11)：

$$\begin{aligned} - \sum_s P_T(s) \log P_T(s) &= - \sum_s \frac{R(s)}{F(s_0)} (\log R(s) - \log F(s_0)) \\ &= \frac{(- \sum_s R(s) \log R(s)) + (\log F(s_0) \sum_s R(s))}{F(s_0)} \\ &= \frac{F'(s_0)}{F(s_0)} + \log F(s_0). \end{aligned}$$

请注意，我们需要 $R(s) < 1$ 以确保奖励 $R'(s)$ (从而流) 为正。 ■

命题 36 给定一个集合

条件变量的情况下，考虑由条件流函数定义的条件流网络

F ，其中终止流匹配目标奖励

R_x 家庭 (在...条件下 x) 满足 $R_x(s) < 1$ 对所有 s ，以及由条件流函数定义的第二个条件流网络 F' ，其中终止流匹配熵奖励函数 R'_x (Eq. (53))，则条件熵

$H[S | x]$ 随机终止状态 $S \in \mathcal{S}^f$ 与条件一致 x 由以下给出

$$H[S | x] = \frac{F'(s_0 | x)}{F(s_0 | x)} + \log F(s_0 | x). \quad (55)$$

特别是对于状态条件下的 GFlowNet ($\mathcal{X} = \mathcal{S}$ 是 DAG 的状态空间)，我们得到

$$H[S | s] = \frac{F'(s | s)}{F(s | s)} + \log F(s | s). \quad (56)$$

更一般地，终止状态的随机抽取 $S = s$ 根据 $P_T(s | x)$ 和条件随机变量 X 之间的互信息 $\text{MI}(S; X)$ 是

$$\text{MI}(S; X) = H[S] - E_X[H[S | X]] = \frac{F'(s_0)}{F(s_0)} + \log F(s_0) - E_X \left[\frac{F'(s_0 | X)}{F(s_0 | X)} + \log F(s_0 | X) \right] \quad (57)$$

其中 $F(s)$ 和 $F'(s)$ 表示无条件流（在没有给定条件 x 的情况下训练），而 $F(s | x)$ 和 $F'(s | x)$ 是它们的条件对应。

证明 方程 (55) 的证明基于每个 (G_x, F_x) 都是一个流网络的事实，我们可以应用定理 35。方程 (57) 是互信息定义、方程 (54) 和方程 (55) 的直接结果。 ■

如果我们有对 $P(X)$ 的采样机制，我们可以通过从 $P(X)$ 中抽取的蒙特卡罗平均来近似方程 (57) 中的期望。

5 集合、图上的 GFlowNets 以及联合分布的边缘化

5.1 集合 GFlowNets

我们首先定义一个用于构建集合的动作空间，并将 GFlowNet 视为生成随机集合 S 的一种手段，并估计该随机变量实现的概率、条件概率或边缘概率等量。这些集合的元素取自一个更大的“宇宙”集合 $\mathcal{U}$ 。

定义 37 给定一个“宇宙”集合 $\mathcal{U}$ ，考虑有向无环图 $G = (\mathcal{S}, \mathbb{A})$ ，其中 $\mathcal{S} := 2^{\mathcal{U}} \cup \{s_f\}$ 是所有子集的集合 $2^{\mathcal{U}}$ 并增加一个状态 $s_f, s_0 = \{\}$ 为空集，并且对于任意两个子集 $s, s' \in 2^{\mathcal{U}}$ ， $s \rightarrow s' \in \mathbb{A} \Leftrightarrow \exists a \in \mathcal{U} \setminus s, s' = s \cup \{a\}$ ；意味着 DAG 中的每次转换都对应于添加一个元素 $a \in \mathcal{U}$ 到当前子集。此外，所有子集都连接到 s_f ，i.e. $\forall s \in \mathcal{S}, s \rightarrow s_f \in \mathbb{A}$ 。A 集合流网络是该图上的流网络 G ，而集合 GFlowNet 是如第 3 节定义的此类流网络的估计器。目标终端奖励函数 $R : s \mapsto F(s \rightarrow s_f)$ 满足：

$$Z = \sum_{s \in 2^{\mathcal{U}}} R(s) < \infty. \quad (58)$$

一个设定流网络定义了一个终止概率分布 P_T 在状态上（参见定理 13 和公式 (44)），具有

$$P_T(s) = e^{-\mathcal{E}(s) + \mathcal{F}(s_0)} = \frac{F(s \rightarrow s_f)}{F(s_0)} \quad (59)$$

其中 $\mathcal{E}$ 表示能量 $-\log R$ 。类似地，定理 33 给出了给定集合 s 的一个超集 s' 在条件下的条件概率公式 P_T ，

$$P_T(s' \mid s' \supseteq s) := e^{-\mathcal{E}(s') + \mathcal{F}(s)} = \frac{F(s' \rightarrow s_f)}{F(s \mid s)} \quad (60)$$

其中 $\mathcal{F}$ 表示自由能（参见定理 27）。请注意，对于带有状态和边流估计器的 GFlowNet $\hat{F}$ ，并不能保证对所有状态都有 $\hat{F}(s) = R(s)$ 成立 $s \in \mathcal{S} \setminus \{s_f\}$ ，因此我们可以估计概率

$$\hat{P}_T(s) = \frac{\hat{F}(s \rightarrow s_f)}{\hat{F}(s_0)} \quad (61)$$

or alternatively

$$\hat{P}_T(s) = \frac{R(s)}{\hat{F}(s_0)}. \quad (62)$$

类似地，我们可以利用公式 (60) 来估计条件超集概率，或者通过

$$\hat{P}_T(s' \mid s' \supseteq s) = \frac{R(s')}{\hat{F}(s \mid s)}, \quad (63)$$

均不保证精确相加等于 1。我们还可以计算给定集合的所有超集的边缘概率 s ，如下所示。

命题 38 根据定理 37 的记号，设 $\mathfrak{S}(s) = \{s' \supseteq s\}$ 为集合 s 的所有超集构成的集合。给定一个集合流网络，从 $\mathfrak{S}(s)$ 中抽取任意元素的概率是

$$P_T(\mathfrak{S}(s)) = \sum_{s' \supseteq s} P_T(s') = \frac{e^{-\mathcal{F}(s)}}{Z} = \frac{F(s \mid s)}{F(s_0)}. \quad (64)$$

证明 我们可以将求和重写如下，首先应用定义 P_T (Eq. (18)), 和定理 32:

$$\begin{aligned} \sum_{s' \supseteq s} P_T(s') &= \sum_{s' \supseteq s} \frac{F(s' \rightarrow s_f)}{F(s_0)} \\ &= \frac{F(s \mid s)}{F(s_0)} \\ &= \frac{e^{-\mathcal{F}(s)}}{Z} \end{aligned}$$

我们注意到，对于集合形式的状态而言，序关系 $s \leq s'$ 等价于子集关系 $s \subseteq s'$ 。 ■

综上所述，一个经过训练以匹配给定能量函数（即派生奖励）的 GFlowNet 可以用来表示该分布，从中采样，估计集合在该分布下的概率，估计配分函数，并搜索最低值

能量集合，从给定集合的超集上采样条件分布，估计给定集合及其超集的条件分布，计算子集的边缘概率（即，对所有超集的概率求和），以及计算集合分布或集合超集的条件分布的熵。例如，在 Malik 等人（2023）的研究中，使用 GFlowNet 来建模集合上的分布已被成功应用于高效主动学习的信息点批量选择。作者进一步展示了基于互信息奖励定义的集合分布可以通过将神经网络作为 GFlowNet 策略的功能逼近器来近似到令人满意的程度（参见第 4.7 节）。

5.2 GFlowNet 在图上的应用

图是一种特殊的集合，其中包含两种类型的元素：节点和边，边是由节点索引对组成的。图还可以在节点和/或边上附加内容。因此，可以相应地将上一节中描述的集合操作进行专门化。某些操作（即 GFlowNet 有向无环图中的边）可能会插入一个节点，而其他操作可能会插入一条边。允许的操作集可以受到限制，例如确保图具有单个连通分量，或者确保图没有环。就像一般的集合一样，不能执行添加已经存在于集合中的节点或边的操作。Deleu 等人（2022）使用 DAG 上的 GFlowNet 来学习贝叶斯网络图形结构的后验分布的近似值。虽然 GFlowNet 通过最小化源自流匹配条件的损失函数（如第 3.2 节所述）进行学习，但他们证明了所得到的分布是对目标后验分布的精确近似。由于图是集合，所有针对集合的 GFlowNet 操作都可以应用于图。

5.3 对缺失变量进行边缘化

GFlowNets 捕捉集合上概率分布的能力可以应用于联合分布的建模，计算给定变量值子集上的边缘概率，以及对任何条件下的采样或概率计算（例如，给定另一组变量的一组变量）。设 $X = (X_1, X_2, \dots, X_n)$ 是一个复合随机变量，包含 n 个元素随机变量 X_i , $1 \leq i \leq n$ ，每个元素可能取值为 $x_i \in \mathcal{X}_i$ （不一定是数字）。如果我们给出一个能量函数或终端奖励函数 $R(x)$ 来评分任何实例 $X = x$ ，我们可以训练一种特定类型的集合 GFlowNet，其中集合元素为 (i, x_i) ，并且集合中最多有一个索引为 i 的元素，对于所有 i 。唯一允许的终止转换是当集合恰好大小为 n 时，并且每个大小为 n 的集合 s 在下一次转换时终止。请注意，如果 P_B 允许该顺序，GFlowNet 可以按任何可能的顺序采样一个 X 。给定一组已有的 (i, x_i) 对（由状态 $s = \{(i, x_i)\}_i$ 表示），我们可以估计这些变量子集的边缘概率（隐式地对所有缺失的进行求和，见公式 (64)）。我们可以通过设置状态为 s 并继续从 GFlowNet 的策略（学习到的前向转换概率函数）中采样其他变量。我们可以通过约束该策略仅添加属于 S' 的元素来从选定的其他变量子集 S' 中采样。此外，我们还可以执行集合 GFlowNet 上可行的所有其他操作

例如，估计配分函数，在偏好早期具有最大边缘概率的子序列的顺序下进行采样，搜索变量的最可能配置，或者估计分布的熵。

5.4 模块化能量函数分解

让我们看看如何将图 GFlowNet 框架应用于一种特殊的图：因子图（Kschischang 等，2001），其中包含可重复使用的因子。这将产生一个分布 $P_T(g)$ 关于图 g ，每个图都与一个能量函数值 $\mathcal{E}(g)$ （以及相应的奖励 $R(g)$ ）相关联。基于能量的模型很方便，因为它们可以将联合概率分解成独立的部分（可能对应于独立的机制，Schölkopf 等，2012；Goyal 等，2019；Goyal 和 Bengio，2020），每个部分对应因子图的一个因子。在我们的案例中，我们希望一组共享的因子 $\mathbb{F}$ 能够在许多因子图之间重复使用 g 。因子图将提供一组随机变量上的能量和概率 $\mathcal{V}$ 。设该图为 $g = \{(F^i, v^i)\}_i$ 可以表示为一系列片段 (F^i, v^i) ，其中 $F^i \in \mathbb{F}$ 是因子的索引，该因子具有能量函数项 $\mathcal{E}_{F^i}$ ，从可能因子的集合 $\mathbb{F}$ 中选择，而其中 $v^i = (v_1, v_2, \dots)$ 是随机变量 $V_j \leftarrow v_j$ 的实现列表，其中 $V_j \in \mathcal{V}$ 是因子图中的一个节点。该列表定义了因子图中连接变量的边 V_j 通过 j -th 参数的 $\mathcal{E}_{F^i}$ 。令我们表示 $\mathcal{E}_{F^i}(v^i)$ 为该能量函数项的值 $\mathcal{E}_{F^i}$ 应用于这些

$$v = v^i, \text{ i.e., } \mathcal{E}_{F^i}(v^i) = \mathcal{E}_{F^i}(v_1, v_2, \dots). \quad (65)$$

这样的图的总能量函数可以分解如下

$$\mathcal{E}(g) = \sum_i \mathcal{E}_{F^i}(v^i). \quad (66)$$

这一构造有趣之处在于，图 GFlowNet 现在可以采样一个图 g ，可能在给定一些条件观测值的情况下进行采样 x ：参见第 4.5 节关于如何联合训练 GFlowNet 和能量函数，包括仅观察部分随机变量的情况。因此，给定一些观测变量（不一定是相同的），图 GFlowNet 可以采样一个包含并连接（通过能量函数项）观测和隐变量的因子图，并且其结构定义了一个关于联合观测和隐变量值的能量函数。我们不仅能够利用 GFlowNet 生成对象的组合性质将总能量分解为对应于理想独立机制的可重用能量项，而且还可以将 GFlowNet 本身分解为与每个机制相关的模块。这个图 GFlowNet 的动作空间相当复杂，每个动作对应添加一个隐变量 V_k 或添加一个图片段 (F^i, v^i) 。这种动作是在 GFlowNet 的状态下进行的，该状态是一个部分构建的图（由之前的动作产生）。因此，GFlowNet 及其相关联的能量函数参数被分解为模块。每个模块知道如何计算能量函数 $\mathcal{E}_{F^i}$ 以及如何竞争性地评分和采样一个新的图片段（以在图中插入相应的因子）。

考虑一些观测变量（ V_j 中值为 v_j 的一组子集），统称为 x 。考虑一个图 g ，其中与 x (i.e. 兼容的部分节点对应于观测变量（ $V_j = v_j$ ），并表示为 h ，这部分由 g 提供但未包含在 x 中。我们可以将隐变量 h 视为对观测变量 x 的解释。注意到通过对所有可能的 h 进行边缘化，我们可以计算出 x 的自由能。第 4.5 节的原则可以应用于训练这种基于能量的 GFlowNet。在能量函数中表示图结构的先验也是有意义的。例如，我们可能偏好稀疏因子（具有较少参数），并且可以引入软约束或硬约束，这些约束与计算机编程和自然语言中常用的类型概念有关。图中的每个随机变量都可以有一个属性类型，每个因子能量函数参数可以期望一种类型。通过添加能量函数项来构建这种先验，以偏好那些变量类型（ V_k ，其实例为 v_k ）与 F_i 的第 k 个参数所期望的类型相匹配的图片段（ $F_i, v^i = (v_k)_k$ ）。这与注意力机制（Bahdanau 等人，2214；Vaswani 等人，2017）非常相似，后者可以看作是将查询（预期类型）与键（与元素关联的类型）进行匹配。例如，Pan 等人（2023）提出了前瞻性的 GFlowNet 框架，该框架利用了能量函数的模块性，如等式 (66)，从而获得了比常规损失更好的目标分布近似。

6 连续或混合动作和状态

上述所有数学推导均使用了对状态或动作求和的方法，其基本思想是这些元素属于离散空间。然而，在大多数情况下，如果状态或动作是连续的或混合型的（即包含离散部分和连续部分），可以将这些求和替换为积分。除此之外，我们将在下文讨论连续值的动作和状态对 GFlowNet 框架的影响。尽管在公式 (40) 中明确出现了对后继者和前驱者的求和，但这种求和也隐藏在公式 (26) 的细致平衡约束中。实际上，这些求和作为归一化常数的一部分隐含在下一个状态或前一个状态的条件密度中（见 $P_F(s_{t+1} | s_t)$ 和 $P_B(s_t | s_{t+1})$ ）。我们将在下文考虑应对这一挑战的方法。

6.1 可积归一化常数

首先，我们注意到，如果我们能够处理连续状态，那么也可以处理混合状态，具体如下。设状态分解为

$$s = (s^i, s^x) \quad (67)$$

其中 s^i 是离散的，而 s^x 是连续的。然后我们可以将任何转移条件分解如下：

$$P_F(s_{t+1} | s_t) = P(s_{t+1}^x | s_{t+1}^i, s_t) P(s_{t+1}^i | s_t). \quad (68)$$

我们注意到，这在形式上等价于将转移分解为两次转移，第一次执行到下一个状态的离散选择，第二次执行连续的选择

选择进入下一个状态（给定离散选择）。神经网络具有连续值输入并无问题。挑战在于如何在输出端表示连续密度，既要能够计算特定值的概率密度（比如 $P(s_{t+1}^x | s_{t+1}^i, s_t)$ ）并能够从中采样。计算分类概率和从条件分类中采样的操作是标准流程，因此我们仅讨论连续条件的情况。一种可能性是参数化 $s_{t+1}^x | s_{t+1}^i, s_t$ 当归一化常数是一个已知的可计算积分，比如高斯分布时。然而，这可能会过度限制模型的能力，并可能妨碍详细平衡或流匹配损失的良好最小化。一个解决方法是增强状态的离散部分 s_i 通过额外的维度对应“聚类 ID”，即把连续密度划分成混合分布。我们知道，只要有足够多的混合成分，我们可以任意好地逼近来自非常大族的密度。其他方法包括使用自回归模型或归一化流模型（Rezende 和 Mohamed, 2015, 此处 flow 一词含义不同）来建模条件密度，或者像在去噪扩散模型（Sohl-Dickstein 等, 2015）中那样，分解采样过程 s^x 分成若干重采样步骤，将其分布从简单形式转换为复杂形式。

为了确保详细平衡约束能够精确满足，我们可以进一步考虑参数化边流 $F((s_i, s_x) \rightarrow (s'_i, s'_x))$ ，并注意到如果使用基于节点的流匹配损失，这是自然的参数化方式。例如，继续使用高斯分布的例子，我们现在在向量 (s_x, s'_x) 中有一个联合高斯能量，对于每个由 (s_i, s'_i) 指定的可行离散组件。需要注意的是，在 GFlowNets 的实际应用中，并非所有满足顺序关系的转换一般都会被允许出现在 GFlowNet 的基础 DAG 中。例如，在集合 GFlowNets 中，唯一允许的操作是向集合中添加一个元素（而不是任意数量的元素）。这些对动作空间的限制意味着合法的 (s_i, s'_i) 对的数量是可以管理的，并且对应于离散动作的数量。因此，整体动作被视为具有离散部分（选择 s'_i 给定 s_i ）和连续部分（选择 s'_x 给定 s'_i, s_i 和 s_x ）。通过这种联合流的形式化，正向和反向条件密度可以精确计算并且彼此兼容。

6.2 GFlowNets 中的 GFlowNets

实现涉及连续变量的边流的另一种方法是使用较低级别的 $\langle \text{GFlowNet}, \text{能量函数} \rangle$ 对来表示其流，条件概率并从中采样。请记住，这样的对可以按照第 4.5 节讨论的方法进行训练。代替给定 (s_x, s'_x) 的 (s_i, s'_i) 的联合高斯分布，我们可以有一个较小规模的 GFlowNet 和能量函数（代表外部 GFlowNet 中的边流）来处理更大规模外部 GFlowNet 中某一类型的一系列转换。假设我们有一个相当任意的能量函数用于此类转换，其中参数是我们学习的。然后，我们也可以训练一个 GFlowNet 来进行双向采样（从 s_t 到 s_{t+1} 或从 s_{t+1} 到 s_t ），并评估相应的归一化常数（从而得出相应的条件概率）。状态及其转换的离散方面可能对应于一系列转换（例如，在图 GFlowNet 中插入特定类型的节点），并且一个单独的 $\langle \text{GFlowNet}, \text{能量函数} \rangle$ 模块可以专门化并训练来处理此类转换。

在本文审稿期间，Lahlou 等人（2023）将 GFlowNets 的理论扩展到了更一般的状态空间，包括连续空间，并通过实验验证了通常的损失函数可以有效地用于连续域中的推理。

7 相关工作

有关给定能量或奖励信号生成多样样本的问题，有几类相关的文献，特别是：• 生成模型（尤其是深度学习生成模型），• 通过某种探索行为或平滑先验来最大化奖励的强化学习方法，• 原则上解决从 $p(x) \propto f(x)$ 采样问题的 MCMC 方法，• 可以通过迭代一个解种群来利用群体多样性的进化方法。

接下来，我们将讨论这些方法，并提供关于 GFlowNets 与其他方法之间相似性和差异性的洞见。需要注意的是，与这个问题相关的文献远超我们在这里能够引用的范围，还延伸到机器学习的许多其他子领域，如生成对抗网络（GANs）（Kumar 等，2019 年），变分自编码器（VAEs）（Kingma 和 Welling，2013；Kusner 等，2017），以及归一化流（Dinh 等，2014，2016；Rezende 和 Mohamed，2015）。另一种相关的方法类型是贝叶斯优化方法（Moćkus，1975；Srinivas 等，2010），这些方法也被用于分子空间的搜索（Griffiths 和 Hern'andez-Lobato，2017）。GFlowNets 与贝叶斯优化方法的主要关系在于，GFlowNets 是生成性的，因此可以补充那些扫描可处理候选列表的贝叶斯优化方法。当搜索空间过大，无法单独计算每个候选者的贝叶斯优化采集函数得分时，使用生成模型是有吸引力的。此外，GFlowNets 用于探索分布的模式，而不是寻找单一最主导的模式。这种差异类似于与经典强化学习方法的差异，将在下文进一步讨论。

7.1 与生成模型对比

GFlowNets 与已建立的深度生成模型如变分自编码器（VAE）或生成对抗网络（GAN）之间的主要区别在于，后者通过提供从目标分布中采样的有限样本集进行训练，而 GFlowNets 通常通过提供能量函数或奖励函数进行训练。该奖励函数不仅告诉我们哪些样本在目标分布下是可能的（可以视为正面样本），还告诉我们哪些样本是不可能的（可以视为负面样本），以及那些介于两者之间的样本（其奖励不是很大但也不是零）。如果我们以最大似然训练目标的角度来看，它就像一个奖励函数，对每个训练样本（被视为正面样本，概率应较高）给予高奖励，而在其他地方给予零奖励。然而，还有其他可能的奖励函数，正如在 GFlowNets 应用于新分子发现的应用中所见（Bengio 等，2021 年），其中奖励不是二进制的，并且随着候选分子的期望属性值增加而单调递增。

然而需要注意的是，当我们将能量函数的学习与 GFlowNet 采样器的学习结合在一起时，与其他生成建模方法之间的区别变得模糊，正如第 4.5 节所述。在这种情况下，可训练的 GFlowNet 采样器和可训练的能量函数组成的配对实现了类似于可训练生成模型的目标。值得注意的是，GFlowNets 被设计用于生成离散变长组合结构（如集合或图），适用于隐变量和观测变量，而 GANs、VAEs 或归一化流则从使用实值固定大小隐变量来建模实值固定大小向量的角度出发。GFlowNets 与大多数生成模型训练框架（通常是最大似然估计的一些变体）之间的一个有趣区别在于 GFlowNets 训练目标的本质。GFlowNets 的训练目标是在主动学习场景下产生的。GFlowNet 训练对 $(s, R(s))$ 可以来自任何关于 s 的分布（任何全支持训练策略 π_T ），并且该分布不必是平稳的（在主动学习设置中通常也不会是平稳的），而最大似然框架对所见数据分布的变化非常敏感。这与流匹配目标的“离线学习”属性（参见第 3.3.3 节等）有关。

7.2 与正则化强化学习的对比

GFlowNets (Bengio 等, 2021) 的流匹配损失源于时间差分训练 (Sutton 和 Barto, 2018) 目标与贝尔曼方程的启发。流匹配方程类似于贝尔曼方程，因为训练目标是局部的（在时间和状态上），信用分配通过引导过程传播，并试图调整参数化，使得这些方程得以满足，从而获得所需的性质。然而，这些所需性质有所不同，将在下一段详细阐述。GFlowNets 开发的背景也不同于通常关于代理在某些环境中学习的方式：我们可以将 GFlowNets 的确定性环境视为涉及认知代理执行某种推理所需的内部动作，即通过一系列步骤（根据其他事物预测或采样某些事物），也就是通过代理内部的动作来控制其计算。这与强化学习的起源不同，后者专注于代理在一个外部未知随机环境中的动作。GFlowNets 被引入作为一种学习内部策略的工具，类似于现代深度学习中注意力的使用，我们知道动作的效果，而这些动作的组合定义了该代理的推理机制。经典强化学习 (Sutton 和 Barto, 2018) 的控制方法通过最大化马尔可夫决策过程 (MDPs) 中的回报来工作；它们的重点在于寻找策略 $\pi^* \in \operatorname{argmax}_{\pi} V^{\pi}(s) \forall s$ 最大化期望回报 $V^{\pi}(s)$ ，这恰好可以通过确定性策略来实现 (Sutton 和 Barto, 2018 年)，即使在随机 MDP 中也是如此。在确定性 MDP 中，这里感兴趣的是，这意味着训练一个强化学习代理就是寻找最有利的轨迹，或者在仅终端奖励的 MDP（再次是这里的兴趣点）的情况下，寻找最有利的终止状态。另一个视角源自概率推理文献 (Toussaint 和 Storkey, 2006 年) 和多臂赌博机文献 (Auer 等人, 2002 年)，关注于

寻找形式为 $\pi(a|s) \propto f(s, a)$ 的策略。事实证明，在控制设置中最大化回报和策略熵（Ziebart 等，2008）会产生这样的策略，使得

$$p(\tau) = \left[p(s_0) \prod_{t=0}^{T-1} P(s_{t+1}|s_t, a_t) \right] \exp \left(\eta \sum_{t=0}^{T-1} R(s_t, a_t) \right) \quad (69)$$

其中 $\tau = (s_0, a_0, s_1, a_1, \dots, s_T)$ 和 η 可以被视为温度参数。这一结果也可以在控制作为推理框架下找到（Haarnoja 等人，2017；Levine，2018）。在确定性马尔可夫决策过程（MDP）中，如果终端奖励存在且未来奖励不被折扣，则简化为 $p(\tau) \propto \exp(\eta \rho(\tau))$ ，其中 ρ 是回报。在最近的文献中，这种熵最大化（MaxEnt）通常被解释为一种正则化方案（Nachum 等人，2017），熵要么被用作内在奖励信号，要么被用作显式的最大化的正则化目标。理解该方案的另一种方式是在对抗性多臂赌博机设置（Auer 等人，2002）中想象自己，每条手臂对应一个独特的轨迹，其概率为 $\propto \exp(\rho(\tau))$ 。需要明确区分 MaxEnt 强化学习和 GFlowNets 之间的区别在于，在一般情况下它们不会得到相同的结果。GFlowNets 学习一个策略使得 $P_T(s) \propto R(s)$ ，而 MaxEnt 强化学习（选择适当的温度和 R ）学习一个策略使得 $P_T(s) \propto n(s)R(s)$ ，其中 $n(s)$ 是所有轨迹的有向无环图（DAG）中通往 s 的所有路径的数量（证明见 Bengio 等人，2021）。仅当 DAG 减去 s_f 后以 s_0 为根形成一棵树时，等价关系才成立，这已被发现是有用的（Buesing 等人，2019）。实际上，通过因子 $n(s)$ 过度加权意味着对应于更长序列的状态（通常会有指数级更多的路径到达这些状态）将倾向于被采样得更多（通常指数级更多）次，而对应于较短序列的状态则较少。显然，这破坏了按终止状态奖励比例进行采样的目标，并提供了考虑使用 GFlowNets 的强烈动机。在强化学习中最大化熵的另一个视角是可以在状态的平稳分布上最大化熵 d^π （Ziebart 等人，2008），而不是在策略上。事实上，可以证明训练一个策略使得 $P_T(s) \propto R(s)$ 的目标等同于训练一个最大化 $r(s, a) = \log R(s, a) - \log d^\pi(s, a)$ 的策略。不幸的是，尽管计算平稳分布是可能的（Nachum 等人，2019；Wen 等人，2020），但这并不总是可行的，也不够精确以用于奖励正则化的目的。

7.3 与蒙特卡洛马尔可夫链方法的对比

马尔可夫链蒙特卡罗方法（MCMC）有着悠久而丰富的历史（Metropolis 等人，1953 年；Hastings，1970 年；Andrieu 等人，2003 年），对于当前的工作尤为相关，因为它也是一种用于从 $P_T(s) \propto R(s)$ 采样的原则性方法类别。基于 MCMC 的方法已经在使用深度神经网络驱动采样方面取得了一定的成功（Grathwohl 等人，2021 年；Dai 等人，2020 年；Xie 等人，2021 年；Nash 和 Durkan，2019 年；Seff 等人，2019 年）。MCMC 的一个重要缺点是它依赖于迭代采样（形成马尔可夫链，每次生成一个配置，每个配置类似于 GFlowNet 的一个终止状态）：在链条的每一步，通过在上一步配置基础上进行微小的随机变化来获得一个新的状态配置。

尽管这些方法保证了在链条长度趋于无穷大时，我们可以得到从正确分布中抽取的样本，但对于一类特定的分布而言，有限长度的链条可能无法提供足够的模式多样性。

这被称为模式混合问题（Jasra 等人，2005 年；Bengio 等人，2013 年；Pompe 等人，2020 年）：如果模式之间被一系列低概率配置隔开，那么从一个模式跳到另一个相邻模式的概率可能会变得非常小（从而需要非常长的链条）。这个问题可以通过增加计算量（即延长链条长度）来缓解，但在模式间隔增大时会变得指数级地不可持续。引入随机抽样（例如，抽取多条链条）和模拟退火（Andrieu 等人，2003 年）可以减少这一问题，以促进模式之间的跳跃。然而，在高维度下以及当模式占据极小体积时（随着维度的增加，这可能成为总空间的一个指数级小的部分），随机抽样不太可能落在某个模式附近。

相比之下，GFlowNets 属于摊销采样方法家族（包括变分自编码器（VAEs），Kingma 和 Welling，2013 年），其中我们训练一个机器学习系统来生成样本：我们将通过长链进行采样的复杂度交换为训练采样器的复杂度。这种摊销采样器的潜在优势在于感兴趣的分布具有可泛化的结构：基于已知高概率样本集合（训练集）的知识，可以合理地猜测高概率样本可能出现的位置。这正是深度生成模型能够工作的基础，因此表明在这样的高维设置中，模式占据微小体积（根据流形假设，Cayton，2005 年；Narayanan 和 Mitter，2010 年；Rifai 等人，2011 年），可以通过已经观察到的 $(x, R(x))$ 对（其中 x 是一个已访问过的配置，而 $R(x)$ 是其奖励）从已知模式“跳跃”到尚未访问的模式，即使这些模式距离已访问的模式很远。

那么这种方法的效果如何将取决于学习者的泛化能力，即其归纳偏置的力量和适当性，正如在机器学习中通常所见。在完全没有结构的情况下（因此在学习分布时没有泛化的可能性），没有理由期望摊销 ML 方法会比 MCMC 表现更好。但如果存在结构，那么在模式之间混合的指数成本可能会消失。有大量证据表明，ML 方法可以在这样的高维空间（如自然图像的空间）中做得很好，这表明在 ML 通常表现良好的地方，考虑 GFlowNets 和其他摊销采样方法是有价值的。分子图生成实验（Bengio 等，2021 年）比较了 GFlowNets 和 MCMC 方法，似乎证实了这一点。

另一个需要考虑的因素（独立于模式混合问题）是计算成本的摊销：GFlowNets 在训练网络时付出高昂的前期成本，然后每次生成新样本时只需较小的成本（从 P_T 采样一次）。相比之下，MCMC 没有前期成本，但每次独立采样时需支付大量成本。因此，如果只需要采样一次，MCMC 可能更有效率；而如果需要生成大量样本，摊销方法可能更有优势。可以想象，在某些情况下，GFlowNets 和 MCMC 可以结合使用，以实现两种方法的优势。

进化方法 进化方法类似于 MCMC 方法，通过随机局部搜索的迭代过程工作，并找到最大化一个或多个目标的候选群体（Brown 等人，2004 年；Salimans 等人，2017 年；Jensen，2019 年；Swersky 等人，2020 年）。从这个角度来看，它们具有相似的优势和劣势。这些方法的一个实用优势是，可以通过群体度量和亚群体选择轻松获得自然多样性（Mouret 和 Doncieux，2012 年）。这并不是 GFlowNet 明确解决的问题，它依赖于独立同分布采样，并赋予次优样本非零概率作为多样性的机制。

序贯蒙特卡洛 序贯蒙特卡洛（SMC，Naesseth 等人，2019 年；Arulampalam 等人，2002 年）方法是一类旨在解决推理问题的方法。与 GFlowNets 类似，SMC 抽样器被训练成从给定未归一化的概率密度分布中采样，并需要正向和反向核函数，就像 GFlowNets 一样。然而，与 GFlowNets 不同的是，它们需要指定中间目标 $\gamma_t(z_t)$ 。此外，GFlowNets 的奖励通常只在序列结束时给出，而不同于 SMC 中用于重新加权粒子的每时间步长似然性。GFlowNets 可以在不符合典型粒子滤波设置的情况下应用，例如那些中间状态不对应于样本空间的有效元素的情况。轨迹不一定表示与相应观测值关联的潜在变量序列，如过滤任务中那样。GFlowNets 轨迹分布仅由终端状态奖励函数定义。

8 结论与开放问题

本文扩展并深化了 GFlowNets（Bengio 等，2021）的数学框架及其数学性质。它将 GFlowNets 中的流概念与轨迹上的测度联系起来，并引入了一种新颖的训练目标（详细平衡损失），使得可以选择一个参数化方法，分离控制事物执行顺序偏好的反向策略 P_B 和由目标奖励函数施加的约束。

本文的重要贡献之一是使用 GFlowNets 进行边缘化或自由能估计的数学框架。这一框架依赖于一个简单想法，即对 GFlowNet 进行条件设置，以便将 Bengio 等（2021）已经提出的估计配分函数的能力推广到更一般的场景中。这原则上使得可以估计任意状态可达的终止状态上的不可计算的奖励总和，从而开启了对超图、超集以及（变量，值）对的超集进行边缘化的可能性。反过来，这提供了估计熵、条件熵和互信息的公式。附录 A 介绍了流匹配目标的替代方案，这些方案可能绕过从动作序列末尾到开始缓慢传播的“自举”信用信息，采用所谓的直接信用分配（与策略梯度有一些相似之处）。这个问题也激发了 Malkin 等（2022）引入的轨迹平衡目标，进一步的工作是有必要的。为了更好地区分 GFlowNets 与更常见的强化学习形式之间的联系，附录 C 考虑了不仅在结束时而且可能在每次动作后提供奖励的情况，以及环境可能是随机的情况。它还展示了

如何从训练好的 GFlowNet 获得一个最大化回报的贪婪策略。在第 D 节中，通过考虑类似于 GFlowNet 中的价值函数，即从给定状态出发的预期下游奖励，引入了与强化学习的另一个联系。In a。类似的精神，在第 E 节中，将 GFlowNet 推广到可以在轨迹过程中获得奖励的情况，从而引入了回报的概念，但仍然保持按比例采样的目标。第 F 节从另一个方向推广了 GFlowNet，考虑在同一图上同时学习一组流的可能性。这开启了 GFlowNet 分布泛化的可能性（类比于分布强化学习），以及无监督 GFlowNet 的概念（其中奖励函数可以在无监督训练后定义），并学习从由一组奖励函数定义的帕累托前沿进行采样。显然，许多开放问题仍然存在，从扩展到连续动作和状态到具有抽象动作的层次版本的 GFlowNet，并将能量函数整合到 GFlowNet 参数化本身中，使一种有趣的模块化和知识分解形式成为可能。重要的是，本文提出的许多数学公式需要经验验证来确定其有用性，改进这些想法，将其转化为有影响力的算法，并探索可能非常广泛的有趣应用，从替代 MCMC 或在某些情况下与 MCMC 结合，到概率推理，再到主动学习在科学研究中的进一步应用。

致谢

作者想感谢 Alexandra Volokhova、Marc Bellemare、Valentin Thomas、Modjtaba Shokrian Zini、Mohammad Pedramfar、Arthur Maffre 和 Axel Nguyen Kerbel 对本文及其想法提供的有用建议和反馈。他们还感谢 CIFAR、三星、IBM、谷歌、微软、JP 摩根大通以及 Thomas C. Nelson 斯坦福跨学科研究生奖学金提供的财政支持。

本研究部分由 JPMorgan Chase & Co. 资助。此处表达的任何观点或意见均为列出的作者个人观点，可能与 JPMorgan Chase & Co. 或其附属机构所表达的观点或意见有所不同。本材料并非 J.P. Morgan Securities LLC 研究部门的产品。本材料不应被视为针对特定客户的个别推荐，也不旨在作为对特定客户的具体证券、金融工具或策略的推荐。本材料不构成任何司法管辖区内的招揽或要约。

参考文献

- C. Andrieu, N. De Freitas, A. Doucet, and M. I. Jordan. An introduction to mcmc for machine learning. *Machine learning*, 50(1):5–43, 2003.
- M. Arulampalam, S. Maskell, N. Gordon, and T. Clapp. A tutorial on particle filters for on-line nonlinear/non-gaussian bayesian tracking. *IEEE Transactions on Signal Processing*, 50(2):174–188, 2002. doi: 10.1109/78.978374.

- P. Auer, N. Cesa-Bianchi, Y. Freund, and R. E. Schapire. The nonstochastic multiarmed bandit problem. *SIAM journal on computing*, 32(1):48–77, 2002.
- D. Bahdanau, K. Cho, and Y. Bengio. Neural machine translation by jointly learning to align and translate. *ICLR’2015*, *arXiv:1409.0473*, 2014.
- S. Bai, J. Z. Kolter, and V. Koltun. Deep equilibrium models. *CoRR*, abs/1909.01377, 2019. URL <http://arxiv.org/abs/1909.01377>.
- M. G. Bellemare, W. Dabney, and R. Munos. A distributional perspective on reinforcement learning. In *International Conference on Machine Learning*, 2017.
- E. Bengio, M. Jain, M. Korablyov, D. Precup, and Y. Bengio. Flow network based generative models for non-iterative diverse candidate generation. *NeurIPS’2021*, *arXiv:2106.04399*, 2021.
- Y. Bengio, G. Mesnil, Y. Dauphin, and S. Rifai. Better mixing via deep representations. In *International conference on machine learning*, pages 552–560. PMLR, 2013.
- N. Brown, B. McKay, F. Gilardoni, and J. Gasteiger. A graph-based genetic algorithm and its application to the multiobjective evolution of median molecules. *Journal of chemical information and computer sciences*, 44(3):1079–1087, 2004.
- L. Buesing, N. Heess, and T. Weber. Approximate inference in discrete distributions with monte carlo tree search and value functions, 2019.
- L. Cayton. Algorithms for manifold learning. *Univ. of California at San Diego Tech. Rep*, 12(1-17):1, 2005.
- H. Dai, R. Singh, B. Dai, C. Sutton, and D. Schuurmans. Learning discrete energy-based models via auxiliary-variable local exploration. In *Neural Information Processing Systems (NeurIPS)*, 2020.
- T. Deleu, A. Góis, C. Emezue, M. Rankawat, S. Lacoste-Julien, S. Bauer, and Y. Bengio. Bayesian structure learning with generative flow networks. In *Uncertainty in Artificial Intelligence*, pages 518–528. PMLR, 2022.
- L. Dinh, D. Krueger, and Y. Bengio. Nice: Non-linear independent components estimation. *ICLR’2015 Workshop*, *arXiv:1410.8516*, 2014.
- L. Dinh, J. Sohl-Dickstein, and S. Bengio. Density estimation using real NVP. *ICLR’2017*, *arXiv:1605.08803*, 2016.
- A. Dosovitskiy and J. Djolonga. You only train once: Loss-conditional training of deep networks. In *International Conference on Learning Representations*, 2019.
- D. Ernst, P. Geurts, and L. Wehenkel. Tree-based batch mode reinforcement learning. *Journal of Machine Learning Research*, 6:503–556, 2005.
- D. Ghosh, A. Gupta, and S. Levine. Learning actionable representations with goal-conditioned policies. *arXiv preprint arXiv:1811.07819*, 2018.

- I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. *Advances in neural information processing systems*, 27, 2014.
- A. Goyal and Y. Bengio. Inductive biases for deep learning of higher-level cognition. *arXiv*, abs/2011.15091, 2020. <https://arxiv.org/abs/2011.15091>.
- A. Goyal, A. Lamb, J. Hoffmann, S. Sodhani, S. Levine, Y. Bengio, and B. Schölkopf. Recurrent independent mechanisms. *ICLR’2021*, *arXiv:1909.10893*, 2019.
- W. Grathwohl, K. Swersky, M. Hashemi, D. Duvenaud, and C. J. Maddison. Oops i took a gradient: Scalable sampling for discrete distributions, 2021.
- R.-R. Griffiths and J. M. Hernández-Lobato. Constrained bayesian optimization for automatic chemical design. *arXiv preprint arXiv:1709.05501*, 2017.
- T. Haarnoja, H. Tang, P. Abbeel, and S. Levine. Reinforcement learning with deep energy-based policies. In *International Conference on Machine Learning*, pages 1352–1361. PMLR, 2017.
- W. K. Hastings. Monte carlo sampling methods using markov chains and their applications. *Biometrika*, 1970.
- E. Hu, N. Malkin, M. Jain, K. Everett, A. Graikos, and Y. Bengio. Gflownet-em for learning compositional latent variable models. *arxiv*, 2023.
- M. Jain, E. Bengio, A. Hernandez-Garcia, J. Rector-Brooks, B. F. P. Dossou, C. Ekbote, J. Fu, T. Zhang, M. Kilgour, D. Zhang, L. Simine, P. Das, and Y. Bengio. Biological sequence design with gflownets. *International Conference on Machine Learning (ICML)*, 2022.
- M. Jain, S. C. Raparthy, A. Hernandez-Garcia, J. Rector-Brooks, Y. Bengio, S. Miret, and E. Bengio. Multi-objective gflownets. *arXiv preprint arXiv:2210.12765*, 2023.
- A. Jasra, C. C. Holmes, and D. A. Stephens. Markov chain monte carlo methods and the label switching problem in bayesian mixture modeling. *Statistical Science*, pages 50–67, 2005.
- J. H. Jensen. A graph-based genetic algorithm and generative model/monte carlo tree search for the exploration of chemical space. *Chemical science*, 10(12):3567–3572, 2019.
- D. P. Kingma and M. Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- F. R. Kschischang, B. J. Frey, and H.-A. Loeliger. Factor graphs and the sum-product algorithm. *IEEE Transactions on information theory*, 47(2):498–519, 2001.
- R. Kumar, S. Ozair, A. Goyal, A. Courville, and Y. Bengio. Maximum entropy generators for energy-based models, 2019.

- M. J. Kusner, B. Paige, and J. M. Hernández-Lobato. Grammar variational autoencoder. In *International Conference on Machine Learning*, pages 1945–1954. PMLR, 2017.
- S. Lahlou, T. Deleu, P. Lemos, D. Zhang, A. Volokhova, A. Hernández-García, L. N. Ezzine, Y. Bengio, and N. Malkin. A theory of continuous generative flow networks. *International Conference on Machine Learning (ICML)*, 2023.
- S. Lange, T. Gabel, and M. Riedmiller. Batch reinforcement learning. In *Reinforcement learning*, pages 45–73. Springer, 2012.
- S. Levine. Reinforcement learning and control as probabilistic inference: Tutorial and review. *arXiv preprint arXiv:1805.00909*, 2018.
- S. A. Malik, S. Lahlou, A. Jesson, M. Jain, N. Malkin, T. Deleu, Y. Bengio, and Y. Gal. Batchgfn: Generative flow networks for batch active learning. *arXiv preprint arXiv:2306.15058*, 2023.
- N. Malkin, M. Jain, E. Bengio, C. Sun, and Y. Bengio. Trajectory balance: Improved credit assignment in gflownets. *arXiv preprint arXiv:2201.13259*, 2022.
- N. Malkin, S. Lahlou, T. Deleu, X. Ji, E. Hu, K. Everett, D. Zhang, and Y. Bengio. GFlowNets and variational inference. *International Conference on Learning Representations (ICLR)*, 2023.
- N. Metropolis, A. W. Rosenbluth, M. N. Rosenbluth, A. H. Teller, and E. Teller. Equation of state calculations by fast computing machines. *The journal of chemical physics*, 21(6): 1087–1092, 1953.
- J. Moćkus. On bayesian methods for seeking the extremum. In *Optimization techniques IFIP technical conference*, pages 400–404. Springer, 1975.
- J.-B. Mouret and S. Doncieux. Encouraging Behavioral Diversity in Evolutionary Robotics: An Empirical Study. *Evolutionary Computation*, 20(1):91–133, 03 2012. ISSN 1063-6560. doi: 10.1162/EVCO_a_00048. URL https://doi.org/10.1162/EVCO_a_00048.
- O. Nachum, M. Norouzi, K. Xu, and D. Schuurmans. Bridging the gap between value and policy based reinforcement learning. *arXiv preprint arXiv:1702.08892*, 2017.
- O. Nachum, Y. Chow, B. Dai, and L. Li. Dualdice: Behavior-agnostic estimation of discounted stationary distribution corrections. *arXiv preprint arXiv:1906.04733*, 2019.
- C. A. Naesseth, F. Lindsten, T. B. Schön, et al. Elements of sequential monte carlo. *Foundations and Trends® in Machine Learning*, 12(3):307–392, 2019.
- H. Narayanan and S. Mitter. Sample complexity of testing the manifold hypothesis. In *NIPS’2010*, pages 1786–1794, 2010.
- C. Nash and C. Durkan. Autoregressive energy machines. In *International Conference on Machine Learning*, pages 1735–1744. PMLR, 2019.

- L. Pan, N. Malkin, D. Zhang, and Y. Bengio. Better training of gflownets with local credit and incomplete trajectories. *arXiv preprint arXiv: 2302.01687*, 2023.
- E. Pompe, C. Holmes, and K. Łatuszyński. A framework for adaptive mcmc targeting multimodal distributions. *The Annals of Statistics*, 48(5):2930–2952, 2020.
- D. Rezende and S. Mohamed. Variational inference with normalizing flows. In *International conference on machine learning*, pages 1530–1538. PMLR, 2015.
- M. Riedmiller. Neural fitted q iteration—first experiences with a data efficient neural reinforcement learning method. In *European conference on machine learning*, pages 317–328. Springer, 2005.
- S. Rifai, Y. N. Dauphin, P. Vincent, Y. Bengio, and X. Muller. The manifold tangent classifier. *Advances in neural information processing systems*, 24:2294–2302, 2011.
- T. Salimans, J. Ho, X. Chen, S. Sidor, and I. Sutskever. Evolution strategies as a scalable alternative to reinforcement learning, 2017.
- J. Schmidhuber. Reinforcement learning upside down: Don’t predict rewards—just map them to actions. *arXiv preprint arXiv:1912.02875*, 2019.
- B. Schölkopf, D. Janzing, J. Peters, E. Sgouritsa, K. Zhang, and J. Mooij. On causal and anticausal learning. In *ICML’2012*, pages 1255–1262, 2012.
- A. Seff, W. Zhou, F. Damani, A. Doyle, and R. P. Adams. Discrete object generation with reversible inductive construction. *arXiv preprint arXiv:1907.08268*, 2019.
- J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning*, pages 2256–2265. PMLR, 2015.
- N. Srinivas, A. Krause, S. M. Kakade, and M. Seeger. Gaussian process optimization in the bandit setting: No regret and experimental design. In *International Conference on Machine Learning (ICML)*, 2010.
- R. S. Sutton and A. G. Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- K. Swersky, Y. Rubanova, D. Dohan, and K. Murphy. Amortized bayesian optimization over discrete spaces. In *Conference on Uncertainty in Artificial Intelligence*, pages 769–778. PMLR, 2020.
- M. Toussaint and A. Storkey. Probabilistic inference for solving discrete and continuous state markov decision processes. In *Proceedings of the 23rd international conference on Machine learning*, pages 945–952, 2006.
- A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in neural information processing systems*, pages 5998–6008, 2017.

- J. Wen, B. Dai, L. Li, and D. Schuurmans. Batch stationary distribution estimation. *arXiv preprint arXiv:2003.00722*, 2020.
- Y. Xie, C. Shi, H. Zhou, Y. Yang, W. Zhang, Y. Yu, and L. Li. {MARS}: Markov molecular sampling for multi-objective drug discovery. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=kHSu4ebxFXY>.
- D. Zhang, N. Malkin, Z. Liu, A. Volokhova, A. Courville, and Y. Bengio. Generative flow networks for discrete probabilistic modeling. *International Conference on Machine Learning (ICML)*, 2022.
- D. W. Zhang, C. Rainone, M. Peschl, and R. Bondesan. Robust scheduling with gflownets. *International Conference on Learning Representations (ICLR)*, 2023.
- B. D. Ziebart, A. L. Maas, J. A. Bagnell, A. K. Dey, et al. Maximum entropy inverse reinforcement learning. In *Aaai*, volume 8, pages 1433–1438. Chicago, IL, USA, 2008.
- H. Zimmermann, F. Lindsten, J.-W. van de Meent, and C. A. Naesseth. A variational perspective on generative flow networks. *arXiv preprint 2210.07992*, 2022.

附录 A. GFlowNets 中的直接信用分配

类似于基于最小化与贝尔曼方程不匹配的时序差分方法，流匹配和细致平衡损失需要多次更新（并采样许多轨迹）才能将终止状态上的奖励不匹配传播到流网络内的转移概率中。这在较长的轨迹上尤为明显，并引发了关于替代更直接训练目标的问题。本节试图回答以下问题：“给定一个训练轨迹 τ ，是否存在更直接的方法来为轨迹中的早期转换分配信用？”。Malkin 等人（2022）通过引入轨迹平衡损失（例 6）提供了另一种答案。我们可以将使用 GFlowNet 采样的轨迹过程视为类似于在随机循环神经网络中采样的状态序列。复杂之处在于这样的神经网络 (i) 并不直接输出与某些目标相匹配的预测，以及 (ii) 状态可能是离散的（或离散和连续成分的组合）。关于 (i)，我们回忆一下，在转移中的流 $s \rightarrow s'$ （参与训练目标）是一个涉及所有可能导向 s 的轨迹的不可计算求和。然而，我们可能能够获得一个随机梯度，该梯度在这些轨迹的平均值上估计所需的量。为此，我们利用流的性质来获得一个随机梯度估计器，通过接下来的三个命题推导出。

通过流匹配约束表示导数的符号：在下文中有时需要区分全导数（记为 $\frac{dy}{dx}$ ），

它考虑了间接影响 由于其他导数的流匹配约束所产生 dx 的效应（记为 $\frac{\partial y}{\partial x}$ 并捕获

仅直接梯度。当约束不改变结果时，可以使用任一表示法。通过隐式依赖计算间接梯度是一个活跃的研究领域，并通常利用隐函数定理，例如，在固定点迭代层和深度平衡模型中的隐式层（Bai 等，2019）。

命题 39 考虑在流匹配约束下，流的对数在

变化的影响：它导致流的对数在

循条件概率

$P(s|s')$ ：

$s < s'$ 处轻微
 s' 处发生变化，遵

$$\frac{d \log F(s')}{d \log F(s)} = P(s|s') \quad (70)$$

其中 F 是轨迹上事件的概率分布。

证明 我们将考虑完全经过 s' 的轨迹划分成那些也经过 s 的轨迹（集合 $\mathcal{T}_{s'}^s$ ）和那些不经过的轨迹（集合 $\mathcal{T}_{s'}^{-s}$ ）。根据定义，我们可以写出：

$$P(s') = P(\mathcal{T}_{s'}^s) + P(\mathcal{T}_{s'}^{-s})$$

Because $\mathcal{T}_{s'}^s = \{\tau \in \mathcal{T} : s \in \tau, s' \in \tau\}$ ，我们可以写出 $P(\mathcal{T}_{s'}^s) = P(s)P(s'|s)$ 因此：

$$F(s') = F(s)P(s'|s) + F(\mathcal{T}_{s'}^{-s}).$$

此外，因为流在 s 不影响在 $\mathcal{T}_{s'}^{-s}$ 的轨迹，则 $\frac{dF(\mathcal{T}_{s'}^{-s})}{dF(s)} = 0$;
which leads to:

$$\begin{aligned}\frac{dF(s')}{dF(s)} &= P(s'|s) \\ \frac{dF(s')}{d \log F(s)} &= F(s)P(s'|s) \\ &= F(s \cap s') \\ &= P(s|s')F(s') \\ \frac{d \log F(s')}{d \log F(s)} &= P(s|s').\end{aligned}$$

■

命题 40 考虑边 $s \rightarrow s'$ 上流的对数发生微小变化的影响： 我们得到在 s' 处流的对数变化，遵循 $P_B(s|s')$ 逆条件概率

$$\frac{d \log F(s')}{d \log F(s \rightarrow s')} = P_B(s|s') \quad (71)$$

其中 F 是轨迹上事件的概率分布。

Proof We first use the chain rule and properties of the derivatives of the log, and then we use from the flow matching constraint that $F(s') = \sum_{s \in \text{Par}(s')} F(s \rightarrow s') \Rightarrow \frac{dF(s')}{dF(s \rightarrow s')} = 1$:

$$\begin{aligned}\frac{d \log F(s')}{d \log F(s \rightarrow s')} &= \frac{1}{F(s')} \frac{dF(s')}{dF(s \rightarrow s')} \frac{dF(s \rightarrow s')}{d \log F(s \rightarrow s')} \\ &= \frac{F(s \rightarrow s')}{F(s')} \frac{dF(s')}{dF(s \rightarrow s')} \\ &= \frac{F(s \rightarrow s')}{F(s')} \\ &= P_B(s|s').\end{aligned}$$

■

直观上，式 (70) 和式 (71) 告诉我们，流场在一个地方的扰动如何导致其他地方的变化，以维持处处的流匹配。通过流动匹配条件，将流动的无穷小变化向前后传播。因此，只有当我们接近匹配流动的极限时，它们才成立。在实践中（使用训练不完美的 GFlowNet），相应的表达式会有偏差。然而，我们可以利用它们来估计长距离平衡梯度，并在定理 41 中获得一个跨长时间轨迹的信用分配估计器。在 GFlowNet 设置中，假设我们通过参数 θ 对边缘流动估计器 $F_\theta(s \rightarrow s')$ 进行参数化。为了理解参数 θ 的变化对我们损失函数 $\mathcal{L}$ 的影响，

我们必须计算总导数 $\frac{dL}{d\theta}$ ，通过求和直接梯度和间接梯度来实现。在我们的上下文中，直接梯度 $\frac{\partial L}{\partial \theta}$ 是由于改变 θ 所引起的损失的显式变化（不考虑流匹配约束），而间接梯度则包括由该约束引起的流的变化。基于此，我们在定理 41 中形式化了总导数 $\frac{dL}{d\theta}$ 的无偏估计器：

命题 41 设 $\mathcal{L}$ 为沿轨迹 $\tau = (s_0, s_1, \dots, s_f)$ 计算的流匹配损失，该轨迹根据 GFlowNet 轨迹分布 $P(\tau)$ 采样。令 $\mathcal{L} = \sum_i L(s_i)$ 将总损失分解为轨迹上各状态的损失 $L(s_i)$ 。令 θ 参数化边缘流估计器 $F_\theta(s \rightarrow s')$ 。然后，在流趋于匹配的极限下，

$$G_1 := \sum_i \frac{\partial L(s_i)}{\partial \theta} + \frac{\partial L(s_i)}{\partial \log F(s_i)} \sum_{t=1}^{i-1} \frac{\partial \log F_\theta(s_{t-1} \rightarrow s_t)}{\partial \theta} \quad (72)$$

是一个总导数的无偏估计量 $\frac{d\mathcal{L}}{d\theta}$ ，保持不变

$$G_2 := \sum_i \frac{\partial L(s_i)}{\partial \theta} + \frac{\partial L(s_i)}{\partial \log F(s_i)} \sum_{t=1}^{i-1} \sum_{s \in \text{Par}(s_t)} P_B(s|s_t) \frac{\partial \log F_\theta(s \rightarrow s_t)}{\partial \theta} \quad (73)$$

即凸组合

$$G = \lambda G_1 + (1 - \lambda) G_2 \quad (74)$$

对于任意 $0 \leq \lambda \leq 1$ $\frac{\partial L(s_i)}{\partial \theta}$ 直观上，通过 F_θ 在 $L(s_i)$ 中的出现直接指示梯度，而 $F(s_i)$ 表示存在于 $L(s_i)$ 中的向前或向后流动总和，以获得通过 s_i 的流动。

证明 我们在不考虑匹配流约束间接影响的情况下使用偏导数记号，在考虑该影响的情况下使用全导数记号，以便应用定理 39。考虑 GFlowNet 轨迹分布下的期望值。

在公式 (72) 中 G 的贡献，利用之前的命题 (公式 (70)) 和链式法则：

$$\begin{aligned}
E[G_1] &= E \left[\sum_i \frac{\partial L(s_i)}{\partial \theta} + \sum_{t=1}^{i-1} \frac{\partial L(s_i)}{\partial \log F(s_i)} \frac{\partial \log F_\theta(s_{t-1} \rightarrow s_t)}{\partial \theta} \right] \\
&= \sum_{s_i} P(s_i) \left(\frac{\partial L(s_i)}{\partial \theta} + \sum_{s \rightarrow s' < s_i} P(s \rightarrow s' | s_i) \frac{\partial L(s_i)}{\partial \log F(s_i)} \frac{\partial \log F_\theta(s \rightarrow s')}{\partial \theta} \right) \\
&= \sum_{s_i} P(s_i) \left(\frac{\partial L(s_i)}{\partial \theta} \right. \\
&\quad \left. + \sum_{s \rightarrow s' < s_i} P_B(s | s') P(s' | s_i) \left(\frac{\partial L(s_i)}{\partial \log F(s_i)} \frac{\partial \log F_\theta(s \rightarrow s')}{\partial \theta} \right) \right) \\
&= \sum_{s_i} P(s_i) \left(\frac{\partial L(s_i)}{\partial \theta} \right. \\
&\quad \left. + \sum_{s \rightarrow s' < s_i} \frac{\partial L(s_i)}{\partial \log F(s_i)} \frac{d \log F(s_i)}{d \log F(s')} \frac{d \log F(s')}{d \log F_\theta(s \rightarrow s')} \frac{\partial \log F_\theta(s \rightarrow s')}{\partial \theta} \right) \\
&= \sum_{s_i} P(s_i) \left(\underbrace{\frac{\partial L(s_i)}{\partial \theta}}_{\text{direct gradients}} + \underbrace{\sum_{s \rightarrow s' < s_i} \frac{dL(s_i)}{d \log F_\theta(s \rightarrow s')} \frac{\partial \log F_\theta(s \rightarrow s')}{\partial \theta}}_{\text{indirect gradients}} \right) \\
&= E \left[\frac{d\mathcal{L}}{d\theta} \right] \\
&= \frac{dE[\mathcal{L}]}{d\theta}
\end{aligned}$$

上述演示表明，在等式 (74) 中的 G 当 $\lambda = 1$ 时是渐近无偏的，因为我们恢复了等式 (72) 中的 G_1 。同样的证明方法可以应用于 G_2 ，它使用从 $P_B(s | s_t)$ 采样的转移 $s \rightarrow s_t$ 而不是轨迹转移 $s_{t-1} \rightarrow s_t$ ，我们得到等式 (74) 中的估计量 G 在 $\lambda = 0$ 时是渐近无偏的。

$$\begin{aligned}
 E[G_2] &= E \left[\sum_i \sum_{t=1}^{i-1} \frac{\partial L(s_i)}{\partial \theta} + \frac{\partial L(s_i)}{\partial \log F(s_i)} \sum_{s \in \text{Par}(s')} P_B(s|s') \frac{\partial \log F_\theta(s \rightarrow s_t)}{\partial \theta} \right] \\
 &= \sum_{s_i} \sum_{s' < s_i} P(s', s_i) \left(\frac{\partial L(s_i)}{\partial \theta} + \right. \\
 &\quad \left. \sum_{s \in \text{Par}(s')} P_B(s|s') \frac{\partial L(s_i)}{\partial \log F(s_i)} \frac{\partial \log F_\theta(s \rightarrow s')}{\partial \theta} \right) \\
 &= \sum_{s_i} P(s_i) \left(\frac{\partial L(s_i)}{\partial \theta} + \right. \\
 &\quad \left. \sum_{s' < s_i} P(s'|s_i) \sum_{s \in \text{Par}(s')} P_B(s|s') \frac{\partial L(s_i)}{\partial \log F(s_i)} \frac{\partial \log F_\theta(s \rightarrow s')}{\partial \theta} \right) \\
 &= \sum_{s_i} P(s_i) \left(\frac{\partial L(s_i)}{\partial \theta} + \right. \\
 &\quad \left. \sum_{s \rightarrow s' < s_i} \left(\frac{\partial L(s_i)}{\partial \log F(s_i)} \frac{d \log F(s_i)}{d \log F(s')} \frac{d \log F(s')}{d \log F_\theta(s \rightarrow s')} \frac{\partial \log F_\theta(s \rightarrow s')}{\partial \theta} \right) \right) \\
 &= \sum_{s_i} P(s_i) \left(\underbrace{\frac{\partial L(s_i)}{\partial \theta}}_{\text{direct gradients}} + \underbrace{\sum_{s \rightarrow s' < s_i} \left(\frac{dL(s_i)}{d \log F_\theta(s \rightarrow s')} \frac{\partial \log F_\theta(s \rightarrow s')}{\partial \theta} \right)}_{\text{indirect gradients}} \right) \\
 &= \frac{dE[\mathcal{L}]}{d\theta}
 \end{aligned}$$

最后一个等式遵循了证明中的第四行 G_1 。最终，两个无偏估计量的凸组合仍然是无偏的，因此我们得出结论，在公式 (74) 中的 G 对于任意 $0 \leq \lambda \leq 1$ 是渐近无偏的。

■

这一令人惊讶的结果表明，接近策略梯度的方法实际上在期望 2 上提供了边缘流参数的渐近无偏梯度（即，在流量匹配的情况下）。请注意，它仅在线设置下精确工作，即当轨迹根据学习者的当前策略进行采样时。否则，梯度估计器可能会有偏差（实际上由于流量永远不会完全匹配，它总是会有偏差）。然而，如果我们从训练分布而不是 GFlowNet 转移概率 $P_F(s_{t+1}|s_t)$ 中采样轨迹

τ

2. 当你设想负的损失时，这种联系变得更加清晰 L 成为奖励本身，我们发现在序列较早的时间点上立即获得了训练信号 G 与策略梯度类似，但也存在差异，因为上述命题依赖于接近学习不动点的位置，在该位置流被匹配。

$\tilde{P}$ 转移概率为 $\sim P(s_{t+1}|s_t)$ 我们可以计算重要性权重 (通过比率 $P(\tau)/\tilde{P}(\tau)$ 修正估计器以适应训练分布 $\tilde{P}$ 应更广泛并具有全面支持, 重要性比率不应爆炸, 但仍可能存在此类重要性加权估计量方差的常规数值问题。我们现在考虑采样策略仅略有不同的设置 $\hat{P}$, 这通常是由于我们希望采样策略更广泛和更具探索性, 以及可能使用延迟数据, 例如带有回放缓冲区的情况。这种细微差异可能会引入偏差, 但仍然可能有利于使用上述梯度估计器。请注意, 它不会与流匹配损失的梯度 (即第一项) 产生冲突。 G)。使用的预期优势为 G 这可能通过直接向完整轨迹的早期转换提供更新来加速初始训练。然而, 类似于时间差分方法和策略梯度方法之间的权衡, 这可能会导致更高的方差。当流匹配且轨迹按照 GFlowNet 的分布进行采样时, 该估计器是无偏的, 但这也非常直观: 如果估计的流在 s_i 过小 (从视觉上看 L_i 通过增加通往该路径的状态转移概率, 可以明显提升这一流程 s_i 即使我们考虑稍微不同的轨迹采样分布, 只要它导致 s_i 我们可以预期, 增加其概率会提高最终处于某种状态的概率 s_i (参见定理 39)。如果状态具有连续部分, 我们还可以增加结束的概率 $\text{up in } s_i$ 通过更频繁地选择一个概率更高的路径来 s_i 这可以通过反向传播通过状态转换 (某种形式的时间反向传播) 来计算。然而, 如果转换不完全已知或不可微分, 则这种方法可能会更具挑战性, 并且与在具有连续状态的强化学习中的信用分配问题类似。最后, 请记住, 更直接的信用分配项在 G 必须与局部项结合 $\frac{\partial L_i}{\partial \theta}$ 这确保了流变得更加匹配, 因为流匹配是必要条件 G 以保持无偏性。

附录 B. 条件 GFlowNets

Definition 42 Consider a set of conditioning information $\mathcal{X}$, a family of DAGs $\mathcal{G} = \{G_x = (\mathcal{S}_x, \mathbb{A}_x), x \in \mathcal{X}\}$, a family of target reward functions $\mathcal{R} = \{R_x : \mathcal{S}_x^f \rightarrow \mathbb{R}^+, x \in \mathcal{X}\}$, and a flow parametrization $(\mathcal{O}_x, \Pi_x, \mathcal{H}_x)$ of (G_x, R_x) for every $x \in \mathcal{X}$. Define the **conditional configuration space** as the product

$$\mathcal{O} := \prod_{x \in \mathcal{X}} \mathcal{O}_x. \quad (75)$$

元素 $o \in \mathcal{O}$ 是一个族 $(o_x)_{x \in \mathcal{X}}$; 我们将 o_x 和 $o(x)$ 互换地表示在条件 x 下的组件。元组 $(\mathcal{X}, \mathcal{G}, \mathcal{R}, \{\mathcal{O}_x\}_{x \in \mathcal{X}}, \{\Pi_x\}_{x \in \mathcal{X}}, \{\mathcal{H}_x\}_{x \in \mathcal{X}})$ 被称为条件 GFlowNet。

与无条件情况类似, 条件 GFlowNets 提供了一种同时从不同的目标奖励函数 R_x 中采样的方法。给定一个配置 $o \in \mathcal{O}$ 的

条件 GFlowNet 和一个条件 $x \in \mathcal{X}$ ，每个条件组件 $o_x \in \mathcal{O}_x$ 诱导了一个分布 $\pi_x := \Pi_x(o_x)$ 在 $\mathcal{T}_x$ 上，即在 G_x 中的所有完整轨迹集合，这隐含地定义了 G_x 中的终止状态概率测度：

$$\forall x \in \mathcal{X} \quad \forall s \in \mathcal{S}_x^f \quad P_T(s | x) := \sum_{\tau \in \mathcal{T}_x: s \rightarrow s_f | x \in \tau} \pi_x(\tau), \quad (76)$$

其中为了清晰起见省略了对 o 在 P_T 中的依赖。条件 GFlowNets 将从目标奖励函数中采样的问题转化为搜索问题：搜索对象 $o \in \mathcal{O}$ 使得 $o_x \in \mathcal{H}_x(\mathcal{F}_{Markov}(G_x, R_x)) \subseteq \mathcal{O}_x$ 。对于这样的对象 $o \in \mathcal{O}$ ，终止状态概率测度对应于感兴趣的分布，即：

$$\forall x \in \mathcal{X} \quad \forall s \in \mathcal{S}_x^f \quad P_T(s | x) \propto R_x(s).$$

类似于无条件情况，我们需要设计一个条件损失函数 $\mathcal{L}$ 在 $\mathcal{O}$ 上，该函数仅在这些对象 o 上等于零。

定义 43 设 $(\mathcal{X}, \mathcal{G}, \mathcal{R}, \mathcal{O}, \Pi, \mathcal{H})$ 是一个条件 GFlowNet。条件流匹配损失是任何满足以下条件的函数 $\mathcal{L} : \mathcal{O} \rightarrow \mathbb{R}^+$ ：

$$\forall o \in \mathcal{O} \quad \mathcal{L}(o) = 0 \Leftrightarrow \forall x \in \mathcal{X} \exists F_x \in \mathcal{F}_{Markov}(G_x, R_x) \quad o_x = \mathcal{H}_x(F_x). \quad (77)$$

如果存在函数 $\mathcal{L}_x : \mathcal{O}_x \rightarrow \mathbb{R}^+$ 使得，则称 $\mathcal{L}$ 是条件可分解的：

$$\forall o \in \mathcal{O} \quad \mathcal{L}(o) = \sum_{x \in \mathcal{X}} \mathcal{L}_x(o_x)$$

备注 44 (摊销参数化) 在实践中，配置 $o \in \mathcal{O}$ 通常由共享参数 θ (例如，神经网络) 进行参数化，使得 $o_x = o_x(\theta)$ 对于所有 $x \in \mathcal{X}$ 成立。在这种摊销设置下，损失变为 $\mathcal{L}(\theta) = \sum_{x \in \mathcal{X}} \mathcal{L}_x(o_x(\theta))$ 。理论保证 ($\mathcal{L} = 0$ 当且仅当所有条件都匹配流动时成立) 仍然有效，但优化在各条件之间耦合。由于有限的模型容量，全局最优 $\mathcal{L} = 0$ 可能无法达到，实用最优则代表了各条件之间的权衡。

我们可以从任意一族流匹配损失出发，获得可条件分解的条件流匹配损失 $\mathcal{L}_x$ 对于 $(G_x, R_x, \mathcal{O}_x, \Pi_x, \mathcal{H}_x)$ (定理 26)。特别是，我们可以选择这些损失函数为状态可分解、边可分解或轨迹可分解。例如，如果每个 $\mathcal{L}_x = \sum_{s \in \mathcal{S}_x} L_x(\cdot, s)$ 如果该状态可分解，则同时采样问题转化为以下最小化问题：

$$\min_{o \in \mathcal{O}} \mathbb{E}_{(x,s) \sim \pi_T} [L_x(o_x, s)], \quad (78)$$

其中 π_T 是定义在 $\mathcal{X} \times \bigcup_{x \in \mathcal{X}} \mathcal{S}_x$ 上的任意条件全支撑分布

$\mathcal{S}_x$ 即一个概率

满足以下分布：

$$\forall x \in \mathcal{X} \quad \forall s \in \bigcup_{x \in \mathcal{X}} \mathcal{S}_x \quad \pi_T(x, s) > 0 \Leftrightarrow s \in \mathcal{S}_x.$$

这样的条件全支撑分布可以从任何具有全支撑的分布开始获得 $\pi_{\mathcal{X}}$ 在 $\mathcal{X}$ 以及分布 π_x 在 $\mathcal{S}_x$ 对于任意 $x \in \mathcal{X}$ ，如下所示：

$$\pi_T(x, s) = \begin{cases} \pi_{\mathcal{X}}(x)\pi_x(s) & \text{if } s \in \mathcal{S}_x \\ 0 & \text{otherwise.} \end{cases}$$

示例 9 考虑集合：

$$\mathcal{O} = \{\hat{F} : \mathcal{X} \times \bigcup_{x \in \mathcal{X}} \mathbb{A}_x^{-f} \rightarrow \mathbb{R}^+, \hat{F}(s \rightarrow s' | x) = 0 \text{ if } s \rightarrow s' \notin \mathbb{A}_x\}.$$

对于每个 $x \in \mathcal{X}$ 函数 $\hat{F}_x := \hat{F}(\cdot | x)$ 是元素属于 $\mathcal{O}_{edge, x}(Ex. 1)$, i.e. it is a 从 $\mathbb{A}_x^{-f}$ 到 x 到 $\mathbb{R}^+$ 的函数。这意味着集合 $\mathcal{O}$ 可以被视为将每个 $x \in \mathcal{X}$ 映射到 $F_x \in \mathcal{O}_{edge, x}$ ³ 的函数。记 $\mathcal{H} : x \in \mathcal{X} \rightarrow \mathcal{H}_{edge, x}$ 和 $\Pi : x \in \mathcal{X} \rightarrow \Pi_{edge, x}$ ，我们得到一个有效的条件流参数化 $(\mathcal{O}, \mathcal{H}, \Pi)$ 。不需要分别学习每个函数 $\hat{F}_x$ ，这种参数化使得能够同时学习条件 x 和非终止边 $s \rightarrow s'$ 上的函数 $\hat{F} \in \mathcal{O}$ ，从而不仅在边上，也在条件上利用机器学习算法的泛化能力。考虑为每个 $x \in \mathcal{X}$ 定义的函数 L_x ：

$$L_x(\hat{F}_x, s') = \begin{cases} \left(\log \left(\frac{\delta + \sum_{s \in Par(s')} \hat{F}(s \rightarrow s' | x)}{\delta + R(s' | x) + \sum_{s'' \in Child(s') \setminus \{s_f | x\}} \hat{F}(s' \rightarrow s'' | x)} \right) \right)^2 & \text{if } s' \neq s_f, \\ \text{否则为 } 0 & \end{cases}$$

其中 $\delta \geq 0$ 是一个超参数。函数 $\mathcal{L}$ 将每个 $\hat{F} \in \mathcal{O}$ 映射到

$$\mathcal{L}(\hat{F}) = \sum_{x \in \mathcal{X}} \sum_{s \in \mathcal{S}_x} L_x(\hat{F}_x, s'),$$

是一个既可分解为条件又可分解为状态的条件流匹配损失。

附录 C. 确定性和随机环境中的策略

迄今为止，我们关注的是确定性环境，在这种环境中，状态变化可以从给定的动作完美计算出来。当动作是认知性的，即代理内部的行为，例如顺序构建问题的候选解决方案（解释、计划、推测等）时，这种情况是有意义的。那么，当动作是外部的并影响现实世界时，情况如何呢？

只能不完全

预测。为了应对这种情况，我们现在将扩展 GFlowNet 框架，以学习代理在一个可能是确定性或随机环境中的策略 π 。

3. The definition of $\mathcal{O}$ as a set of functions is equivalent to the product-space definition $\mathcal{O} = \prod_{x \in \mathcal{X}} \mathcal{O}_{edge, x}$ via the natural isomorphism $\prod_{x \in \mathcal{X}} (\mathbb{A}_x^{-f} \rightarrow \mathbb{R}^+) \cong \left\{ \hat{F} : \bigcup_x \mathbb{A}_x^{-f} \rightarrow \mathbb{R}^+ \mid \hat{F}(s \rightarrow s' | x) = 0 \text{ if } s \rightarrow s' \notin \mathbb{A}_x \right\}$, given by $(\hat{F}_x)_{x \in \mathcal{X}} \mapsto \hat{F}$

其中 $\hat{F}(\cdot | x) = \hat{F}_x(\cdot)$. 函数空间表示在 $\hat{F}$ 由神经网络参数化时很方便，该神经网络将 x 和边作为输入。

定义 45 策略 $\pi : \mathcal{A} \times \mathcal{S} \mapsto \mathbb{R}$ 是在每个状态 s 上动作 $a \in \mathcal{A}$ 的概率分布 $\pi(a|s)$ 。为了表示动作空间可能基于 s 而受限的事实，我们将写成 $\mathcal{A}(s)$ 来表示状态 s 中的有效动作。

为了引入 GFlowNet 框架中的动作，我们将分解转换为两个步骤：首先根据策略 π 从状态 s_t 中采样一个动作 a_t ，然后环境将此动作（可能是随机的方式）转换为一个新的状态。

s_{t+1} 。

定义 46 我们将状态的概念推广如下：偶数状态的形式为 s ，而奇数状态的形式为 (s, a) 。策略 π 管理从偶数状态到兼容的下一个奇数状态的转换，其中包含 $a(s)$ ，而环境 $P(s_t \rightarrow s_{t+1} | s_t, a_t)$ 则管理从奇数状态到下一个偶数状态的转换。

根据上述定义，偶数到偶数的转换可以总结为

$$P_F(s_{t+1}|s_t) = \sum_{a_t} P(s_t \rightarrow s_{t+1} | s_t, a_t) \pi(a_t | s_t). \quad (79)$$

请注意，涉及反向转换 P_B 的细致平衡条件也将被分解为两部分：(1) 用于反转偶数到奇数的转换，以及 (2) 用于反转奇数到偶数的转换，我们必须实际表示（并学习）。

$$P_B(s_t | (s_t, a_t)) = 1 \quad (80)$$

根据定义，为了反转奇数到偶数的转换，我们必须实际表示（并学习）。

$$P_B((s_t, a_t) | s_{t+1}). \quad (81)$$

这个条件分布包含了我们对通向同一状态的不同路径的偏好，同时与环境 $P(s_t \rightarrow s_{t+1} | s_t, a_t)$ 一致。对 $\hat{P}_B$ 的归一化约束可以通过细致平衡保证流匹配，正如在等式 (31) 附近所论证的那样。

C.1 已知确定性环境

确定性环境是完全可控的：我们可以选择从上一个状态出发的有效动作中，导向最期望的下一个状态的动作。在环境为确定性的情况下，我们可以直接应用第 3 节的结果，如下所示。在每个时间步骤 t 和从状态 s_t 出发时，代理根据策略 $\pi(a_t | s_t)$ 选择一个允许的动作 $a_t \in \mathcal{A}(s_t)$ 。允许的动作集应与那些使得 $\pi(a_t | s_t) > 0$ 的动作相吻合。由于环境是已知且确定性的，存在一个确定性函数 $T : \mathcal{S} \times \mathcal{A} \mapsto \mathcal{S}$ ，它给出下一个状态 $s_{t+1} = T(s_t, a_t)$ 。在这种情况下，我们可以忽略奇偶状态的区别，并将可学习策略 π 与 GFlowNets 的可学习转移概率函数 $P_F(s_{t+1} | s_t)$ 等同起来。

命题 47 在确定性环境中，对于具有策略 $\pi(a_t | s_t)$ 和由 $s_{t+1} = T(s_t, a_t)$ 给定的状态转换的 GFlowNet 代理，转移概率 $P_F(s_{t+1} | s_t)$ 由下式给出

$$P_F(s_{t+1} | s_t) = \sum_{a: T(s_t, a) = s_{t+1}} \pi(a | s_t). \quad (82)$$

因此，如果只有单一动作 a_t 可以从 s_t 转移到 $s_{t+1} = T(s_t, a_t)$ ，则

$$P_F(s_{t+1}|s_t) = \pi(a_t|s_t). \quad (83)$$

证明 结果通过关于 a 边缘化获得：

$$\begin{aligned} P_F(s_{t+1}|s_t) &= \sum_a P(s_t \rightarrow s_{t+1}, a_t|s_t) \\ &= \sum_a P(s_t \rightarrow s_{t+1}|s_t, a_t) \pi(a|s_t) \\ &= \sum_{a: s_{t+1}=T(s_t, a)} \pi(a|s_t) \end{aligned}$$

其中 $P(s_t \rightarrow s_{t+1}|s_t, a_t) = 1_{s_{t+1}=T(s_t, a)}$ 。当只有一个可能的动作来实现转移时，因为求和只包含一项。 ■

命题 48 在具有
从前向策略

$s_{t+1} = T(s_t, a_t)$ 的确定性环境中，可以
 π_B 推导出后向转移概率函数，

$$P_B(s_t|s_{t+1}) = \sum_{a: T(s_t, a)=s_{t+1}} \pi_B(a|s_{t+1}) \quad (84)$$

而在单个动作 a_t 解释每个状态转换 $s_{t+1} = T(s_t, a_t)$ 的情况下，

$$P_B(s_t|s_{t+1}) = \pi_B(a_t|s_{t+1}) \quad (85)$$

证明 证明过程与定理 47 完全相同。 ■

C.2 不确定的确定性环境

如果环境是确定性的但未知，我们必须学习转移函数 T ，同时我们也应该学习其逆矩阵 T^{-1} ，即给定下一个状态和动作后恢复前一个状态：

$$T^{-1} : \mathcal{S} \times \mathcal{A} \mapsto \mathcal{S} \quad \text{s.t.} \quad T^{-1}(T(s, a), a) = s. \quad (86)$$

不幸的是，如果状态和动作空间是离散且高维度的，学习 T 并 T^{-1} 以一种能够推广到未见过的状态转移的方式⁴可能会很困难，并且可能通过连续松弛更容易实现。针对随机环境的方法可用于此目的。

4. 已见的转移可以直接记录在表格中，但在组合状态空间中，它们将仅占未来可能遇到的状态的一小部分。

C.3 随机环境

随机环境的设置不太直接但更通用。我们将按照方程 (79) 分解转移，但不假设 $P(s_t \rightarrow s_{t+1} | s_t, a_t)$ 是一个狄拉克分布。首先需要注意的是，我们仍然可以获得马尔可夫流，但我们不能保证能找到与期望终端奖励函数相匹配的策略。

Proposition 49 *In a stochastic environment with environment transitions $P(s_t \rightarrow s_{t+1} | s_t, a_t)$, any policy $\pi(a|s)$ can yield a Markovian flow and it may not be possible to perfectly achieve desired flows $\hat{F}(s \rightarrow s_f) = R(s)$.*

证明 我们通过满足偶数步和奇数步的流量匹配或细致平衡方程来获得流量，这总是可以通过以下原因实现的。从偶数状态开始，我们可以定义一条边流量

$$\hat{F}(s_t \rightarrow (s_t, a_t)) = \hat{F}(s_t) \pi(a_t | s_t)$$

以及反向转移是 $\pi_B(s_t | (s_t, a_t)) = 1$ 。这导致中间状态流量

$$\hat{F}((s_t, a_t)) = \hat{F}(s_t \rightarrow (s_t, a_t))$$

由于进入 (s_t, a_t) 的边仅有一条，即从 s_t 出发并采取行动 a_t 。从奇数状态来看，我们有边流

$$\begin{aligned} \hat{F}((s_t, a_t) \rightarrow s_{t+1}) &= \hat{F}((s_t, a_t)) P(s_t \rightarrow s_{t+1} | s_t, a_t) \\ &= \hat{F}(s_t) \pi(a_t | s_t) P(s_t \rightarrow s_{t+1} | s_t, a_t) \end{aligned}$$

其中 $P(s_t \rightarrow s_{t+1} | s_t, a_t)$ 表示环境，我们通过通常的公式（方程 (22)）获得偶数状态流

$$\hat{F}(s_{t+1}) = \sum_{(s_t, a_t)} \hat{F}((s_t, a_t) \rightarrow s_{t+1}) = \sum_{(s_t, a_t)} \hat{F}(s_t) \pi(a_t | s_t) P(s_t \rightarrow s_{t+1} | s_t, a_t).$$

如果未知，环境转移 $P(s_t \rightarrow s_{t+1} | s_t, a_t)$ 可以通过观察三元组 (s_t, a_t, s_{t+1}) 并估计近似最大化这些观测经验对数似然的转移概率来以通常的监督方式估算。然而，在平稳环境中，转移 $P(s_t \rightarrow s_{t+1} | s_t, a_t)$ 不依赖于策略，而反向转移 $\hat{P}_B((s_t, a_t) | s_{t+1})$ 依赖于正向环境转移和状态流，即依赖于策略。经过足够的训练时间和容量，正向和反向转移可以变得兼容，但正如 GFlowNets 中通常的情况一样，在现实设置下，流匹配方程不会完全实现。如果有足够的容量和训练时间（完成训练），我们就可以得到一个流。然后，通过从上述偶数步和奇数步顺序采样转移定义转移概率，我们得到一个马尔可夫流（定理 16）。为了证明期望的终端流不一定可实现，只需找到一个反例即可。考虑一个终端奖励 $R(s) > 0$ 而环境转移到 s 的概率为零的情况。在这种情况下，无论我们如何选择策略，都无法将期望的流放入状态 s 。

■




图 6: 考虑一个简单的反例，只有两条路径从 s 到 s''' ，给定 $R(s''') > 0$ 。一条路径经过 s' ，另一条经过 s'' 。从 s' 出发，唯一的可行动作 a' 导致 s''' ，同样地，从 s'' 出发，动作 a'' 导致 $P(s'''|s'', a'')$ 。然而，可能环境概率 $P_B((s'', a'')|s''') = 0$ ，这限制了 P_B 为 0。因此，可能无法自由选择反向转移同时匹配流和终端奖励。

还需注意，在实际操作中，即使在完全可控的环境中，我们也无法保证能找到一个与目标终端奖励函数相匹配的流，仅仅是因为 GFlowNet 的有限容量和有限训练时间。而在 GFlowNet 的确定性环境中，我们可以自由选择 P_B 对于非终端边而言，情况并非如此，如下所述。在偶数到奇数的转换上， $P_B(s|s_t, a_t) = 1_{s=s_t}$ 这是由构造决定的。在奇数到偶数的转换上， $(s_t, a_t) \rightarrow s_{t+1}$ 问题在于前向转换不是一个自由参数（它对应于环境的 $P(s_t \rightarrow s_{t+1} | s_t, a_t)$ ）。

反例 50 对于具有固定随机环境的 GFlowNet，可能无法同时自由选择 $P_B(s_t, a_t | s_{t+1})$ 并匹配流和终端奖励。为了提供一个反例，请考虑图 6 所示的设置。假设 $R(s''') \neq 0$ 以及环境提供的转换 $T(s''' | s'', a'') = 0$ 。那么，为了匹配终端奖励 $R(s''')$ ，我们必须要求 $P_B(s', a' | s''') \neq 0$ ，这意味着 P_B 不能被自由选择。

附录 D. 预期下游奖励和奖励最大化策略

我们已经介绍了概率分布 $P_T(s)$ 以及条件概率 $P_T(s' | s \leq s')$ 经过终止状态（即在退出前访问的状态）（ s_f ）。更一般地，可以考虑任何分布 $P_\pi(s)$ 源自 GFlowNet 策略某些任意选择导致的终止状态 π 并计算在此分布下的期望奖励：

定义 51 流在访问状态

R , 在终止状态上的某个分布

s 后, 具有终端奖励函数

P 下, 预期奖励为

$$V_{P_\pi}(s) := E_{P_\pi(S)}[R(S)|S \geq s] = \sum_{s' \geq s} R(s')P_\pi(s'|s \leq s'). \quad (87)$$

命题 52 当终止状态的概率分布由流给出 (参见定理 13) 时, 在此条件下的期望奖励为 P_T 给定, 其下期期望奖励为

$$V_{P_T}(s) = \frac{\sum_{s' \geq s} R(s')^2}{\sum_{s' \geq s} R(s')}. \quad (88)$$

证明 我们应用条件定义 P_T (定理 33) 到方程 (87), 从而得到结果。 ■

尽管我们在预期奖励下有一个简单的表达式 P_T 预期奖励被更广泛地定义为分布 P_π 源自任何政策 π 特别是对于任何策略 $\pi(a|s)$, 我们还可以定义期望奖励 V_{P_π} 在该分布下 P_π 由...引起的终止状态 π 预期奖励在强化学习中扮演的角色类似于状态值函数和状态-动作值函数, 因此当中间奖励为 0 且折扣因子存在时, 它们也满足策略改进定理的等价形式 $\gamma = 1$:

命题 53 设 P_π 是从策略 π , 产生的终止状态分布, 而 $\bar{\pi}$ 是在预期奖励 V_{P_π} , i.e., 下的贪婪策略。

$$\begin{aligned} \bar{\pi}(a|s) &= 0 \quad \text{unless} \\ V_{P_\pi}((s, a)) &\geq V_{P_\pi}((s, a')) \quad \forall a'. \end{aligned} \quad (89)$$

Then for all s

$$V_{P_{\bar{\pi}}}(s) \geq V_{P_\pi}(s). \quad (90)$$

也就是说, 在由 $\bar{\pi}$ 诱导的概率下的预期奖励不劣于由 π 诱导的预期奖励。

证明 让我们用 $\bar{\pi}(s)$ 表示从 s 中贪婪策略 $\bar{\pi}$ 确定性选择的动作, 并用 s_n 表示随机采样的终止状态。那么:

$$\begin{aligned} V_{P_\pi}(s) &\leq V_{P_\pi}((s, \bar{\pi}(s))) \\ &= E_{\bar{\pi}}[V_{P_\pi}(s_{t+1})|s_t = s] \\ &\leq E_{\bar{\pi}}[V_{P_\pi}(s_{t+1}, \bar{\pi}(s_{t+1}))|s_t = s] \\ &= E_{\bar{\pi}}[E_{\bar{\pi}}[V_{P_\pi}(s_{t+2})|s_t = s|s_t = s]] \\ &= E_{\bar{\pi}}[V_{P_\pi}(s_{t+2})|s_t = s] \\ &\dots \\ &\leq E_{\bar{\pi}}[V_{P_\pi}(s_n)|s_t = s] \\ &= E_{\bar{\pi}}[R(s_n)|s_t = s] \\ &= V_{P_\pi}(s) \end{aligned}$$

其中我们利用了对所有 s' , $V_{P_\pi}(s') \leq V_{P_\pi}(s', \bar{\pi}(s'))$ 的事实, 因为 $\bar{\pi}$ 是一个贪婪策略。

■

一个直接的结果如下:

推论 54 存在一个策略

$\pi^*(a|s)$, 它最大化所有状态

s 的预期奖励, 即与生成终端分布

π 的

GFlowNet 策略

$P_T(s) = R(s)/Z$ 相关的定理 53 中的贪婪策略。

如何估计在条件 P_T 下的预期奖励? 我们只需要训练另一个流 (或一组用于 GFlowNet 的头部, 参见 F 节) 以 R^2 作为奖励函数。

命题 55 考虑两个流 F 和 F' , 其中一个匹配终端奖励函数 R , 另一个匹配终端奖励函数 R^2 。那么在分布 P_T (由流 F 定义的终止状态分布) 下的预期奖励是

$$V_{P_T}(s) = \frac{F'(s|s)}{F(s|s)}. \quad (91)$$

证明 我们从上述推论的公式 (88) 开始, 并注意到分子是流 F' 的自流, 而分母是流 F 的自流 (参见公式 (44))。 ■

附录 D.1 对高奖励早期轨迹的偏好

我们在第 2.6 节中已经看到, 通过对 P_B 施加特定偏好, 可以使 GFlowNet 采样机制更倾向于按某种顺序构建状态, 例如, 可以优先选择具有较大预期奖励 (在其潜在延续上的预期奖励) 的状态, 使用定理 51。这足以定义 $P_B(s_t, a_t | s_{t+1})$, 使其将更多的概率质量分配给具有更大 $V((s_t, a_t))$ 的状态-动作对 (s_t, a_t) 。

附录 E. 中间奖励与轨迹回报

到目前为止, 在 GFlowNet 论文 (Bengio 等, 22021) 中, 我们将终端奖励视为每条轨迹仅发生一次的事件, 即在轨迹结束时。相反, 考虑一个代理体验完整的轨迹 τ , 并声明其回报为所有访问状态向汇节点转移时关联的一些中间环境奖励之和。

定义 56 轨迹回报

$\rho(\tau)$ 与部分轨迹

$\tau = (s_i, s_{i+1} \dots, s_n, s_f)$

相关联, 定义为

$$\rho(s_i, s_{i+1}, \dots, s_n, s_f) = \sum_{t=i}^n R(s_t) = \sum_{t=i}^n F(s_t \rightarrow s_f) \quad (92)$$

$$\rho(s_f) = 0 \quad (93)$$

以及与状态 s_t 相关联的预期未来回报 $\bar{\rho}(s_t)$ 定义为

$$\begin{aligned}\bar{\rho}(s_t) &= E[\rho(s_t, s_{t+1}, s_{t+2}, \dots, s_n, s_f) | s_t] \\ &= \sum_{s_{t+1}, \dots, s_n} P(s_{t+1}, \dots, s_n, s_f | s_t) \rho(s_t, s_{t+1}, \dots, s_f)\end{aligned}\quad (94)$$

其中，期望是在轨迹流的概率测度下定义的（条件是轨迹经过状态 s_t ）。

命题 57 从状态

$\bar{\rho}(s)$ 开始的所有轨迹所能达到的预期未来回报 s

满足以下递归关系：

$$\bar{\rho}(s) = R(s) + \sum_{s' \in \text{Child}(s)} P_F(s' | s) \bar{\rho}(s'). \quad (95)$$

证明 根据回报的定义（定理 56），我们得到如下结果：

$$\begin{aligned}\bar{\rho}(s_t) &= \sum_{s_{t+1}, s_{t+2}, \dots} P(s_{t+1}, \dots, s_f | s_t) (R(s_t) + \rho(s_{t+1}, s_{t+2}, \dots, s_n)) \\ &= R(s_t) + \sum_{s_{t+1}} P_F(s_{t+1} | s_t) \sum_{s_{t+2}, \dots, s_n} P(s_{t+2}, \dots, s_n | s_{t+1}) \rho(s_{t+1}, \dots, s_n) \\ &= R(s_t) + \sum_{s_{t+1}} P_F(s_{t+1} | s_t) E[\rho(s_{t+1}, s_{t+2}, \dots) | s_{t+1}] \\ &= R(s_t) + \sum_{s_{t+1}} P_F(s_{t+1} | s_t) \bar{\rho}(s_{t+1}).\end{aligned}$$

■

上述递归之所以有趣，是因为它对应于在没有折扣的情况下（在阶段性设置中）价值函数的贝尔曼方程（Sutton 和 Barto, 2018）。将其与我们为状态流获得的一个方程进行比较（方程 (22)）是很有趣的：

$$\begin{aligned}F(s_t) &= \sum_{s_{t+1}} F(s_{t+1}) P_B(s_t | s_{t+1}) \\ &= R(s_t) + \sum_{s_{t+1} \neq s_f} P_B(s_t | s_{t+1}) F(s_{t+1})\end{aligned}$$

这两个递归是不同的：一个使用前向转移将值向后传播，而另一个使用后向转移将流向前传播。

定义 58 记号

$r(s)$ 表示当智能体访问状态

s 时可能获得的随机环境奖励（通常与 **GFlowNet** 终端在状态

s 处的奖励不同），并考虑部分轨迹

$\tau =$

$(s_0, s_1, \dots, s_n)$ 到达状态

$s_n = s$ 时累积的环境奖励。称 **GFlowNet** 的状态为回报增强型，

如果状态 s 包含累积奖励

$\nu(s)$ ，即存在函数

$\nu(s) =$

$\sum_{t=0}^n r(s_t)$ 。称具有回报增强型状态的 **GFlowNet** 为回报增强型 **GFlowNet**。

我们希望在 GFlowNet 状态中跟踪累积的中间奖励，以便从状态计算终端奖励，并据此训练 GFlowNets 以按累积奖励的比例采样：

命题 59 假设 G 是一个增强回报的 GFlowNet，其目标终端奖励函数 $R(s)$ 等于累积的环境奖励 $\nu(s)$ 。进一步假设 G 被训练至完成。那么从 G 中采样产生的累积奖励 ν 的概率与其成正比 ν 。

证明 由于 G 是一个训练至完成的 GFlowNet，其终端奖励函数为 $R(s) = \nu(s)$ ，我们知道从 G 中采样可以得到累积终端奖励 $\nu(s)$ ，其概率与 ν 成正比。 ■

请注意，这样的 GFlowNet 只能离线训练，即使用已经终止并观察到回报的轨迹进行训练。还需注意的是，如果不将累积奖励添加到状态中，则 GFlowNet 的终端奖励将不是状态的函数。具有回报增强状态也使得在 GFlowNet 框架中处理随机环境奖励成为可能。

附录 F. 多流、分布式 GFlowNet、无监督 GFlowNet 和帕累托 GFlowNet 考虑一个具有随机奖励的环境。如同定理 58 所述，我们可以将状态扩展以包含随机累积奖励，从而（根据定理 59）使 GFlowNet 采样的轨迹具有返回值 ρ 的概率与 ρ 成正比。然而，类似于分布式强化学习（Bellemare 等人，22017），将 GFlowNet 推广以捕捉不仅可实现终端奖励的期望值，还包括其分布的其他统计量可能是有趣的。更一般地，我们可以将其视为一组 GFlowNet，每组在其流中建模特定未来环境结果。通过 GFlowNet 的粒子类比，这就像粒子具有颜色或标签（就像光束中一起传播的一组光子中的每个光子的频率一样），并且我们分别计算所有可能标签类型的流量。如果结果数量（可能的标签数量）较少，可以通过不同的输出头来实现 GFlowNet（例如，每个标签对应的流量有一个输出）。当观察到与特定标签结果相关的轨迹时，相应的头部获得梯度。一种更强大和通用的实现方式是将结果事件作为 GFlowNet 的输入，从而相当于训练一个条件 GFlowNet（参见第 4.4 节），并在下文形式化。

定义 60 我们将结果 $y = f(s)$ 定义为状态 s 的一个已知函数 $f(s)$ 。结果可以是一个环境奖励是否取特定值，也可以是状态 s 的重要特征向量，这些特征足以确定许多可能的环境奖励函数（特别是， f 可以是恒等函数）。我们将称这种条件 GFlowNet 为以 y 作为条件输入，具有针对事件 A 的条件流 $F(A|y)$ ，这些事件与一致的轨迹上的奖励函数

一致的轨迹上的奖励函数。

$$R_y(s) = 1_{f(s)=y} \quad (96)$$

一个结果条件的 GFlowNet，其结果函数为 f 。

在这里，为了简单起见，我们将限制自己考虑离散的结果集，但预计这种方法可以推广到连续的结果集。请注意，如果结果条件的 GFlowNet 训练完成，它使得仅采样产生选定结果 y 的终止状态 s 成为可能。原则上，这允许采样保证具有高奖励的对象（在给定的奖励函数下）。实际上，GFlowNet 永远不会被完全训练完成，我们应该像考虑目标条件策略在强化学习（Ghosh 等人，2218）或奖励条件的倒置强化学习（Schmidhuber，2019）中的情况一样看待这样的结果条件的 GFlowNet。一个有趣的问题是未来工作，即扩展这些结果条件的 GFlowNet 到随机奖励或随机环境的情况。

定义 61 分布式 GFlowNet 是一种结果条件的 GFlowNet，其条件输入是与完整轨迹相关的环境回报值。这可以通过使 GFlowNet 增强回报来实现，这样可以从轨迹的终止状态读取回报。

训练结果条件的 GFlowNet 只能离线进行，因为条件输入（例如，最终回报）可能只有在轨迹被采样后才能知道。因此，一个合理的对比训练过程可以如下进行：1. 根据无条件训练策略 π_I 采样一个轨迹 τ^+ 。

2. 从终止状态 s^+ 获得结果 $y^+ = f(s^+)$ （发生在 sink 状态 s_f 之前，在 τ^+ 中）。

3. 使用 τ^+ 和目标终止奖励 $R(s^+|y^+) =$ 更新条件 GFlowNet。

$$1_{f(s^+)=y^+} = 1.$$

4. 根据条件 GFlowNet 策略和条件抽样轨迹 τ^- y^+ 。

5. 获得实际结果 $y^- = f(s^-)$ 用于终止状态 s^- （发生在汇状态之前 s_f ）在 τ^- 如果 GFlowNet 完全训练好了，我们应该会 $y^+ = y^-$ 但除此之外，特别是当可能的结果数量很大时，这种情况变得不太可能。

6. 使用轨迹 τ^- 和目标终止奖励 $R(s^-|y) = 1_{y^-=y^+}$ （如果可能值很多，则很可能为 0）更新条件 GFlowNet，采用流匹配损失。
 $y)$ 。

一个有趣的未来工作问题是考虑平滑的奖励函数而不是尖锐但稀疏的奖励 $R(s|y) = 1_{f(s)=y}$ 作为条件奖励，以便使训练更容易。

附录 F.1 后验定义奖励函数

奖励函数可能事先未知，或者仅在某些未知常数范围内已知（例如，定义帕累托前沿），或者我们希望将 GFlowNets 泛化，使其可以以更无监督的方式进行训练或预训练，并在之后指定具体的生成任务。以下重要命题允许我们做到这一点，并将结果条件 GFlowNet 转换为根据给定奖励函数采样的 GFlowNet，而无需重新训练网络。

命题 62 考虑一个针对终止状态 s 上的可能结果 $y = f(s)$ 训练完成的结果条件 GFlowNet，以及一个后验给出的终端奖励函数 $R(s) = r(f(s))$ （可能在训练 GFlowNet 之后）作为结果 $y = f(s)$ 的函数 $r(y)$ 。然后，可以通过结果条件 GFlowNet 的流 $F(A|y)$ 获得具有事件 A 上流 $F_{r \circ f}(A)$ 的 GFlowNet，该流匹配目标终端奖励函数 $R = r \circ f$ 。

$$F_{r \circ f}(A) = \sum_y r(y) F(A|y). \quad (97)$$

例如，终端奖励 $R = r \circ f$ 的 GFlowNet 策略 $\pi_{r \circ f}(a|s)$ 可以从

$$\pi_{r \circ f}(a|s) = \frac{\sum_y r(y) F((s, a)|y)}{\sum_y r(y) F(s|y)} \quad (98)$$

或

$$\pi_{r \circ f}(a|s) = \frac{\sum_y r(y) F(s|y) \pi(a|s, y)}{\sum_y r(y) F(s|y)} \quad (99)$$

其中 $F(s|y)$, $F((s, a)|y)$ 和 $\pi(a|s, y)$ 分别是条件状态流、状态-动作流和动作策略。

证明 我们首先澄清 $F_{r \circ f}(A)$ 的含义：

$$F_{r \circ f}(A) = \sum_s r(f(s)) P(A|s \rightarrow s_f) = \sum_s r(f(s)) P_B(A|s \rightarrow s_f) \quad (100)$$

其中 $P(A|s \rightarrow s_f)$ 表示事件 A （例如特定状态或转换）在以终端转换 $s \rightarrow s_f$ 结束的所有轨迹中的概率，并且可以通过 P_B 完全确定（考虑从 s 开始并返回到特定状态或转换的所有反向路径 A ）。这意味着 $P(A|s \rightarrow s_f)$ 不依赖于奖励函数的选择，因此等式 (100) 对任何 r 均有效。显然，当 $r(y') = 1_{y=y'}$ 在某个特定的 y 值处为指示函数时，方程 (97) 在极端情况下成立，因为方程 (97) 中的求和简化为 $F(A|y)$ ，这对应于根据方程 (96) 的奖励函数 R_y 。这得出

$$F_{1_y}(A) = F(A|y) = \sum_s 1_{f(s)=y} P(A|s \rightarrow s_f) \quad (101)$$

其中 1_y 表示给定 s 后返回 $1_{y=s}$ 的函数。

为了完成证明，让我们从等式 (97) 的右侧开始，并插入上述对 $F(A|y)$ (等式 (101)) 的定义，然后交换求和并使用指示函数取消对 y 的求和，最后应用对 $F_{r \circ f}(A)$ in Eq. (100): 的定义

$$\begin{aligned}
 \sum_y r(y)F(A|y) &= \sum_y r(y) \sum_s 1_{f(s)=y} P(A|s \rightarrow s_f) \\
 &= \sum_s \sum_y r(y) 1_{f(s)=y} P(A|s \rightarrow s_f) \\
 &= \sum_s r(f(s)) P(A|s \rightarrow s_f) \\
 &= F_{r \circ f}(A)
 \end{aligned} \tag{102}$$

恢复等式 (97) 的左侧，如预期的那样。 ■

这使得预测所有可能结果 y 的概率并在不同状态下执行采样动作成为可能（在极端情况下，我们对可能的奖励函数一无所知，而结果是 $y = s$ ），然后将该 GFlowNet 实时转换为专门针对给定终端奖励函数 $R = r \circ f$ 的一个。然而，需要注意的是，这需要在运行时对每次动作进行更多的计算：我们必须对结果空间执行这些求和（可能通过蒙特卡洛积分），并且在最终决策中可能存在计算时间与精度之间的权衡（基于用于近似上述求和的蒙特卡洛样本数量）。

F.2 帕累托 GFlowNets

这些思想的相关应用涉及帕累托优化，在这种情况下，我们不确定正确的奖励函数，只知道几个系数形成潜在目标的凸组合。

定义 63 帕累托加性终端奖励函数可以表示为

$$R_\omega(s) = \sum_i \omega_i f_i(s) \tag{103}$$

其中 $\omega \in \{\omega \in W \subset \mathbb{R}^d : \omega_i \geq 0, \sum_i \omega_i = 1\}$ 是凸权重，感兴趣的成果是 d 目标 $y_i = f_i(s)$ ，而 W 是一组离散的凸权重。

定义 64 帕累托乘性终端奖励函数可以表示为

$$R_\omega(s) = e^{-\sum_i \omega_i e_i(s)} \tag{104}$$

其中 $\omega \in \{\omega \in W \subset \mathbb{R}^d : \omega_i \geq 0, \sum_i \omega_i = 1\}$ 是凸权重，感兴趣的成果是 d 目标 $y_i = f_i(s)$ ，而 W 是一组离散的凸权重。

在这种情况下，我们可以训练一个条件 GFlowNet，将 ω 作为条件输入，并将 $R_\omega(s) = R(s|\omega)$ 作为条件终端奖励函数。在运行时，我们可以通过扫描一组 ω 来获得不同的策略或预测概率或自由能。

上述内容可以很容易地推广到目标的非凸和非线性组合，只要组合的目标由 ω 参数化即可。请注意这个想法（以及更广泛的成果条件 GFlowNets）与 Dosovitskiy 和 Djolonga（2019）早期工作的相似之处。通过一种损失规格形式进行条件设置的想法可以应用于 GFlowNets，从而获得一系列 GFlowNets，每个都是针对损失函数的不同变体。具有此类奖励函数的帕累托 GFlowNet 的一个有用应用是从帕累托前沿抽取样本。一旦训练好了帕累托 GFlowNet，我们就可以通过首先抽样凸权重 ω 然后抽样轨迹来从帕累托前沿抽取样本。这在多目标优化或采样中非常有用，因为我们希望抽取对应于各种目标不同权衡点的多样化解决方案。我们还可以通过提供目标值向量 y 作为输入来训练一个结果驱动的 GFlowNet，并利用关于目标的先验知识。例如，我们可能认为不同的目标可以相互独立建模，并且 $F(s|y)$ （或者类似地对于 $F((s,a)|y)$ ）可以表示为基础扩展 $F(s|y) = \sum_{i=1}^d \sum_{j=1}^N \phi_j(y_i) F_{i,j}(s)$ ，使用 N 个基 ϕ_j 来表示目标 y_i 。如果学习不同的目标应该彼此分离（例如，一个是静止的而另一个不是），那么从泛化的角度来看，这可能是有利的。