

轨迹平衡：改进 GFlowNets 中的信用分配

Esmeralda S. Whitammer
Mila, Université de Montréal
Montréal, Québec, Canada

Moksh Jain
Mila, Université de Montréal
Montréal, Québec, Canada

Emmanuel Bengio
Mila, McGill University, Recursion
Montréal, Québec, Canada

Chen Sun
Mila, Université de Montréal
Montréal, Québec, Canada

约书亚·本吉奥 Mila, 蒙特利尔大学 蒙特利尔, 魁北克, 加拿大
{esmeralda.whitammer,moksh.jain,chen.sun,yoshua.bengio}@mila.quebec
emmanuel.bengio@recursionpharma.com

摘要

生成流网络 (GFlowNets) 是一种通过一系列动作从给定的未归一化密度生成组合对象 (如图或字符串) 的方法, 其中许多可能的动作序列可以导致相同的对象。我们发现先前提出的 GFlowNets 学习目标, 流匹配和细致平衡, 类似于时间差分学习, 容易在长动作序列中产生低效的信用传播。因此, 我们提出了一个新的 GFlowNets 学习目标, 即轨迹平衡, 作为之前使用的更高效的目标。我们证明了轨迹平衡目标的任何全局最小值都可以定义一个策略, 该策略能够精确地从目标分布中采样。在四个不同领域的实验中, 我们实证展示了轨迹平衡目标对 GFlowNet 收敛性、生成样本多样性以及对长动作序列和大动作空间的鲁棒性的益处。

1 引言

生成流网络 (GFlowNets; [3, 4]) 是一种模型, 它利用能量函数中的可泛化结构 $\mathcal{E}$ 来摊销在由节点和边组成的图等组合对象空间上的概率密度函数的采样过程 $\mathcal{X}$ 。GFlowNets 学习一个随机策略, 通过生成一系列随机动作来生成这种结构化的对象, 这些动作逐步修改部分对象 (状态), 例如, 在图中添加一条边或一个节点, 从一个通用的初始状态 (如空图) 开始。一个特殊的“退出”动作表示对象构建完成 $x \in \mathcal{X}$, 并且该策略被训练以使生成的概率与给定的未归一化的概率或奖励成正比 $x \quad R(x) = e^{-\mathcal{E}(x)}$ 。

与其他深度强化学习 [RL; 25] 模型一样, GFlowNets 使用参数化策略进行训练, 该策略可以赋予所需的归纳偏置 (例如, 特定的深度网络架构), 并允许推广到训练中未见过的状态。应用 GFlowNets 的自然领域是那些精确采样不可行且局部探索 (MCMC) 方法表现不佳的地方, 但

期望样本多样性 [3, 32, 14, 8] 例如, GFlowNets 已被用于 [3] 通过逐步添加简单的构建块来生成分子的图形描述, 其中奖励 $R(x)$ 是构建分子与蛋白质靶点结合强度的估计值: 候选数量随着分子大小迅速增加, 奖励具有许多分离的模式。如同所有通过迭代采样动作序列进行训练的强化学习模型一样, GFlowNets 面临探索与利用以及信用分配的学习挑战, 即在动作序列中传播奖励信号 [27, 2, 17] 本文关注的是 GFlowNets 在信用分配和训练方面的效率。GFlowNets 解决的学习问题与标准的强化学习奖励最大化范式有两个基本差异。首先, GFlowNets 的目标是使到达终止状态的概率与奖励成正比, 而不是集中在最大奖励的状态上。因此, GFlowNets 必须建模目标分布中的多样性, 而不仅仅是其主导模式。如果每个状态只有一个到达方式, 可以通过适当的熵最大化正则化将强化学习中的奖励最大化转化为按比例采样奖励 [3] 与 RL 中的奖励最大化相比, GFlowNet 训练目标的第二个不同之处在于, 即使多个动作序列导致相同的终止状态, 仍然可以实现正确的采样。请注意, 到达某个状态的可能性是所有导向该状态的动作序列可能性之和, 而这样的路径数量可能与其长度呈指数级增长。

所有可实现的动作和状态序列可以从概念上组织成一个有向图 $G = (\mathcal{S}, \mathcal{A})$ 其中顶点 $\mathcal{S}$ 是状态 (其中一些被指定为终止状态, 与 $\mathcal{X}$) 和边 $u \rightarrow v$ 在 $\mathcal{A}$ 每一种都对应在某状态下执行一个动作 $u \in \mathcal{S}$ 并进入状态 v 。在 [3] 一个 GFlowNet 通过定义在边上的非负函数来描述, 该函数称为边流 $F: \mathcal{A} \rightarrow \mathbb{R}_{\geq 0}$, 其中 $F(u \rightarrow v)$ 是一个未归一化的似然, 用于执行修改状态的动作 u 以表明 v GFlowNet 策略对转移进行采样 $u \rightarrow v$ 从状态 u 以概率 $F(u \rightarrow v) / \sum_{v'} F(u \rightarrow v')$ 其中分母对从节点出发的边进行求和 u 通过与经典网络流概念类比 [9] 可以将这种流视为通过边 (如管道) 或状态 (如管道交汇处的 T 型接头) 流动的水量。研究表明, GFlowNet 策略按比例采样 x 如果 $R(x)$ 满足一组线性流匹配约束 (即守恒定律: 流入一个状态的流之和应等于从该状态流出的流之和)。这些约束被转换成类似于时间差分的目标函数, 可以通过优化近似 F 的神经网络参数来实现。在 F 中提出了基于细致平衡约束的另一种目标函数。[4] 然而, 这些目标函数如同时间差分学习一样, 可能会遭受缓慢的信用分配问题 [27, 2, 17]。

本文的主要贡献 (§ 3) 是一种新的 GFlowNets 参数化和目标函数。该目标函数称为轨迹平衡, 它是在从初始状态到终止状态的采样完整动作序列 (轨迹) 上计算的, 这与流匹配和细致平衡目标函数不同。我们证明了全局最小化轨迹平衡意味着所学的动作策略按比例采样 R 。我们还通过实验证明, 轨迹平衡目标相对于先前提出的其他目标加速了训练收敛, 改善了所学采样策略在多样性度量和奖励函数发散方面的表现, 并允许学习生成比以前更长序列的 GFlowNets。作为次要贡献, 我们进行了首次对细致平衡训练目标的经验验证。对三种 GFlowNet 目标函数和非 GFlowNet 基线的比较评估在四个领域进行, 这些领域展示了奖励景观的不同特征: • 超网格 (§ 5.1), 一个具有模式间隔宽谷的示例合成环境; • 分子综合 (§ 5.2), 一个实用的图生成问题, 在此问题中, 轨迹平衡目标导致显著的计算加速和更多样化的生成候选物; • 序列生成 (§ 5.3), 在此我们展示了在合成数据和实际 AMP 序列数据上的大型动作空间和长动作序列中轨迹平衡的鲁棒性。自本文最初出现在 arXiv 以来, 多篇已发表论文和预印本成功地将轨迹平衡及其推广应用于各种应用中 [32, 14, 8, 18]。

2 预备知识

2.1 马尔可夫流

我们给出一些基本定义，参考自 [4] 的 §2。固定一个有向无环图 $G = (\mathcal{S}, \mathcal{A})$ ，其状态空间为 $\mathcal{S}$ ，动作空间为 $\mathcal{A}$ 。设 $s_0 \in \mathcal{S}$ 为特殊的初始（源）状态，即唯一没有入边的状态，并指定没有出边的顶点为终端（汇）状态¹。我们将顶点称为状态，将边称为动作，将从某个状态出发的出边可达的状态称为其子节点，将入边的来源称为其父节点。

完整的轨迹是一系列状态转移 $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_n)$ 从初始状态开始 s_0 到达终止状态 s_n 其中 $(s_t \rightarrow s_{t+1}) \in \mathcal{A}$ 对于所有 t 。令 $\mathcal{T}$ 表示所有完整轨迹的集合。轨迹流是一个非负函数 $F : \mathcal{T} \rightarrow \mathbb{R}_{\geq 0}$ 。以水流为例，它可以表示沿此路径流动的水分子数量（单位并不重要，因为流函数可以任意缩放，因为我们将其归一化以得到概率）。对于任何状态 s ，定义状态流 $F(s) = \sum_{s \in \tau} F(\tau)$ ，对于任意边 $s \rightarrow s'$ ，边流

$$F(s \rightarrow s') = \sum_{\tau = (\dots \rightarrow s \rightarrow s' \rightarrow \dots)} F(\tau). \quad (1)$$

根据这一定义，对于所有非初始和非终端状态，流匹配约束（流入流量 = 流出流量）均得到满足：

$$F(s) = \sum_{(s'' \rightarrow s) \in \mathcal{A}} F(s'' \rightarrow s) = \sum_{(s \rightarrow s') \in \mathcal{A}} F(s \rightarrow s'). \quad (2)$$

一个非平凡（即不恒为零）的轨迹流 F 确定了一个在轨迹上的分布 F ，

$$P(\tau) = \frac{1}{Z} F(\tau), \quad Z = F(s_0) = \sum_{\tau \in \mathcal{T}} F(\tau). \quad (3)$$

轨迹流 F 若存在动作分布，则具有马尔可夫性 $P_F(-|s)$ 遍历每个非终结状态的子节点 s 使得分布 F 具有因式分解

$$P(\tau = (s_0 \rightarrow \dots \rightarrow s_n)) = \prod_{t=1}^n P_F(s_t | s_{t-1}). \quad (4)$$

等价地 ([4], 命题 3) 存在分布 $P_B(-|s)$ 对于每个非初始状态的父节点 s 使得对于任何终端状态 x ，

$$P(\tau = (s_0 \rightarrow \dots \rightarrow s_n) | s_n = x) = \prod_{t=1}^n P_B(s_{t-1} | s_t). \quad (5)$$

如果 F 是一个马尔可夫流，则 P_F 和 P_B 可以通过状态流和边流来计算：

$$P_F(s' | s) = \frac{F(s \rightarrow s')}{F(s)}, \quad P_B(s | s') = \frac{F(s \rightarrow s')}{F(s')}, \quad (6)$$

假设分母不为零。我们将 P_F 和 P_B 分别称为对应于 F 的前向策略和后向策略。这些关系由细致平衡约束总结

$$F(s) P_F(s' | s) = F(s') P_B(s | s'). \quad (7)$$

唯一性性质。 马尔可夫流由边流唯一确定，即在每条边上选择一个非负值，满足流匹配约束 (2)。根据推论 1[4]，马尔可夫流也可以通过以下任一方式唯一确定：• 每个非终端状态的孩子节点上的常数 $Z = F(s_0) > 0$ 和分布 $P_F(-|s)$ ；或者 • 每个终端状态 x 上的非平凡非负状态流的选择 $F(x)$ 以及每个非初始状态的父节点上的分布选择 $P_B(-|s)$ 。

¹[3] 允许具有出边的终端状态。这一差异很容易通过给每个这样的状态 x 添加一个新的终端状态 $x^\dagger$ 和停止动作 $x \rightarrow x^\dagger$ 来克服。

2.2 GFlowNets

假设在终端状态集合上给出了一个不平凡的非负奖励函数 $R: \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}$ 。GFlowNets [3] 旨在近似一个满足条件的马尔可夫流 F 上的流 G 。

$$F(x) = R(x) \quad \forall x \in \mathcal{X}. \quad (8)$$

本文采用广义定义，将 GFlowNet 视为任何包含以下组成部分的学习算法：• 能够提供初始状态流 $Z = F(s_0)$ 以及任意非终止状态 s 向前动作分布 $P_F(-|s)$ 的模型（因此，通过上述方式，隐式地唯一确定一个马尔可夫流 F ）；• 目标函数，使得如果模型能够表示任何动作分布，并且目标函数全局最小化，则对应的马尔可夫流 F 满足约束 (8)。

GFlowNet 的前向策略可用于从相应的马尔可夫流中采样轨迹 F 通过根据策略迭代地采取行动 $P_F(-|s)$ 。如果目标函数全局最小化，则终止于 x 的概率与其成正比 $R(x)$ 。

一般来说，优化 (8) 的目标不能直接最小化，因为 $F(x)$ 是所有通往 x 的轨迹的总和，计算它可能不实用。因此，之前提出了两个局部目标——流匹配和细致平衡。

流匹配目标 [3]。一个模型 $F_\theta(s, s')$ 带有可学习参数 θ 近似边缘流 $F(s \rightarrow s')$ 。相应的前向策略由 $P_F(s'|s; \theta) \propto F_\theta(s, s')$ (Eq. (6) 给出。记对应的马尔可夫流为 F_θ ，轨迹上的分布为 P_θ 。参数被训练以最小化所有非初始和非终端节点的流匹配约束 (2) 中的误差 s ：

$$\mathcal{L}_{\text{FM}}(s) = \left(\frac{\sum_{(s'' \rightarrow s) \in \mathcal{A}} F_\theta(s'', s)}{\sum_{(s \rightarrow s') \in \mathcal{A}} F_\theta(s, s')} \right)^2 \quad (9)$$

以及类似的优化目标 $\mathcal{L}'_{\text{FM}}$ 在流入处施加 $x \in \mathcal{X}$ 使之等于 $R(x)$ 在终端节点处 x 。此目标针对非终端状态进行优化 s 以及终端状态 x 从训练策略采样的轨迹中 π_θ 。通常， π_θ 被选为一个经过调整的（较高温度）版本 $P_F(-|s, \theta)$ ，这也有助于训练过程中的探索。参数通过随机梯度进行更新

$$\mathbb{E}_{\tau=(s_0 \rightarrow \dots \rightarrow s_n) \sim \pi_\theta} \nabla_\theta \left[\sum_{t=1}^{n-1} \mathcal{L}_{\text{FM}}(s_t) + \mathcal{L}'_{\text{FM}}(s_n) \right]. \quad (10)$$

根据 [4] 中的命题 10，若训练策略 π_θ 具有完全支撑，并且在从 π_θ 采样的轨迹状态上预期损失 (9) 的全局最小值被达到，则 GFlowNet 将从目标分布中采样（即， F_θ 满足 (8)）。

细致平衡目标 [4]。一种具有参数 θ 的神经网络模型，其输入为 s ，并有三种输出：估计的状态流 $F_\theta(s)$ ，估计的子节点分布 $P_F(-|s; \theta)$ ，和估计的父节点分布 $P_B(-|s; \theta)$ 。策略 $P_F(-|s; \theta)$ 和初始状态流 $F_\theta(s_0)$ 唯一地确定了一个马尔可夫流 F_θ ，该流不一定与估计的反向策略 $P_B(-|s; \theta)$ 兼容。在详细平衡约束 (7) 中的误差通过训练策略采样的轨迹上非终端节点之间的动作 $(s \rightarrow s')$ 进行优化：

$$\mathcal{L}_{\text{DB}}(s, s') = \left(\log \frac{F_\theta(s) P_F(s'|s; \theta)}{F_\theta(s') P_B(s|s'; \theta)} \right)^2, \quad (11)$$

类似地，对于导致终端节点的动作，优化了一个类似的约束 $\mathcal{L}'_{\text{DB}}(s, x)$ 。与流匹配类似，参数通过随机梯度进行更新

$$\mathbb{E}_{(s_0 \rightarrow \dots \rightarrow s_n) \sim \pi_\theta} \nabla_\theta \left[\sum_{t=1}^{n-1} \mathcal{L}_{\text{DB}}(s_{t-1}, s_t) + \mathcal{L}'_{\text{DB}}(s_{n-1}, s_n) \right] \quad (12)$$

沿从训练策略采样的轨迹 π_θ 。由命题 6 可知 [4]，在预期细致平衡损失下的全局最小值 π_θ 具有全支持的定义了一个 GFlowNet，该网络从目标分布中采样，即流动 F_θ 满足 (8)。

在实际操作中，向神经网络提供 s 的表示较为方便且经济，该表示同时输出从 s 出发可到达的所有 s' 的状态流 $F_\theta(s, s')$ 。

Algorithm 1 Training a GFlowNet with trajectory balance

input Reward function $R : \mathcal{X} \rightarrow \mathbb{R}_{>0}$, model and optimizer hyperparameters

- 1: Initialize models P_F, P_B, Z with parameters θ
 - 2: **repeat**
 - 3: Sample trajectory $\tau = (s_0 \rightarrow \dots \rightarrow s_n)$ from policy $P_F(-|-; \theta)$ or a tempered version of it
 - 4: $\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}_{\text{TB}}(\tau)$ {gradient update on (14)}
 - 5: **until** convergence monitoring on running $\mathcal{L}_{\text{TB}}(\tau)$
-

备注。在某些问题中，例如自回归序列生成 (§ 5.3)，有向图 G 是一棵树，因此每个状态只有一个父节点。在这种情况下， P_B 变得简单，细致平衡目标简化为流匹配目标，进而可以证明其等价于具有温度 $\alpha = 1$ 、均匀 $q_{\mathbf{a}'}$ 和 $\gamma = 1$ 的 Soft Q-Learning (Q 学习) [12, 5]。

3 轨迹平衡

设 F 是一个马尔可夫流。 F 是根据 (3) 定义的完整轨迹上的分布，令 P_F 和 P_B 是由 F 确定的正向和反向策略。对等式 (3,4,5) 进行直接代数变换，得到任意完整轨迹 $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_n = x)$ 的轨迹平衡约束：

$$Z \prod_{t=1}^n P_F(s_t | s_{t-1}) = F(x) \prod_{t=1}^n P_B(s_{t-1} | s_t), \quad (13)$$

其中我们使用了 $P(s_n = x) = \frac{F(x)}{Z}$ 。正如 § A.2 中所解释的，轨迹平衡约束 (13) 和细致平衡约束 (7) 是一般约束的特殊情况，该一般约束已被研究作为训练目标在 [18] 中。

作为目标的轨迹平衡。本文提出将 (13) 转化为一个目标，以便沿着由训练策略采样的轨迹进行优化。假设参数为 θ 的模型输出状态 s 的估计正向策略 $P_F(-|s; \theta)$ 和反向策略 $P_B(-|s; \theta)$ （就像上面的细致平衡一样），以及一个全局标量 Z_{θ} 来估计 $F(s_0)$ 。标量 Z_{θ} 和正向策略 $P_F(-|-; \theta)$ 唯一地决定了隐含的马尔可夫流 F_{θ} 。对于轨迹 $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_n = x)$ ，定义轨迹损失

$$\mathcal{L}_{\text{TB}}(\tau) = \left(\log \frac{Z_{\theta} \prod_{t=1}^n P_F(s_t | s_{t-1}; \theta)}{R(x) \prod_{t=1}^n P_B(s_{t-1} | s_t; \theta)} \right)^2. \quad (14)$$

如果 π_{θ} 是一个训练策略——通常是给定的 $P_F(-|-; \theta)$ 或其平滑版本——那么轨迹损失会沿着从 π_{θ} 采样的轨迹进行更新，即使用随机梯度

$$\mathbb{E}_{\tau \sim \pi_{\theta}} \nabla_{\theta} \mathcal{L}_{\text{TB}}(\tau). \quad (15)$$

完整的算法，批大小为 1，展示在算法 1 中，并由以下命题保证其正确性。

命题 1。 设 R 是在 $\mathcal{X}$ 上的正奖励函数。

- (a) 如果 $P_F(-|-; \theta)$, $P_B(-|-; \theta)$ 和 Z_{θ} 分别是满足 (8) 式的马尔可夫流 F 的前向和后向策略以及归一化常数，则对于所有完整轨迹 τ 有 $\mathcal{L}_{\text{TB}}(\tau) = 0$ 。(b) 反之，假设对于所有完整轨迹 τ 有 $\mathcal{L}_{\text{TB}}(\tau) = 0$ 。那么对应的马尔可夫流 F_{θ} 满足 (8)，并且 $P_F(-|-; \theta)$ 按奖励比例采样。

证明见 § A.1。特别地，如果 π_{θ} 具有全支撑，并且 $\mathbb{E}_{\tau \sim \pi_{\theta}} \mathcal{L}_{\text{TB}}(\tau)$ 在所有前向和后向策略 (P_F, P_B) 及归一化常数 Z 上全局最小化，则对应的马尔可夫流 F_{θ} 满足 (8)，并且 $P_F(-|-; \theta)$ 按奖励比例采样。（对 R 的正性假设是为了避免在 (14) 式中除以 0，但可以通过引入平滑常数来放宽这一假设，正如在 [3, 4] 中提出的损失所做的那样）

注释。(1) 如 § 2 所述，在自回归生成的情况下， G 是一个有向树，其中每个 $s \in S$ 只有一个父状态。在这种情况下， P_B 显然为 $P_B = 1, \forall s \in S$ 。我们得到

$$\mathcal{L}_{\text{TB}}(\tau) = \left(\log \frac{Z_\theta \prod_{t=1}^n P_F(s_t | s_{t-1}; \theta)}{R(x)} \right)^2 \quad (16)$$

(2) 本文发现，在对数域中参数化 Z ($\log Z$ 是可训练参数) 并将结果输出为 $P_F(-|s; \theta)$ 和 $P_B(-|s; \theta)$ 的对数似然比是有益的，这样 (14) 中的所有乘积在对数下都变成了求和。这与流在 [3] 中的对数域参数化是一致的。此外，本文还发现，将 Z 的学习率设置得高于 P_F 和 P_B 的参数是有帮助的。

3.1 奖励匹配流的标准选择

一般而言，约束 (8) 没有唯一的解：如果 G 的基础无向图包含环，则可能存在多个马尔可夫流，其对应的行动策略按比例采样奖励。然而，根据唯一性性质，对于任何后向策略 $P_B(-|-)$ 的选择，存在一个满足 (8) 的唯一流，因此对于具有非零流的状态，存在一个唯一的相应前向策略 $P_F(-|-)$ (参见图 1)。在某些情况下，固定后向策略 P_B 并仅训练给出 P_F 和 Z_θ 的参数可能是有益的。例如，构建一个输出给定输入状态的父节点分布的模型可能很困难 (例如，在分子领域 (§ 5.2) 中，很难强制分子同构不变性)。一个自然的选择是将 $P_B(-|s)$ 设置为状态的所有父节点上的均匀分布 s , i.e., $P_B(-|s) = 1 / \# \{s' \mid (s' \rightarrow s) \in \mathcal{A}\}$ 。

4 相关工作

强化学习。 GFlowNets 被训练成按比例采样奖励，而不是像通常在 RL 中那样最大化它。然而，在树结构 DAG (自回归生成) 上，它们等价于带有适当的熵正则化或软 Q 学习的 RL，并且控制作为推理 [5, 12, 13]。实验和讨论 [3] 展示了这些方法如何在 GFlowNets 处理良好的一般 DAG 情况下失败。轨迹平衡中跨越几个动作序列的信号传播也与在子轨迹上计算的 RL 损失相关 [22]。

局部探索与未见模式的摊销泛化 GFlowNets 也与从未归一化密度中采样的 MCMC 方法相关。尽管在离散空间中当精确采样不可行时，已有加速或部分摊销采样的工作 [11, 7]，其中一些方法具有特定领域或问题的特性 [30]，但 GFlowNets 将数据中的组合结构视为一个学习问题 (使泛化到未见过的模式成为可能)，而不是作为构建到采样器中的偏差。因此，成本被摊销并通过采样学习该结构来承担，而不是在生成时间通过搜索来承担。

变分推断。 GFlowNets 与拟合层次生成模型的变分方法有关。在 [20] 中提出的作为优化证据下界的控制变量的平方对数比率损失可以被视为轨迹平衡的一个特例。参见 § A.3 进一步讨论，在此我们证明了轨迹平衡的在线策略优化等价于最小化某个 KL 发散。两篇最近的论文 [31, 19] 扩展了我们的观察。

5 实验

我们评估所提出的轨迹平衡目标相对于训练 GFlowNets 的先前目标以及用于学习近似按奖励比例采样对象的标准方法 (如 MCMC) 以及其他强化学习技术的表现。我们的实验包括来自 [3] 的超网格和分子合成任务以及两个新任务，在这些任务中 G 是一个有向树。

³ 由于损失 (14) 在 $\log Z$ 上是二次的，对 $\log Z$ 的梯度更新等同于将其设置为 $\log \prod P_F$ 和 $\log(R(x) \prod P_B)$ 之间差异的加权移动平均值。增强动量的优化器会使情况复杂化：我们将这些问题的经验调查留待未来的工作。

5.1 超网格环境

在本小节中，我们研究由 [3] 引入的合成超网格环境。这个任务比我们研究的其他任务更容易，但我们为了完整性而包含它，并因为它允许我们展示一些有趣的特性。⁴ 在这个环境中，非终止状态 S° 形成一个维度为 D 的超网格，边长为 H ：

$$S^\circ = \{(s^1, \dots, s^D) \mid s^d \in \{0, 1, \dots, H-1\}, d = 1, \dots, D\},$$

动作是对状态的一个坐标加 1 的操作，且不会超出网格范围。初始状态是 $(0, \dots, 0)$ 。对于每一个非终止状态 s ，也存在一个终止动作，该动作会转移到对应的终止状态 $s^\top$ （参见脚注 1）。在终止状态 $s^\top = (s^1, \dots, s^D)^\top$ 处的奖励由

$$R(s^\top) = R_0 + 0.5 \prod_{d=1}^D \mathbb{I} \left[\left| \frac{s^d}{H-1} - 0.5 \right| \in (0.25, 0.5] \right] + 2 \prod_{d=1}^D \mathbb{I} \left[\left| \frac{s^d}{H-1} - 0.5 \right| \in (0.3, 0.4) \right]$$

给出，其中 $\mathbb{I}$ 是一个指示函数，而 R_0 是一个控制探索难度的常数。这个奖励在超网格的角落附近有高度为 $2.5 + R_0$ 的峰值，周围是高度为 $0.5 + R_0$ 的高原。这些高原之间被宽广的低奖励谷地分开，奖励值为 R_0 。图 1 左面板展示了 $H = 8$ 和 $D = 2$ 的情况。此环境评估 GFlowNet 从已访问状态推广到推断尚未访问模式的能力。

我们使用细致平衡 (DB) 和轨迹平衡 (TB) 目标训练 GFlowNets，采用不同的 H, D ，和 R_0 ，除了重现流匹配 (FM) 实验和基于非 GFlowNet 的基线之外 [3] 已发布的代码。本文的 GFlowNet 策略模型是一个多层感知器 (MLP)，其输入为状态的一热编码 s （旨在实现泛化）并输出正向和反向策略的对数几率 $P_F(-|-; \theta)$ 和 $P_B(-|-; \theta)$ （以及估计的状态流 $F_\theta(s)$ 在 DB 的情况下）。前向策略、后向策略和状态流模型共享多层感知机除最后一层权重矩阵外的所有部分。这与 [3] 的模型，其中相同的架构被接受 s 作为输入和输出估计的流量 $F_\theta(s, s')$ 对所有子节点 s' 的 s 。细节见 § B.1。

我们考虑一个四维网格，其维度为 $H = 8$ ，以及一个二维网格，其维度为 $H = 64$ 。两个网格具有相同数量的终止状态，但二维网格的预期轨迹长度更长。对于两种网格大小，我们都考虑 $R_0 = 0.1, 0.01, 0.001$ ，较小的 R_0 会导致更难探索的环境，因为模型穿越低奖励谷地的可能性较低。对于使用 DB 和 TB 训练的模型，我们也探讨了将后退策略固定为均匀分布的效果 (§ 3.1)。

结果。 在图 2 中，我们绘制了训练过程中模型演化的趋势 L_1 真实奖励分布（reward 分布）之间的误差 $R(x)$ 在所有可能的终止状态上进行归一化 ($x \in \mathcal{X}$) 以及最后的经验分布 $2 \cdot 10^5$ 所有设置下的访问状态（其概率为 0 的 x 未访问过）。尽管所有模型和设置都能收敛到相同的稳定最小值，DB 和 TB 训练通常比 FM 更快收敛，在 4 维环境中，TB 相比详细平衡略有优势。

均匀分布的影响 P_B 。 请注意具有固定均匀反向策略的模型与具有学习到的策略的模型之间的学习速度差异 P_B 。正如 § 3.1 中所指出的，当 P_B 固定时，存在一个唯一的 P_B 能够全局最小化目标函数，但可能需要缓慢接近。然而，如果允许 $P_F(-|-; \theta)$ 和 P_B 共同演化，它们可以更快地接近众多最优解之一。这一点通过具有学习到的 P_F 的模型在 P_B 上的快速收敛得到了证实 64×64 网格。我们观察到，尤其是在大尺寸网格的情况下，当 P_B 和 P_F 当两者都被学习后，模型倾向于首先在一个坐标方向上采取所有动作，然后在另一个方向上继续前进直至终止（如同图 1 右侧所示），可能是因为在整个网格的大部分区域上，两个动作（‘继续向右’和‘终止’）的恒定分布可以用更高的精确率建模，而复杂的依赖于位置的分布则如图 1 中间部分所示。

⁴Code: <https://gist.github.com/malkin1729/9a87ce4f19acdc2c24225782a8b81c15>.




图 1: 左: 在一个 8×8 网格环境 (§ 5.1) 上的奖励函数 (带有 $R_0 = 0.1$)。中间和右: 两种向前动作策略——具有固定均匀的 P_B 和具有学习到的非均匀的 P_B ——从这个奖励中采样。从每个状态向上和向右指的箭头长度与相应动作在 P_F 下的概率成正比, 红色八边形的大小与终止动作的概率成正比。




图 2: 在不同网格大小的网格环境中, 真实状态分布与采样状态分布之间的经验误差 L^1 及其它条件 R_0 。5 个随机种子的均值和标准误。PPO 和 MCMC 基线的曲线将超出图表范围。

5.2 小分子药物合成

接下来, 我们考虑分子生成任务 [30, 15, 16, 10, 24], 该任务在 [3] 中为 GFlowNets 引入。我们在 [3] 发布的代码基础上实现了 TB 和 DB 目标。⁵ 目标是生成具有低结合能到 4JNC 抑制剂 (可溶性环氧化物水解酶) 蛋白的分子, 形式为图。生成的图是构建块词汇表的连接树 [15]。奖励定义为通过代理模型预测的归一化负结合能, 该代理模型本身训练用于预测通过对接仿真计算的能量 [26]。最大轨迹长度为 8, 动作数量在大约 100 到 2000 之间变化 (分子越大, 可能添加的数量越多), 这使得 $|\mathcal{X}|$ 大约为 10^{16} 。

结果。 我们在图 3 (左和中) 绘制了对数奖励和对数采样概率 (从学习策略中采样的轨迹终止于 x 的可能性) 之间的相关性, 对于使用 TB、FM 和 DB 训练的 GFlowNets。这种相关性对于使用 TB 训练的模型显著更高。所示的点 x 来自固定测试集, GFlowNets 在训练过程中无法访问此测试集。请注意, 完美模型的相关性应为 1, 因为 $\log R(x)$ 和 $\log p_\theta(x)$ 仅相差一个常数 (等于 $\log Z$), 该常数独立于 x 。在图 3 (右) 中, 我们绘制了训练过程中生成的 1000 个最高奖励样本的平均成对 Tanimoto 相似度 [1]。我们看到 TB 始终生成更多样化的分子比 FM。这些结果展示了 TB 的好处, 不仅在于更快的时间信用分配, 还在于泛化和多样性。此外, TB 相对于 FM 有高达 $5\times$ 的运行时间加速, 因为不需要枚举父节点。参见 § B.2 进行进一步讨论。

5.3 自回归序列生成

最后, 我们在自回归序列生成任务上评估 TB 目标。在 § 5.3.1 中, 我们研究了轨迹长度和动作空间大小对 GFlowNets 学习动态的影响。在 § 5.3.2 中, 我们考虑更现实的任务, 即生成具有抗微生物特性的肽 (短蛋白质序列), 并评估 GFlowNets 相对于标准 RL 和 MCMC 基线的表现。

⁵Code: https://github.com/GFN0rg/gflownet/tree/trajectory_balance.




图 3: 左、中: 奖励与采样概率之间的皮尔森相关性。 $\log p_\theta(x)$ 是从学习到的策略中采样的轨迹的对数似然度 $P_F(-|-; \theta)$ 终止于 x 。左: 测试集上的散点图 x 的最佳超参数对应的 TB、FM 和 DB 的值。中: 小提琴图展示了 16 种超参数设置和每种设置下的 3 个种子的相关性, 表明 TB 能够更好地拟合。右: 随着训练进程, GFlowNets 生成的前 1000 个样本的平均成对 Tanimoto 相似性。线条表示多次运行的平均值, 阴影区域表示标准差。使用 TB 训练的模型始终具有比使用 FM 更低的相似性, 因此具有更大的多样性。我们假设相对于 DB, TB 在相关性和多样性方面的较高方差与随机梯度的高方差有关; 参见 [18]。

5.3.1 二进制序列

任务。 目标是生成固定长度的二进制序列 $n = 120$ ($\mathcal{X} = \{0, 1\}^n$, 其中奖励设计为在一个给定的固定集合 $M \subset \mathcal{X}$ 上具有模式, 而该集合对于学习者来说是未知的。序列 x 的奖励定义为 $R(x) = \exp(1 - \min_{y \in M} d(x, y)/n)$, 其中 d 是编辑距离。我们在 § B.3 中描述了生成 M 的过程。

对于不同整数 k 除以 n 的情况, 我们在 $\mathcal{X}$ 中设计了从左到右生成序列的动作空间, 其中完整的轨迹包含 $\frac{n}{k}$ 个动作, 每个动作在部分序列的末尾添加一个 k 位的‘词’。在这个状态空间上的前向策略等同于一个词汇量大小为 2^k 的自回归序列模型。通过改变 k 而固定 $\mathcal{X}$ 和 M , 我们可以研究轨迹长度 ($\frac{n}{k}$) 与动作空间大小 ($|V| = 2^k$) 之间的权衡效应, 而不改变潜在的概率建模问题。

我们将使用 TB 目标训练的 GFlowNets 与使用 FM 目标训练的 GFlowNets (在这种情况下等同于 DB 和软 Q 学习) 以及两个非 GFlowNets 基线进行比较: 带有熵正则化的 A2C [29, 21]、软演员-评论家 [13, 6] 和 MARS [30]。我们在所有方法中使用基于变换器的架构 [28]。详情请参见 § B.3。

为了评估这些方法, 我们使用 (1) 在测试集上生成序列的概率 $p(x) = F(x)/Z$ 与其奖励 $R(x)$ 之间的斯皮尔曼相关性, 该测试集近似均匀地覆盖了奖励可能值的范围; (2) 捕获的模式数量 (从 M 中参考序列的数量, 其中距离为 δ 的候选序列已被生成)。在我们的实验中, $n = 120$, $|M| = 60$, $k \in \{1, 2, 4, 6, 8, 10\}$, 和 $\delta = 28$ 。

结果。

图 4 (左) 展示了 Spearman 相关性评估的结果。观察发现, 采用 TB 目标训练的 GFlowNets 学习到的策略与奖励的相关性最佳 $R(x)$ 跨越所有动作空间。特别是, 我们观察到在使用 FM 训练的 GFlowNets 中, 无效信用分配的影响, 因为相关性随着增加而提高 k 即较短的轨迹。另一方面, 较大的动作空间也会影响使用 FM 目标训练的 GFlowNets, 而 TB 目标则对此具有鲁棒性。此外, 我们可以在图 4 (右) 中观察到, 在固定 k , 利用 TB 训练的 GFlowNets 比其他方法更快地发现更多模式。

5.3.2 抗菌肽 (AMP) 生成

在本节中, 我们考虑生成具有抗微生物活性的肽序列这一实用任务。目标是生成一个蛋白质序列 (其中词汇由 20 种氨基酸组成,

表 1: AMP 生成任务的结果。

	Top 100 Reward	Top 100 Diversity
GFN- $\mathcal{L}_{TB}$	0.85 ± 0.03	18.35 ± 1.65
GFN- $\mathcal{L}_{FM}/\mathcal{L}_{DB}$	0.78 ± 0.05	12.61 ± 1.32
SAC	0.80 ± 0.01	8.36 ± 1.44
AAC-ER	0.79 ± 0.02	7.32 ± 0.76
MCMC	0.75 ± 0.02	12.56 ± 1.45




图 4: 左: 在不同学习策略下采样概率与测试集上的奖励之间的 Spearman 相关性, 绘制于比特数的函数上 k 在符号中 V 在比特序列生成任务中。通过轨迹平衡训练的 GFlowNets 学习到的策略与奖励具有最高的相关性 $R(x)$ 并且对长度和词汇量大小具有鲁棒性。右图: 在二进制序列生成任务训练过程中发现的模式数量 $k = 1$ 。利用轨迹平衡训练的 GFlowNets 能够更快地发现更多模式。

一个特殊的序列结束动作), 最大长度为 60。我们从 DBAASP 数据库中选取 6438 个已知的 AMP 序列和 9522 个非 AMP 序列 [23]。然后在这个数据集上训练一个分类器, 使用 20% 的数据作为验证集。该模型为序列被分类为 AMP 的概率作为实验中的奖励 $R(x)$ 。状态和动作的设计与前一个实验相同, 每个动作将一个符号添加到状态的右侧。我们再次比较 TB 和 FM, 以及带有熵正则化的 A2C、SAC 和 MCMC 作为基线。我们在所有实验中都使用变换器; 详见附录 B.4。我们从每种方法生成 2048 个序列, 并选择按其奖励排名的前 100 个序列 $R(x)$ 。作为度量, 我们使用这 100 个序列的平均奖励和它们之间的平均成对编辑距离作为多样性的衡量。

结果。我们在表 1 中展示了结果, 在此观察到使用轨迹平衡 (TB) 训练的 GFlowNets 在性能和多样性度量上均优于所有基线。

6 讨论与结论

我们引入了一种新颖的 GFlowNets 训练损失——轨迹平衡 (TB), 它比先前提出的流匹配 (FM) 和细致平衡 (DB) 损失具有更快和更好的训练效果。我们证明了当最小化这一目标时, 可以实现从由未归一化的奖励函数指定的目标分布中采样的 GFlowNets 所需属性。这种新损失的动机在于观察到 FM 和 DB 损失在动作序列中是局部的, 并可能需要许多迭代才能将信用分配传播到早期动作: 如果梯度更新在远离初始状态的某个状态处引入了流量不一致性 (例如, 当采样到一个高奖励的新状态时), 则该状态的父状态必须被访问, 以便更新能够更接近根部传播, 类似于时间差分学习中奖励信号的缓慢传播。我们实证发现, TB 更快地发现了能量函数的更多模式, 并且比 FM 和 DB 更能抵抗状态空间指数增长的影响, 这在一定程度上是因为序列长度以及动作空间大小的原因。解释我们的实验结果时需要考虑的一个因素是, 由于我们使用的是神经网络而非策略的表格表示, 早期状态的转换通过参数共享得到了下游信用分配的信息。早期状态也因为序列末端附近的状态数量多于初始状态附近而得到更多的访问。最后, TB 以立即向早期状态提供信用的优势换取依赖于长轨迹采样的劣势, 从而可能导致随机梯度的方差较高。高梯度方差可能是 TB 在困难环境中的一种局限性, 后续研究已经探讨了通过在局部和轨迹级目标之间进行插值来克服这一问题的方法 [18]。总的来说, 我们发现轨迹平衡在一系列广泛的实验中是一个更优的训练目标, 使其成为未来 GFlowNets 工作的默认选择。

致谢

本研究部分得益于 Compute Canada 提供的计算资源。所有作者的资金均来自其主要学术机构。我们还感谢 CIFAR、三星、IBM、微软以及 Banting 博士后奖学金的资助。作者对 Mila GFlowNet 小组的所有成员表示感谢，特别是张定淮，他们在研究讨论中提供了许多有益的意见，同时也感谢朱义恒对已发布代码的反馈。我们还要感谢匿名审稿人的评论。

参考文献

- [1] Bender, A. and Glen, R. C. Molecular similarity: a key technique in molecular informatics. *Organic & biomolecular chemistry*, 2(22):3204–3218, 2004.
- [2] Bengio, E., Pineau, J., and Precup, D. Interference and generalization in temporal difference learning. *International Conference on Machine Learning (ICML)*, 2020.
- [3] Bengio, E., Jain, M., Korablyov, M., Precup, D., and Bengio, Y. Flow network based generative models for non-iterative diverse candidate generation. *Neural Information Processing Systems (NeurIPS)*, 2021.
- [4] Bengio, Y., Lahlou, S., Deleu, T., Hu, E., Tiwari, M., and Bengio, E. GFlowNet foundations. *arXiv preprint 2111.09266*, 2021.
- [5] Buesing, L., Heess, N., and Weber, T. Approximate inference in discrete distributions with Monte Carlo tree search and value functions. *Artificial Intelligence and Statistics (AISTATS)*, 2019.
- [6] Christodoulou, P. Soft actor-critic for discrete action settings. *arXiv preprint arXiv:1910.07207*, 2019.
- [7] Dai, H., Singh, R., Dai, B., Sutton, C., and Schuurmans, D. Learning discrete energy-based models via auxiliary-variable local exploration. *Neural Information Processing Systems (NeurIPS)*, 2020.
- [8] Deleu, T., Góis, A., Emezue, C., Rankawat, M., Lacoste-Julien, S., Bauer, S., and Bengio, Y. Bayesian structure learning with generative flow networks. *Uncertainty in Artificial Intelligence (UAI)*, 2022.
- [9] Ford, L. R. and Fulkerson, D. R. Maximal flow through a network. *Canadian Journal of Mathematics*, 8:243–248, 1956.
- [10] Gilmer, J., Schoenholz, S. S., Riley, P. F., Vinyals, O., and Dahl, G. E. Neural message passing for quantum chemistry. *International Conference on Machine Learning (ICML)*, 2017.
- [11] Grathwohl, W., Swersky, K., Hashemi, M., Duvenaud, D. K., and Maddison, C. J. Oops I took a gradient: Scalable sampling for discrete distributions. *International Conference on Machine Learning (ICML)*, 2021.
- [12] Haarnoja, T., Tang, H., Abbeel, P., and Levine, S. Reinforcement learning with deep energy-based policies. *International Conference on Machine Learning (ICML)*, 2017.
- [13] Haarnoja, T., Zhou, A., Abbeel, P., and Levine, S. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. *International Conference on Machine Learning (ICML)*, 2018.
- [14] Jain, M., Bengio, E., Hernandez-Garcia, A., Rector-Brooks, J., Dossou, B. F., Ekbote, C., Fu, J., Zhang, T., Kilgour, M., Zhang, D., Simine, L., Das, P., and Bengio, Y. Biological sequence design with GFlowNets. *International Conference on Machine Learning (ICML)*, 2022.
- [15] Jin, W., Barzilay, R., and Jaakkola, T. Chapter 11. junction tree variational autoencoder for molecular graph generation. *Drug Discovery*, pp. 228–249, 2020. ISSN 2041-3211.

- [16] Kumar, A., Voet, A., and Zhang, K. Fragment based drug design: from experimental to computational approaches. *Current medicinal chemistry*, 19(30):5128–5147, 2012.
- [17] Kumar, A., Agarwal, R., Ghosh, D., and Levine, S. Implicit under-parameterization inhibits data-efficient deep reinforcement learning. *International Conference on Learning Representations (ICLR)*, 2021.
- [18] Madan, K., Rector-Brooks, J., Korablyov, M., Bengio, E., Jain, M., Nica, A., Bosc, T., Bengio, Y., and Malkin, N. Learning GFlowNets from partial episodes for improved convergence and stability. *arXiv preprint 2209.12782*, 2022.
- [19] Malkin, N., Lahlou, S., Deleu, T., Ji, X., Hu, E., Everett, K., Zhang, D., and Bengio, Y. GFlowNets and variational inference. *arXiv preprint 2210.00580*, 2022.
- [20] Mnih, A. and Gregor, K. Neural variational inference and learning in belief networks. *International Conference on Machine Learning (ICML)*, 2014.
- [21] Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T., Harley, T., Silver, D., and Kavukcuoglu, K. Asynchronous methods for deep reinforcement learning. *International Conference on Machine Learning (ICML)*, 2016.
- [22] Nachum, O., Norouzi, M., Xu, K., and Schuurmans, D. Bridging the gap between value and policy based reinforcement learning. *Neural Information Processing Systems (NeurIPS)*, 2017.
- [23] Pirtskhalava, M., Armstrong, A. A., Grigolava, M., Chubinidze, M., Alimbarashvili, E., Vishnepolsky, B., Gabrielian, A., Rosenthal, A., Hurt, D. E., and Tartakovsky, M. Dbasp v3: Database of antimicrobial/cytotoxic activity and structure of peptides as a resource for development of new therapeutics. *Nucleic Acids Research*, 49(D1):D288–D297, 2021.
- [24] Shi, Y., Huang, Z., Feng, S., Zhong, H., Wang, W., and Sun, Y. Masked label prediction: Unified message passing model for semi-supervised classification. *International Joint Conference on Artificial Intelligence (IJCAI)*, 2021.
- [25] Sutton, R. S. and Barto, A. G. *Reinforcement learning: An introduction*. MIT Press, 2018.
- [26] Trott, O. and Olson, A. J. AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of computational chemistry*, 31(2):455–461, 2010.
- [27] van Hasselt, H., Doron, Y., Strub, F., Hessel, M., Sonnerat, N., and Modayil, J. Deep reinforcement learning and the deadly triad. *arXiv preprint 1812.02648*, 2018.
- [28] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. Attention is all you need. *Neural Information Processing Systems (NeurIPS)*, 2017.
- [29] Williams, R. J. and Peng, J. Function optimization using connectionist reinforcement learning algorithms. *Connection Science*, 3(3):241–268, 1991.
- [30] Xie, Y., Shi, C., Zhou, H., Yang, Y., Zhang, W., Yu, Y., and Li, L. MARS: Markov molecular sampling for multi-objective drug discovery. *International Conference on Learning Representations (ICLR)*, 2021.
- [31] Zhang, D., Chen, R. T. Q., Malkin, N., , and Bengio, Y. Unifying generative models with GFlowNets. *arXiv preprint 2209.02606*, 2022.
- [32] Zhang, D., Malkin, N., Liu, Z., Volokhova, A., Courville, A., and Bengio, Y. Generative flow networks for discrete probabilistic modeling. *International Conference on Machine Learning (ICML)*, 2022.

检查清单

1. 对于所有作者...

(a) 摘要和引言中提出的主张是否准确反映了论文的贡献和范围? [是] (b) 您是否描述了工作的局限性? [是] 这主要是关于理论和算法的论文。未来将这些算法应用于特定领域 (例如, 用于药物发现的分子设计) 的工作应考虑这些应用的局限性和负面社会影响。(c) 您是否讨论了您的工作可能产生的任何潜在负面社会影响? [N/A] 参见上文。(d) 您是否阅读了伦理审查指南, 并确保您的论文符合这些指南? [是] 2. 如果您包含理论结果...

(a) 您是否陈述了所有理论结果的全部假设? [是]

(b) 您是否包括了所有理论结果的完整证明? [是] 见 § A.1.

3. 如果您进行了实验... (a) 您是否包含了复制主要实验结果所需的代码、数据和说明 (无论是作为补充材料还是 URL)? [是] 对于网格和分子环境。[否] 对于其他环境。

(b) 您是否详细说明了所有训练细节 (例如, 数据划分、超参数及其选择方式)? [是] 请参阅附录。(c) 您是否报告了误差范围 (例如, 通过多次运行实验后关于随机种子的误差)? [是] 请参阅附录。

(d) 您是否包括了计算总量和所使用的资源类型 (例如, GPU 类型、内部集群或云提供商)? [是] 请参阅附录。

4. 如果您正在使用现有资产 (例如, 代码、数据、模型) 或整理/发布新资产.....

(a) 如果您的工作使用了现有资产, 您是否引用了创作者? [是] 请参阅相关实验部分。

(b) 您是否提到了资产的许可证? [N/A] (c) 您是否在补充材料或作为网址中包含了任何新资产? [N/A] 提供了分子和 AMP 序列数据的引用。

(d) 您是否讨论了是否以及如何从您使用/整理的数据主体那里获得了同意? [N/A] 没有进行新的数据收集。(e) 您是否讨论了您使用/整理的数据是否包含个人信息或冒犯性内容? [N/A] 对于研究领域不相关。

5. 如果您使用了众包或对人类受试者进行了研究.....

(a) 您是否包含了提供给参与者的指令全文和截图, 如果适用吗? [N/A]

(b) 您是否描述了参与者可能面临的风险, 并链接到机构审查委员会 (IRB) 的批准, 如果适用的话? [N/A] (c) 您是否包括了支付给参与者的每小时工资估算以及总支出金额? [N/A]

理论附录

A.1 命题 1 的证明

回顾命题 1:

命题。 设 R 是在 $\mathcal{X}$ 上的正奖励函数。

(a) 如果 $P_F(-|-; \theta)$, $P_B(-|-; \theta)$ 和 Z_θ 分别是满足 (8) 式的马尔可夫流 F 的前向和后向策略以及归一化常数, 则对于所有完整轨迹 τ 有 $\mathcal{L}_{\text{TB}}(\tau) = 0$ 。(b) 反之, 假设对于所有完整轨迹 τ 有 $\mathcal{L}_{\text{TB}}(\tau) = 0$ 。那么对应的马尔可夫流 F_θ 满足 (8), 并且 $P_F(-|-; \theta)$ 按奖励比例采样。

证明。部分 (a) 是对轨迹平衡约束 (13) 的基本操作, 其中 $R(x)$ 被奖励匹配假设 (8) 替换为 $F(x)$ 。反之, 如果对于所有完整的轨迹 $\tau = (s_0 \rightarrow \dots \rightarrow s_n = x)$ 有 $\mathcal{L}_{\text{TB}}(\tau) = 0$ 成立, 则策略 $P_F(-|-; \theta)$ 和 $P_B(-|-; \theta)$ 满足该约束

$$Z \prod_{t=1}^n P_F(s_t | s_{t-1}; \theta) = R(x) \prod_{t=1}^n P_B(s_{t-1} | s_t; \theta). \quad (17)$$

设 x 为终止状态。通过迭代全概率公式, 我们得到

$$\sum_{\tau=(s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_n=x)} \prod_{t=1}^n P_B(s_{t-1} | s_t; \theta) = 1. \quad (18)$$

(此求和中的每一项都是在马尔可夫流 τ 下终止于 $s_n = x$ 时 F'_θ 由设定的终端状态流 $F'_\theta(x) = R(x)$ 和反向策略 $P_B(-|-; \theta)$ 唯一确定的条件似然性, 参见唯一性性质。) 另一方面, 我们有

$$\begin{aligned} F_\theta(x) &= \sum_{\tau=(s_0 \rightarrow \dots \rightarrow s_n)=x} F_\theta(\tau) && \text{(by definition of state flows)} \\ &= \sum_{\tau=(s_0 \rightarrow \dots \rightarrow s_n)=x} Z \prod_{t=1}^n P_F(s_t | s_{t-1}; \theta) && \text{(by (4))} \\ &= \sum_{\tau=(s_0 \rightarrow \dots \rightarrow s_n)=x} R(x) \prod_{t=1}^n P_B(s_{t-1} | s_t; \theta) && \text{(by (17))} \\ &= R(x) && \text{(by (18)).} \end{aligned}$$

我们得出结论, F_θ 满足 (8), 正如所期望的。

(我们注意到, 可以通过类似的方式证明对于所有动作 $(s \rightarrow s') \in \mathcal{A}$, $F_\theta(s \rightarrow s') = F'_\theta(s \rightarrow s')$ 成立, 因此, 根据唯一性性质, $F_\theta = F'_\theta$, 即正向和反向策略确定相同的马尔可夫流。) $\square$

A.2 泛化

轨迹平衡约束 (13) 可以推广到部分 (不完整的) 轨迹, 即那些不从 s_0 开始且在终止状态结束的轨迹。这里提出的泛化可能对未来模块化或层次化的 GFlowNets 目标有用, 其中每个模块 (或低级 GFlowNets) 可以将其应用于它们能够访问的子序列 (参见 [4] 中的 § 9.4 和 § 1.0.2)。

子轨迹平衡。 If $\tau = (s_m \rightarrow s_{m+1} \rightarrow \dots \rightarrow s_n)$ is a partial trajectory (i.e., $(s_t \rightarrow s_{t+1}) \in \mathcal{A}$ 对于所有 t), 则对于任何具有正向和反向策略 P_F 和 P_B 的马尔可夫流 F ,

$$F(s_m) \prod_{t=m}^{n-1} P_F(s_{t+1} | s_t) = F(s_n) \prod_{t=m}^{n-1} P_B(s_t | s_{t+1}). \quad (19)$$

这可以通过证明两边都等于来推导

$$\sum_{\tau=(\dots \rightarrow s_m \rightarrow s_{m+1} \rightarrow \dots \rightarrow s_n \rightarrow \dots) \in \mathcal{T}} F(\tau). \quad (20)$$

轨迹平衡约束 (13) 是完整轨迹的特殊情况，而细致平衡约束 (7) 则是仅含一条边的轨迹的特殊情况。此子轨迹平衡约束可以转化为学习目标：模型可以输出估计的状态流 $F_\theta(s)$ 仅对于某些非终止状态 s (“中心节点”)，并且在这些中心节点之间的轨迹段上优化 (19) 中的误差。因此，细致平衡损失对应于所有节点都是中心节点，而轨迹平衡损失仅对应于初始状态 s_0 充当中心节点。

子轨迹平衡已被探讨，并在本文审稿期间发表的一项工作中显示出收敛性优势 [18]。

非前向轨迹。对于具有混合前向和后向步骤的轨迹，轨迹平衡有一个更一般的形式。这里我们仅描述一个例子：从终止状态到终止状态的路径，先进行几次后向步骤，然后进行几次前向步骤。令 $s_1 = s'_1$ 为任意状态（不一定是 GFlowNet 初始状态的子状态 s_0 ）， $(s_1 \rightarrow s_2 \rightarrow \dots \rightarrow s_n)$ 和 $(s'_1 \rightarrow s'_2 \rightarrow \dots \rightarrow s'_{n'})$ 是从 s_0 到终止状态的两条轨迹。那么对于任何马尔可夫流 F ，必须满足以下条件：

$$R(s'_{n'}) \prod_{t=1}^{n'-1} P_B(s'_t | s'_{t+1}) \prod_{t=1}^{n-1} P_F(s_{t+1} | s_t) = R(s_n) \prod_{t=1}^{n-1} P_B(s_t | s_{t+1}) \prod_{t=1}^{n'-1} P_F(s'_{t+1} | s'_t). \quad (21)$$

也就是说，从 s_n 到 s' 的路径 n' ，无论其遍历方向如何，其可能性都相同，直到端点处奖励的比例。一种简单的方法来推导 (21) 是通过为从 GFlowNet 的初始状态到 s_n 和 $s'_{n'}$ 的两条路径写出轨迹平衡约束，这两条路径在 s_1 之前相同，然后在此处分歧，然后将一个约束除以另一个约束。请注意，此处没有出现流 $F(s_1)$ 。因此，(21) 可以转化为一个不需要模型输出任何状态流的学习目标（即使是最初的状态流 Z ）。这样的终止-终止路径也可以用于使用类似 MCMC 的局部搜索算法探索 $\mathcal{X}$ [32]。‘一步后退，两步前进’路径的特例被用于贝叶斯结构学习中的图生成问题 [8]。

附录 A.3 GFlowNets 与变分方法

我们建立了 GFlowNets 的 TB 损失与拟合顺序采样的朴素变分方法之间的联系。

假设反向策略 P_B 是固定的，并为了推导方便，假定已知 $\sum_{x \in \mathcal{X}} R(x) = 1$ 。正如正文所述，我们将 $P_B(\tau|x)$ 记为从状态 x 开始，按照反向策略采样时获得轨迹 τ 的逆轨迹的概率。

关于参数 P_F 的随策略轨迹平衡目标的梯度为：

$$\mathbb{E}_{(\tau, x) \sim P_F} \left[\nabla_\theta \left(\log \frac{R(x) P_B(\tau|x)}{P_F(\tau; \theta)} \right)^2 \right] = \mathbb{E}_{(\tau, x) \sim P_F} \left[-2 \log \frac{R(x) P_B(\tau|x)}{P_F(\tau; \theta)} \nabla_\theta \log P_F(\tau; \theta) \right], \quad (22)$$

该梯度通过采样 $\tau \sim P_F$ （终止于 $x \in \mathcal{X}$ ）并计算期望内部的项来估计。

模型 P_F 也可以通过最小化证据下界（ELBO）目标进行优化，即最小化 $D_{\text{KL}}(P_F(\tau) \| R(x) P_B(\tau|x))$ 。我们推导这个 KL 散度的梯度：

$$\nabla_\theta D_{\text{KL}}(P_F(\tau; \theta) \| R(x) P_B(\tau|x)) \quad (23)$$

$$\begin{aligned} &= \nabla_\theta \mathbb{E}_{(\tau, x) \sim P_F} \left[\log \frac{P_F(\tau)}{R(x) P_B(\tau|x)} \right] \\ &= \mathbb{E}_{(\tau, x) \sim P_F} \left[\nabla_\theta \log \frac{P_F(\tau; \theta)}{R(x) P_B(\tau|x)} + \log \frac{P_F(\tau; \theta)}{R(x) P_B(\tau|x)} \nabla_\theta \log P_F(\tau; \theta) \right]. \end{aligned} \quad (24)$$

最后一步是标准得分函数技巧，Reinforce 估计器通过采样 $\tau \sim P_F(\tau; \theta)$ 并将期望内部的项作为梯度步的方向来优化 KL 散度。但请注意，

$$\mathbb{E}_{(\tau, x) \sim P_F} \left[\nabla_{\theta} \log \frac{P_F(\tau; \theta)}{R(x)P_B(\tau|x)} \right] = \mathbb{E}_{(\tau, x) \sim P_F} [\nabla_{\theta} \log P_F(\tau; \theta)] = 0, \quad (25)$$

由于约束 Σ ，我们得出结论 $P_F(\tau; \theta) = 1$ 论，预期的轨迹平衡梯度（22）等于预期的 Reinforce 梯度（24），相差一个常数。

然而，在最优解附近（当 TB 和 KL 均为 0 时），TB 梯度估计器具有更低的方差，如下所示：

$$\begin{aligned} & \text{Var}_{(\tau, x) \sim P_F} \left[\log \frac{p(x)}{P_F(\tau; \theta)} \nabla_{\theta} \log P_F(\tau; \theta) \right] \\ & - \text{Var}_{(\tau, x) \sim P_F} \left[\nabla_{\theta} \log \frac{P_F(\tau; \theta)}{R(x)P_B(\tau|x)} + \log \frac{P_F(\tau; \theta)}{R(x)P_B(\tau|x)} \nabla_{\theta} \log P_F(\tau; \theta) \right] \\ & = -\mathbb{E}_{(\tau, x) \sim P_F} \left[(\nabla_{\theta} \log P_F(\tau; \theta) \nabla_{\theta} \log P_F(\tau; \theta)^{\top}) \left(1 + 2 \log \frac{R(x)P_B(\tau|x)}{P_F(\tau; \theta)} \right) \right]. \end{aligned}$$

如果括号内的项总是正的（特别是在接近解的区域，对于所有 τ ， $P_F(\tau) = R(x)P_B(\tau|x)$ 成立），那么所有方向导数的方差之差对于所有 θ 都是负的。

GFlowNets 与变分方法之间的联系在两篇论文中得到了更深入的探讨，这两篇论文是在本工作审稿期间发表的 [31, 19]。

附录 B 实验

B.1 超网格

对于 GFlowNet 策略模型，我们使用与 [3] 相同架构的多层感知机，包含两个隐藏层，每层有 256 个隐藏单元。所有模型均以学习率为 0.001（ P_F 和 P_B 策略模型）及 0.1（ Z_{θ} ）进行训练，最多采样 10^6 条轨迹，批大小为 16，使用 Adam 优化器，其余参数均设为其默认值。

为了复现流匹配和非 GFlowNet 基线，我们直接使用了 [3] 发布的代码。对于 TB 和 DB，我们将流模型和策略模型的学习率设置为 10^{-3} ，初始状态流设置为 $10^{-1} \log Z = \log F(s_0)$ 。（在对学习率进行 10 的幂次搜索时，发现 10^{-3} 是不导致模式崩塌形式不稳定的最大值。）所有 TB 和 DB 实验均在 CPU 上运行，每个核心大约需要 2 小时来完成 10^6 个 episode，总共需要 ~ 10 个 CPU 天来完成所有 24 种 DB 和 TB 实验设置，每种设置各有 5 个种子：

$$\{\text{TB, DB}\} \times \{\text{uniform } P_B, \text{learned } P_B\} \times \{R_0 = 10^{-1}, 10^{-2}, 10^{-3}\} \times \{(H, d) = (8, 4), (64, 2)\}.$$

B.2 分子综合

我们使用了由 [3] 提供的数据集和代理模型。我们也使用相同的架构和超参数（除了 β 和学习率）训练了 GFlowNet，但采用了本文提出的轨迹平衡损失，并使用固定的均匀后向策略 P_B 。提供的数据集中计算的结合分数是通过 AutoDock [26] 计算的。

为了测试超参数的鲁棒性，我们使用了奖励指数 $\beta = \{4, 8, 10, 16\}$ 和学习率 $\{5 \times 10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}\}$ 训练模型。与 [3] 不同，我们使用了一种更具探索性的训练策略：以概率 0.1（而不是原始的 0.05）设置轨迹在某个长度 k 停止，该长度在 3 到 8 之间均匀选择，分别为允许的最小和最大轨迹长度。

我们观察到运行时间最多提升了 $5\times$ 相对于 FM。这一改进归因于三个因素：(1) 最重要的是，FM 需要进行与采样轨迹中所有状态的父节点数量相等的模型评估次数，因为该模型给出的是从某个输入状态 $F(s \rightarrow s')$ 出发的流出量 s ，而

目标涉及对流入量的求和。另一方面，TB 和 DB 每个状态只需对前向和后向策略模型进行一次评估。

(2) 平均轨迹长度。若模型学会以更高频率提前终止，轨迹将变短，所需的模型评估次数也将减少。

(3) 硬件及 CPU 与 GPU 的负载比例。分子领域的实验在 Tesla K80 GPU 上运行；TB 的计算时间优势在相同批大小设置的新硬件上似乎较小但仍存在。（同时，轻量级网格领域的实验在 CPU 上运行，轨迹长度是控制运行时间的主要因素。）

B.3 位序列生成

生成参考序列。令 H 为一组符号（长度为 b 的简短比特序列），例如 $H = \{0110, 1100, 1111, 0000, 0011\}$ 。在 S 中，通过随机组合 m 来自 H 的符号来构造序列，例如，0011110000000011，其中 $m = 4$ 。这种构造对 $R(x)$ 施加了一种结构。在我们的实验中，我们设定 $m = \frac{n}{b}$, $b = 8$,
 $H = \{ '00000000', '11111111', '11110000', '00001111', '00111100' \}$ 。

生成测试集。由于奖励基于与集合中序列的编辑距离进行定义 M 我们生成一个测试集，该测试集在可能的值上近似均匀采样 $R(x)$ 如下：(1) 选择一种模式 $s \in M$ ，(2) 修改 i 随机比特 $\forall i < n$ 并且我们对所有模式重复此过程。

实现。我们在 PyTorch 6 中实现了带有 TB 和 FM 的 GFlowNets，用于自回归生成任务，并采用了 A2C 基线。对于 MARS (MCMC) 基线，我们修改了由 [3] 发布的实现。

超参数。我们使用变换器 [28] 作为所有方法的神经网络架构。本文使用具有 64 维度的 3 个隐藏层和 8 个注意力头。所有方法均训练 50,000 迭代次数，批量大小设为 16。我们将随机动作的概率设置为 0.0005 从中选取 $\{0.0001, 0.0005, 0.001, 0.01\}$ ，奖励指数 β 从 3 个中选出 $\{2, 3, 4\}$ ，采样温度为 P_F 对于 GFlowNets 设置为 1。轨迹平衡使用的学习率为 1×10^{-4} 从...中选取 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 对于策略参数和 1×10^{-3} 对于 $\log Z$ 。在流匹配中，我们使用的学习率为 5×10^{-4} 从...中选取 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 带有叶损失系数 $\lambda_T = 10$ 。对于带有熵正则化的 A2C，我们在演员网络和评论家网络之间共享参数，并使用学习率 10^{-4} 从...中选取 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 带有熵正则化系数 10^{-3} 从...中选择 $\{10^{-4}, 10^{-3}, 10^{-2}\}$ 。对于 SAC，我们使用...中的公式 [6] 学习率为 5×10^{-4} 从...中选择 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 目标网络更新频率为 500，初始随机步数为 200。对于 MARS 基线，我们将学习率设置为 5×10^{-4} 从...中选择 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 。对于所有方法，我们均使用 Adam 优化器。总体而言，在 Bit 序列生成实验中，我们使用了 25 个 GPU 天

B.4 AMP 生成

词汇表。20 种氨基酸的词汇表定义为：['A', 'C', 'D', 'E', 'F', 'G', 'H', 'I', 'K', 'L', 'M', 'N', 'P', 'Q', 'R', 'S', 'T', 'V', 'W', 'Y']

奖励模型 我们使用基于变换器的分类器，包含 4 个隐藏层，隐藏维度为 64，以及 8 个注意力头。我们使用批大小为 256 的小批量进行训练，学习率为 10^{-4} ，并在验证集上使用早停策略。

超参数。如同比特序列，我们采用变换器 [28] 作为所有方法的神经网络架构。本文使用具有 64 维度隐藏层和 8 个注意力头的 3 个隐藏层。所有方法均进行了训练 20,000 迭代，采用批大小为 16 的小批量。本文将随机动作概率设置为 0.01 从中选取 $\{0.0001, 0.0005, 0.001, 0.01\}$ ，奖励指数 $\beta: R(x)^\beta$ 从 3 个中选出 $\{2, 3, 4\}$ ，采样温度为 P_F 对于 GFlowNets 设置为 1。轨迹平衡使用的学习率为 5×10^{-3} 从...中选择 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 对于流参数和 1×10^{-2} 对于 $\log Z$ 。在流匹配中，我们使用的学习率为 5×10^{-4} 从...中选择 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 具有叶损失系数 $\lambda_T = 25$ 。对于带有熵正则化的 A2C，我们在演员网络和评论家网络之间共享参数，6Code:
<https://gist.github.com/MJ10/59bfcc8bce4b5fce9c1c38a81b1105ae>。

使用从 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 中选择的 5×10^{-4} 学习率，并将熵正则化系数设置为从 $\{10^{-4}, 10^{-3}, 10^{-2}\}$ 中选择的 10^{-2} 。对于 SAC，我们使用在 [6] 中定义的公式，学习率为从 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 中选择的 5×10^{-4} ，目标网络更新频率为 400，初始随机步数为 200。对于 MARS 基线，我们将学习率设置为从 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 中选择的 5×10^{-4} 。我们在 3 个种子上运行实验，并在表 1 中报告三次运行的平均值和标准误。总体而言，在 AMP 生成实验中，我们使用了 14 个 GPU 天。