

从部分序列学习 GFlowNets 以提高收敛性和稳定性

Kanika Madan^{1,2} Jarrid Rector-Brooks^{*1,2} Maksym Korablyov^{*1,2} Emmanuel Bengio³ Moksh Jain^{1,2}
Andrei Nica^{1,4} Tom Bosc^{1,2} Yoshua Bengio^{1,2,5} Nikolay Malkin^{1,2}

摘要

生成流网络 (GFlowNets) 是一类用于在未归一化的目标密度下训练离散对象的顺序采样的算法, 并已在各种概率建模任务中成功应用。现有的 GFlowNets 训练目标要么针对状态局部, 要么针对转换局部, 或者在整个采样轨迹上传播奖励信号。我们认为这些选择代表了梯度偏差-方差权衡的两个极端, 并提出了一种利用这一权衡来减轻其有害影响的方法。受强化学习中 TD(λ) 算法的启发, 我们引入了子轨迹平衡或 SubTB(λ), 这是一种可以从不同长度的部分动作子序列中学习的 GFlowNet 训练目标。我们展示了 SubTB(λ) 如何加速先前研究和新环境中的采样器收敛, 并使 GFlowNets 能够在具有更长动作序列和稀疏奖励景观的环境中进行训练, 这比以前可能的情况更为复杂。我们还进行了随机梯度动力学的比较分析, 揭示了 GFlowNet 训练中的偏差-方差权衡以及子轨迹平衡的优势。

1. 引言

生成流网络 (GFlowNets; Bengio 等, 2021a) 是一种生成模型, 通过从学习策略中采样的动作序列来构建位于目标空间 X 中的对象。GFlowNets 被训练以使采样对象的概率 $x \in X$ 与给定的非负奖励 $R(x)$ 成正比。GFlowNets 使用一种参数化方法 * 平等贡献 1Mila - 魁北克 AI 研究所 2 蒙特利尔大学 3 递归 4 布加勒斯特理工大学 5 CIFAR 研究员。通信地址: Kanika Madan <madankanika.s@gmail.com>。

Proceedings of the 40th International Conference on Machine Learning, Honolulu, Hawaii, USA. PMLR 202, 2023. Copyright 2023 by the author(s).

度量策略能够推广到训练期间未见过的状态, 使得 GFlowNets 成为各种概率建模任务中基于局部探索方法的竞争替代方案 (Bengio 等人, 2021a; Malkin 等人, 2022; Zhang 等人, 2022; Jain 等人, 2022; Deleu 等人, 2022)。

GFlowNets 解决了变分推断问题, 即通过采样策略诱导出的分布来近似目标分布 π^* 。它们通过类似于强化学习的算法进行训练 (尽管 GFlowNets 模型奖励分布中的多样性, 而不是通过寻找其最大值来最大化奖励)。在大多数以往的研究中 (Bengio 等人, 2021a; Malkin 等人, 2022; Zhang 等人, 2022; Jain 等人, 2022), GFlowNets 通过探索性采样从策略中获取样本, 并根据所采样对象的奖励获得训练信号。GFlowNets 的流匹配 (FM) 和细致平衡 (DB) 学习目标 (Bengio 等人, 2021a; b) 类似于时间差分学习 (Sutton & Barto, 2018)。

Malkin 等人 (2022) 提出了第三个目标, 轨迹平衡 (TB), 以解决 FM 和 DB 目标中缓慢的时间信用分配问题。TB 目标将学习信号传播到整个时间段, 而类似时间差分的目标则使更新局限于状态或动作。Malkin 等人 (2022) 假设, TB 中改进的信用分配是以更高的梯度方差为代价的, 类似于时间差分学习 (TD(n) or TD(λ)) 中不同迹方案下的偏差-方差权衡 (Sutton & Barto, 2018; Kearns & Singh, 2000; van Hasselt 等人, 2018; Bengio 等人, 2020)。这一假设是本文的出发点之一。

本文提出了一种新的 GFlowNets 学习目标, 称为子轨迹平衡 (SubTB, 或 SubTB(λ)) 当其超参数 λ 被指定)。在此基础上, 我们利用 Bengio 等人 (2021b); Malkin 等人 (2022) 的研究成果, 展示了如何构建子时间戳 (SubTB(λ)) 允许从任意长度的部分经验中灵活学习。在两个合成领域和四个现实世界领域的实验支持了三个实证主张: (1) 子 TB(λ) 提升了 GFlowNets 在之前研究环境中收敛性: 使用

SubTB 方法在更少的训练步骤中接近目标分布，并且对超参数的选择不那么敏感。

(2) 子任务树 (SubTB) 能够在奖励函数稀疏或动作序列较长的环境中训练生成流网络 (GFlowNets)，而过去的方法在这些情况下表现不佳。(3) 子 TB(λ) 的优势可以通过随机梯度方差降低来解释，参数 λ 在高偏差低方差的 DB 目标和低偏差高方差的 TB 目标之间进行插值。

2. 方法

2.1. 预备知识

本节总结了关于 GFlowNets 所需的预备知识。我们遵循 Malkin 等人 (22 年) 的符号表示，读者可以参考该文献以获得更详细的介绍，特别是关于轨迹平衡和子轨迹平衡目标的动机。更深入的介绍可以在 Bengio 等人 (2021b) 的文章中找到。

令 $G = (S, \mathcal{A})$ 是一个有向无环图。顶点 $s \in S$ 被称为状态，有向边 $(u \rightarrow v) \in \mathcal{A}$ 被称为动作。如果 $(u \rightarrow v)$ 是一条边，我们说 v is a 是 u 的孩子，而 u is a 是 v 的父节点。存在一个唯一的初始状态 $s_0 \in S$ ，它没有父节点。没有孩子的状态称为终端状态，所有终端状态的集合记为 X 。

轨迹或动作序列是一系列状态 $\tau = (s_m \rightarrow s_{m+1} \rightarrow \dots \rightarrow s_n)$ ，其中每个 $(s_i \rightarrow s_{i+1})$ 都是一个动作。如果 $s_m = s_0$ 并且 s_n 是终端状态，则该轨迹是完整的。所有完整轨迹的集合记为 T 。

一个 (前向) 策略是一组分布的集合 $P_F(-|s)$ 遍历每个非终结状态的子节点 $s \in S$ 。正向策略通过确定 T 的分布

$$P_F(\tau = (s_0 \rightarrow \dots \rightarrow s_n)) = \prod_{i=0}^{n-1} P_F(s_{i+1}|s_i). \quad (1)$$

任何从前向策略产生的完整轨迹上的分布都满足马尔可夫性质：从状态 s 出发选择动作的概率独立于如何到达状态 s 。反之，任何 T 上的马尔可夫分布都可以从前向策略产生 (Bengio 等, 2021b)。

前向策略可以通过从 s_0 开始并迭代地从 P_F 中采样动作，或者等价地说，通过取完整轨迹的终止状态 $\tau \sim P_F(\tau)$ 来采样终端状态 $x \in X$ 。采样 $x \in X$ 的边缘似然性是所有在 x 处终止的完整轨迹的似然性的总和。

假设给定一个非平凡的 (非恒等于 0) 非负奖励函数 $R : X \rightarrow \mathbb{R}_{\geq 0}$ 。GFlowNets 解决的学习问题是估计一个策略 P_F ，使得采样的可能性 $x \in X$ 与其成正比

对 $R(x)$ 。也就是说，应存在一个常数 Z 使得

$$R(x) = Z \sum_{\tau=(s_0 \rightarrow \dots \rightarrow s_n=x)} P_F(\tau) \quad \forall x \in X. \quad (2)$$

If (2) is satisfied, then $Z = \sum_{x \in X} R(x)$.

2.2. GFlowNet 训练目标

由于 (2) 中的求和可能难以计算，在一般情况下无法直接将此约束转换为训练目标。为了解决这个问题，GFlowNet 训练目标通过各种方式引入辅助变量到参数化中，但它们都具有在全局最优解处满足 (2) 的性质。这些目标的关键属性总结于表 1。

流匹配 (FM; Bengio 等人, 2201a). 为了说明“流网络”的术语，Bengio 等人 (2021a) 证明了如果 P_F 源自满足某些约束条件的边流函数，则 (2) 成立。具体来说，对每个动作分配一个非负数 (流量) 的赋值 $F : \mathcal{A} \rightarrow \mathbb{R}_{\geq 0}$ 定义了一个策略。

$$P_F(t|s) = \frac{F(s \rightarrow t)}{\sum_{t': (s \rightarrow t') \in \mathcal{A}} F(s \rightarrow t')}. \quad (3)$$

终止分布的一个充分条件 P_F 与奖励成正比 $R(x)$ 这是一个流匹配 (Flow Matching) 家族的流 = 流出) 条件在所有内部状态中得到满足，并且在终端状态中满足一组奖励匹配条件； $\forall t \in S \setminus (X \cup \{s_0\}) : \sum \square$

$$\begin{aligned} F(s \rightarrow t) &= \sum_{u: (t \rightarrow u) \in \mathcal{A}} F(t \rightarrow u) \\ \sum_{s: (s \rightarrow x) \in \mathcal{A}} F(s \rightarrow x) &= R(x) \quad \forall x \in X. \end{aligned} \quad (4)$$

流 $F(s \rightarrow t)$ 与从 P_F 中采样的完整轨迹包含该动作的边缘似然成正比 $s \rightarrow t$ 。

In Bengio et al. (2021a), a GFlowNet is described by a parametric estimate of the edge flow function, $F(u \rightarrow v; \theta)$ (a neural net with parameters θ). These conditions can be converted into objectives that are minimized when (4) is satisfied. For example, the flow-matching objective at a nonterminal state s is defined by

$$\mathcal{L}_{\text{FM}}(s) = \left(\log \frac{\sum_{s: (s \rightarrow t) \in \mathcal{A}} F(s \rightarrow t; \theta) + \epsilon}{\sum_{u: (t \rightarrow u) \in \mathcal{A}} F(t \rightarrow u; \theta) + \epsilon} \right)^2, \quad (5)$$

哪里 ϵ 是一个平滑常数，如果流被约束为严格正，则可以安全地将其设置为 0，并通过类似的目标函数 (或构造上的约束) 来强制执行流 $F(s \rightarrow x)$ 进入终态 x 以匹配 $R(x)$ 如果这些目标函数在全球范围内对所有状态进行最小化 s ，然后

表 1. GFlowNet 训练目标概述。目标参数化局部性

Objective	Parametrization	Locality
Flow matching	edge flow $F(s \rightarrow t; \theta)$	state s
Detailed balance	state flow $F(s; \theta)$, policies $P_F(- -; \theta)$, $P_B(- -; \theta)$	action $s \rightarrow t$
Trajectory balance	initial state flow Z_θ , policies $P_F(- -; \theta)$, $P_B(- -; \theta)$	complete trajectory τ
Subtrajectory balance	state flow $F(s; \theta)$, policies $P_F(- -; \theta)$, $P_B(- -; \theta)$	(partial) trajectory τ

该策略 $P_F(-|-; \theta)$ 由 $F(-; \theta)$ 通过 (3) 满足 (2)，其中 $Z = \sum_{t: (s_0 \rightarrow \dots \rightarrow t) \in A} F(s \rightarrow t; \theta) = \sum_{x \in X} R(x)$ 。如何采样状态的问题 s 用于训练将在下文讨论。

细致平衡 (DB; Bengio 等人, 2021b; Malkin 等人, 2022)。在 DB 参数化中，直接学习了一个前向策略模型 $P_F(-|-; \theta)$ ，同时学习了两个附加对象：一个后向策略模型 $P_B(-|-; \theta)$ ，可以预测任何非初始状态的父状态分布，以及一个状态流函数 $F(s; \theta)$ （通常在对数域中进行参数化）。细致平衡条件表明

$$F(s; \theta) P_F(t|s; \theta) = F(t; \theta) P_B(s|t; \theta) \quad (6)$$

对于所有动作 $(s \rightarrow t)$ 并且 $F(x; \theta) = R(x)$ 对于 x 终止状态。这些条件对于所有动作的满足 $(s \rightarrow t)$ 并且 $x \in X$ 意味着 P_F 按奖励比例采样（即满足 (2)，其中 $Z = F(s_0)$ ）。DB 条件 (6) 可以转化为平方对数比目标 $\mathcal{L}_{DB}(s \rightarrow t)$ 如同 (4) 推导出 (5)， $\mathcal{L}_{DB}(s \rightarrow t)$ 可以在采样的动作上进行优化 $(s \rightarrow t)$ 。

轨迹平衡 (TB; Malkin 等, 2022 年)。TB 目标所需的参数化包括正向和反向策略模型 $P_F(-|-; \theta)$ 和 $P_B(-|-; \theta)$ ，以及对 (2) 中比例常数的估计 Z_θ 。对于所有完整的轨迹 $\tau = (s_0 \rightarrow \dots \rightarrow s_n)$ 满足以下条件意味着 (2) 成立：

$$Z_\theta P_F(\tau; \theta) = R(s_n) P_B(\tau|s_n; \theta), \quad (7)$$

其中我们采用了如下约定

$$P_F(\tau; \theta) = \prod_{i=0}^{n-1} P_F(s_{i+1}|s_i; \theta), P_B(\tau|s_n; \theta) = \prod_{i=0}^{n-1} P_B(s_i|s_{i+1}; \theta)$$

条件 (7) 可以再次转化为平方对数比目标 $\mathcal{L}_{TB}(\tau)$ 并针对从某个训练策略中抽取的完整轨迹 τ 进行优化。在 Malkin 等 (2022) 的研究中，TB 目标在各种问题领域上表现出比 FM 和 DB 更好的收敛性质。

训练策略与探索。对 FM、DB 和 TB 目标的所有参数值（状态、动作或完整轨迹）进行全局最小化

意味着满足 (2)。因此，在给定足够表达能力强的模型和优化过程收敛的情况下，可以通过最小化这些损失函数来训练一个 GFlowNet 策略，使其采样 x 的概率与 $R(x)$ 成正比，从而实现 GFlowNet 的离线训练。与其他强化学习算法类似，采样的状态、动作或轨迹分布可以固定并采用离策略方法，也可以在训练过程中变化，并以有趣的方式利用关于终止状态的信息（张等, 2022; 德卢等, 2022）。最简单的方法，也是本文所采用的方法，是在策略学习或非常相似的离策略变体中，将当前策略展平以确保探索。完整的轨迹 $\tau = (s_0 \rightarrow \dots \rightarrow s_n)$ 是从前向策略 $P_F(-|-; \theta)$ 中采样的（经过调整或与具有较小权重的均匀策略混合，以确保完全支持和探索）。然后对 $\mathcal{L}_{TB}(\tau)$ 进行梯度下降步骤，或者对所有动作在 τ 上对 $\mathcal{L}_{DB}(s_i \rightarrow s_{i+1})$ 进行梯度下降步骤，或者对所有中间状态在 τ 上对 $\mathcal{L}_{FM}(s_i)$ 进行梯度下降步骤。

本文中的 GFlowNets 是在线训练的，或者通过与均匀策略的混合离线训练： P_F 与均匀策略的混合： $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_n)$ 是按照 $s_{i+1} \sim (1 - \epsilon) P_F(s_{i+1}|s_i; \theta) + \epsilon \# \{(t: (s \rightarrow t) \in A)\}$ 采样的。这里 ϵ 是随机探索权重。

2.3 子轨迹平衡：从部分情节中学习

回忆在 DB 目标中使用的 GFlowNet 参数化，包括状态流估计器 $F(-|-; \theta)$ 和一对策略 $P_F(-|-; \theta)$, $P_B(-|-; \theta)$ 。Malkin 等人 (2022) 在 § A.2 中证明，对于所有动作，细致平衡条件 (6) 成立当且仅当下列子轨迹平衡约束对所有（不一定完整的）轨迹 $\tau = (s_m \rightarrow \dots \rightarrow s_n)$ 成立：

$$F(s_m; \theta) \prod_{i=m}^{n-1} P_F(s_{i+1}|s_i; \theta) = F(s_n; \theta) \prod_{i=m}^{n-1} P_B(s_i|s_{i+1}; \theta), \quad (8)$$

其中我们再次要求如果 x 是终止状态，则 $F(x; \theta) = R(x)$ 成立。观察到当轨迹由一个动作组成时，DB 条件 (6) 是 (8) 的一个特例，而 TB 条件 (7) 正是当 τ 完整时的情况，其识

$$Z_\theta = F(s_0; \theta).$$

上述约束产生了子轨迹平衡目标:

$$\mathcal{L}_{\text{SubTB}}(\tau) = \left(\log \frac{F(s_m; \theta) \prod_{i=m}^{n-1} P_F(s_{i+1}|s_i; \theta)}{F(s_n; \theta) \prod_{i=m}^{n-1} P_B(s_i|s_{i+1}; \theta)} \right)^2. \quad (9)$$

如果对于所有部分轨迹 τ , 将 $R(s_n)$ 替换为 $F(s_n; \theta)$ (如果 s_n 是终止状态), 该目标等于 0, 则策略 P_F 满足期望条件 (2)。(证明: 当 $\mathcal{L}_{\text{SubTB}}(\tau) = 0$ 时, (8) 成立, 这意味着 (7) 和 (6) 都成立。Bengio 等人 (2021b); Malkin 等人 (2022) 表明这些条件中的任何一个都是 (2) 的充分条件。)

提取子轨迹用于训练。假设采样了一个完整的轨迹 (完整轨迹) $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_n)$ 用于训练。存在 $\binom{n+1}{2}$ 个非平凡的 subtrajectories: 凡的

$$\tau_{i:j} := (s_i \rightarrow s_{i+1} \rightarrow \dots \rightarrow s_j), \quad 0 \leq i < j \leq n. \quad (10)$$

在采样了一个完整的轨迹 τ 用于训练后, 我们在子轨迹平衡损失 $\mathcal{L}_{\text{SubTB}}(\tau_{i:j})$: $\theta \leftarrow \theta - \nabla_{\theta} \mathcal{L}$ 的凸组合上进行梯度步, 其中

$$\mathcal{L} = \frac{\sum_{0 \leq i < j \leq n} \lambda^{j-i} \mathcal{L}_{\text{SubTB}}(\tau_{i:j})}{\sum_{0 \leq i < j \leq n} \lambda^{j-i}}. \quad (11)$$

这里 $\lambda > 0$ 是一个超参数, 用于控制不同长度子轨迹所分配的权重, 当 λ 设置为 1 时, 会导致均匀加权方案。请注意, 当 $\lambda \rightarrow 0^+$ 极限恰好导致所有过渡的详细平衡损失平均值 $\mathcal{L}_{\text{DB}}(s_i \rightarrow s_{i+1})$ 时, 在 τ 中, 而当 $\lambda \rightarrow +\infty$ 极限给出轨迹平衡目标 $\mathcal{L}_{\text{TB}}(\tau)$.¹ 其他子轨迹加权方案是可能的, 并应在未来工作中进行探索。

计算考虑。优化 (11) 可能会显得计算成本与轨迹长度呈二次关系。然而, 仔细检查 (11) 相对于状态流 $\log F(s_i; \theta)$ 和正向及反向策略对数的梯度显示, 梯度计算只需要通过神经网络进行一次正向和一次反向传递-

ing $\log F(s; \theta)$, $\log P_F(-|s_i; \theta)$, 以及 $\log P_B(-|s_i; \theta)$. The 仅在执行这些对数流和策略对数的线性操作时才会产生二次计算成本, 而不是在深度网络的评估中。因此, SubTB 损失相对于 DB 或 TB 几乎没有计算开销。

¹ 当使用一批轨迹进行训练时, 凸组合权重可以在批次中所有轨迹的所有子轨迹上进行归一化, 或者独立地在每个轨迹的子轨迹上进行归一化。为了保持一致性, 我们在本文的实验中选择了第一个选项。

假设的好处。我们假设 $\text{SubTB}(\lambda)$ 为 GFlowNet 训练带来了两个好处:

方差缩减。结核损失项 $\mathcal{L}_{\text{TB}}(\tau)$ 对于轨迹 τ 执行给定的动作序列直至到达某个状态 s , 然后发散, 共享这些术语 $\log Z$ 以及所有先前过渡的动作策略对数概率 s 在正方形内部。然而, TB 损失的‘尾部’涉及出现在之后的转换的前向和后向策略对数概率 s 在 τ 可以被视为随机最小二乘回归的目标。也就是说, 如果 $s = s_m$ 在轨迹中 $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_n)$, 然后

$$\left(\log \left(\prod_{i=0}^{m-1} \frac{P_F(s_{i+1}|s_i)}{P_B(s_i|s_{i+1})} \right) \right) \quad (12)$$

被回归到

$$\left(\log F(s_n) \cdot \prod_{i=m}^{n-1} \frac{P_B(s_i|s_{i+1})}{P_F(s_{i+1}|s_i)} \right). \quad (13)$$

类似地, 对于共享后续转移的轨迹 s 但可能在初始动作上有所不同, (12) 是 (13) 的随机回归目标。

子轨迹平衡损失项 $\mathcal{L}_{\text{SubTB}}(\tau_{m:i})$ 对于从 s 开始的部分轨迹, 将对数状态流 $\log F(s)$ 回归到类似于 (13) 的表达式的一部分, 而损失项 $\mathcal{L}_{\text{SubTB}}(\tau_{i:m})$ 将类似于 (12) 的表达式的一部分回归到对数状态流 $\log F(s)$ 。所学的 $\log F(s)$ 因此是对包含 s 的轨迹的 TB 损失的一个随机部分的学习估计。用一个学习估计替换 TB 损失中的随机项, 保证会引入偏差 (相对于 TB 损失的梯度), 但预计会减少方差。这类似于演员-评论家方法在强化学习中减少方差的效果。

这一假设在我们的实验中进行了实证研究, 特别是在第 4.1.1 节, 我们提供了证据表明 $\text{SubTB}(\lambda)$ 是在 TB (高方差) 和 DB (低方差, 相对真实 TB 梯度有高偏差) 损失之间实用的插值。

由于状态流的泛化而导致的学习加速。子轨迹平衡对收敛速度的另一项益处可能源于估计状态流函数 $\log F(s; \theta)$ 能够被高精度建模, 并在状态之间更快地泛化 s , 比通常高维的策略对数几率 $\log P_F(-|s; \theta)$, $\log P_B(-|s; \theta)$ 更快。这种泛化在状态图远离初始状态变得‘宽广’的问题中尤为重要, 这使得接近终止状态的学习信号变得稀疏。确实, 在除了 § 4.1 节中的超网格以及最大超网格之外的所有实验领域中, 终止状态的数量比训练中看到的状态总数大许多数量级。

3 相关工作

资格迹。子轨迹方法 (SubTB(λ)) 受到强化学习 (RL) 中的 TD(λ) 算法启发 (Sutton, 1988; Sutton & Barto, 2018), 该算法通过凸组合形成对未来回报的估计, 每个 n 步回报都由 $(1 - \lambda)\lambda^{n-1}$ 加权。参数 $\lambda \in [0, 1]$ 实现了偏差-方差权衡 (Kearns & Singh, 2000)。较大的 λ 导致较低的偏差和较高的方差, 因为预期回报的估计值接近单点蒙特卡洛估计, 当 $\lambda \rightarrow 1$ 时。我们从这一想法中获得启发, 将不同的 (可能全部) 子轨迹混合在一起, 类似于如何混合 n 步回报。我们假设适当的混合可以降低方差, 与轨迹方法相比, 同时在中间状态之间诱导一致性, 从而有助于更快地传播信用并加速收敛。此外, GFlowNet 训练目标类似于残差梯度 RL 方法 (Baird, 1995; Zhang et al., 2020), 因为在梯度计算中也考虑了“终点” (例如, $F(s_n)$ 在 (9) 中)。

最大熵 RL。强化学习在基于能量的方法或最大熵方法方面有着丰富的文献 (Ziebart, 2010; Mnih 等人, 2016; Haarnoja 等人, 2017; Nachum 等人, 2017; Schulman 等人, 2017; Haarnoja 等人, 2018), 这些方法在某些设置下与 GFlowNet 框架接近或等价 (特别是在 MDP 具有树结构的情况下 (Bengio 等人, 2021a))。与此相关的还有那些不直接最大化策略上的熵, 而是最大化状态访问分布或其代理上的熵的方法 (Hazan 等人, 2019; Islam 等人, 2019; Zhang 等人, 2021; Eysenbach 等人, 2018), 这些方法通过使状态访问分布平坦化来实现类似于 GFlowNet 模型的目标。如果环境的状态图是一个有向树, 那么个体子轨迹上的损失 $\mathcal{L}_{\text{SubTB}}$ 等同于路径一致性学习 (PCL; Nachum 等人, 2017)。然而, 在没有中间奖励的情况下尝试使用 PCL 仅计算长度为 1 或包含终止状态的子轨迹上的损失 (Guo 等人, 2021)。

4. 实验

4.1. 超网格: 对稀疏奖励的鲁棒性

我们研究了 Bengio 等人 (2021a) 引入的合成超网格环境。内部状态集是一个维度为 d -维的超网格, 大小为 $H \times H \times \dots \times H$, 其奖励函数在超网格的每个 2^d 角落附近呈多模态分布 (参见 Bengio 等人 (2021a); Malkin 等人 (2022) 及图 1)。初始状态为 $(0, 0, \dots, 0)$, 每次动作都是一个步骤, 将其中一个 d 坐标值加 1 而不离开网格。从每个状态还可以执行一个特殊的终止动作。该环境旨在挑战学习代理进行推理和发现




图 1. 左: 16×16 超网格奖励函数。右: 从训练在更难变体的 32×32 网格上具有 TB 和 SubTB(λ) 目标的 GFlowNets 获得的 2×10^5 样本分布。

已访问过的那些模式之外的新模式。

我们研究了不同大小的二维和四维超网格, 使用了过去工作中最困难的奖励函数变体 (网格角落以外的最小奖励设置为 10^{-3})。我们训练 GFlowNets 从目标奖励函数中采样, 并绘制了目标分布与训练过程中最后 $2 \cdot 10^5$ 个状态的实测分布之间的 L^1 距离的演变。² 在所有情况下, 我们都调整了 TB 和 SubTB($\lambda = 0.9$) 目标的学习率。(详情见 § A.) 结果 (三次随机运行的均值和标准差) 显示在图 2 的前两行。使用 SubTB(λ) 训练的模型比使用 TB 更快地收敛到真实分布, 并且在不同随机种子之间具有更小的方差, 适用于所有超网格大小。

我们还研究了一种环境的更稀疏变体, 其中背景奖励设置为 10^{-4} 。在这种情况下, SubTB(λ) 继续表现出色 (图 2 的最后一行), 而使用 TB 训练的模型甚至无法发现大于 8×8 的网格的所有模式 (图 1)。

附加结果见 § A.1。特别是, 当仅使用长度小于某个阈值的子轨迹进行训练时, SubTB(λ) 继续表现出色, 这在只有部分情节给定的实际场景中可能是有益的。我们还展示了 λ 对收敛速率的影响 (图 A.2) 以及更具探索性的训练策略的效果 (图 A.3)。

4.1.1. 对梯度方差的进一步观察

我们仔细观察了梯度偏差和方差, 以了解使用 SubTB(λ) 训练 GFlowNets 的好处。这些实验的方法受到 Ilyas² 的启发。这种评估在此合成环境中是可能的, 因为可以有效地计算精确的目标分布函数。请注意, 图 2 中所示的度量与过去工作中所谓的‘ L^1 距离’有所不同, 因为我们没有除以总状态数。




图 2. L^1 在超网格环境中训练过程中，经验分布与目标分布之间的距离。SubTB($\lambda = 0.9$) 在所有网格大小上均比过去研究中最优的目标函数 TB 更快地收敛。差异在奖励函数的较难变体（最后一行）中尤为明显。 x 轴是累计训练轨迹（回合）的数量。




图 3. 在选定的训练迭代中，小批量 (2^k) 和大批量 (1024) 梯度之间的平均余弦相似度。上图：DB、SubTB(λ) 和 TB 目标的小批量与大批量梯度对比。下图：小批量 DB、SubTB(λ) 和 TB 梯度与大批量 TB 梯度的对比。

et al. (2020).

我们在 8×8 网格环境中训练 GFlowNets，并使用 SubTB($\lambda = 0.8$) 监控训练过程中的各种梯度指标。为了消除不同状态下策略之间参数共享的影响，并单独考察目标函数的影响，我们采用了表格形式的 GFlowNet 表示，即所有流和策略对数都是作为独立参数进行优化的。

梯度方差。 为了测量梯度方差，我们对每个训练目标 (DB、TB、




图 4. 在 8×8 网格环境中，小批量 (64) 和大批量 (1024) 梯度之间的平均余弦相似度。左图：DB、SubTB(λ) 和 TB 梯度的自相似性。显示了 $DB < SubTB(\lambda) < TB$ 在梯度方差方面的表现。右图：小批量 DB、SubTB(λ) 和 TB 梯度与大批量 TB 梯度的相似性。表明小批量 SubTB(λ) 梯度是大批量 TB 的良好估计器。

或子表 $B(\lambda)$ 一批大量的 $2^{10} = 1024$ 轨迹被采样，梯度 $g_i^{(0)}$ 针对每个轨迹，在所有状态下关于策略对数几率的目标函数的导数被计算出来 τ_i 在批次中。然后，对于每个 $k \in \{0, 1, \dots, 9\}$ ，梯度 $g_i^{(0)}$ 被结合在一起 2^{10-k} 子批次，每个大小为 2^k 子批次梯度 $g_i^{(k)}$ 对于 i 第 k 子批次设置为轨迹梯度的平均值 $g_i^{(0)}$ 包含在子批次中并计算得出的 $i \in \{1, 2, \dots, 2^{10-k}\}$ 。然后报告子批次与全批次梯度之间的平均余弦相似度：

$$\frac{1}{2^{10-k}} \sum_{i=1}^{2^{10-k}} \frac{g_i^{(k)} \cdot g_1^{(10)}}{\|g_i^{(k)}\| \|g_1^{(10)}\|}.$$

如果这个量是正的，那么沿着随机子批次梯度进行无穷小范数的梯度步长会降低全批次目标的期望值。图 3（左）展示了这个指标在各种迭代中对 k 的依赖关系。较陡峭的曲线，如 DB 和 SubTB(λ)，所示，表示较低的梯度方差。

图 4（左）展示了在训练过程中使用的批大小为 64 时的度量值 $k = 6$ 。DB 梯度具有最高的自洽性，TB 具有最低的自洽性，而 SubTB($\lambda = 0.8$) 介于两者之间。

梯度偏差。 接下来，我们将小批量随机梯度与大批量随机梯度进行比较，其中小批量和全批量使用不同的目标函数。具体而言，我们将小批量 DB、SubTB(λ) 和 TB 梯度与全批量 TB 梯度进行比较。（全批量 TB 梯度可以被视为一种‘规范’梯度，用于衡量偏差，因为其期望等于由 P_F 定义的轨迹分布与由奖励 R 和 P_B 定义的分布之间的 KL 发散的梯度；参见 Malkin 等 (2022) 的 § A.3。）

图 4（底部）展示了在训练过程中使用的批大小的余弦相似度。 值得注意的是，在中间迭代阶段，SubTB(λ) 与 TB 的相似度高于 TB 自身的相似度：尽管存在偏差，小批量 SubTB(λ) 梯度对完整批量 TB 梯度的估计优于小批量 TB 梯度。图 3（右）展示了相似度对 k 的依赖关系，并表明这一效应可能在更小的批大小下更为显著。此外，在 $k = 10$ 处，SubTB(λ vs.) 与 TB 的相似度始终位于 DB 与 TB 以及 TB 与 TB 之间，这表明 SubTB(λ) 在 TB 的无偏估计和 DB 的有偏估计之间进行了插值。

学习状态流的影响。参见 § A.2。

4.2 小分子合成

我们使用 SubTB(λ) 来训练模型，用于 Bengio 等人 (2021a) 提出的分子生成任务。该任务基于对接预测 (Trott & Olson, 2010) 生成 sEH（可溶性环氧化物水解酶）蛋白的结合剂。具体来说，分子通过顺序连接固定库中的“块”到部分分子图上来生成 (Jin 等人, 2020; Kumar 等人, 2012)，从而形成一个估计大小为 10^{12} 的状态空间。奖励函数 R 由 Bengio 等人 (2021a) 提供的预训练代理模型给出。为了调整代理的贪婪程度，使用了一个逆温度超参数 β ，即用于训练的奖励为 $R(x) = \tilde{R}(x)^\beta$ ，其中 $\tilde{R}(x)$ 是代理的预测。

我们使用 DB、TB 和 SubTB(λ) 目标训练模型，每个 λ , β 和学习率分别取四个值，平均—

通过在每种设置下进行 3 次随机运行的结果来衡量。我们通过 $\log R(x)$ 和 $\log p_\theta(x)$ 的相关性来衡量训练模型与目标分布的匹配程度，即 GFlowNet 分配给终端状态集合 x 的对数概率，计算结果见于预留的终端状态集合 x 。³ 结果展示在图 5 中。特别是带有 $\lambda = 1$ 的 SubTB(λ)，当使用最优超参数 $\alpha, \beta_{\text{arc}}$ 时（实线），其表现优于 DB 和 TB，并且对超参数的选择更加鲁棒（虚线）。更多细节请参见 § B。

4.3. 序列生成

我们考虑三种从左到右生成序列的任务，其中每次动作将词汇表中的一个符号添加到部分序列中：一个具有变化序列长度和词汇表大小的合成任务 (§ 4.3.1)，一个实用的生物序列设计任务 (§ 4.3.2)，以及一个新的具有更长序列的蛋白质设计任务 (4.3.3)。对于这三个任务，我们考虑基线软演员 - 评论家 (Haarnoja 等, 2018; Christodoulou, 2019)，带有熵正则化的 A2C (Williams & Peng, 1991; Mnih 等, 2016) 和类似 MARS 的 MCMC (Xie 等, 2021)，并将它们与三个 GFlowNet 训练目标进行比较：TB, FM, 和 SubTB(λ)。

在 § F 中，我们也研究了一个非自回归序列生成问题（逆蛋白质折叠）。

4.3.1. 二进制序列

我们考虑 Malkin 等 (2022) 提出的合成序列生成设置，目标是生成固定长度的二进制序列 $n = 120$ 。奖励由一组模式 $M \subset X = \{0, 1\}^n$ 指定，这些模式对学习代理未知。生成序列的奖励 x 定义为与模式的汉明距离 d ：

$$R(x) = \exp(-\min_{y \in M} d(x, y)).$$

词汇表大小可以变化：对于任何整数 k 除以 120，我们取一个由长度为 k 的词组成的词汇表（因此词汇表大小为 2^k ，整个序列在 $\frac{n}{k}$ 动作中生成）。通过改变 k 的值并保持 n 和 M 不变，我们在不改变基础建模问题的情况下研究具有不同动作空间大小和轨迹长度的学习代理的行为。大多数实验设置来自 Malkin 等 (2022)；详情见 § C。

³ 比较精确采样和目标分布，如 § 4.1 所述，在这里是不可能的，因为我们无法枚举所有终止状态。然而，通过动态规划可以计算训练好的 GFlowNet 生成给定 x 的边缘似然。对于一个完美地从目标分布中采样的模型， $\log(R(x))$ 和 $\log p_\theta(x)$ 将相差一个与 x 无关的常数 $\log Z$ ，因此它们将是完全相关的。




图 5. 分子任务上边缘采样对数似然与对数奖励的相关性。对于每个超参数设置在 x 轴上，我们在左图中绘制其他超参数选择的最佳结果——在左图中是 α ，在中心图中是 β ，在右图中是两者 α 和 β ——用实线表示。其他超参数值的平均结果用虚线表示。




图 6. 上图：对于每个词汇单元中的比特数 $k \in \{1, 2, 4, 6, 8, 10\}$ ，我们绘制了每种方法在测试集上的采样概率与奖励之间的 Spearman 相关性。使用 SubTB(λ) 进行训练导致策略在整个长度和词汇大小范围内与奖励具有最高的相关性。下图：对于 $k = 1$ ，绘制了每种方法在训练过程中发现的模式数量。SubTB(λ) 更快地发现了更多的模式。

通过计算测试序列集 x 上生成 x 的概率与奖励 $R(x)$ 之间的 Spearman 相关性来评估模型。我们还跟踪了所有方法在训练过程中的模式发现数量，见图 6。我们发现，使用

SubTB(λ) 目标训练的模型在训练结束时具有更高的 Spearman 相关性，并且比其他 GFlowNet 目标和非 GFlowNet 基线更快地发现模式。

4.3.2. 抗微生物肽生成

接下来，我们考虑生成具有抗菌特性的肽序列 (AMPs) 的任务。这些序列的最大长度为 60，并使用包含 20 种氨基酸（以及一个序列结束标记）的词汇表，从而形成一个状态空间大小为 21^{60} 的状态空间。奖励函数是一个预训练的代理神经网络，用于估计抗菌活性。（关于此任务的详细信息，请参见 Jain 等人，2022 年）。我们使用 SubTB(λ)、TB 和 FM 损失训练 GFlowNets，并将其与基线进行比较。为了评估训练好的模型，我们从策略中采样 2048 个序列，然后计算排名前 100 的序列的平均奖励和平均成对编辑距离。度量和模型架构取自 Malkin 等人（2022 年）；详情请参见 § D。结果在表 2 中展示。SubTB(λ) 在奖励和多样性方面都显著优于所有基线（包括 TB、FM 和 DB GFlowNets）。

4.3.3. 荧光蛋白生成

我们考虑生成具有荧光特性的蛋白质序列的任务（Trabucco 等人，2022 年），以评估 SubTB(λ) 在较长轨迹设置中的表现。在这个任务中，序列的固定长度为 237，状态空间的大小为 20^{237} 。代理奖励函数 $R(x)$ 是在 Sarkisyan 等人（2016 年）提供的蛋白质及其荧光分数的数据集上训练的。度量和模型与 § 4.3.2 相同；详情请参见 § E。

GFlowNet 目标优于所有其他方法

表 2. AMP 生成任务（上方）和 GFP 生成任务（下方）的结果。3 次运行的平均值和标准误。

Algorithm	Top-100 Reward	Top-100 Diversity
GFN- $\mathcal{L}_{\text{SubTB}(\lambda)}$	0.96 ± 0.02	42.23 ± 3.4
GFN- $\mathcal{L}_{\text{TB}}$	0.90 ± 0.03	31.42 ± 2.9
GFN- $\mathcal{L}_{\text{FM}}/\mathcal{L}_{\text{DB}}$	0.78 ± 0.05	12.61 ± 1.32
SAC	0.80 ± 0.01	8.36 ± 1.44
AAC-ER	0.79 ± 0.02	7.32 ± 0.76
MCMC	0.75 ± 0.02	12.56 ± 1.45
GFN- $\mathcal{L}_{\text{SubTB}(\lambda)}$	1.18 ± 0.10	204.44 ± 0.45
GFN- $\mathcal{L}_{\text{TB}}$	0.76 ± 0.19	204.31 ± 0.44
GFN- $\mathcal{L}_{\text{FM}}/\mathcal{L}_{\text{DB}}$	0.30 ± 0.08	190.21 ± 6.78
SAC	0.23 ± 0.03	120.32 ± 15.57
AAC-ER	0.22 ± 0.02	113.65 ± 21.31
MCMC	0.28 ± 0.01	169.17 ± 12.44

在两个度量中，找到更多样化和高奖励的序列（表 2）。SubTB(λ) 显著优于 TB，同时实现了相似的多样性。我们注意到，SubTB(λ) 的优势大于 AMP 任务中的优势（表 2），并推测 SubTB(λ) 对于更长的动作序列，其优势更为明显。

5. 讨论与结论

本文提供了关于 GFlowNet 训练算法中偏差-方差权衡的证据。TB 的高方差随机回归目标和 DB 的低方差局部一致性目标位于这一范围的两端。我们展示了 SubTB(λ) 能够利用局部目标的方差减少效果，同时保留轨迹级目标的快速信用分配特性。我们认为，在训练中选择和加权（子）轨迹的可学习策略——例如动态选择 λ 和主动学习方法来采样轨迹——是未来工作中最有趣的问题。子轨迹目标从不完整的回合中学习的能力也使其在奖励信号可用于不完整状态的强化学习环境和设置中的应用成为一个有吸引力的研究方向。⁴ 最后，未来的工作应实证评估 SubTB 与 Malkin 等人 (2023) 开发的变分方法之间的联系。

致谢

作者感谢 Salem Lahlou 对第 4.1.1 节实验提出的宝贵建议。

本研究部分得益于加拿大数字研究联盟提供的计算资源。

⁴ 当本文处于审稿阶段时，这些设置已在 Pan 等人 (2023) 的研究中进行了探讨，并应用于 Hu 等人 (2023) 关于组合对象的贝叶斯后验推断。

所有作者的资金均来自其主要机构。我们也感谢 CIFAR、三星、IBM 和微软的资金支持。

参考文献

- Baird, L. Residual algorithms: Reinforcement learning with function approximation. *International Conference on Machine Learning (ICML)*, 1995.
- Bengio, E., Pineau, J., and Precup, D. Interference and generalization in temporal difference learning. *International Conference on Machine Learning (ICML)*, 2020.
- Bengio, E., Jain, M., Korablyov, M., Precup, D., and Bengio, Y. Flow network based generative models for non-iterative diverse candidate generation. *Neural Information Processing Systems (NeurIPS)*, 2021a.
- Bengio, Y., Lahlou, S., Deleu, T., Hu, E., Tiwari, M., and Bengio, E. GFlowNet foundations. *arXiv preprint 2111.09266*, 2021b.
- Brookes, D., Park, H., and Listgarten, J. Conditioning by adaptive sampling for robust design. *International Conference on Machine Learning (ICML)*, 2019.
- Chaudhury, S., Lyskov, S., and Gray, J. J. PyRosetta: a script-based interface for implementing molecular modeling algorithms using Rosetta. *Bioinformatics*, 26(5): 689–691, 2010.
- Christodoulou, P. Soft actor-critic for discrete action settings. *arXiv preprint 1910.07207*, 2019.
- Deleu, T., Góis, A., Emezue, C., Rankawat, M., Lacoste-Julien, S., Bauer, S., and Bengio, Y. Bayesian structure learning with generative flow networks. *Uncertainty in Artificial Intelligence (UAI)*, 2022.
- Eysenbach, B., Gupta, A., Ibarz, J., and Levine, S. Diversity is all you need: Learning skills without a reward function. *International Conference on Learning Representations (ICLR)*, 2018.
- Guo, H., Tan, B., Liu, Z., Xing, E. P., and Hu, Z. Text generation with efficient (soft) Q-learning. *arXiv preprint 2106.07704*, 2021.
- Haarnoja, T., Tang, H., Abbeel, P., and Levine, S. Reinforcement learning with deep energy-based policies. *International Conference on Machine Learning (ICML)*, 2017.
- Haarnoja, T., Zhou, A., Abbeel, P., and Levine, S. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. *International Conference on Machine Learning (ICML)*, 2018.

- Hazan, E., Kakade, S., Singh, K., and Van Soest, A. Provably efficient maximum entropy exploration. *International Conference on Machine Learning (ICML)*, 2019.
- Hu, E. J., Malkin, N., Jain, M., Everett, K., Graikos, A., and Bengio, Y. GFlowNet-EM for learning compositional latent variable models. *International Conference on Machine Learning (ICML)*, 2023.
- Ilyas, A., Engstrom, L., Santurkar, S., Tsipras, D., Janoos, F., Rudolph, L., and Madry, A. A closer look at deep policy gradients. *International Conference on Learning Representations (ICLR)*, 2020.
- Islam, R., Ahmed, Z., and Precup, D. Marginalized state distribution entropy regularization in policy optimization. *arXiv preprint 1912.05128*, 2019.
- Jain, M., Bengio, E., Hernandez-Garcia, A., Rector-Brooks, J., Dossou, B. F., Ekbote, C., Fu, J., Zhang, T., Kilgour, M., Zhang, D., Simine, L., Das, P., and Bengio, Y. Biological sequence design with GFlowNets. *International Conference on Machine Learning (ICML)*, 2022.
- Jin, W., Barzilay, R., and Jaakkola, T. Chapter 11. junction tree variational autoencoder for molecular graph generation. *Drug Discovery*, pp. 228–249, 2020. ISSN 2041-3211.
- Kearns, M. J. and Singh, S. P. Bias-variance error bounds for temporal difference updates. *Conference on Learning Theory (COLT)*, 2000.
- Kumar, A., Voet, A., and Zhang, K. Y. Fragment based drug design: from experimental to computational approaches. *Current medicinal chemistry*, 19(30):5128–5147, 2012.
- Malkin, N., Jain, M., Bengio, E., Sun, C., and Bengio, Y. Trajectory balance: Improved credit assignment in GFlowNets. *Neural Information Processing Systems (NeurIPS)*, 2022.
- Malkin, N., Lahlou, S., Deleu, T., Ji, X., Hu, E., Everett, K., Zhang, D., and Bengio, Y. GFlowNets and variational inference. *International Conference on Learning Representations (ICLR)*, 2023.
- Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T., Harley, T., Silver, D., and Kavukcuoglu, K. Asynchronous methods for deep reinforcement learning. *Neural Information Processing Systems (NIPS)*, 2016.
- Nachum, O., Norouzi, M., Xu, K., and Schuurmans, D. Bridging the gap between value and policy based reinforcement learning. *Neural Information Processing Systems (NIPS)*, 2017.
- Pan, L., Malkin, N., Zhang, D., and Bengio, Y. Better training of GFlowNets with local credit and incomplete trajectories. *International Conference on Machine Learning (ICML)*, 2023.
- Pirtskhalava, M., Armstrong, A. A., Grigolava, M., Chubidze, M., Alimbarashvili, E., Vishnepolsky, B., Gabrielian, A., Rosenthal, A., Hurt, D. E., and Tartakovsky, M. Dbasp v3: Database of antimicrobial/cytotoxic activity and structure of peptides as a resource for development of new therapeutics. *Nucleic Acids Research*, 49(D1):D288–D297, 2021.
- Rohl, C. A., Strauss, C. E., Misura, K. M., and Baker, D. Protein structure prediction using Rosetta. In *Methods in enzymology*, volume 383, pp. 66–93. Elsevier, 2004.
- Sarkisyan, K. S., Bolotin, D. A., Meer, M. V., Usmanova, D. R., Mishin, A. S., Sharonov, G. V., Ivankov, D. N., Bozhanova, N. G., Baranov, M. S., Soylemez, O., et al. Local fitness landscape of the green fluorescent protein. *Nature*, 533(7603):397–401, 2016.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O. Proximal policy optimization algorithms. *arXiv preprint 1707.06347*, 2017.
- Sinai, S., Wang, R., Whatley, A., Slocum, S., Locane, E., and Kelsic, E. AdaLead: A simple and robust adaptive greedy search algorithm for sequence design. *arXiv preprint 2010.02141*, 2020.
- Sutton, R. S. Learning to predict by the methods of temporal differences. *Machine learning*, 3(1):9–44, 1988.
- Sutton, R. S. and Barto, A. G. *Reinforcement learning: An introduction*. MIT Press, 2018.
- Trabucco, B., Geng, X., Kumar, A., and Levine, S. Design-bench: Benchmarks for data-driven offline model-based optimization. *International Conference on Machine Learning (ICML)*, 2022.
- Trott, O. and Olson, A. J. AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of computational chemistry*, 31(2):455–461, 2010.
- van Hasselt, H., Doron, Y., Strub, F., Hessel, M., Sonnerat, N., and Modayil, J. Deep reinforcement learning and the deadly triad. *arXiv preprint 1812.02648*, 2018.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. Attention is all you need. *Neural Information Processing Systems (NIPS)*, 2017.

- Williams, R. and Peng, J. Function optimization using connectionist reinforcement learning algorithms. *Connection Science*, 3:241–, 09 1991. doi: 10.1080/09540099108946587.
- Xie, Y., Shi, C., Zhou, H., Yang, Y., Zhang, W., Yu, Y., and Li, L. MARS: Markov molecular sampling for multi-objective drug discovery. *International Conference on Learning Representations (ICLR)*, 2021.
- Zhang, C., Cai, Y., Huang, L., and Li, J. Exploration by maximizing Rényi entropy for reward-free RL framework. *Association for the Advancement of Artificial Intelligence (AAAI)*, 2021.
- Zhang, D., Malkin, N., Liu, Z., Volokhova, A., Courville, A., and Bengio, Y. Generative flow networks for discrete probabilistic modeling. *International Conference on Machine Learning (ICML)*, 2022.
- Zhang, S., Boehmer, W., and Whiteson, S. Deep residual reinforcement learning. *Autonomous Agents and Multi-Agent Systems (AAMAS)*, 2020.
- Ziebart, B. D. *Modeling purposeful adaptive behavior with the principle of maximum causal entropy*. Carnegie Mellon University, 2010.




Figure A.1. Additional results for hypergrid experiments. **Above:** The evolution of the L^1 between empirical sampling and target distributions on the harder variants of 4-dimensional grids, in the same format as Fig. 2. **Below:** The number of cumulative distinct terminal states visited as a function of training time on the standard 2-dimensional grid. Models trained with SubTB(λ) discover more states faster.

A. 实验细节：超网格

环境与 Malkin 等人 (2022) 中的相同，奖励函数参数为 $(R_0, R_1, R_2) = (10^{-3}, 0.5, 2)$ 用于标准变体网格，而 $(10^{-4}, 1.0, 3.0)$ 用于更难的变体。给出对数几率为 $P_F(-|s)$ 和 $P_B(-|s)$ ，以及 $\log F(s)$ 的模型均为多层感知机，其架构与 Bengio 等人 (2021a) 中的相同，输入为坐标的一热表示 s ，并共享所有层，除了最后一层。初始状态流 $\log Z = \log F(s_0)$ 是一个独立参数，其学习率设置为其他参数学习率的 $10\times$ 。

所有模型均使用 Adam 优化器进行训练，批大小为 16，总共训练了 10^6 轨迹（62500 个批次）。每次实验的最佳学习率从 $\{0.0005, 0.00075, 0.001, 0.003, 0.005, 0.0075, 0.01\}$ 中选择，而 $\lambda = 0.9$ 则从集合 $\{0.8, 0.9, 0.99\}$ 中选择作为最优值。

在更难的变体中进行了梯度偏差和方差的实验 8×8 网格。表格 GFlowNet 使用 Adam 优化器进行训练，学习率为 0.007，并采用 SubTB ($\lambda = 0.8$) 目标。

附录 A.1. 额外实验

图 A.1 展示了在更困难的网格环境中额外的结果。

我们在另一个实验中仅使用长度不超过 4 的子轨迹进行训练，使用 SubTB(λ)

目标（即，公式（11）中的求和被截断以排除对 (i, j) 具有 $j - i > 4$ 的情况）。图 A.4 所示的结果表明，在这种受限设置下，SubTB(λ) 仍然表现出色。

图 A.2 展示了 SubTB 参数 λ 对训练曲线的影响，显示了一个从 DB 到 TB 的逐渐插值过程，并在略小于 1 的值处达到最快收敛。

图 A.3 展示了不同训练算法的探索行为可视化结果。结果显示，TB 在离策略训练中表现更好，并且可以从较高的策略对数温度中获益，但其学习速度仍不及 SubTB(λ)，并且在最大训练迭代次数内未能找到所有模式。

A.2. 更多关于偏差和方差的内容：学习状态流的影响

为了更好地理解 SubTB(λ) 减少方差的特性，我们进行了梯度偏差实验，其中梯度的计算方式经过修改，去除了学习状态流的因素。

回忆 § 2.1 中的内容，前向策略 P_F 唯一确定了一种轨迹分布。如果初始状态流 Z 和前向策略 P_F 固定，则存在唯一的状态流函数 F^F 和后向策略 P_B 满足详细的平衡条件 (6)。这个‘真实的前向’流函数，记作 $F^F(s) = Z \sum_{\tau: s \in \tau} P_F(\tau)$ ，由固定到真实分区函数 $Z = \sum_x \in X R(x)$ 和学习到的前向策略 P_F 决定。类似地，‘真实的后向’流函数，记作 $F^B(s) = \sum_{\tau: s \in \tau} P_B(\tau) R(x_\tau)$ ，其中 x_τ 是状态 τ 的终止状态，由奖励函数 R 和学习到的后向策略 P_B 唯一确定。特别是， $F^B(s_0) = \sum_x \in X R(x)$ 。

我们在梯度偏差上重复实验，但通过将损失中的学习状态流 F 替换为精确计算的真实前向或真实后向状态流（分别为 F^F 或 F^B ），计算当前学习的 P_F 和 P_B 值。这些修改不应用于训练，仅用于计算梯度相似性。环境的小规模使得真实状态流的计算成为可能；这在一般情况下是不可能的。训练过程中梯度相似性的变化如图 A.5 所示（参见正文中的图 4）。子 TB(λ) 在学习和真实前向状态流下的类似行为表明，学习的状态流仍然足够接近其最优值，并且子 TB(λ) 与真实状态流的方差减少效果得以保留。

附录 B. 实验细节：分子

所有使用子目标 B (SubTB(λ)) 的实验均基于 Malkin 等人 (2022) 发布的代码，该代码扩展了 Bengio 等人 (2021a) 的工作。提供奖励的代理模型、用于计算相关性度量的保留分子集以及 GFlowNet 模型架构——一种图神经网络——与 Bengio 等人 (2021a) 中的完全相同，而离策略探索率和早停概率与 Malkin 等人 (2022) 中针对 TB 目标训练所调整的一致。所有模型的最大训练批次数为 50000 个，每个批次包含 4 条轨迹。（某些训练运行因梯度数值溢出而提前终止，在这种情况下，我们报告最后一个稳定模型的度量值，其累计批次数为 5000 的倍数。）

附录 C 实验细节：比特序列

模式 M 以及测试序列的选择方法如 Malkin 等人 (2022) 所述。所有方法的策略由具有 3 层、维度 64 和 8 个注意力头的变换器 (Vaswani 等人, 2017) 参数化。所有方法均使用 Adam 优化器进行 50,000 次迭代的训练，小批量大小为 16。对于具有 FM 目标的 GFlowNets 以及基线，我们使用与 Malkin 等人 (2022) 报告相同的实现和超参数。对于 TB 和子目标 B(λ)，我们从 {0.0075, 0.001, 0.001, 0.003, 0.005} 中选择最佳的学习率作为前向对数几率的学习率，并将 Z 的学习率设置为前向对数几率学习率的 $10 \times$ 倍。对于子目标 B(λ)，我们发现最佳的 λ 值为 1.9，从 {0.8, 0.9, 1.1, 1.3, 1.5, 1.7, 1.9, 2.0} 中选取。

附录 D 实验细节：抗菌肽生成

遵循 Malkin 等人 (2022) 的方法，我们使用以下氨基酸：[‘A’, ‘C’, ‘D’, ‘E’, ‘F’, ‘G’, ‘H’, ‘I’, ‘K’, ‘L’, ‘M’, ‘N’, ‘P’, ‘Q’, ‘R’, ‘S’, ‘T’, ‘V’, ‘W’, ‘Y’]。我们从 DBAASP 数据库 Pirtskhalava 等人 (2021) 中获取 6438 个已知的 AMP 序列和 9522 个非 AMP 序列。作为代理奖励函数的分类器在此数据集上进行训练，使用 20PERCENTof 的数据作为验证集。

奖励模型是一个变换器，具有 4 个隐藏层，隐藏维度为 64，以及 8 个注意力头。我们使用大小为 256 的小批量进行训练，学习率为 10^{-4} ，并在验证集上使用早停。我们使用具有 3 个隐藏层，隐藏维度为 64，以及 8 个注意力头的变换器作为所有方法策略的架构。所有方法都经过 20,000 次迭代的训练，小批量大小为 16，并使用来自 (Malkin et al., 2022) 的所有基线报告的超参数。对于 TB 和 SubTB(λ)，我们从 {0.005, 0.007, 0.01, 0.03, 0.05, 0.07} 中选择最佳的学习率用于前向对数概率，从 {0.007, 0.01, 0.03, 0.05} 中选择用于 $\log Z$ 。对于 SubTB(λ)，表现最佳的 λ 值为 1.9，是从 {0.9, 0.99, 1.1, 1.2, 1.3, 1.4, 1.6, 1.7, 1.8, 1.9, 2.0} 中选择的。

E. 实验细节：荧光蛋白生成

我们考虑 Trabucco 等 (2022) 提出的 GFP 任务的一个变体。氨基酸词汇表与 § D 相同：[A', 'C', 'D', 'E', 'F', 'G', 'H', 'I', 'K', 'L', 'M', 'N', 'P', 'Q', 'R', 'S', 'T', 'V', 'W', 'Y']。根据 Brookes 等 (2019) 处理的 Sarkisyan 等 (2016) 的 56,086 种蛋白质数据集。每种蛋白质都附有一个量化其荧光的分数。与 AMP 数据一样，我们将 20PERCENTof 的数据作为验证集用于早停。回归器使用该数据集进行训练，是一个变换器，具有 4 个隐藏层，隐藏维度为 64，以及 8 个注意力头。我们使用大小为 256 的小批量对其进行训练，学习率为 10^{-4} ，并在验证集上使用早停。所有方法的策略架构均采用具有 3 个隐藏层、隐藏维度为 64 和 8 个注意力头的变换器。所有方法都经过 20,000 次迭代的训练，小批量大小为 16。我们为所有方法使用与 § D 相同的实现。

为了定义探索性训练策略，我们将随机动作的概率设置为 0.01，从 {0.0001, 0.0005, 0.001, 0.01} 中选择，并将奖励指数 β （具有与 § 4.2 相同的含义）设置为 3，从 {2, 3, 4} 中选择。对于轨迹平衡，我们分别为流动参数和 $\log Z$ 设置了学习率为 5×10^{-3} 和 1×10^{-2} ，从 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 中选择。对于子轨迹平衡 (SubTB(λ))，我们选择了最佳的 λ 从 {0.7, 0.8, 0.9, 0.99} 中，发现 $\lambda = 0.99$ 表现最佳。对于轨迹平衡和子轨迹平衡 (SubTB(λ))，我们从 {0.0001, 0.0003, 0.0005, 0.00075, 0.001} 中调优最佳的学习率用于前向对数。对于 $\log Z$ ，我们使用的前向对数的学习率为 $10 \times$ 。

对于 FM，我们从 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 中选择一个学习率为 10^{-3} ，叶损失系数为 $\lambda_T = 30$ 。对于带有熵正则化的 A2C，我们在演员和评论家网络之间共享参数，并从 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 中选择一个学习率为 5×10^{-3} ，熵正则化系数为 5×10^{-2} ，从 $\{10^{-4}, 10^{-3}, 5 \times 10^{-3}, 10^{-2}, 5 \times 10^{-2}\}$ 中选择。对于 SAC，我们采用了 Christodoulou (2019) 中的公式，学习率为 10^{-3} ，从 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 中选择，目标网络更新频率为 400，初始随机步数为 200。对于 MARS 基线，我们将学习率设置为从 $\{10^{-5}, 10^{-4}, 5 \times 10^{-4}, 10^{-3}, 5 \times 10^{-3}\}$ 中选择的 5×10^{-4} 。实验在三个种子上运行，并报告三次运行的平均值和标准误于表 2。

附录 F. 逆蛋白质折叠：非自回归序列生成

我们考虑 Sinai 等人 (2020) 提出的逆蛋白质折叠问题。给定一个目标蛋白质的三维骨架构象，任务是从与目标构象能量对应的 Boltzmann 分布中采样固定长度的氨基酸序列 $L = 40$ 。能量由物理模型提供 (Rohl 等, 2004; Chaudhury 等, 2010)。策略模型是一个三层卷积架构，紧密遵循先前的工作 (Sinai 等, 2020)。具体来说，对于策略函数，卷积大小设置为 7，每层有 32 个隐藏特征和修正线性单元激活。策略网络有一个额外的大小为 20（氨基酸的数量）的卷积层，没有激活函数。流网络有两个额外的线性层，大小分别为 [1280, 64] 和 [64, 1]，中间有修正线性单元激活。我们报告了三次运行的平均结果。

对于此任务，我们不从左到右生成序列，而是考虑一个动作空间，在该空间中动作每次修改序列中任意位置的一个字母。第一个动作均匀随机地采样一个氨基酸序列。在随后的每个动作中，代理选择序列中的一个位置，并将该位置的字母替换为词汇表中的另一个字母。生成在恰好进行了 $N = 40$ 次替换步骤后终止。正向策略根据轨迹中已采取的步数进行条件化；反向策略固定为在 $N \cdot L$ 个动作上均匀分布。

作为衡量学习模型与目标分布匹配程度的度量，我们在保留的终端状态集合上测量 $\log R(x)$ 与边缘采样似然度 $\log p_\theta(x)$ 之间的相关性。结果展示在图 F.1 中。我们观察到，中间值的 lambda 导致与目标分布的最佳拟合。




图 A.2. 在不同值的 λ 上的 8×8 网格上的经验 L^1 曲线。




图 A.3. 使用温度调整训练策略（左）和在每次采样步骤中以概率 ϵ 采取均匀随机动作的训练策略（右）在更难的二维网格变体上训练 GFlowNets。




图 A.4. 使用仅包含短子轨迹的不同网格环境训练 GFlowNets，使用 SubTB($\lambda = 0.9$) 目标。




图 A.5. 通过两种方式（参见 § A.2）分析计算的状态流梯度相似性。（与图 4 比较。）




图 F.1. 绘制了训练过程中不同值的 λ 下采样概率与奖励之间的 Spearman 相关性曲线。