

理解并改进 GFlowNet 训练

Max W. Shen^{1,2} 艾曼纽尔·本吉奥³ 厄桑·哈吉拉梅扎纳利¹ 安德烈亚斯·卢卡斯^{1,2}
Kyunghyun Cho^{1,2,4} Tommaso Biancalani¹

摘要

生成流网络 (GFlowNets) 是一类算法, 用于学习生成策略以采样离散对象 x 具有非负奖励 $R(x)$ 。学习目标保证 GFlowNet 样本的质量 x 来自目标分布 $p^*(x) \propto R(x)$ 当损失在所有状态或轨迹上全局最小化时, 但它们在训练资源限制下的表现尚不清楚。本文提出了一种高效的评估策略, 用于比较学习到的采样分布与目标奖励分布。由于给定训练数据时流可能未被完全确定, 我们阐明了学习到的流对泛化和匹配的重要性 $p^*(x)$ 。实践中, 我们研究了如何更好地学习流, 并提出了 (i) 优先回放训练高奖励 x , (ii) 相对边流策略参数化, 以及 (iii) 一种新颖的引导轨迹平衡目标, 并展示了如何解决子结构信用分配问题。我们在生化设计任务上显著提高了样本效率。

1 引言

生成流网络 (GFlowNet) 学习一种策略, 用于生成离散对象 x , 如图、字符串或集合, 通过迭代执行添加简单构建块到部分对象 (子结构) 的动作 (Bengio 等, 2021a;b)。GFlowNet 将数据生成的马尔可夫决策过程 (MDP) 视为一个流网络, 在该网络中, “水流”、“未归一化的概率”或非负奖励 $R(x)$ 通过 MDP 从源节点 (一个“空”对象) 流向中间节点 (部分对象), 最终到达汇节点 (完整对象)。GFlowNets 可被视为一种摊销方法¹ Genentech, 美国南旧金山² Prescient Design, Genentech, 美国南旧金山³ Recursion Pharmaceuticals, 犹他州盐湖城⁴ 纽约大学计算机科学系, 纽约, 美国。联系人: Max W. Shen <shen.max@gene.com>。

Proceedings of the 40th International Conference on Machine Learning, Honolulu, Hawaii, USA. PMLR 202, 2023. Copyright 2023 by the author(s).

替代局部探索方法 (例如 MCMC), 能够从数据中学习, 从而可能发现新的、遥远的 x 具有高 $R(x)$ 。它们已被应用于主动学习、生物序列设计以及各种概率学习任务 (Bengio 等, 2021a; Jain 等, 2022; Zhang 等, 2022; Deleu 等, 2022)。

GFlowNets 旨在解决一个具有挑战性的未归一化密度估计问题。标准的学习目标保证了 GFlowNet 所学习的分布在 x 与目标分布相匹配 $p^*(x) \propto R(x)$ 当训练损失在所有状态或轨迹上全局最小化时, 但在许多实用领域中, 可能有指数级多的 x 以及每个 x 指数级多的轨迹, 使得在实际的数据量和训练时间内实现这一点变得不可行。

为了在实用约束下洞察 GFlowNet 的学习行为, 我们设计了一种高效的 GFlowNet 评估方案, 该方案精确地将学习到的采样分布与目标奖励分布进行比较。我们发现, 在 GFlowNet 训练过程中, 主要挑战在于学会降低对低回报状态分配的概率 x , 并且即使经过长时间的训练, GFlowNet 仍可能继续过度采样低回报状态 x 。

当空间 x 较大时, 并非所有 MDP 状态都会在训练过程中被观察到, GFlowNet 匹配目标分布的能力取决于其从训练期间学到的流中进行泛化的程度。GFlowNet 最初设计用于任何给定的 $R(x)$ 与多个流兼容的场景 (Bengio 等, 2021a) ——也就是说, 流是欠定的。尽管如此, 已学得的流仍然研究不足, 几乎没有关于哪些已学得的流可能比其他更可取的认识。我们的分析奠定了对已学得流的最优性的明确概念: 如果一个流能够改善对未见状态的泛化并帮助 GFlowNet 更好地匹配目标分布, 则该流更好。

我们分析了现有的训练目标如何学习流, 并识别了一个信用分配问题, 在这个问题中, 最负责奖励 $R(x)$ 的 x 子结构可能不在于到达 x 的采样轨迹上, 并且被流行的训练目标低估了。这对于组合奖励函数来说很重要, 其中 $R(x)$ 的价值部分由 x 的子结构决定。我们提出了引导轨迹平衡, 这是一种新颖的学习目标, 是解决这一信用分配问题的第一个方法。

解决这一信用分配问题的方法。

这一学习目标，连同我们提出的优先回放缓存训练和相对边流参数化，甚至用户选择的数据生成 MDPs，可以改变 GFlowNet 在训练过程中如何学习分配流。在生化设计任务的实验中，我们展示了这些已学得流的变化可以显著影响样本效率和收敛到目标分布的程度，最多可提高 $10 \times$ 倍。我们的工作加深了我们对已学得流对 GFlowNet 行为的影响的理解，并确立了一个基本的开放问题：我们如何诱导 GFlowNet 学习更优的流，从而提高它们解决未归一化密度估计问题的能力。

2 预备知识

生成流网络 (GFlowNet) 通过执行一系列动作来学习构建对象的生成策略 (详见 (Bengio 等, 2021b) 的完整描述)。该策略在一个用户定义的确定性马尔可夫决策过程 (MDP) 中运行，此过程必须满足下文所述的某些约束条件。该 MDP 具有一个状态空间 $\mathcal{S}$ ，一组合法动作 $\mathcal{A}_s$ 。对于每个状态 s ，一个确定性的转移函数 $\mathcal{S} \times \mathcal{A}_s \rightarrow \mathcal{S}$ ，以及奖励函数 R 。GFlowNets 将此马尔可夫决策过程视为一种称为流网络的有向图，其中状态对应于节点，而马尔可夫决策过程的转移函数定义了节点之间的有向边。一个状态的子节点是指可以通过其出边到达的状态，父节点则是其入边的来源。没有出边的状态被称为终止状态 (汇点)，并被称作 $x \in \mathcal{X}$ 。GFlowNets 要求用户定义 MDP，使得该图是有向无环图，并且恰好有一个没有入边的状态， s_0 称为初始状态 (源)，并且具有 $R: \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}$ 。

完整的轨迹是从源状态开始到汇状态的一系列状态序列作为所有完整轨迹的集合。轨迹流是非负函数 $(s_t \rightarrow s_{t+1}) \in \mathcal{A}_{s_t}$ 。我们表示 $\mathcal{T}$

$F \triangleq (\mathcal{T}_0 \rightarrow \mathbb{R}_{\geq 0})$ 描述沿每条完整轨迹从源到汇的归一化概率 τ 。对于任何状态 s ，状态流描述通过该状态的未归一化概率总量 s 而对于任何边 $s \rightarrow s'$ ，边缘流

$$F(s) = \sum_{\{\tau \in \mathcal{T}: s \in \tau\}} F(\tau) \text{ 是 } F(s \rightarrow s') = \sum_{\{\tau \in \mathcal{T}: (s \rightarrow s') \in \tau\}} F(\tau)$$

是马尔可夫的，如果对于每一个非终止状态 s ，存在分布 $P_F(\cdot|s)$ ，并且有一个常数 Z ，使得对于任何完整的轨迹 τ ，我们有 $P_F(\tau) = F(\tau)/Z$ 与

$$P_F(\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_n)) = \prod_{t=1}^n P_F(s_t|s_{t-1}).$$

这称为前向策略，可以从 $P_F(s_{t+1}|s_t)$ 采样完整的轨迹。本文还考虑了 F

$P_B(s_{t-1}|s_t)$ ，一个后向策略。当 F 是马尔可夫流时，这些策略与流的关系为：

$$P_F(s'|s) = \frac{F(s \rightarrow s')}{F(s)}, \text{ and}$$

$$P_B(s|s') = \frac{F(s \rightarrow s')}{F(s')}.$$

生成流网络。 GFlowNet 是一种带有参数的学习算法 θ 包含一个马尔可夫流模型 F_θ ，以及目标函数 (Bengio 等, 2021b)。流模型可以通过以下方式唯一确定：

- 边缘流 $F_\theta(s \rightarrow s')$ ，这诱导了一个前向策略 $P_F(s'|s)$ ，or

- 初始状态流 Z_θ 和前向 $= F_\theta(s_0)$ 策略 $P_F^\theta(s_{t+1}|s_t)$ ，or

$F_\theta(x)$ • 终端状态流与逆向策略

$$P_B^\theta(s_{t-1}|s_t).$$

我们将 GFlowNet 的学习采样分布称为 $p_\theta(x)$ ，该分布通过从 s_0 开始并迭代采样 $P_F^\theta(s_{t+1}|s_t)$ 以到达终止状态 x 来实现。学习目标旨在使 $p_\theta(x)$ 与目标分布相匹配， $p^*(x) \triangleq R(x)/\sum_{\mathcal{X}} R(x)$ 。

轨迹平衡目标 (Malkin 等, 2022). 该目标通过学习 Z_θ 和前向策略 P_F^θ 来使用前向策略参数化，但同时也学习了反向策略 P_B^θ 作为训练工件。轨迹平衡由细致平衡条件所驱动，对于状态流函数 F 的流动

$F(s)$ ，如果对于所有边 $s \rightarrow s'$ 满足

$F(s)P_F(s'|s) = F(s')P_B(s|s')$ 。轨迹平衡目标试图在整个轨迹上强制执行细致平衡：

$$\mathcal{L}_{TB}(\tau) = \left(\log \frac{Z_\theta \prod_{t=1}^n P_F^\theta(s_t|s_{t-1})}{R(x) \prod_{t=1}^n P_B^\theta(s_{t-1}|s_t)} \right)^2 \quad (1)$$

(Malkin 等, 2022) 证明了如果 GFlowNet 达到了在具有全支撑的训练策略轨迹上的目标函数全局最小值，则它可以从目标分布中采样。当许多轨迹可以导致相同的 x 时，轨迹平衡目标可能有多个全局最优解——流是欠定的。然而，对于任何固定的 P_B 选择，存在一个唯一的全局最小值，对应的是一个从目标分布中采样的 P_F (Bengio 等, 2021b)。 (Madan 等, 2022) 研究了轨迹平衡的一个扩展，该扩展能够从部分剧集集中学习。

最大熵 GFlowNets。 (Zhang 等, 2022) 证明了当 P_B 固定为均匀分布时，轨迹平衡目标的唯一全局最小值是一个具有最大流熵的马尔可夫流 F 。

$$\mathcal{H}[F] \triangleq \mathbb{E}_{\tau \sim P_F} \sum_{t=0}^{n-1} \mathcal{H}[P_F(\cdot|s_t)].$$

训练。 GFlowNets 使用随机梯度下降进行训练，以优化从训练策略采样的状态或轨迹的学习目标。通常将训练策略选择为 P_F^θ 和均匀动作策略的混合，以鼓励在训练过程中进行探索。从强化学习的角度来看，GFlowNet 的训练是非策略的。重要的是，GFlowNet 的训练是一个自举过程：当前策略用于在每次训练轮次中采样新的 x 。由于 $R(x)$ 由用户定义，因此它会在每个新采样的 x 上进行计算，并且这个集合 $\{x, R(x)\}$ 被用来更新 GFlowNet 策略。我们将 X 定义为迄今为止在训练过程中看到的所有 x 的集合。该集合最初为空，并随着每次训练轮次而扩展。

3 GFlowNets 的评估与欠拟合

在先前的工作中，GFlowNets 已经通过多种方式进行了评估，通常侧重于其发现具有高奖励的新颖和多样化模式的能力。然而，它们匹配目标分布的能力在实证研究中较少被彻底探讨，尽管这种能力在 GFlowNet 机制中至关重要。

学习匹配目标分布并非易事。理论上，这发生在所有状态或轨迹上的损失被全局最小化时。然而，在维度极高且 $|\mathcal{X}|$ 呈指数级增长的情况下，即使访问每个状态或轨迹一次也是不可行的。

评估 GFlowNets 可能具有挑战性。在许多感兴趣的 MDP 中，每 x ，存在指数级多的轨迹，这可能会使通过动态规划计算 $p_\theta(x)$ 变得代价高昂。而且， $|\mathcal{X}|$ 通常非常大，使得精确刻画目标分布变得不可行。一些研究通过在保留数据上计算 $\log p_\theta(x)$ 和 $R(x)$ 之间的斯皮尔曼相关性来评估 GFlowNets (Madan 等, 2022; Nica 等, 2022)，但当 $\log p_\theta(x) = cR(x)$ 对于任何常数 $c > 0$ 时，这种相关性为 1.0，即使只有当 $c = 1$ 时，GFlowNet 才与目标分布匹配。

本文设计基准时采用了生物数据和奖励，并限制其具有可枚举性 $\mathcal{X}$ ，同时利用 GFlowNet 样本进行评估而非计算 $p_\theta(x)$ 。这使得能够精确高效地观察 GFlowNets 与目标奖励分布统计匹配的程度。本文研究了 Anderson-Darling 统计量，该统计量用于计算 GFlowNet 奖励样本与目标奖励分布之间的拟合优度，并将样本的平均 GFlowNet 奖励 $\mathbb{E}_{p_\theta(x)}[R(x)]$ 与预期的目标奖励 $R(x)^2/Z$ 进行了比较。

我们注意到，该评估方案仅与目标奖励分布进行比较。尽管如此，此方案使我们能够指出，在 GFlowNet 训练中一个关键挑战是欠拟合目标分布，即它们以过高的概率采样低奖励。我们讨论欠-

在此进行拟合，并提出改进措施，将基准详情和实验结果推迟至 § 7。

GFlowNets 在训练过程中对目标分布欠拟合

ing. 在我们的实验（见 § 7）中，平均 GFlowNet 采样奖励 $\mathbb{E}_{p_\theta(x)}[R(x)]$ 初始显著低于目标平均奖励，并且非常缓慢地接近，甚至可能永远达不到目标平均奖励，即使经过数万次的活跃训练轮次也是如此。在初始化时，参数随机选择，我们认为 GFlowNet 平均采样奖励较低，因为 P^θ 具有高熵，因此 $p_\theta(x)$ 通常也具有 $(s_{t+1}|s_t)$ 具有高熵（尽管这取决于 MDP 的选择，见 § A.1）。

这与之前的研究一致，该研究在小分子任务上报告了回归斜率为 0.58，训练完成后在 $\log p_\theta(x)$ 和 $\log R(x)$ 之间，表明低奖励 Oversampling x 。为了鼓励发现高奖励 x ，通常会在奖励值的高指数上进行训练，比如 3 到 10。例如，具有 $10 \times$ 倍更高结合亲和力的分子可能在 $\mathcal{X}$ 中稀有超过 $1000 \times$ 倍，除非将奖励视为结合亲和力的幂次方，否则会降低它们的相对概率。这增加了奖励偏差，降低了目标分布的熵，并扩大了与高熵 GFlowNet 初始设置之间的差距。在先前的研究中，当训练数据的奖励越来越偏斜时，GFlowNets 未能显著提高采样的奖励。

备注 1. 在 GFlowNet 训练过程中，主要的实用挑战在于降低采样低奖励状态的概率 x 。

我们的观察影响了 GFlowNets 的实际应用。通常情况下，GFlowNet 的训练会在收敛或耗尽训练资源时停止，但我们的实验表明，GFlowNets 可能在低于目标均值的情况下收敛，并且即使经过长时间的训练，也可能无法达到目标均值。监测采样平均奖励并与未知的目标均值进行比较并不是常见的做法。因此，在实践中，许多 GFlowNets 可能会无意间过度采样低奖励样本 x 。

这促使我们理解 GFlowNets 的训练行为，并探索可能帮助它们更快地以更高概率采样高回报的策略。这些策略可以帮助 GFlowNets 更快地匹配目标分布。

奖励优先回放训练 (PRT)。本文提出了优先级回放训练 (Prioritized Replay Training, PRT)，该方法专注于高奖励数据，作为一种简单策略以增加采样的奖励。在每次训练轮次中，除了对从训练策略采样的轨迹进行训练外，我们还从 X 所有迄今为止看到的数据中形成一个回放批次，使得 $\alpha\%$ 的批次是从 β 分位数的 $R(x)$ 中采样，其余部分

批次从底部 $1 - \beta$ 百分位采样。为了在回放批次上训练 x ，我们使用 P_B 为其采样轨迹，然后在这些轨迹上进行训练。

回放训练在强化学习中很常见，它可以显著提高样本效率（Fedus 等人，2020）。类似的策略是基于误差优先的经验回放（Schaul 等人，2015），该策略优先选择具有高时间误差的回放样本。（Jain 等人，2022）提出了从固定初始数据集开始的 GFlowNets 回放训练。相比之下，我们的奖励优先回放训练动机在于解决 GFlowNets 在低奖励 Oversampling 方面的困难 x 。

4 流分布与泛化

我们现在转向研究流分布，即 GFlowNets 如何选择在 MDP 图的节点和边之间流动“未归一化的概率”。本节将阐明流分布对于泛化以及高效匹配目标分布的重要性。由于流通常是欠定的，这种澄清引出了一个问题：GFlowNets 如何学习更好的流？

流分布的第一个因素是用户对生成数据的 MDP 的选择。对于任何给定的数据 x ，用户通常可以在不同的 MDP 中进行充分的选择。字符串可以自回归地生成，从空字符串开始，迭代地添加字符。在这种自回归 MDP 中，恰好存在一条以任何 x 结尾的轨迹，这意味着在整个 x 中只有一个与 $R(x)$ 兼容的流。然而，如果合法动作集扩展到前置和后置，则生成的前置/后置 MDP 将有 2^{k-1} 条以长度为 k 的字符串结尾的轨迹，并且有许多与 $R(x)$ 兼容的流。最后，请注意，生成图的 MDP 通常具有两个以上的连接点，并且每 x 有更多的轨迹。

GFlowNets 机制的原始动机及其主要新颖性在于每个 x （具有多条轨迹的 MDP（Bengio 等人，2021a））。正是在这种情况下，自回归或标准强化学习方法学习偏倚的生成概率，而 GFlowNets 不会。当轨迹和 x 是一对一关系时，GFlowNets 退化为一种已知的方法：离散动作软 Q 学习。因此，我们将重点放在多对一的情况下，在这种情况下，给定的流是欠定的。

$R(x)$ 。

训练期间泛化的角色。当 $\mathcal{X}$ 是高维且规模较大时，将状态、轨迹和 x 概念性地划分为训练过程中已见过的部分和尚未见过的部分是有用的。GFlowNet 在 $\mathcal{X}$ 上的策略质量，特别是 $p_\theta(x_{\text{unseen}})$ 与 $p^*(x_{\text{unseen}})$ 匹配的程度，在很大程度上取决于 GFlowNet 从训练过程中所见数据进行泛化的程度。由于 GFlowNet 以自举的方式进行训练，从而不断改进

泛化能力在任何训练步骤上都有助于未来的训练。最后，GFlowNets 只能在极小的一部分 $\mathcal{X}$ 上进行训练，因此其最终匹配目标分布的能力也依赖于泛化。

由于 $p_\theta(x_{\text{unseen}})$ 依赖于学习到的前向策略 P_F^θ 或等效地依赖于学习到的边缘流 $F_\theta(s \rightarrow s')$ ，我们陈述：

注记 2. 流分布对泛化至关重要，而泛化对于匹配目标分布至关重要，即 $\mathcal{X}$ 。此外，给定数据的情况下，流通常规格不足 $\{x, R(x)\}$ 。

此论述奠定了流动分布质量的概念：若一流分布有助于 GFlowNet 更好地泛化，则该分布更优。

相对边缘流参数化 (SSR) 本文对泛化在匹配目标分布中的作用进行了澄清，这促使我们研究了 GFlowNet 参数化中的归纳偏置，这些偏置可能会影响其泛化行为。GFlowNets 通常采用策略参数化，其中 $P_F^\theta(s)$ 是一个称为“SA”的神经网络映射 $\mathcal{S} \rightarrow \mathcal{A}$ 。如果该策略学习到某些状态下的特定动作是有利的 s ，它可以在与之相似的新状态下推广相同的动作偏好 s ，但这种泛化有时可能是不正确的。这一概念与最优传输正则化相关（匿名，2023），旨在明确鼓励在相似状态下采取相似的动作策略。

本文提出了一种替代参数化方法，其中相对边流由神经网络 $f_\theta: \mathcal{S}, \mathcal{S}' \rightarrow \mathbb{R}^+$ 参数化，我们称之为“SSR”。从 s, s' 状态向前转换的概率定义为 $f_\theta(s, s') / \sum_{c \in \text{children}(s)} f_\theta(s, c)$ 。直观上，与 SA 不同，SSR 可以“看到”子状态。概念上，基于子状态，SSR 可以帮助 GFlowNet 泛化到在新状态下采取不同于训练中所见的动作。值得注意的是，相对边流参数化效率较低，并且并不比 SA 更具表现力。

SSR 与直接参数化状态流 $F(s)$ 密切相关（例如，在流匹配目标（Bengio 等，2021a）中），这可能有助于 GFlowNet 从高流量和低流量状态模式泛化到发现与高奖励相关的新状态。相关工作还包括（Madan 等，2022），他们参数化状态流以从部分情节中学习，并假设状态流泛化的益处，但他们的方法并未使用学习的状态流进行决策。

5 组合性和信用分配

我们已经确立了流分布对于泛化到未见过的 x 的重要性，以及匹配目标分布上的 $\mathcal{X}$ 。给定数据 $\{x, R(x)\}$ ，流通常被欠指定，这是一个开放问题，即

GFlowNets 是否倾向于学习某些流分布而不是其他流分布。在本节中，我们将继续探讨 GFlowNet 学习目标如何学会分配流。特别是，我们建立了这一观察（参见图 3 以获得直觉）：

观察 3. 当每个 x 存在许多轨迹时，轨迹平衡和最大熵 GFlowNets 学习流的方式可能无法充分归因于与高奖励相关的子结构 $\bar{x}$ 。这种子结构可能存在，当奖励函数具有组合性时。

我们将逐步建立这一观察：首先讨论组合性奖励函数，子结构信用分配问题，最后研究 TB 和 MaxEnt 目标。

组合奖励函数。 我们已经确定，从已见 $R(X)$ 到未见 x 的泛化对于 GFlowNets 匹配目标分布至关重要，特别是在 λ 较大时。然而，可能的是 $R(x)$ 与 x 之间没有可学习的关系——在这种情况下，泛化是不可能的，没有任何流动分布比其他更好。

因此，GFlowNets 在未归一化密度估计方面优于 MCMC 的核心前提是假设对 $R(x)$ 的泛化是可能的。组合奖励函数是一个重要的例子，在这种函数中， $R(x)$ 的价值主要取决于 $\bar{x}$ 的子部分或子结构及其相互作用（Andreas, 2019; Szabó, 2020），这样的可学习 $R(x)$ 。

例如，小分子的重要性质通常是由分子亚结构的存在引起的，如苯环。这些例子表明，当 $R(x)$ 是组合式的， $\bar{x}$ 的亚结构可以与较高的奖励相关联。我们将这些重要的亚结构称为关键亚结构。

生成离散对象的 GFlowNets 迭代地采取行动，将简单的构建块组合起来，逐步经过与“部分对象”相对应的状态，最终生成完整的对象 x 。当 $R(x)$ 具有组合性，GFlowNets 将更高的流分配给内部 MDP 状态 s 对应重要子结构可能通过以下方式更好地泛化：1) 增加 $p_\theta(x_{\text{unseen}})$ 用于下游任务 x_{unseen} 包含 s ，增加采样的概率 x_{unseen} 与更高回报相关，并使 GFlowNet 能够泛化 s 并发现新的子结构 s_{unseen} 与高回报相关。

亚结构信用分配问题。 在强化学习中，信用分配问题涉及确定系统的整体性能的成功如何归因于系统各组成部分的各种贡献（Minsky, 1961）。一个学习代理在一个环境中采取一系列长期动作以获得最终奖励，该代理必须学会将信用分配给最负责任的动作。

我们认为 GFlowNets 面临类似的挑战——

将流动或信用分配给对 $R(x)$ 最负责任的重要子结构——我们称之为子结构信用分配问题。但在强化学习中，信用分配仅限于特定轨迹上采取的动作，这些动作到达奖励。然而，对于 GFlowNets，在通常情况下，有指数级多条轨迹结束于任何 x ，对 $R(x)$ 最负责任的重要子结构往往不在于到达 x 的训练轨迹上。

现有的学习目标未能充分解决子结构信用分配问题。轨迹平衡（TB）和最大熵（MaxEnt）目标通过梯度步骤来最小化生成轨迹上的损失，该轨迹由训练策略用于到达 x ，这通常不包含重要子结构。此外，TB 对流动的规范不足：许多不同的流动都可以全局最小化损失，并且没有明显的归纳偏置倾向于任何特定的流动分布。MaxEnt 将 P_B 固定为均匀分布，实现了唯一的信用分配解决方案，但这种方案尽可能广泛地分散对 $R(x)$ 的信用，赋予重要子结构极小的信用。

先前的目标低估了重要子结构的信用。 为了形式化直觉，我们研究了 TB 和 MaxEnt 在一个简化但具有代表性的框架中的行为。我们采用了用于研究强化学习算法的表格模型设置（Sutton & Barto, 2018），并考虑了一个具有相关属性的简单马尔可夫决策过程（MDP）。由于篇幅限制，这里提供非正式摘要，完整的陈述和证明见附录。

定义 5.1 (序列前置/后置 MDP 设置)。在这个 MDP 中， s_0 为空字符串，状态为字符串，动作是在字母表 $\mathcal{A}$ 中前置或后置一个符号。这个 MDP 生成长度为 n 的字符串。存在一个固定的数据集 $\{x, x'\}$ ，其中包含 $R(x) = R(x')$ 。记 s^* 为重要子结构，定义为由 x, x' 共享的最长子串，其长度为 k 。记 $s_k(x)$ 为长度为 k 的子串集合，这些子串属于 $\bar{x}$ 。

备注 4. 在这个马尔可夫决策过程（MDP）中，有 2^{n-1} 条轨迹以任何 x 结束，并且每条轨迹恰好通过长度为 k 的一个字符串，该字符串要么是 s^* ，要么是集合 $\{s_k(x) \setminus s^*\}$ 中的任意其他字符串，其中 $\setminus$ 表示集合差。我们研究通过 s^* 的流量 $F(s^*)$ ，以及通过的流量之和 $\{s_k(x) \setminus s^*\}$ ，using $F(s_k(x) \setminus s^*) \triangleq \sum_{s' \in \{s_k(x) \setminus s^*\}} F(s')$ 。

命题 5.2 (最大熵分配最小信用给重要子结构)。在设置 5.1 下，假设 GFlowNet 使用最大熵学习目标进行训练。那么，在全局极小值处，

$$\mathbb{E} \left[\frac{F(s^*)}{F(s_k(x) \setminus s^*)} \right] = \frac{2}{n-k} \quad (2)$$

对 s^* 在 x, x' 中的随机位置取期望。

该命题指出，对于许多具有实用价值的 n, k 值，最大熵方法将少量流量分配给 s^* ，并倾向于以高概率通过非重要子结构采样轨迹。

为了在设置 5.1 中讨论轨迹平衡，我们将之限制在表格化轨迹流更新上，并确保在 x, x' 上的训练步骤相等。

定义 5.3 (表格型，固定数据 TB)。假设所有表格轨迹流

$F(\tau) = \epsilon$ 在初始化时，使得 $F(x) < R(x)$ 对于 x, x' 在初始化时成立。我们在每个 x, x' 上进行 $m/2$ 次训练步骤，以当前值成比例的概率采样一个轨迹 $\tau_{\rightarrow x}$ ，该轨迹 $F(\tau_{\rightarrow x})$ 以那个 x 结束，然后更新

$$F(\tau_{\rightarrow x}) \leftarrow F(\tau_{\rightarrow x}) + \lambda(R(x) - \epsilon)。$$

命题 5.4 (TB 倾向于减少对重要子结构的信用)。假设设置 5.1 并进行 TB 训练 5.3。令 t 表示训练步骤的索引。在任意训练步骤 t ，如果 $F_{t-1}(s^*) < (n-k) \mathbb{E}_{s \sim s_k(x) \setminus s^*}[F_{t-1}(s)]$ 成立（在均匀分布下的期望），那么训练轨迹上的预期轨迹流更新为 τ 有：

$$\mathbb{E}_{\tau} [F_t(s^*)] - F_{t-1}(s^*) < \mathbb{E}_{\tau} [F_t(s_k(x) \setminus s^*)] - F_{t-1}(s_k(x) \setminus s^*)。$$

TB 学习更新倾向于增加通过非重要子结构的流量，以牺牲 s^* 为代价，除非在极少数情况下， $F(s^*)$ 比竞争的非重要子结构的平均流量大得多，大一个因素 $(n-k)$ 。在 § C.7 中，我们将 TB 解释为一个“富者愈富”的波利亚罐模型：训练中高流量轨迹被采样的次数更多，从而进一步增加流量。

综上所述，TB 和 MaxEnt 未能充分解决问题

结构信用分配问题，可能无法学会最优地分配流量。

6 引导轨迹平衡

本文提出了一种新颖的学习目标，称为引导轨迹平衡，它能够灵活地控制信用分配和流量分布。本文提出了一种特定的引导方法，解决了子结构信用分配问题。

一般地，假设对于某些 x 和 $R(x)$ ，我们希望优先沿着某些轨迹为 $R(x)$ 分配信用（即流动）。我们用引导分布 $p(\tau_{\rightarrow x})$ 来表示结束于 x 的轨迹上的这种偏好。

我们强调，引导 $p(\tau_{\rightarrow x})$ 不必是固定的，也不必相对于 MDP (Markov Decision Process) 具有马尔可夫性。一种特别有效的方法是利用 X ，即训练过程中收集到的所有 x 集合，在后续章节中我们将对此进行演示。该方法带来的

指导参数 $p(\tau_{\rightarrow x}|X)$ 在每次训练的新活跃轮次中发生变化，随着 X 的增长。

为了制定一个有效且通用的 GFlowNet 学习目标，我们提出了一个针对终止于 x 的轨迹 $\tau_{\rightarrow x}$ 的引导轨迹平衡约束。定理 6.1 表明，如果一个 GFlowNet 在所有 x 和所有轨迹上满足此约束，则它将从目标分布中采样，从而实现与先前 GFlowNet 学习目标相同的渐近保证。

定理 6.1 (引导轨迹平衡约束)。假设对于任意 x ，以及任何结束于 x 的轨迹 $\tau_{\rightarrow x} = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_n = x)$ ，引导轨迹平衡约束 (3) 成立。

$$Z \prod_{t=1}^n P_F(s_t | s_{t-1}) = p(\tau_{\rightarrow x}) R(x) \quad (3)$$

然后 P_F 样本 x 的概率 $R(x)/Z$ 。

证明。利用 $\prod_{t=1}^n$ ，然后对所有结束于 x 的轨迹求和得到 $\sum_x \prod_{t=1}^n P_F(s_t | s_{t-1}) = P_F(\tau_{\rightarrow x}) Z P_F(x) = R(x)$ 。□

然而，在一般情况下，引导分布可能不是马尔可夫性的，标准 GFlowNets 的马尔可夫流无法处处满足约束 3。我们通过两阶段优化方法解决了这一问题。请注意，引导轨迹平衡 (3) 与轨迹平衡 (1) 之间的关系在于， $p(\tau_{\rightarrow x})$ 扮演着 P_B 的角色。本文首先提出训练 P_B 以匹配 $p(\tau_{\rightarrow x})$ ，使用：

$$\mathcal{L}_{\text{back-GTB}}(\tau_{\rightarrow x}) = \left(\log \frac{\prod_{t=1}^n P_B^\theta(s_t | s_{t-1})}{p(\tau_{\rightarrow x})} \right)^2 \quad (4)$$

该方法学习一个 P_B 作为对 $p(\tau_{\rightarrow x})$ 的马尔可夫近似。收敛后，我们冻结 P_B ，然后在固定 P_B 的情况下通过轨迹平衡来学习 P_F ，这恢复了一个正确的 GFlowNet 学习目标：根据唯一性性质 ((Bengio 等, 2021b), 推论 1)，对于任何固定的马尔可夫型 P_B ，轨迹平衡损失存在唯一的全局最小值，对应的正是从目标分布中采样的马尔可夫型 P_F 。

训练注意事项。 训练轨迹可以从训练策略中采样。或者， x 可以从训练策略中采样，然后从引导中重新采样一个训练轨迹 $\tau_{\rightarrow x}$ 。

实践中，通过交替更新 P_F 和 P_B ，一个有用的 $P_F \cdot P_B$ 可以更快地被学习到，也可以在一个目标上进行训练，该目标混合了当前的 P_B 和引导的 $p(\tau_{\rightarrow x})$ ，权重为 $\alpha \in [0, 1]$ ：

$$\mathcal{L}_{\text{forward-GTB}}(\tau) = (\psi_f - \psi_b)^2 \quad (5)$$

$$\psi_f \triangleq \log Z_\theta + \sum_{t=1}^n \log P_F^\theta(s_t | s_{t-1}) \quad (6)$$

$$\begin{aligned} \psi_b \triangleq & \log R(x) + \alpha \log p(\tau_{\rightarrow x}) \\ & + (1 - \alpha) \left(\sum_{t=1}^n \log P_B^\theta(s_t | s_{t-1}) \right) \end{aligned} \quad (7)$$

子结构引导。 本文提出一种特定引导方法，适用于组合奖励函数，用于训练子结构 GFlowNets。该引导方法通过观察部分来发现重要子结构 x 与所有高回报相关 X 训练过程中迄今所见，并指导信用分配趋向这些经验上重要的子结构。

我们说状态 s 是状态 x 的子结构，或者说是状态 $s \in x$ 的子结构，如果在 MDP 中存在从 s 到 x 的有向路径。一个启发性的洞见是，对于许多组合对象而言，计算 $\in$ 是高效的（集合的子集函数，字符串的子串函数）。对于图而言， $\in$ 对应于 NP 完全的图同构问题，但在实践中当许多节点或边特征不同时，这个问题运行得很快。此外， $\in$ 总是可以通过 MDP DAG 的广度优先搜索来计算，这将其时间复杂度限制在 $O(V + E)$ 。

我们的引导定义为 $p(\tau_{\rightarrow x} | X) = \prod_{t=0}^{n-1} p(s_{t+1} | s_t, x, X)$ ，其中状态转移概率为：

$$p(s_{t+1} | s_t, x, X) = \frac{\phi(s_{t+1} | x, X)}{\sum_{s' \in \text{children}(s_t)} \phi(s' | x, X)}, \quad (8)$$

具有分数函数 $\phi(s | x, X)$ ，该函数倾向于选择作为 x 高平均奖励子结构的子节点：

$$\phi(s | x, X) = \begin{cases} \mathbb{E}_{\{x' \in X: s \in x'\}} R(x'), & \text{if } s \in x \\ 0 & \text{otherwise.} \end{cases} \quad (9)$$

为了便于说明，本描述忽略了特殊情况。我们在 § A.2 中提供了完整的描述。在实践中，并行化和一个效率技巧将增加的开销减少到了可以忽略的程度（详见 § A.2）。

子结构 GFlowNets 为重要的共享子结构分配信用

结构。 在设置 C.3 中，我们展示了 MaxEnt 和 TB 目标未能充分奖励重要的共享子结构， s^* 。相比之下，子结构 GFlowNets 将最大奖励分配给 s^* （命题 C.9），这表明基于子结构的轨迹平衡有助于解决子结构信用分配问题。

7 实验

为了精确高效地评估 GFlowNets 与目标奖励分布的匹配程度，我们设计了可枚举的基准测试 $\mathcal{X}$ ，并使用 GFlowNet 采样的奖励进行评估。Anderson-Darling (AD) 统计量是一种衡量样本与目标分布拟合优度的统计度量，在我们的实验中，它与样本均值和目标均值之间的误差高度相关（中位数 $R^2 = 0.87$ ，§ B，图 B.1），并且当均值误差接近零时，AD 统计量也接近零（表示没有显著差异）。因此，我们报告均值误差以便于解释。在表 1 中，我们报告了收敛时均值的相对误差，或者达到目标均值所需的训练轮数。在图 1 中，我们展示了表 1 中相同运行的训练曲线。我们在表 1 和图 1 中报告了三个重复实验的均值和标准误差 $\pm$ 。

在五个任务中，本文报告了基线 TB 和 Max-Ent 的结果，并与三种提出的训练修改方法进行了比较：优先回放训练（PRT）、相对边缘流策略参数化映射 $\mathcal{S} \times \mathcal{S} \rightarrow \mathbb{R}$ （SSR）以及子结构引导轨迹平衡（Sub）。我们采用了消融系列 TB、TB+PRT、TB+PRT+SSR 和 Sub+PRT+SSR 来分别比较添加 PRT、SSR 以及子结构指导的个体效果。我们仅更改了必要的最少超参数和训练细节以添加每一项提议（详见 § B 中的完整实验细节）。

背包。 ($|\mathcal{X}| \approx 100$ B) 包含 7 种不同元素的多重集，大小为 13。基础奖励为 0.01。如果一个背包包含任何字母 7 次或更多，则它具有“子结构”，此时有 75% 的概率获得 10 的奖励，否则获得 30 的奖励。在这个马尔可夫决策过程中，动作是指向背包中添加一个元素。

SIX6 ($|\mathcal{X}| = 65,536$ (TFBind8)). 一段长度为 8 的核苷酸序列。奖励是通过湿实验室测量的人类转录因子 SIX6 的 DNA 结合活性，数据来源为 (LA 等, 2016; Trabucco 等, 2022)。根据 (Jain 等, 2022)，我们使用奖励指数为 3。尽管自回归 MDP 通常用于字符串，为了将 TB 与子结构引导进行比较，后者仅在生成型 MDP 中有意义，其中每个 x 包含多条轨迹，我们使用序列前置/后置 MDP。我们在后续部分将其与自回归 MDP 进行比较。

PHO4. ($|\mathcal{X}| = 1,048,576$) 一段长度为 10 的核苷酸序列，其湿实验室测量的 DNA 结合活性针对酵母转录因子 PHO4，数据来源为 (LA 等, 2016; Trabucco 等, 2022)。

QM9. ($|\mathcal{X}| = 58,765$) 一个小分子图。奖励来自一个代理深度神经网络，该网络预测从密度泛函理论得出的 HOMO-LUMO 能隙。我们使用 12 个构建块和 2 个茎来构建，并生成每个分子包含 5 个构建块。

sEH. ($|\mathcal{X}| = 34,012,224$) 一个小分子图。奖励来自一个代理模型，该模型训练以预测从 AutoDock 得出的可溶性环氧化物水解酶的结合亲和力。我们使用 18 个构建块和 2 个茎来构建，并生成每个分子包含 6 个构建块。

结果。

PRT、SSR 和子结构指导改进 GFlowNet 训练。在表 1 中，我们观察到，在所有 5 种实验设置中，最佳模型至少包括我们的提议之一 PRT、SSR 和子结构指导。最佳模型在最短轮数内匹配目标均值——在 sEH 的情况下，比 TB 快 9 倍——或者当所有模型都欠拟合目标分布时，实现最高均值。我们在随后的部分讨论每个提议的单独效果。

基线和 GFlowNets 可能难以应对欠拟合问题。

欠拟合。基准测试结果表明，在合理的训练时间内，TB 收敛到的策略在五个环境中的两个环境中对目标均值采样不足，并过度重视低奖励。这一点在 SIX6 中尤为明显，超过 50,000 轮训练中 TB 采样了 800,000 个数据点（每轮批大小为 16），相对比率超过 $12\times$ 状态空间大小 $|\mathcal{X}| = 65,536$ 。尽管对状态空间进行了显著的过采样，但在均值下的收敛表明，在实践中找到所有状态和轨迹的全局最小值非常困难，这可能预示着在更大状态空间中训练 GFlowNets 时会遇到挑战。欠拟合也因环境而异：所有模型在 PHO4 环境中尤其表现不佳。

TB 与最大熵方法通常相似。最大熵方法具有从 P_B 均匀分布流的独特全局最优解，而 TB 原则上可以学习具有更低熵的不同流 P_B 。先前的研究并未提供关于最大熵方法与 TB 之间相似性和差异性的洞见。在我们的实验中，我们观察到最大熵方法和 TB 的训练曲线相似，且通常在样本效率和收敛性方面不如我们的提案。

优先回放训练提高了样本效率。优先回放训练 (PRT) 优于基线。它在 PHO4 环境中实现了所有模型中的最高性能，并将 sEH 中匹配目标均值所需的轮数减少了三倍，从 45840 轮减少到 19390 轮。在 bag 和 SIX6 环境中，优先回放训练并没有改善最终收敛的 GFlowNet（表 1），但显著提高了改善平均误差的样本效率。

学习曲线（比较绿色与蓝色，图 1）。

相对边流参数化的影响。相对边流参数化 (SSR) 进一步显著改善了训练（比较红色与绿色，图 1），特别是在 SIX6 环境中，学习曲线的变化因子高达 $3\times$ 。在 Bag 和 sEH 中，SSR 将匹配目标均值所需的时间缩短了一半。这些实验表明，SSR 可以实质性地改变 GFlowNets 的训练行为，并在某些任务上显著提高它们的表现。进一步的工作可能会继续研究 SSR 并开发出更优的参数化方法。

子结构引导的效果。子结构引导在 SIX6 和 sEH 中效果最为显著，在 SIX6 中，它使得唯一能够匹配目标均值的模型成为可能，并在 sEH 中提高了样本效率，提升了目标均值匹配效率 $2\times$ （表 1）。总体而言，这些结果证实了不同的信用分配偏好可以显著影响 GFlowNet 的训练、收敛和样本效率。

本文提出的子结构引导的效果可能取决于组合性 $R(x)$ 的程度。此外，子结构引导未能改善训练可能是由于过拟合。

自回归 MDP。一般来说，用户在设计生成性 MDP 时有很多选择。TFBind8 是一个字符串生成环境，对于这种环境，通常使用自回归或追加式 MDP 进行 GFlowNet 训练。我们使用自回归 MDP 训练了一个 GFlowNet，在 50,000 轮训练后，最终收敛均值达到了 97.3%，基线为 TB。需要注意的是，在自回归 MDP 中，标准 TB 等同于 MaxEnt，子结构引导没有效果，因为每个 x 只有一个轨迹。添加 PRT 和 PRT+SSR 不会影响最终的 GFlowNet 策略，分别实现了 96.9% 和 96.6%，但显著提高了样本效率，分别在第 8000 轮和第 3500 轮达到最佳策略，这分别是 6 倍和 14 倍的改进（图 2）。

使用每个 x 具有更多轨迹的 MDP 是否有益？对于 SIX6，我们的答案是可以的。使用预置/追加 MDP 结合子结构引导、PRT 和 SSR 是我们实验中唯一能够匹配 SIX6 目标均值的组合（表 1）。这一结果表明，偏好自回归 MDP 并不总是最好的，因为它们对构建顺序的限制可能会限制从某些子结构中构建哪些 x 。

表 1. 收敛学习均值与目标均值对比（100% 为最佳），或匹配目标均值所需的活跃轮数（↓）

METHOD	BAG	SIX6	PHO4	QM9	sEH
TB	100% (13820 ± 1740)	98.0% ± 0.2%	78.3% ± 0.3%	100% (8405 ± 185)	100% (45840 ± 500)
MAXENT	100% (13775 ± 2275)	96.8% ± 0.7%	77.7% ± 0.2%	100% (8735 ± 775)	100% (42670 ± 190)
TB + PRT	100% (20575 ± 2355)	97.3% ± 0.2%	80.2% ± 0.3%	100% (4735 ± 765)	100% (19390 ± 2570)
TB + PRT + SSR	100% (8880 ± 1795)	97.2% ± 0.2%	79.6% ± 0.4%	100% (5630 ± 650)	100% (9920 ± 4880)
SUB + PRT + SSR	100% (7440 ± 1310)	100% (4560 ± 1730)	73% ± 0.5%	98.5% ± 1.0%	100% (5570 ± 290)




图 1. 训练曲线。一般来说，基线（橙色/蓝色）增加奖励最慢，并且比我们的提案（绿色/红色/紫色）更晚收敛或收敛到较低值。这种效应在 Six6、Bag 和 sEH 中最为明显，在 PHO4 和 QM9 中则不太明显。




图 2. SIX6，自回归 MDP。TB 基线（蓝色）在 PRT 和 SSR 下表现不佳。

模式发现与多样性。 我们确认，提高样本效率并更频繁地采样更高奖励 x 也改善了模式发现，同时保持多样性。在 sEH 中，TB 基线在主动轮次 10,000 时发现了 140 种模式，而 Sub+PRT+SSR 发现了 867 种模式（6× 更多）。在排名前 100 的奖励样本中，Tanimoto 多样性（↑ 更好）为 0.55，略高于 TB 基线的 0.517。这一结果与其他实验一致，在这些实验中，我们发现训练策略对样本多样性没有显著影响。

8 讨论

在这项工作中，我们识别了 GFlowNet 训练中匹配目标分布所面临的挑战，并在泛化、流分布和信用分配方面提供了概念理解。我们评估了三种改进 GFlowNet 训练的提议：优先回放缓冲区训练、相对边缘流参数化以及子结构引导轨迹平衡。

我们讨论了 GFlowNet（GFlowNet）评估中的挑战，并研究了在使用生化数据的基准任务上，GFlowNet 的学习行为。我们采用了 Anderson-Darling 统计量来比较 GFlowNet 采样的奖励与目标奖励分布之间的差异，以及采样均值与目标均值之间的差异。我们发现，GFlowNet 训练中的一个关键挑战在于学会避免对均值的欠采样。然而，通过使用采样的奖励进行评估，我们在精确性上做出了牺牲以换取效率。虽然匹配目标均值优于欠采样，但可以在匹配目标均值的同时 $p_\theta(x) \neq p^*(x)$ 对于所有 x 。在未来的工作中，通过对可枚举的真实世界奖励函数的 MDP 进行更彻底的比较，可能会揭示更多关于 GFlowNet 学习行为的洞见 $p_\theta(x)$ 与 $p^*(x)$ 。

我们展示了改变流分布可以显著改变泛化和训练行为，并开发了一种新型训练目标，使信用分配具有灵活控制。虽然我们基于泛化和收敛定义了一种流分布最优性的概念，但如何最好地学习有利的流分布仍是一个开放问题。

参考文献

- Andreas, J. Measuring compositionality in representation learning. In None (ed.), *International Conference on Learning Representations*, 2019. URL <https://openreview.net/forum?id=HJz05o0qK7>.
- Anonymous. Improving generative flow networks with path regularization. In *Submitted to The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=7qyLeRmle3>. under review.
- Bengio, E., Jain, M., Korablyov, M., Precup, D., and Bengio, Y. Flow network based generative models for non-iterative diverse candidate generation. In Beygelzimer, A., Dauphin, Y., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems*, 2021a. URL <https://openreview.net/forum?id=Arn2E4IRjEB>.
- Bengio, Y., Deleu, T., Hu, E. J., Lahlou, S., Tiwari, M., and Bengio, E. Gflownet foundations. *CoRR*, abs/2111.09266, 2021b. URL <https://arxiv.org/abs/2111.09266>.
- Deleu, T., Góis, A., Emezue, C., Rankawat, M., Lacoste-Julien, S., Bauer, S., and Bengio, Y. Bayesian structure learning with generative flow networks. *arXiv*, abs/2202.13903, 2022. URL <https://arxiv.org/abs/2202.13903>.
- Fedus, W., Ramachandran, P., Agarwal, R., Bengio, Y., Larochelle, H., Rowland, M., and Dabney, W. Revisiting fundamentals of experience replay. In III, H. D. and Singh, A. (eds.), *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pp. 3061–3071. PMLR, 13–18 Jul 2020. URL <https://proceedings.mlr.press/v119/fedus20a.html>.
- Jain, M., Bengio, E., Garcia, A.-H., Rector-Brooks, J., Dossou, B. F. P., Ekbote, C., Fu, J., Zhang, T., Kilgour, M., Zhang, D., Simine, L., Das, P., and Bengio, Y. Biological sequence design with gflownets. *arXiv*, abs/2203.04115, 2022. URL <https://arxiv.org/abs/2203.04115>.
- LA, B., A, V., JV, K., JM, R., SS, G., EJ, R., J, W., L, M., KH, K., S, I., T, S., L, S., R, G., N, S., C, C., T, H., S, Y., M, K., MJ, D., M, V., DE, H., and ML., B. Survey of variation in human transcription factors reveals prevalent dna binding changes. *Science*, March 2016. URL <http://web.media.mit.edu/~minsky/papers/steps.html>.
- Madan, K., Rector-Brooks, J., Korablyov, M., Bengio, E., Jain, M., Nica, A., Bosc, T., Bengio, Y., and Malkin, N. Learning gflownets from partial episodes for improved convergence and stability, 2022. URL <https://arxiv.org/abs/2209.12782>.
- Malkin, N., Jain, M., Bengio, E., Sun, C., and Bengio, Y. Trajectory balance: Improved credit assignment in gflownets. In *Advances in Neural Information Processing Systems*, volume abs/2201.13259, 2022. URL <https://arxiv.org/abs/2201.13259>.
- Minsky, M. Steps toward artificial intelligence. *Proc. IRE*, January 1961. URL <http://web.media.mit.edu/~minsky/papers/steps.html>.
- Nica, A. C., Jain, M., Bengio, E., Liu, C.-H., Korablyov, M., Bronstein, M. M., and Bengio, Y. Evaluating generalization in GFlownets for molecule design. In *ICLR2022 Machine Learning for Drug Discovery*, 2022. URL <https://openreview.net/forum?id=JFSaHKNZ35b>.
- Schaul, T., Quan, J., Antonoglou, I., and Silver, D. Prioritized experience replay, 2015. URL <https://arxiv.org/abs/1511.05952>.
- Sutton, R. S. and Barto, A. G. *Reinforcement Learning: An Introduction*. The MIT Press, second edition, 2018. URL <http://incompleteideas.net/book/the-book-2nd.html>.
- Szabó, Z. G. Compositionality. In Zalta, E. N. (ed.), *The Stanford Encyclopedia of Philosophy*. Metaphysics Research Lab, Stanford University, fall 2020 edition, 2020.
- Trabucco, B., Geng, X., Kumar, A., and Levine, S. Design-bench: Benchmarks for data-driven offline model-based optimization, 2022. URL <https://arxiv.org/abs/2202.08450>.
- Zhang, D., Malkin, N., Liu, Z., Volokhova, A., Courville, A., and Bengio, Y. Generative flow networks for discrete probabilistic modeling. *arXiv*, abs/2202.01361, 2022. URL <https://arxiv.org/abs/2202.01361>.

附录：注释

A.1 低回报过采样 x 在初始化时 使用默认的 PyTorch 神经网络初始化方法，我们发现 $P_F(s_{t+1}|s_t)$ 输出实数作为对数几率接近均匀分布。我们可以用一个简单的模型来理解这一点：假设 P_F 恰好是一个均匀分布，所有状态的动作数量完全相同 A ，并且所有轨迹的长度相同 n ：那么任何轨迹的概率是 $1/A^n$ 。很难精确地描述 $p_\theta(x)$ 在随机神经网络初始化时的熵，因为它取决于有多少轨迹结束于每个 x 在 MDP 中；表示这一项 N_x 我们可以将上述简单模型扩展，以发现初始化时，最终结束的流 x 与...成正比 N_x/A^n 。因此 $p_\theta(x)$ 具有最高熵并在 N_x 对所有情况均相同 x 然而，如果 N_x 差异显著，则 $p_\theta(x)$ 将具有更低的熵。

然而，我们注意到，使用高奖励指数（从 3 到 10）的常见做法通常会导致非常低的熵奖励分布，在实践中使得在初始化时，GFlowNet 的采样均值高于目标均值的可能性非常小。

A.2
子结构指南。我们的子结构指南使用评分函数来偏好属于 x 的子状态 s ，这些子状态在 X 中具有高奖励。

在方程 9 中，我们展示了一个简化的评分函数用于演示目的。确切的评分函数是：

$$\phi(s|x_{\text{target}}, X) = \begin{cases} \mathbb{E}_{\{x \in X \setminus \{x_{\text{target}}\} : s \in x\}} R(x), & \text{if } s \in x_{\text{target}} \\ 0, & \text{otherwise,} \end{cases} \quad (10)$$

用文字表述：分数 ϕ 对状态 s 进行评分，给定目标 x_{target} 和 X ，即训练过程中到目前为止所有已观测到的集合 x 。如果状态 s 不在目标 x 的集合 ($\in$) 中，则评分为 0（最后一行）。如果状态 s 为目标的一部分（状态 s 是目标 x 的子结构），则分数是在 X 中属于该子集的 x 上的平均奖励，其中对于该子集中的每个 x ， s 都是该 x 的子结构。此子集不包括目标：我们仅关心包含 s 的 X 中的其他 x 。

当此评分函数用于构建结束于 x_{target} 的轨迹上的引导分布时，它倾向于包含作为高奖励子结构/状态 s 的路径上的轨迹，除此之外还包括其他方面 $x \neq x_{\text{target}}$ 。

与简化方程 9 的主要区别在于，这里排除了目标 x 从集合 X 中。这将重点放在与其他共享的子结构上 x 。

一个特殊情况是没有子状态属于任何 x 在 X 中，除了目标 x ：此时所有子状态的分数为零。在这种情况下，我们将 $p(s_{t+1}|s_t)$ 设置为目标 x 子状态的均匀分布 s 。关于算法的精确描述，请参阅代码。

实现细节。我们在 CPU 上并行计算引导，观察到 GPU 模型训练没有显著的开销，代价是使用稍微过时的 X 。我们通过逐步过滤 X 来高效地采样引导轨迹，随着采样的轨迹变长：请注意，如果某个状态 s 不属于某些 x ，那么其任何后代 s 也不能属于 x 。

附录 A.3 额外的图形。




图 3. 直觉图形。(左) 多条轨迹通向相同的 x 。一个可能的生成顺序 (红色) 与首选的信用分配路径 (绿色) 不一致, 后者包含导致受体结合活性的分子子结构, 这一事实可以通过子结构 GFlowNet 通过查看其他分子 (右) 来学习。

附录 B 实验细节

我们的代码可在 <https://github.com/maxwshen/gflownet> 获取。

实现细节。我们发现将梯度范数裁剪至最大值 10.0 是有用的。我们也对策略 logit 预测进行了裁剪, 最小值为 -50.0, 最大值为 50.0。我们将 $\log Z_\theta$ 初始化为 5.0, 这小于每个环境中的真实 $x R(x)$ 。在实验中, 每一轮活跃训练中, 我们使用当前训练策略采样一个包含 16 x 的批次, 并使用该样本批次更新模型, 然后可选地执行一次回放训练更新。为了监控, 每 10 轮活跃训练中, 我们从 GFlowNet 策略 (而非训练策略) 中采样 128 x 。为了在减少样本噪声的同时评估某一轮的模型, 我们聚合了过去 500 轮的真实策略样本, 有效样本量为 6400。

子结构 gflownets 有几个设计选择。可以从训练策略中采样训练轨迹, 或者从训练策略中采样 x 并使用引导分布重新采样训练轨迹。我们发现前者在实践中表现更好, 尽管它可能会增加损失和梯度范数方差, 而限制梯度范数有助于解决这一问题。方程 5 中的混合权重, α , 是另一个选择。我们发现一般优选 $\alpha = 1$, 这消除了 P_B 项, 仅关注引导似然项。

对于优先级回放训练, 我们专注于按奖励排名的前 10%, 并在其中随机抽样作为批次的 50%, 其余批次由排名较低的 90% 组成。

袋。 ($|\mathcal{X}| \approx 100$ B) 大小为 13 的多重集, 包含 7 个不同的元素。基础奖励为 0.01。如果袋中包含任何字母的 7 次或更多重复, 则视为具有“子结构”, 此时有 75% 的概率获得 10 的奖励, 否则获得 30 的奖励。在这个马尔可夫决策过程中, 动作是向袋中添加一个元素。由于这是一个构造设置, 我们使用了一个小型神经网络策略, 包含两层各 16 个隐藏单元。我们使用的探索 epsilon 值为 0.10。


SIX6 (TFBind8). ($|\mathcal{X}| = 65,536$) 长度为 8 的核苷酸字符串。奖励是通过湿实验室测量的人类转录因子 SIX6 的 DNA 结合活性, 数据来源为 (LA 等, 2016 年; Trabucco 等, 2022 年)。遵循 (Jain 等, 2022 年), 我们使用了奖励指数 3。虽然通常会使用自回归马尔可夫决策过程来处理字符串, 但为了与子结构引导进行比较, 后者仅在生成型马尔可夫决策过程中有意义, 即每个 x 有多条轨迹, 我们使用了序列前置/后置马尔可夫决策过程。我们使用了一个包含两层各 128 个隐藏单元的神经网络, 并设探索 epsilon 值为 0.01。

($|\mathcal{X}| = 1,048,576$) 由实验室测量的 DNA 结合活性与酵母转录因子 PHO4 相关的 10 核苷酸字符串 (LA 等, 2016; Trabucco 等, 2022)。本文采用奖励指数为 3, 并将奖励缩放至最大值 10。本文使用具有三层 512 个隐藏单元的神经网络, 探索 ϵ 值为 0.01。

QM9. ($|\mathcal{X}| = 58,765$) 小分子图。奖励来自代理神经网络预测从密度泛函理论得出的 HOMO-LUMO 间隙。本文采用奖励指数为 5，并将奖励缩放至最大值 100。本文使用 12 个构建块，每个构建块有 2 个茎，每分子生成 5 个构建块。由于所有构建块都有两个茎，我们将 MDP 视为序列前置/后置 MDP。通常，图构建块上的茎位置不对称，因此奖励对字符串反转不具有不变性。本文使用具有两层 1024 个隐藏单元的神经网络，探索 ϵ 值为 0.10。本文使用 1 - Tanimoto 相似性来衡量多样性。

sEH. ($|\mathcal{X}| = 34,012,224$) 小分子图。奖励来自训练以预测与可溶性环氧化物水解酶结合亲和力的代理模型。具体而言，我们在整个空间的 $\mathcal{X}$ 上训练了一个梯度增强回归器，基于代理模型提供的图神经网络预测 (Bengio 等, 2021a)，目标是记忆该模型。我们的代理模型实现了均方误差 0.375，皮尔逊相关系数 0.905。本文采用奖励指数为 6，小于先前工作使用的 10，并将奖励缩放至最大值 10。本文使用 18 个构建块，每个构建块有 2 个茎，每分子使用 6 个构建块。由于所有构建块都有两个茎，我们将 MDP 视为序列前置/后置 MDP。通常，图构建块上的茎位置不对称，因此奖励对字符串反转不具有不变性。本文使用具有两层 1024 个隐藏单元的神经网络，探索 ϵ 值为 0.05。本文定义模式为按 $R(x)$ 排名的 $\mathcal{X}$ 的前 0.5%。本文使用 1 - Tanimoto 相似性来衡量多样性。

B.1 Anderson-Darling 统计量。在图 B.1 中，本文描绘了 GFlowNet 样本与目标分布之间的 Anderson-Darling 统计量关系，以及 GFlowNet 采样均值与目标均值之间的相对误差。



C 附录：证明

在本节中，本文在一个简化但具代表性的设置下研究了各种 GFlowNet 学习目标的信用分配行为。

C.0.1 定义

定义 C.1. (序列前置/后置 MDP)。序列前置/后置 MDP 是一种 MDP，在这种 MDP 中， s_0 为空字符串，状态对应于字符串，动作是在某个离散字母表中前置或后置一个符号， $\mathcal{A}$ to a 字符串。我们认为此马尔可夫决策过程 (MDP) 仅生成长度为 x 的字符串 n ，即退出动作仅在与长度为 n 的字符串相对应的状态下发生，并且在这些状态下只有退出动作可用。

备注 5. 虽然简单，这代表了许多通过组合子部分来构建复合对象的马尔可夫决策过程 (MDP)，例如通过将新节点连接到现有节点来构建图（通常随着图的扩大， > 2 插入点也会增加）。

定义 C.2. (表格化 GFlowNet，带有轨迹流参数化)。表格化 GFlowNet 使用表格来存储流网络。我们考虑轨迹流参数化，其中轨迹流 $F: \mathcal{T} \rightarrow \mathbb{R}_{\geq 0}$ 被存储为一张表格。与函数逼近设置不同，更新表格中的任何条目都不会改变其他条目。我们假设所有轨迹流 $F(\tau)$ 均初始化为一个小的正常数 ϵ 。轨迹流 $F(\tau)$ 通过 y 更新为 $F(\tau) \leftarrow F(\tau) + \lambda(y - F(\tau))$ ，其中步长为 $0 < \lambda \leq 1$ 。

备注 6. 表格设置历来被用于开发、激励和研究强化学习算法的性质 (Sutton & Barto, 2018)。请注意，轨迹流参数化在实践中效率低下，因为计算单个状态的 P_F 可能需要对指数级多的轨迹求和。然而，它对于理论分析来说是一个有用的参数化。

定义 C.3. (设置 A)。该设置包含一个序列前置/后置 MDP，以及一个固定数据集 $\{x, x'\}$ ，每个长度为 n ，其中 $R(x) = R(x')$ 。令 s^* 表示由 x, x' 共享的最长字符串，其长度为 $k < n$ ：即不存在长度为 $k+1$ 且被两者共享的字符串 x, x' 。令 $s_k(x)$ 表示某些字符串的 k -长度子串集合 x 。

注释 7. 在此设置下，每条轨迹都是长度为 $(0, 1, 2, \dots, n)$ 的字符串序列，因此每条轨迹恰好包含每个 $k \leq n$ 的一个长度为 k 的子串。结果，结束于 x 的轨迹必须经过要么是 s^* （共享子串）或者某个子串 $s' \in s_k(x)$ （非共享子串）。我们的分析将关注各种学习目标如何分配流向 $F(s^*)$ 与流向 $F(s_k(x) \setminus s^*)$ 的信用分配行为。

C.0.2 属性

我们现在陈述关于设置 C.3 的各种属性。

属性 1. (每个都有指数级多的轨迹 x)。在序列前置/后置 MDP 中，存在 2^{n-1} 以特定字符串结尾的轨迹 x 其长度为 n 。

证明。为了构建一个长度为 n 的字符串 s ，我们可以选择一个初始零基索引 i 作为我们的第一个字符，然后我们可以按照任意顺序执行 i 次前置操作和 $n-i-1$ 次后置步骤。存在 $n-1$ choose i ($\binom{n-1}{i}$) 种这样的前置和后置操作序列。通过对 i 的选择进行求和，这可以被视为对帕斯卡三角形的一行求和，存在这些轨迹。□

注释 8. 此属性展示了设计一个对于每个 x 具有指数级多条轨迹的 MDP（马尔可夫决策过程）的“容易”程度。请注意，自回归且仅追加的 MDP 对于每个 x 恰好具有一条轨迹。序列前置/追加的 MDP 有两个“插入点”，即可以添加新内容的位置，并且对于每个 x 具有指数级多条轨迹。一般来说，通过组合构建块来构造对象的 MDP 可能会有许多插入点。不具有特定插入位置的 MDP，如集合，也至少对于每个 x 具有指数级多条轨迹。

性质 2. (通过某一状态的轨迹数量 s 对某些 x)。在序列前置/后置 MDP 中，假设长度为 k 的 s 前面有 a 个字符在长度为 n 的 x 中。有 $\binom{n-k}{a}$ 条轨迹经过以...结束

s x .

证明。从根节点到 s 有 2^{k-1} 条轨迹（性质 1）。存在 $\binom{n-k}{a}$ 种不同的动作序列，对应于不同顺序的前置和后置操作，从 s 开始并结束于 x 。因此，总共存在 $\binom{n-k}{a}2^{k-1}$ 条经过 s^* 并最终到达 x 的轨迹。 $\square$

性质 3. 均匀轨迹流分布 $\iff$ 前后一致的策略。在一个序列前置/后置 MDP 中，流动具有均匀的轨迹分布 $F(\tau)$ 当且仅当 P_F 并且 P_B 在每个状态下都是均匀的。

证明。（均匀轨迹流分布 $\implies$ 均匀的正向和反向策略）

设均匀 $F(\tau) = \epsilon$ 。回忆起 $F(s, s') = \sum_{\tau \in \mathcal{T}: (s, s') \in \tau} F(\tau)$ 。假设 s 的长度为 k ，因此 s' 的长度为 $k+1$ 。根据性质 1，从 s_0 到 s 有 2^{k-1} 条轨迹，从 s' 到任何长度为 n 的字符串有 2^{n-k-1} 条轨迹，总共通过边 $s \rightarrow s'$ 的轨迹数为 2^{n-2} 。利用 $F(\tau) = \epsilon$ ，对于任何长度为 k 的 s 和长度为 $k+1$ ， $F(s, s') = 2^{n-2}\epsilon$ 的 s' ，我们有

在任何对应于长度为 k ， P_F 的字符串的状态下，只有长度为 $k+1$ 的字符串分布，以及 P_B 对应于 $k-1$ ，因为 MDP 总是在每次动作中添加一个字符。由于 P_F 和 P_B 以与边流成比例的概率进行采样，并且每条边的边流相同，因此 P_F 和 P_B 是均匀的。 $\square$

证明。（均匀轨迹流分布 $\impliedby$ 均匀的正向和反向策略）

任何轨迹 $\tau = (s_0, s_1, \dots, s_n)$ 都是一个长度为 $(0, 1, 2, \dots, n)$ 的字符串序列。我们首先考虑正向策略。请注意，在 s_0 处，有 $|\mathcal{A}|$ 动作/子节点，对应于添加字母表中的每个字母 $\mathcal{A}$ 。对于任何长度为 1 到 $n-1$ 的字符串，有 $2|\mathcal{A}|$ 动作/子节点。对于任何长度为 n 的字符串，只有一个动作（退出）。利用这一点，我们有对于任何 τ ，

$$p(\tau) = P_F(s_1|s_0) \prod_{t=1}^{n-1} P_F(s_{t+1}|s_t) \quad (11)$$

$$= \frac{1}{|\mathcal{A}|} \prod_{t=1}^{n-1} \frac{1}{2|\mathcal{A}|}. \quad (12)$$

由于这不依赖于状态 τ ，我们有 $p(\tau) = p(\tau')$ 对于任何轨迹 $\tau, \tau' \in \mathcal{T}$ 。请注意 $F(\tau) = Zp(\tau)$ 。

反向策略情况类似，利用每个长度从 2 到 n 的字符串有 2 个父节点这一观察结果。 $\square$

附录 C.0.3 最大熵 GFLOWNETS

回忆最大熵学习目标是学习 P_F^θ

使用轨迹平衡约束：

$$Z_\theta \prod_{t=0}^{n-1} P_F^\theta(s_{t+1}|s_t) = R(x) \prod_{t=0}^{n-1} P_B(s_t|s_{t+1}) \quad (13)$$

对于一个结束于 x 的轨迹 τ 。最大熵目标将 $P_B(s_{t-1}|s_t)$ 设定为均匀分布。轨迹平衡约束是对更简单的细致平衡约束进行代数操作的结果，

$$F(s)P_F(s_{t+1}|s_t) = F(s_{t+1})P_B(s_t|s_{t+1}) \quad (14)$$

这将细致平衡约束贯穿于整个轨迹之中。其他约束可以通过扩展链条至部分轨迹来推导。请注意，当所有 $R(x)$ 已知时，均匀 P_B 的轨迹平衡约束完全确定了 $P_F(s_{t+1}|s_t)$ 。

定理 C.4. (最大熵 GFlowNets 将最小的信用归因于共享子结构)。 在设置 C.3 下, 假设 GFlowNet 使用最大熵学习目标进行训练。那么, 在全局极小值处,

$$\mathbb{E} \left[\frac{F(s^*)}{F(s_k(x) \setminus s^*)} \right] = \Theta \left(\frac{1}{n-k} \right) \quad (15)$$

在 s^* 于 x, x' 中的均匀随机位置上。

注释 9。 由于所有通往 x 的轨迹必须经过共享子串 s^* (长度为 k) 或 $s_k(x) \setminus s^*$ 中的非共享子串, 对 $x, r(x)$ 的信用分配可以通过分配给 s^* 与 $s_k(x) \setminus s^*$ 的流量或奖励来评估。该定理表明, 少数信用被分配给 s^* , 并且它随着 $n-k$ 线性减少。

证明。由于均匀的反向策略会在连接 x 到根节点的轨迹上诱导出均匀的轨迹分布 (属性 3), 并且有 2^{n-1} 条这样的轨迹 (属性 1), 每条以 x 结尾的轨迹具有轨迹流量 $r(x)/2^{n-1}$ 。根据属性 2, 有 $\binom{n-k}{a} 2^{k-1}$ 条通过 s^* 并结束于 x 的轨迹。乘以每条轨迹上的流量, 通过 s^* 并仅结束于 x 的总流量是

$$\frac{\binom{n-k}{a} 2^{k-1} R(x)}{2^{n-1}}. \quad (16)$$

在 a 上的均匀分布下的平均轨迹数, 其范围从 0 到 $n-k$, 是:

$$\frac{1}{n-k+1} \sum_{a=0}^{n-k} \binom{n-k}{a} = \frac{2^{n-k}}{n-k+1} = \mathbb{E}_a \left[\binom{n-k}{a} \right] \quad (17)$$

因此, 在 s^* 于 x 中的均匀随机位置下, 通过 s^* 并仅结束于 x 的预期流量是:

$$\mathbb{E}_a \left[\frac{\binom{n-k}{a} 2^{k-1} R(x)}{2^{n-1}} \right] = \frac{R(x)}{n-k+1} \quad (18)$$

从 s^* 到两个 x, x' 的总预期流量是 $\frac{R(x)+R(x')}{n-k+1}$, 而通过 $s_k(x) \setminus s^*$ 的总预期流量是 $\frac{(n-k)R(x)}{n-k+1}$ 。当 $R(x) = R(x')$ 时, 比率是 $2/(n-k)$, 其缩放为 $\Theta(1/(n-k))$ 。

□

注释 10。 在一个集合 MDP 中, 类似的论证表明, 通过集合 s^* 的流量占所有大小为 k 的子集流量的比例为 $\Theta(1/k)$ 。

C.0.4 轨迹平衡 GFlowNet

轨迹平衡学习目标更难分析, 因为它有许多全局最小值, 这些最小值是由一个自我修改的学习过程达到的, 在这个过程中, 每一步 GFlowNet 策略生成样本 x , 这些样本被用来更新策略。

定义 C.5. (轨迹平衡训练过程: 固定数据集, 表格 GFlowNet 设置)。

这个定义基于设置 C.3 以及表格 GFlowNet 的定义 (定义 C.2)。我们假设所有轨迹流的初始值 ϵ 足够小, 并且 $R(x)$ 足够大, 使得在初始化时,

$$F_{\text{init}}(x) < R(x). \quad (19)$$

我们考虑进行 m 步训练, 学习率为 λ 。在每次训练步骤中, 我们执行以下操作:

1. 根据当前 GFlowNet 策略采样一条以 x 或 x' 结尾的轨迹 τ 。根据我们的表格轨迹流参数化，我们认为这是通过按比例于其流量的概率从所有以 x, x' 结尾的轨迹中采样来完成的（参见备注 12）。

2. 根据轨迹平衡学习目标更新 GFlowNet。我们更新 $F(\tau) \leftarrow F(\tau) + \Delta$ ，其中我们将 $\Delta = \lambda(R(x) - F_{\text{init}}(\tau))$ 标记为正的、常数的流量更新。

若 $\lambda = 2/m$ ，则在对 x 和 x' 进行了恰好 $m/2$ 次训练步骤后，我们有 $F(x) = R(x)$ 和 $F(x') = R(x')$ 。

注释 11. 此训练流程与标准 GFlowNet 主动学习框架 (Bengio 等, 2021a) 密切相关。要求每个轨迹均以 x 固定数据集也在反向轨迹数据增强训练过程中使用，该过程见 (Zhang 等, 2022; Jain 等, 2022)。这种设置概念上等同于标准主动学习 $R(x)$ 具有在任何情况下学习的性质 $x'', R(x'')$ 对于 $x'' \notin X$ 对学习到的流网络的影响可以忽略不计。请注意，该训练程序在表格形式的 GFlowNet 中完全支持状态和轨迹，其中所有轨迹流都被初始化为一个小的正常数。

注释 12. (非马尔可夫轨迹采样)。当每条轨迹具有单独的表格流值时，按其流量比例采样轨迹会诱导出一种非马尔可夫轨迹分布，这种分布作为标准 GFlowNet 过程的一种放松形式，在该过程中，轨迹是根据马尔可夫策略 P_F 或 P_B 进行采样的。从理论上分析，这一简化假设确保了“表格独立性”的原则在轨迹采样中得到遵守——改变某些轨迹的流量 τ 不会改变采样其他任意两条轨迹之间的相对似然比 τ', τ'' 。

* * *

定理 C.6. (轨迹平衡倾向于减少对共享子结构的信用) 在设置 C.3 中，假设 GFlowNet 根据步骤 C.5 进行轨迹平衡训练。令 t 表示训练步数。在任意训练步数 t 处，如果

$$\frac{F_{t-1}(s^*)}{\mathbb{E}_{s \sim s_k(x) \setminus s^*}[F_{t-1}(s)]} < n - k \quad (20)$$

成立（其中期望是在集合上的均匀分布），那么训练轨迹上的预期学习更新为：

$$\mathbb{E}_{\tau} [F_t(s^*)] - F_{t-1}(s^*) < \mathbb{E}_{\tau} [F_t(s_k(x) \setminus s^*)] - F_{t-1}(s_k(x) \setminus s^*). \quad (21)$$

注释 13. 该命题指出，在任何情况下，除非 $F(s^*)$ 支配 $F(s)$ 对于任何 s 不是共享的 k -长度子串，每个轨迹平衡训练步骤倾向于增加非共享子串的流量多于 s^* 。

证明。回忆以下定义： s^* 是在 x, x' 之间共享的最长子串，其长度为 k 。集合 k 长度的字符串在 x 中表示为 $s_k(x)$ ，共有 $n - k + 1$ 个这样的字符串。

由于从 x 到 s_0 的任何轨迹都必须通过 $s_k(x)$ 中的恰好一个字符串，并且状态流被定义为通过该状态的所有轨迹的总流量之和，因此采样通过 s^* 的轨迹的概率为

$$p(s^*) = \frac{F(s^*)}{F(s_k(x))} = \frac{F(s^*)}{\sum_{s \in s_k(x)} F(s)}. \quad (22)$$

假设 $F_{t-1}(s^*) < F_{t-1}(s_k(x) \setminus s^*)$ 。利用 $s_k(x) \setminus s^*$ 中有 $n - k$ 个元素这一事实，这个条件等价于方程 20。这意味着

$$p_{t-1}(s^*) < p_{t-1}(s_k(x) \setminus s^*).$$

请注意，从一个训练步骤预期增加的流量为：

$$\mathbb{E}_{\tau} [F_t(s^*)] - F_{t-1}(s^*) = \Delta p_{t-1}(s^*) \quad (23)$$

$$\mathbb{E}_{\tau} [F_t(s_k(x) \setminus s^*)] - F_{t-1}(s_k(x) \setminus s^*) = \Delta p_{t-1}(s_k(x) \setminus s^*) \quad (24)$$

Using $p_{t-1}(s^*) < p_{t-1}(s_k(x) \setminus s^*)$, 我们得到了我们的命题。 $\square$

* * *

当轨迹根据其流量而不是马尔可夫策略进行采样时，“强者愈强”的性质可以通过波利亚坛模型来理解。

定理 C.7。（轨迹平衡训练作为 Pólyaurn 模型）。 在设置 C.3 中，假设 GFlowNet 按照步骤 C.5 进行轨迹平衡训练。经过 m 个训练步骤后，我们有：

$$p\left(\frac{F_{final}(s^*) - F_{init}(s^*)}{F_{final}(s_k(x, x')) - F_{init}(s_k(x, x'))} > \psi\right) \leq \quad (25)$$

$$1 - \text{BetaBinomialCDF}\left(\psi m; n = m, \frac{\alpha}{\alpha + \beta} = \frac{e}{\pi\sqrt{n-k}}, \alpha + \beta = \frac{\epsilon 2^{n-1}}{\Delta}\right) \quad (26)$$

for $\frac{e}{\pi\sqrt{n-k}} \leq \psi \leq 1$ and $n - k \geq 3$.

备注 14。 Pólyaurn 模型的一个结果是，在训练过程中分配给总流量的比例通过 s^* 的部分遵循 beta-二项式分布。由于每次训练步骤增加的流量是一个常数，这个比例等于“富者愈富”训练过程中通过 s^* 采样的轨迹的比例。

证明。Pólya 鸡尾酒模型如下应用：我们在瓶中放置每种颜色的小球，对应于在 x, x' 中出现的长度为 k 的子串，其中我们回忆一下， s^* 是唯一一个同时出现在两个 x, x' 中的长度为 k 的子串。因此，共有 $2(n-k)+1$ 种颜色。我们将长度为 k 的子串集合记作 $s_k(x, x')$ ，这些子串出现在 x, x' 中。在每次训练步骤中，我们采样一个轨迹 τ ，该轨迹以其中一个状态结束 x, x' ，并且必须恰好通过一个状态 $s \in s_k(x, x')$ ，其概率与之成正比 $F(s)$ ；在波利亚罐模型中，这相当于从罐中按颜色采样一个球 c 。然后，我们沿着路径增加流量 τ 。由于表格化轨迹流参数化以及在 C.5 中假设的表格化轨迹采样，此增加步骤不会改变通往其他状态的流量 $s_k(x)$ 。在波利亚罐模型中，这相当于向罐中添加一个具有特定颜色的球 c 。

从 Pólyaurn 中抽取的球的颜色分布，在经过 m 步之后，遵循 Dirichlet-多项式分布。因为我们只关心 s^* 相对于 $s_k(x, x') \setminus s^*$ 的情况，我们可以将其简化为两种颜色，这遵循 Beta-二项式分布。我们将‘白球’标记为 s^* ，‘黑球’标记为 $s_k(x, x') \setminus s^*$ 。

在初始化时，对于 s^* 的白球数量由 $F(s^*|x, x')$ 决定，这取决于它在 x 和 x' 中的位置（属性 2）。我们对 $F(s^*|x)$ 应用一个上限来消除这种依赖关系，这将使我们能够同等对待 x, x' 并简化我们的解释。

回忆 a 表示在 x 中有多少字符位于 s^* 之前。我们使用上界（参见引理 C.8）：

$$\max_{0 \leq a \leq n-k} \binom{n-k}{a} \leq \frac{e 2^{n-k}}{\pi\sqrt{n-k}}. \quad (27)$$

对于某些 $\hat{x}$ 在 $\{x, x'\}$ 中，回忆一下有 2^{n-1} 条轨迹以 $\hat{x}$ 结束。我们将通过结束于 s^* 的 $\hat{\mathcal{U}}$ 来上界这些轨迹的数量：

$$\binom{n-k}{a} 2^{k-1} \epsilon \leq \frac{e 2^{n-k}}{\pi\sqrt{n-k}} 2^{k-1} \epsilon \quad (28)$$

由于两个 x, x' 长度相同，并且 s^* 是唯一一个在 x 和 x' 中的 k 长度子串，具有 s^* 的轨迹比例的上界对于 x 和 x' 是相等的。这对应于一个“上界”的 Pólya 罐模型，其中具有 s^* 并以 x 或 x' 结尾的轨迹的白球数量与 28 成正比，而任何其他以 x 或 x' 结尾的轨迹的黑球数量与 2^{n-1} 成正比。我们继续使用这个上界的 Pólya 罐进行分析。

我们现在求解用于建模罐抽取的 beta-二项分布的参数。令 α 表示 s^* 初始的白球数量。因为“一个球”是 Δflow ,

$$\alpha = \frac{e2^{n-k}}{\pi\sqrt{n-k}} \frac{2^{k-1}\epsilon}{\Delta} \quad (29)$$

类似地，令 $\alpha + \beta$ 表示初始总球数。

$$\alpha + \beta = (2^{n-k}) \frac{2^{k-1}\epsilon}{\Delta} \quad (30)$$

当 $n - k = 3$ 时，我们有 $\frac{\alpha}{(\alpha+\beta)} = \frac{e}{\pi} \frac{e}{n-k} = 0.499555773$ ，这是归一化贝塔二项分布限制在 0 和 1 之间的均值。由于贝塔二项分布的均值和方差在 $\alpha/(\alpha + \beta) = 0.5$ 时最大，并且随着 $\alpha/(\alpha + \beta)$ 从 0.5 以下减小而减少，对于任何阈值 ψ 大于或等于均值 $\alpha/(\alpha + \beta)$ 的情况，我们的上限贝塔二项分布在大于 ψ 的累积概率密度上比任何具有较小均值的贝塔二项分布更大。因此，我们的上限贝塔二项分布满足命题中的界限。

□

* * *

引理 C.8. (帕斯卡三角形中最大元素的上界)。

For any natural number n ,

$$\max_{0 \leq a \leq n} \binom{n}{a} \leq \frac{e2^n}{\pi\sqrt{n}}. \quad (31)$$

$\binom{n}{0}, \binom{n}{1}, \dots, \binom{n}{n}$ 证明。注意到级数 $\binom{n}{0}$ 对应帕斯卡三角形的一行。首先，考虑当 n 为偶数的情况。此时， $\binom{n}{a}$ 在 $a = n/2$ 时达到最大值。因此，我们需要找到一个上界来限制 $\binom{n}{n/2}$ 。我们使用斯特林近似公式：

$$\binom{n}{n/2} \leq \frac{n!}{(\frac{n}{2}!)^2} \quad (32)$$

$$\leq \frac{en^{n+\frac{1}{2}}e^{-n}}{(\sqrt{2\pi}(\frac{n}{2})^{\frac{n+1}{2}}e^{-n/2})^2} \quad (33)$$

经过代数变形，我们得到

$$\binom{n}{n/2} \leq \frac{e2^n}{\pi\sqrt{n}} \quad (34)$$

现在，考虑当 n 为奇数的情况。此时， $\binom{n}{a}$ 在 a 取 $n/2$ 向上或向下取整时达到最大值。这对应于 $\binom{n}{\frac{n+1}{2}}$ ，我们注意到它等于 $\binom{n}{\frac{n-1}{2}}$ 。根据帕斯卡三角形的递推关系，我们有

$$\binom{n}{\frac{n+1}{2}} + \binom{n}{\frac{n-1}{2}} = \binom{n+1}{\frac{n+1}{2}} \quad (35)$$

$$\binom{n}{\frac{n+1}{2}} = \frac{1}{2} \binom{n+1}{\frac{n+1}{2}}. \quad (36)$$

对偶数情况应用相同的上限策略到 $\left(\frac{n+1}{2}\right)$, we get

$$\binom{n}{\frac{n+1}{2}} \leq \frac{1}{2} \frac{e2^{n+1}}{\pi\sqrt{n+1}} \quad (37)$$

$$\leq \frac{e2^n}{\pi\sqrt{n+1}} \quad (38)$$

由于这个上限小于 $\frac{e2^n}{\pi\sqrt{n}}$ 的上限, 无论 n 是奇数还是偶数, 都可以应用该界限。 $\square$

附录 C.0.5 子结构 GFlowNets

定理 C.9. (子结构 GFlowNets 将信用归因于共享子结构)。在设置 C.3 中, 假设 GFlowNet 作为子结构 GFlowNet 进行训练。那么, 在学习到的马尔可夫策略上的全局最小值处 P_B, P_F ,

$$F(s^*) = R(x) + R(x'), \quad (39)$$

$$F(s_k(x) \setminus s^*) = 0. \quad (40)$$

证明。由于 s^* 是唯一一个在 x, x' 中都存在的长度为 k 的子串, 所有以 x, x' 结尾并由结构感知引导分布采样的轨迹必须包含 s^* 。当 P_B 在匹配引导分布时达到全局最小值, 它也将具有这一性质, 因为这一性质是马尔可夫的: 对于任何连接到 s^* 的长度为 $k+1$ 的 s_{k+1} , 都有 $P_B(s^*|s_{k+1}) = 1$ 。因此, 当 P_F 达到全局最小值时, 它必须将所有从 $R(x), R(x')$ 通过 s^* 的流量分配出去。 $\square$

注记 15。在实践中, 可能不将所有信用分配给 $R(x), R(x')$ 单个子串 s^* 更为可取; 在某些情况下, 这可能对应于过拟合。其他信用分配可以通过其他引导分布设计轻松实现, 或将子结构 GFlowNet 引导分布与均匀引导分布混合。