

生成流网络与变分推断

Nikolay Malkin*, Salem Lahlou*, Tristan Deleu*
Mila, Université de Montréal

Xu Ji, Edward Hu
Mila, Université de Montréal

Katie Everett
Google Research

Dinghuai Zhang
Mila, Université de Montréal

Yoshua Bengio
Mila, Université de Montréal, CIFAR

摘要

本文在两类概率算法之间建立了联系：（层级）变分推断（VI），通常用于建模连续空间上的分布，以及生成流网络（GFlowNets），已被应用于图等离散结构上的分布。我们展示了，在某些情况下，VI 算法与 GFlowNets 的特例在学习目标预期梯度相等的意义上是等价的。然后，我们指出了这两类算法之间的差异，并通过实验展示了这些差异是如何产生的。值得注意的是，借鉴了强化学习思想的 GFlowNets 比 VI 更易于进行不依赖策略的训练，而无需承担由重要性采样引起的高梯度方差的成本。我们认为，GFlowNets 的这一特性可以为其捕捉多模态目标分布中的多样性提供优势。代码：

https://github.com/GFNOrg/GFN_vs_HVI。

1 引言

许多概率生成模型通过一系列随机选择来产生样本。非神经潜变量模型（例如 Blei 等人，2003 年），自回归模型，层级变分自编码器（Sønderby 等人，2016 年），以及扩散模型（Ho 等人，2020 年）可以说都依赖于一个共同的原则：通过将一系列简单动作链接起来，其条件分布易于描述，可以比单步采样生成更丰富的分布。当许多中间采样变量能够生成相同的对象，使得精确似然计算不可行时，层级模型会使用涉及采样序列后验的概率目标进行训练（Ranganath 等人，2016b）。

本文将变分推断（VI）方法应用于层级模型（即通过一系列条件选择进行采样）与新兴的研究领域生成流网络（GFlowNets；Bengio 等，2021a）相连接。GFlowNets 被定义为一种强化学习（RL）算法——具有状态、动作和奖励——通过一系列动作构建对象，使得生成对象的边缘似然与其奖励成正比。虽然层级 VI 通常用于实值对象上的分布，但 GFlowNets 在近似离散结构上的分布方面取得了成功，这些结构的精确采样是不可行的，例如分子发现（Bengio 等，2021a）、贝叶斯后验因果图（Deleu 等，2022）或作为基于能量模型的近似最大似然训练的摊销学习采样器（Zhang 等，2022b）。尽管 GFlowNets 似乎有着不同于层级 VI 算法的基础（Bengio 等，2021b）和应用，但我们在此展示了两者之间存在紧密联系。

作为我们的主要理论贡献，我们证明了变分算法和 GFlowNets 的特殊情况在其期望梯度上是一致的。特别是，层级 VI（Ranganath 等，2016b）和嵌套 VI（Zimmermann 等，2021）与 GFlowNets 的轨迹平衡和细致平衡目标（Malkin 等，2022；Bengio 等，2021b）相关。我们也指出了 VI 和 GFlowNets 之间的差异：值得注意的是，GFlowNets 自动执行梯度方差缩减，通过估计一个边缘量（配分函数）作为基线，并允许无需重新加权的重要性采样的离策略学习。

我们的理论结果伴随有实验，这些实验考察了当将分层 VI 算法应用于离散问题时，GFlowNets *Equal 所做出的贡献中出现的相似性和差异性。联系人：nikolay.malkin@mila.quebec

之前已被使用过。这些实验有两个目的。首先，它们提供了一个缺失的分层变分推断基线，用于那些在以往工作中已应用 GFlowNets 的问题。该基线的相对性能展示了 VI 与 GFlowNets 之间的上述相似性和差异性。其次，这些实验展示了 GFlowNets 的能力，即从离策略分布中学习而不引入高梯度方差，这是分层变分推断所不具备的。我们展示了这种利用探索性的离策略采样的能力在离散概率建模任务中有益，尤其是在目标分布具有许多模式的情况下。

2 理论结果

2.1 GFlowNets: 符号和背景

我们考虑 Bengio 等人 (2021a) 的研究设定。给定一个带有基点的¹ 有向无环图 (DAG) $\mathcal{G} = (\mathcal{S}, \mathcal{A})$ ，其中 $\mathcal{S}$ 是有限个顶点 (状态) 的集合，并且 $\mathcal{A} \subset \mathcal{S} \times \mathcal{S}$ 是一组有向边 (动作)。如果 $s \rightarrow s'$ 是一个动作，我们说 s 是 s' 的父类于 s' 和 s' 是 s 的子代。恰好存在一个没有入边的状态，称为初始状态 $s_0 \in \mathcal{S}$ 。没有出边的状态被称为终止状态。我们用 $\mathcal{X}$ 表示终止状态的集合。一个完整的轨迹是一个序列 $\tau = (s_0 \rightarrow \dots \rightarrow s_n)$ 使得每个 $s_i \rightarrow s_{i+1}$ 都是一个动作，并且 $s_n \in \mathcal{X}$ 。我们用 $\mathcal{T}$ 表示完整轨迹的集合，并用 x_τ 表示完整轨迹的最后一个状态 τ 。

GFlowNets 是一类模型，通过学习目标分布的函数近似来摊销从不可计算的目标分布 $\mathcal{X}$ 中采样的成本，该函数近似基于其未归一化的密度或奖励函数， $R: \mathcal{X} \rightarrow \mathbb{R}^+$ 。尽管存在不同的参数化和损失函数，但所有的 GFlowNets 都定义了一个前向转移概率函数，或者说是前向策略 $P_F(-|s)$ ，这是一个关于每个状态 $s \in \mathcal{S}$ 的子节点分布。前向策略通常由一个神经网络参数化，该网络以状态 s 的表示作为输入，并生成其子节点分布的对数几率。任何前向策略 P_F 都会诱导一个关于完整轨迹的分布 $\tau \in \mathcal{T}$ (同样记为 P_F)，这进而定义了一个关于终止状态的边缘分布 $x \in \mathcal{X}$ (同样记为 $P_F^\top$):

$$P_F(\tau = (s_0 \rightarrow \dots \rightarrow s_n)) = \prod_{i=0}^{n-1} P_F(s_{i+1} | s_i) \quad \forall \tau \in \mathcal{T}, \quad (1)$$

$$P_F^\top(x) = \sum_{\tau \in \mathcal{T}: x_\tau = x} P_F(\tau) \quad \forall x \in \mathcal{X}. \quad (2)$$

给定一个前向策略 P_F ，终止状态 $x \in \mathcal{X}$ 可以从 $P_F^\top$ 中采样。通过采样轨迹 τ 来自 $P_F(\tau)$ 并取其最终状态 x_τ 。

GFlowNets 旨在找到一个前向策略 P_F ，对于该策略 $P_F^\top(x) \propto R(x)$ 。由于公式 (2) 中的求和通常难以精确计算，GFlowNets 的训练目标引入了辅助对象到优化过程中。例如，轨迹平衡目标 (TB; Malkin 等, 22 年) 引入了一个辅助后向策略 P_B ，这是一个学习分布 $P_B(-|s)$ ，覆盖状态集合 $\mathcal{S}$ 中的每个状态 s 的父节点，并估计出一个分区函数 Z ，通常参数化为 $\exp(\log Z)$ ，其中 $\log Z$ 是学习参数。对于完整的轨迹 τ ，TB 目标定义为

$$\mathcal{L}_{\text{TB}}(\tau; P_F, P_B, Z) = \left(\log \frac{Z \cdot P_F(\tau)}{R(x_\tau) P_B(\tau | x_\tau)} \right)^2, \quad (3)$$

其中 $P_B(\tau | x_\tau) = \prod_{(s \rightarrow s') \in \tau} P_B(s | s')$ 。如果对于每个完整的轨迹 $\tau \in \mathcal{T}$ ，对所有 τ ，then $P_F^\top(x) \propto R(x)$ 和 $x \in \mathcal{X}$ ，令其等于 0，并且 Z 是比例常数的逆： $Z = \sum_{x \in \mathcal{X}} R(x)$ 。

目标函数 (3) 通过从某个分布采样轨迹 τ 并针对参数 P_F, P_B 和 $\log Z$ 对 (3) 进行梯度步进来最小化。从其中采样的分布 τ 相当于为在所有 $\tau \in \mathcal{T}$ 上最小化 (3) 的多目标问题选择标量化权重。如果 τ 是从 $P_F(\tau)$ 中采样的——请注意，这是一种非平稳标量化——我们说算法在线运行。如果 τ 是从另一个分布中采样的，则算法离线运行；典型的选择是从 P_F 的温控版本中采样 τ 以鼓励探索 (Bengio 等, 2021a; Deleu 等, 2022)，或者从给定终止状态 x 开始的反向策略 $P_B(\tau|x)$ 中采样 τ (Zhang 等, 2022b)。类比于强化学习的命名法，我们将用于获取随机梯度 (例如，采样 τ 的目标函数 (3) 的梯度 $\mathcal{L}_{\text{TB}}$) 的行为策略称为采样 τ 的策略。

¹ 有指定初始状态的有向无环图。

其他目标在过去的文献中也被研究并成功应用，包括详细平衡 (DB; Bengio 等, 21b 提出, Malkin 等, 22 评估) 和子轨迹平衡 (SubTB; Madan 等, 22)。在接下来的部分中，我们将展示 TB 目标如何与分层变分目标相关。在 § C 中，我们将这一结果推广到 SubTB 损失，其中 TB 和 DB 都是特例。

2.2 分层变分模型与 GFlowNets

变分方法提供了一种通过学习近似概率密度来从分布中采样的方式。层次变分模型 (HVMs; Ranganath 等人, 2016b; Sobolev 和 Vetrov, 2019; Vahdat 和 Kautz, 2020; Zimmermann 等人, 2021) 通常假设样本空间是一组固定长度的序列 $(z_1, \dots, z_n)$ ，并且在给定 z_i 的情况下， z_{i+1} 与 z_{i+1} 之间存在条件独立性，即似然函数具有分解形式 $q(z_1, \dots, z_n) = q(z_1)q(z_2|z_1) \dots q(z_n|z_{n-1})$ 。在层次模型中， z_n 的边缘似然涉及一个可能难以处理的求和项，

$$q(z_n) = \sum_{z_1, \dots, z_{n-1}} q(z_1)q(z_2|z_1) \dots q(z_n|z_{n-1}).$$

变分推断算法的目标是找到使边缘分布 $q(z_n)$ 与目标分布之间的某种发散最小化的条件分布 q 。目标分布通常给出为具有难以处理归一化常数的分布：典型设置是一个贝叶斯后验（用于 VAEs、变分 EM 和其他应用），对于该分布，我们希望 $q(z_n) \propto p_{\text{likelihood}}(x|z_n)p_{\text{prior}}(z_n)$ 。

与 HVM 对应的 GFlowNet: 从层次模型中采样序列 $(z_1, \dots, z_n)$ 等价于在某个有向无环图 G 中采样完整的轨迹。G 的状态距离初始状态 i 的距离与变量 z_i 的可能值一一对应，并且动作分布由 q 给出。从 HVM 中采样等价于从策略 $P_F(z_{i+1}|z_i) = q(z_{i+1}|z_i)$ (和 $P_F(z_1|s_0) = q(z_1)$) 中采样轨迹，边缘分布 $q(z_n)$ 是终止分布 $P_F^\top$ 。

与 GFlowNet 对应的 HVM: 相反，假设 $\mathcal{G} = (S, A)$ 是一个分级有向无环图²，并且给出了 $\mathcal{G}$ 上的正向策略 P_F 。在 $\mathcal{G}$ 中采样轨迹 $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_L)$ 等价于从 HVM 中采样，在该 HVM 中，随机变量 z_i 是第 $(i+1)$ 个状态 s_i 在 τ 中的身份，并且条件分布 $q(z_{i+1}|z_i)$ 由正向策略 $P_F(s_{i+1}|s_i)$ 给出。因此，在具有 n 层的层次模型中指定目标分布的近似等价于在分级有向无环图中指定正向策略 P_F 。

这种对应关系可以扩展到非分级有向无环图。每个有向无环图 $\mathcal{G} = (S, A)$ 可以通过插入只有一个子节点和一个父节点的虚拟状态而被规范地转换成一个分级有向无环图。具体来说，每条边 $s \rightarrow s' \in A$ 被替换为一系列 $\ell' - \ell(s)$ 边，其中 $\ell(s)$ 是从 s_0 到 s , $\ell' = \ell(s')$ 的最长轨迹的长度，如果 $s' \notin X$ ，否则 $\ell' = \max_{s'' \in X} \ell(s'')$ 。这一过程在 § A 中进行了说明。因此，我们在本节中的分析限制在分级有向无环图上，不失一般性。

反向策略的意义: 通常，目标分布是在分级 DAG 的最后一层的对象 X 上，而不是在整个序列或轨迹上。DAG 上的任何反向策略 P_B 将 X 上的未归一化目标分布 R 转换为整个轨迹 T 上的未归一化分布：具有未知的配分函数 $\hat{Z} =$

$$\forall \tau \in \mathcal{T} \quad P_B(\tau) \propto R(x_\tau)P_B(\tau | x_\tau), \quad \sum_{x \in X} R(x). \quad (4)$$

终止状态上的边缘分布 P_B 等于 $R(x)/\hat{Z}$ ，这是由构造决定的。因此，如果 P_F 是一个前向策略，作为轨迹分布等于 P_B ，那么 $P_F^\top(x) = R(x)/\hat{Z} \propto R(x)$ 。

VI 训练目标: 在其最一般的形式下，分层变分目标（本文其余部分称为“HVI 目标”）最小化学习和目标轨迹分布之间的统计发散 D_f ：

$$\mathcal{L}_{\text{HVI},f}(P_F, P_B) = D_f(P_B \| P_F) = \mathbb{E}_{\tau \sim P_F} \left[f \left(\frac{P_B(\tau)}{P_F(\tau)} \right) \right]. \quad (5)$$

我们回顾一些关于偏序集的事实。一个带点分级 DAG 是一个所有完整轨迹长度相同的带点 DAG。带点分级 DAG G 也可以通过以下等价性质来表征：状态空间 S 可以被划分为不相交的集合 $S = \bigcup_{l=0}^L S_l$ ，其中 $S_0 = \{s_0\}$ ，称为层，使得所有边 $s \rightarrow s'$ 都是在相邻层的状态之间 ($s \in S_i, s' \in S_{i+1}$ 对于某个 i)。

两个常见的目标是前向和逆向 Kullback-Leibler (KL) 发散 (Mnih & Gregor, 2014 年)，分别对应于 $f : t \mapsto t \log t$ 对于 $D_{\text{KL}}(P_B \| P_F)$ 和 $f : t \mapsto -\log t$ 对于 $D_{\text{KL}}(P_F \| P_B)$ 。其他 f -发散也被使用过，如 Zhang 等人 (2019b)；Wan 等人 (2020) 所讨论的。请注意，类似于 GFlowNets, (5) 可以相对于前向和反向策略进行最小化，或者可以使用固定的反向策略进行最小化。

两个轨迹分布之间的发散与它们终止状态的边缘分布之间的发散通过数据处理不等式相联系，假设 f 是凸的（参见例如 Zhang 等人 (2019b)），使得前者成为后者的一个合理的替代目标：

$$D_f(R/\hat{Z} \| P_F^\top) \leq D_f(P_B \| P_F) \quad (6)$$

当同时学习 P_B 和 P_F 时，它们优化所依据的发散不必相同，只要两个目标在且仅在 $P_F = P_B$ 时为 0 即可。例如，唤醒-睡眠算法 (Hinton 等人, 1195) 使用 $D_{\text{KL}}(P_B \| P_F)$ 优化生成模型 P_F ，并使用 $D_{\text{KL}}(P_F \| P_B)$ 优化后验 P_B 。表 1 展示了常见的组合。

表 1：算法比较，用于在分层变分模型或 GFlowNet 中近似目标分布。用于更新采样分布和辅助反向策略参数的梯度近似于各种轨迹分布之间的梯度发散。

Algorithm	Surrogate loss	
	P_F (sampler)	P_B (posterior)
REVERSE KL	$D_{\text{KL}}(P_F \ P_B)$	$D_{\text{KL}}(P_F \ P_B)$
FORWARD KL	$D_{\text{KL}}(P_B \ P_F)$	$D_{\text{KL}}(P_B \ P_F)$
WAKE-SLEEP (WS)	$D_{\text{KL}}(P_B \ P_F)$	$D_{\text{KL}}(P_F \ P_B)$
REVERSE WAKE-SLEEP	$D_{\text{KL}}(P_F \ P_B)$	$D_{\text{KL}}(P_B \ P_F)$
On-policy TB	$D_{\text{KL}}(P_F \ P_B)$	see §2.3

我们注意到，对于诸如 (5) 这样的目标，可计算的无偏梯度估计器可能并不总是存在，因为我们无法精确地从 $P_B(\tau)$ 中抽样或计算其密度，当归一化常数 $\hat{Z}$ 未知时。例如，虽然 REINFORCE 估计器可以给出关于 P_F 的梯度的无偏估计，当目标是反向 KL 时（参见 §2.3），其他目标，如正向 KL，则需要重要性加权估计器。这些估计器通过从另一个分布 π （可能等于 P_F ）中抽样一批轨迹 $\{\tau_i\}$ 来近似从 P_B 中抽样，并按比例于 $\frac{P_B(\tau_i)}{\pi(\tau_i)}$ 的标量对每个 τ_i 计算的损失进行加权。尽管这种重新加权的重要采样在样本数量有限时存在偏差（例如，Bornschein & Bengio, 2015; Burda 等人, 2016），但它在各种变分算法中有帮助，但也可能引入随着 P_B 和 π 之间差异增加而增大的方差。

2.3 梯度分析

以下命题总结了我们的主要理论主张，将 (3) 中的 GFN 目标与 (5) 中的变分目标联系起来。在 §C 中，我们将这一结果扩展到子轨迹平衡目标（在 Malkin 等人 (2022) 中引入并在 Madan 等人 (2022) 中经验评估）与嵌套变分目标（Zimmermann 等人, 2021）的自然扩展之间的等价性。这种等价性的特殊情况是在 Detailed Balance 目标（Bengio 等人, 2021b）与嵌套 VI 目标（Zimmermann 等人, 2021）之间的等价性。

命题 1 给定一个分级有向无环图 G ，并记 θ, ϕ 分别为前向策略 P_F 和后向策略 P_B 的参数，TB 目标 (3) 的梯度满足：

$$\nabla_\phi D_{\text{KL}}(P_B \| P_F) = \frac{1}{2} \mathbb{E}_{\tau \sim P_B} [\nabla_\phi \mathcal{L}_{\text{TB}}(\tau)], \quad (7)$$

$$\nabla_\theta D_{\text{KL}}(P_F \| P_B) = \frac{1}{2} \mathbb{E}_{\tau \sim P_F} [\nabla_\theta \mathcal{L}_{\text{TB}}(\tau)]. \quad (8)$$

扩展结果的证明出现在 §C 中。另一种证明在 §B 中提供。

虽然 (8) 是关于参数的在线策略 TB 梯度 P_F ，但 (7) 不是关于参数的在线策略 TB 梯度 P_B ，因为期望是在 P_B 上取的，而不是在 P_F 上。然而，可以通过替代损失来表示在线策略 TB 梯度

$$\mathbb{E}_{\tau \sim P_F} [\nabla_\phi \mathcal{L}_{\text{TB}}(\tau)] = \nabla_\phi \left[D_{\log^2}(P_B \| P_F) + 2(\log Z - \log \hat{Z}) D_{\text{KL}}(P_F \| P_B) \right], \quad (9)$$

其中 $\hat{Z} = \sum_x \in X R(x)$ 是未知的真实划分函数。这里 $D_{\log^2}$ 是伪 f -发散，由 $f(x) = \log(x)^2$ 定义，对于较大的 x 它不是凸的。（证明见 §B.）(7) 中的损失除非使用重要性加权（参见 §2.2 结尾），否则无法直接优化，但通过 (7) 优化 P_B 和通过 (8) 优化 P_F 将得到 REVERSE WAKE-SLEEP 的期望梯度。

Score function estimator and variance reduction: Optimizing the reverse KL loss $D_{\text{KL}}(P_F \| P_B)$ with respect to θ , the parameters of P_F , requires a likelihood ratio (also known as REINFORCE) estimator of the gradient (Williams, 1992), using a trajectory τ (or a batch of trajectories), which takes the form:

$$\Delta(\tau) = \nabla_{\theta} \log P_F(\tau; \theta) c(\tau), \quad \text{where } c(\tau) = \log \frac{P_F(\tau)}{R(x_{\tau})P_B(\tau | x_{\tau})} \quad (10)$$

(请注意, 在 REINFORCE 估计器中通常存在的项 $\nabla_{\theta} c(\tau)$ 在期望下为 0, 因为 $\mathbb{E}_{\tau \sim P_F} [\nabla_{\theta} \log P_F(\tau)] = \sum_{\tau} \frac{P_F(\tau)}{P_F(\tau)} \nabla_{\theta} P_F(\tau) = 0$ 。)(10) 中的估计器已知具有高方差范数, 从而减慢学习速度。一个常见的解决方法是从 $c(\tau)$ 中减去一个基线 b , 这不会使估计器产生偏差。最能减少梯度估计器协方差矩阵迹的基线值 b (也称为控制变量) 是

$$b^* = \frac{\mathbb{E}_{\tau \sim P_F} [c(\tau) \|\nabla_{\theta} \log P_F(\tau; \theta)\|^2]}{\mathbb{E}_{\tau \sim P_F} [\|\nabla_{\theta} \log P_F(\tau; \theta)\|^2]},$$

通常近似为 $\mathbb{E}_{\tau \sim P_F} [c(\tau)]$ (参见, 例如 Weaver & Tao (2001); Wu et al. (2018))。这种近似本身经常被一个依赖于批次的局部基线所近似, 该基线来自一批轨迹 $\{\tau_i\}_{i=1}^B$:

$$b^{\text{local}} = \frac{1}{B} \sum_{i=1}^B c(\tau_i) \quad (11)$$

可以维护一个值的运行平均数 $c(\tau)$, 以获得对期望 $\mathbb{E}_{\tau \sim P_F} [c(\tau)]$ 更好的近似, 从而形成一个全局基线。观察到每批轨迹后, 运行平均数以步长 η 更新:

$$b^{\text{global}} \leftarrow (1 - \eta) b^{\text{global}} + \eta b^{\text{local}}. \quad (12)$$

这与更新规则一致 $-\log Z$ 在最小化过程中 $-\mathcal{L}_{\text{TB}}(P_F, P_B, Z)$ 以学习率 $\frac{1}{n}$ 对于参数 $-\log Z$ (在该参数下, 目标函数为二次型)。因此, 命题 1 中的 (8) 表明参数的更新规则为 P_F 当使用逆向 KL 目标进行优化时, 以 (12) 作为梯度得分函数估计器的控制变量, 其更新规则与通过使用在线策略轨迹优化 TB 目标所获得的更新规则相同。在学习反向策略时 P_B 可以加速收敛 (Malkin 等, 2022 年), TB 目标也可以与固定反向策略结合使用, 在这种情况下, 逆 KL 目标和 TB 目标仅在减少估计梯度的方差方式上有所不同, 如果轨迹是在策略上采样的。在第 4 节中, 我们实验性地探讨了两种学习范式之间的差异, 这些差异在 P_B 被学习, 或者当算法离策略运行时。

3 相关工作

(层次) 变分推断: 变分推断技术 (Zhang 等, 2019a) 起源于图形模型 (Saul 等, 1996; Jordan 等, 2004), 通常包括一个推理机和一个生成机来建模隐变量与观测数据之间的关系。黑盒 VI (Ranganath 等, 2014) 的工作重点在于给定数据生成过程的情况下学习推理机, 即推断隐变量的后验分布。在这样的设置下, 层次建模表现出吸引人的特性, 如 Ranganath 等 (2016b); Yin & Zhou (2018); Sobolev & Vetrov (2019) 所述。另一方面, 变分自编码器 (VAEs) (Kingma & Welling, 2014; Rezende 等, 2014) 的工作重点在于生成建模, 其中推理机——估计的变分后验——是一种辅助生成机或解码器优化的工具。多层次构建多个隐变量也被证明是有益的 (Sønderby 等, 2016; Maaløe 等, 2019; Child, 2021)。

早期的工作通过均场近似简化变分族 (Bishop, 2006), 而现代推理方法依赖于摊销随机优化 (Hoffman 等, 2013)。最古老且最常用的想法之一是 REINFORCE (Williams, 1992; Paisley 等, 2012), 它提供了无偏梯度估计。后续工作 (Titsias & Lázaro-Gredilla, 2014; Gregor 等, 2014; Mnih & Gregor, 2014; Mnih & Rezende, 2016) 提出了先进的估计器以减少 REINFORCE 的高方差。Richter 等 (2020) 提出的对数方差损失在期望梯度 P_F 上与 GFlowNet 的批量最优值的在线策略 TB 损失等价 $-\log Z$ 。另一方面, 路径梯度估计器 (Kingma & Welling, 2014) 具有更低的方差, 但适用范围有限。后来的工作将这两种方法结合应用于特定分布族 (Tucker 等, 2017; Grathwohl 等, 2018)。

除了大多数变分推断方法使用的证据下界 (ELBO) 目标外, 还研究了更复杂的优化目标。更紧的证据界已被证明有利于生成模型的学习 (Burda 等, 2016; Domke & Sheldon, 2018; Rainforth 等, 2018; Masrani 等, 2019)。由于 KL 发散优化存在诸如均值寻求行为和后验方差低估等问题 (Minka, 2005), 其他发散被采用, 如期望传播中的发散 (Minka, 2001; Li 等, 2015), 更一般的 f -发散 (Dieng 等, 2017; Wang 等, 2018; Wan 等, 2020), 其特例 α -发散 (Hernández-Lobato 等, 2016), 以及 Stein 差异 (Liu & Wang, 2016; Ranganath 等, 2016a)。GFlowNets 可以视为提供了一种新型伪发散准则, 即 TB, 正如本工作中讨论的。

唤醒-睡眠算法: 另一分支的工作始于 Hinton 等 (1995), 提出通过交替优化生成模型和推理 (后验) 模型来避免随机优化 (如 REINFORCE) 的问题。现代版本扩展了这一框架, 包括重新加权唤醒-睡眠 (Bornschein & Bengio, 2015; Le 等, 2019) 和记忆化唤醒-睡眠 (Hewitt 等, 2020; Le 等, 2022)。Le 等 (2019) 表明, 唤醒-睡眠算法对于涉及随机分支的任务表现良好。

GFlowNets: GFlowNets 已在其他研究中成功应用于强化学习和马尔可夫链蒙特卡罗方法的场景, 包括分子发现 (Bengio 等, 2021a; Malkin 等, 2022; Madan 等, 2022)、生物序列设计 (Malkin 等, 2022; Jain 等, 2022; Madan 等, 2022) 以及贝叶斯结构学习 (Deleu 等, 2022)。关于 GFlowNets 理论基础与变分方法之间的联系, Malkin 等 (2022) 首次提及, 并在 Zhang 等 (2022a; 2023) 中进一步展开。

一篇同时期且紧密相关的论文 (Zimmermann 等, 2022) 从理论上和实验上探讨了正向和逆向 KL 目标之间的插值。

4 实验

实验的目标是实证调查两个与上述理论分析一致的主要观察结果:

观察结果 1. 在某些情况下, 在线策略价值迭代和目标流网络 (GFlowNet) 目标可以表现出相似的行为, 当两者都能稳定优化时, 而在线策略目标流网络则比模式寻找的逆向 KL 或均值寻找的正向 KL 价值迭代目标达成更好的平衡。这一论点得到了以下三个领域实验的支持。

然而, 在所有情况下, 显著差异依然存在。特别是, HVI 训练在接近收敛时变得更加稳定, 并对学习率敏感, 这与 § 2.3 中关于梯度方差的假设一致。

观察结果 2. 当探索至关重要时, 离策略 TB 优于在策略 TB 和 VI 目标, 避免了离策略 VI 中重要性采样可能引起的高方差。GFlowNets 能够在没有重要性采样的情况下进行稳定的离策略训练。这一论点通过所有领域的实验得到了支持, 尤其在第 4.2 节和第 4.3 节所讨论的实际领域中表现得尤为明显。这种能力为捕捉更多样化的模式提供了优势。

观察 1 和 **观察 2** 提供了证据, 表明在准确拟合目标分布和有效找到模式方面, 离策略 TB 是测试方法中最优的, 其中后者对于下面研究的具有挑战性的分子图生成和因果图发现问题尤为重要。

4.1 超网格: 学习目标的探索

本节中, 我们比较研究了变分目标和 GFlowNet 目标学习由其未归一化密度或奖励函数给出的多模态分布的能力, 即 R 。我们使用 Bengio 等人 (2021a) 引入并由 Malkin 等人 (2022) 进一步探讨的合成超网格环境。状态形成一个维度为 D 的超网格, 边长为 H , 奖励函数在超网格的角落附近有 2^D 个平坦模式。状态形成一个尖锐的 DAG, 源状态是原点 $s_0 = \mathbf{0}$, 每条边对应于在一个状态中增加一个坐标值 1 的动作 (不离开网格)。关于环境的更多细节请参见附录 D.1。我们重点关注学习的情况, 即 P_B , 这已被证明可以加速收敛 (Malkin 等, 22 年)。

在图 1 中, 我们比较了每个学习目标发现四模态的速度 128×128 网格, 带有探索参数 $R_0 = 0.001$ 在奖励函数中。学习到的分布之间的差距 $P_F^\top$ 目标分布通过 Jensen-Shannon 发散 (JSD) 进行测量




图 1：上：JSD (Jeffrey 散度) 在学习采样器 P_F^T 和目标分布之间的演变，在网格 128×128 上的变化，作为采样轨迹数量的函数。阴影区域表示在 5 次不同运行中评估的标准误（左侧在线策略，右侧离线策略）。下：不同算法最终学习到的分布 P_F^T 的平均值（基于 5 次运行），以及目标分布。为了放大变化，图中每个网格位置的强度从近似于 5 次运行分布的高斯分布中重新采样。尽管 WS、FORWARD KL 和 REVERSE WS（离线策略）找到了 4 个目标模式，但它们并未以高精确率建模这些模式，并在模式处产生纹理图案，而该处应为平坦。

在两种分布之间进行选择，以避免偏向某一种 KL 散度。此外，我们展示了学习到的二维终止状态分布的图形表示，以及目标分布。我们在 § E 部分提供了关于如何评估 P_F^T 和 JSD 的细节，以及如何分别优化每种学习算法的超参数。

探索在这个环境中是一个挑战，因为不同的模式之间相距甚远。因此，在我们的分析中包括了每个目标的离线版本，其中行为策略与训练采样器 $P_F(\tau)$ 不同，但相关。这里使用的 GFlowNet 行为策略通过降低在网格任何状态终止轨迹的概率来鼓励探索。这促使学习者采样更长的轨迹，并有助于更快地发现更远的模式。当离线时，HVI 梯度使用重要性采样权重进行校正。

对于使用梯度得分函数估计器的算法（FORWARD KL、REVERSE WS 和 REVERSE KL），我们发现使用全局基线（如 § 2.2 所述）在大多数情况下优于常用的局部基线（见图 D.1）。这使得 VI 方法更接近 GFlowNets，从而将这一问题排除在与 GFlowNet 目标的比较之外。

从图 1 可以看出，虽然 FORWARD KL 和 WS——这两种算法将 $D_{KL}(P_B \parallel P_F)$ 作为 P_F 的目标——更快地发现了分布的四个模式，但它们收敛到局部最小值，并未以高精确率建模所有模式。这是由于前向 KL 目标的均值寻求行为，要求 P_F^T 在终止状态 x 上分配非零质量 $R(x) > 0$ 。使用逆 KL 训练前向策略的目标（REVERSE KL 和 REVERSE WS）具有模式寻求特性，因此可以在不找到所有模式的情况下拥有较低的损失。TB GFlowNet 目标结合了两者的优势，因为它收敛到 JSD 的更低值，发现四个模式，并以高精确率对其进行建模。这支持了观察 1。此外，为了支持观察 2，尽管 TB 目标和 HVI 目标都受益于离线采样，但 TB 的收益更大，因为收敛速度大大加快。

我们在 § D.1 部分通过较小网格上的算法比较分析来补充这项研究。

4.2 分子合成

We study the molecule synthesis task from Bengio et al. (2021a), in which molecular graphs are generated by sequential addition of subgraphs from a library of blocks (Jin et al., 2020; Kumar




图 2: 不同学习算法在分子生成任务上边缘采样对数似然与对数奖励之间的相关性, 展示了离策略 TB (红色) 相对于在策略 TB (橙色) 以及在策略 (蓝色) 和离策略 HVI (绿色) 的优势。对于 x 轴上的每种超参数设置 (α 或 β), 我们选取另一种超参数的最佳选择 (分别为 β 或 α), 并在三个随机种子上绘制平均值和标准误差区域。

等, 2.012)。奖励函数由一个固定的预训练图神经网络 f 表示, 该网络估计与可溶性环氧化物水解酶蛋白 (Trott & Olson, 2010) 的结合强度。具体来说, $R(x) = f(x)^\beta$, 其中 $f(x)$ 是分子 x 上的结合模型输出, 而 β 是一个可以变化的参数, 用于控制采样模型的熵。

由于终止状态的数量过大, 使得目标分布的精确计算变得不可能, 因此我们采用了以往在此任务上的研究工作 (Bengio 等, 2021a) 中使用的性能度量来评估采样代理。具体而言, 对于每个分子 x 在保留集上, 我们计算 $\log P_F^T(x)$, 可能性 x 在训练好的模型下 (可通过动态规划计算, 见 § E), 并评估皮尔森相关性 $\log P_F^T(x)$ 和 $\log R(x)$ 这一值对于完美的采样器应等于 1, 因为 $\log P_F^T(x)$ 和 $\log R(x)$ 会相差一个常数, 即对数配分函数 $\log \hat{Z}$ 。

In Malkin et al. (2022), GFlowNet samplers using the DB and TB objectives, with the backward policy P_B fixed to a uniform distribution over the parents of each state, were trained off-policy. Specifically, the trajectories used for DB and TB gradient updates were sampled from a mixture of the (online) forward policy P_F and a uniform distribution at each sampling step, with a special weight depending on the trajectory length used for the termination action.

本文扩展了 Malkin 等人 (2022) 发布的代码, 实现了 HVI (逆 KL) 目标, 并采用了重新加权的重要性采样修正。我们将过去的离线策略 TB 与离线策略逆 KL 进行了比较, 同时也包括在线策略 TB 和逆 KL 目标。(请注意, 在此设定下, 由于反向策略固定, 因此在线策略 TB 和逆 KL 在期望上是等价的。) 每种算法均使用四个逆温度参数值 β 和四个学习率值 α 进行评估, 总共得到 $4 \times 4 \times 4 = 64$ 种设置。(我们也尝试了离线策略 FORWARD KL / WS 目标来优化 P_F , 但没有一种超参数设置能使平均相关性大于 0.1。) 结果如图 2 所示, 在该图中, 对于每个超参数 (α 或 β), 我们绘制了另一个超参数最优值下的性能。我们三个观察结果: • 支持观察 2, 离线策略逆 KL 相较于其在线策略版本表现较差, 尤其是在目标分布多样性较大的平滑分布 (较小的 β 值) 中。由于两种算法在期望梯度上一致, 这表明重要性采样引入了不可接受的方差到 HVI 梯度中。

• 支持观察 1, 在线策略逆 KL 与在线策略 TB 之间的差异很小, 这与它们的梯度在沿着全批次梯度场下降的极限情况下重合是一致的。然而, 逆 KL 算法对学习率更为敏感。• 支持观察 2, 离线策略 TB 给出了最佳且方差最低的目标分布拟合, 显示了探索性训练策略的重要性, 特别是在稀疏奖励景观 (更高的 β)。

表 2: 贝叶斯结构学习中 Jensen-Shannon 发散的比较, 展示了离线策略 TB 相对于在线策略 TB 和在线或离线 HVI 的优势。JSD 是在真实后验分布 $p(G | \mathcal{D})$ 和学习近似 p^π 之间测量的 $\hat{J}(G)$ 。

Objective	Number of nodes		
	3	4	5
(Modified) Detailed Balance	$5.32 \pm 4.15 \times 10^{-6}$	$2.05 \pm 0.70 \times 10^{-5}$	$4.65 \pm 1.08 \times 10^{-4}$
Off-Policy Trajectory Balance	$3.70 \pm 2.51 \times 10^{-7}$	$9.35 \pm 2.99 \times 10^{-6}$	$5.44 \pm 2.47 \times 10^{-4}$
On-Policy Trajectory Balance	0.022 ± 0.007	0.123 ± 0.028	0.277 ± 0.040
On-Policy REVERSE KL (HVI)	0.022 ± 0.007	0.125 ± 0.027	0.306 ± 0.042
Off-Policy REVERSE KL (HVI)	0.014 ± 0.008	0.605 ± 0.019	0.656 ± 0.009

4.3 贝叶斯结构学习中 DAG 的生成

最后, 我们考虑贝叶斯网络结构的后验分布学习问题, 正如 Deleu 等人 (2022) 所研究的。贝叶斯结构学习的目标是逼近后验分布 $p(G | \mathcal{D})$ 在有向无环图上 G , 给定一个观测数据集 $\mathcal{D}$ 。遵循 Deleu 等人 (2022) 的研究, 我们将生成有向无环图视为一个顺序决策问题, 其中有向边依次添加, 从完全不连通的图开始。由于我们的目标是逼近后验分布 $p(G | \mathcal{D})$, 我们使用联合概率 $R(G) = p(G, \mathcal{D})$ 作为奖励函数, 该函数与前者成比例, 仅相差一个归一化常数。关于如何计算此奖励以及前向策略的参数化 P_F 的详细信息, 请参见 § D.3。请注意, 类似于 § 4.2, 并遵循 Deleu 等人 (2022), 我们将反向策略 P_B 固定为均匀分布。

我们仅考虑可以精确计算真实后验分布 $p(G | \mathcal{D})$ 的情形, 通过枚举所有可能的有向无环图 (DAG) G 来覆盖 d 节点 (对于 $d \leq 5$)。这使我们能够将通过 GFlowNet 目标或 HVI 找到的后验近似值与目标后验分布进行精确比较。状态空间随着节点数量的增长而迅速扩大 (例如, 有 29k 个 DAG 覆盖 $d = 5$ 节点)。对于每个实验, 我们从随机生成的真实图 G^* 中采样了一个包含 100 个观测值的数据集 $\mathcal{D}$; $\mathcal{D}$ 的大小被选择为获得高度多模态的后验分布。除了 Deleu 等人 (2022) 引入的 (修改后的) DB 目标外, 我们还研究了 TB (GFlowNet) 和 REVERSE KL (HVI) 目标, 包括在线策略和离线策略。

在表 2 中, 我们通过 Jensen-Shannon 发散 (JSD) 比较了这些不同目标找到的后验近似与目标后验分布之间的差异 $P(G | \mathcal{D})$ 。我们观察到, 在最简单的设置 (节点数量为 $d = 3$ 的图) 下, 所有方法都能准确地逼近后验分布。但随着问题复杂度的增加 (更大的图), 我们发现 Off-Policy REVERSE KL 找到的近似精度显著下降, 而使用 off-policy GFlowNet 目标 ((修改后的)DB & TB) 找到的近似仍然非常准确。我们还注意到 On-Policy TB 和 On-Policy REVERSE KL 的性能也有所下降, 但不如前者显著; 此外, 这两种方法在所有实验设置下的表现相似, 证实了我们的观察 1, 并且与 § 2.2 中强调的联系相吻合。当问题复杂度增加 (即节点数量 d 增加, 需要更好的探索) 时, off-policy GFlowNet 目标的一致性行为与 on-policy 目标 (TB & REVERSE KL) 相比, 也支持了我们的观察 2。这些观察在比较边缘边际分布 $P(X_i \rightarrow X_j | \mathcal{D})$ 时得到了进一步确认, 如图 D.3 (§ D.3) 所示, 这些分布要么使用目标后验分布计算, 要么使用后验近似。

5 讨论与结论

本文的理论和实验将 GFlowNets 置于变分方法家族中, GFlowNets 最初被引入并作为强化学习方法进行动机阐述。它们表明, off-policy GFlowNet 目标可能是替代先前 VI 目标的优势选择, 尤其是在目标分布高度多模态的情况下, 它在模式寻找 (REVERSE KL) 和均值寻找 (FORWARD KL) 的 VI 变体之间取得了有趣的平衡。这项工作应该促进更多关于如何在 off-policy GFlowNet 训练中选择行为策略的研究, 这被视为一种有效探索和发现模式的手段。

虽然这里进行的实验集中在离散变量领域, 但未来的工作也应该研究 GFlowNets 在连续动作空间中的应用, 作为连续变量域中 VI 的潜在替代方案。我们在附录 (§ F) 中朝着这个方向迈出了第一步。在本文审稿期间, Lahlou 等人 (2023 年) 提出了连续 GFlowNets 的理论, 并展示了我们的某些主张可以扩展到连续域。

作者贡献 N.M.、X.J.、D.Z. 和 Y.B. 观察到了 GFlowNets 与变分推断之间的联系，为本工作的主要思想提供了动机。N.M.、X.J. 和 T.D. 进行了初步实验探索。S.L.、N.M. 和 D.Z. 对理论分析做出了贡献。S.L. 和 N.M. 将理论分析扩展到子轨迹目标。D.Z. 审查了相关工作。S.L. 在超网格域上进行了实验。N.M. 在分子域和随机控制域上进行了实验。T.D.、E.H. 和 K.E. 在因果图域上进行了实验。所有作者都参与了实验规划、结果分析以及论文撰写。

致谢

作者感谢 Moksh Jain 关于该项目的宝贵讨论。

本研究部分得益于加拿大数字研究联盟提供的计算资源。所有作者的资金均来自其主要机构。我们还感谢 CIFAR、Genentech、Samsung 和 IBM 的资助。

参考文献

- Peter W Battaglia, Jessica B Hamrick, Victor Bapst, Alvaro Sanchez-Gonzalez, Vinicius Zambaldi, Mateusz Malinowski, Andrea Tacchetti, David Raposo, Adam Santoro, Ryan Faulkner, et al. Relational inductive biases, deep learning, and graph networks. *arXiv preprint 1806.01261*, 2018.
- Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow network based generative models for non-iterative diverse candidate generation. *Neural Information Processing Systems (NeurIPS)*, 2021a.
- Yoshua Bengio, Salem Lahlou, Tristan Deleu, Edward Hu, Mo Tiwari, and Emmanuel Bengio. GFlowNet foundations. *arXiv preprint 2111.09266*, 2021b.
- Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- David M. Blei, Michael I. Jordan, Thomas L. Griffiths, and Joshua B. Tenenbaum. Hierarchical topic models and the nested Chinese restaurant process. *Neural Information Processing Systems (NIPS)*, 2003.
- Jörg Bornschein and Yoshua Bengio. Reweighted wake-sleep. *International Conference on Learning Representations (ICLR)*, 2015.
- Yuri Burda, Roger Baker Grosse, and Ruslan Salakhutdinov. Importance weighted autoencoders. *International Conference on Learning Representations (ICLR)*, 2016.
- Rewon Child. Very deep VAEs generalize autoregressive models and can outperform them on images. *International Conference on Learning Representations (ICLR)*, 2021.
- Tristan Deleu, António Góis, Chris Emezue, Mansi Rankawat, Simon Lacoste-Julien, Stefan Bauer, and Yoshua Bengio. Bayesian structure learning with generative flow networks. *Uncertainty in Artificial Intelligence (UAI)*, 2022.
- Adji Bousso Dieng, Dustin Tran, Rajesh Ranganath, John William Paisley, and David M. Blei. Variational inference via χ upper bound minimization. *Neural Information Processing Systems (NIPS)*, 2017.
- Justin Domke and Daniel Sheldon. Importance weighting and variational inference. *Neural Information Processing Systems (NeurIPS)*, 2018.
- Dan Geiger and David Heckerman. Learning Gaussian networks. In *Uncertainty Proceedings 1994*, pp. 235–243. Elsevier, 1994.
- Will Grathwohl, Dami Choi, Yuhuai Wu, Geoffrey Roeder, and David Kristjanson Duvenaud. Back-propagation through the void: Optimizing control variates for black-box gradient estimation. *International Conference on Learning Representations (ICLR)*, 2018.
- Karol Gregor, Ivo Danihelka, Andriy Mnih, Charles Blundell, and Daan Wierstra. Deep AutoRegressive networks. *International Conference on Machine Learning (ICML)*, 2014.

- José Miguel Hernández-Lobato, Yingzhen Li, Mark Rowland, Thang D. Bui, Daniel Hernández-Lobato, and Richard E. Turner. Black-box alpha divergence minimization. *International Conference on Machine Learning (ICML)*, 2016.
- Luke B. Hewitt, Tuan Anh Le, and Joshua B. Tenenbaum. Learning to learn generative programs with memoised wake-sleep. *Uncertainty in Artificial Intelligence (UAI)*, 2020.
- Geoffrey E. Hinton, Peter Dayan, Brendan J. Frey, and R M Neal. The “wake-sleep” algorithm for unsupervised neural networks. *Science*, 268 5214:1158–61, 1995.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Neural Information Processing Systems (NeurIPS)*, 2020.
- Matthew D. Hoffman, David M. Blei, Chong Wang, and John William Paisley. Stochastic variational inference. *Journal of Machine Learning Research (JMLR)*, 14:1303–1347, 2013.
- Moksh Jain, Emmanuel Bengio, Alex Hernandez-Garcia, Jarrid Rector-Brooks, Bonaventure F.P. Dossou, Chanakya Ekbote, Jie Fu, Tianyu Zhang, Micheal Kilgour, Dinghuai Zhang, Lena Simine, Payel Das, and Yoshua Bengio. Biological sequence design with GFlowNets. *International Conference on Machine Learning (ICML)*, 2022.
- Wengong Jin, Regina Barzilay, and Tommi Jaakkola. Chapter 11. junction tree variational autoencoder for molecular graph generation. *Drug Discovery*, pp. 228–249, 2020. ISSN 2041-3211.
- Michael I. Jordan, Zoubin Ghahramani, Tommi Jaakkola, and Lawrence K. Saul. An introduction to variational methods for graphical models. *Machine Learning*, 37:183–233, 2004.
- Diederik P. Kingma and Max Welling. Auto-encoding variational Bayes. *International Conference on Learning Representations (ICLR)*, 2014.
- Jack Kuipers, Giusi Moffa, and David Heckerman. Addendum on the scoring of Gaussian directed acyclic graphical models. *The Annals of Statistics*, 42(4):1689–1691, 2014.
- Ashutosh Kumar, Arnout Voet, and Kam Y.J. Zhang. Fragment based drug design: from experimental to computational approaches. *Current medicinal chemistry*, 19(30):5128–5147, 2012.
- Salem Lahlou, Tristan Deleu, Pablo Lemos, Dinghuai Zhang, Alexandra Volokhova, Alex Hernández-García, Léna Néhale Ezzine, Yoshua Bengio, and Nikolay Malkin. A theory of continuous generative flow networks. *arXiv preprint 2301.12594*, 2023.
- Tuan Anh Le, Adam R. Kosior, N. Siddharth, Yee Whye Teh, and Frank Wood. Revisiting reweighted wake-sleep for models with stochastic control flow. *Uncertainty in Artificial Intelligence (UAI)*, 2019.
- Tuan Anh Le, Katherine M. Collins, Luke B. Hewitt, Kevin Ellis, N. Siddharth, Samuel J. Gershman, and Joshua B. Tenenbaum. Hybrid memoised wake-sleep: Approximate inference at the discrete-continuous interface. *International Conference on Learning Representations (ICLR)*, 2022.
- Yingzhen Li, José Miguel Hernández-Lobato, and Richard E. Turner. Stochastic expectation propagation. *Neural Information Processing Systems (NIPS)*, 2015.
- Qiang Liu and Dilin Wang. Stein variational gradient descent: A general purpose Bayesian inference algorithm. *Neural Information Processing Systems (NIPS)*, 2016.
- Ilya Loshchilov and Frank Hutter. SGDR: stochastic gradient descent with warm restarts. *International Conference on Learning Representations (ICLR)*, 2017.
- Lars Maaløe, Marco Fraccaro, Valentin Liévin, and Ole Winther. BIVA: A very deep hierarchy of latent variables for generative modeling. *Neural Information Processing Systems (NeurIPS)*, 2019.
- Kanika Madan, Jarrid Rector-Brooks, Maksym Korablyov, Emmanuel Bengio, Moksh Jain, Andrei Nica, Tom Bosc, Yoshua Bengio, and Nikolay Malkin. Learning GFlowNets from partial episodes for improved convergence and stability. *arXiv preprint 2209.12782*, 2022.

- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in GFlowNets. *Neural Information Processing Systems (NeurIPS)*, 2022.
- Vaden Masrani, Tuan Anh Le, and Frank D. Wood. The thermodynamic variational objective. *Neural Information Processing Systems (NeurIPS)*, 2019.
- Thomas P. Minka. Expectation propagation for approximate Bayesian inference. *arXiv preprint 1301.2294*, 2001.
- Thomas P. Minka. Divergence measures and message passing. 2005.
- Andriy Mnih and Karol Gregor. Neural variational inference and learning in belief networks. *International Conference on Machine Learning (ICML)*, 2014.
- Andriy Mnih and Danilo Jimenez Rezende. Variational inference for Monte Carlo objectives. *International Conference on Machine Learning (ICML)*, 2016.
- John William Paisley, David M. Blei, and Michael I. Jordan. Variational Bayesian inference with stochastic search. *International Conference on Machine Learning (ICML)*, 2012.
- Tom Rainforth, Adam R. Kosiorek, Tuan Anh Le, Chris J. Maddison, Maximilian Igl, Frank Wood, and Yee Whye Teh. Tighter variational bounds are not necessarily better. *International Conference on Machine Learning (ICML)*, 2018.
- Rajesh Ranganath, Sean Gerrish, and David Blei. Black box variational inference. *Artificial Intelligence and Statistics (AISTATS)*, 2014.
- Rajesh Ranganath, Dustin Tran, Jaan Allosa, and David M. Blei. Operator variational inference. *Neural Information Processing Systems (NIPS)*, 2016a.
- Rajesh Ranganath, Dustin Tran, and David Blei. Hierarchical variational models. *International Conference on Machine Learning (ICML)*, 2016b.
- Danilo Jimenez Rezende, Shakir Mohamed, and Daan Wierstra. Stochastic backpropagation and approximate inference in deep generative models. *International Conference on Machine Learning (ICML)*, 2014.
- Lorenz Richter, Ayman Boustati, Nikolas Nüsken, Francisco J. R. Ruiz, and Ömer Deniz Akyildiz. VarGrad: A low-variance gradient estimator for variational inference. *Neural Information Processing Systems (NeurIPS)*, 2020.
- Lawrence K. Saul, T. Jaakkola, and Michael I. Jordan. Mean field theory for sigmoid belief networks. *Journal of Artificial Intelligence Research*, 4:61–76, 1996.
- Artem Sobolev and Dmitry Vetrov. Importance weighted hierarchical variational inference. *Neural Information Processing Systems (NeurIPS)*, 2019.
- Casper Kaae Sønderby, Tapani Raiko, Lars Maaløe, Søren Kaae Sønderby, and Ole Winther. Ladder variational autoencoders. *Neural Information Processing Systems (NIPS)*, 2016.
- Michalis K. Titsias and Miguel Lázaro-Gredilla. Doubly stochastic variational Bayes for non-conjugate inference. *International Conference on Machine Learning (ICML)*, 2014.
- Oleg Trott and Arthur J Olson. AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of Computational Chemistry*, 31(2):455–461, 2010.
- George Tucker, Andriy Mnih, Chris J. Maddison, John Lawson, and Jascha Narain Sohl-Dickstein. REBAR: Low-variance, unbiased gradient estimates for discrete latent variable models. *Neural Information Processing Systems (NIPS)*, 2017.
- Arash Vahdat and Jan Kautz. Nvae: A deep hierarchical variational autoencoder. *Neural Information Processing Systems (NeurIPS)*, 2020.
- Neng Wan, Dapeng Li, and Naira Hovakimyan. f-divergence variational inference. *Neural Information Processing Systems (NeurIPS)*, 2020.

- Dilin Wang, Hao Liu, and Qiang Liu. Variational inference with tail-adaptive f-divergence. *Neural Information Processing Systems (NeurIPS)*, 2018.
- Lex Weaver and Nigel Tao. The optimal reward baseline for gradient-based reinforcement learning. *Uncertainty in Artificial Intelligence (UAI)*, 2001.
- Ronald J Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8(3):229–256, 1992.
- Cathy Wu, Aravind Rajeswaran, Yan Duan, Vikash Kumar, Alexandre M. Bayen, Sham M. Kakade, Igor Mordatch, and Pieter Abbeel. Variance reduction for policy gradient with action-dependent factorized baselines. *International Conference on Learning Representations (ICLR)*, 2018.
- Mingzhang Yin and Mingyuan Zhou. Semi-implicit variational inference. *International Conference on Machine Learning (ICML)*, 2018.
- Cheng Zhang, Judith Bütetage, Hedvig Kjellström, and Stephan Mandt. Advances in variational inference. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41:2008–2026, 2019a.
- Dinghuai Zhang, Ricky T. Q. Chen, Nikolay Malkin, and Yoshua Bengio. Unifying generative models with GFlowNets. *arXiv preprint 2209.02606v1*, 2022a.
- Dinghuai Zhang, Nikolay Malkin, Zhen Liu, Alexandra Volokhova, Aaron Courville, and Yoshua Bengio. Generative flow networks for discrete probabilistic modeling. *International Conference on Machine Learning (ICML)*, 2022b.
- Dinghuai Zhang, Ricky T. Q. Chen, Nikolay Malkin, and Yoshua Bengio. Unifying generative models with GFlowNets and beyond. *arXiv preprint 2209.02606*, 2023.
- Mingtian Zhang, Thomas Bird, Raza Habib, Tianlin Xu, and David Barber. Variational f-divergence minimization. *arXiv preprint 1907.11891*, 2019b.
- Heiko Zimmermann, Hao Wu, Babak Esmaeili, Sam Stites, and Jan-Willem van de Meent. Nested variational inference. *Neural Information Processing Systems (NeurIPS)*, 2021.
- Heiko Zimmermann, Fredrik Lindsten, Jan-Willem van de Meent, and Christian A. Naesseth. A variational perspective on generative flow networks. *arXiv preprint 2210.07992*, 2022.

一个分级有向无环图的标准构造




图 A.1: 展示了有向无环图（左）如何转化为分级有向无环图（右）的过程。双边框节点表示终止状态。虚线边框节点表示为了使有向无环图分级而添加的虚拟状态。

图 A.1 展示了将有向无环图转换为分级有向无环图的标准方法，如 § 2.2 所述。请注意，此操作是幂等的：将其应用于分级有向无环图会得到相同的分级有向无环图。

附录 B 证明

本文证明命题 1。

证明 对于完整的轨迹 $\tau \in \mathcal{T}$ ，记作 $c(\tau) = \log \frac{P_F(\tau)}{R(x_\tau)P_B(\tau|x_\tau)}$ 。我们有如下结果：

$$\nabla_\theta c(\tau) = \nabla_\theta \log P_F(\tau) \quad (13)$$

$$\nabla_\phi c(\tau) = -\nabla_\phi \log P_B(\tau | x_\tau) = -\nabla_\phi \log P_B(\tau) \quad (14)$$

记 $f_1 : t \mapsto t \log t$ 和 $f_2 : t \mapsto -\log t$ 分别对应前向和后向 KL 发散，并从

$$\begin{aligned} \mathcal{L}_{\text{HVI}, f_2}(P_F, P_B) &= D_{KL}(P_F \| P_B) = \mathbb{E}_{\tau \sim P_F} \left[\log \frac{P_F(\tau)}{P_B(\tau)} \right] = \mathbb{E}_{\tau \sim P_F} [c(\tau)] + \log \hat{Z}, \\ \mathcal{L}_{\text{HVI}, f_1}(P_F, P_B) &= D_{KL}(P_B \| P_F) = \mathbb{E}_{\tau \sim P_B} \left[\log \frac{P_B(\tau)}{P_F(\tau)} \right] = -(\mathbb{E}_{\tau \sim P_B} [c(\tau)] + \log \hat{Z}), \end{aligned}$$

出发，我们得到：

$$\begin{aligned} \nabla_\theta \mathcal{L}_{\text{HVI}, f_2}(P_F, P_B) &= \nabla_\theta \mathbb{E}_{\tau \sim P_F} [c(\tau)] = \mathbb{E}_{\tau \sim P_F} [\nabla_\theta \log P_F(\tau) c(\tau) + \nabla_\theta c(\tau)], \\ \nabla_\phi \mathcal{L}_{\text{HVI}, f_1}(P_F, P_B) &= -\nabla_\phi \mathbb{E}_{\tau \sim P_B} [c(\tau)] = -\mathbb{E}_{\tau \sim P_B} [\nabla_\phi \log P_B(\tau) c(\tau) + \nabla_\phi c(\tau)]. \end{aligned}$$

从 (13) 和 (14)，我们得到：

$$\mathbb{E}_{\tau \sim P_F} [\nabla_\theta c(\tau)] = \mathbb{E}_{\tau \sim P_F} [\nabla_\theta \log P_F(\tau)] = \sum_{\tau \in \mathcal{T}} P_F(\tau) \nabla_\theta \log P_F(\tau) = \sum_{\tau \in \mathcal{T}} \nabla_\theta P_F(\tau) = \nabla_\theta 1 = 0$$

因此，对于任意标量 $Z > 0$ ，我们可以写出：

$$\mathbb{E}_{\tau \sim P_F} [\nabla_\theta c(\tau)] = 0 = \mathbb{E}_{\tau \sim P_F} [\nabla_\theta \log P_F(\tau) \log Z]$$

类似地

$$\mathbb{E}_{\phi \sim P_F} [\nabla_\phi c(\tau)] = 0 = \mathbb{E}_{\tau \sim P_B} [\nabla_\phi \log P_B(\tau) \log Z].$$

将这两个等式代入上述 HVI 梯度中，我们得到：

$$\begin{aligned} \nabla_\theta \mathcal{L}_{\text{HVI}, f_2}(P_F, P_B) &= \mathbb{E}_{\tau \sim P_F} \left[\nabla_\theta \log P_F(\tau) \log \frac{Z P_F(\tau)}{R(x_\tau) P_B(\tau | x_\tau)} \right] \\ \nabla_\phi \mathcal{L}_{\text{HVI}, f_1}(P_F, P_B) &= -\mathbb{E}_{\tau \sim P_B} \left[\nabla_\phi \log P_B(\tau) \log \frac{Z P_F(\tau)}{R(x_\tau) P_B(\tau | x_\tau)} \right] \end{aligned}$$

最后两个等式对于任何标量 Z （该标量不依赖于参数 P_F 、 P_B ，也不依赖于任何轨迹）都成立。特别是，这些方程对于轨迹平衡目标的参数 Z 也成立。因此，我们得出：

$$\begin{aligned}\nabla_{\theta} \mathcal{L}_{\text{HVI}, f_2}(P_F, P_B) &= \frac{1}{2} \mathbb{E}_{\tau \sim P_F} \left[\nabla_{\theta} \left(\log \frac{Z P_F(\tau)}{R(x_{\tau}) P_B(\tau | x_{\tau})} \right)^2 \right] = \frac{1}{2} \mathbb{E}_{\tau \sim P_B} [\nabla_{\theta} \mathcal{L}_{\text{TB}}(\tau; P_F, P_B, Z)] \\ \nabla_{\phi} \mathcal{L}_{\text{HVI}, f_1}(P_F, P_B) &= \frac{1}{2} \mathbb{E}_{\tau \sim P_B} \left[\nabla_{\phi} \left(\log \frac{Z P_F(\tau)}{R(x_{\tau}) P_B(\tau | x_{\tau})} \right)^2 \right] = \frac{1}{2} \mathbb{E}_{\tau \sim P_B} [\nabla_{\phi} \mathcal{L}_{\text{TB}}(\tau; P_F, P_B, Z)]\end{aligned}$$

作为直接推论，我们得出预期的在线策略 TB 梯度不依赖于估计的配分函数 Z 。 ■

接下来，我们将证明恒等式 (9)，我们在这里重新陈述：

$$\mathbb{E}_{\tau \sim P_F} [\nabla_{\phi} \mathcal{L}_{\text{TB}}(\tau)] = \nabla_{\phi} \left[D_{\log^2}(P_B \| P_F) + 2(\log Z - \log \hat{Z}) D_{\text{KL}}(P_F \| P_B) \right]. \quad (15)$$

证明 (15) 式的右侧等于

$$\begin{aligned}& \nabla_{\phi} \left[\mathbb{E}_{\tau \sim P_F} \left[\left(\log \frac{P_B(\tau | x_{\tau}) R(x_{\tau})}{\hat{Z} P_F(\tau)} \right)^2 + 2(\log Z - \log \hat{Z}) \log \frac{P_F(\tau) \hat{Z}}{P_B(\tau | x_{\tau}) R(x_{\tau})} \right] \right] \\ &= \mathbb{E}_{\tau \sim P_F} \left[\nabla_{\phi} \left[\left(\log \frac{P_B(\tau | x_{\tau}) R(x_{\tau})}{\hat{Z} P_F(\tau)} \right)^2 + 2(\log Z - \log \hat{Z}) \log \frac{P_F(\tau) \hat{Z}}{P_B(\tau | x_{\tau}) R(x_{\tau})} \right] \right] \\ &= \mathbb{E}_{\tau \sim P_F} \left[2 \nabla_{\phi} \log P_B(\tau | x_{\tau}) \log \frac{P_B(\tau | x_{\tau}) R(x_{\tau})}{\hat{Z} P_F(\tau)} - 2(\log Z - \log \hat{Z}) \nabla_{\phi} \log P_B(\tau | x_{\tau}) \right] \\ &= 2 \mathbb{E}_{\tau \sim P_F} \left[\nabla_{\phi} \log P_B(\tau | x_{\tau}) \log \frac{P_B(\tau | x_{\tau}) R(x_{\tau})}{Z P_F(\tau)} \right] \\ &= \mathbb{E}_{\tau \sim P_F} [\nabla_{\phi} \mathcal{L}_{\text{TB}}(\tau)]\end{aligned}$$

C 子轨迹的变分目标

在本节中，我们将命题 1 中的声明扩展到连接其他 GFlowNet 损失与不同的变分目标。因此，命题 1 是命题 2 的一个特例。这提供了命题 1 的另一种证明。

详细的平衡目标（详细平衡（DB））：（Bengio 等人，2021b）提出的损失函数通过其正向和反向策略 P_F 和 P_B 分别参数化 GFlowNet，并结合一个状态流函数 F ，该函数是一个关于状态的正值函数，在终止状态上匹配目标奖励函数。它分解为一系列依赖于转换的损失之和：

$$\forall s \rightarrow s' \in \mathbb{A} \quad \mathcal{L}_{\text{DB}}(s \rightarrow s'; P_F, P_B, F) = \left(\log \frac{F(s) P_F(s' | s)}{F(s') P_B(s | s')} \right)^2, \text{ where } F(s') = R(s') \text{ if } s' \in \mathcal{X}. \quad (16)$$

子轨迹平衡目标（子 TB）：DB 和 TB 目标均可视为子轨迹平衡目标（Malkin 等，2022；Madan 等，2022）的特殊情况。Malkin 等（2022）建议不定义状态流函数 F 对于每一个状态 s 可以定义一个状态流函数于状态空间 S 的一个子集上，称为枢纽状态。损失可以分解为一系列依赖于子轨迹的损失之和：

$$\forall \tau = (s_1, \dots, s_n) \in \mathcal{T}^{\text{partial}} \quad \mathcal{L}_{\text{SubTB}}(\tau; P_F, P_B, F) = \left(\log \frac{F(s_1) P_F(\tau)}{F(s_n) P_B(\tau | s_1)} \right)^2, \quad (17)$$

其中 $P_F(\tau)$ 对于部分轨迹的定义类似于完整轨迹 (2)， $P_B(\tau | s) = \hat{1}_{(s \rightarrow s') \in \tau} P_B(s | s')$ ，并且我们再次固定 $F(x) = R(x)$ 对于终止状态 $x \in \mathcal{X}$ 。子 TB 目标对于长度为 1 的子轨迹简化为 DB 目标，而对于完整轨迹则简化为 TB 目标，在这种情况下，我们使用 Z 表示 $F(s_0)$ 。

转换的变分目标：从现在开始，我们使用分级有向无环图

$\mathcal{G} = (\mathcal{S}, \mathcal{A})$, , 其中状态空间 $\mathcal{S}$ 被分解成层: $\mathcal{S} = \bigcup_{l=0}^L \mathcal{S}_l$, 其中 $\mathcal{S}_0 = \{s_0\}$ $\mathcal{S}_L = \mathcal{X}$.

HVI 提供了一类算法来在图 $\mathcal{G}$ 上学习正向和反向策略。与使用需要完整轨迹分布的变分目标来学习这些策略 (P_F 和 P_B) 不同, 嵌套变分推断 (NVI; Zimmermann 等人, 2021 年) 结合了嵌套重要性采样和变分推断, 定义了一个处理转移分布或边分布的目标。为此, 它利用了状态的正函数 F_k , 其中 $s_k \in \mathcal{S}_k$, 对于 $k = 0, \dots, L-1$, 定义了两个边缘上的分布集合 $\check{p}_k$ 和 $\hat{p}_k$ 从 $\mathcal{S}_k$ 到 $\mathcal{S}_{k+1}$:

$$\hat{p}_k(s_k \rightarrow s_{k+1}) \propto F_k(s_k) P_F(s_{k+1} | s_k) \quad \check{p}_k(s_k \rightarrow s_{k+1}) \propto \begin{cases} R(s_L) P_B(s_k | s_L) & k = L-1 \\ F_{k+1}(s_{k+1}) P_B(s_k | s_{k+1}) & \text{otherwise} \end{cases} \quad (18)$$

学习策略 $\backslash(P\backslash)$ 和函数是通过最小化如下形式的损失来完成的: $P_F, \backslash(P\backslash), B$ 和函数 F_k

$$\mathcal{L}_{\text{NVI}}(P_F, P_B, F) = \sum_{k=0}^{L-1} D_f(\check{p}_k \| \hat{p}_k) \quad (19)$$

正函数 F_k 扮演的角色类似于 GFlowNets 中的状态流函数 (特别是在 DB 目标中)。在建立 DB 和 NVI 之间的联系之前, 我们首先提出了 NVI 对子轨迹的自然扩展。

C.1 子轨迹的变分目标

考虑一个分级有向无环图 $\mathcal{G} = (\mathcal{S}, \mathcal{A})$, 其中 $\mathcal{S} = \bigcup_{l=0}^L \mathcal{S}_l, \mathcal{S}_0 = \{s_0\}, \mathcal{S}_L = \mathcal{X}$ 。在 $L+1$ 层 $l = 0, \dots, L$ 中, 我们考虑 $K+1 \leq L+1$ 特殊层, 我们称之为连接层, 其状态称为中心状态。我们用 $m_0, \dots, m_K$ 表示这些层的索引, 并约束 $m_0 = 0$ 表示仅包含源状态的层, 而 $m_K = L$ 表示终止状态 $\mathcal{X}$ 。在每个非终止连接层 $m_k \neq L$ 上, 我们定义一个状态流函数 $F_k: \mathcal{S}_{m_k} \rightarrow \mathbb{R}_+^*$ 。给定任何与 DAG $\mathcal{G}$ 一致的正向和反向策略 P_F 和 P_B , 状态流函数定义了两个部分轨迹上的分布集合 $\check{p}_k$ 和 $\hat{p}_k$, 这些部分轨迹始于状态 $s_{m_k} \in \mathcal{S}_{m_k}$ 并结束于状态 $s_{m_{k+1}} \in \mathcal{S}_{m_{k+1}}$ (我们用 $\mathcal{T}_k$ 表示这些部分轨迹的集合, 对于 $k = 0 \dots K-1$):

$$\forall \tau_k = (s_{m_k} \rightarrow \dots \rightarrow s_{m_{k+1}}) \in \mathcal{T}_k \quad \hat{p}_k(\tau_k) \propto F_k(s_{m_k}) P_F(\tau_k), \quad (20)$$

$$\forall \tau_k = (s_{m_k} \rightarrow \dots \rightarrow s_{m_{k+1}}) \in \mathcal{T}_k \quad \check{p}_k(\tau_k) \propto F_{k+1}(s_{m_{k+1}}) P_B(\tau_k | s_{m_{k+1}}), \quad (21)$$

其中 F_K 固定为目标奖励函数 R 。

引理 1 如果 $\hat{p}_k = \check{p}_k$ 对于所有 $k = 0 \dots K-1$ 成立, 则正向策略 P_F 诱导的终止状态分布 $P_F^{\dagger}$ 匹配目标未归一化分布 (或奖励函数) R 。

Proof Consider a complete trajectory $\tau = (s_{m_0} \rightarrow \dots \rightarrow s_{m_1} \rightarrow \dots \rightarrow \dots \rightarrow s_{m_2} \rightarrow \dots \rightarrow \dots \rightarrow s_{m_K})$. 并且令 $\tau_k = (s_{m_k} \rightarrow \dots \rightarrow s_{m_{k+1}})$ $k < K$. 对于每一个表示, 记 $\hat{Z}_k$ 和 $\check{Z}_k$ 分别为 $\hat{p}_k$ 和 $\check{p}_k$ 的划分函数 (即 (18) 式中的比例常数), 对于每一个 $k < K$ 。容易看出对于每一个 $0 < k < K$:

$$\hat{Z}_{k+1} = \check{Z}_k = \sum_{s_{m_{k+1}} \in \mathcal{S}_{m_{k+1}}} F_{k+1}(s_{m_{k+1}}) \quad (22)$$

$$\prod_{k=0}^{K-1} \hat{p}_k(\tau_k) = \frac{\prod_{k=0}^{K-1} F_k(s_{m_k})}{\prod_{k=0}^{K-1} \hat{Z}_k} P_F(\tau), \quad (23)$$

$$\prod_{k=0}^{K-1} \check{p}_k(\tau_k) = \frac{\prod_{k=0}^{K-1} F_{k+1}(s_{m_{k+1}})}{\prod_{k=0}^{K-1} \check{Z}_k} P_B(\tau | s_{m_K}). \quad (24)$$

因为对于所有 $\hat{p}_k = \check{p}_k \dots K \quad k = 0$, 则 (23) 和 (24) 的右侧相等。结合 (22), 我们得到: -1

$$\forall \tau \in \mathcal{T} \quad \underbrace{\frac{F_0(s_0)}{\hat{Z}_0}}_{=1} P_F(\tau) = \frac{R(x_\tau)}{\sum_{x \in \mathcal{X}} R(x)} P_B(\tau | x), \quad (25)$$

这表明对于所有 $\tau \in \mathcal{T}$, TB 约束均得到满足。Malkin 等人 (2022) 证明, 这是由 P_F 诱导的终止状态分布与目标奖励函数 R 相匹配的充分条件, 从而完成证明。 ■

类似于 NVII, 我们可以利用引理 1 定义目标函数的形式为: P_F, P_B, F_k ,

$$\mathcal{L}_{\text{SubNVI},f}(P_F, P_B, F_{0:K-1}) = \sum_{k=1}^{K-1} D_f(\check{p}_k \| \hat{p}_k) \quad (26)$$

需要注意的是, 当所有层均为连接层 (即 $K = L$, 对于所有 $k \leq L$, $m_k = k$), 子 NVI 目标 (26) 与 NVI 目标 (Zimmermann 等, 2021) 一致; 而仅当首尾两层为连接层 (即 $K = 1, m_0 = 0$, $m_1 = L$) 时, 子 NVI 目标 (26) 与 HVI 目标 (5) 一致。

C.2 子 NVI 与子 TB 目标之间的等价性

命题 2 给定一个分级有向无环图 G , 如 §2.1 所述, 以及连接层 $m_0 = 0, m_1, \dots, m_K = L$, 如 §C.1 所述。对于任何前向和后向策略, 以及对于定义在中心节点上的任意正函数 F_k , 考虑在 (20) 和 (21) 中定义的 $\hat{p}_k$ 和 $\check{p}_k$ 。子轨迹变分目标 (26) 等价于特定选择的 f -发散下的子轨迹平衡目标 (17)。具体来说, 记 θ, ϕ 分别为 P_F, P_B 的参数:

$$\mathbb{E}_{\tau_k \sim \check{p}_k} [\nabla_{\phi} \mathcal{L}_{\text{SubTB}}(\tau_k; P_F, P_B, F)] = 2 \nabla_{\phi} D_{f_1}(\check{p}_k \| \hat{p}_k) \quad (27)$$

$$\mathbb{E}_{\tau_k \sim \hat{p}_k} [\nabla_{\theta} \mathcal{L}_{\text{SubTB}}(\tau_k; P_F, P_B, F)] = 2 \nabla_{\theta} D_{f_2}(\check{p}_k \| \hat{p}_k) \quad (28)$$

哪里 $F = F_{0:K-1}$, 和 $f_1: t \mapsto t \log t$ 和 $f_2: t \mapsto -\log t$ 。

Proof For a subtrajectory $\tau_k = (s_{m_k} \rightarrow \dots \rightarrow s_{m_{k+1}}) \in \mathcal{T}_k$, let $c(\tau_k) = \log \frac{F_k(s_{m_k})P_F(\tau_k)}{F_{k+1}(s_{m_{k+1}})P_B(\tau_k | s_{m_{k+1}})}$.

首先, 注意到 $\hat{Z}_k$ 和 $\check{Z}_k$ 不是 ϕ 的函数 $\theta((23))$:

$$\nabla_{\phi} c(\tau_k) = -\nabla_{\phi} \log \frac{F_{k+1}(s_{m_{k+1}})P_B(\tau_k | s_{m_{k+1}})}{\check{Z}_k} = -\nabla_{\phi} \log \check{p}_k(\tau_k) \quad (29)$$

$$\nabla_{\theta} c(\tau_k) = \nabla_{\theta} \log \frac{F_k(s_{m_k})P_F(\tau_k)}{\hat{Z}_k} = \nabla_{\theta} \log \hat{p}_k(\tau_k) \quad (30)$$

我们将证明 (27)。对于 (28) 的证明，采用相同的推理过程，此处留给读者作为练习。

$$\begin{aligned}
 D_{f_1}(\check{p}_k \| \hat{p}_k) &= D_{KL}(\check{p}_k \| \hat{p}_k) \\
 \nabla_\phi D_{f_1}(\check{p}_k \| \hat{p}_k) &= \nabla_\phi \sum_{\tau_k \in \mathcal{T}_k} \check{p}_k(\tau_k) \log \frac{\check{p}_k(\tau_k)}{\hat{p}_k(\tau_k)} \\
 &= -\nabla_\phi \sum_{\tau_k \in \mathcal{T}_k} \check{p}_k(\tau_k) c(\tau_k) + \underbrace{\nabla_\phi \log \frac{\hat{Z}_k}{\check{Z}_k}}_{=0, \text{ according to (23)}} \\
 &= -\sum_{\tau_k \in \mathcal{T}_k} (\nabla_\phi \check{p}_k(\tau_k) c(\tau_k) + \check{p}_k(\tau_k) \nabla_\phi c(\tau_k)) \\
 &= -\sum_{\tau_k \in \mathcal{T}_k} (\check{p}_k(\tau_k) \nabla_\phi \log \check{p}_k(\tau_k) c(\tau_k) + \check{p}_k(\tau_k) \nabla_\phi c(\tau_k)) \\
 &= -\mathbb{E}_{\tau_k \sim \check{p}_k} [\nabla_\phi \log \check{p}_k(\tau_k) c(\tau_k)] + \sum_{\tau_k \in \mathcal{T}_k} \check{p}_k(\tau_k) \nabla_\phi \log \check{p}_k(\tau_k) \quad \text{following (29)} \\
 &= -\mathbb{E}_{\tau_k \sim \check{p}_k} [\nabla_\phi \log P_B(\tau_k | s_{m_{k+1}}) c(\tau_k)] + \underbrace{\nabla_\phi \sum_{\tau_k \in \mathcal{T}_k} \check{p}_k(\tau_k)}_{=0} \\
 &= \mathbb{E}_{\tau_k \sim \check{p}_k} \left[\nabla_\phi \log P_B(\tau_k | s_{m_{k+1}}) \log \frac{F_{k+1}(s_{m_{k+1}}) P_B(\tau_k | s_{m_{k+1}})}{F_k(s_{m_k}) P_F(\tau_k)} \right] \\
 &= \frac{1}{2} \mathbb{E}_{\tau_k \sim \check{p}_k} \left[\nabla_\phi \left(\log \frac{F_k(s_{m_k}) P_F(\tau_k)}{F_{k+1}(s_{m_{k+1}}) P_B(\tau_k | s_{m_{k+1}})} \right)^2 \right] \\
 &= \frac{1}{2} \mathbb{E}_{\tau_k \sim \check{p}_k} [\nabla_\phi \mathcal{L}_{\text{SubTB}}(\tau_k; P_F, P_B, F)] \quad \blacksquare
 \end{aligned}$$

作为命题 2 的一个特例，当状态流函数仅对 s_0 定义（对于终止状态，其等于目标奖励函数），即当 $K = 1$ 时，分布 $\hat{p}_0(\tau)$ 和 $P_F(\tau)$ 相等，分布 $\check{p}_0(\tau)$ 和 $P_B(\tau)$ 也相等。因此，我们从命题 2 得出命题 1 的前两个方程。

D 额外的实验细节

D.1 超网格实验

关于环境的细节 为了完整性，我们提供了更多关于环境的细节，如 Malkin 等人 (2022) 所述。在一个维度为 D 的超网格中，边长为 H ，状态空间 $\mathcal{S}$ 被划分为非终止状态 $\mathcal{S}^o = \{0, \dots, H-1\}^D$ 和终止状态 $\mathcal{S}^\tau = \{0, \dots, H-1\}^D$ 。初始状态是 $\mathbf{0}_{\mathbb{R}^D} = (0, \dots, 0) \in \mathcal{S}^o$ ，除了从一个非终止状态到另一个非终止状态的转换（通过增加状态的一个坐标），对于所有 $s \in \mathcal{S}^o$ ，还可用一个“退出”动作，该动作将导向一个终止状态 $s^\tau \in \mathcal{S}^\tau$ 。在终止状态 $s^\tau = (s^1, \dots, s^D)^\tau$ 处的奖励为：

$$R(s^\tau) = R_0 + 0.5 \prod_{d=1}^D \mathbf{1} \left[\left| \frac{s^d}{H-1} - 0.5 \right| \in (0.25, 0.5] \right] + 2 \prod_{d=1}^D \mathbf{1} \left[\left| \frac{s^d}{H-1} - 0.5 \right| \in (0.3, 0.4) \right], \quad (31)$$

其中 R_0 是一个探索参数（较低值表示更难的探索）。

架构细节 前向和后向策略被参数化为具有两个隐藏层的神经网络，每层有 256 个单元。神经网络接受状态的一热表示（也称为 K 热或多热表示）作为输入，这是一个包含确切 D 个 1 和 $(H-1)D$ 个 0 的 $H \times D$ 向量，并分别输出 P_F 和 P_B 的对数概率。当一个坐标已经被最大化至 $H-1$ 时，禁止的动作通过在前向传递后将相应的对数概率设置为 $-\infty$ 来屏蔽。与 Malkin 等人 (2022) 不同，我们不绑定 P_F 和 P_B 。




图 D.1: 比较所使用的基线类型（局部或全局）用于三种使用梯度评分函数估计器的 HVI 算法。

行为策略 行为策略是从前向策略 P_F 通过从前向策略神经网络输出的对数概率中减去一个标量 ϵ 获得的。 ϵ 的值从 ϵ_{init} 衰减到 0，遵循余弦退火计划 (Loshchilov & Hutter, 2017)，并在迭代 T_{max} 时达到值 $\epsilon = 0$ 。 ϵ_{init} 和 T_{max} 的值被视为超参数。

超参数优化 我们的实验表明，HVI 目标对超参数的选择（主要是学习率）非常敏感，并且 Malkin 等人 (2022) 在轨迹平衡中使用的超参数在我们考虑的更大 128×128 网格中表现不佳。为了在 GFlowNets 和 HVI 方法之间进行公平比较，特别关注了该领域的超参数优化。优化过程分为两个阶段：

1. 对于所有学习目标，无论是在线策略还是离线策略，均采用批大小为 64，并使用 Adam 优化器，其次级参数设置为其默认值，对于 P_F 的参数、 P_B 的参数以及初始化为 0 的 $\log Z$ 。学习率 P_F 、 P_B 、 $\log Z$ ，以及一个调度因子 $\gamma < 1$ ，当 JSD 在超过 500 次迭代（即采样 500×64 轨迹）后趋于平稳时，它们将被乘以该调度因子。针对每种学习目标和采样方法（在线策略或离线策略）组合，分别通过贝叶斯搜索寻找上述参数，其中优化目标是在 200K 轨迹上评估的 JSD。HVI 方法（除 WS 外，WS 没有梯度的得分函数估计器）的基线选择也被视为超参数。

2. 然后，所有目标在第一阶段找到的所有超参数组合下，每种组合使用 5 个种子进行训练，共训练了 10^6 条轨迹。最终，对于每个目标和采样模式，选择导致 JSD 曲线（用梯形法近似计算）面积最小的那一组超参数。

对于离线策略运行， T_{max} 被定义为总迭代次数的分数 $1/n$ （等于 $10^6/64$ ）。 n 和 ϵ_{init} 的值也像学习率和调度一样进行了优化，如上所述。

在图 D.1 中，我们展示了两类型基线（全局和局部）之间的差异，这两种基线用于三种使用梯度得分函数估计器的算法，无论是在线策略还是离线策略。

较小的环境： 本文研究的环境（ 128×128 ，其中包含 $R_0 = 10^{-3}$ ）已经展示了正向和反向 KL 目标之间的一些关键差异。作为对在这一具有挑战性的环境中未能收敛的 HVI 方法的合理性检查，我们考虑了两个替代网格： 64×64 和 $8 \times 8 \times 8 \times 8$ ，这两个网格都具有一个更容易探索的参数（ $R_0 = 0.1$ ），并在这些额外的领域上比较了这五种算法的在线性能。此外，对于二维域（ 64×64 ），我们在图 D.2 中展示了每种方法分别采样 10^6 条轨迹后获得的平均分布的可视化表示。有趣的是，与困难探索域不同，两种模式寻找 KL 算法（反向 KL 和反向 WS）比均值寻找 KL 算法（正向 KL 和 WS）收敛到更低的 JSD，并且与 TB 算法相当。

D.2 分子实验

大多数实验设置与 Malkin 等人 (22 年) 的研究相同，特别是奖励模型（ f 用于计算性能度量的分子保留集）以及 GFlowNet 模型




图 D.2: 上: 在 $8 \times 8 \times 8 \times 8$ 网格左侧和 64×64 网格右侧, JSD (Jensen-Shannon Divergence) 随学习采样器 $P_F^\top$ 与目标分布之间的演化。轨迹按策略采样。阴影区域表示在 5 次不同运行中计算的标准误差。下: 不同算法最终学习到的分布 $P_F^\top$ 的平均值 (基于 5 次运行), 以及目标分布。为了放大变化, 图中每个网格位置的强度从 5 次运行中分布的高斯近似重新采样。

架构 (一种由 Bengio 等人 (2021a) 引入的图神经网络) 和离线探索率。所有模型均使用 Adam 优化器和批大小 4 进行训练, 最多训练 50000 个批次。度量在每 5000 个批次后计算, 并报告最后一次计算的度量值, 有时这并不是在 50000 个批次后的值, 因为由于数值错误导致训练提前终止。

D.3 贝叶斯结构学习实验

贝叶斯网络 贝叶斯网络是一种概率模型, 其中联合分布 d 随机变量 $\{X_1, \dots, X_d\}$ 根据有向无环图 (DAG) 进行分解 G :

$$p(X_1, \dots, X_d) = \prod_{i=1}^d p(X_i | \text{Pa}_G(X_i)),$$

其中 $\text{Pa}_G(X_i)$ 是图 G 中变量 X_i 的父节点集合。因子分解中的每个条件分布都与参数集 $\theta \in \Theta$ 相关联。贝叶斯网络的结构 G 通常被认为是已知的。然而, 当结构未知时, 我们可以基于观察数据集 D 来学习它: 这被称为结构学习。

状态空间的结构 我们使用与 (Deleu 等, 2022) 中描述相同的分级有向无环图 G 的结构, 其中 G 的每个状态本身是一个有向无环图 G , 动作对应于向当前图 G 添加一条边以过渡到新图 G' 。只有那些保持有向无环图 G' 无环性的动作被视为有效; 这确保了所有状态都是定义良好的有向无环图, 意味着所有状态在这里都是终止的 (我们在有向无环图上定义了一个分布)。类似于超网格环境, 动作空间还包含一个额外的动作“停止”, 用于终止生成过程, 并将当前图作为我们分布的一个样本返回; 这个“停止”动作表示为 $G \rightarrow G^\top$, 以遵循 § 2.1 中引入的符号。

奖励函数 在贝叶斯结构学习中, 我们的目标是在给定观察数据集 D 的情况下近似有向无环图 $p(G | D)$ 上的后验分布。由 $G \rightarrow R(G)$ 于我们的目标是找到一个前向策略 P_F , 使得 $P^\top$ (见 § 2.1), 我们可以将奖励函数定义为联合分布 $R(G) = p(G, D) = p(D | G)p(G)$, 其中 $p(G)$ 是对图的先验 (假设在整个论文中是均匀的), 而 $p(D | G)$ 是边缘似然。由于边缘似然涉及对贝叶斯网络参数进行边缘化

$$p(D | G) = \int_{\Theta} p(D | \theta, G) p(\theta | G) d\theta,$$

一般情况下是不可计算的。这里我们考虑一类特殊的模型, 称为线性高斯模型, 在这类模型中, 边缘似然可以闭式计算; 对于这类模型, 对数边缘似然在结构学习文献中也被称为 BGe 得分 (Geiger & Heckerman, 1994; Kuipers 等, 2014)。




图 D.3: 使用目标后验分布和使用通过 GFlowNet 目标或反向 KL 找到的后验近似计算的边缘的比较。性能报告为边缘之间的均方根误差 (RMSE) (越低越好)。

对于每次实验，我们从随机生成的贝叶斯网络中抽取一个包含 100 个样本的数据集 $\mathcal{D}$ 。贝叶斯网络的结构（真实结构）遵循 Erdős-Rényi 模型生成，平均拥有约 d 条边（以鼓励在如此小的图上具有稀疏性，图中有 $d \leq 5$ 个节点）。一旦结构确定，线性高斯模型的参数将从标准正态分布 $\mathcal{N}(0, 1)$ 中随机抽取。关于数据生成过程的更多细节，请参见 (Deleu 等, 2022)。对于每种设置（不同值的 d ）和每个目标，我们在 20 个不同的种子上重复实验。

前向策略 德吕等人 (2022) 参数化了前向策略 P_F 采用线性变换器，考虑所有 d^2 图中的可能边 G 作为输入，并返回这些边的概率分布，其中无效动作被屏蔽。本文选择参数化 P_F 采用更为简单的神经网络架构，基于图神经网络 (Battaglia 等, 2018)。图神经网络 (GNN) 接受图作为输入 G 作为输入，其中图中的每个节点都关联一个（学习到的）嵌入，并为每个节点返回 X_i 一对嵌入 u_i 和 v_i 添加边的概率 $X_i \rightarrow X_j$ 从 G 过渡到 G' （在不终止于 G ）的情况下，该概率由以下给出

$$P_F(G' | G, \neg G^\top) \propto \exp(u_i^\top v_j),$$

assuming that $X_i \rightarrow X_j$ is a valid action (i.e., it doesn't introduce a cycle in G), and where the normalization depends only on all the valid actions. We then use a hierarchical model to obtain the forward policy $P_F(G' | G)$, following (Deleu et al., 2022):

$$P_F(G' | G) = (1 - P_F(G^\top | G))P_F(G' | G, \neg G^\top).$$

回忆一下，反向策略 P_B 在这里是固定的，即在 G 的所有父节点上进行均匀分布（也就是说，所有的图都是从 G 中恰好移除了一条边的结果

(修改后的) 详细平衡目标 为了完整性，我们在此回忆修改后的详细平衡 (DB) 目标 (Deleu 等, 2022)，作为 DB 目标 (Bengio 等, 2021b; 参见 (16)) 的一个特殊情况，当 G 的所有状态都是终止状态时（这在我们的贝叶斯结构学习实验中是成立的）：

$$\mathcal{L}_{(M)DB}(G \rightarrow G'; P_F, P_B) = \left(\log \frac{R(G')P_B(G | G')P_F(G^\top | G)}{R(G)P_F(G' | G)P_F(G^\top | G)} \right)^2.$$

优化 遵循 (Deleu 等, 2022)，我们为所有离线策略目标 ((修改后的)DB、TB 和 REVERSE KL) 使用了一个回放缓冲区。所有目标均通过批大小为 256 的图进行优化，这些图要么是从线上策略中抽取的 P_F ，要么是从回放缓冲区中抽取的。我们使用 Adam 优化器，最佳学习率在 $\{10^{-6}, 3 \times 10^{-6}, 10^{-5}, 3 \times 10^{-5}, 10^{-4}\}$ 中找到。对于 TB 目标，我们使用学习率为 0.1 和动量为 0.8 的 SGD 来学习 $\log Z$ 。

边缘边际 除了真实后验分布之间的 Jensen-Shannon 发散 $\mathcal{D}_{JS}(G)$ (JSD) 之外 $p(G | \mathcal{D})$ 以及后验近似 $P^\top$ (详见 § E 关于此方法的详细信息

计算发散后，我们也比较了两种分布下计算得到的边缘概率。也就是说，对于图中的任意边 $X_i \rightarrow X_j$ ，我们进行比较

$$p(X_i \rightarrow X_j | \mathcal{D}) = \sum_{G | X_i \in \text{Pa}_G(X_j)} p(G | \mathcal{D}) \quad \text{和} \quad P_F^\top(X_i \rightarrow X_j) = \sum_{G | X_i \in \text{Pa}_G(X_j)} P_F^\top(G).$$

边边际量化的是一种边 $X_i \rightarrow X_j$ 存在于贝叶斯网络结构中的可能性，这一概念在（贝叶斯）结构学习文献中尤为重要。为了衡量后验近似 $P_F^\top$ 对于不同目标的准确性，我们使用均方根误差（RMSE）来比较 $p(X_i \rightarrow X_j | \mathcal{D})$ 与 $P_F^\top(X_i \rightarrow X_j)$ ，之间所有可能节点对 (X_i, X_j) 在图中的差异。

图 D.3 展示了不同 GFlowNet 目标和反向 KL（简记为 HVI）下的边缘边际 RMSE。关于边缘边际的结果大体上证实了 § 4.3 中的观察：离线策略 GFlowNet 目标（（修改后的）DB 及 TB）在所有实验设置下表现一致良好；在线策略 TB 及在线策略反向 KL 表现相似，并随着实验复杂度的增加而下降（当 d 增加时）；离线策略反向 KL 的表现随复杂度增加下降最为明显，其中由 $P_F^\top(X_i \rightarrow X_j)$ 给出的边缘边际与真实边缘边际 $p(X_i \rightarrow X_j | \mathcal{D})$ 不匹配。

E 度量

终止状态分布的评估 $P_F^\top$ ：当状态空间足够小（例如，图具有 $d \leq 5$ 在结构学习实验中的节点，或者在超网格实验中的长度为 128 的二维超网格上，我们可以传播流以计算终止状态分布 $P_F^\top$ 来自前向策略 P_F 这通过流动函数实现 F 递归定义：

$$F(s') = \begin{cases} 1 & \text{if } s' = s_0 \\ \sum_{s \in \text{Par}(s')} F(s) P_F(s' | s) & \text{otherwise} \end{cases} \quad (32)$$

$P_F^\top$ 然后由下式给出：

$$P_F^\top(s^\top) \propto F(s) P_F(s^\top | s), \quad (33)$$

递归可以通过动态规划实现，在与分级有向无环图 G 一致的任何拓扑排序中枚举状态。特别是，在给定终止状态下计算流 s 其时间复杂度与通往该状态的所有轨迹上的状态和动作数量成线性关系 s ，而计算完整的分布 $P_F^\top$ 其时间复杂度也与 $|S| + |A|$ 。

Jensen-Shannon 发散（JSD）的评估 类似地，当状态空间足够小时，目标分布 $P^\top = R/Z^*$ 可以精确评估，前提是边缘化仅针对 X 。JSD 是对称发散，因此激励我们的选择。JSD 可以直接评估为：

$$JSD(P^\top \| P_F^\top) = \frac{1}{2} (D_{\text{KL}}(P^\top \| M) + D_{\text{KL}}(P_F^\top \| M)) \quad \text{where } M = (P^\top + P_F^\top)/2 \quad (34)$$

$$= \frac{1}{2} \sum_{s \in S^o} \left(P^\top(s) \log \frac{2P^\top(s)}{P^\top(s) + P_F^\top(s)} + P_F^\top(s) \log \frac{2P_F^\top(s)}{P^\top(s) + P_F^\top(s)} \right) \quad (35)$$

F 连续域的扩展

作为理解具有连续动作空间的 GFlowNets 的第一步，我们在一个随机控制问题上进行了实验。该实验的目标是探索主要文本中的观察结果是否同样适用于连续设置。我们考虑一个环境，其中代理从平面上的点 $\mathbf{x}_0 = (0,0)$ 开始，并在时间间隔 $[0, 1]$ 内通过一系列 $K = 10$ 步移动到点 $\mathbf{x}_{0.1}, \mathbf{x}_{0.2}, \dots, \mathbf{x}_1$ 。从 $\mathbf{x}_t$ 到 $\mathbf{x}_{t+0.1}$ 的每一步都是高斯分布，其均值依赖于 $\mathbf{x}_t$ 和 t 并具有固定的方差；方差是各向同性的，标准差为 $1/2\sqrt{\Delta t}$ 。等价地，代理采样 Euler-Maruyama 离散化，区间为 $\Delta t = \frac{1}{K}$

伊藤随机微分方程

$$d\mathbf{x}_t = f(\mathbf{x}_t, t) dt + \frac{1}{2} d\mathbf{w}_t, \quad (36)$$

其中 $\mathbf{w}_t$ 是二维维纳过程。

漂移函数 f 的选择决定了最终点的边缘密度，即 $\mathbf{x}_1$ 。我们的目标是找到 f ，使得这个边缘密度与给定的奖励函数成正比，在这种情况下，该奖励函数是一个量，它与标准高斯分布的概率密度函数成正比，如图 F.2 所示。我们将分布进行缩放，使得 8 个高斯成分的峰点距离原点的距离为 2，它们的标准差为 0.25。

在 GFlowNet 术语中，状态集是 $\mathcal{S} = \{(\mathbf{0}, 0)\} \cup \{(\mathbf{x}, t) : \mathbf{x} \in \mathbb{R}^2, t \in \{0.1, 0.2, \dots, 1\}\}$ 。具有 $t = 1$ 的状态是终止状态。从 $(\mathbf{x}, t)$ 到 $(\mathbf{x}', t')$ 的动作存在当且仅当 $t' = t + \Delta t$ 。前向策略由条件高斯给出：

$$P_F((\mathbf{x}', t + \Delta t) | (\mathbf{x}, t)) = \mathcal{N}\left(\mathbf{x}' - \mathbf{x}; f(\mathbf{x}, t)\Delta t, \left(\frac{\sqrt{\Delta t}}{2}\right)^2\right). \quad (37)$$

We impose a conditional Gaussian assumption on the backward policy as well, i.e.,

$$P_B((\mathbf{x}, t) | (\mathbf{x}', t + \Delta t)) = \begin{cases} \mathcal{N}(\mathbf{x} - \mathbf{x}'; \mu_B(\mathbf{x}', t + \Delta t)\Delta t, \sigma_B^2(\mathbf{x}', t + \Delta t)\Delta t) & t \neq 0 \\ 1 & t = 0 \end{cases}, \quad (38)$$

其中 μ_B 和 $\log \sigma_B^2$ 是学习得到的。请注意，除了从时间 $1/K$ 到时间 0 的后向策略外，所有策略现在都表示概率密度；状态可以有不可数无限数量的子节点和父节点。

我们将三个函数 $f, \mu_B, \log \sigma_B^2$ 参数化为小型（两层隐藏层，每层 64 个单元）多层感知机，输入为位置 $\mathbf{x}$ 和时间的嵌入 t 。它们的参数可以通过表 1 中的五种算法之一进行优化。³ 图 F.1 展示了不同 t 下训练良好的模型中 $\mathbf{x}_t$ 的边缘密度（使用 KDE 估计），以及一些采样的点和路径。

除了基于策略的训练外，我们还考虑了探索性训练策略，这些策略向每个转移分布的均值添加高斯噪声。我们实验了添加标准正态噪声，其缩放因子为 σ_{exp} ，其中 $\sigma_{\text{exp}} \in \{0, \{0.1, 0.2\}\}$ 。

图 F.2 比较了使用不同算法在在线和离线训练中获得的边缘密度。使用前向 KL 目标进行学习的算法 P_B – 即反向 WS 和正向 KL – 未展示，因为在训练初期即使使用了 $10\times$ 比其他所有算法使用的更低的学习率（ 10^{-3} 对于参数

$f, \mu_B, \log \sigma_B^2$ 和 10^{-1} $\log Z$ 对于 GFlowNet 的参数）。

这些结果表明，对于离散空间 GFlowNet 在正文中的观察可能在连续设置中继续成立。图 F.2 的前两行显示，离策略探索对于找到模式至关重要，并且 TB 达到了更好的目标分布拟合。正如图 1 所示，尽管所有模式都由 WAKE-SLEEP 找到，但它们被建模得精确度较低，显得偏离中心并且形状呈椭圆形，这反映在稍高的 MMD 上。

³ 我们猜想（并在温和假设下强烈相信）但未证明，当概率被概率密度取代时，必要的 GFlowNet 理论仍然成立；这里获得的结果支持这一猜想。




图 F.1: 上方: KDE (2560 个样本, 带宽 0.25) 显示了代理在执行 i 步后的位置分布。 $i = 0, 1, \dots, 10$ ($t = 0, 0.1, \dots, 1$) 对于使用离线策略 TB 训练的模型, 显示与目标分布 (同样通过 KDE 核函数进行卷积以公平比较) 的紧密匹配。下方: 从训练模型中抽取的 2560 个点样本以及其中 128 个点所采取的轨迹。

Algorithm	On-Policy	Off-Policy	
	$\sigma_{\text{exp}} = 0$	$\sigma_{\text{exp}} = 0.1$	$\sigma_{\text{exp}} = 0.2$
TB			
MMD	0.1111	0.0005	0.0075
REVERSE KL			
MMD	0.0027	0.0059	0.0036
WAKE-SLEEP			
MMD	0.0008	0.0036	0.0043
目标			

图 F.2: 使用各种算法和探索策略学习到的边缘分布的 KDE 以及使用高斯核计算的 MMD $\exp(-\|\mathbf{x} - \mathbf{y}\|^2)$, 估计使用了 2560 个样本。