

从变分视角看生成流网络

Heiko Zimmermann

*Amsterdam Machine Learning Lab,
University of Amsterdam*

h.zimmermann@uva.nl

Fredrik Lindsten

*Division of Statistics and Machine Learning,
Linköping University*

fredrik.lindsten@liu.se

Jan-Willem van de Meent

*Amsterdam Machine Learning Lab,
University of Amsterdam*

j.w.vandemeent@uva.nl

Christian A. Naesseth

*Amsterdam Machine Learning Lab,
University of Amsterdam*

c.a.naesseth@uva.nl

摘要

生成流网络（GFNs）是一类用于顺序采样复合对象的模型，它们通过能量函数或奖励来近似目标分布。GFNs 通常使用流匹配或轨迹平衡目标进行训练，这些目标在轨迹上匹配前向和后向转换模型。在这项工作中，我们将 GFNs 的变分目标定义为前向和后向分布之间的 Kullback-Leibler（KL）发散。我们证明，在从前向模型中采样轨迹时，GFNs 中的变分推断等价于最小化轨迹平衡目标。我们通过优化反向和前向 KL 发散的凸组合来推广这一方法。这一洞见表明，变分推断方法可以作为一种手段，定义一个更广泛的训练生成流网络的目标族，例如，通过引入控制变量来减少轨迹平衡目标梯度的方差，这在变分推断中经常被使用。我们通过数值比较两个合成任务上的轨迹平衡目标来评估我们的发现和所提出的变分目标的性能。

1 引言

生成流网络（GFNs）（Bengio 等人，2021a;b）最近被提出作为一种计算效率高的方法，用于采样复合对象，如分子字符串（Bengio 等人，2021a）、DNA 序列（Jain 等人，2022）或图（Deleu 等人，2022）。为了生成此类对象，GFNs 沿着有向无环图（DAG）采样一条轨迹，在该图中，边对应于修改对象的动作。轨迹通过从根节点（初始对象，或空状态）到终止节点（最终复合对象）的逐步转换来构建对象，并根据奖励信号进行评分。尽管在强化学习文献中（Sutton 和 Barto，2018）对动作序列的采样已有广泛研究，但目标通常是找到一个最大化轨迹预期奖励的策略。相比之下，GFNs 通过学习一种分布来训练策略，这种分布覆盖了以概率与分配给它的奖励成比例的终止状态结束的轨迹，从而解决了一个规划作为推理的问题（Toussaint 等人，2006）。这是通过优化旨在满足流匹配或细致平衡条件的目标来实现的（Bengio 等人，2021a）。Malkin 等人（22b）发现这些目标容易导致无效的信用传播，并提出了基于轨迹的替代目标。

平衡 (TB) 条件以缓解这些问题。最近, Madan 等人 (2022) 提出了一种可以在部分轨迹上优化的目标函数, 而 Do 等人 (2022) 则提出了一种基于最优传输的目标函数, 以进一步提升泛化能力和探索能力。

正向奖励函数可以解释为一个未归一化的分布, 我们希望从中生成样本。在这种视角下, 我们对从因子化联合分布中顺序采样感兴趣, 使得最终状态的边缘分布近似等于相应的归一化分布。从一个未归一化的目标分布生成近似样本是概率推理中的常见任务, 为此已经开发了许多方法。这些方法包括基于 MCMC 的方法 (Hoffman 和 Gelman, 2014; Salimans 等, 2015; Li 等, 2017; Hoffman, 2017; Naesseth 等, 2021; Zhang 等, 2022c), 重要性采样 Neal (2001); Del Moral 等 (2006); Naesseth 等 (2019) 以及变分推断 (Blei 等, 2017; Naesseth 等, 2018; Maddison 等, 2017; Le 等, 2018; Zimmermann 等, 2021)。Zhang 等 (2022b) 关于 GFNs 的近期工作采取了类似的观点, 将奖励函数视为基于能量的模型, 可以通过对比发散方法 (Hinton, 2002) 来训练以最大化数据似然, 同时通过优化 TB 目标来训练前向和后向转移模型。

在本研究中, 我们展示了, 在某些情况下, 优化 TB 目标确实等价于优化前向或逆向 Kullback-Leibler 发散。为此, 我们将优化 TB 目标时分别使用从前向转移模型、后向转移模型或两者混合生成的样本进行比较, 与使用相应变分目标进行训练的情况进行对比, 该变分目标的形式为前向和逆向 Kullback-Leibler 发散的凸组合。我们识别出 TB 目标等价于相应变分目标的情况, 并利用这一洞见应用来自变分推断的方差缩减技术。最后, 我们进行了实验, 以评估我们的理论发现和轨迹平衡及其相应变分目标的经验性能。

相关工作 张等人 (2022a) 近期的工作识别出 GFN 与某些生成模型类别之间的等价性。作者观察到, 层次变分自编码器等价于一类特殊的 GFN, 并且通过使用 GFN 完整后向和前向转移模型之间的前向 KL 发散来训练层次隐变量模型, 等价于通过最大化其证据下界 (ELBO) 来训练层次变分自编码器。

在同时进行的独立研究中, Malkin 等人 (2022b) 推导出了与我们在本工作中建立的相同的等价关系, 即优化 TB 目标与正向和反向 KL 发散之间的等价性。我们的工作与他们的不同之处在于, 我们提出了一种基于反向和正向 Kullback-Leibler 发散的凸组合的新颖复合目标。此外, 我们在学习基于能量的模型的背景下讨论并研究了这一目标。最后, 我们也研究了当正向和反向轨迹分布共享参数时, 变分推断与轨迹平衡优化之间的差异。

2 生成流网络

生成流网络 (Bengio 等, 2021a;b) 生成轨迹 $\tau = (s_0, s_1, \dots, s_T, s_f)$ 沿着有向无环图的边 $G = (S, E)$ 每个轨迹始于根节点 s_0 并在终止状态结束, s_T 随后转换到一个特殊的最终状态, s_f 该状态是唯一的叶节点 G 非负奖励信号 $R(s_T)$ 被分配给每个终止状态 s_T 任务是学习一种采样程序, 或流, 用于模拟轨迹, 使得到达终止状态的边缘分布 s_T 与...成正比 $R(s_T)$ 。本文采用如下约定: $s_f = s_{T+1}$ 有向无环图的结构强加了一个偏序关系, $<$, 关于状态 $s, s' \in S$ 使得 $s < s'$ 如果 s 是...的祖先 s' 。因此, 任何轨迹满足 $s_j < s_k$ 对于 $0 \leq j < k \leq T + 1$ 并且因此不包含循环。

2.1 轨迹流

轨迹流是一个非负函数 $F_G : \mathcal{T} \rightarrow \mathbb{R}^+$, 定义在完整的轨迹上 $\mathcal{T}$, 即从初始状态开始 s_0 并结束于最终状态的轨迹 s_f , 这些轨迹与有向无环图 (DAG) 关联 G 。为了表示方便, 下面我们将省略图下标。轨迹流定义了一个概率测度 F , 覆盖完整的

轨迹，使得对于任何事件 $A \subseteq \mathcal{T}$

$$P(A) = \frac{F(A)}{Z}, \quad F(A) = \sum_{\tau \in A} F(\tau), \quad Z = \sum_{\tau \in \mathcal{T}} F(\tau),$$

其中 Z 可以解释为总流量。状态的流量 $F(s)$ 和边上的流量 $F(s \rightarrow s')$ 分别表示为 s, s'

$$F(s) := F(\{\tau \in \mathcal{T} : s \in \tau\}), \quad F(s \rightarrow s') := F(\{\tau \in \mathcal{T} \mid \exists t \in \mathbb{N} : s = s_t, s' = s_{t+1} \in \tau\}).$$

状态 s 被轨迹包含的概率以及前后向转移概率表示为

$$P(s) := \frac{F(s)}{Z}, \quad P_F(s' \mid s) := P(s \rightarrow s' \mid s) := \frac{F(s \rightarrow s')}{F(s)}, \quad P_B(s \mid s') := P(s \rightarrow s' \mid s) = \frac{F(s \rightarrow s')}{F(s')}.$$

若对应的概率测度满足 $P(s \rightarrow s' \mid \tau) = P(s \rightarrow s' \mid s)$ 对于任何连续的状态 s, s' 和部分轨迹 $\tau = (s_0, \dots, s)$ 结束于 s ，则称该流为马尔可夫流。对于一个马尔可夫流和完整的轨迹 $\tau \in \mathcal{T}$ ，我们有，

$$P(\tau) = \prod_{t=0}^T P_F(s_{t+1} \mid s_t) = \prod_{t=0}^T P_B(s_t \mid s_{t+1}).$$

对于流和生成流网络的全面研究，参见 Bengio 等人 (2021b)。

2.2 生成网络的训练

本文考虑 GFNs，其通过建模前向转移概率 $P_F(s' \mid s; \phi)$ 来参数化 DAG 上的马尔可夫流，并结合一个归一化常数 Z_ψ ，该常数可以解释为总流量的一个近似值。轨迹流是

$$F(\tau; \phi, \psi) = Z_\psi \prod_{t=0}^T P_F(s_{t+1} \mid s_t; \phi) = \frac{\prod_{t=0}^T F(s_t \rightarrow s_{t+1}; \phi, \psi)}{\prod_{t=0}^{T-1} F(s_{t+1}; \phi, \psi)} = Z_\psi \prod_{t=0}^T P_B(s_t \mid s_{t+1}; \phi),$$

对于奖励函数 R ，目标是找到使得 $P_B(s_T \mid s_f; \phi) = R(s_T)/Z$ 成立的转移概率。在某些场景下，我们希望固定反向转移模型，例如，均匀分布模型可能有利于探索，或者用一组不同的参数对其进行参数化 θ 。在这种情况下，正向和反向转移概率不对应相同的流，并且在稍微重载符号的情况下，我们将 $P_B(s \mid s'; \theta)$ 称为反向转移概率。

Bengio et al. (2021a) originally proposed objectives to train GFNs based on the flow matching conditions and a detailed balance condition. Malkin et al. (2022a) observe that optimizing these may lead to inefficient credit propagation to early transitions, especially for long trajectories. To alleviate this, Malkin et al. (2022a) propose an alternative TB objective for complete trajectories

$$\mathcal{L}_{\text{TB}}(\tau, \lambda) = \left(\log \frac{Z_\psi \prod_{t=0}^T P_F(s_{t+1} \mid s_t; \phi)}{R(s_T) \prod_{t=0}^{T-1} P_B(s_t \mid s_{t+1}; \theta)} \right)^2 = \left(\log \frac{Z_\psi Q(\tau; \phi)}{Z P(\tau; \theta)} \right)^2, \quad (1)$$

where $\lambda = (\phi, \theta, \psi)$ and we define

$$P(\tau; \theta) := \frac{R(s_T)}{Z} \prod_{t=0}^{T-1} P_B(s_t \mid s_{t+1}; \theta), \quad Q(\tau; \phi) := \prod_{t=0}^T P_F(s_{t+1} \mid s_t; \phi).$$

轨迹 τ 从一个具有完全支持空间的提议分布 q 中采样。时间轴目标通过随机梯度下降进行优化。关于所有参数 $\mathcal{T}$ 的梯度

$\lambda = (\phi, \theta, \psi)$ 计算为一批 S 个独立同分布样本的平均值。解对应于（负）期望梯度的不动点

$$\mathbb{E}_{\tau \sim q} \left[\frac{d}{d\lambda} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] = 0.$$

我们可以利用来自提议分布的样本计算该梯度的无偏估计值，

$$g_{\text{TB}}(\lambda) := \frac{1}{S} \sum_{s=1}^S \frac{d}{d\lambda} \mathcal{L}_{\text{TB}}(\tau_s, \lambda), \quad \tau_s \sim q.$$

在第 4 节中，我们展示了使用 TB 目标优化 GFNs 与对完整轨迹进行变分推断相对应。接下来，我们将完整轨迹上的概率质量函数（ $Q(\tau; \phi)$ ）和（ $P(\tau; \theta)$ ）分别称为前向模型和后向模型。

3 变分推断

寻找对应的前向和后向转移概率的问题可以被重新表述为一个变分推断问题。目标是找到参数（ ϕ ）和（ θ ），使得前向和后向转移概率之间的差异最小化，这个差异由合适的发散度量来衡量。两种常用的发散度量是前向 Kullback-Leibler 发散（FKL）和反向 Kullback-Leibler 发散（RKL），

$$\mathcal{L}_{\text{RKL}}(\phi, \theta) := \text{KL}(Q(\cdot; \phi) \mid P(\cdot; \theta)) = \mathbb{E}_{\tau \sim Q} \left[\log \frac{Q(\tau; \phi)}{P(\tau; \theta)} \right] = \mathbb{E}_{\tau \sim Q} [-\log w], \quad (2)$$

$$\mathcal{L}_{\text{FKL}}(\phi, \theta) := \text{KL}(P(\cdot; \theta) \mid Q(\cdot; \phi)) = \mathbb{E}_{\tau \sim P} \left[\log \frac{P(\tau; \theta)}{Q(\tau; \phi)} \right] = \mathbb{E}_{\tau \sim P} [\log w], \quad (3)$$

其中重要性权重为（ $w := P(\tau; \theta)/Q(\tau; \phi)$ ）。这些发散可以通过随机梯度下降进行优化，其梯度估计分别来自于前向模型（ Q ）和后向模型（ P ，）的样本。在大多数情况下，（ F ）的样本不易获得，需要依赖其他技术生成近似样本，例如使用重要性采样或 MCMC。

计算关于后向转移模型参数（ θ ）的（ $\mathcal{L}_{\text{RKL}}$ ）导数是直接的，依赖关系仅出现在对数权重中。我们可以使用来自前向模型的（ S ）个样本近似得到期望梯度，

$$\frac{d}{d\theta} \mathcal{L}_{\text{RKL}}(\phi, \theta) = \mathbb{E}_{\tau \sim Q} \left[-\frac{d}{d\theta} \log P(\tau; \theta) \right] \approx g_{\text{RKL}}^\theta(\phi, \theta) := \frac{1}{S} \sum_{s=1}^S -\frac{d}{d\theta} \log P(\tau_s; \theta), \quad \tau_s \sim Q(\cdot; \phi).$$

类似地，关于前向转移模型参数（ ϕ ）的（ $\mathcal{L}_{\text{FKL}}$ ）导数及其相应的梯度估计器（ g_{RKL}^ϕ ）是

$$\frac{d}{d\phi} \mathcal{L}_{\text{FKL}}(\phi, \theta) = \mathbb{E}_{\tau \sim P} \left[-\frac{d}{d\phi} \log Q(\tau; \phi) \right] \approx g_{\text{FKL}}^\phi(\phi, \theta) := \frac{1}{S} \sum_{s=1}^S -\frac{d}{d\phi} \log Q(\tau_s; \phi), \quad \tau_s \sim P(\cdot; \theta).$$

另一方面，计算（ $\mathcal{L}_{\text{RKL}}$ w.r.t. ϕ ）和（ $\mathcal{L}_{\text{FKL}}$ w.r.t. θ ）的导数涉及计算所谓的得分函数梯度，

$$\begin{aligned} \frac{d}{d\phi} \mathcal{L}_{\text{RKL}}(\phi, \theta) &= \sum_{\tau \in \mathcal{T}} \log \frac{Q(\tau; \phi)}{P(\tau; \theta)} \frac{d}{d\phi} Q(\tau; \phi) + \left(\frac{d}{d\phi} \log \frac{Q(\tau; \phi)}{P(\tau; \theta)} \right) Q(\tau; \phi) \\ &= \sum_{\tau \in \mathcal{T}} \log \frac{Q(\tau; \phi)}{P(\tau; \theta)} Q(\tau; \phi) \frac{d}{d\phi} \log Q(\tau; \phi) + Q(\tau; \phi) \frac{d}{d\phi} \log Q(\tau; \phi) \\ &= \mathbb{E}_{\tau \sim Q} \left[(-\log w + 1) \frac{d}{d\phi} \log Q(\tau; \phi) \right] = \mathbb{E}_{\tau \sim Q} \left[-\log w \frac{d}{d\phi} \log Q(\tau; \phi) \right] \end{aligned}$$

重要的是，我们可以消去额外的得分函数项（上述方程的最后一等式）作为 $\mathbb{E}_{\tau \sim Q}[a \frac{d}{d\phi} \log Q(\tau; \phi)] = 0$ 对于任何常数 a 。相应的得分函数梯度估计器因此是

$$g_{\text{RKL}}^{\phi}(\phi, \theta) := \frac{1}{S} \sum_{s=1}^S -\log w_s \frac{d}{d\phi} \log Q(\tau_s; \phi), \quad w_s := \frac{P(\tau_s; \theta)}{Q(\tau_s; \phi)}, \quad \tau_s \sim Q(\cdot; \phi).$$

类似地，我们可以计算得分函数梯度的 $\mathcal{L}_{\text{FKL}}$ w.r.t. θ 以及对应的估计器

$$\mathbb{E}_{\tau \sim P} \left[\log w \frac{d}{d\theta} \log P(\tau; \theta) \right] \approx g_{\text{FKL}}^{\theta}(\phi, \theta) := \frac{1}{S} \sum_{s=1}^S \log w_s \frac{d}{d\theta} \log P(\tau_s; \theta), \quad \tau_s \sim P(\cdot; \theta).$$

得分函数梯度估计器可能表现出高方差（Ranganath 等人，2013 年），这可能会对通过随机梯度下降学习变分近似造成问题，因此通常需要采用额外的方差缩减技术。

3.1 得分函数估计器的方差缩减技术

一种常用的减少得分函数估计器方差的技术是使用控制变量 h （Ross，1997 年）来替换梯度估计器 g 与修改后的估计器 $g' = g + c(h - \mathbb{E}[h])$ ，其中 c 是一个缩放参数。控制变量保持梯度估计器的期望值 g 不变， $\mathbb{E}[g] = \mathbb{E}[g']$ ，但有可能降低方差。确实，对于给定的控制变量 h ，我们可以最小化 g' 的方差

$$\text{Var}[g'] = \text{Var}[g] + c^2 \text{Var}[h] - 2c \text{Cov}[g, h] \quad (4)$$

关于缩放参数 c ：

$$c^* = \arg \min_c \text{Var}[g'] = \frac{\text{Cov}[g', h]}{\text{Var}[h]}.$$

得分函数 $\frac{d}{d\phi} \log Q(\tau; \phi)$ （Ranganath 等人，2013 年）是在优化逆 KL 发散时一个有用且易于计算的控制变量，我们将它作为我们的示例。使用得分函数作为控制变量简化了结果梯度估计器的表达式，使得缩放参数 c 可以直接添加到（负）对数重要性权重中，

$$\begin{aligned} g' &= \underbrace{\frac{1}{S} \sum_{i=s}^S -\log w_s \frac{d}{d\phi} \log Q(\tau_s; \phi)}_g + c \underbrace{\left(\frac{d}{d\phi} \log Q(\tau_s; \phi) - \mathbb{E} \left[\frac{d}{d\phi} \log Q(\tau; \phi) \right] \right)}_{=0} \\ &= \frac{1}{S} \sum_{i=s}^S (-\log w_s + c) \frac{d}{d\phi} \log Q(\tau_s; \phi). \end{aligned}$$

蒙特卡洛估计。我们可以估计最优缩放因子 S 独立同分布样本 $\tau_s \sim Q(\tau_s; \theta)$ 用于估计 g 然而，为了使梯度估计器保持无偏，我们必须采用留一法（LOO）估计器 $\hat{c}_s$ （Mnih 和 Rezende，2016），该方法仅利用样本 $\{\hat{\tau}_{s'} \mid s' \neq s\}$ ，使得

$$\mathbb{E} \left[\frac{1}{S} \sum_{i=s}^S (-\log w_s + \hat{c}_s) \frac{d}{d\phi} \log Q(\tau_s; \phi) \right] = \mathbb{E} \left[-\log w_s \frac{d}{d\phi} \log Q(\tau_s; \phi) \right].$$

第 d 维度的最优缩放因子的留一法估计值为 c^*

$$\hat{c}_{d,s}^* = \frac{\widehat{\text{Cov}}_s[g_d, h_d]}{\widehat{\text{Var}}_s[h_d]},$$

哪里 $\text{Cov}_s[\cdot, \cdot]$ 和 $\text{Var}_s[\cdot]$ 分别是经验 LOO 协方差和方差估计值。需要注意的是，估算最优缩放比例需要访问每个样本的梯度信息，因此在许多反向模式自动微分框架中需要进行 S 前向后向传递计算图。两个流行的非最优缩放选择，它们易于计算且不需要访问梯度信息的是 $\hat{c}_s^{\log w} = \mathbb{E}[\log w]$ 和 $\hat{c}_s^{\log Z} = \log \mathbb{E}[w]$ 及其对应的 LOO 估计器

$$\hat{c}_s^{\log w} := \frac{1}{S-1} \sum_{s'=1, s' \neq s}^S \log w_{s'} \quad \hat{c}_s^{\log Z} := \log \frac{1}{S-1} \sum_{s'=1, s' \neq s}^S w_{s'}.$$

有趣的是，对于 $\hat{c}_s^{\log w}$ ，可以证明只需计算固定的缩放因子 $\hat{c}^{\log w}$ ，并通过一个因子 $\frac{1}{S-1}$ 进行修正，即可获得对 $\frac{1}{S} \sum_{i=1}^S g'$ 的无偏估计。

$$\frac{1}{S} \sum_{i=1}^S (-\log w_s + \hat{c}_s^{\log w}) \frac{d}{d\phi} \log Q(\tau_s; \phi) = \frac{1}{S-1} \sum_{i=1}^S (-\log w_s + \underbrace{\frac{1}{S} \sum_{j=1}^S \log w_j}_{\hat{c}^{\log w}}) \frac{d}{d\phi} \log Q(\tau_s; \phi).$$

在第 4 节中，我们将展示如何利用这些方差缩减技术来训练生成流网络（GFNs），通过识别训练 GFNs 与 TB 目标等价于使用得分函数梯度估计器进行变分推断的场景。

4 生成流网络的变分推断

在 3.1 中引入的轨迹平衡目标和变分目标都试图找到一个前向模型 Q 和后向模型，使得

$$P(\tau; \theta) = \pi_T(s_T) \prod_{t=0}^{T-1} P_B(s_t | s_{t+1}; \theta) \approx \prod_{t=0}^T P_F(s_{t+1} | s_t; \phi) = Q(\tau; \phi),$$

从而终止状态 s_T 大致遵循分布 π_T ，该分布与奖励成正比 R 。尽管 TB 目标可以通过具有在 $\mathcal{T}$ 上全支持的任何提议分布生成的样本进行优化，但通常使用来自前向模型 $\tau_F \sim Q$ 或后向模型 $\tau_B \sim P$ 的样本进行优化。类似地，变分推断通常优化 RKL 发散或 FKL 发散，这些可以通过从前向模型和逆模型分别采样来估计。

Zhang et al. (2022b) propose a special case of the trajectory balance objective using a proposal that first samples a Bernoulli random variable $u \sim \mathcal{B}(\alpha)$. This variable then determines whether the trajectory samples are drawn from the forward model or the backward model. The corresponding expected gradient is

$$\mathbb{E}_{u \sim \mathcal{B}(\alpha)} \left[[u=0] \mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\frac{d}{d\lambda} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] + [u=1] \mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\frac{d}{d\lambda} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] \right] \quad (5)$$

$$= \alpha \mathbb{E}_{\tau_B \sim P(\cdot; \theta)} \left[\frac{d}{d\lambda} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] + (1 - \alpha) \mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\frac{d}{d\lambda} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right]. \quad (6)$$

我们可以通过近似前向和后向模型的任何后向比率 $\alpha \in [0, 1]$ 的期望来逼近期望梯度，这等价于优化加权后的 TB 目标，

$$\mathcal{L}_{\alpha \text{TB}}(\tau_F, \tau_B, \lambda) := \alpha \mathcal{L}_{\text{TB}}(\tau_B, \lambda) + (1 - \alpha) \mathcal{L}_{\text{TB}}(\tau_F, \lambda),$$

其中 $\tau_F \sim Q(\cdot; \phi)$ 和 $\tau_B \sim P(\cdot; \theta)$ 。我们可以类似地定义两个 KL 发散的凸组合，分别用 $(1 - \alpha)$ 和 α 惩罚 RKL 目标和 FKL 目标，

$$\mathcal{L}_{\alpha \text{KL}}(\phi, \theta, \alpha) = (1 - \alpha) \mathcal{L}_{\text{RKL}}(\phi, \theta) + \alpha \mathcal{L}_{\text{FKL}}(\phi, \theta).$$

类似于 RKL 和 FKL，这是一个非负且仅在 $P = Q$ 时为零的发散，

我们现在具备了比较不同设置下 α 和正向及反向模型的不同参数化的各种目标的能力。具体来说，我们将区分两种设置：(1) 其中 P_F 和 P_B （因此 Q 和 P ）分别具有不同的参数 ϕ 和 θ 的设置，以及 (2) 其中 P_F 和 P_B 共享参数 $\eta = \phi = \theta$ 的设置。 $\mathcal{L}_{\alpha\text{TB}}$ 的期望梯度可以计算为 TB 目标关于正向模型样本的期望梯度与关于反向模型样本的期望梯度的凸组合（参见方程 5）。类似地， $\mathcal{L}_{\alpha\text{KL}}$ 可以计算为 $\mathcal{L}_{\text{RKL}}$ 和 $\mathcal{L}_{\text{FKL}}$ 的凸组合。因此，在下面我们将分别研究 $\alpha = 0$ 和 $\alpha = 1$ 的情况，而 $0 < \alpha < 1$ 的结果将相应得出。

4.1 具有共享参数的前向模型和后向模型

如果前向和反向模型共享参数 $\eta = (\phi, \theta)$ ，例如当它们由同一个 GFN 参数化时，TB 目标的期望梯度（方程 1）的形式为

$$\mathbb{E}_{\tau \sim q(\cdot; \eta)} \left[\frac{d}{d\lambda} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] = -2\mathbb{E}_{\tau \sim q(\cdot; \eta)} \left[\left(\log w + \log \frac{Z}{Z_\psi} \right) \left(\frac{d}{d\psi} \log Z_\psi + \frac{d}{d\eta} \log Q(\tau; \eta) - \frac{d}{d\eta} \log P(\tau; \eta) \right) \right],$$

其中提议 q 要么是前向模型 $Q(\tau; \phi)$ ($\alpha = 0$)，要么是后向模型 $P(\tau; \theta)$ ($\alpha = 1$)。对应的 RKL 和 FKL 发散的梯度为

$$\begin{aligned} \frac{d}{d\eta} \mathcal{L}_{\text{RKL}}(\eta) &= -\mathbb{E}_{\tau \sim Q(\cdot; \eta)} \left[(\log w + c) \frac{d}{d\eta} \log Q(\tau; \eta) + \frac{d}{d\eta} \log P(\tau; \eta) \right], \\ \frac{d}{d\eta} \mathcal{L}_{\text{FKL}}(\eta) &= \mathbb{E}_{\tau \sim P(\cdot; \eta)} \left[(\log w + c) \frac{d}{d\eta} \log P(\tau; \eta) - \frac{d}{d\eta} \log Q(\tau; \eta) \right], \end{aligned}$$

其中 c 是一个如第 3.1 节所述的缩放参数。

4.2 具有不同参数的前向模型和后向模型

从前向模型采样的情况 ($\alpha = 0$)。当仅使用来自前向模型的样本时，TB 梯度的期望值简化为 $\tau \sim Q(\cdot; \phi)$

$$\begin{aligned} \mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\frac{d}{d\phi} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] &= -2\mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\left(\log w + \log \frac{Z}{Z_\psi} \right) \frac{d}{d\phi} \log Q(\tau; \phi) \right], \\ \mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\frac{d}{d\theta} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] &= 2\mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\left(\log w + \log \frac{Z}{Z_\psi} \right) \frac{d}{d\theta} \log P(\tau; \theta) \right], \\ \mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\frac{d}{d\psi} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] &= 2\mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\left(\log w + \log \frac{Z}{Z_\psi} \right) \frac{d}{d\psi} \log Z_\psi \right]. \end{aligned}$$

有趣的是，关于 ϕ 的期望梯度并不依赖于 $\log Z_\psi$ ，并且与反向 KL 发散的标准得分函数梯度成正比

$$\frac{d}{d\phi} \mathcal{L}_{\text{RKL}}(\phi, \theta) = -\mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[(\log w + c) \frac{d}{d\phi} \log Q(\tau; \phi) \right] = \frac{1}{2} \mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\frac{d}{d\phi} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right].$$

因此，对应的优化问题的解对应于（负）期望梯度的不动点。此外，项 $\log Z/Z_\psi$ 可以解释为类似于第 3.1 节讨论的控制变量的用于方差缩减的学习缩放参数 c_ψ 。关于前向模型参数优化 TB 目标等价于使用带有学习缩放参数 c_ψ 的得分函数估计器来优化 RKL 发散，该参数根据上述梯度进行更新。这一洞见还表明，第 3.1 节中描述的控制变量可以用作学习基线的替代方案，以减少轨迹平衡目标期望梯度估计的方差。

后向模型参数的 RKL 梯度表达式 θ 与相应的 TB 目标预期梯度有所不同

$$\frac{d}{d\theta} \mathcal{L}_{\text{RKL}}(\phi, \theta) = -\mathbb{E}_{\tau \sim Q(\cdot; \phi)} \left[\frac{d}{d\theta} \log P(\tau; \theta) \right].$$

被积函数相差一个乘法因子 $\log w + c_\psi$ 。

直观上，如果样本在反向转移模型 F 下的似然性高于正向转移模型 Q 下的似然性，并且超出由 $-c_\psi = \log(Z_\psi/Z)$ 预测的程度，则 $\log w + c_\psi < 0$ ，TB 目标试图增加样本在 F 下的似然性，反之亦然。相比之下，RKL 目标的梯度试图始终最大化样本在反向转移模型下的似然性，这在其全局最大值处实现为 $P = Q$ 。由于 $\sum_\tau P(\tau; \theta) = 1$ ，增加某些 τ 下 $P(\tau; \theta)$ 的概率会间接降低其他轨迹的概率。因此，尽管两个目标对于足够灵活的 Q 和 P 具有相同的全局最小值，但它们的优化动力学可能有所不同。

从反向模型中采样 ($\alpha = 1$)。当从反向模型中抽取样本时，预期的 TB 梯度简化为 $\tau \sim P(\cdot; \theta)$

$$\begin{aligned} \mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\frac{d}{d\phi} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] &= -2\mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\left(\log w + \log \frac{Z}{Z_\psi} \right) \frac{d}{d\phi} \log Q(\tau; \phi) \right], \\ \mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\frac{d}{d\theta} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] &= 2\mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\left(\log w + \log \frac{Z}{Z_\psi} \right) \frac{d}{d\theta} \log P(\tau; \theta) \right], \\ \mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\frac{d}{d\psi} \mathcal{L}_{\text{TB}}(\tau, \lambda) \right] &= 2\mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\left(\log w + \log \frac{Z}{Z_\psi} \right) \frac{d}{d\psi} \log Z_\psi \right]. \end{aligned}$$

在此，类似的观察结果成立。关于 θ 的期望梯度与参数 θ 的前向 KL 发散的相应梯度成正比

$$\frac{d}{d\theta} \mathcal{L}_{\text{FKL}}(\phi, \theta) = \mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\log w \frac{d}{d\theta} \log P(\tau; \theta) \right] = \frac{1}{2} \mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\frac{d}{d\theta} \mathcal{L}_{\text{TB}}(\phi, \theta, \tau) \right].$$

再次，对应的优化问题的解对应于（负）期望梯度的不动点。此外，类似于前面的情况，关于 θ 优化 TB 目标等价于使用具有学习缩放参数的得分函数估计器来优化关于 θ 的 FKL 发散

$$c_\psi.$$

FKL 梯度关于前向模型参数的表达式 ϕ 与相应的 TB 目标期望梯度在被积函数中相差一个 $\log$ 因子 $w + c_\psi$ 。

$$\frac{d}{d\phi} \mathcal{L}_{\text{FKL}}(\phi, \theta) = -\mathbb{E}_{\tau \sim P(\cdot; \theta)} \left[\frac{d}{d\phi} \log Q(\tau; \phi) \right].$$

观察 TB 目标函数的预期梯度及其对应的 RKL 和 FKL 梯度，可以发现，在某些情况下优化 TB 目标函数等价于使用反向或正向 KL 发散进行变分推断。这一观察还表明，我们可以利用变分推断文献中开发的各种用于得分函数估计器的方差缩减技术。

5 实验

本文已经证明，在特定设置下，优化 α TB 目标等价于优化 α KL 目标在于，不动点相同，并且期望梯度的 α 目标函数与梯度成正比 α KL 目标函数。在这些设置中，我们可以使用得分函数梯度估计器的方差缩减技术来减少 TB 目标函数预期梯度的方差。在优化 α 目标和 α KL 目标不等价，优化是否 α KL 散度目标优于优化 α 目标函数为 TB，反之亦然。在下文中，我们将比较 α TB 和 α KL 目标函数在使用学习到的基线 $\hat{c}^\phi := \log Z_\phi$ 或 LOO 基线 $\hat{c}_s^{\log Z}$ 下的性能，对于不同的值 α 。

评估度量。如果目标分布的样本 π_T 可用，我们可以从后向模型在给定条件下采样轨迹 x 。设

$$P_B(s_{0:T-1} | s_T; \theta) := \prod_{t=0}^{T-1} P_B(s_t | s_{t+1}; \theta) \quad \text{和} \quad P_F(s_{1:T-1} | s_0; \phi) := \prod_{t=0}^{T-2} P_F(s_{t+1} | s_t; \phi).$$

然后，我们可以使用重要性采样估计数据在前向模型下的边缘似然性，

$$\frac{1}{N} \sum_{i=1}^N \frac{P_F(x | s_{T-1}^i; \phi) P_F(s_{1:T-1}^i | s_0^i; \phi)}{P_B(s_{0:T-1}^i | x; \theta)}, \quad s_{0:T-1}^i \sim P_B(s_{0:T-1} | x; \theta). \quad (7)$$

如果没有数据可用，我们将报告预期对数权重 $\mathbb{E}_{x \sim Q(\cdot; \phi)} [\log w] \leq \log Z$ 。

状态空间的结构与表示 遵循 Zhang 等人 (2022b)，我们在终止状态上针对离散分布 $\mathcal{S}_T = \{0, 1\}^D$ ，通过连续地为每一步采样值在 $\{0, 1\}$ 。为此，我们定义状态空间 $\mathcal{S} = \{\emptyset, 0, 1\}^D \cup \{s_f\}$ ，其中 $\emptyset$ 表示尚未为相应位置采样比特值。我们进一步定义边

$$E = \{(s, s') : s \in \mathcal{S} \setminus \{s_f\} \wedge s' \in \mathcal{S}'(s)\} \cup \{(s, s_f) : s \in \mathcal{S}_T\}, \quad \mathcal{S}'(s) = \{s' \in \mathcal{S} \setminus \{s_f\} : |s| = |s'| - 1\},$$

其中 $|s|$ 表示在 s 中设置的比特数。有了这些定义，我们定义一个有向无环图 (DAG) $G(\mathcal{S}, E)$ ，它指定了状态空间的结构。为了数学上的方便，我们将状态 s 映射到数值表示 $\tilde{s}$ ，其中 $\emptyset, 0$ 和 1 分别替换为 $0, -1$ 和 1 。这使我们能够计算设置的比特数 $|s| = \sum_d |\tilde{s}_d|$ ，以及由转换添加的比特的位置和类型 $s \rightarrow s'$ 作为带符号的一热向量 $\tilde{s}' - \tilde{s}$ 。我们还可以计算从翻转新添加的比特在 s' 中得到的状态 $\neg \tilde{s}'(s, s') = \tilde{s} - (\tilde{s}' - \tilde{s})$ 。这些操作对于定义转移模型是有用的。

转移模型。我们考虑一个固定的后向转移模型 $P_B(s_t | s_{t+1})$ ，该模型随机选择一个置位位并将其替换为 $\emptyset$ 。前向转移模型 $P_F(s_{t+1} | s_t; \phi)$ 随机选择一个 $\emptyset$ 位，并将其替换为从伯努利分布采样的比特值，该伯努利分布的 (logit) 参数是一个函数 $f_\phi : \mathcal{S} \times \mathcal{S} \rightarrow \mathbb{R}_+$ 的输出。前向和后向转移模型对应的概率质量函数是

$$P_B(s_t | s_{t+1}) = \frac{1}{|s_{t+1}|}, \quad P_F(s_{t+1} | s_t; \phi) = \frac{1}{D - |s_t|} \frac{f_\phi(\tilde{s}'_t)}{f_\phi(\tilde{s}'_t) + f_\phi(\neg \tilde{s}'_t(s_t, s_{t+1}))}.$$

在实践中， $f_\phi : \mathbb{R}^D \rightarrow \mathbb{R}^{D \times 2}$ 是一个由权重为 ϕ 的多层感知器 (MLP) 参数化的向量值函数。给定一个状态 s_t ，它产生与状态向量中的位置相关的 D 对 logits。状态 s_{t+1} 仅用于计算添加的比特的位置 d ，这用于选择相应的 logits $f_\phi(s)_d \in \mathbb{R}^2$ 。

5.1 合成密度

为了建模终止状态上的离散目标分布 π_T ，我们遵循 Dai 等人 (2020) 和 Zhang 等人 (2022b) 的方法，将连续分布 $\pi_{\text{GT}}^{\text{cont}} : \mathbb{R}^2 \rightarrow \mathbb{R}^+$ 沿每个维度离散化为 2^{16} 个大小相等的网格单元。这些单元被重新映射到格雷码，使得相邻的网格单元恰好在一个比特上不同，从而得到的一对 16 位向量被连接成一个 32 位向量。

我们感兴趣的是两种设置：(1) 学习一个前向模型 $Q(\tau; \phi)$ ，其边缘分布 $Q_T(s_T; \phi)$ 近似于终止状态上的固定分布 $\pi_T(s_T)$ ，以及 (2) 同时学习一个前向模型和能量函数 $\xi : \{0, 1\}^{32} \rightarrow \mathbb{R}$ ，使得离散化的地面真实密度 $\pi_{\text{GT}} \approx \pi_T(s_T; \theta) \propto \exp(-\xi(s_T, \theta))$ 。我们通过最大化负对数似然来优化能量函数，交替更新前向模型和能量函数的梯度。我们近似对数边缘似然的梯度

$$-\frac{d}{d\theta} \log \pi_T(s_T; \theta) = \frac{d}{d\theta} (\xi(s_T; \theta) + \log Z_\theta) = \frac{d}{d\theta} \xi(s_T; \theta) - \mathbb{E}_{s_T \sim \pi_T(\cdot; \theta)} [\xi(s_T; \theta)]$$




图 1: 固定能量函数（在 2 螺旋上预训练）和不同值的 α 下的训练过程中负对数似然。当 $\alpha = 1$ 时， α 目标表现明显劣于 α 发散。

使用基于对比发散的方法（Hinton, 2002），该方法将关于 π_T 的期望替换为关于初始化在数据 x 的 K 步 Metropolis-Hastings (MH) 链的边缘分布的期望 $m(x' | x)$ ，

$$\mathbb{E}_{x \sim \mathcal{U}(\mathcal{X})} \left[\frac{d}{d\theta} \xi(x; \theta) - \mathbb{E}_{x' \sim m(x'|x)} [\xi(x'; \theta)] \right].$$

MH 更新使用 GFN 构建提议（张等, 2022b）。对于此梯度更新恢复了对数边缘似然的预期梯度。 $K \rightarrow \infty$

我们评估了 α TB 目标和 α KL 目标对于不同值的 α 以及两种不同的控制变量的情况，一种是学习的 (LRN) 控制变量 c_ψ ，另一种是使用留一法估计器 (LOO) 估算的控制变量 $c_{\log Z}$ 。对于每个 α ，我们考虑两种设置：1) 联合学习能量函数和 GFN 参数；2) 使用先前学习的固定能量函数，并仅学习 GFN 参数。我们发现，不出所料，当 $\alpha = 0$ 时，优化 α KL 目标等同于使用学习的控制变量优化 α KL 目标，在这种情况下，两个目标在负对数似然方面表现相当（数值相差在一个标准差内）（见表 1）。对于 $0 < \alpha < 1$ 的情况，两个目标的表现相似，但 α TB 在负对数似然方面略优于 α KL。有趣的是，当仅从反向模型采样时，对于 $\alpha = 1$, i.e., α TB 的表现显著下降，而 α KL 目标的表现则保持稳定。

5.2 伊辛模型

我们正在建模一个终止状态对应的离散分布，这些状态对应于伊辛模型的网格单元格。 $s_T \in \{-1, 1\}^D$

$$\pi_T(s_T) \propto \exp(-\beta H(s_T)), \quad H(s_T) = -\frac{1}{2} s_T^\top A_N s_T, \quad (8)$$

表 1: 在学习基线 and 不同后向比下 GFN 测试数据的负对数似然。 α

Method	2spirals	8gaussians	2spirals (fixed ξ)
GFN α TB (LRN, $\alpha=0.0$)	20.163 $\pm$ 0.013	20.006 $\pm$ 0.015	20.307 $\pm$ 0.343
GFN α TB (LRN, $\alpha=0.25$)	20.133 $\pm$ 0.010	20.001 $\pm$ 0.012	20.156 $\pm$ 0.017
GFN α TB (LRN, $\alpha=0.5$)	20.118 $\pm$ 0.006	19.995 $\pm$ 0.008	20.133 $\pm$ 0.003
GFN α TB (LRN, $\alpha=0.75$)	20.118 $\pm$ 0.009	20.006 $\pm$ 0.008	20.133 $\pm$ 0.015
GFN α TB (LRN, $\alpha=1.0$)	20.994 $\pm$ 0.037	20.088 $\pm$ 0.008	21.230 $\pm$ 0.029
GFN α KL (LRN, $\alpha=0.0$)	20.171 $\pm$ 0.015	20.021 $\pm$ 0.018	20.200 $\pm$ 0.015
GFN α KL (LRN, $\alpha=0.25$)	20.142 $\pm$ 0.012	19.999 $\pm$ 0.007	20.153 $\pm$ 0.009
GFN α KL (LRN, $\alpha=0.5$)	20.145 $\pm$ 0.008	20.003 $\pm$ 0.014	20.147 $\pm$ 0.012
GFN α KL (LRN, $\alpha=0.75$)	20.160 $\pm$ 0.008	20.019 $\pm$ 0.009	20.155 $\pm$ 0.011
GFN α KL (LRN, $\alpha=1.0$)	20.174 $\pm$ 0.009	20.019 $\pm$ 0.010	20.172 $\pm$ 0.008




图 2: 运行 MH 链和训练 GFN 的前向模型的伊辛模型近似样本。

表 2: 具有不同控制变量的 TB 的期望对数权重, 针对十个具有不同交互强度的伊辛模型。 α β

	$\beta=-1.$	$\beta=-0.8$	$\beta=-0.6$	$\beta=-0.4$	$\beta=-0.2$
α TB (LRN, $\alpha=0.0$)	183.997 ± 22.010	153.512 ± 13.550	112.511 ± 3.967	42.454 ± 1.905	-60.925 ± 0.388
α TB (LOO, $\alpha=0.0$)	174.101 ± 41.934	144.964 ± 20.893	102.232 ± 21.148	42.742 ± 1.984	-62.970 ± 0.276
	$\beta=0.2$	$\beta=0.4$	$\beta=0.6$	$\beta=0.8$	$\beta=1$
α TB (LRN, $\alpha=0.0$)	-60.900 ± 0.389	40.707 ± 3.733	112.189 ± 4.139	144.608 ± 21.020	174.262 ± 23.712
α TB (LOO, $\alpha=0.0$)	-62.844 ± 0.405	40.932 ± 1.941	97.109 ± 24.809	153.425 ± 13.999	190.531 ± 19.436

其中 A 是具有周期性边界条件的 $\alpha N \times N$ ($D = N^2$ 网格的邻接矩阵, 而 β 表示相互作用强度。在此设定下, 为了获得状态 s 的合适数值表示 $\tilde{s}$, 我们只需将 $\emptyset$ 位映射到 0。

由于我们无法获取伊辛模型的真实样本, 我们使用 GFN 进行训练 $\alpha = 0$ 。在这种设置下, 优化 TB 目标和 KL 目标是等价的, 因此我们将重点放在替换原始 TB 目标中使用的基线, 将其替换为通常用于减少得分函数估计中方差的控制变量上 $\alpha \log Z_\phi$ α LOO

我们报告了不同值的 β 对应的预期对数权重 (见表 2), 这些权重是通过 10 个训练好的 GFN 进行平均得到的。我们在图 5.2 中展示了 GFN 生成的样本以及通过运行 MH 链生成的样本, 以便进行定性比较。我们发现, 在不同的 β 值下, 学习到的基线与 LOO 控制变量之间的性能没有显著差异。

6 结论

本文探讨了最近关于生成流网络的文献与变分推断方法文献之间的联系。我们观察到, GFN 可以使用最小化轨迹正向分布与反向分布之间发散的变分目标进行训练。当最小化逆 Kullback-Leibler 发散时, 该目标类似于标准变分推断方法中最大化对数边缘似然下界的那个目标 (Blei 等人, 2017)。当最小化正向 Kullback-Leibler 发散时, 我们得到一个在唤醒睡眠方法及相关方法中常用的变体目标 (Hinton 等人, 1995; Bornschein 和 Bengio, 2015; Naesseth 等人, 2021)。也可以优化这两个目标的凸组合。这些目标与通常在训练 GFN 时使用的轨迹平衡目标密切相关。具体而言, RKL 梯度与根据正向分布采样的轨迹计算的 TB 目标期望梯度成比例。在合成密度和伊辛模型上的评估表明, GFN 的变分目标在预期对数权重方面相对于轨迹平衡目标的变体实现了可比的性能。这一观察结果为探索新的变分目标提供了机会, 这些目标将信用分配方法 (Schulman 等人, 2015) 以及基于变分序贯蒙特卡洛 (Naesseth 等人, 2018) 或嵌套变分推断 (Zimmermann 等人, 2021) 的重要性采样方法纳入 GFN。

参考文献

- Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow Network based Generative Models for Non-Iterative Diverse Candidate Generation. In *Advances in Neural Information Processing Systems*, volume 34, pages 27381–27394. Curran Associates, Inc., 2021a. URL <https://proceedings.neurips.cc/paper/2021/hash/e614f646836aaed9f89ce58e837e2310-Abstract.html>.
- Yoshua Bengio, Tristan Deleu, Edward J. Hu, Salem Lahlou, Mo Tiwari, and Emmanuel Bengio. GFlowNet Foundations. *arXiv:2111.09266 [cs, stat]*, November 2021b. URL <http://arxiv.org/abs/2111.09266>. arXiv: 2111.09266.
- David M Blei, Alp Kucukelbir, and Jon D McAuliffe. Variational inference: A review for statisticians. *Journal of the American statistical Association*, 112(518):859–877, 2017.
- Jörg Bornschein and Yoshua Bengio. Reweighted wake-sleep. In *International Conference on Learning Representations*, 2015.
- Hanjun Dai, Rishabh Singh, Bo Dai, Charles Sutton, and Dale Schuurmans. Learning Discrete Energy-based Models via Auxiliary-variable Local Exploration. In H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, volume 33, pages 10443–10455. Curran Associates, Inc., 2020. URL <https://proceedings.neurips.cc/paper/2020/file/7612936dcc85282c6fa4dd9d4ffe57f1-Paper.pdf>.
- Pierre Del Moral, Arnaud Doucet, and Ajay Jasra. Sequential Monte Carlo samplers. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 68(3):411–436, 2006. ISSN 1467-9868. doi: 10.1111/j.1467-9868.2006.00553.x. _eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1111/j.1467-9868.2006.00553.x>.
- Tristan Deleu, António Góis, Chris Chinenye Emezue, Mansi Rankawat, Simon Lacoste-Julien, Stefan Bauer, and Yoshua Bengio. Bayesian Structure Learning with Generative Flow Networks. In *The 38th Conference on Uncertainty in Artificial Intelligence*, June 2022. URL <https://openreview.net/forum?id=HElfed8j9g9>.
- Anh Do, Duy Dinh, Tan Nguyen, Khuong Nguyen, Stanley Osher, and Nhat Ho. Improving Generative Flow Networks with Path Regularization, September 2022. URL <http://arxiv.org/abs/2209.15092>. arXiv:2209.15092 [cs, stat].
- Geoffrey E. Hinton. Training products of experts by minimizing contrastive divergence. *Neural Computation*, 14(8):1771–1800, August 2002. ISSN 0899-7667. doi: 10.1162/089976602760128018. URL <https://doi.org/10.1162/089976602760128018>.
- Geoffrey E Hinton, Peter Dayan, Brendan J Frey, and Radford M Neal. The "wake-sleep" algorithm for unsupervised neural networks. *Science*, 268(5214):1158–1161, 1995.
- Matthew D. Hoffman. Learning Deep Latent Gaussian Models with Markov Chain Monte Carlo. In *Proceedings of the 34th International Conference on Machine Learning*, pages 1510–1519. PMLR, July 2017. URL <https://proceedings.mlr.press/v70/hoffman17a.html>. ISSN: 2640-3498.
- Matthew D Hoffman and Andrew Gelman. The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, 15, 2014.
- Moksh Jain, Emmanuel Bengio, Alex-Hernandez Garcia, Jarrod Rector-Brooks, Bonaventure F. P. Dossou, Chanakya Ekbote, Jie Fu, Tianyu Zhang, Micheal Kilgour, Dinghuai Zhang, Lena Simine, Payel Das, and Yoshua Bengio. Biological Sequence Design with GFlowNets, March 2022. URL <http://arxiv.org/abs/2203.04115>. arXiv:2203.04115 [cs, q-bio].
- Tuan Anh Le, Maximilian Igl, Tom Rainforth, Tom Jin, and Frank Wood. Auto-encoding sequential monte carlo. In *International Conference on Learning Representations*, 2018.
- Yingzhen Li, Richard E. Turner, and Qiang Liu. Approximate Inference with Amortised MCMC, May 2017. URL <http://arxiv.org/abs/1702.08343>. arXiv:1702.08343 [cs, stat].

-
- Kanika Madan, Jarrid Rector-Brooks, Maksym Korablyov, Emmanuel Bengio, Moksh Jain, Andrei Nica, Tom Bosc, Yoshua Bengio, and Nikolay Malkin. Learning GFlowNets from partial episodes for improved convergence and stability, September 2022. URL <http://arxiv.org/abs/2209.12782>. arXiv:2209.12782 [cs, stat].
- Chris J Maddison, John Lawson, George Tucker, Nicolas Heess, Mohammad Norouzi, Andriy Mnih, Arnaud Doucet, and Yee Teh. Filtering variational objectives. In *Advances in Neural Information Processing Systems*, pages 6573–6583, 2017.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory Balance: Improved Credit Assignment in GFlowNets. *arXiv:2201.13259 [cs, stat]*, January 2022a. URL <http://arxiv.org/abs/2201.13259>. arXiv: 2201.13259.
- Nikolay Malkin, Salem Lahlou, Tristan Deleu, Xu Ji, Edward Hu, Katie Everett, Dinghuai Zhang, and Yoshua Bengio. GFlowNets and variational inference, October 2022b. URL <http://arxiv.org/abs/2210.00580>. arXiv:2210.00580 [cs, stat] version: 1.
- Andriy Mnih and Danilo Rezende. Variational inference for monte carlo objectives. In *International Conference on Machine Learning*, pages 2188–2196. PMLR, 2016.
- C. A. Naesseth, S. W. Linderman, R. Ranganath, and D. M. Blei. Variational sequential Monte Carlo. In *Proceedings of the 21st International Conference on Artificial Intelligence and Statistics (AISTATS)*, Lanzarote, Spain, Apr 2018.
- C. A. Naesseth, F. Lindsten, and T. B. Schön. Elements of sequential Monte Carlo. *Foundations and Trends® in Machine Learning*, 12(3):307–392, November 2019. Now Publishers, Inc.
- Christian A. Naesseth, Fredrik Lindsten, and David Blei. Markovian Score Climbing: Variational Inference with $KL(p||q)$. *arXiv:2003.10374 [cs, stat]*, February 2021. URL <http://arxiv.org/abs/2003.10374>. arXiv: 2003.10374.
- Radford M. Neal. Annealed importance sampling. *Statistics and Computing*, 11(2):125–139, April 2001. ISSN 1573-1375. doi: 10.1023/A:1008923215028. URL <https://doi.org/10.1023/A:1008923215028>.
- Rajesh Ranganath, Sean Gerrish, and David M. Blei. Black Box Variational Inference. *arXiv:1401.0118 [cs, stat]*, December 2013. URL <http://arxiv.org/abs/1401.0118>. arXiv: 1401.0118.
- Sheldon M Ross. *Simulation*. academic press, 1997.
- Tim Salimans, Diederik Kingma, and Max Welling. Markov Chain Monte Carlo and Variational Inference: Bridging the Gap. In *Proceedings of the 32nd International Conference on Machine Learning*, pages 1218–1226. PMLR, June 2015. URL <https://proceedings.mlr.press/v37/salimans15.html>. ISSN: 1938-7228.
- John Schulman, Nicolas Heess, Theophane Weber, and Pieter Abbeel. Gradient estimation using stochastic computation graphs. *Advances in Neural Information Processing Systems*, 28, 2015.
- Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning, second edition: An Introduction*. MIT Press, November 2018. ISBN 978-0-262-35270-3.
- Marc Toussaint, Stefan Harmeling, and Amos Storkey. Probabilistic inference for solving (PO)MDPs. *Neural Computation*, 31(December):357–373, 2006.
- Dinghuai Zhang, Ricky T. Q. Chen, Nikolay Malkin, and Yoshua Bengio. Unifying Generative Models with GFlowNets, September 2022a. URL <http://arxiv.org/abs/2209.02606>. arXiv:2209.02606 [cs, stat].
- Dinghuai Zhang, Nikolay Malkin, Zhen Liu, Alexandra Volokhova, Aaron Courville, and Yoshua Bengio. Generative Flow Networks for Discrete Probabilistic Modeling. In *Proceedings of the 39th International Conference on Machine Learning*, pages 26412–26428. PMLR, June 2022b. URL <https://proceedings.mlr.press/v162/zhang22v.html>. ISSN: 2640-3498.

Liyi Zhang, David M. Blei, and Christian A. Naesseth. Transport score climbing: Variational inference using forward KL and adaptive neural transport. *arXiv:2202.01841*, 2022c.

Heiko Zimmermann, Hao Wu, Babak Esmaeili, and Jan-Willem van de Meent. Nested Variational Inference. In *Advances in Neural Information Processing Systems*, volume 34, pages 20423–20435. Curran Associates, Inc., 2021. URL <https://proceedings.neurips.cc/paper/2021/hash/ab49b208848abe14418090d95df0d590-Abstract.html>.