

连续生成流网络理论

Salem Lahlou^{1,2} Tristan Deleu^{1,2} Pablo Lemos^{1,3,2} Dinghuai Zhang^{1,2} Alexandra Volokhova^{1,2}
 亚历克斯·赫尔南德斯-加西亚^{1,2} 莱娜·内哈莱·埃津^{1,2} 尤书亚·本吉奥^{1,2,4} 尼古拉伊·马尔金^{1,2}

摘要

生成流网络 (GFlowNets) 是一种通过学习顺序采样策略来从具有组合结构的不可计算分布进行抽样的变分推断算法。直到现在, GFlowNets 的一个关键局限性在于它们仅限于离散空间。本文提出了一个广义 GFlowNets 的理论, 该理论涵盖了现有的离散 GFlowNets 以及具有连续或混合状态空间的 GFlowNets, 并进行了旨在实现两个目标的实验。首先, 我们展示了理论的关键点和各种假设的重要性。其次, 我们实证地展示了关于离散 GFlowNets 的观察如何转移到连续情况, 并在几个先前研究的任务上与非 GFlowNets 基线相比取得了显著的结果。这项工作极大地拓宽了 GFlowNets 在概率推理和各种建模设置中的应用前景。

1. 引言

生成流网络 (GFlowNets; Bengio 等人, 2021a) 是一类越来越受欢迎的方法, 它们通过学习顺序采样策略来从具有组合结构的不可计算分布进行抽样。其应用包括设计生物结构如分子 (Bengio 等人, 2021a; Jain 等人, 2022), 贝叶斯结构学习 (Deleu 等人, 2022; Nishikawa-Toomey 等人, 2022), 以及鲁棒组合优化 (Zhang 等人, 2023b)。自然地, 它们的发展和理论基础 (Bengio 等人, 2021b; Malkin 等人, 2023; Zimmermann 等人, 2022) 都是针对具有离散结构的环境。

由于许多概率推理和建模问题涉及连续变量, 自然会问 GFlowNets 的优势是否适用, 这些优势包括稳定离散化等。联系人: Salem Lahlou <lahlosal@mila.quebec>。

Proceedings of the 40th International Conference on Machine Learning, Honolulu, Hawaii, USA. PMLR 202, 2023. Copyright 2023 by the author(s).

策略学习和捕捉目标分布多种模式的能力扩展到一般空间。例如, 分子设计意味着指定原子之间的相对空间位置, 并且从建模连续变量 (如扭转角) 中获益 (Jing 等人, 2022 年), 贝叶斯结构学习不仅需要发现图形模型的结构, 还需要发现其参数。

Malkin 等人 (2023) 首次尝试使用 GFlowNet 损失来训练一个未归一化的连续密度的摊销采样器, 展示了 GFlowNets 的离策略优势可以扩展到一个玩具随机控制问题。然而, 在具有连续动作域的情况下, 证明 GFlowNet 损失可靠性的理论仍然缺失。最近, 李等人 (2023) 提出了将流匹配条件 (Bengio 等人, 2021a) 扩展到连续域的方法; 然而, 这一扩展依赖于几个无效假设, 我们在 § 3.1 中对此进行了详细说明。

本文提出了一种理论, 将所有已知的 GFlowNet 训练目标扩展到任意空间。该理论基于可测有向图, 这是有向无环图 (DAG) 在可测空间上的推广, 基于 Markov 核函数。我们的主要理论贡献是对流匹配 (FM; Bengio 等人, 2021a)、细致平衡 (DB; Bengio 等人, 2021b) 和轨迹平衡 (TB; Malkin 等人, 2022) 条件的扩展, 以及一个定理, 证明当满足这些条件之一时, 所学的前向核函数可以从目标分布中采样。这些条件导致涉及密度函数的训练损失, 并允许基于梯度的学习。现有的离散 GFlowNet 损失是我们提出的损失的特例。

此外, 我们在具有不同结构的多个领域提供了实验结果, 其中一些包括同时包含离散和连续部分的动作空间。这些实验既验证了理论主张, 也提醒实践者注意特定于连续域的注意事项。我们的比较实验确认了已经证明的离散 GFlowNet 的优势可以转移到更一般的状态空间。

本文其余部分的结构如下:

§ 2 回顾了 GFlowNets 和随机抽样的相关工作;

§ 3 介绍了理论结果和实用总结;

§ 4 致力于通过实证验证理论并比较广义 GFlowNets 与基线模型。

2. 背景及相关工作

2.1. 连续空间中的随机采样

在连续空间中的顺序采样有着悠久的历史。存在专门针对从连续或可微密度中采样的马尔可夫链蒙特卡洛 (MCMC) 方法, 如兰格文和哈密顿蒙特卡洛 (Coffey 等, 2004; Neal, 2012; Hoffman & Gelman, 2011)。

另一条研究路线考虑的是在有限步骤内的随机采样。序贯蒙特卡洛方法族 (Doucet 等, 2001) 以及紧密相关的退火重要性采样 (Neal, 2001) 规定了一系列中间目标密度, 采样器旨在近似满足细致平衡, 但转移核通常不是一个学习到的神经网络策略。最近, 作为基于评分或随机微分方程建模的可学习核采样方法已被用于最大似然生成模型 (例如, Sohl-Dickstein 等, 2015; Song & Ermon, 2019; Ho 等, 2020; Dockhorn 等, 2022), 以及学习从一个难以处理的目标密度中采样 (Zhang & Chen, 2022)。正如我们在实验中所展示的, 这些算法可以被视为特定形式状态空间的 GFlowNets 的特殊情况 (§ 4.2, § 4.5)。

另一个相关方向是随机归一化流 (Wu 等, 2020), 它已经被解释为具有马尔可夫链视角 (Hagemann 等, 2022), 依赖于马尔可夫核和 Radon-Nikodym 导数, 就像我们的广义 GFlowNets 理论一样。

2.2. 离散 GFlowNets

GFlowNets 最初被构架为强化学习 (强化学习) 算法 (Bengio 等人, 2021a), 具有离散的状态和动作空间, 训练一个给定未归一化概率质量函数 (称为奖励) 的目标分布的采样器, 使用一种称为流匹配的局部一致性目标。这与通常旨在最大化给定奖励函数的强化学习算法形成对比, 但在特殊情况下等同于熵正则化的强化学习方法。Bengio 等人 (2021b) 阐述了 GFlowNets 的理论基础, 基于定义在有向无环图上的流网络, 并提出了详细平衡损失作为更有效的替代方案, 绕过了对大量子节点和父节点进行求和的需求, 为连续状态打开了大门。轨迹平衡和子轨迹平衡损失 (Malkin 等人, 2022; Madan 等人, 2022) 被发现更为高效。Pan 等人 (2022) 提出了一种框架, 用于在训练 GFlowNet 时纳入内在探索奖励。Zhang 等人

(2023a); Malkin 等人 (2023); Zimmermann 等人 (2022) 证明了 GFlowNets 与分层变分方法的部分等价性, 但展示了 GFlowNets 在学习由非策略采样的轨迹时的优越性。Zhang 等人 (2022) 使用 GFlowNets 进行基于能量的模型的近似最大似然训练, 绕过了需要给定目标奖励的需求。

Jain et al. (2022) used GFlowNets within an active learning loop to design biological sequences. Zhang et al. (2023b) used GFlowNets for an NP-hard combinatorial optimization problem. Other applications include Bayesian structure learning; Deleu et al. (2022); Nishikawa-Toomey et al. (2022) learn posteriors over the combinatorially large space of causal graphs, which are naturally compositional.

离散 GFlowNets 综述。 给定一个非负目标奖励函数 R 在一个有限空间 X 上, 该空间与称为终止状态的有向无环图顶点子集重合, GFlowNet 训练目标旨在学习沿有向无环图边的转移概率 $P_F(s' | s)$ 。前向动作策略 P_F 诱导了一个关于终止状态的边缘分布 $\hat{P}$, 即从指定初始状态开始并根据 P_F 采样转移的轨迹的最终状态。前向策略的参数 P_F 通过应用于轨迹的客观函数的随机梯度顺序更新, 该轨迹要么从前向策略本身 (策略内) 采样, 要么从其修改版本采样以激励探索 (策略外)。当损失处于全局最小值时, 前向策略能够有效地从一个与 R 成比例的概率分布中采样。

所有 GFlowNet 损失函数必须在参数化中引入额外的对象, 以应对将 $P_F^T(x)$ 表示为通往 x 的所有 (可能呈指数级数量的) 轨迹似然性的总和这一不可处理的问题。例如, DB 和 TB 目标使用了一个参数化的后向策略 $P_B(s | s')$, 该策略指定了 DAG 中任何状态的父节点的概率分布。

3. 广义 GFlowNets 理论

3.1. 实用总结

表 1 提供了离散与广义 GFlowNets 之间关键差异和类比的摘要, 并在 § B 中明确说明了离散 GFlowNets 如何成为广义 GFlowNets 的特例。

本节发展的理论表明, 用于训练离散 GFlowNets 的主要损失函数, 即细致平衡 (Bengio 等, 2021b) 和轨迹平衡 (Malkin 等, 2022) 损失函数, 可以通过将概率质量函数替换为概率密度函数, 自然扩展到广义 GFlowNets。最为重要的是

表 1. 离散与广义 GFlowNets 之间的对照表

Discrete GFlowNet	Generalized GFlowNet	Reference
The state space is a finite set with distinguished source and sink states	The state space is a topological space with distinguished source and sink states, and may consist of both continuous and discrete components	Def. 1
Children and parents of a state s	Supports of the measures $\kappa(s, -)$, $\kappa^b(s, -)$	Def. 1
All states are reachable from s_0	All open sets are reachable from s_0 with nonzero likelihood	(1)
The state $\perp$ has no outgoing edges	The state $\perp$ is absorbing	(2)
The state graph is acyclic ($\Rightarrow$ trajectory lengths are bounded)	The measurable pointed graph is finitely absorbing	(7)
State flow F , forward policy P_F , backward policy P_B	Flow measure μ , forward kernel P_F , backward kernel P_B	Defs. 3 and 5
Transition likelihoods $P_F(- s)$ only positive along edges	Transition kernels $P_F(s, -)$ absolutely continuous w.r.t. κ	Def. 3
Terminating distribution $P_F^\top$	Terminating state measure $P_\top$	Def. 9 and Thm. 1
Flow-matching implies sampler matches reward function R	Flow-matching implies sampler matches reward measure R	Def. 3 and Thm. 1
Detailed balance: $F(s)P_F(s' s) = F(s')P_B(s s')$	Detailed balance: $\mu(ds)P_F(s, ds') = \mu(ds')P_B(s', ds)$	Def. 5
Trajectory balance: $ZP_F(\tau) = R(x_\tau)P_B(\tau x_\tau)$	Trajectory balance: $ZP_F(s_0, ds_1) \dots P_F(s_n, \{\perp\}) = R(ds_n)P_B(s_n, ds_{n-1}) \dots P_B(s_1, \{s_0\})$	Def. 6

重要的是，该理论的可靠性依赖于以下假设，在无限空间中训练 GFlowNet 时需要仔细验证这些假设：(1) 状态空间的结构必须允许从源状态 s_0 (1); 到达所有状态；(2) 结构必须确保从 s_0 到达任何状态所需的步骤数有界 (7)；(3) 学习到的概率测度需要通过状态上的密度来表达，而不是通过动作上的密度。

这些假设在离散域中自然成立，只要状态空间由一个有向无环图 (Bengio 等人, 2021b) 表示。

关于之前尝试训练连续流匹配网络的努力。尽管 Li 等人 (2023) 提出了通过将流匹配条件写作积分而非求和来训练连续流匹配网络的方法，但假设 (1) 和 (3) 以关键方式被违反。首先，Li 等人 (2023) 实验中考虑的环境违反了假设 (1)，没有这个假设，主要的流匹配网络训练定理不成立。其次，关于 (3)，Li 等人 (2023) 隐含地假设对于状态 s 和流向函数 $F(s \rightarrow s)$, $\int$

$$F(s \rightarrow s') ds' = \int_a F(s \rightarrow T(s, a)) da,$$

其中第二个积分是在动作和状态 $T(s)$ 上进行的， a 是从状态 s 采取动作 a 到达的状态。这种变量替换通常是无效的：右侧的被积函数缺少雅可比矩阵项 $dT(s, a)$ ，这不一定等于 1。特别是，在 Li 等人 (2023) 研究的环境中它并不等于 1 (尽管在某些特殊情况下可能成立，比如在欧几里得空间中的采样，其中 $T(s, a) =$

$s + a$)。这些问题对这种方法适用范围的影响令人担忧。

方法的应用性。

3.2 结构化状态空间

注释。为了帮助读者形成概念图像，我们在表 1 中列出了引入的概念及其离散类比，并在 § B 中正式陈述了它们之间的联系。标记为 (★) 的段落解释了技术结果的意义。

(★) 如何在一般空间中描述结构 这与有限集上的有向无环图相似吗？在有限集中，只需枚举所有状态的子集和父集，并约束 s' 是 s 的子集当且仅当 s 是 s' 的父集。然而，在一般的状态空间中，枚举被测度所取代。因此，可以为每个状态定义一个关于状态空间的测度，描述一步内可以访问哪些状态。

我们考虑的结构化状态空间将被称为可测带点图，并依赖于核函数 (Nummelin, 2004; Cappé 等, 2009; Petritis, 2015)，其定义将在 § A 中回顾。

定义 1 (可测有向图)。一个可测有向图 $G = (\bar{S}, \mathcal{T}, \Sigma, s_0, \perp, \kappa, \kappa^b, \nu)$ 包含以下内容：• 一个拓扑空间 $(\bar{S}, \mathcal{T})$ ，其中 $\mathcal{T}$ 是 $\bar{S}$ 的开子集构成的集合，而 Σ 是与 $\bar{S}$ 上的拓扑相关的波莱尔 σ -代数。• 一对不同的特殊状态 $s_0 \in \bar{S}$ 和 $\perp \in \bar{S}$ ，分别称为源状态和汇状态，使得 $\{s_0\}$ 和 $\{\perp\}$ 都是开集和闭集。我们定义 $\mathcal{S} = \bar{S} \setminus \{\perp\}$ 和 $\mathcal{S}^\circ = \mathcal{S} \setminus \{s_0\}$ ，因此 $\bar{S}$ 上的拓扑是 $\{s_0\}$, $\{\perp\}$, 和 $\mathcal{S}^\circ$ 的不相交并拓扑。• 一个有限转移核函数 A σ -finite 转移核 κ 在 $(\bar{S}, \Sigma)$ 上，称为参考核函数。

• $A \sigma$ 有限的转移核函数 κ^b 上的 $(\bar{S}, \Sigma)$, 称为反向参考核函数, • 一个严格正的 σ 有限测度 ν 上的 $(\bar{S}, \Sigma)$, 称为参考测度, 使得以下条件成立:

$$\forall B \in \mathcal{T} \setminus \{\emptyset\} \quad \exists n \geq 0 : \kappa^n(s_0, B) > 0, \quad (1)$$

$$\kappa(\perp, -) = \delta_\perp, \quad (2)$$

$$\forall B \in \Sigma, s \mapsto \kappa(s, B) \text{ is continuous}, \quad (3)$$

$$\forall B \in \Sigma \otimes \Sigma, ((s_0, s_0) \notin B, (\perp, \perp) \notin B) \Rightarrow \nu \otimes \kappa(B) = \nu \otimes \kappa^b(B), \quad (4)$$

$$\forall B \in \Sigma, \kappa^b(s_0, B) = 0, \quad (5)$$

$$\forall s \in S, \kappa(s, \{\perp\}) > 0 \Rightarrow \kappa(s, \{\perp\}) = 1. \quad (6)$$

若可测有向图是有限吸收的, 则称其为

$$\exists N > 0 : \text{supp}(\kappa^N(s_0, -)) = \{\perp\}, \quad (7)$$

在这种情况下, 最小的 N 被称为最大轨迹长度。

(★) 参考转移核函数 κ 提供了一种状态空间“结构”的概念。 $\kappa(s, -)$ (分别 $\kappa^b(s, -)$) 的支持可以被视为状态 s 的子集 (分别父集)。例如, 在离散图中, $\kappa(s, -)$ 可能是状态 s 的孩子节点上的均匀分布。参考核函数不是一个要采样的策略, 而是定义策略概率密度所需的一个对象。参考测度 ν , 用于定义流和奖励, 通常是简单的测度, 如离散集合上的计数测度或欧几里得空间上的标准勒贝格测度。

实际上, 如果结构仅由参考核函数 κ 定义, 则可以在一些温和的假设下从 κ 定义满足定义 1 条件的 ν 和 κ^b , 我们在附录 A.5 的命题 3 中讨论了这一点。

从此以后, 我们固定一个有限吸收可测带点图 $G = (\bar{S}, \mathcal{T}, \Sigma, s_0, \perp, \kappa, \kappa^b, \nu)$, 其最大轨迹长度为 N 。

定义 2 (终止状态) 终止状态集 X 定义为:

$$X = \{s \in S : \kappa(s, \{\perp\}) > 0\}. \quad (8)$$

(★) 终止状态是从这些状态可以以 $\perp$ with 正概率转移到的状态。任何转移核函数都可以被采样 n 步, 从而产生一个关于 n 步轨迹的测度和一个关于经过 n 步后到达状态的边缘测度。正如在附录 (§ A.4) 中所述, 这可以用来定义转移核函数 P_F 的边缘终止测度 $P_\top$, 将在下一节中使用。

3.3. 流

定义 3 (流和流匹配条件)。给定一个 σ -有限测度 μ 在 $(\bar{S}, \Sigma)$ 上, 它是绝对连续的 w.r.t. ν (我们记作 $\mu \ll \nu$), 以及一个 σ -有限马尔可夫核函数 P_F 在 $(\bar{S}, \Sigma)$ 上 (即一个转移核函数, 使得每个 $P_F(s, -)$ 是一个概率测度), 满足: 对于每一个

$$(1) P_F(s, -) \ll \kappa(s, -) \quad s \in \bar{S},$$

(2) $s \mapsto P_F(s, B)$ 对于每一个 $B \in \Sigma$ 都是连续的, P_F 被称为在 G 上的前向核函数。我们说元组 $F = (\mu, P_F)$ 满足流匹配 (FM) 条件, 如果对于任何有界可测函数 $f : \bar{S} \rightarrow \mathbb{R}$ 满足 $f(s_0) = 0$, 我们有 $\int$

$$\int_{\bar{S}} f(s') \mu(ds') = \iint_{S \times \bar{S}} f(s') \mu(ds) P_F(s, ds'). \quad (9)$$

在这种情况下, 我们说 F is a 在 G 上流动。

(★) 绝对连续性的条件相对于参考核函数 κ 表明, 流 F 必须遵循“可测点图”的结构, 仅将正测度分配到由 κ 诱导的测度也为正的空间部分。核函数 P_F 可以通过相对于 κ 的密度函数来表示, 这代表了一个概率质量 (如果动作空间是离散的) 或概率密度 (如果是连续的)。这允许使用密度 (Radon-Nikodym 导数) 来书写诸如 (9) 这样的条件, 从而提供实用的损失函数来训练 GFlowNNet。我们在 § 3.5 中对此进行了详细说明。

定义 4 (奖励匹配条件)。设 $F = (\mu, P_F)$ 是在 G 上的流。给定一个正且有限的测度 R 在 X 上, 称为奖励测度, 满足 $R \ll \nu$, 则流 F 被说成满足奖励匹配条件 w.r.t. R , 如果我们有:

$$R(dx) = \mu(dx) P_F(x, \{\perp\}). \quad (10)$$

在 § E 证明的定理表明, 类似于离散 GFlowNets, 当流和奖励匹配条件得到满足时, 从马尔可夫核函数 P_F 开始递归采样 (从 s_0 开始, 直到达到 $\perp$), 可以得到归一化奖励的样本。

定理 1。如果 $F = (\mu, P_F)$ 是在 G 上的流, 并且满足相对于测度 R 的奖励匹配条件 (10), 那么相应的终止状态测度 $P_\top$ (定义 10) 是一个概率测度, 并且对于所有 $B \in \Sigma_X$, 满足:

$$P_\top(B) = \frac{1}{R(X)} R(B). \quad (11)$$

(★) $R(X)$, 在所有终止状态集 X 上取的奖励测度, 对应于总奖励或 GFlowNets 的分区函数 Z 。某些条件 (定义 3 和 4) 关于 μ , 它代表了一个状态流, 以及 P_F ,

表示一个策略，意味着该策略的边缘终止分布与奖励成正比。这些条件对应于离散有向无环图顶点处的“流入 = 流出”条件。

3.4. 细节平衡与轨迹平衡

在有限的 GFlowNets 中，细节平衡条件 (Bengio 等人, 2021b) 和轨迹平衡条件 (Malkin 等人, 2022) 被转化为训练目标，以便从目标未归一化分布中采样。在本节中，我们将介绍一般可测指针图的类似条件。

定义 5。 设 μ 是 σ -有限测度覆盖 $(\bar{S}, \Sigma)$ 使得 $\mu \ll \nu, P_F$ 前向核函数覆盖 G ，并且 P_B 转移核函数在 $(\bar{S}, \Sigma)$ 上，使得：对于 每一个

- (1) $P_B(s, -) \ll \kappa^b(s, -) \quad s \in \bar{S}$,
- (2) $s \mapsto P_B(s, B)$ is continuous for every $B \in \Sigma$,
- (3) $P_B(s, -)$ is a probability measure for every $s \neq s_0$,

P_B is then said to be a **backward kernel** over G . We say that (μ, P_F, P_B) satisfy the **detailed balance (DB) conditions** if for any bounded measurable function $f : S \times \bar{S} \rightarrow \mathbb{R}$ satisfying $f(s, s_0) = 0$ for every $s \in S$, we have

$$\begin{aligned} \iint_{S \times \bar{S}} f(s, s') \mu(ds) P_F(s, ds') \\ = \iint_{S \times \bar{S}} f(s, s') \mu(ds') P_B(s', ds). \end{aligned} \quad (12)$$

以下命题，在 § E 中证明，展示了 DB 和 FM 条件之间的等价性。

命题 1。 若 (μ, P_F, P_B) 满足定义 5 中的细致平衡条件，则 $F = (\mu, P_F)$ 满足定义 3 中的流匹配条件，从而构成一个流。

定义 6。 设 P_F 是在 G , P_B 是 a 上的前向核函数，在 G 上的后向核函数，并且 $Z \in \mathbb{R}_+$ 。设 R 是 X 上的一个正有限测度。三元组 (Z, P_F, P_B) 满足轨迹平衡 (TB) 条件 w.r.t. R 当且仅当对于任意 $n \geq 0$ 和任意有界可测函数 $f : \bar{S}^{n+2} \rightarrow \mathbb{R}$:

$$\begin{aligned} Z f(s, \overrightarrow{s_{1:n+1}}) \mathbb{1}_{s_n \neq \perp, s_{n+1} = \perp} P_F^{\otimes n+1}(s_0, ds \overrightarrow{ds_{1:n+1}}) \\ = \int_{\bar{S}^{n+1}} \mathbb{1}_{s=s_0} f(s, \overrightarrow{s_{1:n}}, \perp) R(ds_n) P_B^{\otimes n}(s_n, ds' \overrightarrow{ds_{n-1:1}} ds), \end{aligned} \quad (13)$$

其中 $\overrightarrow{s_{1:n}}$ denotes $(s_1, \dots, s_n)$ and $\overrightarrow{ds_{1:n}}$ 表示 $ds_1 \dots ds_n$.

以下命题在 § E 中证明了 TB 与 FM 和奖励匹配条件之间的等价性。

命题 2。 若 (Z, P_F, P_B) 满足关于测度 R 的 TB 条件 (13)，则 $F = (\mu, P_B)$ ，其中 μ 被定义为：

- (1) $\mu(\{\perp\}) = \mu(\{s_0\}) = Z$
- (2) $\forall B \in \Sigma_{|S|} : \mu(B) = \mu(\{s_0\}) \sum_{n=0}^{\infty} P_F^n(s_0, B)$

同时满足流匹配条件 (9) 和奖励匹配条件 (10) w.r.t. R 。

(★) 对于离散 GFlowNets，DB 和 TB 条件的类比被陈述，并证明它们蕴含 FM 条件。在下一节中，这些条件将用于构建参数策略的训练目标。

3.5. GFlowNets 的训练损失

上述内容介绍了三个条件，在这些条件下，基于马尔可夫核 P_F 的采样器可以从给定奖励测度的归一化版本中进行采样。实际上，类似于离散 GFlowNets，感兴趣的对象 (μ, P_F, P_B, Z) 由一个向量 θ 参数化，目标是通过梯度学习来学习 θ 。在本节中，我们将推导出与先前目标相对应的损失函数。

我们回顾 Radon-Nikodym 定理，该定理指出对于任意给定的两个 σ -有限测度 p 和 q 在一个可测空间上 (U ，满足 $p \ll q$ 存在一个可测函数 $f : U \rightarrow \mathbb{R}_+$ ，在测度零的意义下是唯一的 q ，称为密度或 Radon-Nikodym 导数 $\frac{d p}{d q}$ w.r.t. q ，使得：

$$\forall A \in \mathcal{U}, p(A) = \int_A f(u) q(du). \quad (14)$$

这个定理很方便，因为它允许绕过在每个可测集上定义测度 $\mu, P_F(s, -), P_B(s, -)$ 的需求，只需要参数化相应的密度 (相对于 $\nu, \kappa(s, -)$ ，以及 $\kappa^b(s, -)$)。

定义 7 (损失函数) 设和 $u : S \rightarrow \mathbb{R}_+, P_F : S \times \bar{S} \rightarrow \mathbb{R}_+, P_B : S \times S \rightarrow \mathbb{R}_+$ 是三个函数，且 $Z \in \mathbb{R}_+$ 是标量，所有这些都由一个向量 θ 参数化，并满足对于每个 θ ：

$$\forall s \in \bar{S}, \int_{\bar{S}} P_F(s, s'; \theta) \kappa(s, ds') = 1 \quad (15)$$

$$\forall s' \in \bar{S}, \int_{\bar{S}} P_B(s', s; \theta) \kappa^b(s', ds) = 1 \quad (16)$$

流匹配 (FM) 损失对于每个 $s' \in S$ 定义为：

$$L_{FM}(s'; \theta) = \left(\int_{\text{日志}} \frac{u(s; \theta) P_F(s, s'; \theta) \kappa^b(s', ds)}{u(s'; \theta)} \right)^2$$

详细平衡 (DB) 损失定义为对于每一个 $(s, s') \in S \times S$

$$L_{DB}(s, s'; \theta) = \left(\log \frac{u(s; \theta) P_F(s, s'; \theta)}{u(s'; \theta) P_B(s', s; \theta)} \right)^2$$

记密度为 r 奖励测度 R w.r.t. 参考测度 ν ，奖励匹配 (RM) 损失定义为对于任意 $x \in X$ 如下：

$$L_{RM}(x; \theta) = \left(\log \frac{u(x; \theta) p_F(x, \perp; \theta)}{r(x)} \right)^2$$

最后, 轨迹平衡 (TB) 损失定义为对于每一个完整的轨迹 $\tau = (s_0, s_1, \dots, s_n, s_{n+1}) \in \{s_0\} \times \mathcal{S}^n \times \{\perp\}$ (也表示为 $\frac{\cdot}{\tau_n}$) 其中 $s_n \in \mathcal{X}$ 并且 $s_{n+1} = \perp$ as:

$$L_{TB}^n(\tau; \theta) = \left(\log \frac{Z(\theta) \prod_{t=0}^n p_F(s_t, s_{t+1}; \theta)}{r(s_n) \prod_{t=0}^{n-1} p_B(s_{t+1}, s_t; \theta)} \right)^2.$$

请注意, 可以类似地推导出子轨迹平衡损失, 类似于在离散 GFlowNets (Madan 等, 2022) 中使用的损失。

(★) 上述损失类似于离散 GFlowNet 损失。当动作空间是离散的, 并且参考测度是 DAG 顶点上的计数测度时, $p_F(s, s')$ 是一个转移概率 $P_F(s'|s)$ 。当它是连续的时候, 它表示给定 s 的关于 s' 的条件概率密度。

Conversely, from functions $u(-; \theta), p_F(-; \theta), p_B(-; \theta)$, 我们可以定义一个测度 $\mu(-; \theta)$ 在 $(\tilde{\mathcal{S}}, \Sigma)$ 其密度相对于

$p_F(-; \theta), p_B(-; \theta)$ $p_F(s, -; \theta)$ $p_B(s', -; \theta)$ ν 是 u 并且正向和反向核函数使得它们相对于 $\kappa(s, -)$ 和 $\kappa^b(s, -)$ 的密度分别为 1。

(★) 第 E 节证明的定理确保了, 类似于离散情况, 最小化上述损失函数会导致正确的概率测度采样器。

定理 2. (1) 如果 $L_{FM}(-; \theta) = 0$ ν 几乎处处成立, 则 $F = (\mu, P_F)$ 是一个流 (即满足定义 3 中的流匹配条件)。(2) 如果 $L_{DB}(-; \theta) = 0$ $\nu \otimes \kappa$ 几乎处处成立, 则 (μ, P_F, P_B) 满足定义 5 中的细致平衡条件。(3) 如果 $L_{RM}(-; \theta) = 0$ $\nu|_{\mathcal{X}}$ 几乎处处成立, 则 (μ, P_F) 满足 (10) 中的奖励匹配条件。

(4) If $L_{TB}^n(-; \theta) = 0$ $((\nu \otimes \kappa^{n+1})|_{\{s_0\} \times \mathcal{S}^n \times \{\perp\}})$ -almost 如果对每个 $n \geq 0$ 几乎处处成立, 则 $(Z\nu(\{s_0\}), P_F, P_B)$ 满足定义 6 中的轨迹平衡条件。

定理 2 的一个重要推论是, 如果我们能够找到几乎处处实现零损失的密度函数, 包括奖励匹配损失, 那么根据定理 1, 我们就能获得一种按奖励测度 R 比例抽样终止状态 (即 $\mathcal{X}$ 的元素) 的方法。

训练广义 GFlowNets. 频率损失 (FM)、差异备份损失 (DB) 和轨迹备份损失 (TB) 可以通过从训练策略采样的轨迹 (相应地, 后续状态对或轨迹) 获得的状态来最小化 π , 这可以是该策略本身 (在线策略), 也可以是对该策略的修改以鼓励探索 (离线策略) P_F 。定理 2 表明参数 θ 可以被更新 1 测度在 $\perp$ are 无关。




图 1. (a) 第 4.1 节中环境的可测带点图结构: 从 s_0 开始, 第一个动作在灰色四分之一圆内进行一步, 随后的动作则固定步长移动或终止。**(b)** 在使用均匀 P_B 和学习到的 P_B 进行 TB 和 DB 训练过程中 JSD 的变化, 对于 $\rho = 0.25$; **(c)** $\rho = 0.1$ 。横轴表示采样的轨迹数量。阴影区域表示 6 次运行的标准差。

$\sum_{t=1}^n L_{FM}(s_t; \theta) + \alpha L_{RM}(s_n; \theta)$, or $\sum_{t=0}^{n-1} \pi[\nabla_{\theta} \mathcal{L}]$, 其中 L 是 $L_{TB}^n(\tau; \theta)$ or $L_{DB}(s_t, s_{t+1}; \theta)$. 使用随机梯度 $\mathbb{E}_{\tau \sim \pi_{0:n+1}}$

4. 实验

4.1. 一个合成连续环境

在本节中, 我们研究了一个受超网格环境启发的合成环境 (Bengio 等人, 2021a; Malkin 等人, 2022; 2023), 该环境具有变化的轨迹长度和一个指向图结构, 这种结构对策略施加了一种混合离散和连续的概率测度 P_F 。这些实验的代码可以在 <https://github.com/saleml/continuous-gfn> 找到。

状态空间的结构。 可测的指向图由 $\mathcal{S} = [0, 1]^2$ 和 $s_0 = (0, 0)$ 指定。一个超参数 ρ , 称为步长, 控制最大轨迹长度。 $\kappa(s_0, -)$ 是在 D_0 上的勒贝格测度, 它是半径为 ρ 并以 s_0 为中心的东北象限圆盘。当 $s \neq s_0$, 且 $\|s\| < 1 - \rho$, $\kappa(s, -)$ 是一维勒贝格弧长测度在 C_s^+ (半径为 ρ 并以 s 为中心的东北象限圆与 $\mathcal{S}$ 的交集) 上的总和以及狄拉克测度 $\delta_{\perp}$ 。最后, 当 $\|s\| > 1 - \rho$

$\kappa(s, -) = \delta_{\perp}$ 。前向结构如图 1(a) 所示。

后向参考核函数 κ^b 定义类似。

参考测度 ν 是 Lebesgue 测度在 $\mathcal{S}, \delta_{s_0}$ 上的和, 以及 $\delta_{\perp}$ 。除了 s_0 之外的所有状态都是终止状态。

奖励测度 R 在 $\mathcal{X}$ 上由密度函数 r 指定, 该密度函数如图 2(a) 所示。密度 p_F 和 p_B 通过 Beta 分布的混合物对连续部分进行参数化。

在图 1(b,c) 中, 我们将 DB 和 TB 在两种环境版本 ($\rho \in \{0.1, 0.25\}$) 上进行比较, 分别使用均匀分布和学习到的 P_B , 并使用学到的终止状态分布与目标分布之间的 Jensen-Shannon 发散 (JSD, § C.1) 作为评估指标。结果证实了 Malkin 等人 (2022 年) 的研究发现。




图 2. (a) 奖励密度在 $[0,1]^2$. (b) 在使用 TB 训练的模型终止状态下拟合 KDE (Kernel Density Estimation), $\rho = 0.25$. (c) 基于奖励样本的 KDE 拟合, 返回到 D_0 使用统一的 P_B , 对应的 $P_F(s_0, -)$ 需要满足数据库或表格的要求。密度的搜索空间更加丰富 $P_F(s, -)$ 需要拟合此分布。 (d) $P_F(s_0, -)$ 对于一个具有可学习参数的训练模型 P_B . (e) 由训练诱导的测度 P_B 开启 D_0 , 与所学的相匹配 $P_F(s_0, -)$ in (d).




图 3. 随机控制任务的 GFlowNet 状态空间。实线箭头表示可能的采样轨迹，虚线箭头表示其他可能的动作，即指向参考函数 κ 支持中的其他状态。

离散网格域：TB 损失在信用分配方面更为高效，因为它比 DB 更快、更精确地学习目标分布，而轨迹长度较长的环境则更难建模。此外，学习反向策略显著改善了两种方法的学习曲线。图 2(c,d,e) 提供了学习反向策略重要性的证明。图 2(b) 展示了在 TB 训练的模型上从终止状态采样的 KDE 图，该模型是在 $\rho = 0.25$ 域上训练的。我们在 § C.2 中提供更多的细节。

4.2. 低维随机控制

在本节中，我们展示了具有特定形式状态空间的广义 GFlowNets 如何用于学习（离散化）随机微分方程，以便从黑盒目标密度中采样。我们将两篇近期的研究工作联系起来：Zhang & Chen (2022)，从中借鉴数据集和实验设置的许多部分，以及 Malkin 等 (2023)，其中考虑了各种在离散空间训练随机采样器的算法，并验证了这些算法在连续情况下的有效性。

我们用 GFlowNet 术语重新陈述 Zhang & Chen (2022) 所研究的问题。在一个欧几里得空间上给出了奖励密度 $\mathbb{R}^n$ （例如，图 3 中的平面）。状态空间是 $\mathcal{S} = \{s_0\} \cup (\mathbb{R}^n \times \{1, 2, \dots, T\})$ ，其中 T 是代理在终止前将要进行的动作次数（这里， $T = 100$ ）。因此，非初始状态是成对的 (x_t, t) ，其中

表 2. 利用重要性加权估计对数划分函数偏差 B_{RW} （10 次运行的均值和标准差）。每列中的粗体值表示最佳结果以及所有统计上等同于它的值（ $p > 0.1$ 在 Welch's t -test）。假设可访问奖励梯度（非黑盒）的算法用于比较。标记有 * 需要重要性加权来进行梯度估计。带有 - 的单元不稳定优化。最后三行来自张与陈 (2022)。

Black box?			Gaussian mixture	Funnel
✓	Off-policy	GFlowNet TB	-0.003 $\pm$ 0.011	-0.026 $\pm$ 0.020
✓	Off-policy	Reverse KL*	-1.609 $\pm$ 0.546	-
✓	Off-policy	Forward KL*	-0.001 $\pm$ 0.013	-0.087 $\pm$ 0.081
✓	On-policy	GFlowNet TB	-1.301 $\pm$ 0.434	-0.012 $\pm$ 0.108
✓	On-policy	Reverse KL	-1.237 $\pm$ 0.413	-0.040 $\pm$ 0.023
✓	On-policy	Forward KL*	-0.007 $\pm$ 0.023	-0.034 $\pm$ 0.143
✓	Non-SDE	SMC	-0.362 $\pm$ 0.293	-0.216 $\pm$ 0.157
×	On-policy	PIS-NN	-1.192 $\pm$ 0.482	-0.018 $\pm$ 0.020
×	Non-SDE	HMC	-1.876 $\pm$ 0.527	-0.835 $\pm$ 0.257

$x_t \in \mathbb{R}^n$ 和 $1 \leq t \leq T$ ；我们将 s_0 识别为 $(\mathbf{0}, \mathbf{0})$ 。轨迹始于 s_0 并通过 $\mathbb{R}^n$ 的副本逐步移动，直到到达汇状态。

2 学习一个前向策略相当于学习一个条件概率密度 $p(x_{t+1}|x_t, t)$ 覆盖 $\mathbb{R}^n$ 。特别是，如果这个密度是高斯分布，则该策略是 Itô 随机微分方程 (SDE) 的 T 步 Euler-Maruyama 离散化。

张与陈 (2022) 研究了当反向策略固定为具有固定方差的布朗运动离散化情况下的该问题 $\frac{\sigma}{T}$ 固定于 $(\mathbf{0}, \mathbf{0})$ ，并且前向策略被约束为具有相同方差的高斯分布 $\frac{\sigma}{T}$ 但使用了学习到的均值。（SDE 理论表明在 T 极限 $\rightarrow \infty$ ，前向策略 P_F 使得 GFlowNet 损失最小化的确实是具有相同方差的高斯分布 P_B 。）因此，我们的目标是学习一个函数 $\mu(x_t, t)$ ，正向策略的均值，从而使策略从目标奖励密度中采样。

张与陈 (2022) 提出的路径积分采样器 (PIS) 训练目标最小化了两个轨迹测度之间的逆 KL 发散：一个由 P_F 定义，另一个由 R 和 P_B 定义。根据马尔金等人 (2023) 的定理 1（其证明可以简单地推广到连续情况），该目标关于 P_F 参数的梯度，在期望上，与在策略训练时 TB 梯度的比例相同。PIS 与在策略 TB 目标的关键区别在于后者不需要访问奖励分布的梯度，而是将其视为黑盒。

数据集、算法和基线

我们评估测度 ν 是每个副本上的勒贝格测度 $\mathbb{R}^n$ 以及上的计数测度 $\{s_0\}$ 。如果 s_i 是一个处于的 i 第份副本 $\mathbb{R}^n$ (如果 $i > 0$) 或初始状态 s_0 (如果 $i = 0$)，引用核函数 $\kappa(s_i, -)$ 是在 $(i+1)$ -第份副本上定义的勒贝格测度 $\mathbb{R}^n$ 如果 $i < T$ 并且 $\delta \perp$ 如果 $i = T$ ； κ^b 定义类似。

GFlowNets 和基线在两种合成密度上的表现：一个二维的 9 高斯混合模型和来自 MCMC 文献的 10 维漏斗（霍夫曼与杰尔曼，2011）。

除了 GFlowNet TB 之外，我们还评估了马尔金等人（2023）研究的两种用于最小化轨迹测度之间发散的算法：通过策略梯度优化的逆 KL——在期望上等同于 TB——以及前向 KL，其梯度估计需要重要性加权。我们还在离策略设置下评估这些算法，在此设置中，训练轨迹是通过向策略中注入额外的方差来鼓励探索而采样的（详见 § C）。我们还包括了张与陈（2022）的基线。

所有算法都使用与 PIS 基线相同的模型架构对于 $\mu(\mathbf{x}_t, t)$ ，并使用张与陈（2022）定义的两个度量进行评估：使用简单和重要性加权变分界的对数分区函数估计偏差，如 § C.3 所定义。

结果与讨论。 根据表 2 和扩展结果表 C.1 中的数据，我们得出结论，Malkin 等人（2023）的主要观察结果在这一连续设置下仍然成立。首先，正如预期的那样，在两种方法都能稳定优化的情况下，on-policy TB 和 reverse KL 的表现相似。其次，在需要 off-policy 探索的场景中，TB 比其他需要重要性加权进行梯度估计的目标更稳定，并且更好地拟合目标。图 C.1 显示了探索对于发现模式的必要性。最后，我们注意到尽管没有访问奖励密度梯度的能力，TB 仍与 PIS 目标具有竞争力。

4.3. 托鲁斯上的随机控制

我们考虑 § 4.2 中讨论的采样器的一个变体，用于在二维托鲁斯表面上建模奖励密度。分布于托鲁斯上有助于建模分子构象中的扭转角，我们在 § C.4 中进行了说明，并通过图 C.2 中的丙氨酸二肽分子进行了展示。

图 C.2 丙氨酸二肽分子。

为了建模托鲁斯表面，可测量的有向图由 $\mathcal{S} = \{s_0\} \cup [0, 2\pi)^2 \times \{t \in \mathbb{N}, 1 \leq t \leq T\}$ ，定义，其中 t 表示步数， T 表示轨迹长度，且 $s_0 = ((0, 0), 0)$ 。请注意，这里的 $[0, 2\pi)$ 具有圆的拓扑结构，而不是从实线诱导出来的。

我们考虑两种奖励密度：一种合成的多模态密度，以及基于丙氨酸二肽分子两个定义其构象的角度的能 E 的密度。更多细节见 § C.4。我们在图 4 中提供了学习到的和奖励分布的可视化表示。




图 4. 在奖励函数样本 (a: 合成多模态奖励函数, c: 丙氨酸二肽分子主要扭转角的玻尔兹曼分布——详情见 § C.4) 和相应的训练 GFlowNets 样本 (b, d) 上拟合的 KDE。托鲁斯的拓扑结构对 $[0, 2\pi)^2$ 施加了周期性边界条件。

4.4. 贝叶斯结构学习中连续参数的后验分布

为了展示 GFlowNets 在混合空间中对离散量和连续量进行建模的能力，我们从贝叶斯视角研究了学习贝叶斯网络结构及其参数的问题。在此基础上扩展了 Deleu 等人的工作（2022），我们的目标是近似联合后验分布 $P(G, \theta | \mathcal{D})$ 关于有向无环图 (DAG) 结构 G 的贝叶斯网络（离散部分）以及其条件概率分布的参数 θ （连续部分），给定一个观测数据集 $\mathcal{D}$ 。

本文采用结构如下所示的 GFlowNet：从空图开始，有向无环图 G 按照 DAG-GFlowNet (Deleu 等，2022) 的结构，每次生成一条边。当图 G 完全生成后，接着采样与其相关的参数 θ ，以达到有效的终止状态 (G, θ) 。关于状态空间和正向转移概率的详细信息，请参见 § C.5。本文使用子轨迹平衡损失 (Madan 等，2022) 来训练 GFlowNet，其中 $R(G, \theta) = P(\mathcal{D} | \theta, G)P(\theta, G)$ 作为奖励函数。

为了评估我们的近似方法与目标分布的对比，我们考虑那些真实后验分布 $P(G, \theta | \mathcal{D})$ 可以以封闭形式计算的问题。更具体地说，我们假设贝叶斯网络遵循

表 3. GFlowNet 与其他基于变分推断的方法在贝叶斯结构学习任务上的比较。(图) 估计边缘与精确边缘之间的均方根误差。(参数) 在精确后验分布下参数样本的平均负对数概率 $P(\theta | G, D)$

		Number of variables (d)		
		3	4	5
Graphs	BCD Nets	—	2.13×10^{-1}	2.61×10^{-1}
	DiBS	3.28×10^{-1}	2.95×10^{-1}	3.15×10^{-1}
	GFlowNet	1.50×10^{-2}	1.61×10^{-2}	1.80×10^{-2}
Params.	BCD Nets	—	2.17×10^2	2.63×10^2
	DiBS	5.87×10^2	1.12×10^3	2.12×10^3
	GFlowNet	-1.75×10^0	-3.06×10^0	-5.17×10^0

一个线性-高斯模型，并且随机变量的数量为 $d \leq 5$ 。关于实验设置和度量的更多细节，请参见 § C.5。在表 3 中，我们将 GFlowNet 与两种基于变分推断的基线方法进行比较：DiBS (Lorch 等, 2021) 和 BCD Nets (Cundy 等, 2021)。在表 3 (上部)，我们报告了边缘分布的近似值与精确后验之间的均方根误差 (RMSE) $P(G | \mathcal{D})$ ；观察到由 GFlowNet 学习到的模型在离散部分的准确性显著提高，这支持了 Malkin 等 (2023) 的观察结果。此外，在表 3 (下部)，我们发现从 GFlowNet 采样的样本在精确后验下的概率显著更高 θ ；这表明 GFlowNet 对连续部分的近似也更准确 $P(\theta | G, D)$ 。

4.5. 与扩散模型的联系

我们展示了广义 GFlowNet 框架如何应用于超出将采样器拟合到目标奖励函数的设置。正如 Zhang 等 (2023) 所示，GFlowNets 也可以通过一种称为 MLE-GFN 的算法来训练，以最大化给定终止状态集的可能性。在这里，我们将 MLE-GFN 应用于广义 GFlowNets，以改进去噪扩散概率模型 (DDPMs; Ho 等, 2020)。

采样过程。DDPM 中的生成过程可以视为与 § 4.2 和图 3 所示形式相同的广义 GFlowNet 采样过程的一种特殊情况。固定数量的步骤 T 通过高维空间的一系列副本构成 $\mathbb{R}^n$ (带有 i 轨迹中的第- i 状态，表示例如噪声水平下的图像 $T-i$)。第一步的策略，从 s_0 到 $(x_1, 1)$ 被约束为单位高斯分布，而后续步骤则是

条件高斯分布，其方差已知。

更具体地说，扩散模型从噪声分布中抽取一个样本 x_1 ，并通过一系列条件高斯步骤将其转换 $x_1 \rightarrow x_2 \rightarrow \dots \rightarrow x_T$ (请注意这种非常规的逆向和基于-1 的索引)。将中间样本 x_t 视为状态 (x_t, t) ，我们可以将从扩散模型中采样视为从 GFlowNet 中采样，其中第一个动作通过从抽象初始状态 s_0 转换来采样 x_1 ，后续动作遵循一个前向核函数 $P_F(- | (x_t, t))$ 其支撑集为 $\{(x, t+1) : x \in \mathbb{R}^n\}$ ，且其密度是一个基于 x_t 和 t 的条件高斯分布。

加噪过程。虽然 DDPM 通常固定加噪过程——对应于 GFlowNet 中的后向策略 P_B ——并仅学习去噪器 (前向过程)，MLE-GFN 允许同时学习两者 P_F 和 P_B 作为高斯策略。MLE-GFN 的描述及其可靠性证明，以及均值和方差参数化的细节，可以在 Zhang 等人的文章 (2023a) 中找到。

实验结果。我们在 ImageNet-32 数据集 (被视为一组终止状态) 上按照上述方法训练了一个 GFlowNet，共进行了 $T = 100$ 步。表 4 展示了我们的方法在样本质量 (FID) 和密度建模 (NLL) 方面与 DDPM 基线相比的有效性。其他细节和示例图像请参见 § C.6。

5. 结论

我们已经发展了一种广义 GFlowNets 的理论并通过实验进行了说明。未来的工作将利用这一理论并将实验扩展到更复杂和高维的空间，在这些空间中生成包括离散和连续的选择。可能的应用领域包括贝叶斯神经网络后验估计、分子构象生成 (讨论见 § C.4) 以及基于仿真的自然科学研究中的逆问题推理。

致谢

作者感谢 CIFAR、IVADO、Genentech、Samsung 和 IBM 的资金支持。

N.M.感谢 Alexander Tong 和 Yatin Dandi 的有益讨论。

A.V.感谢 Luca Thiede 和 Santiago Miret 在丙氨酸二肽分子实验中的帮助。

T.D. 感谢米祖·尼西卡瓦-图米和吉滕德拉·苏布-ramanian 关于贝叶斯结构学习实验的帮助和有益讨论。

作者贡献

S.L.、T.D.、N.M.发展了该理论，L.N.E.提供了一些证明。
§ 4 中的实验由 S.L.（合成网格）、N.M.（随机控制）、A.V.和 A.H.（环面）、T.D.（贝叶斯结构学习）、D.Z.（扩散）完成。P.L.还完成了关于建模假设重要性的实验。Y.B.构思并指导了该项目。所有作者都参与了设计实验和撰写论文。

参考文献

- Bengio, E., Jain, M., Korablyov, M., Precup, D., and Bengio, Y. Flow network based generative models for non-iterative diverse candidate generation. *Neural Information Processing Systems (NeurIPS)*, 2021a.
- Bengio, Y., Lahlou, S., Deleu, T., Hu, E., Tiwari, M., and Bengio, E. GFlowNet foundations. *arXiv preprint 2111.09266*, 2021b.
- Bergwerf, H. Molview, 2014. URL <https://molview.org>.
- Cappé, O., Moulines, E., and Rydén, T. Inference in hidden markov models. In *Proceedings of EUSFLAT conference*, 2009.
- Coffey, W., Kalmykov, Y., and Waldron, J. *The Langevin Equation: With Applications to Stochastic Problems in Physics, Chemistry and Electrical Engineering*. 09 2004.
- Cundy, C., Grover, A., and Ermon, S. BCD Nets: Scalable variational approaches for Bayesian causal discovery. *Neural Information Processing Systems (NeurIPS)*, 2021.
- Deleu, T., Góis, A., Emezue, C., Rankawat, M., Lacoste-Julien, S., Bauer, S., and Bengio, Y. Bayesian structure learning with generative flow networks. *Uncertainty in Artificial Intelligence (UAI)*, 2022.
- Dockhorn, T., Vahdat, A., and Kreis, K. Score-based generative modeling with critically-damped langevin diffusion. *International Conference on Learning Representations (ICLR)*, 2022.
- Doucet, A., Freitas, N., and Gordon, N. *An Introduction to Sequential Monte Carlo Methods*, pp. 3–14. Springer New York, 2001.
- Hagemann, P., Hertrich, J., and Steidl, G. Stochastic normalizing flows for inverse problems: A Markov chains viewpoint. *SIAM/ASA Journal on Uncertainty Quantification*, 10(3):1162–1190, 2022.
- Ho, J., Jain, A., and Abbeel, P. Denoising diffusion probabilistic models. *Neural Information Processing Systems (NeurIPS)*, 2020.
- Hoffman, M. D. and Gelman, A. The No-U-turn sampler: adaptively setting path lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research (JMLR)*, 15:1593–1623, 2011.
- Jain, M., Bengio, E., Hernandez-Garcia, A., Rector-Brooks, J., Dossou, B. F., Ekbote, C., Fu, J., Zhang, T., Kilgour, M., Zhang, D., Simine, L., Das, P., and Bengio, Y. Biological sequence design with GFlowNets. *International Conference on Machine Learning (ICML)*, 2022.
- Jing, B., Corso, G., Jeffrey Chang, R. B., and Jaakkola, T. Torsional diffusion for molecular conformer generation. *Neural Information Processing Systems (NeurIPS)*, 2022.
- Li, Y., Luo, S., Wang, H., and Hao, J. CFlowNets: Continuous control with generative flow networks. *International Conference on Learning Representations (ICLR)*, 2023.
- Lipman, Y., Chen, R. T. Q., Ben-Hamu, H., Nickel, M., and Le, M. Flow matching for generative modeling. *arXiv preprint 2210.02747*, 2022.
- Lorch, L., Rothfuss, J., Schölkopf, B., and Krause, A. DiBS: Differentiable Bayesian structure learning. *Neural Information Processing Systems (NeurIPS)*, 2021.
- Madan, K., Rector-Brooks, J., Korablyov, M., Bengio, E., Jain, M., Nica, A., Bosc, T., Bengio, Y., and Malkin, N. Learning GFlowNets from partial episodes for improved convergence and stability. *arXiv preprint 2209.12782*, 2022.
- Malkin, N., Jain, M., Bengio, E., Sun, C., and Bengio, Y. Trajectory balance: Improved credit assignment in GFlowNets. *Neural Information Processing Systems (NeurIPS)*, 2022.
- Malkin, N., Lahlou, S., Deleu, T., Ji, X., Hu, E. J., Everett, K. E., Zhang, D., and Bengio, Y. GFlowNets and variational inference. *International Conference on Learning Representations (ICLR)*, 2023.
- Mironov, V., Alexeev, Y., Mulligan, V. K., and Fedorov, D. G. A systematic study of minima in alanine dipeptide. *Journal of Computational Chemistry*, 40(2):297–309, 2018.
- Neal, R. M. Annealed importance sampling. *Statistics and Computing*, 11(2):125–139, 2001.
- Neal, R. M. MCMC using Hamiltonian dynamics. *arXiv preprint 1206.1901*, 2012.
- Nishikawa-Toomey, M., Deleu, T., Subramanian, J., Bengio, Y., and Charlin, L. Bayesian learning of causal structure and mechanisms with GFlowNets and variational bayes. *arXiv preprint 2211.02763*, 2022.

Nummelin, E. 一般不可约马尔可夫链与非负算子. 剑桥大学出版社, 2004.

Pan, L., Zhang, D., Courville, A., Huang, L., 和 Bengio, Y. 生成增强流网络. 学习表征国际会议 (ICLR), 2022.

Petritis, D. 可测空间上的马尔可夫链. 2015. URL <http://perso.univ-rennes1.fr/dimitri.petritis/enseignement/markov/markov.pdf>.

Sohl-Dickstein, J. N., Weiss, E. A., Maheswaranathan, N., 和 Ganguli, S. 使用非平衡热力学进行深度无监督学习. 机器学习国际会议 (ICML), 2015.

Song, Y. 和 Ermon, S. 通过估计数据分布的梯度来进行生成建模. 神经信息处理系统大会 (NeurIPS), 2019.

Thiede, L., Miret, S., Sadowski, K., Xu, H., Phielipp, M., 和 Aspuru-Guzik, A. 使用 SE3 变换器和模仿学习进行构象搜索. NeurIPS 2022 AI 加速材料设计研讨会, 2022.

吴, H., 科勒, J., 和诺埃, F. 随机归一化流. 神经信息处理系统会议 (NeurIPS), 2020.

张, D., 马尔金, N., 刘, Z., 沃洛霍娃, A., 库维尔, A., 和本乔, Y. 离散概率建模的生成流网络. 国际机器学习大会 (ICML), 2022.

张, D., 陈, R.T.Q., 马尔金, N., 和本乔, Y. 统一生成模型与 GFlowNets 及更远. arXiv 预印本 2209.02606, 2209.02606.

张, D., 雷农, C., 佩施尔, M., 和邦德桑, R. 使用 GFlowNets 的鲁棒调度. 国际学习表示会议 (ICLR), 2023b. 即将出版.

张, Q. 和陈, Y. 路径积分采样器: 一种用于采样的随机控制方法. 国际学习表示会议 (ICLR), 2022.

齐默曼, H., 林斯特恩, F., 范德梅恩, J.-W., 和纳塞斯, C.A. 生成流网络的变分视角. arXiv 预印本 2210.07992, 2210.07992.

附录 A. 过渡核函数：附加符号和定义

我们首先回顾转移核函数和马尔可夫核函数的定义

定义 8 (转移核函数). 设 $(\bar{S}, \Sigma)$ 是一个可测 (状态) 空间。若函数 $\kappa : \bar{S} \times \Sigma \rightarrow [0, +\infty)$ 满足以下条件, 则称为正 σ -有限转移核函数

1. 对于任意 $B \in \Sigma$, 映射 $s \mapsto \kappa(s, B)$ 是可测的, 其中空间 $[0, +\infty)$ 关联到 Borel σ -代数 $\mathcal{B}([0, +\infty))$;
2. 对于任意 $s \in \bar{S}$, 映射 $B \mapsto \kappa(s, B)$ 是在 $(\bar{S}, \Sigma)$ 上的正 σ -有限测度

满足映射 $B \mapsto \kappa(s, B)$ 为概率测度的转移核函数称为马尔可夫核函数。

记号。 给定一个可测空间 $(\bar{S}, \Sigma)$, 我们记 $\Sigma|_U$ 为 Σ 在任意子集 U 上的限制。 $\bar{S}$

A.1. 核函数的乘积。

给定一个可测空间 $(\bar{S}, \Sigma)$, 一个正测度 ν 在 $(\bar{S}, \Sigma)$ 上, 以及一个转移核函数 κ 在 $(\bar{S}, \Sigma)$ 上, 我们记 $\nu\kappa$ (分别记作 $\nu \otimes \kappa$) 为在 $(\bar{S}, \Sigma)$ (分别记作 $(\bar{S} \times \bar{S}, \Sigma \otimes \Sigma)$) 上的测度, 定义为对于 $B \in \Sigma$ (分别记作 $B \in \Sigma \otimes \Sigma$) :

$$\nu\kappa(B) = \int_{\bar{S}} \nu(ds) \kappa(s, B). \quad (17)$$

$$\nu \otimes \kappa(B) = \iint_{\bar{S}^2} \mathbb{1}_B(s, s') \nu(ds) \kappa(s, ds') \quad (18)$$

特别地, 对于任意状态 $s \in \bar{S}$, n 步测度 $\kappa^n(s, -)$ 递归定义为 $\kappa^0(s, -) = \delta_s$, 即狄拉克 δ 函数在 s 处, 并且:

$$\kappa^{n+1}(s, -) = \kappa^n(s, -)\kappa. \quad (19)$$

以下引理, 在 § F 中证明了转移核函数之间的绝对连续性可以传递到 n 步测度上。

引理 1. 设 P_F 是一个在 $(\bar{S}, \Sigma)$ 上的转移核函数, 使得 $P_F(s, -) \ll \kappa(s, -)$ 对于每一个 $s \in \bar{S}$ 成立。那么对于每一个 $n \geq 1$, $P_F^n(s, -)$ 和 $\kappa^n(s, -)$ 是绝对连续的。

A.2. 测度间的等价 给定两个测度 p 和 q 在 $(\bar{S}, \Sigma)$ 上, 以及一个函数 $g : \bar{S} \rightarrow \mathbb{R}$, 我们使用如下记号:

$$p(ds) = g(s)q(ds)$$

表示对于任何可测有界函数 $f : \bar{S} \rightarrow \mathbb{R}$:

$$\int_{\bar{S}} f(s)p(ds) = \int_{\bar{S}} f(s)g(s)q(ds). \quad (20)$$

在整个论文中, 当上下文允许时, 我们交替使用这两种记号。我们的证明主要依赖于将等式写成可测有界函数的形式。

关于乘积测度之间的等式需要特别小心, 尤其是在同时使用核函数 κ 和反向操作时 reference kernel κ^b . For example (4) means that for any measurable bounded function $f : \bar{S} \times \bar{S} \rightarrow \mathbb{R}$ satisfying $f(s_0, s_0) = f(\perp, \perp) = 0$:

$$\iint_{\bar{S} \times \bar{S}} f(s, s') \nu(ds) \kappa(s, ds') = \iint_{\bar{S} \times \bar{S}} f(s, s') \nu(ds') \kappa^b(s', ds).$$

我们选择不使用符号 $\nu(ds) \kappa(s, ds') = \nu(ds') \kappa(s', ds)$ 来表示 (4), 因为它没有传达“ ds ”和“ ds' ”何时代表 $\{s_0\}, \{s_0\}$ 或 $\{\perp\}, \{\perp\}$ 的信息

附录 A.3 轨迹测度

定义 9. 设 P_F 是在 $(\bar{S}, \Sigma)$ 上的转移核函数 对于任意的 $n \geq 0$ 和 $s \in \bar{S}$, P_F 诱导出一个测度 $P_F^{\otimes n}(s, -)$ 在乘积空间 $(\bar{S}^{n+1}, \Sigma^{\otimes(n+1)})$. $P_F^{\otimes n}(s, -)$ 上, 称为在 s 处的递归定义的 n 步轨迹测度

$$P_F^{\otimes 0}(s, -) = \delta_s, \quad (21)$$

$$P_F^{\otimes n+1}(s, -) = P_F^{\otimes n}(s, -) \otimes P_F. \quad (22)$$

Notation. We use $\overrightarrow{s_{1:n}}$ 以表示 $(s_1, \dots, s_n)$ 和 $\overrightarrow{ds_{1:n}}$ 表示 $ds_1 \dots ds_n$.

写出例如: $P_F^{\otimes 1}(s, ds' ds_1) = \delta_s(ds') P_F(s', ds_1)$ 和 $P_F^{\otimes 2}(s, ds' ds_1 ds_2) = \delta_s(ds') P_F(s', ds_1) P_F(s_1, ds_2)$,

更一般地:

$$P_F^{\otimes n}(s, ds' \overrightarrow{ds_{1:n}}) = P_F^{\otimes n-1}(s, ds' \overrightarrow{ds_{1:n-1}}) P_F(s_{n-1}, ds_n)$$

A.4. 终止状态测度 给定一个可测的有向无环图 $G = (\bar{S}, \mathcal{T}, \Sigma, s^0, \perp, \kappa, \kappa^b, \nu)$, 任意转移核函数 P_F 开启 $(\bar{S}, \Sigma)$ 诱导终止状态测度 $P_\top$, 即为各项之和 n -步终止状态测度定义如下:

定义 10. 令 P_F 成为上的转移核函数 $(\bar{S}, \Sigma)$. 对于任意 $n \geq 0$ 我们定义了该 n -步终止状态测度 $P_\top^n$ 覆盖 $(X, \Sigma|_X)$, 对于任意 $B \in \Sigma|_X$ 如:

$$P_\top^n(B) = \int_{\bar{S}^{n+1}} P_F^{\otimes n}(s_0, ds_1 \dots ds_{n+1}) \mathbb{1}_B(s_n) \mathbb{1}_{s_{n+1}=\perp}. \quad (23)$$

终止状态的测度定义为:

$$P_\top : B \in \Sigma|_X \mapsto \sum_{n=1}^{\infty} P_\top^n(B) \quad (24)$$

在 § F 证明的引理将终止测度与步测度关联起来: n -步终止测度与 n -步测度 $P_F^n(s_0, -)$:

引理 2. 令 P_F 为定义在 $(\bar{S}, \Sigma)$ 上的转移核函数. 对于每一个 $n \geq 1$, 我们有:

$$P_\top^n(dx) = P_F(x, \{\perp\}) P_F^{n-1}(s_0, dx) \quad (25)$$

附录 A.5 后向参考核函数 给定一个参考核函数 κ , 设计一个后向参考核函数 κ^b 可以通过逆核函数 (Cappé等, 2009) 来实现, 我们在此重新定义如下:

定义 11 (逆核). 令 $(\bar{S}, \Sigma)$ 构成一个可测空间, κ 成为上的转移核函数 $(\bar{S}, \Sigma)$, 和 ν 是一个正测度 于 $(\bar{S}, \Sigma)$. 逆核 κ_ν^r 与...相关 ν 和 κ 是一个过渡核函数覆盖 $(\bar{S}, \Sigma)$ 使得:

$$\nu \otimes \kappa = (\nu \kappa) \otimes \kappa_\nu^r \quad (26)$$

请注意, (26) 与后向参考核函数 (4) 的条件不同. 方便的是, 存在一个参考测度 ν , 使得这两个条件等价, 这意味着后向参考核函数可以定义为与 ν 和 κ 相关的逆核函数. 虽然不能保证逆核函数一般情况下存在或唯一, 但如果 $(\bar{S}, \mathcal{T})$ 是一个波莱空间 (例如离散空间、欧几里得空间 $\mathbb{R}^n$ 、超矩形或球体在 $\mathbb{R}^n$ 中, 或者其可数族的乘积或不相交并集) (Cappé等, 2009), 则存在性是可以保证的. 下面的命题, 在 § F 中证明了这一点.

命题 3. 给定一个波莱空间 $\bar{S}$, 具有源状态和汇状态 $s^0, \perp \in \bar{S}$, 使得 s^0 和 $\{\perp\}$ 都是开闭集, 并且一个满足 (1), (2) 和 (7) 的转移核函数 κ 在 $(\bar{S}, \Sigma)$ 上. 令 ν 是由以下定义的测度:

$$\nu = \sum_{n=0}^N \kappa^n(s_0, -), \quad (27)$$

并且令 κ_{ν}^r 是任何与 κ 和 ν 相关并满足以下两个条件的逆核函数:

$$\kappa_{\nu}^r(s_0, -) = 0 \quad \text{i.e. it's the trivial measure} \quad (28)$$

$$\forall s \in \mathcal{S}, \kappa^b(s, \{\perp\}) = 0. \quad (29)$$

令核函数 κ^b 在 $(\bar{\mathcal{S}}, \Sigma)$ 上由下式定义:

$$\begin{aligned} \forall s \neq \perp, \kappa^b(s, -) &= \kappa_{\nu}^r(s, -), \\ \forall B \in \Sigma_{\perp}, \kappa^b(\perp, B) &= \frac{1}{\nu(\{\perp\})} \nu \otimes \kappa(B \times \{\perp\}), \\ \kappa^b(\perp, \{\perp\}) &= 0. \end{aligned}$$

核函数 ν 严格正, 并且 κ^b 满足 (4)。请注意, 逆核的存在性, 满足 (28) 和 (29), 由引理 3 保证, 该引理在 § F 中证明。

引理 3. 给定一个波莱空间 $(\bar{\mathcal{S}}, \Sigma)$, 带有源状态和汇状态 $s_0, \perp \in \bar{\mathcal{S}}$, 使得 s_0 和 $\{\perp\}$ 都是开集和闭集, 并且一个转移核函数 κ 在 $(\mathcal{S}, \Sigma)$ 上满足 (1), (2) 和 (7)。那么测度 ν 由下式定义:

$$\nu = \sum_{n=0}^N \kappa^n(s_0, -), \quad (30)$$

如果 κ^b 是一个与 ν 和 κ 相关的逆核, 则由下式定义的核函数 κ' :

$$\kappa'(s_0, -) = 0, \quad (31)$$

$$\kappa'(\perp, -) = \kappa^b(\perp, -), \quad (32)$$

$$\forall s' \in \mathcal{S} \setminus \{s_0\}, \kappa'(s', \{\perp\}) = 0 \quad (33)$$

$$\forall s' \in \mathcal{S} \setminus \{s_0\}, \forall B \in \Sigma, \perp \notin B \Rightarrow \kappa'(s', B) = \kappa^b(s, B), \quad (34)$$

也是一个与 ν 和 κ 相关的逆核。

附录 B. 指定点的有向无环图为可测定点图

以下示例表明, 指定点的有向无环图 (Bengio 等人, 2201b) 是有限吸收的可测定点图的一个特例。

示例 1. 有限状态空间是可测带点图的特例。设 $G = (V, E, s_0, \perp)$ 是一个带点有向无环图, 其中 V 是有限顶点集, $E \subset V \times V$ 是有向边集, $s_0 \in V$ 是初始状态, $\perp \in V$ 是汇状态。

顶点集 V 配上离散拓扑即为状态空间。我们可以定义一个转移核函数 κ , 使得对于任何顶点 $s \in V$, 以及任何 $B \in \mathcal{P}(V)$, 其中 $\mathcal{P}(V)$ 是 V 的幂集, 包含所有 V 的子集:

$$\kappa(s, B) = \sum_{s' \in B} \mathbb{1}_{s \rightarrow s' \in E} + \mathbb{1}_{s=\perp, \perp \in B}$$

利用这个转移核函数, 测度 $B \mapsto \kappa^n(s, B)$ 在 $(V, \mathcal{P}(V))$ 上计算从 n 开始长度为 s 并结束于顶点在 B 中的轨迹数量, 在带点图 G 中。

逆核函数可以定义为对于任何顶点 $s' \in V$ 和任何 $B \in \mathcal{P}(V)$ 如下:

$$\kappa^b(s', B) = \sum_{s \in B} \mathbb{1}_{s \rightarrow s' \in E},$$

参考测度 ν 可以定义为计数测度 (即计算任何 $B \in \mathcal{P}(V)$ 中的元素数量)。

由于 $(V, \mathcal{P}(V))$ 是一个离散空间, 条件 (1) 中的可达性仅对单点 $B = \{s\}$ 成立。这一条件对应于从 s_0 出发长度为任意值 $n > 0$ 并结束于 s 的轨迹数量为正, 这正是在 G 中可达性的概念。连续性条件由于拓扑是离散的而显然满足, 条件 (4) 也显然满足。最后, 给定 G 的无环性, 条件 (7) 得以满足。

C. 实验详情

C.1. Jensen-Shannon 发散的近似

给定一个关于有界空间 X 上的勒贝格测度的未归一化目标奖励测度 r 以及一个终止状态的 GFlowNet 采样器 P ，我们按照以下方式逼近所学采样器与归一化分布之间的 JSD $R(dx) = \frac{1}{\int_X r(x')dx'} r(x)dx$ ：

(1) 我们进行采样 N 从目标分布中使用拒绝采样方法抽取样本，以均匀分布作为提议分布，(2) 我们对上述样本拟合一个核密度估计器 (KDE)，(3) 我们对这些样本拟合第二个核密度估计器 N 来自样本 P (4) 我们使用两种 KDE 对定义样本空间 X 离散化的固定点集进行评分，(5) 我们对两组评分进行归一化处理，以便在网格上获得有效的概率质量函数，(6) 我们计算两个概率质量函数之间的 JSD。

C.2. 一个合成连续环境 正向和反向核函数 p_F, p_B 通过它们的概率密度 p_F 和 p_B 相对于参考核函数 κ, κ^b 。 κ, ν, κ^b 定义，并满足有限吸收可测有向图的要求。尤为值得注意的是，所有状态可以从 s_0 在 $1 + 1/\sqrt{\rho}$ 内到达

$$\left[\frac{\sqrt{\rho}}{2}, \frac{\sqrt{\rho}}{\rho} \right] \text{ 米}$$

集合 S 上的拓扑 T 是相交并集拓扑，表示为 $\bar{S} = S \cup \{\perp\}$ 和 $\{s_0, \perp\}$ 。

我们使用四个贝塔分布的混合物对 $p_F(s_0, -)$ 进行参数化，分别用于半径 $r \in (0, \rho)$ 和角度 $\theta \in (0, \frac{\pi}{2})$ 。在建模 $p_F(s, -)$ 和 $p_B(s, -)$ 时，我们使用两个贝塔分布的混合物来表示角度 $\theta \in (\theta_{\min}(s), \theta_{\max}(s))$ 。前向策略神经网络有一个额外的输出头，对应于终止轨迹的概率，i.e. $p_F(s_0, \perp)$ 。所学的概率通过乘以右侧雅可比矩阵来调整，以考虑贝塔分布的支持区间 $[0, 1]$ 与 θ 或 r 的不同。

奖励测度。

奖励测度 R 通过相对于勒贝格测度 r 的密度 λ 在 $X = (0, 1)^2$ 上指定。根据 Bengio 等人 (2021a) 和 Malkin 等人 (2022)，对于每一个 $x = (x_1, x_2) \in X$ ，未归一化的密度定义为：

$$r(x) = 0.1 + 0.5 \mathbb{1}_{|x_1 - 0.5| \in (0.25, 5]} \mathbb{1}_{|x_2 - 0.5| \in (0.25, 5]} + 2 \mathbb{1}_{|x_1 - 0.5| \in (0.25, 5]} \mathbb{1}_{|x_2 - 0.5| \in (0.3, 4)}$$

超参数。

本文通过三层神经网络学习 Beta 分布的浓度参数，每层有 128 个单元，并对 $s \neq s_0$ 使用泄漏修正线性单元激活函数。与 $p_F(s_0, -)$ 对应的参数分别进行学习。

每次迭代包括从正向策略中采样 128 条轨迹，并评估 TB 或 DB 损失（含 $\alpha = 1$ ），然后对学习参数进行梯度步进。模型训练了 20,000 次迭代。对于 DB 和 TB 损失，我们都使用了 10^{-3} 的学习率来更新 $p_F, p_B, p_F(s_0, -)$ 的参数（对于 TB，使用 $\log Z$ ，对于 DB，使用 u ）。学习率每 2500 次迭代使用折扣因子 0.5 进行衰减。

在使用学习到的 p_B 的实验中， p_F 和 p_B 除了输出层外共享参数。在 DB 中， p_F 和 u 除了输出层外也共享参数。

评估度量。 我们按照 § C.1 中所述的方法近似终止状态分布与目标分布之间的 JSD。

C.3. 低维随机控制

神经网络计算 $\mu(x_t, t)$ 具有与张和陈 (2022) 相同的架构：一对两层 MLP 处理 x_t 和一个 128 维傅里叶特征表示的 t ，随后是一个三层 MLP 连接从 x_t 和从 t 提取的特征。我们将高斯密度设置为 $\sigma = 5$ ，漏斗密度设置为 $\sigma = 1$ 。探索算法在每一步的采样策略方差中添加了一个常数 $\frac{\epsilon^2}{T}$ ；我们使用了一个线性退火到 $\epsilon = 0.1$ 的值。




图 C.1. 9 个高斯的目标密度以及使用各种算法训练 1500 批模型后采样的样本。（当训练时间更长时，带有探索的 GFlowNet TB 策略学会了以更高的精确率建模模式。）

在整个训练过程中为 0。所有模型都经过 1500 批每批 300 个样本的训练，策略的学习率为 10^{-2} ，对于 $\log Z$ （在 GFlowNet 算法的情况下）的学习率为 10^{-1} ；我们发现较高的学习率会使优化不稳定。我们还观察到，离策略的前向 KL 和 TB 算法随着训练时间的延长继续改进，而策略上的算法则会经历模式崩塌并停止发现密度景观的新区域。图 C.1 展示了使用各种算法训练的模型的样本，并突显了探索的重要性。

简单的重要加权估计对数分区函数，由张和陈（2022）定义，在 GFlowNet 术语中表示为

$$B = \frac{1}{K} \sum_{i=1}^K \log \frac{R(x_T^{(i)}) p_B^{\otimes T}(\tau^{(i)} | x_T^{(i)})}{p_F^{\otimes T}(\tau^{(i)})},$$

$$B_{\text{RW}} = \log \frac{1}{K} \sum_{i=1}^K \frac{R(x_T^{(i)}) p_B^{\otimes T}(\tau^{(i)} | x_T^{(i)})}{p_F^{\otimes T}(\tau^{(i)})},$$

where the $\tau^{(i)}$ are K trajectories sampled from P_F , the $x^{(i)}$ are their terminating states, and $p_F^{\otimes T}(\tau^{(i)})$, $p_B^{\otimes T}(\tau^{(i)} | x_T^{(i)})$ are

表 C.1. 使用简单 (B) 和重要性加权 (B_{RW}) 界限估计对数分区函数的偏差 (10 次运行的平均值和标准差)。每列中的粗体值表示最佳结果以及所有统计上等效的结果 (在 Welch's t 检验下 $p > 0.1$)。为了进行比较, 展示了假设可以访问奖励梯度 (非黑盒) 的算法。标有 * 的行需要重要性加权来进行梯度估计。标有 - 的单元格优化不稳定。最后三行来自 Zhang & Chen (2022)。

Black box?			Gaussian mixture ($d = 2$)		Funnel ($d = 10$)	
			B	B_{RW}	B	B_{RW}
✓	Off-policy	GFlowNet TB	-0.150 $\pm$ 0.019	-0.003 $\pm$ 0.011	-0.219 $\pm$ 0.020	-0.026 $\pm$ 0.020
✓	Off-policy	Reverse KL*	-1.706 $\pm$ 0.537	-1.609 $\pm$ 0.546	-	-
✓	Off-policy	Forward KL*	-0.306 $\pm$ 0.036	-0.001 $\pm$ 0.013	-2.822 $\pm$ 0.576	-0.087 $\pm$ 0.081
✓	On-policy	GFlowNet TB	-1.409 $\pm$ 0.427	-1.301 $\pm$ 0.434	-0.265 $\pm$ 0.026	-0.012 $\pm$ 0.108
✓	On-policy	Reverse KL	-1.348 $\pm$ 0.397	-1.237 $\pm$ 0.413	-0.259 $\pm$ 0.018	-0.040 $\pm$ 0.023
✓	On-policy	Forward KL*	-0.254 $\pm$ 0.032	-0.007 $\pm$ 0.023	-1.384 $\pm$ 0.284	-0.034 $\pm$ 0.143
✓	Non-SDE	SMC	-0.362 $\pm$ 0.293		-0.216 $\pm$ 0.157	
×	On-policy	PIS-NN	-1.691 $\pm$ 0.370	-1.192 $\pm$ 0.482	-0.098 $\pm$ 0.005	-0.018 $\pm$ 0.020
×	Non-SDE	HMC	-1.876 $\pm$ 0.527		-0.835 $\pm$ 0.257	

轨迹上正向 (相应地反向) 高斯策略密度的乘积。请注意, 对于完美的采样器, 两个估计都会等于奖励密度的真实积分。与 Zhang & Chen (2022) 相同, 我们使用 $K = 2000$ 用于二维高斯混合数据集, 使用 $K = 6000$ 用于十维漏斗数据集。

我们在表 C.1 中展示了扩展结果, 包括简单和重要性加权变分界。

C.4. 托鲁斯环境中的随机控制

转移核 $\kappa(s, -)$ 对于任何 $s = (\tilde{s}, t)$ 当 $t < T$ 是勒贝格测度在 $[0, 2\pi)^2$ 上的乘积与在 $t+1$ 处的狄拉克测度, 并且 $\kappa((\tilde{s}, T), -) = \delta_{\tilde{s}}$ 对于每个 $\tilde{s} \in [0, 2\pi)^2$ 。类似于 § 4.2, 参考测度是 $\nu = \delta_{s_0} + \sum_{t=1}^T \lambda \otimes \delta_t$, 其中 λ 是每个托鲁斯副本上的勒贝格测度 $[0, 2\pi)^2$ 。

我们用由位置测度 μ 和集中度测度 κ 定义的独立冯·米塞斯分布混合物参数化密度 p_F 和 p_B 。我们在由不同奖励函数定义的托鲁斯环境中考虑了两项任务。

合成多模态任务 对于此任务, 我们在环面上设计了一个具有六个模式的奖励密度:

$$R_6(\psi, \varphi) = (\sin(3\psi) + \cos(2\varphi) + 2)^3.$$

分子构象任务。 在此任务中, 我们使用丙氨酸二肽分子的能量 E 定义奖励函数, 该能量取决于分子的构象 C (其原子的空间排列)。这种构象可以通过内部坐标高效地参数化: 键长、键角和扭转角 (Jing 等人, 2022 年; Thiede 等人, 2022 年)。对于丙氨酸二肽, 有四个扭转角对能量影响较大 (参见图 C.2)。在我们的实验中, GFlowNet 生成角度值 ψ 和 φ , 同时保持所有其他坐标固定。这样, 奖励函数的支持区域仍然是一个环面, 其值与能量 E 的玻尔兹曼分布成正比:

$$R_{AD}(\psi, \varphi) = \exp(-\mathcal{E}(C(\psi, \varphi))),$$

图 4 中的图展示了在具有连续合成多模奖励函数 R_6 (参见正文) 的环面空间上训练 GFlowNet 的结果, 以及由丙氨酸二肽分子的玻尔兹曼分布定义的奖励函数 R_{AD} 的结果。这些图像表示空间离散化后的密度 $[0, 2\pi)^2$, 通过拟合 100,000 个样本的 KDE 获得。用于拟合奖励密度的样本 (图 4(a-c)) 是通过拒绝采样获得的, 而 GFlowNet 密度 (图 4(b-d)) 则使用从终止状态的学习分布中获得的 GFlowNet 样本 p_T 。

结果。 为了评估使用 TB 损失训练的 GFlowNet 的性能, 我们计算了 Jensen-Shannon 发散




图 C.2. 丙氨酸二肽三维结构。扭转角 ψ, φ , 和 θ_1, θ_2 对分子能量的影响最大。一对扭转角 φ 和 ψ 可以取任何值 $\in [0, 2\pi]$, 而 θ_1 和 θ_2 则可以接近 0 或 π , 因为存在能量障碍 (Mironov 等人, 2018 年)。该图像是使用 MolView 渲染的 (Bergwerf, 2014 年)

(详见 § C.1 关于其估计的细节) 在学习到的终止状态分布 P_τ 和归一化的奖励分布之间。我们在图 4 中提供了学习到的和奖励分布的可视化表示。定量地, GFlowNet 在合成多模态任务中达到了 JSD 为 0.063, 在分子构象任务中达到了 0.009。这些结果表明, 广义 GFlowNet 可以对非欧几里得空间上的概率密度进行建模。

超参数。 我们将 D_F 和 D_B 都建模为具有 5 层感知机, 每层有 512 个隐藏单元, 并分别训练每个模型的所有参数。这些模型对于每个角度 ψ 和 φ 输出 5 个独立冯·米塞斯分布的位置 μ_i 和浓度 κ_i , 并以学习到的权重 w_i 混合。为了考虑环面的拓扑结构, 我们使用三角变换编码输入角度 ($\sin(k\psi), \cos(k\psi), k = 1, \dots, 5$, 对于两个角度 ψ 和 φ)。我们为模型参数设定了学习率为 10^{-5} , 为 $\log Z$ 设定了学习率为 10^{-2} , 并以长度为 $T = 10$ 的 100 条轨迹批量更新参数。在合成奖励下, 模型在大约 5000 次迭代后收敛; 在分子构象任务中, 我们训练了 40k 次迭代。

C.5. 贝叶斯结构学习中连续参数的后验

贝叶斯网络。 回忆贝叶斯网络是一种概率模型, 其中联合分布 d 随机变量 $\{X_1, \dots, X_d\}$ 根据有向无环图 (DAG) 进行因子分解 G 如:

$$P(X_1, \dots, X_d; \theta, G) = \prod_{i=1}^d P(X_i \mid \text{Pa}_G(X_i); \theta_i),$$

其中 $\text{Pa}_G(X_i)$ 是 X_i 在 G 中的父节点集合, 而 θ_i 是条件概率分布的参数集。我们用 $\theta = \{\theta_1, \dots, \theta_d\}$ 表示该模型的所有 X_i 有参数集。

我们假设 $\theta \in \Theta_G$, 其中 Θ_G 是贝叶斯网络所有参数的空间。请注意, 这个参数空间依赖于贝叶斯网络的结构 G 。例如, 所有随机变量相互独立的贝叶的网络 (对应于 G 为空) 比另一个编码这些随机变量之间依赖关系的贝叶斯网络具有更少的参数。我们还将 G 表示为包含 d 个节点的 DAG 的空间; 这个空间中的元素数量随着 d 呈超级指数增长。

线性高斯模型。 为了以封闭形式计算精确的后验分布 $P(G, \theta \mid \mathcal{D})$, 我们在此考虑一种用于贝叶斯网络中条件概率分布参数化的线性-高斯模型。更具体地说, 条件概率分布由

$$P(X_i \mid \text{Pa}_G(X_i); \theta_i) = \mathcal{N}(X_i \mid \mu_i, \sigma^2) \quad \text{其中} \quad \mu_i = \sum_{X_j \in \text{Pa}_G(X_i)} \theta_{ij} X_j.$$

换句话说, X_i 服从正态分布, 其均值 μ_i 由其父节点的线性组合给出, 并具有固定的方差 σ^2 。对于此类模型,

$$\Theta_G \simeq \bigtimes_{i=1}^d \mathbb{R}^{|\text{Pa}_G(X_i)|}$$

混合状态空间上的 GFlowNet。本文使用 GFlowNet 来逼近联合后验分布 $P(G, \theta | \mathcal{D})$ ，因此其终止状态具有形式 (G, θ) ，其中 $G \in \mathcal{G}$ 是一个有向无环图，而 $\theta \in \Theta_G$ 是相关的参数。与 Nishikawa-Toomey 等人 (2022) 使用变分贝叶斯方法更新参数分布 θ 不同，本文使用单一的 GFlowNet 来建模图和参数的分布。

终止状态的生成遵循两个阶段：在第一阶段，通过每次添加一条边从空图开始构建 DAG G ，遵循 DAG-GFlowNet (Deleu 等, 2022) 的结构。为了达到一个具有 k 条边的图 G ，我们在 GFlowNet 中采取 k 步。在这一阶段遍历的状态没有与其关联的参数；我们将这种（中间）状态表示为 $(G, \#) \in \mathcal{S}$ ，其中 $\# \notin \Theta_{G'}$ 对任何 G' 而言， $\in \mathcal{G}$ 是一个符号，表示 G 没有对应的参数。

然后，在完成添加边的操作（实际上，这个决定是通过选择一个特殊的“停止”动作来做出的）之后，我们通过对 GFlowNet 进行最后一步采样与 G 相关的参数 $\theta \in \Theta_G$ ，以到达终止状态 $(G, \theta) \in \mathcal{X}$ 。由于参数的空间依赖于图 G ，我们将 GFlowNet 的状态空间定义为

$$\mathcal{S} = \bigcup_{G \in \mathcal{G}} \{G\} \times \bar{\Theta}_G \quad \text{and} \quad \mathcal{X} = \bigcup_{G \in \mathcal{G}} \{G\} \times \Theta_G,$$

其中， $\bar{\Theta}_G = \Theta_G \cup \{\#\}$ 表示参数空间，并附加了一个特殊符号 $\#$ 。在这个状态空间中的所有状态都可以从初始状态 $(G_0, \#)$ 访问到，其中 G_0 是空图。

参考核函数。给定一个有向无环图 G ，测度 $\kappa((G, \#), -)$ 是离散测度（用于过渡到另一个中间状态 $(G', \#)$ ）和连续测度（用于过渡到终止状态 (G, θ) ）的总和。我们可以将此测度写作 $\Sigma \square$

$$\kappa((G, \#), -) = \sum_{G' \in \text{Ch}(G)} \delta_{(G', \#)} + (\delta_G \otimes \lambda_{\Theta_G}),$$

其中， $\text{Ch}(G)$ 表示在 DAG-GFlowNet 中的子节点 G ，即通过向 G 添加一条边而获得的图 G' ，而 λ_{Θ_G} 是定义在 Θ 上的勒贝格测度 G 。此外，对于所有终止状态 $(G, \theta) \in \mathcal{X}$ ，我们也有 $\kappa((G, \theta), -) = \delta_{\perp}$ ，换句话说，除了过渡到汇状态外，没有从终止状态的其他过渡。另一方面，反向参考核函数 κ^b 更简单：它始终是一个离散转移核函数，无论处于何种状态。我们有

$$\kappa^b((G, \theta), -) = \delta_{(G, \#)} \quad \text{and} \quad \kappa^b((G', \#), -) = \sum_{G \in \text{Pa}(G')} \delta_{(G, \#)},$$

其中， $\text{Pa}(G')$ 表示在 DAG-GFlowNet 中的父节点 G' ，即它们是从 G' 中移除一条单边而获得的图。

前向转移概率。为了定义 P_F ，我们考虑两种情况：要么我们有一个形式为 $P_F(G' | G)$ 的分布，其中 G' 是通过向 G 添加一条边而得到的结果，或者一个形式为 $P_F(\theta | G)$ 的分布。请注意，这里我们稍微滥用了一下记号，其中 $P_F(G' | G)$ （分别 $P_F(\theta | G)$ ）表示 $P_F((G', \#) | (G, \#))$ （分别 $P_F((G, \theta) | (G, \#))$ ）。分布 $P_F(\theta | G)$ 由正态分布参数化，其均值和（对角线）协方差由神经网络返回。类似于 (Deleu 等人, 2022), P_B 被固定为均匀分布。

数据生成。我们按照以下步骤采样数据集 $\mathcal{D}$ ：(1) 首先从 Erdős-Renyi 模型生成一个有向无环图 (DAG) G^* ，然后 (2) 从正态分布中采样条件概率分布的参数 θ^* ，每条边的权重 $\theta_{ij}^* \sim \mathcal{N}(0, 1)$ ，最后 (3) 使用祖先采样方法从上述贝叶斯网络中采样 $N = 100$ 数据点，使用 (G^*, θ^*) 。请注意，真实值 G^* 和 θ^* 对 GFlowNet 未知，它仅使用来自 $\mathcal{D}$ 的观测值。

评估。为了评估 GFlowNet 所学近似的质量，并将其与基于变分推断的基线方法 (Lorch 等, 2021; Cundy 等, 2021) 进行比较，我们将图的分布（离散部分）和图的分布（连续部分）分开研究。回忆一下，由于我们假设我们的模型在小图上是线性高斯的（ $d \leq 5$ ），我们可以闭式计算精确的后验分布 $P(G, \theta | \mathcal{D})$ 。

在表 3 中，我们将使用后验近似估计的边缘与精确边缘进行了比较。对于

表 C.2. 在贝叶斯结构学习任务上, GFlowNet 与其他基于变分推断的方法在不同感兴趣的图分布边缘上的比较 $P(G | \mathcal{D})$ 。

Number of variables (d)		RMSE			Pearson's r		
		3	4	5	3	4	5
Edges	BCD Nets	–	2.13×10^{-1}	2.61×10^{-1}	–	0.8578	0.7886
	DiBS	3.28×10^{-1}	2.95×10^{-1}	3.15×10^{-1}	0.6903	0.7085	0.7170
	GFlowNet	1.50×10^{-2}	1.61×10^{-2}	1.80×10^{-2}	0.9993	0.9990	0.9990
Paths	BCD Nets	–	2.59×10^{-1}	3.08×10^{-1}	–	0.8378	0.7500
	DiBS	3.50×10^{-1}	3.35×10^{-1}	3.48×10^{-1}	0.6951	0.7080	0.7020
	GFlowNet	3.39×10^{-3}	1.07×10^{-2}	1.99×10^{-2}	1.0000	0.9996	0.9989
Markov blanket	BCD Nets	–	3.02×10^{-1}	3.49×10^{-1}	–	0.8831	0.7864
	DiBS	3.88×10^{-1}	3.80×10^{-1}	4.45×10^{-1}	0.7840	0.7892	0.6888
	GFlowNet	2.14×10^{-2}	2.38×10^{-2}	2.83×10^{-2}	0.9986	0.9982	0.9980

对于任意一对随机变量 (X_i, X_j) , 这意味着评估以下边缘

$$P(X_i \rightarrow X_j | \mathcal{D}) = \sum_{G | X_i \in \text{Pa}_G(X_j)} P(G | \mathcal{D}).$$

为了使用样本 $\{(G_k, \theta_k)\}_{k=1}^K$ 从 GFlowNet (或从变分推断方法) 估计此边缘, 我们可以简单地使用样本图 G_k 来获得边缘后验的实证近似 $P(G | \mathcal{D})$ 。换句话说,

$$\hat{P}(X_i \rightarrow X_j) = \frac{1}{K} \sum_{k=1}^K \mathbb{1}(X_i \rightarrow X_j \in G_k)$$

然后报告使用后验近似估计的边缘与使用精确后验计算的边缘之间的均方根误差 (RMSE) :

$$\text{RMSE}(\hat{P}, P) = \left(\frac{1}{d(d-1)} \sum_{i \neq j} (\hat{P}(X_i \rightarrow X_j) - P(X_i \rightarrow X_j | \mathcal{D}))^2 \right)^{1/2}.$$

在表 C.2 中, 我们也报告了其他边缘的均方根误差: 两个节点之间存在有向路径的边缘 $P(X_i \rightsquigarrow X_j | \mathcal{D})$ 以及节点的边缘分布 X_i 处于马尔可夫毯中 X_j $P(X_i \in \text{马尔可夫毯} (X_j) | \mathcal{D})$. 除了边缘之间的均方根误差外, 我们还报告了皮尔逊相关系数, 如同 (Deleu 等, 2022) 所述。请注意, 对于图上的度量并未进行报告。 $d = 3$ 由于技术原因 (该方法不适用于少于 4 个节点的图), BCD 网络 (Cundy 等, 2021) 中的节点。

为了评估分布连续部分的近似精度, 我们在表 3 中报告了从不同近似方法 (GFlowNet, DiBS(Lorch 等, 2021), 和 BCD 网络 (Cundy 等, 2021)) 采样的参数 θ_k 相对于精确后验分布 $P(\theta | \mathcal{D})$ 的平均负对数概率 G 。更具体地说, 我们计算

$$\text{Measure}_{\theta}(\hat{P}, P) = -\frac{1}{K|\mathcal{D}|} \sum_{k=1}^K \log P(\theta_k | G_k, \mathcal{D})$$

换句话说, 这个度量越低, 那些近似方法下的样本 θ_k 在参数的精确后验分布下就越可能。

C.6. 与扩散模型的联系

我们训练了一个由扩散模型指定的 GFlowNet, 训练步骤为 $T = 100$, 共 200,000 步。这比其他最先进的工作 (如 Lipman 等 (2022)) 所需时间短得多, 并且在单个 V100 GPU 上运行不到 3 天。所有 NLL 结果均已完成计算




图 C.3. 从 MLE-GFN 在 ImageNet-32 数据集生成的样本。

以每维度比特 (BPD) 为单位。我们使用 50,000 个生成样本计算 FID 分数来评估样本质量。Adam 的学习率对于正向策略为 2×10^{-4} ，对于反向策略为 2×10^{-5} 。反向策略的参数为 $\{\phi_i\}_{i=1}^T$ ，其中方差系数 β_i 满足 $\beta_i = \bar{\beta}_i \cdot \exp(\phi_i)$ ，而 $\bar{\beta}_i$ 是 Ho 等人 (2020) 使用的原始方差系数。关于 MLE-GFN 算法的详细信息，请参见 Zhang 等人 (2023a)。图 C.3 展示了该算法生成的图像示例。

D. 额外的引理和命题

在本节中，我们将编写并证明一些引理和命题，这些将有助于解释和简化主文及 § A 部分中提出的主结果的证明，我们在 § E 中提供这些证明。

以下引理确保在一个可测定点图中， $\{s_0\}$ 是不可达的。

Lemma 4. $\forall s \in \mathcal{S}, \kappa(s, \{s_0\}) = 0$

证明 我们将通过反证法给出证明。设 $\mathcal{N} = \{s \in \bar{\mathcal{S}}, \kappa(s, \{s_0\}) > 0\}$ ，并假设 $\mathcal{N} \neq \emptyset$ 。 $(0, \infty)$ 是一个开集，并且 $s \mapsto \kappa(s, \{s_0\})$ 连续，这意味着 $\mathcal{N} \in \bar{\mathcal{T}}$ （即它是开集）。从 (1) 可以得出存在某个 $n \geq 0$ 使得 $\kappa^n(s_0, \mathcal{N}) > 0$ 。

应用 (19)，我们得到：

$$\kappa^{n+1}(s_0, \{s_0\}) = \int_{\bar{\mathcal{S}}} \kappa^n(s_0, ds') \kappa(s', \{s_0\}) \geq \int_{\mathcal{N}} \kappa^n(s_0, ds') \kappa(s', \{s_0\}) > 0.$$

记对于所有 $m > 1$ ：

$$\begin{aligned} \kappa^{m(n+1)}(s_0, \{s_0\}) &= \int_{\bar{\mathcal{S}}} \kappa^{(m-1)(n+1)}(s_0, ds') \kappa^{n+1}(s', \{s_0\}) \geq \int_{\{s_0\}} \kappa^{(m-1)(n+1)}(s_0, ds') \kappa^{n+1}(s', \{s_0\}) \\ &= \kappa^{(m-1)(n+1)}(s_0, \{s_0\}) \kappa^{n+1}(s_0, \{s_0\}), \end{aligned}$$

由此简单归纳可知 $\forall m \geq 1, \kappa^{m(n+1)}(s_0, \{s_0\}) > 0$ ，这与 (7) 相矛盾。

因此 $\mathcal{N}$ 必然是空集。 ■

以下引理确保了终止状态集合 X 与 $\kappa^b(\perp, -)$ 定义之间的兼容性:

引理 5. $\kappa^b(\perp, -)$ 的支持集是 X 的闭包。

证明 设 s 是 $\kappa^b(\perp, -)$ 的支持集中的一个元素。根据支持集的定义, 这意味着对于任何包含 s 的 $B \in \mathcal{T}$, 存在某个 $B' \subseteq B$ 使得 $B' \subseteq X$ 。特别地, $B \cap X \neq \emptyset$ 。这意味着 s 是 X 的一个闭包点。

反之, 设 s 是 X 的一个闭包点。给定任何包含 s 的 $B \in \mathcal{T}$, 作为一个闭包点意味着 $B \cap X$ (这是一个可测集) 是非空的。根据 (4), 我们得到:

$$\nu(\{\perp\})\kappa^b(\perp, B \cap X) = \int_{\bar{S}} \mathbb{1}_{B \cap X}(s') \nu(ds') \kappa(s', \{\perp\})$$

前一等式的右侧为正, 因为 ν 是一个严格正的测度, 并且对于每一个 s' 都有 $\kappa(s', \{\perp\}) > 0$, 根据定义后续可知 $s' \in X$ 。2. 因此 $\kappa^b(\perp, B \cap X) > 0$ 。由此可得 $\kappa^b(\perp, B) \geq \kappa^b(\perp, B \cap X) > 0$ 。这意味着 s 确实 $\kappa^b(\perp, -)$ 位于支持内 $\blacksquare$

引理 2 的证明依赖于以下中介引理, 该引理将 n -步轨迹测度 $P_F^{\otimes n}(s, -)$ 与 n -步测度 P^n 通过 (19) 联系起来。

引理 6. 设 P_F 是在 $(\bar{S}, \Sigma)$ 上的转移核。对于每一个 $s \in \bar{S}$, $n \geq 0$ 以及任何有界可测函数 $f: \bar{S} \rightarrow \mathbb{R}$, 我们有: f

$$\int_{\bar{S}^{n+1}} f(s') P_F^{\otimes n}(s, ds_1 \dots ds_n ds') = \int_{\bar{S}} f(s') P_F^n(s, ds') \quad (35)$$

证明 我们通过归纳法对 n 进行证明。首先, 对于 $n = 0$, 使用 (21)

$$\int_{\bar{S}} f(s') P_F^{\otimes 0}(s, ds') = f(s) = \int_{\bar{S}} f(s') P_F^0(s, ds').$$

然后, 假设对于某个 $n \geq 0$, (35) 成立, 我们得到:

$$\begin{aligned} \int_{\bar{S}^{n+2}} f(s') P_F^{\otimes n+1}(s, ds_1 \dots ds_{n+1} ds') &= \int_{\bar{S}^{n+2}} f(s') P_F^{\otimes n}(s, ds_1 \dots ds_{n+1}) P_F(s_{n+1}, ds') \\ &= \int_{\bar{S}^{n+1}} \underbrace{\int_{\bar{S}} f(s') P_F(s_{n+1}, ds') P_F^{\otimes n}(s, ds_1 \dots ds_{n+1})}_{\triangleq g(s_{n+1})} \\ &= \int_{\bar{S}} g(s_{n+1}) P_F^n(s, ds_{n+1}) = \iint_{\bar{S} \times \bar{S}} f(s') P_F(s_{n+1}, ds') P_F^n(s, ds_{n+1}) \\ &= \int_{\bar{S}} f(s') P_F^{n+1}(s, ds_{n+1}), \end{aligned}$$

其中我们应用了归纳假设到一个新的有界和可测的函数 g , 并应用了递归定义

$$P_F^{n+1}.$$

下一个命题在证明定理 1 中至关重要。

命题 4. 令 $F = (\mu, P_F)$ 是一个流过 G (i.e. F 满足流匹配条件 (9)), 则测度 u 定义为:

$$u: B \in \Sigma_{|S} \mapsto \sum_{n=0}^{\infty} P_F^n(s_0, B), \quad (36)$$

是有限的, 并且对于所有 $B \in \Sigma_{|S}$ 成立。

$$\mu(\{s_0\})u(B) = \mu(B) \quad (37)$$

这可以通过将 $f = f^+ - f^-$ 表示为 f^+ , 其中 f^- 是非负的, 将每个 f^+ , f^- 表示为阶梯函数的极限, 并应用单调收敛定理来观察到。

证明 首先, 通过简单的递归, 我们证明了 $\forall n \geq N, P_F^n(s_0, -) = \delta_\perp$ 。基本情况 ($n = N$) 作为引理 1 的结果以及可测有向图有限吸收性的结果而成立。假设它对某个 $n \geq N$ 成立, 回到 n 步测度的定义, 我们有对于每个 $B \in \Sigma$:

$$P_F^{n+1}(s_0, B) = \int_{\bar{S}} P_F^n(s_0, ds) P_F(s, B) = \int_{\bar{S}} \delta_\perp(ds) P_F(s, B) = P_F(\perp, B) = \delta_\perp(B),$$

其中最后一个等式源于 $P_F(\perp, -)$ 相对于 $\kappa(\perp, -)$ 的绝对连续性和 (7)。

这表明对于每个 $B \in \Sigma_{|S}$:

$$u(B) = \sum_{n=0}^{N-1} P_F^n(s_0, B).$$

这表明测度 u 是有限的。

接下来, 我们将 S 划分成 N 不相交的集合 $S_0, \dots, S_{N-1}$, 其中:

$$s \in S_n \Leftrightarrow n = \max\{m \in \mathbb{N}_0 : \forall B \in \mathcal{T}, s \in B \Rightarrow P_F^m(s_0, B) > 0\}$$

$S_n \in \Sigma$, 给定 $S_n = S'_n \setminus \bigcup_{k=1}^{\infty} S'_{n+k}$, 其中 S'_n 是 $P_F^n(s_0, -)$ 的支持集, 已知这是一个闭集, 因此 measurable.

Writing any $B \in \Sigma_{|S}$ as:

$$B = \bigcup_{n=0}^{N-1} B \cap S_n,$$

并利用测度 u 和 μ 的可加性, 证明 (37) 对于所有 $B \in \Sigma_{|S}$ 成立, 等价于证明它对于所有 $B \in \Sigma_{|S_n}$ 以及所有 $n \in \{0, \dots, N-1\}$ 成立, 因为集合 S_i 本身是可测的。我们通过强归纳法来证明这一点。

n .

Base case: For $n = 0$, $S_0 = \{s_0\}$, and $\Sigma_{|S_0} = \{\{s_0\}\}$.

$$u(\{s_0\}) = P_F^0(s_0, \{s_0\}) = \delta_{s_0}(\{s_0\}) = 1,$$

因此 (37) 对于 $B = \{s_0\}$ 成立。

归纳步骤: 假设对于某个 $n \geq 0$, (37) 成立对于所有 $B \in \Sigma_{|S_m}$ 对于所有 $m \leq n$, 并令 $B \in \Sigma_{|S_{n+1}}$. 定义 $B' = \{s' \in S : P_F(s', B) > 0\}$ 。我们首先证明 $B' \subseteq \bigcup_{m=0}^n S_m$ 。如果存在 $s' \in B'$ 和 $n' > n$ 使得 $s' \in S_{n'}$, 那么对于任何包含 $\tilde{B}$ (i.e. $\tilde{B} \in \mathcal{T}$) 的开集 $s', P_F^{n'}(s_0, \tilde{B}) > 0$. $\tilde{s} \mapsto P_F(\tilde{s}, s, B)$ 作为连续函数, 可以得出 B' 本身是开集。因此 $P_F^{n'}(s_0, B') > 0$ 。注意到:

$$P_F^{n'+1}(s_0, B) = \int_{\bar{S}} P_F^{n'}(s_0, ds') P_F(s', B) \geq \int_{B'} P_F^{n'}(s_0, ds') P_F(s', B) > 0,$$

这将与 $B \subseteq S_{n+1}$ 的事实相矛盾, 给定 $n' + 1 > n + 1$ 。这表明 $B' \subseteq \bigcup_{m=0}^n S_m$ 。

因此:

$$\begin{aligned} \mu(\{s_0\})u(B) &= \mu(\{s_0\}) \sum_{m=0}^{n+1} P_F^m(s_0, B) = \mu(\{s_0\}) \underbrace{\delta_{s_0}(B)}_{=0} + \mu(\{s_0\}) \sum_{m=0}^n P_F^{m+1}(s_0, B) \\ &= \mu(\{s_0\}) \sum_{m=0}^n \int_{B'} P_F^m(s_0, ds') P_F(s', B) = \int_{B'} \mu(\{s_0\}) u(ds') P_F(s', B) \\ &= \int_{B'} \mu(ds') P_F(s', B) = \mu(B), \end{aligned}$$

其中最后两个等式分别来自归纳假设和流匹配条件。 ■

以下引理将源状态和汇状态的流测度与奖励测度相关联，并表明源和汇流对应于“总奖励” $R(\mathcal{X})$ （在离散 GFlowNets 中称为分区函数）：

引理 7. 令 $F = (\mu, P_F)$ 构成流过 G 满足关于测度的条件 (10) 的奖励匹配 R ，然后

$$\mu(\{s_0\}) = \mu(\{\perp\}) = R(\mathcal{X}). \quad (38)$$

证明 将 (10) 应用于函数 $f : x \in \mathcal{X} \mapsto 1$ ，我们得到：

$$\int_{\mathcal{X}} R(dx) = \int_{\mathcal{X}} \mu(dx) P_F(x, \{\perp\}). \quad (39)$$

此外，从 (8)，我们得到 $\forall s \in \mathcal{S} \setminus \mathcal{X}, \mu(s, \{\perp\}) = 0$ 。根据 P_F 的绝对连续性要求， $\forall s \in \mathcal{S} \setminus \mathcal{X}, P_F(s, \{\perp\}) = 0$ 。因此：

$$\int_{\mathcal{X}} R(dx) = \int_{\mathcal{S}} \mu(ds) P_F(s, \{\perp\}) = \iint_{\mathcal{S} \times \bar{\mathcal{S}}} \mathbb{1}_{s'=\perp} \mu(ds) P_F(s, ds') = \int_{\bar{\mathcal{S}}} \mathbb{1}_{s'=\perp} \mu(ds') = \mu(\{\perp\}),$$

其中最后一行来自 (9)。这表明 $\mu(\{\perp\}) = R(\mathcal{X})$ 。

请注意，作为引理 4 和绝对连续性要求的结果，一个 P_F 满足：

$$\forall s \in \bar{\mathcal{S}}, P_F(s, \{s_0\}) = 0 \quad (40)$$

接下来，根据 (9) 和 (40)，我们得到：

$$\iint_{\mathcal{S} \times \bar{\mathcal{S}}} \mu(ds) P_F(s, ds') = \iint_{\mathcal{S} \times \bar{\mathcal{S}}} \mathbb{1}_{s' \neq s_0} \mu(ds) P_F(s, ds') = \int_{\bar{\mathcal{S}}} \mathbb{1}_{s' \neq s_0} \mu(ds') = \mu(\bar{\mathcal{S}}) - \mu(\{s_0\}). \quad (41)$$

另一方面，因为每个 $P_F(s, -)$ 是在 $\bar{\mathcal{S}}$ 上的概率测度，

$$\int_{\mathcal{S} \times \bar{\mathcal{S}}} \mu(ds) P_F(s, ds') = \int_{\mathcal{S}} \left(\int_{\bar{\mathcal{S}}} P_F(s, ds') \right) \mu(ds) = \int_{\mathcal{S}} \mu(ds) = \mu(\mathcal{S}) \quad (42)$$

从 (42) 减去 (41)，我们得到：

$$\mu(\{s_0\}) = \mu(\bar{\mathcal{S}}) - \mu(\mathcal{S}) = \mu(\{\perp\}) = R(\mathcal{X})$$

■

以下引理对于证明命题 2 至关重要：

引理 8. 如果 (P_F, P_B, Z) 满足关于 R 的轨迹平衡条件，那么对于任意 $n \in \{0, \dots, N\}$ ，和任意可测有界函数 $f : \mathcal{S} \rightarrow \mathbb{R}$ ：

$$Z \int_{\mathcal{S}} f(s) P_F^n(s_0, ds) P_F(s, \{\perp\}) = \int_{\mathcal{S}} f(s) P_B^n(s, \{s_0\}) R(ds) \quad (43)$$

证明 使用引理 6，我们有：

$$\begin{aligned} Z \int_{\mathcal{S}} f(s) P_F^n(s_0, ds) P_F(s, \{\perp\}) &= Z \int_{\bar{\mathcal{S}}^{n+1}} \mathbb{1}_{s \neq \perp} f(s) P_F(s, \{\perp\}) P_F^{\otimes n}(s_0, ds' ds_1 \dots ds_{n-1} ds) \\ &= Z \int_{\bar{\mathcal{S}}^{n+2}} \mathbb{1}_{s \neq \perp, s_{n+1} = \perp} f(s) P_F^{\otimes n+1}(s_0, ds' ds_1 \dots ds_{n-1} ds ds_{n+1}) \\ &= \int_{\bar{\mathcal{S}}^{n+2}} \mathbb{1}_{s \neq \perp} \mathbb{1}_{s''=s_0} f(s) R(ds) P_B^{\otimes n}(s, ds' ds_{n-1} \dots ds_1, ds'') \\ &= \int_{\bar{\mathcal{S}}} f(s) \mathbb{1}_{s \neq \perp} R(ds) \int_{\bar{\mathcal{S}}^{n+1}} \mathbb{1}_{s''=s_0} P_B^{\otimes n}(s, ds' ds_{n-1} \dots ds_1, ds'') \\ &= \int_{\bar{\mathcal{S}}} f(s) \mathbb{1}_{s \neq \perp} R(ds) \int_{\bar{\mathcal{S}}} \mathbb{1}_{s''=s_0} P_B^n(s, ds'') \\ &= \int_{\mathcal{S}} f(s) R(ds) P_B^n(s, \{s_0\}) \end{aligned}$$

命题 5 将引理 5 (Bengio 等人, 2021b) 推广到可测有向图, 并在证明命题 2 中至关重要。

命题 5。 设 P_B 为定义在 G 上的后向核函数。设 $P_{B,T}$ 为由下式定义的测度:

$$P_{B,T}(s) = \sum_{n=0}^{\infty} P_B^n(s, \{s_0\}) \quad (44)$$

We have $\forall s \in S$:

$$P_{B,T}(s) = 1 \quad (45)$$

证明 首先, 通过简单的递归, 我们证明对于所有 $n \geq N$, $P_B^n(s, \{s_0\}) = 0$ 成立。基本情况 ($n = N$) 显然满足, 因为可测有向图的最大轨迹长度为 N , 而 $P_B(s_0, -)$ 是平凡测度 (即它将零分配给每个可测集), 鉴于它是关于 $\kappa^B(s_0, -)$ 绝对连续的。假设对于某个 $n \geq N$ 成立, 则有:

$$P_B^{n+1}(s, s_0) = \int_{\bar{S}} P_B(s, ds') P_B^n(s', \{s_0\}) = \int_{\bar{S}} P_B(s, ds') \cdot 0 = 0$$

这表明对于每个 $s \in S$:

$$P_{B,T}(s) = \sum_{n=0}^{N-1} P_B^n(s, ds_0).$$

这说明测度 $P_{B,T}$ 是有限的。

接下来, 我们将 S 划分成 N 不相交的集合 $S_0, \dots, S_{N-1}$, 其中:

$$s \in S_n \Leftrightarrow n = \max\{m \in \mathbb{N}_0 : P_B^m(s, \{s_0\}) > 0\}$$

$S_n \in \Sigma$, 鉴于 $S_n = S'_n \setminus \bigcup_{k=0}^{\infty} S'_{n+k}$, 其中 S'_n 是 $P_B^n(-, \{s_0\})$ 的支持集, 已知这是一个闭集, 因此是可测的。

记为:

$$S = \bigcup_{n=0}^{N-1} S_n,$$

然后对于所有 $s \in S$ 证明 (45), 等同于对于所有 $s \in S_n$ 以及所有 $n \in \{0, \dots, N-1\}$ 证明它。我们通过强 n -归纳法来证明这一点。

Base case: For $n = 0$, $S_0 = \{s_0\}$, and

$$P_{B,T}(s_0) = P_B^0(s_0, \{s_0\}) = \delta_{s_0}(\{s_0\}) = 1,$$

因此当 $n = 0$ 时成立。

归纳步骤: 假设对于某个 $n \geq 0$, (45) 在所有 $s \in S_m$ 以及所有 $m \leq n$ 时成立, 并设 $s \in S_{n+1}$. 定义 $B_s = \{s' \in S : \forall B \in \mathcal{T}, s' \in B \Rightarrow P_B(s, B) > 0\}$ 。我们首先通过反证法证明 $B_s \subseteq \bigcup_{m=0}^n S_m$ 。如果存在 $s' \in B_s$ 并且 $n' > n$ 使得 $s' \in S_{n'}$, 那么 $P_B^{n'}(s', \{s_0\}) > 0$, 并且由于 $\tilde{s} \mapsto P_B^{n'}(\tilde{s}, \{s_0\})$ 的连续性, 存在一个开集 $\tilde{B}$ (i.e. $\tilde{B} \in \mathcal{T}$) 包含 s' 使得 $P_B^{n'}(\tilde{s}, \{s_0\}) > 0$ 对于所有 $\tilde{s} \in \tilde{B}$ 成立。因此:

$$P_B^{n'+1}(s, \{s_0\}) = \int_{\bar{S}} P_B(s, ds') P_B^{n'}(s', \{s_0\}) \geq \int_{\tilde{B}} P_B(s, ds') P_B^{n'}(s', \{s_0\}) > 0,$$

这将与 $s \in S_{n+1}$ 的事实相矛盾, 鉴于 $n' + 1 > n + 1$ 。

因此：

$$\begin{aligned}
 P_{B,T}(s) &= \sum_{m=0}^{n+1} P_B^m(s, \{s_0\}) = \sum_{m=1}^{n+1} P_B^m(s, \{s_0\}) \quad \text{given that } s \neq s_0 \\
 &= \sum_{m=1}^{n+1} \int_{s' \in B_s} P_B(s, ds') P_B^{m-1}(s', \{s_0\}) = \int_{s' \in B_s} P_B(s, ds') \underbrace{\sum_{m=0}^n P_B^m(s', \{s_0\})}_{=1} = \int_{s' \in B_s} P_B(s, ds') = 1
 \end{aligned}$$

■

附录 E 主文结果的证明

我们现在准备证明本文的主要定理，我们在这里重新陈述如下：

定理 1. 若 $F = (\mu, P_F)$ 是流经 G 并满足关于测度 R 的奖励匹配条件 (10)，则终止状态的测度：

$$P_T : B \in \Sigma_{|X} \mapsto \sum_{n=1}^{\infty} P_T^n(B) \quad (46)$$

是一个概率测度，并且对于所有 $B \in \Sigma_{|X}$ 满足：

$$P_T(B) = \frac{1}{R(X)} R(B) \quad (47)$$

证明 使用引理 2，终止状态测度 P_T 对于任何有界可测函数 $f : X \rightarrow \mathbb{R}$ 满足：

$$\int_X f(x) P_T(dx) = \int_X f(x) P_F(x, \perp) \sum_{n=0}^{\infty} P_F^n(s_0, dx).$$

根据命题 4 得出：

$$\mu(\{s_0\}) \int_X f(x) P_T(dx) = \int_X f(x) P_F(x, \perp) \mu(dx).$$

根据引理 7 以及对 R 的正性假设：

$$\int_X f(x) P_T(dx) = \frac{1}{R(X)} \int_X f(x) P_F(x, \perp) \mu(dx).$$

最后，利用 (1.0)，我们得到：

$$\int_X f(x) P_T(dx) = \frac{1}{R(X)} \int_X f(x) R(dx).$$

P_T 作为一个概率测度，通过将最后一个等式应用于函数 $f : x \mapsto 1$ 来得出。

■

接下来，我们将证明命题 1。

命题 1。 如果 (μ, P_F, P_B) 满足定义 5 中的细致平衡条件，则 $F = (\mu, P_F)$ 满足定义 3 中的流匹配条件，从而构成一个流。

证明 对于任意有界可测函数 $f : \bar{S} \rightarrow \mathbb{R}$ 满足 $f(s_0) = 0$ ，我们可以定义一个函数 $g : S \times \bar{S} \rightarrow \mathbb{R}$ ，使得对于所有 $(s, s') \in S \times \bar{S}$ ， $g(s, s') = f(s')$ 。注意到 g 满足 $g(s, s_0) = 0$ 对于每一个 $s \in S$ 。将细致平衡条件应用于函数 g ，我们得到

$$\int_{S \times \bar{S}} g(s, s') \mu(ds) P_F(s, ds') = \iint_{S \times \bar{S}} f(s') \mu(ds) P_F(s, ds')$$

另一方面，使用细致平衡条件中的 (12) 式右侧，我们得到 $\iint$

$$\int_{S \times \bar{S}} g(s, s') \mu(ds') P_B(s', ds) = \iint_{S \times \bar{S}} f(s') \mu(ds') P_B(s', ds) = \int_{\bar{S}} f(s') \mu(ds') \int_S P_B(s', ds),$$

根据公式 (2) 以及 P_B 相对于 κ^b 的绝对连续性条件，我们有：

$$\forall s' \in S, P_B(s', \{\perp\}) = 0,$$

由此得出：

$$\iint_{S \times \bar{S}} g(s, s') \mu(ds') P_B(s', ds) = \int_{\bar{S}} f(s') \mu(ds') \underbrace{\int_S P_B(s', ds)}_{=1}$$

这表明 (μ, P_F) 满足流匹配条件。 ■

接下来，我们将证明命题 2，这里重新陈述该命题：

命题 2。 如果 (Z, P_F, P_B) 满足关于测度 R 的轨迹平衡条件 (13)，那么 $F = (\mu, P_B)$ ，其中 μ 被定义为

$$(1) \mu(\{\perp\}) = \mu(\{s_0\}) = Z$$

$$(2) \forall B \in \Sigma_{\bar{S}}: \mu(B) = \mu(\{s_0\}) \sum_{n=0}^{\infty} P_F^n(s_0, B)$$

同时满足关于 R 的流匹配条件 (9) 和奖励匹配条件 (10)。

证明 首先我们证明 μ 满足流匹配条件。对于任何有界可测函数 $f : \bar{S} \rightarrow \mathbb{R}$ 满足 $f(s_0) = 0$ ，我们有： $\iint$

$$\begin{aligned} \int_{S \times \bar{S}} f(s') \mu(ds) P_F(s, ds') &= \iint_{S \times \bar{S}} f(s') \mu(s_0) \sum_{n=0}^{\infty} P_F^n(s_0, ds) P_F(s, ds') \\ &= \int_{\bar{S}} f(s') \mu(s_0) \sum_{n=0}^{\infty} P_F^{n+1}(s_0, ds') \\ &= \int_{\bar{S}} f(s') \mu(s_0) \sum_{n=0}^{\infty} P_F^n(s_0, ds') \quad (\text{because } f(s_0) = 0) \\ &= \int_{\bar{S}} f(s') \mu(ds') \end{aligned}$$

现在，我们将展示奖励匹配条件。对于任何有界可测函数 $f : X \rightarrow \mathbb{R}$

$$\begin{aligned} \int_X f(s) \mu(ds) P_F(s, \perp) &= \int_S \mathbb{1}_X(s) f(s) \underbrace{\mu(\{s_0\})}_{=Z} \sum_{n=0}^{\infty} P_F^n(s_0, ds) P_F(s, \perp) \\ &= \sum_{n=0}^{\infty} \int_S \mathbb{1}_X(s) f(s) R(ds) P_B^n(s, \{s_0\}) \\ &= \int_S \mathbb{1}_X(s) f(s) R(ds) \sum_{n=0}^{\infty} P_B^n(s, \{s_0\}) = \int_X f(s) R(ds) \end{aligned}$$

其中我们使用了命题 5 和引理 8。 ■

以下是定理 2 的证明，我们在这里重新陈述该定理：

定理 2. (1) 如果 $\int L_{FM}(-; \theta) = 0$ ν 几乎处处成立, 则 $F = (\mu, P_F)$ 是一个流 (即满足定义 3 中的流匹配条件)。(2) 如果 $\int L_{DB}(-; \theta) = 0$ $\nu \otimes \kappa$ 几乎处处成立, 则 (μ, P_F, P_B) 满足定义 5 中的细致平衡条件。(3) 如果 $\int L_{RM}(-; \theta) = 0$ $\nu|_{\mathcal{X}}$ 几乎处处成立, 则 (μ, P_F) 满足 (10) 中的奖励匹配条件。(4) 如果 $\int L_{TB}^n(-; \theta) = 0$ $((\nu \otimes \kappa^{\otimes n+1})|_{\{s_0\} \times S^n \times \{\perp\}})$ 几乎处处成立对每个 $n \geq 0$ 成立, 则 $(Z\nu(\{s_0\}), P_F, P_B)$ 满足定义 6 中的轨迹平衡条件。

证明 我们首先展示流匹配损失的结果。设函数 $v: \bar{S} \rightarrow \mathbb{R}_+$ 是依赖于参数 θ 定义的函数, 定义为 $\forall s' \in \bar{S}$:

$$v(s'; \theta) := \int_S u(s; \theta) p_F(s, s'; \theta) \kappa^b(s', ds).$$

如果假设 $\int L_{FM}(-; \theta) = 0$ ν 几乎处处成立, 那么我们有等价地 $u(-; \theta) = v(-; \theta)$ ν 几乎处处成立。设 $f: \bar{S} \rightarrow \mathbb{R}$ 是一个有界的可测函数, 使得 $f(s_0) = 0$, 则我们有 $\int$

$$\begin{aligned} \int_{\bar{S}} f(s') u(s'; \theta) \nu(ds') &= \int_{\bar{S}} f(s') v(s'; \theta) \nu(ds') \\ &= \int_{\bar{S}} f(s') \int_S u(s; \theta) p_F(s, s'; \theta) \kappa^b(s', ds) \nu(ds') \\ &= \iint_{S \times \bar{S}} f(s') u(s; \theta) p_F(s, s'; \theta) \kappa(s, ds') \nu(ds), \end{aligned}$$

其中我们使用了事实 $\nu \otimes \kappa = \nu \otimes \kappa^b$ (来自定义 1 中的 (4))。将上述等式中的密度 (和参考测度) 替换为其相应的测度 μ 和 P_F , 我们得到

$$\int_{\bar{S}} f(s') \mu(ds') = \iint_{S \times \bar{S}} f(s') \mu(ds) P_F(s, ds').$$

由于这个等式对任何满足 $f(s_0) = 0$ 的有界可测函数 f 都成立, 这就是定义了满足流匹配条件 (定义 3) 的 $F = (\mu, P_F)$ 。详细平衡损失的证明类似。设函数 $g: \bar{S} \times \bar{S} \rightarrow \mathbb{R}_+$ 和 $h: \bar{S} \times \bar{S} \rightarrow \mathbb{R}_+$ 定义为

$$\begin{aligned} g(s, s'; \theta) &:= u(s; \theta) p_F(s, s'; \theta) \\ h(s, s'; \theta) &:= u(s'; \theta) p_B(s', s; \theta). \end{aligned}$$

如果 $\int L_{DB}(-; \theta) = 0$ $\nu \otimes \kappa$ 几乎处处成立, 那么我们有等价地 $g(-; \theta) = h(-, \theta)$ 。设 $f: S \times \bar{S} \rightarrow \mathbb{R}$ 是一个有界的可测函数, 使得 $f(s, s_0) = 0$ 对于所有 $s \in S$ 成立。我们有 $\iint$

$$\begin{aligned} \iint_{S \times \bar{S}} f(s, s') g(s, s'; \theta) (\nu \otimes \kappa)(ds, ds') &= \iint_{S \times \bar{S}} f(s, s') u(s; \theta) p_F(s, s'; \theta) (\nu \otimes \kappa)(ds, ds') \\ &= \iint_{S \times \bar{S}} f(s, s') h(s, s'; \theta) (\nu \otimes \kappa)(ds, ds') \\ &= \iint_{S \times \bar{S}} f(s, s') h(s, s'; \theta) (\nu \otimes \kappa^b)(ds', ds) \\ &= \iint_{S \times \bar{S}} f(s, s') u(s'; \theta) p_B(s', s; \theta) (\nu \otimes \kappa^b)(ds', ds), \end{aligned}$$

其中我们在第三个不等式中使用了 $\nu \otimes \kappa = \nu \otimes \kappa^b$ 。请注意, 虽然函数之间的等式在空间 $\bar{S} \times \bar{S}$ 上几乎处处成立 $\nu \otimes \kappa$, 但我们仅使用了限制在 $S \times \bar{S}$ 上的等式。此外, 由于 u, p_F 和 p_B 分别是相应测度 μ, P_F 和 P_B (相对于适当的参考测度) 的密度, 我们知道对于 $B \in \bar{\Sigma} \otimes \bar{\Sigma} \otimes \bar{\Sigma}$

$$\begin{aligned} (\mu \otimes P_F)(B) &= \iint_B u(s; \theta) p_F(s, ds') (\nu \otimes \kappa)(ds, ds') \\ (\mu \otimes P_B)(B) &= \iint_B u(s'; \theta) p_B(s', ds) (\nu \otimes \kappa^b)(ds', ds). \end{aligned}$$

将这些测度替换到上述等式中，我们得到 $\iint$

$$\int_{S \times \bar{S}} f(s, s') \mu(ds) P_F(s, ds') = \iint_{S \times \bar{S}} f(s, s') \mu(ds') P_B(s', ds).$$

由于此等式对任何有界可测函数 f 均成立，满足 $f(s, s_0) = 0$ 对于所有 $s \in S$ ，这对应于 (μ, P_F, P_B) 满足细致平衡条件（定义 5）。现在，对于轨迹平衡损失：对于轨迹 $(s, s_1, \dots, s_{n+1}) \in S_{n+2}$ ，我们定义：

$$p_F^{\otimes n+1}(s, \overrightarrow{s_{1:n+1}}) = p_F(s, s_1, \theta) \prod_{t=1}^n p_F(s_t, s_{t+1}, \theta)$$

$$p_B^{\otimes n}(\overrightarrow{s_{n:1}}, s) = p_B(s_1, s, \theta) \prod_{t=1}^{n-1} p_B(s_{t+1}, s_t, \theta)$$

对于任何有界可测函数 $f : \bar{S}^{n+2} \rightarrow \mathbb{R}$ ，假设 $L_{TB}^n = 0$ 几乎处处成立，对于每个 $n \geq 0$ ：

$$\begin{aligned} & \int_{S_{n+2}} Z(\theta) f(s, \overrightarrow{s_{1:n+1}}) \mathbb{1}_{s=s_0, s_n \neq \perp, s_{n+1}=\perp} p_F^{\otimes n+1}(s, \overrightarrow{s_{1:n+1}}) \nu \otimes \kappa^{\otimes n+1}(ds \overrightarrow{ds_{1:n+1}}) \\ &= \int_{\{s_0\} \times S^{n-1} \times \mathcal{X} \times \{\perp\}} Z(\theta) f(s, \overrightarrow{s_{1:n+1}}) p_F^{\otimes n+1}(s, \overrightarrow{s_{1:n+1}}) \nu \otimes \kappa^{\otimes n+1}(ds \overrightarrow{ds_{1:n+1}}) \\ &= \int_{\{s_0\} \times S^n \times \{\perp\}} f(s, \overrightarrow{s_{1:n+1}}) r(s_n) p_B^{\otimes n}(\overrightarrow{s_{n:1}}, s) \nu \otimes \kappa^{\otimes n+1}(ds \overrightarrow{ds_{1:n+1}}) \\ &= \int_{\{s_0\} \times S^n} f(s, \overrightarrow{s_{1:n}}, \perp) r(s_n) \underbrace{\kappa(s_n, \{\perp\})}_{=1 \text{ (see (6))}} p_B^{\otimes n}(\overrightarrow{s_{n:1}}, s) \nu \otimes \kappa^{\otimes n}(ds \overrightarrow{ds_{1:n}}) \\ &= \int_{\{s_0\} \times S^n} f(s, \overrightarrow{s_{1:n}}, \perp) r(s_n) p_B^{\otimes n}(\overrightarrow{s_{n:1}}, s) \nu \otimes \kappa^{b, \otimes n}(\overrightarrow{ds_{n:1}} ds) \\ &= \int_{S_{n+1}} f(s, \overrightarrow{s_{1:n}}, \perp) \mathbb{1}_{s=s_0} r(s_n) \nu(ds_n) p_B^{\otimes n}(\overrightarrow{s_{n:1}}, s) \kappa^{b, \otimes n}(s_n, \overrightarrow{ds_{n-1:1}} ds) \end{aligned}$$

将最后一等式中的测度替换后，我们恢复了定义 6 中的 TB 条件，即 $(Z_V(\{s_0\}), P_F, P_B)$ 。这里我们使用了 $\nu \otimes \kappa^{\otimes n} = \nu \otimes \kappa^{b, \otimes n}$, $\forall n \in \{0, \dots, N\}$ 。我们可以通过简单的归纳法证明这一点：对于 $n = 0$ ，它是显然成立的。现在假设对于给定的 $n \leq N - 1$ 它成立，使用 (4)。我们有：

$$\begin{aligned} \nu \otimes \kappa^{\otimes n+1}(ds \overrightarrow{ds_{1:n+1}}) &= \nu \otimes \kappa^{\otimes n}(ds \overrightarrow{ds_{1:n}}) \kappa(s_n, ds_{n+1}) = \nu \otimes \kappa^{b, \otimes n}(\overrightarrow{ds_{n:1}} ds) \kappa(s_n, ds_{n+1}) \\ &= \nu(ds_n) \kappa(s_n, ds_{n+1}) \kappa^{b, \otimes n}(s_n, \overrightarrow{ds_{n:1}} ds) = \nu(ds_{n+1}) \kappa^b(s_{n+1}, ds_n) \kappa^{b, \otimes n}(s_n, \overrightarrow{ds_{n:1}} ds) \\ &= \nu(ds_{n+1}) \kappa^{b, \otimes n+1}(s_{n+1}, \overrightarrow{ds_{n:1}} ds) = \nu \otimes \kappa^{b, \otimes n+1}(\overrightarrow{ds_{n+1:1}} ds) \end{aligned}$$

这证明了上述断言。 ■

附录 F 引理和命题的证明在 § A

引理 1。

证明 我们通过数学归纳法证明该引理 n 。基础情形（ $n = 1$ ）显然成立。假设对于某个 $n \geq 0$ ，令 $s \in \bar{S}$ 且 $B \in \Sigma$ ，使得 $\kappa^{n+1}(s, B) = 0$ 。

$$P_F^{n+1}(s, B) = \int_{\bar{S}} P_F^n(s, ds') P_F(s', B).$$

如果 $P_F^{n+1}(s, B) > 0$ ，这意味着存在一个开集 $B' \in \mathcal{T}$ 使得 $P_F^n(s, B') > 0$ 并且 $P_F(s', B) > 0$ 对于所有 $s' \in B'$ 。根据归纳假设，可以得出 $\kappa^n(s, B') > 0$ 并且 $\kappa(s', B) > 0$ 对于所有 $s' \in B'$ ，这意味着：

$$\kappa^{n+1}(s, B) = \int_{\bar{S}} \kappa^n(s, ds') \kappa(s', B) \geq \int_{B'} \kappa^n(s, ds') \kappa(s', B) > 0.$$

矛盾！因此， $P_F^{n+1}(s, B) = 0$ ■

引理 2。

证明 从定义出发 $P^n \uparrow$ ：

$$\int_X f(x) P_{\uparrow}^n(dx) = \int_{\bar{S}} f(s_n) \mathbb{1}_X(s_n) P_{\uparrow}^n(dx) = \int_{\bar{S}^{n+1}} \mathbb{1}_X(s_n) f(s_n) P_F^{\otimes n}(s_0, ds_1 \dots ds_{n+1}) \mathbb{1}_{s_{n+1}=\perp}$$

Hence, 利用递归定义 (26) of $P_F^{\otimes n}$ 可知，

$$\begin{aligned} \int_X f(x) P_{\uparrow}^n(dx) &= \int_{\bar{S}^{n+1}} \mathbb{1}_X(s_n) f(s_n) P_F^{\otimes n-1}(s_0, ds_1 \dots ds_n) P_F(s_n, ds_{n+1}) \mathbb{1}_{s_{n+1}=\perp} \\ &= \int_{\bar{S}^n} \underbrace{\mathbb{1}_X(s_n) f(s_n) P_F(s_n, \{\perp\})}_{g(s_n)} P_F^{\otimes n-1}(s_0, ds_1 \dots ds_n) \\ &= \int_{\bar{S}^n} g(s_n) P_F^{\otimes n-1}(s_0, ds_1 \dots ds_n) \\ &= \int_{\bar{S}} g(s_n) P_F^{n-1}(s_0, ds_n) = \int_X f(x) P_F(x, \{\perp\}) P_F^{n-1}(s_0, ds_n), \end{aligned}$$

其中应用了关于有界可测函数 g 的引理 6。 ■

引理 3。

证明 设 $f : \bar{S}^2 \rightarrow \mathbb{R}$ 是一个有界可测函数。

$$\begin{aligned} \int_{\bar{S}^2} f(s, s') \nu \kappa(ds') \kappa'(s', ds) &= \int_{\bar{S}} f(s, s_0) \underbrace{\nu \kappa(\{s_0\})}_{=0} \kappa'(s_0, ds) + \int_S \int_{\bar{S} \setminus \{s_0\}} f(s, s') \nu \kappa(ds') \kappa'(s', ds) \\ &\quad + \int_{S \setminus \{s_0\}} f(\perp, s') \nu \kappa(ds') \underbrace{\kappa'(s', \{\perp\})}_{=0} + f(\perp, \perp) \nu \kappa(\{\perp\}) \kappa'(\perp, \{\perp\}) \\ &= \int_S \int_{\bar{S} \setminus \{s_0\}} f(s, s') \nu \kappa(ds') \kappa^b(s', ds) + \int_{\bar{S}} f(s, s_0) \underbrace{\nu \kappa(\{s_0\})}_{=0} \kappa^b(s_0, ds) \\ &\quad + f(\perp, \perp) \nu \kappa(\{\perp\}) \kappa^b(\perp, \{\perp\}) \end{aligned} \tag{48}$$

另一方面，令 B 为集合 S 内的最大开集，使得 $\forall s' \in B, \kappa^b(s', \{\perp\}) > 0$ 。将反核函数的定义 (26) 应用于函数 $f : (s, s') \mapsto \mathbb{1}_{s=\perp} \mathbb{1}_B(s')$ ，我们得到：

$$\int_{\bar{S}} \mathbb{1}_B(s') \nu(\{\perp\}) \kappa(\perp, s') = \int_{\bar{S}} \mathbb{1}_B(s') \nu \kappa(s') \kappa^b(s', \{\perp\})$$

上一等式的左侧为 0，根据 (2) 可知。由此假设 $\forall s' \in B, \kappa^b(s', \{\perp\}) > 0$ 得出：

$\nu\kappa(B) = 0$. Hence:

$$\begin{aligned} & \int_{S \setminus \{s_0\}} f(\perp, s') \nu\kappa(ds') \kappa^b(s', \{\perp\}) \\ &= \int_{\bar{S} \setminus \{s_0\}} \mathbb{1}_{S \setminus B}(s') f(\perp, s') \nu\kappa(ds') \kappa^b(s', \{\perp\}) \\ &+ \int_{\bar{S} \setminus \{s_0\}} \mathbb{1}_B(s') f(\perp, s') \nu\kappa(ds') \kappa^b(s', \{\perp\}) \end{aligned}$$

最后一个等式右侧的第一项根据 B 的定义为零。第二项为零因为。回到 (48)，我们得到：
 $\nu\kappa(B) = 0$

$$\int_{\bar{S}^2} f(s, s') \nu\kappa(ds') \kappa'(s', ds) = \int_{\bar{S}^2} f(s, s') \nu\kappa(ds') \kappa^b(s', ds) = \int_{\bar{S}^2} f(s, s') \kappa(ds) \kappa(s, ds')$$

命题 3。

证明 首先注意到 (2) 和 (7) 意味着 $\forall n \geq N, \kappa^n(s_0, -) = \delta_\perp$ 。这可以通过对 n 进行简单的归纳证明，对于任意的 $B \in \Sigma$ ：

$$\kappa^{n+1}(s_0, B) = \int_{\bar{S}} \kappa^n(s_0, ds) \kappa(ds, B).$$

这意味着 (1) 可以重写为：

$$\forall B \in \mathcal{T} \setminus \{\emptyset\}, \exists n \in \{0, \dots, N\} : \kappa^n(s_0, B) > 0.$$

因此，

$$\forall B \in \mathcal{T} \setminus \{\emptyset\}, \nu(B) > 0.$$

测度 ν 因此严格为正。

请注意，对于 $\Sigma|S$ 中的任何 B ，使得 $s_0 \notin B$ 。

$$\begin{aligned} \nu\kappa(B) &= \int_{\bar{S}} \nu(ds) \kappa(s, B) \\ &= \int_{\bar{S}} \sum_{n=0}^N \kappa^n(s_0, ds) \kappa(s, B) = \sum_{n=0}^N \int_{\bar{S}} \kappa^n(s_0, ds) \kappa(s, B) \\ &= \sum_{n=0}^N \kappa^{n+1}(s_0, B) = \sum_{n=1}^{N+1} \kappa^n(s_0, B). \end{aligned}$$

Because $B \subseteq S$, then $\kappa^{N+1}(s_0, B) = \delta_\perp(B) = 0$. And because $s_0 \notin B$, $\kappa^0(s_0, B) = \delta_{s_0}(B) = 0$. From this it follows that:

$$\nu\kappa(B) = \nu(B)$$

然后, 令 $B \in \Sigma_{|S} \otimes \Sigma_{|S}$, 使得 $(s_0, s_0) \notin B$ 。利用反向核函数的定义, 我们得到:

$$\begin{aligned}
 \nu \otimes \kappa(B) &= (\nu \kappa) \otimes \kappa_\nu^r(B) = \int_{\bar{S} \times \bar{S}} \mathbb{1}_B(s, s') \nu \kappa(ds') \kappa_\nu^r(ds', ds) \\
 &= \int_{S \times (S \setminus \{s_0\})} \mathbb{1}_B(s, s') \underbrace{\nu \kappa(ds')}_{=\nu(ds')} \kappa_\nu^r(ds', ds) + \int_S \mathbb{1}_B(s, s_0) \underbrace{\nu \kappa(s_0)}_{=0} \kappa_\nu^r(s_0, ds) \\
 &= \int_{S \times (S \setminus \{s_0\})} \mathbb{1}_B(s, s') \nu(ds') \kappa_\nu^r(ds', ds) \\
 &= \int_{S \times (S \setminus \{s_0\})} \mathbb{1}_B(s, s') \nu(ds') \kappa_\nu^r(ds', ds) + \int_{S \setminus \{s_0\}} \mathbb{1}_B(s, s_0) \kappa(s_0) \underbrace{\kappa_\nu^r(s_0, ds)}_{=0} \\
 &= \int_{\bar{S} \times \bar{S}} \mathbb{1}_B(s, s') \nu(ds') \kappa_\nu^r(ds', ds) \\
 &= \nu \otimes \kappa_\nu^r(B)
 \end{aligned}$$

Finally, if $B \in \Sigma_{|S}$:

$$\begin{aligned}
 \nu \otimes \kappa(B \times \{\perp\}) &= \int_S \mathbb{1}_B(ds) \nu(ds) \kappa(s, \{\perp\}) = \int_S \mathbb{1}_B(ds) \nu(\{\perp\}) \kappa^b(\perp, ds) = \nu \otimes \kappa^b(B \times \{\perp\}) \\
 \nu \otimes \kappa(\{\perp\} \times B) &= \underbrace{\nu(\{\perp\})}_{=0} \kappa(\perp, B) = \int_S \mathbb{1}_B(s') \nu(ds') \underbrace{\kappa^b(s', \{\perp\})}_{=0} = \nu \otimes \kappa^b(\{\perp\} \times B)
 \end{aligned}$$

■