

离散概率推理作为多路径环境中的控制问题

Tristan Deleu^{1,3}

Padideh Nouri²

Nikolay Malkin¹

Doina Precup^{2,4}

Yoshua Bengio¹

Mila – Quebec AI Institute

¹Université de Montréal ²McGill University ³Valence Labs ⁴Google DeepMind

摘要

我们将从离散和结构化的分布中采样的问题视为一个顺序决策问题，目标是找到一种随机策略，使得在这一顺序过程结束时，对象被采样的比例与某个预定义的奖励成正比。虽然我们可以使用最大熵强化学习（MaxEnt RL）来解决某些分布的问题，但已经证明，在存在多种生成同一对象的方式的情况下，最优策略所诱导的状态分布可能会产生偏差。为了解决这个问题，生成流网络（GFlowNets）通过在整个马尔可夫决策过程（MDP）中近似强制执行流的守恒来学习一种随机策略，该策略按对象的奖励比例进行采样。在这篇论文中，我们扩展了最近用于修正奖励的方法，以确保由最优 MaxEnt RL 策略诱导的边缘分布与原始奖励成正比，无论底层 MDP 的结构如何。我们还证明，GFlowNet 文献中发现的一些流匹配目标实际上等同于具有修正奖励的成熟的 MaxEnt RL 算法。最后，我们实证研究了多个 MaxEnt RL 和 GFlowNet 算法在涉及从离散分布中采样的多个问题上的性能。

与深度神经网络相结合。这一点在连续样本空间中尤为明显，在那里可以通过梯度方法最大化证据下界（ELBO），这得益于路径梯度估计等方法 [Kingma 和 Welling, 2014, Rezende 等人, 2014, Rezende 和 Mohamed, 2015]。然而，在离散和高度结构化的样本空间中，这种“重新参数化技巧”变得更加具有挑战性，因为它通常需要离散分布的连续松弛 [Jang 等人, 2017, Maddison 等人, 2017, Mena 等人, 2018]。在这种情况下，由于得分函数估计 [威廉斯, 1992]，变分推断可以更普遍地进行，尽管代价是高方差 [Mohamed 等人, 2020]。近似推断的另一种方法是通过基于马尔可夫链蒙特卡洛 (MCMC) 的采样方法 [Hastings, 1970, Gelfand 和 Smith, 1990]，当目标分布定义到一个难以处理的归一化常数时。

Bengio 等人 [2021] 提出了一类新的概率模型，称为生成流网络（GFlowNets），从变分视角出发来逼近离散和结构化样本空间上的未归一化目标分布 [Malkin 等人, 2023, Zimmermann 等人, 2022]。GFlowNets 将采样视为一个顺序决策问题，深受强化学习（RL）文献的启发。然而，与寻求最大化累积奖励的最优策略的 RL 不同，GFlowNets 的目标是找到一种策略，使得对象能够按其累积奖励的比例被采样。尽管如此，这种关系导致了来自 RL 文献的最佳实践被转移到 GFlowNets 中，例如使用回放缓冲区 [Shen 等人, 2023, Vemgal 等人, 2023] 和目标网络 [Deleu 等人, 2022]，以及先进的探索策略 [Rector-Brooks 等人, 2023]。

1 引言

近似概率推理取得了巨大的进展，特别是在变分视角方面

尽管 Bengio 等人 [2021] 证明了在某些特定情况下 GFlowNets 与最大熵强化学习（MaxEnt RL；Ziebart, 2010）完全等价，我们将在第 2 节回顾这些情况，但长期以来人们认为这种联系在一般情况下只是表面上的。然而最近，Tiapkin 等人

通信作者：Tristan Deleu <deleutri@mila.quebec> 代码：
<https://github.com/tristandeleu/gfn-maxent-rl>

[2024] 表明, GFlowNets 和最大熵强化学习 (MaxEnt RL) 实际上是相同的, 只需对奖励函数进行修正。这一发现, 连同近期其他研究 [Mohammadpour 等人, 2024, Niu 等人, 2024], 揭示了 GFlowNets 和最大熵强化学习算法之间更深层次的关系。在本研究中, 我们将这种奖励修正扩展到一个更一般的情况, 并建立了 GFlowNet 与最大熵强化学习目标之间的新等价关系, 特别是广泛使用的轨迹平衡损失 (Trajectory Balance loss) [Malkin 等人, 2022] 和最大熵强化学习中的路径一致性学习算法 (Path Consistency Learning) [Nachum 等人, 2017] 之间的等价性。我们还引入了一种依赖于策略的软 Q 学习算法 (Soft Q-Learning) [Haarnoja 等人, 2017] 的变体, 并证明它与 Deleu 等人的修改后的详细平衡损失 (Modified Detailed Balance loss) 等价 [2022]。最后, 我们在三个不同的领域中通过实证展示了这些行为上的相似性, 并将流行的软演员-评论家算法 (SAC; Haarnoja 等人, 2018a) 纳入我们的评估中, 该算法没有现有的 GFlowNet 对应版本, 在相同条件下进行了比较。

2 边缘采样方法 顺序决策制定

给定一个能量函数 $\mathcal{E}(x)$ 定义在一个离散且有限的样本空间上 $\mathcal{X}$, 我们的目标是从 Gibbs 分布中采样对象 $x \in \mathcal{X}$:

$$P(x) \propto \exp(-\mathcal{E}(x)/\alpha), \quad (1)$$

哪里 $\alpha > 0$ 是一个温度参数。我们假设这个能量函数是固定的, 并且我们可以查询该函数以获取任何元素的值 $\mathcal{E}(x)$ 。从这个分布中采样通常是一个具有挑战性的问题, 因为存在配分函数 $Z = \sum_{x \in \mathcal{X}} \exp(-\mathcal{E}(x)/\alpha)$ 作为归一化常数 P , 当样本空间 (组合上) 较大时, 这是不可计算的。本文将重点关注具有某种组合结构的对象 (例如, 图或树), 这意味着它们可以逐部分构建。

2.1 最大熵强化学习

学习

我们考虑一个有限时间范围的马尔可夫决策过程 (MDP) $\mathcal{M}_{\text{soft}} = (\mathcal{S}, \mathcal{A}, s_0, T, r)$, 其中状态空间 $\mathcal{S}$ 和动作空间 $\mathcal{A}$ 都是离散且有限的。假设该 MDP 是确定性的, 其转移函数 $T: \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{S}$ 决定了如何根据动作 a 从当前状态 s 转移到新状态 $s' = T(s, a)$ 。我们识别出一个初始状态 $s_0 \in \mathcal{S}$, 所有轨迹均从此状态开始。此外, 由于我们在有限时间范围内, 所有这些轨迹都是有限的, 并且假设它们最终会结束于一个抽象的终止状态 $s_f \notin \mathcal{S}$, 该状态充当“汇”状态; 我们使用符号 $\bar{\mathcal{S}} = \mathcal{S} \cup \{s_f\}$ 表示这一概念。

状态空间被定义为样本空间的超集 $\mathcal{X} \subseteq \mathcal{S}$, 其结构方式为: $x \in \mathcal{X}$ 当且仅当我们可以从状态 x 过渡到终止状态 s_f (i.e. 时, 存在一个动作 $a \in \mathcal{A}$ 使得 $T(x, a) = s_f$; 这些状态 $x \in \mathcal{X}$ 被称为终止状态, 遵循 Bengio 等人 [2023] 的命名惯例。在整个论文中, 我们将折扣因子设置为 $\gamma = 1$ 。这种具有已知确定性动态的设定在强化学习文献中已有广泛研究 [Todorov, 2006, Kappen 等, 2012]。

由于马尔可夫决策过程 (MDP) 是确定性的, 我们可以将导致状态 $s' = T(s, a)$ 的动作 a 与状态空间中的转移 $s \rightarrow s'$ 相对应。因此, 我们将所有涉及状态-动作对 (s, a) 的量表示为 (s, s') 的形式。奖励函数 $r(s, s')$ 定义为沿着完整轨迹 (回报) 的奖励之和仅取决于终止状态的能量: 对于轨迹 $\tau = (s_0, s_1, \dots, s_T, s_f)$, 我们有

$$\sum_{t=0}^T r(s_t, s_{t+1}) = -\mathcal{E}(s_T), \quad (2)$$

按照惯例 $s_{T+1} = s_f$ 。特别是, 这涵盖了仅在轨迹结束时收到稀疏奖励的情况 (i.e., $r(s_T, s_f) = -\mathcal{E}(s_T)$, 其余地方为零)。这种能量分解为中间奖励的方式类似于 Buesing 等人的做法 [2020]。

虽然强化学习的目标通常是找到一个策略 $\pi(s_{t+1} | s_t)$, 使其期望奖励总和最大化 (这里对应于找到具有最低能量的状态 $x \in \mathcal{X}$, 或者等价地说, 在 (1) 式中找到模式 F), 但在最大熵强化学习 (MaxEnt RL) 中, 我们还寻找一个策略, 使其期望奖励总和最大化, 但这次是与策略的熵相加

$\mathcal{H}(\pi(\cdot | s))$

π 在状态 s :

$$\pi_{\text{MaxEnt}}^* = \arg \max_{\pi} \mathbb{E}_{\tau} \left[\sum_{t=0}^T r(s_t, s_{t+1}) + \alpha \mathcal{H}(\pi(\cdot | s_t)) \right], \quad (3)$$

其中期望是在根据策略 π 采样的完整轨迹 τ 上取的。直观地说, 将熵添加到目标中鼓励最优策略的随机性并提高多样性。为了突出与标准 RL 目标的区别, 我们将 $\mathcal{M}_{\text{soft}}$ 称为软 MDP, 遵循 Ziebart 的命名法 [2010]。

符号约定。在下文中, 将方便地将软 MDP 中的转换视为一个有向无环图 (DAG) $\mathcal{G}$, 该图覆盖状态 $\bar{\mathcal{S}}$ (包括 s_f), 根节点在 s_0 ; 图是无环的, 以确保 $\mathcal{M}_{\text{soft}}$ 是有限时间的。我们将使用符号 $\text{Pa}(s)$ 和 $\text{Ch}(s)$ 分别表示状态 s 在 $\mathcal{G}$ 中的父节点和子节点。对于任何终止状态 $x \in \mathcal{X}$, $s_0 \rightsquigarrow x$ 表示在 $\mathcal{G}$ 中的形式为 $\tau = (s_0, s_1, \dots, x, s_f)$ 的完整轨迹; 该轨迹

到达终止状态在记号中是隐含的，尽管在我们的定义中是必要的。

2.2 从 A 中采样终止状态

软 MDP

根据控制作为推理的文献 [Ziebart 等, 2008, Levine, 2018], 可以证明最大化 (3) 中的 MaxEnt RL 目标的策略会在动态一致的轨迹上诱导出一个分布 $\tau = (s_0, s_1, \dots, s_T, s_f)$ ，该分布依赖于轨迹上的奖励之和：

$$\pi^*(\tau) \triangleq \prod_{t=0}^T \pi_{\text{MaxEnt}}^*(s_{t+1} | s_t) \propto \exp\left(\frac{1}{\alpha} \sum_{t=0}^T r(s_t, s_{t+1})\right). \quad (4)$$

通过我们在公式 (2) 中选择的奖励函数，这表明了一种简单的策略，可以从公式 (1) 中的吉布斯分布进行采样，一旦确定了最优策略 π_{MaxEnt}^* 已知：采样一条轨迹 $\mathcal{M}_{\text{soft}}$ ，从初始状态开始 s_0 并遵循最优策略，仅返回终止状态 s_T 在结束时达到 τ (忽略终止状态 s_f)。然而，一般来说，我们感兴趣的是采样一个对象 $x \in \mathcal{X}$ (终止状态) 使用这一顺序过程，但不涉及该对象是如何生成的 (确切的轨迹)。因此，感兴趣的分布不是像公式 (4) 那样的轨迹分布，而是终止状态的边缘分布：

$$\pi^*(x) \triangleq \sum_{\tau: s_0 \rightsquigarrow x} \pi^*(\tau). \quad (5)$$

$\pi^*(x)$ 被称为与策略相关的终止状态分布 π_{MaxEnt}^* [Bengio 等人, 2023]。当软 MDP 的状态转换图 $\mathcal{G}$ 是一棵以 s_0 为根的树，并且存在一条唯一的完整轨迹 $s_0 \rightsquigarrow x$ 通向任何 $x \in \mathcal{X}$ ，那么这个过程保证等价于从 Gibbs 分布中采样 [Bengio 等人, 2021]。树结构 MDP 的例子包括自回归序列生成 [Bachman 和 Precup, 2015, Weber 等人, 2015, Angermueller 等人, 2020, Jain 等人, 2022, Feng 等人, 2022]，以及从具有固定随机变量顺序的离散因子图中采样 [Buesing 等人, 2020]。

控制与推理 (从 (1) 中采样) 之间的等价性在 $\mathcal{G}$ 为一般有向无环图时不再成立。如图 1 所示，考虑 You 等人 [2018] 中描述的问题，即通过依次添加片段来生成小分子。即使遵循最优策略，尽管轨迹上的分布与 $\exp(-\mathcal{E}(x))$ 成比例，如 (4) 所示，其边缘分布除了终止状态 s_f 外，其父节点始终是 $\mathcal{X}$ 中的所有终止状态。




图 1: 展示了与 π_{MaxEnt}^* 相关的终止状态分布偏差在具有 DAG 结构的软 MDP 上的示意图。MDP 中每条转移上的标签对应于奖励函数，满足 (2) (稀疏奖励设置)。终止状态分布 $\pi^*(x)$ 通过轨迹边缘化 $\pi^*(\tau)$ 计算得出，这些轨迹导向 x (e.g., 基于 (4) 计算两条轨迹 $s_0 \rightarrow s_1 \rightarrow x_4$ 和 $s_0 \rightarrow s_2 \rightarrow x_4$ 到 x_4)。假设 $\alpha = 1$ 。终止状态分布 $\pi^*(x)$ 应与目标 Gibbs 分布 $P(x) \propto \exp(-\mathcal{E}(x))$ 进行对比。归一化常数是 $Z' = \exp(-\mathcal{E}(x_3)) + 2 \exp(-\mathcal{E}(x_4)) + \exp(-\mathcal{E}(x_5))$ 。此 MDP 受到 Jain 等人 [2023a] 的启发。

关于终止状态的偏差是因为有两个轨迹可以导向相同的分子 x_4 (i.e., 并且可以按多种顺序添加片段。这种偏差最早由 Bengio 等人指出 [2021]。

2.3 生成流网络

为解决最大熵强化学习中目标吉布斯分布 (1) 与最优策略诱导的终止状态分布 (5) 之间的不匹配问题，Bengio 等人 [2021] 引入了一种新的概率模型类别，称为生成流网络 (Generative Flow Networks; Bengio 等, 2023)，该模型适用于离散和组合对象。与寻找最大化 (3) 的策略不同，GFlowNet 的目标是找到一个在 $\mathcal{G}$ 的边上的流函数

$F(s \rightarrow s')$ ，该函数满足对于所有状态 $s' \in S$ 的以下流匹配条件，使得 $s' \neq s_0$:

$$F(s \rightarrow s') = \sum_{s'' \in \text{Ch}(s')} F(s' \rightarrow s''), \quad (6)$$

对于每个终止条件增加一个额外的边界条件 state $x \in \mathcal{X}$: $F(x \rightarrow s_f) = \exp(-\mathcal{E}(x)/\alpha)$ 将其放入

词语，(6) 表示流入任意状态 s' 的总流量必须等于从该状态流出的流量，除了初始状态 s_0 作为所有流量的单一“源”。我们可以简单地通过规范化从任意状态 s_t 流出的流量来定义策略 2 ：

$$P_F(s_{t+1} | s_t) \propto F(s_t \rightarrow s_{t+1}). \quad (7)$$

Bengio 等人 [2021] 证明了如果存在一个满足 (6) 中的流匹配条件以及边界条件的流函数，则按照第 2.2 节所述，在软 MDP 中通过跟随 P_F 终止状态的采样等价于从 (1) 中采样。在这种情况下，与策略关联的终止状态分布 P_F 满足 $P_F(x) \propto \exp(-\mathcal{E}(x)/\alpha)$ ，对于任何终止状态 $x \in \mathcal{X}$ ，并且不受导向该状态的轨迹数量的影响 x ，这与最大熵强化学习中的最优策略不同。

3 桥接差距之间 最大熵 RL 与 GFLOWNETS

最大熵强化学习 (MaxEnt RL) 与生成流网络 (GFlowNets) 在它们的 (最优) 策略所诱导的分布与能量之间的关系上存在根本差异：在最大熵强化学习中，该分布是对如何创建对象 (轨迹) 的分布，正如第 2.2 节所述，而生成流网络仅对结果 (终止状态) 产生分布，后者符合吉布斯分布的要求。在本节中，我们将回顾生成流网络与最大熵强化学习之间的一些现有联系 [Tiapkin 等, 2024]，并建立现有最大熵强化学习算法与生成流网络目标之间的新等价关系。

3.1 奖励修正

为了纠正由多条轨迹导向同一终止状态而在图 1 中显示的偏差，我们可以将 (5) 视为轨迹上的期望而非总和，通过使用这些轨迹的概率分布对 $\pi^*(\tau)$ 进行重新加权 (根据 (4) 和 (2)，对于固定的终止状态，该值是常数)。Bengio 等人 [2023] 表明，可以通过引入一个向后的转移概率 $P_B(s | s')$ ，来定义完整的轨迹分布，这个向后的转移概率是一个关于任何状态的父节点 $s \in \text{Pa}(s')$ 的分布 $s' \neq s_0$ 。Tiapkin 等人 [2024] 表明，软 MDP 的奖励可以根据 P_B 进行修改，使得相应的最优策略 π_{MaxEnt}^* 等于 GFlowNet 策略 P_F 中的 (7)。我们在定理 3.1 中重新陈述并推广了这一结果，展示了这种修正如何抵消 (5) 中边缘化的影响。

2 遵循 GFlowNet 文献中的惯例，我们将使用符号 P_F 表示此策略，也称为正向转移概率 [Bengio 等, 2023]，以此与最大熵强化学习中的最优策略 π_{MaxEnt}^* 区分开来。

导致终止状态分布与吉布斯分布相匹配。

定理 3.1 (Gen. of Tiapkin 等, 2024; 定理 1)。设 $P_B(\cdot | s')$ 为任意一个后向转移概率 (即在 $\mathcal{G}$ 中 $s' \neq s_0$ 的父节点上的分布)。设 $r(s, s')$ 为通过 P_B 修正后的 MDP 的奖励函数，满足对于任何轨迹 $\tau = (s_0, s_1, \dots, s_T, s_f)$ ：

$$\sum_{t=0}^T r(s_t, s_{t+1}) = -\mathcal{E}(s_T) + \alpha \sum_{t=0}^{T-1} \log P_B(s_t | s_{t+1}), \quad (8)$$

我们采用了约定 $s_{T+1} = s_f$ 。那么，与最优策略解 (3) 相关的终止状态分布满足 $\pi_{\text{MaxEnt}}^* \pi^*(x) \propto \exp(-\mathcal{E}(x)/\alpha)$ 。

该定理的证明见附录 A。与 (2) 不同，现在的回报依赖于通过 (8) 中的第二项到达 s_T 的轨迹。有趣的是，在最大熵强化学习文献 [Haarnoja 等人, 2017] 中引入的温度参数 α 可以自然地解释为 Gibbs 分布的温度。请注意，(8) 中的修正仅涉及整个轨迹的后向概率 τ ，使其也与非马尔可夫过程兼容 P_B [沈等人, 2023, 本吉奥等人, 2023]。

Tiapkin 等人 [2024] 仅考虑了软 MDP 的奖励函数稀疏的情况，并进行了修正与 $P_B(s_t | s_{t+1})$ 在每次中间转换中添加 $s_t \rightarrow s_{t+1}$ ；我们将在此后的章节中回到这一设定。这种对奖励的修正完全符合我们在第 2.2 节中的观察，即通过采样终止状态来 π_{MaxEnt}^* 生成 (1) 当软 MDP 是一个树结构，并且奖励如 (2) 所示 (未修正) 的情况下，因为在这种情况下任何状态 $s' \neq s_0$ 具有唯一的父节点 s ，因此 $P_B(s | s') = 1$ 正如 Tiapkin 等人所观察到的 [2024]。

3.2 PCL 与 (SUB)TB 之间的等价性

类似于 (2) 涵盖了稀疏奖励的特殊情况，在本节中我们将考虑满足 (8) 的奖励函数，其中能量函数仅在轨迹结束时出现

$$\begin{aligned} r(s_t, s_{t+1}) &= \alpha \log P_B(s_t | s_{t+1}) \\ r(s_T, s_f) &= -\mathcal{E}(s_T), \end{aligned} \quad (9)$$

如 [Tiapkin 等人, 2024] 所述。定理 3.1 表明，使用修正后的奖励解决 (3) 中的最大熵强化学习问题与找到 GFlowNet 的解决方案相当，因为它们都导致了一个其终止状态分布为 Gibbs 分布的策略。事实证明，存在一种特定算法解决这两个问题的等价性，我们的奖励函数选择如下：路径一致性学习 (PCL; Nachum 等人, 2017) 用于最大熵强化学习，以及子轨迹平衡目标 (SubTB; Madan 等人, 2023, Malkin 等人, 2022) 用于




图 2: 最大熵强化学习中带有修正奖励的目标与 GFlowNets 中目标之间的等价性。这些目标根据它们是否在(完整的)轨迹层面(左), 转换层面(中), 或者所有状态都是终止状态(右)进行分类。关于不同残差的形式及其从一个目标转移到另一个目标的对应关系的更多细节, 请参见图 6。

GFlowNets。这两个目标都在部分轨迹的层面运作, 形式为 $\tau = (s_m, s_{m+1}, \dots, s_n)$, 其中 s_m 和 s_n 不再一定是初始状态和终止状态。

一方面, PCL 目标 $\mathcal{L}_{\text{PCL}}(\theta, \phi) = 1$

${}_2\mathbb{E}_{\pi_b}[\Delta_{\text{PCL}}^2(\tau; \theta, \phi)]$ 鼓励策略 π_θ 由 θ 参数化与软值函数 V_{soft}^ϕ 由 ϕ 参数化之间的一致性, 其中 π_b 是关于(部分)轨迹 τ 的任意分布, 残差定义为

$$\Delta_{\text{PCL}}(\tau; \theta, \phi) = -V_{\text{soft}}^\phi(s_m) + V_{\text{soft}}^\phi(s_n) + \sum_{t=m}^{n-1} (r(s_t, s_{t+1}) - \alpha \log \pi_\theta(s_{t+1} | s_t)). \quad (10)$$

另一方面, SubTB 目标 $\mathcal{L}_{\text{SubTB}}(\theta, \phi) =$

$\frac{1}{2}\mathbb{E}_{\pi_b}[\Delta_{\text{SubTB}}^2(\tau; \theta, \phi)]$ 也强制执行某种形式的一致性, 但这次是在策略(前向转移概率) P_F^θ 由 θ 参数化与状态流函数 F_ϕ 由 ϕ 参数化之间, 残差定义为 $\Delta_{\text{SubTB}}(\tau; \theta, \phi) = \log \frac{F_\phi(s_n) \prod_{t=m}^{n-1} P_B(s_t | s_{t+1})}{\prod_{t=m}^{n-1} F_\phi(s_m) \frac{1-t}{n-1} P_F^\theta(s_{t+1} | s_t)}$, 其中

P_B 是后向转移概率, 在这里假设它是固定的——尽管一般情况下, P_B 也可以被学习 [Malkin 等, 22]。除了这个目标外, 还必须对 F_ϕ 施加一些边界条件(取决于 $\mathcal{E}$) , 类似于第 2.3 节中引入的那些; 详情见附录 B.1。以下命题建立了这两个目标之间的等价性, 仅相差一个只依赖于温度 α 的归一化常数, 并提供了一种从最大熵强化学习中的策略/价值函数参数化转换到 GFlowNets 中的策略/流函数参数化的方法。尽管在先前的工作 [Malkin 等, 2022, Jiralerspong 等, 2024, Hu 等, 2024, Mohammadpour 等, 2024] 中提到了这两种方法之间的相似性, 但我们在这里展示了两个目标之间的精确等价性。

命题 3.2. 子轨迹平衡目标 (GFlowNet; Madan 等, 2023) 与路径一致性学习目标 (最大熵强化学习; Nachum 等, 2017) 在软 MDP 上的奖励函数定义在 (9) 中成正比, 具体而言为

$$\text{PCL}(\theta, \phi) = \alpha^2 \mathcal{L}_{\text{SubTB}}(\theta, \phi), \text{ 对应的映射关系为}$$

$$\pi_\theta(s' | s) = P_F^\theta(s' | s) \quad V_{\text{soft}}^\phi(s) = \alpha \log F_\phi(s). \quad (11)$$

该命题的证明可在附录 B.1 中找到。最大熵强化学习中的价值函数与 GFlowNets 中的状态流函数之间的等价性也在 [Tiapkin 等, 2024] 中发现。当应用于完整轨迹时, 这也显示了轨迹平衡目标 (TB; Malkin 等, 2022) 与我们在 (9) 中选择的修正奖励下的 PCL 之间的联系, 后者在 GFlowNet 文献中广泛使用。

在另一个极端, 如果我们把这个命题应用到软 MDP (即长度为 1 的子轨迹) 的状态转移上, 那么通过 Nachum 等人的统一 PCL 视角, 我们可以得到 GFlowNets 中的细致平衡目标 (DB; Bengio 等人, 2023) 与软 Q 学习算法 (SQL; Haarnoja 等人, 2017) 之间的类似等价关系。[2017] 使用软 Q 函数来同时参数化策略和价值函数 (10); 详见推论 B.1。我们注意到 DB 与 SQL 之间的这种联系也在先前的工作中被提及 [Tiapkin 等, 2024, Mohammadpour 等, 2024]。命题 3.2 所导致的不同最大熵强化学习和 GFlowNet 目标之间的联系总结见图 2, 更多细节见图 6。

3.3 带有策略的软 Q 学习 PARAMETRIZATION

在本节中, 我们考虑所有软 MDP 状态都是样本空间的有效元素的情况 $\mathcal{X}$

（换句话说，所有状态都是终止状态）。由于现在每个状态都与某种能量相关联，我们可以重新塑造奖励 [Ng 等人, 1999]，同时仍然满足 (8) 作为

$$\begin{aligned} r(s_t, s_{t+1}) &= \mathcal{E}(s_t) - \mathcal{E}(s_{t+1}) + \alpha \log P_B(s_t | s_{t+1}) \\ r(s_T, s_f) &= 0, \end{aligned} \quad (12)$$

如果我们假设，不失一般性， $\mathcal{E}(s_0) = 0$ （添加到能量函数中的任何偏移量都不会改变 (1)）。这是一个新颖的设置，与 Tiapkin 等人 [2024] 不同，并且得益于我们在定理 3.1 中的通用陈述而成为可能。我们在命题 B.2 中展示了，通过我们上面选择的奖励，特别是终止时不接收任何奖励的事实，我们可以将软 Q 学习的目标表示为由 θ 参数化的策略 π_θ 的函数；我们称其为 π -SQL。目标可以写作 $\mathcal{L}_{\pi\text{-SQL}}(\theta) = \frac{1}{\text{ar.}} \mathbb{E}_{\pi_b}[\Delta_{\pi\text{-SQL}}^2(s, s'; \theta)]$ ，其中 π_b 是过渡上的任意分布 $s \rightarrow s'$ ，使得 $s' \neq s_f$ ，并且 $\Delta_{\pi\text{-SQL}}(s, s'; \theta) = \alpha$

$$\begin{aligned} &[\log \pi_\theta(s' | s) - \log \pi_\theta(s_f | s) \\ &+ \log \pi_\theta(s_f | s')^\top - r(s, s')]. \end{aligned} \quad (13)$$

有了 (12) 中的奖励函数，这种对 SQL 的替代视角值得注意的是，它等同于修改后的详细平衡目标（修改后的 DB；Deleu 等人, 2022），特别是在所有状态都是终止状态的情况下 GFlowNets 的特殊情况下推导出来的。这个目标可以写作 $\mathcal{L}_{\text{M-DB}}(\theta) = \frac{1}{\text{ar.}} \mathbb{E}_{\pi_b}[\Delta_{\text{M-DB}}^2(s, s'; \theta)]$ 这取决于一个策略（正向转换概率） P_F^θ 由 θ 参数化，其中

$$\begin{aligned} \Delta_{\text{M-DB}}(s, s'; \theta) & \quad (14) \\ &= \log \frac{\exp(-\mathcal{E}(s')/\alpha) P_B(s | s') P_F^\theta(s_f | s)}{\exp(-\mathcal{E}(s)/\alpha) P_F^\theta(s' | s) P_F^\theta(s_f | s')}. \end{aligned}$$

命题 3.3. 假设软 MDP 的所有状态都是终止状态 $\mathcal{S} \equiv \mathcal{X}$ 。修改后的详细平衡目标（GFlowNet；Deleu 等人, 2022）与具有策略参数化的软 Q 学习目标（最大熵 RL； π -SQL）在定义于 (12) 的奖励函数下的软 MDP 成正比，在某种意义上， $\mathcal{L}_{\pi\text{-SQL}}(\theta) = \alpha^2 \mathcal{L}_{\text{M-DB}}(\theta)$ ，其中 $\pi_\theta(s' | s) = P_F^\theta(s' | s)$ 。

证明见附录 B.3。这一结果可以进一步推广到并非所有状态都一定是终止状态的情况，但在轨迹过程中可以收到部分奖励的情况下，SQL 与 GFlowNets 中的前瞻详细平衡目标（FL-DB；Pan 等, 2023a）之间存在等价性；详情见附录 B.4。

4 相关工作

最大熵强化学习。与标准强化学习不同，在标准强化学习中，最优策略

可能是完全确定性的（至少在完全可观测的情况下；Sutton 和 Barto, 2018），最大熵 RL 寻求一种随机策略，该策略在最大化奖励和未来动作的最大熵之间取得平衡 [Ziebart, 2010, Fox 等, 2016]。这种类型的熵正则化属于更广泛的正则化 MDPs 领域 [Geist 等, 2019]。这特别有利于改进探索 [Haarnoja 等, 2017] 以及在模型规格不匹配情况下的鲁棒控制 [Eysenbach 和 Levine, 2022]。流行的最大熵 RL 方法包括软 Q 学习、路径一致性学习 [Nachum 等, 2017] 和软演员-评论家 [Haarnoja 等, 2018a]，本文研究了这些方法。

生成流网络。Bengio 等人 [2021] 从强化学习中获得启发，引入了 GFlowNets 作为寻找与目标蛋白结合的多样化分子的解决方案。自那时以来，它们在科学发现的多个领域中找到了应用 [Jain 等人, 2022, 2023a, Mila AI4Science 等人, 2023]，通过将多样性与主动学习相结合 [Jain 等人, 2023b, Hernandez-Garcia 等人, 2023]，也在组合优化 [Zhang 等人, 2023a,b]、因果发现 [Deleu 等人, 2022, 2023, Atanackovic 等人, 2023] 和一般的概率推理 [Zhang 等人, 2022b, Hu 等人, 2023, 2024, Falet 等人, 2024] 中得到了应用。尽管它们被表述得不同，GFlowNets 也与变分推断的文献有着深刻的联系 [Malkin 等人, 2023, Zimmermann 等人, 2022]。

近期的一些研究建立了 GFlowNets 与（最大熵）RL 之间的联系。最接近我们工作的研究是 Tiapkin 等人 [2024]，他们展示了如何根据某些反向转移概率来修正最大熵 RL 中的奖励，使其等同于 GFlowNets。尽管他们的分析仅限于原始软 MDP 中奖励函数稀疏的情况（即，奖励仅在轨迹结束时获得），但他们首次提出了在每个中间转移中进行修正的方法，如第 3.2 节所述。我们在定理 3.1 中对此进行了推广，修正是在轨迹层面进行的，这提供了更多的灵活性，使修正可以沿轨迹分布，并允许中间奖励。Tiapkin 等人 [2024] 还展示了 GFlowNet 目标与最大熵 RL 算法之间的相似性，即详细平衡与对战软 Q 学习 [Wang 等人, 2016]，以及轨迹平衡与策略梯度 [Schulman 等人, 2017]。轨迹平衡与策略梯度之间的对应关系在 [Niu 等人, 2024] 中进一步扩展，这是 GFlowNets、变分推断 [Malkin 等人, 2023] 和强化学习 [Weber 等人, 2015] 之间联系的直接结果。最后，Mohammadpour 等人 [2024] 也引入了一种依赖于 $n(s)$ 到达某个状态的部分轨迹数量的修正方法 s ，该方法可以通过解决一个“逆”MDP 上的第二个最大熵 RL 问题 (3) 来学习。这种修正对应于一种特定的反向转移概率选择。




图 3: 在因子图推理任务上, MaxEnt RL 和 GFlowNet 算法之间的比较, 通过训练过程中终止状态分布与目标分布之间的 Jensen-Shannon 发散来衡量。每条曲线代表了在 20 个随机种子上的平均 JSD 及其 95% 置信区间。

在公式 (8) 中的 $P_B(s_t | s_{t+1}) = n(s_t)/n(s_{t+1})$, 具有最大化流熵的显著特性。

5 实验结果

我们在三个领域中实证验证了第 3 节建立的等价性: 离散因子图上的推理 [Buesing 等人, 2020], 贝叶斯网络的贝叶斯结构学习 [Deleu 等人, 2022] 以及简约系统发生树的生成 [Zhou 等人, 2024]。除了详细平衡 (及其可能的修改版本) 和轨迹平衡 (GFlowNets), 以及软 Q 学习 (可能由策略参数化; 参见第 3.3 节) 和路径一致性学习 (MaxEnt RL) 之外, 我们还考虑了软演员-评论家的离散版本 [Christodoulou, 2021], 它在 GFlowNet 文献中没有自然对应的版本。对于所有 MaxEnt RL 方法, 我们调整了 MDP 以包含对奖励的修正。请注意, 在这里考虑的所有领域中, 原始 MDP 中都存在非平凡的中间奖励, 这意味着所有 DB 的实例实际上都使用前瞻式公式 [Pan 等人, 2023a]; 这些中间奖励的形式以及额外的实验细节可以在附录 C 中找到。

5.1 概率推理 离散因子图

Buesing 等人的概率推理任务 [2020] 包含依次采样值的过程 d 因子图中的一次一个离散随机变量, 按照固定顺序进行。这使得底层马尔可夫决策过程具有树状结构, 消除了对奖励修正的需求, 详见第 2.2 节。我们将该环境适应为允许以任意顺序采样随机变量, 从而导致每个终止状态有多条轨迹。关于能量函数的详细信息, 请参见附录 C.1。

在图 3 中, 展示了不同最大熵 RL 和 GFlowNet 算法在 4 种不同因子图结构上的性能, 这些结构由 Buesing 等人提出 [2020], 其中 $d = 6$

变量及其各自可以取的 5 个可能值之一。我们观察到 TB 与 PCL 表现相似, 验证了命题 3.2, 并且总体上优于所有其他方法。同样, 我们可以看到 DB 与 SQL 的表现也如推论 B.1 所预期的那样相似。最后, 尽管 SAC 通常被视为连续控制领域的强算法 [Haarnoja 等, 2018b], 但我们并未观察到其在 DB/SQL 上的任何显著改进。

5.2 贝叶斯网络的结构学习 网络

我们也从贝叶斯视角 [Deleu 等, 2022] 评估了所有算法在学习贝叶斯网络结构的任务上的表现。给定一个观测数据集 $\mathcal{D}$ 来自联合分布于 d 随机变量 $X_1, \dots, X_d$ 我们的目标是近似后验分布 $P(G | \mathcal{D}) \propto P(\mathcal{D} | G)P(G)$ 在 DAG 结构上 G 编码条件独立性 $P(X_1, \dots, X_d)$ 软 MDP 的构建方法参考了 [Deleu 等, 2022], 其中使用了一个有向无环图 G 通过逐步添加一条边的方式构建, 从一个完全空的图开始, 同时在生成过程的每一步都确保图的无环性 (即, 如果添加某条边会引入环, 则该边不能被添加)。

参考 Malkin 等人的研究 [2023], 我们在此考虑一个相对较小的任务, 其中 $d = 5$, 以便可以解析地评估目标分布 $P(G | \mathcal{D})$, 并与我们的 MaxEnt RL 和/或 GFlowNets 给出的近似值进行比较。与第 5.1 节不同, 我们在比较中还包括了修改后的 DB 损失和 π -SQL, 因为所有状态都是有效的 DAG。从图 4 中可以看出, TB 与 PCL 以及修改后的 DB 与 π -SQL 的表现非常相似, 这在经验上验证了我们上述建立的等价性。尽管进行了轻微的超参数搜索, 但我们发现 SAC 的平均表现明显低于其他方法, 主要是由于训练过程中的不稳定。




图 4: 在贝叶斯结构学习任务上, MaxEnt RL 算法与 GFlowNet 算法之间的比较, 比较依据是在训练过程中终止状态分布与目标后验之间的 Jensen-Shannon 发散度。两个实验在边缘似然 $P(\mathcal{D} | G)$ 的计算方式上有所不同, (左) 使用 BGe 评分 [Geiger 和 Heckerman, 1994], (右) 使用线性高斯评分 [Nishikawa-Toomey 等, 2023]。每条曲线代表 20 个随机种子上的平均 JSD 及其 95% 置信区间。

5.3 系统发生树生成

最后, 我们还将这些方法应用于周等人提出的更为复杂的简约系统发育树生成任务中 [2024]。基于不同物种的生物序列, 目标是在这些物种上找到需要较少突变的系统发育树。软 MDP 的状态对应于物种划分上的树集合, 而动作则对应于通过添加根节点将两棵树合并在一起。请注意, 尽管这些树可能具有不同的轨迹数量 (与图 3 不同), 但通过这种方式采样的所有树都具有相同的大小。一棵树的能量 T 对应于在 T 中捕获的总突变数。

在图 5 中, 我们将所有方法在周等人引入的 6 个数据集上的性能进行了比较。[2024], 在终止状态对数概率 $\log \pi(T)$ 与所学策略相关的未修正回报 $-\mathcal{E}(T)$ 之间的相关性方面, 因为理想情况下我们应该有

$$\log \pi(T) \approx \log \pi^*(T) = -\mathcal{E}(T) - \log Z, \quad (15)$$

根据定理 3.1。我们再次观察到 TB 与 PCL 的表现彼此相似, DB 与 SQL 亦然, 这证实了我们在上述更大规模问题上的观察结果, 在这些问题中, 分区函数是难以处理的。类似于第 5.2 节, 我们也发现 SAC 通常不如 DB/SQL 具有竞争力, 除非是在 DS4 的情况下。

6 讨论

随机环境。类似于 [Mohammadpour 等, 2024], 本文注意到此处的结果仅限于软 MDP 确定性的情况, 以符合 GFlowNet 文献中的标准假设。尽管有些工作尝试将 GFlowNet 推广到随机环境 [Bengio 等, 2023, Pan 等, 2023b], 但关于如何保证这一点尚未达成明显共识

最优策略的存在性 P_F , 其终止状态分布与 (1) 匹配, 当一个对象可能以多种方式生成时 (*i.e.*, $\mathcal{G}$ 是一个有向无环图)。Jiralerspong 等人 [2024] 引入了一个称为 EFlowNet 的随机环境扩展, 在这种环境中, 最优策略的存在性得到了保证, 尽管仅限于软 MDP 具有树结构的情况, 从而避免了任何奖励修正的需求。通常情况下, 确定性的假设并不会限制太多, 因为软 MDP 的结构通常是根据问题本身 (取决于需要近似的分布) 由专家设计的。

具有相同轨迹数量的环境。我们在第 2.2 节看到, 如果不修正奖励函数, 最优策略 π_{MaxEnt}^* 的终止状态分布会偏向于拥有更多完整轨迹通向它们的状态。然而, 在某些情况下, 所有状态都有相同数量的轨迹通向它们。这种情况出现在第 5.1 节研究的离散因子图环境中, 其中所有终止状态都可以通过确切的 n 条轨迹访问, 因为每个 n 变量可以按任意顺序赋值。在这种情况下, 可以直接应用原始奖励在 (2) 中的最大熵强化学习, 无需任何修正, 仍然可以获得等于吉布斯分布的终止状态分布, 因为这个常数可以被吸收进配分函数中。就像当 $\mathcal{G}$ 是一个树的情况一样, 这应该被视为一种特殊情况, 并且通常建议始终使用 P_B 来修正奖励。

策略与状态流的统一参数化。在文献中涉及 SubTB 目标 [Madan 等人, 2023 年, Malkin 等人, 2022 年] 的所有 GFlowNets 应用中, 正向转移概率 P_F^θ 和状态流函数 F_ϕ 总是使用独立的模型进行参数化 (可能共享一个基础结构), 如第 3.2 节所述。然而, 由于命题 3.2 中建立的等价性与 PCL 的关系, 实际上有可能

	TB	PCL	DB	SQL	SAC
DS1	0.7797	0.7399	0.9141	0.8695	0.6003
DS2	0.8550	0.8309	0.8811	0.8922	0.7022
DS3	0.5833	0.6137	0.8649	0.8474	0.6334
DS4	0.9178	0.9177	0.9285	0.8965	0.9320
DS5	0.9688	0.9690	0.9633	0.9712	0.9567
DS6	0.9526	0.9542	0.9496	0.9615	0.8017




图 5: 比较最大熵强化学习和 GFlowNet 算法在生成系统发育树任务上的表现。(左) 根据 1000 棵随机采样的树, 终止状态对数概率与回报之间的皮尔逊相关系数的表现对比。(中) 使用 DB 找到的终止状态对数概率与回报之间的相关性, 每个点代表一棵树, 带有最佳线性拟合线及其斜率。(右) 同样适用于 SQL。所有方法和数据集的相关性图可以在附录 C.3 中找到。

通过统一 PCL 视角 [Nachum 等, 2017], 使用单一“Q 函数”来参数化这两个函数; 请参见附录 B.2, 在 DB 与 SQL 的背景下。具有独立网络的设置更接近于 Tiapkin 等所强调的对战架构的使用 [2024]。在我们的实验中, 我们观察到使用两个独立网络的 DB 整体上与使用单个 Q 网络的 SQL 表现相似, 尽管后者需要较少的参数进行学习。关于这种策略的有效性性与独立网络相比的全面研究留待未来的工作。

连续控制与概率推理。虽然本文主要关注离散分布, 以匹配 GFlowNet 文献中研究广泛的设定, 但定理 3.1 中的奖励修正可以扩展到 Tiapkin 等人所推测的情况, 即当软 MDP 的状态空间和动作空间为连续空间时。软 MDP 的状态空间和动作空间为连续空间的情形。[2024] 通过利用 GFlowNets 在连续空间中的扩展 [李等, 2023, 拉卢等, 2023], 我们可以建立与最大熵强化学习目标相似的联系。有趣的是, 连续 GFlowNets 与扩散模型 [Zhang 等, 2022a, Sendera 等, 2024] 有很强的关联性, 而研究表明强化学习是一种有效的训练方法 [Fan 和 Lee, 2023, Black 等, 2024]。

7 结论与未来工作

在这项工作中, 我们展示了来自 GFlowNet 文献 [Bengio 等, 2023, Malkin 等, 2022, Pan 等, 2023a] 中许多已建立的目标恰好等同于最大熵强化学习中的知名算法。我们的工作基于最近的一系列工作, 这些工作建立了 GFlowNet 与最大熵强化学习之间的联系 [Tiapkin 等, 2024, Mohammadpour 等, 2024, 牛等, 2024], 并扩展了由 Tiapkin 等人引入的奖励修正 [2024], 使其适用于完整的轨迹层面。这一泛化非常重要, 因为它使我们能够建立最大熵强化学习算法与 GFlowNet 目标之间的新联系, 特别是在底层马尔可夫决策过程存在中间奖励的情况下。

这种泛化意义重大, 因为它使我们能够建立最大熵强化学习算法与 GFlowNet 目标之间的新联系, 尤其是在底层马尔可夫决策过程中存在中间奖励的情况下。

这一视角使得能够以原则性的方式整合所有强化学习工具, 用于大规模离散和结构化空间的概率推理。未来工作应致力于进一步研究这一交叉领域, 借鉴强化学习文献中的最佳实践, 以实现该场景下的更高效推理。特别是, 能够更好地探索状态空间, 以找到吉布斯分布的模式 [雷克特-布鲁克斯等, 2023], 例如使用为强化学习代理开发的目标探索策略 [贝尔马尔等, 2016, 帕塔克等, 2017], 对于因果结构学习 [德卢等, 2022] 和分子生成 [本乔等, 2021] 等大规模应用至关重要, 超越了最大熵强化学习在探索方面的能力 [哈诺贾等, 2017]。

致谢

感谢瓦伦丁·托马斯、米哈尔·瓦尔科、皮埃尔·梅纳尔、达尼尔·蒂亚普金和索巴罕·莫罕默德波尔关于本文的有益讨论和评论。多伊娜·普雷库普和约书亚·本乔是 CIFAR 资深研究员。这项研究部分得益于 Mila (mila.quebec) 提供的计算资源和软件。

参考文献

- Christof Angermueller, David Dohan, David Belanger, Ramya Deshpande, Kevin Murphy, and Lucy Colwell. Model-based reinforcement learning for biological sequence design. *International Conference on Learning Representations*, 2020.
- Lazar Atanackovic, Alexander Tong, Jason Hartford, Leo J Lee, Bo Wang, and Yoshua Bengio. DynGFN: Bayesian Dynamic Causal Discovery using Generative Flow Networks. *Advances in Neural Information Processing Systems*, 2023.
- Philip Bachman and Doina Precup. Data Generation as Sequential Decision Making. *Advances in Neural Information Processing Systems*, 2015.
- Marc Bellemare, Sriram Srinivasan, Georg Ostrovski, Tom Schaul, David Saxton, and Remi Munos. Unifying Count-Based Exploration and Intrinsic Motivation. *Advances in Neural Information Processing Systems*, 2016.
- Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow Network based Generative Models for Non-Iterative Diverse Candidate Generation. *Advances in Neural Information Processing Systems*, 2021.
- Yoshua Bengio, Salem Lahlou, Tristan Deleu, Edward J Hu, Mo Tiwari, and Emmanuel Bengio. GFlowNet Foundations. *Journal of Machine Learning Research*, 2023.
- Kevin Black, Michael Janner, Yilun Du, Ilya Kostrikov, and Sergey Levine. Training Diffusion Models with Reinforcement Learning. *International Conference on Learning Representations*, 2024.
- Lars Buesing, Nicolas Heess, and Theophane Weber. Approximate Inference in Discrete Distributions with Monte Carlo Tree Search and Value Functions. In *International Conference on Artificial Intelligence and Statistics*. PMLR, 2020.
- Petros Christodoulou. Soft Actor-Critic for Discrete Action Settings. *arXiv preprint*, 2019.
- Tristan Deleu, António Góis, Chris Emezue, Mansi Rankawat, Simon Lacoste-Julien, Stefan Bauer, and Yoshua Bengio. Bayesian Structure Learning with Generative Flow Networks. *Uncertainty in Artificial Intelligence*, 2022.
- Tristan Deleu, Mizu Nishikawa-Toomey, Jithendara Subramanian, Nikolay Malkin, Laurent Charlin, and Yoshua Bengio. Joint Bayesian Inference of Graphical Structure and Parameters with a Single Generative Flow Network. *Advances in Neural Information Processing Systems*, 2023.
- Benjamin Eysenbach and Sergey Levine. Maximum Entropy RL (Provably) Solves Some Robust RL Problems. *International Conference on Learning Representations*, 2022.
- Jean-Pierre Falet, Hae Beom Lee, Nikolay Malkin, Chen Sun, Dragos Secrieru, Dinghuai Zhang, Guillaume Lajoie, and Yoshua Bengio. Delta-AI: Local objectives for amortized inference in sparse graphical models. *International Conference on Learning Representations*, 2024.
- Ying Fan and Kangwook Lee. Optimizing ddpm sampling with shortcut fine-tuning. *International Conference on Machine Learning*, 2023.
- Leo Feng, Padideh Nouri, Aneri Muni, Yoshua Bengio, and Pierre-Luc Bacon. Designing Biological Sequences via Meta-Reinforcement Learning and Bayesian Optimization. *Workshop on Machine Learning in Structural Biology, NeurIPS*, 2022.
- Roy Fox, Ari Pakman, and Naftali Tishby. Taming the Noise in Reinforcement Learning via Soft Updates. *Uncertainty in Artificial Intelligence*, 2016.
- Nir Friedman and Daphne Koller. Being Bayesian About Network Structure. A Bayesian Approach to Structure Discovery in Bayesian Networks. *Machine Learning*, 2003.
- Dan Geiger and David Heckerman. Learning Gaussian Networks. *Uncertainty in Artificial Intelligence*, 1994.
- Matthieu Geist, Bruno Scherrer, and Olivier Pietquin. A Theory of Regularized Markov Decision Processes. *International Conference on Machine Learning*, 2019.
- Alan E. Gelfand and Adrian FM. Smith. Sampling-based approaches to calculating marginal densities. *Journal of the American statistical association*, 1990.
- Tuomas Haarnoja, Haoran Tang, Pieter Abbeel, and Sergey Levine. Reinforcement Learning with Deep Energy-Based Policies. *International Conference on Machine Learning*, 2017.
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. In *International Conference in Machine Learning*, 2018a.
- Tuomas Haarnoja, Aurick Zhou, Kristian Hartikainen, George Tucker, Sehoon Ha, Jie Tan, Vikash Kumar, Henry Zhu, Abhishek Gupta, Pieter Abbeel, and Sergey Levine. Soft Actor-Critic Algorithms and Applications. *Arxiv preprint*, 2018b.
- W. Keith Hastings. Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, 1970.

- Alex Hernandez-Garcia, Nikita Saxena, Moksh Jain, Cheng-Hao Liu, and Yoshua Bengio. Multi-Fidelity Active Learning with GFlowNets. *arXiv preprint*, 2023.
- Edward J Hu, Nikolay Malkin, Moksh Jain, Katie E Everett, Alexandros Graikos, and Yoshua Bengio. GFlowNet-EM for Learning Compositional Latent Variable Models. *International Conference on Machine Learning*, 2023.
- Edward J Hu, Moksh Jain, Eric Elmoznino, Younesse Kaddar, Guillaume Lajoie, Yoshua Bengio, and Nikolay Malkin. Amortizing intractable inference in large language models. *International Conference on Learning Representations*, 2024.
- Moksh Jain, Emmanuel Bengio, Alex Hernandez-Garcia, Jarrid Rector-Brooks, Bonaventure F.P. Dossou, Chanakya Ekbote, Jie Fu, Tianyu Zhang, Micheal Kilgour, Dinghuai Zhang, Lena Simine, Payel Das, and Yoshua Bengio. Biological Sequence Design with GFlowNets. *International Conference on Machine Learning*, 2022.
- Moksh Jain, Tristan Deleu, Jason Hartford, Cheng-Hao Liu, Alex Hernandez-Garcia, and Yoshua Bengio. GFlowNets for AI-Driven Scientific Discovery. *Digital Discovery*, 2023a.
- Moksh Jain, Sharath Chandra Raparthy, Alex Hernández-García, Jarrid Rector-Brooks, Yoshua Bengio, Santiago Miret, and Emmanuel Bengio. Multi-Objective GFlowNets. *International Conference on Machine Learning*, 2023b.
- Eric Jang, Shixiang Gu, and Ben Poole. Categorical Reparameterization with Gumbel-Softmax. In *International Conference on Learning Representations*, 2017.
- Marco Jiralerspong, Bilun Sun, Danilo Vucetic, Tianyu Zhang, Yoshua Bengio, Gauthier Gidel, and Nikolay Malkin. Expected flow networks in stochastic environments and two-player zero-sum games. *International Conference on Learning Representations*, 2024.
- Hilbert J Kappen, Vicenç Gómez, and Manfred Opper. Optimal control as a graphical model inference problem. *Machine learning*, 2012.
- Diederik P Kingma and Max Welling. Auto-Encoding Variational Bayes. *International Conference on Learning Representations*, 2014.
- Salem Lahlou, Tristan Deleu, Pablo Lemos, Dinghuai Zhang, Alexandra Volokhova, Alex Hernández-García, Léna Néhale Ezzine, Yoshua Bengio, and Nikolay Malkin. A Theory of Continuous Generative Flow Networks. *International Conference on Machine Learning*, 2023.
- Sergey Levine. Reinforcement Learning and Control as Probabilistic Inference: Tutorial and Review. *arXiv preprint*, 2018.
- Yinchuan Li, Shuang Luo, Haozhi Wang, and Jianye Hao. CFlowNets: Continuous control with Generative Flow Networks. *International Conference on Learning Representations*, 2023.
- Kanika Madan, Jarrid Rector-Brooks, Maksym Korablyov, Emmanuel Bengio, Moksh Jain, Andrei Nica, Tom Bosc, Yoshua Bengio, and Nikolay Malkin. Learning GFlowNets from partial episodes for improved convergence and stability. *International Conference on Machine Learning*, 2023.
- Chris J. Maddison, Andriy Mnih, and Yee Whye Teh. The Concrete Distribution: A Continuous Relaxation of Discrete Random Variables. In *International Conference on Learning Representations*, 2017.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in GFlowNets. *Advances in Neural Information Processing Systems*, 2022.
- Nikolay Malkin, Salem Lahlou, Tristan Deleu, Xu Ji, Edward Hu, Katie Everett, Dinghuai Zhang, and Yoshua Bengio. GFlowNets and variational inference. *International Conference on Learning Representations*, 2023.
- Gonzalo Mena, David Belanger, Scott Linderman, and Jasper Snoek. Learning Latent Permutations with Gumbel-Sinkhorn Networks. In *International Conference on Learning Representations*, 2018.
- Mila AI4Science, Alex Hernandez-Garcia, Alexandre Duval, Alexandra Volokhova, Yoshua Bengio, Divya Sharma, Pierre Luc Carrier, Michał Koziarski, and Victor Schmidt. Crystal-GFN: sampling crystals with desirable properties and constraints. *arXiv preprint*, 2023.
- Shakir Mohamed, Mihaela Rosca, Michael Figurnov, and Andriy Mnih. Monte Carlo Gradient Estimation in Machine Learning. In *Journal of Machine Learning Research*, 2020.
- Sobhan Mohammadpour, Emmanuel Bengio, Emma Frejinger, and Pierre-Luc Bacon. Maximum entropy GFlowNets with soft Q-learning. *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2024.
- Ofir Nachum, Mohammad Norouzi, Kelvin Xu, and Dale Schuurmans. Bridging the Gap Between Value and Policy Based Reinforcement Learning. *Advances in Neural Information Processing Systems*, 2017.

- Andrew Y. Ng, Daishi Harada, and Stuart Russell. Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping. *International Conference on Machine Learning*, 1999.
- Mizu Nishikawa-Toomey, Tristan Deleu, Jithendaraa Subramanian, Yoshua Bengio, and Laurent Charlin. Bayesian learning of Causal Structure and Mechanisms with GFlowNets and Variational Bayes. *AAAI Workshop Graphs and More Complex Structures for Learning and Reasoning*, 2023.
- Puhua Niu, Shili Wu, Mingzhou Fan, and Xiaoning Qian. GFlowNet Training by Policy Gradients. *International Conference in Machine Learning*, 2024.
- Ling Pan, Nikolay Malkin, Dinghuai Zhang, and Yoshua Bengio. Better Training of GFlowNets with Local Credit and Incomplete Trajectories. *International Conference on Machine Learning*, 2023a.
- Ling Pan, Dinghuai Zhang, Moksh Jain, Longbo Huang, and Yoshua Bengio. Stochastic Generative Flow Networks. *Uncertainty in Artificial Intelligence*, 2023b.
- Deepak Pathak, Pulkit Agrawal, Alexei A Efros, and Trevor Darrell. Curiosity-driven Exploration by Self-supervised Prediction. *International Conference on Machine Learning*, 2017.
- Jarrid Rector-Brooks, Kanika Madan, Moksh Jain, Maksym Korablyov, Cheng-Hao Liu, Sarath Chandar, Nikolay Malkin, and Yoshua Bengio. Thompson sampling for improved exploration in GFlowNets. *ICML 2023 workshop on Structured Probabilistic Inference & Generative Modeling*, 2023.
- Danilo Rezende and Shakir Mohamed. Variational Inference with Normalizing Flows. In *International Conference on Machine Learning*, 2015.
- Danilo Jimenez Rezende, Shakir Mohamed, and Daan Wierstra. Stochastic Backpropagation and Approximate Inference in Deep Generative Models. In *International Conference on Machine Learning*, 2014.
- John Schulman, Xi Chen, and Pieter Abbeel. Equivalence Between Policy Gradients and Soft Q-Learning. *arXiv preprint*, 2017.
- Marcin Sendera, Minsu Kim, Sarthak Mittal, Pablo Lemos, Luca Scimeca, Jarrid Rector-Brooks, Alexandre Adam, Yoshua Bengio, and Nikolay Malkin. On diffusion models for amortized inference: Benchmarking and improving stochastic control and sampling. *arXiv preprint*, 2024.
- Max W Shen, Emmanuel Bengio, Ehsan Hajiramezanali, Andreas Loukas, Kyunghyun Cho, and Tommaso Biancalani. Towards Understanding and Improving GFlowNet Training. *International Conference on Machine Learning*, 2023.
- Richard S Sutton and Andrew G Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- Daniil Tiapkin, Nikita Morozov, Alexey Naumov, and Dmitry Vetrov. Generative Flow Networks as Entropy-Regularized RL. *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2024.
- Emanuel Todorov. Linearly-solvable Markov decision problems. *Advances in Neural Information Processing Systems*, 2006.
- Nikhil Vemgal, Elaine Lau, and Doina Precup. An Empirical Study of the Effectiveness of Using a Replay Buffer on Mode Discovery in GFlowNets. *ICML 2023 workshop on Structured Probabilistic Inference & Generative Modeling*, 2023.
- Ziyu Wang, Tom Schaul, Matteo Hessel, Hado Hasselt, Marc Lanctot, and Nando Freitas. Dueling Network Architectures for Deep Reinforcement Learning. *International Conference on Machine Learning*, 2016.
- Theophane Weber, Nicolas Heess, Ali Eslami, John Schulman, David Wingate, and David Silver. Reinforced variational inference. *Advances in Neural Information Processing Systems (NIPS) Workshops*, 2015.
- Ronald J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. In *Machine Learning*, 1992.
- Jiaxuan You, Bowen Liu, Zhitao Ying, Vijay Pande, and Jure Leskovec. Graph Convolutional Policy Network for Goal-Directed Molecular Graph Generation. *Advances in Neural Information Processing Systems*, 2018.
- David Zhang, Corrado Rainone, Markus Peschl, and Roberto Bondesan. Robust Scheduling with GFlowNets. *International Conference on Learning Representations*, 2023a.
- Dinghuai Zhang, Ricky T. Q. Chen, Nikolay Malkin, and Yoshua Bengio. Unifying Generative Models with GFlowNets and Beyond. *International Conference on Machine Learning – Beyond Bayes workshop*, 2022a.
- Dinghuai Zhang, Nikolay Malkin, Zhen Liu, Alexandra Volokhova, Aaron Courville, and Yoshua Bengio. Generative Flow Networks for Discrete Probabilistic Modeling. *International Conference on Machine Learning*, 2022b.
- Dinghuai Zhang, Hanjun Dai, Nikolay Malkin, Aaron Courville, Yoshua Bengio, and Ling Pan. Let the Flows Tell: Solving Graph Combinatorial Optimization Problems with GFlowNets. *Advances in Neural Information Processing Systems*, 2023b.

Mingyang Zhou, Zichao Yan, Elliot Layne, Nikolay Malkin, Dinghuai Zhang, Moksh Jain, Mathieu Blanchette, and Yoshua Bengio. PhyloGFN: Phylogenetic inference with generative flow networks. *International Conference on Machine Learning*, 2024.

Brian D Ziebart. *Modeling Purposeful Adaptive Behavior with the Principle of Maximum Causal Entropy*. Carnegie Mellon University, 2010.

Brian D Ziebart, Andrew L Maas, J Andrew Bagnell, Anind K Dey, et al. Maximum Entropy Inverse Reinforcement Learning. *AAAI Conference on Artificial Intelligence*, 2008.

Heiko Zimmermann, Fredrik Lindsten, Jan-Willem van de Meent, and Christian A. Naesseth. A Variational Perspective on Generative Flow Networks. *Transactions of Machine Learning Research*, 2022.

Discrete Probabilistic Inference as Control in Multi-path Environments (Supplementary Material)

Tristan Deleu^{1,3}

Padideh Nouri²

Nikolay Malkin¹

Doina Precup^{2,4}

Yoshua Bengio¹

Mila – Quebec AI Institute

¹Université de Montréal ²McGill University ³Valence Labs ⁴Google DeepMind

奖励修正

定理 3.1 (基于蒂亚普金等, 224 年; 定理 1)。设 $P_B(\cdot | s')$ 为任意后向转移概率 (即, 在 $\mathcal{G}$ 中 $s' \neq s_0$ 的父节点上的分布)。设 $r(s, s')$ 为通过 P_B 修正的 MDP 的奖励函数, 满足对于任何轨迹 $\tau = (s_0, s_1, \dots, s_T, s_f)$:

$$\sum_{t=0}^T r(s_t, s_{t+1}) = -\mathcal{E}(s_T) + \alpha \sum_{t=0}^{T-1} \log P_B(s_t | s_{t+1}), \quad (8)$$

其中我们使用了约定 $s_{T+1} = s_f$ 。那么与最优策略 π_{MaxEnt}^* ((3) 的解) 相关的终止状态分布满足 $\pi^*(x) \propto \exp(-\mathcal{E}(x)/\alpha)$ 。

证明。回忆自齐伯特 [2010], 哈诺贾等 [2017], 最大化 (3) 的最优策略是

$$\pi_{\text{MaxEnt}}^*(s' | s) = \exp \left(\frac{1}{\alpha} (Q_{\text{soft}}^*(s, s') - V_{\text{soft}}^*(s)) \right), \quad (16)$$

其中软值函数 Q_{soft}^* 并满足适应于我们 V_{soft}^* 的确定性软 MDP 的软 Bellman 最优性方程:

$$Q_{\text{soft}}^*(s, s') = r(s, s') + V_{\text{soft}}^*(s') \quad (17)$$

$$V_{\text{soft}}^*(s') = \alpha \log \sum_{s'' \in \text{Ch}(s')} \exp \left(\frac{1}{\alpha} Q_{\text{soft}}^*(s', s'') \right). \quad (18)$$

根据与 π_{MaxEnt}^* 相关联的终止状态分布的定义, 在 (5) 中, 对于任何终止状态 $x \in \mathcal{X}$:

$$\pi^*(x) = \sum_{\tau: s_0 \rightsquigarrow x} \prod_{t=0}^{T_\tau} \pi_{\text{MaxEnt}}^*(s_{t+1} | s_t) \quad (19)$$

$$= \sum_{\tau: s_0 \rightsquigarrow x} \exp \left[\frac{1}{\alpha} \sum_{t=0}^{T_\tau} (Q_{\text{soft}}^*(s_t, s_{t+1}) - V_{\text{soft}}^*(s_t)) \right] \quad (20)$$

$$= \sum_{\tau: s_0 \rightsquigarrow x} \exp \left[\frac{1}{\alpha} \sum_{t=0}^{T_\tau} (r(s_t, s_{t+1}) + V_{\text{soft}}^*(s_{t+1}) - V_{\text{soft}}^*(s_t)) \right] \quad (21)$$

$$= \sum_{\tau: s_0 \rightsquigarrow x} \exp \left[\frac{1}{\alpha} \left(\sum_{t=0}^{T_\tau} r(s_t, s_{t+1}) + \underbrace{V_{\text{soft}}^*(s_f) - V_{\text{soft}}^*(s_0)}_{=0} \right) \right] \quad (22)$$

$$= \sum_{\tau: s_0 \rightsquigarrow x} \exp \left[\frac{1}{\alpha} \left(-\mathcal{E}(x) + \alpha \sum_{t=0}^{T_\tau-1} \log P_B(s_t | s_{t+1}) - V_{\text{soft}}^*(s_0) \right) \right] \quad (23)$$

$$= \exp \left[\frac{1}{\alpha} (-\mathcal{E}(x) - V_{\text{soft}}^*(s_0)) \right] \underbrace{\sum_{\tau: s_0 \rightsquigarrow x} \prod_{t=0}^{T_\tau-1} P_B(s_t | s_{t+1})}_{=1} \quad (24)$$

$$= \frac{\exp(-\mathcal{E}(x)/\alpha)}{\exp(V_{\text{soft}}^*(s_0)/\alpha)} \propto \exp(-\mathcal{E}(x)/\alpha), \quad (25)$$

在 (24) 中我们利用了以下事实： P_B 诱导了一个概率分布于导致任何终止状态的完整轨迹上 x ；参见 [Bengio 等, 2023, 引理 5] 对该结果的证明。 $\square$

附录 B 最大熵 RL 与 GFlowNet 目标之间的等价关系

在本节中，我们将详细阐述所有新的结果，这些结果建立了最大熵 RL 和 GFlowNet 目标之间的等价关系，并给出了它们的证明。我们在表 1 中总结了这些结果及其对应的命题和证明。本文中考虑的所有目标都采取（期望）最小二乘 $\mathcal{L}(\cdot) = \frac{1}{2} \mathbb{E}_{\pi_b} [\Delta^2(\cdot)]$ 的形式，其中 $\Delta(\cdot)$ 是一个依赖于算法的残差项，而 π_b 是对适当量的概率分布（即，轨迹或转换）；参见第 3.2 节中的 PCL 及 SubTB 目标示例。在本节中，为了简单起见，我们将仅使用残差而不是目标本身。我们在图 6 中总结了不同的残差及其对应关系。

表 1: 附录 B 中等价结果及其证明的摘要。

MaxEnt RL	GFlowNet	Proposition	Proof
PCL [Nachum et al., 2017]	SubTB [Madan et al., 2023]	Proposition 3.2	App. B.1
SQL [Haarnoja et al., 2017]	DB [Bengio et al., 2023]	Corollary B.1	App. B.2
SQL* [Haarnoja et al., 2017]	FL-DB [Pan et al., 2023a]	Proposition B.3	App. B.4
π -SQL* (Section 3.3)	M-DB [Deleu et al., 2022]	Proposition 3.3	App. B.3

附录 B.1 PCL 与 SubTB 之间的等价关系

命题 3.2. 子轨迹平衡目标 (GFlowNet; Madan 等人, 2023) 与路径一致性学习目标 (MaxEnt RL; Nachum 等人, 2017) 在软 MDP 上定义的奖励函数 (9) 成正比，具体而言，

$\mathcal{L}_{\text{PCL}}(\theta, \phi) = \alpha^2 \mathcal{L}_{\text{SubTB}}(\theta, \phi)$ ，其对应关系如下

$$\pi_\theta(s' | s) = P_F^\theta(s' | s) \quad V_{\text{soft}}^\phi(s) = \alpha \log F_\phi(s). \quad (11)$$

证明。设 $\tau = (s_m, s_{m+1}, \dots, s_n)$ 为一个子轨迹，其中 s_n 可能是终止状态 s_f 。首先回顾路径一致性学习 (PCL; Nachum 等人, 2017) 和子轨迹平衡 (SubTB; Madan 等人, 2023, Malkin 等人, 2022) 目标的定义。一方面，PCL 目标鼓励策略 π_θ 由参数 θ 表示与价值函数 V_{soft}^ϕ 由参数 ϕ 表示之间的一致性：

$$\Delta_{\text{PCL}}(\tau; \theta, \phi) = -V_{\text{soft}}^\phi(s_m) + V_{\text{soft}}^\phi(s_n) + \sum_{t=m}^{n-1} (r(s_t, s_{t+1}) - \alpha \log \pi_\theta(s_{t+1} | s_t)). \quad (26)$$

另一方面，SubTB 目标也鼓励某种形式的一致性，但这次是在策略（前向转移概率） P_F^θ 由参数 θ 表示与流函数 F_ϕ 由参数 ϕ 表示之间。我们将稍后给出其残差的形式，因为它依赖于轨迹 τ 。最后，回忆一下软 MDP 的奖励函数由 (9) 定义，以便满足应用定理 3.1 所需的奖励修正，遵循与 [Tiapkin 等人, 2024] 相同的分解

$$r(s_t, s_{t+1}) = \alpha \log P_B(s_t | s_{t+1}) \quad r(s_T, s_f) = -\mathcal{E}(s_T). \quad (27)$$




图 6: MaxEnt RL (顶部, 每个框内) 和 GFlowNet (底部, 每个框内) 目标之间的等价性的总结, 使用图 2 中的分类。所有目标都可以写作 $\mathcal{L}(\cdot) = \frac{1}{2} \mathbb{E}_{\pi_b}[\Delta^2(\cdot)]$, 其中 π_b 是对适当量 (即轨迹或转换) 的分布。终端奖励设置对应于 $r(s_t, s_{t+1}) = \alpha \log P_B(s_t | s_{t+1})$ & $r(s_T, s_f) = -\mathcal{E}(s_T)$ (第 3.2 节), 而中间奖励设置对应于 $r(s_t, s_{t+1}) = -\mathcal{E}(s_t \rightarrow s_{t+1}) + \alpha \log P_B(s_t | s_{t+1})$ (如果 $\mathcal{E}(s_t \rightarrow s_{t+1}) = \mathcal{E}(s_{t+1}) - \mathcal{E}(s_t)$ 则为 $\mathcal{S} \equiv \mathcal{X}$, 第 3.3 节) & $r(s_T, s_f) = 0$ (附录 B.4)

为了展示 $\mathcal{L}_{\text{PCL}}$ 和 $\mathcal{L}_{\text{SubTB}}$ 之间的等价性，我们只需要展示它们相应残差的等价性，通过将奖励替换为其上述定义。我们将使用 (11) 中 PCL 的策略/价值函数与 SubTB 的策略/流函数之间的对应关系。我们考虑两种情况：

- 如果 $s_n \neq s_f$ 不是终止状态，则 SubTB 的残差可以写作

$$\Delta_{\text{SubTB}}(\tau; \theta, \phi) = \log \frac{F_\phi(s_n) \prod_{t=m}^{n-1} P_B(s_t | s_{t+1})}{F_\phi(s_m) \prod_{t=m}^{n-1} P_F^\theta(s_{t+1} | s_t)}, \quad (28)$$

其中 P_B 是一个反向转移概率。尽管通常可能学习 P_B [Malkin 等人, 2022]，但我们在这里将其视为固定的。将 (11) 代入残差 Δ_{PCL} :

$$\begin{aligned} \Delta_{\text{PCL}}(\tau; \theta, \phi) &= -V_{\text{soft}}^\phi(s_m) + V_{\text{soft}}^\phi(s_n) + \alpha \sum_{t=m}^{n-1} (\log P_B(s_t | s_{t+1}) - \log \pi_\theta(s_{t+1} | s_t)) \\ &= -\alpha \log F_\phi(s_m) + \alpha \log F_\phi(s_n) + \alpha \sum_{t=m}^{n-1} (\log P_B(s_t | s_{t+1}) - \log P_F^\theta(s_{t+1} | s_t)) \\ &= \alpha \log \frac{F_\phi(s_n) \prod_{t=m}^{n-1} P_B(s_t | s_{t+1})}{F_\phi(s_m) \prod_{t=m}^{n-1} P_F^\theta(s_{t+1} | s_t)} = \alpha \Delta_{\text{SubTB}}(\tau; \theta, \phi). \end{aligned} \quad (29)$$

- 若 $s_n = s_f$ ，则子轨迹平衡目标中的残差 Δ_{SubTB} 必须表示为

$$\Delta_{\text{SubTB}}(\tau; \theta, \phi) = \log \frac{\exp(-\mathcal{E}(s_{n-1})/\alpha) \prod_{t=m}^{n-2} P_B(s_t | s_{t+1})}{F_\phi(s_m) \prod_{t=m}^{n-1} P_F^\theta(s_{t+1} | s_t)}, \quad (30)$$

因为边界条件也必须被强制执行 [Malkin 等人, 2022]。根据价值函数的定义，我们还可以 $V^\phi(s_f) = 0$ 强制要求 V^ϕ 。因此

$$\begin{aligned} \Delta_{\text{PCL}}(\tau; \theta, \phi) &= -V_{\text{soft}}^\phi(s_m) + V_{\text{soft}}^\phi(s_f) - (\mathcal{E}(s_{n-1}) + \alpha \log \pi_\theta(s_f | s_{n-1})) \\ &\quad + \alpha \sum_{t=m}^{n-2} (\log P_B(s_t | s_{t+1}) - \log \pi_\theta(s_{t+1} | s_t)) \end{aligned} \quad (31)$$

$$\begin{aligned} &= -\alpha \log F_\phi(s_m) - \mathcal{E}(s_{n-1}) - \alpha \log P_F^\theta(s_f | s_{n-1}) \\ &\quad + \alpha \sum_{t=m}^{n-2} (\log P_B(s_t | s_{t+1}) - \log P_F^\theta(s_{t+1} | s_t)) \end{aligned} \quad (32)$$

$$= \alpha \Delta_{\text{SubTB}}(\tau; \theta, \phi). \quad (33)$$

请注意，轨迹平衡目标仅在完整轨迹层面操作 [Malkin 等人, 2022]，这对应于其中 $s_m = s_0$ 是初始状态的情况。

这完成了证明，表明 $\mathcal{L}_{\text{PCL}}(\theta, \phi) = \alpha^2 \mathcal{L}_{\text{SubTB}}(\theta, \phi)$ 。 $\square$

B.2 SQL 与 DB 之间的等价性

以下结果建立了 SQL 和 DB 目标之间的等价性，可以视为 Nachum 等人提出的统一 PCL 视角下命题 3.2 的直接推论 [2017]。为了完整性，我们将此作为独立的结果进行陈述和证明。

推论 B.1。 详细平衡目标 (GFlowNet; Bengio 等人, 2023) 与软 Q 学习目标 (最大熵 RL; Haarnoja 等人, 2017) 在定义于 (9) 的奖励函数下的软 MDP 成比例，在某种意义上 $\mathcal{L}_{\text{SQL}}(\theta) = \alpha^2 \mathcal{L}_{\text{DB}}(\theta)$ ，具有以下对应关系

$$F_\theta(s) = \sum_{s'' \in \text{Ch}(s)} \exp\left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s'')\right) \quad P_F^\theta(s' | s) \propto \exp\left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s')\right). \quad (34)$$

证明。设 $s \rightarrow s'$ 为软 MDP 中的一个转移，其中 s' 可能是终止状态。回忆一下，在 SQL 目标中的残差依赖于由 θ 参数化的 Q 函数 Q_{soft}^θ ：

$$\Delta_{\text{SQL}}(s, s'; \theta) = Q_{\text{soft}}^\theta(s, s') - (r(s, s') + V_{\text{soft}}^\theta(s')), \quad (35)$$

$$\text{其中 } V_{\text{soft}}^\theta(s') \triangleq \alpha \log \sum_{s'' \in \text{Ch}(s')} \exp \left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s', s'') \right). \quad (36)$$

当 $s' = s_f$ 为终止状态时，则 $V_{\text{soft}}^\theta(s') = 0$ 。另一方面，DB 目标中残差的确切形式将在下面给出，但总是依赖于一个前向转移概率 P_F^θ 和一个状态流函数 F_θ ，我们假设它们共享参数 θ 。我们考虑两种情况：

- 如果 $s' \neq s_f$ 不是终止状态，则 DB 目标中的残差由下式给出：

$$\Delta_{\text{DB}}(s, s'; \theta) = \log \frac{F_\theta(s) P_F^\theta(s' | s)}{F_\theta(s') P_B(s | s')}. \quad (37)$$

根据 (9) 中的奖励函数定义，我们知道 $r(s, s') = \alpha \log P_B(s | s')$ 。因此，我们可以证明 SQL 和 DB 的残差彼此成比例：

$$\Delta_{\text{SQL}}(s, s'; \theta) = Q_{\text{soft}}^\theta(s, s') - r(s, s') - \alpha \log \sum_{s'' \in \text{Ch}(s')} \exp \left[\frac{1}{\alpha} Q_{\text{soft}}^\theta(s', s'') \right] \quad (38)$$

$$= Q_{\text{soft}}^\theta(s, s') - \alpha \log P_B(s | s') - \alpha \log \sum_{s'' \in \text{Ch}(s')} \exp \left[\frac{1}{\alpha} Q_{\text{soft}}^\theta(s', s'') \right] \quad (39)$$

$$\begin{aligned} &= \alpha \log \left(\exp \left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s') \right) \right) - \alpha \log P_B(s | s') - \alpha \log \sum_{s'' \in \text{Ch}(s')} \exp \left[\frac{1}{\alpha} Q_{\text{soft}}^\theta(s', s'') \right] \\ &\quad - \alpha \log \sum_{s'' \in \text{Ch}(s)} \exp \left[\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s'') \right] + \alpha \log \sum_{s'' \in \text{Ch}(s)} \exp \left[\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s'') \right] \end{aligned} \quad (40)$$

$$= \alpha \left[\log P_F^\theta(s' | s) + \log F_\theta(s) - \log P_B(s | s') - \log F_\theta(s') \right] \quad (41)$$

$$= \alpha \Delta_{\text{DB}}(s, s'; \theta), \quad (42)$$

其中我们使用了以下对应关系： Q_{soft}^θ , P_F^θ 和 F_θ ：

$$F_\theta(s') = \sum_{s \in \text{Pa}(s')} \exp \left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s') \right) \quad P_F^\theta(s' | s) \propto \exp \left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s') \right). \quad (43)$$

- 如果 $s' = s_f$ 是终止状态，则 DB 目标中的残差为：

$$\Delta_{\text{DB}}(s, s_f; \theta) = \log \frac{F_\theta(s) P_F^\theta(s_f | s)}{\exp(-\mathcal{E}(s)/\alpha)}. \quad (44)$$

再次根据我们在 (9) 中对软 MDP 奖励函数的定义，我们知道终止转移的奖励为 $r(s, s_f) = -\mathcal{E}(s)$ 。因此，我们也可以证明在这种情况下两个残差之间的关系：

$$\Delta_{\text{SQL}}(s, s_f; \theta) = Q_{\text{soft}}^\theta(s, s_f) - r(s, s_f) \quad (45)$$

$$= Q_{\text{soft}}^\theta(s, s_f) + \mathcal{E}(s) \quad (46)$$

$$= \alpha \log \left(\exp \left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s_f) \right) \right) + \mathcal{E}(s) \quad (47)$$

$$\begin{aligned} &\quad - \alpha \log \sum_{s'' \in \text{Ch}(s)} \exp \left[\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s'') \right] + \alpha \log \sum_{s'' \in \text{Ch}(s)} \exp \left[\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s'') \right] \\ &= \alpha \left[\log P_F^\theta(s_f | s) + \log F_\theta(s) + \frac{\mathcal{E}(s)}{\alpha} \right] \end{aligned} \quad (48)$$

$$= \alpha \Delta_{\text{DB}}(s, s_f; \theta), \quad (49)$$

其中采用了相同的对应关系 Q_{soft}^θ , P_F^θ ，和 F_θ 如上所述。

这完成了证明，表明 $\mathcal{L}_{\text{SQL}}(\theta) = \alpha^2 \mathcal{L}_{\text{DB}}(\theta)$ 。

□

需要注意，Tiapkin 等人 [2024] 通过一种对抗架构视角建立了 SQL 与 DB 之间的类似联系 [Wang 等, 2016]，其中 Q 函数必须分解为（符号已适应本文）

$$Q^\theta(s, s') = V^\theta(s) + A^\theta(s, s') - \log \sum_{s'' \in \text{Ch}(s)} \exp(A^\theta(s, s'')), \quad (50)$$

其中 $A^\theta(s, s')$ 是优势函数。他们建立的连接一方面在于状态流与 V^θ 之间，另一方面则在于策略与 A^θ 之间，通过

$$\log F_\theta(s) = V^\theta(s) = \log \sum_{s'' \in \text{Ch}(s)} \exp(Q^\theta(s, s'')) \quad (51)$$

$$\log P_F^\theta(s' | s) = A^\theta(s, s') - \log \sum_{s'' \in \text{Ch}(s)} \exp(A^\theta(s, s'')). \quad (52)$$

这与我们的结果不同之处在于推论 B.1 并未明确要求一个独立的优势函数。然而，我们注意到这两个结果实际上彼此等价，因为 (51) 直接对应于推论 B.1 中的 (34)（其中包含 $\alpha = 1$ ），并且从 (52) 开始：

$$\log P_F^\theta(s' | s) = A^\theta(s, s') - \log \sum_{s'' \in \text{Ch}(s)} \exp(A^\theta(s, s'')) \quad (53)$$

$$\begin{aligned} &= \left[Q^\theta(s, s') - V^\theta(s) + \log \sum_{s'' \in \text{Ch}(s)} \exp(A^\theta(s, s'')) \right] - \log \sum_{s'' \in \text{Ch}(s)} \exp(A^\theta(s, s'')) \\ &= Q^\theta(s, s') - V^\theta(s) = Q^\theta(s, s') - \log \sum_{s'' \in \text{Ch}(s)} \exp(Q^\theta(s, s'')), \end{aligned} \quad (54)$$

这也对应于推论 B.1 中的 (34)。通过决斗架构的连接更接近 DB，当策略和状态流网络由两个独立的网络参数化时。

B.3

π 等价性 -SQL 和 修改后的数据库

命题 B.2. 假设软 MDP 的所有状态都是终止状态（即连接到终止状态 s_f ），并且对于所有 $s \in \mathcal{S}$ ，奖励函数满足 $r(s, s_f) = 0$ 。那么，Soft Q-Learning [Haarnoja 等, 2017] 的目标可以表示为策略 π_θ 的函数，该策略由参数 θ 定义。这个目标由 $\mathcal{L}_\pi\text{-SQL}(\theta) = \frac{1}{\alpha}$ 给出 $\mathbb{E}_{\pi_b}[\Delta_{\pi\text{-SQL}}^2(s, s'; \theta)]$ ，其中 π_b 是状态转移上的任意策略 $s \rightarrow s'$ ，满足 $s' \neq s_f$ ，并且

$$\Delta_{\pi\text{-SQL}}(s, s'; \theta) = \alpha \left[\log \pi_\theta(s' | s) - \log \pi_\theta(s_f | s) + \log \pi_\theta(s_f | s') \right] - r(s, s'). \quad (55)$$

证明。回忆一下，Soft Q-Learning 的目标可以通过 Q 函数 Q_{soft}^θ 来表示，该 Q 函数由参数 θ 定义，即 $\mathcal{L}_{\text{SQL}}(\theta) = \frac{1}{\alpha}$

$$\Delta_{\text{SQL}}(s, s'; \theta) = Q_{\text{soft}}^\theta(s, s') - (r(s, s') + V_{\text{soft}}^\theta(s')), \quad (56)$$

$$\text{其中 } V_{\text{soft}}^\theta(s') \triangleq \alpha \log \sum_{s'' \in \text{Ch}(s')} \exp \left[\frac{1}{\alpha} Q_{\text{soft}}^\theta(s', s'') \right]. \quad (57)$$

由于我们假设 $r(s, s_f) = 0$ ，我们可以强制 $r(s, s_f) = 0$ 制在 Q 函数的参数化中 Q^θ 成立。If we define a policy π_θ as

$$\pi_\theta(s' | s) \triangleq \exp \left[\frac{1}{\alpha} (Q_{\text{soft}}^\theta(s, s') - V_{\text{soft}}^\theta(s)) \right], \quad (58)$$

那么根据我们上面的观察，我们特别有 $\pi_\theta(s_f | s) = \exp(-V_{\text{soft}}^\theta(s)/\alpha)$ ，并且我们可以将出现在 (56) 中的价值函数之间的差异写为

$$Q_{\text{soft}}^\theta(s, s') - V_{\text{soft}}^\theta(s') = Q_{\text{soft}}^\theta(s, s') - V_{\text{soft}}^\theta(s) + V_{\text{soft}}^\theta(s) - V_{\text{soft}}^\theta(s') \quad (59)$$

$$= \alpha [\log \pi_\theta(s' | s) - \log \pi_\theta(s_f | s) + \log \pi_\theta(s_f | s')] \quad (60)$$

这完成了证明。

□

命题 3.3. 假设软 MDP 的所有状态都是终止状态 $\mathcal{S} \equiv \mathcal{X}$ 。修改后的详细平衡目标 (GFlowNet; Deleu 等, 2022) 与 Soft Q-Learning 目标成比例, 该目标具有策略参数化 (最大熵 RL; π -SQL) 在软 MDP 上, 奖励函数定义在 (12) 中, 具体来说是 $\mathcal{L}_{\pi\text{-SQL}}(\theta) = \alpha^2 \mathcal{L}_{\text{M-DB}}(\theta)$, 其中 $\pi_\theta(s' | s) = P_F^\theta(s' | s)$ 。

证明。设 $s \rightarrow s'$ 是软 MDP 中的一个转换。为了展示 $\mathcal{L}_{\pi\text{-SQL}}$ 和 $\mathcal{L}_{\text{M-DB}}$ 之间的等价性, 只需展示它们对应的残差 (13) 和 (14) 之间的等价性。回忆一下, (12) 中的奖励函数定义为

$$r(s_t, s_{t+1}) = \mathcal{E}(s_t) - \mathcal{E}(s_{t+1}) + \alpha \log P_B(s_t | s_{t+1}) \quad r(s_T, s_f) = 0. \quad (61)$$

将残差中的奖励替换为 $\Delta \pi\text{-SQL}$, 我们得到

$$\begin{aligned} \Delta_{\pi\text{-SQL}}(s, s'; \theta) &= \alpha [\log \pi_\theta(s' | s) - \log \pi_\theta(s_f | s) + \log \pi_\theta(s_f | s')] - r(s, s') \\ &= \alpha [\log \pi_\theta(s' | s) - \log \pi_\theta(s_f | s) + \log \pi_\theta(s_f | s')] - [\mathcal{E}(s) - \mathcal{E}(s') + \alpha \log P_B(s | s')] \\ &= \alpha \left[-\frac{\mathcal{E}(s)}{\alpha} + \log \pi_\theta(s' | s) + \log \pi_\theta(s_f | s') + \frac{\mathcal{E}(s')}{\alpha} - \log P_B(s | s') - \log \pi_\theta(s_f | s) \right] \\ &= \alpha \left[-\frac{\mathcal{E}(s)}{\alpha} + \log P_F^\theta(s' | s) + \log P_F^\theta(s_f | s') + \frac{\mathcal{E}(s')}{\alpha} - \log P_B(s | s') - \log P_F^\theta(s_f | s) \right] \\ &= -\alpha \log \frac{\exp(-\mathcal{E}(s')/\alpha) P_B(s | s') P_F^\theta(s_f | s')}{\exp(-\mathcal{E}(s)/\alpha) P_F^\theta(s' | s) P_F^\theta(s_f | s)} = -\alpha \Delta_{\text{M-DB}}(s, s'; \theta) \end{aligned}$$

这完成了证明, 表明 $\mathcal{L}_{\pi\text{-SQL}}(\theta) = \alpha^2 \mathcal{L}_{\text{M-DB}}(\theta)$ 。 □

附录 B.4 SQL 与向前展望平衡损失之间的等价性

我们将把命题 3.3 的结果推广到情形 $\mathcal{X} \neq \mathcal{S}$, 但在轨迹上仍然可以获得中间奖励。假设对于任何完整的轨迹 $\tau = (s_0, s_1, \dots, s_T, s_f)$, 在 s_T 处的能量函数可以分解为一系列中间奖励之和 [Pan 等人, 2233a]

$$\mathcal{E}(s_T) = \sum_{t=0}^{T-1} \mathcal{E}(s_t \rightarrow s_{t+1}), \quad (62)$$

为了简化记号, 我们将重载符号 $\mathcal{E}$ 。在这种情况下, 我们可以定义修正后的奖励, 以满足定理 3.1 的条件

$$r(s_t, s_{t+1}) = -\mathcal{E}(s_t \rightarrow s_{t+1}) + \alpha \log P_B(s_t | s_{t+1}) \quad r(s_T, s_f) = 0. \quad (63)$$

这种奖励塑形方式类似于第 3.3 节引入的方式。向前展望平衡损失 (FL-DB; Pan 等人, 2233a) 类似于 DB 的定义, 不同之处在于流函数对应于相对于 $\mathcal{E}(s_t \rightarrow s_{t+1})$ 的未知偏移量, 该偏移量已知, 因此无需学习。对于某个转移 $s \rightarrow s'$ 使得

$s' \neq s_f$, 相应的残差可以表示为

$$\Delta_{\text{FL-DB}}(s, s'; \theta) = \log \frac{\tilde{F}_\theta(s') P_B(s | s')}{\tilde{F}_\theta(s) P_F^\theta(s' | s)} - \frac{\mathcal{E}(s \rightarrow s')}{\alpha}, \quad (64)$$

其中 P_F^θ 是策略 (前向转移概率), 而 $\tilde{F}_\theta$ 是一个由 θ 参数化的偏移状态流函数。需要注意的是, 与 DB 不同, 在 FL-DB 中, 边界条件不再有显式的残差, 因为这一点已经通过 (64) 得到了体现。以下命题建立了 SQL 和 FL-DB 之间的等价性, 类似于推论 B.1 和命题 3.3。

命题 B.3. 前瞻详尽平衡目标 (GFlowNet; Pan 等人, 2023a) 与软化马尔可夫决策过程上的软 Q 学习目标 (MaxEnt RL; Haarnoja 等人, 2017) 成正比, 其中奖励函数定义在公式 (63) 中, 具体而言, $\mathcal{L}_{\text{SQL}}(\theta) = \alpha^2 \mathcal{L}_{\text{FL-DB}}(\theta)$, 其对应关系如下

$$\tilde{F}_\theta(s) = \sum_{s'' \in \text{Ch}(s)} \exp\left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s'')\right) \quad P_F^\theta(s' | s) \propto \exp\left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s')\right). \quad (65)$$

证明。证明类似于附录 B.2 中的证明。令 $s \rightarrow s'$ 为软化马尔可夫决策过程中的一个转移，其中 $s' \neq s_f$ 。回忆一下，在 SQL 目标中的残差是

$$\Delta_{\text{SQL}}(s, s'; \theta) = Q_{\text{soft}}^\theta(s, s') - (r(s, s') + V_{\text{soft}}^\theta(s')), \quad (66)$$

$$\text{其中 } V_{\text{soft}}^\theta(s') \triangleq \alpha \log \sum_{s'' \in \text{Ch}(s')} \exp\left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s', s'')\right). \quad (67)$$

With our choice of reward function in (63), we know that $r(s, s') = -\mathcal{E}(s \rightarrow s') + \alpha \log P_B(s | s')$. We can therefore show that the residuals of SQL and FL-DB are proportional to one-another:

$$\Delta_{\text{SQL}}(s, s'; \theta) = Q_{\text{soft}}^\theta(s, s') - (r(s, s') + V_{\text{soft}}^\theta(s')) \quad (68)$$

$$= Q_{\text{soft}}^\theta(s, s') + \mathcal{E}(s \rightarrow s') - \alpha \log P_B(s | s') - \alpha \log \sum_{s'' \in \text{Ch}(s')} \exp\left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s', s'')\right) \quad (69)$$

$$\begin{aligned} &= Q_{\text{soft}}^\theta(s, s') - \alpha \log \sum_{s'' \in \text{Ch}(s)} \exp\left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s'')\right) + \mathcal{E}(s \rightarrow s') - \alpha \log P_B(s | s') \\ &\quad + \alpha \log \sum_{s'' \in \text{Ch}(s)} \exp\left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s, s'')\right) - \alpha \log \sum_{s'' \in \text{Ch}(s')} \exp\left(\frac{1}{\alpha} Q_{\text{soft}}^\theta(s', s'')\right) \end{aligned} \quad (70)$$

$$= \alpha \left[\log P_F^\theta(s' | s) - \log P_B(s | s') + \log \tilde{F}_\theta(s) - \log \tilde{F}_\theta(s') + \frac{\mathcal{E}(s \rightarrow s')}{\alpha} \right] \quad (71)$$

$$= -\alpha \Delta_{\text{FL-DB}}(s, s'; \theta). \quad (72)$$

其中我们使用了 $\tilde{F}_\theta, P_F^\theta$ 和 Q_{soft}^θ 之间的对应关系，这些对应关系来自公式 (65)。这完成了证明，表明 $\mathcal{L}_{\text{SQL}}(\theta) = -\alpha^2 \mathcal{L}_{\text{FL-DB}}(\theta)$ 。

有趣的是，状态流与策略 (GFlowNet) 和 Q 函数 (MaxEnt RL) 之间的对应关系 (65) 与推论 B.1 中的关系完全相同。

附录 C 实验细节

对于所有算法和所有环境（除非另有说明），我们保持相同的探索计划、目标网络更新频率（如果适用）以及回放缓冲区，以避免将有利的性能归因于这些组件中的任何一个。探索使用简单的 ε 采样方案进行，其中动作以概率 $1 - \varepsilon$ 从当前策略中采样，并以概率 ε 随机均匀地采样。所有算法均经过 100k 次迭代训练，且 ε 在前 50k 次迭代中从 $\varepsilon = 1$ 递减到 $\varepsilon = 0.1$ 。所有算法都使用目标网络，除了 TB/PCL，目标网络每 1000 次迭代更新一次。我们对所有算法使用具有 100k 容量的简单循环缓冲区（TB/PCL 使用轨迹缓冲区，而不是转换缓冲区）。超参数搜索仅针对所有网络的学习率进行，使用简单的网格搜索。

附录 C.1 离散因子图上的概率推理

给定一个具有固定结构的因子图，涉及 d 个随机变量 $(V_1, \dots, V_d)$ ，目标是从吉布斯分布 $P(\mathbf{v}) \propto \exp(-\mathcal{E}(\mathbf{v}))$ 中抽样出这些变量的一个完整赋值 $\mathbf{v}$ ，其中能量函数由

$$\mathcal{E}(v_1, \dots, v_d) = - \sum_{m=1}^M \psi_m(\mathbf{v}_{[m]}), \quad (73)$$

其中 ψ_m 是因子图中的第 m 个因子，而 $\mathbf{v}_{[m]}$ 表示属于此因子的变量值。这些因子 ψ_m 是固定的，并通过与 Buesing 等人相同的过程随机生成 [2020]。每个变量 V_i 假设为离散型，并可取 K 个可能值之一。总体而言，这意味着样本空间中的元素数量为 K^d 。

软 MDP 的状态是一个（可能部分的）值分配，*e.g.*, $(0, \cdot, 1, 0, \cdot, \cdot)$ ，其中 $\cdot$ 表示尚未赋值的变量。初始状态 $s_0 = (\cdot, \cdot, \dots, \cdot)$ 是指没有任何变量被赋值的状态。一个动作包括选择一个尚未赋值的变量（具有一个 $\cdot$ ），并为其分配一个值，共有 K 个可选值。当所有变量都被赋值后，过程终止，这意味着所有完整的轨迹长度为 d 。这与 Buesing 等人提出的 MDP [2020] 不同，因为他们是按照预先确定的固定顺序来赋值变量的，使得 MDP 具有树状结构。

Buesing et al. [2020] defined an intermediate reward function corresponding to a decomposition of the energy (73) as $\mathcal{E}(\mathbf{v}) = \sum_{t=0}^{d-1} \mathcal{E}(s_t \rightarrow s_{t+1})$, where $\mathbf{v}$ is the terminating state of a complete trajectory $(s_0, s_1, \dots, s_d, s_f)$ (*i.e.*, $s_d = \mathbf{v}$), and with the partial energies defined as

$$\mathcal{E}(s_t \rightarrow s_{t+1}) = - \sum_{m=1}^M \psi_m(\mathbf{v}_{[m]}) \mathbb{1}(i \in [m] \ \& \ \mathbf{v}_{[m]} \subseteq s_{t+1}), \quad (74)$$

if the transition $s_t \rightarrow s_{t+1}$ corresponds to assigning the value of a particular variable V_i . In other words, the partial energy corresponds to computing all the factors as soon as all the necessary information is available (*i.e.*, all the values of the input variables of the factors have been assigned, and V_i that was just assigned a value is one of the input variables of the factors).

C.2 贝叶斯网络的结构学习

给定 d 个连续随机变量 $(X_1, \dots, X_d)$ ，有向无环图 (DAG) G 和参数 θ ，贝叶斯网络基于 G 的结构来表示联合分布中的条件独立性。

$$P(X_1, \dots, X_d; \theta) = \prod_{j=1}^d P(X_j \mid \text{Pa}_G(X_j); \theta_k), \quad (75)$$

其中 $\text{Pa}_G(X_j)$ 表示在图 G 中变量 X_j 的父节点变量。我们假设所有条件分布都是线性高斯分布。贝叶斯结构学习的目标是近似 DAG 上的后验分布： $P(G \mid \mathcal{D}) \propto P(\mathcal{D} \mid G)P(G)$ ，其中 $P(\mathcal{D} \mid G)$ 是边缘似然，而 $P(G)$ 是图上的先验，

这里假设为均匀分布。我们的实验在计算边缘似然的方式上有所不同，要么基于 BGe 评分 [Geiger 和 Heckerman, 1994]，要么基于线性高斯评分 [Nishikawa-Toomey 等, 2023]。我们遵循 Deleu 等人的实验设置。

[2022]，其中数据是从随机生成的真实贝叶斯网络 G^* 中生成的，使用 Erdős- Rényi 方案采样，平均每个节点有 1 条边。我们从这个贝叶斯网络中使用祖先采样生成了 100 个观测值。我们对 20 个不同的随机种子重复了这一过程。

软 MDP 的状态对应于一个有向无环图 G 超过 d 节点，初始状态为空图 d 节点。动作包括在两个节点之间添加一条有向边，确保该边尚未存在于图中，并且不会引入循环，从而保证 MDP 的所有状态都是有效的有向无环图；存在一个特殊动作，用于指示是否终止并转换到 s_f 。由于所有状态均为有效的有向无环图 (DAG)，这意味着马尔可夫决策过程 (MDP) 的所有状态都是终止状态，我们可以使用 $r(G_t, G_{t+1}) = \mathcal{E}(G_t) - \mathcal{E}(G_{t+1})$ 作为中间奖励，具有合适的能量函数 $\mathcal{E}(G) = \log P(G_0, \mathcal{D}) - \log P(G, \mathcal{D})$ 。德吕等人 [2022] 证明了能量差异可以高效地通过 delta-score 计算得出 [Friedman 和 Koller, 2003]。

附录 C.3 系统发生树生成

我们考虑周等人引入的环境 [2024]，其中用于分析一组生物进化过程的系统发育树 d 物种根据简约准则生成。确实，编码较少变异的树更受青睐，因为它们更有可能表示现实的关系。给定一棵树 T ，其节点为感兴趣的物种，目标分布由以下给出

$$P(T) \propto \exp(-M(T \mid \mathbf{Y})/C), \quad (76)$$

其中 $C = 4$ 是一个固定的常数，而 $M(T \mid \mathbf{Y})$ 是总突变数（也称为简约分数），基于与每个物种相关的生物序列 $\mathbf{Y}$ ；请注意，为了方便起见，我们将能量函数视为 $\mathcal{E}(T) = M(T \mid \mathbf{Y})/C$ （带有 $\alpha = 1$ ）。我们使用了周等人考虑的 8 个数据集集中的 6 个 [2024]；为了完整性，表 2 回顾了这些数据集的统计信息。

表 2: 用于系统发生树生成任务的数据集统计信息。“长度”表示每个物种的生物序列（例如 DNA 序列）的长度。关于这些数据集的详细信息和参考文献，请参阅 [Zhou 等人, 2024]。物种数量表示树中的节点数量，是任务复杂度的一种度量。

Dataset	# Species (d)	Length
DS1	27	1949
DS2	29	2520
DS3	36	1812
DS4	41	1137
DS5	50	378
DS6	50	1133

软 MDP 的状态是一组覆盖所有物种划分的树（树的叶子是物种），其中初始状态对应于每个物种都有一个单节点（叶子）的树 d 。动作由选择两棵树并通过添加根节点将它们合并组成。当集合中只剩下一棵树时，过程终止，意味着所有完整的轨迹具有相同的长度 $d - 1$ 。样本空间的大小是 $(2d - 3)!!$ （对于 $d \geq 2$ ）。

为了将能量函数分解为 $\mathcal{E}(T) = \sum_{t=0}^{d-2} \mathcal{E}(s_t \rightarrow s_{t+1})$ ，其中 T 是一个完整轨迹的终止状态 $(s_0, s_1, \dots, s_{d-1}, s_f)$ ，我们可以利用周等人 [2024] 提出的观察结果，即总的突变数量 $M(T | \mathbf{Y})$ 可以分解为 (1) 树根的突变数量和 (2) 左子树和右子树中的总突变数量之和。因此，我们可以使用在转换过程中构建的新树的根节点处的突变数量 $s_t \rightarrow s_{t+1}$ 作为中间能量 $\mathcal{E}(s_t \rightarrow s_{t+1})$ （适当缩放由 C ），这可以通过 Fitch 算法 [周等, 2024] 来计算。

除了图 5 外，我们在图 7 和图 8 中还提供了所有算法和所有数据集的终止状态对数概率与回报之间的相关性的完整视图。每个点对应于使用相应算法找到的终止状态分布采样的树。




图 7: 所有算法的相关性图。从上到下依次为: 轨迹平衡 (TB), 路径一致性学习 (PCL), 详细平衡 (DB), 软 Q 学习 (SQL) 和 SAC。从左到右依次显示 DS1 至 DS3。




图 8: 类似于图 7 的相关性图, 从左到右依次展示 DS4, DS5 和 DS6。