

关于训练 GFlowNets 的发散测度

Tiago da Silva Eliezer de Souza da Silva Diego Mesquita
{tiago.henrique, eliezer.silva, diego.mesquita}@fgv.br
School of Applied Mathematics
Getulio Vargas Foundation
Rio de Janeiro, Brazil

摘要

生成流网络 (GFlowNets) 是一种摊销推断模型, 旨在从可组合对象的未归一化分布中进行采样, 在因果发现、自然语言处理和药物发现等领域的生成建模任务中有广泛应用。传统上, GFlowNets 的训练过程寻求最小化提议 (正向策略) 与目标 (反向策略) 分布之间的预期对数平方差异, 这强制执行某些流匹配条件。尽管这种训练过程与变分推断 (VI) 密切相关, 但直接尝试最小化标准 Kullback-Leibler (KL) 发散会导致已证明有偏且可能高方差的估计器。因此, 我们首先回顾四种发散测度, 即 Renyi- α 's、Tsallis- α 's、逆 KL 和正向 KL, 并在训练 GFlowNets 的背景下设计这些测度的随机梯度的统计有效估计器。然后, 我们验证适当最小化这些发散测度能够得到一个理论上正确且经验有效的训练方案, 通常比先前提出的优化方法更快地收敛。为了实现这一点, 我们基于 REINFORCE 留一法和得分匹配估计器设计控制变量, 以减少学习目标梯度的方差。我们的工作通过缩小 GFlowNets 训练与广义变分近似之间的差距, 为受发散最小化视角启发的算法思想铺平道路。

1 引言

难以处理的分布的近似是机器学习和现代统计学中的一个核心问题 [7, 35]。在强化学习 (RL) 中, 一个常见的目标是根据奖励函数找到一组具有高价值的状态-动作轨迹。这个问题可以被表述为按照奖励比例采样轨迹, 这通常是在环境中难以处理的分布 [3, 9, 38, 50]。类似地, 实用的贝叶斯推断和概率模型计算涉及评估难以处理的后验分布 [36, 77, 101]。在变分推断 (VI) 方法中, 规避这种不可处理性包括在一个参数模型族内寻找目标分布的可处理近似。传统上, 该问题归结为最小化变分近似与目标之间的发散测度, 如 Kullback-Leibler (KL) 发散 [7, 36, 91] 或 Renyi- α 发散 [51, 69]。特别是, 生成流网络 (GFlowNets) [3, 4, 48] 是一个最近提出的适用于组合对象 (如图和文本) 分布的变分近似家族。GFlowNets 已经在因果发现 [15, 16]、自然语言处理 (NLP) [29] 以及化学和生物建模 [3, 32] 的各种应用中取得了经验上的成功。简而言之, GFlowNet 学习了一个迭代生成过程 (IGP) [26], 该过程扩展了目标的支持范围, 在过渡核的充分表达参数化下, 能够产生独立且正确分布的样本 [3, 48]。值得注意的是, 训练 GFlowNets 通常包括通过随机梯度下降 (SGD) 最小化扩展空间上提议分布与目标分布之间的对数平方差 [4, 55], 这与 VI 中常用的最小化发散算法形成对比 [7, 71]。

确实, Malkin 等人 [56] 指出, 对于 GFlowNets 而言, 轨迹平衡 (TB) 损失训练比直接最小化逆向和正向 KL 发散更能逼近目标分布, 特别是在奖励稀疏的情况下。然而, 正如我们在第 3 节中强调的那样, 这些结果可能是由于对发散估计的梯度估计存在偏差和高方差所导致的, 这在依赖于稀疏目标分布的评估协议中可能被忽视。因此, 在第 5 节中, 我们进行了全面的经验研究, 探讨了最小化已知 f-发散测度 (包括逆向和正向 KL) 的有效性, 表明这是一种经常加速 GFlowNets 训练收敛的过程, 相对于其他方法。为了实现这些结果, 我们在第 4 节开发了一组控制变量 (CVs) [63, 70], 用于减少方差而不引入对估计梯度的偏差, 从而提高了优化算法的效率 [76, 84]。总之, 我们的主要贡献如下: 1. 我们通过广泛的实证研究评估了正向和逆向 KL-[47]、Renyi- α [73] 和 Tsallis- α [90] 发散作为 GFlowNets 学习目标的性能, 并指出它们通常优于传统使用的损失函数。2. 我们设计了针对 GFlowNets 发散基目标梯度的控制变量。因此, 可以使用自动微分框架 [68] 有效地评估优化目标, 实验结果展示了相应估计器方差的显著降低。3. 我们建立了 GFlowNets 与 VI 之间的理论联系, 超越了有限支持测度的设置 [56, 111], 并为任意拓扑空间建立了结果。

2 重新审视 GFlowNets 与 VI 的关系

最初, 我们回顾了 Lahlou 等人 [48] 关于 GFlowNets 在拓扑空间上分布的工作, 这种视角随后应用于获得更通用设置下的 GFlowNets 训练与 VI 发散最小化的等价性。最后, 我们描述了用于解决随机优化问题的标准方差缩减技术。

符号表示。 设 $(S, \mathcal{T})$ 是一个拓扑空间, 其拓扑为 $\mathcal{T}$, 对应的 Borel σ -代数记为 Σ 。另设 $\nu : \Sigma \rightarrow \mathbb{R}_+$ 是在 Σ 上的测度, 而 $\kappa_f, \kappa_b : \mathcal{S} \times \Sigma \rightarrow \mathbb{R}_+$ 是在 $\mathcal{S}$ 上的转移核。对 $\int_{B_1} \nu(ds) \kappa(s, B_2)$, 于每个 $(B_1, B_2) \in \Sigma \times \Sigma$, 我们记之为 $\nu \otimes \kappa(B_1, B_2) := \int_{B_1} \nu(ds) \kappa(s, B_2)$ 。类似地, 递归定义乘积核为 $\kappa^{\otimes 0}(s, \cdot) = \kappa(s, \cdot)$, 对于 $n \geq 1, \kappa^{\otimes n}(s, \cdot) = \kappa^{\otimes n-1}(s, \cdot) \otimes \kappa$, 其中转移核为 κ 和 $s \in \mathcal{S}$ 。特别注意, $\kappa^{\otimes n}$ 是从 $\mathcal{S} \times \Sigma^{\otimes n+1}$ 到 $\mathbb{R}_+$ 的函数, 其中 $\Sigma^{\otimes n+1}$ 表示乘积 σ -代数的 $\Sigma^{\otimes n+1}$ [1, 95]。此外, 如果 μ 相对于 ν 是绝对连续的, 记为 $\mu \ll \nu$, 则记 $d\mu/d\nu$ 为其相应的密度 (Radon-Nikodym 导数) [1]。进一步地, 我们记 $\mathcal{P}(A) = \{S : S \subseteq A\}$ 为集合 $A \subset \mathcal{S}$ 的幂集, 并记 $[d] = \{1, \dots, d\}$ 为前 d 个正整数。

GFlowNets. 在最一般的形式下, GFlowNet 基于可测有向无环图 (DAG) 的概念 [48], 我们接下来定义这一概念。直观上, 它将流网络的概念扩展到了任意可测拓扑空间, 用转移核替换了有向图, 以指定底层状态之间的连接方式。

定义 1 (可测有向图 [48]). 令 $(\bar{\mathcal{S}}, \mathcal{T}, \Sigma)$ 成为一个配备参考测度的可测拓扑空间 ν 并向前 κ_f 并反向 κ_b 核函数。此外, 令 $\kappa_f(s, \mathcal{S}) > 0$ 和 $\kappa_b(s, \mathcal{S}) = 1 \forall s \in \bar{\mathcal{S}}$ 。Also, 称 (s_o) 为 $\mathcal{S}$ 的初始状态, 并 $\mathcal{S} \setminus \{s_o\}$ 为可测量的有向无环图。然后是一个无环 $(\mathcal{S}, \mathcal{T}, \Sigma)$ 满足 $\kappa_b(s_o, B) > 0$, i.e. B is reachable from s_o .

3. (一致性) 对于每个 $(B_1, B_2) \in \Sigma \times \Sigma$, 使得 $(B_1, B_2) \notin \{(s_o, s_o), (s_f, s_f)\}, \nu \otimes \kappa$ 。此外, $\kappa_b(s_o, B) = 0$ 对于每个 $B \in \Sigma$ 。

4. (连续性) $s \mapsto \kappa_f(s, B)$ 对于 $B \in \Sigma$ 是连续的。

5. (有限吸收性) 存在一个 $N \in \mathbb{N}$, 使得 $\kappa_f^{\otimes N}(s, \cdot) = \delta_{s_f}$ 对于每个 $s \in \mathcal{S}$ 。我们将相应的 DAG 称为有限吸收的。

在这种情况下, 集合 $\mathcal{X} = \{s \in \mathcal{S} \setminus \{s_f\} : \kappa_f(s, \{s_f\}) > 0\}$ 中的元素被称为终端状态。形象地说, 当 $\mathcal{S}$ 是有限的且 ν 是计数测度时, 前面的定义

对应一个连通的有向无环图，从 $s \in \mathcal{S}$ 到 $s' \in \mathcal{S}$ 有一条边当且仅当 $\kappa_f(s, \{s'\}) > 0$ ，其中条件 5) 确保无环性，条件 2) 意味着连通性。GFlowNet 的特征是由一个可测量的有向无环图、终端状态上的潜在未归一化分布 $(\mathcal{X})$ 以及定义在 $(\mathcal{S}(\text{定义 2}))$ 上的可学习转移核函数所构成。实际上，它的目标是在 $(\mathcal{S})$ 上找到一个 IGP，从 (s_o) 开始，按照给定的正函数比例从 $(\mathcal{X})$ 中进行采样。

定义 2 (GFlowNets [48])。GFlowNet 是一个元组 $(\mathcal{G}, P_F, P_B, \mu)$ ，由一个可测的带点有向无环图 $\mathcal{G}, a, \sigma$ 、有限测度 $\mu \ll \nu$ 以及分别称为前向和后向策略的 σ -有限马尔科夫核函数 $P_F \ll \kappa_f$ 和 $P_B \ll \kappa_b$ ，组成。

训练 GFlowNets。实践中，我们用 $p_{F_\theta}: \mathcal{S} \times \mathcal{S} \rightarrow \mathbb{R}_+$ 表示 P_F 相对于 κ_f 的密度，该密度通过带有权重 θ 的神经网络进行参数化。类似地，我们用 p_B 表示 P_B 关于 κ_b 的密度。我们的目标是，对于定义在 $\mathcal{X}$ 上的给定目标测度 $R \ll \mu$ ，其中包含 $r = dR/d\mu$ ，估计出使得由 $P_F(s_o, \cdot)$ 诱导的在 $\mathcal{X}$ 上的分布与 R 相匹配的 θ ，即对于每一个 $B \in \Sigma$ ，

$$\sum_{n \geq 0} \int_{\mathcal{S}^n} p_{F_\theta}^{\otimes n}(s_o, s_{1:n}, s_f) \mathbb{1}_{s_n \in B} \kappa_f^{\otimes n}(s_o, ds_{1:n}) = \frac{R(B)}{R(\mathcal{X})}.$$

重要的是，上述求和只包含有限个非零项，这是因为 κ_f 具有有限吸收性质。为了确保 p_{F_θ} 遵守此方程，Lahlou 等人 [48] 表明，只需满足由 P_F 和 P_B 同时满足的下一个平衡条件之一即可。

定义 3 (轨迹平衡条件)。对于所有 $n \geq 0$ 和几乎所有的 $\mu^{\otimes n}$ ， $\forall s_{1:n} \in \mathcal{S}^n$ ，

$$p_{F_\theta}^{\otimes n}(s_o, s_{1:n}, s_f) = \frac{r(s_n)}{Z_\theta} p_B^{\otimes n}(s_n, s_{n:1}, s_o), \text{ w/ } Z_\theta, \text{ 其中表示目标分布的配分函数。}$$

定义 4 (细致平衡条件) 辅助参数函数 $u: \mathcal{S} \rightarrow \mathbb{R}_+$ 和 $\mu^{\otimes 2}$ 几乎处处在 $(s, s') \in \mathcal{S}^2$, $u(s)p_{F_\theta}(s, s') = u(s')p_B(s', s)$ 和 $u(x) = r(x)$ 上成立，对于 $x \in \mathcal{X}$ 。

为了强制执行轨迹平衡 (TB) 或细致平衡 (DB) 条件，我们通常定义一个随机优化问题，以最小化在适当空间上支持的概率测度 ξ 下，相应条件左右两边的期望对数平方差 [4, 15, 48, 49, 52, 55, 66]。对于结核病 (TB)，例如，令 ξ 在 $\Sigma \otimes_N$ 上定义，并具有支撑 $\text{supp}(\mu^{\otimes N})$ 。然后，我们通过最小化来估计 GFlowNet 的参数 θ

$$\mathbb{E}_{\tau \sim \xi} \left[\left(\sum_{0 \leq i \leq N-1} \left(\log \frac{p_{F_\theta}(s_i, s_{i+1})}{p_B(s_{i+1}, s_i)} \right) + \log \frac{Z_\theta}{r(s_h)} \right)^2 \right] \quad (1)$$

其中 $\tau = s_{0:N}$ 和 $h = \max\{i: s_i \neq s_f\}$ 是 τ 中最后一个非最终状态的索引。如子脚本在 Z_θ 所示，使用 TB 损失意味着需要学习目标的归一化常数。虽然在训练过程中调整 p_B 也是可能的，但通常的做法是将其固定。

自此，我们将考虑迹的可测空间 $(\mathcal{P}_S, \Sigma_P)$ ，其中 $\mathcal{P}_S = \{(s, s_1, \dots, s_n, s_f) \in \mathcal{S}^{n+1} \times \{s_f\}: 0 \leq n \leq N-1\}$ 和 Σ_P 是由生成的 σ -代数。为了记号上的方便，我们使用相同的字母来表示 $\mathcal{P}_S, \Sigma_P$ 及其在 $(\mathcal{P}_S, \Sigma_P)$ 中的自然乘积对应的测度和核函数，这些测度和核函数的存在性由 Carathéodory 延拓定理保证 $\bigcup_{n=1}^{N+1} \Sigma^{\otimes n}$ [95]；例如， $\nu(B) = \nu^{\otimes n}(B)$ 用于 $B = (B_1, \dots, B_n) \in \Sigma^{\otimes n}$ 且是密度为

在本例中，我们将使用 τ 表示 $\mathcal{P}_S$ 中的一个通用元素，并使用 x 表示其终态（该终态是唯一的） $p_{F_\theta}(\tau|s_o; \theta)$ $P_F^{\otimes n+1}(s_o, \cdot)$ 对 $\tau = (s_o, s_1, \dots, s_n, s_f)$ 相对于 $\mu^{\otimes n}$

定义 1). 对于 GFlowNets 的全面概述，请参见 [48, 55]。

GFlowNets 与变分推断。GFlowNets 可以被解释为分层变分模型，通过将正向策略 $p_{F_\theta}(\tau|s_o; \theta)$ 在 $(\mathcal{P}_S, \Sigma_P)$ 视为一个提议来 $r(x)$ Malkin 等人 [56] 展示了对于离散 $p_B(\tau|x)$

目标分布，方程 (1) 中的 TB 损失与 KL 散度在预期梯度方面是一致的。在此基础上，我们的命题 1 确立了这种关系也适用于任意拓扑空间上的分布。

命题 1 (拓扑空间上的 TB 损失和 KL 散度梯度)。设

$$\mathcal{L}_{TB}(\tau; \theta) = (\log Z_{p_{F_\theta}(\tau|s_o; \theta)} / r(x) p_B(\tau|x))^2 \text{ 和 } p_B(\tau) = \frac{r(x)}{Z} p_B(s_{n-1:o}|x) \text{ 对 } \tau = (s_o, \dots, s_{n-1}, x, s_f). \text{ Then,}$$

$$\nabla_\theta \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} [\mathcal{L}_{TB}(\tau; \theta)] = 2 \nabla_\theta \mathcal{D}_{KL}[P_F || P_B], \quad (2)$$

where $\mathcal{D}_{KL}[p_{F_\theta} || p_B] = \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} [\log p_{F_\theta}(\tau|s_o; \theta) / p_B(\tau)]$ is the KL divergence between P_F and P_B .

该命题表明，最小化随策略 TB 损失在收敛速度上理论上与最小化 P_F 和 P_B 之间的 KL 发散相当。由于 TB 损失需要估计不可计算的 $R(\mathcal{X})$ ，而 KL 发散避免了这种估计，因此可能是一个更合适的目标。我们在第 5 节中的实验支持这一点，并在附录 C 中提供了证明。将这一结果扩展到一般的拓扑空间，拓宽了发散最小化策略的应用范围，将离散空间的保证扩展到连续和混合空间。这种泛化与广义贝叶斯推断 [45] 和函数空间中的广义 VI [94] 的进步相一致，通过优化通用发散来实现。我们通过这些更广泛的背景下证明等价性，使该方法在理论上更加坚实，并具有潜在的广泛应用性。

方差缩减。 方程 2 中的梯度的朴素蒙特卡洛估计具有高方差 [19]，影响随机梯度下降的效率 [96]。为了缓解这个问题，我们使用控制变量——具有零期望的随机变量，添加它们以减少估计器的方差而不引入偏差 [63, 70]。这种方法在第 4 节中有详细说明，它显著减少了梯度估计中的噪声，并在实践中提高了训练的收敛性，如第 5 节中的实验所示。

3 学习 GFlowNets 的发散测度 本节介绍了四种不同的发散测度用于训练 GFlowNets 及其相应的梯度估计器，用于随机优化。无论学习目标如何，我们的目标都是通过最小化 P_F 和 P_B 之间的差异测度 D 来估计 θ ，当且仅当 $P_F = P_B$, i.e., 时，该差异测度在全球范围内达到最小值。

$$\theta^* = \arg \min_{\theta} D(P_F, P_B), \quad (3)$$

其中 P_B 通常是固定的，而 P_F 的密度 p_F^θ 由 θ 参数化。

3.1 Renyi- α 和 Tsallis- α 发散 Renyi- α [73] 和 Tsallis- α [90] 是统计发散的一组家族，包括作为极限情况的广泛使用的 KL 发散（第 3.2 节）[58]；参见定义 5。这些发散已被成功应用于变分推断 [51] 和基于模型的强化学习中的策略搜索 [18]。此外，正如我们在第 5 节中强调的那样，它们的性能与基于最小化提议分布和目标分布之间对数平方差的传统 GFlowNets 学习目标相比具有竞争力，有时甚至更好。

定义 5 (Renyi- α 和 Tsallis- α 发散)。设 $\alpha \in \mathbb{R}$ 。另设 p_{F_θ} 和 p_B 分别为 GFlowNet 的正向和反向策略。那么， P_F 和 P_B 之间的 Renyi- α 发散是

$$\mathcal{R}_\alpha(P_F || P_B) = \frac{1}{\alpha - 1} \log \int_{\mathcal{P}_S} p_{F_\theta}(\tau | s_o)^\alpha p_B(\tau)^{1-\alpha} \kappa_f(s_o, d\tau).$$

类似地， P_F 和 P_B 之间的 Tsallis- α 发散是

$$\mathcal{T}_\alpha(P_F || P_B) = \frac{1}{\alpha - 1} \left(\int_{\mathcal{P}_S} p_{F_\theta}(\tau | s_o)^\alpha p_B(\tau)^{1-\alpha} \kappa_f(s_o, d\tau) - 1 \right).$$

根据定义 5，我们可以看到 Renyi- α 和 Tsallis- α 发散从质量覆盖行为转变为模式寻找行为，当 α 从 $-\infty$ 变化到 ∞ 时。关于 GFlowNet 训练，这种灵活性表明 $\mathcal{R}_\alpha$ 和 $\mathcal{T}_\alpha$ 都是适当的选择，例如用于进行贝叶斯推断 [16]——其中目标是获得后验分布的精确近似——以及组合优化 [109]——其中目标是找到几个高价值样本。此外，选择 α 提供了一种控制训练过程中优先采样的轨迹的方法，较大的值倾向于选择导向高概率终端状态的轨迹，类似于施行的效应 ε -贪婪算法 [55]、汤普森抽样算法 [72]、局部搜索算法 [40] 和前瞻式算法 [64, 65]，这些算法用于执行 GFlowNet 的离策略训练 [56]。

为了说明 α 对 GFlowNets 学习动态的影响，我们在图 1 中展示了训练早期阶段从高斯分布的均匀混合中采样的情况，通过最小化 Renyi- α 发散来实现，针对不同值的 α ；关于此实验的详细信息，请参见第 5.1 节。在这一阶段，我们注意到 GFlowNet 覆盖了目标分布的模式，但在 α 较大且为负值时未能将它们分开。相比之下，较大的正值 α 会导致模型专注于单一

高概率区域。因此，使用中间值对于 $\alpha = 0.5$ 最终形成一个能够准确逼近目标分布的模型。同时，我们的早期实验表明，在不同的学习任务中，对 α 存在这种依赖性，其中 $\alpha = 0.5$ 导致最佳结果。因此，我们在整个实验过程中固定 $\alpha = 0.5$ 。

重要的是，我们只需要方程 3 中优化问题的 $\mathcal{R}_\alpha$ 和 $\mathcal{T}_\alpha$ 的梯度，并且特别地，学习目标分布的归一化常数是不必要的，正如我们在下面的引理中强调的那样。这一特性将此类发散测度与方程 1 中的 TB 和 DB 损失区分开来，并且原则上简化了 GFlowNets 的训练。

引理 1 (关于 $\mathcal{R}_\alpha$ 和 $\mathcal{T}_\alpha$ 的梯度) 令 θ 为定义 5 中 p_{F_θ} 的参数，对于 $\tau \in \mathcal{P}_S$, $g(\tau, \theta) = (p_B(\tau|x)r(x)/p_{F_\theta}(\tau|s_o; \theta))^{1-\alpha}$ 。 $\mathcal{R}_\alpha$ 相对于 θ 的梯度是

$$\nabla_\theta \mathcal{R}_\alpha(p_{F_\theta}||p_B) = \frac{\mathbb{E}[\nabla_\theta g(\tau, \theta) + g(\tau, \theta) \nabla_\theta \log p_{F_\theta}(\tau|s_o; \theta)]}{(\alpha - 1)\mathbb{E}[g(\tau, \theta)]};$$

期望是在 P_F 下计算的。类似地， $\mathcal{T}_\alpha$ 相对于 θ 的梯度是

$$\nabla_\theta \mathcal{T}_\alpha(p_{F_\theta}||p_B) \stackrel{C}{=} \frac{\mathbb{E}[\nabla_\theta g(\tau, \theta) + g(\tau, \theta) \nabla_\theta \log p_{F_\theta}(\tau|s_o; \theta)]}{(\alpha - 1)},$$

其中， $\stackrel{C}{=}$ 表示乘法常数下的等价。

引理 1 使用 REINFORCE 方法 [96] 来计算度，并且我们实现蒙特卡洛估计器基于训练期间采样的轨迹批

$\{\tau_1, \dots, \tau_N\}$ 来近似随之而来的期望 [56]。另外，请注意函数是在对数域之外计算的，因此需要特别小心以避免未归一化分布的数值下溢等问题 [3, 86]。在我们的实现中，我们采样了一个初始轨迹批

$\{\tau_i\}_{i=1}^N$ 并计算采样终端状态中的最大值，即 $\log \tilde{r}$ 。然后，我们将 $\log \tilde{r}$ 视为目标的未归一化对数密度。在第 4 节中，我们将考虑设计方差缩减技术以降低梯度估计的噪声水平，从而可能加速学习过程。




图 1: 模式寻找 ($\alpha = 2$) 与质量覆盖 ($\alpha = -2$) 行为在 α -发散中的表现。

$\mathcal{R}_\alpha$ 和 $\mathcal{T}_\alpha$ 的梯

3.2 Kullback-Leibler 发散

KL 发散 [47] 是 Renyi- α 和 Tsallis- α 发散族的极限成员，在特定条件下导出 $\alpha \rightarrow 1$ [69]，并且它是统计学和机器学习中最广泛使用的发散测度。为了进行变分推断，通常会考虑正向和逆向 KL 发散，我们在下面的定义中进行了回顾。

定义 6 (前向和反向 KL)。 目标

P_F is $\mathcal{D}_{KL}[P_B||P_F] = \mathbb{E}_{\tau \sim P_B(s_f, \cdot)} [\log p_B(\tau)/p_{F_\theta}(\tau|s_o)]$ P_B 与提议之间的前向 KL 发散。

$\mathcal{D}_{KL}[P_F||P_B] = \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} [\log p_{F_\theta}(\tau|s_o)/p_B(\tau)]$ 。此外，反向 KL 发散定义为。值得

si

to 注意的是，由于假设的不可计算性

P_B (直接依赖于 R)，我们无法使用简单的蒙特卡洛估计器来近似前向 KL 散度。作为第一步近似，我们可以利用重要性采样方法估计 $\mathcal{D}_{KL}[P_B||P_F]$ ，其中 P_F 作为提议分布，如 [56] 所示：

$$\mathcal{D}_{KL}[P_B||P_F] = \mathbb{E}_{\tau \sim P_F} \left[\frac{p_B(\tau)}{p_{F_\theta}(\tau|s_o)} \log \frac{p_B(\tau)}{p_{F_\theta}(\tau|s_o)} \right], \quad (4)$$

随后实现一个 REINFORCE 估计器来计算 $\nabla_\theta \mathcal{D}_{KL}[P_B||P_F]$ 。然而，由于我们仅需计算梯度下降所需的发散的导数，我们将重要性权重直接应用于梯度估计器。我们在下面的引理中总结了这一方法。

引理 2 (KL 发散的梯度)。 设 θ 为 P_F 和 $s(\tau; \theta) = \log p_{F_\theta}(\tau|s_o; \theta)$ 的参数。那么，相对于 $\mathcal{D}_{KL}[P_F||P_B]$ 的 θ 的梯度满足

$$\nabla_\theta \mathcal{D}_{KL}[P_F||P_B] = \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \left[\nabla_\theta s(\tau; \theta) + \log \frac{p_{F_\theta}(\tau|s_o)}{p_B(\tau|x)r(x)} \nabla_\theta s(\tau; \theta) \right]$$




图 2: 估计梯度的方差作为轨迹批大小的函数。我们的控制变量显著降低了估计器的方差, 即使在相对较小的批大小下也是如此。

相应地, $\mathcal{D}_{KL}[P_B||P_F]$ 关于 θ 的梯度是

$$\nabla_{\theta} \mathcal{D}_{KL}[P_B||P_F] \stackrel{C}{=} -\mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \left[\frac{p_{F_{\theta}}(\tau|s_o)}{p_B(\tau|x)r(x)} \nabla_{\theta} s(\tau; \theta) \right].$$

关键在于, 选择一个合适的学习目标是一个需要根据具体问题进行分析的问题——类似于在马尔可夫链仿真技术之间进行选择的问题 [27]。特别地, 并不存在一种通用的解决方案; 请参见第 5 节进行详尽的实验研究。然而, 无论选择哪种方法, 蒙特卡洛估计量对于引理 2 中概述的数量可能具有较高的方差, 并且可能需要相对较多的轨迹才能得到梯度的可靠估计 [96]。接下来的部分将证明, 方差缩减技术可以缓解这一问题。

4 使用控制变量进行低方差梯度估计

控制变量。我们首先回顾控制变量的概念。令 $f: \mathcal{P}_S \rightarrow \mathbb{R}$ 是一个实值可测函数, 并假设我们的目标是对其进行估计 $\mathbb{E}_{\tau \sim \pi}[f(\tau)]$ 根据概率测度 π 在 Σ 上 F (参见第 2 节以回顾定义)。该量的朴素蒙特卡洛估计器的方差为 $\text{Var}_{\pi}(f(\tau))/n$ 。另一方面, 考虑一个随机变量 (Random Variable) $g: \mathcal{P}_S \rightarrow \mathbb{R}$ 正相关于 f 并且已知期望 $\mathbb{E}_{\pi}[g(\tau)]$ 。然后, 朴素蒙特卡洛的方差为 $\mathbb{E}_{\pi}[f(\tau) - a(g(\tau) - \mathbb{E}_{\pi}[g(\tau)])]$ 对于基线 $a \in \mathbb{R}$ 是

$$\frac{1}{n} [\text{Var}_{\pi}(f(\tau)) - 2a \text{Cov}_{\pi}(f(\tau), g(\tau)) + a^2 \text{Var}_{\pi}(g(\tau))], \quad (5)$$

这可能小于 $\frac{1}{n} \text{Var}_{\pi}(f(\tau))$, 如果 f 和 g 之间的协方差足够大。在这些条件下, 我们选择使方程 5[93] 最小化的 a 值, 即 $a = \text{Cov}_{\pi}(f(\tau), g(\tau)) / \text{Var}_{\pi}(g(\tau))$ 。然后我们调用函数 g 为控制变量 [63]。此外, 尽管定义最佳基线的量 a 通常无法以封闭形式获得, 人们通常会使用批量估计方法来估算 $\text{Cov}_{\pi}(f(\tau), g(\tau))$ 和 $\text{Var}_{\pi}(g(\tau))$; 所引入的偏差相对于方差的减少而言通常是可忽略的 [70, 78, 84]。对于向量值随机变量, 我们令 a 为 a 为对角矩阵, 并在接下来的命题中展示使协方差矩阵的迹最小化的最优基线。

命题 2 (控制变量对于梯度). 设 $f, g: \mathcal{P}_S \rightarrow \mathbb{R}^d$ 为向量值函数, π 为在 $\mathcal{P}_S$ 上的概率测度。考虑一个基线 $a \in \mathbb{R}$, 并假设 $\mathbb{E}_{\pi}[g(\tau)] = 0$ 。则有, $\arg \min_{a \in \mathbb{R}}$

$$\text{Tr Cov}_{\pi}[f(\tau) - a \cdot g(\tau)] = \frac{\mathbb{E}_{\pi}[g(\tau)^T (f(\tau) - \mathbb{E}_{\pi}[f(\tau)])]}{\mathbb{E}_{\pi}[g(\tau)^T g(\tau)]}.$$

需要注意的是, 在实现 REINFORCE 梯度估计器时, 我们希望估计的期望可以一般地表示为 $\mathbb{E}_{P_F(s_o, \cdot)} [\nabla_{\theta} f(\tau) + f(\tau) \nabla_{\theta} \log p_{F_{\theta}}(\tau)]$ 。对于第二项, 我们使用一个留一法估计器 [84], 详见下文。对于第一项, 我们使用 $\nabla_{\theta} \log p_{F_{\theta}}$ 作为控制变量, 其满足

$\mathbb{E}_{P_F(s_o, \cdot)} [\nabla_{\theta} \log p_{F_{\theta}}(\tau|s_o; \theta)] = 0$ 。重要的是, 根据命题 2, 最优基线的估计 a^* 无法高效完成, 因为相应的蒙特卡洛估计器与样本级梯度的非线性依赖关系 [2]; 也就是说, 它不能表示为一个雅可比矩阵-向量乘积的形式, 而后者在反向模式自动微分框架中是高效的计算方法 [8, 68]。因此, 我们考虑对分子进行线性近似

以及在命题 2 中定义的分母 a^* ，可以将其解释为增量方法 [82, 第 7.1.3 节] 的一个实例。然后，给定一批轨迹 $\{\tau_1, \dots, \tau_N\}$ ，我们改为使用

$$\hat{a} = \frac{\left\langle \sum_{n=1}^N \nabla_{\theta} \log p_{F_{\theta}}(\tau_n), \sum_{n=1}^N \nabla_{\theta} f(\tau_n) \right\rangle}{\epsilon + \left\| \sum_{n=1}^N \nabla_{\theta} \log p_{F_{\theta}}(\tau_n) \right\|^2} \quad (6)$$

作为基于批次估计的 REINFORCE 基线； $\langle \cdot, \cdot \rangle$ 表示向量之间的内积。直观地，分子大致是对 $\nabla_{\theta} \log p_{F_{\theta}}$ 和 $\nabla_{\theta} f$ 在 P_F 下的协方差进行线性近似。相比之下，分母大约测量了 $\nabla_{\theta} \log p_{F_{\theta}}$ 的方差，而 $\epsilon > 0$ 被包含进来以增强数值稳定性。因此，对于反向 KL 发散， $\nabla_{\theta} f(\tau) = \nabla_{\theta} \log p_{F_{\theta}}(\tau)$, $\hat{a} \approx 1$ 以及与 $\nabla_{\theta} f(\tau)$ 的期望对应的项消失。我们实证发现，这种方法经常大幅减少估计梯度的方差（参见上文图 2 及下文第 5 节）。

我们期望在批量中获得一个方差较低的估计值作为一种替代估计方法，Shi 等人提出了 $\mathbb{E}_{\tau \sim P_F(s_0, \cdot)}[f(\tau) \nabla_{\theta} \log p_{F_{\theta}}(\tau)]$ 法，[84] 和 Salimans and Knowles [81] proposed a sample-dependent $\frac{1}{N-1} \sum_{1 \leq n \leq N, n \neq i} f(\tau_n)$ for $i \in \{1, \dots, N\}$. The resulting estimator,

$$\delta = \frac{1}{N} \sum_{n=1}^N \left(f(\tau_n) - \frac{1}{N-1} \sum_{j=1, j \neq i}^N f(\tau_j) \right) \nabla_{\theta} \log p_{F_{\theta}}(\tau_n),$$

由于 τ_i 和 τ_j 之间的独立性，对于 $i \neq j$ 而言， $\mathbb{E}[f(\tau) \nabla_{\theta} \log p_{F_{\theta}}(\tau)]$ 是无偏的。值得注意的是，可以通过自动微分迅速计算 δ ：如果 $\mathbf{f} = (f(\tau_n))_{n=1}^N$ 和

$$\mathbf{p} = (\log p_{F_{\theta}}(\tau_n))_{n=1}^N \text{ then}$$

$$\delta = \nabla_{\theta} \frac{1}{N} \left\langle \text{sg} \left(\mathbf{f} - \frac{1}{N-1} (\mathbf{1} - \mathbf{I}) \mathbf{f} \right), \mathbf{p} \right\rangle, \quad (7)$$

其中停止梯度操作由 sg 表示（例如，在 JAX 中表示为 `lax.stop_gradient` 在 JAX 中 [8] 在 PyTorch 中表示为 `torch.detach` [68]）。重要的是，这些技术相对于大幅降低方差而言，对随机优化算法带来的计算开销极小。

与先前工作的关系。重要的是，Malkin 等人 [56] 使用了 $\hat{a} = \frac{1}{N} \sum_n f(\tau_n)$ 作为基线，并引入了重要性加权聚合来调整轨迹的离策略采样，这导致了梯度估计的偏差并放弃了优化过程的保证。还考虑了一个独立训练以匹配 $\hat{b}$ 的学习基线。这可能导致不准确地认为 TB 和 DB 优于标准的发散目标。确实，下一节强调了这样的发散度量是 GFlowNets 在一系列任务上的合理且实用的学习目标。

控制变量有效性的示例。我们使用逐渐增大的批次量 $\{2^i: i \in [5, 10]\}$ 轨迹，包括带有和不带控制变量的情况，来训练 GFlowNets。在此设置下，图 2 展示了由控制变量促进的估计学习目标梯度相对于模型参数的方差（通过协方差矩阵的迹表示）的显著降低。令人印象深刻的是，正如图 5 所示，这种方法显著提高了底层随机优化算法的效率。详情请参见第 5 节和附录 D。

5 使用发散测度训练 GFlowNets

我们的实验有两个目的。首先，在第 5.2 节中，我们展示了最小化基于发散的学习目标通常会带来比基于流网络平衡的日志平方违规的替代方案更具有竞争力且往往更好的近似结果，提供了更广泛的评估设置，补充了先前的证据 [56, 111]。其次，在第 5.3 节中，我们强调通过引入设计良好的控制变量来减少方差，可以显著加速 GFlowNets 的收敛。我们考虑了 GFlowNet 文献中广泛采用的基准任务，这些任务在第 5.1 节中有描述，涵盖了离散和连续的目标分布。关于任务和模型超参数的更多信息，请参见附录 B 和附录 E。




图 3: 基于发散的学习目标通常比 TB 损失导致更快的训练。值得注意的是, 与 [56] 中的实验相比, 并没有单一的最佳损失函数始终导致最快的收敛率, 而最小化已知的发散测度通常在收敛速度方面与或优于最小化 TB 损失。结果是在三个不同的种子上取平均值。此外, 我们固定了 $\alpha = 0.5$ 对于 Tsallis- α 和 Renyi- α 发散。




图 4: 香蕉形状目标的学得分布。Tsallis- α , Renyi- α 和 KL 导出的模型优于 TB 和逆 KL, 它们的行为相似——正如命题 1 所预测的那样。

5.1 生成任务

下面, 我们提供用于合成数据生成和训练的生成任务的高层次特征描述。对于第 2 节的更严格描述, 请参见附录 B。

集合生成 [3, 34, 64, 65]. 状态 s 对应于最多给定大小的集合 S , 终止状态 $\mathcal{X}$ 是大小为 S 的集合; 转移对应于从存款 $\mathcal{D}$ 中添加一个元素到 s 。IGP 从空集开始, 状态 $x \in \mathcal{X}$ 的对数奖励为 $\sum_{d \in x} f(d)$, 其中固定值为 $f: \mathcal{D} \rightarrow \mathbb{R}$ 。

自回归序列生成 [32, 55]. 类似地, 状态是一段最大长度为 S 的序列 s , 终止状态是以序列结束标记结束的序列; 转移是在 s 后追加 $d \in \mathcal{D}$ 。IGP 从空序列开始, 并对函数 f, g 执行 $x \in \mathcal{X}, \log r(x) = \sum_{i=1 \dots |x|} g(i)f(x_i)$ 次操作。

贝叶斯系统发生推断 (BPI) [110]. 状态 s 是由带有标签的叶子节点和未标记的内部节点组成的二叉树森林, 而状态转换则意味着将两棵树的根节点连接到一个新添加的节点上。然后, 当状态成为一个单一的连通树——称为系统发育树时, 它就是终端状态 s 。最后, 给定一组核苷酸序列数据, 奖励函数是由 J&C69 的突变模型 [37] 和均匀先验诱导出的树的未归一化后验概率。

高斯混合模型 (GMS) [48, 108]. IGP 从 $\mathbf{0} \in \mathbb{R}^d$ 开始, 并通过依次替换每个坐标为实值分布的样本来推进。对于一个 K 组件的高斯混合模型, 状态 $\mathbf{x} \in \mathbb{R}^d$ 的奖励定义为 $\sum_{k=1}^K \alpha_k \mathcal{N}(\mathbf{x} | \mu_k, \Sigma_k)$ 含及 $\alpha_k \geq 0, \sum_k \alpha_k = 1$ 。

香蕉形状分布 [57, 75]. 我们使用与二维 GM 相同的 IGP 实现。对于 $\mathbf{z} \in \mathbb{R}^2$, 我们将 $r(\mathbf{x})$ 设置为定义在 $\mathbf{x}$ 的二次函数上的正态似然, 参见补充材料中的方程 8。我们使用 HMC 样本作为真实值来衡量此任务的性能。

5.2 评估收敛速度 接下来, 我们提供证据表明, 最小化基于发散的目标通常会导致比最小化标准 TB 损失更快的收敛速度 [55]。

实验设置。 我们比较了不同学习目标下的 GFlowNet 训练采样过程中分布误差测度减少速率的收敛速度, 这些分布描述于第 5.1 节。对于离散分布, 我们采用了先前工作的评估协议 [3, 54, 55, 65], 并计算学习到的 $p_T(x; \theta)$ 与目标 $r(x)$ 之间的 L_1 距离, 即 $\sum_{x \in \mathcal{X}} |p_T(x; \theta) - r(x)/Z|$ 。

$$p_T(x; \theta) = \mathbb{E}_{\tau \sim P_B(x, \cdot)} [p_{F_\theta}(\tau | s_0; \theta) / p_B(\tau | x)]$$

为了近似 p_T , 我们使用蒙特卡洛估计。对于连续分布,

我们参考 [48, 108], 并计算 $P_T(x; \theta)$ 和 $R(x)$ 之间的 Jensen-Shannon 发散:

$$\mathcal{D}_{JS}[P_T || R] = 1/2 (\mathcal{D}_{KL}[P_T || M] + \mathcal{D}_{KL}[R || M]) = \mathbb{E}_{x \sim P_T} [\log p_T(x) / m(x)] + \mathbb{E}_{x \sim R} [\log r(x) / Z m(x)],$$

其中 $M(B) = 1/2 (P_T(B) + R(B)/R(x))$ 是 P_T 和 R 的平均测度，而 m 是相对于参考测度 μ 的相应密度。值得注意的是，在逼近高斯分布混合的情况下，我们可以直接从目标分布中采样以估计 $\mathcal{D}_{KL}[R||M]$ ，生成过程的自回归性质确保了唯一轨迹 τ 从 s_o 开始到 x 结束时满足 $p_T(x) = p_{F_\theta}(\tau|s_o)$ 。因此，我们得到了 $\mathcal{D}_{KL}[P_T||M]$ 的一个无偏估计。

结果。图 3 显示，最小化发散测度的过程加速了 GFlowNets 的训练收敛，而

表 1: 最小化发散可获得优于或类似于强制执行 TB 的准确率。

图 4 (针对香蕉形状分布) 和表 1 表明，在固定计算预算下，我们获得了一个更精确的模型。对于 BPI 任务而言，学习目标之间的差异在统计上并不显著。

此外，我们可以将逆 KL 在序列生成任务中优于正向 KL 的表现归因于基于重要性采样的梯度估计具有较高的方差。实际上，当我们增加轨迹批次以减少估计器的方差时 (参见附录 D 中的图 7)，观察到差异就消失了。综上所述，基于实验测试多种生成设置并扩展现有技术的实证结果 [48, 56, 111] 显示，通过最小化 f-发散 VI 目标并实现适当的 CVs 进行训练的方法，在许多任务是实用且有效的。

此	BPI	Sequences	Sets	GMs
TB	0.22±0.04	0.28±0.06	0.07±0.00	0.31±0.08
Rev. KL	0.21±0.04	0.16 ±0.06	0.03 ±0.00	0.31±0.09
For. KL	0.22±0.04	0.23±0.12	0.03 ±0.00	0.09 ±0.10
Renyi- α	0.22±0.03	0.23±0.10	0.03 ±0.00	0.19±0.13
Tsallis- α	0.21±0.04	0.22±0.09	0.03 ±0.00	0.21±0.11

5.3 减少估计梯度的方差 图 2 展示了为 REINFORCE 估计器实施控制变量可以显著降低梯度估计的噪声水平。这种方差的减少也加速了训练收敛。为了说明这一点，我们使用第 5.2 节相同的实验设置，并分析每个发散测度的学习曲线，有无控制变量。

结果。图 5 显示，所实现的梯度减少技术显著提升了 GFlowNets 的学习稳定性，并在最小化逆 KL 发散时极大地加速了训练收敛。我们的结果表明，精心设计的 CVs 用于梯度估计可以大大有利于 GFlowNets 的训练。值得注意的是，研究人员在 Langevin 动力学仿真中使用减少方差的梯度估计器以及在 RL 中的策略梯度方法时也观察到了类似的改进 [22, 31, 44][67, 99]。




图 5: 集合生成任务中不同目标函数的学习曲线。梯度估计方差的降低显著提高了训练稳定性和速度。

6 结论、局限性和更广泛影响 我们通过一系列全面的实验表明，在变分推断中常用的 f-发散测度——正向 KL、反向 KL、Renyi- α 和 Tsallis- α ——作为训练 GFlowNets 的学习目标是有效的，达到了与基于流的训练目标相当的性能。对于 f-发散梯度估计器的方差缩减证明了对竞争性结果至关重要，澄清了关于 VI 训练在 f-发散最小化一般设置下的先前结果 [48, 55, 111]。此外，我们建立了 GFlowNets 与 VI 之间的理论联系，超越了有限支持测度的设定，得出了任意拓扑空间的结果。

尽管我们在 $\alpha = 0.5$ 上观察到了有前景的结果，但可能存在不同的 α 选择，根据具体应用，可能会更好地平衡探索与开发，并加快收敛速度。因此，彻底探索不同的 α 可能对实践者特别有用。

总体而言，我们的工作突显了一度被忽视的受启发于 VI 的方案在训练 GFNs 方面的潜在价值，为通过借鉴 VI 文献来改进 GFlowNets 的研究铺平了道路。例如，可以开发基于 χ -发散的损失函数用于 GFNs [19]，结合 GFNs 与 MCMC 使用 Ruiz 和 Titsias [80] 的发散，或者采用类似于重要性加权自编码器的类似目标 [10]。

致谢

本研究得到了里约热内卢州科学研究基金会 FAPERJ (SEI-260003/000709/2023)、圣保罗研究基金会 FAPESP (22023/00815-6)、国家科学技术发展委员会 CNPq (404336/2023-0) 以及硅谷社区基金会通过大学区块链研究倡议 (资助号 2022-199610) 的支持。

参考文献

- [1] S. Axler. *Measure, Integration & Real Analysis*. Springer International Publishing, 2020. ISBN 9783030331436. doi: 10.1007/978-3-030-33143-6.
- [2] A. G. Baydin, B. A. Pearlmutter, A. A. Radul, and J. M. Siskind. Automatic differentiation in machine learning: a survey. *Journal of Machine Learning Research*, 2018.
- [3] E. Bengio, M. Jain, M. Korablyov, D. Precup, and Y. Bengio. Flow network based generative models for non-iterative diverse candidate generation. In *NeurIPS (NeurIPS)*, 2021.
- [4] Y. Bengio, S. Lahlou, T. Deleu, E. J. Hu, M. Tiwari, and E. Bengio. Gflownet foundations. *Journal of Machine Learning Research (JMLR)*, 2023.
- [5] M. Betancourt. A conceptual introduction to hamiltonian monte carlo. *arXiv preprint arXiv:1701.02434*, 2017.
- [6] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2007.
- [7] D. M. Blei and et al. Variational inference: A review for statisticians. *Journal of the American Statistical Association*, 2017.
- [8] J. Bradbury, R. Frostig, P. Hawkins, M. J. Johnson, C. Leary, D. Maclaurin, G. Necula, A. Paszke, J. VanderPlas, S. Wanderman-Milne, and Q. Zhang. JAX: composable transformations of Python+NumPy programs, 2018.
- [9] L. Buesing, N. Heess, and T. Weber. Approximate inference in discrete distributions with monte carlo tree search and value functions. In *AISTATS*, pages 624–634. PMLR, 2020.
- [10] Y. Burda, R. B. Grosse, and R. Salakhutdinov. Importance weighted autoencoders, 2016.
- [11] P. Carbonetto, M. King, and F. Hamze. A stochastic approximation method for inference in probabilistic graphical models. *NeurIPS*, 2009.
- [12] B. Carpenter, A. Gelman, M. D. Hoffman, D. Lee, B. Goodrich, M. Betancourt, M. Brubaker, J. Guo, P. Li, and A. Riddell. Stan: A probabilistic programming language. *Journal of statistical software*, 2017.
- [13] T. da Silva, E. Silva, A. Ribeiro, A. Góis, D. Heider, S. Kaski, and D. Mesquita. Human-in-the-loop causal discovery under latent confounding using ancestral gflownets. *arXiv preprint:2309.12032*, 2023.
- [14] M. P. Deisenroth and C. E. Rasmussen. PILCO: A model-based and data-efficient approach to policy search. In *ICML, Proceedings of Machine Learning Research*, pages 465–472. PMLR, 2011.
- [15] T. Deleu, A. Góis, C. C. Emezue, M. Rankawat, S. Lacoste-Julien, S. Bauer, and Y. Bengio. Bayesian structure learning with generative flow networks. In *UAI*, 2022.

- [16] T. Deleu, M. Nishikawa-Toomey, J. Subramanian, N. Malkin, L. Charlin, and Y. Bengio. Joint Bayesian inference of graphical structure and parameters with a single generative flow network. In *Advances in Neural Processing Systems (NeurIPS)*, 2023.
- [17] T. Deleu, P. Nouri, N. Malkin, D. Precup, and Y. Bengio. Discrete probabilistic inference as control in multi-path environments. *CoRR*, abs/2402.10309, 2024.
- [18] S. Depeweg, J. M. Hernández-Lobato, F. Doshi-Velez, and S. Udluft. Learning and policy search in stochastic dynamical systems with bayesian neural networks. *arXiv preprint arXiv:1605.07127*, 2016.
- [19] A. B. Dieng, D. Tran, R. Ranganath, J. Paisley, and D. Blei. Variational inference via χ upper bound minimization. *NeurIPS*, 2017.
- [20] J. Domke. Provable gradient variance guarantees for black-box variational inference. In *NeurIPS*, pages 328–337, 2019.
- [21] J. Domke. Provable smoothness guarantees for black-box variational inference. In *ICML*, volume 119 of *Proceedings of Machine Learning Research*, pages 2587–2596. PMLR, 2020.
- [22] K. A. Dubey, S. J. Reddi, S. A. Williamson, B. Póczos, A. J. Smola, and E. P. Xing. Variance reduction in stochastic gradient langevin dynamics. In *NeurIPS*, 2016.
- [23] S. Dutta, M. Das, and U. Maulik. Towards causality-based explanation of aerial scene classifiers. *IEEE Geoscience and Remote Sensing Letters*, 2023.
- [24] J.-P. Falet, H. B. Lee, N. Malkin, C. Sun, D. Secrieru, D. Zhang, G. Lajoie, and Y. Bengio. Delta-ai: Local objectives for amortized inference in sparse graphical models, 2023.
- [25] J. Felsenstein. Evolutionary trees from DNA sequences: A maximum likelihood approach. *Journal of Molecular Evolution*, 1981.
- [26] T. Garipov, S. D. Peuter, G. Yang, V. Garg, S. Kaski, and T. S. Jaakkola. Compositional sculpting of iterative generative processes. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023.
- [27] C. J. Geyer. Markov chain monte carlo maximum likelihood. 1991.
- [28] G. Hinton, N. Srivastava, and K. Swersky. Neural networks for machine learning lecture 6a overview of mini-batch gradient descent. 2012.
- [29] E. J. Hu, M. Jain, E. Elmoznino, Y. Kaddar, and et al. Amortizing intractable inference in large language models, 2023.
- [30] E. J. Hu, N. Malkin, M. Jain, K. E. Everett, A. Graikos, and Y. Bengio. Gflownet-em for learning compositional latent variable models. In *International Conference on Machine Learning (ICLR)*, 2023.
- [31] Z. Huang and S. Becker. Stochastic gradient langevin dynamics with variance reduction. *CoRR*, 2021.
- [32] M. Jain, E. Bengio, A. Hernandez-Garcia, J. Rector-Brooks, B. F. P. Dossou, C. A. Ekbote, J. Fu, T. Zhang, M. Kilgour, D. Zhang, L. Simine, P. Das, and Y. Bengio. Biological sequence design with GFlowNets. In *International Conference on Machine Learning (ICML)*, 2022.
- [33] M. Jain, T. Deleu, J. Hartford, C.-H. Liu, A. Hernandez-Garcia, and Y. Bengio. Gflownets for ai-driven scientific discovery. *Digital Discovery*, 2023.
- [34] H. Jang, M. Kim, and S. Ahn. Learning energy decompositions for partial inference in GFlowNets. In *The Twelfth International Conference on Learning Representations*, 2024.
- [35] M. Järvenpää and J. Corander. On predictive inference for intractable models via approximate bayesian computation. *Statistics and Computing*, 33(2), Feb. 2023. ISSN 1573-1375.

- [36] M. I. Jordan, Z. Ghahramani, T. S. Jaakkola, and L. K. Saul. An introduction to variational methods for graphical models. *Mach. Learn.*, 37(2):183–233, 1999.
- [37] T. H. Jukes and C. R. Cantor. Evolution of protein molecules. In *Mammalian Protein Metabolism*. Elsevier, 1969.
- [38] H. J. Kappen, V. Gómez, and M. Opper. Optimal control as a graphical model inference problem. *Mach. Learn.*, 87(2):159–182, 2012.
- [39] K. Kim, Y. Ma, and J. Gardner. Linear convergence of black-box variational inference: Should we stick the landing? In *AISTATS*, volume 238 of *Proceedings of Machine Learning Research*, pages 235–243. PMLR, 2024.
- [40] M. Kim, T. Yun, E. Bengio, D. Zhang, Y. Bengio, S. Ahn, and J. Park. Local search gflownets. *arXiv preprint arXiv:2310.02710*, 2023.
- [41] D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [42] D. P. Kingma, S. Mohamed, D. Jimenez Rezende, and M. Welling. Semi-supervised learning with deep generative models. *NeurIPS*, 2014.
- [43] D. P. Kingma, T. Salimans, B. Poole, and J. Ho. Variational diffusion models, 2023.
- [44] Y. Kinoshita and T. Suzuki. Improved convergence rate of stochastic gradient langevin dynamics with variance reduction and its application to optimization. In *NeurIPS*, 2022.
- [45] J. Knoblauch, J. Jewson, and T. Damoulas. An optimization-centric view on bayes’ rule: Reviewing and generalizing variational inference. *J. Mach. Learn. Res.*, 23:132:1–132:109, 2022.
- [46] A. Kucukelbir, D. Tran, R. Ranganath, A. Gelman, and D. M. Blei. Automatic differentiation variational inference. *J. Mach. Learn. Res.*, 18:14:1–14:45, 2017.
- [47] S. Kullback and R. A. Leibler. On Information and Sufficiency. *The Annals of Mathematical Statistics*, 1951.
- [48] S. Lahlou, T. Deleu, P. Lemos, D. Zhang, A. Volokhova, A. Hernández-García, L. N. Ezzine, Y. Bengio, and N. Malkin. A theory of continuous generative flow networks. In *ICML*, volume 202 of *Proceedings of Machine Learning Research*, pages 18269–18300. PMLR, 2023.
- [49] E. Lau, N. M. Vemgal, D. Precup, and E. Bengio. DGFN: Double generative flow networks. In *NeurIPS 2023 Generative AI and Biology (GenBio) Workshop*, 2023.
- [50] S. Levine. Reinforcement learning and control as probabilistic inference: Tutorial and review. *CoRR*, abs/1805.00909, 2018.
- [51] Y. Li and R. E. Turner. Rényi divergence variational inference. *NeurIPS*, 29, 2016.
- [52] D. Liu and et al. Gflowout: Dropout with generative flow networks. In *International Conference on Machine Learning*, ICML’23. JMLR.org, 2023.
- [53] R. Liu, J. Regier, N. Tripuraneni, M. I. Jordan, and J. D. McAuliffe. Rao-blackwellized stochastic gradients for discrete distributions. In *ICML*, volume 97 of *Proceedings of Machine Learning Research*, pages 4023–4031. PMLR, 2019.
- [54] K. Madan, J. Rector-Brooks, M. Korablyov, E. Bengio, M. Jain, A. C. Nica, T. Bosc, Y. Bengio, and N. Malkin. Learning gflownets from partial episodes for improved convergence and stability. In *International Conference on Machine Learning*, 2022.
- [55] N. Malkin, M. Jain, E. Bengio, C. Sun, and Y. Bengio. Trajectory balance: Improved credit assignment in GFlowNets. In *NeurIPS (NeurIPS)*, 2022.
- [56] N. Malkin, S. Lahlou, T. Deleu, X. Ji, E. Hu, K. Everett, D. Zhang, and Y. Bengio. GFlowNets and variational inference. *International Conference on Learning Representations (ICLR)*, 2023.

- [57] D. Mesquita, P. Blomstedt, and S. Kaski. Embarrassingly parallel MCMC using deep invertible transformations. In *UAI*, 2019.
- [58] T. Minka. Divergence measures and message passing. Technical report, Research, Microsoft, 2005. URL <https://www.seas.harvard.edu/courses/cs281/papers/minka-divergence.pdf>.
- [59] S. Mohamed, M. Rosca, M. Figurnov, and A. Mnih. Monte carlo gradient estimation in machine learning. *J. Mach. Learn. Res.*, 21:132:1–132:62, 2020.
- [60] S. Mohammadpour, E. Bengio, E. Frejinger, and P.-L. Bacon. Maximum entropy gflownets with soft q-learning, 2023.
- [61] R. M. Neal et al. Mcmc using hamiltonian dynamics. *Handbook of markov chain monte carlo*, 2011.
- [62] A. C. Nica, M. Jain, E. Bengio, C.-H. Liu, M. Korablyov, M. M. Bronstein, and Y. Bengio. Evaluating generalization in gflownets for molecule design. In *ICLR2022 Machine Learning for Drug Discovery*, 2022.
- [63] A. B. Owen. *Monte Carlo theory, methods and examples*. 2013.
- [64] L. Pan, N. Malkin, D. Zhang, and Y. Bengio. Better training of gflownets with local credit and incomplete trajectories. *arXiv preprint arXiv:2302.01687*, 2023.
- [65] L. Pan, D. Zhang, A. Courville, L. Huang, and Y. Bengio. Generative augmented flow networks. In *International Conference on Learning Representations (ICLR)*, 2023.
- [66] L. Pan, D. Zhang, M. Jain, L. Huang, and Y. Bengio. Stochastic generative flow networks. In *UAI*, volume 216 of *Proceedings of Machine Learning Research*, pages 1628–1638. PMLR, 2023.
- [67] M. Papini, D. Binaghi, G. Canonaco, M. Pirotta, and M. Restelli. Stochastic variance-reduced policy gradient. In *International Conference on Machine Learning*, 2018.
- [68] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Köpf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala. Pytorch: An imperative style, high-performance deep learning library, 2019.
- [69] B. Poczos and J. Schneider. On the estimation of α -divergences. In *AISTATS*. PMLR, 2011.
- [70] R. Ranganath, S. Gerrish, and D. M. Blei. Black box variational inference. In *AISTATS*, volume 33 of *JMLR Workshop and Conference Proceedings*, pages 814–822. JMLR.org, 2014.
- [71] R. Ranganath, D. Tran, J. Alotaar, and D. M. Blei. Operator variational inference. In *NeurIPS*, pages 496–504, 2016.
- [72] J. Rector-Brooks, K. Madan, M. Jain, M. Korablyov, C.-H. Liu, S. Chandar, N. Malkin, and Y. Bengio. Thompson sampling for improved exploration in gflownets, 2023.
- [73] A. Rényi. On measures of entropy and information. In *Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability, Volume 1: Contributions to the Theory of Statistics*. University of California Press, 1961.
- [74] D. Rezende and S. Mohamed. Variational inference with normalizing flows. In *International conference on machine learning*. PMLR, 2015.
- [75] B. Rhodes and M. U. Gutmann. Variational noise-contrastive estimation. In *AISTATS*, 2019.
- [76] L. Richter, A. Boustati, N. Nüsken, F. J. R. Ruiz, and Ö. D. Akyildiz. Vargrad: A low-variance gradient estimator for variational inference. 2020.
- [77] C. P. Robert et al. *The Bayesian choice: from decision-theoretic foundations to computational implementation*, volume 2. Springer, 2007.

- [78] G. Roeder, Y. Wu, and D. Duvenaud. Sticking the landing: simple, lower-variance gradient estimators for variational inference. In *Proceedings of the 31st International Conference on Neural Information Processing Systems, NIPS'17*, page 6928–6937, Red Hook, NY, USA, 2017. Curran Associates Inc. ISBN 9781510860964.
- [79] T. G. J. Rudner, V. Pong, R. McAllister, Y. Gal, and S. Levine. Outcome-driven reinforcement learning via variational inference. In *NeurIPS*, pages 13045–13058, 2021.
- [80] F. Ruiz and M. Titsias. A contrastive divergence for combining variational inference and mcmc. In *International Conference on Machine Learning*, 2019.
- [81] T. Salimans and D. A. Knowles. On using control variates with stochastic approximation for variational bayes and its connection to stochastic linear regression, 2014.
- [82] M. J. Schervish. *Theory of statistics*. Springer Science & Business Media, 2012.
- [83] M. W. Shen, E. Bengio, E. Hajiramezanali, A. Loukas, K. Cho, and T. Biancalani. Towards understanding and improving gflownet training. In *International Conference on Machine Learning*, 2023.
- [84] J. Shi, Y. Zhou, J. Hwang, M. Titsias, and L. Mackey. Gradient estimation with discrete stein operators. *NeurIPS*, 35, 2022.
- [85] Y. Sun, L. Dong, S. Huang, S. Ma, Y. Xia, J. Xue, J. Wang, and F. Wei. Retentive network: A successor to transformer for large language models, 2023.
- [86] D. Tiapkin, N. Morozov, A. Naumov, and D. Vetrov. Generative flow networks as entropy-regularized rl, 2024.
- [87] E. Todorov. General duality between optimal control and estimation. In *CDC*, pages 4286–4292. IEEE, 2008.
- [88] M. Toussaint and A. J. Storkey. Probabilistic inference for solving discrete and continuous state markov decision processes. In *ICML*, volume 148 of *ACM International Conference Proceeding Series*, pages 945–952. ACM, 2006.
- [89] M.-N. Tran, M. K. Pitt, and R. Kohn. Adaptive metropolis–hastings sampling using reversible dependent mixture proposals. *Statistics and Computing*, 2016.
- [90] C. Tsallis. Possible generalization of boltzmann-gibbs statistics. *Journal of statistical physics*, 52:479–487, 1988.
- [91] M. J. Wainwright and M. I. Jordan. Graphical models, exponential families, and variational inference. *Found. Trends Mach. Learn.*, 1(1-2):1–305, 2008.
- [92] X. Wang, T. Geffner, and J. Domke. Joint control variate for faster black-box variational inference. In *AISTATS*, volume 238 of *Proceedings of Machine Learning Research*, pages 1639–1647. PMLR, 2024.
- [93] L. Weaver and N. Tao. The optimal reward baseline for gradient-based reinforcement learning. *arXiv preprint arXiv:1301.2315*, 2013.
- [94] V. D. Wild, R. Hu, and D. Sejdinovic. Generalized variational inference in function spaces: Gaussian measures meet bayesian deep learning. In *NeurIPS*, 2022.
- [95] D. Williams. *Probability with Martingales*. Cambridge University Press, 1991.
- [96] R. J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 1992.
- [97] B. Xu, N. Wang, T. Chen, and M. Li. Empirical evaluation of rectified activations in convolutional network. *arXiv preprint arXiv:1505.00853*, 2015.
- [98] K. Xu, W. Hu, J. Leskovec, and S. Jegelka. How powerful are graph neural networks? *International Conference on Learning Representations (ICLR)*, 2019.

- [99] P. Xu, F. Gao, and Q. Gu. An improved convergence analysis of stochastic variance-reduced policy gradient. In *UAI*, 2020.
- [100] Z. Yang. *Molecular Evolution: A Statistical Approach*. Oxford University PressOxford, May 2014. ISBN 9780191782251. doi: 10.1093/acprof:oso/9780199602605.001.0001.
- [101] J. S. Yedidia, W. T. Freeman, and Y. Weiss. Bethe free energy, kikuchi approximations, and belief propagation algorithms. *Advances in neural information processing systems*, 13(24), 2001.
- [102] M. Yin and M. Zhou. Semi-implicit variational inference. In *International conference on machine learning*. PMLR, 2018.
- [103] L. Yu and C. Zhang. Semi-implicit variational inference via score matching. *arXiv preprint arXiv:2308.10014*, 2023.
- [104] M. Zaheer, S. Kottur, S. Ravanbakhsh, B. Poczos, R. R. Salakhutdinov, and A. J. Smola. Deep sets. In *NeurIPS*, 2017.
- [105] C. Zhang, B. Shahbaba, and H. Zhao. Hamiltonian monte carlo acceleration using surrogate functions with random bases. *Statistics and computing*, 2017.
- [106] D. Zhang, R. T. Chen, N. Malkin, and Y. Bengio. Unifying generative models with gflownets and beyond. *ICML Beyond Bayes workshop*, 2022.
- [107] D. Zhang, N. Malkin, Z. Liu, A. Volokhova, A. Courville, and Y. Bengio. Generative flow networks for discrete probabilistic modeling. In *International Conference on Machine Learning (ICML)*, 2022.
- [108] D. Zhang, R. T. Q. Chen, C.-H. Liu, A. Courville, and Y. Bengio. Diffusion generative flow samplers: Improving learning signals through partial trajectory optimization, 2023.
- [109] D. Zhang, H. Dai, N. Malkin, A. Courville, Y. Bengio, and L. Pan. Let the flows tell: Solving graph combinatorial optimization problems with gflownets. In *NeurIPS (NeurIPS)*, 2023.
- [110] M. Y. Zhou, Z. Yan, E. Layne, N. Malkin, D. Zhang, M. Jain, M. Blanchette, and Y. Bengio. PhyloGFN: Phylogenetic inference with generative flow networks. In *The Twelfth International Conference on Learning Representations*, 2024.
- [111] H. Zimmermann, F. Lindsten, J. van de Meent, and C. A. Naesseth. A variational perspective on generative flow networks. *Trans. Mach. Learn. Res.*, 2023, 2023.

A 相关工作

生成流网络。GFlowNets (GFlowNets) [3, 4] 最初被提出作为一种强化学习算法，用于在一个离散环境中通过从由奖励函数诱导的分布中采样来寻找多样化的高价值状态。不久之后，它们被扩展到在任意拓扑空间中从复杂分布中采样 [48]。值得注意的是，这一系列模型成功应用于各种问题，包括结构学习和因果发现 (causal discovery) [13, 15, 16]、离散概率建模和图形模型 (graphical models) [24, 30, 106, 107]、组合优化和随机控制 (stochastic control) [108, 109]、药物发现 (drug discovery) [3, 33, 62]、生物序列设计 (biological sequences) [32]、自然语言处理 (natural language processing) [29] 以及空场景分类 (aerial scene classification) [23]。与此同时，在这些进展的基础上，有关开发更高效训练算法的文献也在不断增长，主要从现有的强化学习技术中获得启发 (inspiration) [4, 40, 55, 83]——主要借鉴了强化学习领域的现有技术 [60, 64, 65, 86]。同样地，Tiapkin 等人 [86] 展示了将 GFlowNets 框架视为熵正则化的强化学习的可能性。在一项与我们的研究紧密相关的研究中，Malkin 等人 [56] 证明了 GFlowNets 与离散分布的层次变分推断 (HVI) 之间的等价性；然而，在使用来自变分推断文献中的发散方法训练 GFlowNets 时，作者发现相对于传统的流匹配目标没有改进。因此，超越离散分布，本工作提供了对通过直接优化通常用于变分推断训练的一组发散来训练 GFlowNets 的最终分析，给出了有效使用发散目标进行高效学习程序应用于 GFlowNets 模型的明确背景和条件。

强化学习作为推理。强化学习 (RL) 已被广泛研究作为一种概率推理的形式，产生了相关洞见，并被另称为控制作为推理。Todorov [87] 展示了估计与最优控制之间的对偶性，确立了在何种条件下可以将估计算法应用于控制问题。Kappen 等人 [38] 表明最优控制问题可以被表述为图模型中的推理问题，提供了解决控制任务的统一视角。Levine [50] 提出了一个完整且现代的 RL 形式化，特别与变分推断 (VI) 相联系。Rudner 等人 [79] 进一步整合了 RL 与 VI 方法，展示了利用结果驱动的 RL 与变分推断来优化策略分布的概念和算法优势。进一步发展，Toussaint 和 Storkey [88] 应用了近似概率推理方法来解决具有离散和连续状态的马尔可夫决策过程 (MDP)。该方法也与基于模型的 RL 技术，如 PILCO 相一致，后者利用概率模型来提高策略搜索的数据效率 [14]。Deleu 等人的近期工作 [17] 将离散概率推理定位为多路径环境中的控制问题，强调了控制理论与概率建模在 GFlowNets 上下文中的协同作用。这一系列工作与本文提出的方法相关，比较了轨迹平衡和流匹配损失的优化，这些损失与由 GFlowNet 建模的顺序决策相关，以及与 f-发散测度最小化程序——与近似变分推断和广义后验推断相关 [36, 45, 51, 91, 94]。

发散测度与梯度减少用于 VI。近似推断通过变分推断 (VI) 方法 [6, 7, 36, 91] 最初依赖于消息传递和坐标上升方法来最小化未归一化分布与参数化可处理分布族中的提议之间的 KL 发散。尽管优化视角最初具有普遍性，但算法的具体实现通常需要针对特定模型类别的专门更新方程和学习目标。另一方面，自动微分算法和软件的发展 [2] 以及随机梯度估计器 [59] 的开发解锁了通用梯度基于优化算法在广泛模型类别中的推理和学习任务中的潜在应用。开创性的工作如黑盒变分推断 (Black-Box VI, BBVI) [70]，使用 REINFORCE/评分函数估计器，以及自动微分变分推断 (Automatic Differentiation VI, ADVI) [46]，使用重新参数化和变量变换，展示了在通用模型中进行贝叶斯推断的实用算法，包括结合经典统计建模与神经网络的模型。总体而言，Mohamed 等人 [59] 解释了主要梯度估计器的发展：评分函数 [11, 70, 96, 102] 和路径梯度估计器，也称为参数化技巧 [42, 43, 74]。原始的 REINFORCE/评分函数估计器以其高方差著称 [11, 70, 76, 96]，这促使了一系列探索方差缩减技术的研究。在最初的 BBVI 提案中，Ranganath 等人 [70] 探讨了 Rao-Blackwell 化，结合迭代条件期望和控制变量，使用评分函数估计器（因其零

期望作为控制变量。后续工作继续完善这些技术；刘等人 [53] 使用 Rao-Blackwell 化的随机梯度进行离散分布处理，而 Kim 等人 [39] 以及王等。[92] 探讨了联合控制变量及 BBVI 中可证明的线性收敛。此外，Domke [21] 以及 Domke [20] 提供了平滑性和梯度方差的保证，进一步增强了 VI 方法中得分函数估计器的鲁棒性。我们的工作表明，有效的方差缩减技术应用于 f -发散最小化训练可以显著提高过程的收敛速度和稳定性。在理论和实践中，我们观察到方差减少 f -发散 GFlowNets 训练结果与方差减少得分函数估计量工作之间具有高度兼容性。此外，通过证明这些技术适用于广泛的模型和优化目标，包括连续和混合结构支持，我们推进了 GFlowNets 的发展。 f -发散最小化训练更接近广义贝叶斯推断和广义变分推理的近期概念 [45] 以及函数空间中的变分推断 [94] ——其共同线索在于将后验推断视为由某种发散测度引导的优化问题。这种泛化可以使 GFlowNets 应用于多样化的机器学习任务，增强它们的灵活性和实用相关性。

B 生成任务的详细描述

集合生成 [3, 34, 64, 65]. $\mathcal{S}$ 包含从固定存款 $\mathcal{D}$ 中提取元素的大小不超过 N 的集合，其中固定存款的大小为

$D \geq N$ 和 $s_o = \emptyset$ 。对于 $s \in \mathcal{S}$ ，当 $|s| < N$ ， $\kappa_f(s, \cdot)$ 是一个在 $(\{s \cup \{d\} : d \in \mathcal{D} \setminus s\})$ 诱导的 σ -代数上的计数测度；对于 $|s| = N$ ， $\kappa_f(s, \cdot) = \delta_{s_f}$ 。然后， $\mathcal{X} = \{s \in \mathcal{S} : |s| = N\}$ 。类似地， $\kappa_b(s, \cdot)$ 的支持是 $\{s \setminus \{d\} : d \in \mathcal{D}\}$ 对于 $s \neq s_o$ 。我们通过 $\log r(x) = \sum_{d \in x} f(d)$ 定义未归一化的目标密度 $f(d)$ ，其中固定函数为 $f: \mathcal{D} \rightarrow \mathbb{R}$ 。我们将 $p_F(s, \cdot)$ 参数化为深度集合 [104]，并将 $p_B(s, \cdot)$ 固定为对于 $s \in \mathcal{S}$ 的均匀密度。

自回归序列生成 [32, 55]。一个序列 s 在 $\mathcal{D}^n$ 中，对于任何 $K > n$ ，通过 $s \mapsto \{(s_m, m) : 1 \leq m \leq n\} \cup \{(\perp, m) : K \geq m > n\}$ 与 $\mathcal{D} \times [K]$ 的一个元素一一对应。 $\perp$ 是一个表示序列结束的标记。在此背景下，我们令 $\mathcal{S} \subset \mathcal{P}(\mathcal{D} \times [N+1])$ 为大小不超过 N ，i.e., if $s \in \mathcal{S}$ 的序列集，并且 $(\perp, n+1) \in s$ ，则 $(d, m) \in s$ 当且仅当 $d = \perp$ 对于 $n < m \leq N+1$ 成立，并且存在 $v \in (\mathcal{D} \cup \{\perp\})^n$ 使得 $(v_m, m) \in s$ 对于 $m \leq n$ 成立；初始状态是 $s_o = \emptyset$ 。为了简洁起见，我们写作 $d \notin s$ ，这意味着对于每个 i ，都有 $(d, i) \notin s$ 成立。接下来，如果 $|s| < N$ 和 $\perp \notin s$ ，则 $\kappa_f(s, \cdot)$ 是在 $\{s \cup \{(d, |s|+1)\} : d \in \mathcal{D} \cup \{\perp\}\}$ 处的支持计数测度；如果 $|s| = N$ ，则是在 $\{s \cup \{(\perp, N+1)\}\}$ 处。类似地， $\kappa_b(s, \cdot)$ 是在 $\{s \setminus \{(d, i)\} : (d, i) \in s\}$ 处的支持计数测度。一个（有根的）系统发生树是一棵完全二叉树，其叶子节点带有标签，边具有权重；每个叶子节点对应一种生物物种，临边的权重表示进化时间。 (d, i) 形式上，我们令 $\mathcal{B}$ 为所有可能的生物物种集合 $\mathcal{B}$ 上的有限索引的观测到的物种面接口树的概率表是 $\log r(x) = \sum_{(d,i) \in x} f(d)g(i)$ 。对于函数 $f: \mathcal{D} \rightarrow \mathbb{R}$ 和 $g: \mathcal{B} \rightarrow \mathbb{R}$ ，我们使用多层感知机来参数化 $p(s, \cdot)$ ； $\mathcal{B}$ 作为加权有向树 $G_B = (\mathcal{B}, \mathcal{E}_B, \omega_B)$ 带有边 $\mathcal{E}_B$ 具有权重分配 ω_B ；

我们记其根为 $r(G_B)$ 。在这些条件下，我们定义 $\mathcal{S} = \{\bigcup_{k=1}^K G_{\mathcal{F}_k} : \bigcup_{k=1}^K \mathcal{F}_k = \mathcal{B}\}$ 是一棵树作为基于 phy 构建的森林集

逻辑生成树覆盖不相交子集 $\mathcal{B}$ ； $\bigcup_k \mathcal{F}_k = \mathcal{B} \wedge \mathcal{G}_{\mathcal{F}_k}$ 表示非空集合的不相交并集，而 $\bigcup_{b \in \mathcal{B}} G_{\{b\}}$ 是由单元素树

$s_o = \bigcup_{\text{合并 } G_{\mathcal{F}_k} \text{ 和 } G_{\mathcal{F}_j}, A(G_{\mathcal{F}_k}, G_{\mathcal{F}_j})}$ 组成的森林 $G_{\{b\}}$ 。此外，我们定义两个系统发生树的

$r(G_{\mathcal{F}_k} \cup G_{\mathcal{F}_j})$ 来获得的树，并相应地扩展边的权重。相比之下，树的分解 $G_{\mathcal{F}}, R(G_{\mathcal{F}})$ 返回通过移除

$r(G_{\mathcal{F}})$ 从 $G_{\mathcal{F}}$ 所获得的两个子树的并集。然后， $\kappa_f(s, \cdot)$ 是在 $\{\bigcup_K$ 上支撑的计数测度

；如果 $s = \bigcup_{k=1}^K G_{\mathcal{F}_k} \cup A(G_{\mathcal{F}_k}, G_{\mathcal{F}_j})$ ，因此， $(i, j) \in \mathcal{B}$ 的系统发生树集合 $\mathcal{S}$ 类似地， $\kappa_b(s, \cdot)$ 的支持

度是 $\{\bigcup_{k=1, k \neq j}^K G_{\mathcal{F}_k} \cup R(G_{\mathcal{F}_j}) : i \in [K] \wedge r(G_{\mathcal{F}_i}) \notin \mathcal{B}\}$ 对于 $s = \bigcup_{k=1}^K G_{\mathcal{F}_k}$ 和 $K \leq |\mathcal{B}|$ 。最后，未

归一化的目标是由 JC69 突变模型给定的后验分布 [37]，基于物种在 $\mathcal{B}$ 中的基因组序列数据集。更具体地说，我们设先验为均匀分布-

通过高效的 Felsenstein 算法计算模型诱导的似然函数 [25]。我们假设边的权重是常数。参见 [100] 详情请参阅。本文参数化 $p_F(s, \cdot)$ 使用 GIN [98] 并修复 $p_B(s, \cdot)$ 作为均匀分布。

高斯混合模型 [48, 108] GFlowNets 在连续空间中的训练颇具挑战性，而在这种设置下设计高度表达性的模型的问题仍未得到解决。[16, 48] 然而，正如我们在第 5.2 节所示，基于发散的测度似乎是非常有效的自回归采样的学习目标，适用于稀疏高斯混合。对于一个 d -维高斯分布，以及 $s_o = (0, 0)$ ：注意 $\mathcal{S}$ 与 $\mathbb{R}^d$ 同构。同样地，对于 $s = \{(x_i, i)\}_{i=1}^n$ ， $\kappa_f(s, \cdot)$ 是 $\{s \cup \{(x, n+1)\} : x \in \mathbb{R}\}$ 上的勒贝格测度，如果 $n < d$ 成立，则为 $\kappa_f(s, \cdot) = \delta_{s_f}$ 。特别地， $\mathcal{X} \stackrel{+}{\sim}$ 。

$\mathcal{S} = \{(0, 0), (x_i, i) : 1 \leq i \leq n\} : n \leq d, x \in \mathbb{R}^n\} \subset \{(0, 0)\} \cup \mathcal{P}(\mathbb{R} \times [d])$
is isomorphic to $\mathbb{R}^d$ of $\mathbb{R}^n$ for $n \leq d$.
此外， $\kappa_b(s, \cdot)$ 是在 $\{s \setminus \{(x, |s|)\} : x \in \mathbb{R}\}$ 上的测度，它与 $\mathbb{R}^n$ 同构，而后者是一个单元元素集。我们将目标密度定义为高斯分布的均匀混合， $\frac{1}{n} \sum_{i=1}^n \mathcal{N}(\mu_i, \sigma^2 I)$ 其中 $\mu_i \in \mathbb{R}^d$ 。我们类似地定义 $p_F(s, \cdot)$ 为一维高斯分布的混合，其均值和方差通过多层感知机 (MLP) 学习得到 [48]。
 $\{s \in \mathcal{S} : \max_{(x,i) \in s} i = d\}$ isomorphic to $\mathbb{R}^d$ which is a $\mathbb{R}^d$

香蕉分布。 [57, 75] 我们考虑从香蕉分布中采样，该分布由

$$\mathcal{N} \left(\begin{bmatrix} x_1 \\ x_2 + x_1^2 + 1 \end{bmatrix} \middle| \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0.9 \\ 0.9 & 1 \end{bmatrix} \right). \quad (8)$$

鉴于其几何形状，此分布是近似贝叶斯推断文献中的常见基线 [89, 103, 105]。此任务等同于从高斯分布混合中采样，只是模型在方程 (8) 中指定了不同的目标密度。此外，我们依赖哈密顿蒙特卡罗 (HMC) 的实现 [5, 61]，该实现由 Stan 提供 [12]，以获得来自 (8) 的精确样本。

附录 C 证明 我们将考虑轨迹的可测空间 $(\mathcal{P}_S, \Sigma_P)$ ，其中 $\mathcal{P}_S = \{(s, s_1, \dots, s_n, s_f) \in \mathcal{S}^{n+1} \times \{s_f\} : 0 \leq n \leq N-1\}$ 和 Σ_P 是由 σ 生成的 $\bigcup_{n=0}^{N-1} \Sigma^{\otimes n}$ -代数。为了记号上的方便，我们使用相同的字母来表示 $(\mathcal{S}, \Sigma)$ 及其在 $(\mathcal{P}_S, \Sigma_P)$ 中的自然乘积对应的测度和核函数，这些测度和核函数的存在性由 **Carathéodory** 延拓定理保证 [95]；例如， $\nu(B) = \nu^{\otimes n}(B)$ 对于 $B = (B_1, \dots, B_n) \in \Sigma^{\otimes n}$ 并且 $p_{F_\theta}(\tau|s_o; \theta)$ 是...的密度 $P_F^{\otimes n+1}(s_o, \cdot)$ 对于 $\tau = (s_o, s_1, \dots, s_n, s_f)$ 相对于 $\mu^{\otimes n}$ 。在这种情况下，我们将写作 τ 对于一个一般的元素 $\mathcal{P}_S$ 并 x 对于其终态（根据定义 1，终态是唯一的）。

附录 C.1 命题 1 的证明

我们将证明预期的在线 TB 损失的梯度与前向和后向策略之间的 KL 发散的梯度相匹配。首先，注意到

$$\begin{aligned} \nabla_\theta \mathcal{D}_{KL}[P_F || P_B] &= \nabla_\theta \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \left[\log \frac{p_F(\tau|s_o; \theta)}{p_B(\tau)} \right] \\ &= \nabla_\theta \int_\tau \log \frac{p_F(\tau|s_o; \theta)}{p_B(\tau)} dP_F(s_o, d\tau) \\ &= \nabla_\theta \int_\tau \log \frac{p_F(\tau|s_o; \theta)}{p_B(\tau)} p_F(\tau|s_o; \theta) d\kappa_f(s_o, d\tau) \\ &= \int_\tau \nabla_\theta \log \frac{p_F(\tau|s_o; \theta)}{p_B(\tau)} P_F(s_o, d\tau) \\ &\quad + \int_\tau \log \frac{p_F(\tau|s_o; \theta)}{p_B(\tau)} \nabla_\theta p_F(\tau|s_o; \theta) d\kappa_f(s_o, d\tau) \end{aligned}$$

by Leibniz's rule for integrals and the product rule for derivatives. Then, since $\nabla_\theta f(\theta) = f(\theta) \nabla \log f(\theta)$ for any differentiable function $f : \theta \mapsto f(\theta)$,

$$\begin{aligned} &\nabla_\theta \mathcal{D}_{KL}[P_F || P_B] \\ &= \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \left[\nabla_\theta \log p_F(\tau|s_o) + \log \frac{p_F(\tau|s_o)}{p_B(\tau)} \nabla_\theta \log p_F(\tau|s_o) \right] \\ &= \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \left[\log \frac{p_F(\tau|s_o)}{p_B(\tau)} \nabla_\theta \log p_F(\tau|s_o) \right]; \end{aligned} \quad (9)$$

为了简洁起见，我们省略了 P_F （以及由此产生的 p_F ）对参数 θ 的依赖关系。另一方面，

$$\nabla_{\theta} \mathcal{L}_{TB}(\tau; \theta) = 2 \left(\log \frac{p_F(\tau|s_o; \theta)}{p_B(\tau)} \right) \nabla_{\theta} \log p_F(\tau) \quad (10)$$

根据导数的链式法则。因此，

$$\mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \nabla_{\theta} \mathcal{L}_{TB}(\tau; \theta) = 2 \nabla_{\theta} \mathcal{D}_{KL}[P_F || P_B], \quad (11)$$

确保了在期望梯度方面的等价性，即 $\mathcal{L}_{TB}$ 和 $\mathcal{D}_{KL}$ 在比有限支持分布 [56] 更广泛的背景下成立。

附录 C.2 引理 1 的证明

从此以后，我们将反复提到期望梯度的得分估计器 [96]，即，

$$\nabla_{\theta} \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} [f_{\theta}(\tau)] = \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} [\nabla_{\theta} f_{\theta}(\tau) + f_{\theta}(\tau) \nabla_{\theta} \log p_F(\tau|s_o; \theta)], \quad (12)$$

可以使用前一节中的论点推导出。在此背景下，Renyi- α 的发散满足

$$\nabla_{\theta} R_{\alpha}(P_F || P_B) = \frac{\nabla_{\theta} \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} [g(\tau, \theta)]}{(\alpha - 1) \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} g(\tau, \theta)},$$

含 $g(\tau; \theta) = (p_B(\tau|x)r(x)/p_F(\tau|s_o; \theta))^{1-\alpha}$ 及 $\alpha \neq 1$; 类似地，Tsallis- α 的发散也遵循 by

$$\nabla_{\theta} T_{\alpha}(P_F || P_B) = \frac{1}{(\alpha - 1)} \nabla_{\theta} \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} [g(\tau, \theta)]. \quad (13)$$

通过将 $\nabla_{\theta} \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} [g(\tau, \theta)]$ 替换为由方程 (12) 给出的相应得分估计量，该陈述随之成立。

C.3 证明 引理 2 前向 KL 发散。 通过应用 Leibniz 积分法则，可以直接获得 $\mathcal{D}_{KL}[P_B || P_F]$ 的梯度，

$\nabla_{\theta} \mathcal{D}_{KL}[P_B || P_F] = -\mathbb{E}_{\tau \sim P_B(s_f, \cdot)} [\nabla_{\theta} \log p_F(\tau|s_o; \theta)]$ ，因为平均分布 P_B 不依赖于变化的参数 θ 。然而，在我们对样本 P_F 进行蒙特卡洛平均计算时，我们应用重要性重加权方案 [63, 第 9 章] 到之前的期望值上，从而推断出，至多乘以一个正数常量，

$$\nabla_{\theta} \mathcal{D}_{KL}[P_B || P_F] \stackrel{C}{=} -\mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \left[\frac{p_B(\tau|x)r(x)}{p_F(\tau|s_o; \theta)} \nabla_{\theta} \log p_F(\tau|s_o; \theta) \right],$$

$\stackrel{C}{=}$ 表示在正乘法常数意义下的等价。我们强调，大多数现代随机梯度优化方法，如 Adam [41] 和 RMSProp [28]，当我们将估计的梯度乘以一个固定量时，这些方法保持不变；因此，我们可以安全地计算梯度直到乘法常数。

逆 Kullback-Leibler (KL) 发散。 我们在方程 (9) 中验证了这一点

$$\nabla_{\theta} \mathcal{D}_{KL}[P_F || P_B] = \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \left[\log \frac{p_F(\tau|s_o)}{p_B(\tau)} \nabla_{\theta} s_{\theta}(\tau) \right].$$

由于 $p_B(\tau) = p_B(\tau|x)r(x)/Z$ 和 $\mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \nabla_{\theta} s_{\theta}(\tau) = 0$ ，量 $\nabla_{\theta} \mathcal{D}_{KL}[P_F || P_B]$ 可能

rewri

$$\begin{aligned} \nabla_{\theta} \mathcal{D}_{KL}[P_F || P_B] &= \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \left[\log \frac{p_F(\tau|s_o)}{p_B(\tau)} \nabla_{\theta} s_{\theta}(\tau) \right] \\ &\quad + \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} [(\log Z) \nabla_{\theta} s_{\theta}(\tau)] \\ &= \mathbb{E}_{\tau \sim P_F(s_o, \cdot)} \left[\text{曰志} \frac{p_F(\tau|s_o)}{p_B(\tau|x)r(x)} \nabla_{\theta} s_{\theta}(\tau) \right], \end{aligned}$$

其中 x 是轨迹 τ 对应的终端状态。从而证明了引理 2 中的陈述。




图 6: 通过最小化 TB 损失训练的 GFlowNet 的学习曲线。曲线的平滑性突出了由不使用得分函数估计器的随机梯度 $\mathcal{L}_{TB}$ 引起的优化步骤的低方差。

附录 C.4 命题 2 的证明

我们将推导出向量值控制变量的最佳基线的表达式。为此，设 f 为平均函数， $g: \tau \mapsto g(\tau)$ 为控制变量。不失一般性地假设，对于轨迹空间上的平均分布 π ，有 $\mathbb{E}_\pi[g] = 0$ 。在这种情况下，控制变量 a^* 的最佳基线通过以下方式找到

$$a^* = \arg \min_{a \in \mathbb{R}} \text{Tr}(\text{Cov}_{\tau \sim \pi}[f(\tau) - a \cdot g(\tau)]). \quad (14)$$

因此，

$$a^* = \arg \min_{a \in \mathbb{R}} \text{Tr} \left(-2a \cdot \text{Cov}_\pi[f(\tau), g(\tau)] + a^2 \text{Cov}_\pi(g(\tau)) \right),$$

这是一个凸优化问题，其解为

$$\begin{aligned} a^* &= \frac{\text{Tr}(\text{Cov}_\pi[f(\tau), g(\tau)])}{\text{Tr}(\text{Cov}_\pi[g(\tau)])} \\ &= \frac{\text{Tr} \mathbb{E}_\pi[(f - \mathbb{E}_\pi[f(\tau)])g(\tau)^T]}{\text{Tr} \mathbb{E}_\pi[g(\tau)g(\tau)^T]} \\ &= \frac{\mathbb{E}_\pi[\text{Tr}(f - \mathbb{E}_\pi[f(\tau)])^T g(\tau)]}{\mathbb{E}_\pi[\text{Tr} g(\tau)^T g(\tau)]} \\ &= \frac{\mathbb{E}_\pi[(f - \mathbb{E}_\pi[f(\tau)])^T g(\tau)]}{\mathbb{E}_\pi[g(\tau)^T g(\tau)]}, \end{aligned} \quad (15)$$

其中我们利用了迹的循环性质。此方程与命题 2 的结果完全匹配。在实践中，我们对反向 KL 和 α -发散都使用 $g(\tau) = \nabla_\theta \log p_F(\tau)$ ，这导致了一个依赖于样本梯度的非线性基线 a^* ，因此难以在 GPU 驱动自动微分框架中高效计算。因此，我们使用方程 (6) 来估计 a^* 。

附录 D 额外实验

基于流网络目标的梯度方差。 图 6 展示了生成任务中 TB 损失的学习曲线。值得注意的是，它突出了优化步骤的低方差——与基于发散的方法不同，这些方法不依赖于得分函数估计器——并且表明为估计这些目标的梯度而设计控制变量可能不会显著有帮助。此外，梯度 $\mathcal{L}_{TB}$ 非线性地依赖于得分函数 $\log p_F$ ，因此不清楚如何在这种情况下实现计算高效的方差缩减技术。

用于序列生成的前向 Kullback Leibler (KL)。 图 3 显示，在收敛速度方面，替代方法优于训练以最小化前向 KL 的 GFlowNet。这种表现不佳的一个可能原因是底层重要性采样估计器引起的高方差。为了验证这一点，我们重新运行相应的实验，将前向 KL 估计器轨迹批处理的大小增加到 1024。图 7 展示了




图 7: 使用更大批处理的序列生成结果。

实验结果，增加批处理大小对应于方差较小的估计器，加速了 GFlowNet 的训练收敛。更广泛地说，这表明专门针对 GFlowNet 的方差缩减技术的设计，我们留待未来的工作，可能会导致这一类模型的显著改进。

附录 实现细节

以下段落提供了进一步的实现细节。关于代码的开放访问，我们将在接受后公开代码。

共享配置。 对于每个生成任务，我们使用 Adam 优化器 [41] 进行随机优化，采用的学习率为 10^{-1} 对于 $\log Z_\theta$ 当最小化 $\mathcal{L}_{TB}$ 和 10^{-3} 对于其余参数，遵循先前的工作 [48, 55, 56, 65]。我们使学习率沿训练过程呈多项式衰减至 0，类似于 [85]。此外，我们使用 LeakyReLU [97] 作为所有实现的神经网络的非线性激活函数。

集合生成。 我们实现了一个由两个 64 维层组成的多层感知机来参数化策略的对数概率。我们在 512 个训练轮次中训练模型，每批包含 128 条轨迹用于估计梯度。此外，我们令 $D = 32$ 和 $N = 16$ 分别为源集和目标集的大小。

自回归序列生成。 我们使用一个由两个 64 维层组成的多层感知机来参数化前向策略的对数概率；我们填充序列以考虑其可变大小。我们分别考虑 $D = 8$ 和 $N = 6$ 为源集和序列的大小。为了近似梯度，我们依赖于一批 128 个序列。

贝叶斯系统发育推断。 我们使用一个两层的 GIN [98] 来参数化前向策略的对数概率，其中隐含嵌入维度为 64，并线性投影到 $\log p_F$ 。此外，我们模拟了 JC69 模型 [37] 以获得每个观察物种的 25 个核苷酸序列，设置 $\lambda = 0.3$ 为瞬时突变率；参见 [100] 了解计算系统发育学和分子进化的介绍。为了估计梯度，我们依赖于每批 64 条轨迹。

高斯分布的混合。 我们考虑一个由 9 个二维高斯分布在 $\mu_{ij} = (i, j)$ 处中心化的混合分布，对于 $0 \leq i, j \leq 2$ ，每个分布具有各向同性的方差 10^{-1} ；参见图 1。我们使用一个包含两个 64 维层的多层感知机来参数化前向策略。

香蕉形状分布。 该模型由方程 (8) 指定。我们也考虑使用一个包含两个 64 维层的多层感知机来参数化前向策略。