

非循环生成流网络理论

Leo Maxime Brunswic^{1,2}, Yinchuan Li^{3*}, Yushun Xu¹, Shangling Jui¹, Lizhuang Ma²

¹ Huawei Shanghai Research Center

² Jiaotong Shanghai University

³ Huawei Noah's Ark Lab, Beijing, China

{leomaximebrunswic, liyinchuan, jui.shangling}@huawei.com, xuyushun1@hisilicon.com, ma-lz@cs.sjtu.edu.cn

摘要

GFlowNets 是一种新颖的基于流的方法，用于通过一系列动作生成对象，并使生成的概率与给定的正奖励成比例。我们致力于放宽限制 GFlowNets 应用范围的假设，特别是：非循环性（或缺乏非循环性）。为此，我们在可测空间上扩展了 GFlowNets 的理论，包括没有循环限制的连续状态空间，并在这一广义背景下提供了一个关于循环的泛化。我们展示了迄今为止使用的损失函数会使流陷入循环，并定义了一类解决此问题的损失函数。在图和连续任务上的实验验证了这些原则。

1 引言

Bengio 等人 (Bengio 等人 2021a,b; Zhang 等人 2022; Madan 等人 2022; Malkin 等人 2022) 引入了 GFlowNets (GFN)：一种新的多样化候选生成方法。GFN 的目标是在有向无环图 (DAG) 的状态上按某个奖励函数的比例进行采样 (参见第 2 节的简要介绍)。通过这种方式，GFN 可以与 MCMC (Brooks 等人 2011) 和分布式强化学习方法 (Bellemare, Dabney 和 Munos 2017) 相比较。Bengio 等人在具有挑战性的任务上进行的实验表明，GFN 相对于基于 MCMC 的方法具有优势。GFlowNets 还成功应用于图神经网络 (Li 等人 2023a,b)、领域自适应 (Zhu 等人 2023)、优化 (Zhang 等人 2023a)、大语言模型训练 (Li 等人 2023c)、离线数据 (Wang 等人 2023) 和其他领域。最初将 GFN 限制在 DAG 上是为了满足特定应用的需求，在这些应用中，解决方案是通过应用一系列构造器来构建的，例如分子生成的情况。然而，这种限制似乎过于严格：GFN 和 MCMC 方法都对未归一化的分布进行采样，尝试将 GFN 作为 MCMC 的替代品 (光线追踪 (Veach 和 Guibas 1997) 是 MCMC 的典型工业应用) 导致需要将 GFN 泛化到连续状态空间。此外，某些任务具有内在的对称性，这些对称性更适合用非循环图建模，比如凯莱图

魔方。更糟糕的是，状态空间和转换可能受到限制，使得循环不可避免：可以想象一个游戏中，对手可能会迫使返回到之前的状态。最近的研究 (李等人, 2023d; 拉卢等人, 2023) 尝试解决了前者，但后者仍未得到解决。




图 1: 在网格上生成的路径: 左图使用非无环损失 (我们的方法); 右图使用 FM 损失 (Bengio 等人, 2021a)。

本文的主要目的是澄清在具有循环空间上训练生成流时所遇到的问题。特别地，我们研究这些问题对梯度下降最小化的影响，这些最小化包括在先前工作中引入的 Flow-Matching、Detailed Balance 和 Trajectory Balance 损失函数，用于训练 GFN。鉴于本工作的泛化程度比最初的 GFN 框架高出几个层次，我们使用“生成流”这一术语，使得 GFN 成为生成流在 DAG 上的特例。

本文的主要贡献与概述 1) 在第 3.1 节中，我们描述了图上损失函数的一个性质，该性质导致流被陷阱到循环中，并定义了一种稳定性概念，以控制这种对训练有害并增加推理成本的行为。2) 第 3.2 节从与 Lahlou 等人 (2023) 稍有不同的角度描述了 GFN 的基本测度理论泛化，去除了内置的无环约束。数学框架通过定义一种合适的循环泛化而得到丰富。3) 在第 4 节中，我们将流匹配、细致平衡和轨迹平衡损失重新表述为 f -发散的不同变体，并证明这些损失在我们引入的意义上是不稳定的。我们

Corresponding Author: Yinchuan Li

Copyright © 2024, Association for the Advancement of Artificial Intelligence (www.aaai.org). All rights reserved.

提出一系列稳定的损失函数和正则化方法以增强稳定性。4) 我们在第 5 节通过解决 Hypergrids、Cayley 图 (GFN) 以及来自 Gym 的连续任务 (Brockman 等, 2016; Towers 等, 2023) (CFlowNets) 上的玩具问题来展示稳定性的影响。附录 A 和附录 B 分别提供了额外的理论结果和证明。

2 背景：有向无环图上的生成流

参照 Bengio 等人 (2021a) 及 Bengio 等人 (2021b)，设 G 为一个由其 (可数的) 状态集给出的有向无环图 (DAG) $S := S^* \cup \{s_0, s_f\}$ 及其边集 E^1 包含源状态和汇状态 s_0 并且 s_f 。为了简化起见，假设 G 不是一个多重图。在 G 上的边流是一个分配 F 在每条边上赋予一个非负值， $\forall s \rightarrow s', F(s \rightarrow s') \geq 0$ 。

定义 1. 流是一个满足所谓的流匹配约束 (1) 的边流 F 。给定一个奖励 $R: S^* \rightarrow \mathbb{R}$ ，如果一个边流满足奖励约束 (2)，则称其为一个 R -边流。一个 R -流是指同时满足两个

$$\forall s \in S^*, \quad F(s \rightarrow s_f) = R(s). \quad (1)$$

$$\forall s \in S^*, \quad F(s \rightarrow s_f) = R(s). \quad (2)$$

在这样的有限图上定义的任何边流 G 都会诱导出一个马尔可夫链 $(s_0, s_1, s_2, \dots, s_f)$ ，该链从源点开始 s_0 ，在汇点停止 s_f ，并且在每次时间点 t 上满足条件

$$\mathbb{P}(s_{t+1} = s | s_t) = \frac{F(s_t \rightarrow s)}{\sum_{s' \rightarrow s} F(s_t \rightarrow s')} \quad (3)$$

只要这个公式有意义。这个马尔可夫链会在时间点 s 采样一个状态 τ ，如果 $s_\tau = s$ 和 $s_{\tau+1} = s_f$ 成立，则时间点 τ 即为采样时间。Bengio

等人 (2021a) 的基本结果表明，方程 (1) - (3) 意味着在采样时刻，我们有 s_τ 按比例分布于奖励。通过梯度下降训练参数化的边流模型来满足流匹配约束，而奖励约束则由实现强制执行。为了通过梯度下降训练这样的模型，定义了一个损失函数 $\mathcal{L}$ ，只有当流匹配约束 (1) 得

到满足时，该损失函数才会被最小化。迄今为止，已经提出了三种类型的损失函数：流匹配损失 (FM) (Bengio 等, 2021a)，详细平衡损失 (DB) (Bengio 等, 2021b) 和轨迹平衡损失 (TB) (Malkin 等, 2022)，分别如下所示：

$$\mathcal{L}_{\text{FM}}(F^\theta) = \mathbb{E} \sum_{t=1}^{\tau} \log^2 \frac{\sum_{s_t \rightarrow s'} F^\theta(s_t \rightarrow s')}{\sum_{s' \rightarrow s_t} F^\theta(s' \rightarrow s_t)}, \quad (4)$$

$$\mathcal{L}_{\text{DB}}(F_f^\theta, F_b^\theta) = \mathbb{E} \sum_{t=0}^{\tau-1} \log^2 \frac{F_{\text{out}}^{\theta, f}(s_t) \pi_f(s_t \rightarrow s_{t+1})}{F_{\text{out}}^{\theta, f}(s_{t+1}) \pi_b(s_t \rightarrow s_{t+1})}, \quad (5)$$

$$\mathcal{L}_{\text{TB}}(F_f^\theta, F_b^\theta) = \mathbb{E} \log^2 \frac{F_{\text{out}}^{\theta, f}(s_0) \prod_{t=0}^{\tau-1} \pi_f(s_t \rightarrow s_{t+1})}{R(s_\tau) \prod_{t=0}^{\tau-1} \pi_b(s_t \rightarrow s_{t+1})}. \quad (6)$$

1 我们的表述与 (Bengio 等, 2021a) 略有不同，在其中‘边’被称为‘动作’。2 源点是没有进行中的边的状态，汇点是没有外出边的状态。

上述期望是在路径分布上取的 $\text{distribution of paths}$ $s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_\tau \rightarrow s_f$ 并且我们使用 $\pi_f(s \rightarrow s') := \frac{F_f(s \rightarrow s')}{\sum_{s_t \rightarrow s'} F_f(s_t \rightarrow s')}$ 及 $\pi_b(s \rightarrow s') := \mathbb{P}(s_t = s | s_{t+1} = s') = \frac{F_b(s \rightarrow s')}{\sum_{s'' \rightarrow s'} F_b(s'' \rightarrow s')}$ 。显然，可以通过替换来构建变化版本 $\log x, y \mapsto \log^2 \left(\frac{x}{y} \right)$ 为任何距离类函数。

3 从有向无环图到可测空间

3.1 稳定性、循环与图上的 0-流

非无环图上的损失不稳定性 在 DAG 情况下考虑的所有定义在没有无环假设的情况下仍然适用于有向图。Bengio 的采样定理仍然是正确的，并将作为更一般陈述的一个子情况推导出来，该陈述是在可测状态空间上给出的。然而，在存在循环的情况下训练 GFlowNets 会失败：可以看到训练收敛于沿循环的无限边流。特别是，预期的采样时间 τ 增长到无穷大： $\mathbb{E}(\tau) \rightarrow +\infty$ 。例如，考虑以下由自由非负参数

$$F^\theta \text{ 参数化的边流族 } \theta := (f_1, f_2, f_3, c). \quad s_0 \xrightarrow{f_1} A \xrightarrow{f_2} B \xrightarrow{f_3+c} C \xrightarrow{1} s_f.$$

在这个图上满足奖励约束的流正好是对应于 F^θ 和 $c \geq 0$ 以及 $f_1 = f_2 = f_3 = 1$ 的。然而， $\mathcal{L}_{\text{FM}}$ 可以通过让 $f_2 = f_3$ 和 $f_1, f_2, f_3 \rightarrow 0$ 来

最小化。这由 $\partial_c \mathcal{L}_{\text{FM}}(F^\theta) < 0$ 说明，这个问题也发生在 $\mathcal{L}_{\text{DB}}$ 和 $\mathcal{L}_{\text{TB}}$ 上。图上线性图上的流的典型实现是通过具有两个头的多层感知器：一个 Softmax 函数和一个标量。它们分别输出给定状态下的前向策略和流出流。然而，从分析的角度来看，图上的边流是非负实值映射在边集上：因此，边流的空间是一个向量空间的子域。此外，奖励和流匹配约束是线性的，我们可以得出结论，边流的总和和凸组合以及边流方向上的泛函的方向导数是有意义的。关于流空间的精确描述见附录。

0-流 循环自然地在图上诱导出流：对于一个循环

$\gamma = (s \rightarrow s_1 \rightarrow \dots \rightarrow s_t \rightarrow s_1)$ 我们可以定义 0 流 1_γ 通过 $1_\gamma(s \rightarrow s') = 1$ 如果边 $s \rightarrow s'$ 处于循环中 γ 并且在其他情况下为 0。这样的 1_γ 是一个流，同时也满足零奖励的约束：它是一个 0-流。

定义 2. 0 流是指满足零奖励约束 (2) 的流 $R = 0$

0 流是一种以边流形式讨论循环的好方法：在一个功能在边流方向上的导数在循环的方向上是有意义的。此外，在图上，0 流的空间由循环生成 (见附录)。

稳定性形式化 接下来，定义一个边流 F_0 作为另一个边流 F 的子流，其中 $F_0 \leq F$ 作为定义在边上的函数。我们可以给出以下稳定性定义。

定义 3 (稳定性)。 损失 $\mathcal{L}$ 作用于流族 $(F_1, \dots, F_p)$ 是稳定的, 如果添加零流不会减少损失。更正式地表述: 如果对于任何零流 F_0

$$\mathcal{L}(F_1 + F_0, \dots, F_p + F_0) \geq \mathcal{L}(F_1, \dots, F_p),$$

此时损失函数稳定。

引理 1。 稳定性的一个充分条件是

$$\partial_{F_0} \mathcal{L}(F_1, \dots, F_p) \geq 0$$

对于所有作为每个 F_i 子流的零流量 F_0 。

稳定正则化 上述讨论的第一个结果是采用了稳定性的正则化。

定理 1. 设

$$\mathcal{L}_\alpha(F) = \mathcal{L}(F) + \alpha \mathcal{R}(F) \quad (7)$$

具有 $\mathcal{L}$ 稳定, $\alpha > 0$ 和 $\mathcal{R}$ 使得 $\partial_{F_0} \mathcal{R} > 0$ 对于所有 F_0 子流。设

$\alpha \rightarrow 0^+$ 并且设 $(F_n)_{n \in \mathbb{N}}$ 是一个 $\mathcal{L}_{\alpha_n}$ -最小化 R -边流序列。假设序列 $(F_n)_{n \in \mathbb{N}}$ 收敛到一个流, 则它收敛到一个无环的 R -流。定理 1 表明, 控制总边流大小的正则化, 如图上边流矩阵的范数, 可能有助于消除循环从而缩短预期采样时间。在下一节末尾的定理 2 也朝这个方向发展。

3.2 超越图结构 为了将 GFlowNets 从图的直觉推广到一般的可测状态空间设置, 我们不再考虑单个点的流出或单条边的边流, 而是考虑域上的流: $F(A \rightarrow B)$ 从一个域流出 $A \subset S$

和流向一个域 $B \subset S$ 。在图的情况下, 这可以解释为 $\sum_{s \in A} F(s \rightarrow s')$ 。流入/流出的流分别是 $F(S \rightarrow \cdot)$ 和 $F(\cdot \rightarrow S)$ 。同样地, 奖励被视为返回某个域内总奖励的函数 $A \subset S^*$ 。在图上

这意味着 $R(A) = \sum_{s \in A} R(s)$ 在有限图上, 作为域的函数, R 和 F 进出显然是可加的 e.g. $R(A \cup B) = R(A) + R(B)$ 如果 A, B 是不相交的子集 S^* 。另一方面, 边流 $F(\cdot \rightarrow \cdot)$ 在两个变量上都是可加的。流的概念的一个自然扩展是通过测度: 边流是 S i.e. a 上的双测度: 一个边流是一个 $S \times S$ 在 $\dots$ 期间

$F_{\text{in/out}}$ 和 R 是测度于 S 。出于技术原因, 我们将限制在有限非负测度上: 所有考虑的测度 $F, F_{\text{out}}, F_{\text{in}}, R, \dots$ 假设有限。马尔可夫链在可测环境下的泛化通常通过马尔可夫核函数实现。附录 A.1 专门回顾了这些对象。从边流 F 作为一种测度于 $S \times S$ 我们可以定义从给定域出发/到达该域的流出/流入量 A 通过 $F_{\text{out}}(A) := F(A \rightarrow S)$ 和 $F_{\text{in}}(A) := F(S \rightarrow A)$ 奖励测度的奖励约束 R 开启 S 并且流匹配约束可以很容易地转化为测度之间的等式: $F(\cdot \rightarrow s_f) = R$ 和 $1_S, F_{\text{in}} = 1_S, F_{\text{out}}$ 一条边

流是 R -边缘流如果满足奖励约束条件 R 以及一个 R -流如果同时满足奖励约束

流是 R -边缘流如果满足奖励约束条件 R 以及一个 R -流如果同时满足奖励约束

流是 R -边缘流如果满足奖励约束条件 R 以及一个 R -流如果同时满足奖励约束




图 2: 在一个可测空间上的一个 R -边流的描述。初始流 $F(s_0 \rightarrow \cdot)$ 用蓝色表示, 奖励 R 用绿色表示。一个可能的 0 流用红色高亮显示。

R 和流量匹配约束。特别是, 0-流量是一个满足奖励约束的流量 $R=0$ 。为了正确理解在可测设置下边的泛化 (即过渡限制), 让我们提醒读者以下关于测度之间支配关系的特征:

$$\forall \nu, \mu \text{ measures on } S, \quad \nu \ll \mu \Leftrightarrow \exists \varphi, \nu = \varphi \mu.$$

Say S is given by a graph, taking $\mu := \sum_{s \rightarrow s'} \delta_{s \rightarrow s'}$, the relation $F \ll \mu$ is equivalent to the existence of some function $\varphi: S \times S \rightarrow \mathbb{R}$ such that $F = \sum_{s \rightarrow s'} \varphi(s \rightarrow s') \delta_{s \rightarrow s'}$ in which case the function φ is exactly the edgeflow, i.e.

$$F = \sum_{s \rightarrow s'} F(s \rightarrow s') \delta_{s \rightarrow s'}.$$

因此我们将约束转换的边推广到一个测度 μ 支配边流的数据。源/汇属性的 $\mu(s_f \rightarrow S^*) = \mu(S \rightarrow s_0)$ 和

$$\mu(s_f \rightarrow s_f) = 1$$

来强制执行的。当处理一般测度时, 循环的概念变得不稳定。然而, 前一节给出的 0-流量概念很容易扩展, 因此稳定性的定义相同。将边流与其诱导的向前 (和向后) 策略联系起来时会出现技术难题。一种自然的方法是通过 Radon-Nikodym 微分和测度的张量积, 详见附录 A.2 的更多细节。目前, 我们简单地陈述任何边流 F 诱导一个向前 (或向后) 马尔可夫转移核, 在‘支持’上 F_{out} (或 F_{in}) 明确定义, 并且反之亦然, 从 (π_f, F_{out}) 或 (π_b, F_{in}) 可以

恢复边流 F :

$$(F_{\text{in}}, \pi_b) \xrightarrow{\otimes} F \xleftarrow{\otimes} (F_{\text{out}}, \pi_f).$$

我们现在可以恢复 Bengio 等人 (2021a) 的基本采样结果。令 F 是一个边流, 令 π_f 是其

表 1: 有向图到可测空间的翻译

	Bengio et al. (2021b)	Lahlou et al. (2023)	Measurable (ours)
State space S	DAG	Topological space, Borel σ -algebra	Measurable space
Edgeflow	Function on edges $F(s \rightarrow s')$	Implicit $F_{\text{out}} \otimes \pi_f$	Measure F on $S \times S$
In/Outgoingflow	Functions on states $F_{\text{in/out}}(s)$	Measures $F_{\text{in}}, F_{\text{out}}$ on S	Idem
Trajectory Flow	Function on trajectories	Measure on trajectories	Idem
Reward	Function on states $R(s)$	Measure R on S	Idem
Forward policy	$\mathbb{P}(s_{t+1} s_t) = \frac{F(s_t \rightarrow s_{t+1})}{\sum_{s_t \rightarrow s} F(s_t \rightarrow s)}$	Markov kernel $\pi_f : S \rightarrow S$	$\pi_f(x, A) = \frac{dF(\cdot \rightarrow A)}{dF(\cdot \rightarrow S)}$
Backward policy	$\mathbb{P}(s_t s_{t+1}) = \frac{F(s_t \rightarrow s_{t+1})}{\sum_{s \rightarrow s_{t+1}} F(s \rightarrow s_{t+1})}$	Markov kernel $\pi_b : S \rightarrow S$	$\pi_b(x, A) = \frac{dF(A \rightarrow \cdot)}{dF(S \rightarrow \cdot)}$
Transitions	Edges	Dominating kernel $\pi_f \ll \kappa$	Dominating measure $F \ll \mu$
Cycles?	Acyclic	s_f finitely absorbing hence acyclic	0-flows
Reachable Reward	Connectivity	Ergodicity	Dominating measure $R \ll \nu_{\text{train}}$
Paths length	Finite graph: $\tau \leq \#S$	s_f finitely absorbing: $\tau \leq \tau_{\text{max}}$	Finite measure: $\mathbb{E}(\tau) \leq \frac{F_{\text{out}}(S^*)}{R(S^*)}$

诱导的向前策略。考虑 $(s_t)_{t \geq 0}$ 转移核为 π_f 的马尔可夫链，从 s_0 开始，边流 F 的采样时间是在到达汇之前的位置：

$$\tau = \max\{t \mid s_t \neq s_f\}. \quad (8)$$

定理 2. 假设 $R \neq 0$ ，采样时间 τ 由 F 流几乎总是有限的，且采样分布与 R 成比例。更具体地说：及

$$\mathbb{E}(\tau) \leq \frac{F_{\text{out}}(S^*)}{R(S^*)}, \quad s_\tau \sim \frac{1}{R(S^*)} R. \quad (9)$$

最后，Bengio 等人 (2021b) 引入了一个轨迹流的概念，这在我们的上下文中很容易翻译成从 s_0 到 s_f 的路径空间上的有限非负测度。我们用 F 表示由边流 F i.e. $F_{\text{out}}(s_0)$ 乘以应用内核 π_f 重复开始于 s_0 直到到达 s_f 所得路径的概率分布的轨迹流。图 1 总结了从图到可测状态空间的翻译。

无环 0 流 直观上，循环倾向于引发采样时间爆炸性增长，即 $\mathbb{E}(\tau) \rightarrow +\infty$ 在训练过程中。虽然循环会在图中引入这一问题，但在连续设置下，它们并非唯一导致这种病态行为的因素，如下例所示。考虑 $S^* = \{z \in \mathbb{C} \mid |z| = 1\}$ 单位圆，我们可以考虑一个前向策略的马尔可夫链 π_f 开启 S^* 那是一个不断徘徊但永不循环的过程。甚至可以认为 π_f 确定性地旋转等操作 $\pi_f(z) = \exp(2i\pi\theta)z$ 与 θ 不合理的。在连续情况下，人们可能会认为循环是可以忽略的，但连续情况伴随着许多遍历变换，如上述的无理旋转，每个都诱导出许多‘几乎循环’。上述情况是一个无环 0 流的例子。因此，控制 0 流至少是一个理论上的必要条件，以控制那些永远徘徊的轨迹并限定预期采样时间。

4 稳定的非无环损失

4.1 训练损失作为广义发散

由于流匹配属性是在测度之间建立等式，基于发散构建损失函数是很自然的。

定义

$$\text{div}_{g,\nu}(\alpha, \beta) := \int_{x \in \mathcal{X}} g\left(\frac{d\alpha}{d\beta}(x)\right) d\nu(x), \quad (10)$$

其中 α, β, ν 是在某个可测空间 $\mathcal{X}$ 上的有限测度，而 g 是非负函数。定义 ν_{state} ，作为在 $\mathcal{S}_f \times \mathcal{S}_f$ 上的训练分布。然后，我们可以写出 FM 和 DB 的一般化形式。并通过发散形式计算损失函数 (4)-(6)：

$$\text{dgc}, \nu_{\text{path}} \times \text{th}(s_0, s_f) := \{s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_\tau \rightarrow s_f, \tau \geq 1\} \text{ re-}$$

$$\mathcal{L}_{\text{FM}}(F) = \text{div}_{g,\nu_{\text{state}}}(F_{\text{in}}, F_{\text{out}}), \quad (11)$$

$$\mathcal{L}_{\text{DB}}(F_f, F_b) = \text{div}_{g,\nu_{\text{edge}}}(F_f, F_b), \quad (12)$$

$$\mathcal{L}_{\text{TB}}(F_f, F_b) = \text{div}_{g,\nu_{\text{path}}}(F_f^\otimes, F_b^\otimes) \quad (13)$$

哪里 $F_f^\otimes$ 是轨迹流，在路径空间 Path 上的非负有限测度 (s_0, s_f) ，由某种边流诱导 F_f 需警惕轨迹流 $F_b^\otimes$ 由反向核函数诱导。在图上的直接计算表明了选择 $g = \log^2$ 确实产生了损失 $\mathcal{L}_{\text{FM}}, \mathcal{L}_{\text{DB}}$ 和 $\mathcal{L}_{\text{TB}}$ 给定于 (4)-(6)。在实际应用中， F_f 和 F_b 由 $F_f := \otimes_{(s)} \pi$ 和 $F_b := F_{\text{out}} \otimes \pi_b$ 并约定 $\frac{\text{out}}{\pi_b(s_f, \cdot)} \propto R$ 以强制奖励约束。类似地， $F_f^\otimes$ 和 $F_b^\otimes$ 由 $F_f^\otimes = F_{\text{in}} \delta_{s_0} \pi_f^{\otimes \tau}$ 和 $F_b^\otimes = \int R(S^*) \delta \pi_b^{\otimes \tau}$ 其中，对于任意核函数定义了 π 使得该核函数 $\pi^{\otimes \tau}(x)$ 是从起点出发路径的分布 x 并在首次遇到 s_0 或 s_f 时结束。因此， $\mathcal{L}_{\text{FM}}, \mathcal{L}_{\text{DB}}$ 和 $\mathcal{L}_{\text{TB}}$ 是 (10) 的特殊情况。这些损失函数的自然变体由 f 发散：

$$\mathcal{L}_{\text{FM},f}(F) = \text{div}_f(F_{\text{in}}, F_{\text{out}}), \quad (14)$$

$$\mathcal{L}_{\text{DB},f}(F_f, F_b) = \text{div}_f(F_f, F_b), \quad (15)$$

$$\mathcal{L}_{\text{TB},f}(F_f, F_b) = \text{div}_f(F_f^\otimes, F_b^\otimes) \quad (16)$$

div_f denotes an f -divergence. We allow f 其中发散性被认为是不恰当的，因为我们事先并不假设 f 满足通常的假设 (Polyanskiy 和 Wu 2022+)，即 $f(1) = 0$ f 凸性、严格在 1 处凸性等。我们希望 div_f 在测度上具有距离特性而不

仅在概率测度上成立，即对于所有非负有限测度 α, β ：，有 $\text{div}_f(\alpha, \beta) \geq 0$ 和 $\text{div}_f(\alpha, \beta) = 0 \Rightarrow \alpha = \beta$ 。因此，我们假设 $\forall x \in \mathbb{R}_+^n, f(x) \geq 0$ ，

等号成立当且仅当 $x = 1$ 。特别地，这一假设排除了

Kullback-Leibler 交叉熵。

定理 3 (基于发散的损失函数的不稳定性)。如果 div_f 是一个合适的发散，则 $\mathcal{L}_{\text{FM}, f, \nu}$ 不稳定，除非 div_f 是总变差³。

损失函数 $\mathcal{L}_{\text{FM}, g, \nu}$ 和 $\mathcal{L}_{\text{DB}, g, \nu}$ 是不稳定的。

4.2 一类稳定的损失函数 类似发散的损失函数的问题在于它们的尺度不变性形式： $t \mapsto \frac{d(F_t + F_0)}{d(F_2 + F_0)}$ 随着 $t \geq 0$ 的增长趋近于

1。这表明应将这种尺度不变性替换为零流不变性：

$$\Delta_{f, g, \nu}(\alpha, \beta) := \int_{x \in A} f(\alpha(x) - \beta(x)) g(\alpha(x), \beta(x)) d\nu(x)$$

其中 α, β 是可测函数，将作为所考虑测度相对于背景测度的密度函数 λ 。然后，我们可以得到

$$\mathcal{L}_{\text{FM}, \Delta, f, g, \nu}(F) = \Delta_{f, g, \nu_{\text{state}}}(F_{\text{in}}, F_{\text{out}}), \quad (17)$$

$$\mathcal{L}_{\text{DB}, \Delta, f, g, \nu}(F_f, F_b) = \Delta_{f, g, \nu_{\text{edge}}}(F_f, F_b). \quad (18)$$

在定理 4 中，证明了上述两个损失函数的稳定条件。

定理 4。 若 f, g, ν, R 满足：
• $f \geq 0$ 和 $g \geq 1$ ；
• f 和 g 连续且分段连续可微；
• f 在 $\mathbb{R}_-$ 上递减，在 $\mathbb{R}_+$ 上递增；

则对于 R 边流，损失 $\mathcal{L}_{\text{FM}, \Delta, f, g, \nu}, \mathcal{L}_{\text{DB}, \Delta, f, g, \nu}$ 是稳定的。

根据理论结果，我们可以得到以下稳定损失的例子。遗憾的是，我们无法找到 TB 的稳定条件，因为 TB 的相关理论分析由于算子 $F \mapsto F^*$ 的非线性而非常棘手，该算子返回与

边流相关的轨迹流。我们也给出了 CFlowNet 损失（李等人，2023d）的一个稳定版本，它是 FM 损失的一种变体。例 1（稳定 FM 损失）。对于 $\mathcal{L}_{\text{FM}, \Delta}$ ，一个特别自然的选择是

$$f(x) = \log(1 + \frac{x}{1+x}) \text{ 和 } g(x, y) = (1 + \eta(x+y))^{\beta}; \text{ 在图损失实例中:}$$

$$\mathcal{L} = \sum_{i=1}^n \{$$

$$\mathcal{L} := \mathbb{E} \sum_{t=1}^T \left\{ \log \left[1 + \varepsilon |F_{\text{in}}(s_t) - F_{\text{out}}(s_t)|^{\alpha} \right] \times (1 + \eta(F_{\text{in}}(s_t) + F_{\text{out}}(s_t)))^{\beta} \right\} \quad (19)$$

对于某些 $\varepsilon, \eta, \alpha, \beta > 0$ ，特别是， $(\alpha, \beta, \varepsilon, \eta) = (2, 1, 0.001, 1)$ 是显而易见的，因为凸性应有助于这种欠定线性问题的收敛³ 参见附录以获得更精确的陈述。

并且抑制过大的流匹配误差保持了原始 Bengio 损失的直觉，即不通过远离满足流匹配约束的节点来过度驱动训练。

例 2 (稳定 DB 损失)。可以修改上述的 FM 损失以得到 DB 损失：

$$\mathcal{L} := \mathbb{E} \sum_{t=1}^T \left\{ \log \left[1 + \varepsilon |F^f(s_t \rightarrow s_{t+1}) - F^b(s_t \rightarrow s_{t+1})|^{\alpha} \right] \times (1 + \eta F_{\text{out}}(s_t))^{\beta} \right\}, \quad (20)$$

其中 $F^f(s_t \rightarrow s_{t+1}) = F_{\text{out}}(s_t) \times \pi_f(s_t \rightarrow s_{t+1})$ 及 $F^b(s_t \rightarrow s_{t+1}) = F_{\text{out}}(s_{t+1}) \times \pi_b(s_t \rightarrow s_{t+1})$ 当正向和反向流由正向和反向参数化时分别地反向策略。

示例 3 (稳定的 CFlowNet 损失)。通过将 $F_{\text{in/out}}$ 替换为其关于

于背景测度的密度 $f_{i/o}$ ，可以为 CFlowNets 写出一个连续

$$\text{变化的形式} \left\{ \mathcal{L} := \mathbb{E} \sum_{t=1}^T \left\{ \log \left[1 + \varepsilon |f_i(s_t) - f_o(s_t)|^{\alpha} \right] \times (1 + \eta(f_i(s_t) + f_o(s_t)))^{\beta} \right\} \right\}. \quad (21)$$

5 实验结果 5.1 超网格上的结果 在这里 $S^* = [1, W]^D$ ，除了初始转移 $s_0 \rightarrow a$ 以及给定的某些条件 $a \in S^*$ 和终端转移 $\forall s \in S^* \rightarrow s_f$ 之外，还附加了形式为 $s \rightarrow \pm \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \cdot (0, \dots, 0)$ 的转移。在 Bengio 等人 (2021a) 中选择了更严格的转移 $s \rightarrow s + (0, \dots, 0)$ 来强制执行

行无环性。对于这样的小图，GFlowNet 使用底层图的邻接矩阵实现，同时将每条转移的边流存储在一个数组中。我们将 $\mathcal{L}_{\text{FM}}$ 和 $\mathcal{L}_{\text{TB}}$ 与 $\mathcal{L}_{\text{FM}, \Delta, f, g}$ 进行比较。我们观察到两种损失都导致模型收敛，但路径的行为差异显著：由 $\mathcal{L}_{\text{FM}}$ 引起的预期路径长度随着路径的漫游而爆炸，而对于 $\mathcal{L}_{\text{FM}, \Delta, f, g}$ ，路径相对直接地导向奖励区域。事实上，对于非稳定的 FM 损失，边流发散至无穷大，从而降低了相对奖励信号：即使在 s_t 处的奖励很高，但由于循环的存在，朝向非停止方向的边流也很高，因此 $F(s_t \rightarrow s_f) \ll F(s_t \rightarrow s')$ 对于 $s' \neq s_f$ ，马尔可夫链继续漫游，见图 1 和图 3。对于 $\mathcal{L}_{\text{TB}}$ 的行为更为复杂：它诱导漫游路径，但预期采样时间不会爆炸，而是稳定在比稳定损失情况下显著更高的值上。在其他一些情况下，TB 损失最终达到了与稳定损失相同的预期奖励和预期路径长度，但需要较长的训练时间。

5.2 凯莱图上的结果 在这里 $S^* = \mathfrak{S}_p$ ，置换群为 $[0, p-1]$ 对于某些 $p \geq 1$ 。边由一组生成器给出




图 3: 在 2DW20 网格上使用各种不稳定和稳定损失训练

GFlowNet: $\mathcal{L}_{FM, stable} = \mathcal{L}_{FM, f}$ 与 $f(x) = x^2$; $\mathcal{L}_{FM, X^2, \nu}$ 和 $\mathcal{L}_{FM, TV, \nu}$ 是上述的 $\mathcal{L}_{FM, f, \nu}$ 的实例, 分别具有 $\nu = \frac{1}{1+x^2}$ 和 $f(x) = |1-x|$ 。上图: 训练期间平均奖励的变化。下图: 采样路径平均长度的变化。

$(\sigma_1, \dots, \sigma_p)$ 使得对于所有 $g \in S^*$ 和所有 $i \in [1, q]$, 我们有一条边 $g \xrightarrow{\sigma_i} g\sigma_i$ (更一般地, 可以将 $\mathfrak{S}_p$ 替换为任何离散群)。

$p \geq 25$ 提供了一些图的例子, 这些图即使对于当前的超级计算机来说也难以处理, 但仍然具有较小的直径, 可计算的 FM 损失, 易于实现, 并提供各种结构、对称性和循环。许多任务可以归结为部分排序一个列表, 因此我们被引导构造一个元素 $\mathfrak{S}_p$ 使用与可用操作对应的生成器: 例如, 冒泡排序仅使用列表中相邻对象的置换 L 进行排序, 因此 $p = \text{长度}(L)$ 和 $\sigma_i = (i, i+1)$ 。本实验与其他实验不同之处在于初始策略 $\pi_f(\cdot \rightarrow \cdot)$ 被固定在 S^* 上的均匀分布。两个原因促

使了这一选择。首先, 探索行为不容易强制执行, 但我们可以通过利用凯莱图的高度连接和循环性质来允许从任何位置开始。其次, 它导致学习一种通用策略来解决从任何初始配置的问题。我们比较了使用 $\mathcal{L}_{FM}$ 和 $\mathcal{L}_{FM, \Delta}$ 在两类奖励上的训练: $R(\sigma) := c1_{\sigma \in S^*}$ 和 $R(\sigma) := d(\rho(\sigma), S_2)$ 对于某些子集 $S_1, S_2 \subset S^*$ 。取 $S = \{(\sigma_1, \dots, \sigma_p) \mid \sigma_i \in S^*, i \leq p\}$ 导致模拟部分排序算法, 参见图 4 中的 $p=20$ 和 R_1 其中 $c=20$ 和 $k=1$ 。选择 R_2 模拟常见的启发式方法, 如曼哈顿距离的变化。策略 $\pi_f(s_0 \rightarrow \cdot) = \mathcal{U}(S^*)$

是不可训练的, 以模拟随机初始实例, 从而训练流从任何位置解决部分排序问题。我们观察到, 正如理论预测的那样, 当使用不稳定损失时, 流趋向于不受控制地增长, 而使用稳定损失时, 流保持有界, 从而缓解了采样时间爆炸的问题。

是不可训练的, 以模拟随机初始实例, 从而训练流从任何位置解决部分排序问题。我们观察到, 正如理论预测的那样, 当使用不稳定损失时, 流趋向于不受控制地增长, 而使用稳定损失时, 流保持有界, 从而缓解了采样时间爆炸的问题。

5.3 连续任务的结果

为了展示所提出的稳定 CFlowNets 损失的有效性, 我们在 Point-Robot-Sparse 上进行了实验。




图 4: Stable-GFlowNets (我们的工作)、GFlowNets 以及 Cayley 图上的 Metropolis-Hasting 基线的比较结果 $\mathfrak{S}_{20}$ 由置换、一个 20 阶循环及其逆矩阵生成。奖励为 R_1 如上所述 $k=1$ 和 $c=20$ 路径绘制的截断长度为 80。最优策略下

的预期奖励为 20, 预期长度为 5。上图: 训练过程中平均奖励的变化。下图: 采样路径的平均长度。

在稀疏奖励的连续控制任务中, 智能体的目标是在两个不同坐标 $(10, 10)$ 和 $(0, 0)$ 的目标之间导航。智能体从 $(5, 5)$ 开始, 最大回合长度为 12。我们将智能体移动的角度范围从 $(0, 90^\circ)$ 改为 $(0, 360^\circ)$, 即轨迹中可以生成一个循环。Point-Robot-Sparse 中的所有其他实验设置和算法超参数与 Li 等人 (2023d) 相同。更多细节请参见 Li 等人 (2023d)。至于 Stable-CFlowNets, 我们仅将 CFlowNets 的损失改为示例 3 中的损失。图 5 展示了探索的有效独特轨迹数量以及训练过程中的奖励。经过一定数量的训练轮次后, 收集了 5000 条轨迹。可以看出, 所提出的稳定损失并未影响探索性能, 而奖励有了显著提高, 并且变得更加稳定 (方差范围更小)。值得注意的是, 这两个完全相反的目标对于强化学习算法来说是一个困难的环境, 因此强化学习算法的奖励并不高。

图 6 给出了 Stable-CFlowNets 在 Point-Robot-Sparse 任务上的采样轨迹示例。为了获得这些轨迹, 我们在每个节点上随机采样 1000 个动作以获得相应的流输出 (概率), 然后随机选择最可能的前 300 个动作之一来生成轨迹。可以看出, 在训练开始时, 轨迹中有许多循环, 但在训练结束时仍然能够收敛到目标, 这表明我们的稳定损失对循环非常鲁棒。

6 结论与讨论

我们介绍了一个理论框架, 用于推广 GFlowNets 的概念和定理, 使其超出最初有向无环图的范围, 扩展到可测空间。进行的分析使得可以将采样时间 (即采样的路径长度) 与通过梯度下降训练的稳定性联系起来。这种分析使我们能够定义适用于可能存在循环的空间的损失函数以及正则化方法。




图 5: Stable-CFlowNets (我们的工作)、CFlowNets、DDPG、TD3、SAC 和 PPO 在 Point-Robot-Sparse 上的比较结果。左图: 在 5000 次探索下生成的有效独特轨迹数量。右图: 不同方法的平均奖励。




图 6: Stable-CFlowNets (我们的工作) 在 Point-Robot-Sparse 任务上的采样轨迹示例。左图: 训练开始时。右图: 训练结束时。

机制, 有助于管理循环。

6.1 相关工作

在关于 GFlowNets (Bengio 等, 2021b; Jain 等, 2022a; Malkin 等, 2022; Madan 等, 2022; Zhang 等, 2023b; Jain 等, 2022b; Pan 等, 2023; Deleu 和 Bengio, 2023) 的大量文献中, 有三项研究特别与我们的工作密切相关。Bengio 等 (2021b) 试图奠定 GFlowNets 理论的基础, 并讨论了许多未来应用或探索该方法的可能性。Lahlou 等 (2023) 的工作采用了类似的方法来推广 GFlowNets。最后, Li 等 (2023d) 首次尝试对连续状态空间进行 GFlowNets 训练。然而, 这些工作中没有一项解决了循环空间的局限性, 特别是我们的稳定性属性是全新的。此外, 我们的框架比 Lahlou 等 (2023) 的工作更为简单, 因为大部分基础工作都集中在一般的有限非负测度上。没有使用或甚至明确指定任何额外假设来强制无环性。此外, 我们探讨了图上流的空间结构, 这在总体上是新的, 并朝着更好地理解 GFlowNets 训练的良好实践迈进了一步。在这种一般背景下考虑 GFlowNets, 可以直接将其与 MCMC (Brooks 等, 2011) 和强化学习 (Sutton 和 Barto, 2018) 进行比较。一方面, 从采样的角度来看, GFlowNets 和 MCMC 是可以互换的: 两者都在未规范化设置下工作:

归一化分布在一个空间上, 目标是以该目标分布的比例对空间进行采样。更准确地说, GFlowNets 的可训练性需要与自适应 MCMC (Andrieu 和 Thoms 2008) 进行比较。两个关键差异使我们希望在某些情况下可以用 GFlowNets 替代 MCMC 方法: GFlowNets 具有有限的混合时间, 而 MCMC 具有无限的混合时间, 后者在发现模式后仍难以从一个模式转移到另一个模式, 而前者可以学习执行此类移动的动作序列。模式转换是长期影响 MCMC 效率的问题 (Andricioaei, Straub, 和 Voter 2001; Pompe, Holmes, 和 Łatuszyński 2020; Samsonov 等 2021); 人们希望 GFlowNets 能够提供全局移动来帮助克服这一问题。另一方面, 在图上的 GFlowNets 可以被视为一种分布式的 Q 方法 (Bellemare, Dabney, 和 Munos 2017), 流出流量扮演预期奖励的角色。

6.2 局限性

首先, 我们在不稳定/稳定性结果上使用的假设并非最优, 并且这些假设在技术上允许使用简单的论证。此外, 轨迹平衡损失仅部分进行了研究: 虽然 FM 和 DB 损失被证明是无条件不稳定的, TB 损失仅在某些情况下不稳定, 我们的分析和实验表明它可能在小流的情况下是稳定的。其次, 我们对轨迹平衡损失的理论分析有限。没有提出这种损失的稳定变体, 我们的理论不稳定性结果相当有限。这表明有可能找到约束、正则化或更好的流参数化来稳定轨迹平衡损失。第三, 所进行的实验相对于工作的理论范围来说较为有限。我们没有在连续设置下比较详细平衡损失的稳定版本。需要更彻底地测试非循环 0 流在连续设置下的影响的实验。第四, 未经训练的 GFlowNets 可能难以高效地探索空间以学习目标分布。对于自适应 MCMC 方法, 已知有确保遍历性的标准 (Andrieu 和 Thoms 2008)。然而, GFlowNets 的探索遍历性完全开放, 并且预计会遇到类似于自适应 MCMC 的问题。我们的简单方法是在采样路径时添加一个常数边流或添加一个小背景奖励。第五, 在凯莱图上, 我们无法训练 GFlowNets 使初始流快速收敛到理论值。我们使用初始流作为模型可训练参数的简单实现证明是不够的。最后, 我们在凯莱图上的实验使用了最简单的前馈神经架构。考虑到局部图结构并/或学习图的全局属性的更复杂架构将是理想的。图变换器 (Dwivedi 和 Bresson 2020) 是一个自然的下一步, 已经在 DAG (Zhang 等 2023b) 中使用 topofomers (Gagrani 等 22) 采取了这一步。

参考文献

- Abadi, M.; Agarwal, A.; Barham, P.; and et. al. 2015. TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems. Software available from tensorflow.org.
- Ambrosio, L.; Gigli, N.; and Savare, G. 2006. *Gradient Flows: In Metric Spaces and in the Space of Probability Measures*. Lectures in Mathematics. ETH Zürich. Birkhäuser Basel. ISBN 9783764373092.
- Andricioaei, I.; Straub, J. E.; and Voter, A. F. 2001. Smart darting monte carlo. *The Journal of Chemical Physics*, 114(16): 6994–7000.
- Andrieu, C.; and Thoms, J. 2008. A tutorial on adaptive MCMC. *Statistics and computing*, 18(4): 343–373.
- Bellemare, M. G.; Dabney, W.; and Munos, R. 2017. A distributional perspective on reinforcement learning. In *International Conference on Machine Learning*, 449–458. PMLR.
- Bengio, E.; Jain, M.; Korablyov, M.; Precup, D.; and Bengio, Y. 2021a. Flow Network based Generative Models for Non-Iterative Diverse Candidate Generation. arXiv:2106.04399.
- Bengio, Y.; Deleu, T.; Hu, E. J.; Lahlou, S.; Tiwari, M.; and Bengio, E. 2021b. GFlowNet Foundations. arXiv:2111.09266.
- Bogachev, V. 2007. Measure Theory Volume, volume 1 and 2.
- Brockman, G.; Cheung, V.; Pettersson, L.; Schneider, J.; Schulman, J.; Tang, J.; and Zaremba, W. 2016. OpenAI Gym. arXiv:1606.01540.
- Brooks, S.; Gelman, A.; Jones, G.; and Meng, X.-L. 2011. *Handbook of Markov chain Monte Carlo*. CRC press.
- Deleu, T.; and Bengio, Y. 2023. Generative Flow Networks: a Markov Chain Perspective. arXiv preprint arXiv:2307.01422.
- Douc, R.; Moulines, E.; Priouret, P.; and Soulier, P. 2018. *Markov chains*. Springer.
- Dwivedi, V. P.; and Bresson, X. 2020. A generalization of transformer networks to graphs. arXiv preprint arXiv:2012.09699.
- Gagrani, M.; Rainone, C.; Yang, Y.; Teague, H.; Jeon, W.; Van Hoof, H.; Zeng, W. W.; Zappi, P.; Lott, C.; and Bonde-san, R. 2022. Neural Topological Ordering for Computation Graphs. arXiv preprint arXiv:2207.05899.
- Jain, M.; Bengio, E.; Hernandez-Garcia, A.; Rector-Brooks, J.; Dossou, B. F.; Ekbote, C. A.; Fu, J.; Zhang, T.; Kilgour, M.; Zhang, D.; et al. 2022a. Biological sequence design with gflownets. In *International Conference on Machine Learning*, 9786–9801. PMLR.
- Jain, M.; Raparthy, S. C.; Hernandez-Garcia, A.; Rector-Brooks, J.; Bengio, Y.; Miret, S.; and Bengio, E. 2022b. Multi-Objective GFlowNets. arXiv preprint arXiv:2210.12765.
- Kalpazidou, S. L. 2007. *Cycle representations of Markov processes*, volume 28. Springer Science & Business Media.
- Kifer, Y. 2012. *Ergodic theory of random transformations*, volume 10. Springer Science & Business Media.
- Lahlou, S.; Deleu, T.; Lemos, P.; Zhang, D.; Volokhova, A.; Hernández-García, A.; Ezzine, L. N.; Bengio, Y.; and Malkin, N. 2023. A theory of continuous generative flow networks. arXiv preprint arXiv:2301.12594.
- Li, W.; Li, Y.; Li, Z.; HAO, J.; and Pang, Y. 2023a. DAG Matters! GFlowNets Enhanced Explainer for Graph Neural Networks. In *The Eleventh International Conference on Learning Representations*.
- Li, Y.; Li, Z.; Li, W.; Shao, Y.; Zheng, Y.; and Hao, J. 2023b. Generative Flow Networks for Precise Reward-Oriented Active Learning on Graphs. In *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence, IJCAI-23*. International Joint Conferences on Artificial Intelligence Organization.
- Li, Y.; Luo, S.; Shao, Y.; and Hao, J. 2023c. GFlowNets with Human Feedback. In *The First Tiny Papers Track at ICLR 2023, Tiny Papers @ ICLR 2023, Kigali, Rwanda, May 5, 2023*. OpenReview.net.
- Li, Y.; Luo, S.; Wang, H.; and Hao, J. 2023d. CFlowNets: Continuous Control with Generative Flow Networks. In *The Eleventh International Conference on Learning Representations*.
- Madan, K.; Rector-Brooks, J.; Korablyov, M.; Bengio, E.; Jain, M.; Nica, A.; Bosc, T.; Bengio, Y.; and Malkin, N. 2022. Learning GFlowNets from partial episodes for improved convergence and stability. arXiv preprint arXiv:2209.12782.
- Malkin, N.; Jain, M.; Bengio, E.; Sun, C.; and Bengio, Y. 2022. Trajectory Balance: Improved Credit Assignment in GFlowNets. arXiv preprint arXiv:2201.13259.
- Pan, L.; Zhang, D.; Jain, M.; Huang, L.; and Bengio, Y. 2023. Stochastic Generative Flow Networks. arXiv preprint arXiv:2302.09465.
- Polyanskiy, Y.; and Wu, Y. 2022+. *Information Theory From Coding to Learning*. Cambridge university press.
- Pompe, E.; Holmes, C.; and Łatuszyński, K. 2020. A framework for adaptive MCMC targeting multimodal distributions. *The Annals of Statistics*, 48(5): 2930 – 2952.
- Samsonov, S.; Lagutin, E.; Gabrié, M.; Durmus, A.; Naumov, A.; and Moulines, E. 2021. Local-Global MCMC kernels: the best of both worlds. arXiv preprint arXiv:2111.02702.
- Sutton, R. S.; and Barto, A. G. 2018. *Reinforcement learning: An introduction*. MIT press.
- Towers, M.; Terry, J. K.; Kwiatkowski, A.; Balis, J. U.; Cola, G. d.; Deleu, T.; Goulão, M.; Kallinteris, A.; KG, A.; Krimmel, M.; Perez-Vicente, R.; Pierré, A.; Schulhoff, S.; Tai, J. J.; Shen, A. T. J.; and Younis, O. G. 2023. Gymnasium.
- Veach, E.; and Guibas, L. J. 1997. Metropolis light transport. In *Proceedings of the 24th annual conference on Computer graphics and interactive techniques*, 65–76.
- Wang, H.; Shao, Y.; Hao, J.; and Li, Y. 2023. Regularized Offline GFlowNets. In *The First Tiny Papers Track at ICLR*

Zhu, D.; Li, Y.; Shao, Y.; Hao, J.; Wu, F.; Kuang, K.; Xiao, J.; and Wu, C. 2023. Generalized Universal Domain Adaptation with Generative Flow Networks. In *Proceedings of the 31st ACM International Conference on Multimedia*.

$$\mu \otimes \pi(A \times B) := \int_{x \in A} \pi(x \rightarrow B) d\mu(x)$$

- 在 Lahlou 等人 (2023) 的框架中, 通过参考转移核函数对正向策略的支配来强制执行转移约束; 该命题表明, 结合流出的支配, 这等同于我们对边流的支配。

• 由于转移约束 μ 在 $S \times S$ 上满足 $\mu(s_f \rightarrow \cdot) = \delta_{s_f}$ ，由此诱导出的核函数 π^F 在 s_f 处为 f ，按照惯例， π_f^F 对于所有 $x \in S$ 都是一个马尔可夫核，因此我们有 $\pi_f^F(\delta_{s_f}) = 1$ 。

A.3 采样流及预期采样时间 在对流进行采样时，无论是训练期间还是推理期间，主要关注的是“粒子流”例如由无穷多条路径组成的流，这些路径按照前向策略 π_f 诱导的分布进行采样 F 。这需要一个恰当的定义。

定义 5 (采样流)。 边缘流的采样流 F 正向策略 π_f 并且使得 $\mathbb{E}(\tau) < +\infty$ 是边缘流 (Edgeflow)

$$\bar{F} = \bar{F}_{\text{out}} \otimes \pi_f \quad \text{与} \quad \bar{F}_{\text{out}}(A) := F_{\text{out}}(s_0) \times \mathbb{E}(\text{card}\{t \in \mathbb{N} \mid s_f \neq s_t \in A\}). \quad (24)$$

命题 2. 被精确采样如边缘流，使得 $\bar{F} \in \mathcal{F}_{\text{edgeflow}}^{(S^*)}$ ，则 $\bar{F}$ is a flc。若进一步 F is a R ，则 $\bar{F}$ is a R -流和

$$R \quad \bar{F} \quad F.$$

推论 1。 总流界定了预期采样时间：

根据定理 2，记号 $\bar{F}(S^* \rightarrow S^*)$ 我们有 $R(S^*)$ 。图 7 表示边流与其诱导的采样流之间的差异。




图 7：边流（黑色）及其相关的采样流（红色）

附录 A.4 循环类型的流

尽管 0-流推广了图上的循环，但尚不清楚所有 0-流是否都是循环之和。我们给出了“循环之和”的严格定义，并提供了一个反例。

定义 6。 对于 $\gamma = (s_0, \dots, s_{\ell-1})$ 一个长度 ℓ 循环进入 S^* 定义 0-流 $\mathbf{1}_\gamma = \sum_{i=0}^{\ell-1} \delta_{s_i} \otimes \delta_{s_{i+1}}$ 设 $\Gamma(S^*)$ 表示循环的集合 $(s_0, \dots, s_{\ell-1})$ 任意长度的 $\ell \in \mathbb{N}^+$ 一个 (广义) 0-流 F 若其允许分解，则为循环类型

$$F = \int_{\Gamma} \mathbf{1}_\gamma d\mu(\gamma)$$

对于某些 μ (相应地带有符号的) Γ 上的有限测度 (S^*) 。

定义 7. 若边缘流不存在非平凡的循环类型的 0-子流，则该边缘流是无环的。

命题 3. 边缘流 F 有一个最大的 0-子流，因此它可以表示为

$$F = F_0 + F_{\min}$$


其中 F_0 是一个 0-子流，而 $F_{\min}$ 是最小的边缘流。

我们在附录 A.5 中将证明，在可数状态空间上，所有 0-流都是循环类型的。这使我们能够证明以下引理。

引理 2. 如果 S 至多可数无穷大，则无环边流和极小边流的子集对于狭义收敛而言都是闭的。

对于一个边流，极小意味着无环。对于一个流，极小也意味着恰好采样。如果 S 是不可数的，则一个流可能是无环且恰好采样的，但未必是极小的。

例 7.1. 左侧所示的流包含两个不同的最大 0-子流（红色，蓝色），右侧与之关联的（针对红色）极小子流（绿色）一起展示：



A.5 图上的流空间结构 首先我们注意到一个图 $G = (S, E)$ 可

以被视为至多可数无穷的离散空间 S 以及通过计数测度对流的支配 $E \in \mathcal{F} \ll \mu_E := \sum_{(s,s') \in E} \delta_s \otimes \delta_{s'}$ 上文各节的所有结果均适用

于此设定，因此我们得到了一个采样定理，预期采样时间的上限，一个分解性质以及流匹配损失的选择。我们假设 G 在某种意义上是连通的，即对于每一个状态 s ，存在一条从 s_0 到 s_f 通过 s 。考虑一个拓扑 γ 简单的循环 Γ 在 G 中 $\gamma = s_0 \rightarrow s_1 \leftarrow s_2 \leftarrow s_3 \rightarrow s_4 \rightarrow \dots \rightarrow s_0$ 使得状态仅出现一次（除了第一个状态出现两次）；我们定义

$$\mathbf{1}_\gamma(s \rightarrow s') = \begin{cases} 1 & \text{If } s \rightarrow s' \in \gamma \\ -1 & \text{If } s' \rightarrow s \in \gamma \\ 0 & \text{otherwise} \end{cases}$$

则 $\mathbf{1}_\gamma$ 是一个广义流。 $\mathcal{F}(G), \mathcal{F}^+(G), \mathcal{F}_R(G), \mathcal{F}_R^+(G)$ 分别表示广义流的空间、流的空间、广义 R -流的空间和 R -流的空间。本文用 $\mathcal{F}_1^{(G)}$ 表示由这样的 $\mathbf{1}_\gamma$ 张成的向量空间在 $\mathcal{F}_1^{(G)}$ 中的闭包 $\mathcal{F}_1^{(G)}$ ，其中包含 $\gamma \in G \setminus \gamma$ 。

在这里，拓扑意味着边可以向前或向后交叉。在图的上下文中，广义流的空间 $\mathcal{F}(G)$ 在 $G = (S, E)$ 上是可求和流的空间，即函数 $F : E \rightarrow \mathbb{R}$ 满足 $\|F\|_1 := \sum_{e \in E} |F(e)| < +\infty$ 并满足流匹配性质。可以识别 $\mathcal{F}(G) \subset \ell^1(E) = L^1(E, \mu_E)$ 。

命题 4. 设 $G = (S, E)$ 是一个连通有向图，并设 R 是一个可求和的目标分布。那么 $\mathcal{F}_R$ 是向量空间 $\ell^1(E)$ 的一个非空仿射子

空间 $\mathcal{F}_R = F + H^1(G)$ 中的任意元素。特别地， $\mathcal{F}_0 = H^1(G)$ 。证明包

括在附录中；然而，这个命题可以

从 (Kalpazidou 2007) 中的定理 3.3.1 得出，该定理提供了更强的结果。

推论 2. 所有的图上的广义 0-流都是循环类型的。下面的命题将这一性质扩展到非负流。为此，我们引入 $\mathcal{F}_{R,acyclic}^+$ ，它

由非负无环流组成，以及 $H_+^1(G)$ ，它是 $H^1(G)$ 的闭包，其中 γ 遍历 G 的简单回路（而不是仅仅拓扑简单回路，以便 $\gamma \geq 0$ ）。

命题 5. 设 $G = (S, E)$ 是一个连通有向图，并设 R 是非负奖励函数。那么 $\mathcal{F}_R$ 是向量空间 $\mathcal{F}_R$ 的一个非空凸域。此外，

$$\mathcal{F}_R^+ = \mathcal{F}_{R,acyclic}^+ + H_+^1(G).$$

推论 3. 所有的图上的 0-流都是循环类型的。

附录 B 证明

命题 1. 加权马尔可夫核函数 (π_f, G) 或测度于

$S \times S$ 可以互换地用于定义边流。更精确地说：(a) 对于所有

有非负有限测度 F ，然后 $F = F_{\text{out}} \otimes \pi_f^F$ 对于所有的 $A \subset S$ ：

$$\pi_f^F(\cdot \rightarrow A) := \frac{dF(\cdot \rightarrow A)}{dF(\cdot \rightarrow S)}. \quad (25)$$

Furthermore, for two such measures F_1, F_2 , if $F_1 \ll F_2$ then $F_{1,\text{out}} \ll F_{2,\text{out}}$ and

$$\pi_f^{F_1}(x) \ll \pi_f^{F_2}(x)$$

对于 $F_2(x)$ -几乎所有的 x 。

(b) 对于任意加权马尔可夫核 (π_f, G) 我们有

$$(\pi_f, G) \sim (\pi_f^{G \otimes \pi_f}, G(S)).$$

Furthermore, for any two weighted Markov kernels $(\pi_f^1, G_1), (\pi_f^2, G_2)$ if $G_1 \ll G_2$ and $\pi_1(x) \ll \pi_2(x)$ for G_2 -almost all x then

$$G_1 \otimes \pi_f^1 \ll G_2 \otimes \pi_f^2.$$

证明。(a) 由于 $F \geq 0$ ，我

$$\forall A \in \mathcal{S}, F(\cdot \rightarrow A) \leq F(\cdot \rightarrow S)$$

因此，根据

Radon-Nykodym 定

理， π_f^F 是良好定义

的，并且

$$\forall A \in \mathcal{S}, F(\cdot \rightarrow A) = \pi_f^F(\cdot, A) F_{\text{out}}, \quad \forall A, B \in \mathcal{S}$$

$$F_{\text{out}} \otimes \pi_f^F(A, B) := \int_{x \in A} \pi_f^F(x, B) dF_{\text{out}}(x) \quad (26)$$

$$= (\pi_f^F(\cdot, B) F_{\text{out}})(A) \quad (27)$$

$$= F(A \rightarrow B) \quad (28)$$

so $F = F_{\text{out}} \otimes \pi_f^F$.

设 $\varphi \in L_1(F_2)$ 使得 $F_1 = \varphi F_2$ 我们有对于所

有

$$F_1(A \rightarrow B) = \int_{x \in A} \int_{y \in B} \varphi(x, y) d[\pi_f^{F_2}(x)](y) dF_{2,\text{out}}(x)$$

so $\forall B \in \mathcal{S}, F_1(\cdot \rightarrow B) \ll F_{2,\text{out}}$ and for $F_{2,\text{out}}$ -almost all x :

$$\frac{dF_1(\cdot \rightarrow B)}{dF_{2,\text{out}}}(x) = \int_{y \in B} \varphi(x, y) d[\pi_f^{F_2}(x)](y).$$

Thus $F_{1,\text{out}} = F_1(\cdot \rightarrow S) \ll F_{2,\text{out}}$ $F_{1,\text{out}}$ -almost

并且对于所有 x 和对于所有 $B \in \mathcal{S}$ ：

$$\frac{dF_1(\cdot \rightarrow B)}{dF_1(\cdot \rightarrow S)}(x) = \frac{\int_{y \in B} \varphi(x, y) d[\pi_f^{F_2}(x)](y)}{\int_{y \in S} \varphi(x, y) d[\pi_f^{F_2}(x)](y)}.$$

特别是对于 F_{out}

$$F_{1,\text{out}} \text{ 几乎 } \pi_f^{F_1}(x \rightarrow \cdot) = \Phi_x \pi_f^{F_2}(x, \cdot)$$

所有的 $x \in L^1(\pi_f^{F_2}(x, \cdot))$ given by

$$\Phi_x(y) = \frac{\varphi(x, y)}{\int_{y \in S} \varphi(x, y) d[\pi_f^{F_2}(x)](y)}.$$

(b) Define $F_{\text{out}} := G \otimes \pi_f(\cdot \rightarrow S)$, for all $A \in \mathcal{S}$,

$$F_{\text{out}}(A) := G \otimes \pi_f(A \rightarrow S)$$

$$= \int_{x \in A} \pi_f(x, S) dG(x)$$

$$= \int_{x \in S} dG(x) = G(A).$$

此外，对于任意 $B \subset S$ 可测的，我们有如下测度上的等

式：因此该可测函数 $x \mapsto \pi_f(x, B)$ 是 $F(\cdot, B)$ 关于

$$F(\cdot, B) = F_{\text{out}} \otimes \pi_f(\cdot, B) = \pi_f(\cdot, B) F_{\text{out}}$$

由导数的唯一性，我们有 $G(x)$ -几乎每个 x 其中

$$F(\cdot, B) = \pi_f(\cdot, B) F_{\text{out}}$$

nes o e, we hav

$$\pi_f^{G \otimes \pi_f} = \pi_f(x,$$

$$(\pi_f^{G \otimes \pi_f}, F_{\text{out}}).$$

Given two such weighted Markov kernels, clearly:

$$G_1 \otimes \pi_f^1 = \Phi \times (G_2 \otimes \pi_f^2)$$

$$\text{与 } \Phi(x, y) := \frac{dG_1}{dG_2}(x) \frac{d\pi_f^1(x)}{d\pi_f^2(x)}(y).$$

□

引理 3. 设 F 是在 S 上的一个 (广义) R -边流，则 F 是

一个 (广义) 流当且仅当 $F_{\text{out}} \pi_f - F_{\text{out}} = R(S^*) \delta_{s_f} - F_{\text{out}}(s_0) \delta_{s_0}$

$$F_{\text{out}} \pi_f - F_{\text{out}} = R(S^*) \delta_{s_f} - F_{\text{out}}(s_0) \delta_{s_0}$$

$F_{\text{out}} \pi_f - F_{\text{out}} = R(S^*) \delta_{s_f} - F_{\text{out}}(s_0) \delta_{s_0}$

since F is a R -边流然后 $F_{\text{out}} \pi_f(S \rightarrow s_f) = F(S \rightarrow s_f) = R(S^*)$, $\pi_f(s_f \rightarrow \cdot) = \delta_{s_f}$ and

$F_{\text{out}} \pi_f(s_0) = F(S \rightarrow s_0) = 0$ hence $F_{\text{out}} \pi_f - F_{\text{out}} = R(S^*) \delta_{s_f} - F_{\text{out}}(s_0) \delta_{s_0}$.

$$\text{If } F_{\text{out}} \pi_f - F_{\text{out}} = R(S^*) \delta_{s_f} - F_{\text{out}}(s_0) \delta_{s_0}$$

$$F_{\text{in}} = R(S^*) \delta_{s_f} - F_{\text{out}}(s_0) \delta_{s_0}$$

is

□

那么特别地， $F_{\text{in}} = R(S^*) \delta_{s_f} - F_{\text{out}}(s_0) \delta_{s_0}$ 是一个流。由于它是一个 R 边

流，即 F is a R -流。

命题 6. 广义空间 R -流对于给定的 R 是一个有限测度的闭凸锥。由 R -flows 是一个闭合的凸域。

证明。流匹配约束显然是线性的，而奖励约束显然是仿射的。广义约束的和 R_1 -流与广义 R_2 -flow 是一种广义的 $(R_1 + R_2)$ -流从而确定广义仿射子空间的方向 R -flows 是广义 0-流的线性空间。窄收敛 $F_n \rightarrow F$ 表明 $F_n(A \rightarrow B) \xrightarrow{\mathcal{F}_R} F(A \rightarrow B)$ 对所有 $A, B \in \mathcal{S}$ 因此，流匹配约束和奖励约束趋于极限，从而 $\mathcal{F}_R$ 是闭合的。最后， $\mathcal{F}_R^+$ 是闭合仿射空间的交集 $\mathcal{F}_R$ 与非负测度的闭凸锥的交集。□

定理 2. 假设 $R \neq 0$ ，采样时间 τ of a R -流几乎总是有限的， τ 几乎总是有限的，并且采样分布与 R 成正比。更具体地说：及

$$\mathbb{E}(\tau) \leq \frac{F_{\text{out}}(S^*)}{R(S^*)}, \quad s_\tau \sim \frac{1}{R(S^*)} R. \quad (29)$$

该定理是以下三个命题以及推论 1 的结果。

命题 7. 如果 $R \neq 0$ ，那么 τ 几乎总是有限的。采样时间 τ 几乎总是有限的。

证明。假设 τ 不是有限的，那么 $\tau \geq k$ 对于所有 $k \in \mathbb{N}^+$ 成立。我们根据 (40) 的定义，我们有

$$F_{\text{out}}(s_0) \delta_{s_0} \pi_f^k = (F_{\text{out}} \pi_f^k - F_{\text{out}} \pi_f^{k+1}) + F(S^*, s_f) \delta_{s_f}$$

$$\mathbb{P}(\tau > k) = \delta_{s_0} \pi_f^k(S^*) = \frac{F_{\text{out}} \pi_f^k(S^*) - F_{\text{out}} \pi_f^{k+1}(S^*)}{F(s_0)}$$

注意到序列 $(F_{\text{out}} \pi_f^k(S^*))_{k \in \mathbb{N}^+}$ 是非递增非负的，因此收敛。由此可知 $\lim_{k \rightarrow +\infty} (F_{\text{out}} \pi_f^k(S^*) - F_{\text{out}} \pi_f^{k+1}(S^*)) = 0$ 。因此 $\lim_{k \rightarrow +\infty} \mathbb{P}(\tau > k) = 0$ 。换句话说， τ 几乎 surely 有限。□

命题 8. 在假设 $R \neq 0$ 成立的情况下，抽样分布与 R 成正比。更精确地说：

$$s_\tau \sim \frac{1}{R(S^*)} R. \quad (30)$$

证明。由引理 3 可知序列 $F_{\text{out}} \pi_f^k$ 在区间 S^* 上非负且非增，在区间 s_f 上非减，从而收敛到一个测度 $\mu = \nu + \beta \delta_{s_f}$ ，满足 $\beta \in \mathbb{R}_+ \cup \{+\infty\}$ 且 $\text{supp}(\nu) \subset S^*$ 。此外， $\mu \pi_f = \mu$ 和 $\delta_{s_f} \pi_f = \delta_{s_f}$ ，所以 $\mu \pi_f = \nu$ 。由于 π_f 是马尔可夫的，我们推断出 $\nu \otimes \pi_f = \mu$ 。□

然后，对于 A 的每一个可测子集 S^* ，

$$\begin{aligned} & \mathbb{P}(M_\tau \in A) \\ &= \left(\sum_{k \in \mathbb{N}} \delta_{s_0} \pi_f^k \right) \otimes \pi_f(A \times \{s_f\}) \\ &= \left(\sum_{k \in \mathbb{N}} \frac{1}{R(S^*)} (F_{\text{out}} \pi_f^k - F_{\text{out}} \pi_f^{k+1}) + \delta_{s_f} \right) \otimes \pi_f(A \times \{s_f\}) \\ &= \frac{1}{R(S^*)} (F_{\text{out}} - \nu) \otimes \pi_f(A \times \{s_f\}) \\ &= \frac{1}{R(S^*)} F(A \times \{s_f\}) - \frac{1}{R(S^*)} \underbrace{\nu \otimes \pi_f(A \times \{s_f\})}_{=0} \\ &= \frac{R(A)}{R(S^*)}. \end{aligned}$$

□

命题 2. 设 F 为一条边流，则 $\bar{F}$ 是一个流当且仅当 $\mathbb{E}(\tau) < +\infty$ 。若 F 是 R -流，则 $\bar{F}$ 是 R -流且 $\bar{F} \leq F$ 和 $\mathbf{1}_{S^*}$

$$\lim_{k \rightarrow +\infty} \frac{F_{\text{out}} \pi_f^k}{\text{ampl}} = 0, \quad \lim_{k \rightarrow +\infty} F_{\text{out}} \pi_f^k = 0.$$

证明。如果 F 的期望采样时间不是有限的，那么 $\bar{F}$ 肯定不是一个有限测度，从而不是一个边流，也不是一个流。假设 F 的期望采样时间是有限的，则可以推导出 $\bar{F}$ 是在 $S \times S$ 上的一个有限非负测度，从而是一个边流。定义

$$\bar{R} = \bar{F}(\cdot \rightarrow s_f) \quad \text{记} \quad F_{\text{out}} = F_{\text{out}}(s_0) \mathbf{1}_{S \setminus \{s_f\}} \sum_{k=0}^{+\infty} \delta_{s_0} \pi_f^k$$

We have $\bar{F}_0$.

$$\bar{F}_{\text{out}} - \bar{F}_{\text{out}} \pi_f = F_{\text{out}}(s_0) \delta_{s_0} - \bar{F}(S \rightarrow s_f) \delta_{s_f}$$

so $\bar{F}$ is a $\bar{R}$ -flow by Lemma 3.

假设 F 是一个 R -流。那么，

$$\begin{aligned} \mathbf{1}_{S^*} \bar{F}_{\text{out}} &= \sum_{k=0}^{+\infty} \mathbf{1}_{S^*} F_{\text{out}}(s_0) \delta_{s_0} \pi_f^k \\ &= \mathbf{1}_{S^*} \sum_{k=0}^{+\infty} (F_{\text{out}} \pi_f^k - F_{\text{out}} \pi_f^{k+1}) \\ &= \mathbf{1}_{S^*} \left(F_{\text{out}} - \lim_{k \rightarrow +\infty} F_{\text{out}} \pi_f^k \right). \end{aligned}$$

请注意，在每一步中，右侧可能定义良好，并且每一步都是合法的，即使总和是无限的。

因此，和 $\mathbf{1}_{S^*} \bar{F}_{\text{out}} \leq \mathbf{1}_{S^*} F_{\text{out}}$ 并且因此 $\bar{F}_{\text{out}}(s_f) = 0 \leq F_{\text{out}}(s_f)$ 。有限测度并且 $\bar{F} \leq F$ 。In particular $\bar{F}$ is a R -flow. Furthermore,

$$\bar{R} = \bar{F}(\cdot, s_f) = F_{\text{out}}(s_0) \mathbb{E} \delta_{s_\tau} = F(\cdot, s_f) = R;$$

根据命题 8，我们得出结论 $\bar{R} = R$ 和 $\bar{F}$ is a R -流。边流 $\bar{F}$ 则是一个目标为 $F(\cdot, s_f) = R$ 的流。

最后, 由于 $\bar{F}$ 仅依赖于 π_f 和 $F_{out}(s_0) = \bar{F}_{out}(s_0)$, 我们有 $\bar{F} = F$ so we 在

计算中具有等式

上述计算表明, $\mathbf{1}_{S^*} \lim_{k \rightarrow +\infty} \overline{F_{out}} \pi_f^k = 0$.

命题 3. 边缘流 F 有一个最大的 0-子流, 因此它可以表示为

$$F = F_0 + F_{min},$$

其中 F_0 是一个 0-子流, 而 F_{min} 是最小的边缘流。

证明. 可以在测度上的 0 子流集合上应用佐恩引理 (Zorn's Lemma), 其中测度遵循通常的顺序. 一个由测度组成的全序族, 若其被 F 所限制, 则该族的上确界仍然是被 F 所限制的测度, 并且 0 流性质在上确界下得以保持. 集合非空, 因为零测度是一个由 F 界定的 0 流, 并且 F 是非负的. 因此存在一个 (非唯一的) 最大 0 子流. $\square$

定理 1. 假设 S 至多可数. 令 $0 \leq R$ be a 为奖励函数. 令

$$\mathcal{L}_\alpha(F) = \mathcal{L}_{FM}(F) + \alpha \mathcal{R}(F)$$

与 $\mathcal{L}_{FM}$ 一种强 α 大的流匹配损失函数 R 一边 $\alpha \geq 0$ 边缘流, $\alpha \geq 0$ 和 $\mathcal{R}$ 使得假设矛盾情况成立, 对所有子流 F 局部极小值点不是全局极小值点, 并使用命题 3 来分解一个无环的流, 使得

$$0 = \partial_{F_0} \mathcal{L}_\alpha = \partial_{F_0} \mathcal{L}_{FM} + \alpha \partial_{F_0} \mathcal{R}.$$

但是 $\partial_{F_0} \mathcal{R} > 0$ 和 $\partial_{F_0} \mathcal{L}_{FM} \geq 0$. 矛盾. 最小化 $\mathcal{L}_{FM}$ 的一系列极小值点也是最小化 $\mathcal{L}$ 的一系列极小值点, 因此根据强流匹配假设收敛. 然后, 由前面的结论, 每个 F_n 都是极小的, 根据引理 2, 极限也是极小的. 因此无环.

定理 5. 设 $G = (S, E)$ 是一个连通有向图, 令 R 是一个可求和的目标分布. 则 $\mathcal{F}_R$ is a $\ell^1(E)$ 的非空仿射子空间 $\mathcal{F}_R = F + H^1(G)$,

其中 F 是 $\mathcal{F}_R$ 的任 $\mathcal{F}_R = F + H^1(G)$, 意元素. 特别地,

$$\mathcal{F}_0 = H^1(G) \circ \mathcal{F}_R$$

证明. 根据命题 6 和命题 3, 只需证明 $\mathcal{F}_R = H^1(G)$ 并且 $\mathcal{F}_R$ 非空. 首先,

$H^1(G) \subseteq \mathcal{F}_0$ 显然成立. 取一些 $F \in \mathcal{F}_0$ 以及一些递增的有限子集族 $(K_n)_{n \in \mathbb{N}}$ 属于 S^*

使得 $\bigcup_{n \in \mathbb{N}} K_n = S$ 和 $\bigcup_{n \in \mathbb{N}} E \cap (K_n \times K_n) = E$. 取一些 $n \in \mathbb{N}$, 考虑完全图 $G' = (S', E')$ of $(S', E' = \bigcup_{i, j \in K_n} (i, j))$:

状态集合 $E' =$ 并在 (S', E') 上考虑由定义的 0-流 π 所定义的 π 流

- $\forall e \in K_n \times K_n, F'(e) = F(e)$
- $\forall s \in K_n, F'(s, \infty) = F(s, S^* \setminus K_n)$
- $\forall s \in K_n, F'(\infty, s) = F(S^* \setminus K_n, s)$
- $F'(\infty, \infty) = 0$.

选取边 $e_1 = (s_0, s_1) \in K_n$ 使得 $|F'(e)| > \frac{|F|(K_n, \infty)}{2}$. 根据流匹配性质,

存在另一条入边或出边 $e_2 = s_1 \rightarrow s_2$ 或 $e_2 = s_1 \leftarrow s_2$ 使得 $F'(e_2) \neq 0$.

我们继续此过程直到到达某个已访问过的状态, 从而构造一条包含循环的路径 $\gamma = (s_p)_{p \in [0, q]}$ 含 $0 < q$ 包含一个循环 ω . 如

果 $\omega \subset K_n$ 则保留该循环 $\frac{q}{2} \subset \gamma$. 否则, 我们注意到

$$\begin{aligned} \min_{e \in \omega} |F(e)| &\leq |F'(s_p, s_{p+1})| \\ &\leq |F|(K_n, S^* \setminus K_n) \\ &< |F(e_1)| = |F'(e_1)|. \end{aligned}$$

为了从 e_0 在流 $F'' = F' - \lambda_0 \mathbf{1}_\omega$ 中

构造另一条路径, 利用 $\lambda_0 = \min_{e \in \omega} |F(e)|$. 重复此过程, 由

于 G' 是有限的, 并且 F'' 少了一条非零边, 因此该过程最终会在 K_n 内停止于一个循环. 我们可以考虑一些 $F'_1 = F' - \lambda_0 \mathbf{1}_\omega$, 其中包含 $\lambda_0 = \min_{e \in \omega} |F(e)|$ 和 $\omega \subset K_n$. 注意, F'_1 至少比 F' 少一条非零边, 并且 $\frac{|F'_1|}{|F|} \leq \frac{|F'_1|}{|F|}$.

迭代构造以生成一个序列 $(F'_i)_{i \in \mathbb{N}}$, 使得 $(|F'_i|)_{i \in \mathbb{N}}$ 是递减的. 由于 G' 是有限的, 该过程终止, 从而构建了一组循环流 $(\lambda_i \mathbf{1}_{\omega_i})_{i \in [0, r]}$, 使得 $F' = \sum_{i=0}^r \lambda_i \mathbf{1}_{\omega_i} + F'_r$.

由于无法从 F'_r 中提取更多循环, 这意味着对于所有 $e \in K_n$ 都有

$$\frac{|F'_r|(e)|}{|F'_r|} \leq \frac{|F'_r|(K_n, \infty)}{|F'_r|} \leq \frac{|F'_r|(K_n, \infty)}{|F'_r|}.$$

F :

$$F = \sum_{i=0}^r \lambda_i \mathbf{1}_{\omega_i} + F_1$$

$$\forall e \in K_n \times K_n, |F_1|(e) \leq |F_1|(K_n, S^* \setminus K_n).$$

We thus can construct a sequence of 0-flows $(F_n)_{n \in \mathbb{N}}$ such that $F_0 = F$ and for all $n \in \mathbb{N}$:

$$|F_{n+1}| \leq |F_n|, \quad F_n = \sum_{i=0}^n \lambda_i \mathbf{1}_{\omega_i} + F_{n+1},$$

$$\forall e \in K_n \times K_n, |F_{n+1}|(e) \leq |F_{n+1}|(K_n, S^* \setminus K_n).$$

We deduce from those properties that $\forall n \in \mathbb{N}, |F_n| \leq |F|$ and $\forall e \in E, \lim_{n \rightarrow +\infty} F_n(e) = 0$, therefore $F_n \rightarrow 0$ in $\ell^1(E)$ so that

$$\exists (\lambda_i)_{i \in \mathbb{N}}, (\omega_i)_{i \in \mathbb{N}}, \quad F = \sum_{i=0}^{\infty} \lambda_i \mathbf{1}_{\omega_i},$$

e.g. $F \in H^1(G)$.

To construct an element of $\mathcal{F}_R$, for each final edge, $e = s \rightarrow s_f$ choose a path $\gamma_e := s_0 \rightarrow \dots \rightarrow s \rightarrow s_f$ which exists since G is connected. Then define $F = \sum_e R(e) \mathbf{1}_{\gamma_e}$. By construction, F is a R -flow. $\square$

命题 5. 设 $G = (S, E)$ 是一个连通有向图, 设 R 是非负奖励函数. 那么 $\mathcal{F}_R$ 是 $\mathcal{F}_R$ 的一个非空凸域. 进一步地, 证明如下: 凸性来自于锥体 $\{F \in \mathcal{F}_R \mid F \geq 0\}$ 的凸性. 和集合

作为

$$\mathcal{F}_R^+ = \mathcal{F}_{R,acyclic}^+ + H_+^1(G).$$

Proof. Convex $\{F \in \mathcal{F}_R \mid F \geq 0\}$ 的凸性

$$\mathcal{F}_R^+ = \mathcal{F}_R \cap \{F \in \ell^1(E) \mid F \geq 0\}.$$

在命题证明中构建的元素 $\mathcal{F}_R$ 实际上是非负的。为了证明 $\mathcal{F}^*$
 $0 = H^1_\lambda(G)$ ，相同的证明方法适用，正性确保我们可以选择具有正权重的简单循环。最小性意味着无环，因此命题 3 给出了所需的结果。□

引理 2. 如果 S 至多可数无穷大，则无环边流和极小边流的子集对于狭义收敛而言都是闭合的。

证明。鉴于前面的命题，最小等价于无环，所以我们只需要证明无环的情况。考虑一系列边流 F_n 收敛到某个 F_∞ 。如果 F_∞ 包含一个环 $\gamma = s_0 \rightarrow s_1 \rightarrow \cdots \rightarrow s_p \rightarrow s_0$ ，那么对于所有 $i \in \mathbb{Z}$ ， $\sum_{j=0}^{p-1} F_n(s_j, s_{j+1}) > 0$ 。存在一个 $N \in \mathbb{N}$ 使得 $\forall n \geq N, \forall i \in \{1, \dots, p\}$ ， $F_n(s_{i-1}, s_i) > 0$ 。因此，对于足够大的 n ， $\lambda_1 \leq F_n$ 其中 $\lambda_1 = \min_{i \in \mathbb{Z}} F(s_i, s_{i+1}) > 0$ 。□

附录 B.1 定理 3 的证明

回忆一下， f, g 是函数 $\mathbb{R}_+ \rightarrow \mathbb{R}_+$ ，它们在除零外的所有地方都是零。如果 $\text{div } f$ 是一个适当的发散，则 $\mathcal{L}_{FM,f}, \mathcal{L}_{DB,f}$ 是不稳定的，除非 $\text{div } f$ 是总变差。

损失 $\mathcal{L}_{FM,g,\nu}$ 和 $\mathcal{L}_{DB,g,\nu}$ 是不稳定的。

我们在简单的技术假设下证明这个定理，这些假设涵盖了相当多的实现，并且这些假设是由勒贝格收敛定理的最简单应用所激发的。

命题 9。 若发散 $\text{div } f$ 是适当的发散，则在满足条件 $F_{\text{in}} \ll F_{\text{out}}$ 的边流 f 中， $\mathcal{L}_{FM,f}$ 的极小值点是流。进一步地，假设 f 是连续且可连续微分的

piecewise;
 • assume $\frac{dF_{\text{in}}}{dF_{\text{out}}}$ 是有界的；那么对于任何非平凡的 0-子流 F_0 的 ∇F 方向导数 $\partial_{F_0} \mathcal{L}_{FM,f}(F)$ 存在并且

$\mathcal{L}_{FM,f}(F) \leq 0$ 对于所有这样的情况等式成立 F, F_0 对于所有转换约束，当且仅当 $\text{div } f$ 与总变差成正比。最后，在边缘流上使得 $F_{\text{out}} \ll \nu$ 和 $\nu \ll F_{\text{out}}$ ， $\mathcal{L}_{FM,g,\nu}$ 不稳定。

$\mathcal{L}_{FM,g,\nu}$

命题 10. 若 $\text{div } f$ 是适当的发散，在形式为 $F_f := F_{\text{out}} \otimes \pi_f$ 和 $F_b := F_{\text{in}} \otimes \pi_b$ 的流中，其中 π_f 和 π_b 是独立的并且满足条件 $F_{\text{out}} \ll F_f$ ，则 $\mathcal{L}_{DB,f}(F_f, F_b)$ 的极小值点是流。进一步地，假设 f 是连续且分段连续可微的；

• assume $\frac{dF_b}{dF_f}$ is bounded;

那么对于任何非平凡的 0 子流 F_0 的 ∇F_f 方向导数 $\partial_{F_0} \mathcal{L}_{DB,f}(F_f, F_b)$ 存在并且 $\mathcal{L}_{DB,f}(F_f, F_b) \leq 0$ 对于所有这样的情况等式成立 F_f, F_b, F_0 对于所有转换约束，当且仅当 $\text{div } f$ 与总变差成正比。最后，在边缘流上使得 $F_{\text{out}} \ll \nu$ 和 $\nu \ll F_{\text{out}}$ ， $\mathcal{L}_{FM,g,\nu}$ 不稳定。

$\mathcal{L}_{FM,g,\nu}$

虽然可容许性只是对 (Bengio 等人 2021b) 中可能找到的论据的一种可测变换，但不稳定性的原因是以下两个引理的结果。

引理 4. 设 $\mathcal{X}$ 是一个非空可测空间，设 F_0, F_1, F_2 是在 $\mathcal{X}$ 上的三个有限非负测度。如果发散 $\text{div } f$ 是一个适当的发散，并且 $\bullet \cdot f$ 是连续且分段连续可微的

• $F_2 \ll F_1 \geq F_0$

then

$$\partial_{(F_0,F_0)}\text{div } f(F_2,F_1) \leq 0.$$

The equality is realized for $\text{div } f = \text{div}_{TV}$. Furthermore, if there exists F_0, F_1 as above such that for all $\alpha \in L^1(F_1)$ the equality holds for $(F_0, F_1, F_2 = \alpha F_1)$, then $\text{div } f \propto \text{div}_{TV}$.

Proof. Define

$$\phi(t) = \int_{S^*} g\left(\frac{d(F_2+tF_0)}{d(F_1+tF_0)}\right) d(F_1+tF_0)$$

及 $F_2 = \alpha F_1$ 及 $F_0 = \beta F_1$.

$$\begin{aligned} \phi(t) &= \int_{\mathcal{X}} g\left(\frac{\alpha+t\beta}{1+t\beta}\right) (1+t\beta) dF_1 \\ &= \int_{\mathcal{X}} g\left(1+\frac{\alpha-1}{1+t\beta}\right) (1+t\beta) dF_1 \\ \phi'(t) &= - \int_{\mathcal{X}} g'\left(1+\frac{\alpha-1}{1+t\beta}\right) \frac{(\alpha-1)(1+t\beta)}{(1+t\beta)^2} \beta dF_1 \\ &\quad + \int_{\mathcal{X}} g\left(1+\frac{\alpha-1}{1+t\beta}\right) \beta dF_1 \\ &= \int_{\mathcal{X}} \psi\left(\frac{\alpha-1}{1+t\beta}\right) dF_0, \end{aligned}$$

其中 $\psi(x) = g(1+x) - xg'(1+x)$ 。请注意

$$t, x \mapsto g\left(\frac{\alpha(x)+t\beta(x)}{1+t\beta(x)}\right) (1(x)+t\beta(x))$$

在变量 x 上可测，并在变量 t 上除了孤立点 t 外连续，且关于变量 t 的导数在变量 $t \rightarrow 0$ 的一个邻域内有界，因为根据假设 α 有界，而 $\sup \beta \leq 1$ 由构造可知有界。

因此，在积分号下求导是合法的。由于 g 是凸的， ψ 在区间 $\mathbb{R}_+$ 上非减，在区间 $\mathbb{R}_+$ 上非增，故 $\psi \leq \psi(0) = 0$ 。因此， $\phi'(t) \leq 0$ 使得令 $0 \leq F_0 \leq F_1$ ，对于所有 $\alpha \in L^1(F_1)$ 成立等式

2,

su

对于

$= \alpha F_1$. Take

对 $C \in \mathbb{R}_+$.

由于等式对于 $(F_0, F_1, \alpha_C F_1)$ 成立, 则对于所有 $C \geq 0$ 我们有

$$0 = \phi'(0) = \int_{\mathcal{X}} \psi(C-1) dF_0$$

从而 $\forall x > -1, \psi(x) = 0$ 。根据我们的正则假设, 这意味着 g 解微分方程 $y + (x-1)y' = 0$, 我们推断出 $\forall x \in \mathbb{R}_+^*, g(x) = \omega(x) \frac{y}{x}$

其中 ω 分段常数。由连续性可知, ω 仅在 1 处可能不连续, 因此我们可以将 g 重写为 $g(x) = \omega_1 |1-x| + \omega_2 (1-x)$, 从而得出

结论。

引理 5. 令 $\mathcal{X}$ 是一个非空可测空间。假设 g 连续且分段连

续可微; ψ 仅在 1 处取等号; 那么对于任何 F_0, F_1 满足 $0 \leq F_0 \leq F_1$, 存在 $F_2 \leq F_1$ 使得 $\partial_{(F_0, F_0)} \text{div}_{g, \nu}(F_2, F_1) \geq 0$ 。

$$\partial_{(F_0, F_0)} g, \nu(F_2, F_1) < 0.$$

证明。与前一个引理相同的计算给

$$\psi(x) = -xg'(1+x) \quad \text{if } \partial_{(F_0, F_0)} \text{div}_{g, \nu}(F_2, F_1) \geq 0$$

出 ∂_{F_0, F_0} 除以 $g, \nu(F_2, F_1)$ 对所有 $F_2 \leq F_1$ 然后 $\psi \geq 0$ 从而 g 在

We do not know if this instability results for TB loss as we do for DB and FM losses. This is in part due to the nonlinearity of the operator $F \mapsto F^\otimes$ that associates the trajectory flow to a given edgeflow.

Lemma 6. Let F_f, F_b be edgeflows on some S with transition constraints μ and let F_0 be 0-subflow such that $1_{S^* \times S^*} \mu \ll F_0$. Assume that

- $F_f \ll F_b$ and $\frac{dF_f}{dF_b}$ is bounded,
- for all $\xi \in \mathbb{R}_+$,

$$\int_{\underline{s} \in \text{Path}(s_0, s_f)} g(e^{\xi \text{len}(\underline{s})}) d\nu(\underline{s}) < +\infty,$$

然后:

$$\lim_{c \rightarrow +\infty} \mathcal{L}_{TB, g, \nu}((F_f + cF_0)^\otimes, (F_b + cF_0)^\otimes) =$$

$$\int_{s \in S^* \times S^*} g \left[\frac{dF_f}{dF_b}(s_0 \rightarrow s) \frac{dF_f}{dF_b}(s' \rightarrow s_f) \right] d\omega(s, s')$$

其中 $\omega(\cdot) \ll \phi \cdot \nu$ 并且是映射 $\phi(s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_f) = \frac{F_f(s_0 \rightarrow s_1) \dots F_f(s_{\ell-1} \rightarrow s_\ell)}{F_b(s_0 \rightarrow s_1) \dots F_b(s_{\ell-1} \rightarrow s_\ell)}$ 特别是如果 $\phi(s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_f) = 0$ 那么上述极限为 0。

hen the limit above is 0.

证明。直接计算得出:

$$\frac{dF_f^\otimes}{dF_b^\otimes}(s_0 \rightarrow \dots \rightarrow s_\tau \rightarrow s_f) = \prod_{t=1}^{\tau+1} \left(\frac{dF_f}{dF_b}(s_{t-1} \rightarrow s_t) \right) \prod_{t=1}^{\tau} \left(\frac{dF_{b, \text{in}}}{dF_{f, \text{out}}}(s_t) \right).$$

Write $P := \text{Path}(s_0, s_f)$ 以及路径 $s_0 \rightarrow \dots \rightarrow s_\tau \rightarrow s_f$ by $\underline{s}$. 然后, 我们

$$A_c(\underline{s}) := \prod_{t=1}^{\tau+1} \left(\frac{d(F_f + cF_0)}{d(F_b + cF_0)}(s_{t-1} \rightarrow s_t) \right) \times \prod_{t=1}^{\tau} \left(\frac{d(F_{b, \text{in}} + cF_0)}{d(F_{f, \text{out}} + cF_0)}(s_t) \right)$$

并且

$$B(\underline{s}) := \frac{dF_f}{dF_b}(s_0 \rightarrow s_1) \frac{dF_f}{dF_b}(s_\tau \rightarrow s_f),$$

我们有

$$\begin{aligned} \int_{\underline{s} \in P} g \left[\frac{d(F_f + cF_0)}{d(F_b + cF_0)}(s_0 \rightarrow \dots \rightarrow s_\tau \rightarrow s_f) \right] d\nu(\underline{s}) \\ = \int_{\underline{s} \in P} g[B(\underline{s})] d\nu(\underline{s}) \\ + \int_{\underline{s} \in P} \{g[A_c(\underline{s})] - g[B(\underline{s})]\} d\nu(\underline{s}). \end{aligned}$$

一方面, $B(s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_\tau \rightarrow s_f)$ 仅依赖于 s_1 和 s_τ , 因此

$$\begin{aligned} \int_{\underline{s} \in P} g[B(\underline{s})] d\nu(\underline{s}) &= \\ \int_{\underline{s} \in P} g \left[\frac{dF_f}{dF_b}(s_0 \rightarrow s) \frac{dF_f}{dF_b}(s' \rightarrow s_f) \right] d\omega(s, s'). \end{aligned}$$

On the other hand, since F_0 is a 0-flow in particular $F_0(s_0 \rightarrow \cdot) = F_0(\cdot \rightarrow s_f) = 0$ but since $1_{S^* \times S^*} \mu \ll F_0$, then for μ -almost all $s \rightarrow s'$ from S^* to S^* , $\frac{d(F_f + cF_0)}{d(F_b + cF_0)}(s \rightarrow s') = \frac{a+c\delta}{b+c\delta}$ for some $a, b \geq 0$ and $\delta > 0$. Therefore all terms in $A_c(\underline{s})$ tend towards 1 except $\frac{dF_f}{dF_b}(s_{t-1} \rightarrow s_t)$ and $\frac{dF_f}{dF_b}(s_\tau \rightarrow s_f)$; and thus

$$\forall \underline{s} \in P, \quad \lim_{c \rightarrow +\infty} A_c(\underline{s}) = B(\underline{s}).$$

Since we assumed $\frac{dF_f}{dF_b}$ bounded, it follows that $|g[A_c(\underline{s})] - g[B(\underline{s})]| \leq Cg(e^{\xi \text{len}(\underline{s})})$. 对于某些与 $\underline{s}$ 独立的情况。结果随后由勒贝格得出 convergence Theorem. $C, \xi > 0$

这个引理意味着损失 $\mathcal{L}_{TB, g, \nu}$ 的不稳定, 因为这个极限可能大于或小于损失在 $c=0$ 处的值, 这取决于 F_f 和 F_b 的相对值。根据实际实现, 可以强制初始/终端流约束 $F_f(s_0 \rightarrow \cdot) = F_b(s_0 \rightarrow \cdot)$ 和 $F_f(\cdot \rightarrow s_f) = F_b(\cdot \rightarrow s_f)$ 。这是我们对超网络上 TB 损失实现的情况。

附录 B.2 定理 4 的证明

我们回顾我们假设的一组潜在稳定损失。• $R \ll \nu$ 使得 ν 相对于 R 具有“完全支持”, 并且

- $d\nu$ 是有界的,
- $f \geq 0$ 及 $g \geq 1$,
- $f(x) = 0 \Leftrightarrow x = 0$;

- f 和 g 是连续且分段连续可微的；
- f 在 $\mathbb{R}_-$ 上递减，

在 $\mathbb{R}_+$ 上递增

$$\partial_{(1,1)} g \geq 0$$

定理 4. *If f, g, ν, R satisfy the properties above then for R -edgeflows the loss $\mathcal{L}_{FM, \Delta, f, g}, \mathcal{L}_{DB, \Delta, f, g}$ are stable.*

This theorem is a direct consequence of the following Lemmas.

Lemma 7. *Let $\mathcal{X}$ be a measurable space, the function $\alpha, \beta \mapsto \int_{x \in \mathcal{X}} f(\alpha(x) - \beta(x))g(\alpha(x), \beta(x))d\nu(x)$ defined on $L^\infty(\mathcal{X}, \nu) \times L^\infty(\mathcal{X}, \nu)$ is distance-like.*

Proof. Let $\alpha, \beta \in L^\infty(\nu)$, since f, g are non-negative then so is $I := \int_{x \in \mathcal{X}} f(\alpha(x) - \beta(x))g(\alpha(x), \beta(x))d\nu(x)$. Assuming that $I = 0$ we have $f(\alpha(x) - \beta(x))g(\alpha(x), \beta(x)) = 0$ for ν -almost all x . Since $g \geq 1$ and $f(y) = 0 \Leftrightarrow y = 0$, we conclude that $\alpha(x) = \beta(x)$ for ν -almost all x hence $\alpha = \beta$. $\square$

引理 8. 设 λ 是一个可测空间，对于任意 $\alpha, \beta, \gamma \in L^\infty(\nu)$ 非负，函数 $\phi: t \mapsto \Delta_{f, g, \nu}(\alpha + t\gamma, \beta + t\gamma)$ 在 $t=0$ 处具有非负导数。

证明. 应用积分号下的勒贝格导数定理。 $\square$

附录 C 实现细节

附录 C.1 超网格

实现 实现细节 对于这样的小图，GFlowNets 通过底层图的邻接矩阵来实现。流本身被实现为一个包含每次转移权重的数组。实现使用 tensorflow 版本 2.4.4 (Abadi 等人, 2015)。最小化使用 Adam，学习率为 0.01，其他参数使用默认值。已经测试了各种奖励分布，对最终结果影响不大。自我训练通过定期更新训练分布 ν 到流的“乐观”可达部分密度来模拟，例如 $\mu = F_{out} + \delta$ 与 $\delta > 0$ ，我们使用了 $\delta = 0.001$ 。

我们没有尝试优化 δ ，其最优值可能取决于损失的选择。每个训练轮次更新 μ 如果开启自我训练，则进行 200 步梯度下降。

Metrics We compared Flow Matching losses $\log \mathcal{L}$, sampling distribution error $\mathcal{E}_F := \log \sum_{s \in S^*} \left| \mathbb{P}(M_\tau = s) - \frac{R(s)}{R(S^*)} \right| = \log \sum_{s \in S^*} \left| \frac{\bar{R}(s)}{\bar{R}(S^*)} - \frac{R(s)}{R(S^*)} \right|$, the averaged sampling time $\mathbb{E}(\tau) = \frac{\bar{F}_{out}(S^*)}{\bar{R}(S^*)}$, the reward error $\mathcal{E}_R := \sum_{s \in S^*} \frac{|\hat{R}(s) - R(s)|}{R(S^*)}$ and the initial flow error $\mathcal{E}_I = \log \left| \frac{F(s_0 \rightarrow S^*) - R(S^*)}{R(S^*)} \right|$. Here $R = \max_{S^*} F$, $S^* = \{s \in S \mid F(s) = R\}$, which is thought

阵 π_f 推导出来。前者可以使用 R 计算

$$F_{out|S^*} = F(s_0 \rightarrow \cdot)|_{S^*} (Id_{S^*} - \pi_f|_{S^*})^{-1}$$

但这种方法很快变得计算成本过高。相反，我们使用幂方法来近似 $\bar{F}_{out}$ ，在 λW 和 $\lambda > 1$ 处进行截断，理由是一个好的采样器不需要比宽度更多的步骤。我们通常取 $\lambda \in \{4, 10\}$

以给自己留出一些余地。尽管其中一些估计量是冗余的，但它们的解释不同：• $\mathcal{E}_F$ 衡量流作为采样器的好坏；• $\mathcal{E}_R$ 衡量流作为近似器的好坏；• $\mathcal{E}_I$ 衡量流作为积分器的好坏；• $\mathcal{E}_\tau$ 衡量流的效率； $\mathcal{E}_\delta$ 衡量训练完成的程度。

C.2 凯莱图实现细节 该实现选择了一个单射群同态

$\rho: \mathbb{S}_p \rightarrow \text{GL}(\mathbb{R}^d)$ 对于某个 d 以及一个点 $P \in \mathbb{R}^d$ 使得每个 $g \in S^*$ 与 σ 之关联 $\rho(g)P$ 可训练的边流 F 然后是一个函数 $F^\theta: \mathbb{R}^d \rightarrow \mathbb{R}^d$

使得 $F(\rho(g)P) = (F(g \rightarrow \sigma(g)))_{\sigma \in [1,q]}$ 流入和流出在小规模情况下是可以处理的 q 为了训练流，使用正向策略生成一批路径，忽略流向汇的情况 s_f 使得所有路径达到一个截止长度。这样的未停止路径所到达的状态 $(s_t)_{t \geq 0}$ 根据概率进行加权，该概率由“ $t \leq \tau$ ”条件得出。 $\forall t \leq \tau, s_t = s_\tau$ 这允许使用固定大小的状态

批次工作，并减少损失估计器的方差，该损失由流本身生成的路径密度给出。 ν 实验使用 $\rho(\sigma) := \frac{\text{The experiments}}{(\sigma(1), \dots, \sigma(p))}$ 进行

F 由深度为 3，宽度为 32 且激活函数为 LeakyReLU 的密集 MLP 给出，训练速率为 $1e-2$ ，路径批大小为 64。本文进行了比较 $\mathcal{L}_{FM}$ 与 $\mathcal{L}_{FM, \Delta, f, g}$ 对于一系列函数选择范围

f, g 与超网格相同类型。初始流固定到一个标量参数 $F(s_0 \rightarrow \cdot) = F_{init} \mathcal{U}(S^*)$ 其中 $\mathcal{U}(S^*)$ 是在 S^* 上均匀分布。这使得能

够更好地进行探索，并模拟解决通用问题的过程（例如，从任意位置开始寻找通往奖励的路径）。

稳定损失的比较 对上述引入的多种稳定损失变体进行了测试。我们观察到调整超参数具有挑战性，高稳定的正则化是有用的。在凯莱图上给出的结果中，正则化部分的幂选择 g 有一个缺点：由于幂小于 1，小流倾向于坍缩到 0。有趣的是，正如上面所示，流仍然具有良好的采样特性。不坍缩的稳定损失 ($g(x) = 1 + |x + y|^p$ 与 $\beta = 0$ 或 $\beta > 1$) 表现出不爆炸的行为，但预期回报次优。