

GFLOWNETS 在何时能 够学习到正确的分布?

Tiago da Silva

Getulio Vargas Foundation

{tiago.henrique, rodrigo.alves, eliezer.silva}@fgv.br

Rodrigo Barreto Alves

Eliezer de Souza da Silva

Amauri Souza

Federal Institute of Ceará

amauriholanda@ifce.edu.br

Vikas Garg

YaiYai Ltd and Aalto University

vgarg@csail.mit.edu

Samuel Kaski

Aalto University, Manchester University

samuel.kaski@aalto.fi

Diego Mesquita

Getulio Vargas Foundation

diego.mesquita@fgv.br

摘要

生成流网络 (GFlowNets) 是一类新兴的抽样方法, 适用于离散和组合对象的分布, 例如图。尽管在药物发现和系统发育推断等问题上取得了显著成功, 但关于何时以及是否 GFlowNets 能够学会从目标分布中抽样的问题仍然研究不足。为了解决这一问题, 我们首先评估违反潜在流网络的细致平衡对 GFlowNet 抽样分布正确性的影响程度。具体而言, 我们证明不平衡边对模型准确性的影响力受到通过该边的总流量影响, 并因此在网络中不均匀分布。我们还指出, 根据参数化情况, 不平衡可能是不可避免的。在此背景下, 我们考虑使用由图神经网络 (GNNs) 参数化的 GFlowNets 从图分布中抽样的问题, 并表明 GNNs 的表现力限制决定了这些 GFlowNets 可以近似的分布类型。最后, 我们通过提出一种理论上合理且计算可行的度量来解决这些局限性, 实验显示该度量比流行的评估协议更适合作为正确性的代理。

1 引言

生成流网络 (GFlowNets, Bengio 等人, 2021; 2023) 是一种基于奖励的生成模型, 适用于组合对象 (例如序列或图), 已在多个科学领域成功应用 (Deleu 等人, 2022; 2023; da Silva 等人, 2023; Zhang 等人, 2023d; Jain 等人, 2022; Bengio 等人, 2021; Jain 等人, 2023)。本质上, GFlowNets 将从一个未归一化的分布中采样转化为解决一个网络流问题 (Bazaraa 等人, 2004)。从初始状态开始, GFlowNets 通过根据相邻状态之间的流量量确定的 (前向) 策略网络绘制一系列动作来创建有效样本。这一过程可以解释为将分布的总质量 (源处的流量) 通过导向目标分布支持集元素 (汇节点) 的轨迹进行扩散。

尽管大多数关于 GFlowNets 的工作主要集中在经验研究上, 但深入理解其理论基础对于设计既具有理论依据又在实践中有效的模型和评估方法至关重要。在这方面, Bengio 等人 (2023; 2021) 奠定了 GFlowNets 的技术基础, 证明满足所谓的平衡条件的模型可以从目标离散分布中采样。Lahlou (2023) 将这一理论扩展到任意拓扑空间上的概率测度的上下文中。最近, GFlowNets 与变分推断 (Malkin 等, 2203 年)、强化学习 (Tiapkin 等, 2024 年) 以及扩散模型 (Garipov 等, 2023; Lahlou, 2023) 之间的关系也被正式建立。

表 1: 本工作的主要贡献。加粗项目表示方法上的进步。

Section 3	
Sensitivity to local failures for general SGs and targets	Thm. 1
Formulation of weighted DB loss and comparison against DB	Eq. 6, Fig. 4
Section 4	
Universal approximation of distributions over trees	Thm. 2
Representational limits of 1-WL GFlowNets	Thm. 3
Formulation of Look-Ahead (LA) GFlowNets	Eq. 7
LA-GFlowNets $\succ$ Standard GFlowNets	Thm. 4, Fig. 6
Section 5	
Definition of FCS as a tractable goodness-of-fit metric	Def. 1
Relationship between FCS and TV	Thm. 5, Cor. 1
FCS is highly correlated to TV	Sec. 5.1
Inadequacy of commonly used evaluation protocols	Sec. 5.2

尽管有这些进展，一个具有重要实用启示的问题仍然存在：GFlowNet 在什么情况下能够正确地学习其目标分布？更具体地说，关于 GFlowNet 的准确率对平衡违规的敏感性、不平衡可能的原因，或者如何以一种原则性的方式评估大规模状态空间中 GFlowNet 的分布正确性，目前所知甚少。

本文建立了一系列结果以解决这些基本问题。首先，我们提供了 GFlowNets 作为函数在平衡波动/违反情况下的总变差界限。通过考虑具有相同奖励的树状状态图，我们展示了不同深度处的流不平衡对 GFlowNets 近似能力的影响是非均匀的——更具体地说，根状态附近的平衡不匹配可能比终端状态附近的不匹配影响更大。我们还将分析扩展到证明类似的结果适用于一般的有向无环状态图 (DAGs) 和多模态目标分布。为了展示这些洞见的实际益处，我们设计了一种新型的学习目标家族，扩展了传统的详细平衡损失。正如我们在第 3 节中所展示的，这种方法通常会加速训练收敛。

在深入探讨不平衡流网络对 GFlowNet 准确率的影响后，我们进一步研究其潜在原因。为此，我们研究了在采样图结构对象时 GFlowNet 的分布极限。值得注意的是，大多数 GFlowNet 的应用涉及从图上的分布进行采样，这使得图神经网络 (GNNs) 特别适合于参数化策略网络。事实上，在实践中，GNNs 经常被用来参数化策略 (Bengio 等, 2021; Roy 等, 2023; Zhu 等, 2023; Zhang 等, 2023d; Pandey 等, 2024)。基于此，我们提供了揭示其不足之处的构造。虽然在温和条件下，基于 GNN 的 GFlowNet 可以表示任何树上的分布，但我们证明存在简单的状态图和目标分布，没有任何 GFlowNet 能够正确地从中采样。我们利用这一分析引入了前瞻 GFlowNet (LA-GFlowNet)，这是一种简单而有效的方案，可以证明性地增强 GFlowNet 的表达能力。本质上，LA-GFlowNet 将子节点状态嵌入作为前向策略的输入。这使得 LA-GFlowNet 能够区分导致可区分状态但无法通过 Weisfeiler-Leman (WL) 测试区分开来的动作。

这些不可能性的结果突显了拥有一个可靠的度量来探查训练好的 GFlowNet 准确性的必要性。从这个意义上说，我们也提供了一个理论上合理的框架，用于高维状态空间中 GFlowNet 的分布评估（即拟合优度），我们称之为子图流一致性 (FCS) 度量。简单来说，FCS 是由目标支持的“切割”分布相对于平均 L1 误差的一个蒙特卡洛估计。FCS 度量是 GFlowNet 采样与目标分布之间绝对误差的一个代理，我们实证地展示了 FCS 与（通常难以计算的）L1 误差高度相关，同时计算需求减少了三个数量级。相比之下，我们展示了流行的评估度量未能准确捕捉分布正确性，例如，在训练过程中访问的高奖励状态的数量以及排名前 k 的状态的平均奖励

(姜等, 2024; 金等, 2024; 本吉奥等, 2021). 本文认为, 这一贡献对于确保 GFlowNet 文献的顺利进展具有极高的价值。

在表 1 中, 我们总结了本工作的主要贡献。第 3 节分析了 GFlowNets 的分布正确性作为平衡违规函数, 并利用这些理论洞见提出了加权详细平衡 (WDB) 损失的一系列方法。第 4 节讨论了 GFlowNets 在图领域表示能力的极限, 并提出了 LA-GFlowNets 以增强基于 GNN 的 GFlowNets 的表达能力。最后, 第 5 节提出了 FCS 作为一个理论上可靠的度量来评估 GFlowNets 的准确率, 特别适用于高维设置。重要的是, 本工作所有部分都提供了实验来支持我们的理论分析, 说明了所提出的主张并展示了方法论贡献的实际相关性。

2 背景知识

符号表示。 令 $\mathcal{X}$ 为一个有限集合, 我们称之为终端状态集, 令 R 为在 $\mathcal{X}$ 上的一个未归一化的分布, 也称为奖励函数 (Bengio 等, 2021)。定义状态集 $\mathcal{S}$ 作为对 $\mathcal{X}$ 的扩展, 包含两个独特的元素: 初始状态, $s_o \in \mathcal{S}$ 和最终状态, $s_f \in \mathcal{S}$ 。因此, 定义有向无环图 $\mathcal{G} = (\mathcal{S}, \mathcal{E})$, 称为状态图 (SG), 使得 (i) 没有指向 s_o 的入边; (ii) 对于每个 $x \in \mathcal{X}$, 存在从 s_o 到 x 的有向路径; (iii) 从每个 x 到 s_f 有一条边, 该边不直接连接到 $\mathcal{S}$ 中的其他任何状态; (iv) 没有从 s_f 出发的出边。图 1 展示了状态图, 其中状态表示多重集, 边表示添加一个元素的操作。若轨迹 $\tau = (s_0, s_1, s_2, s_f)$ 表示由转移始于 s_0 并结束于完整轨迹 τ 则称其为完整的。

如, (s_0, s_1, s_2, s_f) 在 $\mathcal{G}$ 中。图 1 是一个完整的轨迹。向前策略覆盖 $\mathcal{G}$ 是一个函数 $p_F: \mathcal{S} \times \mathcal{S} \rightarrow \mathbb{R}_+$, 其中 $p_F(s, \cdot)$ 是在 $\mathcal{G}$ 中 s 的子节点上支持的概率测度, 记为 $\text{child}(s)$ 。我们交替使用 $p_F(\cdot|s)$ 和 $p_F(s, \cdot)$ 。向后策略 p_B 是覆盖 $\mathcal{G}$ 的转置的向前策略。对于一个完整的轨迹 τ , 我们写作 $p_F(\tau) = \prod_{i=1 \dots h} p_F(s_{i-1}, s_i)$ 。我们表示基数运算符为 $\#$ 。对于轨迹 τ , $\#$ τ 表示其状态转移的数量。




图 1: 状态图的示意图。

GFlowNets (GFlowNets). GFlowNet 学习一个前向策略 p_F 和 (有时) 一个后向策略 p_B 以及一个流函数 F on a SG $\mathcal{G}$, 使得边缘分布 p_F 在 $\mathcal{X}$, $p_T(x) = \sum_{\tau: \tau \sim x} p_F(\tau)$ 上的分布 $\tau \sim p_F(\tau)$, 与给定的奖励函数 R 相匹配 (相差一个归一化因子)。我们将 p_T 称为 GFlowNet 的采样分布, 并将 $\pi \propto R$ 称为在 $\mathcal{X}$ 上的由奖励诱导的概率测度。通常, 我们会用 $(\mathcal{G}, p_F, p_B, F)$ 或者 (当没有歧义风险时) 简称 (p_F, p_B, F) 来表示 GFlowNet。在许多应用中, p_F 和 F 被参数化为图神经网络 (Bengio 等, 2021; Zhang 等, 2023d) 或变换器 (Deleu 等, 2022; Kim 等, 2024), 而 p_B 则固定为均匀策略。自 Bengio 等 (2021) 开创性工作以来, 提出了多种学习目标来估计模型参数 (Malkin 等, 2022; 2023; Madan 等, 2022; Zhang 等, 2023b), 其中大多数基于网络平衡的原则——确保状态中的流入和流出流量相等。例如, 详细的平衡 (DB) 损失通过最小化轨迹内状态的流入和流出流量之间的平均对数平方差来强制执行详细的平衡条件 $F(s)p_F(s'|s) = F(s')p_B(s|s')$ (Bengio 等, 2023; Zhang 等, 2023d)

$$\mathcal{L}_{\text{DB}}(p_F, p_B, F) = \mathbb{E}_{\tau} \left[\frac{1}{\# \tau} \sum_{(s, s') \in \tau} \left(\log \frac{F(s)p_F(s'|s)}{F(s')p_B(s|s')} \right)^2 \right] \quad (1)$$

带有硬编码约束 $F(s') = R(s')$ 当 $s' \in \mathcal{X}$ 为终止状态时; 期望是关于轨迹上的任意正概率测度进行计算的。其他流行的学习目标, 如轨迹平衡 (TB) (Malkin 等, 2022) 和子轨迹平衡 (SubTB) (Madan 等, 2022) 损失, 在附录中进行了评述。

GFlowNets 的评估。 对于大多数问题, $\mathcal{X}$ 过大以至于无法直接比较 GFlowNet 的采样分布与目标分布 R 。因此, 评估 GFlowNets 的拟合优度和收敛速率是一个具有挑战性的问题。为了避免这一问题,

文献中的常见做法（潘等，2023a;b; 2024; 张等，2023d; 荣等，2024）是测量训练过程中找到的最高得分状态的数量和平均奖励。直觉是，一个拟合良好的模型将迅速定位目标分布的概率较高的区域。更精确地，设 $\mathcal{X}_T \subseteq \mathcal{X}$ 为训练过程中找到的终止状态， $R_o \in \mathbb{R}_+$ 为手工设定的阈值， $\mathcal{H}(\mathcal{X}_T, R_o) = \{x: x \in \mathcal{X}_T \wedge R(x) \geq R_o\}$ 为在 $\mathcal{X}_T$ 中奖励大于 R_o 的样本。另外，设 $\{x_1, \dots, x_S\} \sim p_T$ 为从训练好的 GFlowNet 中抽取的 S 个样本。然后，我们定义

$$\text{Avg}(\mathcal{X}_T, R_o) = \sum_{x \in \mathcal{H}(\mathcal{X}_T, R_o)} \frac{R(x)}{\#\mathcal{H}(\mathcal{X}_T, R_o)} \text{ and } \text{Acc}(p_T) = \min \left\{ \frac{\frac{1}{S} \sum_{1 \leq i \leq S} R(x_i)}{\mathbb{E}_{x \sim R}[R(x)]}, 1 \right\}. \quad (2)$$

第二个度量，Shen 等人 (2023) 和 Kim 等人 (2024) 称之为准确率，基于预期奖励衡量 GFlowNet 与目标之间的接近程度——假设 $\mathbb{E}_{x \sim R}[R(x)]$ 可以计算。重要的是，我们将在第 5 节展示， $\text{Avg}(\mathcal{X}_T, R_o)$ ， $\#\mathcal{H}(\mathcal{X}_T, R_o)$ 和 $\text{Acc}(p_T)$ 并不一定与 GFlowNet 与其学习目标全局最小值之间的接近程度相关，因此，如果不仔细解读，可能会导致误导性的结论。

GNN 的表达能力和 1-WL 同构测试。 图神经网络 (GNNs) 是图表示学习中占据主导地位的模式（徐等，2019; 汉密尔顿，2020; 王等，2024; 科尔索等，2024）。大多数图神经网络采用多层消息传递方案，在每一层中交替执行邻域聚合和更新操作。具体而言，对于每个节点 v 在层 ℓ ，聚合是非线性函数的 $(\ell - 1)$ -层表示 v 的邻居。更新步骤计算一个新的表示形式 v 基于其在层上的表示 $\ell - 1$ 以及聚合的消息（聚合步骤的输出）。重要的是，消息传递图神经网络具有众所周知的表现力限制，这些限制由一阶 Weisfeiler-Lehman 同构测试 (1-WL) 上限（Xu 等，2019; Weisfeiler & Lehman, 1968）。关于这种关系的更多细节请参见附录 B。

3 流网络中误差传播的研究

我们的研究始于 GFlowNet 中分布误差的主要来源，即底层流网络中缺乏平衡。在此过程中，我们希望解答的主要问题是：违反平衡条件对 GFlowNet 拟合优度的影响是什么？

3.1 GFlowNet 总变差的界限

为了建立直觉，我们的第一个结果（注记 1）量化了单个节点违反细致平衡条件的程度可能如何影响 GFlowNet 采样分布与树结构子图中均匀目标之间的 TV 距离，在应用中经常出现这种结构，例如 (Jain 等, 2022; Jiralerspong 等, 2023; 刘等, 2023; 胡等, 2023)。

备注 1 (树结构 SG 的 TV)。设 (G, p_F, p_B, F) 是一个相对于奖励 R 平衡的 GFlowNet，其中 G 是一个分支因子为 g 且深度为 h 的有向正则树，且 R 是非归一化的均匀分布。此外，考虑 GFlowNet $(G, \tilde{p}_F, p_B, F)$ ，使得 i) $F(s_o) = F(s_o) + \delta$ 和 $F(s^*) = F(s^*) + \delta$ 对于某些子节点 $s^* \in (s_o)$ 和 $\delta \geq 0$; ii) $\tilde{F}(s) = F(s)$ 对于所有不可从 s^* 到达的 s ; iii) $\tilde{F}(s) = \sum_{s' \in \text{child}(s)} \tilde{F}(s')$; 以及 iv) (见图 2 设 $\tilde{p}_T$ 是由 $\tilde{p}_F$ 诱导的边缘分布。 $\tilde{p}_T$ 与 $\pi \propto R$ 之间的总变差满足

$$\epsilon(\delta, g, F(s_o)) \leq \text{TV}(\tilde{p}_T, \pi) \leq \epsilon(\delta, g^h, F(s_o)), \text{ with } \epsilon(\delta, x, t) := (1 - 1/x) \delta / t + \delta. \quad (3)$$

显然，上下界都是随变量增加的函数 δ 。这些界限是紧致的，即对于任何 δ 对于 TV 等于所给定界的情况，存在一个相应的流函数。此外，我们注意到上界 $\epsilon(\delta, g^h, F(s_o))$ 随着叶节点数量的增加而单调增加 g^h ，i.e., 不平衡边的距离越远 (s_o, s^*) 来自叶节点的影响越大，对准确率潜在损害也越大。值得注意的是，这表明平衡性违规对分布近似的影响在 SG 的边之间异质分布。我们在图 3 中通过实验验证了这些发现，针对第 2 节概述的基准任务。




图 2: 带有额外流量的树结构 SG δ 从 s_o 到左子节点。省略节点标签。




图 3: 训练初期沿随机采样的轨迹计算的平均值

$\mathcal{L}_{DB}(s, s') := (\log(F(s)p_F(s, s') - \log(F(s')p_B(s, s'))))^2$ 。根据我们的分析，DB 损失在轨迹上分布不均，不同的转换对损失的影响各异。

正如定理 1 所示，这些直观的结果可以扩展到任意形状的 SG 中标记有任意目标概率测度的情形中去 π 。在这一更广泛的设定下，方程 3 是一个特例，状态的由树继承而来的深度和分支因子的概念被终端后代累积的总概率质量所取代 $s \rightarrow s'$ 。读者可观察到，在备注 1 的假设下，这些性质是可以互换的。然而，从实践者的角度来看，定理 1 中出现的数量的确切计算对于大多数基准和实际问题来说是不可行的。因此，我们在下一节的经验分析将利用定理 1 的洞见以及备注 1 的计算可行性，推导出一种加权细致平衡 (WDB) 损失。该损失通过根据状态距离给不同的转换分配不同的权重，旨在促进平衡流分配的搜索并加速训练收敛。

定理 1 (任意分布的 TV 界)。 设 $(\mathcal{G}, p_F, p_B, F)$ 是一个具有任意状态图的 GFlowNet $\mathcal{G}$ 满足关于任意奖励的 DB 条件 R 类似地，如同注释 1，定义 $(\mathcal{G}, \tilde{p}_F, p_B, \tilde{F})$ 通过增加流量 $F(s)$ 在某些节点 s 通过 δ 并将额外流量重定向到直接子节点 s^* 通过适当调整 $p_F(s, \cdot)$ 同样地， $\tilde{F}$ 通过将额外流传播到所有可达的状态来定义 s^* 。此外，令 $\mathcal{D}_{s^*} \subseteq \mathcal{X}$ 为可从状态到达的终止状态集 s^* 。然后，分配之间的电视 $\tilde{p}_T$ 超过 $\mathcal{X}$ 由...诱导的 $\tilde{p}_F$ 并且归一化的目标 $\pi \propto R$ 满足

$$\frac{\delta}{F(s_0) + \delta} \left(1 - \sum_{x \in \mathcal{D}_{s^*}} \pi(x) \right) \leq \text{TV}(\tilde{p}_T, \pi) \leq \frac{\delta}{F(s_0) + \delta} \left(1 - \min_{x \in \mathcal{D}_{s^*}} \pi(x) \right). \quad (4)$$

3.2 应用于 GFlowNet 训练

加权 DB。 我们注意到，默认情况下，方程 1 中的 DB 损失计算的是转换级别误差的算术平均值。本质上，这种设计编码了每个转换对逼近目标分布这一总体目标具有相同的影响。然而，正如我们在第 3.1 节中的理论和实证分析所指出的那样，情况并非如此。因此，我们构建了一组加权细致平衡 (WDB) 损失，

$$\mathcal{F}_{WDB} = \left\{ \mathcal{L}_\gamma(s, s') : (s, s') \mapsto \gamma(s, s') \left(\log \frac{F(s)p_F(s'|s)}{F(s')p_B(s|s')} \right)^2 \mid \gamma : \mathcal{S} \times \mathcal{S} \rightarrow \mathbb{R}_+ \right\}, \quad (5)$$

并选择一个 $\mathcal{L}_\gamma \in \mathcal{F}_{WDB}$ 来训练 GFlowNet，同时最小化随机目标

$$\mathcal{L}_{WDB}^\gamma(p_F, p_B, F) := \mathbb{E}_\tau \left[\frac{1}{\sum_{(s, s') \in \tau} \gamma(s, s')} \sum_{(s, s') \in \tau} \mathcal{L}_\gamma(s, s') \right]. \quad (6)$$

我们面临选择合适方法的任务 γ 受扩散概率模型近期进展的启发 (Kingma 等, 2021; Kingma & Gao, 2023)，本文可能选择一个 γ 确保方程 6 中的任何项都不主导损失。鉴于注释 1，任何关于 $\#$ 的单调递减函数 $\mathcal{D}_{s'}$ (即终端后代数量) s' 将是一个有原则的选择 γ 。这里，我们使用 $\gamma(s, s') = 1/\# \mathcal{D}_{s'}$ ，但承认其他 γ 可能对不同的任务是最优的。




图 4: WDB 在性能上与 DB、SubTB 和 TB 相比具有竞争力或更优。通过加权每个 (s, s') 与终端后代的数量成反比地 s' (i.e., $\gamma(s, s') = 1/\# \mathcal{D}_{s'}$) 在 DB 损失函数中, 相较于标准目标函数, 在 TV 意义上的收敛速度更快。

经验说明。我们在图 4 中比较了 WDB 与 TB、SubTB 以及标准 DB 目标 (带 $\gamma \equiv 1$) 在 GFlowNets 上的四种基准任务中的性能: 自回归序列设计 (Jain 等, 2022; Malkin 等, 2022; Jiralerspong 等, 2023), 系统发生推断 (Zhou 等, 2024), 集合生成 (Bengio 等, 2023; Pan 等, 2023b; Jang 等, 2024), 以及超网格导航 (Malkin 等, 2022; 2023; Madan 等, 2022)。关于实验设置的更多细节, 请参见附录 E。值得注意的是, 使用 WDB 可以加快 GFlowNet 采样分布向系统发生推断和集合生成的目标分布收敛的速度——这通过 TV 距离来衡量。请注意, 这两个环境正是早期阶段转换主导损失的情况, 如图 3 所示。对于剩下的两种情况, WDB 的表现大致与标准 DB 相当。这些结果在第 E.4 节中有详细讨论 (见图 11), 表明通过适当加权轨迹中的每次转换, 可以大幅改进 DB 损失。

4 图神经网络基础策略网络的分布极限

截至目前, 我们的分析主要集中在不平衡节点对 GFlowNet 采样分布的影响上。现在, 我们将退一步, 分析这种不平衡的一个自然原因: 参数化。值得注意的是, GFlowNets 的一些热门应用领域在于图领域, 并利用图神经网络 (Graph Neural Networks) 来引入期望的归纳偏置 (例如, Bengio 等, 2021; Nica 等, 2022; Roy 等, 2023; Zhang 等, 2023d; Zhu 等, 2023; Pandey 等, 2024)。因此, 本节探讨基于图神经网络的 GFlowNets 的表示极限。为此, 我们展示了它们普遍具备近似树上分布的能力。接着, 我们构建了一类问题, 这类问题基于 1-WL 图神经网络的 GFlowNet, 即 1-WL GFlowNet, 无法解决, 从而表明平衡违反可能源于策略网络的有限表达能力。

我们的首个结果 (定理 2) 表明, 对于任何在树上支持的奖励, 存在一个 1-WL GFlowNet 能够按比例采样该奖励。为了实现这一结果, 我们构建了一个简单的生成过程, 从一个完全不连通的图开始, 每次添加一条边, 始终仅产生一个非单点组件。

定理 2 (1-WL GFlowNets 对树的普适性)。若 $\mathcal{S}$ 是一组树, 使得 $(s, s') \in \mathcal{E}$ 意味着 $s \subset s'$ (s 是 s' 的一个真子树 (且 $\# E(s') = \# E(s) + 1$)), 则存在装备有 1-WL GNNs 的 GFlowNet 可以逼近定义在 $\mathcal{X} \subseteq \mathcal{S}$ 上的任意分布 π 。

定理 2 证明了 1-WL GFlowNets 可以从任意树分布中采样。然而, 1-WL 测试并不是同构性的完美预言。一个自然的问题是: 1-WL GFlowNets 的表现力是否存在限制? 定理 3 展示了一大类情况 (即 SGs 和奖励函数的组合), 在这些情况下, 1-WL GFlowNets 会失败。这一结果基于这样一个事实: 如果导致状态的动作在 1-WL 下无法区分, 则这些状态必须均匀地将流量分配给其子节点。




图 5: 一种状态图与奖励函数的组合, 导致 1-WL GFlowNets 失败。

展示 1-WL GFlowNets 的失败模式。 图 5 提供了一个构造，在该构造中，1-WL GFlowNets 无法实现平衡。请注意，导致 s 的子节点 s' 和 s'' 的动作（用框包围）在 1-WL 下是不可区分的。因此，1-WL 策略将流在 s 中平均分配给 s' 和 s'' ，未能匹配不同的奖励 $R(s') = 4$ 和 $R(s'') = 8$ 。定理 3 将这种直觉扩展到更广泛的案例。

定理 3 (基于 GNN 的 GFlowNets 的局限性)。 设 $\mathcal{G} = (\mathcal{S}, \mathcal{A})$ 是一个状态图， $R: \mathcal{X} \subseteq \mathcal{S} \rightarrow \mathbb{R}^+$ 是一个奖励函数。假设 $\mathcal{G}$ 是一个有向树。令 $T(s) \subseteq \mathcal{X}$ 对于 $s \in \mathcal{S}$ 表示从 s 出发可到达的终端状态集合。如果存在一个状态 $s = (V, E) \in \mathcal{S}$ 和两对节点 $(a, b) \neq (c, d) \in V^2 \setminus E$ 它们不是 1-WL 可区分的，并且 $\sum_{x \in T(s')} R(x) \neq \sum_{x \in T(s'')} R(x)$ 其中 $s' = (V, E \cup \{(a, b)\})$ 和 $s'' = (V, E \cup \{(c, d)\})$ (如图 5 所示)，那么不存在能够近似 $\pi \propto R$ 且总变差为零的 1-WL GFlowNet。

我们现利用这些洞见提出了一种更具表现力的基于 GNN 的 GFlowNet：前瞻 GFlowNets (LA-GFlowNets)。LA-GFlowNets 的设计理念是将子节点的图嵌入作为前向策略的输入。这使得 LA-GFlowNets 能够区分通过 1-WL 等价动作获得的子状态，即使这些动作在视觉上不可区分，只要对应的子状态嵌入不同，就可以分配不均匀的概率。

更正式地，设 s' 和 s 是 SG 中的两个相邻节点，它们仅在边 (u, v) 上有所不同，而该边不在 s 中——请记住， s 和 s' 本身是图。另设 $\phi_{v|G}$ 是图 G 中节点 v 的 1-WL 嵌入。那么，LA-GFlowNets 的前向策略可以描述为

$$p_F(s, s') \propto \exp \left\{ \text{MLP} \left(\psi_1 \left(\{\phi_{u|s}, \phi_{v|s}\} \right) \parallel \psi_2 \left(\{\phi_{w|s'}\}_{w \in V(s')} \right) \right) \right\}, \quad (7)$$

其中 ψ_1 和 ψ_2 是与顺序无关的函数 (Zaheer 等, 2017)。由于子节点嵌入通过连接添加到原始动作嵌入中，因此相对于 1-WL GFlowNets 而言，没有表达能力的损失。另一方面，LA-GFlowNets 可以完美地逼近如图 5 所示的情况。定理 4 说明了 LA-GFlowNets 的优越表达能力。

定理 4 (LA-GFlowNet 比 1-WL GFlowNet 更具表达力)。 如果存在一个 1-WL 前向策略诱导出一个与奖励 R 成比例的采样分布，则存在一个 LA-GFlowNet 前向策略，在相同的子图上具有与 R 成比例的采样分布。反之则不成立。

经验说明。 为了展示 1-WL GFlowNets 的局限性，我们接下来定义一组 $\mathcal{G}$ 子图 (

SGs)，对于这些子图，存在一些操作，尽管它们导致的状态是非同构的，但无法通过基于图神经网络 (GNN) 的策略来区分。在这种情况下，令 $\mathcal{R}_{n,k}$ 为具有 n 个节点且度数为 k 的正则图集合。然后，令 $\mathcal{G}$ 为满足条件的子图集合 $C_1 \leftarrow P \rightarrow C_2$ ，即 $P \in \mathcal{R}_{n,k}$ 和 C_1 以及 C_2 是非同构图，它们与 P 仅相差一条额外的边；请参见补充材料中的图 9 以获得说明。请注意，由于 $P, p_F(P, C_1) = p_F(P, C_2)$ 的 (图论意义上的) 正则性，对于任何基于 GNN 的 p_F ，因此，相应的 LA-GFlowNets 不受这种有限表达能力的限制。作为一个示例，我们创建四个三元组 (C_1, P, C_2) ，其中包含 $n = 8, k = 3, R(C_1) = 0.1$ 和 $R(C_2) = 0.9$ 。在这些条件下，图 6 显示 LA-GFlowNet 可以准确地从目标分布中采样。然而，一个标准的基于 GNN 的 GFlowNet 只能从均匀分布中采样，在整个训练过程中达到一个 (常数) L_1 误差为 0.4。




图 6: 展示了 LA-GFlowNets 成功而基于标准 GNN 的 GFlowNet 失败的示例。

5 GFlowNet 的收敛性诊断

最终，在理解到存在某些分布使得 GFlowNet 无法从中采样的基础上，我们提出一个问题：如何有效地评估一个 GFlowNet 与其目标分布之间的接近程度？为了回答这个问题，我们提出了一种可证明正确的且计算上可行的度量方法，用于探测 GFlowNets 的分布不一致性 (第 5.1 节)，该方法被称为子图中的流一致性 (Flow Consistency in Subgraphs, 简称 FCS)。令人惊讶的是，我们将 FCS 与三种流行的评估 GFlowNet 收敛性的技术进行了比较，即模式数量、最高得分样本的平均奖励以及沈氏准确率，并展示了 FCS 往往是唯一能够准确反映 GFlowNet 拟合优度的度量标准 (第 5.2 节)。

5.1 探测 GFlowNet 的分布不一致性

子图中的流一致性 (FCS)。FCS 的基本原理是在估计概率比值之间的差异而非测量难以处理的学习分布与目标分布之间的发散。为此，我们回顾边缘分布 p_T 的一个 GFlowNet $(\mathcal{G}, p_F, p_B)$ 在终止状态上 $\mathcal{X}$ 可以计算为

$$p_T(x) := \sum_{\tau: s_o \rightsquigarrow x} p_F(\tau) = \mathbb{E}_{\tau \sim p_B(\cdot|x)} \left[\frac{p_F(\tau)}{p_B(\tau|x)} \right] \quad (8)$$

对于每个 $x \in \mathcal{X}$ 。在大多数基准任务中，例如超网格环境 (Malkin 等, 2023 年)，集合生成 (Shen 等, 2023 年) 和序列设计 (Jain 等, 2022 年)，我们可以精确且易于计算地得出 p_T 。在自回归问题 (Jain 等, 2022 年) 中，例如，存在一条单一轨迹 τ_x 通向每个 $x \in \mathcal{X}$ 。因此，

$p_T(x) = p_F(\tau_x)$ 可以直接评估。类似地，对于小状态图，可以通过枚举结束于 x 的轨迹 τ 来明确计算方程 8 中的求和。当精确计算 p_T 不可行时，方程 8 中期望值的蒙特卡洛估计提供了一个准确的近似值。在这种情况下，FCS 由比较 $p_T(x)$ 和 $R(x)$ 限制到 $\mathcal{X}$ 的随机子集构成。我们在下面的定义中形式化了这一过程。

定义 1 (子图中的流一致性)。设 P_S 是 β 大小的 $\mathcal{X}, \beta \geq 2$ 子集上的正概率分布。对于每个 $S \subseteq \mathcal{X}$ ，定义 p_T 和 R 在集合 S 上的限制为

$$p_T^{(S)}(x) = \frac{\mathbf{1}_{\{x \in S\}} p_T(x)}{\sum_{y \in S} p_T(y)} \text{ and } R^{(S)}(x) = \frac{\mathbf{1}_{\{x \in S\}} R(x)}{\sum_{y \in S} R(y)} \text{ for } x \in \mathcal{X}. \quad (9)$$

We define FCS as the expected TV between $p_T^{(S)}$ and $R^{(S)}$:

$$\text{FCS}(p_T, R) := \mathbb{E}_{S \sim P_S} [\text{TV}(p_T^{(S)}, R^{(S)})]. \quad (10)$$

Clearly, $\text{FCS}(p_T, R) \in [0, 1]$. Moreover, [Theorem 5](#) shows that $\text{FCS}(p_T, R) = 0$ only if $p_T(x) \propto R(x)$, asserting the conceptual correctness of our metric.

定理 5 (TV 与 FCS 之间的等价性)。设 P_S 是任意具有全支持的分布在 $\{S \subseteq \mathcal{X}: \#S = \beta\}$ 上，对于某个 $\beta \geq 2$ 。另设 $\text{TV}(p_T, \pi) = 1/2 \sum_{x \in \mathcal{X}} |p_T(x) - \pi(x)|$ 是从 p_T 到 $\pi := R/Z, Z = \sum_{x \in \mathcal{X}} R(x)$ 的 TV 距离。那么， $\text{TV}(p_T, \pi) = 0$ 当且仅当 $\text{FCS}(p_T, R) = 0$ 。

值得注意的是， β 在比率匹配类度量 (Hyvärinen, 2007) ($\beta = 2$) 和 TV 距离 ($\beta = \#\mathcal{X}$) 之间插值 FCS。这里，我们将 β 设置为训练中使用的轨迹批次的大小。在这方面，推论 1 阐明了 β 在 FCS 中接近 TV 距离的角色。是一个分布

Corollary 1 (Role of β in FCS). Let $P_S(S; \beta) = \mathbf{1}_{\{\#S = \beta\}} \binom{n-1}{\beta-1}^{-1} \sum_{x \in S} p_T(x)$

在 β 大小的 $\mathcal{X}$ 子集上。另设 $p_T(S) = \sum_{x \in S} p_T(x)$, and define $\pi(S)$ similarly. Then,

$$\left| \text{TV}(p_T, \pi) - \mathbb{E}_{S \sim P_S(\cdot; \beta)} [\text{TV}(p_T^{(S)}, R^{(S)})] \right| \leq \frac{1}{2} \cdot \frac{\#\mathcal{X}}{\beta} \cdot \max_{S \subseteq \mathcal{X}, \#S = \beta} |p_T(S) - \pi(S)|. \quad (11)$$

FCS 的实现。首先，我们强调 FCS 可以轻松扩展以适应不同大小的子集 $\mathcal{X}_{(i)}$ 。为了说明这一点，设 P_S 为在 $\{S \subseteq \mathcal{X}: \#S \leq \beta\}$ 中的任意正分布，当且仅当 FCS 在该

$\mathbb{E}_{S \sim P_S} [\text{TV}(p_T^{(S)}, R^{(S)})] = 0$ $p_T, R := \mathbb{E}_{S \sim P_S(\cdot; \#S = \beta)} [\text{TV}(p_T^{(S)}, R^{(S)})] = 0$. In
上下文中，FCS 的实现定义 P_S 为从固定策略采样的轨迹批次的终端状态对应的最多包含 β 个元素的子集分布，这些子集来自 $\mathcal{X}$

FCS 的 PAC 统计保证。从统计学的角度来看，FCS 通过在状态图的一小部分上探测模型来逼近 GFlowNet 的分布准确率。人们可能会好奇，在这些条件下，经验估计与确定性的拟合优度量相比如何。推论 2 从可能近似正确的 (PAC) 视角解决了这个问题，表明当采样的子集数量足够大 (大 m) 且模型相对准确 (误差小) 时，FCS 的估计值接近 TV。推论 2 (FCS 的 PAC 界)。设 P_S 如同定理 5 所述。那么，对于任意 $\delta \in (0, 1)$ ，以至少 $1 - \delta$ 的概率选择 m i.i.d. β 大小的子集 $S_1, \dots, S_m \sim P_S$ ，使得 $\mathcal{X}$:

$$\text{TV}(p_T, \pi) \leq \frac{1}{m} \sum_{1 \leq i \leq m} \text{TV}(p_T^{(S_i)}, R^{(S_i)}) + \frac{\#\mathcal{X}}{2\beta} \cdot \max_{S \subseteq \mathcal{X}, \#S = \beta} |p_T(S) - \pi(S)| + \sqrt{2 \log \frac{1}{\delta} / m}.$$




图 7: FCS 是 TV 距离的一种计算上可行的替代方案。（左）FCS 在所考虑的任务中准确地表示了 TV（右），同时其计算速度可快达三个数量级。




图 8: FCS 是唯一能够正确反映 GFlowNet 分布准确性的度量。训练过程中找到的最高得分样本的数量模式（第 3-4 列）和平均奖励（第 5-6 列）并不能准确反映 GFlowNet 的拟合优度，而 FCS 可以（第 1-2 列）。值得注意的是，我们考虑了 LED-和 FL-GFlowNets 的终端不受限变体（参见命题 1）。

经验说明。

图 7（左）显示 FCS 与集合和序列生成任务中的 TV 距离非常相似。实际上，FCS 与 TV 在这类任务中的斯皮尔曼相关性分别为 0.99 和 0.90。然而，重要的是，FCS 的估计比计算 TV 距离快达三个数量级（图 7（右））。值得注意的是，这些结果证明了 FCS 作为 GFlowNets 通用拟合优度度量的实用性。

5.2 案例研究：具有无限流限制的 LED-和 FL-GFlowNets

LED-和 FL-GFlowNets 在训练 GFlowNets 时，学习信号稀疏；仅能在每条轨迹结束时通过奖励函数获得。LED- (Jang 等, 2024 年) 和 FL- (Pan 等, 2023a 年) GFlowNets 旨在通过将 $\log F(s, s')$ 重新参数化为潜在函数的残差来减少这一问题

$$\phi_\theta(s, s'), \text{ i.e., } \log F(s, s') = \phi_\theta(s, s') + \log \tilde{F}(s, s'), \text{ 并最小化}$$

$$\mathcal{L}_{\text{LED}}(s, s') = \left(\log \tilde{F}(s) + \log p_F(s, s') - \log p_B(s', s) - \log \tilde{F}(s') + \phi_\theta(s, s') \right)^2 \quad (12)$$

对于每一个 (s, s') 。对于 FL-GFlowNet, $\phi_\theta(s, s') = \xi(s') - \xi(s)$ 被固定为手工设计的能量函数之间的差距，满足 $\xi(x) = -\log R(x)$ 对于 $x \in \mathcal{X}$ 和 $\xi(s_o) = 0$ (Pan 等, 2023a, 公式 (5))。对于 LED-GFlowNet, $\phi_\theta(s, s')$ 是通过学习获得的。读者可参阅附录 C 以获取更多详情。

具有无限流限制的 LED-和 FL-GFlowNets。 以下发现表明，即使在终端流量 $F(x)$ 对于 $x \in \mathcal{X}$ 不受限于相等 $R(x)$, LED-和 FL-GFlowNets 在传统度量上均显著优于标准 GFlowNet。然而，正如我们从理论上（命题 1）和经验上（图 8）所示，通过约束 $F(x)$ 到 $R(x)$ 确保 GFlowNet 的采样正确性即使在参数化下也是必要的。重要的是，我们有充分的理由相信无需限制 $F(x)$ 曾是 Pan 等 (2023a) 和 Jang 等 (2024) 原始工作中的一些实验的一部分（见附录 E.3），这一事实强化了需要一个标准的、易于计算的且可靠的度量来评估 GFlowNet，如 FCS。

命题 1（具有不受限制终端流的 GFlowNets 的不可预测性）。 考虑一个实现 $\mathcal{L}_{\text{LED}}(s, s') = 0$ 对于所有状态转移 (s, s') 以及轨迹 τ 。然后，学习到的边缘分布为 $\mathcal{X}$ 满足 $p_T(x) \propto R(x)\tilde{F}(x)$ 对于每一个 $x \in \mathcal{X}$ 。

我们将未强制执行 $F(x)=R(x)$ 训练的 GFlowNets 称为终端不限制 (TU)。

实验设置。 我们通过实验证明，在与三种流行的评估模型方法（模式数量、最高得分样本的平均奖励以及沈等人的准确率（见方程 2；沈等人, 2023 年））进行比较时，FCS 是唯一能够表示 GFlowNet 准确率的度量。为此，我们考虑了集合和袋（多重集）生成的标准任务，这些任务也出现在姜等人 (2024 年) 的实验方案中，并设计了可与特定序列结合的 DNA 序列。

酵母 PHO4 转录因子。对于后者，由于缺乏明显候选者，我们省略了 FL-GFlowNet 的结果 ξ ；结果展示在图 13 中。附录 E 包含更多细节。

结果。从图 8 和表 2 中可以得出三个主要结论。首先，我们的基线模型（TB-GFlowNet）能够准确地学习从目标分布中采样（图 8，左），而（终端不受限制的）LED-和 FL-GFlowNets 变体则不能。其次，LED-和 FL-GFlowNets 在训练过程中找到了比其标准对应模型更具有价值的状态空间部分（图 8，中，右），但无法正确采样。报告结果的大方差是由于模型各自的学习目标缺乏唯一稳定解的结果，正如命题 1 所述，并且 Pan 等人（2023a，图 2）也观察到了这一点。第三，沈的准确率并不是拟合优度的合适替代指标。总的来说，我们的实验表明，在比较 GFlowNets 的收敛速度时，应谨慎使用常规度量。

与文献中的传统观点相反，这些量并不直接衡量 GFlowNet 与其学习目标全局最小值之间的接近程度。鉴于此，我们的分析强调了拥有一个理论上合理且计算上可行的度量来评估 GFlowNet 的重要性，以推动该领域的进步。令人惊讶的是，FCS——据我们所知——是唯一满足这两个约束条件的替代方案。

表 2：沈等（2023）的准确率度量错误地将完美分数分配给了显然不成立的 TU-FL 和 TU-LED GFlowNet 变体。

	LED	FL	TB
Sets	100.00 $\pm$ 0.00	100.00 $\pm$ 0.00	93.74 $\pm$ 0.98
Bags	100.00 $\pm$ 0.00	100.00 $\pm$ 0.00	81.38 $\pm$ 6.86
PHO4	100.00 $\pm$ 0.00	NA	96.98 $\pm$ 0.77

6 结论、局限性及更广泛影响

结论。GFlowNets 的学习目标是在流网络中找到一个平衡的流量分配。因此，训练模型的不准确之处是违反所假设的平衡条件的结果。在这项工作中，我们首先论证了一个不平衡节点对 GFlowNet 分布正确性的影响力在整个流网络中是异质分布的。作为结果，我们通过非均匀加权转换项来扩展 DB 损失，以考虑这种异质性，这在实践中被证明是有效的。对于图结构生成任务，我们证明了这些平衡的违反可能与参数化策略网络的 GNN 的有限表达能力有关，这限制了 GFlowNet 可以采样的分布范围。为了缓解这一问题，我们引入了 LA-GFlowNets，通过将状态子节点的嵌入纳入策略网络来增强基于 GNN 的 GFlowNets 的表达能力。最后，我们提出了 FCS 作为一种计算上可行的度量，用于探测当学习到的流量分配可能是不平衡时，GFlowNets 与其目标分布之间的拟合优度。值得注意的是，我们的实验表明，FCS 比传统的诊断方法更能作为 GFlowNet 分布准确性的代理。

局限性。尽管我们的实证分析涵盖了 GFlowNet 文献中的标准基准问题，并在生成任务的多样性方面与其他工作相当，但它并未考虑诸如分子生成（Pandey 等，2024 年）和自然语言处理（Hu 等，2023 年）等专门应用。此外，我们用于 WDB 学习目标的加权方案是基于启发式方法得出的。虽然有效，但通过考虑损失函数的理想属性，如低梯度方差（Richter 等，2020 年；Malkin 等，2023 年），可能进一步改进。最后，我们确立了关于基于 1-WL GNN 的 GFlowNets 的能力与局限性的结果，这源于它们在实践中广泛应用（Kipf & Welling，2017 年；Velicković 等，2018 年；Xu 等，2019 年；Corso 等，2024 年）。然而，将这一分析扩展到更具表现力的（例如，更高阶）GNN 是一个有前景的方向（Morris 等，2021 年）。

更广泛影响。综上所述，我们认为我们的工作为 GFlowNet 文献中的许多进展铺平了道路。首先，第 3 节中 DB 目标更有效的加权方案的发展可能会加快 GFlowNet 的训练速度。同样，第 4 节中基于 GNN 的 GFlowNet 有限的表现力是一个警示故事，提醒我们在参数化模型策略时使用等变神经网络可能存在的问题，并且可能是解释某些分布难以近似以及开发更具表现力模型的有用工具。最后但同样重要的是，我们期望 FCS 对评估 GFlowNet 和验证新型学习目标产生重大影响。

致谢

本工作得到里约热内卢州研究基金会 FAPERJ (SEI-260003/000709/2023)、圣保罗研究基金会 FAPESP (2023/00815-6)、国家科学技术发展委员会 CNPq (404336/2023-0) 以及硅谷社区基金会通过大学区块链研究计划 (资助号#2022-199610) 的支持。感谢 Aalto Science-IT 项目和 FGV TIC 提供的计算资源。

参考文献

- Pierre Alquier. User-friendly introduction to pac-bayes bounds. *Foundations and Trends® in Machine Learning*, 17(2):174–303, 2024.
- Lazar Atanackovic and Emmanuel Bengio. Investigating generalization behaviours of generative flow networks. *arXiv preprint arXiv:2402.05309*, 2024.
- Luis A Barrera, Anastasia Vedenko, Jesse V Kurland, Julia M Rogers, Stephen S Gisselbrecht, Elizabeth J Rossin, Jaie Woodard, Luca Mariani, Kian Hong Kock, Sachi Inukai, et al. Survey of variation in human transcription factors reveals prevalent dna binding changes. *Science*, 351(6280):1450–1454, 2016.
- Mokhtar S. Bazaraa, John J. Jarvis, and Hanif D. Sherali. *Linear Programming and Network Flows*. Wiley-Interscience, 2004.
- Emmanuel Bengio, Moksh Jain, Maksym Korablyov, Doina Precup, and Yoshua Bengio. Flow network based generative models for non-iterative diverse candidate generation. In *NeurIPS*, 2021.
- Yoshua Bengio, Salem Lahlou, Tristan Deleu, Edward J. Hu, Mo Tiwari, and Emmanuel Bengio. GFlowNet Foundations. *JMLR*, 2023.
- Lars Buesing, Nicolas Heess, and Theophane Weber. Approximate inference in discrete distributions with monte carlo tree search and value functions. In *AISTATS*, 2020.
- Gabriele Corso, Hannes Stark, Stefanie Jegelka, Tommi Jaakkola, and Regina Barzilay. Graph neural networks. *Nature Reviews Methods Primers*, 4(1):17, 2024.
- Tiago da Silva, Eliezer Silva, Adèle Ribeiro, António Góis, Dominik Heider, Samuel Kaski, and Diego Mesquita. Human-in-the-loop causal discovery under latent confounding using ancestral GFlowNets. *arXiv preprint:2309.12032*, 2023.
- Tristan Deleu, António Góis, Chris Chinenye Emezue, Mansi Rankawat, Simon Lacoste-Julien, Stefan Bauer, and Yoshua Bengio. Bayesian structure learning with generative flow networks. In *UAI*, 2022.
- Tristan Deleu, Mizu Nishikawa-Toomey, Jithendaraa Subramanian, Nikolay Malkin, Laurent Charlin, and Yoshua Bengio. Joint Bayesian inference of graphical structure and parameters with a single generative flow network. In *NeurIPS*, 2023.
- Joseph Felsenstein. Evolutionary trees from DNA sequences: A maximum likelihood approach. *Journal of Molecular Evolution*, 1981.
- Timur Garipov, Sebastiaan De Peuter, Ge Yang, Vikas Garg, Samuel Kaski, and Tommi S. Jaakkola. Compositional sculpting of iterative generative processes. In *NeurIPS*, 2023.
- Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. In *ICML*, 2017.
- M. Gori, G. Monfardini, and F. Scarselli. A new model for learning in graph domains. In *IJCNN*, 2005.
- Caterina Graziani, Tamara Drucks, Fabian Jögl, Monica Bianchini, Franco Scarselli, and Thomas Gärtner. The expressive power of path-based graph neural networks. In *ICML*, 2024.

- William L Hamilton. *Graph representation learning*. Morgan & Claypool Publishers, 2020.
- William L. Hamilton, Rex Ying, and Jure Leskovec. Inductive representation learning on large graphs. In *NeurIPS*, 2018.
- Edward J. Hu, Moksh Jain, Eric Elmoznino, Younesse Kaddar, and et al. Amortizing intractable inference in large language models. In *ICLR*, 2023.
- Aapo Hyvärinen. Some extensions of score matching. *Computational statistics & data analysis*, 51(5):2499–2512, 2007.
- Moksh Jain, Emmanuel Bengio, Alex Hernandez-Garcia, Jarrid Rector-Brooks, Bonaventure F. P. Dossou, Chanakya Ajit Ekbote, Jie Fu, Tianyu Zhang, Michael Kilgour, Dinghuai Zhang, Lena Simine, Payel Das, and Yoshua Bengio. Biological sequence design with GFlowNets. In *ICML*, 2022.
- Moksh Jain, Sharath Chandra Raparthy, Alex Hernandez-Garcia, Jarrid Rector-Brooks, Yoshua Bengio, Santiago Miret, and Emmanuel Bengio. Multi-objective GFlowNets. In *ICML*, 2023.
- Hyosoon Jang, Minsu Kim, and Sungsoo Ahn. Learning energy decompositions for partial inference in GFlowNets. In *ICLR*, 2024.
- Marco Jiralerspong, Bilun Sun, Danilo Vucetic, Tianyu Zhang, Yoshua Bengio, Gauthier Gidel, and Nikolay Malkin. Expected flow networks in stochastic environments and two-player zero-sum games. In *ICLR*, 2023.
- Thomas H Jukes and Charles R Cantor. Evolution of protein molecules. In *Mammalian Protein Metabolism*. Elsevier, 1969.
- Minsu Kim, Taeyoung Yun, Emmanuel Bengio, Yoshua Bengio Dinghuai Zhang, Sungsoo Ahn, and Jinkyoo Park. Local search GFlowNets. In *ICLR*, 2024.
- Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *ICLR*, 2014.
- Diederik P Kingma and Ruiqi Gao. Understanding diffusion objectives as the ELBO with simple data augmentation. In *NeurIPS*, 2023.
- Diederik P Kingma, Tim Salimans, Ben Poole, and Jonathan Ho. On density estimation with diffusion models. In A. Beygelzimer, Y. Dauphin, P. Liang, and J. Wortman Vaughan (eds.), *NeurIPS*, 2021.
- Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. In *ICLR*, 2017.
- Salem et al. Lahlou. A theory of continuous generative flow networks. In *ICML*, 2023.
- Elaine Lau, Nikhil Vemgal, Doina Precup, and Emmanuel Bengio. DGFN: Double Generative Flow Networks. In *GenBio workshop @ NeurIPS*, 2023.
- Elaine Lau, Stephen Zhewen Lu, Ling Pan, Doina Precup, and Emmanuel Bengio. QGFN: Controllable Greediness with Action Values. In *NeurIPS*, 2024.
- Dianbo Liu and et al. GFlowOut: Dropout with Generative Flow Networks. In *ICML*, 2023.
- Kanika Madan, Jarrid Rector-Brooks, Maksym Korablyov, Emmanuel Bengio, Moksh Jain, Andrei Cristian Nica, Tom Bosc, Yoshua Bengio, and Nikolay Malkin. Learning gflownets from partial episodes for improved convergence and stability. In *ICML*, 2022.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in GFlowNets. In *NeurIPS*, 2022.
- Nikolay Malkin, Salem Lahlou, Tristan Deleu, Xu Ji, Edward Hu, Katie Everett, Dinghuai Zhang, and Yoshua Bengio. GFlowNets and variational inference. *ICLR*, 2023.
- Christopher Morris, Martin Ritzert, Matthias Fey, William L. Hamilton, Jan Eric Lenssen, Gaurav Rattan, and Martin Grohe. Weisfeiler and leman go neural: Higher-order graph neural networks. In *AAAI*, 2021.

- Andrei Cristian Nica, Moksh Jain, Emmanuel Bengio, Cheng-Hao Liu, Maksym Korablyov, Michael M Bronstein, and Yoshua Bengio. Evaluating generalization in gflownets for molecule design. In *Machine Learning for Drug Discovery workshop @ ICLR*, 2022.
- Ling Pan, Nikolay Malkin, Dinghuai Zhang, and Yoshua Bengio. Better training of GFlowNets with local credit and incomplete trajectories. In *ICML*, 2023a.
- Ling Pan, Dinghuai Zhang, Aaron Courville, Longbo Huang, and Yoshua Bengio. Generative augmented flow networks. In *ICLR*, 2023b.
- Ling Pan, Moksh Jain, Kanika Madan, and Yoshua Bengio. Pre-training and fine-tuning generative flow networks. In *ICLR*, 2024.
- Mohit Pandey, Gopeshh Subbaraj, and Emmanuel Bengio. GFlowNet Pretraining with Inexpensive Rewards. In *FM4Science workshop @ NeurIPS*, 2024.
- Pál András Papp and Roger Wattenhofer. A theoretical comparison of graph neural network extensions. In *ICML*, 2022.
- Jarriid Rector-Brooks, Kanika Madan, Moksh Jain, Maksym Korablyov, Cheng-Hao Liu, Sarath Chandar, Nikolay Malkin, and Yoshua Bengio. Thompson sampling for improved exploration in gflownets. In *SPiGM workshop @ ICML*, 2023.
- Lorenz Richter, Ayman Boustati, Nikolas Nüsken, Francisco J. R. Ruiz, and Ömer Deniz Akyildiz. Vargrad: A low-variance gradient estimator for variational inference. In *NeurIPS*, 2020.
- Julien Roy, Pierre-Luc Bacon, Christopher Pal, and Emmanuel Bengio. Goal-conditioned gflownets for controllable multi-objective molecular design. In *Challenges in Deployable Generative AI @ ICML*, 2023.
- Max W. Shen, Emmanuel Bengio, Ehsan Hajiramezani, Andreas Loukas, Kyunghyun Cho, and Tommaso Biancalani. Towards understanding and improving gflownet training. In *ICML*, 2023.
- Amauri H. Souza, Diego Mesquita, Samuel Kaski, and Vikas Garg. Provably expressive temporal graph networks. In *NeurIPS*, 2022.
- Balasubramaniam Srinivasan and Bruno Ribeiro. On the equivalence between positional node embeddings and structural graph representations. In *ICLR*, 2020.
- Daniil Tiapkin, Nikita Morozov, Alexey Naumov, and Dmitry P Vetrov. Generative flow networks as entropy-regularized rl. In *AISTATS*, 2024.
- Brandon Trabucco, Xinyang Geng, Aviral Kumar, and Sergey Levine. Design-bench: Benchmarks for data-driven offline model-based optimization. In *ICML*, 2022.
- Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Lio, and Yoshua Bengio. Graph attention networks. In *ICLR*, 2018.
- Nikhil Vemgal, Elaine Lau, and Doina Precup. An empirical study of the effectiveness of using a replay buffer on mode discovery in gflownets. In *SPiGM workshop @ ICML*, 2023.
- Siddarth Venkatraman, Moksh Jain, Luca Scimeca, Minsu Kim, Marcin Sendera, Mohsin Hasan, Luke Rowe, Sarthak Mittal, Pablo Lemos, Emmanuel Bengio, Alexandre Adam, Jarriid Rector-Brooks, Yoshua Bengio, Glen Berseth, and Nikolay Malkin. Amortizing intractable inference in diffusion models for vision, language, and control. In *NeurIPS*, 2024.
- Qing Wang, Dillon Ze Chen, Asiri Wijesinghe, Shouheng Li, and Muhammad Farhan. $\mathcal{N}$ -WL: A new hierarchy of expressivity for graph neural networks. In *ICLR*, 2023.
- Zhe Wang, Petar Veličković, Daniel Hennes, Nenad Tomašev, Laurel Prince, Michael Kaisers, Yoram Bachrach, Romuald Elie, Li Kevin Wenliang, Federico Piccinini, et al. Tacticalai: an ai assistant for football tactics. *Nature communications*, 15(1):1906, 2024.
- B. Weisfeiler and A. A. Lehman. A reduction of a graph to a canonical form and an algebra arising during this reduction. *Nauchno-Tekhnicheskaya Informatsia*, 2(9):12–16, 1968.

- K. Xu, W. Hu, J. Leskovec, and S. Jegelka. How powerful are graph neural networks? In *ICLR*, 2019.
- M. Zaheer, S. Kottur, S. Ravanbakhsh, B. Poczos, R. Salakhutdinov, and A. Smola. Deep sets. In *NeurIPS*, 2017.
- Bohang Zhang, Shengjie Luo, Liwei Wang, and Di He. Rethinking the expressive power of GNNs via graph biconnectivity. In *ICLR*, 2023a.
- David W Zhang, Corrado Rainone, Markus Peschl, and Roberto Bondesan. Robust scheduling with gflownets. In *ICLR*, 2023b.
- Dinghuai Zhang, Ricky Tian Qi Chen, Cheng-Hao Liu, Aaron Courville, and Yoshua Bengio. Diffusion generative flow samplers: Improving learning signals through partial trajectory optimization. In *ICLR*, 2023c.
- Dinghuai Zhang, Hanjun Dai, Nikolay Malkin, Aaron Courville, Yoshua Bengio, and Ling Pan. Let the flows tell: Solving graph combinatorial optimization problems with gflownets. In *NeurIPS*, 2023d.
- Ming Yang Zhou, Zichao Yan, Elliot Layne, Nikolay Malkin, Dinghuai Zhang, Moksh Jain, Mathieu Blanchette, and Yoshua Bengio. PhyloGFN: Phylogenetic inference with generative flow networks. In *ICLR*, 2024.
- Yiheng Zhu, Jialu Wu, Chaowen Hu, Jiahuan Yan, Chang-Yu Hsieh, Tingjun Hou, and Jian Wu. Sample-efficient multi-objective molecular optimization with gflownets. In *NeurIPS*, 2023.

相关工作

GFlowNets (GFlowNets) . 生成流网络 (GFlowNets) (Bengio 等, 2021; 2023; Lahlou, 2023) 被提出作为蒙特卡洛树搜索 (Buesing 等, 2020) 在有向无环图结构环境中的替代方案。目前, **GFlowNets** 已经在因果发现 (Deleu 等, 2022; 2023; da Silva 等, 2023)、分子发现 (Bengio 等, 2021; Nica 等, 2022; Atanackovic 与 Bengio, 2024; Pandey 等, 2204)、文本填充 (Hu 等, 2023; Venkatraman 等, 2024)、系统发生推断 (Zhou 等, 2024) 和组合优化 (Zhang 等, 2023b;c) 等难题上取得了显著的成功。同样, 大量的努力被投入到开发更易于最小化的学习目标, 这些目标具有改进的信用分配 (Bengio 等, 2023; Malkin 等, 2022; Madan 等, 2022; Pan 等, 2023b; Tiapkin 等, 2024) 以及更好的探索策略 (Pan 等, 2023a; Vemgal 等, 2023; Rector-Brooks 等, 2023; Lau 等, 2023; 2024; Jang 等, 2024; Kim 等, 2024)。在我们的工作中, 我们考虑了轨迹平衡,

$$\mathcal{L}_{\text{TB}}(p_F, p_B, F) = \mathbb{E}_{\tau} \left[\left(\log \frac{F(s_o)p_F(\tau)}{p_B(\tau|x)R(x)} \right)^2 \right], \quad (13)$$

子轨迹平衡 (τ_i 表示 τ 的第 i 个状态, $\# \tau+1$ 表示 τ), 的状态数量)

$$\mathcal{L}_{\text{SubTB}}(p_F, p_B, F) = \mathbb{E}_{\tau} \left[\sum_{1 \leq i < j \leq \# \tau+1} \frac{\lambda^{j-i}}{\sum_{1 \leq s < t \leq \# \tau+1} \lambda^{t-s}} \left(\log \frac{F(\tau_i)p_F(\tau_{i:j}|\tau_i)}{p_B(\tau_{i:j}|\tau_j)F(\tau_j)} \right)^2 \right], \quad (14)$$

这些是最受欢迎的用于训练 GFlowNets 的损失函数。然而, 识别失败模式和合理评估 GFlowNets 准确性的方法在文献中受到的关注较少, Shen 等人 (2023 年) 的工作与我们的研究最为相关。

GNN 的表达能能力。图神经网络 (GNNs) 是处理图结构数据表示和预测学习的领先方法 (Kipf & Welling, 2017; Velićković et al., 2018; Hamilton et al., 2018; Xu et al., 2019; Corso et al., 2024)。尽管它们表现出色, 揭示 GNNs 的局限性仍然是一个活跃的研究方向。值得注意的是, 大多数研究集中在设计额外的图结构特征以增强 GNN 的表达能能力上 (Srinivasan & Ribeiro, 2020; Souza et al., 2022; Zhang et al., 2023a; Wang et al., 2023; Graziani et al., 2024)。通常, 这些特征会增加 GNN 评估的非可忽略成本, 并且与所提出的 LA-GFlowNets 类似, 存在计算复杂度与表达能能力之间的权衡 (Morris et al., 2021)。关于 GNN 扩展在表达能能力方面的比较, 读者可参考 Papp & Wattenhofer (2_2022) 的工作。

消息传递 GNNs 与 1-WL 测试 在这里, 我们将一个图表示为一个元组 $G = (V, E)$, 其中 $V = \{1, 2, \dots, n\}$ 是节点集合, $E \subseteq V \times V$ 是边集合。更具体地说, 我们考虑具有属性的图——即每个节点 $v \in V$ 都有关联的特征 $x_v \in \mathbb{R}^d$ 。此外, 我们将图中节点 v 的邻居集合表示为 $\mathcal{N}_v = \{u : (u, v) \in E\}$ 。

1-Weisfeiler Leman (WL) 测试。Weisfeiler-Lehman 同构测试 (Weisfeiler & Lehman, 1968) 为有属性输入图中的所有节点分配颜色 G 通过应用以下迭代过程: 初始化: 所有节点的颜色 G 使用初始节点特征进行初始化: $\forall v \in V, c^0(v) = x_v$ 。如果节点特征不可用, 则所有节点接收相同的颜色; 细化: 在步骤 ℓ , 所有节点的颜色使用哈希 (单射) 函数进行细化: 对于所有 $v \in V$, 我们应用 $c^{\ell+1}(v) = \text{HASH}(c^\ell(v), \{\{c^\ell(u) : (u, v) \in E\}\})$; 终止: 该测试对两个图并行执行, 并在相应颜色的多重集开始发散时停止, 返回非同构。如果算法运行到不同颜色的数量不再增加, 则测试被认为不确定。

消息传递 GNNs。大多数流行的 GNN 可以使用消息传递范式 (Gilmer 等人, 2017) 来描述。在这个框架内, GNN 将每个节点的嵌入初始化为其原始特征, 即, $h_v^{(0)} = x_v$ 对于所有节点 $v \in V$ 。然后, 在每一层 ℓ , 每个节点 v 从其邻居处收集消息 $u \in \mathcal{N}_v$, 将其编译成一个聚合消息 $m_v^{(\ell)}$:

$$m_v^{(\ell)} = \text{AGGREGATE}_\ell \left(\{h_u^{(\ell-1)} : u \in \mathcal{N}_v\} \right),$$

其中 AGGREGATE_ℓ 是多重集上的任意函数，即它是顺序不变的。随后，每个节点使用所谓的更新函数（例如，前馈神经网络）根据聚合消息刷新其嵌入：

$$h_v^{(\ell)} = \text{UPDATE}_\ell \left(m_v^{(\ell)}, h_v^{(\ell-1)} \right).$$

当聚合函数和更新函数均不丢失信息（即它们是单射的）时，消息传递过程与 1-WL 测试的细化步骤相吻合（徐等，2019）。在这种情况下，GNN 达到了 1-WL 同构测试的能力。相反，1-WL 作为消息传递 GNN 表达能力的上限。

前瞻性和 LED-GFlowNets

如前所述，前瞻性（FL-）和学习能量分解（LED-）GFlowNets 均基于通过重新参数化流函数来增强信用分配的原则。F 将流函数表示为一个基础潜在函数（无论是手工设计还是学习得到）的对数残差 ϕ ，i.e., $\log F(s, s') = \log \phi(s, s') + \log \tilde{F}(s, s')$ 并且 $\tilde{F}(s, s') = \tilde{F}(s)p_F(s'|s)$ 在通常的基于策略的参数化下。从这一新颖的角度来看，DB 损失变为

$$\mathcal{L}_{DB}(p_F, p_B, F) = \mathbb{E}_\tau \left[\frac{1}{\#\tau} \sum_{(s, s') \in \tau} \left(\phi(s, s') + \log \frac{\tilde{F}(s)p_F(s'|s)}{\tilde{F}(s')p_B(s|s')} \right)^2 \right], \quad (15)$$

在约束条件下 $\sum_{(s, s') \in \tau} \phi(s, s') = \log R(x)$ ，其中 x 是轨迹 τ 中唯一的终止状态。回忆一下，对于 FL-GFlowNets， $\phi(s, s') = \xi(s') - \xi(s)$ 对于一个手工设计的能量函数 ξ ，使得 $\xi(s_o) = 0$ 和 $\xi(x) = \log R(x)$ （Pan 等人，2023a，假设 1）。对于 LED-GFlowNets， $\phi(s, s')$ 被参数化为一个神经网络，该网络以向量表示的 s 和 s' 的连接作为输入。然后通过最小化 ϕ 来学习参数

$$\mathcal{L}_{LS}(\tau) = \mathbb{E}_{(m_{s, s'})_{(s, s') \in \tau} \sim \text{Bernoulli}(1-\gamma)} \left[\left(\frac{1}{\#\tau} \xi(x) - \frac{1}{C} \sum_{(s, s') \in \tau} m_{s, s'} \phi_\theta(s, s') \right)^2 \right], \quad (16)$$

其中 $\{m_{s, s'}\}_{(s, s') \in \tau}$ 是随机失活掩码， $C = \sum_{(s, s') \in \tau} m_{s, s'}$ 是未被掩盖的转换数量。在训练过程中，我们交替进行潜在函数 ϕ 和 (p_F, p_B, F) 的梯度更新，直到满足选定的停止条件（例如，最大训练轮次数）。

附录 D 证明

本节包含我们理论结果的自包含和严格的证明。

附录 D.1 定理 1 的证明

修改后的流网络的终端状态将有两种类型的节点，其流量为 E

$\frac{E}{g^h} + \delta_i$ ，其中包含 $\delta_i = 0$ 和 $\sum_{i=1}^{g^{h-1}} \delta_i = \delta$ 。我们将这些概率归一化，以获得每个终端状态的个体概率，这决定了每个样本的密度。由此，我们可以计算 $\tilde{p}_T$

与 π 之间的总变差距离。

$$\begin{aligned} \|\tilde{p}_T - \pi\|_{TV} &= \frac{1}{2} \sum_{x \in \mathcal{X}} |\tilde{p}_T(x) - \pi(x)| \\ &= \frac{1}{2} \left[(g^h - g^{h-1}) \left| \frac{F}{g^h} \frac{1}{F + \delta} - \frac{1}{g^h} \right| + \sum_{i=1}^{g^{h-1}} \left| \frac{F + g^h \delta_i}{g^h} \frac{1}{F + \delta} - \frac{1}{g^h} \right| \right] \\ &= \frac{1}{2} \left[\frac{g^h \delta - g^{h-1} \delta + \sum_{i=1}^{g^{h-1}} |g^h \delta_i - \delta|}{g^h (F + \delta)} \right]. \end{aligned}$$

我们可以对结果的绝对值及求和中的每一项给出下界，从而 $\sum_{i=1}^{g^{h-1}} (g^h \delta_i - \delta) = g^h \delta - g^{h-1} \delta$, taking 得到 $\sum_{i=1}^{g^{h-1}} |g^h \delta_i - \delta| \geq \sum_{i=1}^{g^{h-1}} (g^h \delta_i - \delta)$.

因此我们得到了下界

$$\frac{1}{2} \left[\frac{g^h \delta - g^{h-1} \delta + g^h \delta - g^{h-1} \delta}{g^h(F + \delta)} \right] \leq \frac{1}{2} \left[\frac{g^h \delta - g^{h-1} \delta + \sum_{i=1}^{g^{h-1}} |g^h \delta_i - \delta|}{g^h(F + \delta)} \right]$$

$$\left(1 - \frac{1}{g}\right) \frac{\delta}{F + \delta} \leq \|\tilde{p}_T - \pi\|_{TV}.$$

当所有终端状态中的误差项具有相同的值时，可以达到这个下界 $\delta_i = \frac{\delta}{g^h}$

为了设定上界 $|g^h \delta_i - \delta|$ ，我们应用三角不等式，得到 $|g^h \delta_i - \delta| \leq g^h \delta_i + \delta$ 和 $\sum_{i=1}^{g^{h-1}} |g^h \delta_i - \delta| \leq g^h \delta + g^{h-1} \delta$ ，从而得到上界

$$\|\tilde{p}_T - \pi\|_{TV} \leq \frac{1}{2} \left[\frac{g^h \delta - g^{h-1} \delta + g^h \delta + g^{h-1} \delta}{g^h(F + \delta)} \right]$$

$$\leq \frac{\delta}{F + \delta}.$$

为了获得更紧的界限，我们将求和分解 $\sum_{i=1}^{g^{h-1}} |g^h \delta_i - \delta|$ by partitioning the sum into the first I terms $S_A = g^h \sum_{i=1}^I |\delta_i - \frac{\delta}{g^h}|$ with $\delta_i < \frac{\delta}{g^h}$ and subsequent $g^{h-1} - I$ terms $S_B = g^h \sum_{j=I+1}^{g^{h-1}} |\delta_j - \frac{\delta}{g^h}|$ with $\delta_j \geq \frac{\delta}{g^h}$. By construction, we know that $S_A + g^h \sum_{i=1}^I \delta_i + g^h \sum_{j=I+1}^{g^{h-1}} \delta_j - S_B = g^{h-1} \delta$, simplifying to $S_B - S_A = \delta(g^h - g^{h-1})$. We rewrite $S_A + S_B = S_B - S_A + 2S_A = \delta(g^h - g^{h-1}) + 2S_A$ ，并利用三角不等式在 S_A 上，我们得到上界 $\sum_{i=1}^{g^{h-1}} |g^h \delta_i - \delta| = S_A + S_B \leq g^h \delta - g^{h-1} \delta + 2I\delta$ 。设定 $I = g^{h-1} - 1$ （它在不违反对 δ_i 的约束的情况下可以取到的最大值），则简化为 $S_A + S_B \leq g^h \delta + g^{h-1} \delta - 2\delta$

$$\|\tilde{p}_T - \pi\|_{TV} \leq \frac{1}{2} \left[\frac{g^h \delta - g^{h-1} \delta + \sum_{i=1}^{g^{h-1}} |g^h \delta_i - \delta|}{g^h(F + \delta)} \right]$$

$$\leq \frac{1}{2} \left[\frac{g^h \delta - g^{h-1} \delta + g^h \delta + g^{h-1} \delta - 2\delta}{g^h(F + \delta)} \right]$$

$$\leq \left[\frac{g^h \delta - \delta}{g^h(F + \delta)} \right]$$

$$\leq \left(1 - \frac{1}{g}\right) \frac{\delta}{F + \delta}.$$

附录 D.2 定理 1 的证明 为了证明这一结果，我们需要关于函数 $f(x): x \in \mathbb{R}^n \mapsto \sum_{i=1}^n |x_i - a_i|$ 对于正常数 a_i 的一些事实。

引理 1 (凸性)。 设 $\Delta_{n+1} = \{x \in \mathbb{R}^n: x_i \geq 0 \sum_{i=1}^n x_i = 1\}$ 和 $a \in \mathbb{R}^n$. 那么， f 由 $\Delta_{n+1} \rightarrow \mathbb{R}$ 下列定义 $f(x) = \sum_{i=1}^n |x_i - a_i|$ 是凸的。

证明。这从 $f(\alpha x + (1-\alpha)y) = \sum_{i=1}^n$ 得出。对于

$$| \alpha x_i - \alpha a_i + (1-\alpha)y_i - (1-\alpha)a_i | \leq \alpha |x_i - a_i| + (1-\alpha) |y_i - a_i| = \alpha f(x) + (1-\alpha)f(y) \quad \alpha \in [0, 1] \text{ 和 } x, y \in \Delta_{n+1}. \quad \square$$

引理 2 (边缘处的最大值)。 设 $e_i \in \mathbb{R}^n$ 满足 $e_{ij} = 0$ 对于 $j \neq i$ 和 $e_{ii} = 1$ 。那么，来自引理 1 的函数 f 在其最大值处达到 $\arg \max_{1 \leq i \leq n} f(e_i)$ 。

证明。我们将证明，对于每个 $x \in \Delta_{n+1}$ ，存在一个 i 使得 $f(e_i) \geq f(x)$ 。特别是， f 在其中一个 e_i 处达到最大值。为此，请注意

$$f(x) = f\left(\sum_{i=1}^n x_i e_i\right) \leq \sum_{i=1}^n x_i f(e_i) \leq \max_{1 \leq i \leq n} f(e_i) \quad (17)$$

由于 f 的凸性。因此， f 被上界为 $\max_{1 \leq i \leq n} f(e_i)$ 。相反，存在一个 e_i 使得这个上界被达到。因此， $\arg \max_x f(x) \supseteq \arg \max_{1 \leq i \leq n} f(e_i)$ 。□

引理 3 (最小性)。 设 f 是引理 1 中的函数，并假设 $a \geq 0$ 和 $\sum_{i=1}^n a_i \leq 1$ 。那么， f 由 $1 - \sum_{i=1}^n a_i$ 最小化。

证明。任意选择一个 $j \in \{1, \dots, n\}$ 。因为 $x_j = 1 - \sum_{i=1, i \neq j}^n x_i$,

$$\sum_{i=1}^n |x_i - a_i| = \sum_{i=1, i \neq j}^n |a_i - x_i| + \left| a_j - 1 + \sum_{i=1, i \neq j}^n x_i \right| \geq \left| \sum_{i=1}^n a_i - 1 \right|. \quad (18)$$

相应地，方程 18 中的下界在 $x_i = a_i$ 对于 $i \neq j$ 和 $x_j = 1 - \sum_{i=1, i \neq j}^n a_i \geq 0$ 时达到。这确保了 f 由 $1 - \sum_{i=1}^n a_i$ 最小化。□

用文字表述，引理 1 和引理 2 确保具有有限支撑的概率分布之间的 TV 距离是凸的，并在狄拉克 δ 函数处达到最大值。

定理 1 的证明。初始时，设 δ_x 为额外流量到达 $x \in \mathcal{X}$ 的数量，并定义 $\beta_x = \delta_x / \delta$ 。则，

$$\|p_T - \tilde{\pi}\|_{TV} = \frac{1}{2} \sum_{x \in \mathcal{X}} |p_T(x) - \pi(x)| = \frac{1}{2} \sum_{x \in \mathcal{D}_{s^*}} |p_T(x) - \pi(x)| + \frac{1}{2} \sum_{x \in \mathcal{D}_{s^*}^c} |p_T(x) - \pi(x)|. \quad (19)$$

Since $p_T(x) = \tilde{\pi}(x) + \delta_x / (F + \delta)$ 对 $x \in \mathcal{D}_{s^*}$ 和 $p_T(x) = \tilde{\pi}(x) / (F + \delta)$ 对 $x \in \mathcal{D}_{s^*}^c$,

$$\sum_{x \in \mathcal{D}_{s^*}^c} |p_T(x) - \pi(x)| = \frac{\delta}{F + \delta} \sum_{x \in \mathcal{D}_{s^*}^c} \pi(x). \quad (20)$$

另一方面，

$$\sum_{x \in \mathcal{D}_{s^*}} |p_T(x) - \pi(x)| = \sum_{x \in \mathcal{D}_{s^*}} \left| \frac{\tilde{\pi}(x) + \delta_x}{F + \delta} - \frac{\tilde{\pi}(x)}{F} \right| = \frac{\delta}{F + \delta} \sum_{x \in \mathcal{D}_{s^*}} \left| \beta_x - \frac{\tilde{\pi}(x)}{F} \right|. \quad (21)$$

By Lemma 2, the function $f: \beta \mapsto \sum_{x \in \mathcal{D}_{s^*}} |\beta_x - \pi(x)|$ is maximized at

$$\begin{aligned} \max_{y \in \mathcal{D}_{s^*}} f(e_y) &= \max_{y \in \mathcal{D}_{s^*}} \sum_{x \in \mathcal{D}_{s^*}} |e_{xy} - \pi(x)| \\ &= \max_{y \in \mathcal{D}_{s^*}} \left(\sum_{x \in \mathcal{D}_{s^*}, x \neq y} \pi(x) \right) + (1 - \pi(y)) \\ &= 1 + \sum_{x \in \mathcal{D}_{s^*}} \pi(x) - 2 \min_{y \in \mathcal{D}_{s^*}} \pi(y). \end{aligned} \quad (22)$$

类似地，引理 3 确保

$$\min_{\beta \in \Delta_{\#\mathcal{D}_{s^*}+1}} f(\beta) = 1 - \sum_{x \in \mathcal{D}_{s^*}} \pi(x). \quad (23)$$

因此，由于 $\sum_{x \in \mathcal{D}_{s^*}} \pi(x) = 1 - \sum_{x \in \mathcal{D}_{s^*}^c} \pi(x)$,

$$\frac{\delta}{F + \delta} \left(1 - \sum_{x \in \mathcal{D}_{s^*}} \pi(x) \right) \leq \|p_T - \pi\|_{TV} \leq \frac{\delta}{F + \delta} \left(1 - \min_{y \in \mathcal{D}_{s^*}} \pi(y) \right). \quad (24)$$

□

D.3 定理 2 的证明

作为证明定理 2 的中间步骤，我们首先给出引理 4 和引理 5。

引理 4. 设 $G = (V, E)$ 和 $G' = (V', E')$ 是两个大小不超过 n 的不同构树。设 ϕ 是一个至少有 $2n - 1$ 层的 1-WL GNN 的节点嵌入映射。那么，对于所有的 $v \in V$ 和 $v' \in V'$ ，均有 $\phi_v \neq \phi_{v'}$ 。

证明。回忆 1-WL GNN 可以区分任何一对不同构的树。令 $\mathcal{T}_n$ 和 $\mathcal{T}'_n$ 分别表示在 G 和 G' 中每个节点经过 n 层后的计算树 (CT) 集合。类似地，令 $\mathcal{T}_{2n-1}$ 和 $\mathcal{T}'_{2n-1}$ 表示经过 $2n+1$ 层后的 CT 集合。由于两个图都是不同构的，1-WL 已经在 n 步内收敛——一棵树的最大直径是 $n - 1$ 。不失一般性， $\mathcal{T}_n - \mathcal{T}'_n \neq \emptyset$ ，即在 $\mathcal{T}_n$ 中至少存在一个 CT 与 $\mathcal{T}'_n$ 中的任何树都不同构。同样地，对于 $2n - 1$ 层也成立，即 $\mathcal{T}_{2n-1} - \mathcal{T}'_{2n-1} \neq \emptyset$ 。注意到一个 CT $T_n \in \mathcal{T}_n - \mathcal{T}'_n$ 也是任何 $T_{2n-1} \in \mathcal{T}_{2n-1}$ 的子树。因为 $T_n \notin \mathcal{T}'_n$ ， T_n 不是任何 CT 在 $\mathcal{T}'_{2n-1}$ 中的子树——否则它也会出现在 $\mathcal{T}'_n$ 中。换句话说， $\mathcal{T}_{2n-1} \cap \mathcal{T}'_{2n-1} = \emptyset$ ，这直接支持了我们的论点。

引理 5. 设 $G = (V, E)$ 和 $G' = (V', E')$ 是大小不超过 n ，i.e., $|V|$ 和 $|V'| \leq n$ 的任意两棵树。另设 $I = (U, \emptyset)$ 和 $I' = (U', \emptyset)$ 是由孤立节点组成的图，而 ϕ 是一个至少有 $2n - 1$ 层的 1-WL GNN 的节点嵌入映射。如果对于任何 $(v, u) \in V \times U$ 和 $(v', u') \in V' \times U'$ 都有 $\{\phi_v, \phi_u\} = \{\phi_{v'}, \phi_{u'}\}$ ，那么树 $(V \cup \{u\}, E \cup \{(v, u)\})$ 和 $(V' \cup \{u'\}, E' \cup \{(v', u')\})$ 是同构的。

证明。若 $\{\phi_v, \phi_u\} = \{\phi_{v'}, \phi_{u'}\}$ ，则要么有 i) $\phi_v = \phi_{v'}$ 和 $\phi_u = \phi_{u'}$ ，要么有 ii) $\phi_v = \phi_{u'}$ 和 $\phi_{v'} = \phi_u$ 。在第一种情况下，我们可以应用引理 4 得出结论 $G \cong G'$ （关联双射 g_1 ）。由于 $\phi_u = \phi_{u'}$ ，我们知道 $x_u = x_{u'}$ ，并且相应的单点图显然是同构的（关联双射 g_2 ）。最后，我们可以通过构建双射 g 来匹配合并后的图的顶点，方法是当 $g(v) = g_1(v)$ 时令 $v \in V$ 和 $g(u) = g_2(u) = u'$ 。对于第二种情况，引理 4 表明 G 和 G' 是单点图，具有 $x_u = x_{v'}$ 和 $x_v = x_{u'}$ 。结果是一个完全不连通的图，除了连接两个图中特征相同的节点的边。□

凭借之前的引理，定理 2 在假设 GNN 深度 $2n - 1$ 的情况下是显而易见的。根据引理 5，我们知道任意两个节点的动作嵌入的交集为空。同样地，只有当两个动作从同一状态出发并到达同一状态时，它们的嵌入才相同。因此，SG 中的所有边都具有不同的嵌入。回忆一下，GNN 嵌入被传递给多层感知机层，这些层在宽度足够的情况下是通用逼近器。因此，一个 1-WL GNN 后跟 MLP 可以近似任何策略前向函数 p_F 。同样的结论也适用于反向策略函数 p_B 。我们可以使用相同的组合来获得状态嵌入，这允许近似任何节点流函数 F 。因此，我们可以选择满足 DB 条件的三元组 (p_F, p_B, F) 。

附录 D.4 定理 3 的证明

假设存在一个从 π 采样的 1-WL GFlowNet。由于 $\mathcal{G}$ 是树结构，到达 $T(s_1) \cup T(s_2)$ 的质量必须通过 s ——即，从 s_0 到某个 $x \in T(s_1) \cup T(s_2)$ 的所有路径都会经过 s 。此外，不存在从 s' 到 $T(s'')$ 中任何终端的有向路径，反之亦然，否则 $\mathcal{G}$ 的骨架（即无向结构）将包含一个循环。那么， $F(s, s') = \sum_{x \in T(s')} R(x)$ 和 $F(s, s') = \sum_{x \in T(s')} R(x)$ ，这意味着 $F(s, s') \neq F(s, s'')$ 。

附录 D.5 定理 4 的证明

由于子节点嵌入被作为额外输入提供给 LA-GFlowNets，直接得出 LA-GFlowNets 至少与 1-WL GFlowNets 一样具有表达能力。接下来需要证明相反的情况不成立。在图 5 中，我们提供了一个构造，其中 1-WL GFlowNets 失败，而 LA-GFlowNets 不会失败。

D.6 定理 5 的证明 首先，设

$S = \{x_1, \dots, x_B\} \subseteq \mathcal{X}$ 和

$$e(S) = \frac{1}{2} \sum_{x \in S} \left| \frac{p_T(x)}{p_T(S)} - \frac{R(x)}{R(S)} \right|, \quad (25)$$

$$p_T(S) = \sum_{x \in S} p_T(x)$$

并定义 $\pi(x) = R(x)/R(\mathcal{X})$ 为限制到 S 的 p_T 和 R 之间的 TV 距离。

为了简洁起见，我们写作 $\tilde{p}_T^{(S)}(x) = p_T(x)/p_T(S)$ 和 $\tilde{\pi}^{(S)}(x) = R(x)/R(S)$ 。我们也记 $\pi(x) = R(x)/R(\mathcal{X})$ 为在 $\mathcal{X}$ 中的归一化奖励。类似地，我们定义 $e(p) = \mathbb{E}_{S \sim p}[e(S)]$ 。然后，我们首先证明当 $\text{TV}(p_T, \pi) = 0$ 时， $e(p) = 0$ 成立。为此，请注意 $\text{TV}(p_T, \pi) = 0$ 意味着对于每个 x 都有 $p_T(x) = \pi(x)$ ，从而得出 $p_T(S) = \pi(S) \forall S \subseteq \mathcal{X}$ 。因此，

$$e(p) := \mathbb{E}_{S \sim p} \left[\frac{1}{2} \sum_{x \in S} |\tilde{p}_T^{(S)}(x) - \tilde{\pi}^{(S)}(x)| \right] = 0. \quad (26)$$

另一方面，假设 $e(p) = 0$ 。回忆一下， p 是在 $\{S \subseteq \mathcal{X} : |S| = B\}$ 上的全支持分布，并且 $B \geq 2$ 。特别是， $e(p)$ 确保了

$$e(S, \theta) := \frac{1}{2} \sum_{x \in S} \left| \frac{p_T(x)}{p_T(S)} - \frac{\pi(x)}{\pi(S)} \right| = 0. \quad (27)$$

因此，对于每个 S 和 $x \in S$ ，都有 $p_T(S)\pi(x) = \pi(S)p_T(x)$ 。然后写作 $S = S' \cup \{x\}$ 并得出对于每个 S' 和 $x \notin S'$ 都有 $p_T(S')\pi(x) = \pi(S')p_T(x)$ 。因此，通过将此等式的两边在 $x' \notin S'$ 上求和，我们注意到

$$p_T(S')(1 - \pi(S')) = \pi(S')(1 - p_T(S')), \quad (28)$$

i.e., $p_T(S') = \pi(S')$ 。因此，通过迭代这一过程，我们可以得出结论：对于所有 $p_T(x) = \pi(x)$ 和 S' ，均有 $x \notin S'$ 成立。由于 S' 和 x 是任意选取的，故对于每一个 $p_T(x) = \pi(x)$ ，均有 $x \in \mathcal{X}$ 成立。进而，我们得到 $\text{TV}(p_T, \pi) = 0$ 。这确保了在表征 GFlowNet 分布正确性方面， $e(p)$ 与 $\text{TV}(p_T, \pi)$ 之间的等价性。

附录 D.7 推论 1 的证明

回顾方程 25 中定义的 $e(S)$ 。我们开始证明 $P_S(\cdot; \beta)$ 确实是一个概率分布。显然，对于每一个 $P_T(S; \beta) \geq 0$ ，均有 $S \subseteq \mathcal{X}$ 成立。另一方面，

$$\begin{aligned} \sum_{S \subseteq \mathcal{X}} P_S(S; \beta) &= \sum_{S \subseteq \mathcal{X}, \#S = \beta} \binom{n-1}{\beta-1}^{-1} \underbrace{\sum_{x \in S} p_T(x)}_{p_T(S)} \\ &= \sum_{S \subseteq \mathcal{X}, \#S = \beta} \binom{n-1}{\beta-1}^{-1} p_T(S) \\ &= \sum_{x \in \mathcal{X}} \binom{n-1}{\beta-1}^{-1} \binom{n-1}{\beta-1} p_T(x) = 1, \end{aligned} \quad (29)$$

由于每个 $p_T(x)$ 恰好在上述求和中出现了 $\binom{n-1}{\beta-1}$ 次。因此， $P_S(\cdot; \beta)$ 是一个概率分布。至于其余部分，令 $\hat{e} = \mathbb{E}_{S \sim p}[e(S)]$ ， $\# \mathcal{X} = n$ ， $\mathcal{P}_\beta = \{S \subseteq \mathcal{X} : \#S = \beta\}$ ，以及 $\Delta = \frac{n}{2\beta} \max_{S \in \mathcal{P}_\beta} |p_T(S) - \pi(S)|$ 。我们将首先证明

$$\text{TV}(p_T, \pi) - \hat{e} \leq \Delta. \quad (30)$$

接下来，我们将验证 $\text{TV}(p_T, \pi) - \hat{e} \geq -\Delta$ 。这些不等式将共同推导出推论 1。在这种情况下，请注意存在 $\binom{n-1}{\beta-1}$ 个包含 $x \in \mathcal{X}$ 的 $\mathcal{X}$ 的子集，其中元素数量为 β 。因此，

$$\text{TV}(p_T, \pi) = \frac{1}{2} \sum_{S \in \mathcal{P}_\beta} \sum_{x \in S} \binom{n-1}{\beta-1}^{-1} |p_T(x) - \pi(x)|. \quad (31)$$

For conciseness, define $d_{TV} = \text{TV}(p_T, \pi)$. Hence,

$$\begin{aligned}
 d_{TV} - \hat{e} &= \frac{1}{2} \sum_{S \in \mathcal{P}_\beta} \sum_{x \in S} \binom{n-1}{\beta-1}^{-1} |p_T(x) - \pi(x)| - P_S(S) \left| \frac{p_T(x)}{p_T(S)} - \frac{\pi(x)}{\pi(S)} \right| \\
 &\leq \frac{1}{2} \sum_{S \in \mathcal{P}_\beta} \sum_{x \in S} \binom{n-1}{\beta-1}^{-1} \left(\left| p_T(x) - \frac{p_T(S)}{\pi(S)} \pi(x) \right| + \pi(x) \left| 1 - \frac{p_T(S)}{\pi(S)} \right| \right) \\
 &\quad - \frac{P_S(S)}{p_T(S)} \left| p_T(x) - \frac{\pi(S)}{p_T(S)} \pi(x) \right| \\
 &= \frac{1}{2} \sum_{S \in \mathcal{P}_\beta} \sum_{x \in S} \binom{n-1}{\beta-1}^{-1} \pi(x) \left| 1 - \frac{p_T(S)}{\pi(S)} \right| \\
 &= \frac{1}{2} \binom{n-1}{\beta-1}^{-1} \sum_{S \in \mathcal{P}_\beta} |p_T(S) - \pi(S)| \\
 &\leq \frac{1}{2} \binom{n-1}{\beta-1}^{-1} \binom{n}{\beta} \max_{S \in \mathcal{P}_\beta} |p_T(S) - \pi(S)| = \frac{n}{2\beta} \Delta
 \end{aligned} \tag{32}$$

由于 $P_S(S)/p_T(S) = \binom{n-1}{\beta-1}^{-1}$, 并且 $\mathcal{X}$ 中有 $\binom{n}{\beta}$ 个大小为 β 的子集。对于反向不等式, 注意到

$$\begin{aligned}
 d_{TV} - \hat{e} &= \frac{1}{2} \sum_{S \in \mathcal{P}_\beta} \sum_{x \in S} \binom{n-1}{\beta-1}^{-1} |p_T(x) - \pi(x)| - P_S(S) \left| \frac{p_T(x)}{p_T(S)} - \frac{\pi(x)}{\pi(S)} \right| \\
 &\geq \frac{1}{2} \sum_{S \in \mathcal{P}_\beta} \sum_{x \in S} \binom{n-1}{\beta-1}^{-1} |p_T(x) - \pi(x)| \\
 &\quad - P_S(S) \left(\left| \frac{p_T(x)}{p_T(S)} - \frac{\pi(x)}{p_T(S)} \right| + \left| \frac{\pi(x)}{p_T(S)} - \frac{\pi(x)}{\pi(S)} \right| \right) \\
 &= -\frac{1}{2} \sum_{S \in \mathcal{P}_\beta} \binom{n-1}{\beta-1}^{-1} p_T(S) \sum_{x \in S} \pi(x) \left| \frac{1}{p_T(S)} - \frac{1}{\pi(S)} \right| \\
 &= -\frac{1}{2} \binom{n-1}{\beta-1}^{-1} \sum_{S \in \mathcal{P}_\beta} |p_T(S) - \pi(S)| \geq -\frac{n}{2\beta} \max_{S \in \mathcal{P}_\beta} |p_T(S) - \pi(S)|.
 \end{aligned} \tag{33}$$

D.8 推论 2 的证明

再次回顾方程 25 中 $e(S)$ 的定义。我们现在提供一个自包含的推论 2 的证明, 该证明基于推论 1 和 Hoeffding 不等式 Alquier (2024)。首先, 设 $\hat{e} = \mathbb{E}_{S \sim p}[e(S)]$ 和 $e_i = e(S_i)$ 。由于 $\hat{e} - e_i \in [-1, 1]$, Hoeffding 不等式给出

$$\mathbb{E} \left[\exp \left\{ \lambda \left(\hat{e} - \frac{1}{m} \sum_{1 \leq i \leq m} e_i \right) \right\} \right] \leq \exp \left\{ \frac{\lambda^2}{2m} \right\}. \tag{34}$$

然后, Chernoff 界意味着

$$\mathbb{P}_{S_1, \dots, S_m} \left[\hat{e} \geq \frac{1}{m} \sum_{1 \leq i \leq m} e_i + s \right] \leq \mathbb{E} \left[\exp \left\{ \lambda \left(\hat{e} - \frac{1}{m} \sum_{1 \leq i \leq m} e_i \right) \right\} \right] e^{-\lambda s} \leq \exp \left\{ \frac{\lambda^2}{2m} - \lambda s \right\}$$

根据方程 34。这个上界在 $\lambda = sm$ 时最小化。在这种情况下, $\lambda^2/2m - \lambda s = -s^2 m/2$ 。通过令 $s = -2 \log \delta / m$, 我们验证到

$$\mathbb{P}_{S_1, \dots, S_m} \left[\hat{e} \geq \frac{1}{m} \sum_{1 \leq i \leq m} e_i + \sqrt{\frac{2 \log \frac{1}{\delta}}{m}} \right] \leq \delta. \tag{35}$$

然后，推论 1 和前面不等式的补集意味着

$$\mathbb{P}_{S_1, \dots, S_m} \left[\text{TV}(p_T, \pi) \leq \frac{1}{m} \sum_{1 \leq i \leq m} e_i + \max_{S \subseteq \mathcal{X}, |S|=B} |p_T(S) - \pi(S)| + \sqrt{\frac{2 \log \frac{1}{\delta}}{m}} \right] \geq 1 - \delta. \quad (36)$$

D.9 命题 1 的证明 如附录 C 所述，FL-和 LED-GFlowNets 的学习目标全局最小值满足 $\sum_{(s, s') \in \tau} \phi(s, s') = -\log R(x)$ 对于每条轨迹 τ 。由于 $\mathcal{L}_{\text{LED}}(s, s') = 0$,

$\tilde{F}(s) \exp\{\phi_\theta(s, s')\} p_F(s, s') = p_B(s', s) \sim F(s')$ 对于每条在 x 处结束的轨迹。因此，对于每条轨迹 $\tau \rightsquigarrow x$,

$$\begin{aligned} p_F(\tau) &= p_B(\tau|x) \frac{\tilde{F}(x)}{\tilde{F}(s_o)} \prod_{(s, s') \in \tau} \exp\{-\phi(s, s')\} \\ &= p_B(\tau|x) \frac{\tilde{F}(x)}{\tilde{F}(s_o)} \exp\left\{-\sum_{(s, s') \in \tau} \phi(s, s')\right\} \\ &= p_B(\tau|x) \frac{\tilde{F}(x)}{\tilde{F}(s_o)} R(x). \end{aligned}$$

从而，

$$p_T(x) = \sum_{\tau \rightsquigarrow x} p_F(\tau) = \sum_{\tau \rightsquigarrow x} \frac{\tilde{F}(x) R(x)}{\tilde{F}(s_o)} p_B(\tau|x) \propto \tilde{F}(x) R(x) \sum_{\tau \rightsquigarrow x} p_B(\tau|x) = \tilde{F}(x) R(x), \quad (37)$$

确保终端不受限制的 FL-和 LED-GFlowNets 所学习的边缘分布不一定与 GFlowNet 的目标分布相匹配。

E 实验细节

我们在下文进一步详细说明了各部分的实验设置。实验在配备 A100 GPU 的集群上运行，每次运行使用一个 GPU。我们在附录 E.1 和 E.2 中分别提供了对现有实证结果的更广泛讨论以及额外的实验。附录 E.3 描述了我们对于 FL-和 LED-GFlowNets 及其终端不限制变体的实现。所有实验均依赖于 Adam (Kingma & Ba, 2014)，其学习率分别为 10^{-3} 用于 p_F 和 10^{-2} 用于 $\log Z$ 进行随机优化 (Madan 等, 2022)。

E.1 第 3 节的实验 集合生成。支持集 $\mathcal{X}$ 定义为从存款 $\mathcal{D} = \{1, \dots, 32\}$ 中抽取的包含 16 个元素的集合的集合。为了定义奖励函数，我们设 $f: \mathcal{D} \rightarrow \mathbb{R}$ ，其中 $f(d) \sim \mathcal{U}[0, 1]$ ，并设 $\log R(x) = \sum_{d \in \mathcal{D}} f(d)$ 。我们实现了一个具有两个 256 维隐藏层的多层感知机来参数化前向策略和流函数。对于权重函数 γ ，我们注意到 $\# \mathcal{D}_{s'} = \binom{32-|s'|}{16-|s'|}$ ，其中 $|s'|$ 是当前状态的大小。

序列设计。支持集 $\mathcal{X}$ 定义为从存款 $\mathcal{D} = \{1, \dots, 4\}$ 中提取元素构成的大小不超过 12 的序列集合。我们实现了一个具有两个 256 维隐藏层的 MLP，用于正向策略和流函数，这两个函数都接收一个长度为 12 并用 0 填充的序列为输入。然后，奖励函数 $\alpha: \mathbb{R}^8 \rightarrow \mathbb{R}$ 由 $f: \mathcal{D} \rightarrow \mathbb{R}$ 和 $g: [1, 12] \rightarrow \mathbb{R}$ 定义，并通过 $f(d), g(i) \sim \mathcal{U}[-1, 1]$ 对 $d \in \mathcal{D}$ 和 $i \in [1, 12]$ 进行计算，通过 $\log R(x) = \sum_{i=1}^{12} f(x_i)g(x_i)$ 。对于权重函数 γ ，我们注意到 $\# \mathcal{D}_{s'} = 1 + 4 + \dots + 4^{12-|s'|}$ 是 s' 的终端后代的数量。

系统发育推断。系统发育树由一棵完全二叉树定义 $\mathcal{G}$ 其标记的叶节点对应于观察到的生物物种，匿名的内部节点对应于它们的进化祖先。同时，我们考虑一组 $\mathbf{Y} \in \mathbb{R}^{32 \times 7}$ 与 7 个观察物种相关的 DNA 序列，大小为 32； $\mathbf{Y}$ 的可能性由 J&C69 (Jukes & Cantor, 1969) 的突变模型定义，并通过 Felsenstein 算法 (Felsenstein, 1981) 计算得出，奖励函数是由树上的均匀先验分布诱导出的未归一化的后验概率。我们采用 Zhou 等人 (2024) 提出的迭代过程来使用 GFlowNets 采样系统发育树，并使用图同构网络 (Xu 等, 2019) 进行参数化 p_F 对于加权函数 γ ，我们回顾一下 $\# \mathcal{D}_{s'} = (2 \cdot (7 - |s'|) - 1)!!$ 是终端后代的数量 s' ，与 $|s'|$ 作为连通分量的数量在 s' (?)。

超网格。支持集 $\mathcal{X}$ 由元组 $(x, y) \in [0, 11] \times [0, 11]$ 组成，这些元组描述了 12×12 二维网格。生成过程与 Bengio 等人 (2021)；Malkin 等人 (2022; 2023) 的研究相同。奖励函数特别定义为

$$R(\mathbf{s}) = 10^{-3} + 0.5 \prod_{i=1}^2 \mathbf{1}_{\{|s_i|/11 \in (0.25, 0.5)\}} + 2 \prod_{i=1}^2 \mathbf{1}_{\{|s_i|/11 \in (0.3, 0.4)\}} \quad (38)$$

对于状态 $\mathbf{s} = (s_1, s_2)$ ； $\mathbf{1}_A$ 是事件 A 的指示函数。类似于 Madan 等人 (2022) 的研究，本文使用批大小为 16 条轨迹，并训练模型 62500 个训练轮次 (10^6 轨迹)。本文用一个包含两个 128 维层的多层感知机参数化前向策略。此外， $\# \mathcal{D}_{s'} = (11 - s'_1)(11 - s'_2) + 1$ 是从某个状态 s' 可达的终止状态的数量。

实验细节如下 图 3. 为了进一步理解定理 1 在训练 GFlowNets 的上下文中的意义，我们在图 3 中展示了第 3 节所考虑的生成任务沿轨迹的平均对数平方平衡违反情况。正如预期的那样，DB 损失的大小主要由生成过程的早期转换决定。此外，对于集合生成和系统发生推断问题，这种主导性更为明显，而对于序列设计和超网格导航问题则不太明显，这与图 4 中关于通过最小化我们的加权损失 (方程 6) 相对于传统方法改进性能的结果一致。在这方面，我们强调，在图 3 和图 4 中，序列设计和超网格导航是唯一具有可变长度轨迹的任务。当为这些任务训练模型时，我们观察到在训练初期，大多数采样的轨迹相对较短，这可能会阻碍我们加权学习目标所带来的改进，因为权重之间的相似性。尽管如此，正如我们在第 6 节中承认的那样，还需要更深入地了解每个转换对 GFlowNet 抽样分布准确性的影响力。无论如何，很明显，方程 6 中的传统均匀加权是次优的。重要的是，我们也认为，对于 γ 的最佳选择应该根据具体问题来确定。




图 11: 平均 $\mathcal{L}_{\text{WDB}}^\gamma(s, s') := \gamma(s, s') (\log(F(s)p_F(s, s') - \log(F(s')p_B(s, s')))^2$ 在训练期间随机轨迹上的结果。结果基于 5 次运行的平均值。与图 3 不同，我们观察到 γ 具有先偏斜后平滑的效果，即它最初将较大的权重分配给终端状态（在那里接收到训练信号， R ），然后在各个转移之间平衡权重。这一点在系统发生学和集合任务中尤为明显，这些任务是 $\mathcal{L}_{\text{WDB}}^\gamma$ 表现最佳的任务。

附录 E.2 第 4 节的实验

设置 图 6. 本实验基于具有形式 $L \leftarrow P \rightarrow R$ 的简单 3 状态 SGs 构建，其中 F 是一个 8 节点的 3 正则图，而 L 和 R 是通过添加单个边获得的 P 的两个不同同构子图。特别地，我们为图 6 中的四个图选择了四个不同的元组 (L_i, P_i, R_i) 。参见图 9 以了解所实现的两个 SGs 的示意图。为了参数化 LA- 和标准 GFlowNets 的策略，我们使用了一个具有 32 维层的 3 层 GIN (Xu 等, 2019)，随后是一个包含两个 32 维层的 MLP。对于 LA-GFlowNet，MLP 的输入大小是标准模型的两倍。




图 9: 元组示例 (L_i, P_i, R_i) 。添加的边及其节点被突出显示。

LA-GFlowNets 的运行时间分析。 从理论角度来看，LA-GFlowNet 的时间复杂度与其状态图中状态的最大子节点数量 C 呈线性增长。相比之下，传统的 GFlowNet 实现的成本相对于 C 是常数。请参见图 10，比较 LA-GFlowNet、标准 GFlowNet（通过最小化 TB 进行训练）以及通过流匹配目标 (FM) 训练的 GFlowNet——参见 (Bengio 等, 2021, 方程 11)——在相同超参数下生成集合任务的训练时间。我们报告了在 5 个随机种子上平均 10 个训练轮次的平均运行时间。探讨是否可以在较低复杂度下实现等效的表达能力是一个有前景的研究方向。




图 10: 训练时间。

附录 E.3 第 5 节的实验

流动性和学习能量分解 (LED-) GFlowNets。 在实现 FL- 和 LED-GFlowNets 时，我们遵循了 Pan 等 (2023a) 及 Jang 等 (2024) 的实验设置。为了避免实现偏差，我们使用了 Pan 等 (2023a) 公开发表的代码¹ 重现了实验，并获得了相似的结果。特别是， p_F 和 ϕ 均通过多层感知机进行参数化。对于 LED-GFlowNet，在每次训练轮次中，我们执行了 8 次随机梯度步骤以学习 ϕ 。而对于通过最小化 TB 损失进行训练的标准 GFlowNet，我们遵循了 Malkin 等人 (2022) 的指导。

我们与 LED-GFlowNets 的主要作者 (Jang 等, 2024) 私下交换了电子邮件，讨论他们的实现是否强制执行 $F(x) = R(x)$ 。重要的是，他告知我们，他验证了他们的实验，并确认他们在集合环境中的代码确实没有强制执行 $F(x) = R(x)$ ，从而实现了命题 1 中描述的终端不受限制的 GFlowNet 变体，但他也解释说他的其余实验是正确的。他还告诉我们，他在集合环境中进行实验的基础代码是从 Pan 等 (2023a) 的工作中借用的。

¹ 可在 github.com/ling-pan/FL-GFN 在线获取。




图 12: 展示了 γ 对 GFlowNet 学习收敛性的影响。我们引入了两个新颖的加权函数： γ_1 和 γ_2 。一方面， γ_1 按照每个状态转移后代数量 $\#D_{s'}$ 的平方根的倒数进行加权，并且正如预期的那样，其行为类似于最初提出的 γ 。另一方面， γ_2 ——它是 γ 的逆——显著阻碍了训练的 GFlowNet 的学习收敛性。




图 13: PHO4 任务中对图 8 的补充 (沈等, 2023 年, 第 7 节)。再次说明, FCS 是唯一能够正确反映 GFlowNet 分布准确性的度量。尽管 TU-LED-GFlowNet 迅速覆盖了目标分布的高概率区域 (中间和右侧面板), 但它未能学习到正确的分布 (左侧面板)。结果是基于三次运行的平均值。

集合生成。实验设置与第 3 节所述相同。为了计算沈等 (2023 年) 的准确率, 我们在目标分布下通过广泛枚举 SG 的终端状态预先计算了 $R(x)$ 的平均值。对于 FCS, 我们随机抽取了 32 批大小不超过 128 的终端状态用于蒙特卡洛估计器。

袋生成。实验设置与集合生成时所用的大致相同。然而, 由于袋子的空间显著大于集合的空间, 我们固定 $\mathcal{D} = \{1, \dots, 16\}$ 并生成元素在 $\mathcal{D}$ 。E.4 额外的实验 转换损失对于 $\mathcal{L}_{\text{WDR}}^\gamma$ 。图 11 展示了 $\mathcal{L}_{\text{WDR}}^\gamma(s, s')$ 作为转换深度的函数 (s, s') 沿着随机采样的轨迹。我们注意到, 在初始训练阶段, 标准 DB 损失主要由较早的状态主导 (见图 3), $\mathcal{L}_{\text{WDR}}^\gamma$ 受近终端转移的影响。因此, 在优化过程中, 主要训练信号, 即终端状态的奖励, 会获得更大的权重。另一方面, 随着训练的进行, 轨迹内的损失变化减小, 引导 GFlowNet 在整个状态图上学习一个平衡的流——这对于精确的分布逼近至关重要 (定理 1)。

额外的加权方案用于 $\mathcal{L}_{\text{WDR}}^\gamma$ 。根据图 3, 定理 1 以及上述分析, 我们推断有效的加权函数 γ 应该优先考虑接近终端的状态转移。图 11 通过验证在集合生成和序列设计任务上的直觉 (见图 4) 来

证明当 γ 是状态转移深度的严格递增函数时，所得到的 $\mathcal{L}_{\text{WDR}}^\gamma$ 在实践中能够与标准 DB 损失函数相媲美甚至更优。这些结果可以指导适当权重函数的设计。然而，构建最优的 γ 的原则性方法仍然是一个开放问题，值得未来进一步研究。

FCS 在真实数据集中的有效性。我们在图 8 中重现了采样长度为 10 的 DNA 序列的任务，这些序列的比例由实验室测量的序列与酵母转录因子（PHO4）的结合亲和力定义的奖励函数决定（Shen 等，2023；Jain 等，2022；Barrera 等，2016；Trabucco 等，2022）。为此，我们遵循 E.3 节中对序列设计任务所描述的实验设置。与图 8 一致，图 13 和表 2 显示 FCS 是唯一能够正确推断 TU-LED-GFlowNet 证明错误性的可行度量。确实，在模式发现和 Shen 等（2023）的准确率方面，尽管 TU-LED-GFlowNet 距离目标分布更远，但它优于 TB-GFlowNet。我们省略 FL-GFlowNet，因为没有自然的候选潜在函数。