

重新审视离散环境中的非无环 GFlowNets

Nikita Morozov^{*1} Ian Maksimov^{*1} Daniil Tiapkin²³ Sergey Samsonov¹

摘要

生成流网络 (GFlowNets) 是一类生成模型, 旨在从给定的概率分布中采样对象, 该概率分布可能仅在归一化常数内已知。GFlowNets 不直接在对象空间中工作, 而是通过在一个适当构造的有向无环图环境中采样轨迹来操作, 这极大地依赖于图的无环性。在本文中, 我们重新审视了放松无环假设的理论, 并提出了一个更简单的非无环 GFlowNets 理论框架, 适用于离散环境。此外, 我们提供了关于固定反向策略训练、流函数性质以及熵正则化强化学习与非无环 GFlowNets 之间联系的各种新洞见, 这些自然推广了来自无环设置的相关概念和理论结果。此外, 我们还实验性地重新审视了非无环 GFlowNet 训练中的损失稳定性概念, 并验证了我们的理论发现。

2025) 以及大语言模型和扩散模型的微调 (Hu 等, 2023; Venkatraman 等, 2024; Uehara 等, 2024; Zhang 等, 2025; Lee 等, 2025)。离散环境中的 GFlowNets 详细理论基础在 (Bengio 等, 2023) 中得到发展。尽管大多数 GFlowNets 文献考虑的是离散设置, 但可以将连续 GFlowNets 的方法 (Lahlou 等, 2023) 应用于更一般空间上的采样问题。

GFlowNets 生成过程的核心思想在于, 在适当构建的有向无环图环境中采样轨迹, 而不是直接在对象空间中工作。这一过程的标准直觉是一个动作序列应用于从“块”构建复合对象的过程。这种设置的一个局限性是需要无环性。虽然这个局限性可以在分子生成等场景中自然解释, 但它可能会限制 GFlowNet 环境的实际设计, 并限制 GFlowNets 在其他场景中的适用性。(Brunswic 等人, 2024 年) 提出的非无环 GFlowNets 的一个动机例子与建模具有内在对称性的对象分布有关。考虑一类状态属于某些群 (如对称群或魔方群) 的环境。转移通过该群的生成集给出, 从而对应于将群操作应用于当前状态和生成集中的某个元素, 这导致循环的存在。尽管在某些情况下可以设计无环环境来生成群元素, 但这类“代数”起源的环境自然包含循环, 因此属于我们的研究范围。此外, 越来越多的研究将 GFlowNets 与强化学习联系起来 (Tiapkin 等人, 2024; Mohammadpour 等人, 2024; Deleu 等人, 2024; He 等人, 2024)。大多数 RL 环境包含循环, 因此理解如何在循环环境中应用 GFlowNets 并将它们与 RL 联系起来可能是进一步连接两个研究领域的关键步骤。

1. 引言

生成流网络 (GFlowNets, Bengio 等, 2021) 是一种旨在从按比例已知的概率分布中采样离散对象的模型。它们通过由前向策略定义的一系列随机转换来构建对象。GFlowNets 已成功应用于各个领域, 从分子生成 (Bengio 等, 2021; Shen 等, 2024; Koziarski 等, 2024; Cretu 等, 2025) 和生物序列设计 (Jain 等, 2022; Kim 等, 2024) 到组合优化 (Zhang 等, 2023a;b; Kim 等, * 同等贡献 1 莫斯科俄罗斯国立高等经济学院 2CMAP – CNRS – ‘Ecole polytechnique – 巴黎理工学院, 法国帕莱索, 91128 3 巴黎萨克雷大学, CNRS, LMO, 奥赛, 法国, 91405。通讯作者: 尼基塔·莫罗佐夫 <nmorozov@hse.ru>。

据我们所知, GFlowNets 中处理非无环环境的方法论方面仅在最近 (Brunswic 等人, 2024) 的工作中被考虑过。后者类似于 (Lahlou 等人, 2023), 使用可测空间和测度论的工具, 这使得构建新扩展更加困难

本文的方法论。我们认为离散 GFlowNets (Bengio 等, 2023 年) 背后的理论相较于其一般状态的对应物具有简单性的关键优势。因此, 本文的主要目的是重新审视离散状态空间中非循环 GFlowNets 的理论, 简化 (Brunswic 等, 2024 年) 的构造, 并提供关于在这种设置下训练 GFlowNets 的额外理论和方法论洞见。本文的主要贡献可以总结如下: 1. 我们提出了一种简单直观的方式, 从零开始构建非循环 GFlowNets 在离散环境中的理论。除了简单性之外, 我们的构造还引入并阐明了一些关键点, 这些关键点涉及循环与非循环离散 GFlowNets 之间的相似性和差异性, 而这些内容在 (Brunswic 等, 2024 年) 中并未探讨, 特别是关于流的本质和反向策略的重要性。2. 我们展示了当反向策略固定时, 由 (Brunswic 等, 2024 年) 引入的损失稳定性不会影响优化过程的结果。后者仅在同时训练反向策略时才变得重要。3. 当反向策略被训练时, 我们证明了学习具有最小预期轨迹长度的非循环 GFlowNet 等同于学习具有最小总流量的非循环 GFlowNet。此外, 我们提出了状态流正则化作为解决由此产生的优化问题的一种方式。4. 我们通过实验证明, 在损失中计算流误差的尺度对损失的稳定性起着至关重要的作用。然而, 我们也展示了使用不稳定的损失结合所提出的状态流正则化可以导致更好的采样质量。5. 最后, 我们将 (Tiapkin 等, 2024 年) 关于 GFlowNets 与熵正则化强化学习等价性的关键理论结果推广到非循环设置。源代码:

github.com/GreatDrake/non-acyclic-gfn。

2. 背景

2.1. GFlowNets

本节介绍 GFlowNets 所需的符号和理论背景。GFlowNets 处理从离散空间的概率分布中采样的问题 $\mathcal{X}$ 作为有向无环图 (DAG) 中的顺序决策过程 $\mathcal{G} = (\mathcal{S}, \mathcal{E})$, 其中 $\mathcal{S}$ 是一个有限状态空间并且 $\mathcal{E} \subseteq \mathcal{S} \times \mathcal{S}$ 是一个有限的边集 (或转移集)。存在一个特殊的初始状态 s_0 没有入边的特殊源状态和一个特殊的汇状态 s_f 没有出边的状态。常用的记法变体不包括汇状态 s_f , 但我们更倾向于使用一种变体 s_f , 因为它也在之前关于非单循环 GFlowNets (Brunswic 等, 2024) 的工作中使用, 并且导致了

更加直观的构造。令 τ 是从

$\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_{n_\tau} \rightarrow s_f)$ 到 s_0 的所有轨迹集合 s_f , 其中我们用 n_τ 表示轨迹的长度 τ 。我们约定 $s_{n_\tau+1} = s_f$ 。我们说 τ 在...终止 s 如果其最后一步转移是 $s \rightarrow s_f$ 。这样的转移被称为终止转移, 而具有向外边指向...的状态 s_f 被称为终态。终态集合与... $\mathcal{X}$ 相吻合, 感兴趣的概率分布... $\mathcal{R}(x)/\mathcal{Z}$ 在其上定义, 其中... $\mathcal{R}(x) > 0$ 被称为 GFlowNet 奖励, 而...

$\mathcal{Z} = \sum_{x \in \mathcal{X}} \mathcal{R}(x)$ 是一个未知的归一化常数。此外, 对于任何状态 s , 记入 (s) 为状态集合 s' 使得存在一条边 $s' \rightarrow s \in \mathcal{E}$ (父节点), 以及出 (s) 为状态集合 s' 使得存在一条边 $s \rightarrow s' \in \mathcal{E}$ (子节点)。

GFlowNets 的主要目标是寻找一个分布 $\mathcal{P}$ 超过 τ 使得对于任意 $x \in \mathcal{X}$, 概率为 $\tau \sim \mathcal{P}$ 终止于 x 一致于 $\mathcal{R}(x)/\mathcal{Z}$ 这一属性被称为奖励匹配条件。GFlowNets 使用马尔可夫分布处理轨迹 (关于定义和讨论, 请参见 (Bengio 等人, 2023)), 其主要组成部分包括:

1. 前向策略 $\mathcal{P}_F(s' | s)$, 它是每个状态的子节点上的分布;
2. 后向策略 $\mathcal{P}_B(s | s')$, 它是每个状态的父节点上的分布;
3. 状态/边流 $\mathcal{F}(s), \mathcal{F}(s \rightarrow s')$, 它与轨迹 τ 经过状态/边的未归一化概率相吻合。

$\mathcal{P}_F, \mathcal{P}_B$ 和 $\mathcal{F}$ 通过轨迹平衡条件相连:

$$\mathcal{P}(\tau) = \prod_{t=0}^{n_\tau} \mathcal{P}_F(s_{t+1} | s_t) = \prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t | s_{t+1}), \quad (1)$$

详细平衡条件:

$$\mathcal{F}(s \rightarrow s') = \mathcal{F}(s) \mathcal{P}_F(s' | s) = \mathcal{F}(s') \mathcal{P}_B(s | s'), \quad (2)$$

以及流匹配条件:

$$\mathcal{F}(s) = \sum_{s' \in \text{out}(s)} \mathcal{F}(s \rightarrow s') = \sum_{s'' \in \text{in}(s)} \mathcal{F}(s'' \rightarrow s). \quad (3)$$

如果固定以下任意一项, 则所有这些对象都能被完全唯一地指定: 1) 边缘流 $\mathcal{F}(s \rightarrow s')$, 2) 初始流 $\mathcal{F}(s_0)$ 和 $\mathcal{P}_F$, 3) 初始流 $\mathcal{F}(s_0)$ 和 $\mathcal{P}_B$ 。若流满足 $\mathcal{F}(s \rightarrow s_f) = \mathcal{R}(s)$, 则由相应正向策略定义的轨迹分布将满足奖励匹配条件 (Bengio 等, 2023)。实践中, 利用神经网络来参数化正向策略 (以及可选的反向策略和流)。然后,

训练以最小化某种损失函数，从而强制奖励匹配条件成立。例如，细致平衡损失（Bengio 等人，2023）定义在所有状态转移上 $s \rightarrow s' \in \mathcal{E}$ 如下：

$$\mathcal{L}_{\text{DB}}(s \rightarrow s') \triangleq \left(\log \frac{\mathcal{F}_\theta(s) \mathcal{P}_F(s' | s, \theta)}{\mathcal{F}_\theta(s') \mathcal{P}_B(s | s', \theta)} \right)^2. \quad (4)$$

通过在损失函数中替换 $\mathcal{F}(x \rightarrow s_f) = \mathcal{F}_\theta(s_f) \mathcal{P}_B(x | s_f, \theta) = \mathcal{R}(x)$ 来强制执行奖励匹配。尽管优化任务通常有多种解，但固定反向策略会导致在 $\mathcal{F}$ 和 $\mathcal{P}_F$ 方面具有唯一解（Bengio 等，2023）。

2.2. GFlowNets 在非循环环境中的应用

(Brunswic 等, 2024) 指出，GFlowNet 理论的基本结果同样适用于环境图 $\mathcal{G}$ 可能包含循环的情况，并且所有来自无环情况的定义仍然有效并扩展到有环情况。然而，我们将进一步证明这并不完全正确，例如，流不能一致地定义为未归一化的访问概率。

更具体地说，(Brunswic 等, 2024) 认为，如果边缘流满足 (3)，并且终止转换也满足 $\mathcal{F}(s \rightarrow s_f) = \mathcal{R}(s)$ ，则由该流诱导的前向策略 $\mathcal{P}_F(s' | s) = \frac{\mathcal{F}(s \rightarrow s')}{\mathcal{F}(s)}$ 将满足奖励匹配条件。因此，标准的 GFlowNet 损失函数，如流匹配 (FM, Bengio 等, 2021)、细致平衡 (DB, Bengio 等, 2023) 和轨迹平衡 (TB, Malkin 等, 2022) 可以在非无环环境中应用。

然而，(Brunswic 等, 2024) 指出，非循环与循环 GFlowNets 之间的主要区别在于，在非循环设置中，预期轨迹长度 $\mathbb{E}[n_\tau]$ （在 (Brunswic 等, 2024) 中表示为采样时间）可以由循环而变得任意大，而在循环设置中它总是有界的。为了解决这个问题，引入了一个损失稳定性的概念。如果沿一个循环增加一个常数永远不会减少损失，则称该损失是稳定的，否则称为不稳定（定义 3）。研究表明 FM、DB 和 TB 是不稳定的（定理 3），这可能导致在训练中采样时间变得任意大。相比之下，提出了一类可证明稳定的损失（定理 4）。此外，作者还展示了存在 FM 和 DB 损失的稳定变体，例如稳定的 DB 损失，我们将其表示为 SDB：

$$\begin{aligned} \mathcal{L}_{\text{SDB}}(s \rightarrow s') &\triangleq \log(1 + \varepsilon \Delta^2(s, s', \theta))(1 + \eta \mathcal{F}_\theta(s)), \\ \Delta(s, s', \theta) &\triangleq \mathcal{F}_\theta(s) \mathcal{P}_F(s' | s, \theta) - \mathcal{F}_\theta(s') \mathcal{P}_B(s | s', \theta), \end{aligned} \quad (5)$$

其中 ε 和 η 是超参数。此外，(Brunswic 等, 2024) 表明预期轨迹长度为

受限于总归一化状态流

$$\mathbb{E}[n_\tau] \leq \frac{1}{\mathcal{F}(s_0)} \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathcal{F}(s), \quad (6)$$

并且通过使用一个稳定的损失函数，并加入一个正则化项来控制总流量，例如边流矩阵的范数，可以用来学习一个无环流量（定理 1）。

3. 离散空间中的 GFlowNets 理论

非循环环境

3.1. 环境

关于环境的所有定义可以类似于无环 GFlowNets 的设置引入（参见第 2.1 节），主要区别在于：图 $\mathcal{G}$ 现在可以包含环。除了有限性之外，我们对结构 $\mathcal{G}$ 做出两个技术假设：

假设 3.1. 0) 图 $\mathcal{G}$ 是有限的；1) 存在一个特殊的初始状态 s_0 ，没有入边，并且存在一个特殊的终止状态 s_f ，没有出边；2) 对于任意状态 $s \in \mathcal{S}$ ，存在从 s_0 到 s 的路径以及从 s 到 s_f 的路径。

接下来，我们正式定义轨迹：定义 3.2。序列 $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_f)$ 被称为长度为

$n_\tau \in \mathbb{N}$ 如果所有转换 $s_t \rightarrow s_{t+1} \in \mathcal{E}, t \in \{0, \dots, n_\tau\}$ 。Then $\mathcal{T}$

是所有从 s_0 开始并在 s_f 结束的有限长度轨迹 s_f 的集合

在上述定义及后续内容中，我们使用约定 $s_{n_\tau+1} = s_f$ 。虽然 $\mathcal{G}$ 本身总是有限的，但与无环 GFlowNets 的主要区别在于 $\mathcal{T}$ 可以是无限的，并且 $\mathcal{T}$ 可以包含任意长度的轨迹。

3.2. 后向策略和轨迹分布

在 GFlowNets 中引入轨迹上的概率分布有几种等价的方法。其中一种常见的方法是从引入轨迹流开始（Bengio 等人, 2023）。基于轨迹流的方法的主要理论优势在于它允许非马尔可夫流，参见（Bengio 等人, 2023）。同时，在 GFlowNets 文献中主要考虑的是马尔可夫流，在我们的论文中，我们仅考虑这种设置。与其从流的定义开始，更直观的方法是从前向和后向策略的定义开始。

定义 3.3. 与 $\mathcal{G}$ 一致的前向策略 $\mathcal{P}_F(s' | s)$ 是对于每个 $s \in \mathcal{S} \setminus \{s_f\}$ 定义的在 $s' \in \text{out}(s)$ 上的条件概率分布族。类似地，与 $\mathcal{G}$ 一致的后向策略 $\mathcal{P}_B(s | s')$ 是对于每个 $s' \in \mathcal{S} \setminus \{s_0\}$ 定义的在 $s \in \text{in}(s')$ 上的条件概率分布族。

在本文后续部分，我们始终假设所考虑的 $\mathcal{P}_F$ 或 $\mathcal{P}_B$ 与 $\mathcal{G}$ 一致，并不明确指出这一事实。定义 3.3 与无环 GFlowNets 中的前向和后向策略定义一致 (Bengio 等, 2023, 定义 4)。请注意，结构 $\mathcal{G}$ 关于初始状态 s_0 和汇状态 s_f 之间的互换以及所有边在 $\mathcal{G}$ 中的反转是对称的。因此，从 $\mathcal{P}_F$ 或 $\mathcal{P}_B$ 开始是等价的。我们在后续推导中偏好从后向策略 $\mathcal{P}_B$ 开始。利用 $\mathcal{P}_B$ ，我们根据定义了一个概率分布 $\mathcal{P}$ 覆盖

$$\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_{n_\tau} \rightarrow s_f) \in \mathcal{T}.$$

$$\mathcal{P}(\tau) \triangleq \prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t | s_{t+1}). \quad (7)$$

在这种情况下，我们说轨迹分布 $\mathcal{P}(\tau)$ 是由 $\mathcal{P}_B$ 诱导的。在下面的引理中，我们证明了 $\mathcal{P}(\tau)$ 是定义在 $\mathcal{T}$ 上的正确概率分布。


引理 3.4. 设 $\mathcal{P}_B(s | s')$ 是一个后向策略，使得对于任何边 $\mathcal{P}_B(s | s') > 0$ ，有 $s \rightarrow s' \in \mathcal{E}$ 。那么根据 (7) 定义的 $\mathcal{P}(\tau)$ 是定义在 $\mathcal{T}$ 上的概率分布，即 $\sum_{\tau \in \mathcal{T}} \mathcal{P}(\tau) = 1$ 。此外，其预期轨迹长度总是有限的

$$\mathbb{E}_{\tau \sim \mathcal{P}}[n_\tau] = \sum_{\tau \in \mathcal{T}} n_\tau \mathcal{P}(\tau) < +\infty. \text{ 实际上，条件}$$


$\mathcal{P}_B(s | s') > 0$ 连同假设 3.1 允许我们确保序列 s_i 是一个有限状态空间吸收马尔可夫链。给定这个假设，引理 3.4 的证明几乎与证明这样的马尔可夫链的状态是瞬时的证明相同，参见例如 (Douc 等, 2018)。为了完整性，我们在附录 A.1 中提供了证明。

3.3 状态和边流

给定由 $\mathcal{P}_B$ 诱导的概率分布 $\mathcal{P}(\tau)$ ，我们的下一个目标是定义状态和边流。在进行有效的构造之前，我们提供一些关于定义的直觉。首先，让我们展示，与无环 GFlowNets 不同，我们不能将边流定义为访问概率 $\mathcal{P}(\{\tau \in \mathcal{T} | s \rightarrow s' \in \tau\})$ 。特别是，我们展示了这样的定义不满足流匹配条件 (3)。确实，考虑来自 (Brunswic 等, 2024) 的一个例子：




每条边上方的数字 $s \rightarrow s'$ 表示 $\mathcal{P}_B(s | s')$ 。考虑由 (7) 定义的分 $\mathcal{P}(\tau)$ 。我们将绘制每条边的访问概率：



可以看出，对于状态 b 和 c ，流匹配条件 (3) 不成立，因为 $1 \neq 1 + 0.5$ 。相反，让我们计算每条边的预期访问次数 $s \rightarrow s'$

$$\mathbb{E}_{\tau \sim \mathcal{P}} \left[\sum_{t=0}^{n_\tau} \mathbb{I}\{s_t = s, s_{t+1} = s'\} \right].$$

我们在下图中可视化相应的数字：



容易验证流匹配条件 (3) 现在得到了满足。接下来，我们正式定义：

定义 3.5. 设 $\mathcal{P}_B(s | s')$ 为一种逆向策略，使得对于任意边 $s \rightarrow s' \in \mathcal{E}$ 有 $\mathcal{P}_B(s | s') > 0$ 。然后，给定最终流 $\mathcal{F}(s_f) > 0$ ，我们定义状态和边的流为

$$\begin{aligned} \mathcal{F}(s \rightarrow s') &\triangleq \mathcal{F}(s_f) \cdot \mathbb{E}_{\tau \sim \mathcal{P}} \left[\sum_{t=0}^{n_\tau} \mathbb{I}\{s_t = s, s_{t+1} = s'\} \right], \\ \mathcal{F}(s) &\triangleq \mathcal{F}(s_f) \cdot \mathbb{E}_{\tau \sim \mathcal{P}(\tau)} \left[\sum_{t=0}^{n_\tau+1} \mathbb{I}\{s_t = s\} \right]. \end{aligned} \quad (8)$$

我们说上述定义的流是由反向策略 $\mathcal{P}_B$ 和最终流 $\mathcal{F}(s_f)$ 诱导的。

值得注意的是，如果 $\mathcal{G}$ 不包含循环，(8) 中的预期访问次数与访问概率一致，因此定义 3.5 与无环 GFlowNet 文献中对流的一般理解相符。接下来，我们证明在 (3.5) 中定义的状态和边流满足细致平衡和流匹配条件 (2) - (3)。

命题 3.6. 定义 3.5 中定义的流 $\mathcal{F}$ 满足：

1. $\mathcal{F}(s) \stackrel{(a)}{=} \sum_{s' \in \text{out}(s)} \mathcal{F}(s \rightarrow s') \stackrel{(b)}{=} \sum_{s'' \in \text{in}(s)} \mathcal{F}(s'' \rightarrow s)$,
对于每个 $s \in \mathcal{S} \setminus \{s_0, s_f\}$ 。此外，等式 (a) 对于 s_0 成立，等式 (b) 对于任何 s_f 成立
2. $\mathcal{F}(s \rightarrow s') = \mathcal{F}(s') \mathcal{P}_B(s | s')$ $s \rightarrow s' \in \mathcal{E}$.
3. $\mathcal{F}(s_0) = \mathcal{F}(s_f)$.

证明见附录 A.2。在接下来的命题中，我们将展示一对 $(\mathcal{P}_B, \mathcal{F}(s_f))$ 与边流 $\mathcal{F}$ 之间存在一一对应关系。其证明见附录 A.3。

命题 3.7. 设 $\mathcal{F} : \mathcal{E} \rightarrow \mathbb{R}_{>0}$ 是一个满足流匹配条件 (3) 的函数。定义相应的逆向策略如下关系

$$\mathcal{P}_B(s | s') = \mathcal{F}(s \rightarrow s') / \sum_{s'' \in \text{in}(s')} \mathcal{F}(s'' \rightarrow s').$$

Then $\mathcal{F}$ are edge flows induced by $\mathcal{P}_B$ and $\mathcal{F}(s_f) = \sum_{s'' \in \text{in}(s_f)} \mathcal{F}(s'' \rightarrow s_f)$.

3.4. 正向策略和细致平衡

众所周知，在无环 GFlowNets 理论 (Bengio 等, 2023) 中，对于任何逆向策略 $\mathcal{P}_B$ ，都存在一个唯一的正向策略 $\mathcal{P}_F$ ，它诱导相同的概率分布于 $\mathcal{T}$ 。这一事实的主要启示是，通过固定奖励 $\mathcal{R}(x), x \in \mathcal{X}$ 和每个状态 $s' \in \mathcal{S} \setminus \{s_0, s_f\}$ 的逆向策略 $\mathcal{P}_B(s | s')$ ，自动确定了一个满足奖励匹配条件 (Malkin 等, 2022) 的轨迹分布 $\mathcal{P}(\tau)$ 。然而，从这样的分布中采样是不可行的，因为它需要从根据奖励分布抽取的终端状态开始。因此，在 GFlowNet 训练过程中，尝试找到一个始终允许通过构造进行可行轨迹采样的正向策略，使其匹配这个轨迹分布 $\mathcal{P}(\tau)$ 。可以注意到，这与层次变分推断 (Malkin 等, 2023) 有相似之处。在接下来的命题中，我们将展示这一结果也适用于非无环 GFlowNets。

命题 3.8. 给定任意逆向策略 $\mathcal{P}_B(s | s') > 0$ ，存在一个唯一的正向策略 $\mathcal{P}_F(s' | s)$ ，使得

$$\mathcal{P}(\tau) = \prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t | s_{t+1}) = \prod_{t=0}^{n_\tau} \mathcal{P}_F(s_{t+1} | s_t), \forall \tau \in \mathcal{T}.$$

此外，它满足细致平衡条件

$$\mathcal{F}(s) \mathcal{P}_F(s' | s) = \mathcal{F}(s') \mathcal{P}_B(s | s'), \forall s \rightarrow s' \in \mathcal{E}$$

状态流 $\mathcal{F}$ 由 (8) 定义。

证明见附录 A.4。相反，以下命题表明，如果一个三元组 $\mathcal{F}, \mathcal{P}_F, \mathcal{P}_B$ 满足细致平衡条件 (2)，它将与所有先前的定义和命题一致。

命题 3.9. 设 $\mathcal{F}: \mathcal{S} \rightarrow \mathbb{R}_{>0}$ ，并设 $\mathcal{P}_F(s' | s) > 0$ 和 $\mathcal{P}_B(s | s') > 0$ 分别为正向和反向策略，使得细致平衡条件 (2) 得到满足。那么 $\mathcal{P}_F$ 和 $\mathcal{P}_B$ 诱导相同的轨迹分布：

$$\mathcal{P}(\tau) = \prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t | s_{t+1}) = \prod_{t=0}^{n_\tau} \mathcal{P}_F(s_{t+1} | s_t), \forall \tau \in \mathcal{T}.$$

此外， $\mathcal{F}$ 是由 $\mathcal{P}_B$ 和 $\mathcal{F}(s_f)$ 诱导的状态流。

证明请参见附录 A.5。上述命题直接推广了非循环设置下的相应命题 (Bengio 等, 2023 年)。请注意，由于在 $\mathcal{G}$ 中 s_0 和 s_f 之间的对称性，直到改变边的方向，我们可以从 (7) 中的正向策略及其诱导的轨迹分布开始，然后证明相应的反向策略 $\mathcal{P}_B$ 的唯一性。

3.5. 非循环 GFlowNets 的训练

现在，我们继续 GFlowNets 的主要学习问题：找到一个正向策略，使其匹配终端状态上的奖励分布 $\mathcal{R}(x)/\mathcal{Z}, x \in \mathcal{X}$ 。该

命题展示了如何将奖励匹配条件表述为流的形式。

命题 3.10. *Let $\mathcal{P}_B(s | s') > 0$ be a backward policy, $\mathcal{F}(s_f) > 0$ a final flow, and $\mathcal{R}(x) > 0$ GFlowNet rewards. If edge flows $\mathcal{F}(s \rightarrow s')$ induced by $\mathcal{P}_B$ and $\mathcal{F}(s_f)$ satisfy:*

$$\mathcal{F}(x \rightarrow s_f) = \mathcal{R}(x) \quad \forall x \rightarrow s_f \in \mathcal{E}, \quad (9)$$

由诱导出的轨迹分布 $\mathcal{P}$ 满足奖励匹配条件，即 $\mathcal{P}_B$ (7)

$\mathbb{P}_{\tau \sim \mathcal{P}}[s_{n_\tau} = x] = \mathcal{R}(x)/\mathcal{Z}$ 。那么，相同的轨迹分布是由唯一的相应正向策略诱导出来的 $\mathcal{P}_F$ ，因此也满足奖励匹配条件。

证明。注意到一条进入 s_f 的边只能被访问一次；因此， $\mathcal{F}(x \rightarrow s_f)$ 与终止于 x 的概率 $\mathbb{P}_{\tau \sim \mathcal{P}}[s_{n_\tau} = x]$ 相吻合，乘以最终流量 $\mathcal{F}(s_f)$ 。此外，我们有 $\mathcal{F}(s_f) =$ ，从而

$$\sum_{x \in \text{in}(s_f)} \mathcal{F}(x \rightarrow s_f) = \sum_{x \in \mathcal{X}} \mathcal{R}(x) = \mathcal{Z},$$

$$\mathbb{P}_{\tau \sim \mathcal{P}}[s_{n_\tau} = x] = \mathcal{F}(x \rightarrow s_f) / \mathcal{F}(s_f) = \mathcal{R}(x) / \mathcal{Z}. \quad \square$$

命题 3.10 还通过命题 3.6 暗示了 $\mathcal{F}(s_0) = \mathcal{F}(s_f) = \mathcal{Z}$ 和 $\mathcal{P}_B(x | s_f) = \mathcal{R}(x) / \mathcal{Z}$ 。

在关于无环 GFlowNets 的文献 (Malkin 等人, 2022; Bengio 等人, 2023) 中，一个被 (Brunswic 等人, 2024) 忽视但在非无环情况下也成立的重要事实是，通常很容易手动选择一个反向策略，使得诱导出的轨迹分布将满足奖励匹配条件。一个简单而自然的选择是取 $\mathcal{P}_B(x | s_f) = \mathcal{R}(x) / \mathcal{Z}$ 对于 s_f 并固定 $\mathcal{P}_B(s | s') = 1/|\mathcal{S}'|$ 在 (s') 对于所有其他状态。值得一提的是， $\mathcal{Z}$ 通常是未知的，但这个问题在 GFlowNets 中通过学习未归一化的流或使用 $\mathcal{Z}$ 本身成为可学习参数来规避，这取决于所选的损失函数 (Malkin 等人, 2022; Bengio 等人, 2023; Madan 等人, 2023)。此外，命题 3.8 表明相应的唯一性 $\mathcal{P}_F$ 。因此，我们陈述这个结果的主要实用推论：

推论 3.11. 当反向策略 $\mathcal{P}_B > 0$ 固定时，来自无环 GFlowNet 文献中的任何损失 (Bengio 等人, 2021; Malkin 等人, 2022; Bengio 等人, 2023; Madan 等人, 2023) 都可以用于学习相应的正向策略

$\mathcal{P}_F$ ，即使在非无环情况下也是如此。引理 3.4 和命题 3.8 表明总是存在具有有限期望轨迹长度的唯一解，因此损失的稳定性 (Brunswic 等人, 2024) 不起作用。

在非无环 GFlowNets 中，使用固定反向策略学习的主要劣势在于预期轨迹长度可能较大，而在无环 GFlowNets 中则不会出现这一问题。 $\mathbb{P}_{\tau \sim \mathcal{P}}[n_\tau]$ 人为选择的 $\mathcal{P}_B$ 预期轨迹长度可以很大。解决这一问题的一个自然方法是考虑使用

可学习的反向策略，这也是在无环 GFlowNet 文献中广泛采用的选择 (Malkin 等, 2022; Jang 等, 2024a; Griksaev 等, 2025)。然而, (Brunswic 等, 2024) 发现标准损失在无环 GFlowNet 文献中并不稳定 (定理 3), 这意味着预期轨迹长度在训练过程中可能无法控制地增长。稳定性概念是针对可学习边流引入的 (定义 3), 这表明相应的反向策略在训练过程中也会发生变化。使用稳定的损失, 例如 (5), 被提议作为解决这一问题的方法。同时, 我们认为, 在存在可学习的情况下, 有效训练具有可控预期轨迹长度的非无环 GFlowNet 是一个论点。\$\mathcal{P}_B\$ 无需利用稳定的损失函数即可实现。接下来的命题是定义 3.5 的一个简单推论:

命题 3.12. 给定一个轨迹分布 \$\mathcal{P}\$, 其预期轨迹长度等于归一化的总流量:

$$\mathbb{E}_{\tau \sim \mathcal{P}}[n_\tau] = \frac{1}{\mathcal{F}(s_f)} \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathcal{F}(s). \quad (10)$$

证明见附录 A.6。这一结果是对 (Brunswic 等, 2024) 中定理 2 的细化, 该定理仅陈述了 ‘\$\le\$’ 不等式 (10)。因此, 我们认为我们的关键贡献之一在于指出以下事实:

学习具有最小预期轨迹长度的非无环 GFlowNet 等同于学习具有最小总流量的非无环 GFlowNet。

我们也认为, 利用这种等价性是非无环 GFlowNet 未来研究的关键方向。我们进一步探讨了一种特定解决方案, 该方案建议在现有的 GFlowNet 损失中使用状态流作为正则化器。我们考虑详细平衡损失 DB (4) 的例子。在这种情况下, 命题 3.9 意味着学习具有最小预期轨迹长度的非无环 GFlowNet 可以表述为以下约束优化问题:

$$\begin{aligned} \min_{\mathcal{F}, \mathcal{P}_F, \mathcal{P}_B} \quad & \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathcal{F}(s) \\ \text{subject to} \quad & \left(\log \frac{\mathcal{F}(s) \mathcal{P}_F(s' | s)}{\mathcal{F}(s') \mathcal{P}_B(s | s')} \right)^2 = 0, \quad \forall s \rightarrow s' \in \mathcal{E}, \\ & \mathcal{F}(s_f) \mathcal{P}_B(x | s_f) = \mathcal{R}(x), \quad \forall x \rightarrow s_f \in \mathcal{E}. \end{aligned} \quad (11)$$

作为一种近似求解 (11) 的方式, 可以使用带有状态流正则化的 DB (4):

$$\left(\log \frac{\mathcal{F}_\theta(s) \mathcal{P}_F(s' | s, \theta)}{\mathcal{F}_\theta(s') \mathcal{P}_B(s | s', \theta)} \right)^2 + \lambda \mathcal{F}_\theta(s), \quad (12)$$

其中 \$\lambda > 0\$ 是一个超参数, 用于控制预期轨迹长度与匹配奖励分布的准确度之间的权衡。如同 (4), 通过替换 \$\mathcal{F}_\theta(s_f) \mathcal{P}_B(x | s_f, \theta) = \mathcal{R}(x)\$ 来强制执行奖励匹配。

\$\mathcal{R}(x)\$。

请注意, DB 损失是在单个转换上定义的, 在训练过程中, 它会在由训练策略收集的转换上进行优化。一个标准的选择是通过 \$\mathcal{P}_F\$ 采样的轨迹上的转换来优化它, 但训练策略可以选择不同, 或者从强化学习的角度来看, 可以采用在线策略或离线策略进行训练, 参见 (Tiapkin 等, 2024)。需要注意的是, 不同的状态 \$s\$ 可能会根据训练策略的不同频率出现在损失中, 这可能导致优化问题 (11) 中的偏差。我们在附录 B.1 中详细讨论了这一现象以及可能的缓解方法。

最后, 值得注意的是, 在非有向无环图的情况下, 基于流的正则化器已经被提出

(Brunswic 等, 2024) 的第一定理, 但仅适用于稳定损失设置。此外, 它们被引入是为了找到一个有向无环流。我们的论文进一步探讨并揭示了这一现象的新视角, 表明即使在使用不稳定损失和正则化的情况下也可以进行训练。此外, 当总流最小化时, 可以确保预期轨迹长度尽可能小。还值得一提的是, 引入约束优化问题以适应 GFlowNets 中的循环的想法已经在 (Deleu, 2025) 中提到。

3.6. 与熵正则化 RL 的关系

最近的一系列研究 (Tiapkin 等, 2024; Deleu 等, 2024) 探讨了 GFlowNets 与 RL 之间的联系, 表明在适当构造的确定性 MDP 中, 给定向后策略固定的情况下, GFlowNets 的学习问题等价于熵正则化的 RL 问题 (Neu 等, 2017; Geist 等, 2019)。我们证明了同样的结果也适用于非有向无环图的 GFlowNets。

设 \$\mathcal{G}\$ 为一个非无环 GFlowNet 的图, \$\mathcal{R}\$ 为 GFlowNet 奖励, \$\mathcal{P}_B > 0\$ 为满足奖励匹配条件的固定反向策略。设 \$\mathcal{F}\$ 由 \$\mathcal{P}_B\$ 在 \$\mathcal{F}(s_f) = \mathcal{Z}\$ 下诱导的流, 并设 \$\mathcal{P}_F\$ 为与 \$\mathcal{P}_B\$ 对应的唯一正向策略 (参见命题 3.8)。定义由图 \$\mathcal{G}\$ 诱导的确定性 MDP \$\mathcal{M}_\mathcal{G}\$, 其中状态空间 \$\mathcal{S}\$ 与图 \$\mathcal{G}\$ 的顶点一致, 每个状态 \$s\$ 的动作空间 \$\mathcal{A}_s\$ 对应于 \$\text{out}(s)\$, 转移核定义为图 \$\mathcal{P}(s' | s, a) = \mathbb{1}\{a = s'\}\$, 中的转移 \$a \in \text{out}(s)\$。我们不使用折扣 (\$\gamma = 1.0\$), 并将终止转换的 RL 奖励设置为 \$r(x, s_f) = \log \mathcal{R}(x)\$, 其他所有转换的 RL 奖励设置为 \$r(s, s') = \log \mathcal{P}_B(s | s')\$。那么, 以下陈述成立。

定理 3.13 (定理 1 (Tiapkin 等, 2024) 的泛化)。最优策略 \$\pi_{\lambda=1}^*(s' | s)\$ 对于熵-

正则化马尔可夫决策过程 (regularized MDP) $\mathcal{M}_G$ 的系数 $\lambda = 1$ 对于所有 $s \in \mathcal{S} \setminus \{s_f\}, s' \in \mathcal{A}_s$ 等于 $\mathcal{P}_F(s' | s)$ 。此外，正则化的最优值函数 $V_{\lambda=1}^*(s)$ 和 Q 值函数 $Q_{\lambda=1}^*(s, s')$ 分别与 $\log \mathcal{F}(s)$ 和 $\log \mathcal{F}(s \rightarrow s')$ 一致，对于所有 $s \rightarrow s' \in \mathcal{E}$ 。

证明及所有缺失的定义见附录 A.7。请注意，(Tiapkin 等, 2024) 的证明不能直接应用于非环设置，因为它是基于顶点的拓扑排序进行归纳的 $\mathcal{G}$ ，仅存在于无环图中。

4. 实验

除了验证我们的理论发现外，实验评估的一个目标是检验我们提出的尺度假设：

尺度假设。 当 $\mathcal{P}_B$ 可训练时，对损失稳定性起关键作用的主要因素是计算流之间误差的尺度，即训练后的非循环 GFlowNet 的受控平均轨迹长度。实际上，标准 DB 损失 (4) 在对数流尺度 $\Delta \log \mathcal{F}$ 下操作，而标准 SDB (5) 在流尺度 $\Delta \mathcal{F}$ 下操作。我们假设，在没有正则化的情况下使用对数流尺度损失可能导致任意的轨迹长度，而流尺度损失倾向于具有较小流的解决方案，因此不会出现这个问题。

在本节中，我们使用 DB 或 SDB 来指定所使用的损失函数，使用 $\Delta \log \mathcal{F}$ 或 $\Delta \mathcal{F}$ 来指定用于计算误差的流尺度，并使用 $\lambda = C$ 来指定所提出的状态流正则化的强度（参见第 3.5 节）。例如，图例中的 (DB, $\Delta \log \mathcal{F}$) 对应于 (4)，SDB, $\Delta \mathcal{F}$) 对应于 (5)，而 (DB, $\Delta \log \mathcal{F}, \lambda = C$) 对应于 (12)。关于损失缩放和稳定性的详细讨论请参阅附录 B.2。

4.1. 实验设置

我们考虑两种离散环境进行实验评估：1) 非循环超网格环境 (Bengio 等人, 2021 年) 的非循环版本，该版本在 (Brunswic 等人, 2024 年) 中被引入；2) (Brunswic 等人, 2024 年) 中的非循环排列生成环境，带有更难的奖励函数变体。实验细节请参阅附录 C。

平均样本奖励在 (Brunswic 等人, 2024 年) 中作为度量使用，数值越高被认为越好。然而，我们指出这并不总是代表从奖励分布中采样的准确性 $\mathcal{R}/\mathcal{Z}$ 。实际上，学习从最高奖励模式中采样的模型




图 1. 小规模超网格环境上非循环 GFlowNet 训练损失的比较。我们使用 DB 或 SDB 来指定所使用的损失函数，使用 $\Delta \log \mathcal{F}$ 或 $\Delta \mathcal{F}$ 来指定用于计算损失误差的流尺度，并使用 $\lambda = C$ 来指定是否采用了提议的状态流正则化。上图：样本经验分布与目标分布之间的 L^1 距离随时间的变化。下图：采样轨迹平均长度的变化。

尽管导致模式崩塌，仍然能够获得高平均奖励。例如，近期的研究认为测量平均样本奖励与真实期望奖励之间的偏差 $\sum_{x \in \mathcal{X}} \mathcal{R}(x) \frac{\mathcal{R}(x)}{\mathcal{Z}}$ 可以得到更好的度量，详见 (Shen 等人, 2023 年) 中的详细动机。此外，我们根据环境使用其他度量来跟踪采样的准确性，下面将详细讨论。

在这两个环境中，我们考虑两种设置：使用固定的几乎均匀的反向策略 $\mathcal{P}_B$ 进行训练，以及使用可训练的策略 $\mathcal{P}_B$ 。在第二种情况下，初始对数流

$\log \mathcal{F}_\theta(s_0) = \log \mathcal{Z}_\theta$ 也在学习过程中。因此，我们可以考察其收敛到真实归一化常数的对数 $\log \mathcal{Z}$ 的情况。详情请参阅附录 B.3。

4.2. 超网格

我们从非循环超网格环境 (Brunswic 等, 2024) 开始。这些环境足够小，使得规范化常数 $\mathcal{Z}$ 可以精确计算，并且训练的采样器可以高效地与精确奖励分布进行评估。状态是具有整数坐标的点 $s \in \{0, \dots, H-1\}^D$ ，位于边长为 H 的 $a D$ 维超立方体内，再加上两个辅助状态 s_0 和 s_f 。可能的转换对应于增加或减少任何坐标值 1 而不离开网格。此外，每个状态都有一个终止




图 2. 非循环 GFlowNet 在更大超网格环境上的训练损失比较。我们使用 DB 或 SDB 来指定所使用的损失, $\Delta \log \mathcal{F}$ 或 $\Delta \mathcal{F}$ 来指定用于计算损失误差的流尺度, 并使用 $\lambda = C$ 来指定提议的状态流正则化的使用情况。左: 经验样本分布与目标分布之间的 L^1 距离演变。中: 采样轨迹平均长度的演变。右: 训练初始对数流 $\log \mathcal{Z}_\theta$ 的演变。

表 1. 排列环境下的比较。 $C(k) L^1$ 是真实分布与固定点概率经验分布之间的 L^1 距离, $C(k), \Delta \mathcal{R}$ 是 (Shen et al., 2023) 提出的平均奖励的相对误差, $\Delta \log \mathcal{Z}$ 是 $|\log \mathcal{Z}_\theta - \log \mathcal{Z}|$ 。均值和标准差是在 3 个随机种子计算得出。蓝色表示最佳度量, 红色表示预期轨迹长度最小。

Loss	$n = 8$				$n = 20$			
	$C(k) L^1 \downarrow$	$\Delta \mathcal{R} \downarrow$	$\Delta \log \mathcal{Z} \downarrow$	$\mathbb{E}[n_\tau]$	$C(k) L^1 \downarrow$	$\Delta \mathcal{R} \downarrow$	$\Delta \log \mathcal{Z} \downarrow$	$\mathbb{E}[n_\tau]$
DB, $\Delta \mathcal{F}$	0.215 $\pm$ 0.198	0.214 $\pm$ 0.086	0.814 $\pm$ 0.826	2.43 $\pm$ 0.28	0.453 $\pm$ 0.002	0.343 $\pm$ 0.000	42.98 $\pm$ 0.000	2.00 $\pm$ 0.00
SDB, $\Delta \mathcal{F}$	0.031 $\pm$ 0.012	0.046 $\pm$ 0.023	0.074 $\pm$ 0.025	3.32 $\pm$ 0.15	0.452 $\pm$ 0.001	0.343 $\pm$ 0.000	42.98 $\pm$ 0.000	2.01 $\pm$ 0.00
DB, $\Delta \log \mathcal{F}, \lambda = 10^{-3}$	0.036 $\pm$ 0.015	0.056 $\pm$ 0.024	0.018 $\pm$ 0.010	2.80 $\pm$ 0.04	0.041 $\pm$ 0.002	0.064 $\pm$ 0.000	0.023 $\pm$ 0.005	3.23 $\pm$ 0.00
SDB, $\Delta \log \mathcal{F}, \lambda = 10^{-3}$	0.037 $\pm$ 0.013	0.056 $\pm$ 0.019	0.020 $\pm$ 0.015	2.79 $\pm$ 0.04	0.041 $\pm$ 0.002	0.064 $\pm$ 0.000	0.026 $\pm$ 0.003	3.22 $\pm$ 0.00
DB, $\Delta \log \mathcal{F}, \lambda = 10^{-5}$	0.005 $\pm$ 0.001	0.001 $\pm$ 0.000	0.005 $\pm$ 0.004	4.31 $\pm$ 0.05	0.017 $\pm$ 0.002	0.035 $\pm$ 0.002	0.003 $\pm$ 0.003	7.55 $\pm$ 0.50
SDB, $\Delta \log \mathcal{F}, \lambda = 10^{-5}$	0.005 $\pm$ 0.001	0.002 $\pm$ 0.000	0.006 $\pm$ 0.006	4.36 $\pm$ 0.09	0.014 $\pm$ 0.001	0.025 $\pm$ 0.001	0.005 $\pm$ 0.005	7.31 $\pm$ 0.07

转换 $s \rightarrow s_f$, 因此 $\mathcal{X} = \mathcal{S} \setminus \{s_0, s_f\}$ 。奖励函数在网格角落附近有模式, 中间由具有非常小奖励的宽谷隔开。为了测量采样的准确性, 在真实奖励分布 $\mathcal{R}(x)/\mathcal{Z}$ 和训练过程中看到的最后 $2 \cdot 10^5$ 样本的经验分布之间计算总变差距离, 这与离散域上的 $1/2$ 的 L^1 距离相吻合。

本文分析始于一个 7×7 网格, 用于研究在固定反向策略与可训练反向策略下学习效果的差异。由于环境规模较小, 可以精确找到由固定 $\mathcal{P}_B$ 策略引起的流, 从而也确定其预期轨迹长度, 详见附录 B.4。图 1 展示了结果。首先, 我们注意到两者 (DB, $\Delta \log \mathcal{F}$) 和 (SDB, $\Delta \mathcal{F}$) 固定 $\mathcal{P}_B$ 均收敛到由固定反向策略引起的真正预期轨迹长度, 这与推论 3.11 一致。然而, 对于所有损失函数, 使用可训练 $\mathcal{P}_B$ 策略使我们能够找到具有更短轨迹长度的解决方案。此外, 我们观察到使用 Δ 中的损失函数 $\mathcal{F}$ 缩放结果导致收敛速度变慢, 并且在学习到的前向策略中产生轻微偏差, 相较于 $\Delta \log$ 的情况 $\mathcal{F}$ 缩放对于固定和学习到的情况均适用

$\mathcal{P}_B$ 最后, 值得注意的是, 即使在没有状态流正则化的条件下, 使用不稳定的 DB 损失函数在 $\Delta \log \mathcal{F}$ 尺度下仍可能导致较小的预期轨迹长度, 正如我们在本实验中所见。然而, 我们进一步表明, 这种情况在较大环境中并不成立。

接下来, 我们考虑一个更大的超网格

$20 \times 20 \times 20 \times 20$ 。由选定的固定后向策略引起的预期轨迹长度比小网格大几个数量级, 使得这种方法不切实际。虽然可以尝试手动找到具有较小预期轨迹长度的固定值 $\mathcal{P}_B$, 但这通常是一个具有挑战性的问题, 因此, 我们在这里仅考虑可训练的设置 $\mathcal{P}_B$ 。我们的发现如图 2 所示。类似于 7×7 网格的情况, 我们发现 $\Delta \mathcal{F}$ 尺度下的学习会导致 DB 和 SDB 的策略存在偏差, 并且这种偏差比在较小网格中更为明显。在 $\Delta \log \mathcal{F}$ 尺度下, 通过状态流正则化的 DB 和 SDB 能够学会从奖励分布中正确采样。尽管所有方法都收敛到相似预期轨迹长度, 但在训练过程中间阶段, 即使不使用正则化, $\Delta \mathcal{F}$ 尺度损失也显示出更小的 n_τ , 这支持了我们的缩放假设。此外, 附录 D 中的图 4

显示了在 $\Delta \log \mathcal{F}$ 尺度下的两种损失函数，当训练过程中没有使用状态流正则化时，采样的轨迹平均长度趋向于无穷大。最后，我们注意到， $\Delta \log \mathcal{F}$ 损失函数能够正确学习真实的归一化常数 $\mathcal{Z}$ ，而 $\Delta \mathcal{F}$ 损失函数表现较差。

4.3. 排列

接下来，我们考虑与对称群的凯莱图对应的环境 S_n （置换群，作用于 n 个元素上 $\{1, 2, \dots, n\}$ ），来自 (Brunswic 等, 2024)。每个状态 $s \in \mathcal{S} \setminus \{s_0, s_f\}$ 是一个固定长度的置换 $(s(1), \dots, s(n))$ ，存在 $n-1$ 种可能的转换，这些转换对应于交换相邻的一对元素 $s(k)$ 和 $s(k+1)$ ，以及一个将置换向右循环移动的转换 $(s(n), s(1), \dots, s(n-1))$ 。此外，每个状态都有一个终止转换 $s \rightarrow s_f$ 。实验中使用的 GFlowNet 奖励在 (Brunswic 等, 2024) 中定义为 $\mathbb{I}[s(1) = 1]$ 。我们认为这导致了一个相对简单的任务，并且存在一个简单的正向策略，只需应用循环移位直到 1 位于第一个位置。我们在实验中选择使用更复杂的奖励分布，并根据置换中的不动点数量定义 GFlowNet 奖励 $\mathcal{R}(s) = \exp(\frac{1}{2} \sum_{k=1}^n \mathbb{I}\{s(k) = k\})$ 。

随着 n 的增长，状态的数量 $n!$ 迅速变得过大，无法计算总变差距离，就像对于超网格所做的那样，我们追踪若干统计量收敛到其真实值的过程。首先，我们计算 GFlowNet 样本的平均奖励与真实期望奖励之间的相对误差，正如 (Shen 等, 2023) 所提出的。其次，记 $C(k)$ 为从奖励分布中采样的置换具有 k 个不动点的概率。我们计算向量 $(C(0), C(1), \dots, C(n))$ 与其在训练过程中最后 10^5 个样本上的经验估计之间的 L^1 误差。最后，我们追踪训练后的 $\log \mathcal{Z}_\theta$ 向真实值 $\log \mathcal{Z}$ 的收敛过程。在附录 C.3.1 中，我们展示了如何高效地计算这些量的真实参考值。

表 1 展示了对于 $n = 8$ 和 $n = 20$ 的结果。在这里， $\mathcal{P}_B$ 在所有情况下都进行了训练。虽然对于 $n = 8$ ，环境仍然相对较小，但 $n = 20$ 导致了一个更具挑战性的环境，拥有 $\approx 2.4 \cdot 10^{18}$ 个状态，因此训练出的神经网络需要泛化到训练期间未见过的状态，以便匹配奖励分布。首先，我们注意到，尽管 $\Delta \mathcal{F}$ 尺度损失可以学习到一定程度的奖励分布对于 $n = 8$ ，但对于 $n = 20$ 却失败了。然而，在所有情况下，它们都收敛到了小的 $\mathbb{E}[n_\tau]$ ，支持了我们的缩放假设。另一方面，我们发现，通过使用 $\Delta \log \mathcal{F}$ 损失和状态流正则化的 GFlowNet 训练，对于 $n = 8$ 和 $n = 20$ ，奖励分布近似误差都收敛到了低值。此外，

通过观察，我们发现使用较小的正则化系数 λ ，一方面会导致模型具有较大的预期轨迹长度，但另一方面，也会使模型更好地匹配奖励分布。最后，我们在固定 $\mathcal{P}_B$ 与可训练 $\mathcal{P}_B$ 之间进行了相同的实验，针对长度为 $n = 4$ 的小排列，并在第 4.2 节中提出了类似的观察结果。结果展示在附录 D 的图 6 中。

4.4 讨论

我们的实验评估得出的关键观察结果如下：

1. 使用固定的 $\mathcal{P}_B$ 进行学习是可能的，即使没有稳定的损失和正则化，然而手动选择具有小 $\mathbb{E}[n_\tau]$ 的 $\mathcal{P}_B$ 具有挑战性；
2. 当 $\mathcal{P}_B$ 被训练时，我们的结果实证支持了缩放假设，表明即使在 $\Delta \mathcal{F}$ 尺度上的标准 DB 也是稳定的；然而，使用 $\Delta \mathcal{F}$ 尺度损失训练的非循环 GFlowNets 往往无法准确匹配奖励分布；
3. 在 $\Delta \log \mathcal{F}$ 尺度上，无论是 DB 还是 SDB 都能更好地匹配奖励分布，但需要结合状态流正则化来确保较小的预期轨迹长度 $\mathbb{E}[n_\tau]$ 。

5 结论

在本文中，我们扩展了 GFlowNets 的理论框架，以涵盖非循环离散环境，重新审视并简化了 (Brunswic 等, 2024) 之前的构造。此外，我们提供了关于反向策略和非循环 GFlowNets 中流动性质的若干理论洞见，将已知的 GFlowNets 训练与熵正则化 RL 之间的联系推广到这一设置，并通过实验重新审视了 (Brunswic 等, 2024) 提出的损失稳定性的概念的重要性。

未来的工作可以探索将其他来自循环 GFlowNet 文献中的损失函数应用于非循环设置 (Madan 等, 2023; Silva 等, 2024; Hu 等, 2025)。根据定理 3.13，另一个有前景的方向是将已知的强化学习技术和算法应用于非循环情况下的 GFlowNets，鉴于它们在循环 GFlowNets 中的成功应用 (Tiapkin 等, 2024; Mohammadpour 等, 2024; Lau 等, 2024; Morozov 等, 2024)。最后，在所有状态都是终止状态的环境中，即具有向 s_f 的转换，自然会在非循环情况下出现。然后，可以引入特殊修改以提高训练期间奖励信号的传播 (Deleu 等, 2022; Pan 等, 2023; Jang 等, 2024b)。

致谢

本文感谢 Leo Maxime Brunswic 对本论文实现细节的有益讨论和提供 (Brunswic 等, 2024)。本研究工作得到了俄罗斯联邦经济发展部的支持 (项目编号 25-139-66879-1-0003)。本研究部分通过计算资源由 HSE 大学的高性能计算设施支持 (Kostenetskiy 等, 2021)。

影响声明

本文旨在推进机器学习领域的研究。我们的工作可能带来许多潜在的社会影响, 但没有特别需要在此强调的内容。

参考文献

- Bengio, E., Jain, M., Korablyov, M., Precup, D., and Bengio, Y. Flow network based generative models for non-iterative diverse candidate generation. *Advances in Neural Information Processing Systems*, 34:27381–27394, 2021.
- Bengio, Y., Lahlou, S., Deleu, T., Hu, E. J., Tiwari, M., and Bengio, E. Gflownet foundations. *Journal of Machine Learning Research*, 24(210):1–55, 2023.
- Bertsekas, D. *Dynamic programming and optimal control: Volume I*, volume 4. Athena scientific, 2012.
- Brunswic, L., Li, Y., Xu, Y., Feng, Y., Jui, S., and Ma, L. A theory of non-acyclic generative flow networks. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pp. 11124–11131, 2024.
- Comtet, L. *Advanced Combinatorics: The Art of Finite and Infinite Expansions*. Reidel, 1974.
- Cretu, M., Harris, C., Igashov, I., Schneuing, A., Segler, M., Correia, B., Roy, J., Bengio, E., and Lio, P. SynFlowNet: Design of diverse and novel molecules with synthesis constraints. In *The Thirteenth International Conference on Learning Representations*, 2025.
- Deleu, T. Generative flow networks: Theory and applications to structure learning. *arXiv preprint arXiv:2501.05498*, 2025.
- Deleu, T., Góis, A., Emezue, C., Rankawat, M., Lacoste-Julien, S., Bauer, S., and Bengio, Y. Bayesian structure learning with generative flow networks. In *Uncertainty in Artificial Intelligence*, pp. 518–528. PMLR, 2022.
- Deleu, T., Nouri, P., Malkin, N., Precup, D., and Bengio, Y. Discrete probabilistic inference as control in multi-path environments. In *The 40th Conference on Uncertainty in Artificial Intelligence*, 2024.
- Douc, R., Moulines, E., Priouret, P., and Soulier, P. *Markov chains*. Springer Series in Operations Research and Financial Engineering. Springer, 2018. ISBN 978-3-319-97703-4.
- Geist, M., Scherrer, B., and Pietquin, O. A theory of regularized markov decision processes. In *International Conference on Machine Learning*, pp. 2160–2169. PMLR, 2019.
- Gritsaev, T., Morozov, N., Samsonov, S., and Tiapkin, D. Optimizing backward policies in GFlowNets via trajectory likelihood maximization. In *The Thirteenth International Conference on Learning Representations*, 2025.
- He, H., Bengio, E., Cai, Q., and Pan, L. Random policy evaluation uncovers policies of generative flow networks. *arXiv preprint arXiv:2406.02213*, 2024.
- Hu, E. J., Jain, M., Elmoznino, E., Kaddar, Y., Lajoie, G., Bengio, Y., and Malkin, N. Amortizing intractable inference in large language models. In *The Twelfth International Conference on Learning Representations*, 2023.
- Hu, R., Zhang, Y., Li, Z., and Huang, L. Beyond squared error: Exploring loss design for enhanced training of generative flow networks. In *The Thirteenth International Conference on Learning Representations*, 2025.
- Jain, M., Bengio, E., Hernandez-Garcia, A., Rector-Brooks, J., Dossou, B. F., Ekbote, C. A., Fu, J., Zhang, T., Kilgour, M., Zhang, D., et al. Biological sequence design with gflowNets. In *International Conference on Machine Learning*, pp. 9786–9801. PMLR, 2022.
- Jang, H., Jang, Y., Kim, M., Park, J., and Ahn, S. Pessimistic backward policy for GFlowNets. In *Advances in Neural Information Processing Systems*, volume 37, pp. 107087–107111, 2024a.
- Jang, H., Kim, M., and Ahn, S. Learning energy decompositions for partial inference in GFlowNets. In *The Twelfth International Conference on Learning Representations*, 2024b.
- Kemeny, J. G. and Snell, J. L. *Finite markov chains*, volume 26. van Nostrand Princeton, NJ, 1969.
- Kim, H., Kim, M., Yun, T., Choi, S., Bengio, E., Hernández-García, A., and Park, J. Improved off-policy reinforcement learning in biological sequence design. *arXiv preprint arXiv:2410.04461*, 2024.
- Kim, M., Choi, S., Kim, H., Son, J., Park, J., and Bengio, Y. Ant colony sampling with GFlowNets for combinatorial

- optimization. In *International Conference on Artificial Intelligence and Statistics*. PMLR, 2025.
- Kostenetskiy, P., Chulkevich, R., and Kozyrev, V. Hpc resources of the higher school of economics. In *Journal of Physics: Conference Series*, volume 1740, pp. 012050. IOP Publishing, 2021.
- Koziarski, M., Rekesh, A., Shevchuk, D., van der Sloot, A., Gaiński, P., Bengio, Y., Liu, C., Tyers, M., and Batey, R. Rgfn: Synthesizable molecular generation using gflownets. *Advances in Neural Information Processing Systems*, 37:46908–46955, 2024.
- Lahlou, S., Deleu, T., Lemos, P., Zhang, D., Volokhova, A., Hernández-García, A., Ezzine, L. N., Bengio, Y., and Malkin, N. A theory of continuous generative flow networks. In *International Conference on Machine Learning*, pp. 18269–18300. PMLR, 2023.
- Lau, E., Lu, S., Pan, L., Precup, D., and Bengio, E. Qgfn: Controllable greediness with action values. *Advances in neural information processing systems*, 37:81645–81676, 2024.
- Lee, S., Kim, M., Cherif, L., Dobre, D., Lee, J., Hwang, S. J., Kawaguchi, K., Gidel, G., Bengio, Y., Malkin, N., and Jain, M. Learning diverse attacks on large language models for robust red-teaming and safety tuning. In *The Thirteenth International Conference on Learning Representations*, 2025.
- Madan, K., Rector-Brooks, J., Korablyov, M., Bengio, E., Jain, M., Nica, A. C., Bosc, T., Bengio, Y., and Malkin, N. Learning gflownets from partial episodes for improved convergence and stability. In *International Conference on Machine Learning*, pp. 23467–23483. PMLR, 2023.
- Malkin, N., Jain, M., Bengio, E., Sun, C., and Bengio, Y. Trajectory balance: Improved credit assignment in gflownets. *Advances in Neural Information Processing Systems*, 35:5955–5967, 2022.
- Malkin, N., Lahlou, S., Deleu, T., Ji, X., Hu, E. J., Everett, K. E., Zhang, D., and Bengio, Y. GFlownets and variational inference. In *The Eleventh International Conference on Learning Representations*, 2023.
- Mohammadpour, S., Bengio, E., Frejinger, E., and Bacon, P.-L. Maximum entropy gflownets with soft q-learning. In *International Conference on Artificial Intelligence and Statistics*, pp. 2593–2601. PMLR, 2024.
- Morozov, N., Tiapkin, D., Samsonov, S., Naumov, A., and Vetrov, D. Improving gflownets with monte carlo tree search. *arXiv preprint arXiv:2406.13655*, 2024.
- Neu, G., Jonsson, A., and Gómez, V. A unified view of entropy-regularized markov decision processes. *arXiv preprint arXiv:1705.07798*, 2017.
- Pan, L., Malkin, N., Zhang, D., and Bengio, Y. Better training of gflownets with local credit and incomplete trajectories. In *International Conference on Machine Learning*, pp. 26878–26890. PMLR, 2023.
- Shen, M. W., Bengio, E., Hajiramezanali, E., Loukas, A., Cho, K., and Biancalani, T. Towards understanding and improving gflownet training. In *Proceedings of the 40th International Conference on Machine Learning, ICML’23*. JMLR.org, 2023.
- Shen, T., Seo, S., Lee, G., Pandey, M., Smith, J. R., Cherkasov, A., Kim, W. Y., and Ester, M. TacoGFN: Target-conditioned GFlowNet for structure-based drug design. *Transactions on Machine Learning Research*, 2024. ISSN 2835-8856.
- Silva, T., de Souza da Silva, E., and Mesquita, D. On divergence measures for training gflownets. *Advances in Neural Information Processing Systems*, 37:75883–75913, 2024.
- Tiapkin, D., Morozov, N., Naumov, A., and Vetrov, D. P. Generative flow networks as entropy-regularized rl. In *International Conference on Artificial Intelligence and Statistics*, pp. 4213–4221. PMLR, 2024.
- Uehara, M., Zhao, Y., Biancalani, T., and Levine, S. Understanding reinforcement learning-based fine-tuning of diffusion models: A tutorial and review. *arXiv preprint arXiv:2407.13734*, 2024.
- Venkatraman, S., Jain, M., Scimeca, L., Kim, M., Sendera, M., Hasan, M., Rowe, L., Mittal, S., Lemos, P., Bengio, E., Adam, A., Rector-Brooks, J., Bengio, Y., Berseth, G., and Malkin, N. Amortizing intractable inference in diffusion models for vision, language, and control. *Neural Information Processing Systems (NeurIPS)*, 2024.
- Zhang, D., Dai, H., Malkin, N., Courville, A. C., Bengio, Y., and Pan, L. Let the flows tell: Solving graph combinatorial problems with gflownets. In *Advances in Neural Information Processing Systems*, volume 36, pp. 11952–11969, 2023a.
- Zhang, D., Zhang, Y., Gu, J., Zhang, R., Susskind, J. M., Jaitly, N., and Zhai, S. Improving gflownets for text-to-image diffusion alignment. *Transactions on Machine Learning Research*, 2025. ISSN 2835-8856.
- Zhang, D. W., Rainone, C., Peschl, M., and Bondesan, R. Robust scheduling with gflownets. In *The Eleventh International Conference on Learning Representations*, 2023b.

A. 证明

A.1. 引理 3.4 的证明

考虑一个在 $\mathcal{G}$ 上的随机游走，其转移概率由反向策略给出。具体而言，我们定义一个马尔可夫链 $\{X_n\}_{n=0}^\infty$ ，使得 $X_0 = s_f$ 几乎处处成立，并且 $\mathbb{P}[X_t = s \mid X_{t-1} = s'] = \mathcal{P}_B(s \mid s')$ 。令 $\mathbb{P}[X_t = s_0 \mid X_{t-1} = s_0] = 1$, i.e., s_0 是一个吸收状态。我们希望证明

1. 随机游走在 s_0 终止的概率为 1: $\mathbb{P}[\exists t : X_t = s_0] = 1$; 2. 游走的期望长度是有限的: $\mathbb{E}[n_\tau] = \mathbb{E}[\sum_{t=0}^\infty \mathbb{I}\{X_t \neq s_0\}] < \infty$ 。

特别是，第一个陈述意味着 $\mathcal{P}(\cdot)$ 是对有限轨迹的一个正确的概率测度，因为对于任何 $\tau = (s_0, s_1, \dots, s_{n_\tau}, s_f)$ 都成立

$$\mathbb{P}[(X_{n_\tau+1}, \dots, X_0) = \tau] = \prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t \mid s_{t+1}) = \mathcal{P}(\tau),$$

并且我们有

$$\sum_{\tau \in \mathcal{T}} \mathbb{P}[(X_{n_\tau+1}, \dots, X_0) = \tau] = \mathbb{P}[\exists \tau \in \mathcal{T} : (X_{n_\tau+1}, \dots, X_0) = \tau] = \mathbb{P}[\exists t : X_t = s_0],$$

因为事件 $\{(X_{n_\tau+1}, \dots, X_0) = \tau\}$ 在不同的 τ 下不相交。

首先考虑任何中间状态 $s \in \mathcal{S} \setminus \{s_0, s_f\}$ 并定义一个马尔可夫链 $\{Y_n\}_{n=0}^\infty$ 具有相同的转移概率作为 $\{X_n\}_{n=0}^\infty$ ，与 $Y_0 = s$ 几乎处处。我们定义 $p_s \triangleq \mathbb{P}[\exists t > 0 : Y_t = s]$ 即，该概率 $\{Y_n\}$ 回报到 s 首先。注意到 $p_s < 1$ 确实，基于我们的假设 $\mathcal{G}$ ，至少存在一条路径 τ 来自 s_0 到 s 并且进一步地，存在这样一条不含环路的路径。在这种情况下，我们有

$$\mathbb{P}[(Y_{n_\tau+1}, \dots, Y_0) = \tau] = \prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t \mid s_{t+1}) > 0$$

根据对 $\mathcal{P}_B(s \mid s') > 0$ 的条件对于 $s \rightarrow s' \in \mathcal{E}$ 。注意到 $\{(Y_{n_\tau+1}, \dots, Y_0) = \tau\} \cap \{\exists t > 0 : Y_t = s\} = \emptyset$ ，因为如果随机游走的轨迹已经到达了 s_0 ，它将永远不会返回到 s 。因此， $p_s = \mathbb{P}[\exists t > 0 : Y_t = s] < 1$ 。接下来，对于每个状态 $s \in \mathcal{S} \setminus \{s_0, s_f\}$ ，我们定义 $N_s \triangleq \sum_{t=0}^\infty \mathbb{I}\{X_t = s\}$ 作为原始过程中遇到的状态 s 的访问次数。同时，记 $N'_s \triangleq \sum_{t=0}^\infty \mathbb{I}\{Y_t = s\}$ 为从 s 开始的反向随机游走期间状态 s 的访问次数。我们注意到

$$\mathbb{E}[N_s] = \mathbb{P}[\exists t > 0 : X_t = s] \mathbb{E}[N'_s] \leq \mathbb{E}[N'_s],$$

其中第一个等式是由于强马尔可夫性质。同时，
并且根据马尔可夫性质，我们有

$$\text{我们有 } \mathbb{P}[N'_s > k] = \mathbb{P}[\exists n_1, \dots, n_k > 0 : Y_{n_j} = s], \\ \mathbb{P}[N'_s > k] = p_s^k. \text{ 因此}$$

$$\mathbb{E}[N'_s] = \sum_{k=0}^\infty \mathbb{P}[N'_s > k] = \sum_{k=0}^\infty p_s^k = \frac{1}{1-p_s} < +\infty.$$

最后，我们有

$$\mathbb{E}[n_\tau] = \mathbb{E}\left[\sum_{t=0}^\infty \mathbb{I}\{X_t \neq s_0\}\right] = \mathbb{E}\left[\sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \sum_{t=0}^\infty \mathbb{I}\{X_t = s\}\right] = \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathbb{E}[N_s] \leq \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathbb{E}[N'_s] < +\infty.$$

引理的第一个陈述直接来自于行走的期望长度的有限性，因为否则它将以非零概率具有无限长度，导致矛盾。

A.2. 命题 3.6 的证明

首先，我们证明流匹配条件。我们有

$$\mathcal{F}(s \rightarrow s') = \mathcal{F}(s_f) \mathbb{E}_\tau \left[\sum_{t=0}^{n_\tau} \mathbb{I}\{s_t = s, s_{t+1} = s'\} \right], \quad \mathcal{F}(s) = \mathcal{F}(s_f) \mathbb{E}_\tau \left[\sum_{t=0}^{n_\tau+1} \mathbb{I}\{s_t = s\} \right].$$

接下来，注意到对于任意轨迹 τ 和任意 $s \in \mathcal{S} \setminus \{s_0, s_f\}$ ，以下方程成立：

$$\mathbb{I}\{s_t = s\} = \sum_{s'' \in \text{in}(s)} \mathbb{I}\{s_{t-1} = s'', s_t = s\} = \sum_{s' \in \text{out}(s)} \mathbb{I}\{s_t = s, s_{t+1} = s'\}.$$

然后对于 $s \in \mathcal{S} \setminus \{s_0\}$:

$$\begin{aligned} \mathcal{F}(s) &= \mathcal{F}(s_f) \mathbb{E}_\tau \left[\sum_{t=1}^{n_\tau+1} \sum_{s'' \in \text{in}(s)} \mathbb{I}\{s_{t-1} = s'', s_t = s\} \right] \\ &= \sum_{s'' \in \text{in}(s)} \mathcal{F}(s_f) \mathbb{E}_\tau \left[\sum_{t=1}^{n_\tau+1} \mathbb{I}\{s_{t-1} = s'', s_t = s\} \right] = \sum_{s'' \in \text{in}(s)} \mathcal{F}(s'' \rightarrow s). \end{aligned}$$

Similarly for any $s \in \mathcal{S} \setminus \{s_f\}$:

$$\begin{aligned} \mathcal{F}(s) &= \mathcal{F}(s_f) \mathbb{E}_\tau \left[\sum_{t=0}^{n_\tau} \sum_{s' \in \text{out}(s)} \mathbb{I}\{s_t = s, s_{t+1} = s'\} \right] \\ &= \sum_{s' \in \text{out}(s)} \mathcal{F}(s_f) \mathbb{E}_\tau \left[\sum_{t=0}^{n_\tau} \mathbb{I}\{s_t = s, s_{t+1} = s'\} \right] = \sum_{s' \in \text{out}(s)} \mathcal{F}(s \rightarrow s'). \end{aligned}$$

接下来，我们证明关键关系 $\mathcal{F}(s \rightarrow s') = \mathcal{F}(s') \mathcal{P}_B(s | s')$ 。设 $\{X_n\}_{n=0}^\infty$ 是在引理 3.4 的证明中定义的马尔可夫链，对应于在 $\mathcal{G}$ 上带有反转边和由 $\mathcal{P}_B$ 给出的转移概率的随机游走。我们有

$$\begin{aligned} \mathcal{F}(s \rightarrow s') &= \mathcal{F}(s_f) \mathbb{E}_\tau \left[\sum_{t=0}^{n_\tau} \mathbb{I}\{s_t = s, s_{t+1} = s'\} \right] = \mathcal{F}(s_f) \mathbb{E} \left[\sum_{t=0}^{+\infty} \mathbb{I}\{X_t = s', X_{t+1} = s\} \right] \\ &\stackrel{(a)}{=} \mathcal{F}(s_f) \sum_{t=0}^{+\infty} \mathbb{P}(X_t = s', X_{t+1} = s) = \mathcal{F}(s_f) \sum_{t=0}^{+\infty} \mathbb{P}(X_t = s') \mathbb{P}(X_{t+1} = s | X_t = s') \\ &\stackrel{(b)}{=} \mathcal{F}(s_f) \sum_{t=0}^{+\infty} \mathbb{P}(X_t = s') \mathcal{P}_B(s | s') = \mathcal{F}(s_f) \mathbb{E} \left[\sum_{t=0}^{+\infty} \mathbb{I}\{X_t = s'\} \right] \mathcal{P}_B(s | s') \\ &= \mathcal{F}(s') \mathcal{P}_B(s | s'). \end{aligned}$$

这里在 (a) 中我们使用了以下事实：

$$\mathbb{E} \left[\sum_{t=0}^{+\infty} \mathbb{I}\{X_t = s', X_{t+1} = s\} \right] \leq \mathbb{E}[n_\tau] < \infty$$

由于引理 3.4，因此期望有限，我们可以应用富比尼定理。在 (b) 中，我们利用了马尔可夫性质 $\{X_n\}_{n=0}^\infty$ 。最后， $\mathcal{F}(s_0) = \mathcal{F}(s_f)$ 根据定义 (8)，因为每条轨迹 $\tau \sim \mathcal{P}$ 访问次数 s_0 恰好一次。

A.3. 命题 3.7 的证明

由于 $\mathcal{F}(s \rightarrow s')$ 满足流匹配条件，我们定义

$$\mathcal{F}(s) = \sum_{s' \in \text{out}(s)} \mathcal{F}(s \rightarrow s') = \sum_{s'' \in \text{in}(s)} \mathcal{F}(s'' \rightarrow s).$$

接下来, 取 $\mathcal{P}_B(s | s') = \mathcal{F}(s \rightarrow s') / \mathcal{F}(s')$ 。令 $\hat{\mathcal{F}}$ 表示由 $\mathcal{P}_B$ 和 $\mathcal{F}(s_f)$ (分别对应于由 $\mathcal{P}_B$ 诱导的轨迹分布 $\mathcal{P}$ 的期望访问次数) 诱导的来自定义 3.5 的流。我们的目标是证明 $\mathcal{F}$ 和 $\hat{\mathcal{F}}$ 一致。

根据命题 3.6 和对 $\mathcal{P}_B$ 的定义, 我们有

$$\hat{\mathcal{F}}(s \rightarrow s') = \hat{\mathcal{F}}(s') \mathcal{P}_B(s | s') = \frac{\hat{\mathcal{F}}(s')}{\mathcal{F}(s')} \mathcal{F}(s \rightarrow s') = C(s') \mathcal{F}(s \rightarrow s'),$$

其中我们记作 $C(s) = \hat{\mathcal{F}}(s) / \mathcal{F}(s)$ 。此外, 根据命题 3.6, $\hat{\mathcal{F}}$ 满足流匹配条件, 因此

$$\hat{\mathcal{F}}(s) = \sum_{s' \in \text{out}(s)} \hat{\mathcal{F}}(s \rightarrow s') = \sum_{s'' \in \text{in}(s)} \hat{\mathcal{F}}(s'' \rightarrow s).$$

结合这些陈述, 对于任意的 $s \in \mathcal{S} \setminus \{s_f\}$, 我们有

$$\hat{\mathcal{F}}(s) = C(s) \mathcal{F}(s) = \sum_{s' \in \text{out}(s)} C(s') \mathcal{F}(s \rightarrow s').$$

第一个方程是根据对 $C(s)$ 的定义, 第二个方程是由于流匹配条件。因此, 我们得到了关于 $C(s)$ 的一组线性方程组:

$$\forall s \in \mathcal{S} \setminus \{s_f\}, \quad \sum_{s' \in \text{out}(s)} C(s') \mathcal{F}(s \rightarrow s') - C(s) \mathcal{F}(s) = 0.$$

此外, 根据定义, $\hat{\mathcal{F}}(s_f)$ 等于 $\mathcal{F}(s_f)$ 乘以状态 $\tau \sim \mathcal{P}$ 访问状态 s_f 的期望次数, 后者为 1, 所以我们有 $\hat{\mathcal{F}}(s_f) = \mathcal{F}(s_f)$, 因此额外的方程是 $C(s_f) = 1$ 。总共, 我们有 $|\mathcal{S}|$ 个变量和 $|\mathcal{S}|$ 个方程, 并且感兴趣的是严格正的解。首先, 存在一个平凡解 $C(s) = 1$ 对于每个 $s \in \mathcal{S}$, 这是唯一的常数解, 因为 $C(s_f) = 1$ 。

接下来, 假设存在一个非常数解 $C'(s)$ 。记作 $\mathcal{S}_{\max} = \arg\max_{s \in \mathcal{S}} C'(s)$, 这将是 $\mathcal{S}$ 的一个真子集。让我们考虑两种情况。首先, 假设 $s_f \notin \mathcal{S}_{\max}$ 。令 $\tau = (s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_{n_\tau} \rightarrow s_f)$ 是访问状态集合 $\mathcal{S}_{\max}$ 中的某些状态的任何轨迹。那么存在一个索引 $t \leq n_\tau$ 使得 $s_t \in \mathcal{S}_{\max}$ 和 $s_{t+1} \notin \mathcal{S}_{\max}$ 。然后我们有

$$1 = \frac{\sum_{s' \in \text{out}(s_t)} C'(s') \mathcal{F}(s_t \rightarrow s')}{C(s_t) \mathcal{F}(s_t)} < \frac{\sum_{s' \in \text{out}(s_t)} C(s_t) \mathcal{F}(s_t \rightarrow s')}{C(s_t) \mathcal{F}(s_t)} = \frac{\sum_{s' \in \text{out}(s_t)} \mathcal{F}(s_t \rightarrow s')}{\mathcal{F}(s_t)} = 1.$$

The inequality is due to three facts: (i) $C(s) > 0 \forall s \in \mathcal{S}$, (ii) $s_t \in \mathcal{S}_{\max}$, and thus $C(s_t) \geq C(s')$ for any $s' \in \mathcal{S}$, and (iii) the inequality is strict for at least one edge $s_t \rightarrow s_{t+1}$ such that $C'(s_{t+1}) < C'(s_t)$, and it implies a contradiction.

其次, 假设 $s_f \in \mathcal{S}_{\max}$ 。然后, 记 $\mathcal{S}_{\min} = \arg\min_{s \in \mathcal{S}} C'(s)$, 这将是 $\mathcal{S}$ 的一个真子集。类似于前面的情况, 设 τ 是访问 $\mathcal{S}_{\min}$ 中某些状态的任意轨迹。那么存在一个指标 $t \leq n_\tau$ 使得 $s_t \in \mathcal{S}_{\min}$ 和 $s_{t+1} \notin \mathcal{S}_{\min}$ 。于是我们有

$$1 = \frac{\sum_{s' \in \text{out}(s_t)} C'(s') \mathcal{F}(s_t \rightarrow s')}{C(s_t) \mathcal{F}(s_t)} > \frac{\sum_{s' \in \text{out}(s_t)} C(s_t) \mathcal{F}(s_t \rightarrow s')}{C(s_t) \mathcal{F}(s_t)} = \frac{\sum_{s' \in \text{out}(s_t)} \mathcal{F}(s_t \rightarrow s')}{\mathcal{F}(s_t)} = 1.$$

因此, 在这种情况下也存在矛盾。因此 $C(s) = 1$ 是唯一的解, 这意味着 $\hat{\mathcal{F}}(s) = \mathcal{F}(s)$ 。最后, 对于任何 $s \rightarrow s' \in \mathcal{E}$ $\hat{\mathcal{F}}(s \rightarrow s') = C(s') \mathcal{F}(s \rightarrow s') = \mathcal{F}(s \rightarrow s')$ 。 $\mathcal{F}$ 和 $\hat{\mathcal{F}}$ 一致, 从而命题得证。

附录 A.4. 命题 3.8 的证明

让我们证明相应前向策略的存在性和唯一性。设 $\mathcal{F}$ 是由后向策略 (3.5) 诱导的流。

唯一性。 假设存在这样的前向策略 $\mathcal{P}_F$ ，则由 $\mathcal{P}_B$ 和 $\mathcal{P}_F$ 诱导的在 $\mathcal{T}$ 上的概率分布一致。此外，由于对于任何边 $s \rightarrow s' \in \mathcal{E}$ ，我们有 $\mathcal{P}_B(s \mid s') > 0$ ，并且轨迹的概率分布一致，我们得到 $\mathcal{P}_F(s' \mid s) > 0$ 。类似于引理 3.4 和命题 3.6 的证明，定义一个马尔可夫链 $\{X_n\}_{n=0}^\infty$ 对应于在前向方向上沿 $\mathcal{G}$ 的随机游走，其转移概率由 $\mathcal{P}_F$ 给出。

Formally, $X_0 = s_0$ a.s., $\mathbb{P}[X_t = s' \mid X_{t-1} = s] = \mathcal{P}_F(s' \mid s)$, and $\mathbb{P}[X_t = s_f \mid X_{t-1} = s_f] = 1$.

类似于命题 3.6 的证明，我们有

$$\begin{aligned} \mathcal{F}(s \rightarrow s') &= \mathcal{F}(s_f) \mathbb{E}_\tau \left[\sum_{t=0}^{n_\tau} \mathbb{I}\{s_t = s, s_{t+1} = s'\} \right] = \mathcal{F}(s_f) \mathbb{E} \left[\sum_{t=0}^{+\infty} \mathbb{I}\{X_t = s, X_{t+1} = s'\} \right] \\ &\stackrel{(a)}{=} \mathcal{F}(s_f) \sum_{t=0}^{+\infty} \mathbb{P}(X_t = s, X_{t+1} = s') = \mathcal{F}(s_f) \sum_{t=0}^{+\infty} \mathbb{P}(X_t = s) \mathbb{P}(X_{t+1} = s' \mid X_t = s) \\ &\stackrel{(b)}{=} \mathcal{F}(s_f) \sum_{t=0}^{+\infty} \mathbb{P}(X_t = s) \mathcal{P}_F(s' \mid s) = \mathcal{F}(s_f) \mathbb{E} \left[\sum_{t=0}^{+\infty} \mathbb{I}\{X_t = s\} \right] \mathcal{P}_F(s' \mid s) \\ &= \mathcal{F}(s) \mathcal{P}_F(s' \mid s). \end{aligned}$$

在 (a) 中，我们利用期望值的有限性应用富比尼定理，在 (b) 中，我们利用了 $\{X_n\}_{n=0}^\infty$ 的马尔可夫性质。结合命题 3.6，我们有 $\mathcal{F}(s') \mathcal{P}_B(s \mid s') = \mathcal{F}(s) \mathcal{P}_F(s' \mid s)$ 。因此， $\mathcal{P}_F(s' \mid s) = \mathcal{F}(s') \mathcal{P}_B(s \mid s') / \mathcal{F}(s)$ ，从而完成唯一性的证明。

存在性。取

$$\mathcal{P}_F(s' \mid s) = \frac{\mathcal{F}(s') \mathcal{P}_B(s \mid s')}{\mathcal{F}(s)} = \frac{\mathcal{F}(s \rightarrow s')}{\mathcal{F}(s)}.$$

这始终是一个有效的概率分布，因为 $\mathcal{F}(s) = \sum_{s' \in \text{out}(s)} \mathcal{F}(s \rightarrow s')$ 。Next, for any $\tau \in \mathcal{T}$ we have

$$\prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t \mid s_{t+1}) = \prod_{t=0}^{n_\tau} \frac{\mathcal{F}(s_t \rightarrow s_{t+1})}{\mathcal{F}(s_{t+1})} = \frac{\prod_{t=0}^{n_\tau} \mathcal{F}(s_t \rightarrow s_{t+1})}{\prod_{t=0}^{n_\tau} \mathcal{F}(s_{t+1})}.$$

其中第一个方程是由于命题 3.6。根据命题 3.6，我们也得到 $\mathcal{F}(s_0) = \mathcal{F}(s_f)$ 。于是

$$\frac{\prod_{t=0}^{n_\tau} \mathcal{F}(s_t \rightarrow s_{t+1})}{\prod_{t=0}^{n_\tau} \mathcal{F}(s_{t+1})} = \frac{\mathcal{F}(s_0) \prod_{t=0}^{n_\tau} \mathcal{F}(s_t \rightarrow s_{t+1})}{\mathcal{F}(s_f) \prod_{t=0}^{n_\tau} \mathcal{F}(s_t)} = \frac{\prod_{t=0}^{n_\tau} \mathcal{F}(s_t \rightarrow s_{t+1})}{\prod_{t=0}^{n_\tau} \mathcal{F}(s_t)} = \prod_{t=0}^{n_\tau} \mathcal{P}_F(s_{t+1} \mid s_t).$$

因此存在性得证。最后，细致平衡条件由上述唯一性证明得出。

附录 A.5 命题 3.9 的证明

考虑一个边函数 $\bar{\mathcal{F}}(s \rightarrow s') = \mathcal{F}(s) \mathcal{P}_F(s' \mid s)$ 。它是正的，因为 $\mathcal{F}(s) > 0$ 和 $\mathcal{P}_F(s' \mid s) > 0$ ，根据命题的陈述。由于 $\mathcal{P}_F(\cdot \mid s)$ 是在 $\text{out}(s)$ 上的有效概率分布，我们有

$$\sum_{s' \in \text{out}(s)} \bar{\mathcal{F}}(s \rightarrow s') = \sum_{s' \in \text{out}(s)} \mathcal{F}(s) \mathcal{P}_F(s' \mid s) = \mathcal{F}(s) \sum_{s' \in \text{out}(s)} \mathcal{P}_F(s' \mid s) = \mathcal{F}(s).$$

同样地，因为 $\mathcal{P}_B(\cdot \mid s)$ 是在 $\text{in}(s)$ 上的有效概率分布，并且 $\mathcal{F}$, $\mathcal{P}_F$ 和 $\mathcal{P}_B$ 满足细致平衡条件，我们有

$$\sum_{s'' \in \text{in}(s)} \bar{\mathcal{F}}(s'' \rightarrow s) = \sum_{s'' \in \text{in}(s)} \mathcal{F}(s'') \mathcal{P}_F(s \mid s'') = \sum_{s'' \in \text{in}(s)} \mathcal{F}(s) \mathcal{P}_B(s'' \mid s) = \mathcal{F}(s) \sum_{s'' \in \text{in}(s)} \mathcal{P}_B(s'' \mid s) = \mathcal{F}(s).$$

因此 $\bar{\mathcal{F}}$ 满足流匹配条件。此外

$$\mathcal{P}_B(s \mid s') = \frac{\mathcal{F}(s) \mathcal{P}_F(s' \mid s)}{\mathcal{F}(s')} = \frac{\bar{\mathcal{F}}(s \rightarrow s')}{\mathcal{F}(s')} = \frac{\bar{\mathcal{F}}(s \rightarrow s')}{\sum_{s'' \in \text{in}(s')} \bar{\mathcal{F}}(s'' \rightarrow s')}.$$

因此，将命题 3.7 应用于 $\bar{\mathcal{F}}$ ，我们得到它是由 $\mathcal{P}_B$ 诱导的边流，从而 $\mathcal{F}$ 也是由其诱导的状态流。
 $\mathcal{P}_B \quad \mathcal{F}(s_f)$.

接下来，考虑任意轨迹 $\tau = (s_0, s_1, \dots, s_{n_\tau}, s_f) \in \mathcal{T}$ 。根据细致平衡条件，我们有

$$\prod_{t=0}^{n_\tau} \mathcal{P}_B(s_t | s_{t+1}) = \prod_{t=0}^{n_\tau} \frac{\mathcal{F}(s_t) \mathcal{P}_F(s_{t+1} | s_t)}{\mathcal{F}(s_{t+1})} = \frac{\mathcal{F}(s_0)}{\mathcal{F}(s_f)} \prod_{t=0}^{n_\tau} \mathcal{P}_F(s_{t+1} | s_t) = \prod_{t=0}^{n_\tau} \mathcal{P}_F(s_{t+1} | s_t).$$

最终方程是因为状态流 $\mathcal{F}$ 是由 $\mathcal{P}_B$ 和 $\mathcal{F}(s_f)$ 诱导的，因此根据命题 3.6 我们得到 $\mathcal{F}(s_f) = \mathcal{F}(s_0)$ 。从而命题得证。

附录 A.6. 命题 3.12 的证明

首先注意到，在求和中不包括 s_0 和 s_f 只是轨迹长度定义的问题，正如在 2.1 节中所述，我们不将其首尾状态计入其中。利用轨迹长度等于访问图中每个独立状态次数之和的事实，我们得出

$$\mathbb{E}_{\tau \sim \mathcal{P}}[n_\tau] = \mathbb{E}_\tau \left[\sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \sum_{t=0}^{n_\tau+1} \mathbb{I}\{s_t = s\} \right] = \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathbb{E}_\tau \left[\sum_{t=0}^{n_\tau+1} \mathbb{I}\{s_t = s\} \right] = \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \frac{\mathcal{F}(s)}{\mathcal{F}(s_f)}.$$

附录 A.7. 带熵正则化的强化学习与定理 3.13

关于带熵正则化的强化学习的背景。令 $\mathcal{M}_G$ 是一个由图 G 诱导的确定性马尔可夫决策过程，其状态空间 $\mathcal{S}$ 对应于 G 的顶点，每个状态 s 的动作空间 $\mathcal{A}_s$ 对应于 s 的出边，与 $\text{out}(s)$ 相关联，并令 $\lambda > 0$ 为一个正则化系数。我们将策略 π 定义为从每个状态 $s \in \mathcal{S}$ 到 $\mathcal{A}_s$ 上的概率测度 $\pi(\cdot | s)$ 的映射。

然后，对于任何策略 π ，我们定义所有状态 $s \neq s_f$ 的正则化价值函数如下

$$V_\lambda^\pi(s) \triangleq \mathbb{E}_{\tau \sim \mathcal{P}_\pi} \left[\sum_{t=0}^{n_\tau} r(s_t, s_{t+1}) + \lambda \mathcal{H}(\pi(\cdot | s_t)) \mid s_0 = s \right], \quad (13)$$

并且 $V_\lambda^\pi(s_f) = 0$ ，其中 $\mathcal{H}$ 是香农熵， $\mathcal{P}_\pi$ 是由以下策略诱导的轨迹分布 $\pi: s_t \sim \pi(\cdot | s_{t-1})$ ，对于所有 $t \geq 1$ ，起始状态 s_0 固定为 s （不要与在 G 中的初始状态混淆），并且 n_τ 是 $\mathcal{A}_s$ 轨迹长度定义为 $n_\tau = \min\{k \geq 0 \mid s_{k+1} = s_f\}$ 。总体而言，当不使用折扣时，价值函数是否是一个明确定义的函数尚不清楚（ $\gamma = 1$ ）。我们将这个问题称为正则化最短路径问题，类似于最短路径和随机最短路径问题（Bertsekas, 2012，第三章）。如果策略 π^* 最大化 $V_\lambda^\pi(s_0)$ ，则称其为最优策略。

引理 A.1。假设 (i) 图 G 满足假设 3.1，以及 (ii) 对于任意的 $s \in \mathcal{S}, s' \in \mathcal{A}_s$ 成立 $r(s, s') \leq 0$ ，并且当且仅 $r(s, s') = 0$ 当 $|s'| = 1$ 中。另外，假设对于任何最优策略 π^* 成立 $\mathbb{E}_{\pi^*}[n_\tau] < +\infty$ 。

随后，一个正则化的最短路径问题具有唯一解，其解的值满足软最优贝尔曼方程

$$Q_\lambda^*(s, s') \triangleq r(s, s') + V^*(s'), \quad V_\lambda^*(s) \triangleq \lambda \log \left(\sum_{s' \in \text{out}(s)} \exp \left\{ \frac{1}{\lambda} Q_\lambda^*(s, s') \right\} \right), \quad (14)$$

最优策略可以表示为 $\pi^*(a|s) \propto \exp\{1/\lambda \cdot Q_\lambda^*(s, a)\}$ 。

证明。我们定义一个顶点的访问次数 s 以及一条边 s, s' 在 G 在一个给定的轨迹上 τ 如 $n_\tau(s) = \sum_{t=0}^{\infty} \mathbb{I}\{s_t = s\}$ 和 $n_\tau(s, s') = \sum_{t=0}^{\infty} \mathbb{I}\{s_t = s, s_{t+1} = s'\}$ 在与强化学习中的占用测度类比时，我们采用如下记号 $d^\pi(s) \triangleq \mathbb{E}_\pi[n_\tau(s)]$ 和 $d^\pi(s, s') \triangleq \mathbb{E}_\pi[n_\tau(s, s')]$ 对于预期访问次数。这一定义也对应于逆图中的流函数（参见定义 3.5）以及“反向策略” π 关于预期轨迹的条件

最优策略的长度表明我们可以仅考虑这些策略 π 使得 $d^\pi(s) < +\infty$ 对于任意 $d^\pi(s, s') < +\infty$. $s \in \mathcal{S} \setminus \{s_0, s_f\}$, 从而,

接下来, 我们将初始状态的价值函数重写如下

$$V_\lambda^\pi(s_0) = \sum_{s \in \mathcal{S} \setminus \{s_f\}} \sum_{s' \in \text{out}(s)} d^\pi(s, s') r(s, s') + \lambda \sum_{s \in \mathcal{S}} d^\pi(s) \mathcal{H}(\pi(\cdot|s)).$$

然后, 我们注意到 $d^\pi(s, s') = \pi(s'|s) \cdot d^\pi(s)$, 因此可以将价值重写为以下形式

$$V_\lambda^\pi(s_0) = \sum_{s \in \mathcal{S} \setminus \{s_f\}} \sum_{s' \in \text{out}(s)} d^\pi(s, s') r(s, s') - \underbrace{\lambda \sum_{s \in \mathcal{S}} \sum_{s' \in \text{out}(s)} d^\pi(s, s') \log \left(d^\pi(s, s') / \sum_{s' \in \text{out}(s)} d^\pi(s, s') \right)}_{R(d^\pi)}.$$

作为 $d^\pi(s, s')$ 的函数, 我们看到上述表达式的第一个项是线性的, 而第二个项是相对条件熵 (Neu 等人, 2017 年), 它是强凹的。鉴于所有可接受的 $d^\pi(s, s')$ 构成一个多面体, 该多面体定义为一组满足流匹配条件的负函数 (参见命题 3.6)

$$\mathcal{K} \triangleq \left\{ d: \mathcal{S} \times \mathcal{S} \rightarrow \mathbb{R}_+ \mid \sum_{s' \in \text{out}(s)} d^\pi(s, s') = \sum_{s'' \in \text{in}(s)} d^\pi(s'', s), \sum_{s' \in \text{out}(s_0)} d(s_0, s') = 1, \sum_{s'' \in \text{in}(s_f)} d(s'', s_f) = 1 \right\},$$

其中, 由于逆图中的命题 3.7, 流和策略具有一一对应关系。因为集合 $\mathcal{K}$ 是一个多面体, 对 $V_\lambda^\pi(s_0)$ 进行占据测度的优化是一个严格凸问题, 因此具有唯一的解 d^* , 这对应于唯一的策略 π^* 。

在证明最优贝尔曼方程之前, 我们希望展示 π^* 满足 $\pi^*(s'|s) > 0$ 对于任何 $s \in \mathcal{S}, s' \in \text{out}(s)$ 。为了做到这一点, 我们探索正则化的梯度, 使用 (Neu 等人, 2017 年), A.4 节中的计算: $\frac{\partial R(d^\pi)}{\partial d^\pi(s, s')} = \log \pi(s'|s)$ 。特别地, 这意味着当 $\pi(s'|s) \rightarrow 0$ 时, 那么 $\|\nabla_{d^\pi} \partial R(d^\pi)\| \rightarrow +\infty$, 因此最优策略 π^* 不能满足 $\pi^*(s'|s) = 0$, 因为它将违反最优性条件。

接下来, 我们希望证明最优策略的价值满足软最优贝尔曼方程。首先, 我们注意到通常的贝尔曼方程仍然成立, 因为 n_τ 是一个停止时间

$$Q_\lambda^\pi(s, s') = r(s, s') + V_\lambda^\pi(s'), \quad V_\lambda^\pi(s) = \sum_{s' \in \text{out}(s)} \pi(s'|s) Q_\lambda^\pi(s, s') + \lambda \mathcal{H}(\pi(\cdot|s)),$$

带有额外的初始条件 $V_\lambda^\pi(s_f) = 0$, 通过条件期望的性质。让我们考虑一个正则化策略改进操作, 定义为

$$\pi'(\cdot|s) \triangleq \arg \max_p \left\{ \sum_{s' \in \text{out}(s)} p(s') Q_\lambda^\pi(s, s') + \lambda \mathcal{H}(p) \right\} \propto \exp \left\{ \frac{1}{\lambda} Q_\lambda^\pi(s, \cdot) \right\}.$$

$(s_0) \geq V_\lambda^\pi(s_0)$ 然后我们希望展示 $V^{\pi'}$ 如果策略 π 是正的: $\pi(s'|s) > 0$ 对于所有 $s \in \mathcal{S}, s' \in \text{out}(s)$ 。我们从一个普遍不等式开始, 该不等式对任何

$$\begin{aligned} V_\lambda^{\pi'}(s) - V_\lambda^\pi(s) &= \left(\sum_{s' \in \text{out}(s)} \pi'(s'|s) Q_\lambda^{\pi'}(s, s') + \lambda \mathcal{H}(\pi'(\cdot|s)) \right) - \left(\sum_{s' \in \text{out}(s)} \pi(s'|s) Q_\lambda^\pi(s, s') + \lambda \mathcal{H}(\pi(\cdot|s)) \right) \\ &= \left(\sum_{s' \in \text{out}(s)} \pi'(s'|s) Q_\lambda^{\pi'}(s, s') + \lambda \mathcal{H}(\pi'(\cdot|s)) \right) - \left(\sum_{s' \in \text{out}(s)} \pi'(s'|s) Q_\lambda^\pi(s, s') + \lambda \mathcal{H}(\pi'(\cdot|s)) \right) \\ &\quad + \left(\sum_{s' \in \text{out}(s)} \pi'(s'|s) Q_\lambda^\pi(s, s') + \lambda \mathcal{H}(\pi'(\cdot|s)) \right) - \left(\sum_{s' \in \text{out}(s)} \pi(s'|s) Q_\lambda^\pi(s, s') + \lambda \mathcal{H}(\pi(\cdot|s)) \right) \\ &\geq \sum_{s' \in \text{out}(s)} \pi'(s'|s) [Q_\lambda^{\pi'}(s, s') - Q_\lambda^\pi(s, s')] = \sum_{s' \in \text{out}(s)} \pi'(s'|s) [V_\lambda^{\pi'}(s') - V_\lambda^\pi(s')]. \end{aligned}$$

经过 t 次展开后, 我们得到

$$V_{\lambda}^{\pi'}(s_0) - V_{\lambda}^{\pi}(s_0) \geq \mathbb{E}_{\tau \sim P_{\tau}^{\pi'}} \left[V_{\lambda}^{\pi'}(s_t) - V_{\lambda}^{\pi}(s_t) \right],$$

由于策略 π 为正, 则逆向图中的引理 3.4 表明 $d^{\pi}(s, s'), d^{\pi}(s) < +\infty$, 从而所有值和 Q 值均为有限: $Q^{\pi}(s, s') > -\infty$ 对于任意 $s \in \mathcal{S}, s' \in \text{out}(s)$ 。这表明 π' 也为正。因此, 其轨迹在概率 1 下是有限的, 并产生 $V_{\lambda}^{\pi'}(s_0) \geq V_{\lambda}^{\pi}(s_0)$ 。最后, 对 π^* 应用策略改进, 我们得出结论。 $\square$

定理 3.13 的证明。令 $\mathcal{P}$ 为由 GFlowNet 反向策略诱导的轨迹分布, 而 P_{τ}^{π} 为由 RL 策略 π 诱导的轨迹分布。然后, 我们使用条件期望的塔性质重写方程 (13), 将熵替换为策略的负对数

$$V_{\lambda=1}^{\pi}(s_0) = \mathbb{E}_{\tau \sim P_{\tau}^{\pi}} \left[\sum_{t=0}^{n_{\tau}} r(s_t, s_{t+1}) - \log \pi(s_{t+1} | s_t) \right].$$

注意到熵和奖励前面没有系数, 因为我们在定理陈述中设定了 $\gamma = 1, \lambda = 1$ 。通过简单的代数操作

$$V_{\lambda=1}^{\pi}(s_0) = \mathbb{E}_{\tau \sim P_{\tau}^{\pi}} \left[\sum_{t=0}^{n_{\tau}} \log \exp(r(s_t, s_{t+1})) - \log \pi(s_{t+1} | s_t) \right] = \mathbb{E}_{\tau \sim P_{\tau}^{\pi}} \left[\log \frac{\prod_{t=0}^{n_{\tau}} \exp(r(s_t, s_{t+1}))}{\prod_{t=0}^{n_{\tau}} \pi(s_{t+1} | s_t)} \right].$$

Next, we notice that $r(s, s') = \log \mathcal{P}_B(s | s')$ for all non-terminal s' and, $r(s, s_f) = \log \mathcal{R}(s) = \log \mathcal{P}_B(s | s_f) + \log \mathcal{Z}$ for 由于奖励匹配条件导致的终端转移。因此,

$$V_{\lambda=1}^{\pi}(s_0) = \log \mathcal{Z} - \mathbb{E}_{\tau \sim P_{\tau}^{\pi}} \left[\log \frac{\prod_{t=0}^{n_{\tau}} \pi(s_{t+1} | s_t)}{\prod_{t=0}^{n_{\tau}} P_B(s_t | s_{t+1})} \right] = \log \mathcal{Z} - \text{KL}(P_{\tau}^{\pi} | \mathcal{P}).$$

这里 $\mathcal{P}$ 是由 $\mathcal{P}_B$ (7) 诱导的轨迹分布。我们注意到最终方程与 (Tiapkin 等, 2024 年) 命题 1 中的方程相同, 适用于有向无环图的情况。

因此, 一个最优策略 π^* 达到最大值的 $V_{\lambda=1}^{\pi}(s_0)$ 是最小化 $\text{KL}(P_{\tau}^{\pi} | \mathcal{P})$ 通过引理 3.4 任何最优策略的预期轨迹长度 π^* 与之匹配 $\mathcal{P}$ 是有限的。因此, 根据命题 3.8, 存在唯一的前向策略 $\mathcal{P}_F$ 诱导相同的轨迹分布作为 $\mathcal{P}_B$ 这等价于实现 KL 发散为零。因此, π^* 与 $\mathcal{P}_F$ 一致。通过解的唯一性 (见引理 A.1), 我们得出结论。为了应用引理 A.1, 不失一般性, 我们可以假设 GFlowNet 奖励函数 $\mathcal{R}$ 是归一化的, 即 $\mathcal{Z} = 1$ 和 $\log \mathcal{R}(x) < 0$ 。确实, 由于终止转换 $x \rightarrow s_f$ 总是恰好被访问一次, 这等价于从所有终端奖励中减去 $\log \mathcal{Z}$, 这不会改变最优策略, 并将所有值修改相同的常数。

接下来, 考虑非终止转换的软最优贝尔曼方程 (14)

$$Q_{\lambda=1}^*(s, s') = \log \mathcal{P}_B(s | s') + \log \sum_{s'' \in \text{out}(s')} \exp(Q_{\lambda=1}^*(s', s'')).$$

我们将证明 $Q_{\lambda=1}^*$ 满足 $Q_{\lambda=1}^*(s, s') = \log \mathcal{F}(s \rightarrow s')$ 足这些方程。

$$\begin{aligned} \log \mathcal{F}(s \rightarrow s') &= \log \mathcal{F}(s') + \log \mathcal{P}_B(s | s') = \log \sum_{s'' \in \text{out}(s')} \mathcal{F}(s' \rightarrow s'') + \log \mathcal{P}_B(s | s') \\ &= \log \mathcal{P}_B(s | s') + \log \sum_{s'' \in \text{out}(s')} \exp(\log \mathcal{F}(s' \rightarrow s'')). \end{aligned}$$

这里我们使用了命题 3.6 中的方程。对于终止转换, 我们简单地有 $Q_{\lambda=1}^*(s, s_f) = r(s, s_f) = \log \mathcal{R}(s) = \log \mathcal{F}(s \rightarrow s_f)$ 。由于存在唯一的软最优贝尔曼方程的解, 我们已经证明了 $Q_{\lambda=1}^*(s, s') = \log \mathcal{F}(s \rightarrow s')$ 。至于状态流, 我们有

$$V_{\lambda=1}^*(s) = \log \sum_{s' \in \text{out}(s)} \exp(Q_{\lambda=1}^*(s, s')) = \log \sum_{s' \in \text{out}(s)} \exp(\log \mathcal{F}(s \rightarrow s')) = \log \mathcal{F}(s).$$

因此证明完成。 $\square$

附录 B 算法细节

附录 B.1 训练策略和流权重

回忆优化问题 (11):

$$\begin{aligned} \min_{\mathcal{F}, \mathcal{P}_F, \mathcal{P}_B} \quad & \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathcal{F}(s) \\ \text{subject to} \quad & \left(\log \frac{\mathcal{F}(s) \mathcal{P}_F(s' | s)}{\mathcal{F}(s') \mathcal{P}_B(s | s')} \right)^2 = 0, & \forall s \rightarrow s' \in \mathcal{E}, \\ & \mathcal{F}(s_f) \mathcal{P}_B(x | s_f) = \mathcal{R}(x), & \forall x \rightarrow s_f \in \mathcal{E}. \end{aligned}$$

现在, 假设使用 DB 损失 (4) 和状态流正则化 (12) 进行训练是在策略上的, 即轨迹是使用已训练策略收集的 $\mathcal{P}_F$ 。让我们写出轨迹上损失梯度的期望值 (请注意, 正则化不应用于 $\mathcal{F}(s_0)$ 和 $\mathcal{F}(s_f)$)

$$\mathbb{E}_{\tau \sim \mathcal{P}_F} \left[\sum_{t=0}^{n_\tau} \nabla_\theta \left(\log \frac{\mathcal{F}_\theta(s) \mathcal{P}_F(s_{t+1} | s_t, \theta)}{\mathcal{F}_\theta(s_{t+1}) \mathcal{P}_B(s_t | s_{t+1}, \theta)} \right)^2 + \sum_{t=1}^{n_\tau} \lambda \nabla_\theta \mathcal{F}_\theta(s_t) \right],$$

这可以重写为

$$\mathbb{E}_{\tau \sim \mathcal{P}_F} \left[\sum_{t=0}^{n_\tau} \nabla_\theta \mathcal{L}_{\text{DB}}(s_t \rightarrow s_{t+1}) \right] + \lambda \mathbb{E}_{\tau \sim \mathcal{P}_F} \left[\sum_{t=1}^{n_\tau} \nabla_\theta \mathcal{F}_\theta(s_t) \right].$$

第一项是标准 DB 损失的预期梯度。至于第二项, 我们注意到如果 $\mathcal{F}_\theta$ 恰好是由 $\mathcal{P}_F$ 诱导的状态流, 我们有

$$\begin{aligned} \mathbb{E}_{\tau \sim \mathcal{P}_F} \left[\sum_{t=1}^{n_\tau} \nabla_\theta \mathcal{F}_\theta(s_t) \right] &= \mathbb{E}_{\tau \sim \mathcal{P}_F} \left[\sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \sum_{t=0}^{n_\tau} \mathbb{I}\{s_t = s\} \nabla_\theta \mathcal{F}_\theta(s) \right] \\ &= \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \nabla_\theta \mathcal{F}_\theta(s) \mathbb{E}_{\tau \sim \mathcal{P}_F} \left[\sum_{t=0}^{n_\tau} \mathbb{I}\{s_t = s\} \right] \\ &= \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \frac{\mathcal{F}_\theta(s)}{\mathcal{F}_\theta(s_f)} \nabla_\theta \mathcal{F}_\theta(s) = \frac{1}{2\mathcal{F}_\theta(s_f)} \nabla_\theta \left(\sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathcal{F}_\theta(s)^2 \right). \end{aligned}$$

这意味着在线策略训练试图最小化状态流平方和而不是状态流和。这种情况发生的原因在于用于收集训练数据的轨迹分布 (在这种情况下由 $\mathcal{P}_F$ 诱导) 访问某些状态比其他状态更频繁, 因此在每个状态中的流动赋予了一个权重, 等于预期访问次数。然而, 如果将 $\mathcal{P}_F(s | s_0)$ 固定为在整个 $\mathcal{S} \setminus \{s_0, s_f\}$ 上均匀分布 (参见第 4 节和附录 B.3), 可以通过仅在每个采样轨迹的第一个状态应用流动正则化来规避这一问题。这样, 在预期损失中每个状态中的 $\mathcal{F}_\theta(s)$ 将被赋予相等的权重, 因此我们将最小化状态流之和。然而, 在我们的实验中, 我们注意到这不会显著影响结果, 所以我们把探索这一现象作为进一步的研究方向。

附录 B.2. 损失缩放与稳定性

在本节中, 我们提供了对我们缩放假设的更详细解释 (参见第 4 节)。考虑一个学习 $\mathcal{F}, \mathcal{P}_F$ 和 $\mathcal{P}_B$ 的 GFlowNet。由于这些量由神经网络预测, 一种标准的方法是让其预测前向策略的对数几率、后向策略的对数几率以及状态流的对数。流动函数总是正值, 因此, 以对数尺度预测它们是一个自然的方法 (Bengio 等人, 2021; 2023)。然后, 对于任何转换 $s \rightarrow s'$, 定义两个量:

$$\begin{aligned} \Delta_{\log \mathcal{F}}(s, s', \theta) &\triangleq \log \mathcal{F}_\theta(s) + \log \mathcal{P}_F(s' | s, \theta) - \log \mathcal{F}_\theta(s') - \log \mathcal{P}_B(s | s', \theta), \\ \Delta_{\mathcal{F}}(s, s', \theta) &\triangleq \exp(\log \mathcal{F}_\theta(s) + \log \mathcal{P}_F(s' | s, \theta)) - \exp(\log \mathcal{F}_\theta(s') + \log \mathcal{P}_B(s | s', \theta)). \end{aligned} \tag{15}$$




图 3. 在 $\Delta \mathcal{F}$ 和 $\Delta \log \mathcal{F}$ 尺度下, DB 和 SDB 损失的曲线图, 其中预测的对数后向流动 = 1 固定, 而预测的对数前向流动变化。具体来说, 绿色曲线是 $y = (x-1)^2$, 红色曲线是 $y = (e^x - e^1)^2$, 棕色曲线是 $y = \log(1 + (x-1)^2) \cdot (1 + 0.001e^x)$, 蓝色曲线是 $y = \log(1 + (x-1)^2) \cdot (1 + 0.001e^x)$ 。

第一个是前向和后向方向的预测流动对数之间的差异 $\log \mathcal{F}_F - \log \mathcal{F}_B$, 而第二个是前向和后向方向的预测流动之间的差异 $\mathcal{F}_F - \mathcal{F}_B$ 。然后, 标准 DB 损失 (4) 是 $\mathcal{L}_{\text{DB}}(s \rightarrow s') = \Delta_{\log \mathcal{F}}(s, s', \theta)^2$, 而 SDB 损失 (4) 是在 (Brunswic 等人, 2024) 中提出的

$$\mathcal{L}_{\text{SDB}}(s \rightarrow s') = \log(1 + \varepsilon \Delta_{\mathcal{F}}(s, s', \theta)^2) \cdot (1 + \eta \mathcal{F}_{\theta}(s)).$$

然而, 对于这两种损失函数, 可以将 $\Delta \log \mathcal{F}$ 替换为 $\Delta \mathcal{F}$, 或者反过来。为了可视化, 我们将预测的对数反向流 $\mathcal{F}_B$ 固定为例如 1, 并绘制出随着预测的对数正向流 $\mathcal{F}_F$ 变化的损失函数。这些图示在图 3 中展示。可以看出, 当参数 $\log \mathcal{F}_F$ 减小时, $\Delta \mathcal{F}$ 中的两种损失迅速趋于平稳, 因此它们的导数趋近于零。从优化的角度来看, 这意味着当需要增加预测的对数流时, 梯度步长会非常小, 因为损失的导数几乎为零。另一方面, 当需要减少预测的对数流时, 梯度步长会更大, 因为在相应区域损失具有更高的导数。结合命题 3.12, 这为 $\Delta \mathcal{F}$ 尺度损失的稳定性提供了一种可能的解释: 它们倾向于低估流, 从而偏向于具有更短预期轨迹长度的解。我们注意到, 同样的推理也可以应用于 (Brunswic 等, 224 年) 提出的稳定流匹配损失, 因为它也操作 $\Delta \mathcal{F}$ 尺度下的流之间的差异。

然而, 正如我们在实验评估 (第 4 节) 中所展示的那样, 这以学习 GFlowNets 与奖励分布匹配不准确为代价。

B.3. Fixed $\mathcal{P}_B$ and Trainable $\mathcal{P}_B$

在非有向无环图环境中, s_0 和 s_f 通常是非真实状态, 不对应任何对象。那么 $\mathcal{P}_F(s_f | s)$ 对应于在状态 s 终止轨迹的概率, 而 $\mathcal{P}_F(s | s_0)$ 对应于轨迹从状态 s 开始的概率。因此, 在环境设计中, 选择 $\text{out}(s_0)$ 至关重要。如果这个集合很大, 例如与 $\mathcal{S} \setminus \{s_0, s_f\}$ 重合, 则需要将 $\mathcal{P}_F(s | s_0)$ 固定为某种分布, 例如均匀分布, 否则学习变得不可行。然而, 在这种情况下, $\mathcal{P}_B(s_0 | s)$ 必须可训练, 否则可能无法满足过渡 $s_0 \rightarrow s$ 的细致平衡条件。

在我们的实验中, 我们考虑两种设置: 使用固定的 $\mathcal{P}_B$ 进行训练和使用可训练的 $\mathcal{P}_B$ 。

在固定 $\mathcal{P}_B$ 的情况下, 我们考虑当输出为 $s_0 = \{s_{\text{init}}\}$ 的情形, 其中 s_{init} 是某个固定的状态 $\in \mathcal{S} \setminus \{s_0, s_f\}$ 。因此, 所有轨迹的第一个转换是从 s_0 到 s_{init} 。然后, 对于任意 $s \in \mathcal{S} \setminus \{s_0, s_f, s_{\text{init}}\}$, $\mathcal{P}_B(\cdot | s)$ 来说, 在 s 的父节点上是均匀分布的, 而 $\mathcal{P}_B(s_0 | s_{\text{init}}) = 1 - \varepsilon$ 对于某个小的 $\varepsilon > 0$ 和 $\mathcal{P}_B(s | s_{\text{init}}) = \varepsilon / (\text{在其他转换中输入为 } s_{\text{init}} - 1)$ 的情形 $s \rightarrow s_{\text{init}}$ 。

对于可训练的 $\mathcal{P}_B$ ，我们考虑当输出为 $s_0 = \mathcal{S} \setminus \{s_0, s_f\}$ 的情况。这里我们将第一次正向转移概率固定为均 $\mathcal{P}_F(s | s_0)$ 匀分布于 $\mathcal{S} \setminus \{s_0, s_f\}$ 。在这种情况下，第一次转移的 DB 损失具有特殊形式：

$$\mathcal{L}_{DB}(s_0 \rightarrow s) \triangleq \left(\log \mathcal{Z}_\theta - \log |\mathcal{S} \setminus \{s_0, s_f\}| - \log \mathcal{P}_B(s_0 | s, \theta) - \log \mathcal{F}_\theta(s) \right)^2, \quad (16)$$

其中 $\log \mathcal{Z}_\theta - \log |\mathcal{S} \setminus \{s_0, s_f\}|$ 对应于 $\log \mathcal{F}_\theta(s_0) + \log \mathcal{P}_F(s | s_0)$ 。一个重要的注意事项是，最优解中的 $\log \mathcal{F}_\theta(s_0)$ 总是与 $\log \mathcal{Z}$ 一致；因此，通常对它应用状态流正则化 (12) 是有害的。

B.4. 精确求解小型环境

假设我们有一个固定的反向策略 $\mathcal{P}_B$ 和最终流 $\mathcal{F}(s_f)$ 。那么，对于小型环境，可以精确地获得诱导流 $\mathcal{F}$ 以及相应的正向策略 $\mathcal{P}_F$ 。考虑由命题 3.6 得出的关于 $\hat{\mathcal{F}}(s)$ 的线性方程组：

$$\begin{cases} \hat{\mathcal{F}}(s) = \sum_{s' \in \text{out}(s)} \mathcal{P}_B(s | s') \hat{\mathcal{F}}(s'), \forall s \in \mathcal{S} \setminus \{s_f\}, \\ \hat{\mathcal{F}}(s_f) = \mathcal{F}(s_f). \end{cases} \quad (17)$$

该系统有 $|\mathcal{S}|$ 个变量和 $|\mathcal{S}|$ 个方程。 $\hat{\mathcal{F}}(s) = \mathcal{F}(s)$ 是一个解，其中 $\mathcal{F}(s)$ 是由 $\mathcal{P}_B$ 和 $\mathcal{F}(s_f)$ 诱导的状态流，解的唯一性来自于命题 3.7。因此，通过求解该系统，可以精确找到诱导状态流。然后，根据命题 3.6 和命题 3.8，边流和 $\mathcal{P}_F$ 也可以精确表示为

$$\mathcal{F}(s \rightarrow s') = \mathcal{P}_B(s | s') \mathcal{F}(s'), \quad \mathcal{P}_F(s' | s) = \mathcal{P}_B(s | s') \mathcal{F}(s') / \mathcal{F}(s).$$

最后，根据推论 3.12，可以找到诱导轨迹分布的预期轨迹长度 $\mathcal{P}$ 为：

$$\mathbb{E}_{\tau \sim \mathcal{P}}[n_\tau] = \frac{1}{\mathcal{F}(s_f)} \sum_{s \in \mathcal{S} \setminus \{s_0, s_f\}} \mathcal{F}(s).$$

有趣的是，系统 (17) 也可以从马尔可夫链的角度进行解释。让我们取图 $\mathcal{G}$ 并反转其边，从 s_0 到自身添加一个循环，并使用 $\mathcal{P}_B$ 定义具有以下转移矩阵的马尔可夫链：如果存在边 $s \rightarrow s'$ ，则为 $P(s_0 | s_0) = 1, P(s | s') = \mathcal{P}_B(s | s')$ ，否则为 $P(s | s') = 0$ 。这将是一个吸收马尔可夫链，唯一的吸收状态为 s_0 ，因为根据假设 3.1，它可以由任何其他状态到达。转移矩阵可以写成如下形式：

$$P = \left[\begin{array}{c|c} Q & R \\ \hline \mathbf{0} & 1 \end{array} \right]$$

其中 Q 是 $a |\mathcal{S}| - 1$ 为 $|\mathcal{S}| - 1$ 矩阵， R 是 $a |\mathcal{S}| - 1$ 为 1 矩阵。其基础矩阵 N ，即这样一个矩阵，使得 $N_{s,s'}$ 等于从非吸收状态 s 开始在被吸收之前访问非吸收状态 s' 的预期次数，可以通过以下方式获得：

$$N = \sum_{k=0}^{+\infty} Q^k = (I - Q)^{-1},$$

其中 $I - Q$ 始终可逆 (Kemeny & Snell, 1969, 定理 3.2.1)。可以注意到，归一化的流 $\mathcal{F}(s)/\mathcal{F}(s_f)$ 与从 s 开始访问 s_f 的期望次数一致，因此与矩阵 N 中对应于 s_f 的那一行一致。最后，注意到 $(I - Q)$ 与截断系统 (17) 的转置矩阵一致（除了对应于 s_0 的变量和方程外），因此，该系统具有唯一解 $\mathcal{F}(s_f)(I - Q)^{-T} e_{s_f} = \mathcal{F}(s_f) N^T e_{s_f}$ ，其中 e_{s_f} 是一个大小为 $|\mathcal{S}| - 1$ 的向量，在对应于 s_f 的位置上为 1，其余位置为 0。对应于 s_0 的变量应单独处理，但很容易看出 $\hat{\mathcal{F}}(s_0) = \sum_{s' \in \text{out}(s)} \mathcal{P}_B(s | s') \hat{\mathcal{F}}(s') = \mathcal{F}(s_0)$ 。

C. 实验详情

C.1. 损失函数的选择

虽然 (Brunswick 等, 2024) 在实验评估中使用了原始的流匹配损失 (Bengio 等, 2021)，但之前的研究已经表明，与其他 GFlowNet 损失相比，该损失计算效率较低，并且收敛速度较慢 (Malkin

et al., 2023; Madan 等人, 2023) 在无环情况下进行了研究, 因此我们在更广泛使用的细致平衡损失 (Bengio 等人, 2023) 上进行实验评估。此外, 流匹配损失无法显式参数化反向策略, 也不支持使用固定反向策略进行训练, 这使得我们无法研究实验中探索的一些现象。

此外, 我们注意到所提出的状态流正则化 (12) 可能适用于其他学习流的 GFlowNet 损失函数, 例如 SubTB (Madan 等, 2023), 或者与 (Deleu 等, 2022) 中对 DB 的修改相结合, 该修改隐式参数化流作为 $\mathcal{F}(s) = \mathcal{R}(s)/\mathcal{P}_F(s_f | s)$ 。

C.2. 超网格

形式上, $\mathcal{S} \setminus \{s_0, s_f\}$ 是一个包含整数坐标的点集, 位于一个边长为 H 的 D 维超立方体内。· s_0 和 s_f 是辅助状态, 不对应于网格内的任何点。可能的状态转换对应于增加或减少任一坐标值 1 而不离开网格。此外, 对于每个状态 $s \in \mathcal{S} \setminus \{s_0, s_f\}$, 存在一个终止转换 $s \rightarrow s_f$ 。GFlowNet 在状态 $s = (s^1, \dots, s^D)$ 处的奖励定义为

$$\mathcal{R}(s) \triangleq R_0 + R_1 \prod_{i=1}^D \mathbb{I} \left[0.25 < \left| \frac{s^i}{H-1} - 0.5 \right| \right] + R_2 \prod_{i=1}^D \mathbb{I} \left[0.3 < \left| \frac{s^i}{H-1} - 0.5 \right| < 0.4 \right],$$

在 Brunswic 等人 (2024) 的研究中, 并未明确指定实验中使用的奖励参数, 因此我们采用了 (Malkin 等, 2024) 研究中所用的无环环境版本的参数 $0 < R_0 \ll R_1 < R_2$ 。 (Brunswic 等人 (2024) 并未具体说明其实验中使用的奖励参数, 故我们使用了 (Malkin 等, 2024) 研究中无环环境版本的参数, 2022), i.e. ($R_0 = 10^{-3}, R_1 =$

所用度量: 1 2

$$- \sum_{x \in \mathcal{X}} |\mathcal{R}(x)/\mathcal{Z} - \pi(x)|,$$

其中 $\pi(x)$ 是训练过程中观察到的最后一个 $2 \cdot 10^5$ 样本的经验分布 (从 $\mathcal{P}_F$ 采样的轨迹端点)

所有模型均由具有两层隐藏层和 256 个隐藏单元的多层感知机参数化, 接受 s 的一热编码作为输入。 $\mathcal{F}_\theta(s), \mathcal{P}_F(s' | s, \theta), \mathcal{P}_B(s | s', \theta)$ 共享相同的主干结构, 不同的线性头预测状态流的对数、正向策略的对数和反向策略的对数。在固定的情形下, $\mathcal{P}_B, s_{\text{init}}$ 对应于网格的中心, 我们取 $\varepsilon = 10^{-8}$ (见附录 B.3)。

我们对所有模型进行在线训练。我们使用 Adam 优化器, 学习率为 10^{-3} , 批大小为 16 (每次训练步骤采样的轨迹数量)。对于 $\log \mathcal{Z}_\theta$, 我们使用较大的学习率 10^{-2} (参见 (Malkin et al., 2022))。所有模型均训练至采样到 $2 \cdot 10^6$ 条轨迹, 并在训练过程中最后见到的 $2 \cdot 10^5$ 个样本上计算经验样本分布 $\pi(x)$ 。对于 SDB, 我们将 $\varepsilon = 1.0$ 和 $\eta = 10^{-3}$ 设为特定值。我们发现, 使用较大的 η 值可能导致预期轨迹长度变小, 但也会显著干扰所学 GFlowNet 的采样保真度, 因此我们在实验中选择这些值。

附录 C.3. 排列

所有模型均由具有两层隐藏层和 128 个隐藏单元的多层感知机参数化, 接受 s 的一热编码作为输入。 $\mathcal{F}_\theta(s), \mathcal{P}_F(s' | s, \theta), \mathcal{P}_B(s | s', \theta)$ 共享相同的主干结构, 不同的线性头预测状态流的对数、正向策略的对数和反向策略的对数。在固定的情形下, $\mathcal{P}_B, s_{\text{init}}$ 对应于排列 $(n, n-1, \dots, 2, 1)$, 我们取 $\varepsilon = 10^{-8}$ (见附录 B.3)。

我们对所有模型进行在线训练。我们使用 Adam 优化器, 学习率为 10^{-3} , 批大小为 512 (每次训练步骤采样的轨迹数量)。我们发现, 较小的批大小会显著影响此环境下的训练稳定性; 因此, 我们选择较大的数值。所有模型训练迭代次数为 10^5 。对于 $\log \mathcal{Z}_\theta$, 我们使用较大的学习率 10^{-2} (参见 (Malkin et al., 2022))。为了计算 $\Delta \log \mathcal{Z}$, 我们取最后 10 个训练检查点上 $\log \mathcal{Z}_\theta$ 的平均值。经验分布 $\hat{C}(k)$ 是在训练过程中最后 10^5 个样本上计算得出的。对于 SDB, 我们设置 $\varepsilon = 1.0$ 和 $\eta = 10^{-3}$ 。我们发现, 使用较大的 η 值会导致预期轨迹长度变小, 但也会显著干扰所学 GFlowNet 的采样精度, 因此我们在实验中选择这些值。

假设 $x_1, \dots, x_m$ 是一组 GFlowNet 样本 (从 $\mathcal{P}_F$ 采样的轨迹的终端状态)。那么, 经验

L_1 固定点概率的误差定义为:

$$\sum_{k=0}^N \left| C(k) - \frac{1}{m} \sum_{i=1}^m \mathbb{I}\{x_i(k) = k\} \right|,$$

相对平均奖励误差定义为

$$\left| \frac{\mathbb{E}[\mathcal{R}(x)] - \frac{1}{m} \sum_{i=1}^m \mathcal{R}(x_i)}{\mathbb{E}[\mathcal{R}(x)]} \right|,$$

其中 $\mathbb{E}[\mathcal{R}(x)] = \sum_{x \in \mathcal{X}} \mathcal{R}(x) \frac{\mathcal{R}(x)}{\mathcal{Z}}$. 我们在 10^4 个样本上计算平均奖励。

C.3.1. 奖励分布属性 我们将 GFlowNet 奖励定义为 $\mathcal{R}(s) = \exp(\frac{1}{2})$. 我们感兴趣的是三个量的真实值:

$$\sum_{k=1}^n \mathbb{I}\{s(k) = k\}$$

1. normalizing constant $\mathcal{Z} = \sum_{x \in \mathcal{X}} \mathcal{R}(x)$,

2. true expected reward $\mathbb{E}[\mathcal{R}(x)] = \sum_{x \in \mathcal{X}} \mathcal{R}(x) \frac{\mathcal{R}(x)}{\mathcal{Z}}$, 3. 固定点概率 $C(k) = \mathbb{P}((\sum_{i=1}^n \mathbb{I}\{x(i) = i\}) = k)$ 相对于奖励分布。

虽然对所有排列进行求和的计算是不可行的 n 当超过某个阈值时, 对于这一特定奖励, 我们可以推导出这些量的解析表达式。

首先, 我们将推导出长度为 n 且恰好有 k 个不动点的所有排列总数的公式, 记为 $D(k, n)$ 。在组合数学中, 这样的排列被称为部分错位排列, 这个数量被称为相遇数 (Comtet, 1974, p.180)。需要注意的是

$$D(k, n) = \binom{n}{k} D(0, n-k),$$

选择一个具有 k 个不动点的排列等同于选择 k 个不动点的位置, 并将剩余元素排列使得它们之间没有不动点。因此, 我们从推导 $D(0, n)$ 开始。设 S_i 为在位置 i 上有不动点的 n 个元素的排列集合。然后, 根据包含-排除原理, 我们有

$$\begin{aligned} |S_1 \cup \dots \cup S_n| &= \sum_i |S_i| - \sum_{i < j} |S_i \cap S_j| + \sum_{i < j < k} |S_i \cap S_j \cap S_k| - \dots + (-1)^{n+1} |S_1 \cap \dots \cap S_n| \\ &= \binom{n}{1} (n-1)! - \binom{n}{2} (n-2)! + \binom{n}{3} (n-3)! - \dots + (-1)^{n+1} \binom{n}{n} 0! \\ &= \sum_{i=1}^n (-1)^{i+1} \binom{n}{i} (n-i)! = n! \sum_{i=1}^n \frac{(-1)^{i+1}}{i!}. \end{aligned}$$

于是

$$D(0, n) = n! - |S_1 \cup \dots \cup S_n| = n! - n! \sum_{i=1}^n \frac{(-1)^{i+1}}{i!} = n! \sum_{i=0}^n \frac{(-1)^i}{i!}.$$

因此, 我们得到

$$D(k, n) = \binom{n}{k} D(0, n-k) = \frac{n!}{k!(n-k)!} (n-k)! \sum_{i=0}^{n-k} \frac{(-1)^i}{i!} = n! \sum_{i=0}^{n-k} \frac{(-1)^i}{i!k!}.$$

最后, 我们感兴趣的全部量都可以通过 $D(k, n)$ 轻松表示:

1. $\mathcal{Z} = \sum_{k=0}^n D(k, n) \exp(k/2)$.
2. $\mathbb{E}[\mathcal{R}(x)] = \sum_{k=0}^n D(k, n) \exp(k/2) \frac{\exp(k/2)}{\mathcal{Z}}$.
3. $C(k) = D(k, n) \frac{\exp(k/2)}{\mathcal{Z}}$.

作为参考, 该公式给出了对于 $n = 4, n = 8$, 分别对应的 $\log \mathcal{Z} \approx 3.8262, 11.2533, 42.9843$ 的值为 $n = 20$ 。

附录 D. 额外的图表




图 4. 左：演化过程 L^1 样本经验分布与目标分布之间的距离。右侧：采样轨迹平均长度的演变。这里我们注意到当 $\Delta \log \mathcal{F}$ 在未使用状态流正则化的情况下，缩放损失被采用，平均轨迹长度趋向于无穷大。由于训练是在策略上进行的，因此图表不完整。相应地，完整的训练所需时间也随着轨迹长度的增长而增加。




图 5. 左：演化过程 L^1 样本经验分布与目标分布之间的距离。右侧：采样轨迹平均长度的变化。此处，我们观察到不同强度状态流正则化的影响 λ 较大的值 λ 导致平均轨迹长度减小，然而，如果 λ 如果过大，所获得的前向策略将显著偏倚。




图 6. 小排列环境上非循环 GFlowNet 训练损失的比较。左：真实和固定点概率的经验分布之间的 L^1 距离的演变 $C(k)$ 。右：采样轨迹平均长度的演变。结果与在超网格上的相同实验（图 1）相似，唯一的区别是这里的 SDB 损失在 $\Delta \mathcal{F}$ 尺度下具有快速收敛，并且有一个可训练的后向策略。