

f -Trajectory Balance: A Loss Family for Tuning GFlowNets, Generative Models, and LLMs with Off- and On-Policy Data

杰克·福克斯¹ 杰森·哈特福德^{2,3}

摘要

在 GFlowNets 和变分推断中，已经证明目标和模型对数概率之间的均方误差是一种有效的、低方差的替代损失，用于训练生成模型。这种损失具有这样的性质：当在策略上评估时，其梯度与 KL 发散的梯度相对应，而在离策略时仍然是一个有效的损失，并具有相同的全局最小值。在这项工作中，我们展示了这种构造可以扩展到整个家族的 f -发散，从而形成一组损失，其在策略上的梯度是相应 f -发散的梯度，但在离策略时仍然保留相同的全局最小值。具体来说，我们展示了在策略上的梯度导致了目标和模型对数概率上的平移不变性损失函数与 f -发散之间的一一对应关系。这种等价性使我们能够设计新的替代损失函数，用于调整广泛的生成模型，这些损失函数继承了相应 f -发散的属性，如更全面地覆盖模式，同时适用于离策略数据。我们在一系列任务上应用我们的损失函数，包括经典的合成示例、用于分子发现的 SynFlowNets 以及异步大语言模型 (LLM) 微调，展示了我们的模型在广泛的生成模型中，在策略和离策略时都保留了预期的属性。

文本生成，或是生成流网络 (Generative Flow Networks) 生成分子图——依赖于最小化模型分布之间的差异。在强化学习 (Reinforcement Learning) 微调中，这一目标通常被表述为在 KL 发散惩罚条件下最大化期望奖励，或者等价地，最小化策略与目标分布之间的发散。

传统上，优化这些目标涉及具有高方差的梯度估计器，如 REINFORCE (Williams, 1992 年)，或复杂的策略梯度方法 (如 Schulman 等人, 2017 年)。然而，最近 GFlowNet 文献和 Kimi 团队的大规模 LLM 调优 (2025a 年) 采用了更简单的方法：最小化模型对数概率与目标之间的均方误差 (MSE)。这与 Schulman (2020 年) 提出的 $\mathbb{KL}$ 发散的 K2 估计器有相似之处，我们称之为 $\mathbb{KL}_{sq}$ 。Tang 和 Munos (2025 年) 指出，这种“平方 KL”损失具有一个令人惊讶的特性：虽然它对 $\mathbb{KL}$ 是一个有偏估计器，但在 on-policy 数据上的梯度是对真实 KL 梯度的无偏估计。此外，由于它是基于 MSE 构建的，当应用于 off-policy 数据时，它仍然是一个有效的损失函数，并具有相同的全局最小值 (Bartoldson 等人, 2020 年; Tang 等人, 2025 年)。

尽管 $\mathbb{KL}_{sq}$ 估计器提供了稳定性和 off-policy 兼容性，但其构造继承了反向 KL 发散的性质。特别是，在此目标下训练的模型通常表现出“模式寻找”行为，即模型倾向于集中在相对较少的高概率模式上，而不是覆盖目标分布的全部多样性。在许多生成任务中，如药物发现或探索性代理，“模式覆盖”行为往往更受欢迎，因为生成模型用于探索高奖励候选的空间 (例如所有可能的药物靶点)，而不是寻找一个 (或几个) 特别好的候选者。

在这项工作中，我们展示了 $\mathbb{KL}_{sq}$ 损失的有效性并非仅限于 KL 发散的独特现象，而是通过推导整个 f -发散族的类似损失来证明这一点。我们建立了理论等价性，表明任何对数概率上的平移不变损失函数都对应于特定的 f -发散。这使我们能够推导出一个新的替代损失函数族，

1. 引言

生成模型的对齐与微调——无论是大型语言模型 (LLMs) 生成的内容，都涉及 1 伦敦大学学院统计学系，英国 (实习期间在 Valence Labs 完成的工作)。2Valence Labs，伦敦，英国 3Recursion，伦敦，英国。通讯作者：Jake Fawkes <jakefawkes@gmail.com>，Jason Hartford <jason@valencelabs.com>。

Proceedings of the 43rd International Conference on Machine Learning, Seoul, South Korea. PMLR 306, 2026. Copyright 2026 by the author(s).




图 1. f -发散包括 α -发散族，其中包含正向 KL ($\alpha=0$) 和反向 KL/标准轨迹平衡 ($\alpha=1$) 作为特殊情况。较低的 α 产生更倾向于模式覆盖的损失，较高的 α 则产生更倾向于模式寻找的损失。

继承了其父发散的具体属性（例如，正向 KL 或 Hellinger 距离的模式覆盖行为），同时保留了 $\mathbb{KL}_{sq}$ 估计器的优化优势：on-policy 数据上的低方差梯度和 off-policy 数据的有效性。

我们展示了这一系列损失函数在多种任务中的行为和实用性。在 Hypergrid 任务 (Bengio 等, 2021) ——一个专门设计用于测试模式覆盖范围的合成任务——上，我们证明 Hellinger 和前向 KL 损失比由轨迹平衡损失 (Malkin 等, 2022b) 所暗示的逆向 KL 损失发现了更多的模式。随后，我们将这些损失应用于分子生成——通过修改 SynFlowNet (Cretu 等, 2025) 中的损失函数——扩散模型中的类别条件采样以及语言模型上的异步强化学习。在这两种情况下，我们发现能够利用我们替代损失函数家族中的模式覆盖实例来学习更高熵的策略。综上所述，我们的贡献如下：

- 我们推导出一类广义的平移不变替代损失函数族， $\mathcal{L}_f$ ，其期望自动微分梯度与相应的 f -发散在策略上的梯度相匹配。
- 我们证明了逆关系：任何关于对数概率的凸且平移不变的损失函数都对应于最小化特定的 f -发散。
- 本文将“Vargrad” (Richter 等, 2020 年) 和批量归一化技术推广到任意 f -发散，解决了强化学习微调中不可处理的配分函数问题。
- 本文将此框架应用于 GFlowNets，表明我们的损失函数推广了标准的轨迹平衡目标 (Malkin 等, 2022a)，并在合成网格和 SynFlowNet 上进行了经验验证。

我们可以控制探索与利用之间的权衡（模式搜索与模式覆盖）的分子发现任务，只需更改替代损失函数即可。

2. 相关工作

GFlowNets (GFlowNets) 与 GFlowNets 损失函数

Bengio 等人 (2021) 提出了 GFlowNets，并通过流匹配损失对其进行训练，该损失直接应用于旨在学习给定 GFlowNets 最优马尔可夫流的神经网络，并在动作层面上应用。详细的平衡目标由 Bengio 等人 (2023) 提出，再次在动作层面上应用，但参数化了一个正向和反向策略分布。Malkin 等人 (2022a) 提出了轨迹平衡，它在轨迹层面上强制执行正向策略、反向策略和归一化常数之间的等式约束，并使用均方误差进行惩罚。Malkin 等人 (2023) 表明，使用这种损失的在线训练等同于一种层次变分推断 (Ranganath 等人, 2016)，其中使用了 $\mathbb{KL}$ 发散。我们的结果将这些扩展到所有 f -发散。Vargrad 目标 (Richter 等人, 2020) 经常用于 GFlowNet 训练，它使用与 Malkin 等人 (2022a) 相同的平方误差形式，但在批量基础上估计归一化常数。这种 Vargrad 损失源自 (Nusken 和 Richter, 2021) 引入的日志方差发散，他们还提出了一种基于 Pearson χ^2 发散的方差估计器，这与我们的工作最为相似。然而，这不会共享我们在论文中展示的匹配在线策略梯度的相同属性，正确扩展这一属性的方法是使用广义偏差 (Rockafellar 等人, 2006)，而不是方差。最后，与我们的工作最相关的是 Silva 等人 (2024) 讨论了使用替代发散度量来训练 GFlowNets，然而他们的工作重点在于离线策略设置，在这种设置下，GFlowNets 的主要探索优势

来自离线策略训练。

f -发散与生成模型 f -发散 (Ali 和 Silvey, 1966; Morimoto, 1963) 在概率模型调优中有着悠久的历史 (Minka 等, 2005)。在生成模型的背景下, 它们被广泛应用于变分推断 (Wang 等, 2018) 以及生成对抗网络 (GANs) (Nowozin 等, 2016), 最近一些工作还将 f -发散应用于扩散模型的调优 (Novello 等, 2025; Tang, 2024)。 f -发散在大语言模型系统 (LLMs) 的背景下也被应用, 要么直接作为目标函数 (Go 等, 2023; Han 等, 2024), 要么作为正则化项 (Huang 等)。然而, 据我们所知, 这些工作中没有一个展示了离线策略的有效性, 这是一个重要方面, 因为许多大语言模型的调优是异步进行的 (Intellect, 2025) 或者完全离线策略。 f -发散也被广泛应用于模仿学习 (Ghasemipour 等, 2020; Ke 等, 2020), 这表明我们的工作可以应用于大语言模型的异步蒸馏 (Lu 和 Lab, 2025)。

3. 强化学习调优大语言模型的动机

强化学习 (RL) 调优大语言模型与 KL 梯度 我们将 π_θ 表示为一个给定提示 $\mathbf{x}$ 的序列 $\mathbf{y}$ 上的策略的大语言模型。然后通过最大化分布 $P(\mathbf{x})$ 上提示/状态 $\mathbf{x}$ 的奖励来使用强化学习调优此模型:

$$\mathcal{J}(\theta) = \mathbb{E}_{\mathbf{x} \sim P(\mathbf{x})} [\mathbb{E}_{\mathbf{y} \sim \pi_\theta(\mathbf{y}|\mathbf{x})} [r(\mathbf{x}, \mathbf{y})]], \quad (1)$$

$$- \beta \mathbb{KL}(\pi_\theta(\cdot|\mathbf{x}), \pi_{\text{ref}}(\cdot|\mathbf{x})). \quad (2)$$

该目标通常通过 PPO (Schulman 等, 2017) 或 REINFORCE (Williams, 1992) 进行优化。然而, 由于 Tang 和 Munos (2025) 指出当时许多开源实现的情况, 无法通过蒙特卡洛估计器的 $\mathbb{KL}$ 自动微分获得 $\mathbb{KL}$ 项的梯度。这是因为 $\mathbb{KL}$ 在采样及其目标方面都依赖于 θ , 而自动微分仅考虑后者。正确的梯度是:

$$\nabla_\theta \mathbb{KL} = \mathbb{E}_{\pi_\theta(\mathbf{y}|\mathbf{x})} \left[\log \frac{\pi_\theta(\mathbf{y}|\mathbf{x})}{\pi(\mathbf{y}|\mathbf{x})} \nabla_\theta \log \pi_\theta(\mathbf{y}|\mathbf{x}) \right],$$

而一个简单的自动微分会给出梯度为:

$$\mathbb{E}_{\pi_\theta} \left[\nabla_\theta \log \frac{\pi_\theta(\mathbf{y}|\mathbf{x})}{\pi(\mathbf{y}|\mathbf{x})} \right] = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(\mathbf{y}|\mathbf{x})],$$

其中这个表达式的期望值为零。Tang 和 Munos (2025) 建议使用标准的 REINFORCE 梯度估计器, 但也讨论了 Schulman (2020) 提出的平方 $\mathbb{KL}$ 估计器。这表示为 $\mathbb{KL}_{\text{sq}}$, 由下式给出:

$$\mathbb{KL}_{\text{sq}}(\pi_\theta \| \pi_{\text{ref}})(\mathbf{x}) = \frac{1}{2} \mathbb{E}_{\mathbf{y} \sim \pi_\theta} \left[\left(\log \frac{\pi_\theta(\mathbf{y}|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}|\mathbf{x})} \right)^2 \right],$$

这里我们将其写成条件值 $\mathbf{x}$ 的函数。它本身是对 $\mathbb{KL}$ 的一个有偏估计量, 但它具有这样的性质, 即简单的自动微分梯度在期望上是真实 $\mathbb{KL}$ 的梯度。具体来说,

$$\mathbb{E}_{\mathbf{y} \sim \pi_\theta} \left[\nabla_\theta \frac{1}{2} \left(\log \frac{\pi_\theta(\mathbf{y}|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}|\mathbf{x})} \right)^2 \right] = \nabla_\theta \mathbb{KL}(\pi_\theta \| \pi_{\text{ref}})(\mathbf{x}).$$

一种适用于离策略和在策略强化学习 (RL) 的单一损失函数

$\mathbb{KL}$ 发散 我们现在描述如何使 $\mathbb{KL}_{\text{sq}}$ 估计器导致一个可用于优化方程 1 中的目标的损失函数, 无论是使用离线数据还是在线数据, 如唐等人 (2025 年) 和巴特尔德森等人 (2025 年)。首先, 我们有 $\mathcal{J}(\theta)$ 可以表示为:

$$\begin{aligned} \mathcal{J}(\theta) &= \beta \mathbb{E}_{\mathbf{x} \sim P(\mathbf{x})} \left[\mathbb{E}_{\mathbf{y} \sim \pi_\theta(\mathbf{y}|\mathbf{x})} \left[\log e^{\beta^{-1} r(\mathbf{x}, \mathbf{y})} \right] \right], \\ &\quad - \beta \mathbb{E}_{\mathbf{x} \sim P(\mathbf{x})} \left[\mathbb{E}_{\mathbf{y} \sim \pi_\theta(\mathbf{y}|\mathbf{x})} \left[\log \frac{\pi_\theta(\mathbf{y}|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}|\mathbf{x})} \right] \right] \\ &= \beta \mathbb{E}_{\mathbf{x} \sim P(\mathbf{x})} [-\mathbb{KL}(\pi_\theta \| \pi_\star)(\mathbf{x})] + C \end{aligned}$$

其中 C 是一个与 θ 和 $\pi_\star$ 无关的常数, 定义为:

$$\pi_\star(\mathbf{y}|\mathbf{x}) = \frac{\pi_{\text{ref}}(\mathbf{y}|\mathbf{x}) \exp(\beta^{-1} r(\mathbf{x}, \mathbf{y}))}{Z(\mathbf{x})},$$

$Z(\mathbf{x}) = \int \pi_{\text{ref}}(\mathbf{y}|\mathbf{x}) \exp(\beta^{-1} r(\mathbf{x}, \mathbf{y})) d\mathbf{y}$ 是划分函数。因此, 方程 1 的最大化对应

以最小化 $\mathbb{E}_{\mathbf{x} \sim P(\mathbf{x})} [-\mathbb{KL}(\pi_\theta \| \pi_\star)(\mathbf{x})]$

假设我们现在已知配分函数, $Z(\mathbf{x})$ 那么我们可以利用该

性质来定义损失函数, $\mathbb{KL}_{\text{sq}}$

$$\mathcal{L}_{\mathbb{KL}_{\text{sq}}}(\mathbf{x}, \mathbf{y}, \theta) := \frac{1}{2} \left(\log \frac{\pi_\theta(\mathbf{y}|\mathbf{x})}{\pi_\star(\mathbf{y}|\mathbf{x})} \right)^2$$

哪里 this loss has the property 那个 $\mathbb{E}_{\mathbf{y} \sim \pi_\theta(\mathbf{y}|\mathbf{x})} [\nabla \mathcal{L}_{\mathbb{KL}_{\text{sq}}}(\mathbf{x}, \mathbf{y}, \theta)] = \nabla_\theta \mathbb{KL}(\pi_\theta \| \pi_{\text{ref}})(\mathbf{x})$, so 在策略梯度的期望值等于 $\mathbb{KL}$ 的梯度。这使我们能够定义一个目标函数:

$$\tilde{\mathcal{J}}(\theta) = \mathbb{E}_{\mathbf{x} \sim P(\mathbf{x})} [\mathbb{E}_{\mathbf{y} \sim \pi_\theta(\mathbf{y}|\mathbf{x})} [\mathcal{L}_{\mathbb{KL}_{\text{sq}}}(\mathbf{x}, \mathbf{y}, \theta)]],$$

其中, 预期的自动微分梯度 $\tilde{\mathcal{J}}(\theta)$ 等于 REINFORCE 算法的梯度 $\mathcal{J}(\theta)$ 。鉴于 $\mathcal{L}_{\mathbb{KL}_{\text{sq}}}$ 仅仅是 logprobs 之间的平方损失, 这还具有额外的优势, 即如果我们从某个分布 μ 中离策略采样完成, 并将目标设置为:

$$\tilde{\mathcal{J}}_\mu(\theta) = \mathbb{E}_{\mathbf{x} \sim P(\mathbf{x})} [\mathbb{E}_{\mathbf{y} \sim \mu(\mathbf{y}|\mathbf{x})} [\mathcal{L}_{\mathbb{KL}_{\text{sq}}}(\mathbf{x}, \mathbf{y}, \theta)]],$$

若支持在 $\pi_\theta(\cdot|\mathbf{x})$ 中包含于 $\mu(\cdot|\mathbf{x})$ 对于每个 $\mathbf{x}$ 这些共享相同的最小值点。这一结论源于以下事实: $\tilde{\mathcal{J}}_\mu(\theta)$ 通过最小化 $\mathbb{E}_{\mathbf{y} \sim \mu(\mathbf{y}|\mathbf{x})} [\mathcal{L}_{\mathbb{KL}_{\text{sq}}}(\mathbf{x}, \mathbf{y}, \theta)]$ 对于每个 $\mathbf{x}$ 来实现最小化, 这恰好发生在当 $\pi_\theta(\mathbf{y}|\mathbf{x}) = \pi_\star(\mathbf{y}|\mathbf{x})$ 对于支持在 $\mu(\cdot|\mathbf{x})$ 中的所有 $\mathbf{y}$ 。

未归一化的目标分布 如果 $Z(\mathbf{x})$ 未知，这种情况通常会发生，我们可以使用基于批次的估计方法来计算归一化常数，这可以恢复 VarGrad 估计器 (Richter 等, 2020 年) 对 $\mathbb{KL}$ 梯度的估计。也就是说，对于每个 $\mathbf{x}$ 采样的完成批次 $\mathcal{B} = \{\mathbf{y}_1, \dots, \mathbf{y}_B\}$ ，我们可以估计 $\log Z(\mathbf{x})$ 如下：

$$\widehat{\log Z(\mathbf{x})} = \frac{1}{B} \sum_{i=1}^B \left(\frac{r(\mathbf{y}_i, \mathbf{x})}{\beta} + \log \frac{\pi_{\text{ref}}(\mathbf{y}_i | \mathbf{x})}{\pi_{\theta}(\mathbf{y}_i | \mathbf{x})} \right) \quad (3)$$

形成批量 Vargrad 损失如下：

$$\mathcal{L}_{\text{KL}}^{\text{VG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_{i=1}^B \left[\log \frac{\text{SG}[\widehat{Z}(\mathbf{x})] \pi_{\theta}(\mathbf{y}_i | \mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}_i | \mathbf{x}) e^{r(\mathbf{x}, \mathbf{y}_i)/\beta}} \right]^2$$

其中 $\text{SG}[\cdot]$ 表示停止梯度函数。

这种损失的一个版本被应用于 Kimi K2 (团队等, 2025a) 和 K1.5 (团队等, 2025b) 中，在此生成策略 θ_{old} 作为参考分布，并且所有内容都按 β 进行缩放。这给出了以下损失：

$$\mathcal{L}^{\text{K2}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_{i=1}^B \left[\beta \log \frac{Z \pi_{\theta}(\mathbf{y}_i | \mathbf{x})}{\pi_{\theta_{\text{old}}}(\mathbf{y}_i | \mathbf{x})} - r(\mathbf{y}_i, \mathbf{x}) \right]^2.$$

These papers use the mean rewards, $\bar{r}(\mathbf{x}) = \frac{1}{B} \sum_{i=1}^B r(\mathbf{x}, \mathbf{y}_i)$, as an estimate for $\log Z$ instead of equation 3. This can be viewed as assuming that $0 \approx \beta (\log \pi_{\theta}(\mathbf{y}_i | \mathbf{x}) - \log \pi_{\theta_{\text{old}}}(\mathbf{y}_i | \mathbf{x}))$, which will hold 如果基线是在线策略，即 $\theta = \theta_{\text{old}}$ ，并且近似地如果基线稍微离线策略或 β 是

较小。这具有无需前向传递的优势。
for the whole batch to calculate $\widehat{\log Z}$.

4. 将 Vargrad 推广到任意偏差和 f -发散

在本节中，我们展示了前一节的方法可以推广到任意 f -发散。具体来说，我们可以从任何 f -发散开始，并构造一个替代损失 $\mathcal{L}_f$ ，其梯度与在线策略的 f 发散匹配，并且在离线策略时仍然是一个有效的损失，具有相同的最小值。此外，我们展示了反启示，即对当前和目标分布的对数概率使用任何平移不变损失对应于最小化相应的 f -发散，并且这些映射互为逆。首先，我们给出一个 f -发散的定義。为了清晰起见，我们在整个过程中省略了对 $\mathbf{x}$ 的条件。

定义 4.1. 设 f 是一个凸函数，具有 $f(1) = 0$ ，则相应的 f 发散定义为：

$$\mathcal{D}_f(p \| q) = \mathbb{E}_{\mathbf{y} \sim q(\mathbf{y})} \left[f \left(\frac{p(\mathbf{y})}{q(\mathbf{y})} \right) \right].$$

我们增加额外的要求，即 $f'(1) = 1$ 和 $f''(1) = 1$ ，使得所有 f 发散的尺度标准化。这总是可以实现的，因为 $\tilde{f}(x) = \lambda_1 f(x) + \lambda_2(x-1)$ 是一个凸函数，具有 $f(1) = 0$ 对于 $\lambda_i \geq 0$ ，并且 $\mathcal{D}_{\tilde{f}}(p \| q) = \lambda_1 \mathcal{D}_f(p \| q)$ ，这样缩放不会改变发散的形状。

f 发散不是对称的，在整个过程中我们将目标放在前面，即 $\mathcal{D}_f(p_{\theta} \| p_{\star})$ 。对于任何凸函数， $\tilde{f}(t) = \frac{1}{t} \tilde{f}(\frac{1}{t})$ 是凸的，反向发散 $\mathcal{D}_f(p_{\theta} \| p_{\star}^*)$ 等于 $\mathcal{D}_{\tilde{f}}(p_{\star}^* \| p_{\theta})$ ，因此总可以写成这种形式。鉴于此，第 3 节讨论的 $\mathbb{KL}$ 现在是反向 $\mathbb{KL}$ ，对应于选择 $f(t) = t \log t$ 。一个 f 发散的梯度由对数导数技巧给出：

$$\nabla_{\theta} \mathcal{D}_f(p_{\theta} \| p_{\star}) = \mathbb{E}_{\mathbf{y} \sim p_{\theta}} \left[f' \left(\frac{p_{\theta}(\mathbf{y})}{p_{\star}(\mathbf{y})} \right) \nabla_{\theta} \log p_{\theta}(\mathbf{y}) \right].$$

现在给定这一点，我们定义以下损失函数，它将 $\mathbb{KL}_{\text{sq}}$ 损失推广到任意 f 发散，其意义在于梯度在策略内等价，但它也是一个有效的策略外损失：

命题 4.2. 设 $\Delta_{\theta}(\mathbf{y}) = \log p_{\theta}(\mathbf{y}) - \log p_{\star}(\mathbf{y})$ 。然后函数 $\mathcal{L}_f : \mathbb{R} \rightarrow \mathbb{R}$ 由下式给出：

$$\mathcal{L}_f(\Delta_{\theta}(\mathbf{y})) = \int_0^{\Delta_{\theta}(\mathbf{y})} f'(\exp(t)) - f'(1) dt$$

是一个平移不变的损失函数，它推广了第 3 节中的构造，具体来说：

1. 目标分布和当前分布的对数概率之间的总体损失：

$$\mathcal{J}_{\mu, f}(\theta) = \mathbb{E}_{\mathbf{y} \sim \mu} [\mathcal{L}_f(\Delta_{\theta}(\mathbf{y}))],$$

当 $p_{\theta} = p_{\star}$ 被最小化时，只要 $p_{\star}$ 的支持集包含在 μ 的支持集中。

2. 如果样本是在策略生成的 ($\mu = p_{\theta}$)，那么 $\mathcal{J}_{\mu, f}(\theta)$ 的期望自动微分梯度对应于相关 f -发散的梯度：

$$\nabla_{\theta} \mathcal{D}_f(p_{\theta} \| p_{\star}) = \mathbb{E}_{\mathbf{y} \sim p_{\theta}} [\nabla_{\theta} \mathcal{L}_f(\Delta_{\theta}(\mathbf{y}))]$$

将此构造应用于反向 $\mathbb{KL}$ 发散直接恢复第 3 节中的损失：例 4.3。对于反向 $\mathbb{KL}$ 发散，我们有。这给出了

$f(u) = u \log(u)$ $f'(u) = \log(u) + 1, f'(1) = 1$,
and:

$$\begin{aligned} \mathcal{L}_{u \log(u)}(\Delta_{\theta}(\mathbf{y})) &= \int_0^{\Delta_{\theta}(\mathbf{y})} \log(\exp(t)) dt \\ &= \frac{1}{2} (\Delta_{\theta}(\mathbf{y}))^2 \end{aligned}$$

实际上，这一结果不仅适用于平方误差损失，而且适用于任何平移不变损失函数。具体来说，设 $\ell: \mathbb{R} \rightarrow \mathbb{R}$ 是一个严格凸的可微函数，在 $\ell(0)$ 处取得最小值， $\ell(y - \hat{y})$ 给出预测值 $\hat{\mathbf{y}}$ 与目标值 $\mathbf{y}$ 之间的损失。对于所有这样的损失函数，我们可以证明反向结果，即在目标和模型对数概率之差上使用 $\ell(\cdot)$ 可以与特定的 f 发散相关联，使用其在策略梯度。此外，这些映射互为逆映射：

命题 4.4. 设 $\ell: \mathbb{R} \rightarrow \mathbb{R}$ 是一个平移不变损失函数。则目标：

$$\tilde{\mathcal{J}}_{\mu, \ell}(\theta) = \mathbb{E}_{\mathbf{y} \sim \mu} \left[\ell(\Delta_{\theta}(\mathbf{y})) \right],$$

在 $p_{\theta} = p_{\star}$ 被最小化时，只要 $p_{\star}$ 的支持集包含在 μ 的支持集中。进一步地，它具有其自动微分梯度对应于相应 f -发散梯度的性质：

$$\mathbb{E}_{\mathbf{x} \sim p_{\theta}(\mathbf{y})} [\nabla_{\theta} \ell(\Delta_{\theta}(\mathbf{y}))] = \nabla_{\theta} \mathcal{D}_{f_{\ell}}(p_{\theta} \| p_{\star}),$$

where f_{ℓ} is defined as:

$$f_{\ell}(u) = \lambda_1 \int_1^u \ell'(\log t) dt + \lambda_2(u - 1) + c,$$

for $\lambda_i, c \in \mathbb{R}$ chosen to satisfy $f_{\ell}(1) = 0, f'_{\ell}(1) = 1$, and $f''_{\ell}(1) = 1$. 此外，这种映射是命题 4.2 中的映射的逆，即 $f_{\mathcal{L}_f} = f$ 和 $\mathcal{L}_{f_{\ell}} = \ell$ 。

此处的边界条件确保映射互为逆矩阵，但所有情况下的梯度等价性。然而，这种参数值的选择确实保证了随着模型接近收敛，梯度在发散上的缩放是等价的。附录 A.2.1 显示，从平方损失开始，我们可以返回到 $\mathbb{KL}$ 。

4.1. 批量归一化下的 DevGrad 损失

我们现在介绍 Vargrad 损失的一般化形式，它可以应用于未归一化的目标分布。我们将此称为 DevGrad 损失，因为它对应于将批量方差替换为批量广义偏差（Rockafellar 和 Uryasev, 2013; Rockafellar 等人, 2006）的对数概率差异。这也具有使评分函数系数在批量中居中的性质，即使我们在处理归一化的目标分布时也能减少方差。

设目标密度的形式为 $p_{\star}(\mathbf{y}) = \frac{1}{Z} \exp(\mathcal{R}(\mathbf{y}))$ 其中 $\mathcal{R}(\mathbf{y})$ 是奖励函数或（负）能量函数，而 $Z = \int \exp(\mathcal{R}(\mathbf{y})) d\mathbf{y}$ 是分区函数。分区函数仍然难以计算，但我们可以通过与 Vargrad 相同的方法来估计它，即：

$$\widehat{\log Z} = \min_C \frac{1}{B} \sum_i \mathcal{L}_f(\Delta(\mathbf{y}_i) + C). \quad (4)$$

其中 $\Delta(\mathbf{y}_i) = \log p_{\theta}(\mathbf{y}_i) - \mathcal{R}(\mathbf{y}_i)$ 是未归一化的对数概率/能量函数的差异。基于此，我们定义 Devgrad 损失如下：

定义 4.5. 给定一个如第 4 节所定义的损失函数 $\mathcal{L}_f$ ，我们定义批量的 **Devgrad** 损失 batch $\mathcal{B} = \{\mathbf{y}_1, \dots, \mathbf{y}_B\}$ 为：

$$\mathcal{L}_f^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_i \mathcal{L}_f(\Delta(\mathbf{y}_i) + \text{SG}[\widehat{\log Z}]).$$

where $\widehat{\log Z}$ 满足方程 4.

再次，这对应于取批次广义偏差（Rockafellar 和 Uryasev, 2013; Rockafellar 等, 2006）的批次对数概率差异。当 $\mathcal{L}_f(y) = y^2$ 时，这恢复了方差，但对于其他 $\mathcal{L}_f$ 值，我们得到不同的偏差，例如当 $\phi_f(y) = |y|$ 时，围绕中位数的平均绝对偏差，在 f -发散的意义上对应于总变差。我们在附录 B 中展示了，使用 $\log Z$ 还会中心化批次得分函数系数，从而以与 Vargrad 相同的方式实现方差缩减。

4.2. 温和损失

如果后验概率由奖励倾斜分布定义如下：

$$\pi_{\star}(\mathbf{y}|\mathbf{x}) = \frac{1}{Z(\mathbf{x})} \pi_{\text{ref}}(\mathbf{y} | \mathbf{x}) \exp(\beta^{-1} r(\mathbf{x}, \mathbf{y})), \quad (5)$$

对于小 β ，由于 $\exp(\beta^{-1} r(\mathbf{x}, \mathbf{y}))$ 项，可能会遇到损失爆炸的问题，进而导致梯度爆炸。例如，如果奖励限定在 $[0, 1]$ 范围内，并且 $\beta = 0.005$ 非标准化概率可以达到数量级 e^{200} ，将导致显著的数值溢出。另一方面，如果我们使用剪辑，将会丢失大量信号。例如，将指数值大于 e^{20} 的部分进行剪辑，将使我们无法区分奖励大于 0.1 的样本。

为了解决这个问题，我们首先定义温和分布：

定义 4.6. 对于一个分布 $p(\mathbf{y}|\mathbf{x})$ ，我们定义温和分布 $\tilde{p}_{\beta}(\mathbf{y}|\mathbf{x})$ 为与 $p^{\beta}(\mathbf{y}|\mathbf{x})$ 成比例的分布。在能量函数方面，我们有如果 $p(\mathbf{y}|\mathbf{x}) = \frac{1}{Z(\mathbf{x})} \exp(\mathcal{R}(\mathbf{y}|\mathbf{x}))$ ，则：

$$p^{\beta}(\mathbf{y}|\mathbf{x}) = \frac{1}{\tilde{Z}(\mathbf{x})} \exp(\beta \mathcal{R}(\mathbf{y}|\mathbf{x})). \quad (6)$$

现在，正如上面提到的，对于给定的倾斜分布 $\pi_{\star}$ ，在方程 5 中，我们面临的问题是能量函数的大小 $\mathcal{R}_{\star}(\mathbf{y}|\mathbf{x})$ 与 $\frac{1}{\beta}$ 成比例，使得使用小 β 进行训练变得不切实际。然而，温和分布的能量函数是 $\beta \mathcal{R}_{\star}(\mathbf{y}|\mathbf{x}) = \beta \log \pi_{\text{ref}} +$

$r(\mathbf{x}, \mathbf{y})$ 其大小被限制为 $\beta \rightarrow 0$ 。我们还发现，如果温和和目标对数概率相等，则未温和的对数概率也必须相等。基于此，我们现在可以定义温和损失如下：

定义 4.7. 我们定义相对于某个基准的温控损失为 f -发散 f 如：

$$\tilde{\mathcal{L}}_{f,\beta}(\Delta_\theta(\mathbf{y})) = \frac{1}{\beta} \mathcal{L}_f(\beta \Delta_\theta(\mathbf{y})) \quad (7)$$

哪里 $\Delta_\theta(\mathbf{y}) = \log \pi_\theta(\mathbf{y}) - \mathcal{R}_*(\mathbf{y}|\mathbf{x})$.

通过乘以 $\frac{1}{\beta}$ 来确保梯度大小不随 β 变化。温控损失函数还为 KIMI 损失 (团队等, 2025a;b) 提供了一种新视角，因为它实际上是逆 $\mathbb{KL}$ 损失的温控损失：

示例 4.8. 令 $f(u) = u \log u$ ，则有缓和损失等于：

$$\tilde{\mathcal{L}}_{f,\beta}(\Delta_\theta(\mathbf{y})) = \frac{1}{2\beta} \mathbb{E}_{\mathbf{y} \sim \pi_\theta} \left[\left(\beta \log \frac{\pi_\theta(\mathbf{y}|\mathbf{x})}{\mathcal{R}(\mathbf{y}|\mathbf{x})} - \log \tilde{Z} \right)^2 \right]$$

这导致了在假设 $0 \approx$ 成立的情况下，KIMI 使用 $\log Z$ 的批量归一化 $\bar{r}$ ，正如讨论中提到的 $\beta (\log \pi_\theta(\mathbf{y}_i|\mathbf{x}) - \log \pi_{\theta_{\text{ref}}}(\mathbf{y}_i|\mathbf{x}))$ 3.

5. 对生成流网络的泛化

本文将第 4 节详细阐述的新颖损失函数家族应用于生成流网络 (Generative Flow Networks, GFlowNets) (Bengio 等, 2021; 2023)。生成流网络是一类概率方法，能够对具有组合结构的空间进行采样的摊销。生成流网络的一个关键优势在于，它们支持在线和离线策略训练，并且从离线策略样本中获得探索性益处。

在策略内的情况下，GFlowNets 与分层变分推断 (HVI) 之间存在部分等价性 (Malkin 等, 2023 年)，具体而言，某些损失函数的预期梯度 (Malkin 等, 2022a 年) 与通过 KL 执行 HVI 所得到的预期梯度相匹配。我们证明了我们的损失函数自然地将这些等价性扩展到所有其他 f 发散，并提供了一组新的损失函数用于训练 GFlowNets，无论是策略内还是策略外。首先，我们简要介绍 GFlowNets，为了简单起见，我们将重点放在离散 GFlowNets 上，尽管 GFlowNets 已经被扩展到了连续情况 (Lahlou 等, 2023 年)。

5.1 背景：GFlowNets、轨迹平衡及其变分推断

参照 (Bengio 等, 2021)，定义一个有向无环图 $\mathcal{G} = (\mathcal{S}, \mathcal{A})$ 包含状态 $\mathcal{S}$ ，动作 $\mathcal{A}$ ，初始状态 s_0 ，以及终止状态 $\mathcal{X}$ 。完整的轨迹 $\tau = (s_0 \rightarrow \dots \rightarrow s_n)$ 结束于 $\mathbf{x}_\tau \in \mathcal{X}$ 。GFlowNets 的目标是进行采样 $\mathbf{x} \in \mathcal{X}$ 成比例的

通过学习从一个状态到下一个状态的前向策略 $\pi_F(\cdot|\mathbf{s}, \theta)$ 来获得奖励 $\mathcal{R}(\mathbf{x})$ 。这诱导了一个轨迹分布 $(\mathbf{s}_i, \mathbf{s}_{i-1}) \in \tau \pi_F(\mathbf{s}_i|\mathbf{s}_{i-1})$

$\pi_F(\tau|\theta) = \prod_{i=1}^n \pi_F(\mathbf{s}_i|\mathbf{s}_{i-1})$ 。直接以最大化的边缘求和而变得不可行。Malkin 等人 (2022a) 通过引入可学习的 Z 和向后策略 $\pi_B(\tau|\mathbf{x}_\tau, \phi) = \frac{1}{Z}$ ，并强制执行轨迹平衡约束来解决这一问题：

$$\prod \pi_B(\mathbf{s}_{i-1} | \mathbf{s}_i, \phi)$$

$$Z \pi_F(\tau|\theta) = \mathcal{R}(\mathbf{x}_\tau) \pi_B(\tau|\mathbf{x}_\tau, \phi).$$

Here $\pi_B(\tau | \mathbf{x}_\tau, \phi) = \prod_{(\mathbf{s}_{i-1}, \mathbf{s}_i) \in \tau} \pi_B(\mathbf{s}_{i-1} | \mathbf{s}_i, \phi)$ 及 $Z = \sum_{\mathbf{x} \in \mathcal{X}} \mathcal{R}(\mathbf{x})$. Malkin et al. (2022a) θ, ϕ 表明如果使得对于所有 $\tau \in \mathcal{T}$ 轨迹平衡约束都得到满足，则 $\pi_F(\mathbf{x}|\theta) \propto \mathcal{R}(\mathbf{x})$ 。定义对数轨迹差异为：

$$\Delta(\tau, \theta, \phi) = \log \frac{Z_\phi \pi_F(\tau|\theta)}{\mathcal{R}(\mathbf{x}_\tau) \pi_B(\tau|\mathbf{x}_\tau, \phi)},$$

其中 Z_ϕ 现在是一个可学习参数，轨迹平衡约束得到满足当 $\Delta(\tau, \theta, \phi) = 0$ 对于所有 $\tau \in \mathcal{T}$ ，成立，这导致 Malkin 等人 (2022a) 定义轨迹平衡损失为：

$$\mathcal{L}_{\text{TB}}(\tau, \phi, \theta) := (\Delta(\tau, \theta, \phi))^2. \quad (8)$$

然后使用损失的期望梯度更新参数 θ, ϕ ，即 $\mathbb{E}_{\mu(\tau)} [\nabla \theta \mathcal{L}_{\text{TB}}(\tau, \phi, \theta)]$ 和 $\mathbb{E}_{\mu(\tau)} [\nabla \phi \mathcal{L}_{\text{TB}}(\tau, \phi, \theta)]$ ，使用行为策略下的期望梯度 $\mu(\tau)$ ，通常是温和的 π_F 。

Malkin et al. (2023) relate this to hierarchical variational inference (HVI) (Ranganath et al., 2016), viewing π_B as a posterior and π_F as a generative model minimizing the f -divergence :

$$\mathcal{L}_{\text{HVI},f}(\pi_F, \pi_B) = \mathcal{D}_f(\pi_F || \pi_B) \quad (9)$$

$$= \mathbb{E}_{\tau \sim \pi_B} \left[f \left(\frac{\pi_F(\tau)}{\pi_B(\tau)} \right) \right]. \quad (10)$$


对于逆 KL ($\mathcal{R}-\mathbb{KL}$) 和 KL, Malkin 等人 (2022b) 展示了 HVI 与在线 GflowNet 训练之间的梯度等价性为：

$$\begin{aligned} \nabla_\theta \mathcal{D}_{\mathcal{R}-\mathbb{KL}}(\pi_{B,\phi} || \pi_{F,\theta}) &= \mathbb{E}_{\tau \sim \pi_{F,\theta}} [\nabla_\theta \mathcal{L}_{\text{TB}}(\tau, \phi, \theta)], \\ \nabla_\phi \mathcal{D}_{\mathbb{KL}}(\pi_{B,\phi} || \pi_{F,\theta}) &= \mathbb{E}_{\tau \sim \pi_{B,\phi}} [\nabla_\phi \mathcal{L}_{\text{TB}}(\tau, \phi, \theta)]. \end{aligned}$$

如果 $\mathcal{G}$ 是一棵树， $\pi_B = 1$ ，这意味着我们不需要学习反向策略，并且梯度等价性与第 3 节讨论的一致。

5.2. f -Trajectory Balance

我们现在证明第 4 节引入的损失可以应用于强制执行轨迹平衡约束



(a) Comparison of different losses on the grid task of Bengio et al. (2021). 正向 KL 散度和 Hellinger 距离比标准轨迹平衡更具有模式覆盖性，这意味着它们能够找到所有 4 个模式并更快地拟合分布。Pearson 距离比轨迹平衡更具模式寻找性，并且会附着到它发现的第一个模式上。

在 GFlowNets 中，这样做将 Malkin 等人 (2022b) 的结果推广到了任意的 f -发散。

命题 5.1。 对于一个凸函数， f ，我们有应用于对数轨迹的 $\mathcal{L}_f$ 泛化了轨迹平衡，即我们有：

$$\begin{aligned}\nabla_{\theta} \mathcal{D}_f(\pi_F \| \pi_B) &= \mathbb{E}_{\tau \sim \pi_{F, \theta}} [\nabla_{\theta} \mathcal{L}_f(\tau, \phi, \theta)] \\ \nabla_{\phi} \mathcal{D}_h(\pi_B \| \pi_F) &= \mathbb{E}_{\tau \sim \pi_{B, \phi}} [\nabla_{\phi} \mathcal{L}_f(\tau, \phi, \theta)]\end{aligned}$$

其中， h 定义为：

$$h(u) = \int_1^u \left(2 - f' \left(\frac{1}{t} \right) \right) dt.$$

我们在附录 A.3.3 中证明了反向策略的在线策略梯度并不对应于 f 发散最小化，就像轨迹平衡一样。在这种情况下，它们的有效性来自于 $\mathcal{L}_f$ 是一个有效的损失函数。Malkin 等人 (2022a) 还证明了随着模型接近最优，轨迹平衡损失函数的方差低于 REINFORCE 估计器，我们在附录 B.2 中展示了这一点也适用于 f -轨迹平衡。

6. 实验

我们在四个任务上展示了我们的损失函数族：GFlowNets 的合成网格任务 (Bengio 等, 2021 年)，SynFlowNet 的分子采样 (Cretu 等, 2025 年)，扩散模型微调 (Venkatraman 等, 2024 年)，以及在 GSM8k (Cobbe 等, 2021 年) 和 Hendrycks MATH 数据集上的异步大语言模型微调。

我们在附录 B.2 中提供了完整的 f -发散列表，但理解我们的结果最重要的是由 $f(u) = \frac{1}{\alpha}(u-1)$ 生成的 α -发散族。这个族的关键点不仅在于它包含了最常见的许多 f 发散，包括当 α 时的正向和反向 KL 散度

(b) 使用基于 α 发散的各种损失函数训练 SynFlowNet。在 α 发散中， α 是一个可控参数，较低的值激励模式覆盖，较高的值激励模式寻找，标准轨迹平衡对应于 $\alpha = 1$ 。在训练过程中退火 α 允许这些属性之间的权衡，从而导致采样更多样化的高奖励分子。

分别为 0 和 1¹，但认为该 α 参数控制模式覆盖与模式寻找行为之间的平衡，较低的值表示 α 导致更多的模式覆盖损失。 α 发散损失， $\mathcal{L}_{\alpha}$ 由下式给出：

$$\mathcal{L}_{\alpha}(\Delta) = \frac{1}{(\alpha-1)^2} e^{(\alpha-1)\Delta} - \frac{\Delta}{\alpha-1} - \frac{1}{(\alpha-1)^2}.$$

轨迹平衡在极限情况下作为 $\alpha \rightarrow 1$ 出现


6.1. GFlowNet 实验

6.1.1. 合成网格


本文通过 Bengio 等人 (2021)；Malkin 等人 (2022a) 提出的二维网格实验展示了这一权衡关系，在该实验中，智能体在一个超网格中导航，以发现网格角落的四种模式。动作包括移动到相邻坐标或终止轨迹，而模式之间的低奖励区域模拟了 MCMC 和采样算法中典型的模式发现挑战。我们在该任务上评估了四种 α -发散损失函数， $\mathcal{L}_{\alpha}$ 正向 KL ($\alpha = 0$)，Hellinger ($\alpha = 0.5$)，反向 KL ($\alpha = 1$)，以及 Pearson χ^2 ($\alpha = 2$)。反向 KL 对应于使用标准轨迹平衡进行训练。

图 2a 展示了模式覆盖与模式寻找的特性，其中在正向 KL 和 Hellinger 损失中较低的 α 值得代理找到的模式比标准轨迹平衡更多，并且更快找到这些模式。鉴于 GFlowNets 的一个关键动机是其能够找到模式，这清楚地展示了我们损失函数家族的优势。另一方面，Pearson χ^2 比轨迹平衡更倾向于寻找模式，导致它一旦找到第一个模式就陷入其中。这种行为实际上将在后续帮助我们获得用于强化学习的奖励最大化的损失函数。

¹ 这些点上的值通过极限定义。



(a) 调整预训练扩散模型以分别生成奇数和偶数数字时奖励与先验发散之间的权衡。



(b) 异步调整 LLM 50 步并使用可验证奖励在 GSM8k (Cobbe 等, 2021) 和 Hendrycks MATH (Hendrycks 等) 上进行熵-奖励权衡。

6.1.2. 合成流网络

现在我们将损失应用于调优 SynFlowNets (Cretu 等, 2025), 这是一种受限于从合成可访问分子空间采样的 GFlowNets 类别。目标仍然是按给定奖励模型的比例采样该空间, 例如预测的结合能量或生物活性。对于这些任务, 我们发现 α -发散损失, $\mathcal{L}_\alpha$, 需要更少极端的 α 值来进行稳定训练, 其中 α 更接近轨迹平衡值的 $\alpha = 1$ 。

我们在 3 个 SynFlowNet 任务中评估 $\alpha \in \{0.75, 1.2\}$ 与 TB, 扫描逆温度。 $\alpha = 0.75$ 产生的分子比 TB 更多样化, 而 $\alpha = 1.2$ 导致模式崩塌。在训练过程中将 α 从 0.75 退火到 1.2 可以实现两者的最佳效果, 如图 2b 所示 DRD2。

6.2. 生成模型实验

6.2.1. 条件采样扩散模型

虽然我们展示了 GFlowNets 在离散空间的应用, 但它们已被扩展到连续空间 (Lahlou 等, 2023 年), 并由此应用于扩散模型的调优 (Berner 等; Venkatraman 等, 2024 年)。具体而言, Venkatraman 等 (2024 年) 将生成视为从 GFlowNet 采样的轨迹, 使得预训练的扩散模型, $p_{\text{prior}}(\mathbf{x})$, 可以被调优至一个未归一化的后验分布 $p_{\text{post}}(\mathbf{x}) \propto r(\mathbf{x})p_{\text{prior}}(\mathbf{x})$, 而无需评估最终似然性, 只需中间步骤。

为了证明在这种情况下 f -轨迹平衡可以应用, 我们重复了 Venkatraman 等 (2024 年) 的实验, 通过调优预训练的扩散模型来对 MNIST 数字进行条件采样, 要么是奇数, 要么是偶数。在这种情况下, 目标后验分布具有多个模式, 每个目标数字一个模式, 正确拟合的后验分布应均匀地采样这些模式。图 3a 显示, 标准的轨迹平衡无法做到这一点, 尤其是在偶数的情况下, 附录 B.2 显示它过度采样了 0 和 6。替代的 f -轨迹平衡损失能够

更均匀地采样这些模式, 退火后的 α 发散再次获得了最佳的权衡。

6.2.2. 异步调优 LLMs 与强化学习

最后, 作为一个经典案例, 展示在具有可验证奖励的大规模模型中熵与奖励之间的权衡, 在强化学习中, 我们在 GSM8k (Cobbe 等, 2021 年) 和 Hendrycks MATH (Hendrycks 等) 的混合问题上微调了一些模型。为了展示策略外的有效性, 我们异步训练, 延迟 50 步。对于模型, 我们使用 Qwen 2.5 系列的大小为 3b-14b 以及 OLMo-2-1124-7B, 旨在展示我们的损失函数在不同模型大小和家族中的适用性。由于发现标准 GRPO 不能异步应用 50 步, 我们将其与来自 Intellect (2025 年) 优化的 PPO 损失实现进行比较, 其中包括诸如 CISPO 剪辑 (Chen 等, 2025 年) 和 DAPO (Yu 等, 2025 年) 的变化。对于我们的损失函数, 我们使用未经剪辑、重要性加权或掩码处理的温控 DevGrad 损失 (附录 C)。

我们每种配置使用 3 个种子训练 300 步; 逆 KL、皮尔逊以及正向 KL 再次展示了相同的权衡 (图 3b)。我们也包括了 Jensen-Shannon 发散 (需要数值归一化), 确认其适用于完整的 f -发散家族。优化的 PPO 在不同模型类别之间产生不一致的结果, 这是由于策略外不稳定性。

7. 结论

在本研究中, 我们推导出一个损失函数族, 该族自然扩展了生成模型的 Vargrad 损失和 GFlowNets 的轨迹平衡损失, 通过将它们的策略梯度与 $\mathbb{KL}$ 梯度匹配的性质扩展到整个 f -发散族。我们展示了这样做使我们能够在各种生成模型中控制模式搜索与模式覆盖行为, 同时进行在线和离线训练。

致谢

作者感谢 Julien Roy 和 Emmanuel Bengio 对本工作的反馈。

参考文献

- S. M. Ali and S. D. Silvey. A general class of coefficients of divergence of one distribution from another. *Journal of the Royal Statistical Society: Series B (Methodological)*, 28(1):131–142, 1966.
- B. R. Bartoldson, S. Venkatraman, J. Diffenderfer, M. Jain, T. Ben-Nun, S. Lee, M. Kim, J. Obando-Ceron, Y. Bengio, and B. Kailkhura. Trajectory balance with asynchrony: Decoupling exploration and learning for fast, scalable llm post-training. *CoRR*, 2025.
- E. Bengio, M. Jain, M. Korablyov, D. Precup, and Y. Bengio. Flow network based generative models for non-iterative diverse candidate generation. *Advances in neural information processing systems*, 34:27381–27394, 2021.
- Y. Bengio, S. Lahlou, T. Deleu, E. J. Hu, M. Tiwari, and E. Bengio. Gflownet foundations. *Journal of Machine Learning Research*, 24(210):1–55, 2023.
- J. Berner, L. Richter, M. Sendera, J. Rector-Brooks, and N. Malkin. From discrete-time policies to continuous-time diffusion samplers: Asymptotic equivalences and faster training.
- A. Chen, A. Li, B. Gong, B. Jiang, B. Fei, B. Yang, B. Shan, C. Yu, C. Wang, C. Zhu, et al. Minimax-ml: Scaling test-time compute efficiently with lightning attention. *arXiv preprint arXiv:2506.13585*, 2025.
- K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano, et al. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.
- M. Cretu, C. Harris, I. Igashov, A. Schneuing, M. Segler, B. Correia, J. Roy, E. Bengio, and P. Lio. Synflownet: Design of diverse and novel molecules with synthesis constraints. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=uvHmnaHyp1>.
- S. K. S. Ghasemipour, R. Zemel, and S. Gu. A divergence minimization perspective on imitation learning methods. In *Conference on robot learning*, pages 1259–1277. PMLR, 2020.
- D. Go, T. Korbak, G. Kruszewski, J. Rozen, N. Ryu, and M. Dymetman. Aligning language models with preferences through f -divergence minimization. *arXiv preprint arXiv:2302.08215*, 2023.
- J. Han, M. Jiang, Y. Song, S. Ermon, and M. Xu. f -po: Generalizing preference optimization with f -divergence minimization. *arXiv preprint arXiv:2410.21662*, 2024.
- D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt. Measuring mathematical problem solving with the math dataset. In *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2)*.
- A. Huang, W. Zhan, T. Xie, J. D. Lee, W. Sun, A. Krishnamurthy, and D. J. Foster. Correcting the mythos of kl-regularization: Direct alignment without overoptimization via chi-squared preference optimization. In *The Thirteenth International Conference on Learning Representations*.
- P. Intellect. Prime-rl, 2025. URL <https://github.com/PrimeIntellect-ai/prime-rl>.
- Q. Jin, B. Dhingra, Z. Liu, W. Cohen, and X. Lu. Pubmedqa: A dataset for biomedical research question answering. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2567–2577, 2019.
- L. Ke, S. Choudhury, M. Barnes, W. Sun, G. Lee, and S. Srinivasa. Imitation learning as f -divergence minimization. In *International workshop on the algorithmic foundations of robotics*, pages 313–329. Springer, 2020.
- S. Lahlou, T. Deleu, P. Lemos, D. Zhang, A. Volokhova, A. Hernández-García, L. N. Ezzine, Y. Bengio, and N. Malkin. A theory of continuous generative flow networks. In *International Conference on Machine Learning*, pages 18269–18300. PMLR, 2023.
- K. Lu and T. M. Lab. On-policy distillation. *Thinking Machines Lab: Connectionism*, 2025. doi: 10.64434/tml.20251026. <https://thinkingmachines.ai/blog/on-policy-distillation>.
- N. Malkin, M. Jain, E. Bengio, C. Sun, and Y. Bengio. Trajectory balance: Improved credit assignment in gflownets. *Advances in Neural Information Processing Systems*, 35: 5955–5967, 2022a.
- N. Malkin, S. Lahlou, T. Deleu, X. Ji, E. Hu, K. Everett, D. Zhang, and Y. Bengio. Gflownets and variational inference. *arXiv preprint arXiv:2210.00580*, 2022b.
- N. Malkin, S. Lahlou, T. Deleu, X. Ji, E. J. Hu, K. E. Everett, D. Zhang, and Y. Bengio. GFlownets and variational inference. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=uKiE0ViluA->.

- T. Minka et al. Divergence measures and message passing. 2005.
- T. Morimoto. Markov processes and the h-theorem. *Journal of the Physical Society of Japan*, 18(3):328–331, 1963.
- N. Novello, F. Fontana, L. Cinque, D. Gunduz, and A. M. Tonello. A unified framework for diffusion model unlearning with f -divergence. *arXiv preprint arXiv:2509.21167*, 2025.
- S. Nowozin, B. Cseke, and R. Tomioka. f -gan: Training generative neural samplers using variational divergence minimization. *Advances in neural information processing systems*, 29, 2016.
- N. Nüsken 和 K. Richtel. 使用神经网络求解高维 Hamilton-Jacobi-Bellman 偏微分方程：从受控扩散理论和路径空间测度的角度。偏微分方程及其应用, 2(4):48, 2021.
- R. Ranganath, D. Tran 和 D. Blei. 层次变分模型。** 国际机器学习大会论文集, 第 324 – 333 页。PMLR, 2016.
- L. 迪克特, A. 布斯塔蒂, N. 努斯肯, F. 鲁伊兹, 和 O. D. 阿基-伊尔迪兹.** 低方差梯度估计器用于变分推断. 神经信息处理系统进展, 33:13481 – 13492, 2020.
- R. T. Rockafellar 和 S. Uryasev. 风险管理、优化和统计估计中的基本风险四边形. 运营研究与管理科学调查, 18(1-2):33 – 53, 2013.
- R. T. 岩卡法拉尔, S. 尤里亚塞夫和 M. 扎巴拉恩金.** 一般化风险分析中的标准化偏差。Finance and Stochastics, 10(1):51 – 74, 2006.
- J. Schulman. 近似 kl 发散, 2020. URL**
<http://joschu.net/blog/kl-approx.html>, 2020.
- J. Schulman 和 T. M. Lab. 无悔的 Lora. 连接主义：思考机器实验室, 2025. doi: 10.64434/tml.20250929.
<https://thinkingmachines.ai/blog/lora/>.
- J. Schulman, F. Wolski, P. Dhariwal, A. Radford, 和 O. 克利莫夫.** 近端策略优化算法. arXiv 预印本 arXiv:1707.06347, 2017.
- T. 西尔瓦, E. 德索萨达席尔瓦和 D. 梅斯基塔.** 关于发散-用于训练 gflownets 的生成测度。《神经信息处理系统进展》, 37:75883 – 75913, 2024.
- 唐伟. 扩散模型的微调通过随机控制：熵正则化及其他. 计算机科学评论, 2024.
- 唐勇和 R. Munos. 关于在强化学习中 KL 发散梯度估计的一些陷阱. arXiv 预印本 arXiv:2506.09477, 2025.
- 唐勇, 科恩·泰, 张卫东, 瓦尔科·马特, 蒙诺斯·罗曼** 利用单一算法对来自策略内和策略外数据的大型语言模型进行强化学习微调. CoRR, 2025.
- K. 团队, Y. 白, Y. 包, G. 陈, J. 陈, N. 陈, R. 陈, Y. 陈, Y. 陈, Y. 陈, 等. Kimi k2: 开源代理智能. arXiv 预印本 arXiv:2507.20534, 2025a.
- K. 团队, A. 杜, B. 高, B. 兴, C. 蒋, C. 陈, C. 李, C. 肖, C. 杜, C. 廖, 等. Kimi k1. 5: 扩展强化学习与大语言模型. arXiv 预印本 arXiv:2501.12599, 2025b.
- S. 文卡特拉曼, M. 瞿, L. 斯奇梅卡, M. 金, M. 森德拉, M. 哈桑, L. 罗, S. 米塔尔, P. 莱莫斯, E. 本乔, 等. 在扩散模型中摊销不可计算的推理用于视觉、语言和控制. 神经信息处理系统进展, 37:76080 – 76114, 224 年.
- D. 王, H. 刘, 和 Q. 刘. 利用尾部自适应 f -发散的变分推断. 神经信息处理系统进展, 31, 2018.
- R. J. 威廉斯. 连接主义强化学习的简单统计梯度跟随算法. 机器学习, 8(3):229 – 256, 1992.
- Q. 余, Z. 张, R. 朱, Y. 袁, X. 左, Y. 越, W. 戴, T. 范, G. 刘, L. 刘等. 大波：一个大规模开源的 llm 强化学习系统. arXiv 预印本 arXiv:2503.14476, 2025.

附录 A. 证明与推导

在本附录中，我们提供了第 4 节引入的损失函数族的完整推导。我们证明了定理 4.2 中定义的平移不变损失函数 $\mathcal{L}_f$ 满足两个关键性质：最小化总体损失可以恢复目标分布（离策略一致性），并且策略上的自动微分梯度可以恢复相关 f -发散的梯度。我们还建立了定理 4.4 中描述的逆映射。

附录 A.1. 命题 4.3 的证明

命题 4.3. 设 Δ $\theta(y) = \log p_\theta(y) - \log p_\star(y)$ 。函数：

$$\mathcal{L}_f(\Delta_\theta(y)) = \int_0^{\Delta_\theta(y)} (f'(\exp(t)) - f'(1)) dt$$

是一个平移不变损失函数，它推广了第 3.2 节中的构造。

1. 当支持覆盖假设成立时，人口损失 $\mathcal{J}_{\mu, f}(\theta) = \mathbb{E}_{y \sim \mu}[\mathcal{L}_f(\Delta_\theta(y))]$ 最小化当 $p_\theta = p_\star$ 。

2. 如果 $\mu = p_\theta$ ，预期自动微分梯度与 f -发散梯度相匹配：
 $\mathbb{E}_{p_\theta}[\nabla_\theta \mathcal{L}_f(\Delta_\theta(y))].$

$$\nabla_\theta D_f(p_\theta \| p_\star) =$$

A.1.1. 第一部分的证明：凸性和全局极小值点

设标量损失函数关于对数概率差表示为 $L(\Delta) = \int_0^\Delta (f'(\exp(t)) - f'(1)) dt$ 。我们通过分析其导数来确定 $L(\Delta)$ 的性质。

根据微积分基本定理，一阶导数为：

$$L'(\Delta) = f'(\exp(\Delta)) - f'(1).$$

再次对 Δ 求导，我们得到二阶导数：

$$L''(\Delta) = f''(\exp(\Delta)) \cdot \exp(\Delta).$$

由于 f 是一个定义了 f -发散的凸函数， $f''(u) \geq 0$ 对于所有 $u > 0$ 。此外，指数函数 $\exp(\Delta)$ 对于所有实数 Δ 严格为正。因此：

$$L''(\Delta) \geq 0 \quad \forall \Delta \in \mathbb{R}.$$

这证实了 $L(\Delta)$ 是一个凸函数。为了找到全局极小值点，我们求解驻点 $L'(\Delta) = 0$ ：

$$\begin{aligned} f'(\exp(\Delta)) - f'(1) &= 0 \\ f'(\exp(\Delta)) &= f'(1). \end{aligned}$$

假设 f 具有严格凸性（意味着 f' 是严格单调的），则该等式成立当且仅当：

$$\exp(\Delta) = 1 \implies \Delta = 0.$$

由于 $L(\Delta)$ 是凸的，并且其导数在 $\Delta = 0, \Delta = 0$ 处消失，因此它是全局最小值。由此可知，期望总体损失 $\mathbb{E}_{y \sim \mu}[L(\Delta_\theta(y))]$ 在 $\Delta_\theta(y) = 0$ 几乎处处成立的情况下达到最小值，这意味着 $\log p_\theta(y) = \log p_\star(y)$ ，
 or $p_\theta = p_\star$.

A.1.2. 第 2 部分的证明：梯度匹配条件

我们证明了策略上 f 发散的期望梯度等于损失函数的期望自动微分梯度。

梯度的 f -发散： f 和通过数对数表示 $u(y) = p_\theta(y)/p_\star(y)$ ，梯度 $\nabla_\theta p_\theta = p_\theta \nabla_\theta \log p_\theta$ 为：

$$\begin{aligned} \nabla_\theta D_f(p_\theta \| p_\star) &= \nabla_\theta \mathbb{E}_{p_\star}[f(u(y))] \\ &= \mathbb{E}_{p_\star} \left[f'(u(y)) \frac{\nabla_\theta p_\theta(y)}{p_\star(y)} \right] = \mathbb{E}_{p_\theta} [f'(u(y)) \nabla_\theta \log p_\theta(y)]. \end{aligned}$$

自 $\mathbb{E}_{p_\theta}[\nabla_\theta \log p_\theta(y)] = 0$ 起，我们可以减去一个常数基线 $f'(1)$ 而不改变其值：

$$\nabla_\theta D_f(p_\theta \| p_\star) = \mathbb{E}_{p_\theta} [(f'(u(y)) - f'(1)) \nabla_\theta \log p_\theta(y)].$$

替代损失的梯度： 损失样本 $\mathcal{L}_f$ 关于 θ 的自动微分梯度对积分内的项应用链式法则：

$$\begin{aligned} \nabla_\theta \mathcal{L}_f(\Delta_\theta(y)) &= \frac{\partial \mathcal{L}_f}{\partial \Delta} \nabla_\theta (\log p_\theta(y) - \log p_\star(y)) \\ &= (f'(\exp(\Delta_\theta(y))) - f'(1)) \nabla_\theta \log p_\theta(y). \end{aligned}$$

将 $\exp(\Delta_\theta(y)) = u(y)$ 代入，并对策略上的样本 $y \sim p_\theta$ 取期望：

$$\mathbb{E}_{p_\theta}[\nabla_\theta \mathcal{L}_f] = \mathbb{E}_{p_\theta} [(f'(u(y)) - f'(1)) \nabla_\theta \log p_\theta(y)].$$

这与上述推导的 f -发散的梯度相同。

附录 A.2. 命题 4.5 的证明：逆映射

命题 4.5. 设 $\ell : \mathbb{R} \rightarrow \mathbb{R}$ 是一个严格凸的平移不变损失函数。则目标 $\tilde{\mathcal{J}}_{\mu, \ell}(\theta)$ 在 $p_\theta = p_\star$ 时最小化，并对应于通过生成器定义的最小化一个 f -发散：

$$f_\ell(u) = \lambda_1 \int_1^u \ell'(\log t) dt + \lambda_2(u - 1) + c$$

其中常数被选择以满足标准边界条件 $f(1) = 0, f'(1) = 1, f''(1) = 1$ 。

证明。 我们旨在寻找一个凸生成器 f 使得策略发散的期望在策略梯度上 D_f 与损失函数的期望在策略梯度上的值成正比 ℓ 。

根据命题 4.3 的证明，我们可以将一个 f -发散的梯度表示为关于在策略样本上的期望：

$$\nabla_\theta D_f(p_\theta \| p_\star) = \mathbb{E}_{p_\theta} [(f'(u) - f'(1)) \nabla_\theta \log p_\theta],$$

$u = p_\theta(y)/p_\star(y) = \exp(y - \hat{y})$ 。现在考虑损失函数 ℓ 作用于对数概率差异上的情况 $\Delta = y - \hat{y} = \log u$ 。损失目标的梯度

相对于 θ is:

$$\begin{aligned} \nabla_\theta \ell(\Delta) &= \frac{\partial \ell}{\partial \Delta} \nabla_\theta \Delta \\ &= \ell'(\log u) \nabla_\theta \log p_\theta. \end{aligned}$$

为了使梯度匹配（相差一个缩放因子 λ_1 和一个在期望中消失的得分函数中的加性常数），我们将系数等同于 $\nabla_\theta \log p_\theta$ ：

$$\lambda_1 \ell'(\log u) = f'(u) - C,$$

其中 $C = f'(1)$ 。这给出了第一导数之间的关系。为了验证凸性，我们对 u 求导：

$$\begin{aligned} \lambda_1 \ell''(\log u) \cdot \frac{d}{du}(\log u) &= f''(u) \\ \lambda_1 \frac{\ell''(\log u)}{u} &= f''(u). \end{aligned}$$

由于 $u > 0$ （概率比）和 ℓ 严格凸（ $\ell'' > 0$ ），可以得出 $f''(u) > 0$ （假设 $\lambda_1 > 0$ ）。因此，诱导出的生成器 f 是严格凸的。

为了恢复函数形式 $f(u)$ ，我们将一阶导数关系 $f'(t) = \lambda_1 \ell'(\log t) + C$ 从 1 积分到 u : $f(u) - f(1) = \int_1^u (\lambda_1 \ell'(\log t) + C) dt$.

施加标准的 f 发散约束 $f(1) = 0$ ，并令 $\lambda_2 = C$ ，我们得到：

$$f_\ell(u) = \lambda_1 \int_1^u \ell'(\log t) dt + \lambda_2(u - 1).$$

常数 λ_1 和 λ_2 可以通过标准化约束 $f'(1) = 1$ 和 $f''(1) = 1$ 来求解 $f''(1) = 1 \implies \lambda_1 \ell''(0) = 1 \implies \lambda_1 = \frac{1}{\ell''(0)}$
 $f'(1) = 1 \implies \lambda_1 \ell'(0) + \lambda_2 = 1 \implies \lambda_2 = 1 - \frac{\ell'(0)}{\ell''(0)}$. 因此，任何严格凸的对数概率平移不变损失都对应于一个有效的、严格凸的 f -发散。

A.2.1. $\mathbb{KL}$ 来自平方损失

例 A.1。 设 $\ell: \mathbb{R} \rightarrow \mathbb{R}$ 为平方损失函数，因此 $\ell(x) = x^2$ 对于 $x \in \mathbb{R}$ 。那么 $\ell'(x) = 2x$ 并且：

$$\begin{aligned} f_\ell(u) &= \lambda_1 \int_1^u 2 \log t dt + \lambda_2(u - 1) + c \\ &= 2\lambda_1 u \log(u) + \lambda_2(u - 1) + c, \end{aligned}$$

其中边界条件给出我们 $f_\ell(u) = u \log u$ 。

A.3. 命题 5.1 的证明

命题 5.1。 以下损失函数：

$$\mathcal{L}_f(\Delta(\tau, \theta, \phi)) = \int_0^{\Delta(\tau, \theta, \phi)} (f'(\exp(t)) - f'(1)) dt$$

将轨迹平衡推广到如下形式：

$$\begin{aligned} \nabla_\theta D_f(\pi_F \| \pi_B) &= \mathbb{E}_{\tau \sim \pi_{F, \theta}} [\nabla_\theta \mathcal{L}_f(\tau, \phi, \theta)] \\ \nabla_\phi D_h(\pi_B \| \pi_F) &= \mathbb{E}_{\tau \sim \pi_{B, \phi}} [\nabla_\phi \mathcal{L}_f(\tau, \phi, \theta)] \end{aligned}$$

其中， h 定义为：

$$h(u) = \int_1^u \left(2 - f' \left(\frac{1}{t} \right) \right) dt.$$

证明。 设轨迹对数概率差为 $\Delta(\tau) = \log \pi_F(\tau | \theta) - \log \pi_B(\tau | \phi)$ （吸收 Z 和 R 到定义中以便清晰）。令 $u(\tau) = \exp(\Delta(\tau)) = \frac{\pi_F(\tau)}{\pi_B(\tau)}$ 。标量损失关于 Δ 的梯度为 $\mathcal{L}'(\Delta) = f'(u) - f'(1)$ 。

附录 A.3.1. 正向策略梯度 (∇_θ) 我们考察在正向策略 π_F 下损失关于 θ 的期望自动微分梯度：

$$\mathbb{E}_{\tau \sim \pi_F} [\nabla_\theta \mathcal{L}_f] = \mathbb{E}_{\tau \sim \pi_F} \left[\frac{\partial \mathcal{L}_f}{\partial \Delta} \nabla_\theta \Delta(\tau) \right].$$

由于 π_B 不依赖于 θ , $\nabla_\theta \Delta(\tau) = \nabla_\theta \log \pi_F(\tau)$ 。因此：

$$\mathbb{E}_{\tau \sim \pi_F} [\nabla_\theta \mathcal{L}_f] = \mathbb{E}_{\tau \sim \pi_F} [(f'(u) - f'(1)) \nabla_\theta \log \pi_F(\tau)].$$

根据命题 4.3，我们知道 f -发散 $D_f(\pi_F \| \pi_B)$ 的梯度由下式给出：

$$\nabla_\theta D_f(\pi_F \| \pi_B) = \mathbb{E}_{\tau \sim \pi_F} [(f'(u) - c) \nabla_\theta \log \pi_F(\tau)],$$

其中 c 是任意常数。选择 $c = f'(1)$ 可精确恢复损失梯度。

附录 A.3.2. 反向策略梯度 (∇_ϕ) 我们考察在反向策略 π_B 下损失关于 ϕ 的期望自动微分梯度:

$$\mathbb{E}_{\tau \sim \pi_B} [\nabla_\phi \mathcal{L}_f] = \mathbb{E}_{\tau \sim \pi_B} \left[\frac{\partial \mathcal{L}_f}{\partial \Delta} \nabla_\phi \Delta(\tau) \right].$$

由于 π_F 不依赖于 ϕ , $\nabla_\phi \Delta(\tau) = -\nabla_\phi \log \pi_B(\tau)$ 。因此:

$$\mathbb{E}_{\tau \sim \pi_B} [\nabla_\phi \mathcal{L}_f] = \mathbb{E}_{\tau \sim \pi_B} [-(f'(u) - f'(1)) \nabla_\phi \log \pi_B(\tau)]. \quad (11)$$

现在考虑由凸生成器 h 定义的发散 $D_h(\pi_B \parallel \pi_F)$ 。其关于 ϕ 的梯度 (其中 π_B 是模型, π_F 是目标) 为:

$$\nabla_\phi D_h(\pi_B \parallel \pi_F) = \nabla_\phi \int \pi_F(\tau) h\left(\frac{\pi_B(\tau)}{\pi_F(\tau)}\right) d\tau.$$

Let $v(\tau) = \frac{\pi_B(\tau)}{\pi_F(\tau)} = \frac{1}{u(\tau)}$. 使用对于 f 发散的导数规则 (等同于正文中的公式 54, 但针对的是 h 和 π_B):

$$\nabla_\phi D_h(\pi_B \parallel \pi_F) = \mathbb{E}_{\tau \sim \pi_B} [(h'(v) - h'(1)) \nabla_\phi \log \pi_B(\tau)]. \quad (12)$$

为了匹配公式 (11) 和公式 (12), 我们需要得分函数的缩放项在常数偏移量上是等价的 (该偏移量在期望中消失)。我们将它们设为相等:

$$h'(v) = -f'(u) + C = -f'(1/v) + C.$$

使用命题中给出的 h 定义:

$$h(v) = \int_1^v \left(2 - f'\left(\frac{1}{t}\right) \right) dt \implies h'(v) = 2 - f'\left(\frac{1}{v}\right).$$

将其代入梯度期望中:

$$\nabla_\phi D_h(\pi_B \parallel \pi_F) = \mathbb{E}_{\tau \sim \pi_B} [(2 - f'(u) - h'(1)) \nabla_\phi \log \pi_B(\tau)].$$

将常数 2 和 $h'(1)$ 吸收进基线中, 这与损失梯度项 $-(f'(u) - f'(1))$ 相匹配。因此, 梯度是等价的。

A.3.3. 对于基于策略的反向梯度, 不存在 f -发散 在第 5 节中, 我们已经证明了当从反向策略中采样时, 反向策略 π_B 的梯度对应于最小化一个有效的 f -发散 $D_h(\pi_B \parallel \pi_F)$ 。在本节中, 我们研究在线策略设置, 其中样本是从正向策略 π_F 中抽取的, 并优化 π_B 以最小化替代损失 $\mathcal{L}_f$ 。

我们证明, 在线策略梯度更新对于 π_B 通常不对应于任何有效 f -发散的下降方向。虽然可以推导出生成函数 g 来局部匹配梯度, 但它无法满足标准选择的 f (如 KL 散度) 所需的全局凸性要求 ($g'' \geq 0$)。

A.4. 梯度匹配设置

我们寻求一个凸函数 $g: \mathbb{R}_+ \rightarrow \mathbb{R}$, 使得发散的梯度 $D_g(\pi_F \parallel \pi_B)$ 与从 π_F 采样时替代损失的期望梯度 $\mathcal{L}_f$ 相匹配。请注意, 我们将发散定义为 $D_g(\pi_F \parallel \pi_B)$, 因为期望是在 π_F 上取的。

Let $u(\tau) = \frac{\pi_F(\tau)}{\pi_B(\tau)}$.

1. 替代损失的梯度: 损失相对于反向参数的梯度, 基于策略估计, 为: $\mathcal{L}_f \phi$

$$\begin{aligned} \nabla_\phi \mathcal{J}_{\text{on}} &= \mathbb{E}_{\tau \sim \pi_F} [\nabla_\phi \mathcal{L}_f(\log u)] \\ &= \mathbb{E}_{\tau \sim \pi_F} [(f'(u) - f'(1)) \nabla_\phi (-\log \pi_B)] \\ &= \mathbb{E}_{\tau \sim \pi_F} [-f'(u) \nabla_\phi \log \pi_B] \end{aligned}$$

(常数项 $f'(1)$ 消失是因为 $\mathbb{E}_{\pi_F}[\nabla_\phi \log \pi_B] = 0$).

2. 候选发散的梯度：考虑一般的发散 $D_g(\pi_F \parallel \pi_B) =$ 对 ϕ 求导：

$$\int \pi_B(\tau) g\left(\frac{\pi_F(\tau)}{\pi_B(\tau)}\right) d\tau.$$

$$\nabla_\phi D_g = \int (\nabla_\phi \pi_B \cdot g(u) + \pi_B g'(u) \nabla_\phi u) d\tau$$

利用恒等式 $\nabla_\phi u = \pi_F \nabla_\phi (\pi_B^{-1}) = -u \nabla_\phi \log \pi_B$ 及 $\nabla_\phi \pi_B = \pi_B \nabla_\phi \log \pi_B$:

$$\begin{aligned} \nabla_\phi D_g &= \int \pi_B (g(u) - u g'(u)) \nabla_\phi \log \pi_B d\tau \\ &= \int \pi_F \frac{1}{u} (g(u) - u g'(u)) \nabla_\phi \log \pi_B d\tau \\ &= \mathbb{E}_{\tau \sim \pi_F} \left[\left(\frac{g(u)}{u} - g'(u) \right) \nabla_\phi \log \pi_B \right] \end{aligned}$$

A.5. 生成器的推导 g

令期望内的各项相等，得到梯度匹配的条件：

$$-f'(u) = \frac{g(u)}{u} - g'(u)$$

整理成关于 $g(u)$ 的线性常微分方程：

$$g'(u) - \frac{1}{u} g(u) = f'(u)$$

Using the integrating factor $I(u) = \exp(\int -\frac{1}{u} du) = \frac{1}{u}$ 我们求解：

$$\frac{d}{du} \left[\frac{g(u)}{u} \right] = \frac{f'(u)}{u} \quad (13)$$

$$\frac{g(u)}{u} = \int_1^u \frac{f'(t)}{t} dt + C \quad (14)$$

$$g(u) = u \int_1^u \frac{f'(t)}{t} dt + Cu \quad (15)$$

线性项 Cu 对应于常数期望的梯度，不影响凸性分析。

附录 A.6 非凸性的证明

为了使 D_g 成为有效的发散， g 必须是凸的，即对于所有 $u \in (0, \infty)$ 有 $g''(u) \geq 0$ 。我们计算方程 15 解的二阶导数：一阶导数：

$$g'(u) = \int_1^u \frac{f'(t)}{t} dt + u \left(\frac{f'(u)}{u} \right) = \int_1^u \frac{f'(t)}{t} dt + f'(u)$$

二阶导数：

$$g''(u) = \frac{f'(u)}{u} + f''(u) \quad (16)$$

我们现在测试这种情况最常见的例子：轨迹平衡损失，它对应于 KL 散度。

反例：KL 发散（轨迹平衡） 令 $f(u) = u \log u$ 。则 $f'(u) = 1 + \log u$ 和 $f''(u) = \frac{1}{u}$ 。

Substituting into Eq. 16:

$$\begin{aligned} g''(u) &= \frac{1 + \log u}{u} + \frac{1}{u} \\ g''(u) &= \frac{2 + \log u}{u} \end{aligned}$$

为了使 g 成为凸函数，我们需要对于所有 $u > 0$ ， $g''(u) \geq 0$ 成立。然而：

$$\frac{2 + \log u}{u} < 0 \iff \log u < -2 \iff u < e^{-2} \approx 0.135$$

由于 $u = \pi_F(\tau)/\pi_B(\tau)$ ，比率 u 在逆向策略分配的概率显著高于正向策略的区域很容易低于 e^{-2} 。在这个区域内， g 局部呈凹性。

结论： 因为 $g''(u)$ 并非处处非负， g 不定义一个有效的 f -发散。因此，逆向策略的在线策略优化不能解释为最小化分布之间的距离测度。更准确地说，它被描述为最小化对数比率的方差或满足特定于所选替代损失的矩匹配条件。

附录 B：梯度方差分析

B.1. f -DevGrad Variance Analysis

在本节中，我们证明从批量 DevGrad 损失导出的梯度估计器， $\mathcal{L}_f^{DG}$ ，等同于配备了一般偏差基线的 REINFORCE 估计器。我们证明批量归一化步骤隐式地强制梯度权重的零和约束，从而作为减少方差的控制变量。

梯度形式。 考虑批次损失函数在一批数据 $\mathcal{B} = \{\mathbf{y}_1, \dots, \mathbf{y}_B\}$ 上的偏差 $\Delta(\mathbf{y}_i) = \log \pi_\theta(\mathbf{y}_i) - \mathcal{R}(\mathbf{y}_i)$ ：

$$\mathcal{L}_f^{DG}(\mathcal{B}, \theta) = \min_C \frac{1}{B} \sum_{i=1}^B L_f(\Delta(\mathbf{y}_i) + C).$$

设 $\hat{C}$ 为此目标函数的最小值点（即批次估计值 $-\log Z$ ）。损失函数关于 θ 的梯度，将 $\hat{C}$ 视为固定（通过等式 30 中的停止梯度算子），为：

$$\hat{\mathbf{g}}^{DG} = \frac{1}{B} \sum_{i=1}^B L'_f(\Delta(\mathbf{y}_i) + \hat{C}) \nabla_\theta \log \pi_\theta(\mathbf{y}_i).$$

零和权重属性。 标量 $\hat{C}$ 由内层最小化问题的一阶最优性条件定义：

$$\left. \frac{\partial}{\partial C} \left(\frac{1}{B} \sum_{i=1}^B L_f(\Delta(\mathbf{y}_i) + C) \right) \right|_{C=\hat{C}} = \frac{1}{B} \sum_{i=1}^B L'_f(\Delta(\mathbf{y}_i) + \hat{C}) = 0.$$

设 $w_i = L'_f(\Delta(\mathbf{y}_i) + \hat{C})$ 为第 i 个样本的有效权重。最优性条件意味着 $\sum_{i=1}^B w_i = 0$ 。因此，估计器可以重写为一个依赖样本的基线 REINFORCE 估计器：

$$\hat{\mathbf{g}}^{DG} = \frac{1}{B} \sum_{i=1}^B (\tilde{w}_i - \hat{b}) \nabla_\theta \log \pi_\theta(\mathbf{y}_i),$$

其中 $\tilde{w}_i$ 表示从 f' 导出的未中心化的梯度系数，而 $\hat{b}$ 是从 $\hat{C}$ 得出的隐式基线，使得系数之和为零。

B.2. f -轨迹平衡方差分析

我们将前向策略参数 θ 的梯度估计器的方差，从 f -轨迹平衡损失函数 $\hat{g}_{f\text{-TB}}$ ，与标准得分函数估计器 $\hat{g}_{\text{SF}}$ 进行比较。

设 τ 是从前向策略 $\pi_F(\cdot|\theta)$ 采样的完整轨迹。我们定义轨迹似然比为 $u(\tau) = \frac{Z_\theta \pi_F(\tau|\theta)}{R(x_\tau) \pi_B(\tau|x_\tau, \phi)}$ 。

利用得分函数 $S(\tau) = \nabla_\theta \log \pi_F(\tau|\theta)$ ，估计量由下式给出：

$$\begin{aligned} \hat{g}_{\text{SF}} &= f'(u(\tau))S(\tau), \\ \hat{g}_{f\text{-TB}} &= (f'(u(\tau)) - f'(1))S(\tau) = (f'(u(\tau)) - 1)S(\tau). \end{aligned}$$

由于 $\mathbb{E}_{\tau \sim \pi_F}[S(\tau)] = 0$ ，两个估计量都是无偏的。它们方差之差取决于其期望平方范数之差：

$$\begin{aligned}\text{Var}(\hat{g}_{f\text{-TB}}) - \text{Var}(\hat{g}_{\text{SF}}) &= \mathbb{E}_{\tau \sim \pi_F} [((f'(u(\tau)) - 1)^2 - f'(u(\tau))^2) \|S(\tau)\|^2] \\ &= \mathbb{E}_{\tau \sim \pi_F} [(1 - 2f'(u(\tau))) \|S(\tau)\|^2].\end{aligned}$$

在满足轨迹平衡约束的全局最优解处，我们有 $Z_{\theta} \pi_F(\tau) = R(x_{\tau}) \pi_B(\tau)$ ，这意味着对于所有采样的 τ ，都有 $u(\tau) = 1$ 。给定归一化条件 $f'(1) = 1$ ，期望值内的项变为：

$$1 - 2f'(1) = -1.$$

因此，在最优解处，方差之差为 $-\mathbb{E}[\|S(\tau)\|^2]$ ，对于随机策略而言，该值严格小于零。

由于 f 是严格凸且可微的，因此 f' 是连续的。由此，根据期望值的连续性，在最优解附近存在一个邻域（其中 $u(\tau) \approx 1$ ），使得 $\mathbb{E}_{\tau \sim \pi_F}[(1 - 2f'(u(\tau))) \|S(\tau)\|^2] < 0$ 。因此，在最优解附近， f -轨迹平衡估计器的方差严格低于标准得分函数估计器。

附录 C. 损失导出及其性质

在本附录中，我们给出了多种标准 f -发散的定义，并推导了 f -轨迹损失的闭式形式。我们还推导了批量 DevGrad 归一化、LLM DevGrad 公式以及温度调整后的 LLM DevGrad 公式。我们假设标准归一化条件 $f'(1) = 1$ 和 $f''(1) = 1$ 。回顾符号，我们有：

- **Generic:** $\Delta_{\theta}(\mathbf{y}_i) = \log p_{\theta}(\mathbf{y}_i) - \mathcal{R}(\mathbf{y}_i)$.
- **大型语言模型微调:** 目标是由奖励 $r(\mathbf{x}, \mathbf{y})$ 和参考 π_{ref} 定义的玻尔兹曼分布。

$$\mathcal{R}(\mathbf{y}_i) = \log \pi_{\text{ref}}(\mathbf{y}_i) + \frac{r(\mathbf{x}, \mathbf{y}_i)}{\beta}$$

偏差展开为：

$$\Delta_{\theta}(\mathbf{y}_i) = \log \frac{\pi_{\theta}(\mathbf{y}_i | \mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}_i | \mathbf{x})} - \frac{r(\mathbf{x}, \mathbf{y}_i)}{\beta}$$

损失函数， $\mathcal{L}_f$ ，由 $\mathcal{L}_f(\Delta_{\theta}(\mathbf{y})) = \int \Delta_{\theta}(\mathbf{y}) \cdot 0 \cdot f'(\exp(t)) - f'(1) dt$ 给出。一般批量的 DevGrad 损失定义为：

$$\mathcal{L}_f^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_i \mathcal{L}_f(\Delta(\mathbf{y}_i) + \text{SG}[\widehat{\log Z}])$$

$$\text{where: } \widehat{\log Z} = \arg \min_C \frac{1}{B} \sum_i \mathcal{L}_f(\Delta(\mathbf{y}_i) + C)$$

$$\text{Which must satisfy: } \frac{1}{B} \sum_i \mathcal{L}'_f(\Delta(\mathbf{y}_i) + \widehat{\log Z}) = 0$$

最后，我们将温度为 τ 的停止梯度 Softmax 定义为奖励 $\mathbf{r}$ 的归一化重要性权重：

$$\tilde{\sigma}_{\tau}(\mathbf{r})_i = \frac{\exp(r(\mathbf{x}, \mathbf{y}_i)/\tau)}{\text{SG}[\sum_{j=1}^B \exp(r(\mathbf{x}, \mathbf{y}_j)/\tau)]}$$

其中 $\text{SG}[\cdot]$ 表示停止梯度运算符。

C.1. 反向 KL 发散

生成器： $f(u) = u \log u$.

推导：通过 $f'(u) = 1 + \log u$, 被积函数变为 t .

$$\mathcal{L}_{\text{RKL}}(\Delta) = \int_0^\Delta t dt = \frac{1}{2} \Delta^2.$$

批量归一化：最优性条件 $\sum (\Delta_i + \log Z) = 0$ 得到均值差：

$$\widehat{\log Z} = -\frac{1}{B} \sum_{i=1}^B \Delta(\mathbf{y}_i) \xrightarrow[\text{LLM}]{\pi_\theta \approx \pi_{\text{ref}}} -\frac{1}{B} \sum_{i=1}^B \frac{r(\mathbf{x}, \mathbf{y}_i)}{\beta}.$$

批量偏差梯度损失：我们将均值差代入归一化常数。

$$\mathcal{L}_{\text{RKL}}^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{2B} \sum_{i=1}^B \left(\Delta(\mathbf{y}_i) - \text{SG} \left[\frac{1}{B} \sum_{j=1}^B \Delta(\mathbf{y}_j) \right] \right)^2.$$

批量偏差梯度损失 (LLM)：奖励调整后的对数比率的 Vargrad 损失：

$$\mathcal{L}_{\text{RKL}}^{\text{DG}} = \frac{1}{2} \text{Var} \left[\log \frac{\pi_\theta(\mathbf{y})}{\pi_{\text{ref}}(\mathbf{y})} - \frac{r(\mathbf{x}, \mathbf{y})}{\beta} \right].$$

调温逆 KL 发散 (KIMI 损失) 从例 4.10 可知，逆 KL 对应的调温损失等于奖励调整后的对数概率的方差乘以 β 。这恢复了标准的 Kimi 设置：

$$\tilde{\mathcal{L}}_{\text{RKL}}^{\text{DG}} = \frac{1}{2\beta} \text{Var} \left[\beta \log \frac{\pi_\theta(\mathbf{y}|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}|\mathbf{x})} - r(\mathbf{x}, \mathbf{y}) \right].$$

C.2. 正向 KL 发散

Generator: $f(u) = 2(u - 1) - \log u$.

Derivation: With $f'(u) = 2 - u^{-1}$, the integrand is $1 - e^{-t}$.

$$\mathcal{L}_{\text{FKL}}(\Delta) = \int_0^\Delta (1 - e^{-t}) dt = \Delta + e^{-\Delta} - 1.$$

Batch-wise Normalization: The condition $\sum (1 - e^{-(\Delta_i + \widehat{\log Z})}) = 0$ implies $\sum e^{-\Delta_i} e^{-\widehat{\log Z}} = B$:

$$\widehat{\log Z} = \log \left(\frac{1}{B} \sum_{i=1}^B e^{-\Delta(\mathbf{y}_i)} \right) \xrightarrow[\text{LLM}]{\pi_\theta \approx \pi_{\text{ref}}} \log \left(\frac{1}{B} \sum_{i=1}^B e^{r(\mathbf{x}, \mathbf{y}_i)/\beta} \right).$$

批量偏差梯度损失：将 $\log Z$ 代入鲁棒形式 $\Delta + \log Z + e^{-\Delta} e^{-\widehat{\log Z}} - 1$:

$$\mathcal{L}_{\text{FKL}}^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_{i=1}^B \left[\Delta(\mathbf{y}_i) + \text{SG} \left[\log \left(\frac{1}{B} \sum_{j=1}^B e^{-\Delta(\mathbf{y}_j)} \right) \right] + \frac{e^{-\Delta(\mathbf{y}_i)}}{\text{SG} \left[\frac{1}{B} \sum_{j=1}^B e^{-\Delta(\mathbf{y}_j)} \right]} - 1 \right].$$

批量偏差梯度损失 (LLM)：在 Kimi 假设 ($\Delta \approx -r/\beta$) 下，归一化依赖于带有温度的奖励 β .

$$\mathcal{L}_{\text{FKL}}^{\text{DG}} = \frac{1}{B} \sum_{i=1}^B \left[\log \frac{\pi_\theta(\mathbf{y}_i|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x}) (B \cdot \tilde{\sigma}_\beta(\mathbf{r})_i)} + \frac{(B \cdot \tilde{\sigma}_\beta(\mathbf{r})_i) \pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})}{\pi_\theta(\mathbf{y}_i|\mathbf{x})} - 1 \right].$$

调温正向 KL 发散 将调温变换应用于公式 110。归一化的温度从 β to 1。

$$\tilde{\mathcal{L}}_{\text{FKL}}^{\text{DG}} = \frac{1}{B\beta} \sum_{i=1}^B \left[\log \frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})^{\beta}}{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})^{\beta} (B \cdot \tilde{\sigma}_1(\mathbf{r})_i)} + (B \cdot \tilde{\sigma}_1(\mathbf{r})_i) \left(\frac{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})}{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})} \right)^{\beta} - 1 \right].$$

C.3. Pearson χ^2 Divergence

生成器： $f(u) = \frac{1}{2}(u-1)^2 + (u-1)$.

推导： 利用 $f'(u) = u$ ，被积函数为 $e^t - 1$ 。

$$\mathcal{L}_{\chi^2}(\Delta) = \int_0^{\Delta} (e^t - 1) dt = e^{\Delta} - \Delta - 1.$$

Batch-wise Normalization: The condition $\sum (e^{\Delta_i + \widehat{\log Z}} - 1) = 0$ implies $e^{\widehat{\log Z}} \sum e^{\Delta_i} = B$:

$$\widehat{\log Z} = -\log \left(\frac{1}{B} \sum_{i=1}^B e^{\Delta(\mathbf{y}_i)} \right) \xrightarrow[\text{LLM}]{\pi_{\theta} \approx \pi_{\text{ref}}} -\log \left(\frac{1}{B} \sum_{i=1}^B e^{-r(\mathbf{x}, \mathbf{y}_i)/\beta} \right).$$

批量偏差梯度损失： 将 $\log Z$ 代入鲁棒形式 $e^{\Delta} e^{\log Z} - (\Delta + \widehat{\log Z}) - 1$:

$$\mathcal{L}_{\chi^2}^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_{i=1}^B \left[\frac{e^{\Delta(\mathbf{y}_i)}}{\text{SG} \left[\frac{1}{B} \sum_{j=1}^B e^{\Delta(\mathbf{y}_j)} \right]} - \Delta(\mathbf{y}_i) - \text{SG} \left[-\log \left(\frac{1}{B} \sum_{j=1}^B e^{\Delta(\mathbf{y}_j)} \right) \right] - 1 \right].$$

批量偏差梯度损失 (LLM)： 基于假设 $\Delta \approx -r/\beta$ ，归一化过程实际上采用了负温度。
 $-\beta$.

$$\mathcal{L}_{\chi^2}^{\text{DG}} = \frac{1}{B} \sum_{i=1}^B \left[\frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})}{(B \cdot \tilde{\sigma}_{-\beta}(\mathbf{r})_i) \pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})} - \log \frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})}{(B \cdot \tilde{\sigma}_{-\beta}(\mathbf{r})_i) \pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})} + 1 \right].$$

C.4. Neyman χ^2 Divergence

生成器： $f(u) = \frac{(u-1)^2}{2u} + (u-1)$.

Properties: *Mass-covering*. Heavily penalizes under-estimation of the target probability.

Derivation: With $f'(u) = \frac{3}{2} - \frac{1}{2}u^{-2}$ ，被积函数变为 $\frac{1}{2} - \frac{1}{2}e^{-2t}$.

$$\mathcal{L}_{\text{Ney}}(\Delta) = \frac{1}{2}\Delta + \frac{1}{4}e^{-2\Delta} - \frac{1}{4}.$$

Batch-wise Normalization: The condition $\sum (\frac{1}{2} - \frac{1}{2}e^{-2(\Delta_i + \widehat{\log Z})}) = 0$ implies $e^{-2\widehat{\log Z}} \sum e^{-2\Delta_i} = B$:

$$\widehat{\log Z} = \frac{1}{2 \log} \left(\frac{1}{B} \sum_{i=1}^B e^{-2\Delta(\mathbf{y}_i)} \right) \xrightarrow[\text{LLM}]{\pi_{\theta} \approx \pi_{\text{ref}}} \frac{1}{2} \log \left(\frac{1}{B} \sum_{i=1}^B e^{2r(\mathbf{x}, \mathbf{y}_i)/\beta} \right).$$

批量偏差梯度损失： 将 $\log Z$ 和 $\log Z$ 代入鲁棒形式 $\frac{1}{2}(\Delta + \widehat{\log Z}) + \frac{1}{4}e^{-2\Delta}e^{-2\widehat{\log Z}} - \frac{1}{4}$:

$$\mathcal{L}_{\text{Ney}}^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_{i=1}^B \left[\frac{1}{2} \Delta(\mathbf{y}_i) + \text{SG} \left[\frac{1}{2 \log} \left(\frac{1}{B} \sum_{j=1}^B e^{-2\Delta(\mathbf{y}_j)} \right) \right] + \frac{\frac{1}{4}e^{-2\Delta(\mathbf{y}_i)}}{\text{SG} \left[\frac{1}{B} \sum_{j=1}^B e^{-2\Delta(\mathbf{y}_j)} \right]} - \frac{1}{4} \right].$$

温控 Neyman χ^2 发散 应用温控变换到等式 120。归一化的温度从 $\beta/2$ 变化到 $1/2$ 。

$$\tilde{\mathcal{L}}_{\text{Ney}}^{\text{DG}} = \frac{1}{B\beta} \sum_{i=1}^B \left[\frac{1}{2} \log \frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})^{\beta}}{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})^{\beta} (B \cdot \tilde{\sigma}_{1/2}(\mathbf{r})_i)} + \frac{1}{4} \left(\frac{(B \cdot \tilde{\sigma}_{1/2}(\mathbf{r})_i) \pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})^{\beta}}{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})^{\beta}} \right)^2 - \frac{1}{4} \right].$$

C.5. 平方 Hellinger 距离

生成器： $f(u) = 2(\sqrt{u} - 1)^2 + (u - 1)$.

属性： 模式覆盖/鲁棒。平衡模式覆盖与稳定性。梯度有界为 $\Delta \rightarrow -\infty$ ，不同于 Forward KL 线性增长。

推导： $f'(u) = 3 - 2u^{-1/2}$, 被积函数变为 $2 - 2e^{-t/2}$.

$$\mathcal{L}_{H^2}(\Delta) = \int_0^\Delta (2 - 2e^{-t/2}) dt = 2\Delta + 4e^{-\Delta/2} - 4.$$

Batch-wise Normalization: The condition $\sum (2 - 2e^{-(\Delta_i + \widehat{\log Z})/2}) = 0$ implies $e^{-\widehat{\log Z}/2} \sum e^{-\Delta_i/2} = B$:

$$\widehat{\log Z} = 2 \log \left(\frac{1}{B} \sum_{i=1}^B e^{-\frac{1}{2}\Delta(\mathbf{y}_i)} \right) \xrightarrow[\text{LLM}]{\pi_\theta \approx \pi_{\text{ref}}} 2 \log \left(\frac{1}{B} \sum_{i=1}^B e^{\frac{1}{2\beta} r(\mathbf{x}, \mathbf{y}_i)} \right).$$

批量偏差梯度损失： 将 $\log Z$ 代入鲁棒形式 $2(\Delta + \log Z) + 4e^{-\Delta/2}e^{-\widehat{\log Z}/2} - 4$:

$$\mathcal{L}_{H^2}^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_{i=1}^B \left[2\Delta(\mathbf{y}_i) + \text{SG} \left[4 \log \left(\frac{1}{B} \sum_{j=1}^B e^{-\frac{1}{2}\Delta(\mathbf{y}_j)} \right) \right] + \frac{4e^{-\frac{1}{2}\Delta(\mathbf{y}_i)}}{\text{SG} \left[\frac{1}{B} \sum_{j=1}^B e^{-\frac{1}{2}\Delta(\mathbf{y}_j)} \right]} - 4 \right].$$

批量偏差梯度损失 (LLM)： 归一化项对应于具有温度的 Softmax 函数 2β 。

$$\mathcal{L}_{H^2}^{\text{DG}} = \frac{1}{B} \sum_{i=1}^B \left[2 \log \frac{\pi_\theta(\mathbf{y}_i|\mathbf{x})}{(B \cdot \tilde{\sigma}_{2\beta}(\mathbf{r})_i) \pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})} + 4 \sqrt{(B \cdot \tilde{\sigma}_{2\beta}(\mathbf{r})_i) \frac{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})}{\pi_\theta(\mathbf{y}_i|\mathbf{x})}} - 4 \right].$$

温氏平方 Hellinger 距离 将温氏变换应用于公式 117。归一化温度从 2β 变化到 2。

$$\tilde{\mathcal{L}}_{H^2}^{\text{DG}} = \frac{1}{B\beta} \sum_{i=1}^B \left[2 \log \frac{\pi_\theta(\mathbf{y}_i|\mathbf{x})^\beta}{(B \cdot \tilde{\sigma}_2(\mathbf{r})_i) \pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})^\beta} + 4 \sqrt{(B \cdot \tilde{\sigma}_2(\mathbf{r})_i) \left(\frac{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})}{\pi_\theta(\mathbf{y}_i|\mathbf{x})} \right)^\beta} - 4 \right].$$

C.6. Jensen-Shannon 发散

生成器： $f(u) = u \log u - (u + 1) \log \frac{u+1}{2} + \text{线性项}$ 。推导：使用 $f'(u) = 2 \log(\frac{2u}{u+1}) + 1$ ，我们逐项积分涉及双对数函数 Li_2 。

$$\mathcal{L}_{\text{JSD}}(\Delta) = \Delta^2 + 2\Delta \log 2 + 2\text{Li}_2(-e^\Delta) + \frac{\pi^2}{6}.$$

批归一化：条件 $\sum \log(2 \exp(\Delta_i + \widehat{\log Z})) = 0$ 需要找到根 Z ：

$$\prod_{i=1}^B \frac{2e^{\Delta_i} Z}{e^{\Delta_i} Z + 1} = 1.$$

这没有封闭形式的解，需要数值求根方法。

批量偏差梯度损失： 不存在封闭形式的简化。损失通过数值求解 $\widehat{\log Z}$ 使用上述求根方程，并将其代入损失表达式中计算得出：

$$\mathcal{L}_{\text{JSD}}^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_{i=1}^B \mathcal{L}_{\text{JSD}}(\Delta(\mathbf{y}_i) + \text{SG}[\widehat{\log Z}]).$$

C.7. α -发散

Generator: $f(u) = \frac{u^{\alpha}-u}{\alpha(\alpha-1)} + \frac{\alpha-1}{\alpha}(u-1)$.

Derivation: With $f'(u) = \frac{u^{\alpha-1}}{\alpha-1} + \frac{\alpha-2}{\alpha-1}$, the integrand is $\frac{1}{\alpha-1}(e^{(\alpha-1)t} - 1)$.

$$\mathcal{L}_{\alpha}(\Delta) = \frac{1}{(\alpha-1)^2}e^{(\alpha-1)\Delta} - \frac{\Delta}{\alpha-1} - \frac{1}{(\alpha-1)^2}.$$

批归一化: 条件 $\sum \left(\frac{e^{(\alpha-1)(\Delta_i + \log \hat{Z})} - 1}{\alpha-1} \right) = 0$ implies $e^{(\alpha-1)\log \hat{Z}} \sum e^{(\alpha-1)\Delta_i} = B$ 求解 $\log \hat{Z}$:

$$\widehat{\log Z} = \frac{1}{1-\alpha} \log \left(\frac{1}{B} \sum_{i=1}^B e^{(\alpha-1)\Delta(\mathbf{y}_i)} \right) \xrightarrow[\text{LLM}]{\pi_{\theta} \approx \pi_{\text{ref}}} \frac{1}{1-\alpha} \log \left(\frac{1}{B} \sum_{i=1}^B e^{-(\alpha-1)r(\mathbf{x}, \mathbf{y}_i)/\beta} \right).$$

批量偏差梯度损失: 将 $\log \hat{Z}$ 代入鲁棒形式中, 与 $\mathcal{C}_{\alpha} = \frac{1}{(\alpha-1)^2}$:

$$\mathcal{L}_{\alpha}^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_{i=1}^B \left[\frac{\mathcal{C}_{\alpha} e^{(\alpha-1)\Delta(\mathbf{y}_i)}}{\text{SG} \left[\frac{1}{B} \sum_{j=1}^B e^{(\alpha-1)\Delta(\mathbf{y}_j)} \right]} - \frac{\Delta(\mathbf{y}_i) + \text{SG} \left[\frac{1}{1-\alpha} \log \left(\frac{1}{B} \sum_{j=1}^B e^{(\alpha-1)\Delta(\mathbf{y}_j)} \right) \right]}{\alpha-1} - \mathcal{C}_{\alpha} \right].$$

批量偏差梯度损失 (LLM) : 这有效地使用温度 β 进行归一化 $\frac{1}{1-\alpha}$ 。

$$\mathcal{L}_{\alpha}^{\text{DG}} = \frac{1}{B(\alpha-1)^2} \sum_{i=1}^B \left[\left(B \cdot \tilde{\sigma}_{\frac{\beta}{1-\alpha}}(\mathbf{r})_i \right) \left(\frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})} \right)^{\alpha-1} - (\alpha-1) \log \frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})}{\left(B \cdot \tilde{\sigma}_{\frac{\beta}{1-\alpha}}(\mathbf{r})_i \right) \pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})} - 1 \right].$$

这种统一形式表明 α 控制用于归一化的奖励 Softmax 函数的温度。对于正向 KL ($\alpha \rightarrow 0$), 温度是 β ; 对于 Pearson ($\alpha = 2$), 它是 $-\beta$; 而对于 Hellinger ($\alpha = 0.5$), 它是 2β 。

广义缓和 α -发散 广义形式适用于任何 α , 其中归一化温度变为 $\frac{1}{1-\alpha}$:

$$\tilde{\mathcal{L}}_{\alpha}^{\text{DG}} = \frac{1}{B\beta(\alpha-1)^2} \sum_{i=1}^B \left[\frac{C_{\alpha, \text{temp}}}{\left(B \cdot \tilde{\sigma}_{\frac{1}{1-\alpha}}(\mathbf{r})_i \right)} \left(\frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})} \right)^{\beta(\alpha-1)} - (\alpha-1) \log \frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})^{\beta}}{\left(B \cdot \tilde{\sigma}_{\frac{1}{1-\alpha}}(\mathbf{r})_i \right) \pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})^{\beta}} - 1 \right].$$

C.8. 总变差

生成器: $f(u) = |u-1|$.

推导: 假设次梯度约定满足 $f'(1) = 1$ 和对称性, 我们使用 $f'(u) = \text{sgn}(u-1)$ 。被积函数变为 $\text{sgn}(u \neq 1) (e^t - 1) = \text{sgn}(t)$ 。

$$\mathcal{L}_{\text{TV}}(\Delta) = \int_0^{\Delta} \text{sgn}(t) dt = |\Delta|.$$

批量归一化: 最小化批次损失对应于最小化绝对偏差之和。最小化器是输入值反号后的中位数:

$$\widehat{\log Z} = -\text{Median}(\{\Delta(\mathbf{y}_i)\}_{i=1}^B) \xrightarrow[\text{LLM}]{\pi_{\theta} \approx \pi_{\text{ref}}} \text{中位数} \left(\left\{ \frac{r(\mathbf{x}, \mathbf{y}_i)}{\beta} \right\}_{i=1}^B \right).$$

批量偏差梯度损失: 这导致了对数概率差异的平均绝对偏差 (MAD):

$$\mathcal{L}_{\text{TV}}^{\text{DG}}(\mathcal{B}, \theta) = \frac{1}{B} \sum_{i=1}^B \left| \Delta(\mathbf{y}_i) - \text{SG}[\text{Median}(\{\Delta(\mathbf{y}_j)\}_{j=1}^B)] \right|.$$

批量偏差梯度损失 (LLM) : 这导致了奖励调整后的对数比率的平均绝对偏差。

$$\mathcal{L}_{\text{TV}}^{\text{DG}} = \frac{1}{B} \sum_{i=1}^B \left| \log \frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})} - \frac{r(\mathbf{x}, \mathbf{y}_i)}{\beta} - \text{SG} \left[\text{中位数} \left(\left\{ \log \frac{\pi_{\theta}(\mathbf{y}_j|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}_j|\mathbf{x})} - \frac{r(\mathbf{x}, \mathbf{y}_j)}{\beta} \right\}_{j=1}^B \right) \right] \right|.$$

温控总变差 将温控变换应用于公式 130。归一化依赖于温控偏差的中位数 $\delta \approx -r$ ，消除了绝对差异内部的除以 β 的操作。

$$\tilde{\mathcal{L}}_{\text{TV}}^{\text{DG}} = \frac{1}{B\beta} \sum_{i=1}^B \left| \beta \log \frac{\pi_{\theta}(\mathbf{y}_i|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}_i|\mathbf{x})} - r(\mathbf{x}, \mathbf{y}_i) - \text{SG} \left[\text{中位数} \left(\left\{ \beta \log \frac{\pi_{\theta}(\mathbf{y}_j|\mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}_j|\mathbf{x})} - r(\mathbf{x}, \mathbf{y}_j) \right\}_{j=1}^B \right) \right] \right|.$$

D. DevGrad 损失的梯度分析

在本节中，我们推导出批量 DevGrad 损失的闭式梯度（ $\mathcal{L}_f^{\text{DG}}$ ）。从公式 91 可知，参数 θ 关于 DevGrad 损失的梯度由下式给出：

$$\nabla_{\theta} \mathcal{L}_f^{\text{DG}}(\mathcal{B}) = \frac{1}{B} \sum_{i=1}^B w_i^{\text{DG}} \nabla_{\theta} \log \pi_{\theta}(\mathbf{y}_i|\mathbf{x})$$

其中，第 i 个样本的有效梯度权重为 $w_i^{\text{DG}} = L'_f(\Delta_i + \log Z)$ 。由于 $\log Z$ 的最优性条件（公式 92），这些权重始终满足零和性质 $\sum w_i^{\text{DG}} = 0$ ，起到控制变量的作用。

下文将 $\delta_i = \Delta(\mathbf{y}_i) + \log Z$ 定义为归一化的偏差。我们将批量均值操作表示为 $\mathbb{E}_{\mathcal{B}}[\cdot] = \frac{1}{B} \sum_{j=1}^B (\cdot)$ 。

1. 反向 KL 发散（标准 Vargrad）

归一化： $\log Z = -\mathbb{E}_{\mathcal{B}}[\Delta(\mathbf{y})]$.

• 梯度权重：

$$w_i^{\text{DG}} = \Delta_i - \mathbb{E}_{\mathcal{B}}[\Delta(\mathbf{y})]$$

2. 正向 KL 发散

• **Normalization:** $\log Z$ satisfies $\mathbb{E}_{\mathcal{B}}[e^{-(\Delta + \log Z)}] = 1 \implies e^{\log Z} = \mathbb{E}_{\mathcal{B}}[e^{-\Delta}]$.

• 梯度权重：

$$w_i^{\text{DG}} = 1 - \frac{e^{-\Delta_i}}{\mathbb{E}_{\mathcal{B}}[e^{-\Delta(\mathbf{y})}]}$$

3. 皮尔逊 χ^2 发散

• **Normalization:** $\log Z$ satisfies $\mathbb{E}_{\mathcal{B}}[e^{\Delta + \log Z}] = 1 \implies e^{-\log Z} = \mathbb{E}_{\mathcal{B}}[e^{\Delta}]$.

• 梯度权重：

$$w_i^{\text{DG}} = \frac{e^{\Delta_i}}{\mathbb{E}_{\mathcal{B}}[e^{\Delta(\mathbf{y})}]} - 1$$

4. 内曼 χ^2 发散

归一化： $e^{2\log Z} = \mathbb{E}_{\mathcal{B}}[e^{-2\Delta}]$.

• 梯度权重：

$$w_i^{\text{DG}} = \frac{1}{2} \left(1 - \frac{e^{-2\Delta_i}}{\mathbb{E}_{\mathcal{B}}[e^{-2\Delta(\mathbf{y})}]} \right)$$

5. 平方 Hellinger 距离

归一化： $e^{\frac{1}{2}\log Z} = \mathbb{E}_{\mathcal{B}}[e^{-\Delta/2}]$.

- 梯度权重:

$$w_i^{DG} = 2 \left(1 - \frac{e^{-\Delta_i/2}}{\mathbb{E}_{\mathcal{B}}[e^{-\Delta(\mathbf{y})/2}] \right)$$

6. 总变差

- 归一化: $\log Z = -\text{中位数}(\{\Delta_j\})$ 。
- 梯度权重:

$$w_i^{DG} = \text{sgn}(\Delta_i - \text{Median}(\{\Delta(\mathbf{y})\}))$$

7. General α -发散

归一化: $e^{(\alpha-1)\log Z} = (\mathbb{E}_{\mathcal{B}}[e^{(\alpha-1)\Delta}])^{-1}$.

- 梯度权重:

$$w_i^{DG} = \frac{1}{\alpha - 1} \left(\frac{e^{(\alpha-1)\Delta_i}}{\mathbb{E}_{\mathcal{B}}[e^{(\alpha-1)\Delta(\mathbf{y})}]} - 1 \right)$$

E. 最小实现

在本节中，我们提供了适用于标准情况的损失函数的最小化表述

```
1 import torch, math

3 def log_z_estimate(delta, name='ReverseKL', alpha=1):
4     B = delta.size(0)
5     logmeanexp = lambda k: torch.logsumexp(k * delta, 0) - math.log(B)
6     return {
7         'ReverseKL': lambda: -delta.mean(),
8         'ForwardKL': lambda: logmeanexp(-1.0),
9         'Pearson': lambda: -logmeanexp(1.0),
0         'Hellinger': lambda: 2.0 * logmeanexp(-0.5),
1         'NeymanChi2': lambda: 0.5 * logmeanexp(-2.0),
2         'TotalVariation': lambda: -delta.median(),
3         'Alpha': lambda: (1.0 / (1.0 - alpha)) * logmeanexp(alpha - 1.0)
4     }[name]()

16 def devgrad_loss(delta, name='ReverseKL', alpha=1):
17     name = 'ReverseKL' if (name == 'Alpha' and abs(alpha - 1) < 1e-4) else name
18     d = delta + log_z_estimate(delta, name, alpha).detach()
19     return {
20         'ReverseKL': lambda: 0.5 * d**2,
21         'ForwardKL': lambda: d + (-d).exp() - 1,
22         'Pearson': lambda: d.exp() - d - 1,
23         'Hellinger': lambda: 2*d + 4*(-0.5*d).exp() - 4,
24         'NeymanChi2': lambda: 0.5*d + 0.25*(-2*d).exp() - 0.25,
25         'TotalVariation': lambda: d.abs(),
26         'Alpha': lambda: (1/(alpha-1)**2) * ((alpha-1)*d).exp() - d/(alpha-1) -
27         (1/(alpha-1)**2)
28     }[name]().mean()

29 def tempered_devgrad_loss(log_pi, log_ref, reward, beta=1.0, name='ReverseKL', alpha=1):
30     delta_beta = (beta * (log_pi - log_ref)) - reward
31     raw_loss = devgrad_loss(delta_beta, name, alpha)
32     return raw_loss / beta
```

Listing 1. Implementation of Tempered DevGrad Loss

F. 实验

F.1. 合成网格实验

对于合成网格实验，我们采用了与 Malkin 等人 (2022b) 相同的设置，具体参数如下：

- 维度 (D)：网格的维度性。

$$D = 2$$

- H • 边长 ($:$ 每维网格的分辨率。

$$H = 128$$

- 状态空间 ($\mathcal{S}$)：表示网格中坐标的非终止状态集合。

$$\mathcal{S}^o = \{0, 1, \dots, H-1\}^D$$

过程从初始状态 $s_0 = \mathbf{0} = (0, \dots, 0)$ 开始。

- R_0 • 探索参数 ($:$ 一个背景奖励常数，决定奖励信号的稀缺程度。

$$R_0 = 0.001$$


- 奖励函数 (R)：定义在终止状态上的未归一化密度 $s^\top = (s^1, \dots, s^D)$ 。它由背景项 R_0 以及两个基于区域的项组成，这两个项在角落附近创建模式。

$$R(s^\top) = R_0 + 0.5 \prod_{d=1}^D \mathbb{I} \left[\left| \frac{s^d}{H-1} - 0.5 \right| \in (0.25, 0.5] \right] + 2 \prod_{d=1}^D \mathbb{I} \left[\left| \frac{s^d}{H-1} - 0.5 \right| \in (0.3, 0.4) \right]$$

其中 $\mathbb{I}[\cdot]$ 是指示函数，如果条件成立则为 1，否则为 0。

- 动作空间：在任意状态 $s = (s^1, \dots, s^D)$ 下，允许的动作有：1. 将一个坐标 d 增加 1： $s \rightarrow s + e_d$ (仅当 $s^d < H-1$ 时允许)。2. 终止： $s \rightarrow s^\top$ (转移到相应的终止状态在 $\mathcal{X}$)。

我们还提供了以下图表，展示了相同损失下的在线策略训练，显示出相似的趋势：



(a) JSD vs. Trajectories

(b) Modes Found vs. Trajectories


图 4. 主文中的合成网格实验的在线策略再现。

F.2. SynFlowNet 实验


本文展示了我们在 Cretu 等人 (2025) 提出的三项任务上的 SynFlowNet 实验结果。这些任务均基于生物活性和结合亲和力作为奖励：

- sEH（可溶性环氧化物水解酶）：使用预训练的代理模型（消息传递神经网络）进行训练，以预测 AutoDock Vina 结合能量。
- GSK3 β （糖原合酶激酶-3 β ）：作为 PMO 基准中的预言函数，用于预测生物活性。
- DRD2（多巴胺受体 D2）：作为 PMO 基准中的预言函数，用于预测生物活性。


我们展示了在不同逆温度值， β ，下的实验结果，以便理解我们的 α 参数如何与 GFlowNets 中自然调节模式搜索与覆盖行为的方式相互作用。我们固定了原始 SynFlowNet 实验中使用的超参数设置。首先，我们展示了生成的独特分子的奖励分布以及分子多样性，这表明在训练过程中退火 α 最终会产生更高的奖励分子。这一点也可以从我们随后添加的奖励函数 CDF 的额外图中看出。最后，我们增加了跨实验设置的多样性图，展示对于每个 α, β 设置，我们训练了 5 个种子，每个种子需要 3 小时 H100 来训练。



(a) DRD2 reward distributions



(b) GSK3 reward distributions



(c) sEH reward distributions

图 5. Synflownet 训练中不同 alpha beta 值的扫描奖励分布







图 6. 不同目标（列）和 β 值（行）下 SynFlowNet 训练期间支架 CDF 的比较。在 5/6 的图中，退火 α 的 SynFlowNet 其奖励 CDF 位于通过轨迹平衡训练的右侧，表明它生成了更高比例的高奖励分子。另一方面， $\alpha = 1.2$ 导致明显的模式崩塌，选择了一些高价值分子。



(a) GSK3 diversity



(b) sEH diversity



(c) DRD2 diversity

图 7. 在 SynFlowNet 训练期间，针对 GSK3、sEH 和 DRD2 目标，在不同 α 和 β 值下独特样本的 Tanimoto 多样性。这表明较低的 α 会导致更多样化的分子，并且退火也可以在一系列设置中产生更多样化的分子。

F.3. 扩散模型中的条件采样

这里我们提供了关于扩散模型实验中条件采样的更多细节和进一步分析。

F.3.1. 实验细节

我们的实验设置直接取自 Venkatraman 等人的研究 (2024)，目标是对预训练的扩散模型进行微调，使其仅采样奇数或偶数 MNIST 数字。这是一个有助于说明模式搜索与模式覆盖特性的任务，因为为了有效地采样后验分布，模型必须基于数字的奇偶性从多个不同的数字中进行采样。一个预训练的分类器被用来定义生成样本的奖励，其中奖励由下式给出：

$$r(\mathbf{x}) = \max_{c \in \mathbf{t}} P(c | \mathbf{x}).$$

其中 $P(c | \mathbf{x})$ 来自预训练的分类器。


超参数 我们使用与 Venkatraman 等人 (2024) 相同的参数，这些参数可以在 <https://github.com/GFNOrg/diffusion-finetuning> 的仓库中找到。为了完整性，这些参数包括：

表 1. 模型训练和优化器超参数

Category	Parameter	Value
Training	Epochs	300
	Global Batch Size	128
	Gradient Accumulation	1
	Sampling Steps	200
	Workers	8
Optimizer (Adam)	Learning Rate (η)	6×10^{-4}
	β_1, β_2	0.9, 0.999
	ϵ	1×10^{-8}

F.3.2. 后验拟合的结果

这里包含了一系列结果和图表，旨在展示不同的损失函数如何捕捉后验分布。我们展示了 Venkatraman 等人 (2024) 提出的相对轨迹平衡损失虽然能够生成高奖励样本（即具有正确奇偶性的数字），但这会导致从后验分布中不均匀地采样。这种效果在偶数上尤为明显，因为相对轨迹平衡更倾向于采样 0，因为它们与其他偶数相比与奇数差异更大。



(a) 目标准确率（即目标类别被采样的比例）与通过发散计算得到的后验 FID 之间的关系。

(b) 奖励（即目标准确率）与拟合后验和轨迹上的先验之间的 $\mathbb{KL}$ 发散度。

图 8. 四个模型的奖励和熵训练曲线。可以看出，较大的异步延迟导致 PPO 训练不稳定，而所有 f -轨迹平衡损失均导致稳定训练。

F.3.3. 生成的样本




图 9. 不同模式覆盖和模式寻找的 f 发散损失比较。

图 9 展示了通过调整每种损失函数后生成的扩散模型样本。可以看出，由于反向 KL 和皮尔逊 χ^2 更倾向于寻找模式，导致了更多的模式崩塌，使得模型过度采样 0 或 6。

附录 F.4 异步 RLVR

本节提供了异步 RLVR 任务的详细信息和额外的图表。

附录 F.4.1 实验细节


为了展示我们的损失函数，我们在 Intellect (2025) 提供的 math-group 环境中进行训练，该环境由 (Cobbe 等人, 2201) 和 Hendrycks MATH(Hendrycks 等人) 的样本混合组成。对于超参数，我们使用 Intellect (2025) 的所有默认设置，并采用 LORA 以及 Schulman 和 Lab (2025) 推荐的学习率 10 倍乘数。完整的超参数详情见表 2。

Category	Hyperparameter	Value
General	Max Sequence Length	4096
	Training Steps	300
LoRA	Rank (r)	32
	Alpha (α)	64
Optimizer	Optimizer	AdamW
	Learning Rate	1×10^{-5}
Orchestration	Global Batch Size	512
	Rollouts per Example	16
	Async Level	50
Evaluation	Eval Examples	600
	Temperature	1.0
Loss	β	0.001
	Tempered	True
	Kimi Approximation	True

表 2 模型配置和训练超参数。对于未选择的超参数，我们使用 prime-rl (Intellect, 2025) 的默认值。

我们对 4 个大语言模型 Qwen2.5-3b、-7B、-14B 和 OLMo-2-1124-7B 重复此任务，每个模型使用 3 个种子。每个模型在 4 个 H100 上运行，其中两个用于推理，两个用于训练，使用 prime-rl (Intellect, 2025)。训练时间根据模型大小从 3 到 5 小时不等。作为比较损失，我们使用 prime-rl 中的 PPO 实现，所有标准超参数均采用，特别是没有 KL 正则化。

附录 F.4.2 训练曲线




(a) 奖励训练曲线基于 3 次运行的平均值，使用 10 步指数移动平均。

(b) 熵训练曲线基于 3 次运行的平均值，使用 10 步指数移动平均。


图 10. 四个模型的奖励和熵训练曲线。可以看出，较大的异步延迟导致 PPO 训练不稳定，而所有 f -轨迹平衡损失均导致稳定训练。

F.4.3. 下游任务上的熵

我们现在展示熵权衡可以转移到未训练的任务上。具体来说，包括美国邀请数学考试（AIME）2204 和 OpenPubMedQA Jin 等（2019）。




(a) Entropy by loss and model on AIME 2024.




(b) Entropy by loss and model on PubMedQA (Jin et al., 2019).

为了完整性，我们包含了完全训练模型的奖励，但所有训练模型在这些任务上的得分都很低。



(a) Final reward by loss and model on AIME 2024.



(b) Final reward by loss and model on PubMedQA (Jin et al., 2019).